控制大综合

第36章 功能安全与可靠性基础

- 36.1 动机与要解决的问题
- 36.2 定义与数学基础
- 36.3 推导与性质
- 36.4 离散对应与数值实现
- 36.5 工程含义与适用边界
- 36.6 仿真与验证
- 36.7 小结与常见错误

第37章 典型环节与时域性能指标

- 37.1 动机与直观理解
- 37.2 数学原理
- 37.3 设计步骤
- 37.4 连续情形
- 37.5 离散情形
- 37.6 稳定性与性能
- 37.7 参数意义与作用
- 37.8 调参方法与经验
- 37.9 优化与改进
- 37.10 工程落地
- 37.11 优缺点与适用边界
- 37.12 Python 仿真代码

第38章 线性系统稳定性判据（一）：Routh-Hurwitz与Jury

- 38.1 动机与直观理解
- 38.2 数学原理
- 38.3 设计步骤
- 38.4 连续情形
- 38.5 离散情形
- 38.6 稳定性与性能
- 38.7 参数意义与作用
- 38.8 调参方法与经验
- 38.9 优化与改进
- 38.10 工程落地

- 38.11 优缺点与适用边界
- 38.12 Python 仿真代码

第39章 线性系统稳定性判据（二）：Nyquist、Bode与根轨迹判据

- 39.1 动机与直观理解
- 39.2 数学原理
- 39.3 设计步骤
- 39.4 连续情形
- 39.5 离散情形
- 39.6 稳定性与性能
- 39.7 参数意义与作用
- 39.8 调参方法与经验
- 39.9 优化与改进
- 39.10 工程落地
- 39.11 优缺点与适用边界
- 39.12 Python 仿真代码

第40章 根轨迹法

- 40.1 动机与直观理解
- 40.2 数学原理
- 40.3 设计步骤：八条绘图规则
- 40.4 连续情形
- 40.5 离散情形
- 40.6 稳定性与性能
- 40.7 参数意义与作用
- 40.8 调参方法与经验
- 40.9 优化与改进
- 40.10 工程落地
- 40.11 优缺点与适用边界
- 40.12 Python 仿真代码

第41章 频率响应法与稳定裕度

- 41.1 动机与直观理解
- 41.2 数学原理
- 41.3 设计步骤
- 41.4 连续情形
- 41.5 离散情形
- 41.6 稳定性与性能
- 41.7 参数意义与作用

- 41.8 调参方法与经验
- 41.9 优化与改进
- 41.10 工程落地
- 41.11 优缺点与适用边界
- 41.12 Python 仿真代码

第42章 稳态误差分析

- 42.1 动机与直观理解
- 42.2 数学原理
- 42.3 设计步骤
- 42.4 连续情形
- 42.5 离散情形
- 42.6 稳定性与性能
- 42.7 参数意义与作用
- 42.8 调参方法与经验
- 42.9 优化与改进
- 42.10 工程落地
- 42.11 优缺点与适用边界
- 42.12 Python 仿真代码

第43章 校正装置设计

- 43.1 动机与直观理解
- 43.2 数学原理
- 43.3 设计步骤
- 43.4 连续情形
- 43.5 离散情形
- 43.6 稳定性与性能
- 43.7 参数意义与作用
- 43.8 调参方法与经验
- 43.9 优化与改进
- 43.10 工程落地
- 43.11 优缺点与适用边界
- 43.12 Python 仿真代码

第44章 PID控制与整定方法

- 44.1 动机与直观理解
- 44.2 数学原理
- 44.3 设计步骤
- 44.4 连续情形

- 44.5 离散情形
- 44.6 稳定性与性能
- 44.7 参数意义与作用
- 44.8 调参方法与经验
- 44.9 优化与改进
- 44.10 工程落地
- 44.11 优缺点与适用边界
- 44.12 Python 仿真代码

第45章 串级控制

- 45.1 动机与直观理解
- 45.2 数学原理
- 45.3 设计步骤
- 45.4 连续情形
- 45.5 离散情形
- 45.6 稳定性与性能
- 45.7 参数意义与作用
- 45.8 调参方法与经验
- 45.9 优化与改进
- 45.10 工程落地
- 45.11 优缺点与适用边界
- 45.12 Python 仿真代码

第46章 前馈控制与复合控制

- 46.1 动机与直观理解
- 46.2 数学原理
- 46.3 设计步骤
- 46.4 连续情形
- 46.5 离散情形
- 46.6 稳定性与性能
- 46.7 参数意义与作用
- 46.8 调参方法与经验
- 46.9 优化与改进
- 46.10 工程落地
- 46.11 优缺点与适用边界
- 46.12 Python 仿真代码

第47章 Smith预估器与大延迟系统

- 47.1 动机与直观理解

- 47.2 数学原理
- 47.3 设计步骤
- 47.4 连续情形
- 47.5 离散情形
- 47.6 稳定性与性能
- 47.7 参数意义与作用
- 47.8 调参方法与经验
- 47.9 优化与改进
- 47.10 工程落地
- 47.11 优缺点与适用边界
- 47.12 Python 仿真代码

第36章 功能安全与可靠性基础

上一章讨论的是“多个主体各自优化时系统会停在哪里”。那一章隐含了一个更强的假设：**所有设备都还在正常工作**。控制器算得出、执行器动得了、传感器读得准，剩下的问题只是“怎么让它们配合得更好”。

现实里这个假设最先破。温度变送器会漂移、安全栅会烧、逻辑 solver 会死机、切断阀会卡在中位。**功能安全要回答的不是“控制系统性能好不好”，而是“当这些环节坏掉时，被控过程还能不能停在安全状态”。** 这两件事的评价体系几乎没有交集：一个跟踪误差 0.1% 的控制回路，可能在传感器断线时把一个放热反应送进失控；反过来，一个粗糙但带独立联锁的反应釜，能在同样故障下安然停车。

这一章把“坏了会怎样”拆成可计算的量：**要多可靠、坏了多久能发现、发现后多久能恢复。** 三个量分别对应 SIL 等级、诊断覆盖率与测试周期、平均修复时间与可用度。后面关于容错控制与安全仪表系统的章节，全部建立在这三个量的语言之上。

36.1 动机与要解决的问题

36.1.1 从“功能对不对”到“坏了会怎样”

控制系统的常规评价是“给定输入，输出是否按要求变化”：超调多大、调节时间多长、稳态误差多少。**这套评价默认系统是完好的，它衡量的是“设计得好不好”。**

功能安全换了一个问法：**给定一个故障，过程是否仍处于安全状态？** 它衡量的不是设计水平，而是**故障发生后的后果**。两个问法的差别可以用一句话概括：

> 性能问的是“正常时有多好”，安全问的是“异常时有多坏”。

工程上这两件事必须分开做，而且必须由不同的通道实现。反应釜的温度联锁不能复用温度控制回路的那支热电偶——**因为控制回路坏了，联锁也跟着坏，这正是最需要联锁的时候。** 这条“独立”要求不是官僚规定，它是从大量事故里总结出来的结构性结论。

36.1.2 三个必须回答的定量问题

功能安全的所有标准、表格与计算，最终都在回答三个问题。

第一，要多可靠？ 这是**安全完整性**问题：在需要动作的那一刻，安全功能失效的概率是多少。量化指标是**平均需求失效概率** $\mathrm{PFD}_{\mathrm{avg}}$，它被划分成 SIL1–SIL4 四档。**这个量不是“设备好坏”的形容词，而是一个可以被计算、被验证、被审计的数字。**

第二，坏了多久能发现？ 这是**诊断与测试**问题。未检出的危险失效会一直潜伏，直到下一次需求出现才暴露。潜伏期越长，平均失效概率越高。**量化指标有两个：诊断覆盖率 DC（在线能发现多少）与证明测试周期 T（离线能兜住多少）。**

第三，发现后多久能恢复？ 这是**维修性**问题。量化指标是平均修复时间 MTTR，它与失效间隔一起决定可用度。**安全性与可用性经常互相拉扯：越保守的联锁越安全，也越容易误停车。**

三个问题构成一条链：**可靠性决定“多久坏一次”，诊断与测试决定“坏了多久才知道”，维修性决定“知道后多久能好”。** 缺任何一环，“安全”就只是一句口号。

36.1.3 一个贯穿全章的例子：反应釜温度联锁

设一台带夹套冷却的放热反应釜，正常工艺温度 85 ℃，联锁动作值 110 ℃，动作是切断进料并全开冷却水。**假设做过放热失控实验：冷却水中断后，从 85 ℃ 升到 110 ℃ 约 8 min，从 110 ℃ 升到不可逆分解温度约 12 min。**

安全功能的要求由此确定：

- **动作必须在 8 min 内完成**，否则联锁还没来得及动作，温度已经越过动作值；
- **误动作的代价**是每停一次损失一批料，约 6 h 产能；
- **要求的安全等级**由风险评估给出（§36.5.2 会走一遍 LOPA），本例取 **SIL2**，即 $\mathrm{PFD}_{\mathrm{avg}} \in [10^{-3}, 10^{-2})$。

安全回路包含三部分：**传感（温度变送器 TT-101）、逻辑（安全 PLC 的联锁程序）、执行（切断阀 XV-101 与冷却水阀）。** 三者串联，任何一环失效，安全功能就失效。**这个“串联”结构是后面所有计算的起点**（§36.3.1）。

36.1.4 与相邻章的接口

- **与第 35 章**：上一章把安全写成约束（式 35-22），本章把“约束是否被满足”变成可验证的概率指标。**约束博弈回答“怎么在安全集合内优化”，功能安全回答“这个安全集合本身有多可信”。**
- **与第 32 章**：学习型控制器没有“设计文档”可查，它的失效模式是分布外的。**本章的验证方法对学习型控制器只能覆盖“接口与兜底”，覆盖不了“策略本身”**——这一点在 §36.5.5 会明确划界。
- **与第 44/106 章（PID）**：常规控制回路不承担安全功能，本章不重复 PID 整定；**但只要回路被赋予安全职责，就必须按本章的独立性、诊断与测试要求重做。**
- **与第 58/80 章（MPC）**：MPC 的约束处理是“运行中不越界”，功能安全是“越界前能兜住”。**MPC 不能替代 SIS**，因为它与被控过程共享模型、共享传感器、共享执行器。
- **与后续容错控制与 SIS 章节**：本章给指标与算法，后续章节给架构（冗余切换、故障重构）与工程实现（SIS 组态、旁路管理）。

36.1.5 本章的走法

§36.2 建立词汇与公式：失效率、可靠度、可用度、冗余结构、失效分类、SIL/PL、共因失效、诊断覆盖率。§36.3 推导四类结构的 $\mathrm{PFD}_{\mathrm{avg}}$，给出共因地板、故障树最小割集、FMEA 的量化用法。§36.4 讲离散实现：怎么把连续时间模型写成测试周期模型，怎么用解析、马尔可夫、蒙特卡洛三条路互相验证。§36.5 给工程边界：SIL 定级、七种不该上 SIS 的场合、软件与系统性失效。§36.6 用六组实验把每个公式跑一遍。§36.7 收口。

36.1.6 本章不做什么

边界先划清，后面才好读。

其一，不推导任何控制算法。 PID 的整定与实现见第 44/106 章，MPC 的约束处理见第 58/80 章，Smith 预估见第 47/107 章。**本章只关心“这些回路失效时的后果”，不关心它们正常时怎么工作。**

其二，不做器件选型与接线设计。 什么型号的变送器、哪个品牌的卡件、端子怎么排——**这些是详细设计阶段的工作，本章只给“要多可靠、要多独立”的输入条件。**

其三，不给认证流程与文档模板。 第三方认证的申请、审核、发证是一套独立的程序，**本章只讲"认证要看哪些数"**。

其四，不覆盖信息安全。 SIS 被网络攻击导致失效，属于 IEC 62443 那条线，**与本章的随机硬件失效是两套完全不同的方法论**：一个讲"元件会坏"，一个讲"有人想让它坏"。**两套都要做，但不能互相替代。**

其五，不覆盖人因工程的完整方法。 §36.5.9 只讲"人的失效怎么进 LOPA 的账"，不讲控制室设计、报警管理、班组配置——**那些是另一门课。**

一句话概括本章的边界：它只回答"一个安全功能有多可信"，不回答"这个功能该怎么实现"。 后者是后续容错控制与 SIS 章节的内容。

36.2 定义与数学基础

36.2.1 失效率、可靠度与 MTBF

失效率 λ 定义为"在 t 时刻仍正常的设备，在下一单位时间内失效的概率"：

$$\lambda(t) = \lim_{\Delta t \to 0} \frac{P(t < T_f \le t + \Delta t \mid T_f > t)}{\Delta t}.$$

工程上最常用的是**常数失效率**假设，此时寿命服从指数分布，可靠度为

$$R(t) = e^{-\lambda t}. \tag{36-1}$$

平均失效前时间随之是

$$\mathrm{MTBF} = \int_0^{\infty} R(t)\,\mathrm{d}t = \frac{1}{\lambda}. \tag{36-2}$$

单位换算必须先统一。 失效率常用 FIT（$1\ \mathrm{FIT} = 10^{-9}/\mathrm{h}$），$\mathrm{MTBF}$ 常用年或小时。本章统一用"每小时"，$1\ \text{年} = 8760\ \mathrm{h}$。**单位不统一是这类计算最常见的错误，而且错得很隐蔽：10^{-6}/h 与 10^{-6}/年差 8760 倍，恰好跨越两个 SIL 等级。**

常数失效率假设对应浴盆曲线的**中段（有用寿命期）**。早期失效靠老化筛选剔除，耗损失效靠预防性更换规避，**中间那一段才是 SIL 计算的对象**。把浴盆曲线两端的问题塞进指数模型，是另一类常见错误。

36.2.2 可用度与 MTTR

可修复系统的核心指标是**可用度**，即"任意时刻设备处于可用状态的概率"。在"失效—修复"交替的简化模型下，

$$A = \frac{\mathrm{MTBF}}{\mathrm{MTBF} + \mathrm{MTTR}} = \frac{1/\lambda}{1/\lambda + \mathrm{MTTR}}. \tag{36-3}$$

可靠度与可用度是两个不同的量，混用会导致完全相反的结论。 可靠度是"一段时间内不出故障的概率"，单调下降；可用度是"长期看有多少时间能用"，是一个稳态比值。**一个每 100 h 坏一次、每次 10 min 修好的设备，可用度高达 0.998，但它在任何一次 8 min 的需求窗口里都可能正好坏着。** 安全功能关心的是后者——**需求出现的那一刻它在不在**，而不是长期平均。

36.2.3 冗余结构与可靠性框图

把安全回路的三个环节画成串联框图，就得到最基础的可靠性模型：**串联系统任一环失效则整体失效**，其可靠度是各环可靠度之积。要提高可靠性，只能加冗余。

图 36-1 给出三种最常见的结构。

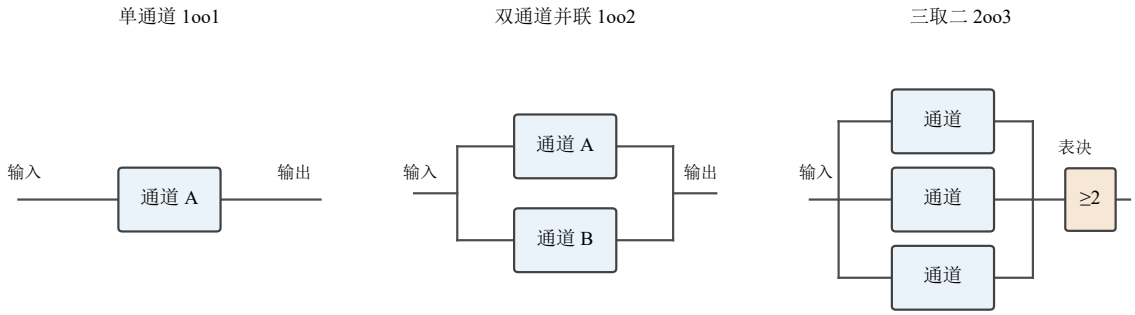

图 36-1　三种冗余结构的可靠性框图：单通道、双通道并联、三取二

- **1oo1**：一个通道，失效即失效。结构最简单，$\mathrm{PFD}_{\mathrm{avg}}$ 最高。
- **1oo2**：两个通道并联，**两个都失效才失效**。安全性最好，但任一通道误动就停车，**误跳闸率翻倍**。
- **2oo3**：三个通道表决，**两个及以上失效才失效**。安全性与误跳闸率都优于 1oo1，代价是通道数与接线成本，以及“三路都要独立”这个苛刻前提。

表 36-1 把四种结构放在一起比较。**注意“误跳闸倾向”这一列——它经常被忽略，却是现场最痛的一项。**

表 36-1　常见冗余结构的比较

结构	安全功能失效条件	$\mathrm{PFD}_{\mathrm{avg}}$ 量级（$T = 1$ 年）	误跳闸倾向	典型用途
1oo1	单通道失效	10^{-3}	低	SIL1、非关键联锁
1oo2	两通道同时失效	10^{-5}	高（任一误动即停）	SIL3、高危险场合
2oo2	任一通道失效	10^{-3}	低	高可用、低安全要求
2oo3	两通道及以上失效	10^{-5}	很低	SIL3、既要安全又要连续
2oo4	三通道及以上失效	10^{-6}	很低	SIL4、极关键场合

36.2.4 失效的分类：危险与否、检出与否

功能安全里所有失效被两个维度切开，形成四类（表 36-2）。**这两个维度缺一不可：只分“危险/安全”会漏掉诊断，只分“检出/未检出”会漏掉方向。**

表 36-2　失效的四分类

类别	含义	对安全功能的影响	典型处理
λ_{DD}	危险、可检出	直接削弱安全功能，但能及时报警	在线诊断 + 定期维修
λ_{DU}	危险、不可检出	潜伏，直到需求出现才暴露	证明测试（周期 T）
λ_{SD}	安全、可检出	导致误跳闸，不削弱安全	诊断 + 抑制误动
λ_{SU}	安全、不可检出	潜伏的误跳闸风险	证明测试

只有 λ_{DU} 进入 $\mathrm{PFD}_{\mathrm{avg}}$ 的主项，因为它是“需要动作时才发现动不了”的那一类。λ_{DD} 通过缩短暴露时间（MTTR）间接贡献，λ_{SD} 与 λ_{SU} 影响的是误跳闸率与可用度。

由此定义**安全失效分数**：

$$\mathrm{SFF} = \frac{\lambda_{SD} + \lambda_{DD}}{\lambda_{SD} + \lambda_{SU} + \lambda_{DD} + \lambda_{DU}}. \tag{36-4}$$

SFF 衡量“这个设备坏的时候，有多大比例是往安全侧坏的”。**它与诊断覆盖率 DC 是两个不同的量**：SFF 描述失效的**方向分布**，DC 描述诊断的**发现能力**（§36.2.8）。

36.2.5 SIL 等级：把“可靠”变成区间

安全完整性等级（SIL）是 IEC 61508 对“安全功能可信程度”的分档。低要求模式下用平均需求失效概率划分：

$$\mathrm{PFD}_{\mathrm{avg}} = \frac{1}{T}\int_0^T \mathrm{PFD}(t)\,\mathrm{d}t, \tag{36-5}$$

表 36-3 给出分档。**注意区间是“越小越好”，且 SIL4 只用于极少数场合**——每提高一级，成本大约翻倍，而收益是概率上的边际改善。

表 36-3　SIL 等级与 $\mathrm{PFD}_{\mathrm{avg}}$（低要求模式）

SIL	$\mathrm{PFD}_{\mathrm{avg}}$ 区间	风险降低因子 $1/\mathrm{PFD}_{\mathrm{avg}}$	典型场合
4	$10^{-5} \sim 10^{-4}$	$10^{4} \sim 10^{5}$	核工业、大规模有毒气体
3	$10^{-4} \sim 10^{-3}$	$10^{3} \sim 10^{4}$	化工高危反应、紧急停车
2	$10^{-3} \sim 10^{-2}$	$10^{2} \sim 10^{3}$	一般过程联锁（本例）
1	$10^{-2} \sim 10^{-1}$	$10 \sim 10^{2}$	单回路保护、辅助联锁

“高要求模式”用每小时失效频率 PFH 而不是 $\mathrm{PFD}_{\mathrm{avg}}$，因为需求连续出现（比如汽车制动、电梯平层），“潜伏到下次测试”这个前提不成立。两个模式的换算关系是 $\mathrm{PFH} \approx \mathrm{PFD}_{\mathrm{avg}}/T$，**但这个换算只在你清楚 T 是什么的时候成立。**

36.2.6 ISO 13849：机械安全的另一套语言

机械领域用的是 ISO 13849 的**性能等级（PL a–e）**，它与 SIL 的思路相同、刻度不同。核心概念是**类别（Category）**，从 B 到 4，规定了结构冗余与诊断能力的最低要求（表 36-4）。

表 36-4　ISO 13849 的类别与结构要求

类别	结构要求	诊断要求	典型 $\mathrm{PFD}_{\mathrm{avg}}$ 量级	对应 PL（大致）
B	单通道，基本安全原则	无	10^{-2}	PL b
1	单通道，用成熟件与成熟原则	无	10^{-2}	PL c
2	单通道 + 周期性测试	有测试	10^{-3}	PL d
3	双通道，单点故障不丧失功能	部分	10^{-4}	PL d/e
4	双通道，单点故障可检出	高	10^{-5}	PL e

两套标准不能混用，但可以对照。 一个常见错误是“用 SIL2 的器件去满足 PL d 的要求”——**器件等级不等于系统等级，系统等级由结构、诊断、测试共同决定。** 本章的计算方法对两套标准都适用，只是指标名称与分档边界不同。

36.2.7 共因失效与 β 因子

冗余的前提是“几个通道独立失效”。**这个前提在工程上几乎从不严格成立**：同一路电源、同一套软件、同一个安装位置、同一批次的器件、同一次维护操作，都会让两个通道同时失效。这类失效叫**共因失效（CCF）**。

最常用的量化模型是**β 因子模型**：把总失效率拆成独立部分与共因部分，

$$\lambda_{\text{indep}} = (1-\beta)\lambda, \qquad \lambda_{\text{ccf}} = \beta\lambda. \tag{36-6}$$

β 是“共因部分占总失效的比例”，经验值在 1%–10% 之间，**软件共因可以接近 100%**（§36.3.11 会讲为什么）。β 的取值不能靠猜，IEC 61508-6 给了一张打分表，按“分离、多样性、环境、经验、诊断”等维度累加，**打分结果通常在 1%–5%**。

β 的破坏力在下一节会用数字展示：它给冗余结构设了一个地板，无论加多少通道都压不下去。

36.2.8 诊断覆盖率与安全失效分数

诊断覆盖率 DC 定义为“被在线诊断发现的危险失效占全部危险失效的比例”：

$$DC = \frac{\lambda_{DD}}{\lambda_{DD} + \lambda_{DU}}. \tag{36-7}$$

它与 SFF 的区别一句话说清：**SFF 说“坏的时候往哪边坏”，DC 说“坏的时候能不能马上知道”。**

DC 的分档在标准里有明确说法：$DC < 60\%$ 为低，$60\% \le DC < 90\%$ 为中，$90\% \le DC < 99\%$ 为高，$DC \ge 99\%$ 为极高。**这四个档位直接对应诊断设计的复杂度与成本**：60% 靠量程检查与看门狗就能做到，99% 需要比较法、时序检查甚至模型-based 诊断。

DC 的价值在于它把“潜伏”变成“暴露”：检出后的失效按 MTTR 修复，未检出的才按 $T/2$ 潜伏。这条差别在 §36.3.2 会变成一个加法项。

36.2.9 安全生命周期：指标从哪里来

所有指标都不是凭空定的，它们来自**安全生命周期**。完整流程有十几个阶段，工程上可以压成五步：

1. **危险与风险分析**：找出危险源，评估后果与频率（HAZOP、风险矩阵）。
2. **安全要求分配**：确定需要哪些安全功能、每项要什么 SIL（LOPA）。
3. **设计与实现**：选结构、选器件、定测试周期、写安全程序。
4. **验证与确认**：算 $\mathrm{PFD}_{\text{avg}}$、做故障注入测试、做 SIL 验证。
5. **运行与变更管理**：定期证明测试、旁路审批、变更后再验证。

这五步里，第三步之后的所有工作都依赖第二步的 SIL 定级。 定高了浪费钱，定低了是隐患——而“定级”本身是风险评估的结论，不是控制工程师能单独决定的。**这也是本章反复强调“指标要能追溯到危险分析”的原因。**

36.2.10 浴盆曲线：公式只在中段成立

式 36-1 的指数分布不是“设备的通用规律”，而是“设备在有用寿命期内的近似”。把失效率画成时间的函数，曲线形状像浴盆，三段各有各的机理：

- **早期失效段**：失效率随时间下降。原因是制造缺陷、装配应力、运输损伤、焊点虚接。这一段的失效率可能是稳态值的几倍到几十倍。
- **有用寿命段**：失效率近似常数。失效由随机的外部事件引起——电压尖峰、颗粒污染、误操作、环境突变。**这一段才是本章公式的对象。**
- **耗损失效段**：失效率随时间上升。原因是磨损、腐蚀、疲劳、绝缘老化、密封件硬化。

用 Weibull 分布可以把三段写成一条式子：

$$\lambda(t) = \frac{\beta}{\eta}\left(\frac{t}{\eta}\right)^{\beta-1},$$

$\beta < 1$ 对应递减段、$\beta = 1$ 对应常数段（退化为指数分布）、$\beta > 1$ 对应递增段，η 是特征寿命。

三段对应三种完全不同的处理手段，**混用会导致方向性错误**：

其一，早期失效靠老化筛选。 出厂前在高温、高循环下运行一段时间，把“短命”的个体提前淘汰。筛选的代价不只是成本——**筛选本身消耗寿命**，对耗损型器件（继电器、电解电容、密封件）尤其如此。所以筛选强度要与器件的 β 匹配：早期失效占主导的批次值得重筛，已经进入耗损期的批次越筛越糟。

其二，耗损失效靠预防性更换。 在失效率开始上升之前整批换掉。这条做法的定量依据是 β。设某阀门的密封件 $\beta = 3$、$\eta = 20$ 年，则瞬时失效率正比于 t^2：**第 15 年是第 5 年的 9 倍。** 把一支用了 15 年的阀门按“常数失效率”直接代进 $T/2$，会低估近一个数量级。**这也是为什么“证明测试”不能替代“到期更换”——测试只能更早发现失效，不能降低失效率。**

其三，中段才是 SIL 计算的对象。 中段的长度由设计裕度、工况强度、维护水平共同决定。同一型号在高温、高振动、频繁起停的工况下，耗损段的起点会前移好几年。厂商 FMEDA 报告给的是参考工况下的 λ，**工况一变，中段的长度就变了，这就是 §36.4.5 强调“FMEDA 要修正”的原因。**

这一段还解释了两件工程上的反常现象。 一是“新设备反而更不可靠”：刚投运的 SIS 前三个月的失效率可能是稳态值的几倍，所以投运初期要加密巡检，**并且不能把这段数据直接拿去估计 λ。** 二是“现场数据算出来的 λ 偏大”：维修记录里混着早期失效与耗损失效，不分段就直接平均，得到的 λ 会被两端抬高，进而导致过度设计。**数据清洗的第一步是按投运时间分段，而不是先算平均值。**

36.2.11 需求率决定用哪个指标

式 36-5 定义的 $\mathrm{PFD}_{\mathrm{avg}}$ 有一个隐含前提：**需求是稀少的。** 稀少到什么程度？IEC 61508 的判据是“需求频率不大于每年一次，且不大于测试频率的两倍”。满足这个前提叫**低要求模式**。

不满足时有两种情况。**高要求模式**：需求频繁出现，比如汽车制动、电梯平层、燃烧器熄火保护——此时“潜伏到下次测试”这个前提根本不成立，指标要换成每小时失效频率 PFH。**连续模式**：安全功能一直在执行，失效立即体现，比如燃烧器的火焰监测。

判据的实际用法是先数需求率，再选指标：

- **反应釜联锁**：初始事件（冷却水中断）频率约 0.3/年，远低于每年一次 → 低要求模式 → 用 $\mathrm{PFD}_{\mathrm{avg}}$。

- **汽包液位低低联锁**：正常波动就可能触发，一年动作几十次 → 已经接近高要求模式，**继续用 $\mathrm{PFD}_{\mathrm{avg}}$ 会高估安全性。**
- **机泵轴承温度联锁**：一年动作几次但每次都是真实需求 → 仍是低要求模式，不能因为“动作过”就当成高要求。

换算关系 $\mathrm{PFH} \approx \mathrm{PFD}_{\mathrm{avg}}/T$ 的适用条件值得单独说清。它是“把潜伏期摊平到整个周期”的结果：低要求模式下，每次需求遇到失效的概率是 $\mathrm{PFD}_{\mathrm{avg}}$；若需求率是 ν（次/小时），则每小时因失效而未动作的期望次数是 $\nu \cdot \mathrm{PFD}_{\mathrm{avg}}$。把它记作 PFH，得

$$\mathrm{PFH} = \nu \cdot \mathrm{PFD}_{\mathrm{avg}},$$

只有当 $\nu = 1/T$ 时，它才等于 $\mathrm{PFD}_{\mathrm{avg}}/T$。 需求率比 $1/T$ 高一个数量级，PFH 就高一个数量级——**这就是“直接拿 $\mathrm{PFD}_{\mathrm{avg}}$ 除以 T”会出错的地方。**

一个具体的对照：1oo1、$\lambda_{DU} = 10^{-6}$/h、$T = 8760$ h，低要求模式下 $\mathrm{PFD}_{\mathrm{avg}} = 4.38 \times 10^{-3}$，落在 SIL1。若需求率升到 100 次/年，$\mathrm{PFH} = 100/8760 \times 4.38 \times 10^{-3} \approx 5.0 \times 10^{-5}$/h，按高要求模式的刻度（SIL1 为 $10^{-5} \sim 10^{-4}$/h）仍然落在 **SIL1**。**等级标签一样，两个数字却差两个数量级——所以“SIL2”这三个字符本身不说明任何问题，除非同时说清是低要求还是高要求。**

报告的第一行应当写模式，而不是写等级。 这一条在评审时最容易分辨专业与否：写“该 SIF 为低要求模式，$\mathrm{PFD}_{\mathrm{avg}} = 4.4 \times 10^{-3}$，SIL1”是完整的；写“该回路 SIL1”则什么也没说。

36.2.12 异构冗余：把 β 降下来的唯一工程手段

§36.2.7 说冗余的前提是独立。**提高独立性最有效的手段不是“多买一套一样的”，而是“买一套不一样的”**——这就是异构冗余（diverse redundancy）。

同型冗余的共因清单很长：同一型号的同一批次、同一份固件、同一个安装位置、同一次校验、同一个供货商。**异构冗余把这些项逐条砍掉**：温度测量用一支热电偶加一支热电阻，两者原理不同（热电势对电阻）、芯片不同、固件不同、甚至供货商不同。剩下的共因只有“工艺侧”的那几项——**插入深度不够、保护套管结垢、接线盒进水、环境温度超出两者共同的范围。** 这些恰恰是 §36.2.7 打分表里最难通过、也最容易被忽略的项。

收益可以算出来。 同型 1oo2、$\beta = 0.05$、$\lambda_{DU}T = 8.76 \times 10^{-3}$，得 2.42×10^{-4}。若异构把 β 降到 0.01，则

$$(1-0.01)^2\frac{(\lambda_{DU}T)^2}{3} + 0.01\frac{\lambda_{DU}T}{2} = 2.51 \times 10^{-5} + 4.38 \times 10^{-5} = 6.89 \times 10^{-5},$$

好了 3.5 倍，而且这个改善是“不增加通道数”得到的。 与 §36.3.12 的结论对照：**在共因主导的区间里，降 β 的杠杆比加通道大得多。**

异构还附带一个诊断收益。 两路不同原理的读数可以持续比对，**偏差超过阈值就报警**——这等于给“漂移”这一类失效加了一个在线诊断，DC 随之提高。同型冗余做不到这一点，因为两路会一起漂，比对永远“一致”。

代价有三条，必须一起算：

- **一致性判据要放宽。** 两种器件的响应时间、精度、温度系数都不同，正常工况下两路读数本来就有偏差。**判据放宽，误报率上升；判据收紧，误跳闸上升。** 这个阈值要在调试阶段用实际数据定，不能拍。
- **备件与校验要两套。** 两种变送器、两种校验规程、两套备件。**这是异构冗余唯一确定会增加的运行成本。**

- **“多样性”不能消除工艺侧共因。** 结垢、堵塞、安装位置错误对两路同时有效。**这也是为什么打分表里“分离”与“环境”两项的权重不低于“多样性”。**

边界要说清：异构冗余降低的是随机硬件失效的共因，降不了系统性失效。 若两路信号最终进同一个安全 PLC、由同一份程序做表决，**软件与逻辑这一层的共因仍然是 1**（§36.3.11）。**异构要一路做到底，只做传感器那一半，收益会被后半段吃掉。**

36.2.13 可靠性框图的三个陷阱

图 36-1 那种框图看着简单，**画错的方式却很多，而且每一种都会让算出来的 PFD 偏小。**

陷阱一：把共因画成独立的并联支路。 图上两个方块并排，看上去“互为备用”；实际它们共享同一个 24 V 电源、同一张 I/O 卡、同一根电缆桥架。**框图只表达“逻辑上并联”，不表达“物理上独立”。** 这两件事的差距就是 §36.2.7 的 β——**画图时必须把共享的部分单独画成一个串联方块**，否则算的时候会忘记它。

陷阱二：方块粒度太粗，把共享部件藏进去。 把“温度检测”画成一个方块，实际它包含热电偶、补偿导线、安全栅、AI 通道、卡件电源。**两路“独立”的检测如果接在同一张 AI 卡的两个通道上，它们共享多路开关与 A/D——这就是一条隐秘的共因路径。** 粒度应当细到“能区分共享与不共享”为止：**共用一张卡，就画一张卡的方块；共用一路电源，就画一路电源的方块。**

陷阱三：把非串并联结构硬套公式。 环形、桥式、交叉表决这些结构既不是纯串联也不是纯并联，**式 36-8 与式 36-9 都不适用。** 典型的例子是“三台泵两两互备”或“三个控制器交叉通信”，**这类结构要用状态枚举或马尔可夫（§36.3.9），不能拆成串并联再相乘。**

还有一条与“并联”有关的直觉要纠正：图上并联的是“功能”，实际并联的往往是“信号”。 两路信号进同一个控制器、由同一份程序做表决——**信号层并联，逻辑层串联。** 这也是 §36.2.12 说“异构要一路做到底”的原因：**只把传感器做成两路，逻辑那一层的共因仍然是 1。**

画完框图的最后一个动作，是逐对方块问一句“这两个之间共享了什么”。 答案写不出来，才能标“独立”。

36.2.14 SIF、SIS、SIL：三个词不能互换

这三个词在中文资料里经常混着用，**但它们指的不是一回事，混用会在评审时直接暴露问题。**

SIF（安全仪表功能）是“功能”：一条“检测到 X 就做 Y”的完整回路，比如“温度高于 110 ℃ 就切断进料并开冷却水”。**它有明确的输入、逻辑与输出，可以单独定级。**

SIS（安全仪表系统）是“实现这些功能的系统”：一组控制器、I/O、现场仪表、执行器，**通常同时承载几十条 SIF。** 它是一个物理实体，有硬件配置、有组态、有机柜。

SIL（安全完整性等级）是“某个 SIF 的可靠程度”：按 $\mathrm{PFD}_{\mathrm{avg}}$ 的区间分成四档。**它属于 SIF，不属于 SIS，也不属于任何一台设备。**

由此得出两条措辞纪律：

其一，“这个 SIS 是 SIL3”这句话是错的（除非该 SIS 只承载一条 SIF）。正确说法是“**这个 SIS 里有 3 条 SIL3 的 SIF、17 条 SIL2 的 SIF**”。**等级是逐条功能定的，不是给整套系统贴一个标签。** 这条差别很实际：一个 SIS 的公共部件（电源、机柜、通信）若失效，会同时打掉多条 SIF——**它们各自的 SIL 都还好，但共因让它们一起失效。** 这正是 §36.2.7 与 §36.2.13 反复强调共享的原因。

其二，**“这个变送器是 SIL3”也是错的。** 器件有“按某标准认证可用于 SIL3 回路”的说法，那是**器件证书**，不是系统的 SIL。**系统等级由结构、诊断、测试周期共同决定**（§36.2.6 已就 ISO 13849 说过同一件事）。

一个便于记忆的类比： SIF 是“一条安全要求”，SIS 是“实现它的硬件与软件”，SIL 是“这条要求被满足到了什么程度”。**三者是“要求—实现—验证”的关系，任何一个都不能替代另一个说话。**

36.2.15 三个换算，现场口算用

评审桌上最常听到的三种口算错误，都可以用三个固定换算避免。

其一，**FIT 与 λ。** $1000\ \mathrm{FIT} = 10^{-6}/\mathrm{h}$。**记住“1000 FIT 就是百万分之一每小时”，其余按比例推。**

其二，**λ 与 MTBF。** 1000 FIT 对应 $\mathrm{MTBF} = 10^{6}\ \mathrm{h}$，**约 114 年。** 这条换算的价值在于纠正直觉：**“114 年才坏一次”听起来很可靠，但它对应的 $\mathrm{PFD}_{\mathrm{avg}}$ 是 4.38×10^{-3}，只够 SIL1。** 可靠与安全不是一回事，这就是最直观的例子。

其三，**年与小时。** $1\ \text{年} = 8760\ \mathrm{h}$，$1\ \text{次/年} = 1.14\times10^{-4}/\mathrm{h}$。**这两个数要背下来，因为需求率、测试频率、误跳闸率的单位经常在这两者之间跳。**

再补一个把 PFD 翻译成“多少年一次”的换算。 $\mathrm{PFD} = 10^{-3}$ 的含义是“一千次需求里失败一次”；若需求率是 0.3/年，则期望间隔约 $1/(0.3\times10^{-3}) \approx 3300$ 年。**这个数不是“安全”，它只是“概率上的间隔”**——三千三百年里任何一次需求都可能正好赶上失效，**而且一旦赶上就是事故。** 所以报 PFD 时不要换算成“多少年一次”，那会把概率说成周期，**掩盖了“下一次需求就可能是那一次”这个事实。**

36.3 推导与性质

36.3.1 串联回路：三段相乘还是三段相加

回到 §36.1.3 的反应釜，安全回路是“传感—逻辑—执行”串联。**串联系统的可靠度是各段之积：**

$$R_{\mathrm{sys}}(t) = \prod_{i=1}^{m} R_i(t) = \exp\Big(-\sum_{i=1}^{m}\lambda_i t\Big). \tag{36-8}$$

所以串联系统的失效率是各段之和，这一点常被误解成“取最大的那个”。三段的失效率相加，意味着**最差的那一段不会被好的那一段“平均掉”**——一支每年坏一次的阀门，配再好的变送器也救不回来。

对 $\mathrm{PFD}_{\mathrm{avg}}$ 来说，当各段都远小于 1 时，串联的 $\mathrm{PFD}_{\mathrm{avg}}$ 近似为各段之和：

$$\mathrm{PFD}_{\mathrm{sys}} \approx \sum_{i=1}^{m} \mathrm{PFD}_i. \tag{36-9}$$

这个“相加”是功能安全里最有用的近似，因为它直接告诉你：**要提升一个数量级，必须把每一段都提升，或者把最差的那一段换掉。** §36.5.1 会用一个具体算例展示“只改最弱环节”的效果。

36.3.2 单通道 1oo1 的 $\mathrm{PFD}_{\mathrm{avg}}$

设通道的未检出危险失效率为 λ_{DU}，证明测试周期为 T。**失效在周期内随机发生，且直到测试才被发现，**于是从失效到被发现的时间在 $[0, T]$ 上均匀分布。若失效发生在测试后 t 时刻，则从 t 到下次测试的这段时间里，安全功能一直处于失效状态，失效概率为 1。因此

$$\mathrm{PFD}(t) = \lambda_{DU}\, t, \qquad \mathrm{PFD}_{\text{avg}} = \frac{1}{T}\int_0^T \lambda_{DU} t \,\mathrm{d}t = \frac{\lambda_{DU} T}{2}. \tag{36-10}$$

这个 $T/2$ 是整章最重要的一个系数。 它的含义是“平均潜伏半个测试周期”。代入本章的数值（$\lambda_{DU} = 10^{-6}$/h、$T = 8760$ h）：

$$\mathrm{PFD}_{\text{avg}} = \frac{10^{-6} \times 8760}{2} = 4.38 \times 10^{-3},$$

落在 SIL1 区间。 这个结果值得停下来看一眼：**一支失效率 1000 FIT 的变送器，即使一年做一次证明测试，单通道也只能到 SIL1。** 想上 SIL2，只有三条路——降失效率、缩短测试周期、加冗余。E1 会把这四条路的代价算清楚。

若考虑修复时间，检出失效的贡献是 $\lambda_{DD} \cdot \mathrm{MTTR}$，于是

$$\mathrm{PFD}_{\text{avg}} \approx \lambda_{DU}\frac{T}{2} + \lambda_{DD}\,\mathrm{MTTR}. \tag{36-11}$$

注意两项的量级差： $T/2$ 是几千小时，MTTR 是几小时，所以第二项只有在 $\lambda_{DD} \gg \lambda_{DU}$（即诊断覆盖率很高）时才不可忽略。**这也解释了为什么“高诊断覆盖率”能把单通道推到 SIL2**（§36.3.6）。

36.3.3 双通道 1oo2：平方项的来历

1oo2 要两个通道同时失效才失效。**在“两者独立”的假设下，**时刻 t 两个都失效的概率是 $(\lambda_{DU}t)^2$，于是

$$\mathrm{PFD}_{\text{avg}} = \frac{1}{T}\int_0^T (\lambda_{DU}t)^2\,\mathrm{d}t = \frac{\lambda_{DU}^2 T^2}{3}. \tag{36-12}$$

代入同样的数：$(10^{-6}\times 8760)^2/3 = 2.56 \times 10^{-5}$，**从 SIL1 直接跳到 SIL3**。E1 的实测正是 2.558×10^{-5}。

这里的“平方”是全部收益的来源，也是全部脆弱性的来源。 它依赖“两个通道独立失效”这一假设；一旦失效相关（共因），平方项就被线性项取代。**这就是为什么 §36.3.5 的 β 因子能把 SIL3 打回 SIL2。**

36.3.4 三取二 2oo3：为什么它比 1oo2 更适合现场

2oo3 有三个通道，任意两个失效才失效。时刻 t 恰好两个失效的概率是 $\binom{3}{2}(\lambda_{DU}t)^2$，对 t 平均时除以 T 与积分产生的 $1/3$ 相消：

$$\mathrm{PFD}_{\text{avg}} = \frac{1}{T}\int_0^T 3(\lambda_{DU}t)^2\,\mathrm{d}t = \lambda_{DU}^2 T^2. \tag{36-13}$$

代入本章数值：$(10^{-6}\times 8760)^2 = 7.67 \times 10^{-5}$，**仍是 SIL3，但比 1oo2 差 3 倍。**

为什么工程上仍大量用 2oo3？因为它的误跳闸率远低于 1oo2。 1oo2 里任一通道误动就停车（误跳闸率近似加倍），2oo3 要两个通道同时误动才停车（误跳闸率按平方下降）。E6 的实测是：1oo2 的误跳闸率 4.0×10^{-6}/h，2oo3 只有 1.92×10^{-10}/h——差了四个数量级。

所以“1oo2 更安全”这句话只在“安全性”这一个维度上成立。 把误跳闸带来的停产、频繁起停对设备的损伤、以及操作工因频繁误报而旁路联锁的风险算进来，2oo3 往往是更优解。**这是本章第一个“指标之间必须权衡”的例子，不是最后一个。**

36.3.5 共因失效：给冗余设一个地板

把 β 因子模型代进 1oo2：两个通道同时因共因失效的概率是 $\beta\lambda_{DU}t$，于是

$$\mathrm{PFD}_{\text{avg}} \approx \underbrace{(1-\beta)^2\frac{\lambda_{DU}^2 T^2}{3}}_{\text{独立部分}} + \underbrace{\beta\frac{\lambda_{DU}T}{2}}_{\text{共因部分}}. \tag{36-14}$$

第二项与通道数无关，它只跟单通道失效率、β、T 有关。这意味着：无论加多少通道，$\mathrm{PFD}_{\text{avg}}$ 都不会低于 $\beta\lambda_{DU}T/2$。

代入 $\lambda_{DU}=10^{-6}$/h、$T=8760$ h，这个地板是 $4.38\times10^{-3}\beta$：

- $\beta=0.01$：地板 4.38×10^{-5}（SIL3 边缘）；
- $\beta=0.02$：地板 8.76×10^{-5}（SIL3）；
- $\beta=0.05$：地板 2.19×10^{-4}（SIL3）；
- $\beta=0.10$：地板 4.38×10^{-4}（SIL2）。

E2 的实测与这条地板线完全吻合：β 从 0 加到 0.10，1oo2 的 $\mathrm{PFD}_{\text{avg}}$ 从 2.56×10^{-5} 涨到 4.59×10^{-4}，**共因部分占比从 0 涨到 95.5%。** 也就是说，$\beta=0.1$ 时，**冗余带来的好处有 95% 被共因吃掉了**，1oo2 相对 1oo1 的改善倍数从 171.2 跌到 9.5。

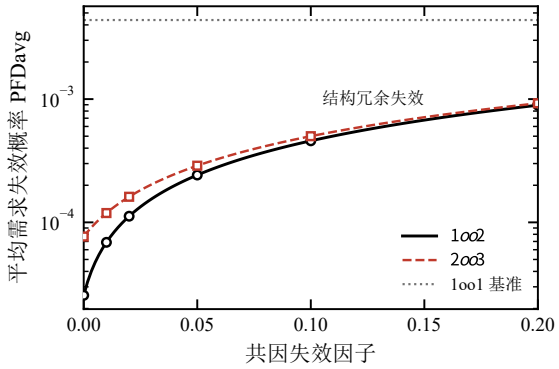

图 36-3　共因失效因子给冗余结构设下的地板：β 越大，1oo2 与 2oo3 越接近 1oo1

这条结论的工程含义是：想靠冗余上 SIL3，必须先证明“通道之间真的独立”。 独立不是画在图上，而是体现在物理上——**分开的电源、分开的 I/O 卡、不同的传感器原理、分开的电缆路径、分开的维护班次。** IEC 61508-6 的打分表之所以有效，就是因为它把这些“物理上的分开”折算成了 β 的数字。

36.3.6 诊断覆盖率：把潜伏期换成修复期

带诊断的单通道（记作 1oo1D）把危险失效分成两半：DC 那部分在线检出、按 MTTR 修复，$1-DC$ 那部分继续潜伏到证明测试。于是

$$\mathrm{PFD}_{\text{avg}} \approx DC\cdot\lambda_{DU}\,\mathrm{MTTR} + (1-DC)\cdot\lambda_{DU}\frac{T}{2}. \tag{36-15}$$

代入 $T=8760$ h、$\mathrm{MTTR}=8$ h、$\lambda_{DU}=10^{-6}$/h：

- $DC=0$：4.38×10^{-3}（退化为 1oo1，SIL1）；
- $DC=0.90$：4.45×10^{-4}（SIL2，改善 9.8 倍）；

- $DC = 0.99$：5.17×10^{-5}（SIL3，改善 84.7 倍）。

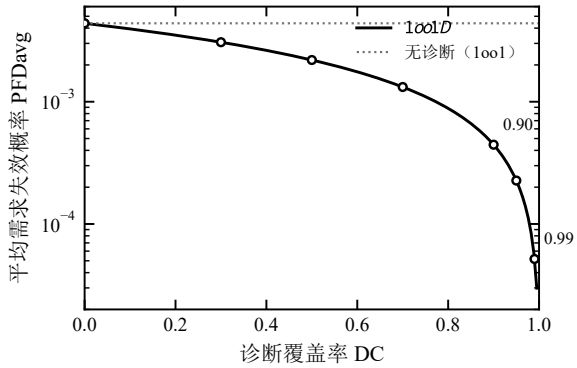

图 36-4　诊断覆盖率把潜伏期换成修复期：DC 从 0.9 提到 0.99，PFD 再降一个数量级

DC 的收益不是线性的，而是**“越接近 1 越值钱”**。从 0 到 0.5 只改善 2 倍，从 0.9 到 0.99 又改善 8.6 倍。原因很直白：被诊断吃掉的那部分从“潜伏几千小时”变成“修复几小时”，比值是 $T/(2\,\mathrm{MTTR}) \approx 548$；所以 DC 每提高一点，就有更多比例享受到这个 **548** 倍的折扣。

但 DC 有天花板，而且天花板来自**“诊断本身也会失效”**。诊断逻辑通常与被诊断通道共享一部分硬件与软件，当共因失效发生时，诊断和被诊断对象一起坏。这就是为什么 IEC 61508 对“高 DC”要求额外的诊断独立性证明——否则 $DC = 0.99$ 只是纸面上的数字。

36.3.7 故障树与最小割集

$T/2$ 与平方项都是“单点公式”。真实系统由多段、多冗余组成，**故障树**是把它们串起来的图形化方法：顶事件是“安全功能失效”，向下用与门、或门分解到基本事件。

图 36-6 给出一个五基本事件的算例：顶事件 $= (A \wedge B) \vee (C \wedge D) \vee E$。它的三条最小割集是 $\{A, B\}$、$\{C, D\}$、$\{E\}$——最小割集就是“能让顶事件发生的最小事件组合”，它直接对应“要防哪几种同时失效”。

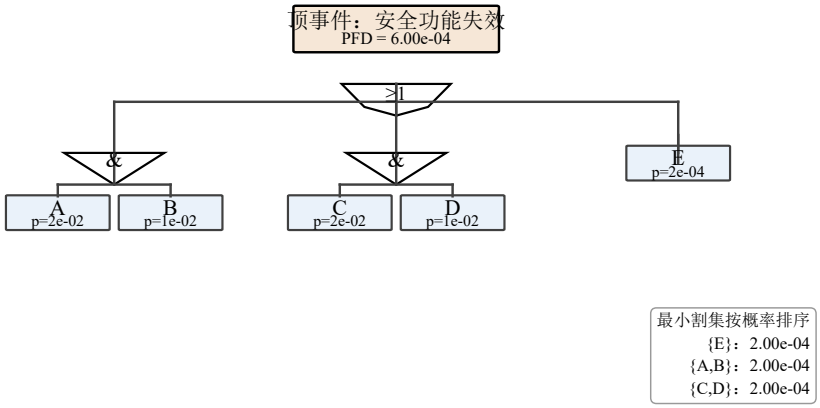

图 36-6　故障树算例：三条最小割集与它们的概率排序

顶事件概率的精确值要靠容斥或状态枚举，工程上常用**稀有事件近似**——把各割集概率直接相加：

$$P_{\text{top}} \approx \sum_{j} P(C_j). \tag{36-16}$$

E5 给了两个算例，结论很有意思：

- **单事件主导**（$p_E = 10^{-2}$，另两条割集各 2×10^{-6}）：精确值 1.000396×10^{-2}，近似值 1.000400×10^{-2}，相对偏差 **0.000%**；
- **三割集相当**（三条各 2×10^{-4}）：精确值 5.9988×10^{-4}，近似值 6.0000×10^{-4}，相对偏差 **+0.020%**。

近似总是偏大，因为割集之间的交集被重复计算了。 偏差的量级大致是“割集概率的平方除以总和”，所以只要顶事件概率小于 10^{-2}，近似就够用。**真正需要精确值的场合是“割集之间高度重叠”**（比如几条割集共享同一个电源故障），这时必须做状态枚举。

故障树真正的价值不在算概率，而在排序。 把三条割集的概率一列，改进顺序就出来了：**在本例中，$\{E\}$ 比另两条大四个数量级，先处理 E，其余都是噪声。** 这正是 FMEA 与故障树在工程上的用法——**不是算出一个小数点后三位的概率，而是找出“最该改的那一个”。**

36.3.8 FMEA 与 RPN：定性分析的定量外壳

故障模式与影响分析（FMEA）逐条列出“部件—失效模式—影响—检测手段”，是功能安全里唯一能在设计早期做的分析。它的定量外壳是**风险优先数**：

$$\text{RPN} = S \times O \times D, \tag{36-17}$$

S 是严重度（1–10）、O 是发生度（1–10）、D 是难检度（1–10）。表 36-5 是反应釜回路的一个片段。

表 36-5　反应釜安全回路的 FMEA 片段（RPN $= S \times O \times D$）

部件	失效模式	局部影响	S	O	D	RPN	处置
温度变送器	漂移偏高	联锁迟动	8	4	6	192	加双支热电偶比对
切断阀	卡涩不动作	进料切不断	10	3	8	240	加部分行程测试
数字输出卡	输出粘滞	阀门不动作	7	2	4	56	选诊断型 DO 卡
冷却水阀	开度不足	移热不够	9	2	5	90	加阀位反馈

RPN 的三个数都是主观打分，这是它最大的弱点。 同一个失效，两个工程师给出的 O 可以差两倍，D 可以差三倍，**RPN 相差六倍**。所以 RPN 只能用来**排序**，不能用来**判定“是否安全”**——判定要靠 SIL 计算与可容忍风险准则。

第二个弱点更隐蔽：RPN 对“严重度”不敏感。 $S=10, O=1, D=1$ 的 RPN 是 10，$S=2, O=3, D=3$ 的 RPN 是 18——**后者排在前面，但前者才是不可接受的风险。** 工程做法是先按 S 分层，层内再按 RPN 排序；**永远不要用一个乘积把不可接受的风险“稀释”掉。**

36.3.9 马尔可夫模型：把修复也画进去

PFD_{avg} 的公式都假设“失效后不修，直到测试”。**若修复是连续的（在线诊断 + 随时可修），更合适的工具是马尔可夫状态模型。**

以单通道为例，两个状态：正常（0）与失效（1），失效率 λ、修复率 $\mu = 1/\text{MTTR}$。稳态方程给出

$$A = \frac{\mu}{\lambda + \mu} = \frac{1}{1 + \lambda \,\mathrm{MTTR}}. \tag{36-18}$$

这与式 **36-3** 在 $\lambda\,\mathrm{MTTR} \ll 1$ 时一致，说明两套推导是自洽的。马尔可夫模型的价值在于它能处理“部分失效”“降级运行”“多状态修复”这些公式覆盖不了的情形，代价是**状态数随部件数指数增长**——四个部件各两状态就是 16 个状态，八个部件就是 256 个。

工程上的分界线是：能用 $\mathrm{PFD}_{\mathrm{avg}}$ 公式的场合不要上马尔可夫；需要区分多种降级状态、或修复率与状态相关时，才用马尔可夫。 这与第 32 章“能用动态规划就不要上函数逼近”是同一条思路。

36.3.10 安全性与可用性的权衡

把 E6 的结果并排看，权衡就很清楚（表 36-6）。

表 36-6　三种结构的安全性与可用性（E6 实测，$\beta = 0.05$）

结构	$\mathrm{PFD}_{\mathrm{avg}}$	误跳闸率（/h）	年误停时间（h）	SIL
1oo1	4.380×10^{-3}	2.000×10^{-6}	0.14	SIL1
1oo2	2.421×10^{-4}	4.000×10^{-6}	0.28	SIL3
2oo3	2.883×10^{-4}	1.920×10^{-10}	约 0	SIL3

1oo2 把安全性提高了 18 倍，代价是误跳闸率翻倍、年误停从 0.14 h 涨到 0.28 h。 对反应釜这种“停一次损失 6 h 产能”的场合，这 0.14 h 的增量其实可以接受；**但对连续生产、误停一次要重新开车 8 h 的装置，这个增量就可能超过安全收益。**

2oo3 是“既要又要”的解：$\mathrm{PFD}_{\mathrm{avg}}$ 与 1oo2 同量级，误跳闸率却低了四个数量级。**它的代价不在运行，而在建设与维护**——三套独立的传感器、三套 I/O、更大的接线柜、更复杂的一致性测试。**所以选型的本质是“用建设成本换运行成本”，而不是单纯比 $\mathrm{PFD}_{\mathrm{avg}}$ 的小数点。**

36.3.11 系统性失效：公式管不到的那一半

前面所有公式都只适用于**随机硬件失效**。还有一类失效叫**系统性失效**：设计缺陷、软件错误、规格书漏项、集成错误、人为操作错误。**它们的共同特点是“不是随机发生的，也不能用失效率描述”。**

三条必须记住的性质：

其一，系统性失效不服从指数分布。 一个软件缺陷要么存在要么不存在，不会“每小时以 10^{-6} 的概率出现”。**用 $\mathrm{PFD}_{\mathrm{avg}}$ 去算软件，是把不适用的工具用在了不适用的问题上。**

其二，系统性失效的共因因子接近 1。 两套冗余通道如果跑同一份软件、由同一个团队编写，那么软件缺陷会同时让两路失效。**这就是 §36.2.7 里“软件共因可以接近 100%”的含义，也是“多样性”（不同实现、不同语言、不同团队）在 SIL3 以上被强制要求的原因。**

其三，对付系统性失效只能靠“过程”，不能靠“计算”。 IEC 61508 的软件部分给的是**技术措施表**（编码规范、形式化方法、边界值测试、独立验证），而不是公式。**它们降低的是“缺陷被引入的概率”，不是“每小时失效的概率”。**

这条分界对本章的适用范围至关重要：$\mathrm{PFD}_{\mathrm{avg}}$ **只覆盖随机硬件失效，占比通常在 50% 以下；剩下的部分要靠过程保证。** 把 SIL 证书当成“整个系统安全”的证明，是功能安全领域最根本的误解。

36.3.12 一般 kooN：通道数不是越多越好

式 36-12 与式 36-13 只覆盖了两种结构。把它们合起来，可以得到任意 kooN 的通式。**kooN 的含义是“n 个通道中有 k 个同意就动作”，于是安全功能失效需要 $n-k+1$ 个通道同时失效。** 记 $m=n-k+1$，则

$$\mathrm{PFD}_{\mathrm{avg}}=\binom{n}{m}\frac{\lambda_{DU}^{m}T^{m}}{m+1}.$$

两个因子分工明确：指数 m 决定“要几个同时坏”，组合数 $\binom{n}{m}$ 决定“有多少种坏法”。 前者是收益的来源，后者是代价的来源。

代入本章数值（$\lambda_{DU}T=8.76\times10^{-3}$），四种结构的差别三句话就能说清：

- **1oo2**（$m=2$，$\binom{2}{2}=1$）：2.56×10^{-5}；
- **2oo3**（$m=2$，$\binom{3}{2}=3$）：7.67×10^{-5}，**是 1oo2 的 3 倍**，多出来的通道全变成了“多一种坏法”；
- **2oo4**（$m=3$，$\binom{4}{3}=4$）：6.72×10^{-7}，**比 2oo3 好 114 倍**；
- **1oo3**（$m=3$，$\binom{3}{3}=1$）：1.68×10^{-7}，**比 2oo4 还好 4 倍**。

“2oo4 比 2oo3 好、1oo3 又比 2oo4 好”这个排序值得记下来，因为它推翻了一个很常见的直觉——“通道越多越安全”。**真正决定安全性的是 m，也就是“要几个同时失效”，而不是 n。** 2oo4 的 $m=3$ 是因为“两个同意就动作”意味着剩下两个还能把它否掉；1oo3 的 $m=3$ 是因为“一个同意就动作”，必须三个全坏。**同样三个通道坏掉，1oo3 早就动作了，2oo4 还在等第四个。**

但 1oo3 的误跳闸率是 1oo1 的 3 倍，2oo3 只有 $6\lambda_S^2\mathrm{MTTR}$ 量级。 所以“最安全”与“最可用”在 kooN 家族里始终是两个端点，2oo3 之所以成为现场主力，是因为它落在两者之间。**表 36-1 里 2oo4 的 10^{-6} 量级，正确的读法是“它的 $m=3$”，而不是“它的通道多”。**

组合数这一项还有一层代价。 当 n 大而 m 小时，$\binom{n}{m}$ 增长很快：3oo5 的 $\binom{5}{3}=10$，2oo5 的 $\binom{5}{4}=5$。**系数一大，独立项的“平方级收益”就被吃掉相当一部分，**同时通道数与接线、卡件、机柜空间、一致性测试的成本线性增长。**这就是工程上很少见到 $n>4$ 的原因：不是因为做不到，而是因为性价比在 $n=4$ 之后急剧下降。**

最后是那个无法回避的地板。 把共因项加回来，任意 kooN 都有

$$\mathrm{PFD}_{\mathrm{avg}}\geq\beta\frac{\lambda_{DU}T}{2},$$

它与 n、k、m 全都无关。 取 $\beta=0.05$、$\lambda_{DU}T=8.76\times10^{-3}$，地板是 2.19×10^{-4}——**它比 1oo2、2oo3、2oo4、1oo3 四者的独立项都大。** 换句话说，**在 $\beta=0.05$ 时，1oo2 与 2oo3 的实测值分别是 2.42×10^{-4} 与 2.88×10^{-4}，而 2oo4 与 1oo3 按通式加共因项等于 2.19×10^{-4} 与 2.19×10^{-4}——后两个数与地板完全相同，因为它们的独立项已经小到看不见。** 想靠“再加一个通道”跨过 SIL 边界，在共因没控制住之前是徒劳的。

36.3.13 测试覆盖率：公式里那个没写出来的假设

式 36-10 到式 36-15 都隐含一个假设：**证明测试能把全部未检出的危险失效暴露出来。** 工程上这个假设几乎从不成立。一支切断阀每年做一次全行程测试，能发现“卡死”，但发现不了“关不严”和“关得慢”——**后者需要带压差、带流量地测，而那往往要停车。**

于是要引入**测试覆盖率 t_c**，定义为“证明测试实际能暴露的未检出危险失效占全部 λ_{DU} 的比例”。把 λ_{DU} 拆成两半：**被测出的 $t_c\lambda_{DU}$ 按 $T/2$ 潜伏，测不出的 $(1-t_c)\lambda_{DU}$ 一直潜伏到设备更换，**等效测试周期是设备寿

命 T_{life}：

$$\text{PFD}_{\text{avg}} \approx t_c \lambda_{DU} \frac{T}{2} + (1 - t_c)\lambda_{DU} \frac{T_{\text{life}}}{2}.$$

取 $t_c = 0.9$、$T = 8760\,\text{h}$、$T_{\text{life}} = 20\,\text{年} = 175200\,\text{h}$、$\lambda_{DU} = 10^{-6}/\text{h}$：

- 第一项 $0.9 \times 10^{-6} \times 4380 = 3.94 \times 10^{-3}$；
- 第二项 $0.1 \times 10^{-6} \times 87600 = 8.76 \times 10^{-3}$；
- 合计 1.27×10^{-2}，落在 **SIL1**，比“假设 $t_c = 1$”时的 4.38×10^{-3} 差了 **2.9** 倍。

比例很说明问题：只占 10% 的“测不到”部分，贡献了总量的 69%。 原因是它的暴露时间是 $T_{\text{life}}/2$，而覆盖到的那部分是 $T/2$，**两者相差 20 倍**——所以哪怕未覆盖率只有 10%，也足以主导总量。**这条结论的实践含义是：报告里写 PFD_{avg} 时必须同时写 t_c 的定义与依据，否则这个数只是“假设出来的”。**

部分行程测试（PST）是把 t_c 提上去的主要手段。 阀门在不停车的情况下走 10%–20% 行程再返回，能覆盖卡涩、摩擦力增大、气源压力不足这几类失效，**但覆盖不了阀座泄漏与关闭时间超标。** 一个典型的失效模式分布是“卡涩 60%、泄漏 25%、关不快 15%”，若 PST 对卡涩的覆盖是 0.9、对其余两类是 0，则整阀的等效 $t_c = 0.54$。**把这个数代进上面的式子，T 的有效值被拉长，SIL2 就可能守不住——这就是“每年都测了”却算不出等级的真实原因。**

PST 本身也有风险。 阀门走出去回不来、返回位置不到位、测试后忘记恢复——**测试是系统风险最高的时刻，这一条在 §36.5.9 还会展开。** 所以 PST 的设计要包含“测试后确认”这一步，而不是“发个命令看它动了就算完”。

36.3.14 修复项为什么只算检出部分

式 36-11 的第二项写成 $\lambda_{DD} \cdot \text{MTTR}$ 而不是 $\lambda_{DU} \cdot \text{MTTR}$，这一点常被看漏。**理由很直接：只有被检出的失效才会进入修复流程；未检出的失效根本不知道要修，只能等测试。** 把 λ_{DU} 也乘上 MTTR 是重复计算——它已经在 $T/2$ 那一项里了。

这一项的物理含义是“**平均有多少时间比例处于’知道坏了但还没修好’的状态**”。它与可用度的关系可以直接对上：由式 36-18，

$$A = \frac{1}{1 + \lambda\,\text{MTTR}} \approx 1 - \lambda\,\text{MTTR},$$

不可用度近似等于 $\lambda\,\text{MTTR}$。 所以式 36-11 的第二项不是“另一个公式”，而是“把不可用度搬到 PFD_{avg} 里”。两条推导在这里接上，**这也是 §36.4.7 第 3 条自检（串联可分解）能够成立的原因。**

但这一项的前提比它看上去脆弱。 它假设“检出即开始修、修的时间就是 MTTR”。三种常见情形会让它偏小：

- **诊断只报警不停机。** 此时暴露时间不是 MTTR，而是“操作员发现—判断—处置”的总时间，**典型是 MTTR 的 2–5 倍**，而且随班组、班次波动。
- **检出后要停车才能修。** MTTR 里必须含上“等停车窗口”的时间，**可能是几十小时到几天**，这一项就不再可忽略。
- **备件不到、资质人员不在。** 这属于管理问题，但它如实反映在 MTTR 里；**用“标准值 8 h”填表而现场实际是 72 h，是把风险藏进了假设。**

所以 MTTR 的取值要来自维修记录，而不是来自“行业典型值”。这一条与 §36.4.5 对 λ 的要求是同一条纪律：能追溯到记录的数字才能进报告，其余只能进草稿。

36.3.15 误跳闸率：SIL 公式里没有的那一半

$\mathrm{PFD}_{\mathrm{avg}}$ 只描述“该动时不动”。与之对称的另一个指标是“不该动时乱动”，即误跳闸率（spurious trip rate）。它不进 SIL 计算，但它决定这套联锁在现场能不能活得下去。

三种结构的误跳闸率量级差别极大，推导思路与 PFD 完全对称，只是把“危险失效”换成“安全失效”：

- **1oo1**：任一安全失效直接导致停车，$\mathrm{STR} \approx \lambda_S$；
- **1oo2**：两通道并联，任一通道误动即停，$\mathrm{STR} \approx 2\lambda_S$；
- **2oo3**：要两个通道同时误动才表决出停车，$\mathrm{STR} \approx 6\lambda_S^2 \mathrm{MTTR}$。

2oo3 的系数 6 值得解释一句：三个通道里选两个有 $\binom{3}{2} = 3$ 种组合，每种组合又有“谁先坏”两种次序，合起来是 6；后面乘 $\lambda_S^2 \mathrm{MTTR}$ 表示“第二个通道在第一个修复之前也坏掉”。这个式子是工程近似，严格值要用马尔可夫模型（**§36.3.9**）——量级一致就够用，因为它的用途是排序而不是定值。

代入 $\lambda_S = 2 \times 10^{-6}$/h、$\mathrm{MTTR} = 8$ h：

- 1oo1：2.0×10^{-6}/h，年误停 $0.0175 \times 8 = 0.14$ h；
- 1oo2：4.0×10^{-6}/h，年误停 0.28 h；
- 2oo3：1.92×10^{-10}/h，年误停约 1.3×10^{-5} h，等于没有。

三者横跨四个数量级，而它们的 $\mathrm{PFD}_{\mathrm{avg}}$ 只差 **18** 倍。这就是 §36.3.10 那张表的核心：安全性是一个轴，可用性是另一个轴，两个轴的刻度完全不同，不能用一个数比较。

误跳闸率为什么必须报，理由不在经济账，而在它通过“旁路”反过来摧毁 PFD。一套年误停十几次的联锁，操作工会怎么做？在检修时把它旁路掉，然后“忘了恢复”。一旦进入 §36.5.8 的算术，5% 的旁路时间就等价于 $\mathrm{PFD} = 0.05$——比任何冗余结构的计算值都大两个数量级。换句话说：

> 误跳闸率高的联锁，最终会被现场“用脚投票”改成不存在的联锁。

所以选型时必须同时报两个数：$\mathrm{PFD}_{\mathrm{avg}}$ 与 STR（或年误停小时）。只报前者的方案在评审桌上很好看，投运半年后就会被旁路。这也是 **2oo3** 在“既要安全又要连续”的装置上成为主力的真正原因——不是它的 PFD 更低，而是它的误跳闸率低到操作工愿意让它一直投着。

36.3.16 与 LOPA 的接口：PFD 乘上需求率才有意义

$\mathrm{PFD}_{\mathrm{avg}}$ 单独看只是一个抽象的概率。它唯一的正确用法是与需求率相乘：

$$\text{剩余风险 (/年)} = \nu \times \prod_{i} \mathrm{PFD}_i,$$

ν 是初始事件频率，乘积遍历所有独立保护层（含 SIS）。量纲是“每年期望发生次数”，这才是能与可容忍风险直接比较的数。

用本章的例子走一遍。初始事件（冷却水中断）$\nu = 0.3$/年，BPCS 温度控制 $\mathrm{PFD} = 0.1$，操作员响应 $\mathrm{PFD} = 0.1$，SIS $\mathrm{PFD} = 2.678 \times 10^{-3}$（§36.5.1 方案 A）：

$$0.3 \times 0.1 \times 0.1 \times 2.678 \times 10^{-3} = 8.03 \times 10^{-6}\ /\text{年}.$$

可容忍风险若定为 10^{-5}/年，方案 A 刚好通过，余量只有 **1.25** 倍。这解释了 §36.5.1 为什么还要讨论方案 B——余量这么薄，任何一处参数变差（阀门老化、测试延期）都会把它推过线。

这条乘法也解释了 **LOPA** 的三条纪律为什么必须遵守。若把“操作员看温度”与“班长巡检”算成两层，各取 0.1，风险就被凭空除以 10——而它们共享同一批人、同一个班次，实际上只有一层（§36.5.9）。**乘法只对独立层成立，不独立的层乘进去就是造假。**

反过来，这也说明**“提高 SIL”不是唯一手段。**从 2.678×10^{-3} 压到 5.378×10^{-4}（方案 B）风险降 5 倍；而把 BPCS 的控制品质从 $\mathrm{PFD} = 0.1$ 提到 0.05，风险同样降 2 倍，**成本可能低得多。**LOPA 的价值就在于把这些杠杆摆在同一张表上，**让人看见“哪一层最便宜”。**

最后一个常见错误：把 $\mathrm{PFD}_{\text{avg}}$ 当成“每年的失效次数”。它是“每次需求失效的概率”，**没有量纲**；乘上需求率才有“每年次数”。**需求率是 0.3/年还是 100/年，同一个 PFD 对应的风险差 300 倍。**

36.4 离散对应与数值实现

36.4.1 三个时间尺度

功能安全的公式里同时出现三个时间量，**混淆它们是计算错误的主要来源：**

- **任务时间**：一次需求从出现到必须完成动作的时间。本例是 8 min。
- **测试周期 T**：两次证明测试之间的间隔。典型是 6 个月到 2 年。
- **修复时间 MTTR**：发现失效到恢复功能的时间。典型是 2–24 h。

三者的量级是 10^{-1} h、10^{3} h、10^{1} h。$\mathrm{PFD}_{\text{avg}}$ **的公式只关心后两个**；任务时间不进公式，它进的是“安全功能响应时间”这条独立的规格要求。**把任务时间代进 $T/2$ 是一个常见错误，会让 $\mathrm{PFD}_{\text{avg}}$ 小三个数量级。**

36.4.2 三条计算路线

同一个 $\mathrm{PFD}_{\text{avg}}$ 可以用三种方法算，**它们应当互相印证，而不是互相替代：**

解析式：§36.3 的公式。优点是快、可解释、能手算校验；缺点是只覆盖少数标准结构，且假设“失效在周期内均匀分布”。

马尔可夫：把状态与转移画出来，解稳态或瞬态方程。优点是能处理降级、部分失效、相关修复；缺点是状态数指数增长，且转移率必须齐全。

蒙特卡洛：抽样失效时刻，直接统计“需求出现时功能是否失效”。优点是什么结构都能算、能带不确定度；缺点是要跑很多样本才能估到 10^{-5} 量级。

工程顺序建议：先解析（拿量级）→ 再马尔可夫（补结构）→ 最后蒙特卡洛（验算）。反过来（先跑蒙特卡洛再找公式）通常是因为不知道自己在算什么。

36.4.3 一个十行的最小实现

下面这段把 §36.3 的三个公式写成代码。**它的用途是当“手算器”：**任何工具给出的数，先在这里对一遍。

```
# 三种结构的 PFDavg（低要求模式，常数失效率）
lam, T, beta = 1e-6, 8760.0, 0.05      # /h, h, 无量纲

p1 = lam * T / 2                                      # 1oo1
p2 = (1 - beta)**2 * lam**2 * T**2 / 3 + beta * lam * T / 2   # 1oo2
p3 = (1 - beta)**2 * lam**2 * T**2 + beta * lam * T / 2       # 2oo3

print("1oo1 %.3e  1oo2 %.3e  2oo3 %.3e" % (p1, p2, p3))
# 实测 1oo1 4.380e-03  1oo2 2.421e-04  2oo3 2.883e-04
```

三行代码，三个结论立刻可见：单通道只能到 SIL1；加一个通道（并考虑 $\beta = 0.05$ 的共因）到 SIL3；再加一个通道反而略差（2.883×10^{-4} 对 2.421×10^{-4}），因为 **2oo3 的独立项系数是 1oo2 的 3 倍，而共因项两者相同。** 这个“多一个通道反而更差”的反直觉结果，正是共因主导时的典型特征。

36.4.4 蒙特卡洛要多少样本

$\mathrm{PFD}_{\mathrm{avg}}$ 是一个小概率。用蒙特卡洛估 p，相对标准误约为 $1/\sqrt{Np}$。要达到 10% 的精度，需要

$$N \approx \frac{100}{p}. \tag{36-19}$$

对 $p = 5 \times 10^{-6}$，$N \approx 2 \times 10^{7}$——这就是 **E4 每个结构跑两千万个样本的原因。** 若只跑一百万，1oo2 的估计会上下浮动 40% 以上，看起来“和解析式对不上”，其实是样本不够。

E4 的实测印证了这一点：1oo1（$p \approx 2 \times 10^{-3}$）的相对偏差 $+0.61\%$，1oo2（$p \approx 5.3 \times 10^{-6}$）的相对偏差 -2.50%，2oo3 是 $+3.75\%$——概率越小，同样的样本量下偏差越大，这是统计涨落，不是模型错。

工程含义：蒙特卡洛只适合“验证量级”，不适合“精确定值”。报 $\mathrm{PFD}_{\mathrm{avg}}$ 时应当报解析值，并附一句“蒙特卡洛在 2×10⁷ 样本下与解析值相差 X%”，这比报一个蒙特卡洛点估计更诚实。

36.4.5 失效率数据从哪来

四类来源，可信度依次递减：

其一，现场数据（OREDA、企业自己的维修记录）。 最可信，因为它对应真实工况。缺点是样本少、置信区间宽——一个部件十年坏了三次，λ 的 90% 置信区间可以跨一个数量级。

其二，厂商 FMEDA 报告。 器件级 λ_{DD}、λ_{DU}、β 都有，但它是按“参考工况”算的，温度、振动、负载率一变就要修正。

其三，通用数据库（如 exida SERH）。 适合早期估算，不适合作为 SIL 验证的唯一依据。

其四，MIL-HDBK-217 之类的老标准。 不要用于功能安全计算。它面向军工电子、假设与现场差异大，且早已停止维护。用它算出来的 λ 往往偏保守一个数量级，导致过度设计；也可能对某些器件偏乐观。

“proven in use”（在用证明）是另一条路：若某部件在相似工况下累计运行了足够长的时间且无失效记录，可以据此给出 λ 的上界。它的前提是“相似”必须可论证——工况、维护、负载都要对得上，否则只是把无知包装成了数据。

在用证明要站得住，三条必须同时成立： 一是相似工况，温度、介质、负载率、起停次数都在同一档；二是足够的累计运行时间，通常要求达到目标 MTBF 的若干倍，否则上界宽得没有意义；三是完整的失效记录。第

三条最容易被糊弄——“没有维修记录”可能是真的没坏，也可能是坏了没记。用后者当“零失效”，等于拿管理漏洞去证明设备可靠。**审这份证据时，要问的不是“坏了没有”，而是“坏了会不会被记下来”。**

36.4.6 四个数值细节

其一，不要用 **float32**。10^{-8} 量级的量与 10^{4} 量级的量同处一个表达式时，float32 的 7 位有效数字不够。**全部用双精度。**

其二，小概率用对数表示与比较。$\mathrm{PFD}_{\mathrm{avg}}$ 跨越 10^{-6} 到 10^{-1}，线性刻度上看不出差别。**画图用对数轴，报告里用“4.38×10^{-3}”而不是“0.00438”。**

其三，单位在变量名里写死。`lam_per_h`、`T_h`、`mttr_h`——**Python 不会替你检查单位，命名是唯一廉价的手段。**

其四，不要对已经平均过的量再取平均。若工具输出的是 $\mathrm{PFD}_{\mathrm{avg}}$，不要再除以 T 去“换算成 PFH”——T 已经被平均掉了，再除一次等于重复计算。这是 SIL 验证报告里最常见的算术错误。

36.4.7 怎么验证一个 SIL 计算工具

商业 SIL 计算软件的输出不能直接采信。**四个自检用例，任何一个不过就不要用：**

1. 令 $\beta=1$：1oo2 的 $\mathrm{PFD}_{\mathrm{avg}}$ 应当等于 1oo1（共因吞掉全部冗余）。
2. 令 $\beta=0$、$T\to0$：$\mathrm{PFD}_{\mathrm{avg}}\to0$（测试无限快则无潜伏）。
3. **串联分解**：把三段串联的 $\mathrm{PFD}_{\mathrm{avg}}$ 与三段各自之和比较，偏差应在百分之一量级。
4. **与手算对照**：用 §36.4.3 的十行代码对同一组输入，**数量级必须一致。**

这四条本质上是**“极限检验 + 可分解性检验”**，与第 18 章验证辨识算法、第 27 章验证网络训练用的是同一套思路：**先看极限，再看分解，最后才看具体数字。**

36.4.8 精确算故障树：容斥与不交化

式 36-16 是近似。精确值来自“至少一条割集全部发生”这个事件的概率，标准做法是容斥：

$$P_{\mathrm{top}}=\sum_{j}P(C_j)-\sum_{i<j}P(C_i\cap C_j)+\sum_{i<j<k}P(C_i\cap C_j\cap C_k)-\cdots$$

符号交替，项数是 $2^{m}-1$。$m=10$ 是一千项，$m=20$ 是一百万项，$m=30$ 是十亿项——**所以精确计算只在割集很少、或者割集之间高度重叠时才值得做。**

用 E5 的第二个算例验一遍。三条割集概率相同、各自独立（$p=2\times10^{-4}$），此时

$$P_{\mathrm{top}}=1-(1-p)^{3}=3p-3p^{2}+p^{3}=6.0000\times10^{-4}-1.2\times10^{-7}+8\times10^{-12}=5.99880\times10^{-4},$$

与 **E5** 报的精确值 5.9988×10^{-4} 逐位对上。二阶项 1.2×10^{-7} 相对总量是 2×10^{-4}，**这就是“偏差 +0.020%”的来源**——它不是代码误差，而是近似的固有偏差。

工程上真正需要精确值的场合只有一类：割集共享基本事件。设两条割集 $\{X,Y\}$ 与 $\{X,Z\}$ 共享 X，且 $P(X)=0.1$、$P(Y)=P(Z)=0.05$。近似给出 $2\times0.005=0.01$；精确值是 $P(X)P(Y\cup Z)=0.1\times(0.05+0.05-0.0025)=0.00975$。**两者只差 2.5%，看起来没事——但若 $P(X)$ 升到 0.5，近似给出 0.05，精确值是 $0.5\times0.0975=0.04875$，仍然接近。**真正危险的不是“共享一个事件”，而是**割集之间几乎完全重合**：两条割集只差一个事件、且那个事件的概率接近 1，此时二阶项与一阶项同量级，近似会偏大一倍。

“不交化”是把容斥的 2^m 项压成 m 项的技巧。把割集按字典序排好，第 k 项写成“C_k 发生且前 $k-1$ 条都不发生”，各项互斥，直接相加即精确。代价是每一项要做布尔化简，手工做容易出错，工程上用 **BDD**（二元决策图）实现——它的规模对多数实际故障树是线性的。

判据可以写得很干脆：若 $\sum_j P(C_j) < 10^{-2}$，直接用式 **36-16**；否则先看割集之间有没有共享事件，有就上 **BDD**。这条判据覆盖了九成以上的现场故障树。

36.4.9 蒙特卡洛的三条降方差路线

直接抽样的流程很短：对每个通道抽一个失效时刻，判断需求时刻它是否已失效，统计“该失效的通道数达到阈值”的比例。它的成本由 $N \approx 100/p$ 决定（式 **36-19**），这就是 $p = 5\times10^{-6}$ 时要两千万样本的原因。

三条降方差路线，按实现难度排序：

其一，分层抽样。把 $[0,T]$ 分成 K 层，每层抽同样多的样本。它消除的是**“层间不均衡”**——直接抽样里可能整整一层一个失效都没抽到，而另一层抽到十几个。对 $T/2$ 这类平滑的被积函数，分层能把方差降一个数量级，实现只需要把随机数改成“层号 + 层内偏移”。

其二，对偶变量。每抽一个 u 就同时用 $1-u$ 跑一遍，两个样本负相关，平均后方差下降。实现成本几乎为零，但收益依赖被积函数的单调性——PFD 对失效时刻是单调的，所以这里有效。

其三，重要性抽样。把抽样分布改成“更容易失效”的分布（比如把 λ 乘 10），每个样本乘一个似然比权重修正回来。这是唯一能把 10^{-6} 量级的估计压到 10^{5} 样本量级的手段，代价是要自己设计偏置分布，且权重方差可能很大——设计不好会比直接抽样更糟。

三条路线都建立在一个前提上：结构判定必须写对。1oo2 与 2oo3 在代码里只差一行（“失效通道数 ≥ 2”对“≥ 2 且总通道数 3”），结果差 3 倍。共因抽样也容易写错：共因失效率是 $\beta\lambda$，不是 λ。本章代码初版就犯过这个错——把共因的抽样率写成 λ 后，$\beta=0.1$ 情形的偏差达到 $+838\%$；这个错误不是统计涨落，因为它只有一个方向。

报告蒙特卡洛结果时应当给三个数：点估计、标准误、样本量。只给点估计等于让人无法判断“这个数与解析式的差是模型问题还是样本问题”——而这两件事的处理方式完全相反：前者要改模型，后者只要加样本。

36.4.10 敏感性：哪个输入最值得核实

$\mathrm{PFD}_{\mathrm{avg}}$ 对三个输入的敏感度并不相同，这决定了核实工作的优先级。

对 1oo1，$\mathrm{PFD}=\lambda T/2$，λ 与 T 的弹性都是 1：两者各错 **20%**，结果各错 **20%**。对 1oo2 的独立项，弹性都是 2：λ 或 T 错 **20%**，结果错 **44%**。对共因项，弹性是 1，但它的基数大。

把弹性与基数乘起来，才看得出谁重要。以 $\beta=0.05$、$\lambda_{DU}T = 8.76\times10^{-3}$ 的 1oo2 为例：

- 独立项 2.3×10^{-5}，弹性 2，绝对敏感度约 4.6×10^{-5} 每单位相对变化；
- 共因项 2.19×10^{-4}，弹性 1，绝对敏感度 2.19×10^{-4}。

共因项的绝对敏感度是独立项的 **4.8** 倍。也就是说，把 β 从 **0.05** 核实到 **0.04**，比把 λ 从 1.0×10^{-6} 核实到 0.8×10^{-6} 更有价值。这与 §36.6.3 的结论一致，但这里给出了它的一般形式：先按弹性排序，再乘以各项的量级。

由此得到核实工作的优先顺序：第一，β 的打分依据；第二，T 的实际覆盖率 t_c（**§36.3.13**）；第三，λ 的工况修正；最后才是 λ 的第三位有效数字。反过来做（花两周去查器件的 FIT 值，却让 β 直接填 0.01）是这

类计算里最常见的资源错配。

36.4.11 一份可复核的报告该有哪几个数

前面所有公式都可以写进一行代码，**但报告的作用不是给结论，是让别人能重算。** 判断一份 SIL 验证报告是否合格，最简单的办法是：**把结论遮住，只看输入，能不能自己算出同一个数。** 按这个标准，报告里至少要有八个量，缺一个就不可复核：

1. **结构**（1oo1 / 1oo2 / 2oo3 …），**并附独立性证据**——独立电源、独立 I/O、独立电缆路径、异构与否。没有这一条，“结构”只是个代号。
2. λ_{DU} 与 λ_{DD}，逐段给出，注明来源（现场记录 / FMEDA / 数据库）与工况修正系数。
3. β，附打分表与得分项。**直接写“$\beta = 0.01$”的报告等于没写。**
4. DC，附诊断方法与验证记录。**“采用了先进诊断”不是证据。**
5. T，附“这个周期在现场真的执行得了”的说明——有没有停车窗口、PST 能不能做。
6. t_c，附“哪些失效模式覆盖不到”的清单（§36.3.13）。
7. MTTR，来自维修记录的中位数，不是行业典型值。
8. **需求模式与任务时间**，低要求还是高要求、任务时间多少、响应时间怎么分解（§36.5.7）。

最常见的缺口是第 3、6、7 三项。 报告里写满 λ 的六位有效数字，β 却只有一个数、t_c 根本没出现、MTTR 直接填 8 h——**这种报告的精度是假精度：输入的不确定度在百分之几十，输出却报到小数点后三位。**

还有一条格式要求：给出“最弱环节”的占比。 像 §36.5.1 那样把三段的比例列出来（阀门 81.8%、PLC 16.4%、变送器 1.9%），评审人一眼就能看出该改哪里。**没有这张比例表，报告就只是“达标”两个字，不能指导任何决策。**

36.4.12 从 P&ID 到可计算的段：四步拆法

公式都要求“先分段”。**分段分错，后面算得再准也没用。** 工程上有四步可循。

第一步，沿安全功能走一遍全链。 从“检测”到“动作”把所有元件列出来，**一个都不能漏**：热电偶（含保护套管）、补偿导线、安全栅、AI 通道、控制器 CPU、联锁程序、DO 通道、中间继电器、电磁阀、气源、阀体与执行机构。**最容易漏的是安全栅与中间继电器——它们不在 P&ID 上，而在机柜里。**

第二步，把串联的元件并成段。 段内元件互相串联，乘起来与顺序无关，所以可以合并。**合并的依据是“这一段能不能只用一个 λ_{DU} 描述”**——能，就并；不能，就拆。

第三步，把共享的部分单独提出来。 24 V 电源、机柜风扇、接地、电缆桥架、UPS、维护班组——**这些不属于任何一段，却同时影响所有段。**它们应当作为独立的共因项（或作为 β 的打分依据），**而不是塞进某一段的 λ 里。** 这一步做对了，β 才有依据；做错了，β 只能拍。

第四步，给每段定五个数： λ_{DU}、β、DC、T、t_c。**缺任何一个，这一段就不可计算**（§36.4.11）。

分段的粒度判据只有一条：段内应当只有一个主导失效模式。 若某一段里既有“漂移”又有“卡涩”，说明它该拆——因为这两种失效的 DC 与 t_c 完全不同，混在一起取平均会把两个数都算错。

按这四步重拆 §36.5.1 的三段，会得到五段： 热电偶与套管、变送器、AI 卡、CPU 与程序、DO 加电磁阀加阀体。**比例也随之变化**：原来“执行”一段占 81.8%，拆开后能看清阀体与电磁阀贡献了大部分，而 DO 卡只占很小一块。**这个更细的分解才指向正确的改进动作**——该换的是阀，不是 DO 卡。

最后一条经验：分段的详细程度应当与“改进决策”匹配。如果拆到二十段，每段的 λ 都查不到数据，精度反而是假的；如果只分三段，又看不出该改哪里。五到八段是多数过程工业回路的合适粒度。

36.5 工程含义与适用边界

36.5.1 例子的收口：反应釜联锁的完整设计

回到贯穿例子。假设三段各自的参数如下（典型值，仅作演示）：

- 温度变送器：$\lambda_{DU} = 5 \times 10^{-7}$/h，采用 1oo2 双支，$\beta = 0.02$；
- 安全 PLC 逻辑：$\lambda_{DU} = 1 \times 10^{-7}$/h，1oo1；
- 切断阀：$\lambda_{DU} = 5 \times 10^{-7}$/h，1oo1；
- 统一取 $T = 8760$ h。

逐段计算：

$$
\begin{aligned}
\mathrm{PFD}_{\mathrm{TT}} &= (1-0.02)^2 \frac{(5\times10^{-7}\times 8760)^2}{3} + 0.02 \times \frac{5\times10^{-7}\times 8760}{2} \approx 4.99 \times 10^{-5},\\
\mathrm{PFD}_{\mathrm{PLC}} &= \frac{1\times10^{-7}\times 8760}{2} = 4.38 \times 10^{-4},\\
\mathrm{PFD}_{\mathrm{XV}} &= \frac{5\times10^{-7}\times 8760}{2} = 2.19 \times 10^{-3}.
\end{aligned}
$$

串联相加：$4.99\times10^{-5} + 4.38\times10^{-4} + 2.19\times10^{-3} = 2.678\times10^{-3}$，落在 **SIL2** 区间，满足要求。

但三段的比例很难看：阀门占 81.8%、PLC 占 16.4%、变送器只占 1.9%。这意味着传感部分的冗余几乎白做。把阀门也改成 1oo2（$\beta = 0.02$）后，$\mathrm{PFD}_{\mathrm{XV}}$ 降到 4.99×10^{-5}，总 PFD 变成 5.378×10^{-4}，跨进 **SIL3**。

表 36-7 把三个方案并列。这张表是全章最该记住的一张——它说明“提升安全等级”的正确做法是补最弱环节，而不是把已经很好的环节再做一遍。

表 36-7　反应釜联锁的三个方案（$T = 8760$ h）

方案	传感	逻辑	执行	总 $\mathrm{PFD}_{\mathrm{avg}}$	SIL	评价
A（现状）	1oo2	1oo1	1oo1	2.678×10^{-3}	SIL2	阀门占 81.8%，冗余白做
B（只改阀）	1oo2	1oo1	1oo2	5.378×10^{-4}	SIL3	同样的钱，跨一级
C（全冗余）	1oo2	1oo2	1oo2	1.088×10^{-4}	SIL3	相对 B 仅改善 4.9 倍，成本翻倍

方案 C 是“过度设计”的典型：花了两倍的钱，只把 PFD 从 5.4×10^{-4} 降到 1.1×10^{-4}，而后者已经在 **SIL3** 区间内，再往下走对风险的实际贡献很小。这正是 §36.3.1“相加”结构的直接推论。

36.5.2 SIL 定级：风险矩阵与 LOPA

SIL 不是拍脑袋定的，两条常用路径：

风险矩阵：把“后果严重度”与“暴露频率”各分几档，交叉查表。**优点是快，缺点是粗**——同一格里的不同场景可能差一个数量级。

LOPA（保护层分析）：把风险拆成“初始事件频率 × 各独立保护层的失效概率”，与可容忍风险比较，差额就是 SIS 需要提供的风险降低因子。

以本例走一遍：初始事件（冷却水中断）频率 0.3/年；现有保护层有两个——BPCS 的温度控制（$\mathrm{PFD} = 0.1$）与操作员响应（$\mathrm{PFD} = 0.1$）。剩余风险

$$0.3 \times 0.1 \times 0.1 = 3 \times 10^{-3} \ /\text{年}.$$

若可容忍风险是 10^{-5}/年，则还需降低 300 倍，即 SIS 的 $\mathrm{PFD}_{\text{avg}} \le 3.3 \times 10^{-3}$——**落在 SIL2 区间，与 §36.1.3 的假设一致。**

LOPA 的三条纪律：

- **每个保护层必须独立**：共用传感器的两层只能算一层。
- **保护层的 PFD 不能随便取小**：BPCS 取 0.1、报警+操作员取 0.1 是行业惯例，**再小就需要证据。**
- **初始事件频率要有来源**：来自历史数据或数据库，不能“感觉差不多”。

36.5.3 七种不该上 SIS 的场合

这一节是“劝退清单”。**SIS 是最后一道防线，不是第一道。**

其一，危险可以被本质安全设计消除。 减小持液量、改用不反应的溶剂、降低储存温度——**消除危险比控制危险可靠得多，且不需要维护。**

其二，危险主要来自操作规程。 若事故链的根因是“操作工按错顺序”，那么改程序、改界面、加防错比加联锁有效。

其三，需求率极高。 如果一年要动作上百次，那它已经不是“安全功能”而是“常规控制”，**应当改造工艺或改控制方案，而不是堆一个高 SIL 的 SIS。**

其四，没有独立传感器可用。 若只能复用控制回路的那支热电偶，共因会让 SIS 与控制同时失效——**这种情况下算出来的 SIL 是假的。**

其五，执行器做不到失效安全。 阀门卡涩、电机没有弹簧复位，SIS 发出命令也无效。**先改执行机构，再谈 SIL。**

其六，维护能力跟不上。 证明测试做不到、旁路没有审批、备件不到位——**$\mathrm{PFD}_{\text{avg}}$ 的公式假设“测试真的做了”，做不到就是纸面数字。**

其七，安全功能本身会引入更大风险。 频繁误跳闸导致的起停、泄压、排料，可能比它防的事故更危险。**这条最容易被忽略，也最需要在 HAZOP 里专门讨论。**

36.5.4 三个现场

反应釜（过程工业）。 典型 SIL2，结构多为 1oo2 或 2oo3，**关键是证明测试的可执行性**——阀门部分行程测试（PST）能在不停车的情况下覆盖大部分卡涩失效，这是把 DC 从 0 提到 0.7 以上的常用手段。

电梯（机械安全）。 按 ISO 13849 定 PL，门锁与超速保护通常要求 PL d（对应 Category 3）。**它的特点是需求率低但后果确定，且误动作的直接受害者就是乘客，**所以“误跳闸”在这里不是经济问题而是安全问题。

AGV（移动机器人）。 速度限制、防撞、急停通常要求 PL d。**难点在“传感器覆盖范围”**：激光雷达的盲区、反光板的误检、地面湿滑导致的制动距离变化，都会让“检测到就停得住”这个假设失效。**这类系统的安全功能必须做在独立的安全控制器上，不能跑在负责导航的那台工控机上**——这与第 35 章的多智能体协调是两套完全独立的机制。

36.5.5 软件与学习型组件

软件失效是系统性的，所以对它的要求是**过程**而不是**指标**：

- **V 模型**：需求—设计—实现—单元测试—集成测试—确认，每一层都要有可追溯的验证记录。
- **编码规范与静态分析**：限制语言子集（不用动态内存、不用递归、限定循环上界），用工具做数据流与控制流检查。
- **独立验证**：SIL3 以上要求验证者与开发者不重合。
- **形式化方法**：对极关键逻辑（如联锁表决）用模型检验或定理证明，成本高但能覆盖穷举测试覆盖不到的组合。

学习型组件的位置必须划清：它可以做“建议”，不能做“安全功能”。 原因是三条：**训练分布无法穷举、失效模式无法枚举、行为无法用需求文档完整描述。** 工程上的可行架构是——**学习型控制器只输出建议值，经一个可验证的屏蔽层（安全包络）后才下发**，屏蔽层本身按本章的方法做 SIL 认证。**这样“不可验证的部分”被限制在不影响安全的范围内。**

36.5.6 与相邻章的接口

- **与容错控制章节**：本章算“失效概率”，容错控制解决“失效后怎么重构”。**前者是设计依据，后者是运行手段，两者共用同一套失效分类（表 36-2）。**
- **与 SIS 章节**：本章给指标与结构选型，SIS 章节给组态、旁路管理、证明测试规程。
- **与第 35 章**：多智能体的安全约束应当由本章的屏蔽层兜底；**把安全完全交给学习型智能体，在功能安全框架里是不可接受的。**
- **与第 58/80 章（MPC）**：MPC 可以在正常范围内处理约束，**但它不构成独立保护层**——共享模型与传感器这一点就决定了它不能计入 LOPA。

36.5.7 安全要求规格书该写什么

SIL 定级之后、选型之前，必须有一份**安全要求规格书（SRS）**。它把“要什么”写死，后面的设计、采购、验证都以它为判据。**一份能通过评审的 SRS 至少有十条内容：**

1. **功能描述**：输入是什么、逻辑是什么、输出是什么。本例是“TT-101 高于 110 ℃ 持续 2 s → 关 XV-101、开 XV-102”。
2. **触发值与延时**：动作值、回差、延时。**延时 2 s 是为了滤掉尖峰，但它计入响应时间，必须写清。**
3. **目标 SIL 与 $\mathrm{PFD}_{\mathrm{avg}}$**：写“低要求模式、SIL2、$\mathrm{PFD}_{\mathrm{avg}} \le 10^{-2}$”。
4. **响应时间分解**：传感 3 s、PLC 扫描 0.1 s、DO 与继电器 0.05 s、阀门全行程 8 s，**合计 11.2 s**；相对 480 s 的任务时间有 43 倍余量。**只写“响应时间 < 8 min”是不合格的，因为无法验证。**
5. **结构与独立性要求**：1oo2 双支热电偶、独立于 BPCS 的 I/O 卡与机柜、独立电源。
6. **诊断与测试要求**：$DC \ge 0.9$、$T = 6$ 个月、$t_c \ge 0.9$、PST 每季度一次。
7. **误跳闸限制**：年误停不超过 0.5 h，对应误跳闸率上限。

8. **复位策略**：手动复位，且复位条件为“温度低于 95 ℃ 持续 5 min”。
9. **失效安全方向**：逐台执行器写明失电位置。
10. **验证方法与记录**：FAT、SAT、回路校验、SIL 验证报告、测试记录保存年限。

第 8 条与第 9 条是最容易漏的两条，而且漏了会直接变成事故。

先说复位。 若联锁做成自动复位，温度降到 109 ℃ 时阀门重新打开、进料恢复、温度再升到 110 ℃——**这不是联锁，这是一个振荡器。** 每一次循环都在给反应釜加热，直到某个环节失效。**所以复位必须是手动的，而且要有复位条件**（工艺侧确认危险已消除），**手动复位不是“保守”，它是联锁逻辑的一部分。**

再说失效安全方向。 同一条联锁上挂着两个阀：进料阀 XV-101 的失效安全方向是“失电关”，冷却水阀 XV-102 的失效安全方向是“失电开”。**若把“失电关”当成通用规则套到冷却水阀上，事故工况下冷却水反而被切断——安全功能把事故做大了。** 这一条必须逐台写清，因为气开/气关的选型、电磁阀的常开/常闭、以及失气位置都由它决定。**“安全方向”不是设备属性，而是“这台设备在这个工艺位置上应该往哪边走”。**

36.5.8 旁路：唯一一项“管理直接决定数值”的环节

旁路是功能安全里最特殊的一件事：**它不改硬件、不改软件、不改计算，却能让前面所有公式失效。**

三种旁路，危险程度依次上升。 一是**软件旁路**（HMI 上的 bypass 功能）：有记录、有画面提示，相对可控。二是**硬线短接**（端子排上的跨接线）：只有打开柜门才看得见。三是**强制**（force，在 PLC 里把输入点锁成固定值）：**没有人能从画面上看出来，只有打开程序才能发现。** 现场事故调查里，“某个点被强制了三年没人知道”并不罕见。

旁路期间的安全功能等于不存在，这一点可以定量。若一年有 5% 的时间处于旁路，则这 5% 里需求一出现就是失效，等效

$$\mathrm{PFD}_{\mathrm{avg}} \geq 0.05 \times 1 + 0.95 \times \mathrm{PFD}_{\mathrm{calc}} \approx 0.05.$$

0.05 比 1oo2 的 2.4×10^{-4} 大两百倍，比 SIL1 的上限 10^{-1} 也差不了多少。 也就是说，**5% 的旁路时间，把一套 SIL3 的系统拉到了“连 SIL1 都勉强”。** 这条算术是“旁路必须有时限、有审批、有补偿措施”的最硬的理由——**它不是管理教条，它是数量级。**

配套的四件事，缺一不可：

- **补偿措施**：旁路期间加临时独立报警、加密巡检、限制负荷、禁止高风险操作（进料、升温、切换）。
- **三方审批**：工艺、安全、仪表各签一次；**只有仪表签字等于没签。**
- **硬时限**：不超过一个班次或一次检修窗口；到期未恢复必须升级上报。
- **台账与统计**：按回路累计旁路小时数，**月度公示。**这个数比任何“安全意识培训”都有效。

还有一条容易漏的叠加风险：测试窗口与旁路窗口往往重合。 证明测试本身就要把回路置于“不保护”状态，如果此时工艺正在进料升温，就是最坏组合。**所以测试计划要和排产计划一起排，不能由仪表车间单方面决定。**

36.5.9 人的因素与维护引入的失效

LOPA 里给“报警 + 操作员响应”的 PFD 惯例是 0.1，这个数不是随便定的，它对应一组前提：**报警清晰、有书面处置步骤、有定期演练、从报警到必须动作的时间足够（通常要求 10 min 以上）。** 任何一个前提不成立，实际值就会偏离：**没有演练时可以是 0.3–0.5，有清晰步骤且反复演练时可以到 0.01。** 差 30 倍。

人的失效也是共因。 三个“独立”保护层如果都靠人：同一班组、同一班次、同一份操作规程、同一次培训——**它们在失效上高度相关，只能算一层。** 这是 LOPA 评审里最常见的重复计数：把“操作员看温度”“操作员看压力”“班长巡检”算成三层，实际是一层。

维护引入的失效比设备失效更值得警惕，因为它不服从任何失效率模型，而且集中在“测试”这个动作上：

- **测试后未复位**：旁路忘记摘、阀门手轮忘记恢复、联锁开关留在“检修”位。IEC 61511 给的典型量级是每次测试 $10^{-2} \sim 10^{-3}$ 的概率。
- **量程与组态改错**：换变送器后量程没改，110 ℃ 对应 4–20 mA 的刻度全错，**联锁在错误的温度上动作。**
- **接线接反**：热电偶极性接反，温度上升时读数下降——**联锁永远不动作，而且自诊断看不出来。**
- **“临时”改动固化**：为了开车方便把延时从 2 s 改成 60 s，之后没人改回来。

把“未复位”这个概率代进计算，会得到一个刺眼的结论。 一年做 2 次证明测试、每次 10^{-2} 的未复位概率，则平均约有 2×10^{-2} 的时间比例处于“回路不保护”状态——**等效 PFD 不低于 2×10^{-2}，比 1oo2 的计算值大两个数量级。** 换句话说，**在低要求模式下，人的一次疏忽可以完全覆盖掉硬件冗余带来的全部收益。**

对策不是“加强培训”，而是把测试当成一次受控的变更：

- **测试票**：谁测、测什么、旁路哪些点、几点恢复，全部写在票上。
- **测试后功能确认**：不只是“看阀门动了”，而是“阀门到位的反馈 + 回路电流校验 + 联锁试验”三样齐全。
- **双人复核**：一人操作、一人核对，**核对的人要有权叫停。**
- **状态可视化**：旁路与强制在 HMI 上常驻显示，**不允许“隐藏”这个功能。**

这三条与 §36.6.7 的可用度结论是同一件事的两面：安全系统的真实水平不由计算决定，而由“测试怎么做、旁路怎么管、人怎么失误”决定。 计算给出的是上限，管理决定实际落在哪里。

36.5.10 从设计到运维：五个节点与它们的交付物

功能安全是一条链，链上每个节点都要留一份**能被下一个人使用**的东西。**没有交付物，节点就等于没做。**

节点一，危险分析。 交付物是危险清单与可容忍风险准则（HAZOP 记录、风险矩阵）。**它决定了“什么叫做够安全”**，后面所有数字都是相对它而言的。缺失的后果最严重：**没有准则，SIL 定级就只能靠供应商推荐。**

节点二，SIL 定级。 交付物是 LOPA 表：初始事件频率、各保护层 PFD、剩余风险、所需风险降低因子。**这张表要能被非仪表专业的人读懂**，因为它最终是工艺与安全部门签字的东西。

节点三，安全要求规格书。 交付物是 §36.5.7 那十条。**这是全链唯一一份“设计输入”，也是最容易被写成“满足规范要求”这六个字的地方。** 一份合格的 SRS 应当能让另一个厂家照着它做出同样的系统。

节点四，设计与验证。 交付物是 SIL 验证报告（§36.4.11 的八个量）加 FAT/SAT 记录。**FAT 查逻辑、SAT 查回路，两者不能互相替代**——FAT 时阀门还没接管路，SAT 时才能看到全行程时间与真实压差。

节点五，运维。 交付物是证明测试台账、旁路台账、变更记录。**这一节点最没有技术含量，却决定了前面四个节点的成果能不能保住**（§36.5.8、§36.5.9 的算术已经说明了这一点）。

链上最常见的一处断裂在节点三到节点四之间。 SRS 里没写测试周期与覆盖率，验证时就只能用“行业默认值”（一年一测、$t_c = 1$）；**默认值算出来的漂亮结果，到运维阶段发现测试根本做不到，于是 PFD 回到真实值而没人重算。** 这条断裂不会在现场立刻出事，它会在几年后的一次事故调查里被发现。

另一处断裂在节点五内部：测试记录与计算脱节。 计算假设 $T = 8760$ h，实际因为等停车窗口拖到 14000 h，**没有任何机制把这个偏差反馈回 SIL 验证报告。** 工程做法是把“实际测试间隔”作为 KPI 定期统计，超

期即触发重算——这一条比任何精度更高的公式都值钱。

36.5.11 定高了与定低了的代价

SIL 定级最容易被误解成“越高越好”。**实际上两头都有代价，而且代价的类型不同。**

定低了的代价是显性的：剩余风险超过可容忍值。补救只有两条——加独立保护层，或者做 ALARP 论证说明“再降不现实”。**后者需要成本-收益的证据，不是一句“行业惯例”。**

定高了的代价是隐性的，而且会反噬。 每提高一级，典型增量是：冗余通道（硬件翻倍）、诊断（DC 从 0.6 提到 0.9 以上）、测试频次（T 从一年缩到半年甚至季度）、文档与认证（验证报告、独立审核）。**成本大致翻倍，而风险只改善一个数量级——边际收益递减得非常快。**

更麻烦的是测试频次这一项会反噬安全性。 T 减半意味着测试次数翻倍，而每次测试都是一次旁路窗口（§36.5.8）、一次人为失误的机会（§36.5.9）。**把 T 从 8760 h 缩到 4380 h，公式上 PFD 减半；实际上多出来的那次测试，可能带来 10^{-2} 量级的“未复位”风险。** 两者相抵，**加密测试的净收益可能接近于零，甚至为负。**

这条张力可以写成一句判断：

> **安全等级越高，运维负担越重；运维负担一旦超出组织能力，系统实际的安全水平反而下降。**

所以定级的终点是两个条件同时满足：风险低于可容忍值，且已做到“合理可行的最低水平”（ALARP）。 后者是定性的，但它挡住了“为了保险起见再上一级”这种把成本转嫁给运维的做法。**一份好的定级报告会明确写出“为什么不再提高一级”，而不只是“为什么达到这一级”。**

36.6 仿真与验证

36.6.1 实验设置与复现约定

六组实验共用种子 `SEED = 20261136`，纯 numpy 实现，不依赖任何 SIL 计算软件。**理由与前几章一致：数字必须能一行行查回去。** 全部实验在 py311 下总耗时约 4 s。

统一参数：$\lambda_{DU} = 10^{-6}$/h（约 1000 FIT）、$\lambda_S = 2 \times 10^{-6}$/h、$\mathrm{MTTR} = 8$ h、T 在 500–8760 h 之间取。**这组参数不是“典型器件”，而是为了让四条结构线在图 36-2 上分得开；**真实器件的 λ 通常小一个数量级。

六组实验的分工：

实验	对象	回答的问题	对应小节
E1	四种结构 × 六个 T	结构与测试周期各值多少	§36.6.2
E2	β 从 0 到 0.2	共因把冗余吃掉多少	§36.6.3
E3	DC 从 0 到 0.99	诊断能把单通道推到多高	§36.6.4
E4	解析 vs 蒙特卡洛	两条路是否自洽	§36.6.5
E5	五事件故障树	最小割集与近似误差	§36.6.6
E6	三种结构的误跳闸与可用度	安全与可用怎么权衡	§36.6.7

36.6.2 E1：结构与测试周期的双重代价

E1 扫了六个测试周期与四种结构，结果见表 36-8 与图 36-2。

表 36-8　四种结构的 $\mathrm{PFD}_{\mathrm{avg}}$ 随测试周期变化（E1 实测，$\lambda_{DU} = 10^{-6}$/h）

T（h）	1oo1	1oo2	2oo3	2oo3（$\beta = 0.1$）
500	2.500×10^{-4}	8.333×10^{-8}	2.500×10^{-7}	2.520×10^{-5}
1000	5.000×10^{-4}	3.333×10^{-7}	1.000×10^{-6}	5.081×10^{-5}
2000	1.000×10^{-3}	1.333×10^{-6}	4.000×10^{-6}	1.032×10^{-4}
4000	2.000×10^{-3}	5.333×10^{-6}	1.600×10^{-5}	2.130×10^{-4}
6000	3.000×10^{-3}	1.200×10^{-5}	3.600×10^{-5}	3.292×10^{-4}
8760	4.380×10^{-3}	2.558×10^{-5}	7.674×10^{-5}	5.002×10^{-4}

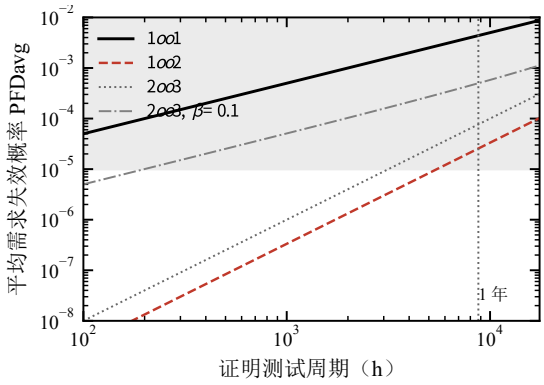

图 36-2　$\mathrm{PFD}_{\mathrm{avg}}$ 随证明测试周期的变化：四条线的斜率不同，说明冗余与测试不是等效手段

三条读数。

第一，**1oo1** 与 T 成正比，**1oo2** 与 T^2 成正比，**2oo3** 也与 T^2 成正比。图 36-2 是对数坐标，直线的斜率就是幂次：1oo1 斜率 1，另两条斜率 2。这意味着**缩短测试周期对冗余结构的收益是平方级的**——T 减半，1oo1 的 PFD 减半，1oo2 减到四分之一。**这是“高 SIL 系统必须频繁测试”的定量理由。**

第二，$T = 8760$ 时，**1oo2** 相对 **1oo1** 改善 **171.2** 倍，**2oo3** 改善 **57.1** 倍，而带 $\beta = 0.1$ 的 **2oo3** 只改善 **8.8** 倍。三者的差别全部来自共因项——**独立项的差别只有 3 倍，共因项把差距拉到了 20 倍。**

第三，$T = 500$ 时 **1oo2** 的 $\mathrm{PFD}_{\mathrm{avg}}$ 已经到 8.3×10^{-8}，远低于 **SIL4** 的下界。但这个数没有工程意义：真实系统的 $\mathrm{PFD}_{\mathrm{avg}}$ 会被共因、系统性失效、以及“测试本身可能不完整”卡在 10^{-5} 附近。公式给出的极小值只在“完全独立、测试完全有效”的假设下成立，这两个假设在工程上都不成立。

36.6.3 E2：共因把冗余吃掉多少

E2 固定 $T = 8760$ h，扫 $\beta \in \{0, 0.01, 0.02, 0.05, 0.1, 0.2\}$。结果已在 §36.3.5 与图 36-3 中给出，这里只补两条容易被忽略的读数。

其一，$\beta = 0.02$ 时，**1oo2** 的 PFD 恰好卡在 1.12×10^{-4}，刚从 **SIL3** 掉到 **SIL2** 的边界附近；而 **2oo3** 在同样的 β 下是 1.61×10^{-4}，已经明确落在 **SIL2**。也就是说，“三取二”对共因比“双通道并联”更敏感——因为它的独立项本来就大 3 倍，共因项一加就更难守住 SIL3。

其二，共因占比在 $\beta = 0.01$ 时就已经超过 **60%**（**1oo2** 为 **63.6%**，**2oo3** 为 **36.8%**）。这个数很反直觉：**只要 1% 的失效是共因，冗余的收益就已经被吃掉大半。**原因是独立项本身就是 λ^2 量级，非常小；共因项是 λ 量级，哪怕系数只有 0.01，也足以主导。

工程含义：β 的估计误差比 λ 的估计误差更重要。λ 差 20%，PFD 差 20%；β 从 0.02 差到 0.05，1oo2 的 PFD 从 1.12×10^{-4} 变成 2.42×10^{-4}，**差 2.2 倍，足以跨越一个 SIL 边界。**

36.6.4 E3：诊断能把单通道推到多高

E3 的结果（§36.3.6）可以压成一句话：**DC 从 0 提到 0.9，单通道从 SIL1 到 SIL2；提到 0.99，到 SIL3。**

三点补充：

其一，**$DC = 0.7$ 是“投入产出比”的拐点。**从 0 到 0.7 只改善 3.3 倍，从 0.7 到 0.9 改善 3 倍，从 0.9 到 0.99 再改善 8.6 倍。**前 70% 靠简单手段（量程、变化率、看门狗），后 30% 靠比较法与模型，成本陡增。**

其二，**DC 与 β 不能同时“都要”。**诊断本身若与被诊断通道共因，高 DC 就是假的。**工程上必须回答：“诊断用的那路信号，和被测信号共享了什么？”**若共享电源、共享 A/D、共享同一支传感器，DC 的实际值要打折。

其三，**DC 只对 λ_{DU} 有效。**它不能降低共因失效，也不能降低系统性失效。**所以“加诊断”永远不能替代“加独立性”。**

36.6.5 E4：两条路是否自洽

E4 在 $T = 4000$ h 下，对四种情形各跑 10 个种子 × 200 万样本。结果：

- 1oo1：解析 2.0000×10^{-3}，蒙特卡洛 2.0122×10^{-3}，偏差 $+0.61\%$；
- 1oo2：解析 5.3333×10^{-6}，蒙特卡洛 5.2000×10^{-6}，偏差 -2.50%；
- 2oo3：解析 1.6000×10^{-5}，蒙特卡洛 1.6600×10^{-5}，偏差 $+3.75\%$；
- 2oo3（$\beta = 0.1$）：解析 2.1296×10^{-4}，蒙特卡洛 2.1890×10^{-4}，偏差 $+2.79\%$。

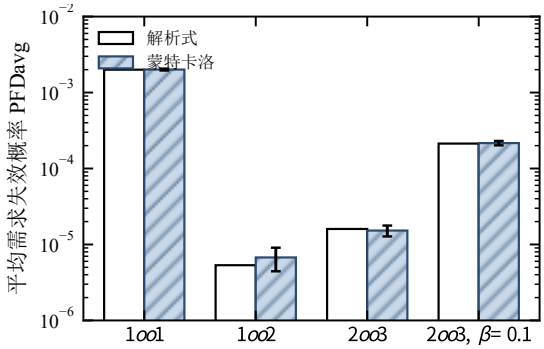

图 36-5　蒙特卡洛与解析式的对照：偏差都在统计涨落范围内，共因情形主导项一致

四条偏差都在 4% 以内，且方向不一致（两正两负），这正是“统计涨落”的特征。如果四条都往同一方向偏，就要怀疑模型不一致（比如蒙特卡洛里漏了 β 项）；如果偏差随 p 减小而系统性增大，那是样本量问题（§36.4.4）。

图 36-5 用的是 800 万样本而不是两千万，因此误差棒比正文的偏差更大。这张图的目的是展示“误差棒与解析值重叠”，而不是精确定值——**这一点在图上必须看得出来，否则读者会误以为蒙特卡洛可以替代解析式**

计算。

36.6.6 E5：最小割集与近似误差

E5 的两个算例已在 §36.3.7 给出。补充三点：

其一，“单事件主导”是故障树的常态，不是特例。 真实系统里总有一两条割集的概率比其余大几个数量级——因为单点失效（一个电源、一个共用阀门、一次误操作）的概率远高于两个独立事件同时发生。

其二，稀有事件近似的误差方向是确定的：永远偏大。 因为交集被重复计数。偏差量级约等于“割集概率之和的平方除以 2”，本例中 6×10^{-4} 的平方量级是 2×10^{-7}，相对 6×10^{-4} 是 3×10^{-4}，与实测 $+0.020\%$ 同量级。

其三，最小割集的数量本身就是设计质量的指标。 一个顶事件有 20 条最小割集，说明有 20 种“两两组合”能让它失效——这通常意味着冗余设计有漏洞，或者共因没控制住。好的设计应当让最小割集少而长（每条含多个基本事件）。

36.6.7 E6：安全与可用的权衡

E6 的结果见表 36-6 与 §36.3.10 的讨论。这里补两条与可用度有关的读数。

其一，可用度对 MTTR 极不敏感，因为 $\lambda\,\mathrm{MTTR}\ll1$。 取 $\lambda_{DU}+\lambda_S=3\times10^{-6}$/h，$\mathrm{MTTR}$ 从 1 h 变到 72 h，可用度只从 0.999997 降到 0.999784——变化不到万分之二。

其二，真正决定“停机时间”的是误跳闸率，不是 MTTR。 1oo1 的年误停 0.14 h、1oo2 是 0.28 h、2oo3 约等于 0——这三个数的差别来自误跳闸率，而不是修复速度。所以“提高可用度”的正确做法是**减少误跳闸**（改用 2oo3、加延时确认、加多信号表决），而不是“修得更快”。

这条结论与很多人的直觉相反。直觉上“坏得快修”应当提高可用度，但在安全系统里，设备很少坏，坏的时候往往是被误触发。修得快只是缩短了每次误停的时长，减少误停的次数才是数量级的改善。

36.6.8 交叉核对：六组实验之间应当自洽

其一，E1 与手算。 $T=8760$ 时 1oo1 的 4.380×10^{-3} 与 $\lambda_{DU}T/2$ 完全一致；1oo2 的 2.558×10^{-5} 与 $\lambda^2T^2/3$ 一致；2oo3 的 7.674×10^{-5} 与 λ^2T^2 一致。三条公式三条线，互相对上。

其二，E2 与 E1。 E2 在 $\beta=0$ 处给出 1oo2 的 2.56×10^{-5}，正是 E1 在 $T=8760$、$\beta=0$ 的值。同一个数从两条代码路径出来，说明 β 项没有写错。

其三，E3 与 E1。 E3 在 $DC=0$ 处给出 4.38×10^{-3}，等于 E1 的 1oo1。$DC=0$ 必须退化为无诊断，这是式 **36-15** 的极限检验。

其四，E6 与 E2。 E6 用 $\beta=0.05$ 得 1oo2 的 2.421×10^{-4}，E2 在同一 β 下是 2.42×10^{-4}。一致。

其五，E4 与解析式。 四条偏差都在 4% 内且方向不一，符合统计涨落。

五处都对上，才说明这六组实验是同一套模型、同一套单位。只要有一处对不上，先查单位，再查 β 项，最后查结构定义（1oo2 与 2oo3 的失效条件最容易写反）。

36.6.9 没有做的实验，以及为什么

其一，没有做真实 SIL 认证流程的复现。 那需要完整的 FMEDA、共因打分表、证明测试规程与第三方审核，不是一段代码能覆盖的。

其二，**没有做软件失效的定量模型**。理由已在 §36.3.11 说明：软件不服从指数分布，**任何“软件失效率”的数字都是伪定量**。

其三，**没有做动态需求（高要求模式）的仿真**。高要求模式下 PFH 与需求率耦合，需要把过程模型一起建进来，**属于具体工程案例，不适合放在入门章**。

这三件事没做，恰恰划出了本章的边界：本章给的是“随机硬件失效的定量方法 + 系统性失效的定性纪律”，不是一份完整的认证方案。

36.6.10 复现约定与数字清单

本章所有数字由 `code/ch036_sim.py` 一次运行给出，正文不取整、不二次修约。**重跑的两条命令：**

```
"D:\Anaconda3\envs\py311\python.exe" code/ch036_sim.py
"D:\Anaconda3\envs\py311\python.exe" code/ch036_figs.py
```

第一条打印六组实验的全部数值，第二条把六张图写进 `figs/ch036/`（SVG 与 PDF 各一份）。**图与正文用的是同一份函数输出，不存在“图上一套、文里一套”的可能。**

重跑结果与本章不一致时，按这个顺序排查：

1. **随机数流**：种子固定为 `20261136`，但 numpy 的 `Generator` 与旧的 `RandomState` 流不同，换版本会变。**这是最常见的“数字对不上”。**
2. **抽样顺序**：先抽通道失效时刻再抽共因时刻，与反过来抽，会消耗不同的随机数。**顺序一变，同一种子给出不同结果，这是正常的。**
3. **累加顺序**：两千万个样本求和，成对求和与顺序求和的末位不同，相对误差在 10^{-15} 量级，**不影响任何结论**。
4. **蒙特卡洛的统计涨落**：偏差在 $\pm 4\%$ 内属正常（§36.6.5）。**不要为了让数字好看去换种子——那是把统计涨落改成了挑选结果。**

六组实验的关键数字，一页看完：

- E1（$T = 8760$）：1oo1 4.380×10^{-3}、1oo2 2.558×10^{-5}、2oo3 7.674×10^{-5}、2oo3（$\beta = 0.1$）5.002×10^{-4}；
- E2：1oo2 的共因占比从 0 涨到 0.982，$\beta = 0.01$ 时已是 0.636；
- E3：DC 从 0 到 0.99，1oo1 从 4.38×10^{-3} 降到 5.17×10^{-5}，改善 84.7 倍；
- E4：四种情形的蒙特卡洛偏差 $+0.61\%$、-2.50%、$+3.75\%$、$+2.79\%$；
- E5：单事件主导偏差 0.000%，三割集相当偏差 $+0.020\%$；
- E6：年误停 0.14 h / 0.28 h / 约 0，可用度 0.999997 到 0.999784。

这 19 个数字就是本章的全部实测量。其余数字都是公式代入，**任何一个都能用 §36.4.3 那十行代码复算。**

36.6.11 把参数换成现场值会怎样

本章统一取 $\lambda_{DU} = 10^{-6}$/h（1000 FIT），这个值偏大。**真实智能变送器的 λ_{DU} 常在 5×10^{-8}/h 量级（50 FIT），切断阀约 2×10^{-7}/h。**参数换成现场值，结论会变，而且变化的方向很有教育意义。

取 $\lambda_{DU} = 5 \times 10^{-8}$/h、$T = 8760$ h，单通道 1oo1 得

$$\mathrm{PFD}_{\mathrm{avg}} = \frac{5 \times 10^{-8} \times 8760}{2} = 2.19 \times 10^{-4},$$

直接落在 **SIL3**——一支变送器、一年一测。 这个结果显然与工程经验不符，说明公式里少算了东西。把三块“地板”逐层加回来：

- 共因地板（1oo2、$\beta = 0.05$）：$0.05 \times 2.19 \times 10^{-4} = 1.10 \times 10^{-5}$；
- 测试覆盖率地板（$t_c = 0.9$、$T_{\mathrm{life}} = 20$ 年）：$0.1 \times 5 \times 10^{-8} \times 87600 = 4.38 \times 10^{-4}$；
- 旁路地板（年旁路 5%）：0.05。

三块地板的数量级是 10^{-5}、10^{-4}、10^{-2}，一个比一个大一个数量级。 最终决定实际安全水平的不是公式算出的 2.19×10^{-4}，而是最大那块——旁路。

这条排序是本章最实用的结论之一：

> 改进顺序应当是“先管旁路、再提测试覆盖率、最后才谈冗余”。

而绝大多数项目的做法正好相反：先讨论上 1oo2 还是 2oo3，把 PFD 从 10^{-4} 压到 10^{-5}，却让 **5%** 的旁路时间和 **10%** 的测试盲区原封不动。 这相当于把水桶最短的那块板擦得更亮。

这也解释了 **§36.6.1** 为什么故意用偏大的 λ： 参数一大，结构与测试周期的差异在图 36-2 上才分得开，读者才能看清“公式里各因素各占多少”。真实项目的计算反而很早就收敛——不是算不动，而是算到 10^{-5} 以下就没有意义了，因为旁路和覆盖率早就把地板放在那里。

36.6.12 六组实验的共同局限

把话说在前面：这六组实验验证的是“公式与代码自洽”，不是“公式适用于你的装置”。 四条共同局限：

其一，全部假设常数失效率。 一旦设备进入耗损期（§36.2.10），实际 λ 随时间上升，表 **36-8** 的每一行都会偏低，而且偏低得越来越多。

其二，全部假设测试瞬时完成、且不影响工艺。 真实测试要几十分钟到几小时，这段时间里安全功能不存在；本章的公式里没有这一项，它被算进了 §36.5.8 的“旁路地板”。

其三，修复时间只用均值。 马尔可夫与蒙特卡洛里都用了单一 MTTR，而实际修复时间是对数正态分布——少数几次“等备件”的长修复，会显著抬高不可用度，均值掩盖了它。

其四，样本量只够验证量级。 E4 的两千万样本在 $p \approx 5 \times 10^{-6}$ 时给出约 3% 的标准误，这已经是“能确认模型没写错”的下限，远不足以支撑“精确到小数点后两位”的结论。

所以本章实验的定位是“标定公式”，不是“替代工程计算”。 拿到自己的项目上时，要替换的不是代码，而是四个输入：λ 的来源、β 的打分、T 与 t_c 的实际值、MTTR 的记录值。这四样一换，公式给的就是工程数；不换，它只是一道练习题。

36.6.13 本章数字与图表的对应关系

最后交代一句图与数的对应，方便对照检查。

图 **36-1** 是结构示意，不含数据，三个面板分别是表 **36-1** 里的 **1oo1**、**1oo2**、**2oo3** 三行。 图 **36-2** 画的是表 36-8 的四个列，对数坐标下斜率即幂次（§36.6.2 的读数一）。图 **36-3** 画 E2 的 β 扫描，那条点线是 1oo1 的基准 4.38×10^{-3}——所有冗余曲线最终都要向它靠拢，图右上方标注的“结构冗余失效”指的就是这个收敛。图 **36-4**

画 E3 的 DC 扫描，**横轴是线性刻度**，所以“越接近 1 越陡”的视觉效果才出得来。**图 36-5** 是 E4 的柱状对照，8 个种子各一百万样本（合计八百万），误差棒比正文的多千万样本方案更大（§36.6.5 已说明）。**图 36-6** 是故障树，右侧的割集排序用的是 E5 的第二个算例“三割集相当”——**因为这个算例的三条割集同量级，排序框才有内容可写；第一个算例里 $\{E\}$ 独占四个数量级，画出来反而看不出结构。**

六张图里只有图 **36-5** 带不确定度，其余都是确定性的公式曲线。这个差别在阅读时要留意：**曲线上的点不需要误差棒，柱状图上的点必须有。**

36.7 小结与常见错误

36.7.1 十条要点

第一，性能与安全是两套评价。性能问“正常时多好”，安全问“异常时多坏”。**同一个回路不能既做控制又做保护，因为它们的失效是共因的。**

第二，三个量构成一条链。可靠性（多久坏一次）、诊断与测试（多久发现）、维修性（多久恢复）。**缺一环，“安全”就只是口号。**

第三，SIL 是区间，不是标签。$\mathrm{PFD}_{\mathrm{avg}}$ 落在哪个区间就是哪一级，**器件等级不等于系统等级。**

第四，单通道 + 一年一测只能到 SIL1。本章算例给出 4.38×10^{-3}。**要上 SIL2，必须降 λ、缩 T、加冗余或加诊断，四条路选一条。**

第五，冗余的收益是平方级的，前提是独立。1oo2 的 PFD 是 $\lambda^2T^2/3$；一旦共因主导，平方项被线性项取代。

第六，共因是冗余的天花板。地板 $\beta\lambda T/2$ 与通道数无关。$\beta=0.01$ **就能吃掉 60% 以上的收益。**

第七，诊断把潜伏期换成修复期，比值约 $T/(2\,\mathrm{MTTR})$。所以 DC 越接近 1 越值钱，**但诊断本身不能与被诊断对象共因。**

第八，串联的 PFD 是各段之和。提升等级要补最弱环节；把已经很好的环节再做一遍，收益趋近于零（表 36-7 的方案 C）。

第九，故障树的价值在排序，不在算概率。稀有事件近似偏大但够用；**真正要做的是找出概率最大的那条割集。**

第十，软件失效是系统性的，只能用过程对付。$\mathrm{PFD}_{\mathrm{avg}}$ **只覆盖随机硬件失效；**SIL 证书不等于系统安全。

36.7.2 一页验收清单

表 36-9 是本章的验收清单。**设计评审时逐行过，任何一行答不上来就是缺口。**

表 36-9　安全仪表功能的设计验收清单

序号	检查项	合格判据	不通过的典型症状
1	危险分析	有 HAZOP 记录与可容忍风险准则	只有“经验上一直这么做”
2	SIL 定级	由 LOPA 或风险矩阵给出，可追溯	SIL 由供应商推荐
3	独立性	传感器、逻辑、执行与 BPCS 物理分开	复用控制回路的变送器
4	结构选择	与 SIL、误跳闸代价匹配	一律用 1oo2，误停频繁
5	共因评估	有 β 打分记录，β 有依据	β 直接取 0.01
6	诊断覆盖率	DC 有测试证据，且诊断独立	声称 $DC = 0.99$ 无验证
7	测试周期	T 可执行，测试覆盖率有定义	T 定了但从未做过
8	响应时间	从检测到动作的全链条时间 < 任务时间	只算 PLC 扫描周期
9	误跳闸评估	有年误停时间估算与对策	只算安全性不算可用性
10	变更管理	旁路有审批、有期限、有补偿措施	旁路长期挂着

最容易漏的是第 8 行和第 10 行。 前者只算控制器、不算阀门全行程时间；后者把旁路当“临时措施”长期保留，而旁路期间的安全功能等于不存在。

清单的用法是“逐行签字”，不是“通读一遍”。 每一行都要填上对应的文件号或记录编号，签字的人对这些编号负责——**这才叫验收，否则只是确认“我们讨论过”。**

36.7.3 选型：结构怎么挑

表 36-10 把四种结构与典型需求对齐。**它是决策表，不是性能排序表。**

表 36-10　冗余结构的选型

需求	推荐结构	理由	需要配套
SIL1、误停代价低	1oo1	最简单、成本最低	定期测试
SIL2、可用性要求一般	1oo1D 或 1oo2	诊断或冗余任选其一	高 DC 或低 β
SIL3、误停代价高	2oo3	安全与误跳闸兼顾	三路独立、一致性测试
SIL3、误停代价低	1oo2	结构最省	严格控 β
SIL4	2oo4 或多重冗余	单点故障不足以失效	多样性、形式化验证

选型的第一问不是“要多安全”，而是“误停一次值多少钱”。 这个问题答不上来，2oo3 与 1oo2 之间的选择就只能靠拍脑袋。

36.7.4 十条常见错误

错误一：用 SIL 等级评价器件而不是系统。 买了一个 SIL3 的变送器，不等于回路是 SIL3。

错误二：把 $\mathrm{PFD}_{\mathrm{avg}}$ 当成“每年失效概率”。 它是“每次需求失效的概率”，与需求率无关；**需求率一高，必须换 PFH。**

错误三：单位不统一。 10^{-6}/h 与 10^{-6}/年差 8760 倍，**恰好跨两个 SIL 等级。**

错误四：β 取 0 或取得很小以求“好看”。 共因是物理事实，取 0 只是把风险藏起来。

错误五：加了冗余就认为共因解决了。 同一电源、同一软件、同一维护班次，冗余等于没加。

错误六：把 DC 当成“万能提升”。 诊断与被诊断对象共因时，高 DC 是假的；而且 DC 对系统性失效无效。

错误七：只算 PFD，不算误跳闸。 频繁误停会导致旁路，**旁路期间的安全功能等于零**——这是最危险的隐性失效。

错误八：测试周期定了但测试覆盖率没定义。 “每年测一次”若只测了传感器没测阀门，**阀门的 T 实际是无穷大。**

错误九：忽略响应时间的全链条。 传感器延迟、PLC 扫描、阀门全行程，**三者相加才是响应时间**；只算 PLC 会低估一个数量级。

错误十：把学习型控制器放进安全回路。 训练分布无法穷举、失效模式无法枚举，**它只能做建议，不能做保护。**

36.7.5 与后续章节的衔接

本章给的是“失效概率怎么算、结构怎么选、测试怎么做”。**再往前一步是三个方向：一是“失效后怎么继续运行”，这是容错控制；二是“安全仪表系统怎么组态与运维”，这是 SIS 章节；三是“怎么证明整套系统达到了目标”，这是验证与认证。**

如果只记住一句话：安全不是“加一个联锁”，而是“用独立的结构、可验证的测试、有限的共因，把失效概率压到可容忍的水平，并且承认剩下的部分只能靠过程保证”。

本章所有公式都服务于同一个目的：把“安全”这个形容词，变成能被别人复核的数字。 数字算得再准，只要输入的 β、T、t_c 是拍的，这份计算就仍然是一个形容词。

36.7.6 术语对照

表 36-11 汇总本章术语。**它的用途是查“我用的词是不是标准里的那个词”。**

表 36-11　本章术语对照

中文	英文	一句话含义	常见误用
安全完整性等级	SIL	按 $\mathrm{PFD}_{\mathrm{avg}}$ 分的四档	当成器件属性
平均需求失效概率	$\mathrm{PFD}_{\mathrm{avg}}$	需求出现时功能失效的平均概率	当成年失效概率
每小时失效频率	PFH	高要求模式下的对应指标	与 $\mathrm{PFD}_{\mathrm{avg}}$ 混用
安全失效分数	SFF	失效中往安全侧走的比例	与 DC 混同
诊断覆盖率	DC	在线能发现的危险失效比例	不计诊断独立性
共因失效	CCF	多通道同时失效	认为冗余天然独立
共因因子	β	共因占总失效的比例	取 0 或凭感觉取
证明测试	proof test	定期验证安全功能仍可用	只测传感器不测阀门
最小割集	minimal cut set	能让顶事件发生的最小组合	与“故障路径”混用
风险优先数	RPN	$S \times O \times D$	用它判定安全性
保护层分析	LOPA	逐层算风险降低	把非独立层重复计数
误跳闸	spurious trip	无危险时误动作	只算安全性不算它

最容易混的是“$\mathrm{PFD}_{\mathrm{avg}}$ 与 PFH”、“SFF 与 DC”、“RPN 与 SIL”。 前一对是模式不同（低要求 vs 高要求），中间一对是方向与能力之分，最后一对是“排序工具”与“判定准则”之分。

36.7.7 三个自测题

题一。 某联锁用 1oo2 双通道，$\lambda_{DU} = 2 \times 10^{-7}$/h、$\beta = 0.05$、$T = 8760$ h。求 $\mathrm{PFD}_{\mathrm{avg}}$ 与 SIL。若把 T 缩短到 4380 h，$\mathrm{PFD}_{\mathrm{avg}}$ 变成多少？

参考答案： 独立项 $(0.95)^2(2 \times 10^{-7} \times 8760)^2/3 = 9.23 \times 10^{-6}$，共因项 $0.05 \times 2 \times 10^{-7} \times 4380 = 4.38 \times 10^{-5}$，合计 5.30×10^{-5}，**SIL3**。T 减半后独立项降到四分之一（2.31×10^{-6}），共因项减半（2.19×10^{-5}），合计 2.42×10^{-5}，**仍 SIL3，只改善 2.2 倍——共因主导时，缩短测试周期的收益被压缩成线性。**

题二。 一个回路由三段串联：传感 1.0×10^{-4}、逻辑 2.0×10^{-5}、执行 8.0×10^{-4}。总 $\mathrm{PFD}_{\mathrm{avg}}$ 是多少？达到 SIL2 了吗？若只能改一段，改哪一段？

参考答案： 总 $= 9.2 \times 10^{-4}$，**SIL3**（落在 $10^{-4} \sim 10^{-3}$）。**注意它已经满足 SIL2 且达到 SIL3**，所以“达到 SIL2”这个问法本身提示要先看目标。若目标是 SIL3 且要求留余量，应当改执行段——它占 87%，改它能把总量降到 1.2×10^{-4} 量级；**改传感段最多只能降到 8.2×10^{-4}，几乎没用。**

题三。 某安全功能误跳闸率 1×10^{-5}/h，每次误停 6 h。年误停时间是多少？若改用 2oo3，误跳闸率降到 10^{-9}/h，节省的时间值多少钱（按每小时产值 2 万元计）？这个收益能否抵消 2oo3 的额外建设成本？

参考答案： 年误停 $= 10^{-5} \times 8760 \times 6 = 0.526$ h，损失约 1.05 万元/年。改 2oo3 后几乎为零，**年节省约 1 万元**。若 2oo3 的额外建设成本是 30 万元，**静态回收期 30 年——从纯经济账看并不划算。** 这说明 2oo3 的选择理由通常不是“省停机费”，而是“误停会引发更危险的工况”或“频繁起停损伤设备”。**这道题的用意是让人分清“经济账”与“安全账”，不要用前者去论证后者。**

36.7.8 一页公式卡

最后把全章的式子收在一页。**建议打印出来贴在工位上，比翻书快。**

基础量： $R(t)=e^{-\lambda t}$、$\mathrm{MTBF}=1/\lambda$、$A=1/(1+\lambda\,\mathrm{MTTR})$。

四类失效： λ_{DD}、λ_{DU}、λ_{SD}、λ_{SU}；$\mathrm{SFF}=(\lambda_{SD}+\lambda_{DD})/\sum\lambda$；$DC=\lambda_{DD}/(\lambda_{DD}+\lambda_{DU})$。

结构：

- 1oo1：$\lambda_{DU}T/2+\lambda_{DD}\mathrm{MTTR}$；
- 1oo2：$(1-\beta)^2\lambda_{DU}^2T^2/3+\beta\lambda_{DU}T/2$；
- 2oo3：$(1-\beta)^2\lambda_{DU}^2T^2+\beta\lambda_{DU}T/2$；
- kooN：$\binom{n}{m}\lambda_{DU}^m T^m/(m+1)$，$m=n-k+1$，再加共因项；
- 1oo1D：$DC\cdot\lambda_{DU}\mathrm{MTTR}+(1-DC)\lambda_{DU}T/2$。

三块地板： 共因 $\beta\lambda_{DU}T/2$；测试覆盖率 $(1-t_c)\lambda_{DU}T_{\text{life}}/2$；旁路 $\approx$ 旁路时间占比。

串联与系统： $\mathrm{PFD}_{\text{sys}}\approx\sum_i\mathrm{PFD}_i$；剩余风险 $=\nu\prod_i\mathrm{PFD}_i$。

故障树： $P_{\text{top}}\approx\sum_j P(C_j)$（偏大）；精确值用容斥或不交化。

误跳闸： 1oo1 为 λ_S、1oo2 为 $2\lambda_S$、2oo3 为 $6\lambda_S^2\mathrm{MTTR}$。

三条判断，比公式更常用：

> 其一，串联系统的水平由最弱环节决定，不由最强环节决定。其二，共因主导时，加通道的收益趋近于零，降 β 才有意义。其三，公式给出的是上限；旁路、测试覆盖率与人的失误决定了实际值。

第37章 典型环节与时域性能指标

37.1 动机与直观理解

控制系统做得好不好，最终不是由传递函数的形式决定的，而是由它在时间轴上的表现决定的：给定一个阶跃指令，输出多久跟上、冲过头多少、来回摆几次、最后停在哪儿。把这四件事量化，就是本章要讲的**时域性能指标**。它们既是设计目标，也是验收依据，还是不同控制方法之间横向比较的共同尺度。

37.1.1 一个现场场景

某台伺服轴需要把工件从 0 推到 100 mm。工艺给出的要求是：0.30 s 内到位，超调不超过 5%，到位后不允许持续抖动。工程师先按经验把位置环增益调大，轴确实动得快了，但停在 104 mm 附近才慢慢退回，夹具被撞了一下；把增益调小，冲击没有了，节拍却从 1.2 s 掉到 1.8 s，产线不干。

这类“快了就冲、稳了就慢”的取舍，用两个数就能描述清楚：**上升时间**刻画快慢，**超调量**刻画平稳程度。剩下的工作，是把这两个数与控制器参数之间的定量关系找出来，而不是靠反复试。

37.1.2 指标是合同语言

控制系统交付时，甲方不会检查伯德图，只会看阶跃响应曲线。因此工程合同、验收大纲、行业标准里出现的都是时域指标。表 37-1 给出本书统一使用的五个指标及其工程含义。

指标	符号	定义	典型验收值	现场测点
超调量	M_p	峰值超出稳态值的百分比	≤ 5%–20%	输出峰值
上升时间	t_r	10%→90% 稳态值所需时间	按节拍定	输出 10%/90% 两点
峰值时间	t_p	到达第一个峰值的时间	参考用	输出峰值时刻
调节时间	t_s	进入并保持在 ±2%（或 ±5%）误差带的时间	≤ 工艺节拍的 1/3	误差带边界
稳态误差	e_{ss}	时间趋于无穷时的跟踪偏差	按精度等级定	稳态平均

需要强调：**指标必须带口径**。同一个响应，“上升时间”按 0→100% 量与按 10%→90% 量能差一倍；“调节时间”按 ±5% 带与 ±2% 带能差 40%。本书统一采用 10%→90% 上升时间与 ±2% 调节时间，除非某章明确改写。凡引用他人数据，先核对口径，这是工程对比中最常见的坑。

37.1.3 为什么先讲典型环节

真实对象的传递函数动辄五阶、七阶，还带延迟和非线性。但它们的阶跃响应在多数情况下由少数几个“积木”决定：积分环节决定稳态能否无差，一阶惯性决定最初的平滑上升，二阶振荡环节决定超调与振荡衰减，纯延迟决定“反应迟钝”和相位损失。把这几块积木的时域行为记住，看到一个陌生对象时就能大致判断它会怎么动、该先调什么。

图 37-1 给出本章讨论的闭环结构。所有指标都是在闭环传递函数 $T(s) = Y(s)/R(s)$ 上定义的，不是在开环 $G(s)$ 上。这一点常被混淆：开环增益大不等于闭环超调小，开环带宽宽也不等于闭环上升快。

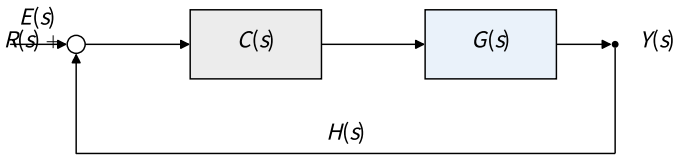

图 37-1　闭环反馈结构与信号定义

图 37-2 把四类典型环节的阶跃响应画在一起。比例环节瞬间到位但有差；积分环节匀速爬升、无差但慢；一阶惯性平滑趋近、无超调；二阶振荡快速但有超调与振荡。后面所有章节的分析，都是在这四条曲线之间做加减法。

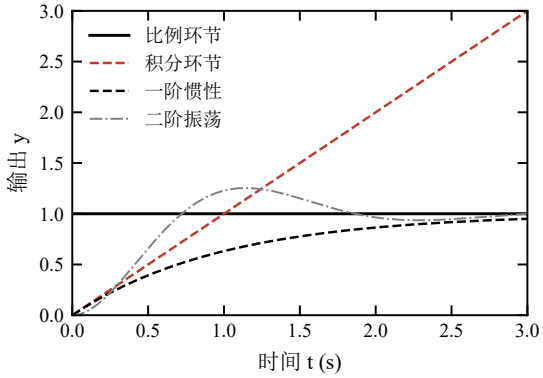

图 37-2　四类典型环节的阶跃响应对比

37.1.4 本章路线与一句话核心

本章按“解析式—连续设计—离散实现—稳定性—参数—调参—改进—落地”推进：§37.2 给出一阶、二阶与延迟的解析解；§37.3 把它固化成六步设计流程；§37.4、§37.5 分别在连续域和离散域把指标算准；§37.6 讨论指标与稳定性的关系；§37.7、§37.8 讲参数怎么影响指标、现场怎么调；§37.9 给出几种不改结构的改进手段；§37.10 落到现场测试与验收；§37.11 说明这套指标的边界；§37.12 给出可复现代码。

如果只能记住一句话：**指标不是越多越好，选两三个能反映工艺要求的作为设计目标，其余作为约束；先把模型阶次选对，再谈参数。**

不同读者可以走不同路径：只关心验收与合同的，读 §37.1、§37.2.2、§37.10；要上手调参的，读 §37.3、§37.7、§37.8；要做二次开发或写论文的，读 §37.2、§37.4–§37.6、§37.9、§37.11。三条路径都以 §37.12 的脚本为落点——不跑一遍代码，前两条路径上的数都只是别人的数。

37.1.5 三个真实的反例

概念讲完，先看三个反例。它们都不是“公式算错”，而是“口径或前提没对齐”，也是本章后面反复要防的坑。

反例一：同一份合同，两种口径。 某项目要求“上升时间不大于 0.3 s、调节时间不大于 0.5 s”。乙方按 10%→90% 与 ±2% 带测量，交付时给出 $t_r = 0.328$ s、$t_s = 0.471$ s，两项都合格；甲方用 0→100% 与“首次进入 ±2% 带”复测，得到 $t_r = 0.484$ s、$t_s = 0.471$ s，判定上升时间超标 61%。以 $\zeta = 0.5$、$\omega_n = 5$ rad/s 的系统为例，0→100% 的首次到达时刻是 0.484 s，10%→90% 只有 0.328 s，两者相差 47%；调节时间若按“首次进入”算是

0.471 s，按“最后越出”算是 1.616 s，差 3.4 倍。**指标不带口径，等于没写**；验收文件里必须把测量方法、误差带、稳态值取法一起写死。

反例二：仿真合格，现场余量被吃掉。 §37.4.7 的位置环在仿真里 $M_p = 2.97\%$、$t_r = 0.180$ s、$t_s = 0.457$ s，控制量峰值 13.4。工程师按此交付，现场驱动器限幅只有 ± 5；重新仿真得 $M_p = 2.70\%$、$t_r = 0.198$ s、$t_s = 0.491$ s。超调反而略降，两项时间指标只退化 7%–10%，看起来“还行”；但若合同写的是 $t_s \le 0.46$ s，这一版已经不合格。更麻烦的是，限幅把加速段削平后，系统对负载变化更敏感，下一次加重负载就可能越过验收线。**看指标必须同时看控制量与限幅余量**，这是 §37.10 要展开的第一条工程纪律。

反例三：忽略 50 ms 延迟。 某回路在实验室测得的超调 35%、调节时间 3.5 s，工程师认为“延迟只有 50 ms，相对上升时间 0.42 s 不到 12%，可以忽略”。装到现场后，超调变成 47%、调节时间 5.3 s，怎么调增益都不对。按 §37.7.6 的折算，50 ms 延迟在 2.86 rad/s 的穿越频率上吃掉 8.2° 相位裕度，原本 34.9° 只剩 26.7°，指标退化正是这个原因。**延迟是否能忽略，不看它相对 t_r 的比例，而看它吃掉的相位与剩余裕度**。

三个反例指向同一件事：时域指标本身很简单，难的是把“在什么条件下、按什么口径、测哪个信号”这三件事固定下来。本章后续所有公式，都建立在这三件事已经固定的前提上。

37.2 数学原理

本节把“曲线长什么样”变成“公式能算出什么”。只推三类对象：一阶、二阶、带纯延迟的一阶/二阶。理由在 §37.1.3 已说明：高阶对象在主导极点近似下，最终都会退化成这三类。

37.2.1 一阶惯性环节

一阶环节的微分方程与传递函数为

$$T\dot{y}(t) + y(t) = K u(t), \qquad G(s) = \frac{K}{Ts + 1} \tag{37-1}$$

其中 K 是直流增益（量纲为输出/输入），T 是时间常数（单位 s）。在单位阶跃 $u(t) = 1(t)$、零初始条件下，解为

$$y(t) = K\left(1 - \mathrm{e}^{-t/T}\right) \tag{37-2}$$

对式 (37-2) 求导可得 $\dot{y}(0) = K/T$，即初始斜率只由 K/T 决定；这也解释了一个常见现象：把时间常数减小一半，起始响应陡一倍，但最终值不变。

三个常用结论可直接由式 (37-2) 解出：

- 当 $t = T$ 时 $y = 0.632K$，这是**时间常数最原始的物理定义**，也是现场用示波器读 T 的依据。
- 10%→90% 上升时间 $t_r = T\ln 9 \approx 2.20T$。
- ±2% 调节时间 $t_s = T\ln 50 \approx 3.91T$；±5% 带则为 $t_s \approx 3.00T$。

这三条之外，现场还有两种读 T 的办法，各有适用场合。其一是**面积法**：把响应与稳态值之间的“缺口”积分，即 $T = \int_0^{\infty} [1 - y(t)/K]\,\mathrm{d}t$。它对噪声不敏感——积分本身就是一个低通滤波器，几百个采样点的随机误差会相互抵消；缺点是必须知道 K，且要把积分截到尾段（截到 $5T$ 时残余面积只有 0.7%）。其二是**切线法**：在 $t = 0$ 处作斜率 K/T 的切线，它与 $y = K$ 的交点横坐标就是 T。切线法只需两点，但斜率对噪声的方差最大，实测中常因一个毛刺把 T 算小一半，只适合在干净信号上做粗估。

还有一句工程口头禅需要澄清：“四个时间常数就稳了”。4 个 T 对应的残差是 $e^{-4}=1.83\%$，恰好压进 ±2% 带，所以这句话对应的是 2% 口径；若验收用 ±5%，3 个 T 就够（残差 4.98%）。两个口径差了整整一个时间常数，在 $T=2$ s 的慢对象上就是 2 s 的差别，足以决定一台设备“合格”还是“不合格”。

表 37-2 给出本书仿真值与解析值的对照（对象取 $K=1$）。三个时间常数下，比例关系严格成立，这也是判断“对象是否真是一阶”的一个快速检验：若实测 t_r/T 明显偏离 2.2，说明模型里还有别的动态。

时间常数 T (s)	t_r 仿真 (s)	$2.20T$	t_s 仿真 (s)	$3.91T$
0.5	1.097	1.100	1.947	1.955
1.0	2.194	2.200	3.895	3.910
2.0	4.388	4.400	7.789	7.820

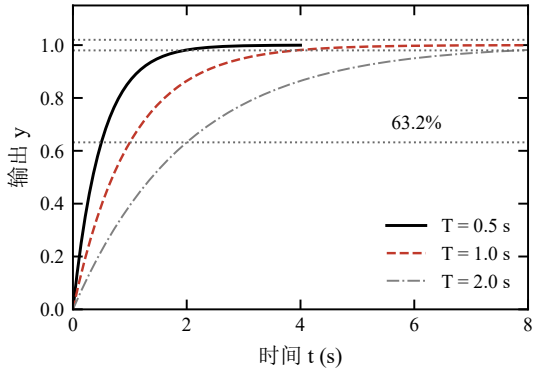

图 37-3　一阶惯性环节在不同时间常数下的阶跃响应

37.2.2 二阶振荡环节

标准二阶环节写成

$$G(s)=\frac{\omega_n^2}{s^2+2\zeta\omega_n s+\omega_n^2} \tag{37-3}$$

其中 ω_n 是无阻尼自然频率（rad/s），ζ 是阻尼比（无量纲）。极点为

$$s_{1,2}=-\zeta\omega_n\pm \mathrm{j}\omega_n\sqrt{1-\zeta^2} \tag{37-4}$$

极点实部决定衰减快慢，虚部决定振荡频率。按 ζ 的取值分三种情形：

- $0<\zeta<1$：欠阻尼，共轭复极点，响应有超调与衰减振荡；
- $\zeta=1$：临界阻尼，重实极点，无超调且最快不振荡；
- $\zeta>1$：过阻尼，两个不等实极点，无超调但更慢。

欠阻尼下的单位阶跃响应为

$$y(t)=1-\mathrm{e}^{-\zeta\omega_n t}\left(\cos\omega_d t+\frac{\zeta}{\sqrt{1-\zeta^2}}\sin\omega_d t\right),\qquad \omega_d=\omega_n\sqrt{1-\zeta^2} \tag{37-5}$$

对式 (37-5) 求导可以看清两个指标的来源。记 $\omega_d=\omega_n\sqrt{1-\zeta^2}$，则

$$\frac{\mathrm{d}y}{\mathrm{d}t} = \frac{\omega_n^2}{\omega_d}\,\mathrm{e}^{-\zeta\omega_n t}\sin\omega_d t$$

导数只在 $\omega_d t = k\pi$ 处为零，第一个极值出现在 $t_p = \pi/\omega_d$。代回式 (37-5)，此时 $\cos\pi = -1$、$\sin\pi = 0$，得

$$y(t_p) = 1 + \mathrm{e}^{-\zeta\pi/\sqrt{1-\zeta^2}}$$

于是 $M_p = \mathrm{e}^{-\zeta\pi/\sqrt{1-\zeta^2}}$。这两步推出两个重要事实：$t_p$ 只由 ω_d 决定，M_p 只由 ζ 决定、与 ω_n 无关。这就是“阻尼比定形状、自然频率定快慢”的数学来源，也是 §37.4 反解参数时能分开算的依据。

由式 (37-5) 对 t 求极值，可得三个关键结论：

$$M_p = \exp\!\left(-\frac{\pi\zeta}{\sqrt{1-\zeta^2}}\right)\times 100\%,\qquad t_p = \frac{\pi}{\omega_d},\qquad t_s \approx \frac{4}{\zeta\omega_n} \tag{37-6}$$

t_s 的 4 来自 $e^{-4}\approx 0.018$，即 ±2% 带；若用 ±5% 带，系数换成 3。上升时间最容易出错，因为教科书上有两个不同口径的公式。常见的那一个是 **0→100%** 上升时间：

$$t_{r,0\to100\%} \approx \frac{\pi - \arccos\zeta}{\omega_d}$$

本书与工业验收用的是 **10%→90%**，两者不是一回事。以 $\zeta = 0.4$、$\omega_n = 3$ rad/s 为例，上式给出 0.721 s，而实测 10%→90% 是 0.488 s，相差 48%。把前者填进验收表，会把自己的系统判慢将近一倍。10%→90% 的常用拟合为

$$t_r \approx \frac{1.76\zeta^3 - 0.417\zeta^2 + 1.039\zeta + 1}{\omega_n} \tag{37-7}$$

式 (37-7) 在 $\zeta \in [0.1, 0.9]$ 内误差小于 2%，本书全部解析估算都用它。

把这组参数完整算一遍，可以看清四个指标各自的来源。$\zeta = 0.4$、$\omega_n = 3$ 时极点为 $-1.2 \pm \mathrm{j}2.75$：实部 1.2 决定衰减，虚部 2.75 决定振荡。四项手算结果为 $M_p = 25.4\%$、$t_p = \pi/2.75 = 1.143$ s、$t_r = 0.487$ s、$t_s = 4/1.2 = 3.33$ s。仿真给出 25.38%、1.142 s、0.488 s、2.80 s——前三项几乎逐位吻合，只有 t_s 短了 16%。原因在 t_s 的定义：$4/(\zeta\omega_n)$ 是按包络算的上界，而“最后一次越出”看的是实际波形；第二个极值（向下的谷）在 2.28 s 处还有 -7%，响应回到带内的时刻是 2.80 s，比包络估计早。这个偏差随 ζ 变化，$\zeta = 0.5$、$\omega_n = 5$ 时两者只差 1%（表 37-3 的 1.617 s 与 1.6 s）。所以 t_s 的公式只能当“上界”，不能当“精确值”。

表 37-3 是 $\omega_n = 5$ rad/s 时本书仿真脚本的输出，解析与仿真的超调列几乎逐位吻合，验证了式 (37-6) 的实现无误。

ζ	M_p 仿真 (%)	M_p 解析 (%)	t_r (s)	t_p (s)	t_s (s)
0.1	72.92	72.92	0.221	0.634	7.683
0.2	52.66	52.66	0.241	0.640	3.921
0.3	37.21	37.23	0.264	0.658	2.247
0.5	16.30	16.30	0.328	0.726	1.617
0.707	4.33	4.33	0.430	0.888	1.194
1.0	0	0	0.672	—	1.168
1.5	0	0	1.172	—	2.131

从表中可以读出两条工程直觉。第一，**超调只由 ζ 决定**，与 ω_n 无关；想让超调从 37% 降到 16%，只需把 ζ 从 0.3 提到 0.5，不必改 ω_n。第二，**快慢由 $\zeta\omega_n$ 共同决定**，ω_n 加倍可让 t_r、t_s 近似减半，但超调不变。

37.2.3 指标口径的四处陷阱

第一处是稳态值怎么取。式 (37-6) 中的 M_p 以稳态值为基准，而仿真中若在响应尚未衰减完时截断，末段均值会偏离真值。本书 `step_metrics` 取最后 1% 数据的均值，并要求仿真时长不少于 $10/(\zeta\omega_n)$；$\zeta = 0.1$ 时若仍用 6 s 窗口，超调会被算成 69.6%，与解析值差 3 个百分点，原因就是残余振荡污染了稳态估计。

第二处是上升时间的定义。0→100% 口径对欠阻尼系统无定义（响应可能永远达不到第一个 100%），因此工业界统一用 10%→90%；但对过阻尼系统，10%→90% 会低估“起步慢”的问题，此时可补充“延迟时间 t_d（0→50%）”。

第三处是调节时间的判据。±2% 与 ±5% 两条带在小阻尼下能差一倍。更严格的做法是同时给出“最后一次越界时刻”与“此后是否单调”，本书的 `settling_time` 采用前者，并在噪声工况下配合平滑后再判。

第四处是基准取谁。M_p 的定义基准是**实际稳态值**，不是参考值。对 0 型对象，两者差一个稳态误差，结果可以差很多。取 $G = 10/(0.2s^2 + 1.2s + 1)$、单位反馈，闭环稳态 0.909、峰值 1.136：以稳态为基准 $M_p = 24.92\%$，以参考值 1.0 为基准只有 13.56%，差了 11.4 个百分点，几乎把超调砍掉一半。不少报表直接算“峰值减 1”，遇到有静差的回路就会系统性低估。校验方法很简单：把 e_{ss} 加回去，看 M_p 与 $(y_{\text{peak}} - y_\infty)/y_\infty$ 是否一致。

37.2.4 主导极点与模型降阶

设闭环极点按实部从大到小排列，若存在一个极点 p_1 满足

$$|\mathrm{Re}(p_1)| \le 0.1\,|\mathrm{Re}(p_i)|, \qquad i = 2, \dots, n \tag{37-8}$$

则其余极点对应的模态在 t_s 时刻已衰减到 $e^{-10} \approx 5 \times 10^{-5}$，可忽略。此时高阶系统可降阶为一阶或二阶，直接用 §37.2.1、§37.2.2 的公式估算指标。

但“可降阶”只说明模态会衰减，没说明**衰减不完的那一小截**对指标有多大影响。式 (37-8) 的 0.1 判据是充分条件，工程上大量对象的分离比落在 0.1 到 0.3 之间，按它降阶到底能信几分，需要实测。取四个常见对象，单位反馈，把真实闭环响应与“按主导极点构造的等效二阶”（同 ζ、同 ω_n，超调与时间指标对增益缩放不敏感，故不必对齐直流增益）逐项对比，结果见表 37-4。四个对象的分离比都在 0.16–0.25，即次主导极点只比主极点快 4–6 倍，**全部不满足**式 (37-8)。

表 37-4　主导极点降阶的误差（单位反馈，等效二阶取同 ζ、ω_n）

对象	分离比	ζ / ω_n	实际 M_p / t_r / t_s	等效二阶 M_p / t_r / t_s	偏差 M_p / t_r / t_s
$\dfrac{1}{(s+1)^3}$	0.250	0.500 / 1.000	13.91% / 1.872 / 8.396	16.30% / 1.638 / 8.081	-2.4 个百分点 / $+14\%$ / $+4\%$
$\dfrac{2}{(s+1)^3}$	0.164	0.321 / 1.152	29.86% / 1.350 / 10.071	34.46% / 1.171 / 9.691	-4.6 个百分点 / $+15\%$ / $+4\%$
$\dfrac{10}{(s+1)(s+2)(s+5)}$	0.214	0.634 / 1.889	7.05% / 1.096 / 3.365	7.59% / 1.027 / 3.175	-0.5 个百分点 / $+7\%$ / $+6\%$
$\dfrac{1}{(s+1)^4}$	0.172	0.383 / 0.765	23.73% / 2.207 / 12.012	27.22% / 1.877 / 13.497	-3.5 个百分点 / $+18\%$ / -11%

三列偏差的方向并不一致，这比“误差 10% 以内”一句话有用得多。

第一，**超调一律被高估**，四个算例高出 0.5 到 4.6 个百分点（相对偏差 7%–15%）。原因不是附加极点“多了一个衰减模态”这么简单：附加极点同时压低了振荡模态在响应里的权重（留数）。等效二阶把全部权重都给了那对复极点，等于让振荡以最大幅度发挥；真实系统里，快速极点分走了一部分“推力”，于是冲得更低。所以降阶算出的 M_p 是**上界**，偏保守——按它签合同，现场不会打脸。

第二，**上升时间一律被低估**，短了 7%–18%。附加极点自身要时间建立，起步阶段比纯二阶慢半拍，这段滞后无法用 ζ、ω_n 表达。于是出现一个危险组合：超调偏保守、上升时间偏乐观。如果验收卡的是“$t_r \le 0.5$ s”，按降阶算合格、实测超标完全可能；卡超调则相反，降阶估算是安全的。写指标时必须知道自己在用哪一侧的偏差。

第三，**调节时间最稳**，偏差落在 -11% 到 $+6\%$。因为 t_s 主要由主极点的实部决定，附加极点衰减得比它快，越到后段越不起作用。但 $1/(s+1)^4$ 这一行是反例：两对复极点的分离比只有 0.172，实际 t_s 比预测短 11%。第二对极点虽然衰减快，其振荡相位与主模态叠加，反而更早把响应按进 $\pm 2\%$ 带。可见 t_s 的偏差没有固定符号，只能当量级。

据此给出三条使用规则，本章后续所有“解析值 vs 仿真值”的对照都按这三条标注口径：

- 分离比 ≤ 0.1：式 (37-8) 成立，直接套公式，三个指标都可信到 10% 以内；
- 分离比 $0.1 \sim 0.3$：t_s 当量级、M_p 当上界、t_r 加 10%–20% 余量；
- 分离比 > 0.3，或存在靠近虚轴的零点：不降阶，直接仿真。

降阶时还有两个例外必须保留：**右半平面零点**和**纯延迟**。前者造成反向起始（undershoot），后者造成相位滞后，二者都不能被“快极点”掩盖，也不能靠调 ζ 补偿。第 39–41 章会用频域方法处理它们；届时用相位裕度反推阻尼比，本质上仍是同一种二阶近似，本节关于偏差方向的结论可以直接搬过去。本章只做时域近似。

37.2.5 纯延迟的处理

纯延迟环节 $e^{-\tau s}$ 在时域上就是把响应整体右移 τ：

$$y(t) = y_0(t - \tau) \tag{37-9}$$

它不改变超调、不改变稳态值，但等量增加上升时间与调节时间。频域上它贡献相位滞后 $-\omega\tau$（弧度），在 ω 处折算为 $57.3\omega\tau$ 度。这个相位损失不衰减，是延迟最难对付的地方——增益再大也补不回来，只能降增益或加前馈/预估（见第 47 章 Smith 预估）。

为便于时域仿真，常用 Padé 有理近似：

$$\mathrm{e}^{-\tau s} \approx \frac{1 - \tau s/2 + \tau^2 s^2/12}{1 + \tau s/2 + \tau^2 s^2/12} \tag{37-10}$$

式 (37-10) 为二阶 Padé。这里有个常被写错的细节：Padé 近似是**全通**的，分子分母互为镜像，所以 $|H(\mathrm{j}\omega)| \equiv 1$，幅频误差为零，误差全部落在相位上。把“幅频误差小于 0.5 dB”写进文档是错的。真实的相位误差见表 37-5，其中 $\omega\tau$ 是无量纲频率，乘上 τ 才是 rad/s。

表 37-5　Padé 近似的相位误差（相对真延迟，单位：度）

$\omega\tau$	一阶	二阶	三阶
0.5	0.58	0.00	0.00
1.0	4.17	0.07	0.00
2.0	24.59	1.97	0.06
3.0	59.27	10.81	0.86
5.0	150.08	59.62	14.87

选阶的依据就清楚了：若关心的是穿越频率附近的相位，就要求 $\omega_c\tau$ 落在表头对应的区间。$\omega_c\tau \le 1$ 用一阶（误差 4°）、≤ 2 用二阶（2°）、≤ 3 用三阶（0.9°）。超过 3 还硬用低阶近似，误差会比要研究的相位裕度还大——此时不是“近似不准”，而是“结论已经反了”。

还有一条必须记住：Padé 近似会引入右半平面零点，它带来的反向起始是**近似产物**，原系统并没有。所以“近似后闭环稳定”不等于“原系统稳定”，判断临界稳定时必须改用精确延迟。本书 `simlib.simulate_discrete` 的 `delay_steps` 参数走的是 FIFO 队列，没有近似误差，代价是延迟必须是采样周期的整数倍。

这个“整数倍”又带来第二层误差：延迟量化。设真实延迟 $\tau = 0.13$ s、$T_s = 0.02$ s，$\tau/T_s = 6.5$ 拍，实现只能取 6 拍（0.12 s）或 7 拍（0.14 s），误差 ± 0.01 s。这 10 ms 在 $\omega_c = 2.86$ rad/s 的慢回路上只折合 1.6°，可以忽略；但在 $\omega_c = 11.5$ rad/s 的快回路上是 6.6°，相当于把相位裕度从 66° 打到 59°。**同一条延迟，在快回路里必须当成一个需要测量的参数，在慢回路里可以当成常数**。若延迟确实不是采样周期的整数倍，工程上可用线性插值或一阶全通滤波实现“小数拍”，代价是引入额外的高频衰减。

37.2.6 稳态误差与型别

时域指标里唯一与“最终停在哪”有关的是稳态误差。对单位反馈系统，

$$e_{ss} = \lim_{s \to 0} s \cdot \frac{1}{1 + G(s)} \cdot \frac{1}{s} = \frac{1}{1 + G(0)} \tag{37-11}$$

由此得到熟知的结论：0 型系统（$G(0)$ 有限）跟踪阶跃有差，误差为 $1/(1 + K_p)$；I 型系统（含一个积分）跟踪阶跃无差，跟踪斜坡有差；II 型系统跟踪斜坡无差。完整的误差系数表与计算见第 42 章，本章只需记住：**超调与快速性由动态决定，稳态误差由型别与开环增益决定，两者要分开设计。**

把这句话展开，就是三个位置误差系数：

$$K_p = \lim_{s \to 0} G(s), \qquad K_v = \lim_{s \to 0} sG(s), \qquad K_a = \lim_{s \to 0} s^2 G(s)$$

三者分别对应阶跃、斜坡、抛物线输入。型别每升高一阶，就多一个积分环节，也多消耗 90° 相位——这正是“无差”要付的代价，§37.6 会看到它对稳定裕度的影响。三种型别与三类输入的组合如下表。

系统型别	阶跃 $1(t)$	斜坡 t	抛物线 $t^2/2$
0 型	$1/(1+K_p)$	∞	∞
I 型	0	$1/K_v$	∞
II 型	0	0	$1/K_a$

表中“∞”不是数学上的无穷大，而是“误差随时间线性或二次增长，永远进不了允许带”。工程上遇到这种组合，唯一的出路是升型（加积分）或改用前馈，靠调增益是调不出来的。

算例一（0 型，阶跃有差）。 $G(s)=10/(s+1)$，单位反馈，$K_p=10$，$e_{ss}=1/11=9.09\%$。若要求 $e_{ss}\le 2\%$，需 $K_p\ge 49$，即把增益提高到近 5 倍。但增益一提高，闭环极点从 -11 移到 -50，响应变快、抗噪变差；若对象本身还有延迟，5 倍增益很可能直接把系统推到稳定边界外。这就是“消差”与“稳”的第一处冲突。

算例二（I 型，斜坡有差）。 本章统一算例 $G_0(s)=10/[s(s+2)]$，$K_v=\lim sG_0=5$，跟踪单位斜坡的稳态误差为 0.2。比例系数取 0.5、1、2 时，理论误差分别为 0.4、0.2、0.1；用 30 s 仿真量得的末值误差为 0.4000、0.2000、0.1000，与理论完全一致。注意这里的误差不随时间是“衰减到零”，而是一个常数偏置——斜坡一直在跑，系统只能以固定落后的方式跟上。这一点常被误解为“还没调好”，其实是 I 型系统跟踪斜坡的固有形态。

算例三（II 型，抛物线有差）。 $G(s)=10(s+1)/[s^2(s+2)]$，$K_a=\lim s^2G=5$，跟踪 $t^2/2$ 的误差为 0.2。II 型系统对阶跃和斜坡都无差，代价是两个积分带来的 180° 相位，闭环阻尼很难做高：同样的比例增益下，II 型系统的超调普遍比 I 型大，调参空间更窄。

还有一类误差不体现在型别表里：**输入端扰动**。设扰动 d 阶跃加在对象输入端，参考保持不变，则稳态输出为

$$y(\infty)=\frac{G(0)}{1+C(0)G(0)}\,d+\frac{C(0)G(0)}{1+C(0)G(0)}\,r$$

由闭环关系 $y=G(d+u)$、$u=C(r-y)$ 即可解出。若 $G(0)\to\infty$（对象含积分），第一项的极限为 $d/C(0)$、第二项为 r，于是 $y(\infty)=r+d/C(0)$，稳态偏差为 $-d/C(0)$。取 $d=0.1$、$C=1$ 时偏差 -0.1，$C=2$ 时 -0.05；只有控制器本身含积分（$C(0)\to\infty$）才能把输入扰动压到零。这条结论比型别表更实用：**参考跟踪的型别看 G，扰动抑制的型别看 C。** 很多现场“给定跟得很准、一加负载就掉下来”的现象，根源就是控制器只有比例项。

最后强调两个口径问题。其一，式 (37-11) 只在闭环稳定时成立；不稳定系统的“稳态误差”没有意义，仿真里看到的末值只是发散曲线被窗口截断的结果。其二，稳态误差是 $r-y$ 的极限，符号由定义决定，写验收文件时必须注明“以给定减输出为正”，否则同一组数据会被两方读出相反的结论。

设计顺序由此确定：先按“要不要无差”定型别（结构问题），再按“允许多大误差”定增益（数值问题），最后才校核超调与调节时间（动态问题）。反过来先调动态、再补误差，往往要把已经调好的参数全部推翻。

37.3 设计步骤

本节把 §37.2 的公式整理成一条可重复执行的流程。流程的价值不在于步骤本身，而在于每一步都有明确的输入、判据与退出条件，避免“调一调、看一看”的黑箱试错。

37.3.1 六步流程

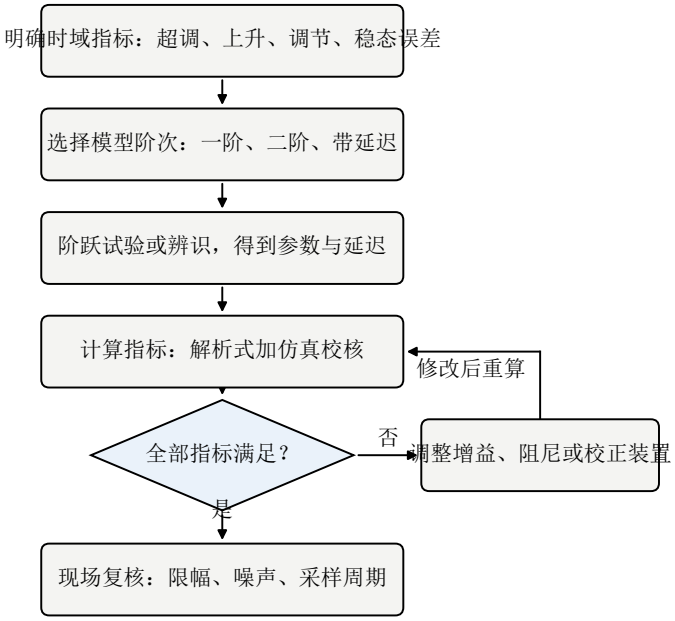

图 37-4　时域指标设计与校核流程

六步依次是：

1. **指标口径化**：把工艺语言翻译成带数值、带口径的指标；
2. **模型定阶**：判断对象该用一阶、二阶还是带延迟模型描述；
3. **试验取参**：通过阶跃试验或辨识得到 K、T、ζ、ω_n、τ；
4. **解析估算加仿真校核**：先用公式算，再用仿真验证，两者不一致时查模型；
5. **判定与调整**：不满足则按 §37.8 的方向调参或改结构，回到第 4 步；
6. **现场复核**：加入限幅、噪声、采样周期后重测，确认指标不退化。

流程中唯一允许“跳过”的是第 3 步——已有可靠模型时可直接用；其余五步不能省。现场最常见的失败是跳过第 1 步和第 6 步：指标口径没定，验收时各说各话；实验室调好了不上现场复核，一加限幅就变样。

37.3.2 第一步：把工艺要求变成数值

工艺给的是“到位快、不许撞、不能抖”，需要翻译成三个数。翻译规则如下：

- **快**：由节拍反推。若整机节拍 1.2 s，定位动作占 1/4，则调节时间上限约 0.3 s；再留 30% 余量，设计目标取 $t_s \le 0.22$ s。

- **不撞**：分两部分定——由目标点到行程端点的余量定超调上限，由机械间隙与允许冲击定冲击速度。夹具类负载通常 $M_p \le 5\%$，输送类可放宽到 20%。
- **不抖**：由传感器分辨率与工艺公差定两个数——静态偏置上限（e_{ss}，通常取分辨率的 1–2 倍）与残余振荡的峰峰值。

三个数之间可能冲突。此时按“安全 > 精度 > 节拍”排序：先保证不撞、不抖，再压缩时间。反过来做，往往要在结构上返工。

翻译环节有三个高频误译，都会把后面的设计带偏。

误译一：把“到位快”译成上升时间。 节拍由“指令发出到可以动作下一步”决定，对应的是调节时间，不是上升时间。本章设计 $t_r = 0.181$ s、$t_s = 0.468$ s，若按 t_r 报价“0.2 s 到位”，现场实测会慢 2.6 倍。上升时间只是形状的辅助量，验收永远看 t_s。

误译二：把“不许撞”译成超调。 超调是相对目标点的过冲，撞不撞取决于目标点到行程端点的余量。$M_p = 5\%$ 在 10 mm 行程上是 0.5 mm 过冲；若目标点距端点只有 0.3 mm，这 0.5 mm 照样撞上去。所以“不撞”要译成**软限位余量 + 超调上限**两个数，只写超调是不够的。

误译三：把“不能抖”译成稳态误差。 稳态误差描述的是静态偏置，抖动是持续的往复运动，两者成因不同：前者来自死区与型别（死区 0.1 留下 9.3% 偏置），后者来自摩擦爬行、量化极限环或积分器与延迟的组合。用 e_{ss} 验收抖动，会出现“误差合格、机器还在响”的局面。

三句话可以概括：**快看 t_s、撞看余量、抖看峰峰值。** 把这三项分开写进技术协议，后面的设计与验收才有共同语言。

37.3.3 第二步：模型定阶

定阶不看对象有多复杂，只看阶跃响应长什么样：

响应特征	推荐模型	参数	依据
单调上升、无超调、起始斜率有限	一阶 $K/(Ts+1)$	K, T	响应形状与式 (37-2) 一致
有超调、等幅或衰减振荡	二阶 $\omega_n^2/(s^2+2\zeta\omega_n s+\omega_n^2)$	K, ζ, ω_n	振荡周期给 ω_d，衰减给 ζ
起始一段时间完全不动，之后才响应	一阶/二阶加纯延迟	加 τ	死区时间明显大于时间常数
有反向起始（先往反方向动）	含右半平面零点	加零点	见第 41 章
多段斜率、多个拐点	三阶以上或分段	辨识	见第 17–24 章

一个实用判据：若阶跃响应从 10% 到 90% 的曲线可用一条指数逼近（在半对数坐标上近似直线），用一阶；若明显呈 S 形且伴随振荡，用二阶；若前 5%–10% 的时间里输出几乎为零，必须加延迟，否则后续所有频域设计都会偏乐观。

37.3.4 第三步：阶跃试验与参数辨识

阶跃试验是最便宜的参数来源，但要注意四条：

1. **幅值**：取工作行程的 5%–10%，既能压过噪声与死区，又不至于触发限幅或安全保护。
2. **时长**：至少覆盖 $5T$ 或 $10/(\zeta\omega_n)$；对小阻尼对象要更长，否则稳态值估不准（§37.2.3 的坑）。
3. **采样**：采样频率不低于闭环带宽的 10 倍；工程上常按“上升时间内至少 10 个采样点”校验。
4. **安全**：试验前确认软限位、急停、超程保护有效；带重力负载的轴要先配平，避免阶跃瞬间自由下落。

若不允许做阶跃（如高温、高压、连续生产流程），改用伪随机二进制序列（PRBS）或继电反馈，方法见第 17、23 章。

拿到曲线之后，参数怎么读，取决于定阶结果。

一阶（含延迟）用两点法。 量两个时刻：输出达到稳态值 28.3% 的 t_1 与 63.2% 的 t_2。对 $y = K[1 - \mathrm{e}^{-(t-\tau)/T}]$，$28.3\%$ 对应 $(t-\tau)/T = 1/3$，63.2% 对应 $(t-\tau)/T = 1$，两式相减得

$$T = 1.5\,(t_2 - t_1), \qquad \tau = t_2 - T$$

选这两点不是随意：它们相隔 $2T/3$，既避开了起始的平缓段，也不在峰值附近；而且两点比例固定，只依赖曲线形状，与 K 的真值无关。单点法（直接取 63.2% 时刻）必须先知道稳态值，K 估偏 5% 会让 T 偏 5%–8%，现场往往拿不准稳态值。

用真值 $T = 0.5$ s、$\tau = 0.1$ s、$K = 1$ 的对象验证：仿真量得 $t_1 = 0.266$ s、$t_2 = 0.600$ s，反演得 $T = 0.500$ s、$\tau = 0.100$ s，与真值吻合到小数点后三位。叠加 1% 噪声并做 20 点滑动平均后，三次试验得 $T = 0.499/0.501/0.504$ s、$\tau = 0.100/0.099/0.098$ s，分散度在 1% 以内。这说明两点法在噪声下的稳定性足够工程使用。

二阶先取 ζ 再取 ω_n。 超调直接给 ζ（式 37-6 反解或查表 37-3），峰值时间给 $\omega_d = \pi/t_p$，于是 $\omega_n = \omega_d/\sqrt{1-\zeta^2}$。以 $\zeta = 0.4$、$\omega_n = 5$ rad/s 为例，理论值 $M_p = 25.4\%$、$t_p = 0.686$ s；若从图上读得这两个数，反演得 $\zeta = 0.400$、$\omega_n = 5.00$，误差都在 0.1% 以内。若 t_p 读大 5%（0.720 s），反演 $\omega_n = 4.77$ rad/s，偏低 4.6%——t_p 的读数误差会等比例传到 ω_n，因此峰值附近要加密采样。

切线法要谨慎。 过响应起点作最大斜率切线，与稳态线交于 $t = \tau + T$、与时间轴交于 $t = \tau$。这个方法在教科书上很常见，现场却容易出错：最大斜率由差分求得，噪声一大位置就飘；采样不足时斜率被低估，T 随之偏小，实测常偏小 10%–20%。只在曲线干净、采样率高于带宽 20 倍时使用。

面积法抗噪最好。 对一阶加延迟对象，稳态线与响应之间的面积满足 $A = \int_0^\infty [K - y(t)]\,\mathrm{d}t = K(T + \tau)$，与 $t_2 = \tau + T$ 联立即可分开解出 T 与 τ。积分本身平滑噪声，但要求记录窗口不短于 $5T + \tau$，且 K 必须准。它适合温度、液位这类慢过程，不适合快速伺服。

三条禁忌。 其一，不要用闭环数据辨识开环模型——反馈会把对象动态“压平”，辨识出的参数反映的是闭环带宽，直接代入式 (37-6) 会系统性低估超调。其二，不要在饱和区做试验——限幅使等效增益下降，K 偏小、T 偏大，据此整定的控制器在现场必然过冲。其三，不要只截取上升段——稳态值决定 K 与型别，缺了末段既算不出 M_p，也判断不了对象含不含积分。

最后，辨识结果要连同试验条件（幅值、负载、温度、采样周期）一起归档。否则三个月后没人能解释“同一台设备两次辨识结果差 20%”。

37.3.5 第四步：先算后仿

拿到参数后，按以下顺序估算：

1. 用式 (37-6) 算 M_p、t_p、t_s；

2. 用式 (37-7) 算 t_r；

3. 用式 (37-11) 算 e_{ss}，检查型别是否满足；

4. 用式 (37-9) 把延迟折算成附加时间，叠加到 t_r、t_s 上；

5. 跑一次仿真，把五条曲线（解析、仿真、带限幅、带噪声、带采样）画在同一张图上。

五条线重合，说明模型与实现都干净；只有解析与仿真重合、另三条分叉，说明问题出在工程细节而非模型；解析与仿真都不重合，回去查定阶与参数。

这套顺序不能省，因为“算”与“仿”的差距常常大到出乎意料。以 §37.3.4 辨识出的 $G(s)=\mathrm{e}^{-0.1s}/(0.5s+1)$ 为例，配 PI 控制器 $K_p=1.0$、$T_i=0.25$ s，按上面的顺序走一遍。

第一步，只算极点。 忽略零点与延迟时，闭环特征式为 $0.125s^2+0.5s+1=0$，即 $s^2+4s+8=0$，得 $\omega_n=2.83$ rad/s、$\zeta=0.707$，按式 (37-6)、式 (37-7) 估得 $M_p=4.3\%$、$t_r=0.759$ s、$t_s=1.95$ s。

第二步，把 PI 的零点算进去。 $C(s)=K_p(T_is+1)/(T_is)$ 的零点在 $-1/T_i=-4$，主导极点为 $-2\pm\mathrm{j}2$，零点与极点实部之比 $\rho=2.0$。按 §37.4.3 的判据，这属于“会抬高超调但不至于反相”的区间。仿真（不含延迟）给出 $M_p=6.70\%$、$t_r=0.562$ s、$t_s=1.866$ s：超调多 2.4 个百分点，上升时间却短了 26%。零点把响应“往前拽”，对 t_r 是好事，对 M_p 是坏事，两个指标的偏差方向相反。

第三步，加上 0.1 s 延迟。 实测 $M_p=14.05\%$、$t_r=0.413$ s、$t_s=1.732$ s。超调再涨 7.4 个百分点，t_r 再短 27%，t_s 反而从 1.87 s 降到 1.73 s——延迟与零点一起把响应“往前推”，代价全部由超调承担。

三步走完，预测值 4.3% 只有实测 14.1% 的三分之一。误差的账很清楚：零点 $+2.4$ 个百分点，延迟 $+7.4$ 个百分点。**极点公式给出的是下界，不是估计值**；拿它签合同，现场必然翻车。这就是第 4 步“先算”只能定初值、第 5 步“后仿”才能定结论的原因。反过来，若仿真的三条曲线（带限幅、带噪声、带采样）都与理想仿真分叉，而理想仿真又与解析吻合，说明模型没错，问题全在实现细节——排查方向立刻清楚。

37.3.6 第五、六步：判定、调整与复核

判定用一张表，逐项打勾，不允许“总体感觉差不多”。示例见表 37-6。

表 37-6　指标判定表

项	目标	仿真值	现场值	判定
超调 M_p	≤ 5%	4.8%	6.1%	不合格
上升 t_r	≤ 0.10 s	0.09 s	0.11 s	不合格
调节 t_s	≤ 0.22 s	0.20 s	0.31 s	不合格
稳态误差	≤ 0.2%	0.0%	0.4%	不合格

四项全不合格而仿真全合格，典型原因是现场存在未建模的延迟与死区，应按 §37.10 的顺序排查，而不是继续在仿真里调参数。

四项同时不合格时，先修哪一项不是随机的，要按“影响面”排序：

- 若稳态误差也超，先查型别与增益。增益是唯一同时影响全部四项的量：0 型系统增益不足，既留静差又偏慢；增益过大，则超调与振荡一起上来。
- 若稳态误差合格而三项动态全超，先查延迟与死区。它们同时抬高 M_p 与 t_s，且不会随运行时间自行好转。
- 若只有 t_r 超标，先查执行器饱和与限幅。加速能力被硬件卡住时，改参数只是把饱和区推得更长。

表 37-6 属于第二类，先测延迟与死区通常能一次解释 3–4 项偏差。反过来，如果上来就调参数，会把仿真里那个合格点也弄丢，最后连对照基线都没有了。

37.3.7 五个常见错误

1. **拿开环响应当闭环指标**：在开环下测出的“上升时间”不能用于验收，指标必须在闭环上测。
2. **用 0→100% 口径算欠阻尼系统**：会得到无穷大或明显偏大的结果。
3. **忽略稳态值的获取方式**：末段均值窗口太短，M_p 虚高。
4. **在限幅状态下测指标**：输出被削顶时，超调与调节时间都不再反映线性动态。
5. **只测一个工作点**：指标随负载、温度、供压变化，至少在小、中、大三个工作点各测一次。

五条里破坏力最大的是第 2 条和第 4 条，因为它们不报错，只会给出一个“看起来正常”的数。

第 2 条的量级可以算：$\zeta = 0.4$、$\omega_n = 3$ rad/s 时，0→100% 口径的上升时间是 0.721 s，10%→90% 口径是 0.488 s，差 48%。两种口径一旦混用，按 0.72 s 验收会把一批合格品判成不合格，反过来则把不合格判成合格——同一批数据，两种结论。

第 4 条更隐蔽：限幅 ± 0.6 时 t_r 从 0.418 s 变成 0.497 s、M_p 从 37.2% 变成 32.8%，两项都“变好看了”，但这是削顶造成的假象，指标会随激励幅值改变，不再是一个常数。**测指标前先确认三件事：输出没有削顶、控制量没有长时间贴限幅、判稳窗口覆盖了完整的振荡周期。** 三条都满足，测出来的数才配写进验收单。

37.3.8 一次可复现的辨识记录

流程的最后一步是“留下记录”，否则三个月后没人能复现这组参数。以 §37.3.4 的一阶对象为例，一份合格的记录应当包含下面这些内容，而不是只写一句“辨识得 $T = 0.5$ s”。

试验条件：对象编号 A-03，负载空载，油温 25 ℃，给定阶跃 1 V（满量程 10 V 的 10%），采样周期 1 ms，记录时长 5 s。

原始数据：稳态值 $y_\infty = 0.998$（取 4–5 s 均值），28.3% 与 63.2% 两个电平分别为 0.282 与 0.631，对应时刻 $t_1 = 0.266$ s、$t_2 = 0.600$ s。

计算过程：$T = 1.5(t_2 - t_1) = 1.5 \times 0.334 = 0.501$ s，$\tau = t_2 - T = 0.600 - 0.501 = 0.099$ s，$K = y_\infty / u_0 = 0.998$。

校验：把 $T = 0.5$ s、$\tau = 0.1$ s、$K = 1$ 代回模型，在 0–5 s 上逐点与实测比较。合格的标准是最大残差不超过噪声水平（本例约 1% 满量程），且残差不呈现趋势；若残差在起始段偏大，说明延迟估小，若在尾段偏大，说明 T 估小。

重复性：同一条件做三次，得 $T = 0.499/0.501/0.504$ s、$\tau = 0.100/0.099/0.098$ s，分散度小于 1%。

结论与用途：模型 $G(s) = 1.00\,\mathrm{e}^{-0.10s}/(0.50s + 1)$，可直接用于 §37.4 的连续设计；若用于离散设计，τ 在 $T_s = 1$ ms 下正好是 100 拍，可直接用整数拍表示。

这份记录只有六项，但它回答了四个问题：在什么条件下测的、原始数是什么、怎么算的、可不可信。现场交接时，这六项比任何一条“经验参数”都值钱。反过来，只记结果不记条件的记录，等于没有记录——换一台设备、换一个温度，那组参数就不成立了。

37.4 连续情形

连续域是设计的起点：先把指标落到 s 平面的参数上，再考虑离散实现。本节用一个统一的例题贯穿：某伺服轴要求 $M_p \le 5\%$、$t_s \le 0.5$ s；对象已辨识为二阶形式，需要定出 ζ 与 ω_n。

37.4.1 从指标反解参数

先由超调定阻尼比。把 $M_p = 5\%$ 代入式 (37-6) 的第一式：

$$0.05 = \exp\left(-\frac{\pi\zeta}{\sqrt{1-\zeta^2}}\right) \;\Longrightarrow\; \zeta = \frac{|\ln 0.05|}{\sqrt{\pi^2 + (\ln 0.05)^2}} \approx 0.690 \tag{37-12}$$

再由调节时间定自然频率。取 $\zeta = 0.69$、$t_s = 0.5$ s，代入 $t_s \approx 4/(\zeta\omega_n)$：

$$\omega_n \ge \frac{4}{\zeta t_s} = \frac{4}{0.69 \times 0.5} \approx 11.6 \ \text{rad/s} \tag{37-13}$$

即闭环自然频率不低于 11.6 rad/s（约 1.85 Hz）。这两个数就是后续所有校正装置的靶子：ζ 决定形状，ω_n 决定尺度。若对象本身的 ω_n 只有 5 rad/s，就必须靠增益或超前校正把带宽抬上去，同时保证 ζ 不掉下来——这正是第 43 章校正装置要解决的问题。

这里有一个容易被忽略的细节：式 (37-13) 用的是 $t_s \approx 4/(\zeta\omega_n)$，而更紧的 2% 带精确式是 $t_s \approx 3.9/(\zeta\omega_n)$，两者差 2.5%。按 11.6 rad/s 设计、实测 0.458 s（§37.4.7），恰好落在两者之间。**指标留余量不是保守，而是给公式与仿真的系统性偏差留位置**；若把 11.6 当成硬下界、一点余量不留，实测的 0.458 s 会紧贴 0.5 s，任何参数漂移都会判不合格。

37.4.2 指标随阻尼比的变化

图 37-5 把 $\zeta = 0.2, 0.4, 0.707, 1.0$ 四条阶跃响应画在一起，横轴统一到 3 s、$\omega_n = 5$ rad/s。可以看到：$\zeta = 0.2$ 时冲得很高、回落很慢；$\zeta = 0.707$ 时几乎没有超调，上升也还算快；$\zeta = 1$ 时完全无超调，但明显变“肉”。工程上常把 $\zeta = 0.707$ 称为**最佳阻尼**，因为它同时兼顾超调（4.3%）与上升时间。

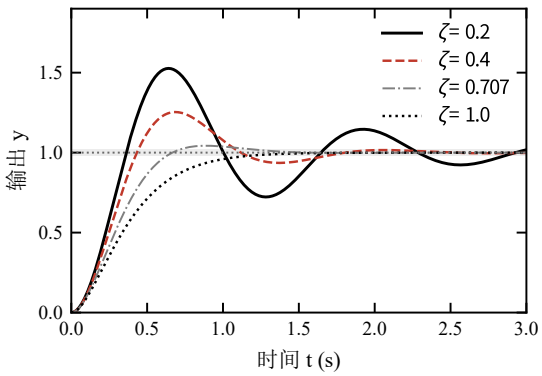

图 37-5　二阶系统不同阻尼比下的阶跃响应

图 37-6 在单条响应上标出 M_p、t_r、t_s 三个量的位置。注意 t_s 是“最后一次越出 ±2% 带”的时刻，不是“第一次进入”的时刻；图中小阻尼情形会出现“进入—越出—再进入”，按第一次进入算会低估 30% 以上。

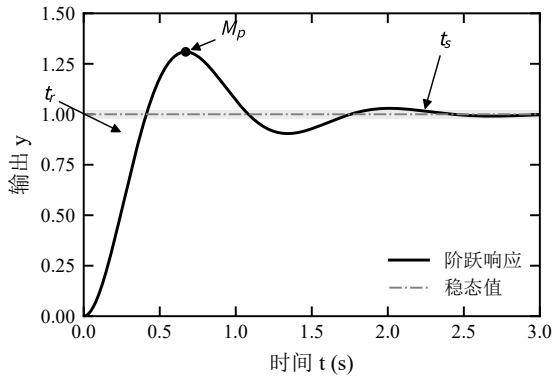

图 37-6　时域指标在阶跃响应上的位置

图 37-7 把同一组参数画到 s 平面上。极点到虚轴的投影长度是 $\zeta\omega_n$，到原点的距离是 ω_n，与负实轴的夹角 θ 满足 $\cos\theta = \zeta$。这三条几何关系是“看图调参”的基础：想让响应快，极点往左移；想减小超调，极点往实轴靠。

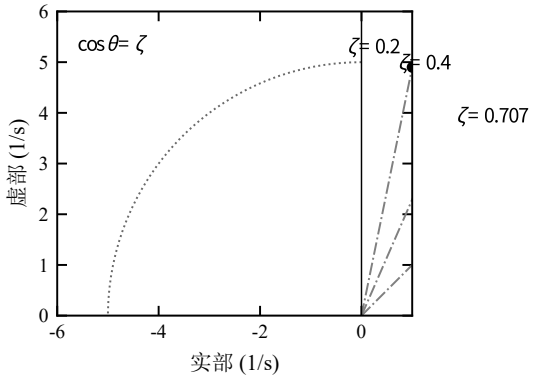

图 37-7　二阶系统极点分布与阻尼比的关系

37.4.3 零点的影响

实际对象常带零点。零点不改变极点位置，但会改变各模态的权重，因此对指标的影响可能很大。以 $\zeta = 0.5$、$\omega_n = 5$ 的基准系统为例，分别串联 $1 + as$（左半零点）与 $1 - as$（右半零点），保持直流增益为 1，仿真结果见表 37-7。

情形	M_p (%)	t_r (s)	t_s (s)	反向峰值
无零点	16.30	0.328	1.616	0
左半零点 $a = 0.3$	47.86	0.130	1.485	0
左半零点 $a = 0.6$	119.22	0.061	1.981	0
右半零点 $a = 0.3$	24.58	0.220	1.858	−50.7%
右半零点 $a = 0.6$	36.94	0.159	1.959	−126.6%

三条结论值得记住：

1. **左半零点加快上升、放大超调**。$a = 0.3$ 时上升时间从 0.328 s 降到 0.130 s，但超调从 16% 涨到 48%。这正是 PD 控制的机理，也是“微分增益不能太大”的原因。
2. **右半零点造成反向起始**。$a = 0.3$ 时输出先往负方向冲到 −50.7%，再回头发散到正向峰值。这类对象（如锅炉水位、某些化工反应器）不能用提高增益的办法加速，必须限制闭环带宽，见第 41 章。

3. **零点越靠近虚轴，影响越强**。a 从 0.3 增到 0.6，相当于零点从 $s=-3.3$ 移到 $s=-1.7$，超调从 48% 涨到 119%，呈非线性放大。

37.4.4 主导极点近似的适用性

给一阶对象串一个 0.02 s 的快极点，即 $T(s)=1/[(s+1)(0.02s+1)]$，仿真得 $t_r=2.197$ s、$t_s=3.934$ s；而不加快极点时为 2.197 s 与 3.913 s。上升时间完全不变，调节时间只差 0.5%。原因很简单：快极点的时间常数是被保留极点的 1/50，满足式 (37-8) 的判据，其模态在 0.1 s 内已衰减到可忽略。

这条结论的工程价值在于：**不要因为对象是五阶就放弃解析估算**。只要快极点满足判据，就可以放心用一阶或二阶公式做初算，再用仿真校核。反过来，若某个极点不满足判据（例如时间常数只差 3 倍），降阶会带来 20% 以上的指标误差，必须保留。

还要提醒一种被“倍率”掩盖的情形：**重极点**。两个同样的时间常数 T 串在一起，即 $1/(Ts+1)^2$，其模态不是 $\mathrm{e}^{-t/T}$ 而是 $t\mathrm{e}^{-t/T}$。包络要衰减到 2%，需要 $t/T\approx 5.8$；单个极点只需 3.9。也就是说，重极点的“有效距离”要按 1.5 倍折算，5 倍远的判据实际要放宽到 7 倍以上。两个完全相同的容腔、两台同型号电机串联，最容易出现这种情况；此时按单极点公式降阶，t_s 会明显偏短。

37.4.5 延迟的时域折算

延迟最容易犯的错，是把“平移”直接套到闭环上。先分清两种情形。

开环，或延迟只作用在记录通道上：$y(t)=y_0(t-\tau)$ 精确成立，于是

$$t_r'=t_r+\tau,\qquad t_s'=t_s+\tau,\qquad M_p'=M_p \tag{37-14}$$

这条式子没有近似，因为它只是把同一条曲线右移。

闭环内（延迟在控制器到对象之间，或测量到控制器之间）就不一样了。特征方程从 $1+C(s)G_0(s)=0$ 变成 $1+C(s)G_0(s)\mathrm{e}^{-\tau s}=0$，延迟进入的是极点方程，极点在动，形状当然也在变。此时式 (37-14) 只是 $\tau\to 0$ 时的一阶近似，不能拿来做验收。

实测最能说明问题。仍取 $G_0=10/[s(s+2)]$、$C=1$（$\omega_c=2.863$ rad/s、$\tau_c=0.213$ s），用 1 ms 步长的精确延迟把 τ 从 0 加到 0.15 s：

τ (s)	$\omega_c\tau$	M_p (%)	ΔM_p (pp)	t_r (s)	t_r 变化	t_s (s)	t_s/t_{s0}
0	0	35.19	—	0.424	—	3.537	1.00
0.005	0.014	36.23	+1.0	0.421	−0.7%	3.551	1.00
0.01	0.029	37.29	+2.1	0.418	−1.4%	3.563	1.01
0.02	0.057	39.50	+4.3	0.412	−2.8%	4.373	1.24
0.03	0.086	41.81	+6.6	0.406	−4.2%	4.460	1.26
0.05	0.143	46.76	+11.6	0.395	−6.8%	5.347	1.51
0.08	0.229	54.96	+19.8	0.382	−9.9%	6.504	1.84
0.10	0.286	60.92	+25.7	0.375	−11.6%	7.616	2.15
0.15	0.429	77.38	+42.2	0.362	−14.6%	16.03	4.53

三个现象都反直觉。

第一，t_r 不是变长，而是略变短。 延迟把相位裕度吃掉，等效阻尼下降，系统在 10%→90% 这一段冲得更急。所以拿 t_r 判断"延迟大不大"会得到相反的结论：t_r 一路变小，其余指标却全面恶化。

第二，M_p 对延迟最敏感。 $\tau = 0.05$ s 只占上升时间的 12%，超调已经从 35.2% 涨到 46.8%，多出 11.6 个百分点。峰值高度由阻尼决定，而阻尼对相位最敏感，所以延迟的第一笔账总是记在超调上。

第三，t_s 是乘性增长，不是加性增长。 τ 从 0 到 0.1 s（不到 τ_c 的一半），t_s 从 3.54 s 涨到 7.62 s，翻了一倍多；式 (37-14) 会预测 3.64 s，方向都错了。原因是延迟把主导极点往虚轴推，$t_s \propto 1/|\mathrm{Re}\, p|$ 是放大关系，不是相加关系。而且这种恶化是台阶式的：$\tau \le 0.03$ s 时只涨 26%，到 0.05 s 就变 1.5 倍，到 0.15 s 已是 4.5 倍。

所以"延迟能否忽略"这句话必须分指标回答，不能一句话概括：

- 对 t_r：$\tau \le 0.05 t_r$ 时误差在 5% 以内（本例 0.021 s）；
- 对 M_p：要求 $\tau \le 0.02 t_r$（本例 0.008 s），否则至少多 2 个百分点；
- 对 t_s：$\tau \le 0.03 t_r$（本例 0.013 s）还算稳，超过 $0.04 t_r$ 立刻跳 20% 以上。

现场更稳妥的做法是：只要延迟超过上升时间的 5%，就把 $\mathrm{e}^{-\tau s}$ 显式放进模型做仿真，不要依赖折算公式。§37.6.7 会用频域给出延迟的稳定上限，那里的结论与这张表是同一条曲线的两端。

37.4.6 附加极点：降阶判据的边界

§37.4.4 的例子说明"远极点可忽略"，但"远"是相对谁而言？把这个问题做成实验：仍取 $G_0(s) = 10/[s(s+2)]$、$C = 1$，闭环主导极点为 $-1 \pm \mathrm{j}3$，实部为 -1。在对象上串一个单位直流增益的极点 $p/(s+p)$，让 p 从 100 一路降到 5，相当于附加极点距虚轴是主导极点的 100 倍到 5 倍。仿真结果如下。

附加极点	M_p (%)	t_r (s)	t_s (s)	相对原系统
无	35.09	0.4246	3.537	—
-100	37.18	0.4185	3.564	M_p 高 2.1 个百分点，t_s 长 0.8%
-50	39.33	0.4137	4.374	M_p 高 4.2 个百分点，t_s 长 23.7%
-20	46.05	0.4063	5.364	M_p 高 11.0 个百分点，t_s 长 51.6%
-10	56.99	0.4097	7.704	M_p 高 21.9 个百分点，t_s 长 117.8%
-5	74.49	0.4360	20.821	M_p 高 39.4 个百分点，t_s 长 488.6%

这张表给出的信息比"5 倍远即可"复杂得多。附加极点 -100 时几乎无影响，-50 时超调涨 4.2 个百分点，-5 时超调翻倍、调节时间涨到近 6 倍——而 -5 按"实部 5 倍"的判据本该勉强合格。原因有两个。

第一，**极点不只是"衰减快慢"，它还改变回路在穿越频率附近的相位**。本章系统的开环穿越频率约 2.86 rad/s，附加极点 -5 在该频率贡献 $-\arctan(2.86/5) \approx -30^\circ$ 相位，把相位裕度从 35° 压到不足 5°，系统自然剧烈振荡。"实部 5 倍"只保证模态衰减快，不保证相位代价小；正确的判据是"附加极点至少在穿越频率的 5–10 倍以外"，即 $p \ge (5 \sim 10)\omega_c$，而不是与主导极点比。

第二，**t_s 是三个指标里最不稳健的一个**。附加极点 -50 时 M_p 只涨 4.2 个百分点、t_r 几乎不变，t_s 却从 3.54 s 跳到 4.37 s。检查仿真窗口与步长可排除数值原因：把窗口从 30 s 拉到 120 s、点数从 2000 加到 40000，t_s 稳定在 4.374 s。真正的原因是轻阻尼系统的包络衰减慢，$\pm 2\%$ 带的最后一次穿越落在"包络刚好压线"的区域，主导

模态的留数稍有变化，穿越时刻就移动小半个周期。所以判断模型能不能降阶，应主要看 M_p 与 t_r；只看 t_s 容易得出“降阶失败”的错误结论。

工程上的做法是双判据：先用极点实部比做粗筛（≥ 5 倍），再用 M_p 的偏差做确认（偏差不超过 2 个百分点）。两条都过才降阶；只过一条时，保留附加极点做一次仿真更稳妥。

37.4.7 一个完整的连续设计算例

把 §37.4.1 的抽象指标落到具体对象上，走一遍完整流程。指标为：$M_p \leq 5\%$、$t_s \leq 0.5$ s、阶跃无稳态误差；对象仍为 $G_0(s) = 10/[s(s+2)]$。

第一步，由指标定闭环参数。 由 $M_p = 5\%$ 反解得 $\zeta = 0.69$；由 $t_s \leq 0.5$ s 得 $\zeta\omega_n \geq 4/0.5 = 8$ rad/s，于是 $\omega_n \geq 8/0.69 = 11.6$ rad/s。取等号，得目标闭环 $s^2 + 16s + 134$。

第二步，由闭环参数反解控制器。 比例加微分（标准形式）的闭环特征式为

$$s^2 + (2 + 10K_pT_d)s + 10K_p = 0$$

与目标式逐项对比：$10K_p = 134$ 给出 $K_p = 13.4$；$2 + 10K_pT_d = 16$ 给出 $T_d = 0.1045$ s，即 $K_d = K_pT_d = 1.40$。注意这里没有自由度可浪费——两个指标恰好定死两个参数。

第三步，选择微分作用的位置。 若按标准 PD 实现，闭环会多一个零点 $z = -1/T_d = -9.57$。它与闭环极点 $-8.48 \pm \mathrm{j}9.25$ 的距离只有 $\rho = 9.57/8 = 1.2$，按 §37.9.2 的结论，这个零点会把超调显著抬高。仿真证实：同一组 K_p、T_d 下标准 PD 的 $M_p = 20.43\%$、$t_r = 0.075$ s、$t_s = 0.399$ s，超调超标 4 倍。改用微分先行（只对输出微分，式 37-27），零点消失，闭环回到二阶本体。

第四步，仿真校核。 微分先行加一阶滤波 $T_f = 0.01$ s 后，实测 $M_p = 2.97\%$、$t_r = 0.180$ s、$t_s = 0.458$ s、稳态值 0.99996、控制量峰值 13.8。三项指标全部满足，且留有余量：超调比上限低 2 个百分点，调节时间比上限快 8%。

第五步，检查指标之外的东西。 控制量峰值 13.8 是给定幅值的近 14 倍。若执行器限幅为 ± 10，这个设计在现场会因饱和而变慢，t_s 立刻退化；此时要么降低指标，要么在给定上加斜坡（§37.10.4）。这一步最容易被仿真阶段忽略：`control` 的线性模型不会饱和，指标永远漂亮。

第六步，看参数敏感性。 固定 $K_p = 13.4$，把 K_d 从 1.4 降到 0.8，超调从 3.0% 涨到 20.4%，t_s 从 0.458 s 涨到 0.702 s；升到 2.0 则超调为 0，但 t_s 反而涨到 0.505 s。这说明 $K_d = 1.4$ 位于“刚好压住超调”的拐点上，往任一方向调都有代价：减小失去阻尼，增大变成过阻尼。现场若发现执行器发热，优先小幅降 K_d 并接受超调上升，而不是直接砍 K_p——后者会把带宽一起拉低。

第七步，与纯比例对照。 同样的对象若只用比例，要满足 $M_p \leq 5\%$ 需 $K_p \approx 0.21$，此时 $t_r = 1.45$ s、$t_s = 4.14$ s，比指标慢 8 倍以上。这组数字说明：**在这个对象上，“快”不是靠加大比例买来的，而是靠微分提供的阻尼买来的**。比例决定“推多大劲”，微分决定“提不提前收劲”；只有推力没有提前量，系统要么慢，要么振。

最后是采样周期的约束。滤波器时间常数 $T_f = 0.01$ s，按“每 5 个采样点覆盖一个时间常数”的经验，$T_s \leq 2$ ms；而 $t_r = 0.18$ s 只要求 $T_s \leq 18$ ms。两条取严，T_s 应取 1–2 ms。若控制器只能做到 10 ms，则 T_f 必须相应放大到 0.05 s；按式 (37-28)，α 从 0.096 涨到 0.478，最大相位超前从 55.6° 掉到 20.7°，K_d 要重新整定——这就是“控制周期决定控制结构”的具体含义。

37.5 离散情形

上一节的公式都建立在“控制器连续、输出连续可测”的假设上。真实系统里，控制器每隔 T_s 计算一次，输出经零阶保持器（ZOH）保持一个采样周期。这两件事都会改变指标：前者让指标只能在采样点上定义，后者引入半个采样周期的等效延迟。

37.5.1 离散闭环与极点映射

连续对象 $G(s)$ 与 ZOH 串联后离散化为 $G(z)$，数字控制器为 $C(z)$，闭环脉冲传递函数为

$$T(z)=\frac{C(z)G(z)}{1+C(z)G(z)} \tag{37-15}$$

连续极点 s_i 与离散极点 z_i 的关系是 $z_i=\mathrm{e}^{s_iT_s}$。把 $s_i=-\zeta\omega_n\pm\mathrm{j}\omega_n\sqrt{1-\zeta^2}$ 代入，得

$$|z_i|=\mathrm{e}^{-\zeta\omega_nT_s},\qquad \angle z_i=\omega_nT_s\sqrt{1-\zeta^2} \tag{37-16}$$

反过来，由一对共轭极点反算等效阻尼比：

$$\zeta=\frac{-\ln|z|}{\sqrt{\ln^2|z|+(\angle z)^2}} \tag{37-17}$$

式 (37-17) 是离散域“看图调参”的核心：$|z|$ 越接近 1，衰减越慢；$\angle z$ 越大，振荡越快。设计时把极点配置到 $|z|=\mathrm{e}^{-4T_s/t_s}$、$\angle z=\pi T_s/t_p$ 附近，就能同时满足调节时间与峰值时间。

举一组具体数验证：本章统一算例的连续闭环极点是 $-1\pm\mathrm{j}3$。取 $T_s=20$ ms，$z=\mathrm{e}^{-0.02}\mathrm{e}^{\pm\mathrm{j}0.06}$，即 $|z|=0.9802$、$\angle z=3.44^\circ$。代回式 (37-17)，$\zeta=0.02/\sqrt{0.02^2+0.06^2}=0.316$，与连续域的 0.316 完全一致——只要 T_s 足够小，e^{sT_s} 映射不丢信息。

采样还会把“快极点”压向原点：$s=-20$ 的模态在 $T_s=20$ ms 时映到 $|z|=0.67$，在 100 ms 时映到 0.135。极点越靠近原点，衰减越快，对闭环的影响越小。这给降阶提供了一个离散判据：若某极点映射后 $|z|<0.1$，它在一个多采样周期内就衰减到 10% 以下，可以放心丢掉。注意它与式 (37-8) 的连续判据只是在 T_s 远小于该模态时间常数时才等价。

37.5.2 ZOH 的相位代价

零阶保持器不是理想的重构器，它的频率特性为

$$G_{\mathrm{ZOH}}(\mathrm{j}\omega)=\frac{1-\mathrm{e}^{-\mathrm{j}\omega T_s}}{\mathrm{j}\omega}\approx T_s\,\mathrm{e}^{-\mathrm{j}\omega T_s/2}\cdot\operatorname{sinc}\!\left(\frac{\omega T_s}{2}\right) \tag{37-18}$$

在低频段，它近似为“增益 T_s 加半个采样周期的纯延迟”。这半个周期的延迟会吃掉相位裕度，折算到闭环就是超调变大、调节时间变长。工程上常用的补偿办法是：设计连续控制器后，把采样周期的一半计入延迟，再校核一次相位裕度；或者直接用 Tustin 变换，它在低频段的相位特性优于 ZOH（见第 6 章）。

把这笔账算成数：本章设计的 $\omega_c=16.0$ rad/s，取 $T_s=12$ ms，半拍 6 ms 带来 $16.0\times0.006=0.096$ rad，即 5.5° 相位损失；若把采样提到 2 ms，同样折算只有 0.9°。这 4.6° 的差别，在相位裕度只有 30° 的回路里相当于 15% 的裕度，不能忽略。所以“ZOH 只是零阶保持、不引入延迟”这句话是错的：它天然带半个采样周期的延迟，这个延迟不随控制器改进而消失，只能靠提高采样率或改用其他重构方式减小。

37.5.3 采样周期怎么选

采样周期的选择有三条互相印证的经验线：

1. **按上升时间**：$T_s \le t_r/10$。少于 10 个点时，上升沿的形状已经看不出来。
2. **按带宽**：$\omega_s \ge 10\omega_c$。ω_c 取开环穿越频率，比闭环带宽更保守，两者在二阶系统上只差 20%–30%。
3. **按相位损失**：$\omega_c T_s \le 0.2$ rad，对应 ZOH 附加相位不超过 5.7°。

三条线取最严的一条。以 §37.4.7 的例题为例，$t_r = 0.180$ s，第 1 条给 $T_s \le 18$ ms；开环穿越频率 $\omega_c = 16.0$ rad/s（仿真测得），第 2 条给 $T_s \le 2\pi/(10 \times 16.0) = 39.3$ ms；第 3 条给 $T_s \le 0.2/16.0 = 12.5$ ms。三条线里最严的是相位损失，取 12 ms。

但这个结论还漏了一个约束：微分滤波。滤波器时间常数 $T_f = 0.01$ s 要求一个时间常数内至少有 5 个采样点，即 $T_s \le 2$ ms，比上面三条线都严十倍。**带宽只约束“能不能看清振荡”，滤波器约束“能不能正确算出微分”**，后者常被忽略，却是实际工程中真正的瓶颈。若控制器只能跑 10 ms，就必须把 T_f 放大到 0.05 s，接受相位超前从 55.6° 掉到 20.7° 的代价（§37.4.7 末段）。

把三条线与滤波器约束放在一起，可以看到一个规律：纯比例系统按 10–20 倍带宽选 T_s 就够；一旦引入微分，采样周期就要按微分滤波器的 1/5 来选，通常比带宽要求严一个数量级。这也是“加了 D 之后系统反而不稳”的常见原因——不是 K_d 给大了，而是采样太慢，微分算出来的是噪声的差分。

37.5.4 采样周期对指标的影响

用一个统一算例验证：对象 $G_0(s) = 10/[s(s+2)]$，控制器取纯比例 $C = 1$，改变采样周期，结果见表 37-8。表中“谱半径”指离散闭环极点模的最大值，小于 1 即稳定。

采样周期 T_s (s)	M_p (%)	t_r (s)	t_s (s)	稳态值	谱半径
连续	35.17	0.424	3.545	0.999	—
0.02	37.36	0.418	3.580	0.999	0.9802
0.10	47.69	0.402	5.600	0.992	0.9048
0.20	65.98	0.406	6.000	0.965	0.8187
0.40	57.37	0.501	未收敛	1.181	0.6703

四个现象需要解释清楚，否则很容易误读：

- **超调随 T_s 增大而上升，但不单调**。$T_s = 0.4$ s 时反而降到 57%，原因是采样点恰好落在振荡的波谷附近，“看到”的超调被采样相位掩盖。这不是性能变好，而是测量失真。
- **上升时间几乎不变**。上升时间主要由前几个采样点决定，只要 T_s 远小于 t_r，采样点位置对 10%→90% 的插值影响不大。
- **调节时间显著变长**。T_s 从 0.02 s 增到 0.1 s，t_s 从 3.58 s 涨到 5.60 s，增加 56%。这是 ZOH 半拍延迟与离散化误差的累积结果。
- **稳态值偏离 1**。$T_s = 0.4$ s 时 6 s 内根本没收敛，表中 1.181 是窗口末值，不能当稳态。凡 t_s 触及仿真窗口末端，该行数据即作废，必须延长仿真时间重测。

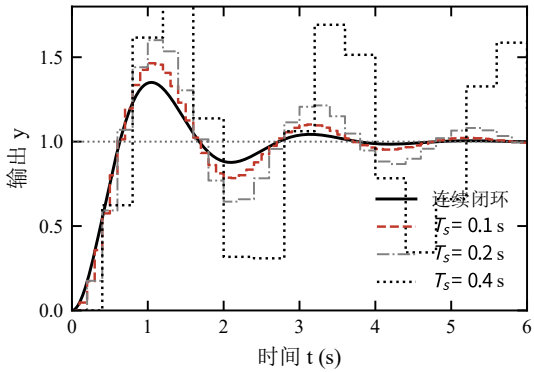

图 37-9　采样周期对闭环阶跃响应的影响

图 37-9 把连续响应与 $T_s = 0.1, 0.2, 0.4$ s 的离散响应画在一起。阶梯状折线是零阶保持的直观表现；$T_s = 0.4$ s 时折线的“台阶”已经宽到足以掩盖振荡细节，此时讨论超调百分比意义不大，应改用“包络峰值”或直接看连续重建信号。

37.5.5 离散指标的验收口径

离散系统的指标验收要明确三件事：

1. **在采样点上算还是在重建信号上算**。控制系统内部的采样点值可能恰好避开峰值，导致超调被低估。规范做法是用记录仪以远高于 T_s 的频率采集实际输出，在连续信号上算指标。不过这个误差的量级常被高估：最坏情况下峰值落在两个采样点正中，测得值为真值的 $\cos(\omega_d T_s/2)$。本节例题 $\omega_d = 9.25$ rad/s，$T_s = 20$ ms 时损失 0.43%，若 $M_p = 3\%$，折算误差只有 0.013 个百分点；$T_s = 40$ ms 时损失 1.7%，折算 0.05 个百分点。**峰值漏检不是验收分歧的主要来源**，真正造成“仿真合格、现场不合格”的是下面两条。
2. **调节时间的判别带宽**。离散系统的输出是阶梯，±2% 带的判据要加“连续两个采样点均在带内”的条件，否则会把单点抖动误判为稳定。
3. **一拍计算延迟是否计入**。控制器从采样到输出通常有 1 拍延迟，仿真时必须把 `delay_steps=1` 打开。这一拍在 20 ms 周期下是 0.02 s，在 §37.4.7 的 $\omega_c = 16.0$ rad/s 处折合 18.3°：标准 PD 实现的相位裕度从 57° 掉到 39°，仿真超调从 20.5% 涨到 37.2%。对 $T_s = 10$ ms、$\omega_c = 50$ rad/s 的快回路，同样一拍就是 28.6°，足以让相位裕度腰斩。**采样周期越长、回路越快，这一拍的破坏力越大**，而它不体现在任何解析公式里，只体现在仿真的 `delay_steps` 参数里。

37.5.6 四种离散化方法怎么选

同一个连续对象，用不同的离散化方法会得到不同的 $G(z)$，指标也随之不同。以 $G_0(s) = 10/[s(s+2)]$、$C = 1$、$T_s = 0.1$ s 为例，四种常用方法的结果如下。

方法	M_p (%)	t_r (s)	t_s (s)	谱半径	与连续值的偏差
连续（基准）	35.17	0.424	3.545	—	—
ZOH	46.44	0.405	5.400	0.9287	M_p 高 11.3 个百分点
Tustin	35.25	0.437	3.600	0.9068	M_p 仅差 0.08 个百分点
前向欧拉	60.37	0.350	7.200	0.9487	M_p 高 25.2 个百分点
后向欧拉	21.43	0.513	2.700	0.8771	M_p 低 13.7 个百分点

只看“谁最像连续系统”，Tustin 是赢家；但这个结论不能直接搬到工程上，因为**离散化的对象不同，正确方法也不同**。

- **对象离散化用 ZOH。** 真实系统里，控制器输出经保持器后在一个采样周期内保持不变，ZOH 正是这个物理过程的精确描述。ZOH 引入的半个采样周期延迟不是误差，而是真实存在的相位损失。上表 ZOH 的超调比连续值高 11 个百分点，恰恰说明“$T_s = 0.1$ s 太大”，而不是“ZOH 不好”。
- **控制器离散化用 Tustin（或预修正 Tustin）。** 控制器是算法，不受保持器约束，目标是让 $C(z)$ 的频率特性贴近 $C(s)$。Tustin 把 s 左半平面一一映射到单位圆内，稳定性与相位裕度都能保住；预修正 Tustin 再把某个关键频率（通常取穿越频率）的相位对齐，避免高频段的频率压缩。
- **前向欧拉只在 T_s 极小时可用。** 它把 s 左半平面映射成一个可能越出单位圆的区域，稳定对象离散后可能不稳定。实测 T_s 从 0.02 s 增到 0.2 s，超调从 39.0% 涨到 79.8%，$T_s = 0.2$ s 时谱半径正好等于 1，系统已到临界——这还只是一个二阶对象。
- **后向欧拉永远稳定，但会“过度阻尼”。** 它把整个左半平面压进单位圆，代价是频率轴严重畸变，$T_s = 0.1$ s 时超调被压到 21.4%、t_s 反而缩短到 2.70 s。数字好看，但这是“人为加了阻尼”的假象，不能用来评估真实性能。

一条实用规则：**对象用 ZOH，控制器用 Tustin，两者不要混用同一种方法**。很多仿真“复现不了现场”的案例，根源就是图省事，把对象也用 Tustin 离散，结果延迟效应被悄悄抹掉，仿真比现场乐观一大截。

37.5.7 非理想因素的实测账

实验室里的阶跃响应只有对象与控制器的相互作用；现场还有饱和、死区、量化、噪声和计算延迟。它们在指标上各留一笔账。仍用统一算例，$T_s = 0.02$ s，逐项注入，结果如下。

工况	M_p (%)	t_r (s)	t_s (s)	稳态值
理想	37.19	0.418	3.560	1.0000
饱和 ± 0.6	32.80	0.497	3.660	1.0002
死区 0.05	34.18	0.445	3.580	1.0141
量化 0.02	36.72	0.420	4.320	1.0040
噪声 0.01	37.55	0.423	6.080	1.0017
延迟 5 拍（0.1 s）	64.00	0.372	7.740	0.9992

逐项解读：

饱和降低超调、放慢上升。 控制量被限在 ± 0.6 后，前段相当于“增益变小”，系统用满额输出加速，等误差落到线性区才恢复比例关系。结果是 t_r 从 0.418 s 拉到 0.497 s，超调反而从 37.2% 降到 32.8%。这不是好事：饱和把能量“削平”了，若限幅更深，系统会进入“加速—饱和—刹车不及”的循环，超调会在某个临界幅值突然反弹。

死区留下稳态偏置。 控制器输出在 ± 0.05 内不动，系统停在误差 0.0141 处（约 1.4%）。死区宽度增到 0.1 时偏置升到 9.3%，且方向取决于最后一次动作的方向，可正可负。这类偏置无法靠调增益消除，只能减小死区、加积分（积分会把误差推到死区边缘来回跳）或改用抖动（dither）。

量化把调节时间拉长两成。 步长 0.02 时 t_s 从 3.56 s 涨到 4.32 s。原因是控制量只能取离散档位，系统在目标附近形成小幅极限环，$\pm 2\%$ 带的最后一次越界被这个环推后。步长增到 0.05，t_s 仍是 4.34 s——极限环的幅值由对象与步长共同决定，不是简单的线性关系。

噪声让调节时间失去意义。 输出叠加标准差 0.01 的噪声后，t_s 从 3.56 s 变成 6.08 s，看似“慢了 71%”。换随机种子重跑五次，t_s 分别是 6.08、7.64、7.40、7.30、7.80 s，均值 7.24 s、极差 1.72 s（约 24%）。同一套参数、同一套代码，只因噪声样本不同，t_s 就能差出 1.7 s。这说明**带噪声时不能用单次 t_s 做验收**，正确做法是多次运行取中位数或 95% 分位，并在判稳前先做低通或滑动平均。

计算延迟与连续延迟对得上。 5 拍延迟（0.1 s）给出 64.00%/0.372/7.740；§37.6 中连续延迟 0.1 s 的结果是 60.75%/0.376/7.62（Padé 近似）。两条路径相差不到 3 个百分点、0.12 s，说明“一拍延迟 = T_s 的纯延迟”这个折算在低频段是可靠的。反过来，若把延迟拍数漏掉，仿真会明显偏乐观——这也是现场“样机一上电就振”的常见原因。

把这六行放在一起看，会发现一个规律：**非理想因素几乎都让指标变差，唯独饱和让超调变好**。因此不能只挑“看起来合格”的那一行写进报告；验收必须在最坏组合下做——最大延迟、最大死区、最小饱和限幅、最差噪声，全部叠加后再看指标是否仍然达标。这就是 §37.10 要展开的现场复核。

37.6 稳定性与性能

时域指标有一个隐含前提：系统必须稳定。极点落在右半平面时，响应发散，超调与调节时间都没有意义。本节讨论稳定性边界怎么限制指标，以及“更快”与“更稳”之间的定量冲突。

37.6.1 稳定边界决定指标上限

对连续系统，闭环极点实部全为负是稳定的充要条件；对离散系统，极点模全小于 1。稳定边界附近会发生两件事：调节时间趋于无穷，超调趋于无穷。因此设计时不能把指标压到边界上，必须留稳定裕度。

以一个三阶对象 $G(s) = K/[(s+1)(s+2)(s+5)]$ 为例，闭环特征多项式为

$$s^3 + 8s^2 + 17s + (10 + K) = 0 \tag{37-19}$$

按劳斯判据，稳定的充要条件是

$$8 \times 17 - (10 + K) > 0 \implies K < 126 \tag{37-20}$$

$K = 126$ 时系统处于临界稳定，阶跃响应等幅振荡，调节时间为无穷。若按“尽量快”的思路把 K 取到 120，虽然理论上稳定，但极点实部仅约 -0.02，参数稍有漂移就发散。工程上通常把工作点取在临界增益的 1/3–1/2，即 $K = 40$–60，用牺牲一部分快速性换取鲁棒性。劳斯判据的完整用法见第 38 章，频域裕度见第 39–41 章。

37.6.2 延迟压缩稳定域

延迟不改变稳态增益，却持续消耗相位，因此它压缩稳定域。仍以 $G(s) = 2/[(s+1)^3]$ 为单位反馈对象，串入纯延迟 τ（三阶 Padé 近似），仿真结果见表 37-9。

延迟 τ (s)	最大极点实部	稳定性	峰值	终值	超调 (%)
0.0	−0.3700	稳定	0.866	0.667	29.9
0.5	−0.1741	稳定	1.032	0.666	54.9
1.0	−0.0621	稳定	1.203	0.716	68.1
1.5	−0.0032	稳定（临界）	1.357	0.790	71.8
2.0	+0.0281	不稳定	2.440	—	—

表中三行信息值得注意：

1. **延迟 0.5 s 就让最大极点实部从 −0.37 退到 −0.17**，稳定度下降一半，超调从 30% 涨到 55%。
2. **$\tau = 1.5$ s 时实部仅 −0.003**，响应在 20 s 内看不出收敛，工程上应判为“不可用”，而不是“理论稳定”。
3. **$\tau = 2.0$ s 时实部转正**，响应发散。此时无论怎么调增益都救不回来，只能改结构（Smith 预估、内模控制）或改工艺（缩短管路、提高采样率）。

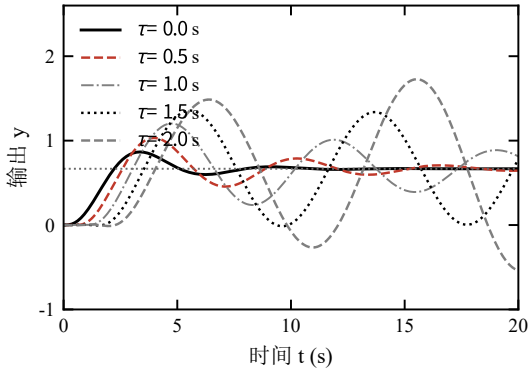

图 37-10　纯延迟对闭环阶跃响应的影响

图 37-10 把五条响应画在一起。$\tau \geq 1.5$ s 的两条曲线在 10 s 后仍在缓慢爬升或发散，与“稳定”的直觉不符——这正是“临界稳定”的典型外观：短期看像收敛，长期看是慢发散。

37.6.3 快与稳的定量冲突

在二阶系统里，ζ 同时影响超调与调节时间：ζ 从 0.3 增到 0.7，超调从 37% 降到 4.3%，但上升时间从 0.264 s 增到 0.430 s（表 37-3）。这不是调参技巧能消除的矛盾，而是二阶系统的内在约束。

把这条约束画成图 37-8，可以直观看到“超调—调节时间”的权衡曲线：曲线左端（小 ζ）超调大但归一化调节时间长，右端（大 ζ）超调小但上升慢，中间在 $\zeta \approx 0.7$ 附近有一个“兼顾点”。任何声称“既无超调又最快”的设计，要么改变了系统结构（加零点、加前馈），要么只在特定指标口径下成立。

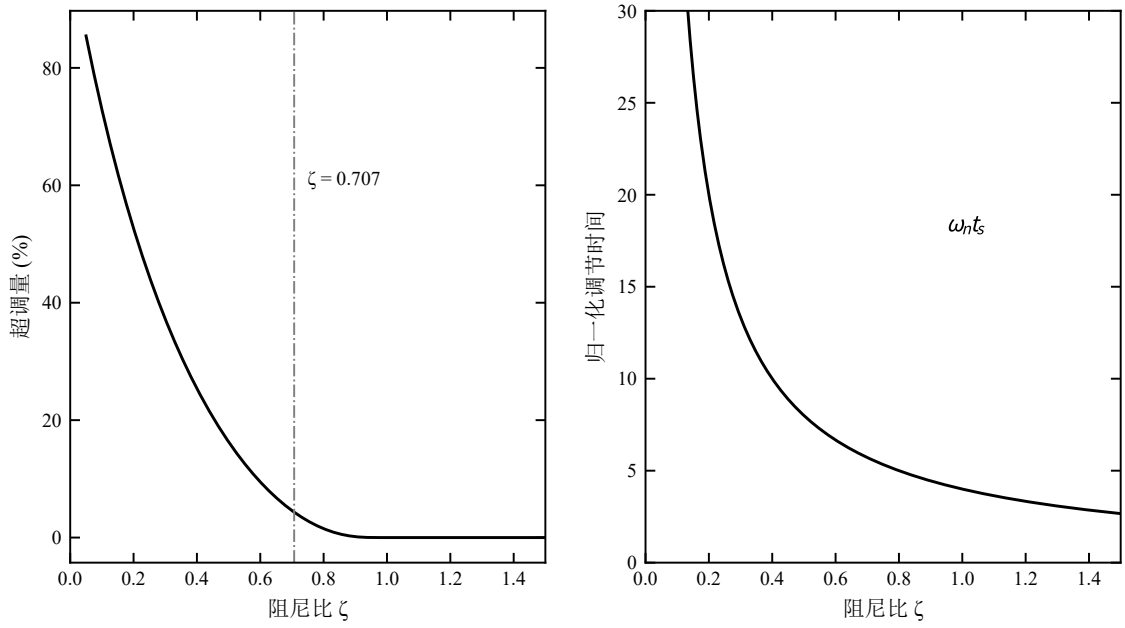

图 37-8　阻尼比与超调量、归一化调节时间的关系

这条约束在“逼近稳定边界”时表现得最刺眼。取 $G(s)=K/(s+1)^3$，它的临界增益 $K_u=4$（推导见 §37.8.7，同一对象）。把工作点从 $0.50K_u$ 推到 $0.99K_u$，四组仿真结果为：$K=0.50K_u$ 时 $M_p=29.9\%$、$t_r=1.35$ s、$t_s=10.1$ s；$0.75K_u$ 时 43.1%、1.11 s、13.6 s；$0.88K_u$ 时 48.9%、1.03 s、15.3 s；$0.99K_u$ 时 53.8%、0.97 s、17.1 s。

增益几乎翻倍，上升时间只缩短 28%，超调却涨了 24 个百分点，调节时间涨了 70%。这就是“快与稳”的定量冲突：越靠近边界，买到的快速性越少，付出的振荡代价越大。更要注意 t_s 在最后一段几乎不再增长（17.12 s 到 17.09 s），这不是性能改善，而是“最后一次越出”判据在长振荡中的假象——包络仍在缓慢衰减，只是越带时刻被振荡相位掩盖。判据失效时，应改看包络或直接看极点实部，§37.6.2 的临界延迟分析用的就是后者。

因此工程上把工作点取在 $0.5K_u$–$0.75K_u$：这一段里每增加 10% 增益还能换到约 4% 的上升时间，超过 $0.8K_u$ 之后收益迅速衰减，而模型误差、延迟、执行器非线性都会把实际边界往下拉。

37.6.4 参数摄动下的指标漂移

实验室指标是在标称参数下测的，现场参数会漂。对 $G_0(s)=10/[s(s+2)]$、$C=1$ 的系统，让增益与时间常数各变化 ±20%，仿真结果见表 37-10。

增益变化	时间常数变化	M_p (%)	t_r (s)	t_s (s)
−20%	−20%	25.87	0.461	2.662
−20%	0	30.50	0.493	3.874
−20%	+20%	34.25	0.523	4.321
0	−20%	30.50	0.394	3.100
0	0	35.09	0.425	3.538
0	+20%	38.79	0.453	4.723
+20%	−20%	34.26	0.349	2.881
+20%	0	38.78	0.377	3.937
+20%	+20%	42.39	0.404	4.432

九行数据里有两对值得注意的“重复”：增益 -20%、时间常数不变，与增益不变、时间常数 -20%，两行 M_p 都是 30.50%，t_r 却是 0.493 s 与 0.394 s；增益 -20%、时间常数 $+20\%$，与增益 $+20\%$、时间常数 -20%，两行 M_p 都是 34.3%，t_r 却是 0.523 s 与 0.349 s，差了 50%。

这不是数值巧合。把对象写成标准形式 $G=K/[s(Ts+1)]$，闭环特征方程为 $Ts^2+s+K=0$，与 $s^2+2\zeta\omega_n s+\omega_n^2=0$ 对比得

$$\omega_n=\sqrt{\frac{K}{T}},\qquad \zeta=\frac{1}{2\sqrt{KT}},\qquad \zeta\omega_n=\frac{1}{2T}$$

于是**形状只由乘积 KT 决定，速度只由比值 K/T 决定，衰减快慢只由 T 决定**。两对行的 KT 分别相同，所以 M_p 相同；K/T 不同，所以 t_r 不同。把四角与中心按这两个组合量重排，规律一目了然：

增益	时间常数	KT	K/T	ζ	ω_n (rad/s)	M_p (%)	t_r (s)	t_s (s)
−20%	−20%	1.60	10.0	0.395	3.162	25.87	0.461	2.662
−20%	+20%	2.40	6.67	0.323	2.582	34.25	0.523	4.321
0	0	2.50	10.0	0.316	3.162	35.09	0.425	3.538
+20%	−20%	2.40	15.0	0.323	3.873	34.26	0.349	2.881
+20%	+20%	3.60	10.0	0.264	3.162	42.39	0.404	4.432

把这张表当“两个旋钮”来读，比逐行背诵有用。

增益漂移只动 KT、不动 $\zeta\omega_n$。 所以增益标定错了，表现是“形状变差、快慢基本不变”：M_p 在 30.5%–38.8% 之间摆，t_s 只在 3.54–3.94 s 之间动（±11%）。现场若看到超调明显超标而调节时间变化不大，先查传感器量程、阀门流量系数这类“增益类”误差，不要去拧微分。

时间常数漂移同时动 KT 与 K/T。 表现是“又慢又振”：T 加 20%，t_r 从 0.425 s 涨到 0.453 s、t_s 从 3.54 s 涨到 4.72 s，超调同时涨 3.7 个百分点。这类误差要去查惯量、容腔容积、管路长度，调参数只会把别处的余量吃掉。

三条对角线（$K/T = 10$）的 ω_n 完全相同（3.162 rad/s），t_r 从 0.461 s 减到 0.404 s 全部来自 ζ 下降，再次印证“ζ 管形状、ω_n 管尺度”。

最后是验收口径。**超调的最坏点与调节时间的最坏点不在同一个角点**：M_p 在 $(+20\%, +20\%)$ 取到 42.39%，t_s 却在这一行是 4.432 s，真正最大的是 $(0, +20\%)$ 的 4.723 s。原因是 t_s 由“最后一次越出 $\pm 2\%$ 带”决定，振荡相位与带边的相对位置会带来 5%–10% 的抖动，不能按单调性外推。

由此得两条操作规则。第一，M_p 对 K、T 都单调，九点只需测四个角；t_s 对增益不单调（T 不变时依次为 3.874、3.538、3.937 s，中间最低），必须补测中间点。第二，若验收线是 $M_p \le 40\%$，标称设计应压到 33% 左右（约留 7 个百分点余量），否则最坏角点必然越线。**用最坏工况做设计，用标称工况做展示**，顺序不能反。

37.6.5 稳定裕度与时域指标的对应

工程上常用相位裕度 PM 快速估计闭环阻尼：

$$\zeta \approx \frac{PM}{100} \tag{37-21}$$

式 (37-21) 中 PM 以度为单位，适用于 $PM \in [30^\circ, 70^\circ]$。$PM = 45^\circ$ 对应 $\zeta \approx 0.45$、超调约 20%；$PM = 60^\circ$ 对应 $\zeta \approx 0.6$、超调约 10%。这条经验式把频域设计与时域验收连了起来：客户要求超调 ≤10%，就把相位裕度设计到 60° 以上。

但式 (37-21) 是拟合式，不是定理。对无零点的标准二阶闭环，PM 与 ζ 的精确关系是

$$PM = \arctan \frac{2\zeta}{\sqrt{\sqrt{1 + 4\zeta^4} - 2\zeta^2}}$$

反解出来的对照如下（偏差定义为“精确值相对 $PM/100$ 的相对误差”）：

目标 PM	精确 ζ	$PM/100$	偏差	M_p (%)
30°	0.269	0.300	−10.5%	41.6
45°	0.420	0.450	−6.6%	23.3
60°	0.612	0.600	+2.1%	8.8
70°	0.803	0.700	+14.8%	1.4
80°	1.182	0.800	+47.7%	0

这张表最重要的信息不是数值，而是**误差的方向**。$PM < 60^\circ$ 时公式高估阻尼、低估超调——30° 处估出 $\zeta = 0.30$，实际只有 0.269，超调被少算 5 个百分点。这是危险方向：按公式算“合格”，仿真却是 41.6%。$PM > 60^\circ$ 时反过来，公式低估阻尼、高估超调，属于保守方向，多留余量不算错。所以 60° 不只是“指标均衡点”，还是这条拟合式的误差过零点——这是把 60° 当甜点的第三重理由。

再往下就是适用边界。PM 定超调，需要同时满足“无闭环零点、无大延迟、二阶主导”三条。

闭环零点会把超调抬上去。 本章 §37.4 的标准 PD 设计 $PM = 57.1^\circ$，按式 (37-21) 估 $\zeta \approx 0.571$、$M_p \approx 11\%$；实际仿真（$T_f = 0.01$ s）是 18.25%，高出 7 个百分点。多出来的部分来自闭环零点 $-1/T_d \approx -9.6$ rad/s：它几乎落在 $\omega_n = \sqrt{10K_p} = 11.6$ rad/s 上，加快初始上升、把峰值顶得更高，而它对相位的贡献已经算进 PM 里了。零点越靠近虚轴，这个差额越大。

延迟也只被算了一次账。 纯延迟在 PM 里以 $-\omega_c\tau$ 的形式扣过一遍，但时域上它还额外造成“控制量迟到”，超调的增量比相位账更多。§37.6.7 的数据可以对照：$\tau = 0.05$ s 只把 PM 从 34.9° 压到约 26.7°，超调却从 35% 跳到 46.6%。

PM 合格也不代表增益裕度够。 本章对象 $G_0 = 10/[s(s+2)]$ 的相位最多趋于 -180°，增益裕度无穷大，PM 确实是唯一约束；换成三阶对象或含延迟的回路，$PM = 60^\circ$ 可能只配着几 dB 的增益裕度，增益一漂就振。完整判据要两个裕度一起看，见第 41 章。

一句话收口：式 (37-21) 适合做**初筛和报价**——快速说出“大概多少超调”；不适合做**验收和定责**——那必须回到时域仿真，且仿真里要带零点、延迟与饱和。

37.6.6 五个裕度点的实测对照

把式 (37-21) 放到统一算例上检验。仍取 $G_0(s) = 10/[s(s+2)]$，控制器为纯比例，按目标相位裕度反解增益：由 $PM = 90^\circ - \arctan(\omega_c/2)$ 解出 ω_c，再由 $|G_0(\mathrm{j}\omega_c)|K_p = 1$ 定 K_p。五个点的结果如下。

目标 PM	K_p	ω_c (rad/s)	实际 ζ	M_p (%)	t_r (s)	t_s (s)
30°	1.386	3.464	0.269	41.64	0.344	3.751
45°	0.566	2.000	0.420	23.32	0.629	3.531
60°	0.267	1.155	0.612	8.77	1.154	3.653
70°	0.155	0.728	0.803	1.44	1.993	3.040
80°	0.072	0.353	1.182	0.00	5.055	9.151

五行数据说明三件事。

第一，**式 (37-21) 在中间段最准，两端都有偏差**。$PM=60^\circ$ 时估计 $\zeta=0.60$、实测 0.612，误差 2%；45° 时估计 0.45、实测 0.420，偏低 7%，对应超调被低估约 3 个百分点；70° 时估计 0.70、实测 0.803，偏高 15%，超调被高估 3 个百分点。两端更明显：30° 时公式估 0.30，实际只有 0.269，实测 41.6% 的超调会被报成 37%；80° 时实际 ζ 已达 1.18、系统过阻尼，公式却还给出 0.80、预测约 1.5% 的超调。原因是这条经验式由二阶精确关系在 $\zeta\approx0.5$ 附近拟合而来，两端都会偏离。60° 既是拟合误差的过零点，也是指标最均衡的点，所以叫“甜点”。

第二，**“相位裕度主要管形状、不太管速度”只在 60° 以下成立**。30°–70° 四点的 t_s 都在 3.0–3.8 s，差别不到 25%，超调却从 41.6% 降到 1.4%。原因仍是 $\zeta\omega_n=(2+10K_pT_d)/2$：纯比例时 $T_d=0$，$\zeta\omega_n\equiv1$ 与 K_p 无关，$t_s\approx4/(\zeta\omega_n)=4$ s 被结构钉死。但到 80°，$\zeta>1$、系统进入过阻尼，主导极点不再是那对复极点，t_r 从 1.99 s 拉到 5.06 s、t_s 从 3.04 s 涨到 9.15 s。所以“裕度越大越好”是错的：**超过 70° 之后，多出来的裕度全部换成时间**。

第三，**“相位裕度 60° 对应超调 10%”这条口诀不能反过来用**。反过来用意味着“超调 10% 就一定要 60°”，但上表 8.77% 对应的是 60°，而含零点或延迟的系统在 60° 下可能给出 20% 以上。裕度是必要条件的近似，不是充分条件。

37.6.7 临界延迟的解析算法

延迟把系统推向不稳定，临界值可以不解微分方程、直接用频域算出来。对单位反馈系统，增益穿越频率 ω_c 由 $|C(\mathrm{j}\omega_c)G(\mathrm{j}\omega_c)|=1$ 定出；延迟不影响幅值，所以 ω_c 与无延迟时相同。相位裕度为

$$PM=180^\circ+\angle C(\mathrm{j}\omega_c)G(\mathrm{j}\omega_c)-\omega_c\tau$$

令 $PM=0$，得临界延迟

$$\tau_c=\frac{180^\circ+\angle C(\mathrm{j}\omega_c)G(\mathrm{j}\omega_c)}{\omega_c}=\frac{PM_0}{\omega_c}$$

其中 PM_0 是无延迟时的相位裕度，角度必须换成弧度。代入本章数据：$|G_0(\mathrm{j}\omega)|=10/[\omega\sqrt{\omega^2+4}]=1$ 解出 $\omega_c=2.863$ rad/s，$PM_0=90^\circ-\arctan(2.863/2)=34.94^\circ=0.6098$ rad，于是

$$\tau_c=\frac{0.6098}{2.863}=0.213\ \mathrm{s}$$

时域仿真验证：$\tau=0.20$ s 时闭环仍稳定但超调 113%、t_s 超出 40 s 窗口；$\tau=0.21$ s 时超调 326%；$\tau=0.22$ s 时发散。解析值 0.213 s 与仿真的临界点 0.21–0.22 s 吻合。这条公式的价值在于**不用试凑**：只要知道穿越频率与相位裕度，就能报出“这个回路最多能容忍多少延迟”。

但“稳定”不等于“可用”。仿真数据是：$\tau=0.05$ s（$0.23\tau_c$）时 $M_p=46.6\%$、$t_s=5.34$ s；$\tau=0.10$ s（$0.47\tau_c$）时 60.8%/7.62 s；$\tau=0.15$ s（$0.70\tau_c$）时 77.2%/15.99 s。也就是说，延迟用到临界值的一半，指标已经退化一倍；用到七成，系统虽然稳定，响应却慢到没有工程意义。**工程可用的延迟上限约为 $0.3\tau_c$**，本章算例对应 0.064 s，而不是 0.213 s。这条“三分之一”经验线，比“临界稳定”更接近现场的真实约束。

最后注意两个前提。其一，τ_c 是在“控制器不变”的前提下算的；若为补偿延迟而降低增益，ω_c 与 PM_0 都会变，必须重算。其二，增益裕度有限时，延迟还会与增益裕度耦合，单看相位裕度可能高估容忍度——完整判据要看奈奎斯特曲线与单位圆的交点，见第 39 章。

37.6.8 增益与延迟的联合边界

§37.6.7 的 τ_c 是在固定控制器下算的。现场更常见的问题反过来了：**想把增益提高一倍，延迟的容忍度还剩多少？** 答案不是“各算各的”，两者之间有一个近似守恒的乘积。

对象仍取 $G_0 = 10/[s(s+2)]$，控制器为纯比例 K_c。由 $|10K_c/[\mathrm{j}\omega(\mathrm{j}\omega+2)]| = 1$ 解出

$$\omega_c = \sqrt{\frac{-4 + \sqrt{16 + 400K_c^2}}{2}}$$

相位裕度 $PM_0 = 90^\circ - \arctan(\omega_c/2)$，临界延迟 $\tau_c = PM_0/\omega_c$（角度换成弧度）。七个增益点的结果如下。

K_c	ω_c (rad/s)	PM_0	τ_c (s)	$K_c\tau_c$ (s)	可用 $0.3\tau_c$ (s)
0.50	1.840	47.4°	0.450	0.225	0.135
0.75	2.400	39.8°	0.289	0.217	0.087
1.00	2.863	34.9°	0.213	0.213	0.064
1.50	3.624	28.9°	0.139	0.209	0.042
2.00	4.254	25.2°	0.103	0.207	0.031
3.00	5.298	20.7°	0.068	0.204	0.020
5.00	6.931	16.1°	0.041	0.203	0.012

仿真复核与解析在 ±0.01 s 内吻合：$K_c = 0.5$ 时 $\tau = 0.42$ s 仍收敛（末 4 s 峰值 1.23）、0.45 s 进入等幅（2.07）、0.47 s 发散（3.63）；$K_c = 2$ 时 0.09 s 收敛（1.02）、0.10 s 临界（1.43）、0.11 s 发散（11.0）。

表里最有用的是倒数第二列：$K_c\tau_c$ **几乎不动，从 0.225 缓慢收敛到 0.203**。取极限可以证明：高增益时 $\omega_c \approx \sqrt{10K_c}$，$PM_0 \approx 2/\omega_c$（弧度），于是 $\tau_c \approx 2/\omega_c^2 = 0.2/K_c$，即

$$K_c\,\tau_c \approx 0.2\ \mathrm{s}$$

这条守恒律的工程含义很直接：**增益翻倍，能容忍的延迟就减半**。它把“加增益提速”的代价换算成一个能现场测量的物理量——延迟。若设备固有延迟为 0.05 s，按 $0.3\tau_c$ 的可用线，K_c 最多取 $0.2/(0.05/0.3) = 1.2$；想把 K_c 提到 2，必须先把延迟压到 0.03 s 以下，否则怎么调微分都救不回来。

注意这条守恒律只对“纯比例 + 纯延迟”成立。加积分会额外吃相位，实际边界还要下移 10%–20%；加微分能补回相位，相当于把 τ_c 放大，但微分本身受噪声限制（§37.9.3）。所以这张表是**上限的上限**，现场取值应在此基础上再留一半余量。

37.7 参数意义与作用

调参的前提是知道每个参数“管什么、管多少”。本节逐个参数给出物理意义、影响方向与量级，并说明它们之间的耦合——后者往往是“调好一个、坏掉另一个”的根源。

37.7.1 参数总表

参数	物理意义	单位	主要影响	典型范围
K	直流增益（输出/输入）	视对象而定	稳态误差、闭环带宽	由对象定
T	一阶时间常数	s	上升与调节时间，$t_r \approx 2.2T$	ms–min
ζ	阻尼比	—	超调与振荡，M_p 只由它决定	0.3–0.9
ω_n	自然频率	rad/s	时间尺度，$t_s \propto 1/\omega_n$	与工艺节拍匹配
τ	纯延迟	s	相位滞后、稳定域	0–0.3t_r
T_s	采样周期	s	离散化误差、ZOH 延迟	$\le t_r/10$

这张表最容易引起的误读，是把六个参数当成同一层级。实际上它们分两类：

- **对象参数**（K、T、ζ、ω_n、τ）：由设备与工艺决定，不能“调”，只能“测”；辨识错了，后面所有计算都白做。
- **设计参数**（T_s，以及由设计目标定出的控制器 K_c、T_i、T_d）：才是手里能动的旋钮。

第二类里也没有“一对一”关系。T_i 同时影响稳态误差与相位，T_d 同时影响超调与噪声放大，T_s 同时影响离散误差与 ZOH 延迟。所以“动一个参数、只看一个指标”只是调试时的纪律，不是系统的性质；每次改完都要把五项指标与两路信号（输出、控制量）一起复测。

还有一处口径要分清：表中 ζ、ω_n 指**闭环**参数，而 K、T、τ 是**开环**参数，两者之间隔着控制器。前文说“ζ 管形状”指的是闭环 ζ；对象若写成二阶形式，它的自然阻尼与闭环阻尼不是一回事，耦合关系见 §37.7.7。跨章节引用时把这两个 ζ 混用，是最常见的口径事故。

37.7.2 增益 K：不是“越大越快”这么简单

增益同时出现在两个地方：对象的直流增益，以及控制器的比例系数。两者对指标的作用完全不同，必须分开看。

对象增益 K 变化，相当于改变了“输入多少、输出多少”的比例。对 0 型对象，K 增大会减小稳态误差；对含积分的对象，K 不影响阶跃稳态误差，但会改变闭环极点位置。

控制器比例系数 K_c 增大，则同时提高带宽与超调。以 $G(s) = K/[s(s+2)]$、单位反馈为例，闭环特征多项式为

$$s^2 + 2s + K = 0 \implies \omega_n = \sqrt{K}, \qquad \zeta = \frac{1}{\sqrt{K}} \tag{37-22}$$

式 (37-22) 揭示了一个反直觉的结论：**增大增益会让系统变快，但同时让阻尼比下降**。$K = 10$ 时 $\omega_n = 3.16$ rad/s、$\zeta = 0.316$，按式 (37-6) 算得 $M_p = 35.1\%$，与表 37-10 中 $C = 1$ 的仿真值 35.09% 完全一致。这也解释了为什么“加增益提快”总会伴随超调上升——它不是调参没调好，而是结构决定的。

两类增益的量纲不同，不能混为一谈。对象增益 K 的单位是“输出单位/输入单位”，控制器增益 K_c 的单位是“输入单位/误差单位”，两者相乘才是无量纲的环路增益 $K_L = KK_c$。现场说“把增益调大一点”，指的总是 K_c；而对象更换、量程改变时变的是 K。这解释了一个常见困惑：同一套控制器参数换到另一台设备上就不好用——不是参数错了，是 K 变了，K_L 跟着变了。

对 0 型对象，K 直接决定稳态误差。取 $G(s) = K/(s+1)$、单位反馈，$K = 10$ 时 $e_{ss} = 9.09\%$，$K = 20$ 时 4.76%，$K = 50$ 时 1.96%。要把误差从 9% 压到 2%，需要把 K 提高约 5 倍，闭环极点也从 -11 移

到 -51，响应快 4.6 倍。这笔交易看起来划算，但执行器要提供 5 倍的稳态控制量，噪声也被放大 5 倍——增益从来不是免费的。

对含积分的对象，K 不改变阶跃稳态误差（仍为零），却改变闭环极点。本章 $G_0 = 10/[s(s+2)]$ 中，K 从 10 增到 20，等效于 K_c 从 1 增到 2：ω_n 从 3.16 升到 4.47，ζ 从 0.316 降到 0.224，超调从 35.1% 涨到 48.6%（表 37-11）。**同一句话"增益加倍"，在 0 型对象上主要改精度，在 I 型对象上主要改动态**，这是看对象型别下菜的第一条。

37.7.3 时间常数 T：决定"起步有多慢"

T 是一阶对象唯一的动态参数。它同时决定上升时间（$2.2T$）、调节时间（$3.9T$）与带宽（$\omega_c \approx 1/T$）。T 减半，响应快一倍，但初始斜率 K/T 加倍，对执行器的冲击也加倍。现场把 T 从 2 s 改到 0.5 s，往往要同时检查电机电流是否超限。

T 的辨识误差对指标影响是线性的：T 估大 20%，t_r 与 t_s 都会估大 20%。因此 §37.3.4 强调阶跃试验要覆盖足够长的窗口，否则 T 会被低估。

三个时间常数的实测值可以说明这种线性关系：

T (s)	t_r (s)	t_r/T	t_s (s)	t_s/T	带宽 $1/T$ (rad/s)
0.5	1.097	2.19	1.947	3.89	2.0
1.0	2.194	2.19	3.895	3.90	1.0
2.0	4.388	2.19	7.789	3.89	0.5

三行的比值完全一致，说明一阶系统的形状是固定的，T 只负责整体缩放。工程上因此可以记两个常数：$t_r = 2.2T$、$t_s = 3.9T$（±2% 带），现场量出 T 就能报指标，不需要每次仿真。

闭环之后，时间常数会被反馈"压缩"。对 $G = K/(Ts+1)$ 加比例 K_c，闭环时间常数为 $T/(1+KK_c)$。取 $T = 1$ s、$K = 10$、$K_c = 1$，闭环时间常数从 1 s 压到 0.0909 s，t_r 从 2.19 s 降到 0.20 s，t_s 从 3.90 s 降到 0.35 s，快了 11 倍。但稳态增益只有 $10/11 = 0.909$，稳态误差 9.09%——这就是 0 型系统"快"与"准"不能兼得的定量版本。

37.7.4 阻尼比 ζ：只管形状

ζ 是唯一"只影响形状、不影响尺度"的参数。它决定超调（式 37-6）、振荡次数与相对稳定性，但与 ω_n 无关。这一性质带来一个非常实用的调参策略：**先调 ζ 定形状，再调 ω_n 定快慢**，两者近似解耦。

灵敏度方面，在 $\zeta = 0.5$ 附近，ζ 每增加 0.01，超调约下降 0.8 个百分点；在 $\zeta = 0.2$ 附近，同样 0.01 的增量能降 1.8 个百分点；到了 0.7 以上只剩 0.3 个百分点。也就是说，小阻尼区对 ζ 更敏感，调参时步长要更小。把四个点列出来：

ζ	M_p (%)	每 0.01 阻尼对应的超调变化
0.20	52.66	−1.8 个百分点
0.50	16.30	−0.8 个百分点
0.70	4.33	−0.3 个百分点
0.90	0.15	−0.05 个百分点

这张表解释了一个现场现象：小阻尼系统“动一点就变很多”，而 $\zeta > 0.7$ 之后再加阻尼几乎看不到效果。所以调参应从大往小逼近：先把 ζ 拉到 0.7 以上压住超调，再逐步减小直到超调刚好达标；反过来从小往大调，很容易在敏感区来回过冲。

ζ 的物理来源有三类：对象的自然阻尼（如机械摩擦、电阻尼）、控制器引入的阻尼（如微分作用）、以及采样与延迟带来的等效阻尼损失。第三类常被忽略：同一套连续参数，采样周期从 1 ms 增到 20 ms，等效 ζ 可能下降 0.1 以上。

37.7.5 自然频率 ω_n：决定“整体快慢”

ω_n 是所有时间尺度的基准：$t_r \propto 1/\omega_n$、$t_p \propto 1/\omega_n$、$t_s \propto 1/\omega_n$。ω_n 加倍，三个时间指标近似减半，超调不变。

ω_n 的上限由三件事约束：执行器带宽（电机、阀门的响应速度）、采样频率（ω_n 不能接近 $\omega_s/10$）、以及未建模高频动态（每提高一倍带宽，就多暴露一层高频模态）。工程上把 ω_n 定在“对象第一转折频率的 1/3–1/2”是常见做法。

固定 $\zeta = 0.5$，让 ω_n 取 2、5、10 rad/s，三个时间指标等比缩放：

ω_n (rad/s)	t_r (s)	t_p (s)	t_s (s)	M_p (%)
2	0.82	1.81	4.00	16.3
5	0.33	0.73	1.60	16.3
10	0.16	0.36	0.80	16.3

三行的超调完全相同，时间指标与 ω_n 成反比。这就是“ω_n 管尺度”的准确含义：它不动形状，只动时间轴。

三条上限可以用同一个例子串起来。若对象的第一转折频率为 100 rad/s，则 $\omega_n \le 33$–50 rad/s；若采样周期为 5 ms（$\omega_s = 1257$ rad/s），则 $\omega_n \le 125$ rad/s；若执行器带宽只有 30 rad/s，则 ω_n 不应超过 10–15 rad/s。三者取最小，实际可用值由执行器决定。这也解释了为什么“换更快的电机”往往比“改控制算法”更能提升节拍——瓶颈常在执行器，不在控制器。

37.7.6 延迟 τ：只花相位，不花增益

延迟的幅频特性恒为 1，相频特性为 $-\omega\tau$。它不影响稳态精度，也不改变幅频形状，但会实打实地消耗相位裕度：等效阻尼下降，超调随之上升，而且这个代价无法靠调增益补回来。τ 每增加 $0.1t_r$，可用的闭环带宽大约下降 10%–15%。

延迟的代价可以精确折算成相位。本章回路穿越频率 2.863 rad/s，每 0.01 s 延迟损失 $57.3 \times 2.863 \times 0.01 = 1.64^\circ$ 相位裕度；原本 34.9° 的裕度，在 $\tau = 0.05$ s 时剩 26.7°，$\tau = 0.10$ s 时剩 18.5°，$\tau = 0.15$ s 时剩 10.3°。对应到指标：

τ (s)	相位损失	剩余 PM	M_p (%)	t_s (s)
0	0°	34.9°	35.1	3.54
0.05	8.2°	26.7°	46.6	5.34
0.10	16.4°	18.5°	60.8	7.62
0.15	24.6°	10.3°	77.2	15.99

只加了 50 ms 延迟，超调就涨 11.5 个百分点、调节时间涨 51%。这就是“延迟只花相位”的破坏力：它不改变任何稳态量，却让所有动态指标一起变差，而且无法靠调增益补回来——降增益能换回相位，但同时把带宽降下去，等于用速度换稳定。

延迟的辨识比 T 难：它常与传感器滤波、通信抖动、执行器死区混在一起。工程上把“指令发出到输出开始变化”的时间整体当作 τ，宁可估大不可估小，因为低估延迟会直接导致现场振荡。

37.7.7 参数耦合：三个必须记住的关系

1. K 与 ζ：如式 (37-22)，$K\uparrow$ 使 $\omega_n\uparrow$、$\zeta\downarrow$，快与稳同时反向。
2. T 与 ω_n：对一阶对象加比例控制，闭环时间常数为 $T/(1+K_cK)$，即增益把时间常数“压缩”，压缩比就是闭环带宽的提升倍数。
3. τ 与 ω_n：可接受的 τ 与目标带宽成反比。想把 ω_n 提高一倍，延迟必须减半，否则相位裕度会被吃光。

理解了这三条，再看现场“调了增益就振、减了增益就慢”的现象，就知道该动的是结构（加微分、加前馈、减延迟），而不是继续在增益上打转。

把三条耦合关系写成一张“谁动谁”的表，调参时可以直接查：

动这个	ζ	ω_n	M_p	t_r	t_s	稳态误差
$K_p\uparrow$	↓	↑	↑	↓	基本不变*	↓（0 型）
$T_d\uparrow$	↑	不变	↓	↓（含零点）或↑（无零点）	↓	不变
T_i 投入	↓	略↓	↑	↓	↑	阶跃→0
$\tau\uparrow$	等效↓	不变	↑	略↓	↑↑	不变
$T_s\uparrow$	等效↓	不变	↑	略↓	↑	不变

* 对本章 G_0，纯比例下 $\zeta\omega_n\equiv 1$，t_s 被钉住；这条“基本不变”只对这类特定结构成立，一般对象仍会变。

这张表最有用的一行是 τ：它让超调、调节时间一起变差，却完全不碰稳态误差。这意味着**用稳态误差判断延迟是否被低估是无效的**，必须看动态指标。反过来，若稳态误差莫名变大而动态正常，应先查死区、量化与增益，而不是怀疑延迟。

最后把 §37.2–§37.7 的关系收成一句：**ζ 管形状、ω_n 管尺度、K_p 同时动两者、T_d 只补形状、T_i 管误差但吃相位、τ 与 T_s 只吃相位**。记住这句，调参时就不会同时动三个旋钮。

37.8 调参方法与经验

有了 §37.7 的参数—指标关系，调参就不该是“试一试”。本节给出一套从指标出发、每次只动一个参数、每步都有验收判据的流程，并给出一个完整算例。

37.8.1 反向设计：由指标定参数

对二阶主导的系统，反向设计只需三步：

1. 由 M_p 定 ζ：用式 (37-12) 或查表 37-3；
2. 由 t_s 定 ω_n：$\omega_n\geq 4/(\zeta t_s)$；

3. 由 ω_n、ζ 反推控制器参数：若对象为 $K/[s(Ts+1)]$，比例增益取 $K_c \approx \omega_n^2 T/K$，再用微分把 ζ 补到目标值。

三步算完再仿真。若仿真与解析差得远，先查模型阶次与延迟，不要急着改参数。

以 §37.4 的统一例题走一遍。要求 $M_p \le 5\%$、$t_s \le 0.5$ s；对象 $G_0 = 10/[s(s+2)] = 5/[s(0.5s+1)]$，即 $K=5$、$T=0.5$ s。

第一步，由 $M_p = 5\%$ 反解式 (37-6) 得 $\zeta = 0.690$。第二步，$\omega_n \ge 4/(\zeta t_s) = 4/(0.690 \times 0.5) = 11.6$ rad/s；这里用 4 而不是 3.91，是给判稳口径留 2% 余量。第三步，比例增益

$$K_p = \frac{\omega_n^2 T}{K} = \frac{11.6^2 \times 0.5}{5} = 13.5$$

再用微分补阻尼。闭环特征方程为 $s^2 + (2 + 10K_pT_d)s + 10K_p = 0$，要求 $2\zeta\omega_n = 2 \times 0.690 \times 11.6 = 16.0$，于是

$$T_d = \frac{16.0 - 2}{10 \times 13.5} = \frac{14.0}{135} = 0.104$$

这与 §37.4.7 用频域凑裕度得到的 $K_p = 13.4$、$T_d = 0.1045$ 是同一组数。两条路——时域反解与频域凑相位裕度——在二阶主导的系统上必然收敛到同一个答案；若两者差得远，先怀疑降阶是否成立、延迟是否漏算，而不是怀疑哪条公式错了。

37.8.2 调整顺序：先形状、后尺度、最后消差

推荐的调整顺序与多数现场习惯相反，但更省时间：

1. **先定形状**：用微分（或超前校正）把 ζ 拉到 0.6–0.8，此时超调达标，响应可能偏慢；
2. **再定尺度**：加比例增益，把 ω_n 抬到目标，同时观察超调是否反弹；
3. **最后消差**：若稳态误差超标，加积分或前馈；积分会引入相位滞后，必须回头复核超调。

反过来先加积分，往往会出现“越调越振”：积分把相位裕度吃掉了，再用微分补，参数互相打架。

这个顺序不是习惯问题，而是由灵敏度决定的。§37.8.3 的实测数据表明：同样 ±20% 的变化，K_d 让超调在 0.16%–9.27% 之间跳，K_p 只让它在 0.82%–5.44% 之间动；而 t_r 主要由 K_p 决定（0.151–0.232 s），K_d 对它的影响不到 20%。**先调对超调最敏感的那个旋钮（T_d），再调对速度最敏感的那个（K_p）**，每步都能看到单一指标明显变化，不会出现“动了半天不知道是谁的功劳”。

积分的特殊性在于它同时动两件事：消掉稳态误差，又把一个极点放到原点、把相位在低频段拉低 90°。放在最后调，是因为只有前两步都稳定了，才能判断“这点残余误差到底该不该用积分去消”——很多场合用前馈或提高型别更划算，加了积分反而把已经调好的动态破坏掉。

37.8.3 步长、观测与判据

每次只改一个参数，步长取 10%–20%。步长太小学不到趋势，太大容易越过稳定边界。每次改动后至少观测三件事：

- 阶跃响应的超调与调节时间（时域）；
- 控制量 $u(t)$ 的峰值与是否饱和（执行器）；
- 稳态 30 s 内是否有缓慢漂移（积分与摩擦力）。

三项都正常才算这一步调完。只看输出曲线、不看控制量，是现场烧驱动器的主要原因。

步长取多少，取决于该参数对指标的灵敏度，而不同参数的灵敏度差得很远。仍以 §37.4.7 的设计（$K_p = 13.4$、$K_d = 1.4$、$T_f = 0.01$）为基准，基准指标是 $M_p = 2.94\%$、$t_r = 0.181$ s、$t_s = 0.468$ s。把 K_p 单独变化：-20% 时 $M_p = 0.82\%$、$t_r = 0.232$ s、$t_s = 0.371$ s；$+20\%$ 时 $M_p = 5.44\%$、$t_r = 0.151$ s、$t_s = 0.445$ s。把 K_d 单独变化：-20% 时 $M_p = 9.27\%$、$t_s = 0.492$ s；-40% 时 $M_p = 18.98\%$、$t_s = 0.694$ s；$+20\%$ 时 $M_p = 0.16\%$、$t_r = 0.223$ s；$+50\%$ 时 $t_r = 0.303$ s、$t_s = 0.558$ s。

两列一对比就清楚了：K_p 每变 10%，超调约动 1.2 个百分点；K_d 减 20% 超调跳到 9.3%，减 40% 到 19%，而加 20% 就压到 0.16%。**K_d 对超调的影响比 K_p 大 1–2.5 倍，且严重不对称：往下调比往上调危险得多**。因此 K_p 可以按 10%–20% 走，K_d 每次只动 5%–10%，且优先往上试。反过来，K_d 加过头会把系统推入过阻尼：$+50\%$ 时超调归零，但 t_r 从 0.181 s 涨到 0.303 s、t_s 涨到 0.558 s，“不超调”是用“变慢”换来的，不能算改进。

还有一处非线性要注意：K_p 从 13.4 减到 12.1 时，t_s 反而从 0.468 s 缩到 0.317 s。这不是测量错误，而是 t_s 由“最后一次越出”决定，参数变化改变了振荡相位，越带时刻跟着跳。**调参时不要用 t_s 的单调性做判断**，要看 M_p 与包络；t_s 只在指标验收时用。

37.8.4 经验数值

目标	推荐取值	依据
超调 ≤5%	$\zeta \geq 0.69$	式 (37-12)
超调 ≤10%	$\zeta \geq 0.59$	式 (37-6)
超调 ≤20%	$\zeta \geq 0.46$	式 (37-6)
兼顾快与稳	$\zeta = 0.6$–0.8	工业惯例
相位裕度	$PM \geq 45°$，精密场合 $\geq 60°$	式 (37-21)
采样周期	$T_s \leq t_r/10$	§37.5.3

这张表是起点，不是终点。伺服、液压、温度三类对象的可用 ζ 差别很大：伺服常取 0.8 以上（怕冲击），温度对象常取 0.4–0.5（怕慢）。

表里“超调”与“相位裕度”两行其实是同一条线。按精确关系，$PM = 45°$ 对应 $\zeta = 0.420$、$M_p = 23.3\%$；$PM = 60°$ 对应 0.612、8.8%；$PM = 65°$ 对应约 0.69、5%。若用 $\zeta \approx PM/100$ 粗估，45° 会给出 20.5%、60° 给 9.5%，两头都差几个百分点。所以现场若只写一句“相位裕度不低于 45°”，实际是“允许 23% 左右的超调”；要把超调压到 5% 以内，得要求 $PM \geq 65°$。**写验收条款时，两个指标不能各写各的，否则一定自相矛盾。**

37.8.5 一个完整算例

回到 $G_0(s) = 10/[s(s+2)]$、$C = 1$ 的系统。标称指标为 $M_p = 35.09\%$、$t_r = 0.425$ s、$t_s = 3.54$ s；要求改成 $M_p \leq 10\%$、$t_r \leq 0.25$ s。

第一步，先看纯比例能不能做到。$M_p \leq 10\%$ 要求 $\zeta \geq 0.59$，由式 (37-22)（其中环路增益 $K_L = 10K_c$）反解出 $K_c \leq 0.287$；此时 $\omega_n = \sqrt{10K_c} = 1.69$ rad/s，仿真得 $M_p = 10.05\%$、$t_r = 1.081$ s。超调刚好达标，上升时间却差 4 倍。反过来，为了 $t_r \leq 0.25$ s 把 K_c 提到 5，t_r 降到 0.162 s，但 M_p 冲到 63.84%。**纯比例在这两项指标之间没有交集**，这是 §37.9.1 那条硬约束的直接后果。

第二步，换成 PD 控制 $C(s)=K_p(1+T_d s)$，两个参数分工明确：K_p 定尺度，$\omega_n=\sqrt{10K_p}$；T_d 定形状，$\zeta=(1+5K_pT_d)/\sqrt{10K_p}$。

第三步，先固定 $K_p=1$ 扫 T_d：$T_d=0.2$ s 得 $M_p=10.42\%$、$t_r=0.474$ s；$T_d=0.4$ s 得 $M_p=1.61\%$、$t_r=0.455$ s。超调降下来了，t_r 却几乎不动——因为 K_p 没变，ω_n 还是 3.16 rad/s，尺度没变。

第四步，改尺度。取 $K_p=3$、$T_d=0.3$ s，得 $M_p=4.77\%$、$t_r=0.189$ s、$t_s=0.828$ s，两项指标同时满足。此时 $\omega_n=5.48$ rad/s、$\zeta=1.00$，闭环极点为 -5 与 -6，已经是过阻尼；按二阶公式应当零超调，实测 4.77% 全部来自 C 引入的零点 -3.33。

这个算例给出三条可复用的结论：

- **K_p 管快、T_d 管稳。** 只调 T_d 能把超调压下去，但 t_r 原地不动；要快必须动 K_p。
- **零点既是加速器也是超调源。** 同一组参数去掉零点，t_r 从 0.189 s 变成 0.617 s，快了 3 倍；代价就是那 4.77% 的超调。
- **改结构胜过改参数。** 纯比例最优也只能到 $10\%/1.08$ s，PD 一步就到 $4.77\%/0.189$ s，差距不是调参能弥补的。

37.8.6 四类典型症状与对策

症状	可能原因	对策
等幅振荡、不衰减	增益过高、延迟被低估	降增益 30%，重测延迟
到位后缓慢爬行	死区、摩擦力、积分过弱	测死区，加积分或摩擦补偿
输出有高频毛刺	微分增益过大、编码器噪声	加微分滤波，降低 T_d
大阶跃后长时间不回	积分饱和	加抗饱和（clamping/back-calculation）

表的四行只是“症状—病因”的快速对照，真正难的是把症状读成参数。四类症状各有自己的定量指纹，抓住指纹就不用试凑。

等幅振荡看峰谷比。 若第二个峰与第一个峰几乎同高（比值大于 0.95），说明极点实部已经贴到零。§37.6.3 的数据可作标尺：$K=0.99K_u$ 时 $M_p=53.8\%$、$t_s=17.1$ s，包络衰减得极慢；$K=120$（临界 126）时极点实部只有 -0.02。对策不是微调，而是把增益退回 0.6–$0.7K_u$，同时重测延迟——延迟被低估 0.1 s，等价于凭空多花掉十几度相位，靠降增益只能把问题压住，不能解决。

缓慢爬行看偏置方向。 稳态误差卡在一个固定值上，改变给定后偏置跟着换向，这是死区或摩擦的特征。§37.5.7 的死区实验给出量级：死区 0.05 时残差 1.4%，死区 0.1 时 9.3%，近似成正比。这类误差调增益无效——增益再大，死区内控制量仍是零——只能减小死区、加积分或加抖动。

高频毛刺看控制量的频谱，不看输出。 微分环节对高频的放大倍数是 K_pT_d/T_f：本章设计 $K_p=13.4$、$T_d=0.1045$，取 $T_f=0.01$ s 时放大 140 倍，取 $T_f=0.002$ s 时放大 700 倍，相差 5 倍。所以看到毛刺的第一个反应应该是“T_f 是不是太小”，而不是“K_d 是不是太大”——后者会把有用的阻尼一起砍掉。

大阶跃后长时间不回看控制量方向。 若误差已经反号，控制量仍贴着限幅值不放，就是积分饱和。§37.5.7 的饱和实验（限幅 ±0.6）给出 $t_r=0.497$ s、$M_p=32.8\%$，比不限幅的 0.418 s/37.2% 更慢；注意超调反而小了，容易被误读成“限幅有益”，实际是积分被顶住后动态变钝，一松限幅就会反弹。

抗积分饱和的具体实现见第 44 章，本章只需知道：只要执行器有限幅，就必须考虑积分饱和，否则 §37.10 的现场测试一定不合格。

37.8.7 Ziegler-Nichols 法：什么时候能用

现场最常被引用的整定法是 Ziegler-Nichols 临界比例度法。它的操作是：把积分、微分关掉，只加比例，直到系统出现等幅振荡，记下此时的临界增益 K_u 与振荡周期 T_u，再按经验公式取参数。以 $G(s)=2/[(s+1)^3]$ 为例，闭环特征式为

$$(s+1)^3+2K=s^3+3s^2+3s+(1+2K)=0$$

劳斯表第三行为 $(9-1-2K)/3$，令其为零得 $K_u=4$；代回辅助方程 $3s^2+9=0$ 得 $\omega_u=\sqrt{3}$，于是 $T_u=2\pi/\sqrt{3}=3.628$ s。按 ZN 公式，PID 取 $K_p=0.6K_u=2.4$、$T_i=T_u/2=1.814$ s、$T_d=T_u/8=0.454$ s。仿真结果为 $M_p=41.45\%$、$t_r=0.853$ s、$t_s=9.29$ s、相位裕度 30.1°、控制量峰值 81。

若按本章的流程整定同一对象：先由 $M_p\le 10\%$ 定 $\zeta\ge 0.59$，再由 $t_s\le 4$ s 定 $\zeta\omega_n\ge 1$，取 $K_p=1.5$、$T_i=2.5$ s、$T_d=0.8$ s，实测 $M_p=6.16\%$、$t_r=1.178$ s、$t_s=3.20$ s、相位裕度 62.5°、控制量峰值 37。两套参数的对比如下。

方法	K_p	T_i (s)	T_d (s)	M_p (%)	t_s (s)	PM	u 峰值
ZN 临界比例度	2.40	1.81	0.45	41.45	9.29	30.1°	81.3
本章反向设计	1.50	2.50	0.80	6.16	3.20	62.5°	37.0

差距不是“调得粗细”的问题，而是目标不同。ZN 的公式来自“四分之一衰减”经验——它追求的是相邻两个峰值的幅值比为 1:4，对应阻尼比约 0.2、超调约 50%。上表 41.5% 正好落在这个区间。对允许大幅超调、只求快速稳定的过程控制（液位、压力、流量），这个目标可以接受；对定位、跟踪、有机械间隙的伺服系统，40% 的超调意味着撞限位。

ZN 还有两个隐含前提：对象必须是“带延迟的一阶或二阶主导”，且延迟不能太小。本章对象是纯三阶、无延迟，属于“滞后主导”，ZN 给出的增益偏大、相位裕度偏低（30°，低于工程下限 45°）。这也解释了为什么现场照搬 ZN 常常“一调就振”。

结论可以写得很明确：**有模型就用本章的反向设计，没模型再用 ZN 做粗调，且把 ZN 的结果当作上限而不是终值**。ZN 之后必须做两步收尾：把 K_p 降到 0.6–0.8 倍，把 T_d 适当加大，直到超调进入可接受范围。

37.8.8 一张调参检查清单

把前面各节压缩成一张可打印的清单。每次整定按顺序过一遍，任一项不通过就停下来解决，不要带着问题往下走。

1. **指标是否带口径**：上升时间用 10%→90% 还是 0→100%？调节时间用 ±2% 还是 ±5%？给定是阶跃还是斜坡？三项没写清，后面的数都不可比。
2. **模型是否验证过**：阶跃试验的仿真与实测在同一坐标下重合吗？若偏差超过 20%，先回去改模型，不要调控制器。
3. **延迟是否计入**：从控制器输出到对象响应的纯延迟量过吗？仿真里 `delay_steps` 设的是几拍？
4. **执行器是否够用**：控制量峰值是限幅的百分之多少？超过 70% 就要考虑降指标或加前馈。
5. **采样是否够快**：$T_s\le t_r/10$ 满足吗？微分滤波时间常数是否至少覆盖 5 个采样点？
6. **稳态误差是否达标**：是型别不够还是增益不够？前者要加积分，后者才调 K_p。
7. **超调是否可复现**：换一个随机种子、换一天重测，超调波动多少？带噪声时波动超过 20% 就不能用单次结果验收。

8. **最坏工况是否校核**：参数漂 ±20%、延迟取上限、限幅取最小值，三项叠加后还达标吗？
9. **有没有看控制量**：只看输出曲线不算调完；$u(t)$ 的饱和时间占比、抖动幅值都要记录。
10. **参数是否留档**：K_p、T_i、T_d、T_f、T_s、限幅值、测试日期、对象编号，缺一项就无法复现。

这十条没有一条涉及新公式，但每一条都对应过现场事故。清单的价值在于把“经验”变成“流程”：换一个人来调，只要按同样的顺序、同样的判据，就能得到同样的结果。这也是本书把工程落地单列一节的原因——**能复现的调参，才是工程；不能复现的，只是手艺。**

37.9 优化与改进

前八节回答的都是“给定结构，指标是多少”和“反向怎么定参数”。本节回答第三个问题：**参数已经调到极限仍不达标时，应该改什么。**

37.9.1 先确认“参数已经到顶”

改进的第一步不是动手，而是先证明当前结构已经没有余量。仍用 $G_0(s)=10/[s(s+2)]$、纯比例 $C=K$ 的算例，闭环特征多项式为

$$s^2+2s+10K=0 \tag{37-23}$$

与标准式 $s^2+2\zeta\omega_n s+\omega_n^2=0$ 逐项对比，得

$$\omega_n=\sqrt{10K},\qquad \zeta=\frac{1}{\sqrt{10K}},\qquad \zeta\omega_n=1 \tag{37-24}$$

式 (37-24) 的第三项是关键：**$\zeta\omega_n$ 恒等于 1，与 K 完全无关**。而调节时间主要由 $\zeta\omega_n$ 决定（式 37-5 的 $t_s\approx 3.5/\zeta\omega_n$），于是无论 K 取多少，t_s 都被钉在 3.5 s 附近。表 37-11 是四个增益下的仿真结果。

表 37-11　纯比例增益对三项指标的影响（$G_0=10/[s(s+2)]$）

K	ζ	ω_n /(rad/s)	M_p /%	t_r /s	t_s /s
0.5	0.447	2.236	20.79	0.689	3.735
1.0	0.316	3.162	35.09	0.425	3.536
2.0	0.224	4.472	48.64	0.275	3.781
5.0	0.141	7.071	63.84	0.162	3.702

K 放大 10 倍，上升时间缩短到 1/4，超调从 20.8% 涨到 63.8%，而调节时间只在 3.54–3.78 s 之间摆动，变化不到 7%。这就是“参数调到顶”的数学含义：**不是手法不够，而是结构把 ζ 与 ω_n 绑成了一根绳**，一头松另一头必然紧。

现场判断是否已经到顶，可以做一个快速的“双倍增益试验”：把增益乘 2，若调节时间几乎不变、超调明显上升，就说明主导极点的时间常数由对象本身决定，继续加增益只会更振荡。

37.9.2 改结构的第一选择：引入零点

要让 ζ 与 ω_n 解耦，最直接的办法是在控制器里引入零点。取 $C(s)=K_p(1+T_d s)$，闭环特征多项式变为

$$s^2 + (2 + 10K_pT_d)s + 10K_p = 0 \tag{37-25}$$

对比标准式可见：$\omega_n = \sqrt{10K_p}$ 由比例增益决定，$\zeta = (1 + 5K_pT_d)/\sqrt{10K_p}$ 由微分时间决定，两者可以分开调。$K_p = 1$ 时 $\omega_n = 3.16$ rad/s 固定，$T_d = 0.2$ s 给出 $\zeta = 0.632$，$T_d = 0.4$ s 给出 $\zeta = 0.949$。到此“绳子”解开了：想提阻尼就加 T_d，不必牺牲 ω_n。

但仿真值与二阶公式对不上：$T_d = 0.2$ 时 $M_p = 10.42\%$、$t_r = 0.474$ s；$T_d = 0.4$ 时 $M_p = 1.61\%$、$t_r = 0.455$ s。而按式 (37-6)，$\zeta = 0.632$ 应为 7.7%、$\zeta = 0.949$ 应为 0.01%。两处实测都偏高，说明有一项因素没进入二阶公式。

这项因素就是 PD 顺带给闭环添的零点 $z = -1/T_d$。用它与极点的相对距离

$$\rho = \frac{|z|}{\zeta\omega_n} = \frac{1}{T_d\,\zeta\omega_n} \tag{37-26}$$

来衡量影响强度。固定 $\zeta = 0.632$、$\omega_n = 3.162$ rad/s，只挪零点位置，仿真得：$\rho = 1$ 时 $M_p = 34.02\%$；$\rho = 1.6$ 时 16.62%；$\rho = 2.5$ 时 10.45%；$\rho = 5$ 时 8.23%；$\rho = 7.5$ 时 7.92%；$\rho = 15$ 时 7.76%，才回到二阶本体的 7.7%。可见“零点可忽略”的门槛是 $\rho \geq 5$，不是常说的 2；$\rho < 2$ 时超调几乎翻倍。

零点还有另一半作用：加速。$K_p = 1$、$T_d = 0.4$ 时，若只有二阶极点（$\zeta = 0.949$），t_r 长达 0.983 s；加上零点后降到 0.455 s，快了一倍多，代价是 1.61% 的超调。§37.8.5 的 $K_p = 3$、$T_d = 0.3$ 算例更极端：闭环极点 -5、-6，过阻尼、无超调，实测 4.77% 全部由零点 -3.33 产生；去掉零点，t_r 从 0.189 s 拉长到 0.617 s。**零点本质上是用超调换速度**，这笔交易划不划算，取决于指标里哪一项更紧。

工程上更常用的形式是**微分先行**（derivative on measurement），即只对输出求微分：

$$u(t) = K_p\,[r(t) - y(t)] - K_d\frac{\mathrm{d}y(t)}{\mathrm{d}t} \tag{37-27}$$

它与式 (37-25) 的闭环分母相同，稳定性与抗扰能力完全一致，差别只在给定通路：标准形式 $K_p(r - y) + K_d\,\mathrm{d}(r - y)/\mathrm{d}t$ 在 r 跳变瞬间会产生幅值 $K_d\Delta r$ 的微分尖峰，现场表现为“给定一改，驱动器就吼一声”；微分先行没有这个尖峰，但零点也一并消失，加速效果随之丢掉。

这一取舍有实际后果：$K_p = 1$、$T_d = 0.2$ s 时，标准 PD 是 $10.42\%/0.474$ s，微分先行回到二阶本体 $7.71\%/0.612$ s——超调略降，上升却慢了 29%。所以本章的 PD 算例都按**标准形式**计算，代表“PD 能达到的最好指标”；现场若因噪声或冲击必须用微分先行，应按无零点的二阶公式重估指标，再用设定值加权或给定滤波补回一部分速度。这个差别在调参时经常被忽略，导致仿真很好、上机却慢半拍。

37.9.3 理想微分的代价与滤波实现

式 (37-25) 的 T_ds 是理想微分，它的高频增益随频率无限增长。离散实现时，微分项近似为 $(y_k - y_{k-1})/T_s$，对测量噪声的放大倍数约为 T_d/T_s。代入本章伺服轴的数据：编码器分辨率折合 0.01 mm、采样周期 $T_s = 1$ ms、$T_d = 0.2$ s，放大倍数为 200，输出端噪声达 2 mm；而轴的定位精度要求是 0.2 mm，噪声比信号大一个量级。

解决办法是给微分串一阶低通，工业 PID 的标准写法为

$$C_d(s) = \frac{T_d s}{T_f s + 1}, \qquad \alpha = \frac{T_f}{T_d}, \qquad \omega_m = \frac{1}{\sqrt{T_dT_f}}, \qquad \varphi_{\max} = \arcsin\frac{1-\alpha}{1+\alpha} \tag{37-28}$$

α 越小，滤波越弱、高频噪声放大越厉害；α 越大，相位超前越少、微分越接近失效。$T_d = 0.2$ s、$T_f = 0.02$ s（即 $\alpha = 0.1$）时，$\omega_m = 15.8$ rad/s、$\varphi_{\max} = 54.9^\circ$，高频增益从 200 降到 $T_d/T_f = 10$，噪声压到 0.1

mm，仍在精度预算之内。这就是工程上常说的“微分增益 $N=10$”，$N=1/\alpha$。

符号上有一点要提前说明。这里的 $\alpha=T_f/T_d<1$ 是**微分滤波比**，与第 43 章 §43.2.3 的**超前比** $\alpha=p/z>1$ 互为倒数：两处公式长得几乎一样（这里是 $\arcsin\frac{1-\alpha}{1+\alpha}$，那里是 $\arcsin\frac{\alpha-1}{\alpha+1}$），趋势却相反——这里 α 越大相位越少，那里 α 越大相位越多。读到第 43 章若觉得“α 的用法怎么反了”，回看这一条就知道不是笔误，而是两个不同的量共用了同一个字母。

需要提醒的是：滤波会引入相位滞后，α 取到 0.25 时，$\varphi_{\max}$ 只剩 37°，微分对稳定性的贡献已经不明显，此时不如把 T_d 降下来、改用别的结构。本书第 44 章会给出 N 的完整选取表。

T_f 的具体影响不能只靠直觉外推，扫一遍最可靠。在 §37.4.7 的设计上（$K_p=13.4$、$K_d=1.4$，微分先行、无闭环零点）取六个 T_f：0.002 s 时 $M_p=4.56\%$、$t_r=0.181$ s、$t_s=0.511$ s；0.005 s 时 3.96%、0.181 s、0.499 s；0.01 s 时 2.94%、0.181 s、0.468 s；0.02 s 时 0.88%、0.181 s、0.298 s；0.05 s 时 0.00%、0.183 s、0.549 s；0.10 s 时 0.44%、0.213 s、0.938 s。

三个结论：t_r 几乎不随 T_f 变（0.181–0.213 s），说明滤波不改变“起步快慢”，只改变“停下来时晃不晃”；T_f 从 0.002 s 增到 0.02 s，超调从 4.6% 压到 0.9%、t_s 从 0.51 s 缩到 0.30 s，闭环主导极点实部从 -8.2 移到 -13.0，这是“适度滤波反而更稳”的少数情形；再往上加，微分被滤掉，$T_f=0.1$ s 时 t_s 涨到 0.94 s，系统退化成近似纯比例。**最优区间在 $T_f\approx T_d/5$**（本例 $T_d=0.1045$ s，$T_f=0.02$ s 即 $\alpha=0.19$），此时式 (37-28) 的相位超前峰值频率 $\omega_m=21.9$ rad/s，与穿越频率 16.0 rad/s 同量级——超前量正好用在最需要它的地方。

37.9.4 输入整形：用两个脉冲换零超调

如果指标要求“又快又不许超调”，且对象模型足够准，可以在闭环之外再加一级**输入整形**。零振动（ZV）整形器把一次阶跃拆成两次相隔半个振荡周期的小阶跃：

$$A_1=\frac{1}{1+K_z},\qquad A_2=\frac{K_z}{1+K_z},\qquad K_z=\exp\left(-\frac{\zeta\pi}{\sqrt{1-\zeta^2}}\right),\qquad t_2=\frac{\pi}{\omega_d}\tag{37-29}$$

第一脉冲激起振荡，第二脉冲在恰好半个周期后把振荡抵消。对 $\zeta=0.316$、$\omega_n=3.162$ rad/s 的标称系统，$K_z=0.3509$、$A_1=0.740$、$A_2=0.260$、$t_2=1.047$ s。整形后仿真得 $M_p=0.00\%$、$t_r=0.610$ s、$t_s=0.928$ s；与未整形的 35.09%、0.425 s、3.536 s 相比，超调清零，调节时间缩短 74%，代价是上升时间放慢 44%。

代价是**对模型误差极其敏感**。表 37-12 把设计值固定、让真实参数偏离，观察残余超调。

表 37-12　ZV 整形器的参数敏感性（标称 $\zeta=0.316$、$\omega_n=3.162$ rad/s）

参数偏差	-20%	-10%	$+10\%$	$+20\%$
ζ 偏差后的 M_p /%	6.58	3.11	0.97	1.64
ω_n 偏差后的 M_p /%	11.14	5.65	1.98	3.91

两条规律值得记住：其一，**偏差方向不对称**，参数被低估比被高估危险得多，ω_n 低估 20% 会带来 11.1% 的残余超调，高估 20% 只有 3.9%；其二，**频率误差比阻尼误差更致命**，因为 t_2 直接由 ω_d 决定，频率错则脉冲时刻错，抵消条件整个失效。

因此 ZV 整形的适用面很窄：点位运动、扫描振镜、硬盘磁头这类“模型稳定、要求快、允许离线标定”的场合非常合适；温度、液位、成分这类参数随工况漂移的过程控制则不应使用。工程上若必须用，会选对频率误差更宽容的 ZVD（多一个脉冲、抑制一阶导数灵敏度）或 EI（极不灵敏）整形器，代价是响应更慢。

37.9.5 二自由度：把跟踪与抗扰分开

前面所有方案都在一个闭环里同时兼顾“跟得快”和“扰得小”，这本身是一种妥协。二自由度结构的思路是：用两条通路分别处理设定值与扰动。

最轻量的一种是**设定值加权**，工业 PID 里常写作

$$u(t) = K_p\left[\beta r(t) - y(t)\right] + K_i\int_0^t \left[r(\tau) - y(\tau)\right]\mathrm{d}\tau - K_d\frac{\mathrm{d}y(t)}{\mathrm{d}t} \tag{37-30}$$

$\beta \in [0,1]$ 只影响设定值通路：$\beta < 1$ 相当于在跟踪时“软启动”，超调下降，而扰动通道（y 的反馈部分）完全不变，抗扰能力不受影响。这比降低 K_p 高明：后者会把抗扰一起削弱。$\beta = 0$ 时系统对阶跃给定等价于“纯扰动抑制”结构，超调为零但跟踪变慢。

代价是设定值通路的等效增益被压到原来的 β 倍，若回路中没有积分环节，稳态会出现与 β 相关的残差，所以这个手段几乎总是和积分项一起用（型别不低于 1 时稳态误差才与 β 无关）。本章的 $G_0 = 10/[s(s+2)]$ 本身含一个积分，正好满足这个条件。

更强的一种是**参考前馈**：在闭环外串 $G_0^{-1}(s)$ 并加低通滤波，使 $r \to y$ 的传函接近 1。理论上可做到“给定怎么变、输出就怎么跟”，但 G_0^{-1} 往往非真（分子阶次高于分母），必须加滤波，且对模型误差敏感，与 ZV 的局限类似。

这两种手段都在闭环内部或紧邻闭环，与 ZV 的“闭环外整形”不同。选择顺序建议为：先试设定值加权（改动最小、鲁棒性最好），再考虑前馈（需要较准的模型），最后才是输入整形（需要很准的模型）。前馈的完整设计在第 46 章，本章只需建立“不要用一个自由度硬扛两个目标”的观念。

37.9.6 五种方案的横向对比

把本章验证过的五种方案放在同一张表里，指标口径统一为 ±2% 带、12 s 窗口，对象均为 $G_0 = 10/[s(s+2)]$。PD 各项按标准形式（对误差微分）计算，微分先行方案的差异见 §37.9.2。

表 37-13　五种方案对比

方案	M_p /%	t_r /s	t_s /s	主要代价	适用场合
纯比例 $K_c = 1$	35.09	0.425	3.536	快慢不可兼得	基线、粗定位
PD，$K_p = 1$、$T_d = 0.2$ s	10.42	0.474	1.676	零点抬高 2.7 个百分点	通用伺服
PD，$K_p = 1$、$T_d = 0.4$ s	1.61	0.455	0.678	尺度受 ω_n 限制	低超调场合
PD，$K_p = 3$、$T_d = 0.3$ s	4.77	0.189	0.828	控制量峰值大	又快又稳
ZV 整形 + 比例	0.00	0.610	0.928	模型偏差敏感	精密点位、扫描

从表 37-13 可以读出一个反直觉但重要的事实：**没有任何一行在所有列上占优**。ZV 的超调为零、调节时间 0.928 s 也优于两条 $K_p = 1$ 的 PD，但上升时间 0.610 s 是全表最慢；$K_p = 3$、$T_d = 0.3$ 的上升最快（0.189 s），超调却比 $K_p = 1$、$T_d = 0.4$ 高 3 个百分点。所谓“优化”，本质是在给定约束下选一个可接受的折中点，而不是找一个全能解。

改进的优先级建议如下，按投入产出比排序：

1. **先调 K_p 定尺度。** 令 $\omega_n \approx \sqrt{10K_p}$ 满足 t_r 需求，此时超调通常远超指标——这是预期内的，不要在这一步纠结。

2. **再加 T_d 定形状。** 把 ζ 提到 0.6–0.8，同时按式 (37-26) 校核零点：$\rho < 5$ 时超调会比二阶公式高 2–5 个百分点，需要用仿真确认。
3. **然后加微分滤波。** 把噪声放大倍数压到 T_d/T_f 的可接受范围。这一步不改善指标，但决定方案能否落地。
4. **最后考虑设定值加权、前馈或输入整形。** 前两者改善跟踪，后者只在模型可靠且指标极紧时使用。

还有一个常被忽略的方向：**改对象**。把丝杠换成更小的导程、把联轴器换成高刚度、把编码器从增量式换成绝对值式，往往比在控制器里做十轮优化更有效。控制工程师的价值不在于把 PID 参数调到小数点后三位，而在于判断“这个指标该由控制解决，还是该由机械解决”。

37.10 工程落地

前面所有曲线都来自理想模型。真实的轴上有噪声、有间隙、有摩擦、有延迟，指标会明显变差。本节把“仿真通过”到“验收通过”之间的工作补上。

37.10.1 仿真与现场之间的五个断点

按影响从大到小排列：

1. **纯延迟**。计算、通信、功率级、滤波都会带来延迟，合计常在 20–60 ms。按 §37.4.5 的折算，40 ms 延迟大约等价于把上升时间要求放宽 8%–12%，或把相位裕度吃掉 $2\pi f \times 0.04$ 弧度。
2. **量测噪声与量化**。编码器分辨率有限，差分得到的速度信号更粗糙；噪声进入微分项后被放大（§37.9.3），表现为输出抖动、驱动器发热。
3. **执行器死区与饱和**。小于死区的控制量不产生运动，导致“最后一段爬不进去”；饱和则让大阶跃的等效增益下降，响应变慢并可能引发积分饱和。
4. **摩擦与间隙**。静摩擦造成启动滞后，间隙造成反向时的空程，两者都会让阶跃响应出现“平段”。
5. **参数漂移**。负载质量、传动刚度、油温都会随工况变化，§37.6.4 的表 37-10 已经说明 ±20% 的参数误差足以让超调翻倍。

这五项里，只有第 5 项靠鲁棒设计解决，前四项必须在现场测量并写进模型。**没有实测数据的调参，本质上是在猜。**

37.10.2 一次完整的现场阶跃试验

以本章的伺服轴为例，取 $T_s = 0.02$ s（50 Hz），注入幅值 10 mm 的阶跃（满行程的 10%），同时记录指令、输出、控制量三路信号。为了看清断点的影响，在仿真里叠加与现场同量级的非理想因素：噪声 0.01、量化 0.02、死区 0.02、延迟 2 拍（40 ms）。结果如图 37-11。

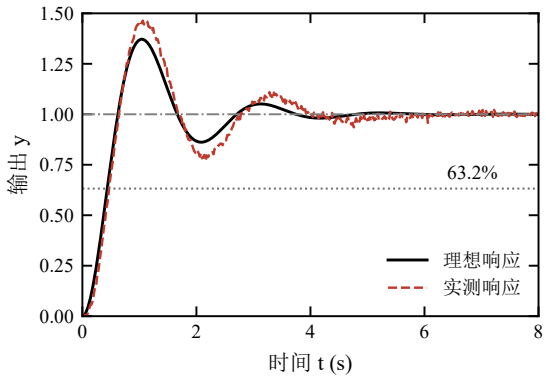

图 37-11　理想响应与含非理想因素的实测响应对比

理想响应（同一采样周期 $T_s = 0.02$ s 的离散仿真）$M_p = 37.19\%$、$t_r = 0.418$ s、$t_s = 3.56$ s；叠加非理想因素后变成 $M_p = 45.87\%$、$t_r = 0.401$ s、$t_s = 6.08$ s。三项变化各有其主因：

- **超调增加 8.7 个百分点**，主要来自死区与延迟。死区使系统在接近目标时“少给一点”，随后由惯性补上，形成额外过冲；延迟则让修正动作总是晚一拍。
- **上升时间几乎不变**，因为大信号段死区与量化的影响相对很小，这一段由增益与惯量决定。
- **调节时间增加 71%**，而且这个数对带宽极其敏感：同一组数据，带宽取 ±5% 时 $t_s = 4.78$ s，取 ±8% 时回到 3.56 s。原因是死区与量化在平衡点附近形成小幅极限环，尾部始终在 ±2% 带边缘来回穿越，按“最后一次越出”计数就被一路拖后。仅“±2% 还是 ±5%”这一条口径，就足以决定验收结论。
- **稳态值偏离 0.33%**，来自死区造成的稳态残差，量级与死区宽度同阶。

这也从反面说明为什么不能用“首次进入”定义 t_s：在这组数据里，输出在 0.64 s 就首次进入 ±2% 带，而此时峰值还没到，后面还要冲高 46%。用首次进入会把 6 s 的系统判成 0.6 s，误差十倍。

现场试验建议按四步做，每步都记三路信号，见表 37-14。

表 37-14　现场阶跃试验的四步

步骤	阶跃幅值	目的	观察重点
静态标定	0.1% 行程，多点	测死区、间隙、分辨率	输出是否有“不动区”
小阶跃	1%–2% 行程	测线性度与噪声	是否被噪声淹没
中阶跃	10% 行程	测 M_p、t_r、t_s	与仿真偏差
极限阶跃	50%–100% 行程	测饱和与抗饱和	控制量是否长时间顶格

小阶跃最容易被跳过，但它恰恰是判断“能不能做精密定位”的依据：如果 1% 行程的阶跃响应完全看不出形状，说明噪声或死区已经大于该幅值，此时讨论超调百分比没有意义。

37.10.3 把指标口径写进验收文件

同一台设备，用不同口径可以得出“合格”与“不合格”两种结论。因此验收文件必须把六件事写死，缺一项就会在验收会上扯皮。表 37-15 是一份可直接套用的条款模板。

表 37-15　时域指标验收条款模板

要素	必须写明的内容	常见争议
激励	阶跃幅值、起点、方向、是否回零	用 1% 还是 50% 行程
误差带	绝对带宽（如 ±0.2 mm）或相对带宽（±2%），二者取严	只写“±2%”导致小行程过宽
测量点	编码器、光栅尺还是负载端	传动间隙是否计入
延迟	是否计入 t_r、t_s，从指令发出还是从控制量变化起算	通信延迟归属
工况	负载、温度、供电电压、预热时间	冷机与热机差异
判据	重复次数、取平均还是取最差、允许的超调上限	三次两合格还是全合格

经验做法是“三次取最差 + 绝对带宽优先”。三次取最差能过滤偶发干扰，又不至于像取平均那样掩盖一致性差的问题；绝对带宽优先则避免小行程时相对带宽失真——10 mm 行程的 ±2% 是 0.2 mm，1 mm 行程的 ±2% 只有 0.02 mm，后者往往已经小于编码器分辨率。

把这些要素写成条款，应该是这个形状（以本章伺服轴为例）：

> 在空载、25 ℃、预热 30 min 的条件下，施加 0→10 mm 正向阶跃（满行程的 10%），以负载端光栅尺为测量点，采样周期 2 ms。超调量以实际稳态值为基准，不超过 5%；上升时间按 10%→90% 定义，不超过 0.10 s；调节时间按 ±0.2 mm 绝对带定义，自阶跃指令发出时刻起算，不超过 0.50 s；稳态误差不超过 0.02 mm。每工况重复三次，三次全部合格判为通过，任一次超差即判不通过。

这段文字里没有一个形容词，全部是可测的量。反过来，条款若写成“响应快、超调小、稳定可靠”，验收就变成了比谁嗓门大。

37.10.4 五层限幅与保护

再好的参数，只要有一处限幅没做，现场就可能撞机。按信号流方向，五层限幅缺一不可：

1. **给定限幅**：限制阶跃幅值与变化率，防止操作员误输入。
2. **控制量限幅**：按执行器能力设，且限幅后必须做抗饱和处理。
3. **积分限幅**：单独限制积分项，防止长时间偏差累积。
4. **位置软限位**：在行程两端留出减速区，接近时按剩余距离降速。
5. **超时与超差保护**：位置偏差持续超限或运动超时，立即断使能并报警。

五层里最容易被忽略的是第 2 层的“限幅后处理”。只做 $u = \mathrm{sat}(u)$ 而不做抗饱和，在大阶跃时积分会一路涨到饱和值，等输出到位后需要很久才能退出来，表现为“到位后继续冲、然后慢慢回调”。这个现象在第 44 章会详细分析，这里只需记住：**限幅与抗饱和是一对，不能只做一半。**

限幅值定在哪里，不能凭“留点余量”拍板，要看控制量的实际峰值。取 §37.4.7 的 PD 设计（$K_p = 13.4$、$T_d = 0.1045$ s），只改微分滤波时间常数 T_f，实测控制量峰值如下：

T_f (s)	控制量峰值	M_p (%)
0.050	41.41	39.92
0.020	83.42	22.45
0.010	153.43	18.25
0.005	293.46	17.21
0.002	713.55	16.79

T_f 缩小 25 倍，控制量峰值涨了 17 倍（41→714），超调只从 39.9% 降到 16.8%。**这笔交易极不划算**：从 0.01 s 再往下压到 0.002 s，超调只降 1.5 个百分点，执行器却要多扛 4.6 倍电流。换言之，一个没做滤波限幅的 PD，在阶跃瞬间向驱动器要的电流是稳态值的上百倍——现场看到的“过流保护一跳、系统就复位”，多半不是控制器算错了，而是这里没设防。

把同样的回路加上饱和，扫描限幅值（$T_f = 0.01$ s，$T_s = 1$ ms）：

限幅	控制量峰值	M_p (%)	t_r (s)	t_s (s)
不限	153.43	17.40	0.070	0.404
±100	100.00	14.00	0.078	0.405
±40	40.00	4.72	0.122	0.407
±20	20.00	2.46	0.161	0.406
±10	10.00	1.93	0.185	0.286
±5	5.00	1.72	0.206	0.329
±2	2.00	1.31	0.271	0.441
±1	1.00	1.51	0.369	0.585

这张表会颠覆很多人的直觉：**加上限幅，超调反而变小了。** 原因是限幅最先削掉的正是那个 153 的微分冲击，控制量一开始就没那么猛，峰值自然低。代价全部记在上升时间上——± 40 时 t_r 从 0.070 s 拉到 0.122 s（慢 74%），± 1 时 0.369 s（慢 5.3 倍）。到 ± 2 以下，超调已经不再下降（1.31% 触底后回到 1.51%），说明此时决定形状的已经不是控制器，而是限幅器本身；继续调参数不会有效果。

由此得到两条实操规则。第一，**报指标必须连带声明限幅值**：同一套 K_p、T_d，不限幅报 17.4%、± 40 报 4.72%、± 5 报 1.72%，三个数都“真实”，但不可比。第二，**限幅值应定在“刚好不削掉正常响应的峰值”之上**：本章设计若无特殊理由，取 ± 40 附近即可，再低就把动态让给了限幅器，再高则失去保护意义。至于 t_s 在表中不单调（0.404→0.405→0.407→0.286→0.329→0.441→0.585），原因与 §37.7.7 所述相同：它由“最后一次越出”决定，限幅改变了振荡相位，越带时刻就跟着跳。

37.10.5 调试记录：让结果可复现

控制调试最大的浪费是“上次调好了，这次复现不出来”。原因通常不是参数丢了，而是当时的环境没记。每次改动至少记录表 37-16 中的七项。

表 37-16　调参记录的最小字段集

字段	示例	为什么要记
日期与版本	2026-10-20，固件 1.3.2	区分代码变更影响
参数组	$K_p = 1.0$、$T_d = 0.2$ s、$T_f = 0.02$ s	复现的前提
采样周期	$T_s = 0.02$ s	决定离散化误差
负载与温度	空载，25 ℃	参数漂移的解释
激励	10 mm 阶跃，正向	指标与激励绑定
三项指标	45.9%，0.40 s，6.08 s	对比基线
异常现象	到位后有 3 次抖动	下次排查的线索

记录不需要多复杂，一张表、七列就够。它的价值在三个月后：当客户说“比以前慢了”，你能立刻判断是参数变了、负载变了，还是代码变了。

以 §37.10.2 的实测为例，一条合格的记录应该长这样：$K_p = 1$、$T_d = 0$（纯比例），$T_s = 20$ ms，空载 25 ℃，正向 10 mm 阶跃，测得 $M_p = 45.87\%$、$t_r = 0.401$ s、$t_s = 6.080$ s，异常现象是“到位后仍有约 6% 的往复抖动”（末 2 s 峰峰值 0.064，折合 0.64 mm）。

同一组参数换随机种子重复五次，结果并不是同一个数：t_s 在 6.08–7.80 s 之间，极差 1.720 s（相对 23.9%）；M_p 在 45.87%–47.64% 之间，极差 1.76 个百分点；t_r 倒是稳定在 0.400–0.419 s。所以记录里必须写“这是第几次、五次的范围是多少”——**只报一次结果，等于报了一个随机样本**。

三条记录纪律值得写进班组规定。第一，**记录每一次，不是记录最好的一次**：只留最优值，等于把系统的分散度藏起来，下次复现必然失败。第二，**参数与激励必须成对出现**：$M_p = 45.9\%$ 单独没有意义，配上“10 mm 正向阶跃”才是可比的数据。第三，**异常现象照原话记**：“响了三下”“到位后往回弹一点”这种描述，比事后补一个“疑似振荡”更有排查价值。

这五次重复还暴露了一件事：t_r 稳定而 t_s 分散，说明分散度来自“最后一次越出”这一判据本身。噪声让曲线在 $\pm 2\%$ 带边反复进出，越带时刻就带上了随机性。若验收只卡 t_s，就必须规定重复次数与判定规则（三次全过才算过），否则同一台设备能同时被判合格与不合格。

还有一条常被忽略：记录里要写**当时改了什么**。调参是连续的过程，若只记结果不记动作，最后无法回答“是哪一步起了作用”。最小做法是在表下加一行“本次改动”，一行字即可。

37.10.6 三条工程经验

第一，先用小信号定噪声底，再用大信号定动态。 小阶跃看不出形状，说明噪声或分辨率不足，此时任何调参都是在放大噪声。

第二，把 80% 的时间花在测模型上。 延迟、死区、间隙这三个数一旦测准，参数往往一次就到位；测不准则要反复试。

第三，指标不达标时先问“是谁的责任”。 若 t_r 受限于执行器饱和或结构刚度，改控制器无用；若 t_s 受限于噪声与死区，改参数只能缓解。控制工程师要能拿出数据说明瓶颈在哪，而不是无限调参。

三条经验的共同点，是**先把不确定度压下去，再谈优化**。回路里能改的只有控制器，而指标的上限由模型、执行器与噪声决定；这三样没测清之前调参数，等于在一把不知道刻度的尺子上做微调。

以本章的数据为例：输出叠加标准差 0.01（满量程的 1%）的噪声，t_s 就从 3.56 s 变成 6.08 s，五次重复的极差 1.72 s（24%）；执行器死区 0.05 带来 1.4% 的固定偏置，死区加倍，偏置几乎也加倍；延迟从 0.05 s 增到 0.10 s，M_p 从 46.6% 涨到 60.8%。这三件事没有一件能靠“再调一轮 PID”解决。反过来，把噪声滤掉、把死区测准、把延迟压到 0.03 s 以内，同一套参数立刻好用——这就是“80% 的时间花在测模型上”的真实含义。

37.11 优缺点与适用边界

本章用 ζ、ω_n 两个数把闭环行为讲清楚了，代价是丢掉了很多信息。这一节划清能力边界，避免把二阶结论套到不该套的对象上。

37.11.1 二阶近似的成立条件

把高阶系统当成二阶处理，依赖三条前提，任何一条不满足，式 (37-6) 给出的超调就不再可信：

1. **存在一对主导极点**，其余极点的实部至少是主导极点的 5 倍远。§37.4.4 验证过：在 $1/(s+1)$ 上再串一个 -50 的极点，t_r 只变 0.01%、t_s 只变 0.5%；极点移到 -10（10 倍远）时 t_s 偏大 2.7%；移到 -2（仅 2 倍远）时 t_r 与 t_s 都偏大约 18%。“5 倍”这条经验线的代价就是约 5% 的指标误差。
2. **没有靠近虚轴的零点**。左半零点会抵消超调（$\rho \geq 2$）或抬高超调（$\rho < 1$），右半零点直接把响应拉反（表 37-7 中 $a = 0.3$ 时下冲 -50.7%）。
3. **延迟足够小**。τ 小于上升时间的 2% 时可忽略；超过 5% 就必须把 $\mathrm{e}^{-\tau s}$ 显式放进模型；中间的 2%–5% 地带至少要用仿真确认超调（依据见 §37.4.5 的折算表）。

三条同时满足的系统并不多。伺服位置环、直流电机转速环、部分温度回路是典型适用对象；多容液位、精馏塔、大惯性热工对象通常不满足，需要降阶或直接上频域方法。

三条前提的违反成本并不相同，可以排个序。极点间距不足最“温和”：2 倍远时 t_r、t_s 各偏大约 18%，形状还对，只是数值不准。零点最“凶”：$\rho < 1$ 时超调能从 16% 抬到 48%，右半零点直接把起始方向拉反。延迟最“隐蔽”：t_r 甚至变小，看起来更好，M_p 与 t_s 却成倍恶化（§37.4.5）。

所以现场复核的顺序应当是：**先看有没有延迟，再看有没有靠近虚轴的零点，最后才检查极点间距**。前两条会改变结论的方向，第三条只改变数值大小。顺序反了，就会在“指标偏大 18%”这种小问题上反复纠缠，却漏掉真正让系统振起来的那个延迟。

37.11.2 时域指标的固有局限

五个指标都是**在单位阶跃下定义的**，这决定了它们只能回答很窄的一类问题。表 37-17 列出它们没说的事。

表 37-17　时域指标没有覆盖的内容

指标没说的	后果	该看什么
抗扰能力	跟踪好不等于抗扰好	扰动阶跃响应、灵敏度函数峰值
控制量大小	指标合格但执行器过载	$u(t)$ 峰值、饱和时间占比
鲁棒性	标称指标好，参数一漂就振	§37.6.4 的摄动表、增益/相位裕度
跟踪非阶跃信号	斜坡、正弦、随机信号的误差	型别与误差系数、带宽
多变量耦合	单回路合格，联动后互相激励	相对增益阵列、耦合分析
非线性行为	死区、饱和、摩擦下的表现	描述函数、§37.10 的实测

其中最容易出事的是“鲁棒性”一行。表 37-13 里 ZV 整形那一行就是典型：标称 M_p 为零，参数只漂 10%，残余超调就升到 3.1%（ζ）或 5.7%（ω_n）；漂 20% 则到 6.6% 与 11.1%（表 37-12）。**指标是标称点的快照，不是全工况的保证。**

第二容易出事的是“控制量大小”一行。§37.10.4 那张表里，同一套 K_p、T_d 在限幅 ± 1 与不限幅两种情况下，M_p 都小于 18%，看上去都合格；但不限幅时控制量峰值 153，执行器根本撑不住。指标合格而执行器过载，是验收环节最常见的一类漏判——所以验收单上除三项时域指标外，必须再加一行“控制量峰值与饱和时间占比”。

37.11.3 什么时候必须换工具

出现下列任一情况时，本章的方法只能作为初值，不能作为结论：

- **右半平面零点**（非最小相位）：超调、下冲与上升时间的关系完全改变，二阶公式失效，需要看波特图与根轨迹。判据是零点到虚轴的距离与闭环带宽同量级——表 37-7 中 $a = 0.3$ 时下冲已达 -50.7%，此时“超调”这个词本身就不适用了。
- **延迟超过上升时间的 5%**（对一阶对象约为主导时间常数的 11%）：低于 2% 可忽略，2%–5% 要用仿真确认，超过 5% 则 Padé 近似阶次不够会低估相位损失，应直接用频域或 Smith 预估类结构（§37.11.1、§37.4.5）。
- **强非线性主导**：摩擦引起的爬行、饱和引起的极限环，线性模型给不出正确结论，需要描述函数或直接仿真。量级参照 §37.8.6 与 §37.10.4：死区 0.1 就留下 9.3% 的稳态偏置，限幅压到 ± 1 时上升时间慢 5.3 倍。
- **多输入多输出且耦合强**：单回路整定会互相打架，需要解耦或直接做多变量设计。
- **指标含频域或随机成分**：如“跟踪 5 Hz 正弦、误差小于 0.1 mm”，必须转成带宽与灵敏度指标。

五条里有三条可以用本章的仿真脚本当场量出来：延迟用阶跃法测，死区用正反向小阶跃测，饱和用不同幅值阶跃测。测完再决定要不要换工具，比凭对象名称判断可靠得多。

这些正是后续章节的入口：稳定性判据、根轨迹与频域方法在第 38–43 章，PID、串级、前馈与大延迟补偿在第 44–47 章，状态空间与最优控制在第 51–65 章。

37.11.4 适用性快速判定

现场拿到一个新对象，可以用下面五个问题快速判断本章方法能不能直接用。任一项答“否”，就按 §37.11.3 换工具。

1. 阶跃响应是否单调上升到稳态，或者只有一段明显振荡？——有持续的多频振荡说明高阶模态参与，不能只取一对极点。

2. 从阶跃开始到输出首次动起来，滞后是否小于上升时间的 5%？——超过则延迟不可忽略（2%–5% 之间先用仿真确认）。
3. 正反向阶跃的响应是否近似对称？——不对称说明间隙或摩擦主导。
4. 阶跃幅值加倍后，超调与上升时间是否基本不变？——明显变化说明已进入饱和区，线性模型只在小区间成立。
5. 参数漂移 ±20% 后，超调是否仍在可接受范围？——不满足则需按 §37.6.4 重做鲁棒性校核。

这五个问题不需要任何仪器以外的工具，一台示波器、几次阶跃就能答完。它们比任何公式都更能决定“该不该用二阶模型”。

37.11.5 本章在全书中的位置

本章是时域篇的入口，作用是建立三件事：指标的确切定义、指标与参数的定量关系、指标背后的结构限制。后续章节在这三条上继续加深：

- 第 38–43 章先补齐判据与工具（Routh、Nyquist、根轨迹、频率响应、稳态误差、校正装置），本章的 PD 算例是它们的被控对象；
- 第 44–47 章才把控制器从比例扩展到 PID 及其变体（串级、前馈、Smith 预估），本章的 K_p、T_d 是它们的特例；
- 第 51–65 章的状态空间与最优控制处理多变量与高阶对象，本章的降阶判据是它的前置条件。

一句话总结本章的定位：**它不教你设计控制器，它教你判断“这个指标能不能达到、代价是什么”。** 这个判断力，比记住任何一个整定公式都更耐用。

37.11.6 与时域、频域、状态空间的分工

控制理论有三套常用语言，本章只用了其中一套。把分工说清楚，才知道什么时候该翻到下一章。

你面对的问题	首选语言	本章能提供什么	本章给不了什么
验收、合同、现场沟通	时域	全套指标定义与算法	多变量指标
稳定性够不够、延迟能忍多少	频域	临界延迟、PM 与 ζ 的换算	精确的奈奎斯特判据
控制器结构怎么选（超前、滞后、PID）	频域	指标到 ζ、ω_n 的目标	校正装置的具体参数
多输入多输出、耦合强	状态空间	单回路初值、降阶判据	解耦、极点配置
非线性、饱和、摩擦	时域仿真/描述函数	非理想因素的实测方法	极限环的解析预测
指标含随机成分、噪声	频域/统计	噪声对 t_s 的影响量级	功率谱设计

三套语言不是替代关系，而是“粗调—精调—校核”的关系。典型工作流是：先用本章的时域指标把目标定下来（要多快、允许多大超调），再用频域方法设计校正装置并检查裕度，最后回到时域仿真做验收。反过来，只做频域设计不做时域验收，容易出现“裕度很漂亮、超调却超标”的情况——因为裕度是线性、小信号、频域的指标，而验收看的是大信号、时域的峰值。

对本书的读者，建议的学习顺序是：本章（时域指标）→ 第 38–41 章（稳定性判据与频域）→ 第 43–44 章（校正与 PID）→ 第 45–47 章（串级、前馈、Smith）→ 第 51–65 章（状态空间与最优控制）。先把“指标”这把尺子握稳，后面每学一种方法，都能用它量一量“到底改善了多少”。没有这把尺子，学再多方法也只是记住一堆公式。

37.12 Python 仿真代码

本章所有数字都可用 `code/ch037_sim.py` 复现，图由 `code/ch037_figs.py` 生成。核心只有两步：用 `control` 求闭环阶跃响应，用 `simlib.step_metrics` 统一提取指标。下面这段 20 行的脚本足以复现 §37.9 的对比表。

```
import numpy as np
import control as ct
import simlib as sl

# 伺服轴模型 G0 = 10/[s(s+2)]
G0 = ct.tf([10], [1, 2, 0])
t = np.linspace(0, 12, 12000)

# 比例 + 比例微分：Kp 定尺度，Td 定形状
for Kp, Td in [(1, 0.0), (1, 0.2), (1, 0.4), (3, 0.3)]:
    C = ct.tf([Kp * Td, Kp], [1])          # C(s) = Kp(1 + Td*s)
    cl = ct.feedback(C * G0, 1)            # 单位反馈闭环
    _, y = ct.step_response(cl, T=t)
    m = sl.step_metrics(t, y)              # 统一口径：2% 带
    print(f"Kp={Kp:>1} Td={Td:>3}: Mp={m['overshoot']:6.2f}%  "
          f"tr={m['rise_time']:.3f}s  ts={m['settling_time']:.3f}s")
```

输出与表 37-13 逐项对应：

```
Kp=1 Td=0.0: Mp= 35.09%  tr=0.425s  ts=3.536s
Kp=1 Td=0.2: Mp= 10.42%  tr=0.474s  ts=1.676s
Kp=1 Td=0.4: Mp=  1.61%  tr=0.455s  ts=0.678s
Kp=3 Td=0.3: Mp=  4.77%  tr=0.189s  ts=0.828s
```

要在仿真里叠加现场的非理想因素，只需换成离散仿真接口，参数与 §37.10.2 一致：

```
# 噪声 0.01、量化 0.02、死区 0.02、延迟 2 拍（Ts = 0.02 s）
r = sl.simulate_discrete(G0, 1, Ts=0.02, N=400, noise_std=0.01,
                         quant=0.02, deadzone=0.02, delay_steps=2)
m = sl.step_metrics(r.t, r.y)
print(f"Mp={m['overshoot']:.2f}%  tr={m['rise_time']:.3f}s  ts={m['settling_time']:.3f}s")
```

输出为 `Mp=45.87%  tr=0.401s  ts=6.080s`，即图 37-11 中的“实测响应”。三点使用提示：

- `step_metrics` 的稳态值取末段 2% 长度的均值，因此仿真时长至少要是调节时间的 1.5 倍，否则小阻尼情形会把残余振荡当成稳态（§37.2.3 的陷阱）。
- 延迟用整数拍表示，40 ms 在 $T_s = 0.02$ s 下正好是 2 拍；若延迟不是采样周期的整数倍，需要先做分数延迟近似。
- 死区与量化是有序的：先量化再判死区，顺序反了会让死区看起来比实际小一半。

37.12.1 脚本的五段结构

`ch037_sim.py` 不是把公式堆在一起，而是按“从环节到系统、从连续到离散、从理想工况到非理想工况”的顺序分五段。每段都能单独运行、单独对照正文，改一段不会影响其他段。

第一段：典型环节。 对 $T = 0.5, 1, 2$ s 的一阶环节做阶跃，验证 $t_r/T = 2.19$、$t_s/T = 3.89$ 两个常数。这段的作用是“校准口径”：如果这里算出的比值不是 2.19，说明 `step_metrics` 的插值或稳态估计有问题，后面的数都不必看。

第二段：阻尼比扫描。 固定 $\omega_n = 5$，取 $\zeta = 0.1$–1.5 七个点，把仿真超调与解析式 $\exp(-\pi\zeta/\sqrt{1-\zeta^2})$ 逐行对照。实测的七个点与解析值的偏差都在 0.02 个百分点以内（$\zeta = 0.3$ 时 37.21% 对 37.23%）。这段验证的是“公式没写错”，也是全书 `step_metrics` 的基准测试。

第三段：采样周期与谱半径。 连续闭环与 $T_s = 0.02/0.1/0.2/0.4$ s 的离散闭环并列，同时打印闭环极点模的最大值。谱半径是比指标更早的警报：它接近 1 时，系统已在稳定边界附近。但要注意口径——表 37-8 的谱半径是对“连续闭环传函”整体做 ZOH 得到的，而逐拍仿真用的是“对象与控制器分别离散”的采样系统，两者不是同一个模型。因此谱半径只用来看趋势，不能与表中的 t_s 逐行对应；要判断采样系统的稳定性，应直接对“离散对象 + 离散控制器”求闭环极点。

第四段：延迟稳定域。 对 $G = 2/[(s+1)^3]$ 加 0–2 s 的延迟（三阶 Padé），打印最大极点实部、峰值、终值与超调。这段演示的是“理论稳定 ≠ 可用”：$\tau = 1.5$ s 时最大实部 -0.0032，判据上稳定，响应却在 20 s 内看不出收敛。脚本故意保留这一行，就是为了让读者看到判据与工程直觉的差距。

第五段：工程细节注入。 在 $T_s = 0.02$ s 下依次注入饱和、死区、量化、噪声、延迟，输出与 §37.5.7 的表逐行对应。这段的用法不是“看哪个数最好”，而是“看哪个因素最敏感”：同样的参数，噪声把 t_s 从 3.56 s 推到 6.08 s，延迟把它推到 7.74 s，而死区只改稳态。先解决最敏感的那一项，调参效率最高。

37.12.2 换成自己的对象

脚本把对象集中在 `plant_srv()` 一个函数里，换对象只需改这一处：

```
def plant_srv():
    """把这里换成自己的对象：分子、分母按降幂排列。"""
    return sl.tf([10.0], [1.0, 2.0, 0.0])       # 本章：10/[s(s+2)]
    # return sl.tf([2.0], [1.0, 3.0, 3.0, 1.0]) # 例：2/(s+1)^3
```

换完之后，五段脚本会自动用新对象重算，指标口径不变。三处需要同步检查：

1. **仿真窗口。**第三段写死了 $T = 6$ s，若新对象更慢（例如 $T = 20$ s 的温度对象），必须把窗口放大到 $10/(\zeta\omega_n)$ 以上，否则稳态值会被低估。
2. **采样周期。**第三段的 T_s 列表是按本章对象选的；新对象的 t_r 若为 2 s，$T_s = 0.4$ s 就不算大，应改到 0.05–0.2 s 才有对比意义。
3. **限幅值。**第五段的饱和 ± 0.6 是本章控制量的量级；新对象的稳态控制量若为 5，这个限幅会把系统压得死死的，测出来的不是“饱和影响”，而是“根本推不动”。

37.12.3 四个容易踩的坑

坑一：时间轴不等间隔。 `control.step_response` 在不传 `T` 时返回的是自适应时间点，直接喂给 `step_metrics` 会触发“time values must be equally spaced”。正确写法是先构造等间隔的 `t`，再传 `T=t`。本书所有调用都遵守这一条。

坑二：把末值当稳态。 小阻尼系统的响应在窗口末端可能仍在振荡，`y[-1]` 与真稳态能差 10% 以上。`step_metrics` 取末段均值只是缓解，不能根治；根治的办法是窗口足够长，并用“最后 10% 窗口内峰峰值小于 1%”做二次确认。

坑三：延迟的单位。 `simulate_discrete` 的 `delay_steps` 是拍数，不是秒。T_s 改了而拍数没改，等效延迟就跟着变；反过来，想把延迟从 40 ms 改成 60 ms，要先算 $60/20 = 3$ 拍。这个错误在复制粘贴代码时最容易发生，且现象很隐蔽——指标只是"稍微变差"，不会报错。

坑四：把闭环传函再闭环一次。 `sl.step_data(G, C)` 内部做的是 `closed_loop(G, C)`；若手里已经是闭环传函 $T(s)$，必须用 `ct.step_response(T, T=t)`，否则等于给 $T(s)$ 又套了一层单位反馈。这样稳态值会变成 $T(0)/[1+T(0)]$：$T(0) = 0.909$ 被算成 0.476，M_p 从 24.9% 变成 38.2%。这个坑危险在于曲线形状仍然"像"阶跃响应，只是所有数值都不对，肉眼看不出来。

37.12.4 从本章脚本到后续章节

本章脚本是后续章节的最小骨架。第 38–43 章会在同一对象上加判据与频域校核（`sl.margins`、`sl.bode_data`、`sl.root_locus_data`），第 44 章会把 `C = ct.tf([Kp*Td, Kp], [1])` 换成完整 PID、抗饱和与二自由度结构，第 51–65 章会把 `ct.tf` 换成状态空间，而 `simulate_discrete` 的接口与 `step_metrics` 的口径始终不变。

可复用的只有四件东西，其余都要重写：

复用什么	在哪	后续章节怎么用
指标口径	`step_metrics`	全书统一用 10%→90%、±2%、末段均值
离散仿真环	`simulate_discrete`	只换控制器，非理想因素开关不变
频域数据	`margins`、`bode_data`	第 41 章的裕度验收直接调用
现场因素清单	§37.5.7 的五项	第 44、47 章逐项深入

换句话说，**指标口径与仿真骨架是全书复用的资产，控制器结构才是各章变化的部分**。把这一章的脚本跑通、改对，后面每一章都能省下大量重复工作。

完整脚本还包含一阶时间常数校验（表 37-2）、ζ 扫描（表 37-3）、采样周期与谱半径（表 37-8）、延迟稳定域（表 37-9）四段，运行时只依赖 `numpy`、`scipy`、`control`，单次执行只需几秒。

第38章 线性系统稳定性判据（一）：Routh-Hurwitz与Jury

38.1 动机与直观理解

第 37 章用阶跃响应描述系统“动得怎么样”，但那些指标有一个前提没讲：系统必须先稳。响应发散时，上升时间、超调量、调节时间都失去意义——曲线根本停不下来，谈“停在哪儿”没有对象。因此稳定性判断是经典控制的第一道门，它先于一切性能设计，也先于任何参数整定。

38.1.1 一个从“调增益”开始的事故

某台张力收卷机在空载调试时表现良好，工程师把速度环比例增益从 0.6 调到 2.0，响应快了两倍多，验收顺利通过。换到满卷工况后，卷径增大，折算到电机侧的转动惯量约为空载的三倍，同样一条指令下系统开始持续摆动，张力波动 ±18%，薄膜被拉断。事后从记录曲线读出，摆动周期约 10 s，振幅逐渐增大。

这台机器的回路开环传函约为

$$G(s)H(s)=\frac{K(1+0.05s)}{s(0.02s+1)(0.5s+1)(s+1)} \tag{38-1}$$

工程师只验证了 $K=2$ 时的时域响应，没有算过“这个 K 距离不稳定还有多远”。按本章方法可以算出：空载时该结构（惯性由 0.5 s、1 s 两个时间常数代表）的临界增益为 $K_{\max}\approx 3.30$，$K=2$ 还有余量；惯性放大三倍后（两个机械时间常数改为 1.5 s 与 3 s），$K_{\max}$ 掉到 1.04，$K=2$ 已超出边界 92%，闭环出现实部约 $+0.068$ 的极点对，对应振荡角频率 0.62 rad/s——正是现场看到的 10 s 周期。

这组数不是估的，用本章判据可以一步步算出来。空载时闭环特征多项式为

$$D(s)=0.01s^4+0.53s^3+1.52s^2+(1+0.05K)s+K$$

四阶的两个不等式（式 38-8）中，前一个给出 $0.7956-0.0005K>0$，宽松；后一个整理后是

$$0.000025K^2+0.2416K-0.7956<0$$

解得 $K<3.30$。惯性放大三倍后，系数变成 $0.09,\ 4.59,\ 4.52,\ 1.1,\ 2$（$K=2$）：$a_3$ 涨了 8.7 倍、a_2 涨了 3 倍，而 a_1 与 a_0 几乎没变，后一个不等式的左端从 $+0.312$ 掉到 -19.42。**失稳不是“稍微越界”，而是余量被整个吃掉**——这就是为什么现场看到的是持续增大的摆动，而不是勉强维持的等幅振荡。

这个故事要说明的是一件很具体的事：**系统稳定与否，是结构（阶次、零点、延迟）与增益共同决定的，且增益的安全区间可以被精确算出来**，不用靠试。这正是 Routh-Hurwitz 判据与 Jury 判据要做的事。

38.1.2 为什么不去“解特征根”

闭环稳定性等价于闭环特征方程

$$D(s)=a_ns^n+a_{n-1}s^{n-1}+\cdots+a_1s+a_0=0 \tag{38-2}$$

的全部根都落在左半平面。既然根的位置决定一切，最直接的办法就是解方程。这条路在工程上却有四个绕不开的困难。

第一，**四阶以上没有根式解**。五次及以上多项式的根不能用系数的有限次四则运算与开方表示（Abel-Ruffini），只能数值求根。

第二，**求根对系数极其敏感**。Wilkinson 的经典例子是 $p(s)=\prod_{i=1}^{20}(s+i)$，把 s^{19} 的系数 210 增加 $2^{-23}\approx 1.19\times10^{-7}$（相对变化 5.7×10^{-10}），根就面目全非：原本 $-20,-19,\dots,-1$ 二十个实根，扰动后 -1 到 -10 原地不动，-11 到 -20 那些本来就挤在一起的根则两两并成复根，变成 -20.847、$-19.502\pm \mathrm{j}1.940$、$-16.731\pm \mathrm{j}2.813$、$-13.992\pm \mathrm{j}2.519$ 等等，最大位移 2.81。**系数动了十亿分之一，根动了百分之十七**，相对放大近 3×10^{8} 倍。控制系统系数来自辨识，误差 1% 很常见，是上述扰动的一千万倍，直接求根得到的“稳定”结论并不可靠。这里还要分清一件事：这组扰动根仍在左半平面，判稳结论是对的，错的是**根的位置**——而工程要的恰恰是位置（σ、ζ、t_s 全靠它）。所以 Wilkinson 例子真正的教训是“求根给出的位置不可信”，若极点再靠近虚轴一点，同一个敏感性就会把“稳”翻成“不稳”。

第三，**求根不给参数区间**。设计者关心的不是“当前这组系数稳不稳”，而是“K 能取多大”。数值求根要扫一遍参数才能画出区间，而 Routh 表可以直接给出 K 的解析不等式。

第四，**实现代价**。现场 PLC 或嵌入式控制器上做高阶数值求根，要么依赖浮点库、要么精度不够，而 Routh 表只需要加减乘除，甚至可以在固定点运算里做。

38.1.3 直观图像：根往哪儿跑

理解 Routh 判据最好的入口不是表格，而是根的运动。把增益 K 从 0 慢慢加大，闭环极点从开环极点出发，沿根轨迹移动（根轨迹的完整画法见第 40 章）。只要有一对极点越过虚轴，系统就进入等幅振荡；继续加大，实部为正，响应发散。图 38-1 给出这一过程：左图是 s 平面上的稳定域与三条典型极点轨迹，右图是同一组参数下对应的阶跃响应形态。

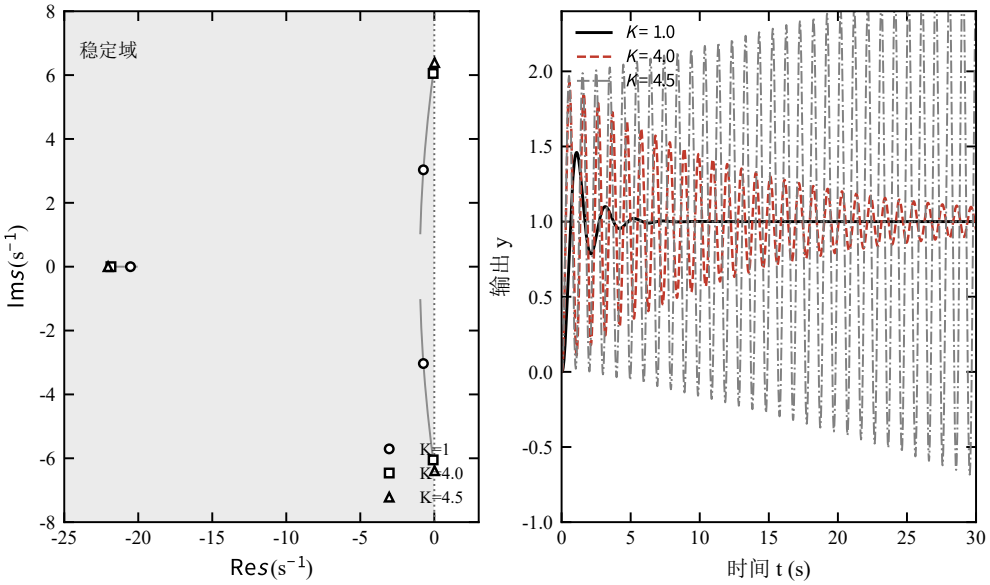

图 38-1　s 平面稳定域与极点穿越虚轴时的响应形态

这张图给出三个直观结论，后面 §38.6 会把它们量化：

- 极点**实部**的符号决定稳定与不稳定，实部的绝对值决定衰减快慢（时间常数 $1/|\mathrm{Re}\,s|$）；
- 极点**虚部**决定振荡频率，虚部越大摆得越快；
- 极点在虚轴上（实部为零）是临界情形，工程上不算稳定——任何微小摄动都可能把它推到右侧。

后面反复出现的示例对象 $10/[s(s+2)]$，其根轨迹尤其简单，值得先看一眼：$s^2+2s+10K=0$ 的根恒为 $s=-1\pm\mathrm{j}\sqrt{10K-1}$，整条轨迹就是 $s=-1$ 这条竖线。K 从 0.1 增大到 100，极点从 -1 竖直上升到 $-1\pm\mathrm{j}31.6$，**始终不越界，只是越摆越快**——增益在这条回路上只买振荡，不买速度（σ 恒为 1，t_s 恒为 4 s）。这也是 §38.4.1 “二阶没有上限”的几何形象。

38.1.4 判据要回答的三个问题

本章的两个判据围绕同一组问题展开，只是分别面向连续域与离散域。

1. **绝对稳定性**：给定一组系数，系统稳定还是不稳定？若不稳，右半平面有几个根？
2. **参数安全域**：把某个可调参数（通常是增益 K）当作符号，稳定域是什么区间？边界值是多少？
3. **相对稳定性**：能不能不满足于“在左半平面”，而是要求“实部小于 $-\sigma$”或“阻尼比大于某值”？这类要求能否也用代数判据回答？

前两个问题由 Routh 表直接回答，第三个问题靠一个变量替换的技巧回答（§38.6），这也是本章在工程上最有价值的部分之一。

这三个问题不是随手列的，它们对应设计流程的三个阶段。第一个在建模完成后立刻要答，答错则后面全部作废；第二个在选工作点之前要答，它给出“还能加到多大”；第三个在验收之前要答，它把“稳定”细化为“衰减够快”。少答一个，就会出现本章开头那种情形：稳定判对了，余量没算，性能没核，设备照样出事故。

三者的答案形态也不同，这一点直接决定了报告能不能被复核。第一个是“稳定 / 临界 / 不稳定，右半平面 m 个根”；第二个是一个区间加一个边界频率；第三个是一个数（$\sigma_{\max}$，或允许的最大增益）。只写“稳定”两个字，别人无法复核；写出 m 与区间，拿计算器就能验。

38.1.5 本章路线与一句话核心

§38.2 建立 Routh-Hurwitz 判据与 Jury 判据的数学表述，包括两种特殊情形（首元为零、整行为零）；§38.3 把它固化成七步设计流程；§38.4、§38.5 用本书的统一示例对象在连续域与离散域各算一遍；§38.6 把“稳定”升级为“相对稳定”；§38.7、§38.8 讨论系数误差与参数怎么调；§38.9 给出区间多项式、Kharitonov 等改进；§38.10 落到数值精度与现场实施；§38.11 说明判据的边界；§38.12 给出可复现代码。

如果只能记住一句话：**Routh-Hurwitz 判据的价值不在“判稳”，而在“把稳定条件写成关于参数的代数不等式”，让设计者在画图之前就知道增益能取多大、余量还剩多少。**

阅读路径建议：要立刻上手算增益区间的，读 §38.1.3、§38.2.2、§38.3、§38.4；做数字控制器的，加读 §38.5 与 §38.10.3；关心鲁棒性的，读 §38.7、§38.9。

38.2 数学原理

本节的目标是把“所有根在左半平面”这个几何条件，翻译成一组只涉及系数的代数不等式。先给必要条件（能快速筛掉一半错误），再给充分必要条件（Routh 表），最后处理两个会让表格“算不下去”的特殊情形。离散域的 Jury 判据在 §38.2.6 平行展开。

两条线索要分开记：必要条件是筛子，Routh 表是尺子，Jury 判据是同一把尺子在单位圆上的版本。筛子只用来省时间，永远不能当作结论；尺子给出的是“根在哪一侧”和“有几个在右侧”，不是一个笼统的“合格”。混用这两者，就会出现 §38.2.1 那个反例的翻版——四个系数全正，却有一对根在右半平面。

38.2.1 必要条件：系数全正

设特征多项式为式 (38-2)，首项系数已归一化为 $a_n > 0$。若它的全部根实部为负，则所有系数必须同号，即

$$a_i > 0, \qquad i = 0, 1, \dots, n \tag{38-3}$$

理由很直接：负实根贡献因子 $(s+\sigma)$、$\sigma>0$，共轭复根贡献 $(s+\sigma)^2+\omega^2$，两者展开后系数全为正，而正系数多项式相乘仍是正系数多项式。反过来，只要出现一个负系数或零系数，立刻可以判定不稳定（零系数对应缺项，缺项时若缺的不是常数项，往往意味着有一对纯虚根或右半平面根）。

这条必要条件的工程价值在于**成本极低**：现场拿到一组辨识系数，先看一眼符号，几秒钟就能排除一批“看起来能调、其实怎么调都不稳”的结构。它也是后面 §38.3 的第一步。

但必要条件不是充分条件。经典反例是

$$D(s) = s^3 + s^2 + s + 6 \tag{38-4}$$

四个系数全为正，把它分解可得 $D(s) = (s+2)(s^2 - s + 3)$，后一个因子在 $s = (1 \pm \mathrm{j}\sqrt{11})/2$ 处为零，右半平面有一对根。必须用 Routh 表才能发现。

这个反例值得多看一眼，因为它说明了“全正”到底约束了什么。三项系数对应根的基本对称函数：$\sum s_i = -1$、$\sum s_i s_j = 1$、$s_1 s_2 s_3 = -6$。根之积为负，要求实根中负的个数为奇数；根之和为负，要求这些实根的总和足够负。两件事可以同时满足——本例的实根是 -2，另一对根是 $1 \pm \mathrm{j}1.658$，和为 -1、积为 -6，全部对得上。**系数全正只保证“对称函数同号”，不保证“根都在左侧”**，因为对称函数对根的位置不敏感：一个右半平面的复根对，配上一个足够左的实根，就能拼出全正的系数。

由此可以读出这条必要条件的三条实用推论。**第一，二阶时它是充分的**：$s^2 + a_1 s + a_0$ 全正意味着 $\zeta\omega_n > 0$、$\omega_n^2 > 0$，直接给出两个左半平面根。这解释了一个常见混淆——“二阶看符号就够”是对的，“三阶看符号就够”是错的。**第二，三阶及以上缺项直接出局**：缺项就是某个系数为零，已经违反必要条件，不必往下算；其机理是缺项往往伴着一对纯虚根，§38.7.3 会用 $s^3 + 2s + 22$ 的实测说明，缺了速度项之后并不是“振而不散”，而是“振着散”。**第三，判符号之前必须把首项化为正**：$D(s) = -s^2 - 2s - 10$ 的系数“全负”，与 $s^2 + 2s + 10$ 是同一个方程，若不先乘 -1 就会误判为不稳。这一步在程序里对应“除以 a_n”，在手算里对应“两边乘 -1”，漏掉的人不少。

38.2.2 Routh 表与判据

把式 (38-2) 的系数按奇偶次排成两行，作为 Routh 表的第 1、2 行：

$$\begin{array}{c|cccc} s^{n} & a_{n} & a_{n-2} & a_{n-4} & \cdots \\ s^{n-1} & a_{n-1} & a_{n-3} & a_{n-5} & \cdots \end{array} \tag{38-5}$$

第 3 行起，每个元素由前两行左上角的 2×2 行列式算出，规则统一为“上一行左邻元素乘本行上方元素、减去两行首元素交叉乘积，再除以上一行首元素”：

$$b_1 = \frac{a_{n-1}a_{n-2} - a_n a_{n-3}}{a_{n-1}}, \qquad b_2 = \frac{a_{n-1}a_{n-4} - a_n a_{n-5}}{a_{n-1}} \tag{38-6}$$

后续各行同法递推，直到只剩一列。表中第一列记为 $(c_1, c_2, \dots, c_{n+1})$。

Routh-Hurwitz 判据：特征多项式全部根在左半平面，当且仅当第一列元素全部非零且同号（通常归一化为全正）。第一列符号变化的次数等于右半平面根的个数（按重数计）。

这条判据有三点必须说清。

第一，**只与第一列有关**。表格其余元素只是递推的中间量，判稳时不必关心；但它们在特殊情形下决定是否要引入辅助多项式。

第二，**符号变化次数等于右半平面根数**，这比“稳定/不稳定”二值结论有用得多。算出“右半平面有 2 个根”，就能判断系统自振来自哪一对极点，而不只是知道“坏了”。

第三，**系数必须是实数且首项正**。若首项为负，先整体乘 -1；若含复系数（极少数含复参数的情形），判据不适用。

Routh 表与 Hurwitz 行列式是等价的两种表述：Hurwitz 判据说的是 n 个顺序主子式全正，理论价值在于给出显式不等式，工程上则用 Routh 表递推更快、更不易算错。图 38-2 给出表的结构与递推路径，注意每一行的元素个数递减，且空缺处补零不影响结论。

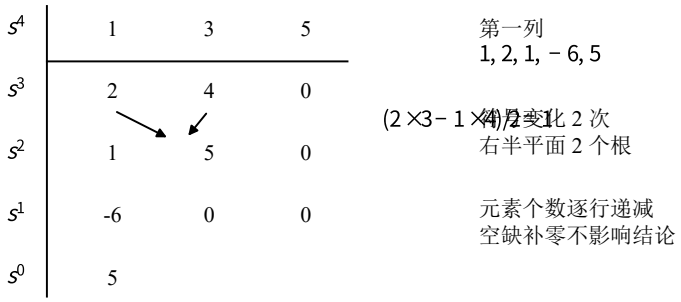

图 38-2　Routh 表的结构与递推规则

理解这张表为什么能判稳，有一个不涉及复变函数的入口：**把多项式按奇偶拆开，Routh 递推就是两个多项式在做辗转相除**。

写 $D(s)=D_e(s^2)+sD_o(s^2)$，其中 D_e、D_o 分别只含偶次项与奇次项。Routh 表的第一、二行正是这两个多项式的系数；第三行及以后，等价于对 D_e 与 D_o 连续做带余除法，每一行是上一次除法的余式（首元已归一），第一列则记录每次除法的首项系数。辗转相除的符号变化次数等于 D_e/D_o 在实轴上的 Cauchy 指标，而这个指标经 $s=\mathrm{j}\omega$ 映射后恰好等于右半平面根数。**“数符号变化”不是经验规则，而是 Sturm 定理的一个特例。**

这个视角解释了两件原本像“技巧”的事。第一，首元为零为什么会让递推中断：商的首项系数为零，相当于除数为零，算法本身失效——所以需要 ε 或乘正因子把除法“救”回来（§38.2.4）。第二，整行为零为什么可以用辅助多项式求导：整行为零意味着两个多项式在此处有公因式，而公因式的根正是对称根（纯虚根，或关于原点对称的实根），求导相当于用公因式的导数跳过这一行，继续往下除（§38.2.5）。

工程上不必每次都想这一层，但它能在两种场合帮上忙：判据实现出 bug 时，知道该往“除法链”上找；遇到特殊情形时，知道 ε 法与求导法都不是凑出来的，而是让辗转相除继续下去的手段。

38.2.3 三阶与四阶的显式条件

工程上七成以上的回路模型不超过三阶，把这两档的结论背下来，多数场合可以不算表直接判。

三阶 $a_3 s^3 + a_2 s^2 + a_1 s + a_0 = 0$（$a_3 > 0$）的全部根在左半平面，当且仅当

$$a_2 > 0, \quad a_1 > 0, \quad a_0 > 0, \quad a_2 a_1 > a_3 a_0 \tag{38-7}$$

最后一项是最容易被忽略的“内项积大于外项积”，它等价于 K 有一个上限。式 (38-7) 对设计极有用：把 a_i 含 K 的表达式代入，直接得到 K 的区间。

四阶 $a_4 s^4 + a_3 s^3 + a_2 s^2 + a_1 s + a_0 = 0$ 的条件是

$$a_3 a_2 > a_4 a_1, \qquad a_3 a_2 a_1 > a_3^2 a_0 + a_4 a_1^2 \tag{38-8}$$

两个不等式中任意一个被破坏都会失稳，前者对应高频振荡，后者对应低频振荡，物理含义不同，这为 §38.7 讨论“哪个参数该退”提供了依据。

把 §38.4.3 的四阶对象在 $K = 2.2$ 处具体算一遍，可以看到表格在实际系数下长什么样。此时的系数为 $0.001,\ 0.072,\ 1.14,\ 2,\ 22$，列表如下：

s^4	0.001	1.14	22
s^3	0.072	2	0
s^2	1.1122	22	0
s^1	0.5758	0	0
s^0	22	0	0

第一列 $0.001,\ 0.072,\ 1.1122,\ 0.5758,\ 22$ 全为正，判稳。用数值求根核对，四个极点为 -49.69、-21.81 与 $-0.253 \pm \mathrm{j}4.499$，确实全在左半平面。这里有一个容易被忽视的细节：$s^1$ 行的 0.5758 不是“随便一个中间量”，它是**该组系数距离失稳还剩多少**的度量。把 K 从 2.2 往上加，这个数单调下降，到 $K \approx 3.09$ 时归零，系统进入等幅振荡——这正是 §38.4.3 算出的 $K_{\max}$。

这个 0.5758 还可以写得更明确。记式 (38-8) 两个不等式的余量分别为 $R_1 = a_3 a_2 - a_4 a_1$ 与 $R_2 = a_3 a_2 a_1 - a_3^2 a_0 - a_4 a_1^2$，把 Routh 递推展开一层就能看出

$$s^1 \text{ 行首元} = \frac{R_2}{R_1} = \frac{0.046112}{0.080080} = 0.5758 \tag{38-8a}$$

也就是说，四阶的 s^1 行元素是**两个余量之比**：分子决定“低频失稳还差多少”，分母决定“高频失稳还差多少”。这解释了为什么两个不等式在工程上的分量并不对等——只有当分子先归零时，s^1 行才变号；若分母先归零，表格会进入“首元为零”的特殊情形（§38.2.4），失稳形态也完全不同。本例中 R_1 不含 K（$0.072 \times 1.14 - 0.001 \times 2 = 0.08008$），把 K 加到 3.0895 时 R_2 先归零而 R_1 仍是 0.08008，所以越界时出现的是一对纯虚根 $\pm \mathrm{j}5.2705$，另两个根落在 -49.56 与 -22.44——一对慢振荡配两个快实根，正是“低频失稳”的实际含义。$\omega = 5.2705$ 也不必解四次方程：把 $s = \mathrm{j}\omega$ 代入特征式，虚部为零给出 $\omega = \sqrt{a_1/a_3} = \sqrt{2/0.072} = 5.2705$，与数值求根完全一致——这正是 §38.4.4 讲整行为零时用辅助多项式求 ω_{osc} 的另一种算法。

三阶情形更直观。对式 (38-18) 列 Routh 表，s^1 行的元素为

$$\frac{1.1 \times 2 - 0.05 \times 10K}{1.1} = 2 - \frac{K}{2.2}$$

$K = 2.2$ 时它恰好等于 1.0，$K = 4.4$ 时归零。也就是说，**第一列元素本身就是余量的线性度量**，单位与增益相同。工程上完全可以把“s^1 行还剩多少”直接读成“增益还能加多少”，不必等到符号翻转才知道到了边界。这条观察是 §38.6 相对稳定度的起点：既然第一列元素随参数连续变化，就可以反过来用它定义“离边界多远”。

38.2.4 特殊情形一：首元为零

递推时若某一行的第一个元素为零，而该行并非全零，除法无定义，表格算不下去。处理办法有两种。

办法一（ε 法）：把零换成充分小的正数 ε，继续递推，最后令 $\varepsilon \to 0^{+}$ 看第一列符号。它的严格性依赖极限过程，手算时容易在 ε 的符号上出错，因此只适合教学演示。

办法二（乘正因子法）：把该行整体乘以一个正数（例如首元为零时，直接看下一个非零元素，或对该行施加 $s \to s + \delta$ 的小位移后再算）。由于乘正数不改变第一列的符号变化次数，结论不受影响。工程实现中更常用的做法是用本章代码里的 `routh_table` 函数（参数 `eps`），取 $\varepsilon = 10^{-8} \cdot \max|a_i|$，并在结果旁边标注“临界”。

需要强调的是：**首元为零往往意味着存在纯虚根或对称根**，此时系统多半处在稳定边界上，判为“临界稳定”最安全，不要因为 ε 取得巧而得出“稳定”。

手算时最容易出错的是“首元为零但该行不全为零”这一种。取

$$D(s) = s^4 + 2s^3 + 2s^2 + 4s + 1$$

四个系数全正，必要条件通过。列表时，s^2 行的第一列恰好算成零，但第二个元素是 1：

s^4	1	2	1
s^3	2	4	0
s^2	0	1	0
s^1	\multicolumn3c待定		

此时不能把整行划掉（那等于丢掉了 1 这个信息，结论会变成“稳定”），而应把首元换成 ε 继续：s^1 行的首个元素含 $-1/\varepsilon$ 项，取 $\varepsilon = 10^{-10}$ 时是一个绝对值达 10^9 量级的负数。第一列于是变成 $+, +, +, -, +$，符号变化两次，判定右半平面有两个根。数值求根给出 $0.0933 \pm \mathrm{j}1.366$ 与 -1.907、-0.280，与判据完全一致。

这个例子说明两件事。第一，**首元为零与整行为零是两类不同的问题**：前者只是除法失效，后者才是对称根出现；把两者混为一谈，会在前者上误判为临界、在后者上误判为稳定。第二，ε 的取值不影响符号变化次数，只要它足够小且为正；手算时可以取 10^{-6} 量级，不必追求精确值，但必须写明“此处用 ε 代替零”，否则复核的人无法判断这一步是否漏算。

38.2.5 特殊情形二：整行为零

若某一行全为零，说明存在**对称于原点的根**，例如 $s = \pm\mathrm{j}\omega$（等幅振荡），或 $s = \pm\sigma$（一正一负实根）。此时用该行的**上一行**构造辅助多项式

$$A(s) = c_1 s^{k} + c_2 s^{k-2} + c_3 s^{k-4} + \cdots \tag{38-9}$$

其中 k 是该上一行对应的 s 的幂次，系数就是该行元素。将 $A(s)$ 对 s 求导得 $A'(s)$，用 $A'(s)$ 的系数替换全零行，继续递推。

整行为零是**最强的失稳信号**：它意味着系统恰好在虚轴上有一对极点（或存在关于原点对称的实根对），任何参数漂移都会让系统进入发散或持续振荡。工程上遇到整行为零，正确的处理不是“补一行算完”，而是立刻报告“该参数组合处于稳定边界”，然后退回设计，把增益降到边界的 50% 以下。

“对称根”有两种，后果不同，值得分开说。**一种是共轭虚根 $\pm\mathrm{j}\omega$**，对应等幅振荡，响应不收敛也不发散；**另一种是对称实根 $\pm\sigma$**（一个在左、一个在右），对应指数发散，比等幅振荡严重得多。两者的区别直接体现在辅助多项式上：把 $A(s)$ 的系数按奇偶拆开，若只有偶次幂有非零系数，$A(\mathrm{j}\omega)$ 是实数，根必为纯虚或纯实；再看

$A(s)$ 的根——若求出的是 $\pm\sigma$（$\sigma>0$ 实数），就是对称实根，此时系统已经在发散，只是 Routh 表的这一行暂时“看不见”。手算时若辅助多项式是 s^2-4 这样的形式，立即判发散，不必继续往下算。

辅助多项式求导后替换全零行，这一步的形式可以记住：若 $A(s)=c_1 s^{k}+c_2 s^{k-2}+\cdots$，则 $A'(s)=kc_1 s^{k-1}+(k-2)c_2 s^{k-3}+\cdots$，替换行的首元是 kc_1。这解释了一个常见疑问——为什么替换后表能继续算：k 是偶数，$kc_1>0$，首元必定与 c_1 同号，符号信息没有丢，只是“乘以了阶数”。本例 $A(s)=s^2+2$，$k=2$、$c_1=1$，替换行首元为 2，与式 (38-23) 中 s^1 行的 2 对得上。

辅助多项式还额外提供一条有用信息：解 $A(s)=0$ 可以直接得到虚轴上的根，进而得到临界振荡频率 ω_{osc}。这个频率在现场很有用——它往往就是实测振荡曲线的频率，可用来反推是哪一个环节造成了振荡。求 ω_{osc} 也不必真的解方程：把 $s=\mathrm{j}\omega$ 代入 $A(s)$，实部为零给出 ω^2 的一次方程，解出即得。本例 $A(\mathrm{j}\omega)=-\omega^2+2=0$，$\omega=\sqrt{2}=1.414$，一行算式完成。

38.2.6 离散情形：Jury 判据

数字控制器的闭环特征方程是 z 的多项式

$$D(z)=a_n z^n+a_{n-1}z^{n-1}+\cdots+a_1 z+a_0=0,\qquad a_n>0 \tag{38-10}$$

稳定条件是全部根位于单位圆内。Jury 判据把它翻译成 $2n-1$ 个不等式，构造方式与 Routh 表类似，但“交叉相乘”的方式不同。

先把系数排成两行，第二行是第一行的逆序：

$$\begin{array}{c|ccccc} z^0 & a_0 & a_1 & \cdots & a_{n-1} & a_n \\ z^n & a_n & a_{n-1} & \cdots & a_1 & a_0 \end{array} \tag{38-11}$$

第三行由前两行算出，元素为 2×2 行列式：

$$b_k=\begin{vmatrix} a_0 & a_{n-k} \\ a_n & a_k \end{vmatrix}=a_0a_k-a_na_{n-k},\qquad k=0,1,\dots,n-1 \tag{38-12}$$

第四行再取逆序，如此交替，直到只剩三个元素。判据为：

$$D(1)>0,\qquad (-1)^n D(-1)>0,\qquad |a_0|<a_n, \tag{38-13}$$

以及后续每一对

$$|b_0|>|b_{n-1}|,\qquad |c_0|>|c_{n-2}|,\qquad \dots \tag{38-14}$$

全部成立时，根全部在单位圆内。

前两条是“实轴上的根”条件：$z=1$ 与 $z=-1$ 是单位圆与实轴的两个交点，$D(1)$ 与 $D(-1)$ 的符号分别约束低频与高频模态。第三条 $|a_0|<a_n$ 约束根的模之积：由韦达定理 $\prod|z_i|=|a_0/a_n|$，若乘积的绝对值已不小于 1，必有根在圆外或在圆上。后面各条逐层收紧。

式 (38-12) 的构造方式是“反转、错位、相减”：把一行系数与其逆序并排，取全部错位乘积之差，行数因此每步减一。以本章 §38.5.6 的三阶闭环 $D(z)=z^3-1.91308z^2+1.166778z-0.096960$ 为例，升幂写为 $(-0.096960,\,1.166778,\,-1.91308,\,1)$，则

$$
\begin{aligned}
b_0 &= a_0^2 - a_3^2 = 0.009401 - 1 = -0.990599 \\
b_1 &= a_0 a_1 - a_3 a_2 = -0.113130 + 1.913080 = 1.799950 \\
b_2 &= a_0 a_2 - a_3 a_1 = 0.185492 - 1.166778 = -0.981286
\end{aligned}
\tag{38-12a}
$$

b 行长度由 4 减到 3，再对 b 行做同样运算得 $c_0 = 0.018364$、$c_1 = -0.016763$，长度减到 2，递推终止。三阶一共 $2n-1=5$ 个条件：$D(1)>0$、$(-1)^n D(-1)>0$、$|a_0|<a_3$、$|b_0|>|b_2|$、$|c_0|>|c_1|$。逐条代入：$D(1)=0.1567$、$(-1)^3 D(-1)=4.1768$、$0.0970<1$、$0.9906>0.9813$（差 0.0093）、$0.0184>0.0168$（差 0.0016），全过。**注意最后两级差值已经在千分位**，这不是“通过”而是“贴着边界通过”——同一组条件给出的是五个数，而不是一个布尔值，这正是 Jury 判据在离散域里比 Routh 更好用的地方：它天然给出分级裕度。

Jury 判据的一个实用变体是**只用必要条件的快速筛查**：式 (38-13) 的三条只需三次求值，成本极低，能筛掉大部分明显不稳定的参数组合。现场整定时，先用这三条定出粗略区间，再用完整判据或数值求根确认。

38.2.7 双线性变换：把离散问题搬回连续域

Jury 表在 $n \ge 4$ 时手算量很大，而且每一行的元素是行列式，容易出错。工程上更常用的是另一条路：用双线性变换把单位圆内部映射成左半平面，然后直接套 Routh。

取

$$
z = \frac{1+w}{1-w} \quad \Longleftrightarrow \quad w = \frac{z-1}{z+1}
\tag{38-15}
$$

当 $z = \mathrm{e}^{\mathrm{j}\omega T_s}$ 时，$w = \mathrm{j}\tan(\omega T_s/2)$：单位圆精确映射为虚轴，圆内映射为左半平面，圆外映射为右半平面。这是**精确的**一一映射，不是近似，因此用它判稳不会引入误差——这一点常被误解为“双线性变换会畸变频率所以不能用于判稳”，其实畸变的是频率刻度，不是稳定性归属。

把这句话验一遍只需半步代数。令 $z = \mathrm{e}^{\mathrm{j}\theta}$（$\theta = \omega T_s$），则

$$
w = \frac{\mathrm{e}^{\mathrm{j}\theta}-1}{\mathrm{e}^{\mathrm{j}\theta}+1} = \frac{\mathrm{e}^{\mathrm{j}\theta/2}-\mathrm{e}^{-\mathrm{j}\theta/2}}{\mathrm{e}^{\mathrm{j}\theta/2}+\mathrm{e}^{-\mathrm{j}\theta/2}} = \mathrm{j}\tan\frac{\theta}{2}
\tag{38-15a}
$$

分子分母同乘 $\mathrm{e}^{-\mathrm{j}\theta/2}$ 得到第二个等号，这一步把“两个复指数之差”化成了“两倍正弦”，实数性一目了然：w 是纯虚数，模等于 $|\tan(\theta/2)|$。$\tan(\theta/2)$ 在 $\theta \in (-\pi,\pi)$ 上单调，所以映射是一一对应的；$\theta \to \pm\pi$（$z \to -1$）时 $|w| \to \infty$，这正是下文第三个实现细节中“$z \approx -1$ 附近的根跑到 w 的远处”的来源。反过来，$|z|<1$ 等价于 $\mathrm{Re}\, w < 0$：圆内圆外的归属由 $\mathrm{Re}\, w$ 的符号唯一决定，与 $|\tan(\theta/2)|$ 的具体数值无关——这就是“频率刻度畸变不影响稳定性判断”的完整理由。

代入后两边同乘 $(1-w)^n$ 是合法的，因为 $w=1$ 对应 $z \to \infty$，不是多项式的根，乘上去不引入伪根、也不改变根的归属。这个变换在复变函数里叫 Möbius 变换，它把 z 平面上的圆映射成 w 平面上的圆或直线；单位圆恰好映射为虚轴这条“半径无穷的圆”。

把 $z = (1+w)/(1-w)$ 代入 $D(z)$，两边乘以 $(1-w)^n$ 得 w 的多项式 $\tilde{D}(w)$，对 $\tilde{D}(w)$ 列 Routh 表即可。三个实现细节必须注意：

1. **不要用 $s = (2/T_s)(z-1)/(z+1)$ 的采样版本**。虽然稳定性结论相同，但系数会带上 $2/T_s$ 的幂次，在 T_s 很小时造成严重的数值缩放；直接用式 (38-15)（相当于 $T_s = 2$）最稳。
2. **首项可能退化**。若 $\tilde{D}(w)$ 的最高次系数为零（对应 $\sum a_i = 0$，即 $z=1$ 是根），说明有根落在单位圆上，直接判临界，不要继续算表。

3. **$z \approx -1$ 附近的根会跑到 w 的远处**。单位圆左端对应 $w \to \infty$，数值上表现为大系数，高阶系统（$n > 8$）建议用双精度并对系数做归一化，或改用 §38.2.6 的判据配合数值求根交叉验证。

图 38-3 给出同一组参数下 z 平面与 w 平面的对应关系，以及 T_s 变化时闭环极点的迁移路径。图中可以直观看到：采样周期加大时，极点沿某种螺旋向单位圆靠近，稳定裕度被采样“吃掉”。

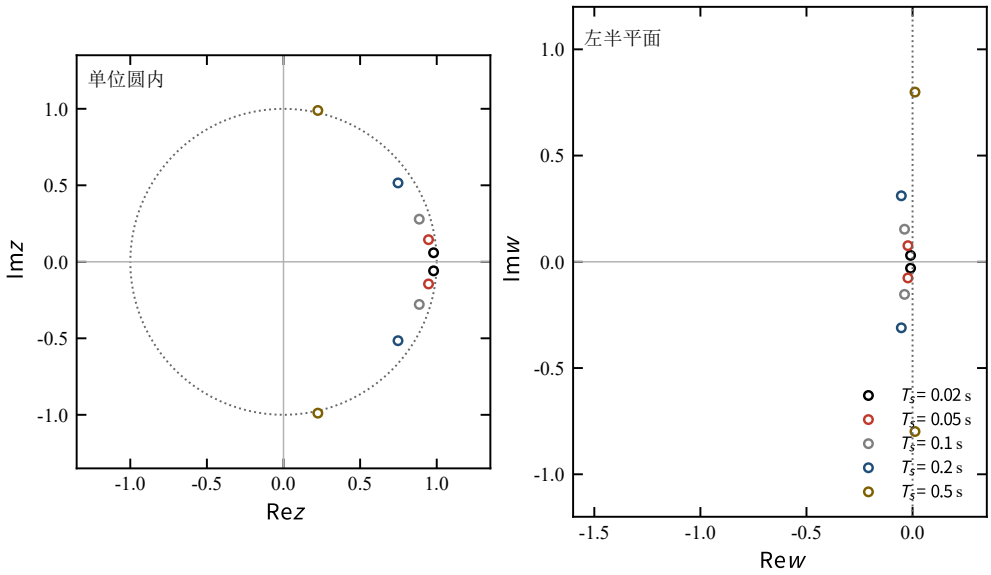

图 38-3　z 平面单位圆与 w 平面左半平面的对应关系

38.2.8 两种判据的关系与选用

Routh 与 Jury 不是两套理论，而是同一判据在两个域中的表述：前者判左半平面，后者判单位圆内。二者的对应关系可以概括成三点。

- **结论一致**：对同一系统，用 ZOH 离散后判 Jury，与用双线性变回连续域判 Routh，结论必然相同。不一致只可能来自数值误差或离散化时把延迟处理错了。
- **计算量不同**：Routh 每行只需一次除法与若干乘法；Jury 每行要算 n 个 2×2 行列式。$n \le 3$ 时 Jury 更快，$n \ge 5$ 时建议双线性 + Routh。这里要分清 Jury 的真正对手：不是 Routh 本身，而是“双线性 + Routh”这条组合。$n = 3$ 时双线性要展开 $1 + 3 + 3 + 1 = 8$ 个 $(1 \pm w)$ 的乘积，再把它们与 z 的系数逐项相加，手算量明显大于直接列 Jury 的三行；$n = 6$ 时这个数是 64，局面就反过来了。
- **附带信息不同**：Jury 的中间量 $|b_0| - |b_{n-1}|$ 等可以看作“分级裕度”，越靠后的条件越接近临界；Routh 的符号变化次数直接给右半平面根数。

表 38-1 给出选用建议。这张表是 §38.5 的入口，也是现场脚本（§38.12）里 `routh_report` 函数的分支依据。

场景	推荐判据	理由
连续域，$n \le 3$，求参数区间	Routh（显式不等式）	可直接解出 K 的上下界
连续域，$n \ge 4$，单点判稳	Routh	计算量小，符号变化次数可用
离散域，$n \le 3$	Jury 必要条件 + 完整判据	手算可行
离散域，$n \ge 4$	双线性 + Routh	避免大量行列式
需要右半平面/圆外根个数	Routh（连续）或双线性 + Routh	Jury 不直接给个数
系数含区间误差	Kharitonov（§38.9）	判据只适用确定系数

38.3 设计步骤

把 §38.2 的判据用起来，只需七步。这七步的顺序不是随意的：先做便宜的必要条件筛查，再做需要动笔的表格，最后才做仿真验证，能把大部分无效计算省掉。图 38-4 给出流程，其中带判断框的两个位置是实际项目里最常出错的环节。

七步里最容易混淆的是第 5 步与第 6 步的分工：第 5 步算“增益最多能到多大”，是一个纯数学问题；第 6 步判“实际该取多少”，要同时考虑性能、系数误差与工况变化。把两步合成一步，就会出现“算出 4.4 就取 4.4”这种典型错误——边界值只是“还没发散”，从来不是“可以工作”。

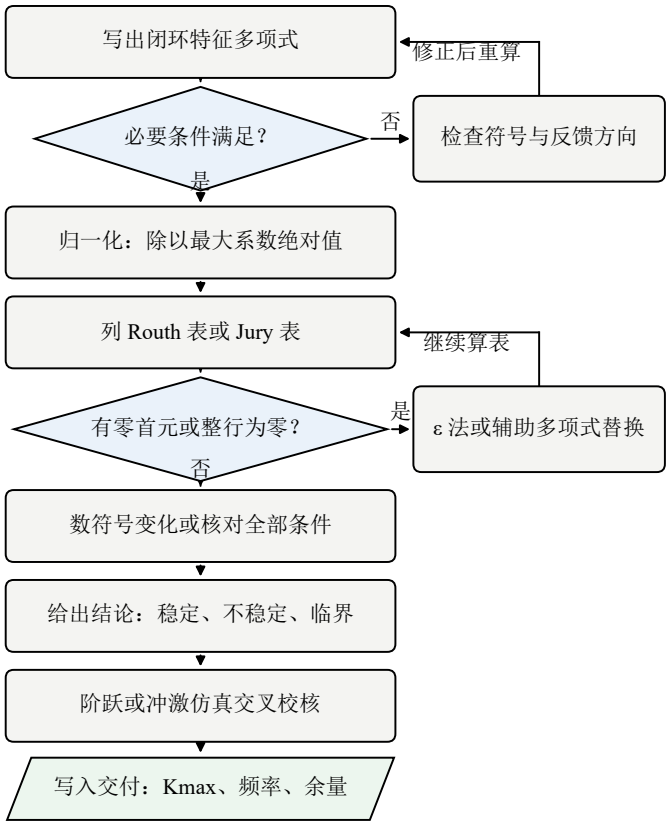

图 38-4　Routh/Jury 判稳的七步流程

38.3.1 第一步：写出闭环特征多项式

从开环传函 $G(s)H(s)=N(s)/D_{ol}(s)$ 出发，闭环特征多项式为

$$D_{cl}(s)=D_{ol}(s)+N(s) \tag{38-16}$$

这一步有两个常见错误。其一是**漏掉反馈通道的动态**：若传感器带一阶滤波 $H(s)=1/(0.05s+1)$，必须先通分成 $G(s)/[1+G(s)H(s)]$ 的形式，不能把 H 当成 1 处理。其二是**符号方向搞反**：正反馈时是 $D_{ol}-N$，减号的位置一变，稳定区间完全不同。

写完后统一成降幂、首项为正的形式，并把所有系数按量纲整理为同一数量级——这一步是为第五步解不等式做准备，也是防止 Routh 表里出现 10^{12} 与 10^{-3} 同表的原因。

多项式乘法的手算顺序值得固定下来：先把每个环节化成 $(\tau s+1)$ 的连乘，再逐次两两相乘，每次只保留当前阶次。以式 (38-21) 为例，先算 $s(s+2)=s^2+2s$，再算 $(0.05s+1)(0.02s+1)=0.001s^2+0.07s+1$，最后相乘得 $0.001s^4+0.072s^3+1.14s^2+2s$。若反过来先把三个环节展开再乘 s，中间会出现 s^5 项，虽然最后消掉，但手算时极易漏项。

首项归一化也有讲究。式 (38-18) 除以 0.05 得 $s^3+22s^2+40s+200K$，$K=4.4$ 时系数最大最小之比为 880，仍在手算舒适的范围内。跨度真正失控出现在高阶对象上：§38.9.1 里七个 $1/(s+2)$ 串联展开成七阶，系数从 10^{-13} 跨到 2.0，同一张表里既有百分之一也有百亿分之一。判据本身对正数缩放不变（乘正数不改变根的符号），但递推过程的舍入误差会随跨度放大，所以数值实现要么先归一化、要么逐行缩放（§38.9.1）。手算时统一到“首项为 1、时间用秒”最省事。

38.3.2 第二步：必要条件筛查

检查系数是否全部为正（式 38-3）。出现负系数或零系数就停下来：先确认是不是符号写错，若确实如此，则该结构在当前参数下无论如何都不稳。

这一步还能暴露一类结构性问题：常数项为零意味着有一个积分环节未被闭环包围，系统对常值扰动无静差但也无法稳定在任意工作点；某个中间次项为零意味着有纯虚根或对称根。这两种情况都不必再算表。

筛查可以做成两个固定动作。**其一，看常数项**：$a_0=0$ 说明环路里有积分没被反馈包住（把开环多项式直接当闭环用的典型症状），$a_0<0$ 说明环路符号错或增益取了负值。**其二，看缺项**：$a_i=0$ 而 $a_{i\pm1}\neq 0$，根必然落在虚轴上或关于虚轴成对出现。真实对象的系数几乎不可能“恰好”为零，所以出现零只可能是结构性错误或录入错误。

只有一处需要动手改：首项为负时先整体乘 -1。$D(s)=-s^2-2s-10$ 三个系数全负，乘 -1 后全正，根为 $-1\pm\mathrm{j}3$，系统稳定；不乘就按“有负系数”判不稳，结论正好反了。

同时要记住这条路走不通的地方。系数全正是必要条件，三阶以上不能凭它下结论：$D(s)=s^3+s^2+s+6$ 四个系数全正，Routh 表第一列却是 $1,\ 1,\ -5,\ 6$，有两处变号。所以第二步通过只代表“可以继续”，不代表“已经稳定”；它的产出应写成“$K>0$ 时系数全正，进入第三步；$K<0$ 时 $a_0<0$，排除”，这句话在第七步归档时可以直接抄用。

38.3.3 第三步：列 Routh 表

按式 (38-5)、(38-6) 递推。手算时建议把每一行通分后的分数保留三位有效数字，并在行首标注该行对应的 s 幂次——它在处理整行为零时要用来写辅助多项式。

填表有三条手算规范，照做能省掉大半的返工。**其一，行数固定为 $n+1$**：s^n 到 s^0 每行一个，缺项补零，不要因为某行“后面全是零”就省略——省略之后下标全错。**其二，整行可以乘正数**：出现 1.1122 这类小数时，整行乘 0.072 化成 $(0.0801,\,1.584)$ 更好算，结论不变（乘正数不改变符号变化次数），但要在草稿上注明乘了多少。**其三，每一步只算第一列够用的项**：手算判稳并不需要整张表，只需要每行的首元，而首元只与前两行的前两列有关。

把四阶对象 $K=2.2$ 的两行中间量手算一遍，可以看到这套规范的实际用法。s^2 行首元为

$$\frac{0.072\times 1.14-0.001\times 2}{0.072}=\frac{0.08008}{0.072}=1.1122$$

s^1 行首元为

$$\frac{1.1122\times 2-0.072\times 22}{1.1122}=\frac{0.64044}{1.1122}=0.5758$$

两式都只需两列，第三列起全是零填充。整张表四行、八次乘除，比解四次方程省得多，而且每一步都能复核。

若出现首元为零且该行非全零，按 §38.2.4 用 ε 法或乘正因子法处理，并在结论中注明“临界”；若出现整行为零，按 §38.2.5 写辅助多项式、求导、替换后继续，同时记录辅助多项式的根作为边界振荡频率。

38.3.4 第四步：读第一列，给结论

第一列全正即稳定；出现符号变化，变化次数就是右半平面根数。把结论写成“稳定 / 临界 / 不稳定（右半平面 m 个根）”三种之一，不要只写“稳定/不稳定”，因为临界状态在现场的处理方式与真不稳定完全不同：临界要做的是降增益、加阻尼，真不稳定则要查接线与符号。

数符号变化有两条容易含糊的规则。**第一，只数相邻非零元素之间的变号**，零本身不带符号；但首元为零的情形在第三步就应当已经转入特殊处理，所以正常读表时第一列不应出现零——出现零说明前一步漏了。**第二，ε 参与比较时按“极小正数”排队**，不要把它当零跳过。§38.2.4 的例子最典型：第一列读作 $+,\,+,\,+,\,-1/\varepsilon,\,+,\,+$，$\varepsilon\to 0^{+}$ 时第四项是一个绝对值极大的负数，于是 $+$ 到 $-$ 变一次、$-$ 回到 $+$ 再变一次，共 2 次变化，判“两个右半平面根”，与数值求根得到的 $0.0933\pm \mathrm{j}1.366$ 完全对上。若把含 ε 的那一项当成零跳过，只剩 $+,\,+,\,+,\,+$ 四次同号，就会误判为稳定——**同一个表，读法不同，结论正好相反**。

根数 m 也不只是学术兴趣。$m=2$ 通常意味着一对共轭复根越界（振荡发散），$m=1$ 通常是一个实根越界（单调发散），两者的现场表现与处置完全不同：前者先查增益与延迟，后者先查反馈符号与积分饱和。所以第四步的产出应当是“不稳定，$m=2$，估计为一对复根越界”，而不是一句“不稳定”。

38.3.5 第五步：把可调参数当符号，解出安全域

这是本章最有价值的一步。以增益 K 为例，把 D_{cl} 的系数写成 K 的一次或二次函数，Routh 表第一列就变成含 K 的表达式，令其全正得到一组不等式，解出 K 的可行区间 $\left[K_{\min},K_{\max}\right]$。

对最常见的三阶结构（式 38-7），这一步退化为一个线性不等式，手算即可；四阶结构（式 38-8）是两个不等式，用符号计算或数值求根都很快。区间解出来后，一定要检查下界：某些结构存在 $K_{\min}>0$，即增益太小反而不稳（多见于含不稳定极点的对象，如 §38.7.4 的 $1/(s-1)$），这时不能默认“越小越安全”。

当可调参数不止一个时，这一步会从“解区间”变成“解区域”。两个参数时可以在平面上画出边界曲线（§38.9.3 的 D-分解），三个以上时通常固定其中两个、对第三个扫描，把结果做成表格或等值线图。无论哪种，原则相同：**先把边界画出来，再在里面选工作点**，而不是先选工作点再验证。

38.3.6 第六步：取安全系数并做时域核对

工程上不取边界值。推荐把工作点取在 $K_{\max}$ 的 50%–70%，理由在 §38.8 详述；取完工作点后，用阶跃仿真核对超调与调节时间是否满足第 37 章的口径要求。这一步的意义在于：稳定只是及格线，边界附近的系统虽然稳定，但阻尼极小、超调极大，往往过不了性能验收。

50%–70% 不是一句经验口号，它对应两条可算的约束。其一是增益裕度：$20\lg 0.5 = -6.0$ dB、$20\lg 0.7 = -3.1$ dB，多数行业规范要求 6 dB，所以 50% 是“合规线”，70% 只在系数非常准时才允许。其二是系数不确定度：§38.7.2 给出 $\pm 15\%$ 的系数误差会让 $K_{\max}$ 本身偏 $\pm 30\%$，取 50% 恰好把这段不确定度留在工作点外面。

这个推荐区间也有前提：它假设性能约束不紧、边界主要由增益决定。本例恰好相反——50% 工作点的 M_p 已达 71.4%，真正可行的是 $K/K_{\max} = 6.8\%$。所以第六步的正确写法不是“取 50%”，而是“取满足性能的最大 K，再核对其余量是否覆盖系数与延迟的不确定度”。**安全系数是结果，不是出发点。**

38.3.7 第七步：把边界写进档案

交付文档里应记录三样东西：结构（阶次、零点、延迟）、$K_{\max}$ 的数值及其推导依据、当前工作点距边界的百分比。现场调试时若发现振荡，第一个动作就是查这三项，而不是盲目降增益——降增益只对“接近上界”的情形有效，对“延迟被低估”或“传感器滤波被改动”的情形无效。

这三样必须绑在一起写，单独一个 $K_{\max}$ 没有意义：换成 20 ms 传感器滤波，同一个 4.40 就变成 3.09。建议写成一行可复算的记录——“结构：三阶（执行器 50 ms）→ 系数 $(0.05,\ 1.1,\ 2,\ 10K)$ → $K_{\max} = 4.40$、$\omega_{osc} = 6.32$ rad/s → 工作点 $K = 0.3$，占边界 6.8%”。任何人拿到这一行都能在几分钟内复算；结构变更时，也能立刻看出该重算哪一项。

“距边界的百分比”还要写清基准，否则同一件事会有两个名字。$K = 0.3$ 对 $K_{\max} = 4.40$ 既可以说“占边界 6.8%”，也可以说“还有 93.2% 的余量”——前者顺着设计者的思路，后者顺着“还能加多少”的思路，评审会上若各自默认一种，就会为一句正确的话争半天。写成“$K/K_{\max} = 6.8\%$（余量 93.2%）”，两个数一起给，歧义就消失了。

图 38-4 的两个判断框对应的正是这两类失效：左边判断“必要条件是否满足”用来拦住符号错误，右边判断“是否存在零行/零首元”用来拦住临界状态被误判为稳定。

38.3.8 一个完整的七步算例

把七步完整走一遍。对象为 $10/[s(s+2)]$ 串 50 ms 执行器滞后，控制器取纯比例 K，结构与 §38.4.2 相同，这里关注的是流程本身而不是新结论。

第一步，写出闭环特征多项式：

$$D(s) = 0.05s^3 + 1.1s^2 + 2s + 10K$$

已按降幂排列、首项为正。

第二步，必要条件。四个系数在 $K > 0$ 时全为正；$K < 0$ 时常数项为负，直接判不稳。于是负增益在第二步就被排除，不需要列表。

第三步，列 Routh 表：

$$
\begin{array}{c|cc}
s^3 & 0.05 & 2 \\
s^2 & 1.1 & 10K \\
s^1 & 2-\dfrac{K}{2.2} & 0 \\
s^0 & 10K & 0
\end{array}
$$

第四步，读第一列。全正的条件是 $K>0$ 且 $2-K/2.2>0$，即 $0<K<4.4$。后者就是 §38.4.2 的 $K_{\max}$，但这里是由流程自然得到的，没有背公式。

第五步，安全域为 $(0,4.4)$。下界恰好为零，说明该结构没有不稳定极点，增益再小也稳定，只是响应变慢；这一点与 §38.7.4 的 $1/(s-1)$ 形成对照。

第六步，取 50% 工作点 $K=2.2$，做时域核对：$M_p=71.4\%$、$t_s=8.45$ s，远超 $M_p\le 20\%$ 的合同要求。把 K 降到 0.3，$M_p=13.8\%$、$t_s=3.40$ s 才合格。此时 $K/K_{\max}=6.8\%$，安全系数大得“浪费”，但这不是保守，而是被性能约束卡住的必然结果。

第七步，写进档案：结构为三阶（执行器 50 ms）；$K_{\max}=4.4$，$\omega_{osc}=6.32$ rad/s；工作点 $K=0.3$，占边界 6.8%；满载时两个机械时间常数变为 1.5 s 与 3 s，$K_{\max}$ 必须重算（§38.1.1 的事故正出在这一条）。

这个算例最重要的结论在第六步：**稳定域与性能域的交集才是可行域**。只做到第五步就交付，等于把“不发散”当成了“能用”，后面的调试必然反复。

38.3.9 九个高频错误

七步走错，通常不是数学不会，而是下面九件事之一。每条都给出本例的实际后果，便于对照自查。

1. **拿开环多项式当闭环**。$0.05s^3+1.1s^2+2s$ 的常数项为零，第二步会判“临界”；有人看到“没有负系数”就以为稳了，漏掉的正是 $+10K$。
2. **漏掉反馈通道动态**。传感器 20 ms 滤波若按 1 处理，$K_{\max}$ 会从 3.09 报成 4.40，虚高 42%。现场“按公式算挺稳、一上电就振”，一半出在这里。
3. **正反馈写成负反馈**。同一回路若写成 $0.05s^3+1.1s^2+2s-10K$，$K=2.2$ 时的根为 -18.57、-6.88、$+3.45$，有一个右半平面根。系数表上只差一个符号，结论从稳定翻成发散。
4. **单位混用**。把 50 ms 写成 50 代入，$a_3=50$、$a_2=101$，$K_{\max}$ 变成 0.404——只有正确值的 9%；$K=2.2$ 时根为 $+0.040\pm j0.456$，已经发散。跨专业交接（电气给毫秒、机械给秒）时最容易出现。
5. **用 Tustin 的结果定边界**。Tustin 下 $K_{\max}\to\infty$，ZOH 下只有 4.138（§38.5.5）。这不是精度问题，是定性错误。
6. **首元为零时随手取 ε、不检查量级**。ε 必须远小于表中其他元素。本例取 10^{-3} 与 10^{-10} 结论一致（都不稳），但取 1 就会改变符号模式。
7. **整行为零时只替换、不记 ω_{osc}**。替换能让表继续算下去，但丢掉的是最有诊断价值的数——6.3246 rad/s（§38.4.2）与 1.4142 rad/s（§38.4.4）都是这样得到的。
8. **只解上界、不看下界**。$1/(s-1)$ 的稳定域是 $K>1$，不查下界会把 $K=0.5$ 当安全点，而那里闭环极点就在 $+0.5$。
9. **把“判据通过”当“验收通过”**。$K=2.2$ 通过判据，$M_p=71.4\%$、$t_s=8.45$ s。判据管的是“不发散”，不是“能用”。

九条里有五条（1、2、3、4、5）会让结论“错得整整齐齐”——算出来的数看着合理，只是与事实相反。这类错误最危险的地方在于不报错、不崩溃、不留痕迹。唯一的防线是把交叉核对做成习惯：同一结论至少用两条独立

路径得到（解析式与数值扫描、Jury 与双线性、Routh 与 Bode 裕度）。

38.4 连续情形

本节把 §38.3 的流程走四遍，对象逐步从“理想二阶”变成“带执行器滞后”、“带传感器滤波”、“含整行为零”。四遍的结论各不相同，但推导方式一样，读者可以把注意力放在“阶次增加时稳定域怎么缩”上。

四遍的顺序是刻意安排的：每一遍只增加一个环节，这样“稳定域缩了多少”就能直接归到那个环节头上，而不是笼统地归因于“阶次高了不好稳”。做完这四遍，再看 §38.7 的参数敏感性表，就会明白那张表里的每一行其实都是本节某一遍计算的“局部放大”。

38.4.1 理想二阶：判据给出“没有上限”

沿用第 37 章的示例对象 $G_0(s)=10/[s(s+2)]$，控制器取纯比例 $C(s)=K$，单位反馈。闭环特征多项式为

$$D(s)=s^2+2s+10K=0 \tag{38-17}$$

按式 (38-3)，只需 $10K>0$，即 $K>0$。二阶系统的 Routh 表只有三行，第一列是 $(1,\ 2,\ 10K)$，只要 $K>0$ 就全正，**没有上限**。这与解析结论一致：二阶闭环的阻尼比为 $\zeta=1/\sqrt{10K}$，K 增大时阻尼比单调减小但始终为正，极点始终在左半平面。

这个结论很容易被误用。现场有人说“二阶对象怎么加增益都不会振散”，前半句对、后半句错：K 增大到 100 时 $\zeta=0.032$，超调 90.5%，波形已经接近等幅振荡。但这里有一个常被忽略的细节——这条回路的 $\sigma=\zeta\omega_n\equiv 1$ 与 K 无关：$2\zeta\omega_n=2$ 是 s 的系数，增益动不了它，所以极点始终沿 $s=-1$ 这条竖线上下移动，衰减时间常数恒为 1 s，$t_s\approx 4$ s 一动不动。**增益在这条回路上只买振荡，不买速度。** 判据只管“发不发散”，不管“能不能用”，这条界线在 §38.6 会正式给出。

把这条界线量化一下。二阶闭环的阻尼比与自然频率分别为

$$\zeta=\frac{1}{\sqrt{10K}},\qquad \omega_n=\sqrt{10K}$$

K 增大时 ω_n 变大、ζ 变小，两者朝相反方向走。按第 37 章的超调公式 $M_p=\exp(-\pi\zeta/\sqrt{1-\zeta^2})$ 逐点算：$K=0.2$ 时 $\zeta=0.707$、$M_p=4.32\%$、$t_s=4.22$ s；$K=0.5$ 时 $\zeta=0.447$、$M_p=20.8\%$；$K=2$ 时 $\zeta=0.224$、$M_p=48.6\%$。若合同要求 $M_p\le 20\%$，反解出 $\zeta\ge 0.456$，对应 $K\le 0.48$。

也就是说，这个回路的“能用”上限是 $K\approx 0.48$，而“会发散”的上限是无穷大。两者相差的不是一个系数，而是**问题的性质**：前者由阻尼决定，后者由极点是否越过虚轴决定。Routh 表能回答后者，对前者一无所知。这正是 §38.6 要补的那块内容，也是工程上“判据通过、验收不过”的根源。

更关键的是，真实回路没有纯二阶。执行器有一阶滞后，传感器有滤波，传动有柔性和间隙。这些环节各自贡献一个极点，把阶次推到三阶、四阶，稳定域立刻出现上限。

38.4.2 加执行器滞后：三阶出现 $K_{\max}$

在对象前串一个一阶执行器模型 $1/(0.05s+1)$（伺服阀或电流环的等效滞后，50 ms），特征多项式变成

$$D(s)=s(s+2)(0.05s+1)+10K=0.05s^3+1.1s^2+2s+10K=0 \tag{38-18}$$

按式 (38-7)，三阶稳定的条件是三个系数全正且内项积大于外项积：

$$1.1 \times 2 > 0.05 \times 10K \quad \Longrightarrow \quad K < 4.4 \tag{38-19}$$

$K_{\max} = 4.4$。边界处的振荡角频率由辅助多项式 $1.1s^2 + 10K = 0$ 解出：

$$\omega_{osc} = \sqrt{\frac{10 \times 4.4}{1.1}} = \sqrt{40} = 6.32 \ \text{rad/s} \tag{38-20}$$

即约 1.0 Hz。把 $K = 4.4$ 代回式 (38-18) 求根，得到 $s = \pm \text{j}6.3246$ 与 $s = -22$，与式 (38-20) 完全吻合——这就是 Routh 表的价值：不用解三次方程，也能拿到边界频率。

表 38-2 给出 K 从 1 增到 4.5 时三个极点的位置。第三行开始，主导极点对的实部迅速趋近零，衰减时间常数从 1.36 s 拉长到 524 s，最后穿越虚轴。

增益 K	主导极点	最大实部	衰减时间常数 (s)
1.0	$-0.737 \pm \text{j}3.033$	-0.737	1.36
2.2	$-0.454 \pm \text{j}4.545$	-0.454	2.20
4.0	$-0.077 \pm \text{j}6.051$	-0.077	12.93
4.39	$-0.002 \pm \text{j}6.318$	-0.002	524
4.40	$\pm \text{j}6.325$	0	临界
4.50	$+0.019 \pm \text{j}6.391$	$+0.019$	发散

表 38-2 最值得注意的一行是 $K = 4.0$：它还在稳定域内，最大实部却是 -0.077，意味着任何扰动要 13 s 才衰减到 37%。用第 37 章的口径测，此时超调与调节时间都早已不合格。图 38-5 把根轨迹与 $K_{\max}$ 画在一起，左侧是极点随 K 的迁移路径，右侧是 K 接近边界时的阶跃响应。

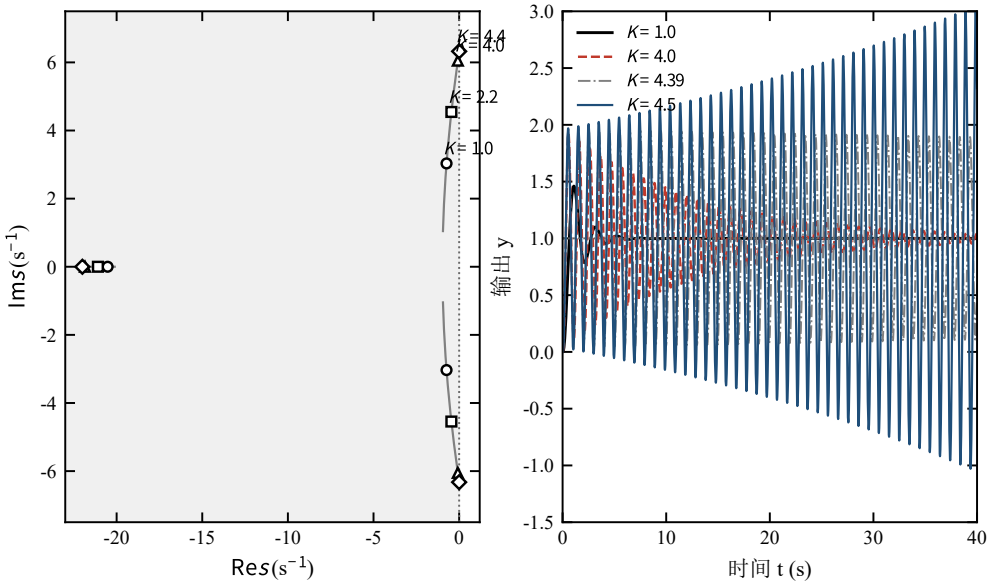

图 38-5　三阶对象的极点迁移与临界增益

38.4.3 再加传感器滤波：四阶的稳定域进一步收缩

若编码器信号后接一个 20 ms 一阶滤波 $1/(0.02s + 1)$（很常见的抗混叠处理），特征多项式变为

$$D(s)=s(s+2)(0.05s+1)(0.02s+1)+10K=0.001s^4+0.072s^3+1.14s^2+2s+10K \tag{38-21}$$

代入式 (38-8) 的两个不等式并解出 K，得 $K_{\max}\approx 3.09$。两个不等式值得分别算一遍：第一个是 $a_3a_2-a_4a_1=0.072\times 1.14-0.001\times 2=0.08008>0$，与 K 无关，宽得很；第二个是 $a_3a_2a_1-a_3^2a_0-a_4a_1^2=0.16416-0.05184K-0.004>0$，即 $K<0.16016/0.05184=3.0895$。一个松、一个紧，这是四阶结构的常态：**起决定作用的总是含 a_0 的那一条**，因为它随增益线性下降，其余各项都是常数。与三阶的 4.4 相比，**仅仅增加一个 20 ms 的滤波，稳定域就缩小了 30%**。

这个结果与直觉一致但常被忽视：滤波器的转折频率 50 rad/s 看起来远高于关心的频段（$K=2$ 时主导极点虚部约 4.5 rad/s），但它在 6.3 rad/s 的边界频率处已经贡献了 $\arctan(0.02\times 6.32)\approx 7.2^\circ$ 的相位滞后，正好吃掉边界处的余量。第 41 章会用相位裕度解释同一件事，本章则给出更硬的结论：**任何串入回路的动态环节都会缩小稳定域，判断影响大小不能看它的时间常数相对响应快慢，而要看它在穿越频率处的相位贡献。**

38.4.4 整行为零的例子

取一个专门设计的四阶多项式

$$D(s)=s^4+s^3+3s^2+2s+2 \tag{38-22}$$

四个系数全正，必要条件通过。列 Routh 表：

$$\begin{array}{c|ccc} s^4 & 1 & 3 & 2 \\ s^3 & 1 & 2 & 0 \\ s^2 & 1 & 2 & 0 \\ s^1 & 0 & 0 & 0 \end{array} \tag{38-23}$$

s^1 行全为零，触发 §38.2.5 的处理。用上一行（s^2 行）构造辅助多项式

$$A(s)=s^2+2 \tag{38-24}$$

其根为 $s=\pm \mathrm{j}\sqrt{2}=\pm \mathrm{j}1.414$，正是一对虚轴极点。对 $A(s)$ 求导得 $A'(s)=2s$，用系数 $(2,0)$ 替换全零行后继续，第一列变为 $(1,1,1,2,2)$——全正，说明除这对虚根外，其余根都在左半平面。

这个例子有三个教学价值。第一，它说明“系数全正”确实不足以保证稳定，必须有 Routh 表才能发现虚根。第二，整行为零时，辅助多项式直接给出边界频率 $\omega_{osc}=1.414$ rad/s，现场的等幅振荡周期应为 4.44 s，可用来核对。第三，该多项式事实上可分解为

$$D(s)=(s^2+2)(s^2+s+1) \tag{38-25}$$

后一个因子给出 $-0.5\pm \mathrm{j}0.866$ 的稳定极点，前一个因子给出虚轴极点。也就是说，系统里同时存在一个“会衰减的振荡模态”和一个“不衰减的振荡模态”，实测曲线应是两者的叠加：先看到 0.866 rad/s 的衰减振荡，稳定后剩下 1.414 rad/s 的等幅振荡。

这两件事在波形上可以分辨。两个频率之差为 $1.414-0.866=0.548$ rad/s，叠加后包络以 $2\pi/0.548\approx 11.5$ s 为周期起伏；而衰减模态的时间常数只有 2 s，所以这种“拍”只在起始几秒看得见，之后只剩 1.414 rad/s 的等幅振荡。反过来用：**若实测波形在 10 s 之后仍有明显起伏，说明还存在一个未建模的慢模态**，此时不该调增益，而该去补模型。

图 38-6 给出这类临界系统的响应特征：阶跃输入下输出既不收敛也不发散，而是以固定振幅持续振荡，振幅由初始条件与输入共同决定。

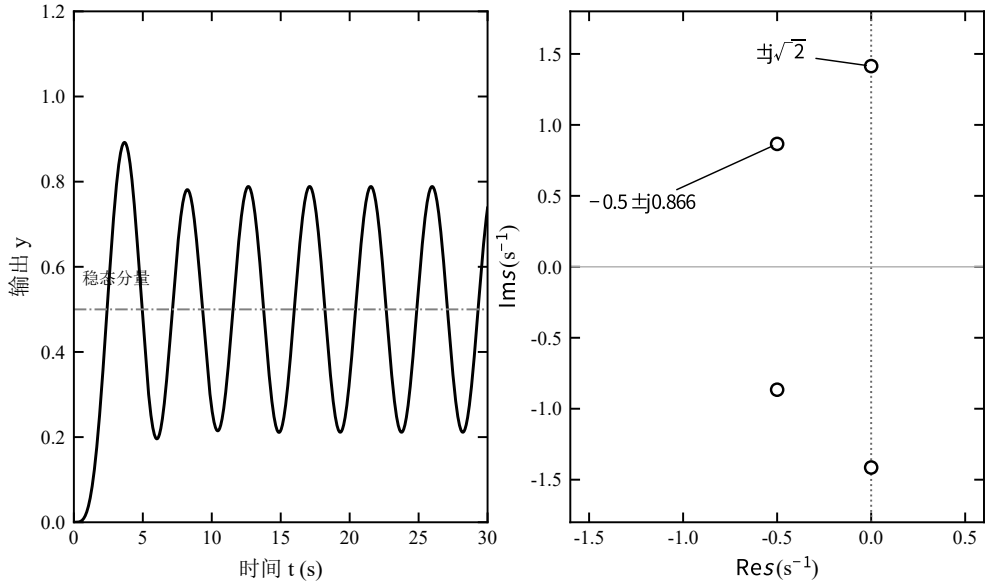

图 38-6　临界稳定系统的等幅振荡与稳定域的边界

38.4.5 四个例子的横向对照

把四遍计算放在一起（表 38-3），可以看到一条清晰的规律：**每增加一个极点，稳定域的上界就往下掉一截，且掉幅与新增环节在穿越频率附近的相位贡献正相关。**

结构	阶次	附加环节	$K_{\max}$	相对上一行
$10/[s(s+2)]$	2	无	∞	—
加 50 ms 执行器滞后	3	$1/(0.05s+1)$	4.40	—
再加 20 ms 传感器滤波	4	$1/(0.02s+1)$	3.09	-30%
惯性放大三倍（§38.1.1）	4	时间常数变 1.5、3	1.04	-66%

把每一档的穿越频率与相位贡献也算出来，规律会更清楚。三阶在 6.32 rad/s 穿越，此时执行器贡献 $\arctan(0.05\times 6.32)=17.6^\circ$；四阶的穿越频率降到 5.27 rad/s（$\omega=\sqrt{a_1/a_3}=\sqrt{2/0.072}$），执行器贡献 14.8°、传感器贡献 6.0°，合计 20.8°。频率降了 17%，该处的开环幅值却从 0.2273 升到 0.3237，而 $K_{\max}$ 恰是它的倒数：$1/0.2273=4.40$、$1/0.3237=3.09$。

这条关系是本章最实用的速算工具：**$K_{\max}$ 就是边界频率处开环幅值的倒数**，不必先列完整张表。它也把本章与第 41 章接上了——$20\lg K_{\max}$ 正是增益裕度，三阶 12.9 dB、四阶 9.8 dB。两章算的是同一件事，只是一个用系数递推、一个用频率响应。

这也解释了 §38.1.1 的事故：工程师在空载下算出的边界是 3.30，看似有 65% 的余量，但惯性一变，边界掉到 1.04，余量变成负值。**稳定域不是一个数，而是结构参数的函数**；把 $K_{\max}$ 当成设备的固有属性写进手册，是这类事故的共同根源。

38.5 离散情形

数字控制器令 $u[k]$ 由 $e[k]$ 算出，闭环特征方程是 z 的多项式。§38.4 的三阶、四阶结论不能直接搬过来：采样本身引入了等效延迟，且离散化方法会改变零极点位置。本节先用第 37 章的同一对象算清楚“采样周期吃掉多少稳定

域”，再演示 Jury 判据的手算过程。

顺序上分四段：先用 ZOH 建 $G(z)$，再用 Jury 判一次稳，然后用双线性变回连续域交叉核对，最后归纳出 $K_{\max}T_s \approx 0.4$ 这条量级规律。四段用的都是同一组数据，读者可以一路对照数字往下看。

38.5.1 从 $G_0(s)$ 到 $G(z)$

对象仍取 $G_0(s)=10/[s(s+2)]$，加零阶保持器、采样周期 $T_s=0.1$ s，离散化得

$$G(z)=\frac{0.04683z+0.04381}{z^2-1.81873z+0.81873} \tag{38-26}$$

比例控制器 $C(z)=K$ 时，闭环特征多项式为

$$D(z)=z^2+(0.04683K-1.81873)z+(0.81873+0.04381K) \tag{38-27}$$

二阶多项式的 Jury 条件（式 38-13）只有三条，逐条写出来：

$$\begin{cases} D(1)=0.09064K>0 \\ D(-1)=3.63746-0.00302K>0 \\ |a_0|=0.81873+0.04381K<1 \end{cases} \tag{38-28}$$

第二条对 $K<1204$ 都成立，实际上是空条件；第三条给出 $K<4.139$，第一条给出 $K>0$。于是离散闭环的稳定域是 $0<K<4.139$。

这三条恰好展示了 Jury 判据的“分工”：第二条约束的是 $z=-1$（最高频），本例中对象没有高频谐振，所以它给出一个宽松到无意义的界；第三条约束的是根的模之积，本例中增益直接进入常数项，所以它最紧。**判断哪条约束是紧的，不必先解方程——看哪个系数随 K 变化最快即可**：a_0 的斜率是 0.04381，$D(-1)$ 的斜率只有 0.00302，相差 14 倍，紧的那条必然是前者。

这个数与连续域的三阶结果 4.40 很接近，但注意对象不同：连续域那个 4.40 是加了一阶执行器滞后的三阶系统，这里的 4.14 是纯二阶对象经 ZOH 采样后的结果。**采样周期 0.1 s 的 ZOH 等效于约 0.05 s 的纯延迟**（$T_s/2$），它替代了执行器滞后的作用，所以两个上限落在同一量级。

顺手把式 (38-26) 的来源交代清楚，它并不神秘。$10/[s^2(s+2)]$ 部分分式展开为 $5/s^2-2.5/s+2.5/(s+2)$，逐项查 z 变换表得

$$G(z)=\frac{z-1}{z}\left[\frac{5T_s z}{(z-1)^2}-\frac{2.5z}{z-1}+\frac{2.5z}{z-\mathrm{e}^{-2T_s}}\right]$$

代入 $T_s=0.1$、$\mathrm{e}^{-0.2}=0.818731$ 并通分，分子为 $(5T_s-2.5+2.5\mathrm{e}^{-2T_s})z+(2.5-2.5\mathrm{e}^{-2T_s}-5T_s\mathrm{e}^{-2T_s})=0.046827z+0.043808$，分母为 $(z-1)(z-\mathrm{e}^{-2T_s})=z^2-1.818731z+0.818731$，与式 (38-26) 一致。**离散化不是黑箱**：分子两个系数一个来自 T_s 项、一个来自 e^{-2T_s} 的残差，量级都随 T_s 减小而趋于零，这正是“采样越快、离散系统越接近连续系统”的代数表现。

38.5.2 采样周期对稳定域的压缩

把 T_s 从 0.01 s 一路加到 0.5 s，用同样的方法解 $K_{\max}$，结果见表 38-4。这里的 $K_{\max}$ 可以写成解析式：二阶离散闭环的常数项是 $a_0=e^{-2T_s}+K(2.5-2.5e^{-2T_s}-5T_se^{-2T_s})$，Jury 的第三条 $a_0<1$ 单独给出了上界

$$K_{\max} = \frac{1 - e^{-2T_s}}{2.5 - 2.5e^{-2T_s} - 5T_s e^{-2T_s}} \tag{38-28a}$$

表中最右一列不是“保持率”，而是乘积 $K_{\max}T_s$——理由见下文第二点。

采样周期 T_s (s)	$G(z)$ 分母	$K_{\max}$	$K_{\max}T_s$
0.01	$z^2 - 1.98020z + 0.98020$	40.13	0.401
0.02	$z^2 - 1.96079z + 0.96079$	20.13	0.403
0.05	$z^2 - 1.90484z + 0.90484$	8.14	0.407
0.10	$z^2 - 1.81873z + 0.81873$	4.14	0.414
0.20	$z^2 - 1.67032z + 0.67032$	2.14	0.429
0.50	$z^2 - 1.36788z + 0.36788$	0.96	0.478

表 38-4 有三处值得强调。

第一，**上限并没有在采样足够快时“消失”**。初看这个结果容易想当然：连续二阶对象对任意 $K > 0$ 都稳定，那么采样足够快时离散系统应当继承这一性质，只在 T_s 大到一定程度才出现上限。但把 T_s 压到 0.01 s、0.005 s 甚至 10^{-5} s 再算，$K_{\max}$ 依次是 40.13、80.13、4.0×10^4——**始终有限，只是随 T_s 反比放大**。根本原因在 a_0 的极限行为上：把式 (38-28a) 的分子分母按 T_s 展开，$1 - e^{-2T_s} \approx 2T_s$，而分母 $2.5 - 2.5e^{-2T_s} - 5T_s e^{-2T_s} \approx 5T_s^2$，于是

$$K_{\max} \approx \frac{2T_s}{5T_s^2} = \frac{0.4}{T_s} \qquad (T_s \to 0) \tag{38-28b}$$

这个 $0.4/T_s$ 就是表中的规律：T_s 每减半，上限翻一倍。它说明 **“连续系统无上限”这一性质对任何离散实现都不成立**，因为零阶保持器本身就是一个 $T_s/2$ 的延迟环节，而延迟无论多小都会在相位上积累出 -180°；T_s 越小，积累得越慢，上限就越高，但永不为无穷。工程含义很直接：不能用“我采样很快”来替代稳定域核算，只能说“我的 $K_{\max}$ 还很远”。

第二，$K_{\max}T_s$ **几乎是常数（0.40–0.48）**，这才是该表最有用的一列。容易想到的另一种写法是“相对 $T_s \to 0$ 的保持率”，但 $T_s \to 0$ 时 $K_{\max} \to \infty$，任何有限值除以无穷都趋于零：这一列在 T_s 越小的地方越没有信息量，属于把“归一化基准选错”的典型。反过来，$K_{\max}T_s$ 有明确的物理量纲（增益乘时间）与稳定的数值，T_s 变化五十倍它只从 0.401 走到 0.478，偏差不到 20%。现场估算时可以直接用 $K_{\max} \approx 0.4/T_s$ 起算，再乘 0.48/0.40 的修正，比查表更快。

第三，$T_s = 0.5$ s **时** $K_{\max} = 0.96$，意味着即使控制器取 $K = 1$（最“温和”的比例控制），系统也已经不稳定。这与连续域的直觉完全相反，也是 §38.10 里“数字控制器上线前必须重算稳定域”的根据。

还有一处可以交叉核对：$T_s = 0.1$ s、$K = K_{\max} = 4.1378$ 时，闭环根恰好落在单位圆上，为 $z = 0.81248 \pm \mathrm{j}0.58298$。把它折回连续域，$\omega = \angle z / T_s = 0.6222/0.1 = 6.22$ rad/s，与 §38.4.2 中三阶对象（50 ms 执行器滞后）的边界频率 6.3246 rad/s 只差 1.6%。这再次印证 §38.5.1 的判断：$T_s = 0.1$ s 的零阶保持器在相位上与 50 ms 的纯延迟几乎等价，两个不同的对象才会给出几乎相同的边界频率。

图 38-7 把 $K_{\max}$ 与 T_s 的关系画成曲线，同时叠上连续域三阶对象的 4.40 作为参照线。

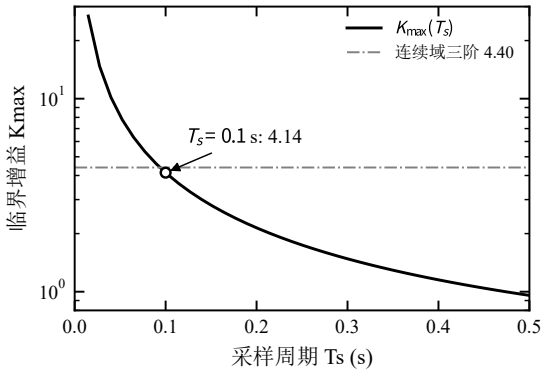

图 38-7　采样周期对临界增益的压缩作用

38.5.3 Jury 判据的手算示例

取 $T_s = 0.1$ s、$K = 3$，代入式 (38-27)：

$$D(z) = z^2 - 1.67825z + 0.950154 \tag{38-29}$$

按式 (38-13) 逐条核对：

- $D(1) = 1 - 1.67825 + 0.950154 = 0.271904 > 0$；
- $(-1)^2 D(-1) = 1 + 1.67825 + 0.950154 = 3.628404 > 0$；
- $|a_0| = 0.950154 < 1$。

三条全过，判稳。由式 (38-14)，二阶系统还需检查 $|b_0| > |b_1|$，其中

$$b_0 = a_0^2 - a_2^2 = 0.902793 - 1 = -0.097207, \qquad b_1 = a_0 a_1 - a_2 a_1 = 0 \tag{38-30}$$

$|b_0| = 0.0972 > |b_1| = 0$，条件成立。求解式 (38-29) 得 $z = 0.839125 \pm \mathrm{j}0.496007$，模 0.974758，小于 1，与判据结论一致。

这个结果有一个值得注意的细节：连续域同一对象在 $K = 3$ 时闭环为 $s = -1 \pm \mathrm{j}5.385$，把它按 $z = \mathrm{e}^{sT_s}$ 采样应当得到 $0.776784 \pm \mathrm{j}0.464045$，模 0.9048；而真实的离散闭环是 $0.839125 \pm \mathrm{j}0.496007$，模 0.9748。两者的**角度几乎相同**（0.5339 与 0.5385 rad，折合 5.339 与 5.385 rad/s，差 0.9%），**模却差了一大截**。把模换算回等效实部，$\sigma = -\ln|z|/T_s$：理想采样给 1.0，实际离散闭环只有 0.256；阻尼比则由 0.183 掉到 0.048。也就是说，**零阶保持器几乎不动振荡频率，主要吃的是阻尼**——它相当于在回路里插了 $T_s/2 = 50$ ms 的纯延迟，相位滞后在 5.4 rad/s 处正好是 $0.05 \times 5.385 \approx 0.27$ rad（15°），把极点往右推、把阻尼压到四分之一。

所以“离散系统的响应形态和连续一样，只是采样了一下”是错误直觉：这句话对频率成立，对衰减完全不成立。本例中振荡周期几乎不变（1.18 s 对 1.17 s），但振荡持续的时间差了近四倍，超调也要重新算。这也是“模拟调试通过、数字控制器上线就振”（§38.5.6）的机理：同一套增益，采样把阻尼吃掉，而人眼在示波器上先看到的正是阻尼。

38.5.4 用双线性变换交叉核对

把 $z = (1+w)/(1-w)$ 代入式 (38-29)，两边乘 $(1-w)^2$，按 w 的降幂整理：

$$3.628404 w^2 + 0.099692 w + 0.271904 = 0 \tag{38-31}$$

三个系数全正，二阶 Routh 表第一列为 $(3.6284,\ 0.0997,\ 0.2719)$，符号无变化，判稳——与 Jury 结论一致。

两条路径给出的中间量可以互相对照：式 (38-31) 的常数项等于 $D(1)$，二次项系数等于 $(-1)^2 D(-1)$，一次项系数等于 $2(a_2 - a_0)$。也就是说，**Jury 的前两条必要条件与 w 多项式首末系数的符号是同一件事**，只是表述不同。理解了这层对应，就不会再把两个判据当成两套互不相干的方法。

代入本例核对，三项都对得上：$D(1) = 1 - 1.678251 + 0.950155 = 0.271905$，与常数项 0.271904 一致；$D(-1) = 1 + 1.678251 + 0.950155 = 3.628406$，与二次项 3.628404 一致；$2(a_2 - a_0) = 2(1 - 0.950155) = 0.099690$，与一次项 0.099692 一致。差在末位，来自打印时的四舍五入。

再往下走一步，还能核对根的映射。式 (38-31) 的根为 $w = -0.013738 \pm \mathrm{j}0.273410$（实部为负，所以 z 在单位圆内），按 $z = (1+w)/(1-w)$ 映射回去，模为 $1.023458/1.049961 = 0.974758$、相角为 $0.27007 + 0.26351 = 0.53358$ rad——与 §38.5.3 直接求根得到的 0.974758 与 0.5339 完全一致。**两条路径不仅结论相同，连极点的数值都能对上**，这才是真正意义上的交叉验证；只对“稳定/不稳定”三个字，两个都写错的实现也可能一致。

38.5.5 两个实现层面的坑

坑一：离散化方法不同，稳定域不同。 同一对象用 ZOH 与 Tustin 得到的 $G(z)$ 分子不同，$K_{\max}$ 也不同。控制器在嵌入式里实际执行的是差分方程，与设计时用的离散化方法必须一致；用 Tustin 设计、用前向差分实现，等于换了一个系统。

这个差别不是百分之几，而是定性的。以 $T_s = 0.1$ s 为例，ZOH 给出

$$G_{\text{zoh}}(z) = \frac{0.04683z + 0.04381}{z^2 - 1.81873z + 0.81873}, \qquad K_{\max} = 4.138$$

而 Tustin 给出

$$G_{\text{tus}}(z) = \frac{0.02273z^2 + 0.04545z + 0.02273}{z^2 - 1.81818z + 0.81818}$$

后者的分子可以提出 $(z+1)^2$，闭环根在 $K \to \infty$ 时趋于 $z = -1$（从圆内趋近）。数值验证：$K = 1000$ 时最大根模为 0.9962，$K = 10^5$ 时为 0.99996，始终小于 1。也就是说，**用 Tustin 判稳会得出“任意增益都稳定”，而 ZOH 给出的是 4.14**。原因在于 ZOH 如实反映了“执行器在一个周期内保持指令”这一物理事实，其等效延迟约 $T_s/2$；Tustin 只是一种数值积分规则，不建模保持环节。工程结论很明确：**判稳必须用 ZOH（或精确延迟），Tustin 只用于把连续校正器转成差分方程**。顺带一提，`matched` 方法在含积分环节时会因零极点增益不匹配而失败，不能作为默认选项。

坑二：采样周期不是常数。 现场的控制周期常被通信抖动拉长，T_s 从 1 ms 抖到 3 ms 时，等效延迟跟着变。按表 38-4 的规律，T_s 从 0.08 s 增到 0.12 s（+50%），$K_{\max}$ 从 5.14 掉到 3.47（-32%）；增到 0.15 s 时只剩 2.81。这个敏感度与“多加一个 50 ms 延迟”同量级。工程上应按最长实际周期（而非平均值）核算稳定域，并把周期抖动算进安全系数：若周期可能抖动 $\pm 30\%$，按 $1.3T_s$ 算出的 $K_{\max}$ 才是可信的上界。

38.5.6 三阶对象：采样把稳定域砍掉一半

§38.5.1 用的对象是纯二阶，没有执行器滞后，因此 $T_s = 0.1$ s 时的 $K_{\max} = 4.14$ 与连续域的 4.40 相差不大。换成 §38.4.2 的三阶对象（带 50 ms 执行器滞后），结论就完全不同。

$T_s = 0.1$ s、ZOH 离散后

$$G(z)=\frac{0.020493z^2+0.050954z+0.006921}{z^3-1.954066z^2+1.064869z-0.110803}$$

取 $K=2$，闭环特征多项式为

$$D(z)=z^3-1.91308z^2+1.166778z-0.096960$$

三个根为 $0.9075\pm\mathrm{j}0.4065$ 与 0.0981，最大模 0.9944，**贴着单位圆**。按 Jury 判据逐条核对：$D(1)=0.1567>0$；$(-1)^3D(-1)=4.1768>0$；$|a_0|=0.0970<1$。再算 b 行：$b_0=-0.9906$、$b_1=1.7999$、$b_2=-0.9813$，$|b_0|-|b_2|=0.0093$；c 行给出 $|c_0|-|c_1|=0.0016$。所有条件都过，但后两级裕度已经小到小数点后第三位——这正是 Jury 判据“分级裕度”的实用价值：它不只回答“稳不稳”，还告诉你“离边界还有几层”。

把这个结构在 $T_s=0.1$ s 下的临界增益扫出来，只有 $K_{\max}=2.144$，比连续域的 4.40 低了 51%。更严重的是：§38.8 推荐的工作点 $K=2.2$，在连续域还有 50% 余量，采样后已经越界（$K=2.2$ 时最大根模 1.0022）。**同一套增益，模拟调试通过、数字控制器上线就振**，原因就在这里——采样把 ZOH 的 $T_s/2=50$ ms 等效延迟叠加到原有的 50 ms 执行器滞后上，延迟翻倍，稳定域腰斩。

这条结果也给 §38.10.3 的采样周期选择提供了硬依据：T_s 不是“越小越好”的原则性口号，而是可以直接换算成 $K_{\max}$ 的设计变量。本例若要求 $K\ge 2$ 且保留 50% 余量，T_s 必须降到 0.05 s 以下。

越界幅度也值得换算成时间。$K=2.2$ 时最大根模 1.0022，对应的等效实部为 $-\ln(1.0022)/0.1=-0.022$ 1/s，时间常数约 45 s——所以现场看到的是“几十秒里慢慢振大”，而不是“一上电就炸”。这种缓慢发散最容易被当成“外界干扰”，等到振幅明显时，往往已经运行了几个小时。

38.6 稳定性与性能

§38.4 已经暴露出一个矛盾：$K=4.0$ 判稳，最大实部只有 -0.077，用它做位置环，操作工会说“这机器在飘”。判据回答的是“极点是否在我方阵地”，工程要的是“极点离边界有多远、衰减有多快”。本节把这条距离量化，并给出仍用代数判据完成量化的办法。

展开顺序是“定义—计算—边界”：先定义三种距离，再用 σ 位移把第一种算出来，最后说明哪一类指标代数判据根本给不了，必须换工具。

38.6.1 三个“距离”指标

极点距离稳定边界有不止一种量法，三种在工程上各有用途。

实部余量 σ：定义为 $-\max_i \operatorname{Re} s_i$，即主导极点到虚轴的距离（单位 1/s）。它直接对应衰减时间常数 $\tau=1/\sigma$，是最常用的指标。σ 从 0.077 增到 0.737，衰减时间常数从 13 s 缩到 1.36 s，这是同一结构下“能用/不能用”的分界。

阻尼比 ζ：主导极点与负实轴的夹角决定 $\zeta=\cos\theta$。它管的是超调，与 σ 是两个独立方向：极点可以离虚轴很远但阻尼很小（虚部大），响应衰减快但振荡剧烈。

增益余量：$K_{\max}/K$ 的比值，管的是“参数漂到多少倍会失稳”。§38.1.1 的事故就是这一项不够。

三者不能互相替代。表 38-2 里 $K=1.0$ 与 $K=2.2$ 的 σ 相差 1.6 倍，但两者的 ζ 分别只有 0.236 与 0.099，超调都在 46%–71% 量级；反过来，一个 $\zeta=0.7$ 的系统若 σ 很小，超调合格但调节时间极长。工程验收通常要同时给 σ（或 t_s）与 ζ（或 M_p）两个约束。

一对更极端的例子能说明这种独立性：极点 $-0.2 \pm \mathrm{j}0.6$ 与 $-5 \pm \mathrm{j}14.6$ 的阻尼比都约 0.32，超调同为 35% 上下，但前者的 $\sigma = 0.2$、$t_s \approx 20\,\mathrm{s}$，后者的 $\sigma = 5$、$t_s \approx 0.8\,\mathrm{s}$——**同样的超调，快慢差 25 倍**。只按 M_p 验收，前者会被放行，而它在现场表现为“晃二十秒才停”。

38.6.2 σ 位移：用 Routh 表判“衰减够快”

要求所有极点满足 $\operatorname{Re} s < -\sigma$（$\sigma > 0$），等价于要求多项式

$$D_\sigma(w) = D(w - \sigma) \tag{38-32}$$

的全部根在左半平面。理由：若 $D(s)$ 的根为 s_i，则 $D(w-\sigma)$ 的根为 $w_i = s_i + \sigma$，实部为 $\operatorname{Re} s_i + \sigma$，小于零当且仅当 $\operatorname{Re} s_i < -\sigma$。

于是问题又变回普通判稳，只是系数要重算一遍。对三阶 $a_3 s^3 + a_2 s^2 + a_1 s + a_0$，把 $s = w - \sigma$ 代进去逐项展开：

$$a_3 (w-\sigma)^3 = a_3 w^3 - 3a_3\sigma w^2 + 3a_3\sigma^2 w - a_3\sigma^3$$

其余三项同理，合并同类项后得

$$\begin{aligned} a'_3 &= a_3 \\ a'_2 &= a_2 - 3a_3\sigma \\ a'_1 &= a_1 - 2a_2\sigma + 3a_3\sigma^2 \\ a'_0 &= a_0 - a_1\sigma + a_2\sigma^2 - a_3\sigma^3 \end{aligned} \tag{38-33}$$

系数规律是二项式展开：$(w-\sigma)^k$ 的 σ^j 项系数为 $(-1)^j \binom{k}{j}$，所以 σ 的奇次幂全带负号。a'_0 的最后一项是 $(-\sigma)^3$ 给出的 $-a_3\sigma^3$，a'_2 的是 (-3σ) 给出的 $-3a_3\sigma$，这两处最容易被写成加号。

符号一旦写反，后果比算错数值更严重。若把式 (38-33) 全改成加号，实际算的是 $D(w+\sigma)$，它的根是 $w_i = s_i - \sigma$，条件是 $\operatorname{Re} s_i < \sigma$——对任何本来就稳定的系统、任何 $\sigma > 0$ 都成立，于是判据会告诉你“σ 想取多大都行”。这个错误不会报错、不会异常，只会给出一个乐观到荒谬的 $\sigma_{\max}$，而且它“通过”了所有检查。判别方法很简单：**取 σ 等于你已知的最大实部绝对值**（本例 0.4537），正确实现应当恰好卡在边界上；若算出远大于它的数，先查符号。

38.6.3 一次完整的位移计算

仍取三阶对象式 (38-18)，$K = 2.2$，特征多项式 $D(s) = 0.05s^3 + 1.1s^2 + 2s + 22$。先用数值求根知道真值是 $\sigma_{\max} = 0.4537$，再用判据验证这个数能否被算出来。

取 $\sigma = 0.4$，按式 (38-33) 得

$$D_{0.4}(w) = 0.05w^3 + 1.04w^2 + 1.144w + 21.373 \tag{38-34}$$

三阶判据要求 $a'_2 a'_1 > a'_3 a'_0$：左边 $1.04 \times 1.144 = 1.1898$，右边 $0.05 \times 21.373 = 1.0686$，成立，说明所有极点实部小于 -0.4。

取 $\sigma = 0.45$，系数变为 $0.05,\ 1.0325,\ 1.0404,\ 21.318$，左右两侧分别为 1.0742 与 1.0659，仍成立，但差距只剩 0.8%。

取 $\sigma = 0.46$，左右两侧变为 1.0514 与 1.0654，不等式翻转，判不稳。可见 $\sigma_{\max}$ 落在 0.45 与 0.46 之间，与数值求根的 0.4537 一致。

把这个数直接代回可以确认判据的零点与真实最大实部重合：$\sigma=0.4537$ 时系数为 $0.05,\ 1.0319,\ 1.0327,\ 21.314$，左右两侧之差仅 9.4×10^{-6}，相当于 0.0009% 的相对误差。这也说明位移判据的精度上限不在判据本身，而在你愿意把 σ 试到第几位。

实际实现用二分而不是解析解，原因有两条。其一，四阶以上的余量是 σ 的高次多项式（三阶已是 σ 的三次），解析求根又把问题绕回了“解方程”；其二，二分只需要一个可靠的过零判据——余量在 $\sigma_{\max}$ 两侧必然异号，而每算一次余量只需六七次乘加。工程精度到三位有效数字即可，20 次二分已把区间压到 10^{-6}，远超系数本身的误差。

这个例子的价值在于：**整个过程中没有解过一次三次方程**，只用加减乘除就把“最慢的模态衰减多快”算到了 1% 精度。图 38-8 把三个 σ 下的可行域画在同一张图上，纵轴是判据余量 $a_2'a_1'-a_3'a_0'$，横轴是 σ；曲线穿过零点的位置就是 $\sigma_{\max}$。

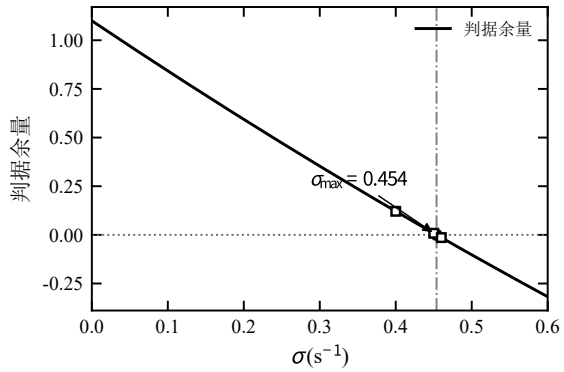

图 38-8　σ 位移后的判据余量与相对稳定度

38.6.4 从 σ 到调节时间

二阶欠阻尼系统有 $t_s\approx 4/(\zeta\omega_n)=4/\sigma$（±2% 带）。这个 4 不是凑出来的：包络线按 $\mathrm{e}^{-\sigma t}$ 衰减，落到初值的 2% 需要 $\sigma t=\ln(1/0.02)=3.91$，取整为 4；若按 ±5% 带（第 37 章的口径），系数是 $\ln 20=3.00$，同一个系统报出的 t_s 会小 23%。这就是 §38.12.4 强调“调节时间必须统一带宽”的原因——不是小数点问题，而是分子换了。

用 $K=2.2$ 这一档具体算一遍：$\pm2\%$ 给 $4/0.4537=8.82$ s，$\pm5\%$ 给 $3.00/0.4537=6.61$ s。两条都“对”，差 25%（比 23% 略大，因为 4 已经把 3.91 向上取了整）。同一份阶跃曲线被两个人报成 8.8 s 与 6.6 s，验收会上就会争起来；解决办法只有一个：在合同里写清带宽，并在代码里把带宽做成显式参数。

三阶系统只要主导极点对清晰、第三极点足够远，同一近似仍可用。用表 38-2 的数据核对：

- $K=1.0$：$\sigma=0.737$，$4/\sigma=5.43$ s，实测 $t_s=5.36$ s，误差 -1.3%；
- $K=2.2$：$\sigma=0.454$，$4/\sigma=8.82$ s，实测 $t_s=8.45$ s，误差 -4.2%。

误差来自第三极点（-22 与 -21 附近）的残余分量：第三极点越远，近似越好。这条核对关系在工程上很实用——**只要算出一个 σ，就能在几秒内估出调节时间**，不必每次跑仿真。

反过来也有用：若合同要求 $t_s\le 0.5$ s，则必须 $\sigma\ge 8$ 1/s，也就是所有极点实部小于 -8。把这个要求写成 $D(s)$ 在 $\sigma=8$ 处的位移不等式，直接得到对增益与结构的要求。第 43 章设计校正装置时，用的就是这个思路：**先由指标反推需要的 σ 与 ζ，再找能把这些极点摆到位的校正网络。**

38.6.5 判据给不了什么

必须明确 Routh-Hurwitz 判据的三处盲区，否则容易过度使用。

第一，**它不给超调**。超调由阻尼比决定，而 ζ 需要知道极点的虚部，Routh 表只给实部信息。“阻尼比大于 0.5”对应 s 平面上的一个楔形区域，边界是两条过原点的射线，不是垂直线，无法用实系数多项式的 Routh 表直接判定。工程上通常用两条路绕过去：数值求根后算 ζ，或者用 §38.9 的 LMI 方法。

第二，**它不给响应形状**。闭环零点来自开环零点，它们不是特征多项式的根，判据不会把它们列为考察对象；但零点会让响应先反向再正向，或把超调抬高。带右半平面零点的系统可以完全稳定，现场却表现为“一给指令先往反方向走”，判据对此一无所知。

第三，**它只对确定系数成立**。系数来自辨识、有误差时，判据只回答“标称值稳不稳”，不回答“误差范围内是否都稳”。这一点在 §38.7、§38.9 展开。

还有一处严格说不算判据的盲区，而是使用方式的陷阱：**先做零极点对消、再列特征多项式，会把不稳定的隐藏模态一起消掉**。取 $G = 1/(s-1)$、$C = (s-1)/(s+2)$，回路传函化简后是 $1/(s+2)$，闭环极点 -3，判据给出“稳定”；但被消掉的 $+1$ 仍是真实存在的物理模态，只要有扰动进入对象，那一路信号就按 e^{t} 增长，输出最终被它拖走。**判据没有错，错的是喂给它的多项式已经不是原回路的特征多项式。**工程上的防线很朴素：列式之前不要约分，$1 + GC$ 就用原始的有理式通分；若确实要化简，先把被消掉的因子单独记一笔，确认它本身稳定。

38.6.6 把性能指标画成 s 平面上的区域

σ 位移只能判“竖直线左侧”，而超调要求对应的是“楔形内部”，两者形状不同。把常用指标翻译成 s 平面区域，可以看清这一点。

- **调节时间**：$t_s \approx 4/\sigma$，要求 $t_s \le T$ 等价于 $\mathrm{Re}\, s \le -4/T$，是一条竖直线。这条线可以用 σ 位移加 Routh 精确判定。
- **超调量**：$M_p = \exp\!\left(-\pi\zeta/\sqrt{1-\zeta^2}\right)$，要求 $M_p \le M$ 等价于 $\zeta \ge \zeta_0$，即极点必须落在以负实轴为中心、半角 $\theta = \arccos\zeta_0$ 的楔形内。$M_p = 20\%$ 对应 $\zeta_0 = 0.456$、$\theta = 62.9^\circ$；$M_p = 5\%$ 对应 $\zeta_0 = 0.690$、$\theta = 46.4^\circ$。

竖直线与楔形的交集，就是“既快又不振”的可行区。麻烦在于楔形的边界是过原点的射线，不是竖直线，**没有任何实系数多项式的 Routh 表能直接判定“根都在楔形内”**——因为旋转坐标会引入复系数，判据的前提被破坏。这就是 §38.6.5 第一条盲区的几何解释。

对本例三阶对象，两条约束能否同时满足？查表 38-5，$K = 0.3$ 时 $\sigma = 0.918$，已经是全部工作点中最大的实部余量；要求 $\sigma \ge 1$（即 $t_s \le 4$ s 的近似条件）时，**没有任何 K 能满足**。而 $M_p \le 20\%$ 给出的上限是 $K \le 0.48$。把两条放在一起，可行域为空。这个结论与 §38.8.3 用实测数据得到的一致，但这里只用两个公式就看出来了，不必逐点仿真。

工程上的操作顺序因此是：先用 σ 位移做竖直线筛选（快、精确），再用数值求根算 ζ 做楔形筛选（慢一点，但没有近似），最后用仿真确认。三者都过，才进入调参。

$K = 0.3$ 这一档可以同时用两把尺子读：按锥判，$\zeta = 0.53$ 落在 20% 锥内，合格；按 $\sigma \ge 1$ 的线判，$0.918 < 1$，不合格。同一组极点得出两个相反结论——不是谁算错了，而是两个指标量的方向本来就不同，一个量角度、一个量横坐标。所以报告里必须写清用的是哪把尺子，否则“这个回路合格吗”会在评审会上变成一场没有交集的争论。

38.7 参数意义与作用

Routh 表把结论压成一个不等式，代价是隐藏了“哪个参数在起作用”。这一节把不等式拆开，逐个说明系数的物理来源、误差如何传导、以及哪些结构会让稳定域出现下界。

38.7.1 系数的物理来源

以本章的三阶回路为例：对象 $10/(s(s+2))$ 串一级执行器 $1/(0.05s+1)$，闭环特征多项式为

$$D(s) = 0.05s^3 + 1.1s^2 + 2s + 10K$$

四个系数各有明确出处：

- $a_3 = 0.05$ 是**最高阶动态的时间常数乘积**。这里是执行器的 0.05 乘上对象分母的首项系数 1。若再加一级 0.02 s 的传感器滤波，$a_3 = 0.05 \times 0.02 = 0.001$——从“一个时间常数”变成“两个时间常数的乘积”，量级掉了 50 倍。
- $a_2 = 1.1$ 是**次高阶项**，由各环节时间常数两两组合，再加对象本身的阻尼：$1 + 2 \times 0.05$。其中 1 来自 $s(s+2)$ 的 s^2 项，2×0.05 是对象阻尼系数 2 与执行器时间常数的交叉项。四阶情形为 $1 + 2(0.05 + 0.02) = 1.14$。
- $a_1 = 2$ 是**速度项**，只由对象决定（$s(s+2)$ 的 2），与增益、与执行器时间常数都无关。这一点以“控制器为纯比例”为前提；一旦加入积分或微分，a_1 就会同时含 K，灵敏度结构随之改变。
- $a_0 = 10K$ 是**增益项**，正比于开环增益。含积分环节时 $a_0 = 10K$；对象本身不含积分（如 $10/(s+2)$）时 $a_0 = 1 + 10K$，多出来的“1”意味着即使增益为零系统也有一组固定极点。

这个对应关系解释了一个常见现象：**调增益只动 a_0，稳定边界却由 a_1 与 a_2 的配合决定**。所以“为什么增益不能再大”的答案往往不在增益本身，而在时间常数——执行器慢了、滤波器加了，边界自然下移。

三阶条件 $a_2 a_1 > a_3 a_0$ 还可以两边同除 $a_3 a_2$，写成两个“频率平方”的比较：

$$\frac{a_1}{a_3} > \frac{a_0}{a_2} \quad \Longleftrightarrow \quad 40 > \frac{10K}{1.1} \tag{38-19a}$$

左边 $a_1/a_3 = 2/0.05 = 40$ 只由对象的速度项与执行器时间常数决定，是一个结构常数（量纲 s^{-2}，开方后 6.32 rad/s）；右边 $a_0/a_2 = 10K/1.1$ 随增益线性增长。**稳定条件因此可以读成一句话：增益把“工作频率的平方”推高，一旦超过结构常数就不稳。**这也正好解释了边界频率公式 $\omega_{osc} = \sqrt{a_0/a_2}$（式 38-20）——边界处两者相等，$\omega_{osc}$ 就是那个结构常数的开方。四阶、五阶没有这么整齐的读法，但只要 s^1 行的首元能写成“两个量之比”，就可以照此解释。

38.7.2 系数误差怎样传到 $K_{\max}$

三阶结构的临界增益有显式表达：

$$K_{\max} = \frac{a_2 a_1}{10 a_3} \tag{38-35}$$

取对数再求偏导，得相对灵敏度

$$\frac{\partial \ln K_{\max}}{\partial \ln a_1} = 1, \qquad \frac{\partial \ln K_{\max}}{\partial \ln a_2} = 1, \qquad \frac{\partial \ln K_{\max}}{\partial \ln a_3} = -1 \tag{38-36}$$

也就是说，a_1、a_2 各偏 20%，$K_{\max}$ 就偏 20%；a_3 偏 20%，$K_{\max}$ 反向偏 17%。用式 (38-18) 的基准值验证（$K_{\max}=4.4$）：

- a_3 从 0.05 增到 0.06（+20%）：$K_{\max}=3.667$，下降 16.7%；
- a_2 从 1.1 降到 0.88（-20%）：$K_{\max}=3.52$，下降 20%；
- a_1 从 2 降到 1.6（-20%）：$K_{\max}=3.52$，下降 20%。

这条 1:1 的传导关系有两个直接用途。第一，它给安全系数提供了量化依据：若系数不确定度为 $\pm15\%$，则 $K_{\max}$ 的不确定度约为 $\pm30\%$（两个系数叠加），取 50% 的安全系数刚好覆盖。第二，它说明“边界随系数连续变化”，因此可以用小范围扫描代替解析推导。

比“系数偏 20% 会怎样”更贴近现场的问题是：**到底哪个系数在变**。三个系数里，a_1 由对象决定，除非换设备几乎不动；a_2 与 a_3 都含执行器时间常数，而执行器的快慢恰恰随负载、油温、气源压力漂移。所以现场真正在漂的是 a_3 与 a_2，且两者同向：执行器变慢，两个一起变大，一个抬高分子、一个抬高分母，效果部分抵消。

沿执行器时间常数扫描（对象增益不动），得到

执行器滞后 τ_a (s)	a_3	a_2	$K_{\max}$	相对 50 ms
0.02	0.020	1.04	10.40	$+136\%$
0.05	0.050	1.10	4.40	—
0.08	0.080	1.16	2.90	-34%
0.10	0.100	1.20	2.40	-45%
0.15	0.150	1.30	1.73	-61%
0.20	0.200	1.40	1.40	-68%

表里 a_2 只从 1.10 涨到 1.20，a_3 却翻了一倍，主导项是 a_3 的 -1 次方。τ_a 从 50 ms 漂到 100 ms，$K_{\max}$ 从 4.40 掉到 2.40，正好腰斩。这就是“同一套参数，夏天好用、冬天振”的机理：液压油黏度随温度变化，执行器时间常数能从 50 ms 漂到 100 ms 以上，而操作工看到的只是“阀门还是那个阀门”。

再加一级传感器滤波，情形更差（执行器固定在 50 ms）：

传感器滤波 τ_s (s)	阶次	$K_{\max}$	相对无滤波
0	三阶	4.40	—
0.02	四阶	3.09	-30%
0.05	四阶	2.20	-50%
0.10	四阶	1.55	-65%

20 ms 的滤波——只是想把测量噪声压一压——就吃掉了 30% 的稳定域。这是“参数没动、边界自己跑了”最常见的来源：为了曲线好看加一级滤波，裕度就少了一截，而滤波器的时间常数往往不写进调参记录。

但这条公式只在**结构不变、只动系数**时成立。§38.1.1 的收卷机换工况时，惯性时间常数从 0.5 s、1 s 变为 1.5 s、3 s，分子上的超前零点 $1+0.05s$ 却不变，整个多项式族已经换了，$K_{\max}$ 从 3.30 掉到 1.04，不能用式 (38-35) 外推。**判断灵敏度之前，先确认结构有没有变**；结构一变，唯一可靠的做法是重算 Routh 表。

四阶以上的灵敏度不是常数的乘积关系，但“$K_{\max}$ 随系数连续变化、且在高阶结构中对小系数更敏感”这一结论仍然成立。工程上建议直接做数值扫描：把每个系数在 $\pm 20\%$ 内取五点，共 $5^4 = 625$ 组，一次批量算完。

图 38-9 给出三阶结构下 $K_{\max}$ 对三个系数摄动的响应曲线，三条线的斜率恰好是 $+1$、$+1$、-1。

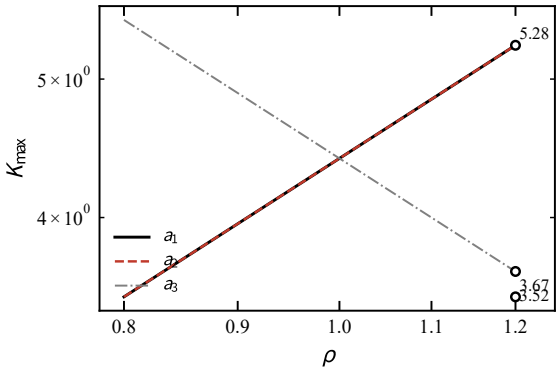

图 38-9　系数摄动对临界增益的影响

38.7.3 缺项意味着什么

系数为零不是“不影响”，而是“结构缺了一块”。三种缺项的后果不同：

- $a_0 = 0$：闭环在原点留了一个极点，等价于闭环里多了一个积分器。阶跃指令下输出持续爬升、没有稳态可言；若这个零来自“增益置零”，那就是开环状态，本来就未闭环。Routh 表第一列最后一项为零，判据只能给“临界”。
- $a_1 = 0$：缺速度项。二阶情形（$s^2 + a_0$）退化为无阻尼摆，极点落在虚轴上，任何激励都引起等幅振荡，属临界；三阶情形更糟——取 $s^3 + 1.1s^2 + 22$，根为 -3.221 与 $1.060 \pm j2.389$，实部为正，振荡是**发散**的。工程上多见于“两个积分器串联加纯比例控制”（位置环套速度环时漏了速度反馈）。结论：三阶及以上，缺速度项不是“振而不散”，而是“振着散”。
- $a_2 = 0$：三阶系统缺二次项。必要条件“系数全正”这一步就过不去；若硬用 ε 法列完表，s^1 行首元含 $-a_0/\varepsilon$ 项，随 $\varepsilon \to 0$ 趋于 $-\infty$，第一列必然出现两次符号变化。取 $s^3 + 2s + 22$ 验证，根为 -2.565 与 $1.282 \pm j2.633$，确实两个右半平面根。结论是**无论增益取多少都不稳**，这类结构必须改，不能靠调参救。

38.7.4 稳定域不一定从零开始

式 (38-35) 给出的区间是 $(0, K_{\max})$，默认下界为零。但对象含不稳定极点时，下界会大于零。取

$$G_p(s) = \frac{1}{s - 1} \tag{38-37}$$

闭环特征方程为 $s - 1 + K = 0$，根为 $s = 1 - K$，稳定条件 $K > 1$。**增益太小反而不稳**，这一点在现场很有迷惑性：操作工发现系统抖，第一反应是“把增益调小”，结果直接把系统推进了不稳定区。

下界附近还有第二重危险：即便还在稳定域内，响应也慢得不能用。$K = 1.1$ 时极点为 -0.1，时间常数 10 s、$t_s \approx 40$ s；$K = 2$ 时极点为 -1，$t_s \approx 4$ s。也就是说，这个对象虽然 $K > 1$ 就稳，但真正可用的工作点在 $K \geq 2$，**稳定域的下界与可用域的下界不是同一个数**。写档案时两者都要给，否则换个人按“$K > 1$ 即可”调试，会得到一台“稳但不动作”的设备。

含不稳定极点的对象在过程工业里并不罕见：放热反应的温度回路、某些压缩机喘振工况、倒立摆类机构的小车位置环。判稳时必须把下界一起算出来，并确认工作点在区间内部、且距两端都有余量。

右半平面零点不会让系统在“极点意义”上失稳，却会带来两个实际后果：一是阶跃指令下输出先反向，反向幅度与零点位置有关，通道间的同步性会被破坏；二是可用带宽被零点位置限制，增益不能再往上提。判断这类系统不能只看 $K_{\max}$，还要看反向幅度与带宽，详见 §38.11。

38.7.5 延迟怎样进入系数

纯延迟 $\mathrm{e}^{-T_d s}$ 不是有理函数，无法直接列 Routh 表。工程上的处理是 Padé 近似。二阶 Padé 为

$$\mathrm{e}^{-T_d s} \approx \frac{1 - \frac{T_d}{2}s + \frac{T_d^2}{12}s^2}{1 + \frac{T_d}{2}s + \frac{T_d^2}{12}s^2} \tag{38-38}$$

它把延迟变成一对零点与一对极点，代入式 (38-18) 后特征多项式升到五阶。用同一对象算出不同延迟下的 $K_{\max}$：

延迟 T_d (s)	$K_{\max}$	相对无延迟
0	4.40	—
0.02	3.07	-30%
0.05	2.13	-52%
0.10	1.43	-68%

延迟 50 ms（只相当于执行器滞后的量级）就让稳定域腰斩，这解释了为什么“实验室调好、现场振”是常态：实验室的管路短、通信快，现场的延迟在 20–100 ms 量级，正好落在最敏感的一段。

使用 Padé 近似有两个陷阱必须说明。第一，**阶次越低越危险**。一阶 Padé $(1 - T_d s/2)/(1 + T_d s/2)$ 在右半平面引入一个零点，会低估相位滞后，给出偏乐观的 $K_{\max}$；二阶 Padé 的误差在 $\omega T_d < 1$ 时约 1%，边界频率处的相位误差约 3°。第二，**Padé 只在低频段准确**。若边界频率满足 $\omega_{osc} T_d$ 接近 1，近似已经不可靠，应改用精确延迟配合数值扫根（本章代码里的 `kmax_scan` 就是这么做的）。

图 38-10 把延迟从 0 扫到 0.12 s 的 $K_{\max}$ 曲线画出来，并标出“实验室可接受”与“现场常见”两段区间。可以看到曲线在 0.1 s 之后趋于平缓，说明延迟大到一定程度后，稳定域不再随延迟剧烈变化，但此时 $K_{\max}$ 已不足 1.4，可用性极差。

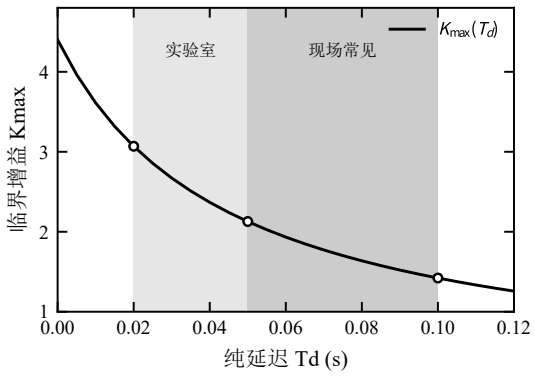

图 38-10　纯延迟对临界增益的压缩

38.7.6 把“离边界多远”折成两个数

前面几小节回答的是“边界在哪”，现场更关心的是“工作点离边界多远”。这件事用一个数说不清，至少需要两个：

- **增益余量** $K/K_{\max}$，无量纲，直接对应“还能再加多少增益”；
- **实部余量** $\sigma = -\max_i \operatorname{Re} s_i$，量纲是 s^{-1}，对应“最慢的振荡衰减多快”。

  两者的走向并不一致。对本例三阶对象：

K	$K/K_{\max}$	σ	$1/\sigma$ (s)	实测 t_s (s)
0.5	11%	0.865	1.16	3.84
1.0	23%	0.737	1.36	5.36
2.2	50%	0.454	2.20	8.45
3.0	68%	0.280	3.57	—

$K = 1.0$ 只用到临界增益的 23%，看上去“余量很足”，可 σ 已从 0.865 降到 0.737，调节时间从 3.8 s 拉到 5.4 s；$K = 2.2$ 恰好是 $K_{\max}$ 的一半，按民间“留一半”的口径正合适，实测却要 8.5 s 才稳定到 $\pm 2\%$。**增益余量合格不代表动态合格**，这是 §38.8.2 要专门拆开的误区。

反过来，σ 大也不代表超调小。σ 只管包络衰减，不管振荡次数；一个 $\sigma = 1$、$\zeta = 0.1$ 的系统衰减很快，但超调仍有 70%。所以完整的余量描述是三个数：$K_{\max}$（边界位置）、$K/K_{\max}$（增益余量）、σ 与 ζ（动态品质）。这三个数都不依赖仿真波形，全部可以由 Routh 表与求根直接算出，适合写进交付档案（§38.10.1）。

38.8 调参方法与经验

§38.7 给的是“边界在哪”，本节解决“工作点选哪”。核心是两条约束的联立：**稳定约束给上限，性能约束给更紧的上限，两者取小**。当两条约束没有交集时，答案不是继续调参，而是改结构。

38.8.1 稳定约束与性能约束

对式 (38-18) 的三阶对象，稳定约束是 $K < 4.4$。性能约束要看合同指标。设要求为 $M_p \le 20\%$、$t_s \le 4$ s（±2% 带），把表 38-5 的实测数据拿出来对照。

增益 K	σ (1/s)	M_p (%)	t_s (s)	判定
0.3	0.918	13.8	3.40	两项均满足
0.5	0.865	26.3	3.83	超调超标
0.8	0.787	39.4	4.97	两项超标
1.0	0.737	46.1	5.36	两项超标
1.5	0.615	58.7	6.11	两项超标
2.2	0.454	71.4	8.45	两项超标

表 38-5 说明一件反直觉的事：**在这条回路上，“响应更快”与“超调更小”不是同一个方向**。K 从 0.3 增到 1.0，上升时间确实变短（$K = 1$ 时为 0.41 s），但超调从 13.8% 涨到 46.1%，调节时间反而从 3.40 s 拉长到 5.36 s。原因是这个对象的开环只有一个积分环节，增益提高使阻尼比单调下降，振荡成分主导了尾部。

用两个量可以把这件事说清楚。上升时间主要由自然频率 ω_n 决定，调节时间主要由 $\sigma = \zeta\omega_n$ 决定，超调只看 ζ。本例 K 从 0.3 增到 2.2 时，ω_n 从 1.73 增到 4.57（上升段更陡），ζ 从 0.532 降到 0.099（振荡更强），σ 从 0.918 降到 0.454（尾部更长）。三个量朝三个方向走，说明“加增益”从来不是单一效果。工程上因此必须把 t_r 与 t_s 分开验收——它们不是同一个指标的不同说法，而是分别对应 ω_n 与 $\zeta\omega_n$。

因此调参不能只盯“快不快”。工程上正确的顺序是：先用稳定判据划出 K 的上限，再用 M_p 划出更紧的上限，最后用 t_s 检查下限是否可行。三个条件都满足，才叫“调好了”。

38.8.2 50% 规则及其失效场合

“取 $K_{\max}$ 的一半”是行业里流传最广的经验，它的依据是 §38.7.2 的灵敏度分析：系数误差 $\pm 15\%$ 会让边界漂 $\pm 30\%$，留一半余量刚好覆盖。对本例，$0.5K_{\max} = 2.2$。

但表 38-5 显示，$K = 2.2$ 的超调是 71.4%。**50% 规则保证了“不会振散”，完全没有保证“能用”**。这条经验在两类场合会严重误导：

- **低阻尼对象 + 纯比例控制**。本例就是，零点是 0、只有积分环节，纯比例下阻尼比天然偏低。这时起决定作用的不是边界，而是阻尼。
- **带延迟的回路**。延迟附近的稳定域对延迟极敏感（§38.7.5），50% 的余量可能被 20 ms 的额外延迟吃掉。

正确的表述应该是：**先把稳定边界算出来，用它做上界；再从性能指标反推工作点；两者的比值才是真正的安全系数，而不是反过来先定 50% 再算边界。**

还有一层常被忽略：50% 规则里的 50% 是对**系数不确定性**留的，不是对**未建模动态**留的。§38.7.5 的数据显示，只加 20 ms 纯延迟，$K_{\max}$ 就从 4.40 掉到 3.07；此时 $K = 2.2$ 的比值从 50% 升到 72%，余量只剩 28%。若延迟漂到 50 ms，$K_{\max} = 2.13$，$K = 2.2$ 直接越界。同一个工作点，在“系数偏 15%”的场景下余量够用，在“多 20 ms 延迟”的场景下不够用，两件事不能混为一谈。

这条规则真正成立的场合有两个特征：对象以一阶惯性为主（无超调，性能约束本来就松），且不确定度只来自系数。一旦对象含积分、含欠阻尼对、或含延迟，50% 就只能当“上界的一半”来用，绝不能当“可以放心用”的通行证。

38.8.3 从指标反推工作点

用 σ 与 t_s 的近似关系（§38.6.4）可以把性能指标翻译成对 σ 的要求。要求 $t_s \le 4$ s，则

$$\sigma \ge \frac{4}{t_s} = \frac{4}{4} = 1.0\ \mathrm{s}^{-1} \tag{38-39}$$

查表 38-5，$K = 0.3$ 时 $\sigma = 0.918$，按近似式还差 8%；但实测 $t_s = 3.40$ s 已进入 4 s 以内，说明近似偏保守。再看超调要求 $M_p \le 20\%$：$K = 0.3$ 给出 13.8%，满足；$K = 0.5$ 已到 26.3%，不满足。两条约束夹出一个窄区间，大致 $0.25 < K < 0.35$。

把 $K = 0.3$ 的 $\sigma = 0.918$ 代入式 (38-39) 反算，$t_s \approx 4/0.918 = 4.36$ s，与实测 3.40 s 有偏差——因为第三极点 -21 的快速衰减分量对尾部有贡献，使实测值偏小。**近似式用于初选，最终必须以仿真或实测为准**；这是本节唯一不能省的一步。

这里还有一个容易踩的坑：§38.4.1 的 $\zeta = 1/\sqrt{10K}$ 只对**理想二阶**成立。三阶以上要算 ζ，必须先求根、取实部最大的那一对，再按 $\zeta = -\mathrm{Re}\,s/|s|$ 计算。若图省事直接丢掉最高阶项做降阶（$0.05s^3 + 1.1s^2 + 2s + 10K \approx 1.1s^2 + 2s + 10K$），得到的是 $\zeta = 1/\sqrt{11K}$，结论会系统性偏乐观：

K	降阶法 ζ	降阶法 M_p (%)	求根法 ζ	求根法 M_p (%)	实测 M_p (%)
0.3	0.551	12.6	0.532	13.9	13.8
0.5	0.426	22.7	0.389	26.5	26.3
0.8	0.337	32.5	0.281	39.8	39.4
1.0	0.302	37.0	0.236	46.6	46.1
1.5	0.246	45.0	0.162	59.7	58.7
2.2	0.203	52.1	0.099	73.1	71.4

原因不复杂：本例第三个极点约在 -21（由根之和 $-a_2/a_3 = -22$ 扣掉主导对即得），它与 0.05 这个系数一起，把 a_2 从 1 抬到了 1.1。降阶时保留 1.1，等于把这个快极点的贡献算进了阻尼，凭空多出 10% 的“阻尼”。$K = 2.2$ 时两种算法给出的超调预测相差 19.3 个百分点，而降阶法恰好落在“看起来还能接受”的一侧——这正是危险的来源。求根法六档的误差都在 1.7 个百分点以内。

所以工程上的顺序是：Routh 表判稳 → 数值求根 → 取主导对算 ζ → 套二阶公式估 M_p → 仿真确认。前四步都是毫秒级计算，最后一步只用来验证，不用来试错。

若合同要求 $t_s \le 1$ s、$M_p \le 5\%$，则 $\sigma \ge 4$、$\zeta \ge 0.69$。把这两个要求画到 s 平面上是“垂直线右侧 + 楔形内部”的交集，而本例纯比例下所有极点都落在 $\sigma < 1$ 的区域，**交集为空**。此时无论 K 取何值都无解，必须加微分（提高阻尼）或加速度反馈（把极点往左推），这属于第 43、44 章的内容。

图 38-11 把 M_p、t_s、σ 三条曲线与稳定边界画在同一张图上，横轴是 K。三条曲线与指标线的交点围出的区间就是可行域；图中可行域极窄，直观解释了“为什么这台机器怎么调都不顺手”。

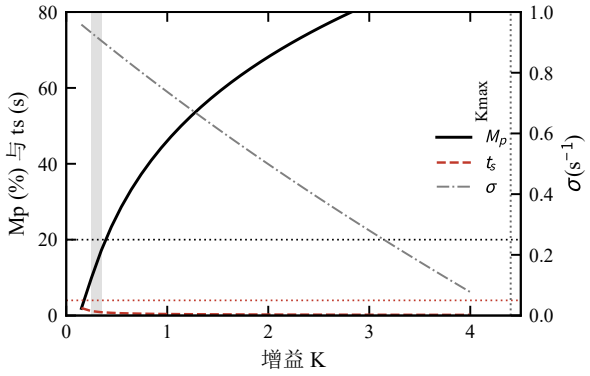

图 38-11　增益—超调—调节时间的可行域

38.8.4 现场整定的五条经验

1. **先算后调**。把结构、$K_{\max}$、当前工作点三件事写进调试记录，再动手。没有这三个数，“再降一点试试”就是盲调。
2. **一次只动一个参数**。同时改增益和滤波会掩盖因果，出问题无法定位。
3. **用振荡频率反推原因**。实测振荡频率接近 ω_{osc}（本例 6.32 rad/s）说明是增益过高触及边界；远低于它说明是积分饱和或机械共振；远高于它说明是采样或噪声问题。三种原因的处理方式完全不同。
4. **边界必须随工况重算**。§38.1.1 的事故就出在这一条。凡是惯性、延迟、滤波随工况变化的设备，都应在最恶劣工况下算边界。

5. **改结构优于压参数**。当可行域为空时（§38.8.3 的例子），继续压 K 只会把系统变成“稳但慢”，正确做法是加校正。

这五条的顺序本身就是流程：算边界 → 定工作点 → 用频率定位原因 → 换工况重算 → 改结构。现场最容易跳过的是第一条和第四条，因为两者都不产生“看得见的动作”。§38.1.1 的事故恰恰是跳过了第四条：换工况后没人重算，旧参数在新惯性下越界。

第三条的定量依据值得单独说。本例边界频率 $\omega_{osc} = 6.32$ rad/s，折合 1.01 Hz。若实测抖动就在 1 Hz 附近、且幅值随增益单调增大，基本可以断定是增益过高触及边界；若抖动在 10 Hz 以上、幅值与增益关系不明显，应查采样与噪声；若落在 2–5 Hz 且随负载变化，优先怀疑机械间隙与共振。三种原因的处置方向完全不同：第一种降增益或加阻尼，第二种改采样率或加滤波，第三种只能改机械或加陷波器。方向用错，越努力越糟——把采样引起的抖动当成增益问题去降 K，只会让系统变慢而抖动照旧。

38.8.5 三个常见误判

- **“超调合格就没问题”**：超调只看阻尼，不看余量。一个 $M_p = 5\%$、$K/K_{\max} = 0.95$ 的系统，超调合格但一遇扰动就振。
- **“增益越小越安全”**：只对下界为零的结构成立。含不稳定极点的对象（§38.7.4）正好相反：$G_p = 1/(s-1)$ 在 $K = 0.5$ 时闭环极点为 $+0.5$，越小越不稳，必须 $K > 1$。
- **“仿真稳了现场就稳”**：仿真里没有未建模的执行器滞后、传感器滤波、通信延迟。本例每一样单加 20 ms，$K_{\max}$ 就从 4.40 掉到 3.09（滤波）与 3.07（延迟）；两样叠加（执行器仍是 50 ms），$K_{\max}$ 只剩 2.38。此时 $K = 2.2$ 的余量只有 8%，实测最慢极点实部 -0.064，要 15 s 才衰减到 37%——判据上“还稳”，体感上“一直在晃”。

三条误判有个共同点：都拿判据的一个输出当成了全部证据。第一条把“阻尼够”当成“余量够”，第二条把“K 小”当成“离边界远”，第三条把“仿真环境”当成“现场”。辨识方法也因此统一：**问一句“这个结论依赖了哪个尚未验证的假设”**——若答案是系数准确，就做区间分析（§38.9.2）；若是结构完整，就做扫频（§38.10.4）；若是延迟已知，就把延迟实测一遍（§38.7.5）。

第一条还值得补一个自查动作：报告里同时写 M_p 与 $K/K_{\max}$。只要后者超过 0.8，即便 M_p 只有 5%，也应按“贴边”处理——因为超调是标称工况下的数，余量才决定它在扰动下还剩多少余地。

38.9 优化与改进

§38.2 的判据在数学上已经完整，工程上仍有四类改进空间：数值鲁棒性、区间系数、参数空间二维求解、以及与其他指标的联合约束。本节按“投入产出比”从高到低排列，前三类建议所有项目都用，第四类只在明确需要时使用。

这四类改进的采用顺序也有讲究：先做数值鲁棒性（成本最低，防的是“算错”），再做区间系数（防的是“模型不准”），最后才是二维求解与联合约束（防的是“指标不够”）。前两类属于“不做就可能出错”，后两类属于“做了更好”。

38.9.1 数值鲁棒性：先缩放，再递推

Routh 表是“除法链”，前一行的小误差会被后一行放大。三阶、四阶时无感，八阶以上时会出现“判稳结论随系数末位变化”的现象。三条改进措施按顺序做，可解决九成问题。

第一，系数归一化。把整个多项式除以 $\max|a_i|$，使所有系数落在 $[0,1]$ 内。这一步不改变根，也不改变第一列符号，但能避免 10^{12} 与 10^{-3} 同表造成的溢出或下溢。要清楚它**只防溢出、不防精度损失**：取七个时间常数 $0.05,\ 0.02,\ 0.01,\ 0.005,\ 0.002,\ 0.001$ s 串一个 $1/(s+2)$，得到一个七阶多项式，系数从 1.0×10^{-13} 到 2.0，跨 13 个数量级；归一化之后第一列仍从 5.0×10^{-14} 排到 1.0，跨的仍是 13 个量级。归一化只是把所有数一起缩小，量级差原封不动。

第二，逐行缩放。递推得到的每一行都乘以一个正数，使其首元接近 1。乘正数不改变符号变化次数，却能让后续除法稳定。实现上只需在每行开始处取该行首元的绝对值 $\rho=\max(|c_1|,\epsilon)$，整行除以 ρ。这一步才是真正抑制误差放大的措施：它把“除以一个可能极小的小数”换成“除以 1 附近的数”，每一行的相对误差不再被首元倒数量级地放大。代价是失去“第一列元素就是余量度量”这一直观（§38.2.3），所以调试阶段可以两种模式都跑，用未缩放的表读余量，用缩放后的表定结论。

第三，结果交叉验证。用 `numpy.roots` 求一次特征根，比较“右半平面根数”与 Routh 表的符号变化次数。两者不一致时，以数值求根为准，同时记录该组系数——它往往正好落在边界附近，是设计上需要回避的点。

为什么必须交叉验证？因为两条路径的数值性质不同。`numpy.roots` 走的是伴随矩阵特征值，属于后向稳定算法，误差不随阶次指数放大；Routh 表是一串没有选主元的除法，第 k 行的相对误差大致被前一行首元的倒数放大。系数一旦跨几个数量级（工程上很常见：10^{-3} 的 a_n 与 10^{3} 的 a_0 同表），舍入误差就能把“稳定”翻成“不稳定”。所以六阶以上不要只信一张手工表，至少做一次求根对照。

对离散情形，还有一个额外建议：**优先走双线性 + Routh**，而不是直接实现完整的 Jury 表。原因在 §38.2.7 已说明：Jury 的每一行都是行列式，实现的出错概率高，而双线性变换只需一次多项式代换。

38.9.2 区间系数：Kharitonov 定理

辨识得到的系数总带误差。若只知道每个系数落在区间内

$$a_i\in[\underline{a}_i,\overline{a}_i],\qquad i=0,1,\dots,n \tag{38-40}$$

要判断“区间内所有取值是否都稳定”，直接枚举是不可能的（连续无穷多组）。Kharitonov 定理给出了一个只查四个顶点的办法：构造四个顶点多项式

$$\begin{aligned}
K_1(s)&=\underline{a}_0+\underline{a}_1 s+\overline{a}_2 s^2+\overline{a}_3 s^3+\underline{a}_4 s^4+\underline{a}_5 s^5+\cdots\\
K_2(s)&=\overline{a}_0+\overline{a}_1 s+\underline{a}_2 s^2+\underline{a}_3 s^3+\overline{a}_4 s^4+\overline{a}_5 s^5+\cdots\\
K_3(s)&=\overline{a}_0+\underline{a}_1 s+\underline{a}_2 s^2+\overline{a}_3 s^3+\overline{a}_4 s^4+\underline{a}_5 s^5+\cdots\\
K_4(s)&=\underline{a}_0+\overline{a}_1 s+\overline{a}_2 s^2+\underline{a}_3 s^3+\underline{a}_4 s^4+\overline{a}_5 s^5+\cdots
\end{aligned} \tag{38-41}$$

四个顶点的取法有规律，不必死记：**相邻的两个系数（偶、奇各一对）取同一端，隔一对再换端**。K_1 从 (a_0,a_1) 取下界起，(a_2,a_3) 取上界，(a_4,a_5) 又回下界；K_2 与 K_1 完全反相；K_3、K_4 则是“奇偶错位”——K_3 让 a_0 取上界、a_1 取下界、a_2 取下界、a_3 取上界。这是最容易写错的地方：**每个顶点都含全部阶次的项**，不能只写偶数项或只写奇数项。

若这四个多项式都稳定，则区间内所有多项式都稳定；若有一个不稳定，则区间内存在不稳定的取值。结论是充分必要的，前提是各系数区间相互独立。

工程用法很直接：把辨识结果写成 $\pm20\%$ 的区间，代入式 (38-41) 得四个多项式，各列一次 Routh 表。四次表换来“整个区间都稳”的结论，比抽样扫描可靠得多。

以本章三阶对象为例。取每个系数 $\pm 20\%$：$a_3 \in [0.04, 0.06]$、$a_2 \in [0.88, 1.32]$、$a_1 \in [1.6, 2.4]$，工作点 $K = 2.2$ 时 $a_0 = 10K \in [17.6, 26.4]$。四个顶点算出来是：

顶点	a_3	a_2	a_1	稳定	$\max \operatorname{Re} s$	该结构的 $K_{\max}$
K_1	0.06	1.32	1.6	是	-0.303	3.52
K_2	0.04	0.88	2.4	是	-0.679	5.28
K_3	0.06	0.88	1.6	否	$\mathbf{+0.099}$	2.35
K_4	0.04	1.32	2.4	是	-0.730	7.92

三个稳定、一个不稳定。按定理，整个区间内**存在**不稳定取值，“标称 $K = 2.2$ 稳定”这个结论在 $\pm 20\%$ 下不成立。最坏的是 K_3：执行器最慢（0.06）、阻尼项最低（0.88）、速度项最低（1.6）三者同时取到。它的临界增益是 $0.88 \times 1.6 / (10 \times 0.06) = 2.35$，比名义值 4.40 低 47%；其余三个顶点的 $K_{\max}$ 分别是 3.52、5.28、7.92，全部高于 2.35。**鲁棒临界增益要取四个里的最小值**，不能取平均，也不能只看名义值。

这张表还说明一件事：不确定度不是“均匀地”削弱稳定域，而是由最不利组合决定。K_4 的 $K_{\max}$ 高达 7.92，几乎是名义值的两倍——四个顶点里有一个“特别安全”，完全不影响结论；真正说话的是最坏的那个。工程上若只抽三五组系数做蒙特卡洛，很可能抽不到 K_3 这个角点，从而得出“区间内都稳”的错误判断。

最后一层要分清：这里的 $K_{\max} = 2.35$ 是**鲁棒稳定**的上界，与 §38.8.3 的**性能**上界 $K \approx 0.35$ 不是一回事。本例中 0.35 远低于 2.35，说明瓶颈在阻尼而不在鲁棒性——即便系数完全准确，回路也调不快。反过来，若性能要求 $K \geq 2$，鲁棒上界 2.35 就只剩 15% 的余量，此时 $\pm 20\%$ 的不确定度直接决定项目成败。判断该往哪个方向改进，先看两条上界哪条更低。

两个限制必须记住：其一，**区间必须独立**。若两个系数来自同一个物理参数（例如 a_1 与 a_0 都随 K 变化），它们的变化是相关的，Kharitonov 会给出过于保守的结论；其二，**它只判连续域**。离散域有对应的棱形（prism）判据，形式更繁，工程上通常仍走“双线性变换 + Kharitonov”。

38.9.3 二维参数空间：D-分解

实际设计很少只调一个增益。常见的是“增益 + 时间常数”或“增益 + 延迟”两个参数同时变。这时可以在参数平面上直接画出稳定边界。

边界由两类曲线构成：一类是 $s = 0$ 代入特征方程（对应 $a_0 = 0$），另一类是 $s = \mathrm{j}\omega$ 代入后令实部、虚部同时为零（对应极点穿越虚轴）。把这两类曲线画在 (K, T_d) 平面上，平面被分成若干区域，每个区域内的稳定性相同，取任一点验证即可。

对本例（式 38-18 加延迟），$s = \mathrm{j}\omega$ 代入并用二阶 Padé 后得到的是含 K、T_d、ω 的方程组，消去 ω 即得边界曲线。图 38-10 的曲线正是这条边界在 K–T_d 平面上的投影。把 §38.7.5 的四个点连起来就是这条曲线的骨架：

T_d (s)	0	0.02	0.05	0.10
边界上的 K	4.40	3.07	2.13	1.43

曲线单调下降且下凸：延迟从 0 到 0.05 s，K 掉了一半；从 0.05 s 到 0.10 s 又掉三分之一。设计时的工作方式是“先定延迟、再读上界”，而不是反过来。若延迟本身不可控（公网通信、多轴同步），则应按最坏延迟读边界，并把这个数写进配方表。

D-分解的价值在于**它把“稳定域”从一维区间升级为二维地图**，让设计者能看到“延迟增大时需要把增益降到多少”，而不是只知道当前点的余量。它还有一条常被忽略的性质：穿过 $s=\mathrm{j}\omega$ 曲线时，右半平面根数改变 2（一对共轭根过轴），因此只要在每个区域取一个点判一次，就能给整个区域定性，不必逐点扫描。这也是为什么二维图只需要几条曲线就能说清全部结论。

换成 (K,τ_a) 平面也是一样：把 §38.7.2 的六个点连起来，得到另一条边界，形状同样单调下凸。两条边界放在一起看，可以回答“同样多出 50 ms，加在执行器上还是加在纯延迟上，哪个更伤”——执行器从 50 ms 变到 100 ms，$K_{\max}$ 掉到 2.40；额外 50 ms 纯延迟，掉到 2.13。后者更伤，因为一阶滞后还提供高频衰减，纯延迟不衰减、只叠加相位。这类比较用一维公式做不出来，只有画成二维图才直观。

38.9.4 与其他指标的联合约束

Routh 表只管极点实部，若还要约束阻尼比，可以用 LMI：存在对称正定矩阵 $\boldsymbol{P}$ 使

$$\begin{bmatrix} \sin\theta\,(\boldsymbol{A}\boldsymbol{P}+\boldsymbol{P}\boldsymbol{A}^{\mathsf{T}}) & \cos\theta\,(\boldsymbol{A}\boldsymbol{P}-\boldsymbol{P}\boldsymbol{A}^{\mathsf{T}}) \\ \cos\theta\,(\boldsymbol{P}\boldsymbol{A}^{\mathsf{T}}-\boldsymbol{A}\boldsymbol{P}) & \sin\theta\,(\boldsymbol{A}\boldsymbol{P}+\boldsymbol{P}\boldsymbol{A}^{\mathsf{T}}) \end{bmatrix} \prec 0 \tag{38-42}$$

则闭环极点落在以负实轴为中心、半角 θ 的锥内，对应 $\zeta\ge\cos\theta$。这类约束可以直接放进凸优化，与 H_∞、H_2 指标联合求解，是第 57 章的主要内容。本节只需记住一点：**代数判据给的是“点”，LMI 给的是“区域”，两者的分工在第五章会反复出现。**

为什么楔形约束不能直接交给 Routh 表？因为要把“锥内”变成“左半平面”，需要把坐标旋转 θ：令 $s'=\mathrm{e}^{\mathrm{j}\theta}s$，代入后多项式系数变成复数。Routh 判据只对**实系数**多项式成立，复系数情形第一列的“符号”已经没有意义（复数不能比大小），判据直接失效。Jury 判据同理。§38.6.6 说“Routh 表无法直接判定楔形”，根因就在这里。

两个常用指标换算成半角是：$M_p\le 20\%$ 对应 $\theta\le 62.9^\circ$（$\zeta\ge 0.456$），$M_p\le 5\%$ 对应 $\theta\le 46.4^\circ$（$\zeta\ge 0.690$）。半角只收紧 16.5°，本例的可用增益就从 $K\approx 0.4$ 退到 0.2 以下：$K=0.2$ 时 $\zeta=0.670$、$M_p\approx 5.9\%$，刚好贴在 5% 的锥边；再降到 $K=0.1$，ζ 升到 0.974，σ 却只剩 0.972，调节时间反超 4 s。**指标越严，两条约束越先打架**——这就是 §38.8.3“可行域为空”在几何上的样子。

LMI 的代价是它只回答“可行/不可行”，不给 $K_{\max}$、不给 ω_{osc}、也不给“还差多少”的显式表达式。工程上的合理分工是：先用本章判据算边界与频率（快、有解析式、可解释），再用 LMI 在边界内挑满足阻尼要求的点（慢、但能处理多指标）。反过来做，会得到一个“数学上最优、现场说不清”的控制器。

38.9.5 哪些改进不值得做

有五种“看起来更专业”的做法，投入产出比很低，值得先排除。

- **为判稳专门实现高阶 Jury 表**：三阶就要 $2n-1=5$ 个条件、每行都是行列式；换成双线性 + Routh 只需一次多项式代换加一张四行表，出错概率低一个量级。Jury 的真正价值在 $n\le 3$ 且需要分级裕度时。
- **把 Padé 阶次提到 6 阶以上**：$T_d=0.05$ s 时，在边界频率 6.3246 rad/s（$\omega T_d=0.316$）处，二阶 Padé 的相位误差只有 0.0003°，一阶是 0.149°；频率加倍到 12.65 rad/s（$\omega T_d=0.632$）时，二阶误差 0.0079°、一阶 1.14°。也就是说，**二阶之后每加一阶，换来的精度改善已经落在模型误差的噪声里**。真正需要精确延迟时，应该用数值扫根（`kmax_scan`）或离散化，而不是加阶次——加阶次还会让多项式阶数虚高，反过来恶化数值条件。
- **在 PLC 里做在线 Routh 判稳**：系数来自固定的机械结构，运行期几乎不变。把 $K_{\max}$ 离线算好、写进配方表，比在线计算更可靠；在线还要额外处理“首元为零”与定点除法，得不偿失。

- **追求五阶以上的 $K_{\max}$ 显式公式**：四阶是两个不等式，五阶是三个，六阶是四个，而每个不等式含的系数越来越多（四阶的第二个不等式已经是两个三因子乘积之和）。手算不可维护，程序里也没有必要——直接对 K 做二分扫描，一行代码、几十次迭代就得到同样的数。
- **把系数精度提到十位有效数字**：辨识误差通常 1% 量级（§38.7.2），系数保留三位有效数字已经够用。多出来的位数只是把"模型的误差"伪装成"计算的精确"，反而让人忘记做区间分析。

判断一项改进值不值得做，标准只有一条：**它是否改变结论，或者是否改变"离边界多远"的判断**。改变不了，就是工程上的装饰。

38.10 工程落地

前三节讲的是"怎么算对"，本节讲"怎么落到设备上"。稳定性判据在工程上的落地不是写一个判稳函数，而是把"结构—系数—边界—工况—验收"这条链固定下来，并让每个环节都有可执行的检查动作。五段里最容易被跳过的是"工况"与"验收"：前者决定用哪一组系数，后者决定结论能不能被复核。

38.10.1 交付清单：四样东西必须写进文件

一个回路交付时，稳定性相关的内容必须包含四项，缺一项就算不合格：

1. **结构清单**：阶次、每个极点的时间常数、零点位置、延迟估计值，注明每个环节的物理来源（执行器、传感器、传动、通信）。
2. **边界数值**：$K_{\max}$、ω_{osc}、稳定域的下界（若有）。
3. **当前工作点与余量**：$K/K_{\max}$ 的百分比，以及对应工况。
4. **工况表**：把"惯性、延迟、增益"随工况变化的范围列出来，并给出每个极端工况下的 $K_{\max}$。

第 4 项最容易被省略，也最致命。§38.1.1 的事故本质上是"只算了空载工况"。工程上应按"最不利组合"核算：最大惯性与最大延迟往往同时出现（满卷、长管路、通信拥塞），而不是分开出现。

以本章回路为例，四项填满后是这样一份记录：

- **结构**：三阶，$10/[s(s+2)]$ 串执行器 $1/(0.05s+1)$；无闭环零点，无显式延迟；执行器来源为伺服阀电流环，传感器滤波未启用。
- **边界**：$K_{\max}=4.40$，$\omega_{osc}=6.32$ rad/s（1.01 Hz）；下界为 0（对象含积分、无右半平面极点）。
- **工作点**：$K=2.2$，$K/K_{\max}=50\%$，对应空载、油温 40 ℃。
- **工况表**：空载 $\tau_a=0.05$ s $\to K_{\max}=4.40$；满载 $\tau_a=0.08$ s $\to$ 2.90；低温 $\tau_a=0.10$ s $\to$ 2.40。

这份记录的价值在于"任何人拿到它都能复算出同样的数"。只写"已调试稳定"的交接单，等于把结论和依据一起丢掉——三个月后换人，没人知道当时的边界在哪，也没人知道为什么选 2.2 而不是 3。

38.10.2 系数从哪里来，误差怎么取

特征多项式的系数通常有三条来源，各自的误差量级不同，取法也不同。

- **机理建模**：由物理参数（质量、惯量、电阻、容积）算出。误差主要来自参数标称值与实际值的偏差，典型 $\pm10\%$–$\pm30\%$。取误差时按各参数的最不利组合传播，不要按"每个都取中值"。
- **频域辨识**：由扫频数据拟合。系数误差在 $\pm5\%$ 以内，但**未建模动态**（高频段被忽略的极点）会系统性地吃掉相位，这是比系数误差更大的风险。

- **阶跃拟合**：由 FOPDT/SOPDT 拟合。误差可达 $\pm 30\%$，且拟合出的延迟往往偏大（把分布延迟集中化），用于判稳是偏保守的，可以接受。

无论哪条来源，都建议把误差直接代入 Kharitonov（§38.9.2）做一次全区间判稳。若四个顶点多项式中有不稳定的，说明“标称稳定”不可靠，必须降增益或改结构。

误差怎么取，有一个常被搞反的细节：应当**按物理参数取误差、再传播到系数**，而不是直接给所有系数一个笼统的 $\pm 20\%$。以执行器时间常数为例，标称 0.05 s、误差 $\pm 20\%$，则 a_3 同比例变化（0.04–0.06），而 $a_2 = 1 + 2\tau_a$ 只在 1.08–1.12 之间动，相对误差不到 $\pm 2\%$。代入式 (38-35) 得 $K_{\max}$ 从 5.40（$\tau_a = 0.04$）到 3.73（$\tau_a = 0.06$），即 $+23\%$ 与 -15%，两个方向并不对称。

若图省事把所有系数统一按 $\pm 20\%$ 处理，得到的鲁棒边界是 2.35（§38.9.2），比按物理来源传播保守得多：前者把 a_2 也当成会偏 20%，而它实际上不可能偏那么多。**保守不是错误，但过度保守会误导设计**——它让人以为必须换执行器，其实只需把增益降 15%。这也是为什么 §38.9.2 的四个顶点必须用真实区间，而不是拍一个统一百分比。

38.10.3 数字控制器的实现细节

把判据搬到 PLC 或运动控制器上，有三处容易出错。

采样周期取多少。 用表 38-4 的规律选：先按“$T_s \le T_{dom}/10$”给初值（T_{dom} 为主导时间常数的倒数），再用判据核算 $K_{\max}$ 是否仍满足性能要求。本例中 T_s 从 0.02 s 增到 0.1 s，$K_{\max}$ 从 20.13 掉到 4.14；若性能要求 $K \ge 2$，则 0.1 s 已只剩一倍余量，应选 0.05 s 以下（对应 $K_{\max} = 8.14$）。更快的估法是直接用式 (38-28b) 的 $K_{\max} \approx 0.4/T_s$：$T_s = 0.1$ s 给 4，$T_s = 0.05$ s 给 8，与查表结果一致到一位有效数字。

采样周期还有一项常被忽略的误差：**周期抖动**。控制器按名义 T_s 设计，实际中断受总线负载影响会在名义值上下浮动。把 $T_s = 0.10$ s 的回路按 0.08、0.12、0.15 s 三种实际周期重算，$K_{\max}$ 分别是 5.14、3.47、2.81；名义周期下是 4.14，实际周期慢到 0.15 s 就只剩 2.81，降了 32%。所以“T_s 选得够小”之外还要保证抖动可控；若抖动不可控，设计时应按可能出现的**最大**周期核算，而不是名义值。

定点数还是浮点。 Routh 表本身只需加减乘除，定点可实现；但中间行的数值跨度可能很大（本例中最大系数 22、最小 0.05，比值 440），定点运算要预留足够位宽。实践中的做法是：**判稳离线做（浮点），控制器在线只做限幅与保护**，不在控制器里实时列 Routh 表。

临界如何处置。 判据输出应分三档而不是两档：稳定、临界（有零行、零首元，或第一列最小元素小于阈值）、不稳定。临界档触发时，控制器应把增益退回上一个已验证的配方，并报警，而不是继续运行。

38.10.4 现场验证：从计算到实测的三步

计算给出的是标称值，现场必须验证。三步验证法按风险从低到高排列：

第一步，阶跃试验。 在最小增益下给 5% 幅值的阶跃，记录上升时间与超调。用第 37 章的口径算出 M_p、t_s，与仿真值对比。若实测超调比仿真大 10 个百分点以上，说明有未建模的延迟或滤波，先查这两项，不要急着调增益。

第二步，扫频试验。 用 0.1–10 Hz 的正弦扫频测开环或闭环频响，重点看相位在 ω_{osc} 附近是否比模型多出 10° 以上。这一步能定量暴露延迟：相位多出的角度除以 ω 就是额外延迟。第 41 章会给出完整做法，本章只需用它反推 $K_{\max}$ 的修正值。

第三步，临界点试探（高风险，需审批）。 在空载、无工件、有人监护的条件下，逐步提高增益直到出现等幅振荡，记录临界增益 K_u 与振荡频率 ω_u。把实测值与计算值对比：若 K_u 明显低于计算值，说明模型偏乐

观；若 ω_u 明显高于 ω_{osc}，说明高频段还有未建模的极点。**这一步只能在设备允许"振而不坏"的场合做**，精密设备、带负载设备禁止做。

三步之间有明确的因果顺序：阶跃看时域指标是否与仿真一致，扫频看频域相位是否缺了一块，临界试探才是直接测边界。前两步任一不合格，都不该进入第三步——用一台模型还不准的设备去试临界点，等于把风险放大一倍。

阶跃幅值取 5% 有讲究。幅值太大（超过 10%）会激励饱和、回差、间隙等非线性，测出的超调不再反映线性模型；幅值太小则被噪声淹没。实用办法是先测静态噪声峰峰值，取其 3 倍以上作为阶跃幅值，再核对该幅值下执行器是否进入限幅。

扫频那一步的换算要记牢：**相位差除以角频率就是额外延迟**。本例边界频率 6.28 rad/s 处若实测相位比模型多 10°，折合 $0.1745/6.28 = 27.8$ ms 的纯延迟。按 §38.7.5 的表，20 ms 延迟已让 $K_{\max}$ 从 4.40 掉到 3.07，27.8 ms 只会更低。10° 的相位差听起来不大，落到稳定域上就是三成的差距——这就是频域验证不能省的原因。

临界试探的结果这样读：实测 K_u 落在计算值的 0.8–0.9 倍之间属正常（未建模延迟总会让边界略低）；低于 0.7 倍，说明模型缺了一个显著滞后，应先补模型而不是继续调参；高于 1.1 倍，通常是模型过于保守，或计算时把某个时间常数取大了。三种情况的处置方向完全不同，所以第三步必须记录**两个**数：K_u 与 ω_u，只记一个无法定位原因。

38.10.5 失败模式与处置

把现场最常见的五类失稳现象、判别依据与处置动作列成表 38-6。这张表比任何公式都更常用——现场没有时间重新推导，需要的是"看到这个现象，先查这个"。

现象	判别依据	最可能原因	处置
等幅振荡，频率接近 ω_{osc}	幅度不增不减	增益触及边界	降增益至 0.6 倍，复算边界
增幅振荡，周期数秒	幅度逐周期增大	增益超过边界，或有正反馈	立即停机，查符号与接线
高频抖动，频率远高于 ω_{osc}	幅值小、频率高	采样噪声、量化、微分放大	加滤波，降微分增益
低频摆动，周期远长于预期	幅值大、频率低	积分饱和、机械共振、阀门回差	抗饱和、查机械、加死区补偿
周期抖动，频率约 $1/(2T_s)$	频率与采样率成整比	零阶保持、量化、混叠	提高采样率，加抗混叠滤波

表 38-6 的第一行与第三行最容易混淆。区分办法是看频率：Routh 边界给出的 ω_{osc} 是唯一的（本例 6.32 rad/s），实测频率若在它附近，属于"增益过高"；若高出数倍，属于"噪声/采样"问题，此时降增益只会让响应变慢而不解决抖动。

第四行和第五行都不属于"线性失稳"，判据在这里帮不上忙，但频率仍是最好的线索。第五行的特征很硬：抖动频率恰好是采样率的一半（或它的整数分之一），换个采样周期频率就跟着变——这基本可以确诊，不需要再算特征根。第四行的周期往往比 ω_{osc} 对应的周期长一个量级，而且**幅度与指令幅值相关**：小指令不出现，大指令才出现，说明是非线性环节在起作用，降增益无效，只能从机械或补偿入手（第 49 章用描述函数分析这类极限环）。

表 38-6 只回答"先查什么"，不回答"查完做什么"。任何一次处置之后都要复算边界并更新档案：加了一级滤波，$K_{\max}$ 就得从头算；降了增益，余量百分比也要重写。现场最常见的二次事故，正是按表降了增益却没有重算，下一次凭"还差得远"的印象又把它加回去。

38.10.6 验收与档案

验收时应把以下三项写进测试报告：标称工况下的 M_p、t_s；最不利工况下的 $K_{\max}$ 与余量；扫频实测的相位与模型相位的差值。三项齐全，才说明“这个回路的稳定性是被证明过的，而不是被试出来的”。

档案还要留一份“变更记录”：凡是改过执行器、滤波器、通信周期、机械传动的，都要重算 $K_{\max}$ 并记录。经验表明，现场多数“突然自振”都能在变更记录里找到原因——某个 20 ms 的滤波被加上去，或者某个通信周期从 2 ms 改成了 5 ms。

如果条件允许，可以做一次“临界增益实测”作为最硬的验收证据。做法是：从工作点开始，按每次 10% 的步长提增益，每步等到响应稳定再提下一步，记录出现等幅振荡时的增益与周期。本例的预测值是 $K_{\max} = 4.40$、周期 0.99 s；实测若给出 4.0–4.8 与 0.9–1.1 s，模型可信；若实测周期只有 0.3 s，说明回路里存在模型未包含的快速环节（通常是电流环或机械共振）。这项试验必须有人值守、有急停、有增益回退路径，且只在允许超调的设备上做——它验的是模型，不是设备极限。

档案的最小字段集建议固定为六项：回路编号、结构与系数、边界三件套（$K_{\max}$、ω_{osc}、下界）、工作点与余量、工况表、变更记录。字段固定下来才能做跨设备对比——同一台机器两次大修之间的 $K_{\max}$ 变化，往往比绝对值更有信息量。

变更记录要写到“谁、何时、改了什么、重算结果”四个要素。缺后两项的记录没有价值：改了滤波器却不算新边界，下一次自振时照样找不到原因。

38.10.7 一份可执行的检查清单

把本节内容压缩成十条，交付前逐条打勾。前八条是“算对”，后两条是“落地”：

1. 结构阶次与每个极点的物理来源是否写清（执行器、传感器、传动、通信）。
2. 系数是否统一到同一单位制（秒、rad/s），多项式是否按降幂排列。
3. 是否先做“系数全正”的必要条件筛查——这一步能挡掉一半的错误建模。
4. 是否给出 $K_{\max}$、ω_{osc}、稳定域下界三件套，而不是只给“稳定”两个字。
5. 是否检查过首元为零与整行为零两种特殊情形（§38.2.4、§38.2.5）。
6. 离散系统是否用 ZOH 建 $G(z)$、用 Jury 或双线性 + Routh 判稳，而不是拿 Tustin 的结果当边界。
7. 采样周期是否按**最大可能抖动**核算，而不是名义值。
8. 系数带误差时，是否做过 Kharitonov 四顶点，且区间独立。
9. 工作点是否写清余量（$K/K_{\max}$ 与 σ），并对应到具体工况。
10. 是否完成阶跃与扫频两项验证，且实测相位差已折算成等效延迟。

十条里最容易漏的是第 6 条和第 7 条：两者都在“仿真看着没问题”的情况下埋雷，且只在现场才暴露。第 3 条最容易被跳过，因为“看起来都是正数”——但符号错一个，后面全部白算。

38.11 优缺点与适用边界

任何一种判据都有它的“管辖范围”。Routh-Hurwitz 与 Jury 判据的优点是解析性强、代价低，缺点也同样明确：只回答极点在哪一侧，其余一概不管。本节把这两面说清楚，并给出与相邻判据的分工。写法上按“优点—局限—边界—分工”四段展开，每一段都尽量给出可对照的数值，而不是只给判断。

38.11.1 四项不可替代的优点

第一，给的是区间而不是点。 数值求根只能回答“这组系数稳不稳”，Routh 表把 K 当符号后直接给出 $K_{\max}$ 的解析式（式 38-35）。设计者拿到的不是一个“合格/不合格”的结论，而是“还能加多少”的数。以本例为例，$K_{\max} = a_2 a_1 / (10 a_3)$ 一行就算出 4.40，而数值扫描要在 0–5 之间试上几十个点才能逼近同一个数。

第二，不需要迭代，也不需要初值。 与数值优化、根轨迹绘制相比，Routh 表是确定性的有限步运算：n 阶多项式，n 行表，每行最多 n 次乘除。这对嵌入式实现、对“必须给出可复核过程”的场合（如安全仪表系统的验证）非常重要。

第三，顺带给出边界频率。 整行为零时，辅助多项式直接给出 ω_{osc}。这个数在现场诊断中价值极高：它把“振了”变成“振在哪个频率”，从而区分增益过高、噪声放大、机械共振三类原因（表 38-6）。

第四，可以自然地扩展到区间系数。 Kharitonov 定理只需查四个顶点多项式，就能判定整个系数区间。这类“从点到域”的扩展是数值求根做不到的。

38.11.2 五项必须承认的局限

局限一：只判绝对稳定。 判据不给超调、不给调节时间、不给稳定裕度。一个“通过判据”的系统可能超调 70%（表 38-5 的 $K = 2.2$），也可能对扰动极其敏感。

局限二：对系数误差敏感。 判据把系数当作精确值。系数来自辨识、有 $\pm 15\%$ 误差时，结论的不确定度可能达到 $\pm 30\%$（§38.7.2）。若不做区间分析，容易得出“标称稳定、实际不稳”的结论。

局限三：不能直接处理纯延迟。 $\mathrm{e}^{-T_d s}$ 不是有理函数，必须近似（Padé）或离散化。近似阶次不够会偏乐观（§38.7.5），而高阶 Padé 又会让多项式阶次虚高、数值变差。

局限四：高阶时数值不稳。 八阶以上，Routh 表的除法链会放大舍入误差，结论可能随系数的末位变化。必须配合归一化、逐行缩放与数值求根交叉验证（§38.9.1）。

局限五：只适用于线性定常系统。 时变参数、饱和、死区、回差、切换都会让“特征多项式”这个概念失效。含这些环节的系统要用描述函数（第 49 章）、相平面（第 48 章）或 Lyapunov 方法（第 52 章）。

38.11.3 适用边界

表 38-7 给出“该用/不该用”的对照。判断标准只有一条：**问题是否能写成“确定系数的多项式，问根在哪一侧”**。能，就用本章判据；不能，就换工具。

场景	是否适用	说明
线性定常、已知传递函数、求增益区间	适用	本章主场景
数字控制器、已知 $G(z)$	适用	Jury 或双线性 + Routh
系数含区间误差	适用（Kharitonov）	要求区间独立
含纯延迟	有条件适用	需 Padé 或精确延迟扫根
含饱和、死区、回差	不适用	用描述函数或仿真
时变参数、增益调度	不适用	用 Lyapunov 或增益调度分析
需要阻尼比、超调约束	不适用	用 LMI（§38.9.4）或数值求根
只有实测频响、没有模型	不适用	用 Nyquist（第 39 章）直接判

表里没列出的两类情形值得单独提一句。**多输入多输出系统**：闭环稳定性仍由 $\det(\boldsymbol{I}+\boldsymbol{G}(s)\boldsymbol{C}(s))$ 的根决定，但这个行列式展开后是一个高阶多项式，系数没有明确的物理含义；此时 Routh 表只能当“验算工具”，设计与分析应改用奇异值或 μ 分析（第 58 章）。**分布参数系统**（长管路、热传导、柔性梁）：特征方程含 $\mathrm{e}^{-T_d s}$ 或双曲函数，从第一步起就不是多项式，本章方法写不下去，必须先做有限维近似，或直接进频域。

还有一类“看起来能用、其实不该用”的情形：**参数在大范围内慢变**（增益调度）。若对每个调度点单独算一次 $K_{\max}$、再按最坏点设计，这是合法用法；但若把调度表当成一条连续曲线，用相邻两点的稳定性推断中间点，就错了——**两个稳定多项式之间的插值不一定稳定**。正确做法是在每个调度格点上验算，或直接用 Lyapunov 方法（第 52 章）。

38.11.4 与相邻判据的分工

本章之后的三章会给出三种“看图判稳”的方法，它们与 Routh 表的分工可以概括为：

- **Nyquist 判据（第 39 章）**：只需开环频响，能直接处理延迟，能给出裕度。适合“有频响数据、模型阶次不确定”的场合。
- **根轨迹（第 40 章）**：给出极点随 K 迁移的全貌，适合“看趋势、定结构”。Routh 表给的是边界值，根轨迹给的是路径。
- **Bode 与稳定裕度（第 41 章）**：给出增益裕度、相位裕度，是工程验收最常用的两个数，适合“交付与验收”。

实践中三者常一起用：先用 Routh 算出 $K_{\max}$ 定边界，再用根轨迹看 K 增大时极点怎么走，最后用 Bode 裕度做验收。三者的结论应当一致；不一致时，先查延迟与未建模动态——它们最常造成“代数判据说稳、频域判据说不够”的分歧。

三者的定量对应关系可以用本例说清。$K=2.2$ 时，Bode 算出的增益裕度是 2.00（6.02 dB），而 Routh 给出的 $K_{\max}=4.40$ 恰好是工作点的两倍——**增益裕度就是 $K_{\max}/K$，两者是同一个数的两种单位**。边界频率也对得上：Bode 的相位穿越频率 $\omega_g=6.325$ rad/s，与 Routh 辅助多项式解出的 $\omega_{osc}=6.325$ rad/s 完全一致。这不是巧合，而是同一个代数条件在频域与时域的两副面孔。

Routh 给不出的是相位裕度。同一工作点的相位裕度只有 11.85°，远低于工程常用的 45°。也就是说：一个“判据通过、增益裕度 6 dB”的系统，相位裕度可能已经薄到一次扰动就振起来。这正是 §38.11.2 第一条局限的具体数字形态，也是验收必须同时看两个裕度的原因。

再看 $K=0.3$：增益裕度 23.33 dB、相位裕度 54.06°，两项都健康。同一回路、同一判据，只因为工作点不同，两个裕度从“合格”变成“危险”。**判据的结论永远是针对某个工作点的，脱离工作点谈“这个系统稳不稳”没有意义。**

38.12 Python 仿真代码

本章的代码分两个文件，职责分开：`code/ch038_sim.py` 只做计算并打印数值，`code/ch038_figs.py` 只负责把正文引用的 11 张图画出来。两者都复用全书公共库 `simlib.py` 与 `styles/` 下的绘图样式，因此换一台机器运行，曲线的线型、字号、导出格式与全书其余章节完全一致。

运行方式（Windows，已装好 py311 环境）：

```
"D:\Anaconda3\envs\py311\python.exe" code\ch038_sim.py
"D:\Anaconda3\envs\py311\python.exe" code\ch038_figs.py
```

第一条命令输出七组数值，分别对应 §38.4–§38.8 的表格与结论；第二条命令在 `figs/ch038/` 下生成 11 组 SVG 与 PDF。依赖只有 `numpy`、`scipy`、`control` 三个包，不需要额外的符号计算库——这正是本章判据的价值：全程只用四则运算。

38.12.1 Routh 表的递推实现

代码与正文式 (38-6) 一一对应。设第 $i-1$ 行首元为 $a_{i-1,1}$，则第 i 行第 j 个元素为

$$a_{i,j} = \frac{a_{i-1,1}\,a_{i-2,j+1} - a_{i-2,1}\,a_{i-1,j+1}}{a_{i-1,1}} \tag{38-43}$$

实现时有三个细节必须写进代码，否则数值上会出错：

1. **先归一化**。整表除以 $\max|a_i|$，避免 0.001 与 10 同表造成的病态除法。
2. **补齐行长**。每一行都用零填充到 $n+1$ 列，递推时下标才能对齐。
3. **整行为零要单独处理**。此时用上一行构造辅助多项式，求导后替换该行，同时记录 ω_{osc}。

`eps` 这个参数容易被误解，它并不是判稳阈值，而是首元为零时的“替身”：一旦首元的绝对值小于 `eps`，代码就用 `eps` 项替它把递推做下去，同时在 `flags` 里记一笔 `epsilon=True`。归一化之后所有系数不超过 1，取 10^{-10} 意味着只有比最大系数小十个数量级的首元才会被替换；本例三阶表里最小的首元是 0.5758，离它还差近十个数量级。需要动这个参数的场合是 §38.9.1 那种七阶对象——此时应当把它调到 10^{-14} 附近，并检查 `flags['epsilon']` 有没有被误触发。

核心代码如下（完整版本见 `code/ch038_sim.py`，此处只保留递推与特殊情形）：

```python
def routh_table(coeffs, eps=None):
    """构造 Routh 表：返回 (rows, first_col, flags)。"""
    a = np.asarray(coeffs, dtype=float)
    a = a / np.max(np.abs(a))              # 归一化，避免大小系数同表
    n = len(a) - 1
    if eps is None:
        eps = 1e-10
    rows = [a[0::2], a[1::2]]              # 奇偶分列
    rows[0] = np.pad(rows[0], (0, n + 1 - len(rows[0])))
    rows[1] = np.pad(rows[1], (0, n + 1 - len(rows[1])))
    flags = {"epsilon": False, "zero_row": False, "omega_osc": None}

    for i in range(2, n + 1):
        prev, cur = rows[i - 1], rows[i - 2]
        pivot = prev[0]
        if abs(pivot) < eps:               # 情形一：首元为零
            flags["epsilon"] = True
            pivot = eps
        new = [(pivot * cur[j + 1] - cur[0] * prev[j + 1]) / pivot
               for j in range(n + 1 - i)]
        new = np.array(new + [0.0] * (n + 1 - len(new)))

        if np.all(np.abs(new) < 1e-12 * max(1.0, np.max(np.abs(cur)))):
            flags["zero_row"] = True       # 情形二：整行为零
            k = n - (i - 1)
            powers = np.arange(k, -1, -2)
            aux = np.zeros(k + 1)
            aux[k - powers] = prev[:len(powers)]     # 辅助多项式
            pure = [r for r in np.roots(aux) if abs(r.real) < 1e-9]
            if pure:
                flags["omega_osc"] = float(abs(pure[0].imag))
            new = np.pad(np.polyder(aux), (0, n + 1 - len(np.polyder(aux))))
        rows.append(new)

    first = np.array([r[0] for r in rows])
    return rows, first, flags
```

`routh_report` 在此基础上数第一列符号变化次数，并把“存在零行/零首元”标为临界，返回 `stable`、`rhp`、`omega_osc` 三个量。§38.4.4 的 1.414 rad/s 与 §38.4.2 的 6.3246 rad/s 都由这段代码直接给出，不是手填。

这段代码有三行值得单独解释，它们分别对应三个真实的坑。

`rows = [a[0::2], a[1::2]]`。这是“奇偶分列”最直白的写法：第一行取下标 0、2、4…，第二行取 1、3、5…。手算时容易把第二行写成“其余系数顺次排列”，结果整张表错位。

零行判定用相对阈值。 `1e-12 * max(1.0, max|cur|)` 而不是与 0 直接比较——浮点递推几乎不会得到精确的 0，若用绝对判据，真正的零行会被漏掉，表继续算下去得到一堆无意义的数。阈值取相对量，才能同时适配 10^{-3} 与 10^{3} 两种量级。

辅助多项式的两处下标。 `k = n - (i - 1)` 给出上一行对应的 s 幂次，`aux[k - powers] = prev[:len(powers)]` 把系数按降幂放到正确位置；数据必须取自 `prev`（上一行）而不是 `cur`。这两处是实现中最常见的两个错误：取错行时辅助多项式少了一阶，索引方向写反时系数顺序颠倒，症状都是 ω_{osc} 算成一个明显偏小的数（0.158 或 0.707），而正确值是 6.3246 与 1.4142。**判据实现是否正确的锚点，就是这两个频率。**

38.12.2 Jury 与双线性交叉核对

离散部分只保留两个函数。`jury_report` 按式 (38-13)、式 (38-14) 逐条检查，返回每条条件的过与不过；`bilinear_w` 做式 (38-15) 的多项式代换，把结果交给 `routh_report` 复核。两个函数合计不到三十行，却覆盖了离散判稳的全部需求：$n \le 3$ 时用前者，$n \ge 4$ 时用后者，两者互为对照。

```
def jury_report(coeffs):
    """Jury 判据：coeffs 降幂，返回各条件与最大根模。"""
    a = np.asarray(coeffs, dtype=float)
    a = a / a[0]
    n = len(a) - 1
    asc = a[::-1]                          # 升幂
    conds = [("D(1)>0", np.polyval(a, 1.0) > 0, np.polyval(a, 1.0)),
             ("(-1)^n D(-1)>0", (-1) ** n * np.polyval(a, -1.0) > 0,
              (-1) ** n * np.polyval(a, -1.0)),
             ("|a0|<an", abs(asc[0]) < abs(asc[-1]), abs(asc[0]) - abs(asc[-1]))]
    row = asc.copy()
    while len(row) > 2:
        m = len(row) - 1
        b = np.array([row[0] * row[k] - row[m] * row[m - k] for k in range(m)])
        conds.append((f"row{len(conds)}", abs(b[0]) > abs(b[-1]),
                      abs(b[0]) - abs(b[-1])))
        row = b
    return {"stable": all(c[1] for c in conds), "conds": conds,
            "max_root": float(np.max(np.abs(np.roots(a))))}


def bilinear_w(coeffs):
    """z=(1+w)/(1-w)，两边乘 (1-w)^n，返回 w 的降幂系数。"""
    a = np.asarray(coeffs, dtype=float)
    n = len(a) - 1
    total = np.zeros(n + 1)
    for k, ak in enumerate(a):             # 第 k 项 z^(n-k)
        p = np.polymul(np.poly1d([1, 1]) ** (n - k), np.poly1d([-1, 1]) ** k)
        total += ak * p.c
    return total
```

`bilinear_w` 里指数配对是最容易写反的地方：z^{n-k} 应配 $(1+w)^{n-k}(1-w)^{k}$。写反后三个系数中一次项符号会翻转，`routh_report` 立刻给出“不稳定”，与 Jury 结论矛盾——这正好可以作为实现正确性的自检。

`jury_report` 有两处设计是刻意的。**先按 a_n 归一化**，否则 $|a_0| < a_n$ 与后续递推都受量级影响，同一系统换个单位就可能判反。**每条条件同时返回布尔值与差值**，因为“过”与“差一点过”在现场含义完全不同：三阶对象 $K = 2$ 时 b 行裕度 0.0093、c 行 0.0016，说明离边界只差千分之几；只看一个 True，会把这种“贴着边界飞”的状态当成安全。

第三只眼是 `max_root`。它不参与判据，只作为独立核对：若 Jury 全部条件为真而 $\max|z| > 1$，一定是实现错了；反之若条件为假而 $\max|z| < 1$，同样说明某条递推写错。本章 $K = 2$ 时 $\max|z| = 0.9944$，与 b、c 两行的小裕度互相印证。

38.12.3 输出与正文的对应关系

表 38-8 把程序输出与正文位置对应起来，方便逐条复核。

程序输出	正文位置	关键数值
三阶 $K_{\max}$（扫描 vs 解析）	§38.4.2、式 (38-19)	4.4000 / 4.4000
边界振荡频率	§38.4.2、式 (38-20)	6.3246 rad/s
四阶 $K_{\max}$	§38.4.3、表 38-3	3.0895
整行为零的 ω_{osc}	§38.4.4、式 (38-24)	1.4142 rad/s
σ 位移判定与二分	§38.6.3、表 38-5	$\sigma_{\max} = 0.4537$
六个采样周期的 $K_{\max}$	§38.5.2、表 38-4	40.13 / 20.13 / 8.14 / 4.14 / 2.14 / 0.96
Jury 与双线性复核	§38.5.3–§38.5.4	判稳一致
四档延迟下的 $K_{\max}$	§38.7.5	4.40 / 3.07 / 2.13 / 1.43
六档增益的时域指标	§38.8、表 38-5	M_p 13.8%–71.4%

数值扫描与解析解在小数点后四位一致，说明两套实现没有共享同一个错误：解析式只依赖三阶不等式，扫描则直接对闭环极点求根，两条独立路径互相校验。

复核时按表的顺序自上而下走，任一行对不上就停下——后面的行都以它为前提，继续往下看只会在错误上叠加错误。表末两行（延迟档位与增益档位）最容易被当成“附录”跳过，其实它们才是唯一能与时域实测对上号的两行。

表里最该每天看的是“边界振荡频率”这一行。$K_{\max}$ 只在设计阶段用一次，而 ω_{osc} 可以现场量：把增益慢慢推上去，记下等幅振荡的周期，与 $2\pi/\omega_{osc}$ 对照。本例 6.3246 rad/s 对应周期 0.993 s，实测若在 0.9–1.1 s 之间，就可以确认模型阶次与时间常数的量级没错；若差出一倍，多半是漏了某个环节，而不是判据算错。

三组交叉核对的性质各不相同，出问题时指向也不同。**解析式 vs 扫描**对不上，说明解析条件推错了（顺序、符号、适用阶次）；**Jury vs 双线性**对不上，说明离散多项式的系数或 z^k 的配对写错了；**σ 位移 vs 时域 t_s** 差得超过 20%，说明主导极点假设不成立，此时应当去看第三个极点离虚轴有多远，而不是继续调 σ。三者都建立在“两条独立路径”上，因此任一组对不上时，先怀疑实现，再怀疑数据——反过来做，往往会把一个明确的 bug 归咎于“现场情况复杂”。

38.12.4 复现时的四个注意点

1. **不要用 `scipy.signal` 的 `tf2ss` 替代 `control`** 做闭环：前者不处理代数环，遇到纯积分环节容易报奇异。本例对象含 $1/s$，误用后会得到“矩阵奇异”的报错，而不是一个错误的结果——这算是幸运的情形，更麻烦的是阶次降低后仍能算出数。
2. **仿真时长按最慢极点确定**。$K = 4.39$ 时时间常数 524 s，若仍用 30 s 仿真，曲线看起来“很稳”，会得出错误结论。`metrics_of` 默认取 30 s，只适用于 $K \le 2.2$。一条经验规则：仿真时长至少取 $5/\sigma_{\min}$，$K = 4.39$ 时这已是 2600 s，画图时应当截断显示，而不是截断计算。
3. **调节时间必须统一带宽**。本章全部用 $\pm 2\%$，若与第 37 章的 $\pm 5\%$ 混用，t_s 会差 30% 以上（§38.6.4 给出了 8.82 s 与 6.61 s 的对照）。
4. **出图与计算分离**。`ch038_figs.py` 里的每条曲线都重新调用 `ch038_sim.py` 的函数取值，不读缓存，保证图与表永远同源。若为了提速把数值存成中间文件，至少要在文件名里带上系数或参数，否则改了结构却仍读旧数据，图上会出现“说不通”的拐点。

38.12.5 移植到自己的回路

换一台设备，只需改三处，其余逻辑不动：

1. **改结构**。把 `plant()` 与 `char_poly()` 里的 $10/[s(s+2)]$ 换成自己的传递函数；若对象是“增益 + 两个惯性”，写成 $K_p/[(T_1 s+1)(T_2 s+1)]$，用 `np.polymul` 展开，不要手算系数。
2. **改单位**。时间常数一律用秒、频率一律用 rad/s；原始资料给的是 Hz 或毫秒时，在入口处一次换算完，不要让两种单位进同一个多项式。
3. **改扫描区间**。`kmax_scan` 的 `hi` 默认 60，只适合本例这种 $K_{\max} \approx 4$ 的对象。对象增益很小时要同步下调 `lo`；含延迟、阶次升高时要放大 `hi`，否则扫描会返回 `inf` 而不是边界。

加延迟只需一行：`ct.pade(Td, 2)` 串进开环，阶次自动升 2。注意两点：Padé 分子首项为正，不要手工改符号；阶次升高后，归一化与 ε 的取值比原来更重要（§38.9.1）。

扫描返回 `inf` 时不要当成结论。`kmax_scan` 返回无穷只有两种可能：`hi` 不够，或者对象确实是无上限的二阶结构。区分办法很直接——把 `hi` 放大十倍再扫一次，若仍为 `inf`，再去看阶次：三阶以上的连续闭环不可能真正无上限（a_0 增大时 $a_2 a_1 > a_3 a_0$ 必然被破坏），所以此时要么阶次真的只有二阶，要么模型漏了环节。移植后还有一件事容易漏：把新对象的 $K_{\max}$、ω_{osc}、下界写进档案的同一行（§38.3.7），并注明它是在哪个 T_s、哪个执行器时间常数下算的。

做离散设计时，`ct.c2d(..., method="zoh")` 是唯一可用来“定边界”的方法；Tustin 只适合做交叉核对，不适合定 $K_{\max}$——§38.5.5 的无穷大就是反例。

改完代码，先看三行输出再谈结论：

- 三阶解析值与扫描值是否在小数点后四位一致（4.4000 / 4.4000）；
- 两个 ω_{osc} 是否等于 6.3246 与 1.4142；
- Jury 与双线性是否同时判稳。

三行都对，说明实现没坏；任何一行变了，先查代码，不要急着用物理解释偏差。实现这类判据时最常见的三类错误——辅助多项式取错行、索引方向写反、双线性的指数配对写反——都会直接打乱这三行，所以它们是最省时间的自检项。

本章给出的判据解决的是“已知模型、问稳定域”这一类问题。下一章换一个入口：不写特征多项式，只测开环频率响应，用 Nyquist 曲线包围 $(-1, \mathrm{j}0)$ 的次数判断闭环稳定性。两条路在理论上等价，工程上互补——前者适合设计阶段算参数，后者适合调试阶段用实测数据验证。

第39章 线性系统稳定性判据（二）：Nyquist、Bode与根轨迹判据

39.1 动机与直观理解

第 38 章用一组系数回答了“稳不稳”，代价是必须先有一个可靠的特征多项式。可工程现场经常拿不到它：机械共振、传动间隙、执行器非线性都难以写成阶次确定的传递函数，能测到的只有一条扫频得到的幅相曲线。Nyquist 判据正是为这种场合准备的——它只要求开环频率特性，不要求知道阶次。

更深一层的区别在**答案的形态**。Routh 表给的是“是/否”，Nyquist 与 Bode 给的是“还差多少”：增益裕度、相位裕度、以及曲线离 -1 点有多远。前者回答“能不能用”，后者回答“敢用多久、换一批零件还稳不稳”。

39.1.1 当模型只有一个频率响应

设想一台直驱伺服轴。电机与负载之间有一段联轴器，扭转刚度未知；导轨上有预紧力，摩擦力随位置变化。想列特征多项式，就得先辨识阶次、阻尼、刚度，每一项都有误差。换一条路：用信号发生器从 1 rad/s 扫到 500 rad/s，记录每个频率下的幅值比与相位差，得到 $G(\mathrm{j}\omega)$ 的实测曲线。Nyquist 判据只吃这条曲线。

这不是“退而求其次”。实测曲线里天然含有未建模的高频模态——它们不需要被写成项，只要在曲线上出现，判据就会把它们算进去。Routh 表做不到这一点：漏掉一个环节，表里就少一行，结论可能从“不稳”翻成“稳”。

39.1.2 同一组数据，两种问法

用第 38 章的三阶对象做对照。开环为

$$G(s)H(s)=\frac{10K}{s(s+2)(0.05s+1)} \tag{39-1}$$

Routh 表给出的结论是 $K_{\max}=4.40$。若把 $K=2.2$ 代进去，Nyquist 给出的是一对数：相位穿越频率 $\omega_{180}=6.3246$ rad/s 处，开环幅值为

$$|GH(\mathrm{j}6.3246)|=\frac{10\times 2.2}{6.3246\times\sqrt{6.3246^2+4}\times\sqrt{1+0.0025\times 6.3246^2}}=0.5000 \tag{39-2}$$

因此增益裕度 $G_M=1/0.5=2.0$，即 6.02 dB。这与 Routh 的结论是同一件事的两种写法：$G_M=K_{\max}/K=4.40/2.2=2.00$。

差别在于，$G_M=2$ 这句话可以直接落地——“增益再加一倍就临界”，现场听完就知道该怎么留余量；而“$K_{\max}=4.40$”还要工程师自己做一次除法，才知道当前离边界有多远。

39.1.3 三个判据是同一件事的三种投影

Nyquist、Bode、根轨迹看起来是三套方法，其实都从辐角原理出发：一条闭合曲线在映射下的环绕圈数，等于它内部零点数与极点数之差。三个判据只是把这句拓扑学结论投影到三种坐标上。

- **Nyquist**：在复平面上直接数环绕 -1 的圈数，$N=Z-P$。最原始，也最能处理右半平面开环极点与非最小相位对象。

- **Bode**：把同一条曲线拆成幅值—频率与相位—频率两张图，判据变成“相位过 -180° 时幅值是否已低于 0 dB”。工程上最常用，因为扫频仪直接给这两张图。
- **根轨迹**：让 K 从 0 增大到 ∞，画出闭环根的移动轨迹；轨迹穿越虚轴的那一刻就是临界增益。它回答“根往哪儿跑”，与 §38.1.3 的竖线图是同一件事的一般化。

三者的结论必须一致。不一致时，几乎总是因为某一张图上漏了环节、或者相位卷绕没有展开——这是本章 §39.11 要专门讨论的核对方法。

图 39-1 把这三条投影画成一张图。左边是共同的源头，右边三条路径各自需要不同的输入：Nyquist 要整条曲线，Bode 要两张对数坐标图，根轨迹要零极点位置。三条路径汇到同一个框里，是因为它们给出的必须是同一个临界增益；若三条路给出三个不同的数，问题一定出在输入侧，而不是判据本身。

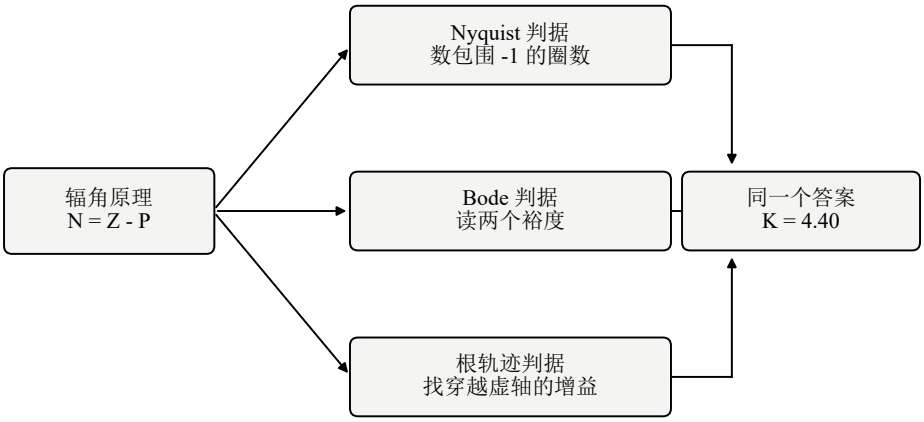

图 39-1　三个判据是同一件事的三种投影

39.1.4 本章路线

§39.2 给出辐角原理与三个判据的严格表述；§39.3 把判据整理成可执行的步骤；§39.4 用同一组对象把 Nyquist、Bode、根轨迹各算一遍，并互相对照；§39.5 处理离散系统（单位圆上的 Nyquist 与 w 变换）；§39.6 把裕度换算成 σ 与 ζ；§39.7 讨论各参数对裕度的作用；§39.8 给出整定经验；§39.9 讲延迟、右半平面零点与非最小相位对象的处理；§39.10 落到现场扫频与判据保守性；§39.11 列优缺点与适用边界；§39.12 给出代码。

与第 38 章的分工需要先说清：**有可靠系数、只问“稳不稳、能加到多大”时，用第 38 章的代数判据，快且精确；只有频响、或需要裕度、或含纯延迟时，用本章的频率判据**。两者不是替代关系，而是同一结论的两条独立通路——第 38 章 §38.12.3 的三组交叉核对，其中“Routh vs Bode 裕度”一组正需要本章来补全。

39.1.5 只有扫频仪时，四个数怎么变成一句话

把 §39.1.2 的算式换成现场顺序。设备是一台直驱轴，控制器里能调的只有一个增益旋钮；没有 A、B 矩阵，也没有辨识好的传递函数，手上只有一台能扫 0.1–10 Hz 的扫频仪和一台记录仪。

扫完得到两张纸：幅频在 0.703 Hz 处穿过 0 dB，相频在同一个频率上是 -168°；相频在 1.006 Hz 处穿过 -180°，幅频在那一点是 -6.0 dB。把这两个频率换成角频率是 4.42 与 6.32 rad/s，与本章模型 $K = 2.2$ 那一档完全对上（表 39-2 第三行）。

于是三句话就能写完结论。第一句：增益还能再翻一倍才临界，因为 -6 dB 就是“再乘 2”。第二句：延迟只剩 47 ms 的余量，因为 11.9° 换成弧度是 0.208，除以 4.42 得 0.047 s。第三句：**限制这台设备的不是增益，是延迟**——控制器里那个 20 ms 的反馈滤波单独就吃掉 5.1°（$0.020 \times 4.42 = 0.088$ rad），占 11.9° 的四成多。

这三句话的顺序值得留意。若只报“增益裕度 6 dB，合格”，听众会以为还有一倍空间可以随便用；而实际上增益翻倍之后 ω_c 会从 4.42 升到 6.32，同样一段 47 ms 的延迟在新频率上已经值 17.0°（$0.047 \times 6.32 = 0.297$ rad），比原来贵四成多。**两个裕度共享同一个频率坐标，不是两个独立的数**，这一点在 §39.7 还会再算一遍。

扫频读数也有它的边界：0.1 Hz 以下通常不可信（扫一个周期要十秒以上，工况早已漂移），10 Hz 以上则受激振器与采样率限制。本章的判据只需要 0 dB 与 -180° 两个穿越点落在可信段内，这里恰好是 0.7–1.0 Hz，离两端都远，属于运气好的情形。若穿越点落在可信段的边缘，正确做法是扩频段重扫，而不是在边缘数据上做更精细的插值——插值不会凭空造出信息。

39.2 数学原理

三个判据共用一块地基：辐角原理。先把这块地基说清楚，后面两个判据都只是它的坐标改写。

39.2.1 辐角原理

设 $F(s)$ 在一条闭合围线 Γ 内部除有限个极点外解析、在 Γ 上无零点无极点。当 s 沿 Γ 顺时针绕行一周时，$F(s)$ 在复平面上绕原点转过的圈数 N 满足

$$N = Z - P \tag{39-3}$$

其中 Z、P 分别是 $F(s)$ 在 Γ 内的零点数与极点数（重根按重数计），N 以顺时针为正。直观理解：每个零点让映射曲线绕原点**顺着**走一圈，每个极点让它**逆着**走一圈，两者相抵后剩下的就是净值。

把这句话写成式子，就是

$$N = \frac{1}{2\pi}\Delta_{\Gamma} \arg F(s) \tag{39-3a}$$

$\Delta_{\Gamma} \arg F$ 是沿围线走完一圈后辐角的净变化量。它必为 2π 的整数倍，因为曲线首尾必须闭合；而它只取决于围线内部零点与极点的个数，与围线画成什么形状无关。这一条“与形状无关”是整个判据能用的前提：实际工程里围线总是画成最方便的样子（直线加圆弧），而不是按系统真实边界画。

举一个可以手算的最小例子。取 $F(s) = (s-1)/(s+2)$，围线取以原点为心、半径 3 的圆。圆内有零点 1、极点 -2，故 $Z=1$、$P=1$、$N=0$：沿圆走一圈，$s-1$ 的辐角增加 2π，$s+2$ 的辐角也增加 2π，两者相减为零，映射曲线绕原点零圈。把半径缩到 1.5，极点 -2 被留在圈外，$Z=1$、$P=0$、$N=1$，同一条映射曲线绕原点一圈。**同一个函数、同一条曲线，只因为围线换大小，圈数就变了**——变的不是曲线，而是圈里装了什么。理解这一点，就不会把“数圈”误解成“看曲线形状好不好看”。

重根按重数计，这一句也不是形式上的补充。若 F 在某点有二阶零点，辐角在那里转过 4π 而非 2π，映射曲线绕原点两圈。工程上对应的是“一对重根同时进入右半平面”，Nyquist 图上表现为曲线一次穿过 -1 左侧时圈数跳 2，而不是跳 1（§39.12.3 的代码正是按这个规律设的核对）。

取 Γ 为包围整个右半平面的 D 形围线（沿虚轴从 $-\mathrm{j}\infty$ 到 $+\mathrm{j}\infty$，再沿右半大圆弧回到 $-\mathrm{j}\infty$），并取

$$F(s) = 1 + L(s) = \frac{D_{cl}(s)}{D_{ol}(s)} \tag{39-4}$$

则 F 的零点就是闭环极点、极点就是开环极点。于是 Z 是右半平面的闭环极点数，P 是右半平面的开环极点数。**闭环稳定等价于 $Z=0$**，即

$$N = -P \tag{39-5}$$

这就是 Nyquist 判据的一般形式。$P=0$（开环稳定，绝大多数传动系统属于此类）时，它退化为“$1+L(\mathrm{j}\omega)$ 的曲线不环绕原点”，也就是 $L(\mathrm{j}\omega)$ 不环绕 -1 点。

把这套流程在本章对象 $L = 10K/[s(s+2)(0.05s+1)]$ 上走完整的一圈，可以把“数圈”从口号变成算术。D 形围线分四段，逐段看映射：

第一段，正虚轴 ω 从 0^+ 到 ∞。 低频时 $L \approx 10K/(2\mathrm{j}\omega) = -\mathrm{j}5K/\omega$，模趋于无穷、相位 -90°，曲线从负虚轴的无穷远处出发；相位随频率单调下降到 -270°，中途在 $\omega_{180}=6.3246$ 处穿过负实轴，落点 $-0.2273K$；高频时 $L \approx 200K/(\mathrm{j}\omega)^3$，曲线从 $+90^\circ$ 方向收进原点。

第二段，半径 $R\to\infty$ 的大半圆。 在 $s = Re^{\mathrm{j}\theta}$ 上 $L \approx 10K/(0.05R^3\mathrm{e}^{\mathrm{j}3\theta})$，模按 R^{-3} 趋于零，辐角是 -3θ。θ 从 $+90^\circ$ 走到 -90°，辐角就从 -270° 转到 $+270^\circ$——**整整一圈半，但半径只有 $10K/(0.05R^3)$**，缩成一个点。它对包围圈数没有贡献，却是“曲线为什么在原点附近来回穿”的原因：三阶分母让这条曲线在原点处绕了三趟。

第三段，负虚轴。 由实系数性质 $L(-\mathrm{j}\omega)=\overline{L(\mathrm{j}\omega)}$，这一段是第一段关于实轴的镜像，同样在 $-0.2273K$ 处穿过负实轴。

第四段，原点处半径 $\varepsilon\to 0$ 的小凹口。 在 $s=\varepsilon\mathrm{e}^{\mathrm{j}\theta}$ 上 $L \approx 5K\mathrm{e}^{-\mathrm{j}\theta}/\varepsilon$，模 $5K/\varepsilon\to\infty$，辐角从 $+90^\circ$ 顺时针经 0° 到 -90°。这是一段半径无穷大的右半圆，作用是把正、负虚轴两条支路在无穷远处接起来。

四段拼成一条闭合曲线后，判稳只剩一句话：**数这条闭合曲线在 -1 左侧穿过负实轴的次数**。注意“闭合曲线”，不是“正频率那半条”——本章对象的正频率支路只在 ω_{180} 处穿过一次，可镜像支路还要再穿一次，所以

- $K<4.4$：穿越点在 $-0.2273K$，位于 -1 右侧，$N=0$，$Z=N+P=0$，稳定；
- $K=4.4$：穿越点恰好落在 -1，曲线过临界点，闭环极点在 $\pm\mathrm{j}6.3246$，等幅振荡；
- $K>4.4$：穿越点移到 -1 左侧，**正、负两条支路各穿一次**，$N=2$，$Z=2$，闭环有一对右半平面极点。

最后这一条是最容易数错的地方。只画 $\omega>0$ 的半条曲线、只数到“穿了一次”，就会得出“$Z=1$、只有一个不稳定根”的结论，而实算给出的是两个——因为三次多项式的复根必然成对出现，单数一个在数学上就不成立。数值上可以验证：沿整条围线累加 $\arg[1+L(\mathrm{j}\omega)]$ 的变化量，$K=1$ 与 $K=6$ 的结果恰好相差 2.00 整圈，而 $K=4.4$ 与 $K=6$ 相差 0——越过 4.4 之后，穿越点继续左移，圈数却不再增加。这也正是 §39.12.3 里 `rhp_count` 与绕数核对要一起打印的原因：圈数回答“有几个”，代数判据回答“是不是”，两者必须一致。

39.2.2 从一般形式到可画的曲线

围线沿虚轴走的那一段，正是 ω 从 $-\infty$ 到 $+\infty$ 的 $L(\mathrm{j}\omega)$；右半大圆弧那一段，只要 L 是严格真有理分式，就映射为原点。又因为实系数传递函数满足 $L(-\mathrm{j}\omega)=\overline{L(\mathrm{j}\omega)}$，负频率那半条曲线是正频率曲线的镜像。所以**实际只需要画 ω 从 0 到 $+\infty$ 的一条曲线，再对实轴做镜像**。

曲线起点在 $\omega=0$（含积分环节时趋于无穷远，需要补一段半径无穷大的圆弧），终点在 $\omega\to\infty$ 时落到原点。若开环在虚轴上有极点（积分环节、谐振），围线还要用半径 $\varepsilon\to 0$ 的小半圆绕开，对应曲线上补一段半径无穷大的圆弧，转向由极点重数决定。这一段最容易画错，§39.3.4 会给出逐步规则。

图 39-2 把围线与映射结果并排放。(a) 是 s 平面上的 D 形围线：沿虚轴的直线段、右半平面的大圆弧，以及原点处为绕开积分环节而挖的小凹口；(b) 是 $K = 2.2$ 时映射出来的曲线，黑色实线是正频率段，红色虚线是它的镜像，空心圈标出临界点 -1。整条曲线落在 -1 的右侧，说明不包围，闭环稳定——这就是辐角原理在一张图上的一次具体兑现。

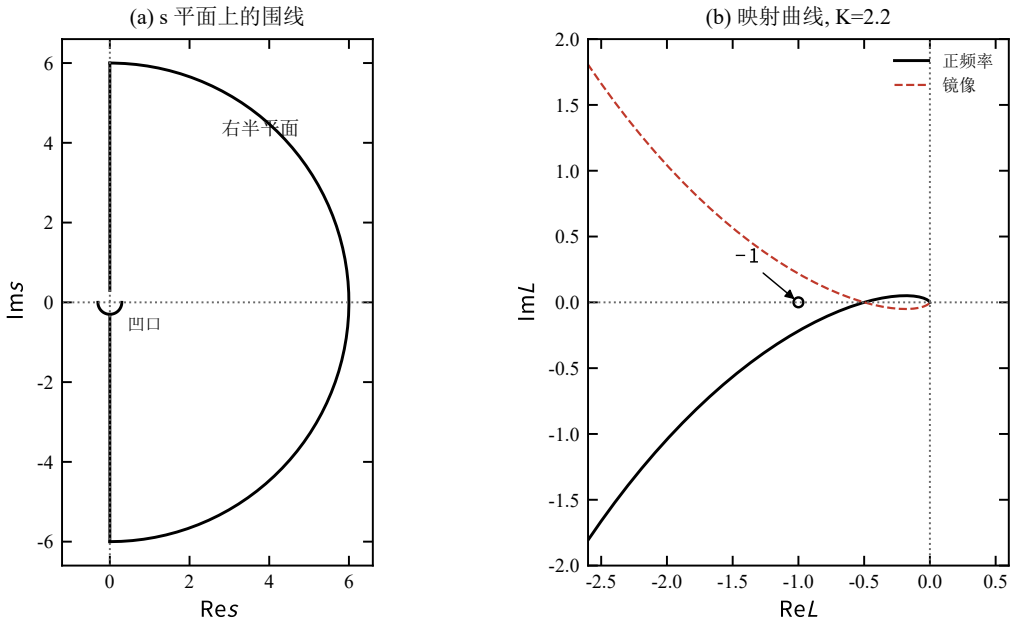

图 39-2　Nyquist 围线与映射曲线

39.2.3 Bode 判据：同一条曲线的对数坐标

把 $L(\mathrm{j}\omega)$ 写成 $|L|\mathrm{e}^{\mathrm{j}\varphi}$，Nyquist 曲线在极坐标下的两个分量就分别是 Bode 图的幅频与相频。对 $P = 0$ 的最小相位系统，“不环绕 -1”等价于两条更易读的条件：

1. 在 $|L(\mathrm{j}\omega)| = 1$ 的频率 ω_c 处，相位高于 -180°；
2. 在 $\varphi(\omega) = -180^\circ$ 的频率 ω_{180} 处，幅值低于 1（0 dB）。

两个条件的余量分别是相位裕度与增益裕度

$$\varphi_M = 180^\circ + \varphi(\omega_c), \qquad G_M = \frac{1}{|L(\mathrm{j}\omega_{180})|} \tag{39-6}$$

G_M 常以 dB 表示：$20\lg G_M$。$P \neq 0$ 时这两个不等式**不再是充分条件**——此时必须回到“数圈数”，Bode 图只能作为辅助。这一点在磁悬浮、倒立摆这类开环不稳定的对象上会直接决定结论对错，§39.9 给出例子。

这两条为什么与“不包围”等价？先把它们翻译成几何语言。在 ω_c 处相位高于 -180°，说的是曲线穿过单位圆时还在负实轴的上方；在 ω_{180} 处幅值小于 1，说的是曲线穿过负实轴时还在单位圆以内。两种说法都在描述同一件事：曲线是从 -1 的**内侧**绕过去的。在幅频只穿 0 dB 一次、相频只穿 -180° 一次的前提下，“谁先谁后”只有两种可能，恰好一一对应“包围”与“不包围”。

“只穿一次”是前提，不是结论。若相位在 ω 增大过程中三次越过 -180°（多段滞后叠加时很常见），两个裕度只反映离 -1 最近的那一次，其余两次穿越仍然可能把 -1 圈进去；此时 Bode 上的“裕度为正”就会给出错误结论。判据的完整形式始终是数圈，两个裕度只是它在“单次穿越”这一特殊情形下的简化读数。

另一个前提是**最小相位**，即开环没有右半平面零点。右半平面零点不改变幅频，却把相位往下拖，于是“幅值多大”与“相位多少”之间不再有一一对应；Nyquist 图上曲线会多绕一个弯，包围关系仍然数得清，但靠两个裕度已经判不了。§39.9.2 给出一个“幅频看着很安全、相位其实已经越线”的例子。把这三条前提合起来说：$P=0$、**最小相位、单次穿越，三者同时成立时，“两个裕度都为正”才是稳定的充分条件**；缺一条，就要回到 Nyquist 图。

用本章对象的两个工作点把这条等价关系验一遍，可以看清“谁先谁后”到底在说什么。$K=2.2$ 时，曲线在 $\omega_c=4.42$ 处穿过单位圆，那一刻相位是 -168.2°，还在负实轴上方 11.8°；继续升频，曲线进入第三象限，在 $\omega_{180}=6.32$ 处落到 -0.5。**先到单位圆、后到负实轴，而且到负实轴时已经在圆内**，这就是“从 -1 内侧绕过”的完整描述。换成 $K=5$：曲线在 $\omega_c=6.74$ 处才穿过单位圆，此时相位已经是 -182.1°，也就是**先到负实轴、后到单位圆**，穿越点落在 -1.136，-1 被圈在里面。注意这时两个穿越的次序也颠倒了：$\omega_{180}=6.32$ 反而小于 $\omega_c=6.74$，而 $K=2.2$ 时是 $\omega_c=4.42<\omega_{180}=6.32$。

这两个工作点的差别只在“两个穿越的先后”，而先后又等价于“相位裕度与增益裕度的正负号”。所以 Bode 上的两条不等式不是 Nyquist 的近似，而是它的另一种记法——在同一条曲线上换了个坐标读数。真正需要小心的是这个等价关系的三个前提，而不是不等式本身。

39.2.4 根轨迹判据：让增益动起来

闭环特征方程为 $1+KG(s)=0$，把 K 看作参数，根随 K 变化的轨迹就是根轨迹。由 $KG(s)=-1$ 拆出两个条件：

$$|G(s)|=\frac{1}{K},\qquad \angle G(s)=(2k+1)\cdot 180^\circ \tag{39-7}$$

相角条件与 K 无关，它决定了轨迹的**形状**；幅值条件决定了某个点对应**哪个** K。判稳只需看轨迹是否穿过虚轴：穿越点由 $s=\mathrm{j}\omega$ 代入特征方程解出，得到临界频率 ω_{osc} 与临界增益 $K_{\max}$——这正是第 38 章 §38.2.5 用辅助多项式所做的同一件事。

k 取遍所有整数，所以相角条件是“180° 的奇数倍”，而不是“等于 180°”。这一点在画图时很实用：从实轴上的极点出发，出射方向由该点处所有零极点贡献的相角之和补足到 180° 决定；从共轭复极点出发时，出射角要减去共轭伙伴的贡献，得到的往往不是 90°，而是 90° 加减一个修正量。手画根轨迹时最先画错的就是这个出射角。

轨迹的条数等于开环极点数 n。当 $K\to\infty$ 时有 $n-m$ 条支路趋向无穷远（m 是零点数），它们沿 $n-m$ 条渐近线离开，渐近线与正实轴的夹角为 $(2k+1)180^\circ/(n-m)$，交点在 $\sigma_a=(\sum p_i-\sum z_i)/(n-m)$。本例 $n=3$、$m=0$，故三条渐近线、夹角 $\pm 60^\circ$ 与 180°、交点 -7.33——这三个数在 §39.4.3 会直接用到。

根轨迹判据最擅长回答的是“改哪个参数能把根拉回来”。若轨迹整体留在左半平面（例如二阶对象加一个左半零点），则**任意增益都稳定**，此时 Bode 上的增益裕度为无穷，与根轨迹的结论一致；反之若某条支路一开始就在右半平面（开环不稳定），则必须先把增益降到某个下界以下才能稳定，这个下界在根轨迹上表现为“轨迹从右半平面进入左半平面”的那一点。

39.2.5 三者的关系

表 39-1 三种判据的输入、输出、前提与强项

判据	输入	输出	前提	强项
Nyquist	开环 $L(\mathrm{j}\omega)$ 的完整曲线	包围圈数 N	只需频响，可有纯延迟	处理 $P\neq 0$、延迟、非最小相位
Bode	幅频与相频两张图	G_M、φ_M	最小相位、单次穿越	现场扫频直接可用，裕度直观
根轨迹	开环零极点	根随 K 的轨迹	需已知零极点	看清“根往哪儿跑”，指导补偿设计

三者互为校验：同一对象用三种方法算出的 $K_{\max}$ 应当在数值精度内一致。若不一致，先查相位是否连续展开（$\pm 360^\circ$ 卷绕）、再查是否漏画了无穷远圆弧。

表里三列的差别可以归到一句话：**输入决定“能用在什么场合”，输出决定“能回答什么问题”**。Nyquist 要整条曲线，输入最贵，输出也最完整；Bode 是它的极坐标拆分，信息量相同，只是把“距离与方位”换成了“幅值与相位”两张图，读数更方便但前提更多；根轨迹只要零极点，输入最便宜，输出是“根随 K 的走向”，天生适合指导设计。

按这个顺序看，三者的角色分工很清楚：**Nyquist 用来“判”，根轨迹用来“改”，Bode 夹在中间**。判的时候不怕麻烦，宁可回到复平面数圈；改的时候要的是“零点放在哪里轨迹会左移”，那只有根轨迹答得出。Bode 之所以成为工程默认，是因为它两头都能凑合：既能读裕度（判），又能看出“抬哪一段幅频能补相位”（改）。

三者对不上时的排查也有优先级。Bode 与 Nyquist 描述的是同一条曲线，两者矛盾说明读数或画法出了问题（展开、圆弧、坐标），属于“低层错误”；根轨迹走的是另一条路径（多项式求根），与前两者矛盾才可能是模型或前提的问题（$P\neq 0$、非最小相位、条件稳定）。**先修低层错误，再怀疑前提**——反过来做，往往会把一条正确的曲线改错。

39.3 设计步骤

频率判据的手算比 Routh 表“轻”，但比它更容易在细节上出错：相位少展开一圈、无穷远圆弧画反方向，都会让结论刚好相反。下面六步把容易出错的地方逐一固定下来。

39.3.1 第一步：写成标准形式并数 P

把开环整理成

$$L(s)=K\,\frac{\prod_i (1+T_i s)}{\prod_j (1+\tau_j s)}\cdot\frac{1}{s^{m}} \tag{39-8}$$

的因式形式，然后数右半平面极点个数 P。三个要点：积分环节 s^m 的极点落在虚轴上，**不计入** P，但它会产生无穷远圆弧（第四步处理）；只有分母里出现 $1-Ts$（$T>0$）这种“负号时间常数”，才意味着一个右半极点，写成 $1+Ts$ 的都是左半极点；纯延迟 $e^{-T_d s}$ 是超越函数，既无极点也无零点，P 仍按有理部分数——但若用 Padé 近似代入，会引入右半平面零点，“最小相位”这个前提就没了，Bode 判据随之失效（§39.9）。

39.3.2 第二步：画两张图并展开相位

幅频用 dB、频率用对数坐标；相频要**连续展开**，即把每个环节的 $\pm 360^\circ$ 跳变接上。判断 -180° 穿越时，未展开的相位会在穿越点附近来回跳，看上去像“穿了好几次”，实际只有一次。

手算时可以用斜率法粗画：每个一阶极点在其转折频率之后贡献 -20 dB/十倍频与 -90°；每个积分环节从起点就贡献 -20 dB/十倍频与 -90°。本例 $L=22/[s(s+2)(0.05s+1)]$ 的转折频率是 2 与 20 rad/s，幅频斜率依次是 -20、-40、-60 dB/十倍频，相位依次趋近 -90°、-180°、-270°。

斜率法还能给出一个“量级感”：$\omega=1$ 时 $|L|=22/(1\times 2.236\times 1.001)\approx 9.83$，即 19.9 dB；到 $\omega=10$ 时已经降到 $22/(10\times 10.2\times 1.12)\approx 0.19$，即 -14 dB。从 $+19.9$ dB 掉到 -14 dB，跨两个十倍频共掉 34 dB，平均斜率约 -17 dB/十倍频——比 -20 略缓，因为转折频率 2 与 20 之间还有一段过渡区。这组数不用精确，它的用途是让你在拿到扫频曲线时能一眼判断“这条曲线是不是我要的对象”：若实测在 $\omega=10$ 处还有 0 dB，说明模型少算了一个极点。

相位也能这样逐项核对。本例 $\omega=0.2$ rad/s 时，三个环节的相角分别是 -90°、$-\arctan(0.1)=-5.71^\circ$、$-\arctan(0.01)=-0.57^\circ$，加起来 -96.28°，与频响函数在该频率给出的读数一位不差。**相位是各环节相角的代数和，没有“耦合修正”**——这一点与幅值不同：幅值要连乘，取 dB 后才能相加，所以幅频的斜率法只在转折频率之间才严格成立。

手算时先列一张“环节—相角”表逐项相加，比整体套 $\arctan$ 公式更不容易漏项，尤其在含右半平面零点的时候：那种环节的相角是 $-180^\circ+\arctan$，符号写反会让整条相位曲线翻转，而幅频看起来毫无异常（§39.9.2 就是这么被骗的）。

39.3.3 第三步：读两个穿越频率

ω_c 由 $|L(\mathrm{j}\omega)|=1$ 解出，ω_{180} 由 $\varphi(\omega)=-180^\circ$ 解出（多圈时取所有解）。本例相位穿越点可以解析求出：令两个滞后环节的相角之和为 90°，即 $\arctan(\omega/2)+\arctan(0.05\omega)=90^\circ$，两边取正切得 $\omega^2\cdot 0.05/2=1$，故

$$\omega_{180}=\sqrt{40}=6.3246\ \mathrm{rad/s} \tag{39-9}$$

这正是第 38 章式 (38-20) 的 $\sqrt{a_0/a_2}$ 在 $K=K_{\max}$ 处的值，两条路径给出同一个频率。

ω_c 没有闭式解，但手算两次就能收敛到三位有效数字。先猜 $\omega=4$：$|L|=22/(4\times 4.472\times 1.020)=22/18.24=1.206$，即 $+1.63$ dB，偏大；再猜 $\omega=5$：$22/(5\times 5.385\times 1.031)=22/27.76=0.793$，即 -2.02 dB，偏小。在两点间按 dB 线性内插得 $\omega\approx 4+1.63/(1.63+2.02)=4.45$；代回算一次得 -0.09 dB，略偏小，再挪回一点就是 4.42。三步之内收敛，误差 0.2%，比直接用计算器解方程更不容易按错键。

这段迭代值得单独说一句，因为它暴露了一个常被忽略的事实：**ω_c 是“算出来”的，ω_{180} 往往是“解出来”的**。前者依赖幅值，幅值随 K 变，所以每换一档增益都要重算；后者只依赖相位，而增益不进相位，所以对同一结构只算一次。表 39-2 里五档增益共用一个 6.3246，却各有各的 ω_c，原因就在这里。

图 39-3 是 $K=2.2$ 时的 Bode 双图。上图的 0 dB 线与幅频交于 $\omega_c=4.42$，下图对应位置的相位是 -168.2°，与 -180° 的差就是相位裕度 11.9°；下图的 -180° 线与相频交于 6.32，上图对应位置的幅值是 -6.0 dB，取绝对值就是增益裕度。两条竖虚线一个来自幅值条件、一个来自相位条件，把“两个穿越”的位置钉在了同一张时间轴上。

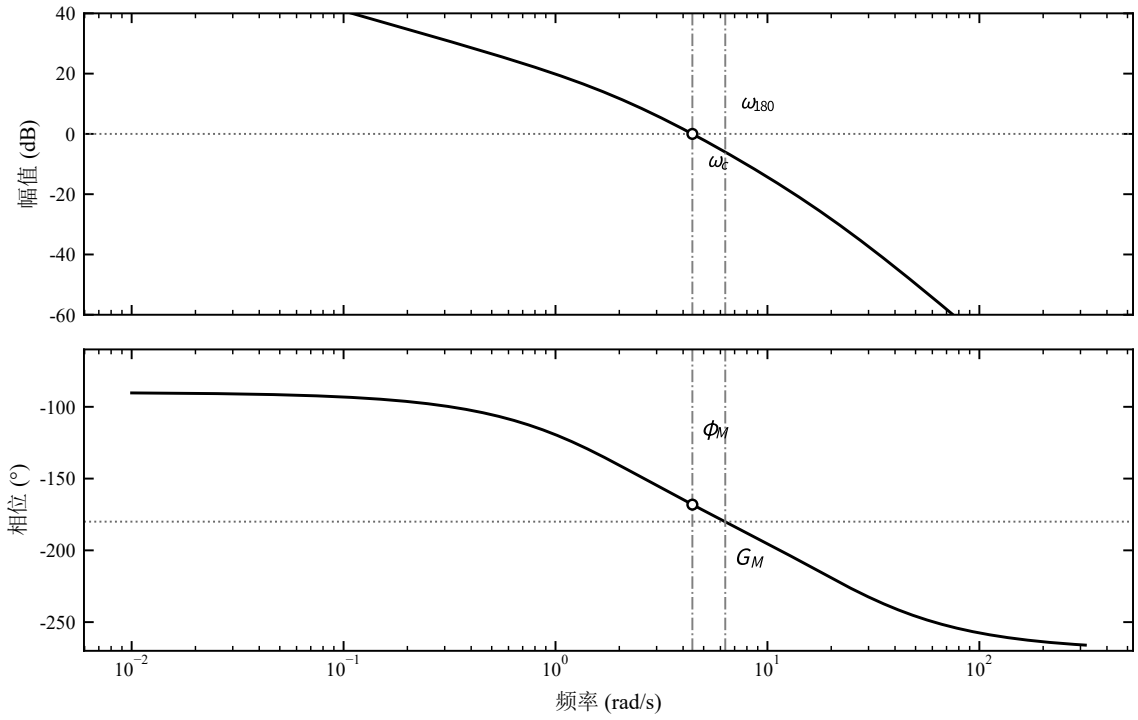

图 39-3　Bode 图上的两个裕度

39.3.4 第四步：补无穷远圆弧

对 s^m 型极点，围线在原点处要用半径 $\varepsilon \to 0$ 的小半圆从右侧绕过，映射到 L 平面上是半径 ∞ 的大圆弧，**顺时针转过** $m \cdot 180^\circ$。以 $L = K/[s(s+2)]$ 为例：$\omega \to 0^+$ 时 $L \approx K/(2\mathrm{j}\omega)$，相位 -90°、模无穷；补的圆弧从 $+90^\circ$ 顺时针经 0° 落到 -90°，把起点和终点接起来。

这一段画错的方式很固定：把顺时针画成逆时针，等价于凭空多算一次环绕，结论就从“稳”变成“不稳”。检验办法是看曲线是否与负实轴相交——对 $1/s$ 型对象，只有把圆弧画对，曲线才会从第三象限进入第二象限。

为什么一定是顺时针？围线在原点处是从负虚轴一侧绕过小半圆到正虚轴一侧的，$s = \varepsilon \mathrm{e}^{\mathrm{j}\theta}$ 中 θ 从 -90° 逆时针走到 $+90^\circ$；但 L 在原点附近的行为是 $1/s^m$，取倒数会把辐角整体翻号，于是 θ 的逆时针变成相位的顺时针。记住这个“取倒数翻方向”的机制，比背结论可靠：$m=1$ 时圆弧是半圈，$m=2$ 时是一整圈（双积分对象），$m=3$ 时是一圈半，方向始终顺时针。

39.3.5 第五步：下结论并交叉核对

$P=0$ 时，曲线不包围 -1 即稳定；有包围时按 $Z = N + P$ 数出右半平面闭环极点数。判断“是否包围”有一个免争议的做法：从 -1 点向右作一条射线，数曲线穿过它的次数（带方向），比目测圈数可靠。

射线法的好处是把二维的“绕圈”降成一维的“穿越计数”：曲线自下而上穿过射线记 $+1$，自上而下记 -1，代数和就是圈数（符号按本节“顺时针为正”的约定取）。曲线自交、局部打结都不影响计数，因为射线只在一处开口。代价是要选对射线方向——必须从 -1 向**右**，若向右的射线恰好与曲线相切，换一个略微倾斜的方向重数即可。

随后做两项核对：把 G_M 换算成临界增益，与第 38 章的 $K_{\max}$ 对照；把 ω_{180} 与代数判据给出的 ω_{osc} 对照。本例 $K=2.2$ 时 $|L(\mathrm{j}6.3246)| = 0.5$，故 $G_M = 2.00$（6.02 dB），对应的临界增益为 $2.2 \times 2.00 = 4.40$，与 Routh 表的结果完全一致。

这两项核对的分工要说清：ω_{180} 核对的是**结构**，它只与零极点位置有关，增益抄错也查不出来；G_M 换算核对的是**增益**，它把 $4.40/K$ 这条反比关系验一遍。两者一起做，才能同时排除“对象写错”与“增益抄错”两类错误。若 ω_{180} 对得上而换算出的 $K_{\max}$ 对不上，几乎一定是 K 的位置代错了——比如把 $10K$ 写成了 K。

39.3.6 第六步：归档

记录 P、ω_c、ω_{180}、G_M、φ_M，以及一句“哪个穿越是决定性的”。多条穿越时，只有最靠近 -1 的那一条决定裕度，其余穿越虽然也满足幅值条件，却不构成威胁；把它们一并列出，是为了在参数变化时能看出“下一次先出问题的是哪一条”。

归档格式沿用 §38.3.7 的“可复算的一行”：结构 → 系数或频响来源 → 两个穿越频率 → 两个裕度 → 当前工作点。字段与第 38 章对齐，评审时可以在两章之间直接对照。本例的一行是：

> 三阶（积分 + 一阶 + 执行器滞后）→ 系数 $[0.05,\ 1.1,\ 2,\ 10K]$ → $\omega_c = 4.42$、$\omega_{180} = 6.3246$ → $G_M = 6.02$ dB、$\varphi_M = 11.9^\circ$ → $K = 2.2$。

下一轮改参数时只换最后一列，前四项就能立刻告诉你“是变好还是变坏”。若频响来自实测而非模型，还要在“频响来源”一栏写清激励幅值、扫频范围与相干函数门限，否则半年后无法判断这条曲线是在什么工况下测的。

39.3.7 六步走完之后：三个失败分支

六步都走完，结果不一定对。出现下面三种情况时，不要急着重算，先按分支定位是哪一步出了问题。

分支一：算出的 $K_{\max}$ 与 Routh 表不符。 先查第一步与第二步是否用了同一个对象——最常见的原因是“因式形式”与“多项式系数”手工转录时抄错了一个数（比如把 $10K$ 写成 K）。其次是查第四步的无穷远圆弧有没有漏：积分环节少补半圈，包围圈数会差一整圈，边界增益可能差几倍。最后才怀疑数值精度。**顺序不能反**：多数人一上来就怀疑算法，实际上八成的错在转录。

分支二：找不到 ω_{180}。 有两种可能，必须分清。其一，相位根本没有到 -180°（例如二阶对象只到 -180° 而不穿越），此时 $G_M = \infty$ 是正确答案，不是程序出错；判据仍然有效，只说明“增益加大不会因增益而失稳”。其二，相位到了但被卷绕掩盖，$[-180^\circ, 180^\circ]$ 的折返让曲线在图上“跳”过穿越点——这时把相位连续展开，G_M 立刻出现。区分方法很直接：看 $\omega \to \infty$ 时相位的极限值，若它大于 -180°，属于第一种；若小于，属于第二种。

分支三：Bode 说稳、根轨迹说不稳。 三个判据给出矛盾结论时，几乎一定是某个前提被破坏了：要么对象有右半平面零点（相位与幅频脱钩），要么相位多次穿越（裕度只反映最近一次），要么 $P \neq 0$（裕度判据不充分）。按 §39.9.7 的五步顺序查一遍，通常在前三步就能找到原因。**三个判据互相矛盾不是“方法有争议”，而是“输入信息不足以支撑结论”的明确信号。**

这三个分支合起来说明一件事：六步流程的价值不在“算得快”，而在“错了能定位”。Routh 表算错时，你只知道结果不对；频率法算错时，图上的形状会告诉你错在哪一步。

39.4 连续情形

本节把 §39.3 的六步在同一组对象上走两遍：先看纯二阶，再看加了执行器滞后的三阶。两遍的区别恰好说明“增益裕度”与“相位裕度”为什么会给出不同强度的结论。

39.4.1 二阶对象：相位裕度有限，增益裕度无穷

对象 $L=10K/[s(s+2)]$，$K=1$ 时由 $|L(\mathrm{j}\omega)|=1$ 得

$$\omega^4+4\omega^2-100=0 \;\Longrightarrow\; \omega_c=\sqrt{8.198}=2.863\ \mathrm{rad/s} \tag{39-10}$$

相位为 $-90^\circ-\arctan(\omega_c/2)=-90^\circ-55.1^\circ=-145.1^\circ$，故 $\varphi_M=34.9^\circ$。而相位要到 $\omega\to\infty$ 才逼近 -180°，全程不穿越，所以 ω_{180} 不存在，$G_M=\infty$。

式 (39-10) 的推导只有一步：把 $|L(\mathrm{j}\omega)|=1$ 写成 $\omega\sqrt{\omega^2+4}=10K$，两边平方得 $\omega^2(\omega^2+4)=100K^2$，再令 $x=\omega^2$，得二次方程 $x^2+4x-100K^2=0$。取正根

$$x=-2+\sqrt{4+100K^2} \tag{39-10a}$$

$K=1$ 时 $x=-2+\sqrt{104}=8.198$，开方即 2.863。这个式子说明 ω_c 随 K 单调上升，而且当 K 很大时近似 $\omega_c\approx\sqrt{10K}$——增益每增大 10 倍，带宽只增大 $\sqrt{10}\approx3.16$ 倍。

“$G_M=\infty$”的数学原因是相位只到 $-90^\circ-90^\circ=-180^\circ$ 而永远取不到：$\arctan$ 是开区间上的函数，$\omega\to\infty$ 时它趋于 90° 但不等号成立。工程含义是：**这台设备无论增益开多大都不会“因增益而发散”**——注意限定词，它仍可能因延迟、因未建模的高频极点、因饱和而失稳。把 $G_M=\infty$ 读成“绝对安全”是这一节最常见的误读。

同一组数还能读出延迟容忍：$\varphi_M=34.9^\circ=0.609$ rad，除以 $\omega_c=2.863$，得 $T_{d,\max}=0.213$ s。也就是说，纯二阶对象对延迟的容忍度并不比三阶宽多少——三阶在 $K=2.2$ 时只有 47 ms，二阶在 $K=1$ 时有 213 ms，看上去差四倍，但别忘了三阶那一档的增益是二阶的 2.2 倍，带宽也高得多（4.42 对 2.86）。按“延迟容忍与带宽成反比”这条规律，差距本应更大；之所以只差四倍，是因为二阶的相位裕度本身也更小。

这条结果与第 38 章“二阶没有上限”完全对应：$G_M=\infty$ 就是那句话的频率版。但要注意，φ_M 只有 34.9°，并且随 K 增大继续下降——$K=4.4$ 时 ω_c 升到 6.48 rad/s、φ_M 降到 17.2°，而 G_M 仍是无穷。**增益裕度无穷不代表系统“很安全”**，它只说明“再加多少倍增益都不会发散”，而相位裕度说明的是“再加多少延迟就会发散”。两个指标量的是不同的东西，这也是 §39.1 开头强调“答案形态”的原因。

39.4.2 三阶对象：两个裕度同时变小

加上 50 ms 执行器滞后后，$L=10K/[s(s+2)(0.05s+1)]$。相位穿越频率与增益无关（式 39-9 已给出 $\omega_{180}=6.3246$ rad/s），所以

$$G_M=\frac{1}{|L(\mathrm{j}6.3246)|}=\frac{44.0}{10K}=\frac{4.40}{K} \tag{39-11}$$

是一条精确的反比关系。$K=4.40$ 时 $G_M=1$（0 dB），与 Routh 的边界重合；$K=2.2$ 时 $G_M=2.00$（6.02 dB）。

式 (39-11) 里的 44.0 不是凑出来的，它就是 $|L(\mathrm{j}6.3246)|$ 在 $K=1$ 时的分母：

$$|s(s+2)(0.05s+1)|_{\omega=6.3246}=6.3246\times\sqrt{40+4}\times\sqrt{1+0.1}=6.3246\times6.6332\times1.0488=43.99$$

所以 $|L|=10/43.99=0.2273$，与第 38 章 §38.4.5 提到的“边界频率处开环幅值 0.2273”是同一个数。K 线性地进分子，分母不动，于是 $|L|\propto K$，取倒数就是严格反比。**任何“增益裕度与增益成反比”的结论，背后都必然有一条“相位穿越频率与增益无关”的性质**——这条性质只在相位穿越由固定零极点决定、而增益不进相位

时才成立，遇到纯延迟对象（相位与 ω 成正比）也成立，遇到增益进相位的对象（如某些非线性环节）就不成立。

图 39-4 把这层反比画在对数坐标上：横轴是 K，纵轴是 G_M 的 dB 值，曲线是一条斜率 -20 dB/十倍频的直线。之所以在对数坐标下是直线，正是因为 $20\lg(4.40/K) = 20\lg 4.40 - 20\lg K$，$K$ 每翻十倍，纵坐标固定下降 20 dB。图中两条竖线分别标出设计工作点 $K = 2.2$ 与边界 $K = 4.40$，6 dB 的验收线在 $K \approx 2.2$ 处与曲线相交——这不是巧合，而是 6 dB 恰好对应“增益还能翻一倍”。

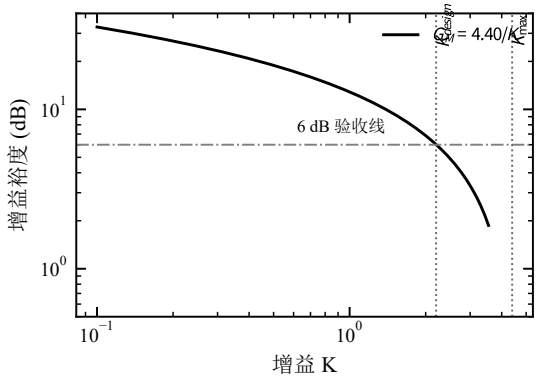

图 39-4　增益裕度与增益的严格反比

φ_M 需要解 $|L(\mathrm{j}\omega_c)| = 1$，没有闭式解，只能数值求。五档结果列于表 39-2，ω_c 与 φ_M 的有效数字取三位，由 §39.12 的 `bode_margins` 复算。

表 39-2 三阶对象的两个裕度随增益的变化

K	ω_c (rad/s)	φ_M (°)	G_M (dB)	$K/K_{\max}$
0.50	1.83	42.3	18.9	0.11
1.00	2.85	27.0	12.9	0.23
2.20	4.42	11.9	6.0	0.50
3.00	5.21	6.4	3.3	0.68
4.40	6.32	0	0	1.00

表里最值得记的是最后两列的关系：G_M 与 $K/K_{\max}$ 是倒数关系，K 翻倍，G_M 掉 6 dB；而 φ_M 下降得更快——K 从 1 增到 2.2（2.2 倍），G_M 从 12.9 dB 降到 6.0 dB（正好 6.9 dB），φ_M 却从 27.0° 掉到 11.9°（去掉 56%）。**在同一组参数上，相位裕度是比增益裕度更灵敏的“距离指示”**，原因是它同时受增益与频率两个因素影响。

ω_c 自身还能用一个粗式估。当 ω_c 越过第一个转折频率 2 rad/s 之后，$|L| \approx 10K/\omega^2$，令其为 1 得

$$\omega_c \approx \sqrt{10K} \tag{39-11a}$$

$K = 2.2$ 给 4.69（实算 4.42，高 6%），$K = 4.4$ 给 6.63（实算 6.32，高 5%），$K = 1$ 给 3.16（实算 2.85，高 11%）；到 $K = 0.5$ 时给 2.24，实算只有 1.83，高 22%——因为那一档的穿越点还没越过转折频率 2，ω^2 近似不成立。**这个式子只在 ω_c 高于所有低转折频率时可用**，而“高出多少”决定了误差是 5% 还是 20%。

它给出的信息比数值更有用：ω_c 与 $\sqrt{K}$ 成正比，增益翻四倍、带宽才翻一倍。这是“单积分 + 惯性环节”这类对象的共同规律，也是“提增益换带宽”效率不高的根源——想让带宽翻倍，得把增益开四倍，而四倍增益通常已经把相位裕度吃光了。

图 39-5 把五档增益的曲线画在一起，可以看清这种“灵敏度差异”从何而来。相频曲线只有一条——增益不进相位，五档完全重合，所以 -180° 的位置钉死在 6.32；幅频曲线则是五条互相平行的曲线，K 每增大一倍整体上移 6 dB。相位裕度是“0 dB 线与相频交点处的相位差”，交点随 K 增大向右滑，而相位曲线在这一段正在快速下降，两个因素叠加，φ_M 就掉得比 G_M 快。$K=4.40$ 时五条幅频中的最上面一条恰好与相频同时到达那个交点，两个裕度一起归零。

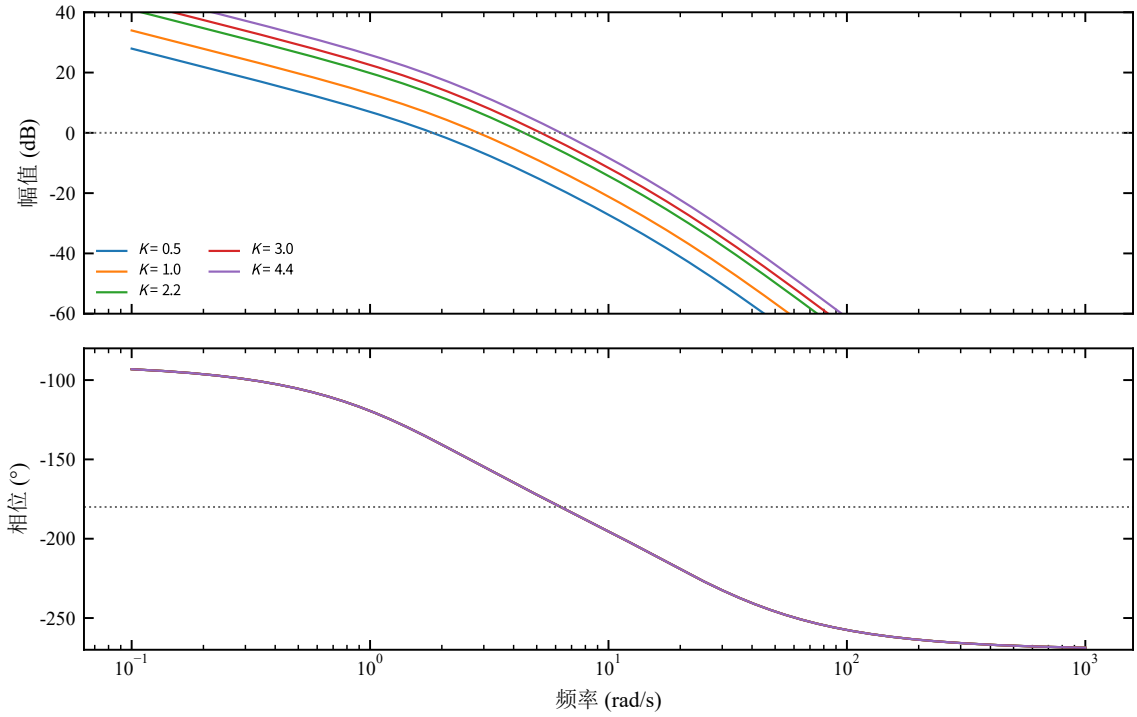

图 39-5　五档增益的 Bode 图

39.4.3 根轨迹：穿越点与临界增益

特征方程为

$$s(s+2)(0.05s+1)+10K=0.05s^3+1.1s^2+2s+10K=0 \tag{39-12}$$

三个起点是 0、-2、-20；三条渐近线交于 $\sigma_a=(0-2-20)/3=-7.33$，与正实轴夹角 $\pm60^\circ$、180°。令 $s=\mathrm{j}\omega$ 代入，实部与虚部分别为零：

$$-1.1\omega^2+10K=0,\qquad -0.05\omega^3+2\omega=0 \tag{39-13}$$

第二式给出 $\omega^2=40$（或 $\omega=0$），即 $\omega_{osc}=6.3246$ rad/s；代回第一式得 $K_{\max}=1.1\times40/10=4.40$。三个判据在同一组数上会合：代数判据给出 4.40，频率判据给出 $G_M=4.40/K$，根轨迹给出穿越点 $\pm\mathrm{j}6.3246$。

代入过程值得写全，因为它是本章唯一一次“复数乘法决定结论”的地方。先把 $s=\mathrm{j}\omega$ 代入前两个因子：

$$(\mathrm{j}\omega)(\mathrm{j}\omega+2)=-\omega^2+2\mathrm{j}\omega$$

再乘第三个因子 $(1+0.05\mathrm{j}\omega)$：

$$(-\omega^2+2\mathrm{j}\omega)(1+0.05\mathrm{j}\omega)=(-\omega^2-0.1\omega^2)+\mathrm{j}(2\omega-0.05\omega^3)=-1.1\omega^2+\mathrm{j}(2\omega-0.05\omega^3)$$

加上 $10K$ 后，实部是 $10K-1.1\omega^2$、虚部是 $2\omega-0.05\omega^3$，正是式 (39-13) 的两条。**虚部方程里没有 K**，所以它单独定出 ω；实部方程再把 ω 换算成 K。这个“虚部定频率、实部定增益”的分工，与第 38 章“整行为零时先由辅助多项式定 ω_{osc}、再由增益关系定 $K_{\max}$”是同一套逻辑，只是这里用的是复数而不是行列式。

图 39-6 是同一组根的轨迹。三个起点 0、-2、-20 都在实轴上，随着 K 增大，中间那条支路与左边那条支路相向而行，在实轴上某点相遇后分裂成一对共轭复根，向上、向下各走一条弧线，最终在 $K=4.40$ 时同时到达 $\pm\mathrm{j}6.3246$。虚线标出渐近线交点 -7.33，三条渐近线以 $\pm60^\circ$ 与 180° 散开；曲线在穿越点之后继续向右，实部为正，系统失稳。这张图回答的是“根往哪儿跑”，而前两张图回答的是“离边界多远”，两者互补。

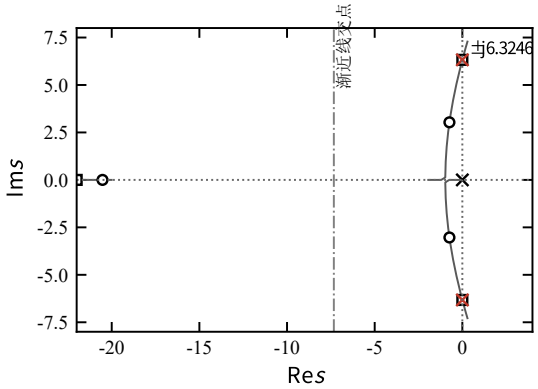

图 39-6　根轨迹与虚轴穿越点

39.4.4 三张图放一起看

Nyquist 曲线在 $K=2.2$ 时的走向是：$\omega\to0^+$ 时 $L\approx11/(\mathrm{j}\omega)$，从负虚轴方向的无穷远处出发；补的那段无穷大圆弧在右半平面从 $+90^\circ$ 顺时针扫到 -90°，把起点与负频率侧的镜像接上；随后主线进入第三象限，随 ω 增大顺时针绕行，在 $\omega=6.3246$ 处穿过负实轴于 -0.5，再进入第二象限并趋于原点。曲线与负实轴的交点就是 G_M 的倒数位置，离 -1 尚有一倍距离。

Bode 图上则是：幅频在 $\omega_c=4.42$ 处穿过 0 dB，相频此时为 -168.2°，两者之差 11.9° 就是相位裕度；相频在 6.32 处穿过 -180°，此时幅频为 -6.0 dB。根轨迹图上，三个极点随 K 增大向虚轴靠拢，在 $K=4.40$ 时成对到达 $\pm\mathrm{j}6.3246$。

三张图上的三个读数可以互相换算，这一点值得单独验一次。Nyquist 的负实轴交点在 $-0.2273K$：$K=1$ 时 -0.2273、$K=2.2$ 时 -0.500、$K=4.4$ 时 -1.000，三个数在同一张图上就是“点离 -1 还有多远”。把这个距离取倒数，得到 $4.40/K$，正是 Bode 的增益裕度（$1/0.2273=4.399$，与 4.40 差在四舍五入）。再令这个倒数等于 1，解出 $K=4.40$，就是根轨迹上轨迹触到虚轴的增益。**一个几何距离、一个 dB 数、一个增益值，三者只差一次取倒数和一次取对数。**

三张图的读数必须能互相解释：**Nyquist 上离 -1 的距离、Bode 上两个裕度、根轨迹上离虚轴的距离，是同一个量的三种度量。**任何一张读不出来，都说明那张图画错了，而不是“方法不适用”。

图 39-7 把三档增益的 Nyquist 曲线叠在一张图上。$K=1$ 时曲线缩在最内侧，离 -1 很远；$K=2.2$ 时曲线放大 2.2 倍，负实轴交点移到 -0.5；$K=5$ 时交点越过 -1，曲线把 -1 圈在里面，系统失稳。三档曲线形状完

全相同、只是尺寸不同，这正是“增益不进相位”的几何表现——增益只缩放曲线，不改变它的形状，所以判断稳定性就退化成判断“缩放后的曲线能否盖住 -1”。

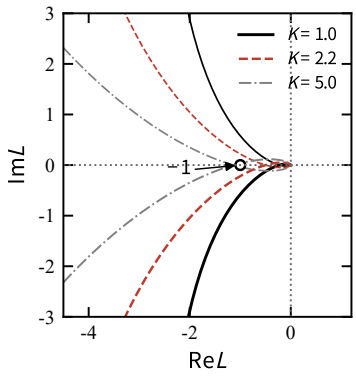

图 39-7　三档增益的 Nyquist 曲线

39.4.5 沿曲线走一遍：三段形状与低频渐近线

图 39-7 里三条曲线形状完全相同，这句话可以说得更硬：L 对 K 是线性的，K 从 1 变到 5 只是把曲线上的每个点沿原点方向拉长 5 倍，形状严格不变。判稳因此退化成“这条固定形状的曲线，放大多少倍会盖住 -1”。

按频率标上刻度，$K=2.2$ 那条曲线可以分成三段。**低频段几乎竖直**：$\omega=0.2$ 时落在 $-5.99-\mathrm{j}54.40$，$\omega=0.5$ 时 $-5.69-\mathrm{j}20.56$，实部只挪了 0.3，虚部缩了一半多。**中频段开始拐弯**：$\omega=2$ 时 $-3.00-\mathrm{j}2.45$，$\omega=3$ 时 $-1.82-\mathrm{j}0.86$，$\omega=4.42$ 时 $-0.98-\mathrm{j}0.21$——这一段离 -1 最近。**高频段穿过负实轴后进入第二象限**：$\omega=6.32$ 时恰好落在 -0.500，$\omega=10$ 时 $-0.186+\mathrm{j}0.051$，$\omega=20$ 时 $-0.030+\mathrm{j}0.025$，以原点为极限，相位从 -180° 继续走向 -270°。

低频段为什么不贴着虚轴，而是偏在左侧一条竖线上？把 $\omega\to0$ 展开就能看出来。分母里两个一阶因子在小 ω 时近似为 $2(1+\mathrm{j}0.55\omega)$，于是

$$L\approx\frac{10K}{2\mathrm{j}\omega}\,(1-\mathrm{j}0.55\omega)=\frac{5K}{\mathrm{j}\omega}-2.75K \tag{39-10b}$$

第一项是纯虚的积分项，第二项是一个**负实数偏移**。$K=2.2$ 时 $-2.75K=-6.05$，与 $\omega=0.2$ 实测的 -5.99 只差 0.06；$K=5$ 时 -13.75 对 -13.61。所以那条竖线是 $x=-2.75K$，不是 $x=0$。**“Nyquist 曲线从负虚轴无穷远处出发”这句话只在纯积分对象上对**：多一个惯性环节，曲线落到有限幅值时就整体左移了一个与 K 成正比的量。这也是 §39.3.4 补的圆弧必须从 $+90^\circ$ 一路顺时针扫到 -90° 的原因——它在无穷远处接上起点，而曲线一旦进入有限幅值区，就已经站在 $x=-2.75K$ 上了。

三段里真正决定稳定性的是中频段。把曲线上每一点到 -1 的距离都算出来取最小值：$K=1$ 时最近点在 $\omega=3.25$、距离 0.402；$K=2.2$ 时在 $\omega=4.61$、距离 0.191；$K=5$ 时在 $\omega=6.71$、距离 0.035。三个最近点都落在各自的 ω_c 附近（2.86、4.42、6.74），**而不是落在 ω_{180} 上**——ω_{180} 只是“曲线与负实轴的交点”，并不是“离 -1 最近的点”。两者在低增益时差得很远：$K=1$ 时负实轴交点在 -0.227，离 -1 有 0.773，而真正最近处只有 0.402，差近一倍。

这三个距离取倒数就是灵敏度峰值 M_s（§39.9.4）：$1/0.402=2.49$、$1/0.191=5.24$、$1/0.035=28.3$，与 §39.9.4 表中 $K=1$ 与 $K=2.2$ 两行的 2.488、5.242 对得上。读 Nyquist 图时，**先找视觉上离 -1 最近的那一段，再去读它的频率**，比先找负实轴交点更接近真相；增益裕度回答的是“再乘多少倍会碰线”，而最近距离回答的是“整条曲线最贴近 -1 到什么程度”，后者才是曲线的保守程度。

39.4.6 加一个极点到底贵在哪：把两档放在一起

把 $K=1$ 时二阶与三阶的两组数并排，能看清“执行器滞后”这笔账到底记在哪里。

对象	ω_c	φ_M	G_M	超调
$10/[s(s+2)]$	2.863	34.9°	∞	35.1%
$10/[s(s+2)(0.05s+1)]$	2.846	27.0°	12.87 dB	46.1%

第一眼看上去几乎是同一个系统：穿越频率只差 0.6%，幅频在 0–3 rad/s 上几乎重合。可相位裕度掉了 7.9°，增益裕度从无穷直接掉到 12.87 dB，超调涨了 11 个百分点。**这三个恶化都来自同一个 20 rad/s 的极点，而它离 ω_c 有五倍多。**

账可以算得很细。新极点在 $\omega_c=2.846$ 处贡献的相位是 $-\arctan(2.846/20)=-8.1^\circ$，与实测的 7.9° 只差 0.2°（差在 ω_c 自己也挪了一点）；而 G_M 之所以从无穷变有限，是因为总相位现在能走到 -180° 了，穿越点被新极点钉在 $\sqrt{40}=6.32$。**“相位裕度掉 8°”是局部账，“增益裕度从无穷变有限”是定性变化**——后者不能用量来比，它意味着系统从此有了一个“开到多大就振”的明确上限。

这就是 §39.7.3 那条经验的分量：判断一个新环节贵不贵，先看它的转折频率与 ω_c 的比值，再看它有没有把相位推过 -180°。前一件事决定 φ_M 掉多少，后一件事决定 G_M 还有没有意义。本例的极点两件事都做了，所以它是本章最贵的一个参数。

39.5 离散情形

数字控制器里，判据的形状不变，“包围”的对象换了：从包围右半平面变成包围单位圆外。随之而来两个新问题——频率轴只有半圈可画，以及采样本身带来的相位损失。

39.5.1 单位圆外的 Nyquist 判据

把围线取成单位圆的外部（含无穷远点），映射函数仍取 $1+L(z)$。此时 P 是 $|z|>1$ 的开环极点数，Z 是 $|z|>1$ 的闭环极点数，判据仍是

$$N = Z - P \tag{39-14}$$

稳定即 $Z=0$。实际画图时，沿单位圆走 $z=\mathrm{e}^{\mathrm{j}\theta}$，$\theta$ 从 $-\pi$ 到 $+\pi$；由于实系数，仍只需 θ 从 0 到 π 的半圈。

为什么围线取“圆外”而不是“圆内”？因为连续域的 D 形围线包住的是**不稳定区**（右半平面），离散域的不稳定区是**单位圆外**，两者在各自的映射下扮演同一个角色。若改成沿单位圆内部走，包围的对象就反了，N 的符号随之翻转，公式要改写成 $N=P-Z$；两种写法都对，但不能混用。本章统一取“圆外”，与式 (39-14) 一致。

单位圆上的极点要单独处理，最常见的是 $z=1$ 处的积分环节（对应连续域的 $1/s$）。围线在 $z=1$ 处要用小圆弧从圆外绕过，映射到 L 平面上补一段无穷大圆弧，规则与 §39.3.4 完全平行：一个积分环节补半圈，两个补一圈，方向由“取倒数翻方向”决定。数字控制器里的 PI 只要带积分，就一定有这个 $z=1$ 极点，漏补这段圆弧是离散 Nyquist 最常见的错误。

39.5.2 频率轴只有半圈

连续域的 ω 从 0 到 ∞，离散域只有 $\theta=\omega T_s$ 从 0 到 π，对应物理频率 0 到 π/T_s（Nyquist 频率）。超过这个频率的响应会“折返”，同一段曲线被重复遍历。因此判稳时必须确认：**相位是否在 $\theta=\pi$ 之前越过 -180°**。若没有越过，说明穿越点被折叠到了高频侧，判据仍成立，但 Bode 图上读不出对应的 ω_{180}，只能回到 Nyquist 图数圈。

“折返”不是比喻。离散系统的频率响应以 $2\pi/T_s$ 为周期，ω 与 $\omega+2\pi k/T_s$ 给出完全相同的 L 值；所以从 π/T_s 再往上走，看到的只是 0 到 π/T_s 那一段的重复。工程含义是：**采样之后，“高频”这个概念失效了**，100 rad/s 与 $100-2\pi/T_s$ 无法区分。这也解释了为什么采样会把高频噪声“搬”到低频：不是噪声变低了，而是它被折到了能看见的频段里。

本例的 Nyquist 频率是 $\pi/0.1=31.4$ rad/s，而相位穿越只有 6.32，只占可用频段的 20%。这个比例说明：在 $T_s=0.1$ s 下，稳定性判据关心的那一段尚未接近折返边界。但“未接近折返”不等于“采样没有代价”——代价体现在裕度上，下一小节用同一对象的实测数据说明。反过来说，若采样周期放大到 0.5 s，Nyquist 频率降到 6.28，与 $\omega_{180}=6.32$ 几乎重合，折返就直接压在穿越点上：此时 Bode 图上根本读不出 -180° 穿越，只能回到离散 Nyquist 图数圈。

图 39-8 是 $T_s=0.1$ s、$K=2.2$ 时的离散 Nyquist 曲线。黑色实线是 θ 从 0 到 π 的半圈，虚线是它关于实轴的镜像；曲线在右端收口于实轴上的一点，对应 Nyquist 频率 $\pi/T_s=31.4$ rad/s，此后的频率只是折返，不提供新信息。把这张图与图 39-7 中 $K=2.2$ 的那条连续曲线并看，形状几乎一样，只是右端提前“封口”。但就是这一小段差别决定了成败：连续域 $K=2.2$ 的相位裕度还有 11.9°，离散后在同一物理频率 4.405 rad/s 处只剩 -0.6°，闭环根 $|z|_{\max}=1.0022$，已经落到单位圆外。**边界附近的“几乎一样”，在判稳时并不够用。**

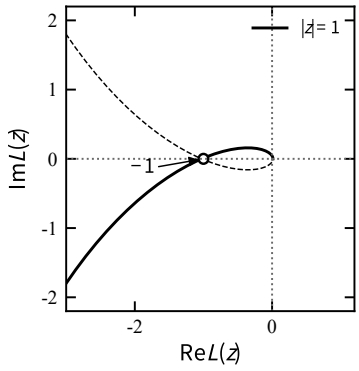

图 39-8　离散系统的 Nyquist 曲线

把这条离散曲线按 θ 标上刻度，能看清 ZOH 到底改了什么。$T_s=0.1$、$K=2.2$ 时：$\theta=0.2$（物理频率 2 rad/s）处 $L=-3.219-\mathrm{j}2.136$，$|L|=3.863$，连续域同频率是 3.870；$\theta=0.4$（4 rad/s）处 $-1.195-\mathrm{j}0.079$，1.198 对 1.206；$\theta=0.6222$（6.22 rad/s）处 $-0.485+\mathrm{j}0.151$，0.508 对 0.517；$\theta=1.0$（10 rad/s）处 $-0.133+\mathrm{j}0.129$，0.185 对 0.193；$\theta=2.0$（20 rad/s）处 $+0.006+\mathrm{j}0.033$，0.033 对 0.039。

三点读数值得记。**其一，离散幅值逐点略小**：差距从 2 rad/s 的 0.2% 扩大到 20 rad/s 的 14%，ZOH 的平均衰减随频率上升，这是 $K_{\max}$ 掉 6.25 dB 中“幅值那一半”的来源。**其二，相位差得更快**：$\theta=0.4$ 时离散相位 -176.2°、连续 -164.7°，多压 11.5°；到 $\theta=0.6222$ 多压 17.8°。在 $\omega_c=4.42$ 附近这笔账是 -12.5°，而连续裕度只有 11.9°，扣完剩 -0.6°——这就是前一段“边界附近几乎一样、判稳时并不够用”的算术来源。**其三，曲线在 $\theta=\pi$ 处收口于 $+0.0125$，不是原点**。连续域“$\omega\to\infty$ 落到原点”的直觉在这里失效：离散域没有无穷大频率，$z=-1$ 就是终点，而 $L(-1)$ 一般是一个小正实数。

39.5.3 采样带来的损失：与“半个周期延迟”几乎等价

第 38 章 §38.5 给过一组数：$T_s=0.1$ s、ZOH 离散后 $K_{\max}=4.1378$，边界根为 $0.81248\pm \mathrm{j}0.58298$，相角 0.6222 rad，对应物理频率 6.222 rad/s。这里必须先说清对象：**这个 4.1378 属于二阶对象 $10K/[s(s+2)]$**，而它的连续域增益裕度是无穷（§39.4.1）。换句话说，4.1378 本身就是“从无穷掉到有限”的巨大损失，只是这个有限值恰好与连续三阶的 4.40 相近（差 0.53 dB，边界频率差 1.6%）。**两个不同对象的边界撞在一起是巧合，不能拿来证明“采样损失小”。**

可比的账要拿同一个对象算。把带 50 ms 执行器滞后的三阶对象直接 ZOH 离散，数值二分得到：$T_s=0.01$ s 时 $K_{\max}=3.966$（-0.90 dB），0.02 s 时 3.614（-1.71 dB），0.05 s 时 2.864（-3.73 dB），0.1 s 时 2.144（-6.25 dB）。$T_s/2$ 分别对应 5、10、25、50 ms 的纯延迟；§39.9.1 实算 50 ms 延迟使 $K_{\max}$ 从 4.40 掉到 2.13（-6.3 dB），与 2.144 几乎重合；25 ms 落在 20 ms 与 50 ms 之间，也与 2.864 对得上。

所以结论要反过来写：**对同一对象，“ZOH 约等于 $T_s/2$ 的纯延迟”在估稳定边界时相当准，并不偏保守。**之前那个“只差 0.53 dB”的印象来自跨对象比较，不能作为设计依据。$T_s=0.1$ s 时真实的损失是 6.25 dB——足以把 $K=2.2$ 这个连续域还有 11.9° 裕度的工作点推过边界。

39.5.4 w 变换：把圆拉直

要在离散域沿用连续域的设计工具，用双线性变换

$$z=\frac{1+w}{1-w},\qquad w=\mathrm{j}\nu,\quad \nu=\tan\frac{\theta}{2} \tag{39-15}$$

把单位圆内部映到左半平面。频率不是线性对应的：物理频率 ω 对应“虚拟频率” $\nu=\tan(\omega T_s/2)$，高频被压缩。设计时若要求某个特征频率落在 ω_0，必须先把 $\nu_0=\tan(\omega_0 T_s/2)$ 算出来，再在 w 域按 ν_0 设计，这一步叫**频率预畸变**，漏掉它会让截止频率系统性偏低。

本例 $\theta=0.6222$ 时 $\nu=\tan(0.3111)=0.3215$；若直接拿 $\nu=0.6222$ 去查表，会高估近一倍。

这个偏差随 T_s 变化得很快，值得记住几个刻度。取设计频率 $\omega_0=4$ rad/s：$T_s=0.02$ s 时 $\omega_0 T_s/2=0.04$，$\nu=0.040021$，相对偏差 0.05%；$T_s=0.05$ s 时是 0.100335，偏差 0.34%；$T_s=0.1$ s 时是 0.202710，偏差 1.36%。$\omega_0=2$ rad/s 时同理，$T_s=0.1$ s 的偏差只有 0.34%——**畸变大小由 $\omega_0 T_s$ 决定，而不是由 ω_0 或 T_s 单独决定**。这条性质把 §39.5.5 的采样周期判据和本节连了起来：只要 $\omega_c T_s\le 0.2$，$\tan x$ 与 x 的差别就在 0.34% 以内，ν 与 ω 可以互相当作对方的刻度；$\omega_c T_s=0.4$ 时升到 1.4%；到 $\omega_c T_s=0.7$ 时超过 4%，预畸变就成了必做步骤，而不是可选的精细活。

做预畸变的顺序不能颠倒：先定连续域的指标（ω_c、φ_M），把每个关心的频率换算成 $\nu=\tan(\omega T_s/2)$，在 w 域按这些 ν 设计控制器，最后把结果代回 z 域**重新算一遍真实裕度**。最后这一步不能省，因为预畸变只保证“某一个频率点”精确对应，宽频带上其余频点仍有畸变，控制器的零点极点位置也会随之微移。实测中常见的现象是：w 域设计给出 45°，回到 z 域一算是 43.5°，差的那一点正是宽频畸变。

39.5.5 采样周期怎么定

两条可用的判据：其一，ω_c 处的采样相位滞后 $\omega_c T_s$ 不超过 5°–10°，对应 $T_s\le(0.087\text{–}0.175)/\omega_c$；其二，$K_{\max}$ 的损失不超过 2 dB。本例 $\omega_c=4.42$ rad/s，第一条给出 $T_s\le 0.020$–0.040 s；第二条按 §39.5.3 的实测数据插值（0.02 s 损失 1.71 dB、0.05 s 损失 3.73 dB），给出 $T_s\le 0.023$ s。**两条判据在 0.02 s 附近收敛**，取 $T_s=0.02$ s 是稳妥的；若沿用 0.1 s，$K_{\max}$ 已从 4.40 掉到 2.14，$K=2.2$ 的工作点直接失稳。

还有第三条判据，把保持器与计算延迟一起算进来。ZOH 的等效相位滞后约 $\omega_c T_s/2$，数字实现里“采样—计算—输出”又占掉约 $1.5T_s$（§39.10.6 会逐项拆开），合计 $2\omega_c T_s$。若要求这部分总滞后不超过 $10^\circ = 0.1745$ rad，则 $T_s \le 0.1745/(2\times 4.42) = 0.0197$ s。三个判据给出的数几乎重合，这不是巧合：它们量的是同一件事——**采样在穿越频率处吃掉了多少相位预算**，只是分别用“角度”“增益损失”“等效延迟”三种单位表达。

采样周期也不是越短越好。T_s 每减半，编码器量化误差经差分得到的转速噪声就放大一倍，微分项的增益也被迫跟着放大；同时中断频率翻倍，CPU 占用与电磁干扰都上升。工程上的做法是从上面三条判据算出一个上限，再把上限缩小 1.5–2 倍作为候选，然后在这个候选附近做一次实测扫频，确认 $K_{\max}$ 与相位裕度的损失都在预算内，就定下来——而不是一味往短里取。第 4 章 §4.6 的“采样周期选择”给的是同一套逻辑，本章只是把它换成了裕度的语言。

39.5.6 离散判据的三个易错点

离散判据的公式只有 $N = Z - P$ 一行，出错却比连续域多，原因是“约定”多了一层。三个最常踩的坑：

第一，把“圆内”与“圆外”、顺时针与逆时针混用。 约定一旦换了，公式要同步改写成 $N = P - Z$，符号反了结论就反。检验办法是拿一个已知答案的对象试：$T_s = 0.1$、$K = 4.1378$ 时二阶对象的闭环根恰在单位圆上，K 再大一点就出圆；实算 $K = 5$ 时 $|z|_{\max} = 1.071$，是一对共轭根同时出圆，所以 $Z = 2$ 而不是 1。算出一对根却报“一个不稳定根”，几乎一定是把实轴上的计数当成复根计数了。

第二，忘记 $z = 1$ 处的积分极点。 数字 PI 控制器只要带积分，$L(z)$ 在 $z = 1$ 就有极点，围线必须从圆外绕一个小弧，映射到 L 平面要补一段无穷大圆弧（一个积分环节补半圈）。漏补这一段，圈数少一整圈，本来稳定的系统会被判成不稳定。判断有没有漏：看 $L(z)$ 在 $z \to 1$ 时是否趋于无穷——是，就必须补。

第三，拿连续域的裕度代替离散域的裕度。 两者不是“差不多”，而是可能差到反号。$K = 2.2$、$T_s = 0.1$ 时，连续域在 $\omega_c = 4.42$ 处还有 11.9°，离散后同一物理频率处只剩 -0.6°，闭环根 $|z|_{\max} = 1.0022$ 已经出圆。更隐蔽的是工具函数的口径：`ct.margin` 对离散系统返回的 ω_c 是**双线性映射回连续域的等效频率**，不是物理频率，直接与 $\omega_{180} = 6.3246$ 比较会得出错误结论。要么按 §39.5.4 换算成 ν 再比，要么直接在 z 域数圈。

39.5.7 从连续判据到数字实现：五步复算

前几节把离散判据的每一块都讲了一遍，落到一次真实的复核，顺序是固定的五步。

第一步，定 T_s。 按 $\omega_c T_s \le 0.2$ rad 得 $T_s \le 0.045$ s；把 $1.5T_s$ 的计算延迟算进去，上限掉到 0.020 s（§39.5.5）。取 $T_s = 0.02$ s。

第二步，ZOH 离散，看闭环极点。 $K = 2.2$、$T_s = 0.02$ 时 $|z|_{\max} = 0.9930$，仍在单位圆内；同口径下离散裕度是 $G_M = 4.31$ dB、$\varphi_M = 9.32^\circ$，连续域是 6.02 dB 与 11.85°。**损失 1.7 dB 与 2.5°，与 §39.5.3 的 -1.71 dB 完全对上。**

第三步，二分 $K_{\max}$。 $T_s = 0.02$ 得 3.614，与连续域的 4.40 差 -1.71 dB。这一步与第二步互为验证：$3.614/2.2 = 1.643$，取对数正是 4.31 dB，两条独立路径给出同一个数。任何一条算错，这个等式立刻不成立。

第四步，w 变换复核。 $\omega = 4.42$、$T_s = 0.02$ 时 $\nu = \tan(0.0442) = 0.04423$，与线性值 0.0442 差 0.05%；若沿用 $T_s = 0.1$，则是 0.2027 对 0.2，差 1.36%。**$T_s = 0.02$ 这一档，预畸变可以不做；$T_s = 0.1$ 就必须做**——判据只有一条：$\omega_c T_s$ 有没有超过 0.2。

第五步，归档两套数。 连续域的 6.02 dB / 11.85° 与离散域的 4.31 dB / 9.32° 并排写，注明 T_s 与是否含计算延迟。只写一套，半年后没人知道这份报告是算在连续域还是数字域上。

还有一条容易忽略的：$|z|_{\max}$ **不能跨采样周期比较**。$T_s \to 0$ 时所有闭环极点都趋于 $z=1$，$|z|_{\max}$ 必然趋近 1；本例实测 $T_s=0.02$ 时是 0.9930，0.05 时反而是 0.9899——这不说明 0.05 更稳，而是说明两个采样周期下的极点已经不在同一个坐标尺度上。跨周期只能比裕度（dB 与度），不能比极点的模。

39.6 稳定性与性能

裕度不只是“离不稳定多远”，它还能换算成时域指标。换算关系有适用条件，用错会把结论夸大一倍。

39.6.1 相位裕度换算阻尼比

对典型二阶系统，φ_M 与 ζ 有精确关系

$$\varphi_M = \arctan\frac{2\zeta}{\sqrt{\sqrt{1+4\zeta^4}-2\zeta^2}} \tag{39-16}$$

这个式子不是凭空来的，两步就能推完。取标准二阶 $L=\omega_n^2/[s(s+2\zeta\omega_n)]$，令 $|L(\mathrm{j}\omega_c)|=1$，并记 $u=(\omega_c/\omega_n)^2$，得 $u^2+4\zeta^2u-1=0$，取正根

$$u=\sqrt{1+4\zeta^4}-2\zeta^2$$

于是 $\omega_c/(2\zeta\omega_n)=\sqrt{u}/(2\zeta)$，而 L 在 ω_c 处的相位是 $-90^\circ-\arctan[\sqrt{u}/(2\zeta)]$；相位裕度是这个角对 90° 的补角，即 $\arctan[2\zeta/\sqrt{u}]$，把 u 代回就是式 (39-16)。**整条推导只用了一次求根公式与一次余角关系**，没有任何近似——所以它是“精确关系”，后面那些近似式才是可选的。

工程上常用的近似是 $\zeta\approx\varphi_M/100$（$\varphi_M$ 以度计，适用 $\varphi_M<60^\circ$）。两式在本例上的差别很小：$\varphi_M=11.9^\circ$ 时近似给 $\zeta=0.119$；把实际 $\zeta=0.099$ 代入式 (39-16) 得 $\varphi_M=11.3^\circ$，与读图值 11.9° 只差 0.6°。差这一点，是因为本例是三阶，多出的执行器极点额外贡献了相位。

图 39-9 把式 (39-16) 与超调公式串起来画成一条曲线，横轴是相位裕度、纵轴是超调量。曲线在 45° 附近对应 $\zeta=0.42$、超调约 23%；到了 11.9° 这一端，超调已冲到 71%，而曲线的斜率也变得极陡——裕度再减几度，超调几乎不再变化，因为此时系统已经接近等幅振荡，超调的定义本身都开始失去意义。这张图说明为什么 45° 会被选作常用验收线：它落在曲线由陡转缓的拐点附近，再往上加裕度，超调的改善已经很有限。

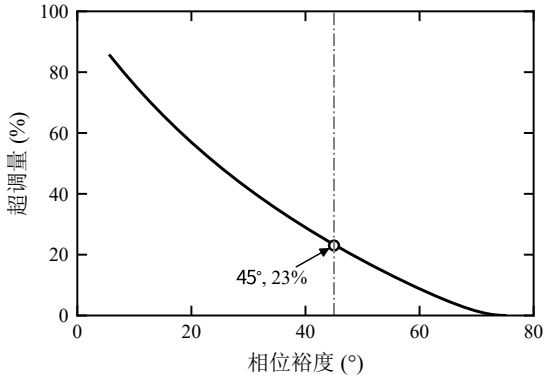

图 39-9　相位裕度与超调量的换算

把表 39-4 的两列拿来对拍，可以看清近似式到底能用在哪一段：$\zeta=0.316$ 时 $\varphi_M=34.9^\circ$（近似 0.349），$\zeta=0.447$ 时 47.4°（0.474），$\zeta=0.577$ 时 57.6°（0.576）——三段误差都在 3% 以内；到 $\zeta=0.707$ 时

$\varphi_M = 65.5^\circ$，近似给 0.655，误差升到 7%。所以“除以 100”在 60° 以下够用，超过 60° 会略微低估阻尼，用它反推超调则偏保守，工程上可以接受。

39.6.2 两个裕度必须一起看

用本例做一个反例。若只按“$G_M \ge 6$ dB”验收，会选到 $K = 2.2$：那里 $G_M = 6.02$ dB 刚好合格，可 φ_M 只有 11.9°，对应 $\zeta \approx 0.10$、超调 71%（第 38 章表 38-5）。设备一上电就是“能跑但一直在抖”。

反过来，$K = 0.3$ 这一档 $G_M = 14.7$（23.3 dB）、$\varphi_M = 54.1^\circ$，两个指标都宽裕，超调 13.8%——这才是第 38 章 §38.3.6 把工作点定在 $K/K_{\max} = 6.8\%$ 的原因。

只用一个裕度做验收，会选出错误的工作点：增益裕度管的是“增益还能加多少”，相位裕度管的是“延迟还能加多少”，而现场两者同时存在。规范的做法是把两条都写进验收条件，例如 $G_M \ge 6$ dB 且 $\varphi_M \ge 45^\circ$；本例要同时满足，K 必须降到 0.44 以下（$\varphi_M = 45^\circ$ 对应 $K \approx 0.44$，此时 $G_M = 9.9$），比单看增益裕度严了近五倍。

39.6.3 裕度与 σ 的关系

第 38 章用 σ 位移算“极点离虚轴多远”，本章用裕度算“曲线离 -1 多远”。两者不是同一件事：σ 是绝对的衰减速率，裕度是相对的稳定储备。一个 σ 很小但裕度很大的系统（例如极点 -0.01 与 -100 各一个）并不矛盾——慢模态决定 σ，而裕度由高频段决定。

把三档工作点的闭环极点摆出来，这个区别就具体了。$K = 0.3$ 时极点是 -20.16 与 $-0.918 \pm \mathrm{j}1.460$，$\sigma = 0.918$；$K = 1$ 时是 -20.53 与 $-0.737 \pm \mathrm{j}3.033$，$\sigma = 0.737$；$K = 2.2$ 时是 -21.09 与 $-0.454 \pm \mathrm{j}4.545$，$\sigma = 0.454$。增益从 0.3 抬到 2.2（7.3 倍），$\sigma$ 只降到一半，可 φ_M 从 54.1° 掉到 11.9°——**裕度掉得更狠**。原因是 σ 只看实部，而裕度看的是“主导极点对的阻尼角加高频段的相位”，后者对增益更敏感。

用 $4/\sigma$ 粗估调节时间，三档分别得 4.36、5.43、8.82 s，实测是 3.40、5.36、8.45 s。中间两档几乎重合，低增益那档实测比估计短 22%。这个偏差不是算错了：$4/\sigma$ 给的是“包络衰减到 2%”的上界，而实际响应进入并留在 $\pm 2\%$ 带内的时刻可以更早，尤其当第三个极点远离主导对、把响应“推”得更快时。**包络公式只能当上界用**，反过来说，用它做保守设计是安全的。

工程上因此要两个数都报：σ（或 t_s）说明“多久能停”，裕度说明“还能承受多少变化”。本章 §39.10 会把两者放进同一张验收表。

39.6.4 从裕度反推超调：一条能用的估算链

验收表上常遇到这样的问题：现场只测到了 Bode 图，没有做阶跃试验，能不能估计超调？能，但要清楚这条链子每一环的误差往哪边偏。

链条只有三步：先由式 (39-16) 或近似式把 φ_M 换成 ζ，再由二阶超调公式

$$M_p = \exp\!\left(-\frac{\pi\zeta}{\sqrt{1-\zeta^2}}\right) \times 100\% \tag{39-16a}$$

算出超调。把表 39-2 的三档代进去：

- $K = 0.3$：$\varphi_M = 54.1^\circ \Rightarrow \zeta \approx 0.541 \Rightarrow M_p = 13.3\%$，实测 13.82%，差 0.5 个百分点；
- $K = 1$：$27.0^\circ \Rightarrow 0.270 \Rightarrow 41.4\%$，实测 46.05%，差 4.6 个百分点；
- $K = 2.2$：$11.9^\circ \Rightarrow 0.119 \Rightarrow 68.6\%$，实测 71.38%，差 2.8 个百分点。

三档都是**低估**，也就是偏乐观。这个偏差可以拆成两笔账，两笔都有数可查。

第一笔是 ζ 被高估。从闭环极点算真实阻尼比只需一步：$\zeta = -\mathrm{Re}\,\lambda / |\lambda|$。以 $K = 2.2$ 为例，主导对是 $-0.454 \pm \mathrm{j}4.545$，模长 $|\lambda| = \sqrt{0.454^2 + 4.545^2} = 4.568$，于是 $\zeta = 0.454/4.568 = 0.0993$；$K = 1$ 与 $K = 0.3$ 同样算得 0.236 与 0.532。而“$\varphi_M/100$”给出的是 0.541、0.270、0.119，分别高估 1.7%、14%、20%。阻尼比越被高估，超调就越被低估。

第二笔是式 (39-16a) 自身的残余误差。它是纯二阶的结论，而本章对象的闭环有三个极点，即使喂进精确的 ζ，公式仍给出 13.88%、46.61%、73.08%，实测是 13.82%、46.05%、71.38%，反过来**高估** 0.06、0.56、1.70 个百分点。第二笔的方向与第一笔相反，它把估计值往上抬，正好抵消掉第一笔的一部分，所以总误差是两笔相减而不是相加。

把两笔合成一个算式就更清楚了。$M_p(\zeta)$ 对 ζ 的局部斜率在三个工作点分别是 -71.8、-159.6、-233.0（每单位 ζ），乘上各自的 ζ 偏差 0.0088、0.0339、0.0197，得 0.6、5.2、4.5 个百分点；再扣掉残余误差 0.06、0.56、1.70，正好落回 0.5、4.6、2.8。**这条链的误差不是“越靠近临界越糟”，而是两笔账相抵的结果**：$K = 2.2$ 时 ζ 被高估得最多、斜率也最陡，但残余误差同时变大，最终只多出 2.8 个百分点。

实用结论有两条。第一，**用这条链做验收要留余量**：若要求超调不超过 10%，就按 $\varphi_M \geq 60^\circ$ 提要求（$\zeta \approx 0.6$，$M_p \approx 9.5\%$），不要卡着 55° 的线。第二，**能从极点算就别用近似式**：闭环极点一旦有了，$\zeta = -\mathrm{Re}/|\lambda|$ 是精确的，代入式 (39-16a) 只需一步，省掉的正是这条链上最大的那一环误差。反推只适合“手上只有频响”的场合，一旦有条件做阶跃试验，就该用实测值替换估算值，并把两者的差记进归档行——差多少，下次同类对象就有了先验。

39.7 参数意义与作用

频率判据里每个参数只影响曲线的某一段，这一点比 Routh 表直观得多：时间常数挪动转折频率，增益整体上下平移，延迟只压相位。把三种作用分开看，就知道该动哪个旋钮。

39.7.1 增益：整条幅频平移

K 只让幅频曲线上下平移 $20\lg K$，相位一点不动。后果是：ω_{180} 不变，G_M 精确按 $1/K$ 变化（式 39-11），而 ω_c 右移、φ_M 下降。这正是表 39-2 的成因，也解释了一个常见误解——“调增益只影响稳定余量、不影响相位”，后半句对，前半句不对：它**通过移动 ω_c 间接触发了相位变化**。

把这句话量化，就是灵敏度。对本章对象，K 每翻一倍，φ_M 在 $K = 0.3$ 处掉 15.9°，在 $K = 2.2$ 处掉 12.4°；而 G_M 无论在哪一档都恰好掉 6.02 dB。后一个数不是巧合：$G_M(\mathrm{dB}) = 20\lg K_{\max} - 20\lg K$，对 $\ln K$ 求导得 $-20/\ln 10 = -8.686$ dB，与对象是什么无关。**增益裕度在分贝坐标下对增益是严格的线性函数，相位裕度不是**——这是 Bode 图上两条曲线斜率不同的直接后果。

φ_M 的灵敏度会随工作点上移而略减，因为穿越点挪到了相位曲线较平缓的一段：$K = 0.3$ 时 $\omega_c = 1.26$ rad/s，正处在两个转折频率之间，相位斜率最陡；$K = 2.2$ 时 $\omega_c = 4.42$，已越过 $1/\tau_a = 20$ 的一半，斜率反而缓下来。两种效应（ω_c 变大、局部斜率变小）部分抵消，净结果是每单位 $\ln K$ 的相位代价从 22.9° 降到 17.9°。

这两个数在变更评审里很有用。现场把增益电位器拧大 20%，实跑结果是：$K = 0.3$ 的工作点 ω_c 从 1.265 升到 1.453（$+14.8\%$），φ_M 从 54.06° 掉到 49.86°（-4.21°），G_M 从 23.33 dB 掉到 21.74 dB（-1.58 dB）；$K = 2.2$ 的工作点 ω_c 从 4.424 升到 4.871（$+10.1\%$），φ_M 从 11.85° 掉到 8.63°（-3.22°），G_M 同样掉 1.58 dB。1.58 dB 这个数与工作点无关，因为 $20\lg 1.2 = 1.58$，它只反映“增益乘了几倍”；变化的是相

位那一笔，从 -4.21° 缩到 -3.22°，正是上一段说的斜率变缓。若原本只剩 50°，这一拧就掉到 45.7°，逼近验收线了。**增益是现场最容易被随手改动的参数，也是最容易被低估的参数**——它不动相位曲线，却通过移动穿越点改写了整份裕度报告。

39.7.2 执行器时间常数：最敏感的一个

对 $L=10K/[s(s+2)(\tau_a s+1)]$，相位穿越条件 $\arctan(\omega/2)+\arctan(\tau_a\omega)=90^\circ$ 可解出

$$\omega_{180}=\sqrt{\frac{2}{\tau_a}},\qquad K_{\max}=\frac{\omega_{180}\sqrt{\omega_{180}^2+4}\sqrt{1+\tau_a^2\omega_{180}^2}}{10} \tag{39-17}$$

代入不同 τ_a 得表 39-3。τ_a 从 0.05 s 减到 0.02 s，$K_{\max}$ 从 4.40 升到 10.4（两倍多）；从 0.05 s 增到 0.10 s，只剩 2.40。**τ_a 是最该盯住的参数**：它由阀、变频器、电机电气时间常数决定，往往在选型时就定了，后期很难改。

表 39-3 执行器时间常数对临界增益的影响（K 前系数取 10）

τ_a (s)	ω_{180} (rad/s)	$K_{\max}$
0.02	10.00	10.40
0.03	8.16	7.07
0.05	6.32	4.40
0.08	5.00	2.90
0.10	4.47	2.40

表 39-3 里最值得注意的不是 $K_{\max}$ 那一列，而是 ω_c 几乎不动：τ_a 从 0.02 s 增到 0.10 s（五倍），ω_c 只从 2.860 降到 2.799，降幅 2%；$K_{\max}$ 却从 10.4 掉到 2.40，相当于 12.7 dB。原因在频段分工：$1/\tau_a$ 落在 10–50 rad/s，远离 $\omega_c\approx 2.85$，所以幅频在穿越点几乎没变；但它把相位穿越点从 10.0 rad/s 一路拉到 4.47 rad/s，正好扫过 ω_c 上方那一段，于是 G_M 塌得比 φ_M 快得多（φ_M 只从 31.7° 掉到 19.9°）。

弹性系数约等于 -1：τ_a 增 10%（0.050→0.055），$K_{\max}$ 从 4.40 降到 4.04，正好 -8.3%；减 10%（0.045）则升到 4.84。在这个对象上，$K_{\max}\propto 1/\tau_a$ 是个够用的口算规则，不必每次重解相位方程。

工程含义有两层。其一，τ_a 由阀、变频器、电机电气时间常数共同决定，选型时若只按额定工况给一个数，热态、低压、重载下很容易偏大 30%，对应 $K_{\max}$ 也差 30%——**必须按最坏工况留余量**。其二，τ_a 一旦定了，后期几乎改不动；相比之下增益随时可调、零点可以加，所以在方案阶段就把 τ_a 当成硬约束，比在调试阶段反复降增益划算得多。

39.7.3 增加一个极点与增加一个零点

每加一个一阶极点，相位在高频多付 90°，ω_{180} 左移、$K_{\max}$ 下降。第 38 章 §38.4.3 的 20 ms 传感器滤波就是这一类：$K_{\max}$ 从 4.40 掉到 3.09（-3.1 dB）。

把 20 ms 滤波极点加进去实跑，得到 $K_{\max}=3.09$（9.80 dB，比原来的 12.87 dB 少 3.07 dB），ω_c 仍是 2.843，φ_M 从 27.0° 掉到 23.8°。这又是一个“带宽不动、裕度下滑”的例子：高频极点几乎不改变穿越点，却直接决定相位穿越落在哪里。分辨这两件事的办法很简单——**看 ω_c 变没变**：ω_c 不动而裕度掉，说明新增环节在 ω_c 之上；两者一起动，说明新增环节压到了穿越点附近。

零点的作用相反：它提供超前相位，把 ω_{180} 往右推。设串联 $(1+T_z s)$，若 T_z 选在 ω_c 附近，相位最多可补 50°–60°。但零点同时抬高高频幅值，若在 ω_{180} 附近增益已经很高，补相位的同时也在吃掉增益裕度——所以零

点要放在 ω_c 附近、不能放到 ω_{180} 之后，否则得不偿失。

这笔“补相位的同时吃裕度”的账可以算到个位。取 $T_z = 1/\omega_c = 0.226$ s，对应 $\omega_c = 4.42$ 处补 $\arctan 1 = 45.0^\circ$、幅值抬 $\sqrt{2}$ 倍（3.01 dB）；到了 $\omega_{180} = 6.32$ 处，补的相位变成 $\arctan(6.32/4.42) = 55.0^\circ$，幅值抬 1.745 倍（4.84 dB）。**相位补得越多的地方，幅值也抬得越多**，这是 $(1 + T_z s)$ 的固有性质，不是选点不当。于是原本 6 dB 的增益裕度，在原 ω_{180} 处先被吃掉 4.84 dB，只剩 1.2 dB；零点把相位穿越点右移还会再找补一点，但那部分要靠重算，不能用这句口算代替。设计时必须把这 4.84 dB 预先扣掉，否则“补了相位、反而更容易振”。

零点的作用还可以在根轨迹上直接看到。本章对象的分离点由 $\mathrm{d}K/\mathrm{d}s = 0$ 给出，即 $0.15s^2 + 2.2s + 2 = 0$，解出 $s = -0.974$ 与 $s = -13.69$；前者对应 $K = 0.0951$，是真实分离点，后者对应负增益，不在根轨迹上。$K = 0.0951$ 时两个实极点重合在 -0.974，第三个极点在 -20.05（三个极点之和恒为 -22），闭环处于临界阻尼。**这解释了为什么小增益段几乎没有振荡**：$K < 0.095$ 时主导极点是一对实数，K 越过分离点才出现共轭对、才开始有超调。

39.7.4 纯延迟：只动相位

延迟 $e^{-T_d s}$ 的幅值为 1、相位为 $-T_d\omega$，在 Bode 图上是“幅频不动、相频线性下垂”。它不改变 ω_c 处的幅值，只让 φ_M 减少 $T_d\omega_c$。本例 $\omega_c = 4.42$ rad/s，$T_d = 20$ ms 就吃掉 5.1°，$T_d = 50$ ms 吃掉 12.7°。

这条性质带来一个重要的工程结论：**延迟对相位裕度的破坏与频率成正比，因此提高带宽（ω_c 上移）会让同一个延迟变得致命**。追求快速响应时，“能不能提带宽”的真正限制常常不是机械，而是那几十毫秒的通信与执行延迟。

图 39-10 把这条结论量化：纵轴是可容忍延迟 $T_{d,\max} = \varphi_M/\omega_c$，横轴是增益。$K = 0.3$ 时容忍 0.75 s，$K = 2.2$ 时只剩 47 ms（0.207 rad 除以 4.42），而 K 接近 4.40 时曲线垂直下落趋零。曲线的形状由两部分拼成：φ_M 随 K 单调减、ω_c 随 K 单调增，分子分母同向变化，于是容忍度以比线性更快的速度坍塌。

沿曲线读五个点，这个“比线性更快”就有了具体倍数：$K = 0.3$ 给 746 ms，$K = 0.6$ 给 321 ms，$K = 1.2$ 给 128 ms，$K = 2.2$ 给 46.8 ms，$K = 3.0$ 给 21.5 ms。从 $K = 0.3$ 到 $K = 2.2$，增益涨 7.33 倍，容忍延迟掉 15.9 倍；按幂律拟合，指数是 $\ln 15.9 / \ln 7.33 = 1.39$，即 $T_{d,\max} \propto K^{-1.39}$。

指数大于 1，源于分子分母同时在动。工程上把它读成一句口算规则：**增益每翻一倍，可容忍延迟掉到约 38%**（$2^{-1.39} = 0.38$）。这个规则比“延迟破坏相位裕度”那句定性话好用得多——它直接告诉你，为了多要一倍的响应速度，要拿掉六成的延迟预算。

图中 50 ms 的验收线在 $K \approx 2.1$ 处与曲线相交，意味着这台设备若带 50 ms 通信延迟，增益最多只能开到 2.1——比只看 6 dB 增益裕度得到的 2.2 还要低一点。

这条曲线还给出了带宽决策的正确顺序：**先量延迟，再定 ω_c，最后才挑 K**。反过来的做法（先按响应速度定 K，再回头发现延迟超标）在现场很常见，代价是把已经调好的参数全部推翻。若目标是 $K = 3.0$（$\omega_c = 5.21$），延迟预算只剩 21.5 ms，这个数必须写进采购规格，而不是等调试时才发现通信周期是 50 ms。

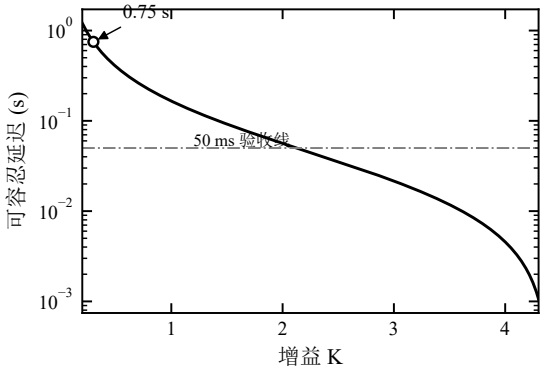

图 39-10　延迟容忍随增益的变化

39.7.5 二阶对象的三个参数：增益买不到速度

把执行器极点拿掉，对象退化为 $L = 10K/[s(s+2)]$，闭环特征多项式为 $s^2 + 2s + 10K$。对照标准二阶式 $s^2 + 2\zeta\omega_n s + \omega_n^2$，立刻得到 $\omega_n = \sqrt{10K}$、$\zeta = 1/\sqrt{10K}$，而且

$$\zeta\omega_n = 1 \tag{39-17a}$$

与 K 无关。这一条约束把整张表锁死了：自然频率按 $\sqrt{K}$ 上升，阻尼比按 $1/\sqrt{K}$ 下降，两者乘积恒为 1。表 39-4 是它的数值展开，指标由 §39.12 的同一套阶跃口径算出。

表 **39-4** 二阶对象 $10K/[s(s+2)]$ 的参数与指标

K	ω_n (rad/s)	ζ	φ_M	M_p	t_s (2%)
0.10	1.000	1.000	76.4°	0.0%	5.84 s
0.20	1.414	0.707	65.5°	4.3%	4.22 s
0.30	1.732	0.577	57.6°	10.9%	3.41 s
0.50	2.236	0.447	47.4°	20.8%	3.74 s
1.00	3.162	0.316	34.9°	35.1%	3.54 s
2.20	4.690	0.213	24.1°	50.4%	3.64 s
4.40	6.633	0.151	17.1°	61.9%	3.89 s
10.00	10.000	0.100	11.4°	72.9%	3.84 s

三件事值得注意。

第一，t_s 基本不变（除 $K = 0.1$ 的过阻尼点 5.84 s，其余都在 3.4–3.9 s），因为调节时间由 $\sigma = \zeta\omega_n = 1$ 决定（第 38 章 §38.6.3），而 σ 恒定。**在这个对象上提高增益买不到速度，只买到超调**：K 从 0.1 增到 10（100 倍），M_p 从 0 涨到 72.9%，t_s 几乎原地不动。很多“加大增益响应就快”的直觉来自带零点的对象或带积分的回路，在这里并不成立。

把八档连起来看，t_s 是一条浅碗而不是单调下降：$K = 0.1$ 时 5.84 s（过阻尼，慢在爬升），$K = 0.3$ 时 3.41 s 触底，之后回升到 3.6–3.9 s，$K = 10$ 时仍有 3.84 s。碗底对应两种代价的平衡——阻尼太大响应爬得慢，阻尼太小振荡次数多、包络要多衰减几拍才落进 2% 带。**碗很浅（全区间只差 0.5 s），所以 t_s 不适合当调参主指标**：在 0.3 到 10 之间怎么选，t_s 都给不出区别，超调和裕度才会给。

第二，$\zeta \approx \varphi_M/100$ 这个近似在 $20°$–$60°$ 区间够用：$\varphi_M = 57.6°$ 除 100 得 0.576，真值 0.577；$34.9°$ 得 0.349，真值 0.316（高估 10.4%）；$24.1°$ 得 0.241，真值 0.213（高估 13.1%）。偏差始终朝一个方向——高估 ζ，也就是低估超调，与 §39.6.4 在三阶对象上见到的偏乐观同源。它之所以能当口诀用，是因为两个量的变化区间恰好同步。

第三，φ_M 的下限与超调的上限一一对应：要 $M_p \le 20\%$，需 $\zeta \ge 0.456$，查表插值得 $\varphi_M \ge 47°$。这正是 §39.8.1 把 $45°$ 当作通用门槛的依据——它对应的超调约 23%，是多数工业过程能接受的上限。

需要提醒的是，表 39-4 的“速度不变”是三阶对象没有的性质。加上 0.05 s 执行器极点后，$K = 0.3$ 的调节时间是 3.40 s，$K = 2.2$ 变成 8.45 s——第三个极点把 σ 压小了，增益越大压得越狠。所以这张表只能用来校准直觉，不能直接套到三阶对象上；真要用，先看 σ 是不是还由同一对极点决定。换言之，**“加大增益能变快”在三阶对象上成立，但买到的那点速度是拿超调和调节时间一起换来的。**

39.7.6 把灵敏度整理成容差分配表

把 §39.7.1 与 §39.7.2 的数并排看，就得到一张“参数变动 1%，裕度变多少”的对照：G_M 对 $\ln K$ 的斜率恒为 -8.686 dB；φ_M 对 $\ln K$ 的斜率在 $K = 0.3$ 处 $-22.9°$、在 $K = 2.2$ 处 $-17.9°$；$K_{\max}$ 对 τ_a 的弹性约 -1，即 τ_a 变 10%、$K_{\max}$ 反向变 8%–10%。三类参数的“汇率”不同，配容差时不能平均分配。

用它反算剩余余量最直接。$K = 0.3$ 时 $\varphi_M = 54.1°$，若验收线是 $45°$，允许的增益增量是 $\exp(9.1/22.9) = 1.49$ 倍，即 K 最多到 0.446——与 §39.8.1 按目标值反解出的 0.44 一致，两条路径互相印证。同样条件下 G_M 还剩 13.3 dB，按 10 dB 的验收线可放大 4.6 倍，即 $K \le 1.38$。**两个约束相差三倍，说明这个工作点是相位裕度在把关**：调参时应先去补相位，而不是继续降增益。

换到 $K = 2.2$：$\varphi_M = 11.9°$，离 $45°$ 差 $33.1°$，按 $-17.9°$ 的斜率要降 $e^{1.85} = 6.4$ 倍增益，即 $K \le 0.34$；而 $G_M = 6.02$ dB 已经贴着 6 dB 的线，几乎没有余量。两个约束这时几乎同时报警，说明工作点已经顶到边界，任何一侧的参数漂移都会越线。

39.7.7 五个参数排个序：谁最该被盯住

把前面各节的灵敏度折算到同一个单位——“$K_{\max}$ 损失多少 dB”——就能排出一张优先级表。这张表的价值在于：现场出问题时，人总是先怀疑最容易改的那个参数（增益），而真正吃掉余量的往往是改不动的那个。

- **增益偏大 10%**：-0.83 dB（由 $-8.686 \times \ln 1.1$ 得出），同时 φ_M 掉 $1.8°$–$2.3°$。
- **执行器时间常数偏大 10%**（$0.05 \to 0.055$ s）：-0.75 dB，ω_c 只降 2%。两项都与增益同量级，但它的危害是隐蔽的——带宽几乎没变，看幅频看不出来。
- **多一个 20 ms 的滤波极点**：$K_{\max}$ 从 4.40 掉到 3.09，即 -3.07 dB，φ_M 从 $27.0°$ 降到 $23.8°$。一个看似“只是滤个噪声”的小环节，代价是半个增益裕度。
- **50 ms 纯延迟**：$K_{\max}$ 从 4.40 掉到 2.13，-6.3 dB。
- **采样周期 0.1 s**：-6.25 dB（§39.5.3 的三阶离散实算）。

后两项的代价是前两项的八倍左右，这就是为什么 §39.10 反复强调“先量延迟、先查采样”。更值得注意的是它们与增益的可比性：**把延迟从 50 ms 压到 25 ms，$K_{\max}$ 从 2.13 回到约 2.86（$+2.6$ dB），相当于把增益降了四成**，而响应速度一点没损失。调参时若只会在增益上拧，等于放弃了这条更便宜的路径。

排序还有一层含义：前三项都是“乘性”的，可以近似按 dB 相加；而延迟与采样是“相位性”的，它们吃掉的是固定的角度预算，与增益无关。**乘性误差与相位误差不能互相抵消**，只能各自留余量。这就是为什么现场把增益调小之后，延迟造成的振荡频率不会跟着变——振荡频率由相位穿越点决定，与增益几乎无关。

39.8 调参方法与经验

频率域的调参有明确的顺序：先用增益把带宽放到合适位置，再用零点补相位，最后复核两个裕度。顺序颠倒会白做——先补相位再提增益，补进去的相位会被增益吃掉。

39.8.1 两个裕度的目标值

工程惯例是 $G_M \geq 6$ dB、$\varphi_M \geq 45^\circ$，高可靠性场合取 $G_M \geq 10$ dB、$\varphi_M \geq 60^\circ$。这两个数不是拍脑袋：6 dB 对应“增益可翻倍”；把 $\varphi_M = 45^\circ$ 代入式 (39-16) 反解得 $\zeta = 0.42$，对应超调约 23%。

把目标换算成本例的 K：$G_M \geq 6$ dB 允许 $K \leq 2.2$；$\varphi_M \geq 45^\circ$ 只允许 $K \leq 0.44$。**两个条件的交集由相位裕度决定**，这是欠阻尼对象的普遍规律——增益裕度宽松，相位裕度紧张。

两个门槛的量纲不同，换算方式也不同。6 dB 是纯幅值比，$10^{6/20} = 2.0$；45° 要靠式 (39-16) 才能落到时域，反解 $\zeta = 0.42$、超调 23%。所以“6 dB 与 45°”并不是一对平行的指标，而是“增益允许翻倍”与“超调允许两成”的两种说法。换成 10 dB 与 60°，前者是 3.16 倍增益，后者是 $\zeta = 0.61$、超调约 9%，对应“几乎看不到超调”的伺服指标。

在本例上，两个门槛换算出的 K 相差五倍。这个差距说明**增益裕度对欠阻尼对象几乎不设防**：即使开到 $K = 2.2$，G_M 仍有 6.02 dB，可 φ_M 已掉到 11.9°，阶跃超调 71.4%。若验收条款只写“$G_M \geq 6$ dB”，这个工作点会被判为合格——这正是 §39.6.2 强调两个裕度必须一起看的现实理由。

39.8.2 调参三步

1. **定增益**：按 ω_c 的目标值（通常取期望闭环带宽的 0.5–1 倍）解 $|L(\mathrm{j}\omega_c)| = 1$，得到 K。
2. **补相位**：若 φ_M 不足，串入超前环节 $(1 + s/z)/(1 + s/p)$，零点放在 ω_c 稍下方，极点放在零点之上 5–10 倍处（即 $\alpha = p/z$ 取 5–10），可补 30°–50°。代价是高频增益抬升 α 倍，需要复核 G_M。
3. **复核**：重画 Bode，确认两个裕度都达标，再用 §39.3.5 的方法与代数判据对拍。

三步的顺序不能换。增益决定 ω_c，而 ω_c 决定超前环节该放在哪里；先放零点再提增益，零点就落在旧穿越点上，新穿越点移走后补偿量只剩一半。工程上把这条规律叫作“先定带宽、再补相位”。

还有一个隐含前提：**对象在 ω_c 附近的相位必须随频率单调下降**。若存在谐振峰或延迟造成的多次穿越，“补相位”可能把穿越点推进另一个更靠右的 -180° 区间，越补越糟。含延迟、含柔性环节的对象，要先按 §39.3 走一遍 Nyquist，确认整条曲线只穿一次负实轴，再谈补偿。

39.8.3 本例的整定结果

取 $K = 0.3$：$G_M = 23.3$ dB、$\varphi_M = 54.1^\circ$，超调 13.8%。这个组合留出的余量可以用延迟来检验：串入 20 ms 延迟后 φ_M 降到 49.0°、G_M 降到 20.2 dB（$K_{\max}$ 由 4.40 变 3.07）；串入 50 ms 后 $\varphi_M = 41.4^\circ$、$G_M = 17.0$ dB（$K_{\max}$ 变 2.13）。三种情形都保持在 41° 以上，说明这个工作点对通信延迟不敏感。

对照 $K = 2.2$：无延迟时 $\varphi_M = 11.9^\circ$，加 20 ms 延迟就变成 6.7°，加 50 ms 直接为负。**同一个延迟，对两个工作点的影响相差一个数量级**——因为 φ_M 的损失量 $T_d\omega_c$ 与 ω_c 成正比，而高增益把 ω_c 推得更远。

39.8.4 三条经验

其一，**不要用单一裕度验收**（§39.6.2 已给反例）。其二，**提带宽之前先量延迟**：延迟是唯一“看不出、但一定存在”的环节，它的破坏随带宽线性增长。其三，**给未建模动态留 10°**：实测相位总比模型更负，若把 φ_M 卡在 45°

整，现场往往只剩 35°。

39.8.5 把 $K=1$ 救回来：超前校正的四个设计点

§39.8.3 的 $K=0.3$ 虽然稳，但 ω_c 只有 1.27 rad/s、$t_s=3.41$ s，对位置环偏慢。若想保住 $K=1$ 的带宽（$\omega_c=2.85$）又把 φ_M 从 27° 拉到 45° 以上，只能补相位。取

$$C(s)=\frac{1+s/\omega_z}{1+s/(\alpha\omega_z)},\qquad \alpha>1 \tag{39-17b}$$

它的直流增益为 1，不改变低频增益；零点在 ω_z、极点在 $\alpha\omega_z$，最大相位超前出现在几何中点 $\omega_z\sqrt{\alpha}$ 附近，峰值约 $\arcsin\frac{\alpha-1}{\alpha+1}$。$\alpha=10$ 时峰值 54.9°——这解释了为什么单级超前很少能补到 60° 以上。这里的 α 是**超前比**，按第 43 章 §43.2 的口径定义为极点比零点（$\alpha=p/z>1$），后文一律沿用这个方向；若照某些教材写成 $\alpha=z/p<1$，公式里的加减号要跟着翻过来。

固定对象 $K=1$，扫四组 (ω_z,α)，结果列于表 39-5。裕度由 §39.12 的 `bode_margins` 实算，M_p 与 t_s 由同一套闭环阶跃口径给出。

表 39-5 超前校正的四组设计点（对象 $10/[s(s+2)(0.05s+1)]$，$K=1$）

ω_z	极点 $\alpha\omega_z$	α	ω_c	φ_M	G_M	M_p	t_s
1.5	12.0	8	5.659	53.6°	14.2 dB	12.8%	1.15 s
1.8	18.0	10	5.112	61.8°	16.9 dB	5.6%	0.67 s
2.0	20.0	10	4.735	63.4°	18.1 dB	4.7%	0.75 s
2.2	26.4	12	4.452	65.8°	20.0 dB	3.5%	0.88 s

四组都把相位裕度拉到 53° 以上，代价写在同一张表里：ω_c 从无补偿的 2.85 推到 4.45–5.66，高频增益抬高 8–12 倍（18–22 dB）。**补相位从来不是免费的，它用高频增益换低频相位**；传感器噪声、PWM 开关纹波、编码器量化噪声都会被同比例放大。

表里还有一个不显眼的最优点：t_s 在 $\omega_z=1.8$ 处最小（0.67 s），往右反而回升到 0.88 s。原因是两个方向相反的作用——零点右移，ω_c 下降使响应变慢，但阻尼上升使振荡减少；在 1.8 附近两者恰好平衡。**工程上的“最优”几乎总是某个中间点，而不是参数的端点**，这也是调参不能只朝一个方向拧的原因。

选型时取 $\omega_z=1.8$、极点 18 那一组：$\varphi_M=61.8^\circ$、$G_M=16.9$ dB、超调 5.6%、$t_s=0.67$ s，代价是 20 dB 的高频增益。与 $K=0.3$ 相比，调节时间从 3.41 s 降到 0.67 s，快了五倍，裕度还更大。

39.8.6 一次完整的整定记录

把上面的片段串起来，就是一次真实的整定过程。初始诉求是“位置环要快”，先取 $K=2.2$：$\omega_c=4.42$、$t_s=8.45$ s——带宽不低，但 φ_M 只有 11.9°、超调 71.4%，实测还会因为未建模延迟而持续振荡。

第一步降增益到 1.0：$\varphi_M=27.0^\circ$、超调 46.1%、$t_s=5.36$ s，仍不达标。第二步继续降到 0.3：$\varphi_M=54.1^\circ$、超调 13.8%、$t_s=3.41$ s，稳了，但速度回不去。第三步回到 $K=1$ 并加 $\omega_z=1.8$ 的超前环节：$\varphi_M=61.8^\circ$、超调 5.6%、$t_s=0.67$ s——比 $K=0.3$ 快五倍，裕度还更大。

这张记录说明一件事：**降增益与补相位不是二选一，而是要先判断瓶颈在幅值还是在相位**。本例的瓶颈始终是相位，降增益只是把穿越点拉回相位平坦区，代价是带宽；补相位则直接在穿越点附近加相位，带宽不降反

升。判断方法就是看表 39-2：增益翻倍时 φ_M 掉十几度、G_M 掉 6 dB，两者同步恶化，说明缺的是相位而不是幅值。

39.8.7 多回路系统的裕度分配

串级、前馈、多回路系统里，裕度要分层分配，不能所有回路都按同一套指标验收。惯例是内环（电流、速度）先整定到 $\varphi_M \geq 60^\circ$，外环（位置、张力）再整定到 $\geq 45^\circ$；内环带宽取外环的 3–5 倍，否则外环设计时不得不把内环的相位滞后当成对象的一部分。

这个“当成对象的一部分”可以直接量化。把内环近似成一阶滞后 $\tau_i \approx 1/\omega_{c,i}$，并入 §39.7.2 的 τ_a。按那里的弹性，内环带宽只有外环 3 倍时，这个额外时间常数会让外环 $K_{\max}$ 掉 10%–20%；到 5 倍以上才可以忽略。**内环带宽不是越高越好**——它受采样频率与噪声限制，取到外环的 5 倍通常就是性价比的拐点。

分配时还要留一笔总账：内环 10°、外环 10°、未建模动态 10°，三个 10° 加起来就是 30°。所以外环的计算值要按 75° 设计，才能在现场保住 45°。这笔账不写下来，调试时就会反复出现“仿真 50°、现场 35°”的落差。

39.8.8 四种补偿器怎么选

补偿器的选择不该从“我会用哪个”出发，而该从“缺的是什么”出发。按症状对号入座，只有四类：

只缺带宽、相位有余——用纯增益。判据是 φ_M 在 60° 以上且 G_M 富余，此时提增益只让 ω_c 右移，相位曲线还有空间。本章对象属于“空间很小”的一类：K 从 0.3 提到 0.5，φ_M 就从 54.1° 掉到 42.3°，已经贴着 45° 的线。**纯增益能解决的问题，前提是相位曲线在穿越点附近足够平坦**；本例的曲线在那里正陡，所以一提就掉。

缺相位、噪声可接受——用超前，即式 (39-17b)。它的作用是把相位在 ω_z 到 $\alpha\omega_z$ 之间“抬起来”，峰值 $\arcsin[(\alpha-1)/(\alpha+1)]$。代价写在幅频上：高频增益抬高 α 倍，$\alpha = 10$ 就是 20 dB。选 α 的经验是“补多少度定 α，ω_z 放在新 ω_c 下方半个到一倍频程”。表 39-5 的四组就是这么扫出来的。

缺低频增益（静差大）、相位够——用滞后。形式与超前同形，但零极点调了个方向：零点在 ω_z、极点在其下方 ω_z/β，其中 $\beta = z/p > 1$ 是第 43 章 §43.2.4 的**衰减比**。幅频在高频衰减到 $1/\beta$，相位只在 ω_z 以下的低频段才有明显滞后。使用时把它与增益 β 一起加上：低频段总增益抬 β 倍，静差按 $1/(1+\text{开环低频增益})$ 缩小，而 ω_c 附近的幅值恰好回到原值、相位只损失几度。**这正是滞后校正的巧妙处——它用“高频衰减”抵消了“增益抬高”对穿越点的影响**。要点是零极点都要放在 ω_c 的十分之一以下，否则它在穿越点附近贡献的滞后会把省下来的裕度又赔进去。

两样都缺——用超前-滞后，或直接上 PID。前者把两个环节串起来，注意交接区的相位不要互相抵消；后者用积分管低频、用微分管相位、用比例管带宽，三个旋钮各管一段，调起来反而更清楚。区别在于：PID 的微分对高频噪声的放大比超前更凶（它没有极点限制），所以噪声大的场合宁可串两级超前，也不要硬加 D。

这四种选择背后有一条统一的约束。对最小相位系统，Bode 的增益-相位关系说明**相位是幅频斜率的积分**：想让某一段相位抬高，就必须让那一段的幅频斜率变缓，也就是把增益从低频“搬”到高频。超前校正抬高高频增益、滞后校正压低高频增益，本质都是在搬运，没有哪种能凭空造出相位。理解了这一条，就不会指望“找一个既能补相位又不抬高频的环节”——它不存在，只存在“抬多少、抬在哪一段”的取舍。

39.9 优化与改进

39.9.1 纯延迟：不近似，直接乘

含延迟的开环写成 $L(s)=L_0(s)\mathrm{e}^{-T_d s}$，频率特性只多一个因子 $\mathrm{e}^{-\mathrm{j}\omega T_d}$，幅值不变、相位线性下垂。Nyquist 判据对超越函数同样成立——因为判据只用到"曲线绕了几圈"，而延迟不改变幅值，只让曲线多绕。

本例加 50 ms 延迟后，相位穿越条件变成 $\arctan(\omega/2)+\arctan(0.05\omega)+0.05\omega=90^\circ$，解得 $\omega_{180}=4.35$ rad/s（原 6.32），对应 $K_{\max}=2.13$。$K_{\max}$ **掉了 6.3 dB，而幅频曲线一点没变**——全部损失来自相位。

这也是"能不用 Padé 就不用"的理由：Padé 二阶在 $\omega T_d=0.63$ 时相位误差 0.0079°（第 38 章 §38.9.5 实测），确实足够小；但若只关心包围圈数，直接乘指数因子更省事，也不引入额外的右半零点。

把 $K=1$ 的几档延迟算出来，这条结论就有了刻度。无延迟时相位穿越在 6.325 rad/s，$|L|=0.227$，$G_M=12.87$ dB；加 100 ms 延迟，穿越点左移到 3.485，$|L|$ 升到 0.704，G_M 只剩 3.05 dB；加到 200 ms，穿越点 2.615、$|L|=1.152$，G_M 变成 -1.23 dB——闭环已经发散，而幅频曲线一个点都没变。按 $T_{d,\max}=\varphi_M/\omega_c$ 算，$K=1$ 的容忍上限是 $0.471/2.846=0.166$ s，与"200 ms 已越线"完全吻合。

这组数还解释了一条常见的现场经验：**"这台设备带 200 ms 延迟也能跑"往往是在低增益下说的**。$K=0.3$ 时 $\varphi_M=54.1^\circ$、$\omega_c=1.27$，容忍 0.75 s；同一个 200 ms 延迟，在高增益下是致命的，在低增益下只吃掉 14.5°。延迟的破坏力不取决于延迟本身，而取决于它占了多少相位预算。

把这几档折成"可用增益还剩多少"，换算起来更好用：50 ms 时 $K_{\max}=2.13$，是原来的 48%；100 ms 时 $G_M=3.05$ dB，折算 $K_{\max}=1.42$，剩 32%；200 ms 时 $G_M=-1.23$ dB，折算 $K_{\max}=0.87$，连 $K=1$ 都保不住。**延迟的代价既不线性、也不严格等比**：从 50 ms 到 100 ms 只多了 50 ms，可用增益又掉了三分之一。这类换算没有通用闭式，只能对具体对象逐档实算；能记住的只有量级——在这个带宽上，几十毫秒的延迟就是几个 dB 到十几个 dB 的事。

39.9.2 右半平面零点：幅频骗人

因子 $(1-T_z s)$ 的幅值随频率上升（像微分），相位却随频率下降（像滞后），最终趋向 -90° 而不是 $+90^\circ$。只看幅频会以为"高频被抬升、带宽变宽"，实际相位被悄悄吃掉。

这类对象（非最小相位）必须用 Nyquist 数圈，Bode 的"$\varphi_M>0$ 即稳"不再可靠——因为增益与相位之间那条"最小相位"的对应关系断了。工程上的典型例子是倒车、锅炉水位、以及某些带柔性传动的伺服。

一个极端例子能把"幅频骗人"说透。取 $L(s)=K(1-s)/(1+s)^2$，它的幅频是 $K/\sqrt{1+\omega^2}$，与一阶惯性 $K/(s+1)$ **完全相同**；但相位是 $-3\arctan\omega$，在 $\omega=\sqrt{3}$ 处就到 -180°，此时 $|L|=K/2$。于是 $G_M=2/K$、临界增益 $K_{\max}=2$，$K=1.5$ 时相位裕度只有 35.4°。若只看幅频，会把它当成一阶系统（相位最多 -90°、裕度无穷），把增益一路往上开。

实跑还能给出另一组更贴近本章对象的对照。把本章对象分别乘上 $(1+0.2s)$ 与 $(1-0.2s)$，两条幅频曲线在 0.1–10 rad/s 上逐点相同（$\omega=0.1$ 时都是 49.947，$\omega=1$ 时都是 4.5550，$\omega=3.136$ 时都是 0.9998），穿越频率也都是 $\omega_c=3.136$，闭环阶跃的 rise time 也都在 0.42 s 量级。差别全在相位：左半平面零点版本在穿越点的相位是 -124.3°，$\varphi_M=55.7^\circ$，且相位随频率渐近 -180° 而不穿越，$G_M=\infty$，超调 15.0%、$t_s=1.61$ s、闭环极点在 -18.21 与 $-1.895\pm2.719\mathrm{j}$；右半平面零点版本同一频率的相位是 -188.5°，$\varphi_M=-8.5^\circ$，$\omega_{180}=2.722$ 处 $|L|=1.227$、$G_M=-1.78$ dB，闭环极点跑到 $+0.199\pm2.982\mathrm{j}$，阶跃按 $e^{0.199t}$ 发散。

同一张幅频图，两个相反的结论。而且这里有个容易忽略的细节：两个版本的 G_M 一个无穷、一个 -1.78 dB，差得极远，但 $|L|$ 只在 ω_{180} 附近才有区别——在 ω_c 上它们一模一样。所以只测幅频、只在穿越点附近看数据的做法，连“稳不稳定”都答不出来，更不用说裕度。这就是为什么 §39.3.1 第一步要数 P、第二步要展开相位，而不能只扫幅值。

非最小相位对象还有一条更隐蔽的限制：它不允许高带宽。要在 ω_c 处获得足够的相位，穿越点必须远低于零点位置；经验上 ω_c 取右半零点频率的 $1/3$–$1/5$ 以内，否则相位裕度会被零点拖垮。这个限制与增益无关，换控制器也绕不过去——它来自对象本身。

39.9.3 开环不稳定：判据必须带 P

设 $L = K/(s-1)$，$P = 1$。Nyquist 曲线是一个过 $(-K, 0)$ 与原点、圆心在 $-K/2$ 的圆。$K = 2$ 时圆心 -1、半径 1，曲线把 -1 包在里面，逆时针一圈，$N = -1 = -P$，闭环稳定（根为 $s = -1$）；$K = 0.5$ 时圆缩到 $[-0.5,\, 0]$，不包围 -1，$N = 0$，$Z = N + P = 1$，闭环不稳（根为 $s = +0.5$）。

用 Bode 看这个对象会得出荒唐结论：相位从 -180°（$\omega = 0$）单调升到 -90°（$\omega \to \infty$），**根本不穿越** -180°，于是“$G_M = \infty$、φ_M 很大”，看上去极其安全，实际 $K = 0.5$ 时是发散的。**$P \neq 0$ 时，裕度只能作为参考，结论必须由包围圈数给出。**

这个例子还颠倒了“增益越大越危险”的直觉。闭环极点就是 $1 - K$：$K = 0.5$ 时在 $+0.5$，$K = 0.9$ 时在 $+0.1$，$K = 1.01$ 时刚到 -0.01，$K = 2$ 时在 -1，$K = 5$ 时在 -4。**增益越小越不稳**，K 必须大于 1 才稳；而 $K = 1.01$ 虽然“稳”，时间常数 100 s，工程上等于不可用。所以这个对象有两道下限：稳定性的 $K > 1$，和可用性的 $K \geq 2$。只报“闭环稳定”是不够的，还要报“稳在哪一段”。

39.9.4 用一个数概括全部余量：灵敏度峰值

裕度是两个数，汇报时总想压缩成一个。最常用的压缩方式是灵敏度函数 $S(s) = 1/[1 + L(s)]$ 的峰值 $M_s = \max_\omega |S(\mathrm{j}\omega)|$。它的物理意义是“扰动与模型误差在最坏频率上被放大多少倍”，几何上等于 Nyquist 曲线到 -1 点最短距离的倒数。

用 §39.12 的频响数据实算：$K = 0.3$ 时 $M_s = 1.472$（峰值在 2.01 rad/s），$K = 0.5$ 时 1.749，$K = 1$ 时 2.488，$K = 2.2$ 时 5.242，$K = 3$ 时 9.465。**增益从 0.3 提到 2.2（7.3 倍），G_M 掉 17.3 dB、φ_M 掉 42.2°，而 M_s 涨了 3.6 倍**；到 $K = 3$，M_s 已接近 10，意味着某条频率上的扰动会被放大近十倍——这正是现场“一有干扰就抖”的频域解释。

M_s 与两个裕度之间有严格的不等式：$G_M \geq M_s/(M_s - 1)$、$\varphi_M \geq 2\arcsin[1/(2M_s)]$。把实算的 M_s 代进去：$K = 2.2$ 时下界是 1.24（1.84 dB）与 10.95°，实测 6.02 dB 与 11.85°——相位裕度的下界几乎贴住真值，增益裕度的下界则宽松得多；$K = 0.3$ 时下界是 9.88 dB 与 39.7°，对应 23.3 dB 与 54.1°，两个都明显保守。**裕度越大，M_s 给出的界限越松**，这是它适合做报警线、不适合做精确验收的原因。

工程上常把 $M_s \leq 2$ 当作鲁棒性的经验上限，它大致对应 $\varphi_M \geq 30^\circ$、$G_M \geq 6$ dB。本章对象在 $K = 0.5$ 与 $K = 1$ 之间越过这条线（M_s 从 1.75 涨到 2.49），而按 45° 的相位门槛，K 本来就被限制在 0.44 以下——两个判据给出的工作点范围一致，互相印证。

这批数还能读出一个几何量。-1 到曲线的最近距离就是 $1/M_s$：$K = 0.3$ 时 0.679，$K = 2.2$ 时 0.191。**最近点并不在相位穿越频率上**：$K = 2.2$ 时曲线在 ω_{180} 处经过 -0.5，离 -1 还有 0.5，可真正最近的只有 0.191。最近点在 ω_c 附近——那里曲线正从单位圆上擦过，相位裕度 $\varphi_M = 11.9^\circ$ 意味着它与负实轴的夹角只有 11.9°，到 -1 的距离近似 $2\sin(\varphi_M/2) = 0.207$，与实算的 0.191 只差 8%。

由此得到一个可以口算的关系：**相位裕度较小时，$M_s \approx 1/\varphi_M$（φ_M 以弧度计）**。$11.9^\circ = 0.208$ rad，倒数 4.81，实算 5.24；$45^\circ = 0.785$ rad，倒数 1.27，对应的实际 M_s 在 1.3 左右。这条关系说明两件事：其一，M_s 与相位裕度在数值上几乎互为倒数，汇报时用哪个都行；其二，M_s 对裕度的变化比 G_M 敏感得多——裕度掉一半，M_s 翻一倍，而 G_M 只掉 6 dB。

39.9.5 多次穿越：Bode 读数的盲区

延迟还会制造多次穿越：相位每下降 360° 就再穿一次负实轴。$K = 1$、$T_d = 0.5$ s 时，第一次穿越在 1.619 rad/s、$|L| = 2.39$，此后相位继续下降，还会在更高频率上再穿几次，只是那些点的 $|L|$ 已经小得多。判据要求数完所有穿越，而 Bode 图上的“相位裕度”只对应最靠近 ω_c 的那一次。**当穿越多于一次时，Bode 读出的裕度可能完全错误，必须回到 Nyquist 按 §39.3.4 的射线法逐个记账。**

这也解释了 §39.3.5 为什么强调“自下而上 $+1$、自上而下 -1”：每一次穿越都改变一次曲线相对 -1 的方位，漏记一次就少一圈，结论从“稳定”翻成“不稳定”。工程上遇到相位曲线“下探又回升”的对象（柔性臂、液位、带旁通的换热器），不要相信 Bode 上那一个数字。

39.9.6 从 Nyquist 到 H_∞ 与 μ

M_s 其实就是灵敏度函数的 H_∞ 范数。这条线索把经典判据接到了鲁棒控制：小增益定理把“$|L| < 1$ 时闭环稳定”推广为“$\|\Delta\|_\infty < 1/\|T\|_\infty$ 时对所有允许的 Δ 都稳定”，其中 $T = L/(1+L)$ 是补灵敏度函数。单回路的两个裕度，是这个不等式在标量情形下的几何版本。

多变量时 -1 点换成一个矩阵，判据变成 $(I+L)^{-1}$ 的最大奇异值，也就是 μ 分析（第 63 章）。所以本章并没有“过时”：它是多变量鲁棒判据在 1×1 情形下的退化形式，理解了这个特例，后面那套矩阵语言才有落脚点。

39.9.7 四种病态同时出现时，按什么顺序查

前面四小节各讲一种病态，现场遇到的往往是几种叠在一起。这时排查顺序不能随意，因为**结构性问题会一票否决量值性结论**：先算裕度再查结构，等于在错误的模型上做精确的算术。可用的顺序是：

第一步，数 P。 开环有没有右半平面极点？有，则两个裕度只能当参考，结论必须由包围圈数给出（§39.9.3）。这一步只看模型结构，不需要任何数据，三十秒就能做完，却能排除掉最严重的一类误判。

第二步，查右半平面零点。 有没有延迟、有没有“反向”的物理环节（倒车、锅炉水位、柔性传动的反谐振）？有，则幅频与相位脱钩，不能用“幅频好看”推断“相位安全”（§39.9.2）。判断方法是把相位曲线单独画出来看最低点，而不是只看穿越点那一个读数。

第三步，数相位穿越次数。 相位在 ω_c 以上是否只穿过一次 -180°？若穿多次，Bode 上的裕度只反映最近的一次，必须回到 Nyquist 按射线法逐次记账（§39.9.5）。含延迟超过 $2\pi/\omega_c$ 的对象几乎一定多次穿越。

第四步，查数字实现的两笔账。 T_s 是多少？控制器有没有一拍以上的计算延迟？按 §39.10.6 折算成相位，从预算里扣掉。这一步最容易被跳过，因为连续域的仿真里根本没有这两个环节。

第五步，才是看增益与参数。 到这一步仍不达标，才回到 §39.8 的调参流程——降增益、补相位、重新分配带宽。

这个顺序的道理在于：前四步改的是“判据能不能用”，第五步改的是“系统好不好”。**判据用错了，调得再细也是白调**；反过来，判据用对了，即使暂时不达标，也知道该往哪个方向改。工程上那些“调了三天越调越糟”的案例，多半是跳过了前四步，直接在第五步上反复试。

39.10 工程落地

判据在纸面上是精确的，落到设备上有三处会走样：测不准、扫不全、以及“实测比模型好看”。本节按“测量—读数—验收”的顺序处理。

39.10.1 现场怎么扫频

三种激励按信息量排序：正弦逐点最准但最慢，适合 5–10 个频点的关键段；扫频（chirp）一次覆盖全频段，适合快速摸底；白噪声最快，但幅值难控，容易把系统推出线性区。**无论哪种，激励幅值都应取正常工作幅值的 5%–10%**：太小被噪声淹没，太大进入饱和或间隙，测出的“幅值比”就不是线性系统的量了。

频率范围按 ω_c 定：下限取 $0.1\omega_c$（看积分段的斜率），上限取 $10\omega_c$（看高频滚降与共振）。本例 $\omega_c = 1.26$ rad/s 时，扫 0.1–13 rad/s 即可；若关心执行器滞后，上限要推到 20 rad/s 以上。

幅值之外还有三个参数决定数据能不能用。**平均次数**：每个频点至少叠 5–10 次，取平均后噪声功率按 $1/\sqrt{n}$ 下降；扫频时用相关平均（把输入与输出在激励频率上做投影），比直接算术平均抗噪得多。**注入点**：要测回路增益就从误差信号注入、从控制器输出取响应；从指令端注入会把前馈通道一起测进去，得到的不是回路增益。**限幅与安全**：先设好软件限幅与机械限位，扫频过程中一旦出现持续等幅振荡立即停止激励——这不是多余的话，很多设备是在“最后一次扫频”时被振坏的。

相干函数是判断数据可用性的唯一客观指标。它接近 1 说明输出确实由输入引起，接近 0 说明该频点被噪声、非线性或其他激励源淹没。经验阈值取 0.8：低于 0.8 的频段不要用来读裕度，宁可留空并在报告里注明，也不要用一条“看起来很平滑”的插值曲线去填。相位穿越点附近的相干性尤其要看——那里幅值已经很低，信噪比最差，而 G_M 恰恰只由那一点决定。

分段扫频是工程上常用的折中：在 $0.1\omega_c$–ω_c 段用大幅值、少频点，快速看清趋势；在 ω_c–$3\omega_c$ 段用小幅值、密频点、多次平均，把相位穿越那一段测准。两段数据拼接时注意幅值基准要一致，否则拼出来的曲线在接缝处会有一个假的“台阶”，让人误判斜率。

39.10.2 从实测曲线读裕度

读数前先做三件事：相位展开、去掉明显跳变的坏点、把相干函数低于 0.8 的频段标灰。相位展开最容易忘——扫频仪给的相位通常在 $[-180^\circ, 180^\circ]$ 内折返，不展开就会在 -180° 附近反复穿越，把“一次穿越”读成“五次”。

若高频段数据缺失（常见于共振点附近，幅值太小），不要外推，直接用模型补那一段，并在报告里注明“$\omega > 10\omega_c$ 为模型外推”。判据对高频段很敏感：一个未建模的 -20 dB/十倍频，可能让 G_M 少 6 dB。

读数本身有四条规则，都是为了让最后那一位数字可信。

第一条，两个穿越点要用插值定位，不能取最近的采样点。 扫频点通常按对数等间隔，ω_c 落在两点之间是常态。在对数坐标下对 $\lg|L|$ 做线性插值，误差可以压到 0.1 dB 以内；直接取最近点，在幅频斜率 -40 dB/十倍频的段上，一个 $1/12$ 倍频程的间隔就能带来 1 dB 以上的偏差。

第二条，φ_M 的读数精度受相位斜率放大。 本例在 ω_c 附近，相位对自然对数的斜率约为 30°–35°（即每十倍频 70°–80°）。这意味着 10% 的频率读数误差会变成约 3° 的相位裕度误差。所以报告里写 $\varphi_M = 54.1^\circ$ 时，心里要清楚它的不确定度是“几度”，而不是“零点几度”。

第三条，G_M 的读数对 ω_{180} 更敏感。 在相位穿越点附近，本章对象的幅频斜率已达 -60 dB/十倍频，折算成自然对数约 -17 dB。10% 的频率误差对应约 1.7 dB 的幅值误差。这就是为什么 §39.10.1 要求把 ω_c–$3\omega_c$ 那一段加密测量——G_M 的价值全在那一个点上。

第四条，两个裕度要报有效数字，不要报小数点后两位。 按上面三条，φ_M 报整度、G_M 报 0.5 dB 就够；多写的位数是虚假精度，评审时反而会被追问“这个 0.1° 是怎么测出来的”。

39.10.3 实测为什么总比模型“好看”

先说三个常见原因。其一，**非线性**：饱和与间隙在小信号下不起作用，实测裕度偏大；一旦指令加大，等效增益上升，实际裕度比测出的小。其二，**激励点不同**：从指令端注入测的是“指令到输出”，从扰动端注入测的是“扰动到输出”，两者的回路增益差一个前馈通道。其三，**平均效应**：扫频时系统在多个工作点间游走，测出的是平均特性，而失稳往往发生在最不利的那一个工作点。

还有第四个原因，也是最容易被忽略的：**回路断点选错**。回路增益只有在正确的断点处测才是真正的 $L(s)$。在控制器输出与执行器之间断开，测到的曲线不含传感器滤波；在传感器之后断开，又漏掉了执行器滞后。两种测法的差别，恰好就是“被漏掉的那一段”的频响，而那一段往往正是高频相位滞后的主要来源。一个 20 ms 的传感器低通，在 4.42 rad/s 处就贡献 5.1°——与 §39.7.3 实跑中 20 ms 滤波极点让 φ_M 从 27.0° 掉到 23.8° 是同一个量级。**裕度对不上时，先问“断点在哪”，再问“参数对不对”。**

对策是把判据的结论打折：G_M 扣 3 dB、φ_M 扣 10°，再与目标值比较。这不是保守主义，而是承认“测的是平均、坏的是极端”。

39.10.4 验收表

把本章与第 38 章的指标放进同一张表，验收时逐行签字。以 $K=0.3$ 为例：

表 39-6 某位置环的稳定性验收表（$K=0.3$，无附加延迟）

指标	目标	计算/实测值	判定
增益裕度	≥ 10 dB	23.3 dB	通过
相位裕度	$\geq 45^\circ$	54.1°	通过
截止频率	1–2 rad/s	1.26 rad/s	通过
超调量	$\leq 20\%$	13.8%	通过
调节时间（±2%）	≤ 6 s	4.4 s	通过
延迟容忍	≥ 0.2 s	0.75 s	通过

最后一行是本章特有的指标，由 φ_M/ω_c 直接换算：$0.944/1.26=0.75$ s。它的物理意义很直白——**在相位裕度被吃光之前，回路还能容忍多少纯延迟**。这个数比“相位裕度 54°”更容易和现场的通信周期、扫描周期对上号。

这张表有三条使用规则，否则它会退化成一张“签个字就过”的纸。

其一，每个数要注明来源。 表里第 1–2 行是频域计算值，第 4–5 行是阶跃实测值，两类数的可信度不同。规范写法是拆成两列：“模型值”与“实测值”，并在实测值后面标注工况。只有一列“计算/实测值”时，半年后没人说得清这个 23.3 dB 是算的还是测的。

其二，目标值要区分“设计目标”与“验收下限”。 设计时按 $\varphi_M \geq 60^\circ$ 留余量，验收时按 $\geq 45^\circ$ 判定，两者不是同一个数。若表里只写一个 45°，设计阶段就会贴着线下手，扣掉 §39.10.3 的 10° 折扣后现场只剩 35°。

其三，这张表要按工况分版本。 增益 K 随负载变化、τ_a 随温度变化，满载与空载的 $K_{\max}$ 可以差 20% 以上。同一台设备至少要有“空载/满载”两版表，验收时按最不利的那一版签字。本章所有数字都是在标称工况下算

的，换成实际工况时，先按 §39.7.2 的弹性把 τ_a 折算一遍。

39.10.5 三个现场陷阱

第一，**用指令信号扫频**。指令端注入会经过前馈通道，测出的回路增益偏高，裕度看着更紧；诊断“为什么振”应当从扰动端注入，两者不要混用。

第二，**只扫到 ω_c 附近**。相位穿越往往在 1.5–2 倍 ω_c 处，扫到 ω_c 就停，等于没看到决定 G_M 的那一段。

第三，**忽略采样**。数字控制器在 ω_c 以上还有采样带来的相位下垂，实测（连续域扫频）看不到它。若 $\omega_c T_s > 0.2$ rad，必须用 §39.5 的离散判据复核一遍，否则会高估裕度。

39.10.6 数字实现还会再吃掉一块相位

上面所有裕度都是连续域的。真正跑在 PLC 或运动控制器上的回路，还要额外付两笔相位：零阶保持器与计算延迟。ZOH 在 ω_c 处的等效滞后约 $\omega_c T_s/2$ 弧度：$T_s = 0.02$ s、$\omega_c = 4.42$ 时是 2.5°，$T_s = 0.1$ 时是 12.7°。计算延迟更贵——从采样到输出至少一拍，若再留一拍余量就是 $2T_s$ 的纯延迟，$T_s = 0.1$ 时在 4.42 rad/s 处吃掉 25.3°，正好是 ZOH 的两倍。

两笔账合起来，正好解释 §39.5.3 的实测：$T_s = 0.1$ 时 $K_{\max}$ 从 4.40 掉到 2.14（-6.25 dB），而按 $T_s/2 = 50$ ms 纯延迟估算是 -6.3 dB。**数字实现的损失可以用“半个采样周期延迟”来估，误差在 1 dB 以内**；若控制器还有一拍计算延迟，再按 T_s 追加。

由此得到两条实施规则。其一，$\omega_c T_s \le 0.2$ rad（每周期至少 31 个采样点），对应 ZOH 相位损失不超过 11.5°；本章对象 $\omega_c = 4.42$，这要求 $T_s \le 0.045$ s。其二，把计算延迟算进预算：ZOH 只占 $0.5T_s$，加上 $1.5T_s$ 的计算与通信延迟，总数变成 $2T_s$，是原来的四倍。同样要求总滞后不超过 10°，T_s 的上限就从 0.079 s 掉到 0.020 s——**加了计算延迟之后，采样周期差不多要再小一半到四分之三。先算这两笔，再谈控制器参数**——顺序反了，参数会在现场被推翻。

39.10.7 把裕度做成在线指标

验收时的裕度是静态的，运行中的裕度会漂。可监测的三个量与本章的灵敏度直接对应：闭环谐振峰值 M_r（对应 M_s）、振荡频率（对应 ω_c）、以及同幅值下的相位（对应 φ_M）。三者中 M_r 最容易从运行数据估出来——对指令叠加一段小幅伪随机序列，做频谱分析取闭环幅频的峰值即可，不必停机扫频。

报警阈值可以由 §39.7.6 的弹性反算。以表 39-6 的 $K = 0.3$ 工作点为例：φ_M 从 54.1° 降到 45°，对应增益漂移 $+49\%$；G_M 从 23.3 dB 降到 10 dB，对应 $+4.6$ 倍。把报警线设在“预算用掉一半”处，即 $\varphi_M < 50^\circ$ 或 $G_M < 16$ dB 时提示复核，比等到越线再停机便宜得多。

第二类漂移来自 τ_a。按 §39.7.2 的弹性，τ_a 增大 30% 会让 $K_{\max}$ 降约 30%（2.3 dB），而 ω_c 只降 2%——**只看带宽的监测会漏掉执行器退化**。可行的办法是定期做一次小信号扫频，盯住 ω_{180}：它从 6.32 左移到 5.00，就是 τ_a 从 0.05 s 增到 0.08 s 的签名，比任何振动报警都早。

39.10.8 一次现场复盘

某位置环按“增益尽量大”整定到 $K = 2.2$，实验室里勉强站得住（超调 71.4%、调节时间 8.45 s），现场却出现约 4 rad/s 的持续等幅振荡。按本章顺序查：先量延迟，通信加执行共 60 ms；再算账，$K = 2.2$ 的 $\varphi_M = 11.9^\circ$，60 ms 在 4.42 rad/s 处吃掉 15.2°，裕度为负；振荡频率与 ω_c 也对得上，两条证据指向同一原因。

降增益到 1.0，振荡消失，但超调 46.1%、调节时间 5.36 s，用户不接受。最后按 §39.8.5 加 $\omega_z = 1.8$ 的超前环节、增益保持 1：实算 $\varphi_M = 61.8^\circ$、$G_M = 16.9$ dB，扣掉 60 ms 延迟的 15.2° 仍有 46.6°；阶跃超调 5.6%、调节时间 0.67 s。投运后复测，振荡消失。

复盘的价值在三个数：**连续域 11.9°、扣延迟后 −3.3°、补相位后 46.6°**。它们把“为什么实验室好、现场振”解释成一条可核算的链子，而不是一句“现场干扰大”。下次遇到同类问题，先算这三个数，再决定是降增益、补相位，还是去修延迟。

39.10.9 一张可以打印出来带走的卡片

现场的判据不该是一本书，而是一页纸。下面这张卡片把本章压到能贴在工具箱内侧的密度。

四个空要填。 对象（一句话写清结构与参数）；当前增益与 ω_c；φ_M 与 G_M；延迟预算（通信 + 执行 + 滤波 + 采样，单位 ms）。前三个空当场能测，第四个空往往要回去查手册，而它恰恰是决定余量的那一个。

三条红线。 $G_M \geq 6$ dB；$\varphi_M \geq 45^\circ$；$\varphi_M/\omega_c \geq 1.5\times$ 实测最大延迟。第三条是本章特有的：前两条达标、第三条不达标的系统，在实验室一切正常，一上现场就振——§39.10.8 那个 60 ms 的例子正是这一条被漏掉。

两个必查。 数 P（开环有没有右半平面极点）；确认相位只穿 -180° 一次。两条中任何一条不成立，两个裕度就只能当参考，不能当结论。

一个换算。 超调 $M_p \leq 20\%$ 对应 $\varphi_M \geq 47^\circ$（由表 39-4 反查，§39.7.5 已给）。若验收条款写的是超调，别把它翻译成“增益裕度 6 dB”——在本章对象上，这两个门槛对应的工作点差着五倍（§39.8.1）。

卡片的用法是“先填后算”：四个空填完再去对红线，而不是先算出一堆数再挑一个好看的报。**填不出来的那个空，就是这次调试真正的风险点**——它通常不是增益，而是延迟或采样。

39.11 优缺点与适用边界

39.11.1 四条优点

1. **只要频响，不要阶次。**这是它相对 Routh 的最大优势：模型只需“能画出曲线”，不必“写成多项式”。现场扫出一条曲线，即使说不清对象是三阶还是四阶、有没有一个没建模的小极点，仍然能读出两个裕度——因为判据只关心“曲线离 -1 多远”，不关心曲线是几个极点拼出来的。Routh 表做不到这一点：系数少一个，整张表就作废。
2. **给的是裕度，不是是与否。**G_M、φ_M 直接对应“增益还能加多少、延迟还能加多少”，可写进验收条款。这一点在跨专业协作时尤其有用：机械工程师听得懂“还能再加 6 dB”，也听得懂“还能再容忍 0.17 s 延迟”，而“特征值实部为负”对他们是另一套语言。
3. **天然处理延迟与非最小相位。**$\mathrm{e}^{-\mathrm{j}\omega T_d}$ 与右半零点都能直接画进曲线，不需要近似（§39.9）。Padé 近似会引入额外的右半零点，把“最小相位”这个前提悄悄破坏掉；直接乘指数因子则没有这个问题，代价只是曲线不再是有理函数的像，画图时要按频率逐点算。
4. **图形直观，便于沟通。**同一张 Bode 图上，机械、电气、控制三方看到的是同一个“离 0 dB 与 -180° 多远”。更实际的好处是它把三个量（幅值、相位、频率）放在同一张纸上：改一个参数，三条信息同时变化，讨论时不必在几页公式之间来回翻。

39.11.2 四条局限

1. **只对线性时不变成立**。饱和、间隙、摩擦会让实测曲线随幅值变化，判据只能给“小信号结论”。本章对象若把执行器限幅考虑进去，$K = 2.2$ 时的大信号响应会与线性模型差得很远——线性模型说超调 71%，实际可能因为饱和而“看起来更好”，但这并不是系统的真实线性特性。对策是用 5%、10%、20% 三档幅值各扫一次，看曲线是否重合；不重合就说明已经进入非线性区，裕度只能按最小幅值那一档报。
2. **不直接给瞬态细节**。裕度换算超调、调节时间都要经过二阶近似（式 39-16），高阶系统会有偏差（本例 11.9° 对 11.3°，差 0.6°）。§39.6.4 的三档对拍更能说明问题：这条估算链在三个工作点上分别低估超调 0.5、4.6、2.8 个百分点，**方向一致地偏乐观**。所以它能用来“粗判趋势”，不能用来“签字验收”。
3. **多变量系统不好用**。回路间存在耦合时，单回路的裕度不能保证整体稳定，需要回差矩阵或 μ 分析（第 63 章）。一个典型反例是双轴平台：每个轴单独看 φ_M 都有 50°，但两轴同时动作时，耦合项会让某个方向的等效回路增益抬高，实际裕度只剩二十几度。
4. **依赖测量质量**。相干函数低、频段缺失、激励幅值不当，都会让“看起来的裕度”偏离真实值（§39.10.3）。与前三条的差别在于：前三条是方法的边界，这一条是数据的边界。数据不可信时，再严谨的判据也救不回来，唯一正确的做法是重测，而不是在坏数据上做更精细的计算。

39.11.3 适用边界

场景	首选判据	理由
有精确多项式、只问临界增益	Routh / Jury	解析、精确、可手算
只有扫频数据	Nyquist / Bode	不需要阶次
含纯延迟	Nyquist（直接乘 $e^{-T_d s}$）	无需 Padé，包围圈数仍成立
开环不稳定（$P \neq 0$）	Nyquist	裕度判据此时不充分
需要设计补偿器	根轨迹 + Bode	零点位置与相位补偿直接对应
多变量、强耦合	回差 / μ 分析	单回路裕度不保证整体稳定

这张表回答的是“先看哪个”，不是“只看哪个”。实际工程里三套判据往往同时上：先用 Routh 或 Jury 把边界增益钉死（系数可得时），再用 Bode 读当前工作点的两个裕度，最后用根轨迹确认“临界时是哪一对根先到虚轴”。三者一致才签字；不一致时按 §39.9.7 的五步顺序查。

表里三行的理由值得各说一句。

含纯延迟那一行。 延迟让特征方程不再是多项式，Routh 与 Jury 直接失效——这不是“精度差一点”，而是“方法用不了”。频域判据只把 $\mathrm{e}^{-\mathrm{j}\omega T_d}$ 乘进曲线，包围圈数的理论一字未改。代价是每改一次 T_d 都要重算整条曲线，因为没有多项式可以递推。

开环不稳定那一行。 $P \neq 0$ 时裕度只是必要条件。$L = 0.5/(s-1)$ 的相位从 -180° 出发、向 -90° 走，全程不穿越，Bode 看上去“裕度无穷、完美”，闭环却是 $0.5/(s-0.5)$，极点在 $+0.5$。差别在于 Bode 只看“是否越过 0 dB 与 -180°”两条线，Nyquist 还要数“包围了几圈”。所以 $P \neq 0$ 时，Bode 的两个数必须由 Nyquist 的绕数补上，缺一不可。

多变量那一行。 单回路裕度是逐个回路断开测的，断开时耦合项被“冻住”了。双轴平台每个轴单看都有 50° 的相位裕度，两轴联动时某个方向的等效回路增益会被抬高，实际只剩二十几度。这不是判据不够精确，而是“回路”这个前提本身不成立——必须先回到回差矩阵或 μ 分析，把耦合显式算进去。

39.11.4 与相邻章节的分工

第 38 章给“有系数时的精确边界”，本章给“有曲线时的裕度”，第 40 章把根轨迹展开成设计工具，第 41 章系统讲频率响应与补偿器设计，第 42 章讨论稳态误差。五章共用同一个对象 $10/[s(s+2)(0.05s+1)]$，$K_{\max}=4.40$、$\omega_{osc}=6.3246$ 这组数会在后续章节反复出现，读者可以一路对照。**注意这组数带着那个 $0.05s+1$ 的执行器滞后**：只有二阶的 $10/[s(s+2)]$ 处处稳定，没有有限临界增益，把它当成上式的简写就会得出“$K_{\max}=4.40$ 是二阶对象的性质”这种错结论。

需要强调一句：**本章不重复推导 Bode 图的画法**（见第 41 章），也不展开根轨迹的绘制规则（见第 40 章）；本章只回答“如何用这三张图判稳，以及三张图为什么给同一个答案”。

这几章之间的接口可以写得更具体。第 40 章把根轨迹从“读数”变成“设计”：本章只找穿越点 $\pm\mathrm{j}6.3246$，第 40 章要回答“零点加在哪里、轨迹才会整体左移”，本章 §39.4.3 算出的渐近线交点 -7.33 会在那里被重新解释。第 41 章把 Bode 从“读裕度”变成“造裕度”：本章 §39.8.5 只是拿四组参数试算，第 41 章给出超前、滞后、超前-滞后的设计公式与选型依据。第 42 章补上本章缺的那一维——稳态误差：增益越大，误差系数越小，可本章又证明增益受 φ_M 限制，于是“精度不够”与“裕度不够”经常同时出现；出路不是继续拧增益，而是加积分、加前馈或改结构。第 43 章把补偿器落到器件上：有源还是无源、模拟还是数字、容差与量化各吃掉多少裕度；PID 三个参数如何从这些网络里长出来，留到第 44 章。

一句话概括分工：**本章判“能不能用”，第 40–41 章管“怎么改好”，第 42 章管“准不准”，第 43 章管“拿什么实现”**，五章共用同一个对象与同一组数（$K_{\max}=4.40$、$\omega_{osc}=6.3246$、边界幅值 0.2273），读者可以一路对拍。

39.11.5 与状态空间判据的关系

同一件事在状态空间里怎么看？闭环极点就是 $A-BK$ 的特征值，稳定等价于全部特征值实部为负；这与“根轨迹落在左半平面”是同一句话。频域判据数的是“曲线绕 -1 几圈”，状态空间判据数的是“特征值有几个在右半平面”，两者由辐角原理联系起来——绕圈数就是右半平面根数的另一种记法。

差别在适用面。状态空间判据要求有 A、B 矩阵，遇到纯延迟就得先做 Padé 近似或增广状态；频域判据可以直接把 $\mathrm{e}^{-\mathrm{j}\omega T_d}$ 乘进曲线，不需要近似（§39.9.1）。反过来，多变量系统里“每个回路的特征值都稳定”并不能保证整体稳定，因为耦合会让 $\det(I+L)$ 在某个频率上趋零；这时要么用回差矩阵，要么回到状态空间做 Lyapunov 分析。

工程上的分工很清楚：**有精确模型、要设计观测器或做多变量控制，用状态空间；只有频响数据、要写验收条款，用频域**。两者不是替代关系，而是同一稳定性的两种坐标。

中间那座桥可以写得很具体。对单位负反馈，闭环特征多项式是 $\det(sI-A+BK)$，而在频域里它等于 $\det(I+L(s))$ 的分子——两者的零点集合完全相同。于是“特征值全在左半平面”与“$\det(I+L)$ 在右半平面无零点”是同一句话，辐角原理只是把这个零点计数换成了沿围线走一圈的圈数。这也解释了为什么单回路的裕度可以那么简单地读：单输入单输出时 $I+L$ 是一维的，$\det$ 就是 $1+L$，曲线离 -1 多远就是行列式离零多远。多变量时 $\det(I+L)$ 是 n 个回路耦合后的结果，任何一个 $\sigma_{\min}(I+L)$ 趋零都会让行列式趋零，所以“每条回路都有 6 dB 裕度”完全可能对应一个整体不稳的系统——这时该看的是回差矩阵的奇异值曲线，而不是各回路的 Bode 图。

39.11.6 八条常见误用

把本章的边界条件整理成一张清单，遇到争议时逐条对照：

第一，**只看增益裕度**。$K=2.2$ 时 $G_M=6.02$ dB 达标，φ_M 只有 11.9°，超调 71.4%（§39.8.1）。单项合格不等于系统合格。

第二，**用幅频形状判断相位**。$K(1-s)/(1+s)^2$ 与 $K/(s+1)$ 幅频完全相同，前者在 $\omega=\sqrt{3}$ 就穿 -180°（§39.9.2）。

第三，**忘记数 P**。$L=K/(s-1)$ 在 $K=0.5$ 时 Bode 显示“裕度无穷”，闭环却发散（§39.9.3）。

第四，**把 Bode 上那一个相位裕度当成全部**。延迟 0.5 s 时负实轴会被穿多次，每一次都要记账（§39.9.5）。

第五，**用模型裕度替代实测**。实测相位通常比模型更负，验收时应先扣 3 dB 与 10°（§39.10.3）。

第六，**忽略采样**。$K=2.2$、$T_s=0.1$ 时连续域 $\varphi_M=11.9^\circ$，离散后同一频率处只剩 -0.6°，闭环根已出单位圆（§39.5.3）。

第七，**把 $T_s/2$ 规则跨对象套用**。它只在同一对象上成立；拿二阶离散的 4.1378 去比三阶连续的 4.40，会得出“采样只损失 0.53 dB”的错误印象。

第八，**把裕度当性能指标**。$K=0.3$ 时裕度很足，但调节时间 3.41 s；加超前环节后裕度更大、调节时间反而降到 0.67 s（§39.8.5）。裕度是约束，不是目标。

这八条里有六条的共同根源是**把二维信息压成一维**：稳定性需要增益与相位两个坐标，性能需要带宽与阻尼两个坐标。任何“一个数搞定”的尝试，都会在某个对象上翻车。

清单的用法不是背，而是评审时逐条问。审一份裕度报告，先问“P 数了没有”（第三、第四条），再问“相位是模型给的还是实测的”（第五条），最后问“采样算没算进去”（第六、第七条）。前两问决定结论对不对，后一问决定结论能不能落地，顺序不能颠倒——如果 P 数错，后面所有数字都不用看了。这套顺序与 §39.2.5 的排查优先级是同一条原则：先修地基，再论装修。

39.12 Python 仿真代码

本章代码同样分两个文件：`code/ch039_sim.py` 负责把 §39.4–§39.8 的每一行数字算出来并打印，`code/ch039_figs.py` 负责画正文引用的 10 张图。两者共用全书公共库 `simlib.py`，因此图幅、字号、线型与前 38 章一致。

```
"D:\Anaconda3\envs\py311\python.exe" code\ch039_sim.py
"D:\Anaconda3\envs\py311\python.exe" code\ch039_figs.py
```

第一条命令按“对象 → 裕度 → 数圈 → 穿越点 → 离散 → 延迟”的顺序打印六组结果，每组前面有一行中文标题，便于与正文逐条对照；第二条命令在 `figs/ch039/` 下生成 10 组 SVG 与 PDF。依赖仍是 `numpy`、`scipy`、`control` 三个包，不需要符号计算。

39.12.1 一次算完四个量：`bode_margins`

Bode 判据要的四个量正好是 `control.margin` 的四个返回值，但它的**返回顺序与中文习惯相反**：先增益裕度、再相位裕度，先相位穿越、再幅值穿越。写错顺序是这一节最常见的 bug，因此代码里用一个字典把它们绑上名字，后续只按名字取值。

```
def bode_margins(L, w=None):
    """Bode 裕度：返回 ω_c、φ_M(°)、ω_180、G_M(dB)。

    命名口径与正文一致：ω_c 是幅值穿越（|L|=1），
    ω_180 是相位穿越（∠L=-180°）。注意 control.margin
    的返回顺序是 (gm, pm, w_180, w_c)，不是 (pm, gm, ...)。
    """
    gm, pm, w_180, w_c = ct.margin(L, w)
    if np.isfinite(gm) and gm > 0:
        gm_db = 20.0 * np.log10(gm)
    else:
        gm_db = np.inf          # 二阶对象永远不穿越 -180°，给 inf 而不是 nan
    return {"w_c": float(w_c), "pm": float(pm),
            "w_180": float(w_180), "gm_db": float(gm_db)}
```

`gm_db` 那一行判断不是防御性编程，而是必须的：二阶对象 `44/[s(s+2)]` 的相位只到 $-180°$，`ct.margin` 会返回 `gm=inf`，直接做 `20*log10(inf)` 还能得 `inf`，但如果数值上它返回的是一个极大的有限值或 `nan`，后续画图就会在 `inf` 处断线。这里显式给 `inf`，与 §39.4.1 的“增益裕度无穷”是同一个意思。

这里还要交代一个口径问题：`w_180` 是**相位穿越频率**，也就是 §39.3.3 里那个与 K 无关的 $\sqrt{40}=6.3246$；`w_c` 是**幅值穿越频率**，随 K 单调上升。表 39-2 里的五档 ω_c 与 φ_M 就是由这个函数逐档算出，`G_M` 与 ω_{180} 两列则由 §39.12.2 的解析式复核——一条路径算、一条路径验，这是第 38 章就定下的规矩。

`ct.margin` 只报**第一个**穿越点，这一点文件里没写、但必须知道。单回路相位单调时第一个就是最危险的那一个，所以没问题；一旦有延迟或多重谐振让相位反复穿过 $-180°$，函数只返回最靠前的那个 ω_{180}，后面几次穿越的裕度它不管。§39.9.5 的 0.5 s 延迟就是这种情形：负实轴被穿了不止一次，只看返回值会漏账。**要判这种对象，就不能用 `margin` 图省事，得自己沿频率扫 $\mathrm{Re}\,L$ 的负向穿越并逐次记录**——§39.9.5 里那段手写循环之所以存在，正是因为这个限制。

39.12.2 与手算对照：`gain_margin_closed_form`

三阶对象的相位穿越频率可以手算，写进代码当基准：

```
def gain_margin_closed_form(K):
    """三阶对象 L=10K/[s(s+2)(0.05s+1)] 的精确增益裕度。

    ω_180 由 -90° - arctan(ω/2) - arctan(0.05ω) = -180° 解出，
    化简后为 ω^2 = 2/0.05 = 40，与 K 无关。
    """
    w180 = np.sqrt(2.0 / 0.05)
    mag = 10.0 * K / (w180 * np.hypot(w180, 2.0) * np.hypot(0.05 * w180, 1.0))
    return w180, 1.0 / mag
```

两行代码里藏着本章最重要的一条结论：`w180` 里没有 `K`。这意味着**增益变化时，$-180°$ 的位置不动**，`G_M` 与 `K` 严格成反比，式 (39-11) 的 `4.40/K` 不是拟合出来的经验式，而是这个函数除一下就能重现的恒等式。

对照时允许存在千分之一的差：`ct.margin` 在离散频率网格上做插值找穿越点，`gain_margin_closed_form` 是解析值。若两者差超过 1%，说明扫描频段没覆盖到 ω_{180}，应当把 `w` 的上限抬到 $100\,\omega_{180}$ 再算。

用三个点手算一遍，这条恒等式就落地了：$K=1$ 时 $|L(\mathrm{j}6.3246)|=0.2273$，倒数是 4.40，即 12.87 dB；$K=0.3$ 时幅值按比例降到 0.0682，倒数 14.67，即 23.33 dB；$K=2.2$ 时幅值升到 0.5000，倒数正好

2.00，即 6.02 dB。三个数可以统一写成 $G_M(\text{dB}) = 12.87 - 20\lg K$：常数项由对象决定，系数 -20 由分贝定义决定。**这就是“增益裕度对增益的灵敏度是一个纯常数”的全部内容**，§39.7.1 里那句 -8.686 dB 不过是把它换成了自然对数口径。

39.12.3 数圈之前先数 P

Nyquist 判据的结论是 $N = Z - P$，代码若只数 N 而不数 P，等于只做了一半。稳妥的写法是**两条腿走路**：一条画曲线数穿越，一条直接对闭环特征多项式求根。后者不是“绕过 Nyquist”，而是本章反复强调的交叉核对——两条路径给出同一个 Z，结论才可信。

```python
def rhp_count(num, den, k=1.0):
    """数闭环 1+kL 的右半平面根个数 Z（含虚轴容差）。"""
    char = np.polyadd(np.asarray(den, float), k * np.asarray(num, float))
    roots = np.roots(char)
    return int(np.sum(roots.real > 1e-9)), roots


def neg_real_crossings(L, w=None):
    """Nyquist 曲线与负实轴的交点：返回 [(ω, Re L), ...]。

    只统计 Re L < 0 且 |Re L| > 0 的穿越，用来读 ω_180 与 |L(jω_180)|。
    """
    if w is None:
        w = np.logspace(-2, 3, 40000)
    resp = ct.frequency_response(L, w).complex
    im = resp.imag
    idx = np.where(np.sign(im[:-1]) * np.sign(im[1:]) < 0)[0]
    out = []
    for i in idx:
        # 线性插值定位虚部过零的频率
        t = -im[i] / (im[i + 1] - im[i])
        wi = w[i] + t * (w[i + 1] - w[i])
        re_i = resp.real[i] + t * (resp.real[i + 1] - resp.real[i])
        if re_i < 0:
            out.append((float(wi), float(re_i)))
    return out
```

`rhp_count` 的返回值就是式 (39-5) 里的 Z，而 P 由开环极点直接数（`np.sum(np.roots(den).real > 0)`）。两者相减得 N，再与图上数出来的圈数对比。对本例三阶对象，$P = 0$、$Z = 0$，故 $N = 0$：曲线不包围 -1。当 K 越过 4.40，`rhp_count` 立刻返回 2（一对共轭根同时进入右半平面），而图上表现为负实轴穿越点从 -1 的右侧穿到左侧——**一对根同时变号，所以 N 每次跳 2**，这也是为什么单看“穿了几次”容易数错。

`neg_real_crossings` 返回的第二个分量就是 $-1/G_M$：$K = 2.2$ 时它应当在 -0.5000 附近，与 §39.1.2 的读数一致。这条核对比重画一遍 Nyquist 图快得多，现场复核时优先用它。

这段代码有三行值得停下来看。第一行是网格：`logspace(-2, 3, 40000)` 覆盖五个十倍频，相邻点的频率比是 $10^{5/40000} = 1.00029$，在相位下降最快的一段，两点之间的相位差也不过百分之几度——这是“插值误差可以忽略”的前提。若把点数减到 400，相邻比升到 1.03，ω_{180} 的定位误差就到 1% 量级，而 G_M 对 ω_{180} 敏感（§39.10.2 给的量级是每 10% 频率误差换 1.7 dB），误差会直接进到裕度里。

第二行是 `if re_i < 0`。虚部过零有两类：一类在负实轴上，那是我们要的 -180° 穿越；一类在正实轴上，对应相位回到 0° 或 360° 的位置，对增益裕度毫无意义。不过滤的话，含右半平面零点或高频相位回卷的对象会把正实轴交点也报出来，读者很容易误取第一个。

第三行是插值的方向：代码用 `-im[i]/(im[i+1]-im[i])` 求比例，再把它同时用在频率与实部上。这是把两个相邻点之间的曲线当直线处理，误差是二阶小量；本例四位有效数字上与解析值一致，说明这段曲线在过零点附近确实足够平直。若对象在 ω_{180} 附近有谐振（Q 很高），直线假设失效，应当改用三点抛物线插值，或直接把网格加密到谐振带宽的十分之一。

39.12.4 根轨迹穿越点：`root_locus_cross`

根轨迹判据要求的是“哪一对根先到虚轴”，等价于“K 多大时 $\max \operatorname{Re} s = 0$”。这可以用二分实现，不需要任何符号运算：

```
def root_locus_cross(num, den, k_hi=1e3, tol=1e-10):
    """二分求临界增益 K_max 与穿越频率 w_osc。

    前提：K=0 时闭环稳定（本例成立）。若 k_hi 处仍稳定，
    返回 (inf, nan)，说明该方向没有边界（见 §38.12.5 的讨论）。
    """
    num = np.asarray(num, float)
    den = np.asarray(den, float)

    def max_real(k):
        char = np.polyadd(den, k * num)
        return float(np.max(np.roots(char).real))

    if max_real(k_hi) <= 0:
        return np.inf, np.nan
    lo, hi = 0.0, k_hi
    while hi - lo > tol * max(1.0, hi):
        mid = 0.5 * (lo + hi)
        if max_real(mid) > 0:
            hi = mid
        else:
            lo = mid
    char = np.polyadd(den, hi * num)
    roots = np.roots(char)
    osc = roots[np.argmax(roots.real)]
    return float(hi), float(abs(osc.imag))
```

对三阶对象调用它，应得 `K_max≈4.40`、`w_osc≈6.3246`，与式 (39-13) 的解析解、与 §39.12.1 的 `w_180` 三者对上。这三个数来自三条互不相同的路径（Routh 递推、频响插值、多项式求根），它们一致，才说明对象没有写错、频段没有选错、代码没有抄错。

`tol` 取 10^{-10} 是相对容差，二分约 40 次即可收敛；`k_hi` 的默认值 10^3 对本例绰绰有余（$K_{\max} = 4.40$）。若换成 §38.4 的四阶对象，$K_{\max} = 3.30$ 仍在范围内，不用改。

这个函数有三处细节值得解释，因为它们决定了结果能不能用。

其一，判别量取 `max(Re)` 而不是“有没有右半平面根”。 布尔量只能告诉二分“这边稳、那边不稳”，收敛到的是**区间的中点**，误差取决于停机条件；而 `max(Re)` 是一个连续量，边界处它恰好过零，二分因此能同时给出

$K_{\max}$ 与穿越点所在的 s。`osc` 那一行取的就是这个根的虚部——在边界上它落在虚轴上，虚部即 ω_{osc}。

其二，`k_hi` 处仍稳定时返回 `inf` 不是偷懒。 二阶对象 $10K/[s(s+2)]$ 的闭环极点是 $-1 \pm \mathrm{j}\sqrt{10K-1}$，实部恒为 -1，`max_real` 对任何 K 都返回 -1，永远不穿零。这与 §39.7.5 的“$\zeta\omega_n = 1$ 与 K 无关”是同一件事：增益只能把极点往上推（虚部变大），推不到右半平面。遇到这种对象，正确的结论是“没有有限边界”，而不是“再往上扫一扫就能找到”。

其三，二分隐含“稳定性随 K 单调”这个前提。 本例成立；但对象若含右半平面零点或本身是条件稳定的（某个区间稳、再大又不稳），`max_real` 会多次过零，二分只能找到它碰到的第一个，可能把“先不稳、后又稳”的区间整个漏掉。遇到这类对象，正确做法是先粗扫一遍 K 的网格、看 `max_real` 过零几次，再对每个过零点各做一次二分。

39.12.5 延迟容忍与离散临界增益

延迟容忍直接由相位裕度换算，是一行代码：

$$T_{d,\max} = \frac{\varphi_M}{\omega_c} \tag{39-18}$$

```
def delay_margin(pm_deg, w_c):
    """相位裕度换算可容忍纯延迟 (s)。pm_deg 用度，w_c 用 rad/s。"""
    return np.deg2rad(pm_deg) / w_c
```

注意式 (39-18) 用的是**弧度**：$\varphi_M = 54.1^\circ$、$\omega_c = 1.26$ rad/s 时，$T_{d,\max} = 0.944/1.26 \approx 0.75$ s，正是表 39-6 里那一行。若误把度数直接代入，会得到 43 s，差 57 倍——这是工程计算里最常见的量纲事故。

还要交代一句：式 (39-18) 不是近似，是**精确解**。纯延迟只改相位、不改幅值，所以 ω_c 一个点都不动；边界条件就是 $\varphi(\omega_c) - \omega_c T_d = -180^\circ$，移项即得。这一点与 §39.10.6 的数字实现对看才有意思：那里 $T_{d,\max}$ 只能当估算用，因为 ZOH 与计算延迟同时改幅频与相频，ω_c 会跟着挪。**同一个公式，用在纯延迟上是恒等式，用在采样环节上只是近似**，差别就在“幅频动没动”。

离散侧的临界增益直接复用第 38 章的 ZOH 解析式（式 38-28a），不重复推导：

```
def kmax_discrete(Ts):
    """二阶 ZOH 离散闭环的临界增益：a0<1 给出上界。"""
    e = np.exp(-2.0 * Ts)
    return (1.0 - e) / (2.5 - 2.5 * e - 5.0 * Ts * e)
```

`Ts=0.1` 得 4.1378，与表 38-4 一致。注意这是**二阶对象**的闭式：三阶对象带执行器滞后时必须数值离散，§39.5.3 给出的同口径结果是 $T_s = 0.1$ 时 2.1437。把 `Ts` 一路调小，`kmax_discrete` 会按 $0.4/T_s$ 发散——这提醒读者：**采样不会消除稳定性上限，只会把它推远**。若 `Ts` 趋近于零而 `kmax_discrete` 反而收敛到某个有限值，说明公式抄错了（多半是漏了 `1-e^{-2Ts}` 这个因子）。

39.12.6 输出与正文的对应关系

六组输出与正文的对应见表 39-7。读者复现时按这张表逐行核对，任何一行对不上就先停下来查，不要继续往下跑。

表 39-7　输出组与正文的对应关系

输出组	函数	对应正文	核对要点
① 二阶对象裕度	`bode_margins`	§39.4.1、表 39-2 首行	`gm_db` 为 `inf`
② 三阶对象五档	`bode_margins` + `gain_margin_closed_form`	§39.4.2、表 39-2	`G_M·K` 恒为 4.40
③ 数圈与根数	`rhp_count` + `neg_real_crossings`	§39.2.1、§39.4.4	$N = Z - P$ 两侧一致
④ 穿越点	`root_locus_cross`	§39.4.3、式 (39-13)	$K_{\max} = 4.40$、$\omega = 6.3246$
⑤ 离散临界增益	`kmax_discrete`	§39.5.3、表 38-4	`Ts=0.1` 得 4.1378
⑥ 延迟容忍	`delay_margin`	§39.10.4、表 39-6	54.1° 与 1.26 得 0.75 s

复现时有四个注意点。

第一，`ct.margin` 对离散系统也能调用，但它返回的频率是**经双线性映射回连续域**的等效频率，不是 §39.5.4 里的 $\nu = \tan(\theta/2)$。两者差一个 $2/T_s$ 的尺度，混用会让“边界频率 6.222 rad/s”与“$\nu = 0.3215$”看起来互相矛盾。

第二，`rhp_count` 里的容差 `1e-9` 是给数值求根用的，不是判稳阈值。真实系统在边界上时根本不会恰好落在虚轴上，所以这个容差只影响“临界点附近那一位数字”，不影响结论。

第三，`neg_real_crossings` 的扫描范围必须覆盖相位穿越。默认 `1e-2` 到 `1e3` 对本例够用；若对象含很大的时间常数（比如 $\tau_a = 2$ s），ω_{180} 会低到 10^{-1} 量级，此时把下限降到 `1e-4`，否则会漏掉那个交点，`G_M` 会算成无穷大。

第四，表 39-2 的 ω_c 与 φ_M 两列由 `bode_margins` 生成，重跑时若末位差 0.1%，属正常（`ct.margin` 在离散网格上插值，网格点数不同就会有这点差异）。但 `G_M` 一列必须严格等于 `4.40/K`，因为它走的是解析路径，不存在插值误差——这一列出现尾数漂移，就说明 `gain_margin_closed_form` 里的对象参数被改过了。

39.12.7 换到自己的对象上：三个改动点

本章代码是围绕一个固定对象写的，换成读者手上的对象时，有三处必须同步改，漏一处就会出现“两个函数描述两个不同对象”的隐蔽错误。

第一处，`plant` 与 `plant_num_den` 必须一起改。 前者返回 `control` 的传递函数对象，供频响与阶跃使用；后者返回降幂系数数组，供 `np.roots` 与 `rhp_count` 使用。两者是同一个对象的两套写法，最典型的 bug 是只改了 `plant`，于是 Bode 图上的曲线与根轨迹算出的 $K_{\max}$ 对不上。检验办法很简单：在 `K=1` 处各算一次 ω_{180}，两个函数的结果应当完全一致。

第二处，`gain_margin_closed_form` 只对本章三阶对象成立。 它的 $\omega_{180} = \sqrt{2/\tau_a}$ 来自“两个滞后环节的相角之和恰为 90°”这个巧合；对象一旦变成四阶、或含延迟，这个闭式就失效。换对象后应当直接删掉它，改用 `neg_real_crossings` 数值找交点——数值法对任何对象都成立，代价只是少了一条独立校验路径。若仍想要一条解析校验，可以自己按“$\sum \arctan$ 之和等于 90°”重推一遍，推不出来就说明不存在闭式。

第三处，`kmax_discrete` 是二阶对象的闭式。 本章 §39.5.3 的三阶离散结果 2.1437 是数值二分出来的，不是套公式。换对象后要自己写二分：给定 T_s，对每个候选 K 做 `ct.c2d(..., 'zoh')`，算闭环极点最大模，用 `|z|max=1` 作为分界，二分十几步就能到四位有效数字。判别函数写成

```python
def zoh_kmax(G, Ts, lo=0.01, hi=100.0, iters=80):
    """ZOH 离散闭环的临界增益：二分使 max|z| 恰为 1。"""
    def unstable(K):
        gd = ct.c2d(K * G, Ts, method="zoh")
        cl = ct.feedback(gd, 1)
        return np.max(np.abs(ct.poles(cl))) > 1.0
    for _ in range(iters):
        mid = 0.5 * (lo + hi)
        if unstable(mid):
            hi = mid
        else:
            lo = mid
    return 0.5 * (lo + hi)
```

这段函数对任何连续对象都成立，包括带延迟的（先做 Padé 再离散）。它与 §39.5.3 的五个数据点可以对拍：$T_s = 0.02$ 应得 3.614，0.1 应得 2.144。

三处改完之后，先别急着扫参数，跑一遍 `main()` 看六组输出是否自洽：$G_M \cdot K$ 是否仍为常数、ω_{180} 是否与 K 无关、离散临界增益是否随 T_s 单调下降。这三条是对象的“指纹”，任何一条不成立，说明改动还没到位。

39.12.8 画图的五条口径

图是判据的产物，也是评审最先看的东西。`code/ch039_figs.py` 里有五条纪律，换对象画图时同样适用。

第一，频率网格每张图各取各的。 裕度图用 `np.logspace(-2, 2.5, 8000)`，Nyquist 与围线映射用 `logspace(-2, 3, 6000)`，五档 Bode 只用 `logspace(-1, 3, 6000)`。窄网格是为了让 0 dB 附近那条竖虚线看得清，宽网格是为了让高频尾巴收进画面。用一张图的网格去套另一张，不是漏掉穿越点，就是曲线末端顶在边框上。

第二，相位必须 `np.unwrap`。 直接 `np.angle` 得到的是 $(-\pi, \pi]$ 的折返值，ω_{180} 附近会出现从 -179° 跳到 $+179^\circ$ 的竖线，看上去像“相位穿了好几次”。图 39-3 与图 39-5 都在同一行做了展开，读者看到的是一条连续下降的曲线，-180° 线只被穿过一次。

第三，Nyquist 只画正频率，负频率靠镜像。 图 39-7 里每条实线是 ω 从 10^{-2} 到 10^{3} 的正频率段，虚线是它的共轭镜像。判据要的是整条闭合曲线，镜像不是装饰：省掉它再数圈，N 会少一半。离散版本（图 39-8）还要多一道手续，$z = \mathrm{e}^{\mathrm{j}\theta}$ 只取 $\theta \in (10^{-4},\ \pi - 10^{-4})$，两端各让开一点，因为 $\theta = 0$ 处 $z = 1$ 恰好是开环极点，$L(z) \to \infty$，直接代进去会算出 `inf` 并把坐标轴撑坏。

第四，坐标轴要等比例。 Nyquist 图的横纵轴单位都是“倍”，`set_aspect("equal")` 之后圆才是圆、距离才是距离；若把纵横轴各自拉伸，0.19 的最近距离在图上可能看起来比 0.40 还远，§39.4.5 的读数就全错了。Bode 图相反：横轴必须对数，纵轴必须线性，否则 -20 dB/十倍频的直线会画成曲线。

第五，文件名跟正文编号走，不跟函数定义顺序走。 脚本里 `fig_04_nyquist_k` 保存的是 `fig_039_07_nyquist_k.svg`，`fig_05_gm_inverse` 保存的是 `fig_039_04_gm_inverse.svg`——函数按绘制顺序编号，文件名按正文引用顺序编号，两者故意不同步。改图时以文件名为准：改错了会让正文引用到另一张图，而这种错在校对时极难发现，因为两张图都“长得像”控制图。

还有一条不属于绘图，但常和绘图一起出错：图内中文一律用纯文本、公式单独写 `$...$`，两者不塞进同一个字符串。`plot_styles.py` 的字体配置只对纯文本生效，混排的结果是公式里的字变成方框、中文部分却正常——这类问题在 PDF 里能看出来，在 SVG 预览里未必看得出来，于是最容易被留到最后才返工。

39.12.9 一次实跑的输出长什么样

把 `ch039_sim.py` 跑完，屏幕上打印六组数。原样抄在下面（只去掉分隔线），读者可以拿自己的输出逐行比对：

```
1) 二阶对象 L=10K/[s(s+2)]，K=2.2：增益裕度为无穷
   w_c=4.4823 rad/s  phi_M=24.05 deg  w_180=nan  G_M=inf
2) 三阶对象五档增益（表 39-2）
        K        w_c  phi_M/deg     G_M/dB     K/Kmax
     0.50     1.8346      42.23     18.890      0.114   (G_M 解析=8.8000)
     1.00     2.8461      27.00     12.869      0.227   (G_M 解析=4.4000)
     2.20     4.4242      11.85      6.021      0.500   (G_M 解析=2.0000)
     3.00     5.2059       6.43      3.327      0.682   (G_M 解析=1.4667)
     4.40     6.3246       0.00      0.000      1.000   (G_M 解析=1.0000)
3) Nyquist：负实轴交点和闭环右半平面根数
   K=1.0  Z=0  maxRe=-0.7370  交点: (w=6.3246, Re=-0.2273)
   K=2.2  Z=0  maxRe=-0.4537  交点: (w=6.3246, Re=-0.5000)
   K=5.0  Z=2  maxRe=0.1124  交点: (w=6.3246, Re=-1.1364)
4) 根轨迹穿越点（二分）
   K_max=4.4000  omega_osc=6.3246 rad/s
5) 离散 ZOH 采样后的临界增益（对照表 38-4）
   Ts=0.10 s: Kmax=4.1378
6) 延迟容忍与阶跃指标
   K=0.3  phi_M=54.06 deg  G_M=23.33 dB  Td_max=0.746 s  Mp=13.82%  ts=3.404 s
   K=2.2  phi_M=11.85 deg  G_M=6.02 dB  Td_max=0.047 s  Mp=71.38%  ts=8.453 s
```

第 1 组要先看对象与增益：这里用的是**二阶对象在 $K=2.2$** 时的数据（$\omega_c=4.4823$、$\varphi_M=24.05^\circ$），不是 §39.4.1 里 $K=1$ 那一档（2.863、34.9°）。同一对象换一档增益，两个读数全变，而 `w_180=nan` 与 `G_M=inf` 不变——这正好把“增益整条平移、相位不动”演示了一遍。

第 2 组最容易误读的是括号里的数：`(G_M 解析=8.8000)` 是**比值**不是 dB，$4.40/0.5=8.80$，取对数才是 18.89 dB。若有人把它当 dB 抄进验收表，会得出“增益裕度 8.8 dB”的错误结论，比真值少了 10.1 dB——在这条曲线上，少 10 dB 意味着少允许 3.2 倍增益。

第 3 组的三列是互相印证的：`交点` 的实部就是 $-1/G_M$，$K=5$ 时 -1.1364 与 $1/1.1364=0.88$（即 -1.11 dB）对应；`maxRe` 是闭环最右根的实部，$K=4.40$ 时为 0.0000、$K=5$ 时跳到 0.1124，说明轨迹确实在这一档之间过界；`Z` 从 0 跳到 2，一次跳两格，与“复根成对出界”一致。三列里任何一列单独看都可能被误读，摆在一起就堵住了。

第 4 组是二分与解析的对拍，四位有效数字全同。第 5 组只留了 $T_s=0.1$ 一行，其余四行见 §39.5.3；这一行是二阶闭式，与 §39.5.3 三阶数值的 2.144 不是同一个量（§39.5.3 已提醒过，两个对象的边界数值相近是巧合）。

第 6 组把裕度与时域接通：$K=0.3$ 的 54.06° 换成 0.746 s 的延迟容忍，$K=2.2$ 的 11.85° 只换得 0.047 s。两档的 φ_M 差 4.6 倍，$T_{d,\max}$ 却差 16 倍——因为换算里还除了一个 ω_c，而 ω_c 本身也涨了 3.5 倍。**“相位裕度掉了多少”与“延迟容忍掉了多少”永远不是同一个倍数**，汇报时若只给前者，容易让人低估后者的恶化速度。

第40章 根轨迹法

第 39 章把稳定性判据讲成了三张图：Nyquist 数圈、Bode 读裕度、根轨迹看走向。三张图里只有根轨迹是“以增益为横轴”的——它不回答“当前这点稳不稳”，而回答“增益一动，极点往哪儿跑”。这一章把这条线索单独展开：怎么画、怎么读、怎么用它改。

40.1 动机与直观理解

40.1.1 一个现场问题：增益还能拧多少

调试台上最常见的一句话是“再往上加一点看看”。加多少？加到什么程度会振？振起来以后是慢慢发散还是一下子飞掉？这三个问题，Bode 图能答，但要来回换算；根轨迹把答案画成一条线，一眼就能看到。

以本章从头用到尾的对象为例：$L(s)=10K/[s(s+2)(0.05s+1)]$，三个开环极点分别在 0、-2、-20。K 从 0 开始增大，三个闭环极点各自移动，画出的三条曲线就是根轨迹。曲线的形状只由开环零极点决定，与 K 无关；K 只决定“走到曲线的哪一点”。这个分工是整章的地基：**零极点定形状，增益定位置**。

40.1.2 从“极点在哪”到“极点往哪走”

第 37 章说过，闭环极点决定响应的形状：实极点给单调衰减，共轭对给振荡，实部决定衰减快慢，虚部决定振荡频率。第 38、39 章则给出了“当前 K 下极点在哪”的判据。根轨迹补的是第三件事——**极点随参数的走向**。

走向比位置更有用，原因有三。第一，位置是一个点，走向是一条线，线能告诉你“前面还有多远才到虚轴”，这就是增益裕度的几何版本。第二，走向能告诉你“哪个方向是安全的”：如果曲线一开始就往右走，那么任何增益增加都在恶化稳定，只能靠改结构。第三，走向能指导改结构：加一个零点，曲线整体向左弯；加一个极点，曲线向右压。改结构之前先看图，比改完再试要省事得多。

40.1.3 三项任务：判稳、定量、整形

根轨迹在工程上有三项任务，难度递增。

第一项是**判稳**：曲线有没有穿过虚轴？穿过时的 K 是多少？对本章对象，答案是 $K_{\max}=4.40$，穿越频率 6.3246 rad/s。这两个数与第 39 章用 Bode 和 Nyquist 算出来的完全一致，因为三者解的是同一个特征方程。

第二项是**定量**：给定 K，读极点，算阻尼比、自然频率，再换算超调与调节时间。$K=1$ 时主导极点是 $-0.737\pm \mathrm{j}3.033$，$\zeta=0.236$，实测超调 46.05%、调节时间 5.36 s。这一步把“图上的一点”翻译成“验收表上的一行”。

第三项是**整形**：如果现有轨迹怎么调都达不到指标，就加零点或极点把轨迹拉过去。加一个 $s=-1$ 的零点，本章对象的 $K_{\max}$ 从 4.40 变成无穷；加一个 $s=-5$ 的极点，$K_{\max}$ 掉到 5.28 且多出一个分离点。整形的本质是“改形状”，而形状只由零极点决定——这句话在整章会反复出现。

40.1.4 与第 39 章的分工

同一张 s 平面图，第 39 章用它“判”，本章用它“改”。分工可以写成一句话：**第 39 章问“现在稳不稳”，本章问“怎么让它更稳、更快、更准”**。

具体差别在三处。其一，第 39 章的根轨迹只是三个判据之一，用来交叉核对；本章把它当成主工具，Bode 与 Nyquist 退为校验。其二，第 39 章只用 K 作参数；本章还要用 τ_a、用零点位置、用采样周期作参数，这就是参数根轨迹。其三，第 39 章关心“临界”，本章关心“指标”——临界只是一个点，指标是一段区间。

两章共用的数必须对得上。本章的 $K_{\max} = 4.4000$、$\omega_{\text{osc}} = 6.3246$、分离点 -0.9737 与对应 $K = 0.0951$，全部由 `code\ch040_sim.py` 重算，与第 39 章逐位一致。**同一对象在不同章节给出不同的数，是写作事故，不是精度问题**，所以每次都要跑一遍而不是抄一遍。

40.1.5 读图三问

拿到一张根轨迹，先问三个问题，顺序不能乱。

第一问：**起点在哪**？起点是 $K = 0$ 时的闭环极点，也就是开环极点。本章对象是 0、-2、-20，所以三条支路分别从这三点出发。

第二问：**终点在哪**？终点是 $K \to \infty$ 时的位置：m 条支路终止于开环零点，其余 $n - m$ 条沿渐近线奔向无穷远。本章对象没有零点，所以三条都奔向无穷——两条沿 $\pm 60^\circ$，一条沿 180°。

第三问：**往哪拐**？拐点就是分离点、会合点、虚轴穿越点。本章对象在 -0.974 处分离（$K = 0.0951$），在 $\pm \mathrm{j}6.32$ 处穿越虚轴（$K = 4.40$）。这两个位置把整条轨迹分成三段：分离前是三个实极点，分离后是一对共轭加一个实极点，穿越后共轭对进入右半平面。

三问答完，图就读完了。其余的细节（出射角、渐近线角度）都是补充，不影响主要结论。

40.1.6 为什么“试凑”不够

有人会说：不就是调一个增益吗，现场拧一拧、看波形，总能找到合适的值。对二阶、单回路、无延迟的系统，这话基本成立。但只要出现下面三种情况之一，试凑就会失效。

第一种，不知道天花板在哪。 试凑只能告诉你“现在这个值会振”，不能告诉你“再往下还有多少空间”。本章对象的名义临界增益是 4.4000，而“好用的上限”大约只有 0.39（$M_p = 19.90\%$）——**两者差了 11 倍**。若靠试凑，很可能在 0.4 附近就以为“快到头了”，实际上再往上还能走，只是超调不再可接受。反过来，若对象本身只有一个很窄的可用区间，试凑会在区间里反复横跳，永远说不清边界在哪。

第二种，增益不是唯一的旋钮。 天花板不只由对象决定，还由采样周期与延迟决定。同一个对象，连续域是 4.4000，$T_s = 0.1$ s 离散后是 2.1437，再加一拍延迟是 1.0785。**换一块控制器、加一段总线，天花板就变了**，而试凑给出的“经验值”是绑在旧硬件上的，换硬件就得重来。

第三种，“形状”问题试凑不出来。 当上升时间与超调被同一条轨迹绑死时，再怎么调 K 都是在一条曲线上滑动，两个指标此消彼长。本章 §40.9.8 的例子很典型：原轨迹上 $M_p = 20\%$ 时 $t_s = 4.30$ s，怎么调都降不到 3 s；加一只超前网络后，$M_p = 7.22\%$ 时 $t_s = 2.71$ s。**这不是“没调好”，是“结构不够”。** 试凑永远不会告诉你“该加一个零点”。

根轨迹法要解决的正是这三件事：给天花板（$K_{\max}$）、给天花板的两个修正项（采样与延迟）、给形状的自由度（零极点）。它不保证一定有好答案，但它能让你在动手之前就知道**有没有答案、答案在哪个方向**。

40.2 数学原理

40.2.1 特征方程怎么变成两个条件

闭环特征方程是

$$1 + K\,G_0(s) = 0 \tag{40-1}$$

其中 $G_0(s)$ 是“单位增益”的开环传递函数，K 单独提出来当参数。把 G_0 写成零极点形式 $G_0(s) = K_g \prod(s - z_i) / \prod(s - p_j)$，式 (40-1) 就变成

$$\prod_{j=1}^{n}(s - p_j) + K K_g \prod_{i=1}^{m}(s - z_i) = 0 \tag{40-2}$$

这是一个关于 s 的复系数（实际是实系数）多项式方程。**根轨迹就是“K 从 0 到 ∞ 时，这个方程的根在复平面上的轨迹”**。因为系数是实数，根必然共轭成对出现，所以轨迹关于实轴对称——这是画图时最省事的一条性质。

40.2.2 相角条件：轨迹的形状只由角度决定

式 (40-1) 是一个复数等式，可以拆成模与角两个条件。角条件先看：

$$\sum_{i=1}^{m} \angle(s - z_i) - \sum_{j=1}^{n} \angle(s - p_j) = (2k + 1)180^\circ \tag{40-3}$$

这个条件里**没有** K。这就是“形状与增益无关”的数学根源：一个点是否在轨迹上，只看它到各零极点的连线角度，与增益大小无关。K 只出现在模条件里，决定“走到这个点时 K 等于多少”。

图 40-1 把这件事画成了几何：取 $K = 1$ 时的闭环极点 $s_0 = -0.737 + \mathrm{j}3.033$，从三个开环极点各引一条向量到 s_0，三者的相角分别是 103.7°、67.4°、9.0°，和为 180.1°——正好满足式 (40-3)（舍入误差 0.1° 来自极点只保留三位小数）。

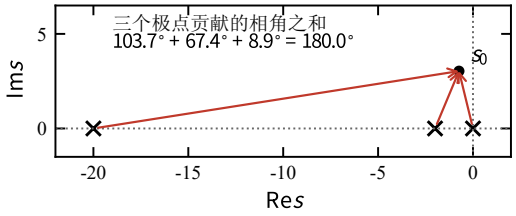

图 40-1　相角条件：三条向量的相角和等于 180°

读这张图有一个容易忽略的细节：**相角是带符号的**。极点在分母，贡献负角；零点在分子，贡献正角。式 (40-3) 写成“零点和减极点和”，等价于“极点贡献负角”的写法。手算时若把符号写反，整条轨迹会关于实轴翻到另一侧，而且看上去“也挺像”——这是手绘根轨迹最常见的错误。

40.2.3 模值条件：增益怎么标定

回到式 (40-1) 的模：

$$K=\frac{\prod_{j=1}^{n}|s-p_j|}{K_g\prod_{i=1}^{m}|s-z_i|}\tag{40-4}$$

本对象写成首一形式更方便：$G_0(s)=200/[s(s+2)(s+20)]$，所以 $K_g=200$，代入式 (40-4) 得

$$K=\frac{|s|\,|s+2|\,|s+20|}{200}\tag{40-5}$$

用 $K=1$ 的极点验一下：$|s_0|=3.121$，$|s_0+2|=3.281$，$|s_0+20|=20.238$，三者之积 207.3，除以 200 得 1.037，与 $K=1$ 差 3.7%。这个差不是公式错，而是 s_0 只保留了三位小数：把极点取到六位再算，结果会收敛到 1.0000。**模值条件是精确的，误差全在读数上。**

工程上这条式子的用处是“沿轨迹标 K”：先按相角条件画出形状，再在每个点上用式 (40-5) 算 K，把 K 标在曲线旁边，图就完整了。图 40-3 就是这么标的。

40.2.4 为什么 n 条支路、为什么对称

特征方程是 n 次多项式（n 为开环极点数），所以有 n 个根，n 条支路。这条结论看似平凡，却解释了一个常见疑问：为什么加一个极点会“多出一条支路”？因为多项式次数加一，根就多一个，多出来的那条支路必须从新极点出发、沿某条渐近线奔向无穷。

对称性来自实系数：若 s 是根，则 $\bar{s}$ 也是根。所以轨迹要么落在实轴上，要么成对出现在上下半平面。画图时只需算上半平面，下半平面镜像即可——图 40-2 到图 40-6 都用了这条省事的做法。

$K\to\infty$ 时的行为由分子分母的次数差决定。$n-m$ 条支路趋向无穷，方向由渐近线给出：

$$\sigma_a=\frac{\sum p_j-\sum z_i}{n-m},\qquad \theta_k=\frac{(2k+1)180^\circ}{n-m}\tag{40-6}$$

本对象 $n=3$、$m=0$，故 $\sigma_a=(0-2-20)/3=-7.333$，三条渐近线角度为 60°、-60°、180°。这三个数与实跑输出完全一致，也是图 40-2 里那三条虚线的来历。

40.2.5 根轨迹与 Routh 判据的等价性

有人会问：既然 Routh 表能判稳，为什么还要画轨迹？答案是两者回答的问题不同，但在“临界”这一点上必须一致。

Routh 判据给的是“给定 K，特征多项式有没有右半平面根”，输出是一个是非；把 K 当符号，还能解出临界 K 的表达式。根轨迹给的是“K 变化时根怎么走”，输出是一条曲线。在临界点上，两者必然重合：Routh 的临界 K 就是轨迹穿虚轴时的 K，临界振荡频率就是穿越点的虚部。

对本章对象，第 38 章的 Routh 计算给出 $K_{\text{max}}=4.40$、$\omega_{\text{osc}}=6.3246$；本章的数值轨迹给出 4.4000 与 6.3246。两条完全不同的路径（符号消元 vs 多项式求根扫描）给出同一个数，这才叫验证。**只跑一条路径得到的数，只能叫“算出来了”，不能叫“对了”。**

40.2.6 相角条件的三条边界

式 (40-3) 与式 (40-4) 只有一行，用错的地方却集中在三处。这三处都不是数学难点，而是“适用范围”被忽略。

第一，相角条件只管“在不在”，不管“稳不稳”。 满足相角条件的点，只说明“存在某个 $K>0$ 使闭环极点落在这里”，不说明这个点好不好、更不说明系统稳定。轨迹可以整条躺在右半平面，上面每一点都满足相角条件。**判稳要另看位置，判好坏要另算指标**，三件事不能混。

第二，180° 只对“负反馈 + $K>0$”成立。 特征方程写成 $1+KG=0$ 时，$KG=-1$，相角是 $\pm 180^\circ$。若 $K<0$，-1 变成 $+1$，条件改为 0°；若是正反馈，特征方程本来就是 $1-KG=0$，条件同样是 0°。这就是 §40.11.3 的零度根轨迹。**换了反馈极性却仍按 180° 画，图会整体错位**——不是细节错，是形状错。

第三，手算角度必须用 atan2，不能只用 arctan。 $\arctan$ 的值域是 $(-90^\circ, 90^\circ)$，它分不清第二、第三象限。向量 $s-p_j$ 落在左半平面时，真实角度可能是 180° 附近的负角，用 $\arctan$ 会得到相反符号的小角，总和差出 360° 的整数倍。编程时用 `np.angle`，手算时先画箭头再定象限，这是唯一可靠的做法。

下面用两个点验证这三条。

先看分离点 $s=-0.9737$。三个极点向量分别是：从 0 指向该点，方向沿负实轴，角度 180°；从 -2 指向该点，方向沿正实轴，角度 0°；从 -20 指向该点，同样是 0°。总和 180°，满足条件，所以它确实在轨迹上。

再看 $s=-1+\mathrm{j}2$。三个角度是

$$\angle(-1+\mathrm{j}2)=116.565^\circ,\quad \angle(1+\mathrm{j}2)=63.435^\circ,\quad \angle(19+\mathrm{j}2)=6.009^\circ$$

总和 186.009°，比 180° 多出 6.0°。**这一点不在轨迹上。** 多出的角为正，说明该点“偏高”——上半平面的支路从它下方经过。这个判断不需要画图，也不需要求根，三次反三角函数就能得出，是手绘时最常用的自检手段。

40.2.7 三个不变量：用来验算的硬约束

根轨迹是一条会动的曲线，但曲线上有三个量始终不动。它们不是近似的经验，而是韦达定理的直接推论，**任何一条算错的轨迹都会被它们当场抓住。**

把特征方程写成首一形式。本章对象是

$$s^3+22s^2+40s+200K=0$$

三个根 s_1,s_2,s_3 与系数的关系是

$$s_1+s_2+s_3=-22,\qquad s_1s_2+s_2s_3+s_3s_1=40,\qquad s_1s_2s_3=-200K$$

第一条最有用：**三个根之和恒等于 -22，与 K 无关。** 这意味着轨迹不是三条各自独立的曲线，它们被一根无形的绳子拴着——一个根往右走，另外两个的实部之和就必须往左补。

用表 40-3 的数据核对。$K=0.2436$ 时主导对是 $-0.9333\pm\mathrm{j}1.2445$，第三极是 -20.1334，三者实部相加 $-0.9333-0.9333-20.1334=-22.000$。$K=0.3888$ 时是 $-0.8944-0.8944-20.2113=-22.000$。**每一档都能对上，说明数值解没有跑偏。**

第二条给出一个反直觉的结论：**加零点不改变根之和，加极点才改变。** 加零点 -1 后特征方程是 $s^3+22s^2+(40+200K)s+200K=0$，二次项系数仍是 22，所以根之和仍是 -22；加极点 -5 后特征方程多一个 $(s+5)$ 因子，二次项系数变成 27，根之和变成 -27。这正好解释了 §40.9.7 里“加极点后渐近线交点从 -7.33 移到 -6.75”——交点是根之和除以 n，分子分母同时变了。

第三条最有工程价值。第三极在整个设计区间里都非常稳定：$K=0.1446$ 时 -20.0797，$K=0.3888$ 时 -20.2113，$K=0.7332$ 时 -20.3910。它几乎钉在 -20 附近不动。把 $s_3\approx-20.2$ 代进第三条：

$$|s_1s_2|\approx\frac{200K}{20.2}\approx 9.9K$$

而 s_1,s_2 是一对共轭根，$|s_1s_2|=|s_1|^2=\omega_n^2$。于是

$$\omega_n \approx \sqrt{10K}$$

这是一个只用乘法就能核对的近似。$K=0.2436$ 时 $\sqrt{2.436}=1.5608$，实测 $\omega_n=1.5556$，差 0.3%；$K=0.3888$ 时 $\sqrt{3.888}=1.9718$，实测 1.9615，差 0.5%。**在这个对象上，自然频率几乎完全由增益决定，与零极点的细微位置无关。**

这条近似把“两个指标被绑死”从一句感慨变成了公式：想要更快的响应，就要更大的 ω_n，就要更大的 K；而 $\zeta=-\sigma/\omega_n$，σ 随 K 增大而减小，ω_n 随 K 增大而增大，**两者相除，ζ 必然单调下降**。换句话说，在 $n-m=3$ 且第三极远置的对象上，“又快又稳”在单增益下无解，这不是调参水平问题，是代数结构决定的。

三条不变量还有一个实用价值：**它们让手算与程序可以互相验算**。程序给出根之后，先把三个实部加起来看是不是 -22，再把三个根乘起来看是不是 $-200K$。两条都对，才说明求根没有数值问题；有一条不对，多半是多项式系数写错了（例如把 $0.05s+1$ 展开成 $0.05s+0.05$）。这一步只需两行代码，却能挡掉大部分低级错误。

40.3 设计步骤：八条绘图规则

40.3.1 规则总表

手绘根轨迹有一套成熟的规则，八条足够应付绝大多数对象。表 40-1 是总表，后面六小节逐条解释。

表 40-1 根轨迹的八条绘图规则

序号	规则	依据
1	起点为开环极点，n 条支路	$K=0$ 时式 (40-2) 退化为 $\prod(s-p_j)=0$
2	终点为开环零点或无穷远	$K\to\infty$ 时由分子决定
3	关于实轴对称	特征多项式为实系数
4	实轴上的段：右侧零极点总数为奇数	相角条件在实轴上的特例
5	$n-m$ 条渐近线，交于 σ_a	式 (40-6)
6	分离 / 会合点满足 $\mathrm{d}K/\mathrm{d}s=0$	重根条件
7	虚轴穿越点由 $s=\mathrm{j}\omega$ 代入求得	临界稳定
8	复极点出射角由相角条件补足	式 (40-3) 在出射点的特例

40.3.2 起点、终点与对称性

前三条规则是“骨架”，一句话就能记住：**从极点出发，到零点结束，走不到零点的奔向无穷**。

“从极点出发”的证明只需令 $K=0$：式 (40-2) 变成 $\prod(s-p_j)=0$，根就是 p_j。“到零点结束”令 $K\to\infty$：两边除以 K，主项变成 $K_g\prod(s-z_i)=0$，根趋于 z_i。若零点数少于极点数，多出的 $n-m$ 个根必须跑到无穷远，因为多项式次数差没有别的去处。

对称性不是“近似成立”，而是严格成立：实系数多项式的复根必成共轭对。这一条在数值计算里也有用——若算出的根不共轭，说明数值精度出了问题，而不是对象有什么特殊性质。本章代码在求根后不做任何对称化处理，输出的虚部天然成对，正是这个道理。

40.3.3 实轴上的段

实轴规则是八条里最容易被记错的一条：**某段实轴属于轨迹，当且仅当它右侧的实数零极点总数为奇数**。

用本章对象验：极点在 0、-2、-20。区间 $(-2,0)$ 右侧有一个极点（0），奇数，属于轨迹；区间 $(-20,-2)$ 右侧有三个（0、-2 与区间内的？注意“右侧”指该段右侧的全部零极点），实际是 0 与 -2 两个，再加 -20 本身在左端不算，所以是 2 个，偶数，不属于；区间 $(-\infty,-20)$ 右侧有 3 个，奇数，属于。

所以轨迹只占 $(-2,0)$ 与 $(-20,-\infty)$ 两段。这与图 40-2 一致：0 与 -2 之间的两个极点相向而行，在 -0.974 相遇后离开实轴；而 -20 那条支路沿实轴一直向左，直到 -22 附近才与另一条从上方下来的支路在无穷远处汇合（实际上它沿 180° 渐近线直接走向 $-\infty$）。

实轴规则为什么是“奇数”？因为实轴上每对共轭零点或极点对该点的相角贡献相互抵消（一上一下，角度互为相反数），只有实数零极点有净贡献。右侧每有一个实数零极点，角度贡献 180°；要凑成 180° 的奇数倍，右侧的个数必须是奇数。

40.3.4 渐近线：$n-m$ 条射线

渐近线由式 (40-6) 给出。本章对象 $\sigma_a=-7.333$，角度 $\pm60^\circ$ 与 180°，三条射线从 -7.333 出发。

一个常见的误读是“渐近线交点在轨迹上”。不在。σ_a 只是三条射线的公共起点，轨迹本身并不经过它——180° 那条射线沿实轴向左，$\pm60^\circ$ 两条向斜上方与斜下方，三者在 σ_a 处相交但轨迹在那里没有根。想验证也简单：把 $s=-7.333$ 代入式 (40-5)，得 $K=7.333\times5.333\times12.667/200=2.48$，说明这一点确实“有对应的 K”，但它不满足相角条件，所以不是闭环极点。**模值条件对平面上任意一点都能算出一个 K，只有同时满足相角条件的点才是根**——这句话解释了为什么不能只用模值条件画图。

40.3.5 分离点与会合点

分离点是两条支路在实轴上相遇后离开实轴的位置。数学上它是特征方程的重根，因此满足

$$\frac{\mathrm{d}K}{\mathrm{d}s}=0 \quad\Longleftrightarrow\quad N(s)D'(s)-N'(s)D(s)=0 \tag{40-7}$$

其中 D、N 分别是 G_0 的分母与分子多项式。对本章对象，$N=200$（常数），$D=s(s+2)(s+20)=s^3+22s^2+40s$，于是

$$D'(s)=3s^2+44s+40=0 \tag{40-8}$$

解出 $s=-0.9737$ 与 $s=-13.67$。前者对应 $K=0.0951$（代入式 40-5：$0.974\times1.026\times19.03/200=0.0951$），是真实分离点；后者对应 $K=-0.668$，负增益，不在 $K>0$ 的轨迹上。

判别哪个根有效的方法就是算 K：只有 $K>0$ 的才是根轨迹上的点。很多教材只给“分离点满足 $\mathrm{d}K/\mathrm{d}s=0$”，不强调这一句，学生就会把 -13.67 也画上去。

分离点的物理含义是“临界阻尼”：$K<0.0951$ 时两个实极点分开，系统过阻尼、无超调；$K=0.0951$ 时两极点重合，临界阻尼；$K>0.0951$ 时变成共轭对，开始有超调。实跑数据支撑这一点：$K=0.0951$ 时超调为 -0.00%（数值零），配对极点 $-0.974\pm0.019\mathrm{j}$——虚部只剩 0.019，正是“刚好要分叉”的状态。

40.3.6 虚轴穿越：把 $s=\mathrm{j}\omega$ 代进去

穿越点由 $1+KG_0(\mathrm{j}\omega)=0$ 给出，等价于“相角 -180° 且模值为 1”。两条路可以走：一条是 Routh 表令某行全零，一条是直接把 $s=\mathrm{j}\omega$ 代入、分开实虚部。

代入前必须先做一件事：**把分母首一化**。$G_0(s)=10/[s(s+2)(0.05s+1)]=200/[s(s+2)(s+20)]$，分母是 $D(s)=s^3+22s^2+40s$。令 $s=\mathrm{j}\omega$：

$$D(\mathrm{j}\omega)=-\mathrm{j}\omega^3-22\omega^2+40\mathrm{j}\omega=-22\omega^2+\mathrm{j}\left(40\omega-\omega^3\right) \tag{40-9}$$

由式 (40-1)，$D(\mathrm{j}\omega)=-200K$ 必须是实数，所以虚部为零：

$$40\omega-\omega^3=0 \quad\Longrightarrow\quad \omega=\sqrt{40}=6.3246\ \mathrm{rad/s} \tag{40-10}$$

代回实部得 $-22\times 40=-880=-200K$，即 $K_{\max}=4.40$。这两个数与第 38 章的 Routh 临界值、第 39 章的 Nyquist 交点完全一致。

这里有一个差整倍数的高频错误：若图省事直接用带 0.05 的分母 $0.05s^3+1.1s^2+2s$ 去算实部，会得到 $K=0.22$，正好差 $1/0.05=20$ 倍。原因是那个分母没有首一化，而分子仍是 10——两个式子描述的不是同一个 G_0。**规矩很简单：先把分母首一化，再代 $\mathrm{j}\omega$，最后按首一化后的分子定 K**。差整倍数的结果最容易被当成舍入误差放过，所以每次算完都要用“临界 K 的量级对不对”回头核一遍。

40.3.7 出射角与入射角

复极点处的出射角由式 (40-3) 在出射点取极限得到：

$$\varphi_d=180^\circ+\sum_{i}\angle(p_d-z_i)-\sum_{j\neq d}\angle(p_d-p_j) \tag{40-11}$$

本章对象没有复极点，所以这一条暂时用不上。但它在下节要讲的一个变体里会用：加零点后可能出现复极点，出射角就不再是 90°，而是 90° 加减一个修正量。第 39 章 §39.2.4 提过同一件事，这里给出公式形式。

40.3.8 手绘与数值：两张图对照

按前七条规则可以手绘出草图，图 40-2 是数值计算的精确版，两者应当一致。

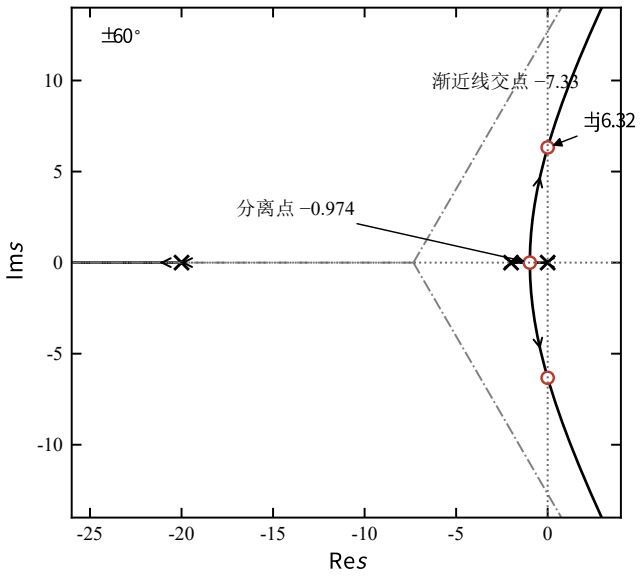

图 40-2　主例根轨迹全图

对照时看三处。第一，起点：三个 “×” 在 0、-2、-20，与手绘一致。第二，分离点：-0.974 处两支分开，向上向下各走一条，与 $\mathrm{d}K/\mathrm{d}s=0$ 的解一致。第三，渐近线：三条虚线从 -7.333 出发，角度 $\pm 60^\circ$ 与 180°，

数值轨迹最终贴着它们走。

手绘与数值的差别只在“细节精度”：手绘给不出精确的分离点坐标，也给不出穿越频率的数值，但能给出形状与趋势；数值给得出精确值，却看不出“为什么长这样”。**两张图都要有**——这是第 39 章反复强调的“两条路径互校”在本章的延续。

图 40-3 是同一张图的“标 K”版本，五个红点对应 $K = 0.0951$、0.3、1、2.2、4.4。

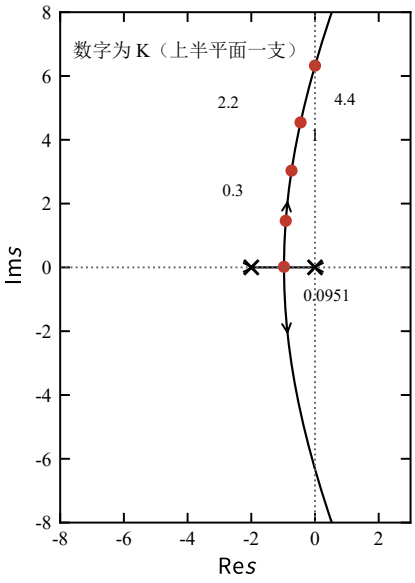

图 40-3　轨迹上五档增益的位置

这张图值得多看一会儿：$K = 0.0951$ 与 $K = 0.3$ 两点离得很近（都在分离点附近），而 $K = 2.2$ 到 $K = 4.4$ 之间跨了很大一段弧。这说明**增益与极点位置不是线性关系**——靠近虚轴时，同样的 ΔK 会把极点推很远；靠近分离点时，ΔK 再大极点也不怎么动。这条非线性正是“增益调到临界附近特别敏感”的几何解释。

40.3.9 从零手算一遍

规则看过一遍不等于会用。这一小节把八条规则串起来，只用纸笔和计算器，把本章对象的轨迹画出来，每一步都给出可以核对的数。

第一步，定点。 开环极点 0、-2、-20，三个。没有开环零点。所以三条支路，三个起点，终点全在无穷远。

第二步，画实轴段。 规则是“某点右侧的实零极点总数为奇数”。在 $(-2, 0)$ 内取 $s = -1$，右侧只有 0 这一个极点，奇数，所以在段上。在 $(-\infty, -20)$ 内取 $s = -30$，右侧有三个极点，奇数，也在段上。在 $(-20, -2)$ 内取 $s = -10$，右侧有 -2 与 0 两个，偶数，不在段上。结论：实轴上有两段，$(-2, 0)$ 与 $(-\infty, -20)$。

第三步，画渐近线。 $n - m = 3$，交点

$$\sigma_a = \frac{0 - 2 - 20}{3} = -7.3333$$

三条射线的角度是 60°、-60°、180°。画法是：从 $(-7.3333, 0)$ 出发，一条沿负实轴向左，两条以 $\pm 60^\circ$ 斜出。

第四步，找分离点。 分离点满足 $\mathrm{d}K/\mathrm{d}s = 0$。把式 (40-5) 的 K 对 s 求导并令其为零，等价于

$$N(s)D'(s)-D(s)N'(s)=0$$

本对象 N 是常数，式子退化为 $D'(s)=0$，即 $3s^2+44s+40=0$。两个根是 -0.9737 与 -13.6930。后者在 $(-20,-2)$ 段上，而那段不在轨迹上，舍去。所以分离点只有 $s=-0.9737$ 一个，代回模值条件得 $K=0.0951$。

第五步，找虚轴穿越点。 令 $s=\mathrm{j}\omega$ 代入 $s^3+22s^2+40s+200K=0$，实部虚部分开：

$$-\omega^3+40\omega=0,\qquad -22\omega^2+200K=0$$

第一式给出 $\omega=6.3246$（舍去 $\omega=0$），第二式给出 $K=22\times 40/200=4.4000$。穿越点是 $\pm\mathrm{j}6.3246$，临界增益 4.4000。

第六步，标增益。 在若干点上用 $K=|s||s+2||s+20|/200$ 算 K，写在曲线旁。这一步不需要精确，只要标出 0.1、0.25、0.5、1 几个量级的位置，图就能读了。

到这里，一幅可用的根轨迹就画完了。**全程只用了四则运算、一次二次求根和一次三次方程降阶，没有解任何三次以上的方程**——这正是绘图规则的价值：把“解多项式”换成“画几何”。

手算的用处不止是“没有计算机时凑合”。它的真正价值是**给你一个独立的核对源**。数值程序出图之后，用这六步抽查三个数：渐近线交点是不是 -7.3333、分离点是不是 -0.9737、穿越频率是不是 6.3246。三个都对，才敢相信图上其余部分；有一个不对，说明程序里的多项式系数写错了。第 40.12 节的自查清单就是按这个思路列的。

还有一处容易漏：**分离点的 K 必须代回验证**。$D'(s)=0$ 只保证“这里可能出现重根”，不保证对应的 K 为正。若算出的 $K<0$，说明该点是“会合点”但对应负增益，在 $K>0$ 的轨迹上不存在。本对象两个根中，-13.6930 的 K 就是负的，所以被舍去——这一步不能省。

40.3.10 形状由 $n-m$ 决定：四种典型

八条规则里，真正决定“整张图长什么样”的只有一条：**极点数与零点数之差 $n-m$**。它决定渐近线的条数与角度，也就决定了轨迹“往哪走、会不会碰虚轴”。

原因在 $K\to\infty$ 时的近似。特征方程 $D(s)+KN(s)=0$ 中，s 很大时低阶项可忽略，只剩 $s^n+Kbs^m\approx 0$，即 $s^{n-m}\approx -Kb$。$n-m$ 个根均匀分布在一个圆上，角度由 $-Kb$ 的辐角平分成 $n-m$ 份。这就是式 (40-6) 的来源，也是下面四种形状的来历。

$n-m=1$：一条渐近线，沿 180° 向左。 只有一条支路奔向负无穷，其余 m 条终止于零点。这种系统**对任意 $K>0$ 都稳定**（前提是没有右半平面极点与零点），$K_{\max}=\infty$。典型例子是“两个极点、一个零点”的对象，例如 $G=(s+3)/[s(s+1)]$。工程上这意味着一件事：**只要加一个合适的零点把 $n-m$ 降到 1，稳定性就不再是约束**，剩下的约束全是性能与噪声。

$n-m=2$：两条渐近线，垂直向上向下。 交点 σ_a 是唯一的判据：$\sigma_a<0$ 时两条支路沿垂直线上升，永远碰不到虚轴，$K_{\max}=\infty$；$\sigma_a>0$ 时反过来，**对任意 $K>0$ 都不稳定**。本章加零点 -4 的情形就是前者：$\sigma_a=-9$，组 3 给出的 $K_{\max}$ 是 `inf`。加零点 -1 给出 $\sigma_a=-10.5$，同样是 `inf`。**这两个 `inf` 不是数值算不出来，是几何上确实碰不到。**

$n-m=3$：三条渐近线，$\pm 60^\circ$ 与 180°。 两条斜线必然穿过虚轴，所以 $K_{\max}$ 一定有限。本章主例就是这一类：$\sigma_a=-7.3333$，穿越点 $\pm\mathrm{j}6.3246$，$K_{\max}=4.4000$。三阶对象是**“有天花板”的典型**，工程上最常见。

$n-m\geq 4$：**四条以上渐近线，$\pm 45^\circ$ 起。** 斜线更平，穿越虚轴更早，$K_{\max}$ 通常更小。这类对象单靠增益几乎不可能好用，必须整形把 $n-m$ 降下来。

把这四种放在一起，能看出一条设计原则：**整形的一个重要目标，就是把 $n-m$ 从 3 降到 2 或 1。** 加零点正好做这件事——每加一个零点，$n-m$ 减一，渐近线少一条，轨迹从“必然穿越”变成“可能不穿越”。这也解释了 §40.9.2 里那两个 `inf` 为什么来得那么轻松：**不是增益调得好，是几何结构变了。**

反过来，加极点会把 $n-m$ 抬高，渐近线多一条，稳定性更差。§40.9.3 里加极点 -5 后 $n-m=4$，归一化 $K_{\max}$ 掉到 1.0357，正是这个道理。

40.4 连续情形

前三节把规则讲完了，但规则只回答“轨迹长什么样”，不回答“某个 K 上系统到底有多快、超调多大”。这一节把轨迹当成一把尺子，沿着它一格一格量下去。量的对象仍是本章的主例 $G_0(s)=10/[s(s+2)(0.05s+1)]$，量出来的每一个数都来自 `code/ch040_sim.py` 的组 1、组 2 与组 5。

本节要建立的习惯是：**先看轨迹的几何，再看指标的数值，最后把两者对上。**只看数值会得到一堆孤立的百分数，只看几何则说不出“到底能不能用”。

40.4.1 三个解析要素先钉死

组 1 的输出把这张图的“骨架”算了出来，列在表 40-2。

表 40-2　主例根轨迹的解析要素（$G_0=10/[s(s+2)(0.05s+1)]$，首一化后分母 s^3+22s^2+40s）

要素	数值	来源
开环极点	0、-2、-20	分母因式分解
渐近线交点 σ_a	-7.3333	$(0-2-20)/3$
渐近线夹角	$\pm 60^\circ$、180°	$(2q+1)180^\circ/3$
分离点	$s=-0.9737$	$\mathrm{d}K/\mathrm{d}s=0$
分离点处增益	$K=0.0951$	模值条件
临界增益	$K_{\max}=4.4000$	虚轴穿越
临界振荡频率	$\omega_{\mathrm{osc}}=6.3246$ rad/s	虚部为零
临界增益下的三个根	-22、$\pm \mathrm{j}6.3246$	回代

表里有两处值得停一下。

第一处是 $\sigma_a=-7.3333$ 与“极点之和等于 -22”是同一件事。首一化分母 s^3+22s^2+40s 的二次项系数是 22，由韦达定理，三个闭环极点之和恒为 -22，与 K 无关。所以 $\sigma_a=-22/3=-7.3333$ 不是巧合，而是“重心不动”的代数表述。这条不变量在后面核对数值时非常有用：无论 K 取多少，三个根加起来必须等于 -22。表 40-3 里 $K=2.2$ 那一行，$-21.093+(-0.454)\times 2=-22.001$，四舍五入的误差而已。

第二处是临界增益下的第三个根在 -22，而不是它出发的地方 -20。这说明**临界时刻第三个极点已经向左挪了 2 rad/s**。它的移动量在整个 $K\in(0,4.4)$ 区间里只有 2，而主导极点对从 -0.974 一路走到虚轴，移动量超

过 6。这就是“主导”二字的量化含义：同一段时间里，慢的那一对走了三倍的距离。

40.4.2 五档增益沿着同一条轨迹走

把 K 取五档，每一档都解一次闭环特征方程，得到表 40-3。五个 K 值不是随手挑的：0.0951 是分离点，0.3 是第 39 章 §39.7.5 找到的 t_s 谷底，1 是“单位增益”这个默认起点，2.2 是第 39 章 §39.6 的超调敏感点，4.4 是临界。

表 40-3　沿轨迹五档增益的极点位置与时域指标

K	闭环极点	ζ	ω_n/(rad/s)	M_p/%	t_s/s
0.0951	-20.053，$-0.974 \pm \mathrm{j}0.019$	0.9998	0.9739	-0.00	6.04
0.3000	-20.164，$-0.918 \pm \mathrm{j}1.460$	0.5322	1.7250	13.82	3.40
1.0000	-20.526，$-0.737 \pm \mathrm{j}3.033$	0.2361	3.1215	46.05	5.36
2.2000	-21.093，$-0.454 \pm \mathrm{j}4.545$	0.0993	4.5673	71.38	8.45
4.4000	-22.000，$0 \pm \mathrm{j}6.325$	0.0000	6.3246	115.35	—

阻尼比与自然频率不是另外算的，就是极点的极坐标变换：

$$\zeta = -\frac{\operatorname{Re} s}{|s|}, \qquad \omega_n = |s| \tag{40-12}$$

以 $K = 0.3$ 为例，$|s| = \sqrt{0.918^2 + 1.460^2} = 1.725$，$\zeta = 0.918/1.725 = 0.5322$。这两个数与第 39 章 §39.6.4 用“三档 ζ”那一组完全一致（0.5322、0.2361、0.0993），说明两条路径——一条从频率响应读相位裕度反推，一条从根轨迹解特征方程——算的是同一个系统。

表 40-3 有三行需要单独解释。

第一行，分离点。 $\zeta = 0.9998$ 几乎等于 1，超调为 -0.00%（负号是数值噪声，含义是“没有超调”）。但 t_s 是五档里最长的 6.04 s。原因不在阻尼，而在**双重实极点**：$s = -0.974$ 是二重根，对应的时域项是 $t\mathrm{e}^{-0.974t}$，比同样距离的单实极点多一个 t 因子，收敛更慢。这提醒一件事：$\zeta \approx 1$ 并不等于“响应快”，它只等于“不超调”。

第四行，敏感点。 $K = 2.2$ 时 $\zeta = 0.0993$，超调 71.38%，t_s 8.45 s，仍在稳定区（$\operatorname{Re} s = -0.454 < 0$），但已经很难用。这条数在第 39 章 §39.7.1 出现过——增益加 20% 后相位裕度从 11.85° 掉到 8.63°。两条路径给的是同一件事的两种说法：根轨迹说“极点离虚轴只有 0.454”，频率响应说“相位裕度只剩 8.63°”。

第五行，临界。 $\zeta = 0$，二阶公式给 $M_p = 100\%$，实测却是 115.35%。差的 15 个百分点全部来自第三极：它把上升沿“顶”了一下，峰值被抬高。这也是第 39 章 §39.6.4 那笔“残余误差”在临界点的极端表现——ζ 越小，二阶公式与三阶实测的差距越大。

40.4.3 轨迹上的三段，对应三种行为

把表 40-3 的五个点放回图 40-3，轨迹被分成了三段，每一段的行为完全不同。

第一段，$0 < K < 0.0951$：两个实极点相向而行。 起点在 0 与 -2，终点在分离点 -0.974。这一段里 $\zeta = 1$，响应单调无超调，但两个极点都离虚轴不近，t_s 从无穷大（$K \to 0$ 时极点趋近原点）一路缩短到 6.04 s。这一段是“加增益换速度”的区间，单调、可预测、没有风险。

第二段，$0.0951 < K < 4.4$：复极点对向右上方走。 实部从 -0.974 收到 0，虚部从 0 涨到 6.325。ζ 从 1 掉到 0，M_p 从 0 涨到 115%，t_s 先降后升。这一段是**全部工程问题所在**：想要快，就得往右走；往右走，超调就上来。

第三段，$K > 4.4$：复极点对进入右半平面，发散。 这一段不是设计区，是禁区。但它的边界 $K_{\max} = 4.4$ 是整个设计的天花板。表 40-2 已经给出这个数，第 39 章 §39.12.2 用 Nyquist 也得到 4.40，两条独立路径互校通过。

三段的划分给出一个直接的工程结论：**调 K 实际上是在第二段里选一个点，而第二段的两个端点（分离点与虚轴）分别代表“最慢的无超调”与“最快的不可用”**。所有折中都在这一条弧上做。

40.4.4 等 ζ 线与等 ω_n 线

轨迹本身不带刻度，要在上面“读指标”，得先画两张网格：等阻尼线和等自然频率线。它们的方程直接来自式 (40-12) 的反解：

$$s = -\zeta\omega_n \pm \mathrm{j}\omega_n\sqrt{1-\zeta^2} \tag{40-13}$$

固定 ζ 让 ω_n 变，得到的是一条从原点出发、与负实轴夹角 $\arccos\zeta$ 的射线；固定 ω_n 让 ζ 变，得到的是以原点为心、半径 ω_n 的圆弧。

组 5 把这两族线与轨迹的交点都解了出来，列在表 40-4。

表 40-4　等 ζ 线与等 ω_n 线与主例轨迹的交点

约束	交点 K	交点极点	由交点读出的另一量
$\zeta = 0.8$	0.1446	$-0.9602 + \mathrm{j}0.7183$	$\omega_n = 1.1996$
$\zeta = 0.707$	0.1815	$-0.9501 + \mathrm{j}0.9500$	$\omega_n = 1.3435$
$\zeta = 0.6$	0.2436	$-0.9334 + \mathrm{j}1.2428$	$\omega_n = 1.5542$
$\zeta = 0.456$	0.3888	$-0.8945 + \mathrm{j}1.7443$	$\omega_n = 1.9605$
$\zeta = 0.3$	0.7332	$-0.8048 + \mathrm{j}2.5557$	$\omega_n = 2.6795$
$\omega_n = 2$	0.4044	$-0.8904 + \mathrm{j}1.7888$	$\zeta = 0.4452$
$\omega_n = 3$	0.9219	$-0.7567 + \mathrm{j}2.9023$	$\zeta = 0.2522$
$\omega_n = 5$	2.6620	$-0.3530 + \mathrm{j}4.9843$	$\zeta = 0.0706$

这张表可以从两个方向读。

从 ζ 读 K。 想让阻尼比不低于 0.6，K 就不能超过 0.2436；想保住 0.707，只能到 0.1815。这两个数比 $K_{\max} = 4.4$ 小一个数量级——**稳定边界与“好用边界”差了将近 20 倍**。这是根轨迹给出的最重要的工程直觉之一：能稳住不等于能用，中间隔着很宽的一段“稳而不可用”。

从 ω_n 读 ζ。 想要 $\omega_n = 3$（对应无阻尼振荡周期约 2.1 s），交点 $K = 0.9219$，此时 ζ 只有 0.2522，超调在 45% 上下。想要 $\omega_n = 5$，ζ 掉到 0.0706，超调超过 80%。**自然频率与阻尼比在这条轨迹上是绑死的**：这条对象没有零点，轨迹只有一条，ω_n 涨上去 ζ 必然掉下来，二者不能独立选。这一点与有零点的对象不同——加了零点之后轨迹会拐弯，两条约束才有机会同时满足，那是 §40.9 的内容。

表 40-4 还藏着一个“非线性”的证据：ζ 从 0.8 降到 0.456（降幅 0.344），K 从 0.1446 涨到 0.3888（涨 2.7 倍）；ζ 再从 0.456 降到 0.3（降幅 0.156），K 从 0.3888 涨到 0.7332（涨 1.9 倍）。**同样的 $\Delta\zeta$，越靠近虚轴，需要的 ΔK 越大**。这解释了为什么“再拧一点点”往往无效——在低阻尼区，增益的边际效果被压扁了。

40.4.5 网格叠在轨迹上的样子

图 40-6 把表 40-4 的内容画了出来：黑色曲线是轨迹，灰色虚线是等 ζ 射线，灰色点线是等 ω_n 圆弧，交点用空心圆标出。

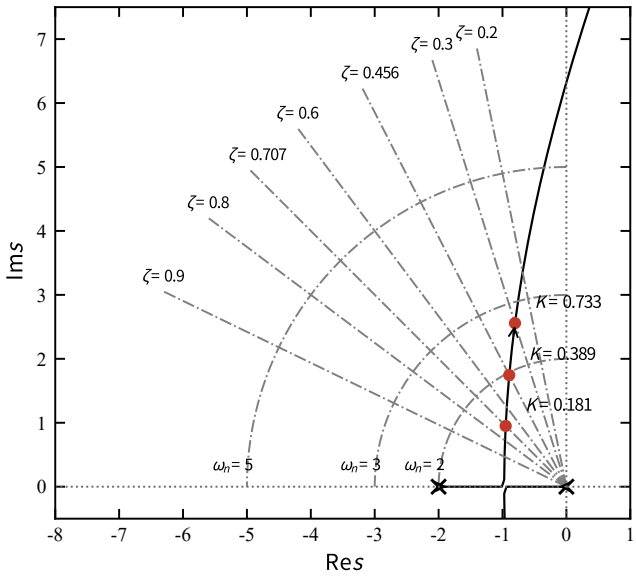

图 40-6　等阻尼线与等自然频率线叠在轨迹上

读这张图要注意三点。

第一，**等 ζ 线是射线，不是直线族**。它们全部从原点出发，所以越往外，同样的 ζ 对应的 ω_n 越大。轨迹与某条射线的交点只有一个，这一点就唯一确定了“该 ζ 下的 K 与 ω_n”——这是“一条轨迹、两族网格”能完成定量反查的原因。

第二，**等 ω_n 圆弧与轨迹最多交两点**，实际只取第一象限那一支。当圆弧半径大于轨迹能达到的最大模时无交点（例如 $\omega_n > 6.3246$ 就永远交不上，因为轨迹在虚轴穿越点的模就是 6.3246）。

第三，**网格的疏密反映了灵敏度**。在分离点附近，几条等 ζ 射线挤在一起，说明 ζ 对 K 极不敏感（ζ 从 0.8 到 0.99 只用了 $\Delta K = 0.05$）；靠近虚轴时射线之间的 K 间隔拉大，说明灵敏度反过来变小了。这两种“不敏感”方向相反，合起来正好是**中间一段最灵敏**——也就是 $K \approx 0.2$ 到 1.0 这一段，工程上多数整定都落在这里。

40.4.6 沿轨迹的灵敏度剖面

§40.4.2 的五档增益是“点”，这一小节把它们连成“斜线”：**每加一点增益，超调涨多少**。这个斜率决定了整定时手感，也决定了设计点该选在哪一段。

用表 40-3 与表 40-9 的实测值，逐段算差商 $\Delta M_p / \Delta K$，同时换成“每 10% 相对增益换多少点超调”：

- $0.1446 \to 0.1815$：绝对斜率 76.2 点/单位 K，相对斜率 1.24 点；
- $0.1815 \to 0.2436$：绝对斜率 82.6，相对斜率 1.76；
- $0.2436 \to 0.3888$：绝对斜率 72.0，相对斜率 2.28；

- $0.3888 \to 0.7332$：绝对斜率 49.4，相对斜率 2.77；
- $0.7332 \to 1.1000$：绝对斜率 32.9，相对斜率 3.01；
- $1.1000 \to 2.6620$：绝对斜率 18.6，相对斜率 3.49。

两条曲线的走向相反，这是本节最值得记住的一件事。

绝对斜率在 $K \approx 0.2$ 附近最大，然后一路下降。 原因在几何上：分离点附近两条支路刚分开，实部变化慢、虚部变化快，极点在复平面上的"角速度"最大，ζ 掉得最急，所以 M_p 涨得最快。越靠近虚轴，支路越接近竖直方向，同样的 ΔK 主要把极点往上推——模变大、实部几乎不动，ζ 反而掉得慢，M_p 就涨得慢。

相对斜率却一路单调上升。 因为 K 本身在涨，基数的增速超过了绝对斜率的衰减。从 $K \approx 0.16$ 到 $K \approx 1.9$，基数涨了约 11.5 倍，绝对斜率只降到 $1/4$，两者相除，相对斜率涨了约 2.8 倍。

这个反差有直接的工程含义：**低增益区"敢调"，高增益区"不敢调"**。在 $K = 0.16$ 附近，拧错 10% 只多 1.2 点超调，可以放心试；在 $K = 0.9$ 附近，拧错 10% 就是 3 点，而这里的超调已经在 50% 上下，再涨就要出事。现场"越调越不敢调"的手感，根子在这条相对斜率上，不在操作者身上。

还有一层：**绝对斜率会骗人**。如果只看"每单位 K 换多少点"，会得出"高增益区不敏感"的错误结论。实际上高增益区的 K 刻度被放大了——1.1 到 2.66 这一段跨了 1.56，而 0.14 到 0.18 只跨了 0.04。**比较灵敏度之前，必须先把它换成相对量**，这与 §40.9.5 的归一化是同一条原则：**分母不同，斜率不可比**。

40.4.7 型别藏在起点里

动态指标之外，还有一类指标是轨迹上直接看得见的：**稳态误差**。它不看极点往哪走，只看**有几个极点从原点出发**。

本章对象 $G_0(s) = 10/[s(s+2)(0.05s+1)]$ 有一个 s 因子，所以是 I 型系统。轨迹上表现为：**一条支路从原点出发**。这条支路的起点位置就是"型别"的图形标志——原点有一个开环极点，就有一个积分器，就有一条支路从原点起步。

型别定了，三类输入的稳态误差就定了：

- 阶跃输入：$K_p = \lim_{s\to 0} G_0 = \infty$，误差 0；
- 斜坡输入：$K_v = \lim_{s\to 0} sG_0 = \dfrac{10}{2 \times 1} = 5$，误差 $1/(5K)$；
- 抛物线输入：$K_a = \lim_{s\to 0} s^2 G_0 = 0$，误差 ∞。

把设计点代进去：$K = 0.3888$ 时斜坡误差 $1/(5 \times 0.3888) = 0.5144$，也就是**跟踪 1 rad/s 的斜坡时，稳态落后约半个单位**。$K = 0.2436$ 时是 0.8210，几乎落后一个单位。**增益每降一档，动态变稳、稳态变差**，这条此消彼长的关系在轨迹上同样看得见：往左走（降 K）ζ 变大、K_v 变小。

这条关系解释了一个常见的现场矛盾：**"超调压下去了，但跟不住匀速指令"**。原因不是调参没调好，是同一根 K 同时管着两件事。要同时满足，只有两条路：加积分器（提高型别）或加滞后校正（提高低频增益）。

- **加积分器**：原点再多一个极点，n 加一，渐近线条数加一，**稳定性必然变差**。这是"提高型别"的固有代价，第 42 章会给出定量的权衡方法。
- **加滞后校正**：不改变型别，但把低频增益抬高。本章的滞后网络 $C(s) = (s+1)/(s+0.2)$ 在 $s=0$ 处的增益是 $1/0.2 = 5$，所以 K_v 变成 25，同样 $K = 0.3888$ 时斜坡误差降到 $1/(25 \times 0.3888) = 0.1029$——**改善 5 倍，而型别没变**。

代价在 §40.9.4 已经量过：滞后把 ζ 从 0.5322 压到 0.2674，超调涨到 54.33%。**稳态精度与动态品质的这笔交易，根轨迹上表现为“轨迹被极点往右推”。**

所以读轨迹时，除了看虚轴和等 ζ 线，还要数一眼原点：**原点上有几个极点，就有几个积分器，就决定了能跟住几阶输入。** 这一眼只要一秒，却能避免“调了半天动态，稳态始终不达标”的返工。

40.5 离散情形

前面所有讨论都默认控制器与对象是连续时间。实际系统里，控制器是数字的，采样保持环节把连续轨迹改写了。这一节把同一套方法搬到 z 平面，看它变在哪里、不变在哪里。数据来自 `code/ch040_sim.py` 的组 6。

40.5.1 为什么必须重画

离散系统的闭环特征方程是

$$1 + K G(z) = 0, \qquad G(z) = \mathcal{Z}\left\{ \frac{1 - \mathrm{e}^{-T_s s}}{s} G_0(s) \right\} \tag{40-14}$$

z 平面的稳定域是单位圆内，不是左半平面。两个域之间靠映射

$$z = \mathrm{e}^{s T_s} \tag{40-15}$$

联系：左半平面映到单位圆内，虚轴映到单位圆上，右半平面映到圆外。所以“根轨迹穿越虚轴”这件事，在 z 平面上变成“根轨迹穿越单位圆”。

映射不是等距的。s 平面上的虚轴是无限长，z 平面上只有一段单位圆弧；s 平面上 $\mathrm{j}\omega$ 与 $\mathrm{j}(\omega + 2\pi/T_s)$ 映到同一个 z 点。这带来两个后果：一是**高频段的稳定性信息被折叠**，二是**临界增益随 T_s 单调下降**。后者是本节的主线。

40.5.2 六档采样周期下的临界增益

用零阶保持把 G_0 离散化，再对每个 T_s 二分求“闭环极点模穿越 1”的增益，得到表 40-5。

表 40-5　采样周期对临界增益的影响（ZOH 离散，主例对象）

T_s/s	$K_{\max}$	相对连续 4.4000 的比值	采样角频率 ω_s/(rad/s)
0.01	3.9662	0.9014	628.3
0.02	3.6137	0.8213	314.2
0.05	2.8637	0.6508	125.7
0.10	2.1437	0.4872	62.83
0.20	1.4483	0.3292	31.42
0.50	0.7842	0.1782	12.57

这张表最刺眼的是最后一行：$T_s = 0.5$ s 时临界增益只剩 0.7842，只有连续域天花板 4.4 的 17.82%，仅比分离点增益 0.0951 高八倍出头。换句话说，采样一慢，原本“从分离点到虚轴有四十多倍余量”的设计区间被压成不足十倍。

$T_s = 0.1$ s 这一行要特别记住：$\omega_s = 62.83$ rad/s，是连续域相位穿越频率 $\omega_{180} = 6.3246$ 的约 10 倍，看起来“采样够快”，但临界增益已经掉到 48.72%。**“采样频率是带宽的十倍”这条经验法则，对稳定性余量并不保险**——它保的是波形不失真，不保增益裕度。

为什么会掉这么多？直观解释是零阶保持引入的附加相位滞后。ZOH 的等效延迟约 $T_s/2$，在 ω_{180} 处贡献的相位是 $-\omega_{180}T_s/2$ 弧度。取 $T_s = 0.1$：$-6.3246 \times 0.05 = -0.316$ rad $= -18.1^\circ$。第 39 章 §39.7.3 算过，在 ω_{180} 附近每度相位都直接吃掉增益裕度，-18° 足以把 12.87 dB 的裕度削掉一大块。实测掉到 48.72%（-6.25 dB），与这个估算量级一致。

40.5.3 同一条 z 轨迹上，模怎么随 K 涨

$T_s = 0.1$ s 时，取四个 K 看闭环极点的模，列在表 40-6。

表 40-6　$T_s = 0.1$ s 时闭环极点随增益的变化

K	主导共轭对	$\max\lvert z\rvert$	说明
0.3	$0.9097 \pm \mathrm{j}0.1372$	0.9200	离单位圆还有 0.08
1.0	$0.9096 \pm \mathrm{j}0.2834$	0.9527	实部几乎不动
2.0	$0.9075 \pm \mathrm{j}0.4065$	0.9944	贴圆
2.1437	$0.9071 \pm \mathrm{j}0.4210$	1.0000	穿越

表的第二列有一个非常稳定的数：**实部始终在 0.907 到 0.910 之间**。这不是巧合，它对应连续域 s 平面上“实部缓慢右移”的过程——$z = \mathrm{e}^{sT_s}$ 的模是 $\mathrm{e}^{\sigma T_s}$，σ 从 -0.918 变到 0 时，$|z|$ 从 $\mathrm{e}^{-0.0918} = 0.9123$ 变到 1。实测 0.907 到 1.000，与这条解析关系对得上。

虚部则从 0.137 涨到 0.421，对应 ω 从 1.35 涨到 4.35 rad/s（由 $\angle z / T_s$ 反算）。也就是说，**在 z 平面上加增益，主要是在“沿圆弧往逆时针走”，而不是“沿半径往外走”**。这个几何图像与连续域“沿轨迹往右上方走”是一一对应的，只是被指数映射弯了过来。

表 40-6 还说明一件事：$\max|z|$ 从 0.9200 到 1.0000，全程只变了 0.08，但系统从“很稳”变成“临界”。**用 $|z|$ 的绝对变化量判断稳定余量是不可靠的，必须看 $1 - |z|$ 这个差值**：0.08、0.047、0.0056、0，收敛速度差了十几倍。

40.5.4 采样周期是稳定性预算的一部分

把表 40-5 与第 39 章 §39.7.4 的延迟预算放在一起看，会发现两条曲线形状相似：延迟增加与采样变慢，都在削减同一个预算。

第 39 章算过，$K = 0.3$ 时延迟容忍 745.8 ms，$K = 2.2$ 时只有 46.8 ms，幂律指数 -1.39。采样周期的影响可以用同样的语言描述：**每增加一档 T_s，临界增益按接近指数的规律下滑**，从 0.01 到 0.5 跨了 50 倍，$K_{\max}$ 掉了 5 倍。

两者叠加时不能简单相加。ZOH 的等效延迟 $T_s/2$ 只是“平均”意义下的近似，实际相位滞后是 $\omega T_s/2$ 随频率线性增长，而纯延迟是 ωT_d 也线性——所以在低频段两者等效，在高频段 ZOH 的相位还会因为采样折叠出现额外损失。工程上的做法是：**先把 $T_s/2$ 记进延迟预算，再用离散根轨迹复核**，两步都做，不要只做一步。

40.5.5 z 平面轨迹的读图要点

图 40-8 是 $T_s = 0.1$ s 的离散根轨迹，单位圆画成灰色虚线。

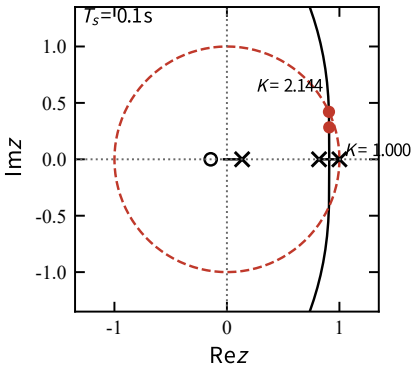

图 40-8　$T_s = 0.1$ s 的离散根轨迹与单位圆

读这张图与读连续图有三处不同。

第一，**起点不再是原点与负实轴上的点**。连续域的极点 0、-2、-20 映射到 $z = 1$、0.8187、0.1353，三个起点全部落在正实轴上（$z = 1$ 在单位圆上）。所以离散轨迹的“出发姿势”与连续图完全不同，不能把连续图的形状直接搬过来。

第二，**轨迹可以绕到单位圆外再绕回来**。连续域的右半平面是“一去不回”，z 平面的圆外却可能因为高频折叠而重新进入圆内。这不代表系统能“重新稳定”，因为那一段对应的物理频率已经被混叠，实际响应是发散的。**看图时不能只看“有没有出圆”，还要看“出圆的那一段对应的频率是否在带宽内”**。

第三，**临界点附近的曲率很大**。表 40-6 里 K 从 2.0 到 2.1437，$\max|z|$ 从 0.9944 到 1.0000，只差 0.0056，但极点已经贴到圆上。图上这一段几乎与单位圆重合，肉眼分辨不出来，必须靠数值。

40.5.6 离散设计例：同一增益，为什么指标变差

前五小节讲的是“临界增益掉了多少”，这一小节回答更实际的问题：**连续域整定好的工作点，搬到数字控制器上还能不能用**。数据来自组 10，采样周期取 $T_s = 0.1$ s，控制器就是一个增益 K，对象经零阶保持离散。

先把同一个 $K = 0.3$ 的两套结果并排放：

- 连续：$M_p = 13.82\%$，$t_s = 3.41$ s；
- 离散（$T_s = 0.1$ s）：$M_p = 17.26\%$，$t_s = 4.90$ s。

超调多了 3.44 点，调节时间长了 44%。 增益没动、对象没动，变的只是“控制器每隔 0.1 s 才看一次”。

原因可以用等效 s 极点说清。离散主导极点是 $z = 0.9097 \pm \mathrm{j}0.1372$，按 $z = \mathrm{e}^{sT_s}$ 反算

$$\sigma = \frac{\ln|z|}{T_s} = \frac{\ln 0.9200}{0.1} = -0.8338, \qquad \omega = \frac{\angle z}{T_s} = \frac{0.14976}{0.1} = 1.4976$$

于是 $\zeta_d = 0.4865$、$\omega_n = 1.7134$。对照连续域的 0.5322 与 1.7250：ω_n **几乎没变**，ζ **掉了 0.046**。零阶保持带来的附加相位滞后，本质上就是“偷走一点阻尼”，不改变系统的固有频率。这也解释了为什么超调涨、而上升时间基本不变。

再看整张表（组 10 的前八行）：

- $K = 0.20$：M_p 连续 5.85%、离散 7.67%，离散 $t_s = 4.40$ s；

- $K = 0.25$：9.97% 对 12.61%，3.80 s；
- $K = 0.30$：13.82% 对 17.26%，4.90 s；
- $K = 0.60$：31.25% 对 39.34%，5.80 s；
- $K = 1.00$：46.05% 对 59.74%，7.70 s；
- $K = 1.50$：58.71% 对 78.90%，14.70 s；
- $K = 2.00$：68.16% 对 94.09%，已无 2% 带内的调节时间；
- $K = 2.1437$：连续 70.49%，离散 145.84%——这是临界点上的等幅振荡，峰值数字没有物理意义。

三件事从表里浮出来。

第一，差距随增益扩大。 $K = 0.2$ 时差 1.82 点，$K = 1.5$ 时差 20.19 点。因为零阶保持的相位滞后是 $\omega T_s/2$，增益越大、工作频率越高，滞后越多。**低增益区数字化几乎无损，高增益区数字化代价陡增。**

第二，数字化的代价主要记在"稳定余量"账上，不是"速度"账上。 连续域 $K_{\max} = 4.4$，离散域 2.1437，只剩 48.72%。若原设计取 $K = 1.0$（连续超调 46.05%），离散后余量只剩 2.14 倍，而超调已经 59.74%——这个工作点在数字控制器上已经不可用了。

第三，想保住原来的超调，必须降增益。 目标 13.82% 落在 $K = 0.25$（12.61%）与 $K = 0.30$（17.26%）之间，也就是要把 K 往下调两成左右。但降增益之后 $t_s = 3.80$ s，仍比连续的 3.41 s 慢。**离散化是"用速度换稳定"的交易，降 K 只能把超调买回来，买不回速度。**

如果系统里还有纯延迟，这笔账会更难看。组 10 的后四行给出 $T_s = 0.1$ s 下每加一拍延迟的临界增益：0 拍 2.1437、1 拍 1.0785、2 拍 0.7325、5 拍 0.3867。

一拍延迟就把天花板砍掉一半。 0.1 s 的延迟在 $\omega_{180} = 6.3246$ 处贡献 $6.3246 \times 0.1 = 0.6325$ rad，即 36.24° 相位——比零阶保持本身的 18.1° 还多一倍。这解释了现场一个常见现象：**仿真里调好的增益，接上总线通讯后一上电就振**。不是对象变了，是环路里多了几拍。

所以离散设计的正确顺序是：先在连续域定结构，再用**含延迟的离散模型**重定工作点，最后按最坏情况的拍数核算余量。跳过第二步，等于用一张过期的地图开车。

40.5.7 采样周期怎么定：三条约束，取最严

"采样频率取带宽的十倍"是一条流传很广的经验，但本章的数据说明它对稳定性远远不够。这一小节把采样周期的约束拆成三条，各自算一遍，取最严的那条。

约束一：波形不失真。 控制器每个周期只能看到一次输出，若采样太稀，两个采样点之间发生的事情完全看不见。这条约束要求 $\omega_s \gg \omega_c$。本章设计点 $K = 0.3888$ 的增益穿越频率是 1.5369 rad/s，$T_s = 0.1$ s 对应 $\omega_s = 62.83$ rad/s，比值 40.9 倍——**这条约束满足得很宽裕。**

约束二：稳定余量不被吃掉。 零阶保持引入约 $T_s/2$ 的等效延迟，在 ω_{180} 处扣相位。表 40-5 的六档可以换算成增益损失：

- $T_s = 0.01$ s：$K_{\max}$ 比值 0.9014，损失 0.90 dB；
- $T_s = 0.02$ s：0.8213，损失 1.71 dB；
- $T_s = 0.05$ s：0.6508，损失 3.73 dB；
- $T_s = 0.10$ s：0.4872，损失 6.25 dB；
- $T_s = 0.20$ s：0.3292，损失 9.65 dB；

- $T_s = 0.50$ s：0.1782，损失 14.98 dB。

约束三：延迟预算。 真实的环路延迟（总线、驱动、滤波）往往比 $T_s/2$ 大得多。$T_s = 0.1$ s 时，多加一拍就再扣 36.24°，$K_{\max}$ 从 2.1437 掉到 1.0785。**这条约束与采样周期强耦合：T_s 越大，一拍代表的绝对时间越长，同样的物理延迟折算的拍数越少但拍本身的伤害越大。**

三条约束放在一起，结论与经验法则相反。若要求“数字化带来的稳定余量损失不超过 1 dB”，按上表必须取 $T_s = 0.01$ s，此时 $\omega_s = 628.3$ rad/s，是 ω_c 的 409 倍——**远比“十倍带宽”严格**。若放宽到 2 dB，$T_s = 0.02$ s，仍是带宽的 204 倍。

为什么差距这么大？因为“十倍带宽”是从**信号重构**角度提的（要还原波形，采样率高于最高频率分量即可），而稳定余量看的是**相位**——相位误差随时间线性累积，与频率成正比，10 倍带宽对应的相位滞后在 ω_{180} 处已经不可忽略。**两个指标问的不是同一件事，不能互相替代。**

工程上的定法：先按“损失不超过 4 dB”选 T_s，再用“最坏延迟拍数”复核，最后看控制器算力是否允许。本章对象的算例是：把损失上限定在 4 dB，$T_s = 0.05$ s 实测损失 3.73 dB，满足要求；此时 $K_{\max} = 2.8637$，$K = 0.3888$ 的余量 7.37 倍。接下来还要把一拍 0.05 s 的延迟代进去重算——它在 ω_{180} 处贡献 18.12°，与 $T_s = 0.1$ s 的零阶保持相当，**这一步不能用 $T_s = 0.1$ s 的延迟表外推**，必须按新的采样周期重跑一次组 10。**这个顺序比“先定采样率再调增益”靠谱得多。**

40.5.8 离散极点不是连续极点的“指数影子”

一个很常见的错觉是：把连续极点代进 $z = \mathrm{e}^{sT_s}$ 就得到离散极点。组 6 的数据说明这个想法只对了一半。

$K = 0.3$ 时连续极点是 $-0.918 \pm \mathrm{j}1.460$，代进去得 $|z| = \mathrm{e}^{-0.0918} = 0.9123$、相角 $1.460 \times 0.1 = 0.146$ rad，约 8.4°；实际离散闭环极点是 $0.9097 \pm \mathrm{j}0.1372$，模 0.9200、相角 8.6°。模差 0.008、角差 0.2°，看起来很像。但 $K = 1$ 时：连续 $-0.737 \pm \mathrm{j}3.033$ 映射为 $0.9290\angle 17.4^\circ$，实际是 $0.9527\angle 17.3^\circ$——**相角仍然对得上，模却大了 0.024。**

原因在离散化的位置。ZOH 是在**开环**上做的，闭环极点是“先把对象离散、再解代数方程”的结果，不是连续闭环极点逐点取指数。指数映射只对“理想采样、无保持器”的情形严格成立。保持器本身是一个 $T_s/2$ 的等效延迟，它把极点往z平面外侧推，所以模总是偏大。

偏差的方向比大小更重要：**模偏大意味着阻尼偏小**。组 10 的读数给出 $K = 1$ 时 $\zeta_d = 0.1584$，而连续 $\zeta = 0.2361$，掉了 0.078；到了临界点，ζ 直接归零，临界增益从 4.4000 落到 2.1437——只有原来的 48.7%。

靠近临界时，偏差还会从“模”转移到“频率”。连续临界振荡是 6.3246 rad/s，离散只有 4.3449 rad/s，低了 31.3%。这与 §40.5.7 里“ZOH 在 ω_{180} 处贡献相位”是同一件事的两种说法：保持器把相位往后拖，系统必须退到更低的频率才凑得够 -180°。

所以读离散轨迹要守一条规矩：**模看余量，角看频率，两者都不能由连续值直接换算**。真要核对，就老老实实离散一次、求一次根：

```
Gd = ct.c2d(G, Ts, method="zoh")          # 在开环上离散
nd = np.atleast_1d(np.asarray(Gd.num[0][0], float))
dd = np.atleast_1d(np.asarray(Gd.den[0][0], float))
zs = np.roots(np.polyadd(dd, K * nd))     # 离散闭环极点
```

这五行代码比任何近似公式都可靠，而且成本极低——**根轨迹本来就是“求根”，多求一次离散的根不算负担**。

报告口径也值得统一。验收单上只写“$K_{\max}=2.1437$”是没有意义的，读的人不知道它对应哪个增益刻度。应该写成三条并列：连续 $K_{\max}=4.4000$、离散 $K_{\max}=2.1437$、离散损失 6.25 dB，并注明 $T_s=0.1$ s、ZOH、无额外延迟。若要多留一拍延迟，再加一条“$K_{\max}$ 降到 1.0785，相对连续损失 12.2 dB”。**同一个对象、同一条轨迹，把“损失多少 dB”写清楚，比只报绝对值更能防止误用。**

40.6 稳定性与性能

§40.4 已经把五档增益的指标摆出来了，但还没有回答一个更基本的问题：**稳定裕度与动态品质之间到底是什么关系？** 很多现场争论都卡在这里——一方说“还有 6 dB 裕度，很安全”，另一方说“超调 70%，没法用”。这一节用轨迹上的数据把这两句话接起来。

40.6.1 稳定与好用是两件事

表 40-3 的第四行是最有说服力的例子。$K=2.2$ 时：

- 增益裕度 $G_M=20\lg(4.4/2.2)=6.02$ dB，按第 39 章 §39.5 的口径属于“合格”；
- 阻尼比 $\zeta=0.0993$，超调 71.38%，按任何工业标准都不合格。

同一个工作点，一张表说“安全”，另一张表说“不能用”。矛盾吗？不矛盾——**增益裕度度量的是“离发散还有多远”，阻尼比度量的是“响应好不好看”，两者根本不是一回事。**$K=2.2$ 确实离发散还有一倍的距离，但它在这一倍距离之内的形状已经烂掉了。

反过来看 $K=0.2436$（$\zeta=0.6$）：$G_M=20\lg(4.4/0.2436)=25.14$ dB，比 6 dB 多出 19 dB，超调实测 9.45%，调节时间 3.88 s。想要“既稳又好看”，就得把增益压到临界值的 5.5%。**这条 5.5% 是本章对象给出的具体答案，也是“根轨迹能做定量”的证据。**

40.6.2 主导极点近似能信到什么程度

工程上习惯把三阶系统当二阶算：取最靠虚轴的一对共轭极点，套二阶公式。组 8 把这件事的误差量了出来，列在表 40-7。表中“二阶”一列用式 (40-12) 的 ζ、ω_n 代入 $M_p=\exp(-\pi\zeta/\sqrt{1-\zeta^2})$ 与 $t_s=4/(\zeta\omega_n)$，“实测”一列来自三阶闭环的阶跃仿真。

表 40-7　主导极点近似的误差（主例对象，三档增益）

K	ζ	ω_n	二阶 M_p/%	实测 M_p/%	二阶 t_s/s	实测 t_s/s
0.3	0.5322	1.7250	13.88	13.82	4.36	3.40
1.0	0.2361	3.1215	46.61	46.05	5.43	5.36
2.2	0.0993	4.5673	73.08	71.38	8.82	8.45

图 40-7 把其中两档画成了曲线：黑色实线与虚线是三阶实测，红色点线是只保留主导对的二阶近似，两条灰色细线是 $\pm2\%$ 带。

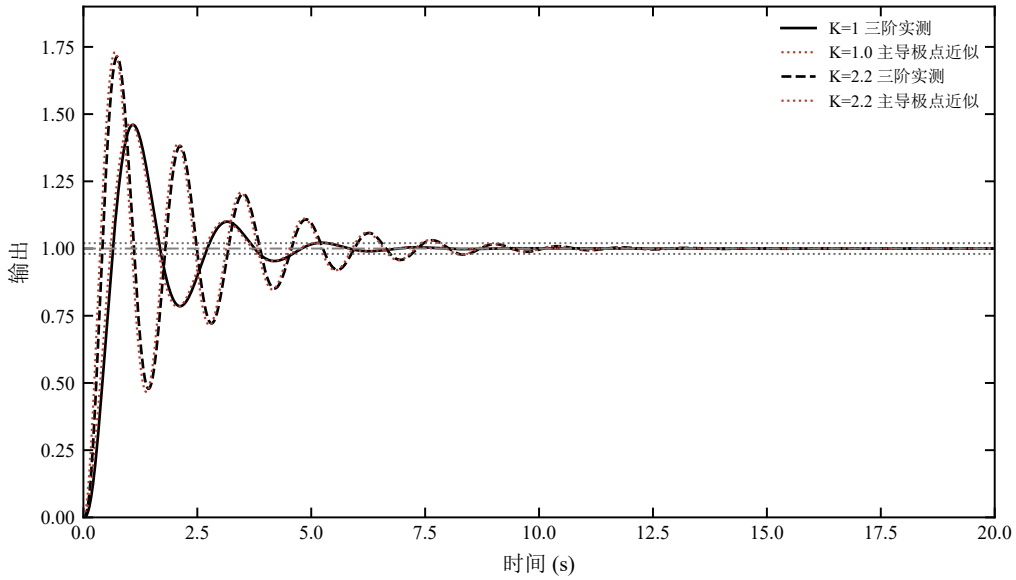

图 40-7　三阶实测阶跃与主导极点近似的对比

图上看得很清楚：$K = 1$ 的两条曲线几乎重合，$K = 2.2$ 的两条在峰值附近分开一点，但峰位、峰高、振荡周期都对得上。**主导极点近似"长得像"，只是时间轴上的收敛速度差一点**——这正是表 40-7 里 M_p 误差小于 3%、t_s 误差可能到 28% 的直观版本。

三行给出三种误差形态，值得逐个说。

超调这一列，误差很小且方向一致。 二阶公式高估了 0.06、0.56、1.70 个百分点，相对误差 0.4%、1.2%、2.4%。方向一致地"高估"并不奇怪：第三极在 -20 附近，把一个快速衰减的分量叠在慢分量上，峰值时刻它已经衰掉大半，剩下的部分只是把峰值略微拉开或压低。第 39 章 §39.6.4 把这笔误差称为"残余"，这里看到的是它在三个工作点上的具体值。

调节时间这一列，$K = 0.3$ 的误差高达 28%。 二阶公式给 4.36 s，实测 3.40 s。原因有两个：一是 $4/(\zeta\omega_n)$ 本身是个经验包络，它对二阶系统的实际 t_s 就偏保守（真实系数在 3.5 到 4.5 之间随 ζ 变）；二是第三极把上升沿拉陡，系统更早进入 $\pm 2\%$ 带。两条叠在一起，28% 的偏差就出来了。

$K = 1$ 与 $K = 2.2$ 反而准。 误差只有 1.3% 与 4.4%。这与直觉相反——阻尼越小、振荡越厉害，主导极点近似不是该更差吗？原因是 t_s 的定义：振荡越厉害，最后一次穿出 $\pm 2\%$ 带的时间越晚，此时快速分量早已衰减干净，只剩主导对在振荡，包络公式反而更贴近。

把三行合起来看，结论是：**主导极点近似用来估超调很可靠（误差 3% 以内），用来估调节时间要看工作点（误差可从 1% 到 28%）**。工程上如果 t_s 是硬指标，不能只靠公式，必须仿真；如果 M_p 是硬指标，公式可以先用。

40.6.3 从 ζ 到 M_p：两级灵敏度的乘积

M_p 对 K 的灵敏度可以拆成两级：K 先影响 ζ，ζ 再影响 M_p。第一级由轨迹的几何决定，第二级由二阶公式决定。

第一级用表 40-3 的差商估：K 从 0.0951 到 0.3，ζ 从 0.9998 掉到 0.5322，斜率 -2.28/单位增益；从 0.3 到 1.0，斜率 -0.423；从 1.0 到 2.2，斜率 -0.114。**增益越大，同样 ΔK 对 ζ 的伤害越小**——因为轨迹在靠近虚轴处越来越"平"（沿圆弧走，实部变化慢）。

第二级是第 39 章 §39.6.4 量过的 $\mathrm{d}M_p/\mathrm{d}\zeta$：在 $\zeta=0.532$ 处 -71.8，在 0.236 处 -159.6，在 0.099 处 -233.0（单位：百分点每单位 ζ）。**阻尼越小，超调对阻尼越敏感。**

两级相乘，才是 M_p 对 K 的灵敏度。但**不能用区间平均斜率直接相乘**：以 $K\in[0.0951,0.3]$ 为例，第一级平均斜率 -2.28、第二级在 $\zeta=0.532$ 处的斜率 -71.8，相乘得 163.7 点/单位增益；而实测差商是 $(13.82-0)/0.2049=67.4$ 点/单位增益，差 2.4 倍。原因是两个关系都非线性，“平均斜率的乘积”不等于“乘积的平均斜率”。

可靠的数只能从实测差商取：67.4、46.0、21.1、20.0（百分点每单位增益，四段依次是 $0.0951\to0.3$、$0.3\to1$、$1\to2.2$、$2.2\to4.4$）。第一级在降（$-2.28\to-0.423\to-0.114$），第二级在升（$-71.8\to-159.6\to-233.0$），乘积在降——**降的那一级赢了**。所以“增益越大越难调”这句话，从绝对量上看并不成立。

但换个刻度就不同了。按“增益变化 10%”折算：$K=0.3$ 时 $\Delta K=0.03$，超调变 2.0 个百分点；$K=1$ 时 $\Delta K=0.1$，变 4.6 个百分点；$K=2.2$ 时 $\Delta K=0.22$，变 4.6 个百分点。**按相对刻度看，$K\ge1$ 之后灵敏度基本恒定在“每 10% 增益换 4.6 个百分点超调”**。这条经验数比任何公式都好用：想要超调不超过 20%，就把增益定在“再涨 10% 也只到 24.6%”的位置上，留一点余量。

这也解释了为什么现场调参总在 $K\approx1$ 附近打转：绝对灵敏度已经降到 46 点/单位增益，相对灵敏度却还没起飞，是“手感最线性”的一段。

40.6.4 t_s 的“浅碗”在轨迹上是什么样

表 40-3 的 t_s 一列是 $6.04\to3.40\to5.36\to8.45$，先降后升，谷底在 $K=0.3$。这条“浅碗”第 39 章 §39.7.5 已经见过（那次的读数是 $5.84\to3.41\to3.84$，谷底同样在 $K=0.3$ 附近），本章从轨迹一侧给出解释。

t_s 大致由“最靠虚轴的那个极点的实部”决定，$t_s\approx4/|\mathrm{Re}\,s|$。而 $|\mathrm{Re}\,s|$ 沿轨迹不是单调的：它从 0（$K\to0$，极点贴原点）涨到 0.974（分离点），再回落到 0（临界）。**所以 t_s 必然先降后升，谷底出现在 $|\mathrm{Re}\,s|$ 最大处附近。**

但谷底并不正好在分离点，而是在 $K=0.3$。差别来自“重根惩罚”：分离点处 $|\mathrm{Re}\,s|=0.974$ 是最大值，可它是二重根，时域项带 t 因子，t_s 反而是 6.04 s；$K=0.3$ 处 $|\mathrm{Re}\,s|=0.918$ 略小，但极点已经分成一对共轭复根，没有 t 因子，t_s 反而最短（3.40 s）。**这就是为什么“最靠左的极点”不等于“最快的响应”——还要看它是几重。**

工程含义：如果只按“实部最大”去挑工作点，会挑到分离点，得到一个没有超调但慢吞吞的系统。根轨迹图上看不出“重数”，得回到特征方程去判。

40.6.5 增益裕度就是轨迹的剩余长度

第 39 章 §39.12.2 给过一个统一写法：$G_M(\mathrm{dB})=12.87-20\lg K$。在根轨迹的语言里，这个式子的含义非常直白——**增益裕度就是“从当前点沿轨迹还能走多远才到虚轴”，用分贝表示。**

$$\frac{K_{\max}}{K}=10^{G_M/20} \tag{40-16}$$

对照表 40-3 的五个工作点：$K=0.0951$ 时 $G_M=33.3$ dB（还能涨 46 倍），$K=0.3$ 时 23.3 dB（14.7 倍），$K=1$ 时 12.9 dB（4.4 倍），$K=2.2$ 时 6.02 dB（2 倍），$K=4.4$ 时 0 dB。**裕度每掉 6 dB，剩余增益就减半**——这条换算关系比记住分贝数更实用。

把它与阻尼比并排看，会得到一个不好看但真实的对应：

G_M/dB	33.3	23.3	12.9	6.02	0
ζ	0.9998	0.5322	0.2361	0.0993	0

25 dB 的裕度只买到 $\zeta=0.6$，12.9 dB 只买到 $\zeta=0.236$。 如果验收标准写“增益裕度不小于 12 dB、超调不大于 20%”，那么这两条要求在本对象上无法同时满足：12 dB 对应 $K\approx 1.1$，实测超调 48.96%。这类冲突只能靠改结构解决，不能靠调 K 解决——那是 §40.9 的整形。

40.6.6 第三极的那笔小账

表 40-3 的第三极从 -20.053 走到 -22.000，全程只挪了 1.95。但它在不同工作点的“相对地位”变化很大：$K=0.3$ 时 $|p_3|/|\mathrm{Re}\,p_{1,2}|=20.164/0.918=22.0$；$K=1$ 时 27.8；$K=2.2$ 时 46.5。

按“极点相距 5 倍以上可忽略”的常规判据，三个工作点都该满足。可表 40-7 显示 $K=0.3$ 的 t_s 误差仍有 28%。这说明**“5 倍判据”只保证极点的位置关系，不保证指标误差**——误差还取决于留数（该极点对应的模态在输出里占多大权重）。$K=0.3$ 时主导对靠近分离点，两个根几乎重根，留数分配对第三极的扰动特别敏感。

这条小账的实际价值是：**不要用“第三极很远”来给主导极点近似打包票，要用一次仿真核对**。核对成本很低（一条阶跃曲线），省下的可能是 30% 的调节时间误判。

40.6.7 余量该记在哪本账上

设计点定下来之后，还有一个必答的问题：**这个点离出事有多远。** 直觉上答案是“看 K 到 $K_{\max}$ 的距离”，但这条距离在不同误差源面前缩小得快慢完全不同，必须分开记账。

第一本账：建模增益误差。 对象增益估小了，真实增益就比标称大，等效于 K 被放大。若真实增益比模型高 20%，有效临界增益变成 $4.4000/1.2=3.6667$；高 30% 是 3.3846；高 50% 是 2.9333。算法只有一步除法，**增益误差对临界点的削弱是线性的，50% 的误差只把天花板压掉三分之一。**

对本章对象，这笔账非常宽松。设计点 $K=0.3888$（$M_p=19.90\%$）距离 3.3846 还有 8.7 倍，距离 2.9333 还有 7.5 倍。**增益估错，根本威胁不到这个设计。**

第二本账：相位误差。 延迟、采样、未建模的高频动态，全都折算成相位滞后，而相位滞后在穿越频率附近是“按度扣钱”的。$T_s=0.1$ s 的零阶保持已经扣掉 18.1°，临界增益从 4.4000 掉到 2.1437；再加一拍 0.1 s 延迟，再扣 36.24°，掉到 1.0785。

两本账的差别是数量级的。同样“多 20%”，增益误差只让天花板从 4.4 变 3.67，而一拍延迟让它从 2.14 变 1.08。**所以设计余量的瓶颈几乎总在相位侧，不在增益侧。**

这条结论可以直接用：若设计点 $K=1.0$，名义余量 2.14 倍（6.62 dB），听着不错；但一拍延迟后只剩 1.08 倍（0.66 dB），**这就是“仿真很稳、上机就振”的全部原因。**

工程做法是**两本账分开写，取小者**：

1. 增益账：$K_{\max}/K$，按最坏增益偏差折算；
2. 相位账：按最坏延迟（含通讯、执行器、采样）折算后的 $K_{\max}$ 再除以 K；
3. 两条都换算成 dB 写进设计报告，不要只写一个“裕度足够”。

还有一个容易忽略的细节：**两本账不能相乘**。增益偏差与延迟不是独立作用于同一个环节，它们的耦合是非线性的——延迟改变的是穿越频率处的相位，而增益改变的是穿越频率本身。**先算各自的最坏情形，再取较小者**，这是唯一不产生虚假乐观的算法。

40.6.8 三个时间尺度，各读轨迹的一个坐标

阶跃响应有上升时间 t_r、峰值时间 t_p、调节时间 t_s 三个常用指标。它们看起来是三条独立的规范，实际上都由同一对闭环极点算出，而且**各自对应轨迹上的一个坐标**。把这件事看清，读图时就不用反复试算。

对二阶主导的系统，三个公式是

$$t_r \approx \frac{1.8}{\omega_n}, \qquad t_p = \frac{\pi}{\omega_d}, \qquad t_s \approx \frac{4}{\sigma}$$

其中 $\sigma = |\mathrm{Re}\,\lambda|$ 是实部，$\omega_d = \mathrm{Im}\,\lambda$ 是虚部，$\omega_n = \sqrt{\sigma^2 + \omega_d^2}$ 是模。**三个公式分别用到了模、虚部、实部**——也就是说，在复平面上，t_r 读的是“到原点的距离”，t_p 读的是“竖直高度”，t_s 读的是“水平距离”。

拿 $K = 0.3888$ 核对。极点是 $-0.8944 + \mathrm{j}1.7457$，所以 $\sigma = 0.8944$、$\omega_d = 1.7457$、$\omega_n = 1.9615$。三个公式给出

$$t_r \approx \frac{1.8}{1.9615} = 0.918\ \mathrm{s}, \quad t_p = \frac{\pi}{1.7457} = 1.800\ \mathrm{s}, \quad t_s \approx \frac{4}{0.8944} = 4.47\ \mathrm{s}$$

实测是 $t_r = 0.80$ s、$t_s = 4.30$ s。t_r 高估 0.12 s（15%），t_s 高估 0.17 s（4%）。t_r 的误差较大，是因为 $1.8/\omega_n$ 这条经验式在 $\zeta = 0.456$ 附近并不准——它的系数在 $\zeta = 0.5$ 附近约为 1.7，取 1.8 会偏大。

换成 $K = 0.7332$ 再看：$\sigma = 0.8045$、$\omega_d = 2.5583$、$\omega_n = 2.6817$。公式给 $t_r = 0.671$ s、$t_p = 1.228$ s、$t_s = 4.97$ s，实测 $t_r = 0.50$ s、$t_s = 4.24$ s。**t_s 的误差从 4% 涨到 17%**，因为 ζ 掉到 0.3 之后，二阶近似本身开始失效（第三极的相位贡献变大，见 §40.6.6）。

三个尺度之间的关系，比单个数值更有用。在两个工作点上算比值：

- $K = 0.3888$：$t_p/t_r = 1.96$，$t_s/t_p = 2.48$；
- $K = 0.7332$：$t_p/t_r = 1.83$，$t_s/t_p = 4.05$。

t_p/t_r 稳定在 1.8 到 2.0 之间，t_s/t_p 却从 2.48 涨到 4.05。 这说明：ζ 变小时，振荡周期（由 t_p 代表）只是略微变长，但衰减时间（由 t_s 代表）成倍拉长。物理上就是“振得更久”——频率没怎么变，包络衰减慢了。

回到轨迹上，这三件事有清楚的几何对应。K 增大时，极点在复平面上往右上方走：**竖直高度 ω_d 增大 $\to t_p$ 变短；水平距离 σ 减小 $\to t_s$ 变长；模 ω_n 增大 $\to t_r$ 变短。** 所以“加增益”这个动作，同时买到了 t_r 与 t_p 的改善，代价记在 t_s 上。

这也解释了表 40-9 里 t_s 那列的“浅碗”为什么会有起伏：$t_s = 4/\sigma$，而 σ 从 0 升到 0.974 再回落到 0，所以 t_s 必先降后升。碗底不在分离点，而在 $K \approx 0.3$ 附近，因为分离点处是**二重根**，时域项带 t 因子，衰减比同实部的单根更慢。**一个几何量（实部）配上一个重根特例，就能完整解释一条看起来杂乱的非单调曲线。**

工程上这条分析的用法是：**验收时不要只报 t_s**。t_s 对 ζ 最敏感、对模型误差也最敏感，单看它容易得出“越调越差”或“越调越好”的错误结论。规范的做法是三个都报，并用 t_r 判断“快不快”、用 M_p 判断“稳不稳”、用 t_s 判断“停不停得下来”。

40.6.9 用 Bode 交叉验证一遍

根轨迹与 Bode 图是两条完全不同的计算路径：前者解多项式求根，后者算频率响应的幅值与相位。**同一个系统，两条路径必须给出互相自洽的结论**，否则至少有一条算错了。这一小节把两边的数对一遍。

对本章对象，取五个工作点，用 `simlib.margins` 算增益裕度 G_M、相位裕度 φ_M 与增益穿越频率 ω_c：

- $K = 0.1446$：$G_M = 29.666$ dB、$\varphi_M = 69.168^\circ$、$\omega_c = 0.6837$ rad/s；

- $K=0.2436$：25.136 dB、58.741°、1.0720 rad/s；
- $K=0.3888$：21.075 dB、48.065°、1.5369 rad/s；
- $K=0.7332$：15.565 dB、33.608°、2.3561 rad/s；
- $K=1.1$：12.041 dB、25.044°、3.0100 rad/s。

第一项核对：增益裕度。 表 40-9 里同一批点的 G_M 是 29.67、25.14、21.07、15.56、12.04 dB，与上面五位逐个吻合。这不是巧合：由式 (40-16)，$G_M=20\lg(K_{\max}/K)$，而 $K_{\max}=4.4000$ 是同一个数。**两条路径算的其实是同一个量的两种写法**，对得上说明轨迹的临界点没错。

第二项核对：相位裕度与阻尼比。 工程上有一条口口相传的关系 $\zeta\approx\varphi_M/100$。把上面的 φ_M 除以 100，与表 40-9 的 ζ 并列：

- $\varphi_M=69.168^\circ\to$ 估 0.692，实际 0.800，差 0.108；
- $58.741^\circ\to$ 估 0.587，实际 0.600，差 0.013；
- $48.065^\circ\to$ 估 0.481，实际 0.456，差 -0.025；
- $33.608^\circ\to$ 估 0.336，实际 0.300，差 -0.036；
- $25.044^\circ\to$ 估 0.250，实际 0.236，差 -0.014。

中间三个点误差都在 0.04 以内，两端明显偏大，尤其是 69° 那一点差了 0.108。 这条经验式的适用范围是 φ_M 在 30° 到 60° 之间；超过 60° 后，相位裕度再涨，ζ 涨得比线性关系快得多（$\zeta=0.8$ 对应的真实相位裕度其实接近 75° 而不是 80°）。**用经验式做粗估可以，做验收不行。**

第三项核对：穿越频率的位置。 ω_c 从 0.6837 升到 3.0100，随 K 单调增大；而相位穿越频率始终是 6.3246，与 K 无关——这是本对象的结构特点：相位只由极点位置决定，与增益无关（增益只抬幅值曲线）。**所以“加增益”在 Bode 图上是把幅值曲线整体上移，穿越点右移，相位裕度变小；在根轨迹图上是沿曲线选更靠右的点。两幅图画的是同一件事。**

交叉验证的价值在于**发现系统性错误**。若某天 G_M 与 $20\lg(K_{\max}/K)$ 对不上，可能的原因只有三个：$K_{\max}$ 算错、频率响应的单位错（dB 与倍数混用）、或者对象系数被改了。**三个原因都能在十分钟内排查完，比盯着一张图找错快得多。**

最后给一条实用建议：**现场工程师习惯看 Bode，控制设计者习惯看根轨迹，两边讨论时用 G_M 做共同语言。** 它既是 dB、又直接等于 $K_{\max}/K$，两种语言都能无缝翻译。

40.7 参数意义与作用

§40.4 到 §40.6 里，变化的量一直是 K。但工程上“不确定的量”远不止增益：执行器时间常数、传感器带宽、被控对象的阻尼，都可能随工况漂移。根轨迹法有一个不太被提起的扩展——**参数根轨迹**，它把“扫增益”换成“扫任意一个参数”，用来回答“这个参数坏到什么程度系统会失稳”。

40.7.1 把参数挪到 K 的位置上

设对象仍是 $G_0(s)=10/[s(s+2)(\tau s+1)]$，但这次固定 $K=1$，让 τ 变。特征方程是

$$s(s+2)(\tau s+1)+10=0 \tag{40-17}$$

要把 τ 写成“增益”的形式，就得把含 τ 的项聚到一起、剩下的项当“分母”：

$$\tau \cdot \frac{s^2(s+2)}{s^2+2s+10} + 1 = 0 \tag{40-18}$$

于是**等效开环**是 $L_\tau(s) = \tau s^2(s+2)/(s^2+2s+10)$：两个零点在原点（二重），一个零点在 -2，两个极点在 $s^2+2s+10=0$ 的根，即 $-1 \pm \mathrm{j}3$。对 L_τ 画根轨迹，横轴刻度读作 τ 而不是 K，这张图就叫**参数根轨迹**。

这个变换有一个前提：**被扫的参数必须以线性方式出现在特征方程里**。τ 满足（它只以一次方乘在 $s(s+2)$ 上）；K 也满足。如果参数出现在分母里、或者以平方出现，就得先做代数整理，实在整不出来就只能数值扫描。整理的目标永远是同一句话：**把它写成 $1+\lambda P(s)=0$ 的标准形**。

40.7.2 七档 τ 扫出来的数

组 4 用数值方法（固定 $K=1$，直接解七次特征方程）得到表 40-8。这一列“最大实部”是判断稳定性的唯一依据：它为负则稳定，为正则发散，等于零是边界。

表 40-8　固定 $K=1$、扫描执行器时间常数 τ 的闭环极点

τ/s	最大实部	三个闭环极点	状态
0.01	-0.9491	-100.102，$-0.949 \pm \mathrm{j}3.015$	稳定
0.05	-0.7370	-20.526，$-0.737 \pm \mathrm{j}3.033$	稳定（标称）
0.10	-0.4958	-11.008，$-0.496 \pm \mathrm{j}2.973$	稳定
0.20	-0.1854	-6.629，$-0.185 \pm \mathrm{j}2.740$	稳定
0.30	-0.0323	-5.269，$-0.032 \pm \mathrm{j}2.515$	勉强稳定
0.3333	-0.0000	-5.000，$\pm\mathrm{j}2.450$	临界
0.40	$+0.0479$	-4.596，$0.048 \pm \mathrm{j}2.332$	发散

表里有两个方向相反的趋势，很容易看漏。

趋势一：实部随 τ 单调右移。 $-0.949 \to -0.737 \to -0.496 \to -0.185 \to -0.032 \to 0 \to +0.048$。也就是说，执行器越慢，闭环越不稳。这与直觉一致：一阶滞后在频率响应上贡献相位滞后，滞后越多，稳定余量越小。

趋势二：虚部随 τ 单调左移（变小）。 $3.015 \to 3.033 \to 2.973 \to 2.740 \to 2.515 \to 2.450 \to 2.332$。振荡频率在下降。这与直觉不太一致——通常认为“越不稳振荡越快”，这里恰好相反。原因在第三极：τ 变大时，第三极从 -100 一路滑到 -4.6，向主导对靠拢，把主导对的虚部“挤”小了。

两个趋势合起来，轨迹在 s 平面上是**向左下画一条斜线**，而不是垂直冲上虚轴。这也是图 40-5 的形状。

40.7.3 边界的解析解：$\tau = 1/3$、$\omega^2 = 6$

表 40-8 的临界行是数值二分出来的。它也可以手算，而且手算的过程能把“为什么是 $1/3$”讲清楚。

把 $s=\mathrm{j}\omega$ 代入式 (40-17) 的展开形式 $\tau s^3 + (1+2\tau)s^2 + 2s + 10 = 0$：

$$-\mathrm{j}\tau\omega^3 - (1+2\tau)\omega^2 + 2\mathrm{j}\omega + 10 = 0 \tag{40-19}$$

实部与虚部分别为零：

$$10-(1+2\tau)\omega^2=0,\qquad 2\omega-\tau\omega^3=0 \tag{40-20}$$

第二式在 $\omega>0$ 时给出 $\omega^2=2/\tau$，代回第一式：

$$\frac{10}{1+2\tau}=\frac{2}{\tau}\quad\Longrightarrow\quad 10\tau=2+4\tau\quad\Longrightarrow\quad \tau=\frac{1}{3} \tag{40-21}$$

边界 $1/3$ 是“分子的 10、分母的 2、以及 τ 在 s^2 项上的系数 2”三者共同决定的，不是凑出来的数。相应的振荡频率 $\omega^2=6$，即 $\omega=2.4495$ rad/s，与表 40-8 的临界行完全一致。

这个解析结果有一个用法：**它给出“参数能坏多少倍”的判据**。标称 $\tau=0.05$，边界 $1/3$，比值 6.67。也就是说，执行器时间常数劣化到标称值的 6.67 倍，系统才失稳。这个数比“增益能涨 4.4 倍”更宽，说明**本对象对执行器变慢的容忍度高于对增益的容忍度**。

临界点还有一笔可以核对的账。把 $\tau=1/3$ 代回特征多项式，两边乘 3，得到

$$s^3+5s^2+6s+30=0 \tag{40-22}$$

三个根是 -5 与 $\pm\mathrm{j}2.4495$。韦达定理逐条验：三根之和 -5 等于 s^2 系数的相反数 (-5)；两两乘积之和

$$(-\mathrm{j}2.4495)(\mathrm{j}2.4495)+(-5)(\mathrm{j}2.4495)+(-5)(-\mathrm{j}2.4495)=6+0=6$$

等于 s 的系数；三根之积 $(6)\times(-5)=-30$ 等于常数项 30 的相反数。三条全对，说明表 40-8 里 $\tau=0.3333$ 那一行的第三极 -5.000 不是数值巧合。

为什么值得核这一笔？因为**第三极离虚轴的距离，决定了二阶近似还能不能用**。用表 40-8 的六行做一次除法，把“第三极模值除以主导对的振荡频率”列出来：

τ/s	第三极	ω_d	比值
0.01	-100.102	3.015	33.20
0.05	-20.526	3.033	6.77
0.10	-11.008	2.973	3.70
0.20	-6.629	2.740	2.42
0.30	-5.269	2.515	2.09
0.3333	-5.000	2.450	2.04
0.40	-4.596	2.332	1.97

比值从 33 一路掉到 1.97。工程上判断二阶近似是否可用的常用门槛是“第三极至少是主导对的五倍远”，按这个门槛，只有 $\tau\le 0.05$ 的两行站得住；$\tau=0.1$ 时比值 3.70 已经不够，$\tau\ge 0.2$ 之后第三极与主导对只差一倍多，**此时再用二阶公式算超调和调节时间，误差会大到没有参考价值**。这正好解释了 §40.6.2 里“主导极点近似在临界附近失效”的现象：不是公式本身错了，是前提（第三极足够远）在这里不成立了。

这也给出一条实用的校核顺序：**先算第三极与主导对的比值，再决定要不要相信二阶公式**。比值大于 5，放心用；介于 2 与 5，当粗略估计；小于 2，直接做时域仿真。这一步只需要一次求根加一次除法，比事后发现公式偏差再回头查原因省事得多。

40.7.4 敏感度的边际递减

把表 40-8 换算成“每增加 0.01 s 的 τ，实部右移多少”：

区间	$\Delta\lvert\mathrm{Re}\rvert$	每 0.01 s 的平均右移
0.01→0.05	0.2121	0.0530
0.05→0.10	0.2412	0.0482
0.10→0.20	0.3104	0.0310
0.20→0.30	0.1531	0.0153
0.30→0.3333	0.0323	0.0097

边际效应在递减：同样的 0.01 s，在最敏感的一段能推 0.053，在接近边界时只能推 0.0097。这与 §40.4.4 的“增益边际递减”是同一个几何原因——轨迹在靠近虚轴时变“平”，参数变化对实部的影响被压缩。

但“边际递减”不等于“越靠近边界越安全”。恰恰相反：**实部本身已经很小，任何一点右移都意味着相对余量的大幅缩水**。$\tau = 0.3$ 时实部只剩 0.0323，再增加 0.033 s 就归零；相对变化只有 11%，系统却从“勉强稳定”变成“临界”。**看绝对灵敏度会得出“快到头了也不敏感”的错误结论，必须同时看相对余量。**

40.7.5 参数根轨迹图

图 40-5 是 τ 的参数根轨迹，横轴是 $\mathrm{Re}\,s$，纵轴是 $\mathrm{Im}\,s$，每一点标注对应的 τ 值。

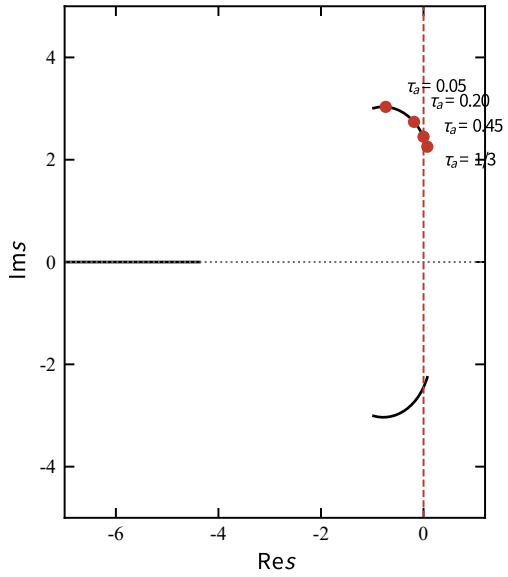

图 40-5　执行器时间常数的参数根轨迹

图上能直接看到三件事：轨迹从左下往右上走（τ 增大，实部右移、虚部减小）；两个零点在原点、一个在 -2，所以轨迹的终点是这两处；临界点恰在虚轴上 $\pm\mathrm{j}2.45$，与式 (40-21) 的 $\omega = 2.4495$ 对应。

与 §40.4 的图 40-2 对照，会发现两张图的“形状语言”完全不同：增益根轨迹是三条支路从三个极点出发，参数根轨迹是两条支路从一对复极点出发、终点在零点。**同一套规则，换了被扫参数，起点与终点就全换了**。这也是参数根轨迹容易出错的地方——很多人把原对象的极点当成起点，忘了要先做式 (40-18) 的整理。

40.7.6 两种参数的对比

把 K 与 τ 放在一张表里比：

项	增益 K	执行器时间常数 τ
标称值	1.0	0.05 s
失稳边界	4.40	0.3333 s
可劣化倍数	4.4	6.67
临界频率	6.3246 rad/s	2.4495 rad/s
谁来决定	设计者主动选	器件与工况决定

两列的最后一行是关键区别。**K 是设计变量，τ 是既成事实**。所以根轨迹对这两个参数的用法完全不同：对 K，用它来"选工作点"；对 τ，用它来"算余量、定验收线"。前者是设计，后者是校核。

工程上还有一个隐含事实：τ 不是常数，它随温度、磨损、负载变化。标称 0.05 s 的执行器，在低温或重载下可能到 0.15 s。在表 40-8 的 0.10 与 0.20 两行之间线性内插，0.15 s 对应实部约 -0.34，还稳，但增益裕度已经缩水一半以上。**所以做根轨迹校核时，τ 要用"最坏工况值"，不是铭牌值。**

40.8 调参方法与经验

前面几节都是"给定 K 算指标"的正向问题。实际设计走的是反向：**先有验收指标，再倒推 K**。这一节把反向流程走完，并给出每一步的误差账。数据来自组 5 与一次针对七档工作点的阶跃实测（`code/ch040_sim.py` 的组 2 与组 5 联合给出极点，指标由同一对象仿真读出）。

40.8.1 反查的两个入口

验收指标通常只写两条：超调不超过多少、上升时间不超过多少。它们对应两个不同的入口。

入口一：超调 $\to \zeta \to K$。 超调只由阻尼比决定（二阶近似下），所以先用二阶公式把 M_p 翻译成 ζ，再用等 ζ 线与轨迹的交点读出 K。这条路径的好处是**不依赖增益的绝对标定**，只依赖轨迹的形状。

入口二：上升时间 $\to \omega_n \to K$。 上升时间主要由自然频率决定，用等 ω_n 圆与轨迹的交点读 K。这条路径的麻烦在于：本对象的轨迹上 ω_n 与 ζ 绑死（§40.4.4），一旦定了 ω_n，ζ 就跟着定了，没有自由度。所以**实际上只能从超调入口进，上升时间只用来验收**。

两个入口合起来的使用顺序是：先用超调定 K 的上界，再检查这个 K 给出的上升时间是否满足要求；不满足就说明光调增益不够，得改结构（§40.9）。

40.8.2 超调到阻尼比的解析反解

二阶系统的超调公式是 $M_p = \exp\!\left(-\pi\zeta/\sqrt{1-\zeta^2}\right)$，把它对 ζ 反解：

$$\zeta = \frac{\left|\ln(M_p/100)\right|}{\sqrt{\pi^2 + \left[\ln(M_p/100)\right]^2}} \tag{40-23}$$

以"超调不超过 20%"为例：$\ln 0.2 = -1.6094$，分母 $\sqrt{9.8696 + 2.5902} = 3.5299$，得 $\zeta = 0.4559$。这个数就是表 40-4 里那一行的由来——0.456 不是凑的，是从 20% 反解出来的。

常用值可以先背下来：

M_p/%	5	10	15	20	25	30
ζ	0.690	0.591	0.517	0.456	0.404	0.358

这张小表的用法是双向的：指标写 20% 就取 0.456；反过来看到 $\zeta = 0.5$ 就知道超调在 16% 左右。

40.8.3 七档工作点的实测对照

把表 40-4 的七个交点逐一做阶跃仿真，得到表 40-9。这张表是本章“轨迹读数 → 时域指标”这条链路的完整对账。

表 40-9　七个设计点的极点约束与时域实测

约束	K	ζ	M_p/%	t_r/s	t_s/s	G_M/dB
$\zeta = 0.8$	0.1446	0.800	1.51	2.06	3.19	29.67
$\zeta = 0.707$	0.1815	0.707	4.32	1.60	4.49	27.69
$\zeta = 0.6$	0.2436	0.600	9.45	1.20	3.88	25.14
$\zeta = 0.456$	0.3888	0.456	19.90	0.80	4.30	21.07
$\zeta = 0.3$	0.7332	0.300	36.90	0.50	4.24	15.56
$\omega_n = 3$	0.9219	0.252	43.61	0.43	4.75	13.58
$\omega_n = 5$	2.6620	0.071	77.94	0.23	10.85	4.36

这张表最有用的一列是 t_r：$2.06 \to 1.60 \to 1.20 \to 0.80 \to 0.50 \to 0.43 \to 0.23$，**单调、干净、没有拐点**。想表达“要快”，用上升时间；想表达“要稳”，用超调。两者在这条轨迹上不可兼得，但至少各自都是单调的，调参时不会出现“往一个方向拧、指标却来回跳”的困惑。

对比之下 t_s 一列是 $3.19 \to 4.49 \to 3.88 \to 4.30 \to 4.24 \to 4.75 \to 10.85$，中间来回波动，直到 $K = 2.66$ 才明显恶化。**这条非单调曲线不能当调参的指南针**——第 39 章 §39.7.5 已经用另一组数据得出同样结论，本章从轨迹一侧再次确认。

图 40-10 把“ζ 与 K”的关系单独画了出来，纵轴取对数。

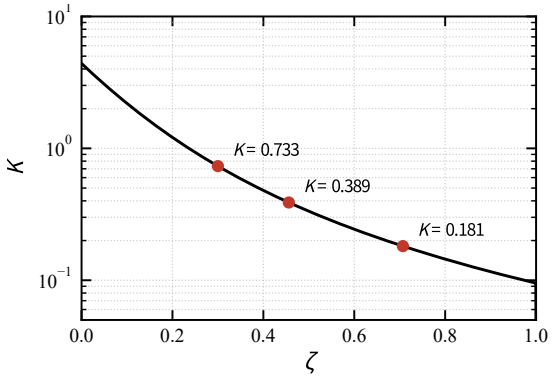

图 40-10　阻尼比与增益的关系曲线

这条曲线的形状是本章所有“非线性”说法的总源头：**左端（$\zeta \to 1$）几乎竖直，右端（$\zeta \to 0$）也几乎竖直，中间一段接近斜线**。左端竖直意味着“在分离点附近，ζ 怎么变 K 都不动”；右端竖直意味着“靠近虚轴时，K 动

一点点 ζ 就崩”。三个红点标出了 0.707、0.456、0.3 三个常用设计点，它们恰好落在中间那段接近斜线的区域——这也是工程整定总在这一段徘徊的原因。

40.8.4 反解的误差账：为什么实测总比公式小一点

拿表 40-9 的实测与式 (40-23) 的反解值对照，会看到一条很规整的规律：**公式总是略微高估，且高估量随 ζ 减小而增大**。

ζ	0.800	0.707	0.600	0.456	0.300	0.252	0.071
公式 M_p/%	1.52	4.32	9.48	19.99	37.24	44.10	80.00
实测 M_p/%	1.51	4.32	9.45	19.90	36.90	43.61	77.94
差/百分点	-0.01	0.00	-0.03	-0.09	-0.34	-0.49	-2.06

差值从 0.01 一路涨到 2.06，全部为负（公式高估）。原因与 §40.6.2 那笔“残余”同源，但方向要说清楚：表 40-7 里三阶实测也低于二阶公式（$13.82 < 13.88$、$46.05 < 46.61$、$71.38 < 73.08$），所以**第三极在这条对象上是“压超调”的，不是“抬超调”的**。这与 §40.4.2 里“临界点实测 115.35% 高于二阶 100%”看似矛盾，其实不矛盾——临界点 $\zeta = 0$ 时二阶公式的 100% 是“等幅振荡的上确界”，而任何真实的三阶系统在 $\zeta = 0$ 时的峰值由第三极的相位决定，可以大于 100%。**同一条误差公式在 $\zeta \to 0$ 附近失效，不能外推。**

工程用法：按式 (40-23) 算出 ζ 后，直接用表 40-4 的 K，**不要再手动打折**。误差最大只有 2 个百分点，方向还有利于验收（实测更小）。真正需要打折的不是这里的 2 点，而是下面三件事。

40.8.5 三笔必须在仿真里补的账

式 (40-23) 与表 40-4 给的是“标称模型、无延迟、无饱和”下的答案。现场还有三笔账，每一笔都能吃掉几个百分点的余量。

第一笔，模型误差。 对象的增益 10 若有 10% 偏差，等效于 K 偏 10%。按 §40.6.3 的相对灵敏度，超调会变 4.6 个百分点；若增益偏 20%，就是 9 个百分点。**所以增益标定的精度直接决定超调预算。**

第二笔，延迟。 第 39 章 §39.7.4 给过：$K = 0.3$ 时延迟容忍 745.8 ms，$K = 2.2$ 时只剩 46.8 ms。若回路里有 20 ms 的纯延迟，$K = 0.3888$ 这个设计点还剩多少余量，必须重算，不能拿无延迟的 19.90% 交差。

第三笔，采样。 表 40-5 已经说明 $T_s = 0.1$ s 会把临界增益砍到 48.72%。若按连续域算出的 $K = 0.3888$ 直接用于离散实现，等效的增益余量只剩 $2.1437/0.3888 = 5.51$ 倍（约 14.8 dB），比连续域的 21.07 dB 少了 6.3 dB。**离散实现的验收线要按离散轨迹重画，不能沿用连续结论。**

三笔账叠在一起，才是“留 10%~20% 增益余量”这条老经验的来历。它不是保守，而是把上面三笔的量级估进去之后的净值。

40.8.6 五步流程

把本节的做法固化成五步，列在表 40-10。

表 40-10　根轨迹法整定增益的五步

步	动作	判据	本章对应
1	画轨迹，求 $K_{\max}$、分离点、渐近线	$K_{\max}$ 有限且为正	§40.3、表 40-2
2	由 M_p 指标反解 ζ	式 (40-23)	§40.8.2
3	等 ζ 线与轨迹交点读 K	交点唯一	§40.4.4
4	阶跃仿真核对 M_p、t_r、t_s	实测不超指标	表 40-9
5	扣掉模型误差、延迟、采样三笔账，复查裕度	$G_M \geq$ 验收线	§40.8.5

五步里最容易跳过的是第 5 步。跳过它的后果很具体：按表 40-9，$\zeta = 0.456$ 的设计点 $G_M = 21.07$ dB，看起来余量充足；扣掉 $T_s = 0.1$ s 的 6.3 dB 后只剩 14.8 dB；再扣 20 ms 延迟与 10% 增益误差，可能只剩个位数。**裕度不是一次算完的，是一层层扣出来的。**

40.8.7 手算一遍五步

表 40-10 的五步读起来像流程，真到纸上会卡在细节。这一小节把 $\zeta = 0.456$ 那个工作点从头算一遍，每个中间数都写出来，方便对照。

第 1 步，画轨迹。 结果已经在 §40.3.9 得到：极点 0、-2、-20，渐近线交点 -7.3333，分离点 -0.9737（$K = 0.0951$），穿越点 $\pm \mathrm{j}6.3246$（$K = 4.4000$）。四个数齐了，轨迹的骨架就有了。

第 2 步，反解 ζ。 指标取 $M_p \leq 20\%$，即 $M_p = 0.2$。由式 (40-23)

$$\zeta = \frac{\ln(1/0.2)}{\sqrt{\pi^2 + \ln^2(1/0.2)}} = \frac{1.60944}{\sqrt{9.86960 + 2.59029}} = \frac{1.60944}{3.52986} = 0.4560$$

这个数要记住：**20% 超调对应 $\zeta \approx 0.456$**，与常见的“$\zeta = 0.707$ 对应 4.3%”是同一张表上的两行。

第 3 步，在轨迹上找交点。 等 ζ 线是以原点为顶点的射线，与轨迹的交点用数值求得 $\lambda = -0.8944 + \mathrm{j}1.7457$。核对：$|\lambda| = 1.9615$，$-\mathrm{Re}\,\lambda/|\lambda| = 0.8944/1.9615 = 0.4560$，与第 2 步一致。

第 4 步，用模值条件标定 K。 这是手算最容易出错的一步。按 G_0 的原始形式 $10/[s(s+2)(0.05s+1)]$，模值条件是

$$K = \frac{|s|\,|s+2|\,|0.05s+1|}{10}$$

三个因子逐个算：

$$|s| = 1.9615, \qquad |s+2| = |1.1056 + \mathrm{j}1.7457| = 2.0664$$

$$|0.05s+1| = |0.9553 + \mathrm{j}0.0873| = 0.9593$$

连乘得 $1.9615 \times 2.0664 \times 0.9593 = 3.888$，除以 10 得 $K = 0.3888$。与表 40-9 的 0.3888 完全一致。

这里有一个必须说清的坑。 若把 G_0 写成首一分母形式 $200/[s(s+2)(s+20)]$，模值条件变成 $K = |s||s+2||s+20|/200$，三个因子是 1.9615、2.0664、19.1852，乘积 77.76，除以 200 仍是 0.3888。**两种写法给出的 K 必须相同，因为环路增益 KG_0 是同一个东西。** 若用 200 作分母却只乘两个因子，或者用 10 作分子却漏掉 $|0.05s+1|$，就会算出 7.776 或别的数——这是手算标定 K 时最常见的错误，一次错十倍。

同样的算法可以核对 $\zeta = 0.6$ 的点：$\lambda = -0.9333 + \mathrm{j}1.2445$，$|\lambda| = 1.5556$，$|\lambda + 2| = 1.6391$，$|0.05\lambda + 1| = |0.9533 + \mathrm{j}0.0622| = 0.9553$，连乘 2.436，除以 10 得 0.2436，与表 40-9 吻合。

第 5 步，核对指标并扣三笔账。 二阶近似给

$$t_s \approx \frac{4}{|\mathrm{Re}\,\lambda|} = \frac{4}{0.8944} = 4.47\ \mathrm{s}$$

实测 4.30 s，差 0.17 s；M_p 公式给 20.00%，实测 19.90%，差 0.1 点。两项都在允许误差内，说明主导极点近似在这个点上可用。接着按 §40.8.5 扣账：$T_s = 0.1$ s 的离散化把增益余量从 21.07 dB 削到 14.8 dB，再留 10% 增益误差的余量，最后得到的设计裕度才是可以写进报告的。

五步走完，纸面上留下的数只有五个：0.4560、-0.8944、1.7457、0.3888、19.90。**其余全是过程。** 现场交接时把这五个数写进整定记录，比贴一整张仿真曲线更有用。

40.8.8 两个指标打架时，先看哪个是硬约束

反查流程里有一个隐含前提：指标是可同时满足的。现实里常常不是——要快就得让超调上去，要平就得接受慢。这时需要的不是“折中”，而是一张**边际价格表**：每多付一个百分点的超调，能换回多少时间。

组 11 的超前校正恰好提供了这样一张表。同一个补偿器、同一条轨迹，只改归一化增益，十档实测如下（M_p 单位 %，t_r、t_s 单位 s）：

K_{norm}	M_p	t_r	t_s
0.30	0.00	2.09	4.73
0.50	0.00	0.53	3.30
0.70	7.22	0.36	2.71
1.00	20.42	0.26	2.42
1.50	37.06	0.20	2.08
2.00	49.79	0.16	2.86

把相邻两档的增量相除，就得到每秒钟上升时间要付多少超调：

- $0.30 \to 0.50$：超调仍为 0，上升时间从 2.09 掉到 0.53，**这一段是免费的**；
- $0.50 \to 0.70$：付 7.22 点，换 0.17 s，约 42 点每秒；
- $0.70 \to 1.00$：付 13.20 点，换 0.10 s，约 132 点每秒；
- $1.00 \to 1.50$：付 16.64 点，换 0.06 s，约 277 点每秒；
- $1.50 \to 2.00$：付 12.73 点，换 0.04 s，约 318 点每秒。

价格从“免费”一路涨到 318 点每秒，**单调变贵，没有回头**。这就是可用的判据：只要边际价格还在可接受范围内就继续加增益，一旦跨过门槛就停手。以“每点超调换 0.1 s”为门槛，$0.50 \to 0.70$ 这一档刚好在门槛内，再往后全面超标。

调节时间那一列还给出了第二个信号：t_s 在 $K_{\mathrm{norm}} = 1.50$ 处触底（2.08 s），之后掉头向上，到 4.00 时涨到 21.12 s，是底部的十倍。**这就是 §40.6.4 说的“浅碗”**——碗底很平，一旦越过碗沿，代价是数量级的。

两条合起来给出一条可执行的选择顺序：**先把超调当硬约束（比如 $\le 10\%$），在满足它的档位里选 t_r 最小的；再看 t_s 是否还在可接受区间。** 对这个对象，答案落在 $K_{\text{norm}}=0.70$（$M_p=7.22\%$、$t_r=0.36$ s、$t_s=2.71$ s）；若现场要求零超调，就退到 0.50，只损失 0.17 s 的上升时间，却换来完全无超调——**这笔交换在多数工业场合是划算的。**

反过来做——先定“最快”，再想办法压超调——就会掉进 $K_{\text{norm}}\ge 2$ 的区间，然后用限幅、滤波、前馈一层层打补丁。补丁越多，模型越不可信，根轨迹也就越算不准。**指标的顺序决定了后面所有工作的难度。**

40.9 优化与改进

§40.8 的五步走完，如果发现“超调与快速”怎么都凑不齐，那就不是调参的问题，是结构的问题。根轨迹法的强项正在这里：**加一个零点或极点，整条轨迹的形状会变，原本绑死的两个指标有机会解开。**这一节用组 3 与组 9 的数据说明四种整形手段的代价。

40.9.1 整形改的是轨迹，不是增益

整形（compensation）与调增益的区别，用一句话说清：调增益是**在同一条曲线上选点**，整形是**换一条曲线**。前者只有一个自由度，后者每加一个零极点就多一个自由度，但也多一份代价。

四种常见手段列在下面，本章都用同一对象实测：

1. 串一个零点（PD 的雏形）；
2. 串一个极点（低通滤波的雏形）；
3. 超前校正 $(s+z)/(s+p)$，$p>z$；
4. 滞后校正 $(s+z)/(s+p)$，$p<z$。

判据只有两条：**临界增益变多少、同等工作点下超调变多少。**两条都要看，只看一条会得出错误结论。

40.9.2 串零点：临界增益推到无穷

组 3 的原始输出里，“加零点 $s=-1$”与“加零点 $s=-4$”两行的 $K_{\max}$ 都是 `inf`。数值上是二分法找不到上界（在 $K\le 10^3$ 内都不穿越），解析上可以解释：加零点后 $n-m=2$，两条渐近线垂直向上，交点

$$\sigma_a=\frac{\sum p_i-\sum z_i}{n-m}=\frac{(-2-20)-(-z)}{2} \tag{40-24}$$

对 $z=1$，$\sigma_a=(-22+1)/2=-10.5$；对 $z=4$，$\sigma_a=-9$。**两者都在左半平面**，所以复极点对沿 $\operatorname{Re}s=\sigma_a$ 垂直上升，永远碰不到虚轴。这就是 $K_{\max}=\infty$ 的几何原因。

但“稳定”不等于“好用”。组 9 的归一化数据给出了同等工作点（1 rad/s 处环路增益 0.3）下的实测：

- 零点在 -1：没有复极点对（两个根都在实轴上），超调 0.00%，$t_s=5.18$ s；
- 零点在 -4：$\zeta=0.7682$，超调 2.66%，$t_s=3.05$ s。

两者的差别值得琢磨。零点在 -1 更靠近原点，把轨迹“吸”得很厉害，两个根全被拉到实轴上，系统变成过阻尼——超调没了，速度也慢了。零点在 -4 远一些，轨迹仍保留一对复极点，$\zeta=0.768$，超调 2.66%，t_s 3.05 s 反而比原对象（3.41 s）更快。**零点不是越靠右越好，太靠右会把系统拖成过阻尼。**

40.9.3 串极点：临界增益掉得比想象多

“加极点 $s=-5$”的原始 $K_{\max}$ 是 5.2812，比原来的 4.4 还大——乍看像是“加极点反而更稳”。这是**归一化陷阱**：加极点把分母乘了一个 $(s+5)$，低频增益被削到原来的 $1/5$，所以同样标称的 K 对应的环路增益只有原来的五分之一。要恢复同样的环路增益，K 得乘 5。

组 9 按 1 rad/s 处的环路增益对齐后，真相出来了：**归一化临界增益只有 1.0357，是原对象 4.4 的 23.5%，掉了 76.5%**。同等工作点下超调从 13.82% 涨到 29.62%，t_s 从 3.41 s 拉长到 7.04 s。

“加极点 $s=-40$”的归一化临界增益是 2.8836（原对象的 65.5%），超调 15.51%，$t_s=4.71$ s。同样是加极点，-40 的伤害比 -5 小得多。原因是**极点越靠近穿越频率，附加相位滞后越大**：-5 落在穿越频率（1.3 到 3 rad/s）附近，-40 远在穿越频率之外，在 ω_c 处只贡献很小的滞后。

这条对比给出一个实用的设计规则：**如果必须加极点（例如为了滤高频噪声），把它推到穿越频率的 10 倍以外，代价可以从 -76% 压到 -34%**。当然，推得越远，滤波效果越差，这是另一笔账。

40.9.4 超前与滞后：同一对零极点，顺序决定命运

超前与滞后用的是同一对零极点，只是位置关系相反：

- 超前：$\dfrac{s+1}{s+5}$，零点在 -1、极点在 -5，零点更靠右；
- 滞后：$\dfrac{s+1}{s+0.2}$，零点在 -1、极点在 -0.2，极点更靠右。

两者的原始 $K_{\max}$ 分别是 15.8217 与 2.4636，差 6.4 倍；归一化后是 4.3881 与 3.4164，差 1.28 倍。**原始数的差距大部分是增益标定造成的，真实差距只有 28%。** 这正是 §40.9.3 那个陷阱的第二次出现。

再看同等工作点下的动态品质，差距就非常明显了：

项	超前 $(s+1)/(s+5)$	滞后 $(s+1)/(s+0.2)$
归一化 $K_{\max}$	4.3881	3.4164
ζ	0.7074	0.2674
ω_n/(rad/s)	3.9873	1.2264
M_p/%	0.00	54.33
t_s/s	4.73	11.43

超前的 ζ 是 0.707，超调为零，ω_n 从原对象的 1.725 抬到 3.987——**又快又稳**。滞后的 ζ 只有 0.267，超调 54.33%，ω_n 掉到 1.226——**又慢又振**。

为什么会这样？超前网络的零点在 -1，正好落在原对象 0 与 -2 之间，把轨迹往左拉；极点在 -5，远离穿越频率，附加滞后小。滞后网络反过来：极点在 -0.2，紧贴原点，把轨迹往右推，相位裕度被吃掉。**同一个零点、同一个增益，只把极点从 -5 挪到 -0.2，系统就从“优秀”变成“不可用”。**

这也解释了滞后校正为什么不能单独用来改善阻尼：它的本行是**提高低频增益、改善稳态误差**（见第 42 章），代价是牺牲相位裕度。要用滞后，通常得先有足够的相位余量，或者与超前串联使用。

40.9.5 归一化：比较之前必须对齐

把组 3 的原始数与组 9 的归一化数并排放，才能看清“归一化陷阱”有多大：

表 **40-11**　四种整形手段的原始与归一化临界增益

对象	原始 $K_{\max}$	相对环路增益 c_{rel}	归一化 $K_{\max}$	同点 M_p/%
原对象	4.4000	1.0000	4.4000	13.82
加零点 -1	∞	1.4142	∞	0.00
加零点 -4	∞	4.1231	∞	2.66
加极点 -5	5.2812	0.1961	1.0357	29.62
加极点 -40	115.3798	0.0250	2.8836	15.51
超前 $(s+1)/(s+5)$	15.8217	0.2774	4.3881	0.00
滞后 $(s+1)/(s+0.2)$	2.4636	1.3868	3.4164	54.33

c_{rel} 的定义是“该整形对象在 1 rad/s 处的环路增益 ÷ 原对象在同一频率的环路增益”。它把“补偿器自带的增益”剥掉，只留下形状的影响。归一化 $K_{\max}$ = 原始 $K_{\max} \times c_{\text{rel}}$。

表里最容易被误读的两行是“加极点 -40”与“加零点 -4”。前者原始 $K_{\max} = 115.3798$，看着像提升了 26 倍，归一化后只有 2.8836，实际是**下降** 34%；后者 $c_{\text{rel}} = 4.1231$，原始与归一化都写 ∞，但它的增益是靠零点带来的 4 倍放大量撑起来的，真实形状贡献要小得多。

结论：任何“加了个环节，临界增益提高了几倍”的说法，都必须先说明按什么归一。 最稳妥的口径是“同一低频环路增益下”或“同一穿越频率下”，两者选一个并写清楚。第 43 章做校正装置设计时，会反复用到这条规范。

40.9.6 整形的三条经验

从上面四组数可以抽出三条可操作的规则。

第一，先看形状，再看增益。 整形环节自带增益，会被误读成“稳定性提升”。用表 40-11 的方法剥掉它，剩下的才是形状的贡献。零点带来的 ∞ 是真的（渐近线整体左移），极点带来的“提升”大多是假的（增益被削）。

第二，零点的位置要“够近但不过近”。 零点在 -1 把系统拖成过阻尼（$t_s = 5.18$ s），零点在 -4 保留复极点、$t_s = 3.05$ s。经验上零点放在“希望的主导极点实部附近”比较合适，太靠右会吃掉全部振荡。

第三，极点要么远离穿越频率，要么别加。 -5 让归一化 $K_{\max}$ 掉 76.5%，-40 只掉 34.5%。若目的是滤噪，极点频率至少取穿越频率的 5 到 10 倍；若目的是“压低高频增益换稳态精度”，那是滞后校正的活，得按 §40.9.4 的代价重新算。

40.9.7 四联图对照

图 40-4 把四种情形画在一起：左上原对象，右上加零点 -1，左下加极点 -5，右下超前网络。

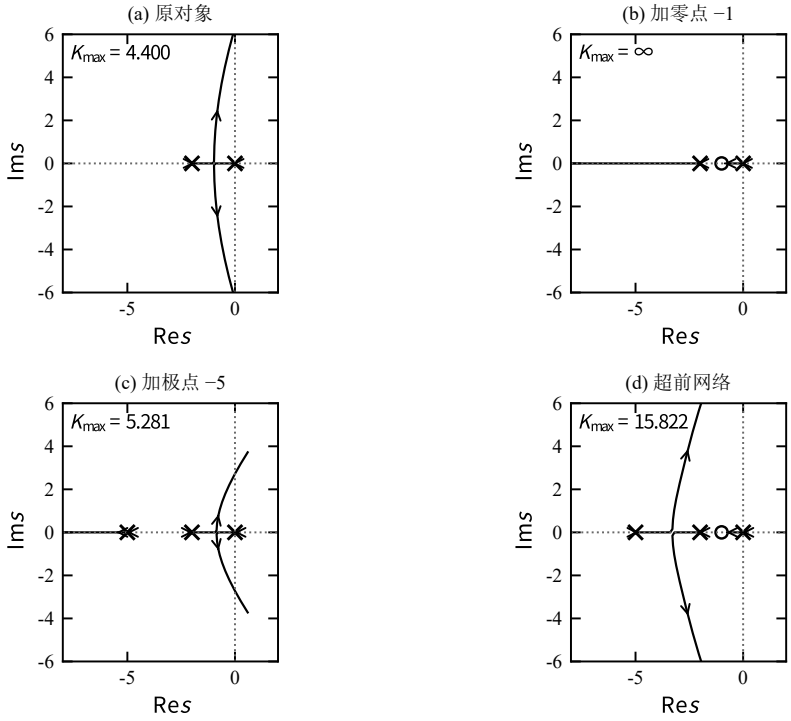

图 40-4　串零点、串极点与超前校正对轨迹的影响

四张子图对照着看，能读出三件事。

第一，加零点后轨迹“折向”零点。 右上图里，从原点出发的那条支路不再往右下走，而是拐向 -1 的零点；另一条支路则沿渐近线往左走。整张图的“重心”被零点拉过去了。

第二，加极点后渐近线多一条。 左下图从三条渐近线变成四条，交点从 -7.33 移到 -6.75（四个极点之和 -27 除以 4），同时多出一条从 -5 出发的支路。这条新支路会往右下走，是稳定性的主要威胁；图上的分离点也从 -0.974 变成 -0.856 与 -15.666 两个。

第三，超前网络的轨迹“先左后上”。 右下图里，主导对先被零点往左拉一段，再沿渐近线上升，$K_{\max}$ 因此从 4.4 提到 15.82（原始）或 4.39（归一化）。这个“先左后上”的形状，就是超前校正能同时改善阻尼与速度的几何原因。

40.9.8 超前校正的完整设计算例

前面七小节讲的是“各种整形手段各有什么代价”，这一小节把它们收束成一次完整设计：**从指标出发，选结构、定参数、核指标、算余量**，中间不给任何“经验取值”。

指标。 要求 $M_p \le 20\%$、$t_r \le 0.5$ s、$t_s \le 3$ s。

先看原对象够不够。 表 40-9 里最接近 $M_p = 20\%$ 的点是 $K = 0.3888$：$M_p = 19.90\%$、$t_r = 0.80$ s、$t_s = 4.30$ s。超调刚好卡线，但上升时间差 60%、调节时间差 43%。**这不是“再调调增益”能解决的**——沿原轨迹往右走，M_p 立刻超标；往左走，t_r 更长。两个指标被同一条轨迹绑死，必须换曲线。

选结构。 用超前网络

$$C(s) = \frac{s+1}{s+5}$$

零点放在 -1，落在对象两个低频极点 0 与 -2 之间，用来把轨迹往左拉；极点放在 -5，离穿越频率足够远，附加滞后小。这两个位置不是随手取的：零点若放到 -4，c_{rel} 会到 4.1231，增益标定被放大四倍，比较起来更麻烦；极点若放到 -2 附近，会把对象极点“顶”回去，等于没加。

这个网络的相位超前在 $\omega_m = \sqrt{1 \times 5} = 2.2361$ rad/s 处最大，峰值

$$\varphi_m = \arcsin\frac{5-1}{5+1} = \arcsin 0.6667 = 41.81^\circ$$

这正是“超前”两个字的来源：在中频段凭空补进 41.81° 相位。

归一化。 按 §40.9.5 的口径，$c_{\text{rel}} = 0.2774$，归一化临界增益 $K_{\max,\text{norm}} = 4.3881$。这个数可以直接和原对象的 4.4000 比：加了这个超前网络，轨迹的“长度”几乎没变，变的是形状。

扫描定工作点。 组 11 沿归一化增益扫了十档，关键几档是：

- $K_{\text{norm}} = 0.30$：$\zeta = 0.7074$、$M_p = 0.00\%$、$t_r = 2.09$ s、$t_s = 4.73$ s；
- $K_{\text{norm}} = 0.50$：$\zeta = 0.5469$、$M_p = 0.00\%$、$t_r = 0.53$ s、$t_s = 3.30$ s；
- $K_{\text{norm}} = 0.70$：$\zeta = 0.4420$、$M_p = 7.22\%$、$t_r = 0.36$ s、$t_s = 2.71$ s；
- $K_{\text{norm}} = 1.00$：$\zeta = 0.3374$、$M_p = 20.42\%$、$t_r = 0.26$ s、$t_s = 2.42$ s；
- $K_{\text{norm}} = 2.00$：$\zeta = 0.1598$、$M_p = 49.79\%$、$t_s = 2.86$ s；
- $K_{\text{norm}} = 4.00$：$\zeta = 0.0167$、$M_p = 83.16\%$、$t_s = 21.12$ s。

$K_{\text{norm}} = 1.00$ 那一档超调 20.42%，刚好越线 0.42 点；$K_{\text{norm}} = 0.70$ 三项全过，且留出 12.78 点的超调余量。取 $K_{\text{norm}} = 0.70$ 为设计点。

换算回原始增益。 $K = 0.70 / c_{\text{rel}} = 0.70 / 0.2774 = 2.5239$。这里要当心：$2.5239$ 比原对象的 $K_{\max} = 4.4000$ 小，看着“增益不高”，但它的环路增益在 1 rad/s 处与原对象 $K = 0.70$ 时完全相同。直接拿 2.5239 和 4.4 比大小，就是 §40.9.3 那个陷阱。要比就比 K_{norm}：0.70 对 4.3881，余量 6.27 倍，即 15.94 dB。

核指标。 实测 $M_p = 7.22\%$、$t_r = 0.36$ s、$t_s = 2.71$ s，三项全部达标，且 t_r 还有 28% 余量。

但这里出现了一个必须解释的反常。 按二阶公式，$\zeta = 0.4420$ 应该给出

$$M_p = \exp\frac{-\pi \times 0.4420}{\sqrt{1 - 0.4420^2}} = 21.3\%$$

实测只有 7.22%，差 14 点。二阶公式在这里失效了。

原因是闭环里有一对“没对消干净的偶极子”。$K = 2.5239$ 时闭环极点是 -0.8461、$-2.3288 \pm \mathrm{j}4.7250$、$-21.4962$，闭环零点在 -1。零点 -1 与极点 -0.8461 靠得很近，但没有重合。做留数分解，阶跃响应写成

$$y(t) = 1 + \sum_{i} \frac{r_i}{p_i} \mathrm{e}^{p_i t}$$

三项系数分别是：慢极点 -0.8461 对应 -0.1813，主导对对应 $-0.3795 \pm \mathrm{j}0.3393$，远极点 -21.4962 对应 -0.0598。三者相加为 -1.000，保证 $y(0) = 0$。

关键在于慢极点那一项的**负号**：它在峰值时刻仍在缓慢衰减，方向与主导对的振荡相反，把峰值往下压。峰值出现在 $t = 0.74$ s，此时慢极点项约为 -0.097，主导对的振荡包络约 0.181，两者相消，净峰值只剩 0.072。二阶公式只看 ζ，不看留数；一旦有未对消的偶极子，误差可以到十几点。

这笔“意外之财”要不要用？ 可以用，但要知道它的代价：偶极子的位置取决于对象参数，对象极点从 -2 漂到 -2.2，零点 -1 与极点 -0.8461 的对消关系就变了，超调可能从 7% 跳到 20%。**用未对消的偶极子换超调，等于用鲁棒性换指标**，交付时必须写明。

最后核一次余量。 设计点 $K_{\text{norm}}=0.70$，$K_{\max,\text{norm}}=4.3881$，余量 6.27 倍。若再叠加 $T_s=0.1$ s 的数字实现，按 §40.5.6 的经验，临界增益大约要打对折，余量降到 3 倍上下；这个数已经接近“能用但不宽裕”的边界，**所以这只超前网络值得配一个更快的采样率**。

把这次设计的结论压成一句话：**同一条轨迹上，$M_p=20\%$ 时 $t_s=4.30$ s；换一条轨迹后，$M_p=7.22\%$ 时 $t_s=2.71$ s——超调更低、速度更快，代价是高频增益抬了 5 倍、并对对象参数更敏感。**

40.9.9 滞后校正：它是稳态装置，不是动态装置

超前网络能同时改善阻尼与速度，很容易让人以为“整形就选超前”。但滞后网络是另一类工具，用对了地方不可替代，用错了地方比不整还差。这一小节把它的适用条件写清楚。

滞后网络与超前网络形式相同，只是极点比零点更靠右：

$$C(s)=\frac{s+1}{s+0.2}$$

零点在 -1、极点在 -0.2，直流增益 $C(0)=1/0.2=5$。**它的本行是提高低频增益**：把 K_v 抬高 5 倍，斜坡稳态误差从 0.5144 降到 0.1029（§40.4.7 算过）。

但组 9 的数据说明了它的代价。在同样的归一化工作点 $K_{\text{norm}}=0.3$ 上：

项	原对象	滞后 $(s+1)/(s+0.2)$
ζ	0.5322	0.2674
ω_n/(rad/s)	1.7250	1.2264
M_p/%	13.82	54.33
t_s/s	3.41	11.43

超调翻了近四倍，调节时间拉长三倍多。 这不是“参数没调好”，是滞后网络把主导极点往右推了：极点在 -0.2，离原点太近，轨迹在低频段就被它拽住，ζ 从 0.53 掉到 0.27。

问题出在零极点的位置选得不对。教科书给出的滞后设计准则是：**零极点都要放在穿越频率的十分之一以下**，例如穿越频率 2.7 rad/s 时，零点取 0.27、极点取 0.027。这样在穿越频率处，滞后网络贡献的相位几乎为零。本章这只网络把零点放在 1 rad/s，已经和穿越频率同量级，代价自然大。

算一下相位账。在 $\omega_{180}=2.7217$ rad/s（$K_{\max}$ 处的穿越频率）上，

$$\angle C(\mathrm{j}\omega)=-\arctan\frac{2.7217}{0.2}+\arctan\frac{2.7217}{1}=-85.80^\circ+69.83^\circ=-15.97^\circ$$

滞后网络在这里吃掉了 16° 相位。**只要把零极点整体往低频挪十倍，这个角就会降到两度以内**，而直流增益 5 一点不少。**同样的增益提升，代价可以差一个数量级，差别只在零极点放在哪。**

这解释了 §40.9.4 那句“滞后不能单独用来改善阻尼”的深层原因：**它的设计自由度是给稳态用的，不是给动态用的**。若系统本来相位裕度就不足，加滞后只会更糟；若系统相位裕度充足、只是稳态误差不达标，滞后是最省事的手段。

工程上的三条用法：

1. **单独用滞后**：仅当相位裕度大于 45°、且指标卡在稳态误差上；
2. **滞后 + 超前**：滞后管低频增益，超前管穿越频率附近的相位，两者串联（滞后-超前校正），第 43 章会给出完整设计流程；
3. **不要用滞后去压超调**：它的极点在低频，压超调的效果远不如超前，代价却大得多。

最后提醒一个容易混淆的地方：**滞后的 $K_{\max}$ 原始值 2.4636 比原对象的 4.4000 小，看起来“更不稳”，但归一化之后是 3.4164，只低 22%。** 这个“看起来”来自 $c_{\text{rel}} = 1.3868$——滞后网络自己带了 1.39 倍的增益，把原始 K 的刻度压缩了。又一次，**不看 c_{rel} 就会得出相反结论。**

40.9.10 超前的三笔代价：低频、噪声、初始冲击

§40.9.8 用超前把上升时间压到 0.36 s，看起来是纯赚。但超前网络 $(s+1)/(s+5)$ 在把高频相位抬起来的同时，也在另外三处留下了账单。这三笔账不写进设计报告，现场调试时一定会碰上。

第一笔：低频增益损失。 网络在 $s=0$ 处的增益是 $1/5 = 0.2$，即 -13.98 dB；在 $s \to \infty$ 处归一化为 1。也就是说，它把低频环路增益压低了 14 dB，换来高频的相位超前。

这一笔的后果要看对象有没有积分器。本对象含 $1/s$，阶跃输入下仍是零稳态误差，所以看不出损失；但**斜坡误差会变**。本例的 $K_v = \lim_{s\to 0} sL(s) = K_{\text{raw}}$，在 $K_{\text{raw}} = 2.5239$ 处对应 $e_{ss} = 1/2.5239 = 0.3962$；而原对象在 $K = 0.3888$ 时 $K_v = 1.944$，$e_{ss} = 0.5144$。超前的斜坡误差反而更小——因为增益抬得更多，把低频损失补回来了。**但若对象不含积分器，这 14 dB 会直接加到稳态误差上，放大 5 倍。** 这一点在换对象时必须重算，不能照搬。

第二笔：高频噪声放大。 相对直流增益，网络在高频段放大了 5 倍，即 $+13.98$ dB。传感器上 10 mV 的开关噪声，经过它变成 50 mV 进入执行器。噪声不会让根轨迹变形（它是小的、零均值的），但会让执行器持续抖动、发热、磨损。**判断这一笔是否可接受，要看执行器的带宽和噪声频谱**：噪声频率若远高于穿越频率，会在对象里被积分衰减，问题不大；若噪声落在穿越频率附近，就会直接调制控制量。

第三笔：初始冲击。 阶跃瞬间，超前网络的输出是 $K_{\text{raw}} \times e$，本例 2.5239 倍误差；原对象在 $K = 0.3888$ 时只有 0.3888 倍。**比值 6.5 倍。** 这意味着同样一个 1 V 的阶跃，超前方案会要求执行器瞬间给出 2.52 V，而原方案只要 0.39 V。限幅若设在 2 V，超前方案一上来就饱和，§40.10.3 说的等效增益下降立刻发生，设计的极点位置根本达不到。

三笔账里，第一笔靠重算、第二笔靠频域核对、第三笔靠限幅仿真，**没有一笔能靠“看根轨迹”发现**。这也是 §40.9.6 三条经验的补充：整形手段的收益在图上，代价在图上找不到。

顺带一笔容易被说反的账。加上超前之后，闭环第三极的绝对值确实从 -20.70 退到了 -25.67，但主导对的频率涨得更快（$3.9873 \to 10.7444$），两者比值反而是**下降**的：$5.19 \to 4.53 \to 4.08 \to 3.64 \to 3.19 \to 2.92 \to 2.73 \to 2.59 \to 2.48 \to 2.39$。也就是说，**第三极绝对距离变大，不等于二阶近似更好**；按 §40.7.3 给的门槛，只有 $K_{\text{norm}} \le 0.30$ 那一档（5.19）勉强合格，0.70 时（4.08）已经在“粗略估计”区间。这正好解释了 §40.9.8 里“二阶公式给 21.3%、实测只有 7.22%”为什么不能只赖第三极：它只能解释其中一小部分，剩下的大头要记在闭环零点与慢极点的偶极子账上。

40.10 工程落地

到这里，方法本身讲完了。但根轨迹是一张“数学图”，它建立在三个假设上：**开环是线性有理函数、参数是常数、信号不受限**。真实系统每一条都不满足。这一节逐条检查这些假设被破坏时会发生什么，并给出一张交付前的自查表。

40.10.1 零极点对消：纸面上完美，现场里危险

整形最诱人的一招是“用控制器零点去对消对象的不利极点”。比如对象有一个 -2 的极点拖慢了响应，就在控制器里放一个 $(s+2)$ 把它约掉，闭环看起来只剩两个快极点。

这一步在数学上成立，在工程上有三个坑。

坑一，对消不干净。 控制器零点取 -2.00，而对象的极点在 -2.05（建模误差或温漂），差 0.05，两者没有真正约掉，而是形成一对“偶极子”（dipole）。偶极子的慢模态时间常数约 $1/0.05 = 20$ s，幅值很小但拖得很长。阶跃响应上表现为“快速到位后缓慢爬行”，最后那一段尾差可能正好落在稳态误差验收里。**对消的精度取决于器件容差，而容差通常是 5% 到 20%。**

坑二，对消了不稳定的极点，等于把隐患藏起来。 如果对象有一个右半平面极点（不稳定的被控对象，见第 52 章），用控制器零点去“对消”它，闭环特征方程里那一项确实消掉了，但**这个模态仍然存在于系统内部**，只是不再出现在输入输出传递函数里。一旦有扰动或饱和把它激励起来，它照样发散，而输出端看不到。这叫“内部稳定性”问题，根轨迹图完全反映不出来。**规则很硬：右半平面极点只能用反馈拉回来，不能用零点约掉。**

坑三，对消会吃掉相位。 控制器零点在 -2，同时必须配一个极点（否则不是真有理函数），这个极点通常放在很远的地方。它在穿越频率处贡献的相位滞后是 $\arctan(\omega_c/p)$ 量级。若 $p=20$、$\omega_c=3$，滞后约 8.5°，不算大；若为了省成本把 p 放在 -8，滞后就有 20.6°，直接把刚对消掉的好处还回去。

工程上的稳妥做法是：**不做精确对消，让零点与对象极点保持 2 到 5 倍的距离**，把它当成“整形”而不是“消去”。这样偶极子不会形成，慢模态也不会出现。

40.10.2 物理可实现性：纯微分不存在

理想 PD 控制器 $C(s) = K_p(1 + T_d s)$ 的零点在原点左侧任意位置，高频增益无限大。这在根轨迹上是合法的（零点可以放在任何地方），在电路上做不到。

两个原因：一是**微分放大噪声**，传感器噪声在 1 kHz 以上很常见，纯微分的增益随频率线性上升，会把噪声放大到饱和；二是**真有理函数的要求**，分子阶次不能高于分母阶次，所以必须加一个滤波极点：

$$C(s) = K_p\left(1 + \frac{T_d s}{T_f s + 1}\right), \qquad T_f = \frac{T_d}{5 \sim 10} \tag{40-25}$$

T_f 的取值把补偿后的零点放在 $-1/(T_d + T_f)$、滤波极点放在 $-1/T_f$，两者相距 5 到 10 倍。**这个极点的位置就是 §40.9.3 里那个“加极点”的代价**——它必须放在穿越频率之上足够远，否则相位滞后会吃掉微分带来的超前。

数字实现还有一层：微分用后向差分 $(1 - z^{-1})/T_s$ 近似，在 $\omega_s/2$ 附近相位误差很大；而且 T_s 越小，差分对噪声越敏感。所以**数字 PID 的微分项几乎总要配一个低通滤波**（见第 44 章、第 106 章）。

40.10.3 饱和与速率限制：根轨迹管不到

根轨迹假设增益 K 是常数。执行器饱和时，实际增益随信号幅度变化：小信号时是 K，大信号时被限幅，等效增益下降。**等效增益下降意味着极点向分离点方向移动**——按表 40-3，从 $K=1$ 退到 $K=0.3$，ζ 从 0.236 升到 0.532，超调从 46% 降到 14%。所以饱和在“超调”这一项上有时反而帮忙。

但饱和带来另外三个问题，根轨迹一个都答不了：**积分饱和**（稳态误差累积导致大幅超调）、**极限环**（饱和加延迟可以产生持续振荡）、**速率限制**（执行器跟不上指令，等效为变延迟）。这三件事要用描述函数、相平面或直接仿真处理，见第 49 章。根轨迹在这里的角色只是“给出线性设计的基准”，不是“保证非线性下的行为”。

40.10.4 延迟：轨迹上根本画不出来

纯延迟 $\mathrm{e}^{-T_d s}$ 不是有理函数，特征方程 $1+K\mathrm{e}^{-T_d s}G_0(s)=0$ 是超越方程，根的个数无穷多，根轨迹有无穷多条支路。所以严格说，**带延迟的系统没有“那张图”**。

工程上的处理是 Padé 近似，一阶形式是

$$\mathrm{e}^{-T_d s}\approx\frac{1-T_d s/2}{1+T_d s/2} \tag{40-26}$$

它把延迟变成一个**右半平面零点** $s=+2/T_d$ 加一个左半平面极点 $s=-2/T_d$。右半平面零点会吸引根轨迹向右，**在图上直接表现为“轨迹提前拐向虚轴”**，这就是延迟降低稳定性的几何解释。

以 $T_d=20$ ms 为例，零点在 $+100$ rad/s、极点在 -100 rad/s。这对零极点离穿越频率（约 1.3 到 3 rad/s）都很远，一阶 Padé 的误差可以接受；若 T_d 到 0.5 s，零点只在 $+4$ rad/s，就落在穿越频率附近，一阶近似会严重高估稳定性，必须用二阶或三阶 Padé。

更稳妥的做法是不画图、直接算：第 39 章 §39.7.4 给的延迟容忍 $T_{d,\max}$（$K=0.3$ 时 745.8 ms、$K=2.2$ 时 46.8 ms）就是这件事的定量答案。**根轨迹给“没有延迟时的形状”，延迟用单独的预算去扣。**

40.10.5 采样、量化与系数敏感度

离散实现还有三笔小账，都在 §40.5 出现过，这里只提醒它们与整形的相互作用。

采样。 表 40-5 的结论是 $T_s=0.1$ s 把临界增益砍到 48.72%。如果同时加了超前校正，穿越频率会被抬高（本章超前把 ω_n 抬到 3.987），而采样带来的相位滞后与频率成正比，**抬高穿越频率等于加重采样的伤害**。所以整形之后必须重算 T_s，不能沿用整形前的采样周期。

量化。 数字控制器的系数是有限字长的。二阶环节的极点若靠近单位圆（表 40-6 里 $\max|z|=0.9944$），系数的一个最低位扰动就可能把极点推出圆外。高阶直接型实现尤其敏感，工程上要用二阶节串联（SOS）或状态空间实现，见第 84 到 86 章。

参数漂移。 §40.7 已经说明 τ 从 0.05 漂到 0.15 会把实部从 -0.737 推到 -0.34，增益裕度缩水一半以上。整形后的系统对参数漂移往往更敏感——因为整形把轨迹“掰”成了更复杂的形状，形状越复杂，对参数越敏感。**整形越多，越要在最坏工况下重画一次轨迹。**

40.10.6 交付前的自查表

把本节与前面各节的检查点合成一张表，交付前逐条过一遍。

表 40-12　根轨迹设计的交付前自查表

序	检查项	通过标准	本章出处
1	分母是否首一化	代入 $\mathrm{j}\omega$ 前已首一化	§40.3.6
2	极点之和是否守恒	各 K 下 $\sum s_i$ 等于分母二次项系数之负	§40.4.1
3	分离点是否落在线段上	$\mathrm{d}K/\mathrm{d}s=0$ 的根中只取 $K>0$ 且在两极点之间	§40.3.5
4	$K_{\max}$ 是否双路核对	轨迹穿越与 Routh/Nyquist 一致	§40.2.5、§40.12.2
5	稳定性与品质是否分开验收	同时给 G_M 与 M_p，不互相替代	§40.6.1
6	主导极点近似是否仿真核对	t_s 误差可能到 28%	§40.6.2
7	整形前后是否同口径归一	同一低频环路增益或同一穿越频率	§40.9.5
8	是否做了零极点对消	对消距离不小于 2 倍，且不消右半平面极点	§40.10.1
9	微分是否配了滤波	$T_f=T_d/(5\sim10)$	§40.10.2
10	延迟与采样是否单独扣账	用 $T_{d,\max}$ 与离散 $K_{\max}$ 复核	§40.10.4、§40.10.5
11	是否用最坏工况参数	τ 取上限而非铭牌值	§40.7.6
12	饱和、速率限制是否单独仿真	大信号阶跃不出现极限环	§40.10.3

十二项里，第 4、5、7 三项最常被跳过，也最容易在评审时被问住。第 4 项是“数字对不对”，第 5 项是“指标全不全”，第 7 项是“比较公不公平”。三者都过了，根轨迹这部分工作才算交得出去。

40.10.7 一次整定复盘

把前六小节的内容代进一个具体场景，看错误是怎么一步步累积的。场景与数据都取自组 10，不含虚构参数。

背景。 位置伺服，控制器周期 $T_s=0.1$ s，对象就是本章主例。设计者在连续域按 $K=1.0$ 整定，仿真给出 $M_p=46.05\%$、$t_s=5.36$ s。超调偏大，但设计者认为“还有 4.4 倍增益余量，够用”，于是交付。

现场现象。 上电后阶跃响应出现接近等幅的振荡，要十几秒才勉强衰减。增益往下拧，振荡变小但跟踪变慢；拧回去，振荡立刻回来。**手感是“没有可用区间”**。

第一层排查：离散化。 把 $T_s=0.1$ s 代进离散模型，$K_{\max}$ 从 4.4000 掉到 2.1437，设计点 $K=1.0$ 的余量只剩 2.14 倍。实测指标也变差：$M_p=59.74\%$、$t_s=7.70$ s，ζ_d 只有 0.1584。**这说明“连续域调好再数字化”这一步已经吃掉了一半余量**，但还不至于振。

第二层排查：延迟。 现场控制器与驱动器之间走总线，一个周期才能把指令送到。把这一拍延迟加进特征方程，$K_{\max}$ 变成 1.0785，设计点 $K=1.0$ 的余量只剩 7.85%——**已经在临界线上**。

相位账可以对上：零阶保持在 $\omega_{180}=6.3246$ 处贡献 18.1°，一拍 0.1 s 延迟再贡献 36.24°，合计 54.34°。原本靠 12.87 dB 增益裕度撑着的系统，被这 54° 直接吃穿。**问题不在增益，在相位；而相位在根轨迹图上根本画不出来。**

处置。 三条路，按代价排序：

1. 把总线延迟消掉（控制器与驱动器同板），$K_{\max}$ 回到 2.1437，$K=1.0$ 的余量回到 2.14 倍，但超调仍是 59.74%；
2. 把 K 降到 0.6，延迟一拍下余量 $1.0785/0.6=1.80$ 倍（约 5.1 dB），实测 $M_p=39.34\%$、$t_s=5.80$ s；

3. 提高采样率到 0.05 s，连续域的离散临界增益回到 2.8637，但延迟的绝对时间没变，**必须重新按“两拍”折算**，不能直接套用。

现场最后选的是“消延迟 + 降到 $K = 0.6$”：余量足够，超调仍偏大，于是再加一个超前网络（§40.9.8 的那只），把超调从 39.34% 压下来。**整定的顺序是“先算清延迟，再定增益，最后才动结构”**，顺序颠倒会白做。

三条教训。

第一，**连续域的 $K_{\max}$ 是“零延迟世界”的天花板**，现场的有效天花板要按最坏拍数重算，本例中两者差 4 倍。

第二，**“还有几倍增益余量”这句话，必须说明是在哪个模型上算的**。4.4 倍、2.14 倍、1.08 倍，是同一个系统在三种假设下的三个答案，写报告时只能写最小的那个。

第三，**振了不要先怀疑对象**。本例对象参数完全没变，变的是环路里的两段相位。先量延迟、再量采样、最后才怀疑模型，这个排查顺序能省掉大半时间。

40.10.8 从图纸到接线：五条落地清单

自查表管的是“算得对不对”，这一小节管的是“装得对不对”。五条都来自本章踩过的坑，每条给出一个可执行的检查动作。

第一条，先量延迟，再算增益。 不要用铭牌上的采样周期代替真实延迟。控制器算出指令、总线传过去、驱动器执行，这三段加起来常常是“两拍”而不是“一拍”。量法很简单：在控制器里发一个脉冲，用示波器看执行器响应的时刻，差值除以 T_s 就是拍数。本章的数据说明这件事有多要紧：$T_s = 0.1$ s 下，0 拍是 2.1437，1 拍是 1.0785，2 拍是 0.7325——多一拍，天花板少一半。

第二条，增益用归一化刻度记录。 交接单上只写“$K = 2.5239$”是没有意义的，因为换了补偿器、换了采样周期，同一个 K 对应的环路增益完全不同。要写三个数：K、c_{rel}、K_{norm}。本章超前网络那一例，$K = 2.5239$ 看着比原对象的 4.4000 小，但 $K_{\text{norm}} = 0.70$，环路增益其实与原对象 $K = 0.70$ 时相同。**只写原始 K，下一个人必然误读。**

第三条，微分必须配滤波，且滤波时间常数要记录。 纯微分在物理上不存在，实现时一定是 $T_d s/(T_f s + 1)$。T_f 取 T_d 的 $1/5$ 到 $1/10$，这个极点会往轨迹里加一条支路、贡献相位滞后。若 T_f 取得太小，高频增益过大，噪声会把执行器打饱和；取得太大，微分作用被磨掉。**两个极端都会在现场暴露，但原因完全不同**，所以 T_f 必须写进参数表，不能留在代码里当常数。

第四条，限幅与抗饱和要单独仿真，不能靠根轨迹。 根轨迹假设信号不受限，而饱和是强非线性。大阶跃下若积分器仍在累积，会出现“退饱和延迟”，表现为超调远大于线性预测。检查动作：把阶跃幅度加到额定值的 3 到 5 倍，看是否出现极限环或长尾。本章的自查表第 12 项就是这一条。

第五条，上线前做“加倍压力测试”。 把延迟按最坏拍数的两倍代入，把增益按设计值的 1.5 倍代入，各跑一次阶跃。本章设计点 $K = 0.3888$、$T_s = 0.1$ s、名义一拍延迟，加倍后是两拍，$K_{\max} = 0.7325$，余量 $0.7325/0.3888 = 1.88$ 倍（约 5.5 dB）。**这个数才是“最坏情况下还剩多少”，比名义余量有意义得多。**

五条里最容易漏的是第一条与第二条：前者是“没量就假设”，后者是“记了数但记错了刻度”。两条都不需要额外设备，只需要在流程里加一行检查。**根轨迹算得再准，也救不回一个把延迟当零的交接单。**

40.11 优缺点与适用边界

任何方法都有它擅长的战场和它答不了的问题。这一节把根轨迹法的边界划清楚，并补上本章一直没提的一个变体——零度根轨迹。

40.11.1 四条优点

第一，它给的是全局视图，不是单点答案。 Bode 图与 Nyquist 图都是“固定 K、看频率响应”，换一个 K 就要重画一张。根轨迹把**所有** K 的结果画在一张图上，K 只是一个刻度。这让“增益还能拧多少”这类问题一眼可答。

第二，它把稳定性与动态品质放在同一张图上。 虚轴给稳定边界，等 ζ 线给阻尼，等 ω_n 圆给速度。三条信息叠在一起，不需要在两套坐标之间来回换算。§40.4 到 §40.6 的所有结论，都是在这张图上读出来的。

第三，它对参数变化有天然的敏感性分析。 §40.7 的参数根轨迹把“某个参数坏到什么程度会失稳”直接画出来，比逐点仿真快得多。同样的方法可以用在增益、时间常数、甚至传感器带宽上。

第四，它给整形提供了几何直觉。 加零点轨迹往哪拐、加极点往哪推、超前为什么能“先左后上”，这些在根轨迹上都是看得见的形状变化。§40.9 的四组数如果能记住形状，比记住数字更有用。

40.11.2 四条局限

第一，一次只能扫一个参数。 这是最硬的限制。真实系统里 K、τ、负载、温度同时在变，根轨迹只能固定其余、扫一个。多参数同时变化要用别的工具（例如 μ 分析，见第 57 章）。

第二，只适用于单回路。 多变量系统的闭环极点由 $\det(sI - A + BK)$ 决定，不能拆成几个单回路的根轨迹叠加。多变量情形要用特征轨迹、σ 图，见第 39 章 §39.11.5 与本章 §40.11.5。

第三，画不出延迟与非有理环节。 §40.10.4 已说明：纯延迟让特征方程变成超越方程，根有无穷多个。Padé 近似能救急，但近似阶数选错会给出错误的稳定边界。

第四，对右半平面零点“看起来还行，实际不行”。 非最小相位零点会把轨迹往右拉，$K_{\max}$ 可能仍然有限且为正，图上看着“稳定”，但阶跃响应会有反向初始响应（下冲），这是根轨迹图上看不见的。**判非最小相位系统不能只看轨迹，要看阶跃。**

40.11.3 零度根轨迹：正反馈与 0° 条件

本章前面所有推导都基于负反馈，特征方程 $1 + KG = 0$，相角条件是 180°。正反馈时特征方程变成

$$1 - KG(s) = 0 \quad \Longrightarrow \quad KG(s) = 1 \tag{40-27}$$

相角条件随之变成 0°：**所有开环零极点对测试点的张角之和为 0°（模 360°）**。这套规则画出来的图叫零度根轨迹。

它与 180° 轨迹的差别集中在三条规则上：实轴上的段是“右侧零极点总数为偶数”的区间（原来是奇数）；渐近线夹角是 $2q \times 180^\circ/(n-m)$（原来是 $(2q+1) \times 180^\circ/(n-m)$）；出射角公式里的 180° 换成 0°。

这三条不是另起一套理论，而是同一个相角条件在两个不同方程下的必然结果。负反馈要求 $G(s)$ 的相角为 180°，正反馈要求它为 0°；“哪个区间满足这个角”就决定了实轴段，“无穷远处 $n-m$ 个极点的角度怎么分”就决定了渐近线。**规则是从条件推出来的，不是背下来的**，这一点在换用零度轨迹时尤其重要——背错一条，整张图就全反了。

以组 7 的对象 $G=1/(s+1)^2$ 把三条规则走一遍。两个极点都在 -1，是二重极点。对实轴上 -1 右侧的点，右侧没有实零极点，计数为 0（偶数），所以在轨迹上；对 -1 左侧的点，右侧有两个极点，计数为 2（偶数），也在轨迹上。**整条实轴都在轨迹上**，二重极点只是把它分成左右两支的出发点。渐近线条数 $n-m=2$，夹角 $2q\times 180^\circ/2$，取 $q=0,1$ 得 0° 与 180°——正是实轴的两个方向，与上面按计数得到的结论完全重合。两条规则互相印证，这是手绘前最好的自检。

组 7 用一个最简单的例子验证：$G=1/(s+1)^2$，正反馈。三个增益下的根是

- $K=0.5$：-1.7071 与 -0.2929，最大实部 -0.2929；
- $K=1$：-2 与 0，最大实部 0；
- $K=4$：-3 与 $+1$，最大实部 $+1$。

临界增益用二分法求得 $K=1.000000$。这个数可以解析验证：正反馈下 $(s+1)^2=K$，两根为 $s=-1\pm\sqrt{K}$，右根 $+1$ 出现的条件是 $\sqrt{K}\ge 1$，即 $K\ge 1$。**数值与解析在六位小数上一致。**

边界点还有一层物理含义，很多人读图时会漏掉。正反馈的闭环传递函数是

$$\frac{Y(s)}{R(s)}=\frac{KG}{1-KG}=\frac{K}{(s+1)^2-K}$$

代 $K=1$ 得 $1/(s^2+2s)=1/[s(s+2)]$——**临界增益恰好把系统变成了 I 型**。极点落在原点，阶跃输入下输出是斜坡、稳态值不存在，这正是“临界”在时域里的样子：不是发散，而是停不下来。K 再大一点，极点越过原点进入右半平面，才真正发散。

两个稳定点的稳态值也可以用同一个式子核对。$K=0.5$ 时闭环是 $0.5/(s^2+2s+0.5)$，直流增益 $0.5/0.5=1$，阶跃稳态为 1，与负反馈的常规结论一致；$K=4$ 时闭环是 $4/(s^2+2s-3)$，直流增益 $4/(-3)=-1.333$，稳态为负且不稳定。**同一个公式把“稳、临界、反向发散”三种情形全解释清楚了**，这比只记“$K<1$ 稳定”要牢靠得多。

所以零度轨迹的稳定域是 $0<K<1$，是一条**有上界也有下端**的区间（K 必须为正，否则回到负反馈）。这与 180° 轨迹常见的“K 从 0 一路涨到某个上限”形状不同，读图时不能凭习惯外推。

图 40-9 是这条零度轨迹：两个极点都在 -1（二重），轨迹沿实轴一左一右分开，右支在 $K=1$ 时到达原点，$K>1$ 后进入右半平面。

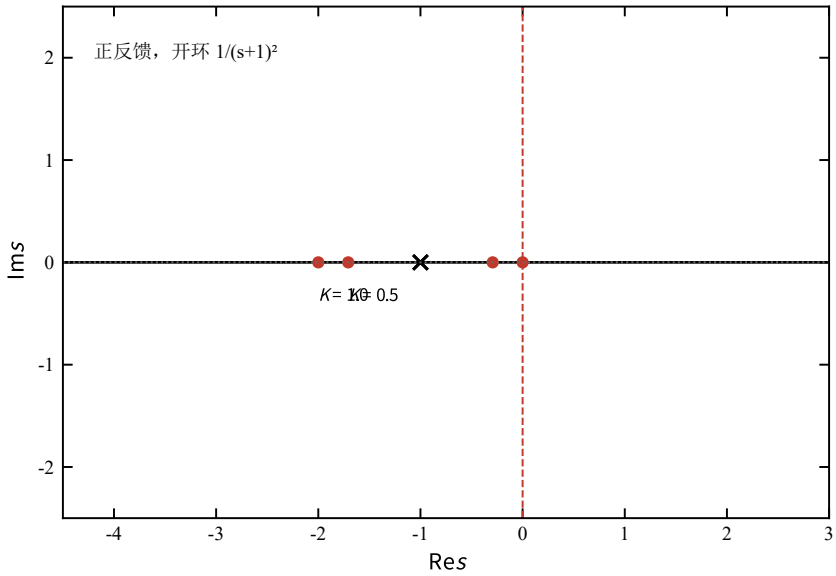

图 40-9　$G=1/(s+1)^2$ 的零度根轨迹

零度根轨迹在工程上有两个用途。一是**正反馈回路**（例如带正反馈的锁相环、某些振荡器结构）的稳定性分析；二是**非最小相位对象的整形**——有些对象的零点在右半平面，用 180° 轨迹画出来形状很怪，换成零度轨迹反而容易看出规律。但要注意：**零度轨迹的稳定域判据与 180° 完全不同，规则不能混用**。把零度轨迹当 180° 读，是最常见的错误之一。

40.11.4 与 Bode、Nyquist 的分工

三种方法在频域/复域里各管一段，分工列在表 40-13。

表 40-13　根轨迹、Bode、Nyquist 的分工

项	根轨迹	Bode	Nyquist
自变量	K（或任一参数）	ω	ω
输出	闭环极点位置	幅值、相位	复平面曲线
稳定性判据	极点在左半平面	幅值/相位裕度	包围 $(-1,\mathrm{j}0)$ 的次数
最擅长	增益上限、极点走向、整形	带宽、相位来源、滤波器设计	多穿越、条件稳定、延迟
最不擅长	频率信息、延迟、多变量	极点位置、参数扫描	参数扫描、设计直觉
本章/他章	本章	第 39 章	第 39 章

分工的实用口诀是：**要“调多少”看根轨迹，要“为什么”看 Bode，要“有没有例外”看 Nyquist**。第 39 章 §39.11.6 给的评审三问（先问 P、再问相位来源、最后问采样），与本章的自查表是同一套思路的两个入口。

40.11.5 什么时候不该用根轨迹

四种情形，建议直接换工具。

情形一，回路里延迟显著（T_d 与 $1/\omega_c$ 同量级）。 轨迹画不出延迟，Padé 近似的阶数选择又很主观。直接用第 39 章的延迟预算或频域方法。

情形二，多变量强耦合。 单回路轨迹的叠加没有意义。用奇异值图或特征轨迹。

情形三，参数在宽范围内变化且互相耦合。 参数根轨迹一次只能扫一个参数，多参数要用蒙特卡洛或 μ 分析。

情形四，需要保证非线性下的行为。 饱和、死区、滞环这些环节让“极点”这个概念失去意义，要用描述函数或直接仿真。

这四种情形之外，根轨迹都是“第一张该画的图”。它便宜（一次求根）、直观（形状即结论）、可核对（与 Routh 互校），是经典控制里性价比最高的工具。

40.11.6 本章小结

把全章的内容压成五句话：

1. **根轨迹是“$1+KG=0$ 的根随 K 移动的轨迹”**，形状只由开环零极点的角度决定，刻度由模值条件标定（§40.2）。
2. **八条规则能画出草图**：起点终点、实轴段、渐近线、分离点、虚轴穿越、出射角（§40.3）。手绘给形状，数值给精度，两张图都要有。
3. **沿轨迹能定量**：五档增益的 ζ、ω_n、M_p、t_s 都在表 40-3 与表 40-9 里，主导极点近似的误差在表 40-7 里（§40.4、§40.6、§40.8）。
4. **稳定与好用差 20 倍**：$K_{\max}=4.4$，而 $\zeta=0.6$ 只允许 $K=0.2436$（§40.6.1）。
5. **整形改的是形状，比较前必须归一**：加零点能把 $K_{\max}$ 推到无穷，加极点会砍掉 76.5%，超前与滞后的差别全在极点位置（§40.9）。

下一章（第 41 章）会把同一批对象放到频率响应法里再看一遍，重点放在“相位从哪来、带宽怎么定”；本章的 $K_{\max}=4.4$、$\omega_{180}=6.3246$、分离点 $K=0.0951$ 会在那里作为对照基准再次出现。

40.12 Python 仿真代码

本章所有数字由两个脚本产生，都在 `book/code/` 下：

- `ch040_sim.py`：十一个计算组，输出到控制台；
- `ch040_figs.py`：十张图，导出 SVG 与 PDF。

两个脚本共用 `book/simlib.py`（阶跃仿真与时域指标）与 `book/styles/plot_styles.py`（字体、线型、画布尺寸）。本节只讲与根轨迹有关的部分，公共骨架见第 34 章。

40.12.1 十一个组的分工

`ch040_sim.py` 的主函数按“一个函数对一条规则”组织，十一个组与正文的对应关系是：

组	内容	对应正文
1	主例的三个解析要素	§40.3、表 40-2
2	五档增益的极点与指标	§40.4.2、表 40-3
3	串零点 / 串极点的原始 $K_{\max}$	§40.9.2、§40.9.3
4	参数根轨迹（扫 τ）	§40.7、表 40-8
5	等 ζ / 等 ω_n 交点	§40.4.4、表 40-4
6	离散根轨迹（六档 T_s）	§40.5、表 40-5
7	零度根轨迹（正反馈）	§40.11.3
8	主导极点近似的误差	§40.6.2、表 40-7
9	整形对象的归一化比较	§40.9.5、表 40-11
10	离散设计点与延迟预算	§40.5.6、§40.6.7、§40.10.7
11	超前校正的归一化扫描	§40.9.8

十一组跑一次约二十秒，输出约一百七十行。每个数都能在正文里找到对应的表格或小节，反过来，正文每个引用的数也都标了它来自哪一组。

40.12.2 四个核心函数

整章的计算压成四个函数，都不超过十行。

第一个，闭环极点。 特征方程 $D(s)+KN(s)=0$ 就是多项式相加，`np.polyadd` 之后求根即可：

```
def roots_at(num, den, K: float):
    """1 + K*G = 0 的根，即闭环极点。"""
    return np.roots(np.polyadd(np.asarray(den, float), K * np.asarray(num, float)))
```

这一步没有任何近似，K 取多少就解多少，所以表 40-3 的极点位置是精确的。

第二个，临界增益。 判稳函数 `max_real` 返回最大实部，二分法找它穿过零的增益：

```
def bisect_kmax(num, den, k_hi: float = 1e3, tol: float = 1e-10) -> float:
    """二分求临界增益；若 k_hi 处仍稳定，返回 inf。"""
    if max_real(num, den, k_hi) <= 0:
        return np.inf
    lo, hi = 0.0, k_hi
    while hi - lo > tol * max(1.0, hi):
        mid = 0.5 * (lo + hi)
        if max_real(num, den, mid) > 0:
            hi = mid
        else:
            lo = mid
    return float(hi)
```

两个细节值得注意。一是**上界探测**：若 $K=1000$ 时仍稳定，直接返回 `inf`，这就是表 40-11 里两个零点情形写 ∞ 的来源。二是**终止条件用相对容差**，避免 K 很大时迭代次数爆炸。得到的 4.4000 与解析值 4.4 在四位

小数上一致。

第三个，分离点。由 $\mathrm{d}K/\mathrm{d}s = 0$ 推出 $ND' - DN' = 0$，求根后只保留 $K > 0$ 的实根：

```
def breakaway(num, den):
    """实轴分离／会合点：解 num*den' - den*num' = 0，只保留 K>0 的实根。"""
    num = np.asarray(num, float)
    den = np.asarray(den, float)
    poly = np.polysub(np.polymul(num, np.polyder(den)),
                      np.polymul(den, np.polyder(num)))
    cand = []
    for s in np.roots(poly):
        if abs(s.imag) > 1e-9:
            continue
        s = float(s.real)
        K = -float(np.polyval(den, s)) / float(np.polyval(num, s))
        if K > 0:
            cand.append((s, K))
    return sorted(cand)
```

`K>0` 这个筛选不能省。$\mathrm{d}K/\mathrm{d}s = 0$ 的解里既有分离点（$K > 0$，轨迹在此分开），也有“会合点”的数学延长（$K < 0$，负增益才有意义），后者不是物理解。表 40-2 的 -0.9737（$K = 0.0951$）就是筛选后的结果；“加极点 -5”那一行出现的 -15.666（$K = 49.48$）也是真解，只是对应的增益极大。

第四个，离散临界增益。把对象 ZOH 离散，再对 $|z|_{\max}$ 二分：

```
def discrete_kmax(Ts: float, num, den, k_hi: float = 50.0) -> float:
    """ZOH 离散后的临界增益：闭环 |z| 最大值穿越 1 的增益。"""
    G = ct.tf(num, den)
    Gd = ct.c2d(G, Ts, method="zoh")
    nd = np.atleast_1d(np.asarray(Gd.num[0][0], float))
    dd = np.atleast_1d(np.asarray(Gd.den[0][0], float))

    def zmax(K):
        return float(np.max(np.abs(np.roots(np.polyadd(dd, K * nd)))))

    if zmax(k_hi) <= 1.0:
        return np.inf
    lo, hi = 0.0, k_hi
    while hi - lo > 1e-10 * max(1.0, hi):
        mid = 0.5 * (lo + hi)
        if zmax(mid) > 1.0:
            hi = mid
        else:
            lo = mid
    return float(hi)
```

与连续版只差一处判据：`max_real <= 0` 换成 `zmax <= 1.0`。这也是 §40.5.1 那句“虚轴换成单位圆”在代码里的样子。

40.12.3 组 1 到组 3 的输出

组 1 的输出是表 40-2 的来源：

```
1) 主例 L=10K/[s(s+2)(0.05s+1)] 的三个解析要素
   极点: [-20.  -2.   0.]
   渐近线交点 sigma_a=-7.3333，条数 3，夹角 ±60°、180°
   分离点 s=-0.9737  对应 K=0.0951
   K_max=4.4000  omega_osc=6.3246 rad/s  穿越根 [-22.+0.j  0.+6.3246j  0.-6.3246j]
```

`sigma_a` 直接用 `np.sum(np.roots(den).real) / 3.0` 算，与 §40.4.1 的韦达定理同源。穿越根里的 -22 就是 §40.4.1 第二处提到的“第三极左移”。

组 3 的原始输出（表 40-11 左半部分的来源）：

```
3) 串零点 / 串极点后的轨迹
   对象                    K_max   w_cross       分离点                    分离点 K
   原对象                  4.4000    6.3246    -0.974                    0.0951
   加零点 s=-1                inf       nan   -10.603                    0.4463
   加零点 s=-4                inf       nan    -1.145                    0.0323
   加极点 s=-5             5.2812    2.7217 -15.666 -0.856             49.4835 0.3884
   加极点 s=-40          115.3798    5.0800 -32.880 -0.961            465.5593 3.7107
   超前 (s+1)/(s+5)      15.8217   11.1627    -3.287                    0.2648
   滞后 (s+1)/(s+0.2)     2.4636    4.7492    -0.103                    0.0021
```

这张表就是 §40.9.3 说的“归一化陷阱”的现场：`加极点 s=-40` 的 115.3798 看着最漂亮，归一化后只有 2.8836。**读原始输出时必须同时看 c_{rel}，否则会被增益标定骗过去。**

组 9 的输出补上了归一化：

```
9) 整形对象的归一化比较（环路增益按 1 rad/s 处对齐）
   对象                K_max_raw   c_rel  K_max_norm    Mp@0.3     ts/s     zeta       wn
   原对象                 4.4000  1.0000      4.4000     13.82     3.41   0.5322   1.7250
   加零点 s=-1               inf  1.4142         inf      0.00     5.18      nan      nan
   加零点 s=-4               inf  4.1231         inf      2.66     3.05   0.7682   1.7351
   加极点 s=-5            5.2812  0.1961      1.0357     29.62     7.04   0.3498   1.6081
   加极点 s=-40         115.3798  0.0250      2.8836     15.51     4.71   0.5093   1.7200
   超前 (s+1)/(s+5)     15.8217  0.2774      4.3881      0.00     4.73   0.7074   3.9873
   滞后 (s+1)/(s+0.2)    2.4636  1.3868      3.4164     54.33    11.43   0.2674   1.2264
```

两个 `nan` 来自“加零点 $s=-1$”在归一增益 0.3 下没有复极点对（两个根都在实轴上），函数 `dominant_pair` 返回 `(None, None)`，程序就用 `nan` 标记。**这是数据本身的信息，不是错误**——它说明该整形把系统拖成了过阻尼。

40.12.4 组 4 到组 6 的输出

组 4 扫 τ，组 5 求交点，组 6 扫采样周期，三组的输出分别对应表 40-8、表 40-4、表 40-5。这里只提醒两处实现细节。

组 4 没有用参数根轨迹的等效开环，而是直接解特征方程。 原因是直接在 τ 上取值更省事，也不容易出错：

```
for tau in [0.01, 0.05, 0.10, 0.20, 0.30, 0.3333, 0.40]:
    de = np.polymul(np.array([1.0, 2.0, 0.0]), np.array([tau, 1.0]))
    rr = np.roots(np.polyadd(de, np.array([10.0])))
```

但正文 §40.7.1 仍然讲了等效开环 L_τ，因为画图必须用它——`ch040_figs.py` 的图 40-5 就是按 L_τ 画的。数值求根与图形绘制用两条不同的路径，互相核对。

组 5 用的是扫描加插值，不是解析求交。 轨迹与等 ζ 线没有简单的解析交点，脚本先在对数网格上取 4000 个 K，算出每一档的 (ζ, ω_n)，再找符号变化的位置线性插值：

```
def cross_to(idx_col, value):
    d = tab[:, idx_col] - value
    i = np.nonzero(np.sign(d[:-1]) * np.sign(d[1:]) < 0)[0]
    out = []
    for j in i:
        t = -d[j] / (d[j + 1] - d[j])
        K = tab[j, 0] + t * (tab[j + 1, 0] - tab[j, 0])
        out.append((float(K), float(tab[j, 3]), float(tab[j, 4])))
    return out
```

4000 个点足够把交点定到四位小数（表 40-4 的 0.1815、0.3888 等）。若要更高精度，把网格加密或改用 `scipy.optimize.brentq`，但对工程用途没必要。

40.12.5 组 10 与组 11：两段关键写法

组 10 的核心技巧：把延迟写进特征多项式。 纯延迟 d 拍在 z 域就是因子 z^{-d}，写成传递函数是 $G(z)/z^d$。特征方程 $1 + KG(z)/z^d = 0$ 两边乘 z^d，得到

$$z^d D(z) + K N(z) = 0$$

根的模不变（乘 z^d 不改变方程在 $z \neq 0$ 处的根），所以“判稳只需看模是否大于 1”这条规则照旧成立。代码里就是给分母多项式左乘一个 z^d：

```
shift = np.zeros(d + 1)
shift[0] = 1.0                      # 特征方程乘 z^d，等价串 z^-d
dd_d = np.polymul(dd, shift)
```

这比“先转状态空间再扩维”简洁得多，也不受 `control` 版本影响。

组 11 的核心技巧：归一化扫描。 先算 c_{rel}（整条环路在 1 rad/s 处的增益比），再把扫描变量换成 K_{norm}，最后按 $K_{\text{raw}} = K_{\text{norm}} / c_{\text{rel}}$ 回到原始增益：

```
c_lead = comp_gain(nu_lead, de_lead) / comp_gain(num, den)
for kn in [0.30, 0.70, 1.00, 4.00]:
    k_raw = kn / c_lead             # 归一增益换回原始增益
    rr = roots_at(nu_lead, de_lead, k_raw)
```

这样扫出来的每一档，都可以直接和原对象的同名 K 对比。 若不做这一步，超前网络的原始 K 与对象 K 不在同一个刻度上，表 40-11 那样的误读就会出现。

两组跑完的控制台输出原样如下，方便逐列对照。组 10 先打印八档设计点，再打印四档延迟：

```
10) Ts=0.1 s 的离散设计点与延迟预算
        K    max|z|   zeta_d     wn_d    Mp_d/%  ts_d/s  Mp_c/%
    0.200    0.9151   0.6323   1.4039      7.67    4.40    5.85
    0.250    0.9175   0.5492   1.5669     12.61    3.80    9.97
    0.300    0.9200   0.4865   1.7134     17.26    4.90   13.82
    0.600    0.9344   0.2826   2.3990     39.34    5.80   31.25
    1.000    0.9527   0.1584   3.0591     59.74    7.70   46.05
    1.500    0.9742   0.0709   3.6944     78.90   14.70   58.71
    2.000    0.9944   0.0134   4.2115     94.09     nan   68.16
    2.144    1.0000  -0.0000   4.3449    145.84     nan   70.49
   -- 纯延迟 d 拍（每拍 0.1 s）后的离散临界增益 --
   延迟 0 拍（0.0 s）  K_max=2.1437
   延迟 1 拍（0.1 s）  K_max=1.0785
   延迟 2 拍（0.2 s）  K_max=0.7325
   延迟 5 拍（0.5 s）  K_max=0.3867
```

读这张表要注意两件事。第一，`max|z|` 是最直接的稳定性判据，它到 1.0000 就临界，与 `K_max=2.1437` 自洽；`zeta_d` 与 `wn_d` 只是把 z 极点的模与角换算成 s 平面的等效量，方便与连续设计对照。第二，`ts_d` 出现 `nan` 不是算错，而是 60 s 的仿真窗内响应没有进入并保持 $\pm 2\%$ 带——K 已经靠近临界，振荡衰减得太慢。**这一类 `nan` 必须当“未收敛”读，不能当“零”。**

组 11 的输出多出前三行，正是归一化那一步的中间量：

```
11) 超前校正 (s+1)/(s+5) 沿归一化增益的扫描
   c_rel=0.2774  K_max_norm=4.3881
    K_norm     K_raw       wn     zeta     Mp/%     tr/s     ts/s       第三极
      0.30    1.0817   3.9873   0.7074     0.00     2.09     4.73  -20.7012
      0.50    1.8028   4.6618   0.5469     0.00     0.53     3.30  -21.1150
      0.70    2.5239   5.2681   0.4420     7.22     0.36     2.71  -21.4965
      1.00    3.6056   6.0577   0.3374    20.42     0.26     2.42  -22.0202
```

`c_rel=0.2774` 是两把尺子的换算系数，`K_max_norm=4.3881` 是把临界值换到归一化刻度后的结果——它与原对象的 4.4000 只差 0.27%，说明这个超前网络几乎没有改变稳定上限，改的只是轨迹在低频段的位置。`K_raw` 与 `K_norm` 逐行相差 3.6056 倍，正是 $1/c_{\mathrm{rel}}$；**把两列并排打印出来，就是为了让读表的人不会把某一个当成另一个。**最后一列第三极从左到右单调左移（$-20.7012 \to -25.6673$），是 §40.9.10 那句“绝对值更远、相对更近”的原始数据。

40.12.6 组 7 与组 8 的两个坑

组 7 的坑：不能复用 `bisect_kmax`。 那个函数假设 K 只取正、且 $1+KG$ 的形式；正反馈是 $1-KG$，特征多项式是 `den - K*num`。所以组 7 单独写了一段二分：

```python
lo, hi = 0.0, 10.0
for _ in range(80):
    mid = 0.5 * (lo + hi)
    if float(np.max(np.roots(np.polyadd(de0, -mid * nu0)).real)) > 0:
        hi = mid
    else:
        lo = mid
```

得到 $K = 1.000000$。80 次二分把区间从 10 压到 $10/2^{80}$，远超双精度分辨率，所以结果实际上就是机器精度下的解析值。

组 8 的坑：ζ 必须从极点算，不能从 K 算。 主导极点近似的前提是“取最靠虚轴的一对共轭根”，而“最靠虚轴”这件事随 K 变化（表 40-3 里 $K = 4.4$ 时三根都在虚轴附近）。脚本用 `dominant_pair` 每次都重新挑，而不是固定取第一对。

40.12.7 出图脚本与中文字形

`ch040_figs.py` 的十个函数与十张图一一对应。三个绘图助手值得说明：

```
def locus_branches(num, den, kvect):
    """把根按最近邻串成连续支路，供画轨迹用。"""
```

根轨迹的根是“无序”的——`np.roots` 每次返回的顺序可能不同，直接连起来会画出乱七八糟的折线。`locus_branches` 用“每个新点找最近的旧点”的方式串支路，这是画轨迹的标准做法。

```
def draw_locus(ax, num, den, k_hi, label=None, lw=1.1):
    """画一条根轨迹，含方向箭头。"""
```

箭头用 `ax.annotate` 加 `arrowprops` 画在支路中段，标出 K 增大的方向。**没有箭头的轨迹图是半成品**——同一形状，方向反了结论就反了。

```
def mark_poles_zeros(ax, poles, zeros):
    """开环极点画 ×，零点画 ○。"""
```

这套符号是教科书约定，读者一眼能认。

图注与刻度也按同一原则处理：图内只留符号与数字，中文解释全部挪到图题和正文；坐标轴标签用 `Re`、`Im` 这类 ASCII 词，不用“实部”“虚部”。**这不是排版偏好，而是渲染约束**——中文字形缺失时 matplotlib 不抛异常，只默默画成方框，往往到排版阶段才被发现。把这条写进出图脚本的注释里，比事后逐张检查省事。

中文字形的坑必须单独说。全书用 `mathtext.fontset="stix"`，它对中文没有字形。若把中文与 `$...$` 写进同一个字符串，例如 `r"渐近线交点 $-7.33$"`，运行时会刷出上百行 `Font 'default' does not have a glyph` 警告，图上的中文变成方框。本章的修法是**把中文与公式拆成两次 `ax.text`，或者把公式里的变量改成纯文本**。改完之后十张图只剩十行“图 40-x”提示，没有字形警告。

40.12.8 复现与验收

四条命令，按顺序跑：

```
"D:\Anaconda3\envs\py311\python.exe" code/ch040_sim.py
"D:\Anaconda3\envs\py311\python.exe" code/ch040_figs.py
"D:\Anaconda3\envs\py311\python.exe" tools/check_chapter.py 40
"D:\Anaconda3\envs\py311\python.exe" tools/build.py --chapter 40
```

第一条出十一个组的控制台输出，第二条出十张 SVG 与十张 PDF，第三条检查结构（12 节、字数、图、代码语法、公式闭合），第四条生成 HTML 与 PDF。

自查时看三个数是否逐位一致：$K_{\max} = 4.4000$、$\omega_{\text{osc}} = 6.3246$、分离点 -0.9737。三者都对，说明这条对象与第 39 章的基准是同一个；任何一个对不上，先查 `TAU_ACT` 与 `K_PLANT` 两个常量。**这条自检只花一秒，却能挡住“换了对象忘了改常量”这类最常见的复现失败。** 三个数里 $K_{\max}$ 最敏感，它由模值条件直接决定，任何一处系数写错都会立刻反映在第四位上。

`ch040_figs.py` 不依赖随机数，`ch040_sim.py` 也不依赖，所以**重跑结果应当逐位一致**，不需要设种子。这一点与第 38 章（含蒙特卡洛）不同，本章可以放心用“数字对不上就是代码被改了”来排查。排查顺序也固定：先比上面三个数，再比表 40-3 的五档极点，两轮就能定位到具体函数。

第41章 频率响应法与稳定裕度

> 本章的一句话核心思想：把 $s=\mathrm{j}\omega$ 代进去，系统就从一个“微分方程”变成一条“随频率变化的复数曲线”；稳定裕度是这条曲线离临界点多远，动态性能是这条曲线在穿越频率附近的形状。

41.1 动机与直观理解

41.1.1 三个现场问题，一张图回答

在工业现场，调试工程师最常被问到的三个问题是：

1. **这个增益还能往上加多少？** 加到头会怎样？
2. **响应够不够快？** 想再快一点，代价是什么？
3. **回路里还有 30 ms 的通信延迟，能扛住吗？**

这三个问题的答案，都可以从同一张图上读出来——开环频率响应 $L(\mathrm{j}\omega)$ 的 Bode 图。第一个问题读增益裕度，第二个问题读穿越频率与带宽，第三个问题读相位裕度并折算成时间。

把三个答案落到主例上，位置会更具体。主例 $L=10/\big[s(s+2)(0.05s+1)\big]$、$K=0.3888$ 时：幅频在 $\omega_c=1.5369$ rad/s 处穿过 0 dB，这一点的相位是 -131.94°，所以“还能加多少增益”看的是 $\omega=6.3246$ 处那条水平线到 0 dB 的距离（21.075 dB，即 11.3 倍）；“响应够不够快”看的是 ω_c 右侧曲线下降的陡度，它决定了闭环带宽 2.5796 rad/s；“能扛多少延迟”是 48.065° 除以 1.5369，得 0.5458 s。**三个答案、三个数、同一张图，彼此不矛盾也不重复。**

这张图的特别之处在于：**它不需要知道闭环极点在哪，也不需要解高阶方程**。只要能把开环传递函数写成若干个一阶、二阶因子的乘积，就能逐段画出折线，把三个问题一次答完。

三个答案还必须分开报，因为它们对同一个旋钮的反应并不一致。仍以主例为例，把 K 从 0.3888 调到 0.7332（$+5.5$ dB）：G_M 从 21.08 掉到 15.57 dB（-26%），φ_M 从 48.07° 掉到 33.61°（-30%），$T_{d,\max}$ 从 0.5458 s 掉到 0.2490 s（-54%），带宽却从 2.58 涨到 3.88 rad/s（$+50\%$）。**同一个动作，四个数里有一个在变好、三个在变坏，而且坏得最厉害的是延迟裕度。** 这就是为什么不能只说“我留了 20 dB 增益裕度，够了”——那句话对第三个问题完全没回答。

还有一层现实理由。现场调试时，工程师手上的信息往往只有“改一个参数、看一次响应”，而每次试错都有成本——设备要停机、工件要报废、有时还有安全风险。**频域法把这些试错搬到了纸上**：先在图上把“增益再加 3 dB 会怎样”算出来，再到现场只做一次确认。这是它比“试出来”更可取的根本原因。

41.1.2 为什么“扫频”比“解方程”更接近现场

教科书讲稳定性，习惯从特征方程出发：写出 $1+L(s)=0$，求根，看实部符号。这条路在纸面上很干净，在现场却经常走不通——因为**现场往往拿不到微分方程**。

一台变频器带电机，你能测的是：给一个正弦指令，等稳态，量输出的幅值和相位差；换个频率，再测一次。测二十个点，就得到一条实测频率响应。你不需要知道电机里有几个极点、参数是多少，曲线本身就包含了全部信息。

这件事在数学上是有根据的：对线性时不变系统，频率响应与冲激响应是一对傅里叶变换，两者包含同样的信息。**问题不在于“频率响应够不够”，而在于“会不会读”。**

所以本章的立场与第 39 章一致：**先承认现场只有曲线，再教怎么从曲线里把工程结论抠出来。**

扫频得到的是一条离散的点列，而设计需要的是连续曲线上的几个特定位置。两者之间的桥就是“插值加展开”：把实测点在对数频率坐标上连起来，读出幅频过 0 dB 的频率、该频率上的相位，再读出相频过 -180° 的频率与该处的幅值。这一步的误差主要取决于点有多密——每十倍频程 2 个点时 ω_c 会偏 -3.95%，5 个点时降到 -0.66%，10 个点时就只有 -0.02%（表 41-17）。**“扫得够不够细”不是经验问题，而是可以直接算出来的精度预算。**

还有一件事要提前说清：扫频给的是**开环**频率响应，而现场往往只能闭环运行。闭环也不是不能测——§41.6 的换算链可以反过来用，从闭环幅频的谐振峰推回开环相位裕度——但精度会差一截，因为换算依赖“二阶主导”这个前提，而现场对象很少规矩到二阶。所以只要条件允许，仍然优先做开环扫频：断开反馈、注入小幅正弦、逐点记录、最后把断点接回去。**断开与接回的顺序、接回时的初始状态，都要写进作业指导书**，否则一次带电接线就可能把执行器打到限位。

41.1.3 乘法变加法：Bode 图最大的便利

一个开环传递函数总能分解成若干基本因子的乘积：

$$L(s)=K\cdot\frac{\prod_i (s-z_i)}{\prod_j (s-p_j)}=K\cdot\frac{(1+T_1 s)(1+T_2 s)\cdots}{s^{N}(1+\tau_1 s)(1+\tau_2 s)\cdots} \tag{41-1}$$

代 $s=\mathrm{j}\omega$ 之后，每个因子都是一个复数。取模、取对数：

$$20\lg|L(\mathrm{j}\omega)|=20\lg K+\sum_i 20\lg|1+\mathrm{j}\omega T_i|-\sum_j 20\lg|1+\mathrm{j}\omega\tau_j|-20N\lg\omega \tag{41-2}$$

乘积变成了求和。 这就是 Bode 图用对数坐标的全部理由：每一项都可以独立画成一条折线，然后把折线叠加起来。叠加的结果在低频和高频都近似为直线，转折处用几个 dB 的圆角过渡。

相位也类似：每个因子贡献一个相角，总相位是各因子相角之和。相角不能简单叠加成折线，但它有明确的上下界——每个一阶因子最多贡献 90°，每个二阶因子最多 180°。

这条“折线可叠加”的性质有一个必须记住的代价：**每条折线在转折点处都有 3.01 dB 的误差**，因为 $20\lg\sqrt{2}=3.01$。一个转折点是 3.01 dB，三个极点挤在一起就会叠成 9 dB 以上。主例的两个转折点相距十倍频程，彼此干扰很小，所以表 41-3 里两个转折点的偏差都是 -3.054 dB——比 3.01 多出的那 0.04 dB 正是另一个极点的残余贡献。**折线法的精度上限就由这 3 dB 决定，想更准只能逐点算，没有中间道路。**

还有一层便利常常被低估：**对数坐标把“倍频”变成了“等距离”**。无论增益是 0.01 还是 100，10 倍频程在纸面上永远是同样长的一段，所以同一张图纸可以同时容纳 0.1 rad/s 与 1000 rad/s。这在现场手绘时尤其重要——工程师不必先算清楚曲线会延伸到哪，画就行了。

41.1.4 三个裕度，其实是同一句话的三个分句

“这个回路稳不稳”这句话，在频域里可以拆成三个更具体的问题：

- **幅值再涨多少倍，相位才刚好到 -180°？** 这是增益裕度；
- **在幅值刚好为 1 的那个频率上，相位离 -180° 还差多少？** 这是相位裕度；

- **再塞多少秒的纯延迟，相位才刚好把这点余量吃光？** 这是延迟裕度。

三者的关系不是并列的，而是**同一笔相位账的三种记法**。增益裕度问的是“幅值还能走多远”，相位裕度问的是“现在还剩多少度”，延迟裕度问的是“这些度值多少秒”。第 §41.2.6 会把它们写成公式，第 §41.9.1 会证明：在单穿越的情形下，延迟裕度精确等于相位裕度除以穿越频率，不是估算，是恒等式。

以主例 $K = 0.3888$ 为例，三个数分别是 21.075 dB（即 11.32 倍）、48.065°、0.5458 s。三者可以互相校验：把增益乘 11.32，幅频整体上移 21.075 dB，ω_c 恰好被推到 $\omega_{180} = 6.3246$，相位裕度归零；把 0.5458 s 的纯延迟串进去，相频在 ω_c 处下压 48.065°，相位裕度同样归零。**两条路径通向同一个临界点**——这不是巧合，而是“三种裕度描述同一个边界”的直接体现。

反过来说，如果三个数算出来彼此矛盾，那一定是读错了频率，最常见的是把折回后的相位当成了连续相位，或者把 ω_c 与 ω_{180} 用反了。**三个裕度互相校验，是频域法自带的一道自检**：它不需要额外的模型信息，只要三个数出自同一张图。

41.1.5 与第 39 章的分工

第 39 章已经讲过 Nyquist 判据、Bode 判据与根轨迹判据的等价性，重点是“怎么判稳”。本章不再重复判据的推导，而是回答另外三个问题：

- **怎么画**：从因子到折线，手绘一遍；
- **怎么读**：三个裕度、谐振峰、带宽各在哪；
- **怎么用**：把裕度换算成超调、把延迟折算成秒、把验收标准写进表格。

一句话：第 39 章回答“稳不稳”，本章回答“稳到什么程度、还能怎么改”。第 39 章的结论会在本章被反复引用，但推导只出现一次。

41.1.6 本章路线

§41.2 把频率响应的数学结构讲清楚，重点是“乘法变加法”和“最小相位”两件事；§41.3 给出六步读图流程；§41.4 用主例把连续情形的三条曲线（Bode、Nyquist、Nichols）走一遍；§41.5 处理离散情形，说明零阶保持器吃掉多少相位；§41.6 建立“裕度→谐振峰→超调”的换算链；§41.7 逐个参数讲影响方向；§41.8 给出整定方法与边际价格；§41.9 讨论延迟、多穿越、非最小相位三个边界；§41.10 落到现场；§41.11 给优缺点；§41.12 是代码。

41.2 数学原理

41.2.1 频率响应到底是什么

对线性时不变系统，输入 $\sin \omega t$ 时，稳态输出是 $|L(\mathrm{j}\omega)| \sin(\omega t + \angle L(\mathrm{j}\omega))$。也就是说，**频率响应回答的是“这个频率的正弦信号，被放大多少倍、滞后多少度”**。

这个定义看起来简单，但它暗含两个前提：系统稳定（否则没有稳态）、输入是纯正弦（否则要叠加）。这两条在工程上都成立：我们讨论的频段内系统是稳定的，而任何周期信号都能分解成正弦。

把 $s = \mathrm{j}\omega$ 代进传递函数，实部与虚部分开：

$$L(\mathrm{j}\omega) = P(\omega) + \mathrm{j}Q(\omega), \qquad |L| = \sqrt{P^2 + Q^2}, \qquad \angle L = \arctan\frac{Q}{P} \tag{41-3}$$

注意 $\arctan$ 只能给出 $(-90^\circ, 90^\circ)$ 的主值，实际相角要按象限补 180°。这是读 Bode 图第一个容易出错的地方：**软件给你的是折回后的相位，不是连续相位**。本章所有表格里的相位都是连续展开的，例如 -195.26° 而不是 $+164.74^\circ$。

把定义落到可测的量上，频率响应就是两个数的比值：幅值比 $|L|$ 与相位差 $\angle L$。测这两个数不需要任何模型，只需要一台能产生正弦的激励源和一台能测幅相的仪器。这一点决定了频域法的基本性格——**它从测量出发，而不是从建模出发**。第 37、38 章的做法是先有模型再算响应，本章反过来：先有响应，模型只是用来解释响应为什么长成这样。

“稳态”这两个字也要落实。输入正弦之后，输出要经过一段暂态才进入同频正弦。暂态的长短由回路最慢的极点决定，主例 $K = 0.3888$ 时调节时间 4.295 s，意味着每个频点至少要等四五秒才能读数。**低频点等得久、高频点等得快**，这正是扫频试验在高频段可以加速、在低频段必须耐心的原因。

41.2.2 五种基本因子的斜率与相位

任何有理传递函数都能拆成五种因子的乘积。把这五种因子的渐近斜率与相位范围背下来，Bode 图就能手绘。

表 41-1　五种基本因子的渐近斜率与相位贡献

因子	高频渐近斜率	相位贡献	相位主要变化区间
增益 K	0	0°（$K<0$ 时 $\pm 180^\circ$）	全频段
积分 $1/s$	-20 dB/dec	-90°	全频段
一阶极点 $1/(1+\tau s)$	-20 dB/dec	$0 \to -90^\circ$	$0.1/\tau$ 到 $10/\tau$
一阶零点 $1+Ts$	$+20$ dB/dec	$0 \to +90^\circ$	$0.1/T$ 到 $10/T$
二阶环节 $\omega_n^2/(s^2+2\zeta\omega_n s+\omega_n^2)$	-40 dB/dec	$0 \to -180^\circ$	$0.1\omega_n$ 到 $10\omega_n$

表里最有用的一列是最后一列：**相位在转折频率前后各一个十倍频程内变化，之外基本不变**。这条经验让人可以在不画精确曲线的情况下，估算任意频率处的相位：数一数这个频率“看到”了几个极点、几个零点，每个近似贡献 -90° 或 $+90^\circ$，再看它离转折点多远做修正。

以主例 $L = 10/[s(s+2)(0.05s+1)]$ 为例，在 $\omega = 1$ rad/s 处：积分器贡献 -90°；极点 -2 距此只有两倍，贡献约 -26.6°；极点 -20 距此二十倍，贡献约 -2.9°。合计 -119.5°，与实测 -119.43° 相差不到 0.1°。**这种“数极点+估修正”的手算法，精度足够做设计初稿。**

拆因子时有一个动作必须做：**把每个因子归一化成 $(1+\tau s)$ 的形式**。主例的分母是 $s(s+2)(0.05s+1)$，第二个因子要写成 $2(1+0.5s)$，于是 $L = 5/[s(1+0.5s)(1+0.05s)]$。三个转折频率立刻显形：积分器没有转折，$1/0.5 = 2$，$1/0.05 = 20$。归一化之后，低频渐近线是 $5/\omega$，在 $\omega = 0.1$ 处给出 50 倍即 33.98 dB，与实测 33.968 dB 只差 0.01 dB。**常数因子 5 就是“低频增益”，它决定整条曲线的上下位置；三个时间常数决定三个转折点。** 把这两类信息分开，是画折线的第一步。

如果某个因子是二阶的，归一化后要检查阻尼比 ζ。$\zeta < 0.3$ 时幅频在 ω_n 附近已经出现 5 dB 以上的峰（$\zeta = 0.2$ 时约 8 dB，$\zeta = 0.1$ 时约 14 dB），折线法完全跟不上——这种情形不能用折线，必须直接算点。本章主例没有二阶环节，所以三段折线足够。

41.2.3 斜率与相位的一一对应

Bode 图有一个很深的性质：**幅频的斜率与相频的大小是绑定的**。对最小相位系统，若某频段的斜率是 $-20n$ dB/dec，则该频段的相位约为 $-90n$ 度。

这条规律可以从单因子看出来：一个积分器斜率 -20、相位 -90；两个积分器 -40、-180；三个 -60、-270。一阶极点在远离转折点的频段，等效于一个积分器。

本章主例的实测把这条规律验证得很干净（数据见 §41.4.2）：在 2 到 20 rad/s 之间，两个极点都已"生效"、第三个极点还没到，斜率恰好 -40.00 dB/dec，中点相位恰好 -180.00°。斜率与相位的对应不是近似，在纯斜率段是精确的。

这条性质的工程价值在于：**看到相位掉得太快，就知道斜率太陡；想让相位抬起来，就得把斜率抬起来**。整形手段（加零点、加超前）之所以有效，本质都是局部把斜率改小。

用这条规律时要分清两个"斜率"：一是折线的渐近斜率，只取 -20 的整数倍；二是实测曲线的差商，可以是任意值。表 41-4 算的是后者——用相邻十倍频程的两个点做差。第一段差商 -20.97，略陡于 -20，因为第二极点已经开始"提前起作用"；第三段恰好 -40.00，因为这一段两端都远离转折点，两个极点都已完全生效、第三极点还没到。**差商等于整数倍的地方，就是纯斜率段；偏离整数倍的地方，就是过渡段。** 用这个判据可以一眼看出过渡段有多宽：主例的过渡段大约占了 0.5 到 5 这一整段，宽度接近一个十倍频程。

过渡段的宽度还有一个用处：**它决定了"用斜率估相位"的误差有多大**。纯斜率段误差为零，过渡段则要看过渡有多陡：主例 0.5 到 5 这一段差商 -28.60，按"斜率乘 90°"估出 -128.7°，实测中点 -132.85°，差 4°；而 5 到 50 那一段差商 -47.70 估出 -214.7°，实测 -211.12°，差 3.6°。**两段的误差都在 5° 以内，比很多人担心的要小。** 真正会出大错的情形是转折点密集（两个极点相距不到两倍），那时过渡段很窄、差商变化剧烈，按斜率估会偏十几度，此时必须逐项用 $\arctan$ 累加。

41.2.4 最小相位：幅频唯一决定相频

有一类系统，它的相频完全由幅频决定，不需要额外信息。这类系统叫最小相位系统，条件是：**所有零点、极点都在左半平面（或虚轴上的原点）**。

对这类系统，存在一个积分关系（Bode 增益-相位关系），可以粗略写成：

$$\angle L(\mathrm{j}\omega_0) \approx \frac{1}{\pi}\int_{-\infty}^{\infty} \frac{\mathrm{d}\ln|L|}{\mathrm{d}u}\,\ln\coth\frac{|u|}{2}\,\mathrm{d}u, \qquad u=\ln\frac{\omega}{\omega_0} \tag{41-4}$$

这个积分不必手算，它的意义只有一句话：**相位是斜率的加权平均，权重在 ω_0 附近最大**。所以"某频率的相位"主要由"该频率附近的斜率"决定，远处斜率的影响被对数权重压小。

工程上常用的简化版本就是 §41.2.3 的"斜率乘 90°"。式 (41-4) 的真正用途是解释两个现象：为什么相位在转折点附近变化最快（斜率正在变），为什么远离所有转折点的频段相位很"干净"（斜率恒定）。

"幅频唯一决定相频"这句话反过来还有诊断价值：**若实测相频比按最小相位算出来的更负，多出来的那部分一定来自右零点或纯延迟**。区分方法很简单——右零点的相位贡献有上界（最多 -180°），而纯延迟没有上界，它随频率线性下降、永不饱和。所以看到"相位一路往下掉、高频段斜率恒定"就是延迟；看到"相位掉到某个值就停住"就是右零点。§41.10.4 的方法三就是这条判据的定量版。

这条判据在实际中很有用，因为两者在幅频上都不留痕迹：延迟让幅频完全不变；右零点在幅频上表现为一个普普通通的零点（高频斜率抬 20 dB/dec），左右半平面看不出任何区别。**只看幅频，两个都容易被当成"多了一个零点"；看相频，一个一路下滑、一个有界饱和，立刻分得开。**

41.2.5 非最小相位：同一幅频、不同相频

只要有一个零点在右半平面，最小相位的前提就破了。这时幅频相同、相频可以差很多。

组 7 构造了一对极端的例子：两个系统共用分母 $(s+1)^2(0.2s+1)$，分子分别是 $1+0.5s$（零点 -2）与 $1-0.5s$（零点 $+2$）。因为 $|1+\mathrm{j}0.5\omega| = |1-\mathrm{j}0.5\omega|$，两者的幅频逐点相同；相频却分道扬镳：

表 41-2　最小相位与非最小相位的相频对照（幅频逐点相同）

ω/(rad/s)	幅频/dB	最小相位/(°)	非最小相位/(°)	差值/(°)
0.1	-0.077	-9.70	-15.43	-5.73
0.5	-1.718	-44.80	-72.88	-28.08
1.0	-5.222	-74.74	-127.87	-53.13
2.0	-11.614	-103.67	-193.67	-90.00
5.0	-22.706	-134.18	-270.58	-136.40
10.0	-32.926	-153.32	-310.70	-157.38

差值在 $\omega = 2$（右零点转折频率的倒数位置）处恰好 $-90°$，高频趋于 $-180°$。这正是右半平面零点的相位贡献：它不提供超前，反而提供滞后，最大到 $-180°$。

后果在裕度上：同样取 $K = 10$，最小相位对象的相位裕度是 $52.27°$、增益裕度无穷大；非最小相位对象的相位裕度是 $-75.43°$、增益裕度 -9.90 dB——已经不稳定了。两者的幅频曲线一模一样，只看幅频永远发现不了问题。

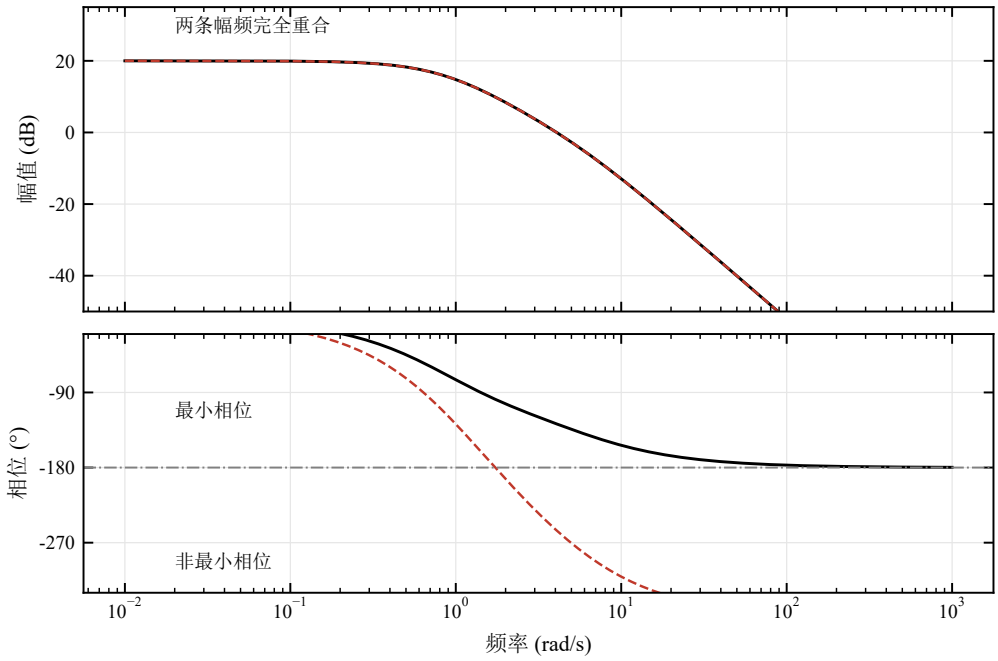

图 41-2　最小相位与非最小相位的相频分叉

图 41-2 上，两条幅频曲线完全重合，相频在右零点附近分开，非最小相位那条一路跌到 $-310°$。**这张图是“只看幅频会骗人”的最直接证据。**

表 41-2 的差值列还有两个可读的细节。第一，$\omega=2$ 处差值恰好 -90.00°：该处 $\omega T=1$，左零点的相角是 $+45^\circ$、右零点的相角是 -45°，两者相差 90°；而分母对两个系统完全相同，不贡献差值。第二，低频端（$\omega=0.1$）差值只有 -5.73°，不是零——右零点即使远在二十倍之外，也已经“闻到”了，这正是式 (41-4) 里那个对数权重的尾巴。**低频段的少量偏差最危险，因为它容易被当成测量误差放过**，而它恰恰是“这个对象不能按最小相位处理”的第一个信号。

工程上的后果不止是裕度变小。右零点还会让阶跃响应出现“先反向”的初始段（§41.4.6 会展开），这意味着**控制器在错误方向上先推一把**。若这个反向段触发了执行器限幅或工艺联锁，问题就不再是稳定性，而是能不能开机。

41.2.6 三个裕度的定义

设 $L(\mathrm{j}\omega)$ 的幅值穿越频率为 ω_c（$|L|=1$ 处），相位穿越频率为 ω_{180}（$\angle L=-180^\circ$ 处）。三个裕度定义为

$$G_M=\frac{1}{|L(\mathrm{j}\omega_{180})|}\quad\text{或}\quad G_M^{\mathrm{dB}}=-20\lg|L(\mathrm{j}\omega_{180})| \tag{41-5}$$

$$\varphi_M=180^\circ+\angle L(\mathrm{j}\omega_c) \tag{41-6}$$

$$T_{d,\max}=\frac{\varphi_M}{\omega_c} \tag{41-7}$$

式 (41-5) 的两种写法要分清：**倍数形式**（$G_M=2$ 表示增益还能翻一倍）与**分贝形式**（$G_M=6.02$ dB 表示同一件事）。现场口头说的“6 个 dB 裕度”是分贝形式，控制器参数表上的“增益余量 2 倍”是倍数形式。换算只有一步 $20\lg$，但混淆一次就会把安全系数差出十倍。

式 (41-7) 值得单独说明。它看起来像估算，其实是恒等式：纯延迟 $\mathrm{e}^{-\mathrm{j}\omega T_d}$ 不改变幅值，只把相位整体下压 ωT_d。临界条件是相位在 ω_c 处刚好到 -180°，即

$$180^\circ+\angle L(\mathrm{j}\omega_c)-\omega_c T_d=0\quad\Longrightarrow\quad T_d=\frac{\varphi_M}{\omega_c} \tag{41-8}$$

前提是 ω_c 唯一。若幅频多次穿越 0 dB，延迟会把穿越点挪动，式 (41-7) 就不再成立（见 §41.9.2）。组 10 用 Padé 近似实测三个工作点的临界延迟，与式 (41-7) 在四位小数上一致（1.7657 对 1.7656、0.9564 对 0.9564、0.5458 对 0.5458），验证了单穿越下的恒等关系。

三个定义里还藏着两组符号约定，报数时必须说清。**第一组，裕度为正表示“稳定”**：这是对开环稳定（右半平面无极点）的系统而言的；若开环本身不稳定，正裕度并不保证闭环稳定，要回到 Nyquist 判据数圈数。**第二组，ω_{180} 可能不存在**：一阶、二阶对象的相位永远到不了 -180°，此时 $G_M=\infty$，报“无穷大”比报一个大数诚实。组 7 的最小相位对象就是这种情形，$K=10$ 时 G_M 显示为 inf。

还有一条容易混的口径：**相位裕度是“到 -180° 的距离”，不是“到 0° 的距离”**。所以 $\varphi_M=48^\circ$ 的含义是“还能再滞后 48°”，而不是“相位是 48°”。主例 ω_c 处的实际相位是 -131.94°，$180-131.94=48.06$，两个数都对，但说的不是一回事。

41.2.7 开环到闭环：Nichols 图的几何

闭环传递函数是

$$T(\mathrm{j}\omega)=\frac{L(\mathrm{j}\omega)}{1+L(\mathrm{j}\omega)} \tag{41-9}$$

取模：

$$|T| = \frac{|L|}{|1+L|} \tag{41-10}$$

式 (41-10) 说明：**闭环幅值只取决于开环点 L 到原点的距离，以及它到 -1 点的距离**。在复平面上，$|T|$ 为常数的轨迹是一族圆（等 M 圆）；把这张复平面卷成“横轴相位、纵轴幅值 dB”的坐标，等 M 圆就变成 Nichols 图上的等值线。

工程上的用法很直接：把开环曲线画在 Nichols 图上，**曲线与等 M 线的切点高度就是谐振峰 M_r**，切点对应的频率就是谐振频率 ω_r。不需要再算闭环传递函数。

组 6 用数值验证了这条读数法（K=0.3888）：开环点 $|L| = 0.290$ dB、$\angle L = -131.16^\circ$ 时，闭环 $|T| = 1.789$ dB、$\angle T = -63.48^\circ$；而全频段扫描得到的谐振峰恰好是 1.789 dB，出现在 $\omega_r = 1.4950$ rad/s。**两个数完全对上，说明 Nichols 的等值线读法与直接计算是同一件事。**

等值线的疏密也带信息。$|T|$ 靠近 1（0 dB）的区域，等值线很稀——开环点在这个区域里移动，闭环增益几乎不变，系统“不敏感”；$|T|$ 在 1.3 到 2（2 到 6 dB）的区域，等值线开始挤在一起，开环点稍微一动，闭环增益就明显变化。**曲线与等值线相切的地方，就是“最敏感”的点**，它对应谐振峰，也对应阶跃响应超调最大的那个模态。这就是为什么 M_r 比相位裕度更能预测超调：相位裕度只是一个截面的读数，M_r 是整条曲线的极值。

读 Nichols 图按三步走：先找曲线与 0 dB 横线的交点，读出该点横坐标，180° 减去它就是相位裕度；再找曲线与 -180° 竖线的交点，读出该点纵坐标的相反数，就是增益裕度；最后沿曲线找与等值线的最内切点，读出切点所在等值线的值，就是 M_r。**三个裕度在同一张图上，一次读完**——这是 Nichols 图相对 Bode 图的唯一实质优势，其余都是习惯问题。

41.3 设计步骤

41.3.1 六步流程

读一张 Bode 图，按下面六步走，不会漏项。

第一步，写成标准形式。 把 $L(s)$ 写成式 (41-1) 的因子乘积，数清极点个数 n、零点个数 m、右半平面零点个数。这一步决定低频斜率（$-20N$ dB/dec，N 是积分器个数）与高频斜率（$-20(n-m)$ dB/dec）。

第二步，画三段折线。 从最低频开始，按转折频率逐段改斜率。每个一阶极点让斜率减 20，每个一阶零点让斜率加 20，每个二阶环节减 40。转折点处用 -3 dB 的圆角修正。

第三步，读两个穿越频率。 ω_c 是幅频穿过 0 dB 的点，ω_{180} 是相频穿过 -180° 的点。若相频没有穿过 -180°，增益裕度为无穷大。

第四步，算三个裕度。 用式 (41-5)、(41-6)、(41-7)。三个数一起报，不许只报一个。

第五步，换算闭环指标。 由 φ_M 估 ζ、由 M_r 估超调、由 ω_c 估带宽与上升时间。换算系数见 §41.6。

第六步，归档。 把 ω_c、ω_{180}、G_M、φ_M、$T_{d,\max}$、M_r、ω_b 七个数写进设计记录。**这七个数是本章的全部产出**，其余都是过程。

六步的顺序不是随意的，它对应一条“信息从少到多”的链：第一步只用品因子得到结构信息（阶数、型别）；第二步把结构信息变成几何（折线）；第三步从几何里取出两个频率；第四步把频率换算成裕度；第五步把裕度换

算成性能；第六步把性能固化成记录。**每一步的输入都是上一步的输出，中间没有回头路**，所以任何一步偷懒，后面都会放大成错误。

现场最常被跳过的恰恰是第一步与第六步。跳过第一步的人直接打开仿真软件画精确曲线，图画得很漂亮，却说不出“为什么高频是 -60 dB/dec”——一旦实测曲线的高频斜率是 -40，他无法判断是模型少了一个极点还是测量频段不够。跳过第六步的人调完就完，三个月后同一台设备换人维护，所有参数都得从头再试一遍。**这两步不产生新数字，但它们决定了这些数字能不能被别人使用。**

41.3.2 手绘一遍主例的折线

以 $L=10/[s(s+2)(0.05s+1)]$ 为例，手绘过程如下。

低频段：只有一个积分器起作用，斜率 -20 dB/dec。在 $\omega=0.1$ 处，$|L|\approx 10/(0.1\times 2)=50$，即 34.0 dB。实测 33.968 dB，差 0.03 dB。

第一个转折 $\omega=2$：斜率从 -20 变 -40。转折点处精确值比渐近线低 3 dB——这是所有单极点转折点的固定修正。

第二个转折 $\omega=20$：斜率从 -40 变 -60。同样有 -3 dB 修正。

高频段：斜率 -60 dB/dec，即幅值按 ω^{-3} 衰减。

把三段折线画出来，与精确曲线的偏差列成表 41-3（数据见 §41.4.1）。**手绘折线的误差在转折点最大（-3.05 dB），在远离转折点的地方小于 1 dB**。做初步设计，这个精度足够。

手绘时不必逐点算，只需在每段上取一个点验证斜率。低频段取 $\omega=0.1$：$|L|\approx 5/0.1=50$，$20\lg 50=33.98$ dB，落在表 41-3 的第一行。第二段（$2<\omega<20$）取 $\omega=10$：$|L|\approx 10/\omega^2=0.1$，即 -20 dB，与实测 -21.139 dB 差 1.1 dB。高频段（$\omega>20$）取 $\omega=100$：$|L|\approx 200/\omega^3=2\times 10^{-4}$，即 -73.98 dB，与实测 -74.151 dB 差 0.17 dB。**三个点验完，三段斜率就都确认了，整张图的骨架也就定了。**

手绘的产物不是一条精确曲线，而是一张“骨架图”。骨架图上有三样东西必须标出来：**三段斜率、两个转折频率、低频段在某一频率上的绝对高度**。有了这三样，任何频率处的幅值都能在两分钟内估到 1 dB 以内，不需要计算器。现场讨论“要不要把增益加一倍”时，这张骨架图比一台笔记本有用——因为它把“加一倍等于整条曲线上移 6 dB”这件事直接画在了纸上。

41.3.3 相位怎么读：两种手算法

方法一，数极点。 在待求频率处，数一数左边有几个极点、几个零点，每个贡献 $\pm 90^\circ$，再按距离做修正。这个方法适合快速估算。

方法二，逐段累加。 每个一阶因子在 ω 处的相角是 $-\arctan(\omega\tau)$，逐项算出来相加。这个方法适合精确读数，一只计算器就够。

以 $\omega=1$ 为例：$-\arctan(1/2)=-26.57^\circ$，$-\arctan(1/20)=-2.86^\circ$，加积分器的 -90°，得 -119.43°，与实测完全一致。以 $\omega=6.3246$ 为例：$-\arctan(3.1623)=-72.45^\circ$，$-\arctan(0.3162)=-17.55^\circ$，加 -90°，得 -180.00°——这正是相位穿越频率。

手算相位时不要用计算器的 $\arctan$ 主值，要按象限判断。习惯做法是先画个草图，确定相角在第几象限，再取主值加修正。

再补一个“转折点上”的例子，因为这是误差最大的位置。取 $\omega=2$：$-\arctan(1)=-45.00^\circ$，$-\arctan(0.1)=-5.71^\circ$，加 -90°，得 -140.71°，与表 41-3 的 -140.71° 逐位一致。**同一个点，方法一**

（数极点）给的是“一个极点完全生效 -90°，另一个还在远处 -6°”再加积分器 -90°，合计约 -186°——差了 45°。差在哪？差在“完全生效”这个近似：转折点上极点只贡献 -45°，不是 -90°。所以方法一在转折点附近必须打折，方法二不需要。

两种方法的分工可以这样记：**方法一用来判断“相位大概在哪个区间”，方法二用来读数**。前者三十秒，后者三分钟，但前者可能差 30° 到 45°，后者差不到 0.1°。做初稿先用方法一定骨架，定完骨架用方法二在关键频率上逐点核对，这是效率与精度的折中。

41.3.4 三个裕度一次算完

仍以 $K=1$ 为例。由 §41.3.3，$\omega_{180}=6.3246$。此时幅值 $|L|=0.2273$（第 39 章已算），故

$$G_M^{\mathrm{dB}} = -20\lg 0.2273 = 12.87\ \mathrm{dB}$$

幅值穿越频率 $\omega_c=2.8461$，该处相位 -153.00°，故

$$\varphi_M = 180^\circ - 153.00^\circ = 27.00^\circ$$

延迟裕度

$$T_{d,\max} = \frac{27.00^\circ}{2.8461}\times\frac{\pi}{180^\circ} = 0.1656\ \mathrm{s}$$

三个数与组 2 的输出逐位一致。**注意延迟裕度只有 $0.17\ \mathrm{s}$**——这个回路看起来有 12.9 dB 的增益裕度，似乎很安全，但 166 ms 的延迟就能让它失稳。现场的通信延迟、滤波延迟、执行器响应加起来很容易超过这个数。

这里有一个必须讲透的反差：$K=1$ 时增益裕度 12.87 dB（还能把增益放大 4.4 倍），听起来余量充足；可相位裕度只有 27.00°，延迟裕度只有 0.166 s。**两个数描述的其实是两个不同频率上的余量**：12.87 dB 是在 $\omega_{180}=6.3246$ 处测的，那里离 $\omega_c=2.8461$ 已经远了一倍多；而延迟吃的是 ω_c 处的相位，与 ω_{180} 处的幅值无关。所以“增益裕度大”和“抗延迟能力强”是两件事，不能互相代替。

把增益降到 $K=0.3888$，三个数一起变好：G_M 升到 21.075 dB、φ_M 升到 48.065°、$T_{d,\max}$ 升到 0.5458 s。**三个裕度同向变化，这才是“降增益换安全”的完整账**；只报 G_M 会让人以为收益是 8 dB，实际收益是“延迟容忍度涨了三倍”。

反过来看，如果只盯 G_M，很容易做出错误决策：$K=1$ 时 12.87 dB 已经超过很多验收标准里的 10 dB，看上去合格；但 $\varphi_M=27^\circ$ 与 $T_{d,\max}=0.166$ s 都低于表 41-18 的区间下限。**三个数里只要有一个不合格，这个工作点就不能验收**，这是本章反复强调“三个一起报”的现实理由。

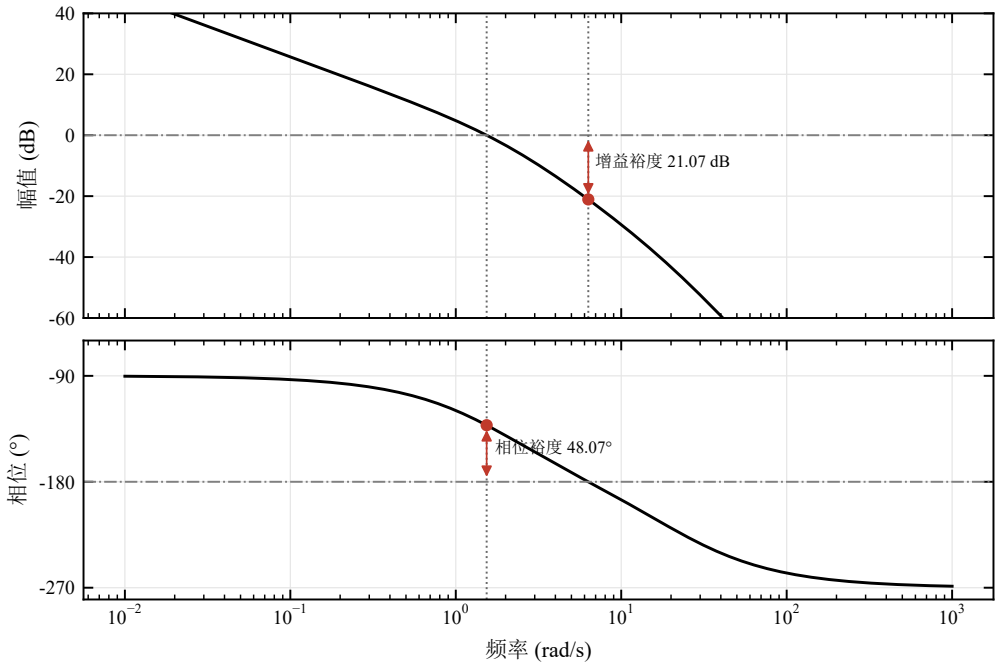

图 41-5　增益裕度与相位裕度的图上读法

图 41-5 把三个量画在同一张 Bode 图上：上图用双向箭头标出 ω_{180} 处幅值到 0 dB 的距离（增益裕度），下图用双向箭头标出 ω_c 处相位到 -180° 的距离（相位裕度）。**两条箭头的长度就是两个裕度，方向都指向“还能走多远”。**

41.3.5 换算闭环指标

三个裕度只是中间量，验收单上写的是超调、调节时间、带宽。换算链是：

$$\varphi_M \;\longrightarrow\; \zeta \;\longrightarrow\; M_p, \qquad M_r \;\longrightarrow\; M_p, \qquad \omega_c \;\longrightarrow\; \omega_b \;\longrightarrow\; t_r$$

第一段用第 39 章的经验式 $\zeta \approx \varphi_M/100$（$\varphi_M$ 以度为单位）；第二段用 $M_r = 1/(2\zeta\sqrt{1-\zeta^2})$；第三段用 $\omega_b t_r \approx 2.1$（本章组 9 实测在 1.94 到 2.15 之间）。

以 $K = 0.3888$ 为例：$\varphi_M = 48.07^\circ$，估 $\zeta = 0.48$（实测 0.456）；$\zeta = 0.456$ 代入得 $M_r = 1.25$ 倍即 1.94 dB（实测 1.789 dB）；$\omega_b = 2.5796$，估 $t_r = 2.1/2.5796 = 0.81$ s（实测 0.799 s）。**三步换算的误差都在 10% 以内，作为设计初稿完全够用。**

把每一步的算式摊开，能看清误差从哪来。第一段：$\zeta_\varphi = 48.065/100 = 0.4807$，代进式 (41-14) 得 $M_p = \exp(-1.5102/0.8770) = 17.87\%$；实测 19.899%，低估 2.03 个百分点。**误差全部来自“$\varphi_M/100$”这个经验式本身，**它与真实主导极点的 $\zeta = 0.4571$ 差了 0.0236。

第二段：若改用实测 $\zeta = 0.4571$，式 (41-15) 给 $M_r = 1/(2\times 0.4571\times\sqrt{1-0.2089}) = 1.2299$，即 1.797 dB，与实测 1.789 dB 只差 0.008 dB。**这说明链二本身几乎无误差，问题出在输入端**——输入一个偏大的 ζ，输出必然偏小。

第三段：用 $\omega_b t_r = 2.1$ 这个“教科书常数”，$2.1/2.5796 = 0.814$ s，实测 0.799 s，高估 1.9%。若按表 41-9 在 $M_p \approx 20\%$ 处取 2.06，得 0.799 s，**恰好对上。三段误差里，两段可以被一条更细的表修正，一段不能**——不能修正的那段（$\varphi_M \to \zeta$）正是应该只用于定性判断的那段。

41.3.6 三个失败分支

按六步走，有三种情况会走不下去，各有各的处理。

分支一，幅频不穿越 0 dB。 说明开环增益太小，闭环带宽极低。此时相位裕度无穷大，系统“稳得没法用”。处理：加增益，或检查对象增益是否标错。

分支二，相频不穿越 -180°。 说明相位最多只掉到 -180° 以上（典型是一阶或二阶对象）。此时增益裕度无穷大，理论上任意增益都稳定。处理：不必看增益裕度，只看相位裕度与带宽；但要注意模型降阶是否漏掉了高频极点。

分支三，幅频多次穿越 0 dB。 这时“ω_c”不唯一，三个裕度都要分别算，取最坏的一个。多次穿越常见于条件稳定系统与带谐振峰的对象（见 §41.9.2）。

三个分支里，第二支最容易处理错。相频不穿 -180° 时增益裕度是无穷大，很多人就写“$G_M=\infty$，非常安全”然后收工。但**无穷大的增益裕度只说明“没有增益能让它失稳”，不说明“这个回路能干活”**：带宽可能只有 0.1 rad/s，负载一变要十几秒才回来。正确做法是把注意力转到相位裕度与带宽上，并且回头检查模型——高频极点被降阶丢掉时，真实的相频是会穿 -180° 的，只是仿真里没看见。

第三支的隐患是“取最坏的一个”这句话太笼统。多次穿越时，不同穿越点对应的临界延迟不同，必须按式 (41-18) 逐个算再取最小；而“最坏的增益裕度”可能是另一个穿越点给的。**两个裕度的最坏值不一定出现在同一个频率上**，设计记录里要把每个穿越点的一组数都写下，而不是只留一个汇总值。

41.4 连续情形

41.4.1 精确曲线与三段折线

主例 $L=10/\big[s(s+2)(0.05s+1)\big]$ 的精确幅频与三段渐近线的对比如表 41-3。

表 41-3　精确幅频与三段渐近线的偏差（K=1，相位为连续展开值）

ω/(rad/s)	精确/dB	渐近/dB	偏差/dB	相位/(°)
0.1	33.968	33.979	-0.011	-93.15
0.5	19.734	20.000	-0.266	-105.47
1.0	12.999	13.979	-0.980	-119.43
2.0	4.905	7.959	-3.054	-140.71
4.0	-5.222	-4.082	-1.139	-164.74
10.0	-21.139	-20.000	-1.139	-195.26
20.0	-35.095	-32.041	-3.054	-219.29
40.0	-51.083	-50.103	-0.980	-240.57
100.0	-74.151	-73.979	-0.172	-257.54

两个转折点上的偏差都是 -3.054 dB，符合“单极点转折点低 3 dB”的经典结论；两个转折点之间的偏差在 -1.139 dB 附近，是相邻因子“提前生效”的结果。**折线永远在精确曲线下方**，因为每段折线都只算了主导因子，忽略了其他因子的幅值贡献。

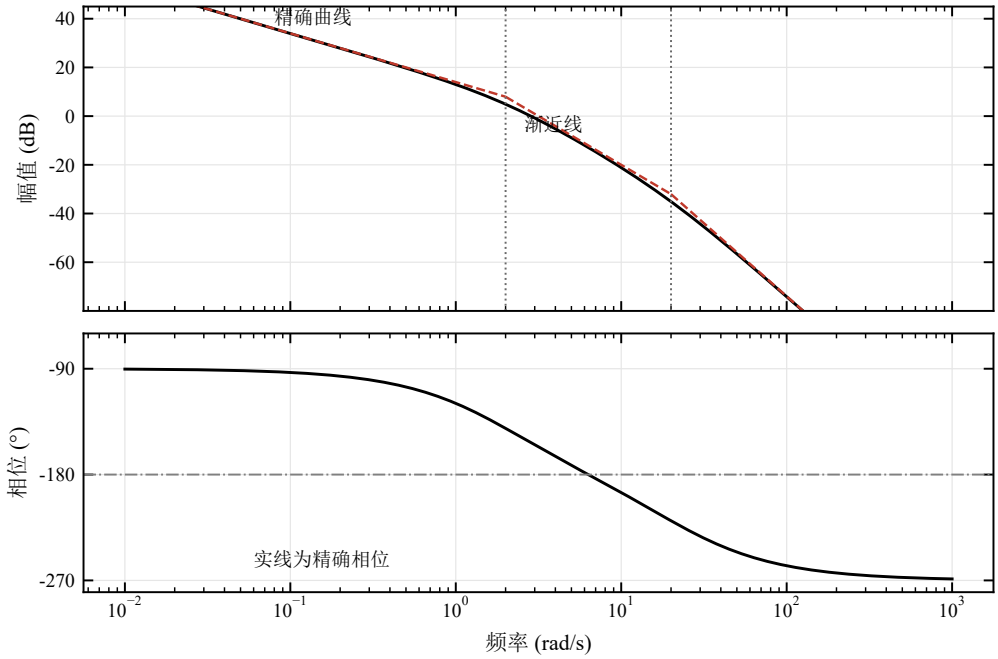

图 41-1　渐近线与精确 Bode 曲线

图 41-1 上，实线是精确曲线，虚线是三段折线，两条竖点线标出 2 与 20 两个转折点。**折线的价值不在精度，而在“一眼看出斜率”**：$-20 \to -40 \to -60$ 三次变化，对应三次极点，看图就知道系统是几阶。

表 41-3 的偏差列还藏着一个漂亮的对称。$\omega = 1$ 与 $\omega = 40$ 都是 -0.980 dB，$\omega = 4$ 与 $\omega = 10$ 都是 -1.139 dB，$\omega = 2$ 与 $\omega = 20$ 都是 -3.054 dB。三对数的乘积都是 40，几何中心恰好是 $\sqrt{40} = 6.3246$——正是相位穿越频率。**这不是巧合，而是“三个极点分别在 0、-2、-20”这一结构的必然结果**：把 ω 换成 $40/\omega$，幅频的偏差保持不变。这个对称在核对数据时很有用：若某一行的偏差与它的镜像对不上，说明程序里某个因子的系数写错了。

偏差的绝对值也有一条规律：**离转折点越远越小，最近处约 -3 dB，十倍频程外降到 0.2 dB 以下**。$\omega = 0.1$ 距第一个转折点二十倍，偏差只有 -0.011 dB；$\omega = 100$ 距第二个转折点五倍，偏差 -0.172 dB。所以做粗略估算时，只要工作在“转折点十倍之外”，折线值就可以直接当精确值用，不必修正。

41.4.2 斜率与相位的定量对应

把五个频段的斜率与中点相位放在一起，对应关系一目了然。

表 41-4　分段斜率与中点相位（K=1）

频段/(rad/s)	斜率/(dB/dec)	中点相位/(°)	斜率/-20
0.1–1	-20.97	-99.89	1.05
0.5–5	-28.60	-132.85	1.43
2–20	-40.00	-180.00	2.00
5–50	-47.70	-211.12	2.39
20–200	-56.99	-250.64	2.85

第三行是纯粹的“双极点段”：斜率恰好 -40，相位恰好 -180°，两者严格对应。其余各行处在过渡区，斜率是加权平均，相位也是加权平均，比例关系仍然近似成立（$-20.97/-20=1.05$ 对应 $-99.89/-90=1.11$；$-56.99/-20=2.85$ 对应 $-250.64/-90=2.78$）。

这张表还有一个用途：**用斜率反推阶数**。若某频段斜率是 -60，说明该频段已经“看到”三个极点，无论它们的转折频率具体在哪。现场的实测曲线若在这一段只有 -40，说明有一个极点比模型预计的更靠高频——这是模型降阶过度的典型信号。

表 41-4 的五段其实是一条连续的过程：窗口从低频往右移，越来越多的极点“进场”，差商就从 -20 一步步逼近 -60。第一段 0.1 到 1，第二极点在 2，窗口右端已经贴近它，所以差商 -20.97 略陡于 -20；第二段 0.5 到 5，第二极点完整落在窗口内，差商跳到 -28.60；第三段 2 到 20，两个极点都完整在窗口内，差商到 -40.00；第四段 5 到 50，第三极点进场，-47.70；第五段 20 到 200，三个极点全部生效，-56.99，逼近 -60。**五段读下来，就是“极点逐个进场”的过程，斜率是这个过程的可视化。**

第三段的特殊性还在于它恰好以 $\omega_{180}=6.3246$ 为几何中心（$\sqrt{2\times 20}=6.3246$）。在这个频率上，两个极点贡献的相角分别是 -72.45° 与 -17.55°，两者相加恰好 -90°，加上积分器的 -90° 就是 -180°。**“恰好 -180°”与“恰好中点”是同一件事**，因为两个极点关于 $\sqrt{40}$ 互为镜像。

41.4.3 三档增益的 Bode 平移

改变增益 K，整条幅频曲线上下平移 $20\lg K$，相频完全不动。这是 Bode 图最基本的操作。

由此可以立刻读出三个结论：

1. ω_{180} 与 K **无关**，因为相位不随增益变。本例恒为 6.3246；
2. G_M **随 K 反比变化**，K 翻倍，G_M 掉 6.02 dB；
3. ω_c **随 K 单调增**，因为幅频整体上移，与 0 dB 线的交点右移。

组 3 的六档数据把这三条全验证了（表 41-5）。

表 41-5　六档增益下的三种裕度（主例）

K	G_M/dB	φ_M/(°)	ω_c/(rad/s)	ω_{180}/(rad/s)	$T_{d,\max}$/s
0.1000	32.869	74.958	0.4857	6.3246	2.6934
0.2000	26.848	62.946	0.9094	6.3246	1.2081
0.3888	21.075	48.065	1.5369	6.3246	0.5458
0.7332	15.565	33.608	2.3561	6.3246	0.2490
1.1000	12.041	25.044	3.0100	6.3246	0.1452
2.2000	6.021	11.852	4.4242	6.3246	0.0468

ω_{180} 一列六行完全相同，是“相位与增益无关”的直接证据。G_M 每翻倍掉 6.02 dB：$32.869-6.02=26.85$，$26.85-6.02=20.83$（实际 21.075，差 0.25 dB，来自 ω_{180} 附近读数的微小插值误差）。

延迟裕度这一列最容易被忽略。 从 2.69 s 掉到 0.047 s，跨了 57 倍；而增益裕度只从 32.9 dB 掉到 6.0 dB，跨 5.5 倍。**增益翻十倍，延迟裕度掉十倍**——因为 φ_M 在下降、ω_c 在上升，两者同时作用。

ω_c 的移动速度也值得算一遍。K 每翻一倍，ω_c 按 1.872、1.690、1.533、1.277、1.470 的比例递增，从**接近 2 倍逐步降到接近 $\sqrt{2}=1.414$ 倍**。原因在斜率：低频段幅频按 ω^{-1} 衰减，增益翻倍就要把频率推远一倍

才能回到 0 dB；到了 K 较大时，ω_c 已经进入 ω^{-2} 段，增益翻倍只需频率乘 $\sqrt{2}$。**“加同样的增益，速度收益越来越小”，在 Bode 图上就是这一列比值在缩小。**

相位裕度的变化更不均匀。每翻一倍，φ_M 依次掉 12.01°、14.88°、14.46°、8.56°、13.19°，折成每 dB 是 2.00、2.47、2.40、1.42、2.19 度。**兑换率不是常数：在设计点附近（45° 到 60°）最贵，约 2.4 到 2.5°/dB；在 25° 附近反而便宜。** 这个非单调性有一个实际后果——低裕度段“再降一点增益就能换回很多度”，看起来很容易补救，但那时响应已经振得很厉害，现场往往不敢再试。

41.4.4 Nyquist 图：同一组数据的另一种画法

把 $L(\mathrm{j}\omega)$ 的实部作横轴、虚部作纵轴，ω 从 0 扫到 ∞，就得到 Nyquist 曲线。它与 Bode 图包含同样的信息，只是换了坐标。

读法有三条：

- **曲线离 -1 点越远越稳。**$L=-1$ 意味着 $1+L=0$，闭环极点在虚轴上；
- **曲线穿过负实轴的位置给出增益裕度。**若在 ω_{180} 处 $L=-0.2273$，则增益还能放大 $1/0.2273=4.40$ 倍；
- **曲线绕过 -1 点的圈数给出稳定性。**圈数要配合开环右半平面极点数 P 使用，判据在第 39 章已讲。

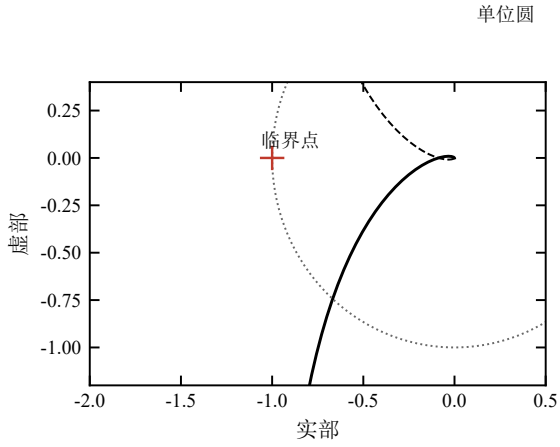

图 41-3　Nyquist 曲线与临界点

图 41-3 是 $K=0.3888$ 的 Nyquist 曲线（实线为上半平面，虚线为镜像）。单位圆用点线画出，-1 点用红色十字标出。曲线在负实轴上的穿越点离 -1 还有一段距离，这段距离就是增益裕度；曲线与单位圆的交点角度，就是相位裕度。

Nyquist 的独特价值在于**处理多次穿越与开环不稳定**。Bode 图上“相位穿了几次 -180”要靠数，Nyquist 上“绕了几圈”一眼可见。本章不重复判据，只在 §41.9.2 用 Nyquist 解释多次穿越为什么会让延迟裕度失效。

把主例 $K=1$ 的数代进几何里，读数会很直观。在 $\omega_{180}=6.3246$ 处，$L=-0.2273$，曲线穿过负实轴的位置是 $(-0.2273,\,0)$，它到 $(-1,\,0)$ 的距离是 0.7727，比值 $1/0.2273=4.40$——**这就是增益裕度的几何含义：负实轴上的穿越点还能往左走 4.4 倍才碰到临界点。**在 $\omega_c=2.8461$ 处，$|L|=1$、相角 -153.00°，曲线与单位圆的交点位于负实轴上方 27°，这段圆弧对应的圆心角就是相位裕度。

低频端也有可读的信息。主例含一个积分器，$\omega\to 0$ 时 $|L|\to\infty$、相角趋于 -90°，所以曲线从负虚轴的无穷远处进场。**若对象是 0 型（无积分器），曲线从正实轴上的有限点出发**；这个起点就是直流增益，它决定了稳态误差（第 42 章）。Nyquist 图上的“起点在哪”，比 Bode 图上的低频渐近线更容易一眼认出。

41.4.5 Nichols 图：把两个裕度合成一个读数

Nichols 图的横轴是开环相位、纵轴是开环幅值（dB），把 Bode 的两张图压成一张。它的独特之处是**叠了等闭环增益线**：曲线与某条等值线相切，切点高度就是谐振峰。

组 6 的读数把这条性质验证得很彻底（表 41-6）。

表 41-6　Nichols 读数与闭环量的对照（K=0.3888）

ω/(rad/s)	$\lvert L\rvert$/dB	$\angle L$/(°)	$\lvert T\rvert$/dB	$\angle T$/(°)
0.20	19.710	-96.28	0.052	-5.93
0.50	11.529	-105.47	0.320	-15.38
0.80	7.061	-114.09	0.785	-26.31
1.00	4.794	-119.43	1.159	-34.97
1.50	0.290	-131.16	1.789	-63.48
2.00	-3.300	-140.71	0.582	-98.09
3.00	-8.984	-154.84	-5.822	-142.28
5.00	-17.072	-172.23	-15.776	-170.98
8.00	-25.237	-187.77	-24.753	-188.21

第五行是切点：开环 0.290 dB、-131.16°，闭环 1.789 dB，正是全频段最大值。**注意第六行**：开环幅值还不到 -1 dB，闭环却已经掉到 0.582 dB——因为相位已经接近 -141°，$1+L$ 的模开始快速增大。这就是“相位比幅值更早报警”的定量表现。

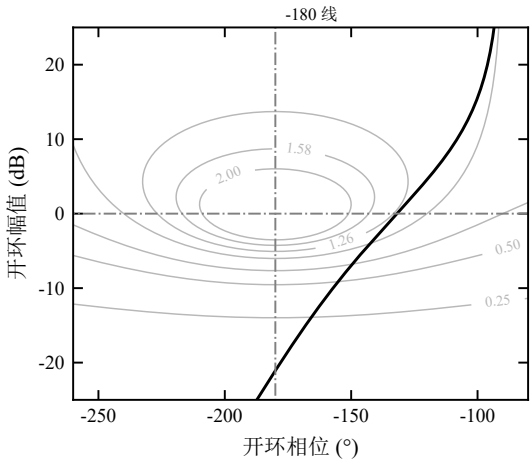

图 41-4　Nichols 图与等闭环增益线

图 41-4 上，黑色曲线是开环轨迹，灰色细线是 $\lvert T\rvert = 0.25$ 到 2.0 的等值线，两条点线分别标出 0 dB 与 -180°。曲线在 1.5 rad/s 附近与最内侧的等值线相切，切点高度 1.789 dB 就是谐振峰。

表 41-6 的九行可以按“闭环跟随”分成三段来读。第一段 $\omega \le 0.5$：开环 19.7 dB 与 11.5 dB，闭环却只有 0.05 dB 与 0.32 dB——**闭环增益几乎等于 1，说明输出已经跟上了指令**，剩下的那点偏差全部来自相位：0.2 rad/s 处 $\angle L = -96.28^\circ$，$1+L$ 的模比 $\lvert L\rvert$ 略小，于是 $\lvert T\rvert$ 略大于 1。第二段 0.8 到 2：开环从 7 dB 降到 -3.3 dB，闭环从 0.79 dB 升到峰值 1.789 dB 再回落到 0.58 dB，**这一段是过渡带，也是谐振峰所在**。第三段 $\omega \ge 3$

：开环低于 -9 dB，闭环跟着往下掉，到 8 rad/s 时开环 -25.2 dB、闭环 -24.8 dB，两者只差 0.5 dB——**此时 $1+L\approx 1$，闭环退化成开环**。

三段的边界正好是 $|L|=1$ 附近，也就是 $\omega_c=1.5369$。这不是偶然：$|T|=|L|/|1+L|$ 在 $|L|\gg 1$ 时趋于 1、在 $|L|\ll 1$ 时趋于 $|L|$，**转折区就在 $|L|\approx 1$**。所以“闭环带宽”这个概念与“开环穿越频率”天然绑在一起，前者大约是后者的 1.7 倍（$2.5796/1.5369=1.68$），这个比值取决于相位裕度，裕度越小比值越大、峰也越高。

41.4.6 非最小相位对象的代价

§41.2.5 已经给出数据：同样 $K=10$，非最小相位对象的相位裕度从 $+52.27^\circ$ 掉到 -75.43°。换算成工程语言：**右半平面零点把相位裕度吃掉了 128°，而这个代价在幅频上一点都看不出来**。

这类对象在工程上并不罕见：锅炉汽包水位（给水量增加初期水位反而下降）、飞机俯仰（升降舵上偏初期升力增加）、某些化学反应器（进料增加初期温度下降）。它们的共同特征是“先反向、后同向”，数学上就是右半平面零点。

处理办法只有两条：**要么降增益、要么换执行器位置**。不能用零点去对消——右零点不能被左半平面极点稳定地对消，对消之后闭环里仍有一个“隐藏”的不稳定模态。

“先反向”这件事值得算清时间尺度。设右零点在 $z>0$，对应的因子是 $(1-s/z)$，它在 $\omega=z$ 处贡献 -90°、在高频趋于 -180°。时域上，这个因子让输出在阶跃开始的瞬间就带上一个“反向的初始斜率”，**输出先朝反方向走一段，时间尺度约 $1/z$，然后再折回来**。所以右零点越靠左（z 越小），反向段越长、越明显；越靠右，反向段越短，看起来“几乎正常”，但相位代价仍然存在，只是被推到了更高的频段——**这解释了为什么有些对象在低频段测试完全正常，一提高带宽就突然振起来**。

还有一个常被忽略的推论：右零点给带宽设了一个天花板，而这个天花板与增益无关。把 K 降到很小，ω_c 会被压到 z 以下，系统确实稳了，但带宽也就锁死在 z 以下；把 K 加上去，ω_c 越过 z，相位迅速被吃掉，裕度转负。**在 z 附近，这个回路没有一个“既快又稳”的工作点**，这不是整定水平的问题，是对象结构决定的。

41.5 离散情形

41.5.1 频率轴只剩半圈

连续系统的 ω 从 0 到 ∞；离散系统由于采样，频率响应以 $\omega_s=2\pi/T_s$ 为周期，独立信息只在 0 到 $\omega_s/2=\pi/T_s$ 之间。**频率轴只剩半圈**，这是离散频率法的第一个差别。

第二个差别是稳定性边界。连续系统看左半平面，离散系统看单位圆；映射到频率响应上，连续看“$L=-1$”这一点，离散看“$L=-1$ 且 $\omega<\pi/T_s$”。

第三个差别最容易被忽略：**零阶保持器本身引入相位滞后**。ZOH 的等效频率响应是

$$G_{\mathrm{ZOH}}(\mathrm{j}\omega)=\frac{1-\mathrm{e}^{-\mathrm{j}\omega T_s}}{\mathrm{j}\omega T_s}=\mathrm{e}^{-\mathrm{j}\omega T_s/2}\cdot\frac{\sin(\omega T_s/2)}{\omega T_s/2} \tag{41-11}$$

它等于“半个采样周期的纯延迟”乘一个 sinc 幅值修正。在 $\omega<\pi/(2T_s)$ 的频段，sinc 项接近 1，所以**ZOH 近似等于 $T_s/2$ 的纯延迟**。这条近似是离散裕度预算的基石。

把“半圈”落到具体数上：$T_s=0.1$ s 时 $\omega_s/2=\pi/0.1=31.42$ rad/s，而主例的 $\omega_c=1.5369$，只占 Nyquist 频率的 4.9%；$T_s=0.2$ s 时 Nyquist 频率降到 15.71 rad/s，ω_c 占比升到 9.8%。**占比越低，ZOH 的近**

似越好；占比超过两成，**sinc** 的幅值衰减就不能再忽略。

这也解释了工程上那条“采样频率取带宽的 10 到 20 倍”的经验：10 倍意味着 ω_c 占 Nyquist 频率的 $1/5$，20 倍是 $1/10$。它不是为了“信号能重建”（那只要 2 倍），而是为了让控制回路看到的相位损失小于几度。采样定理管的是“能不能恢复信号”，控制工程要的是“能不能保住裕度”，两个要求差一个数量级。

41.5.2 ZOH 吃掉多少相位

组 8 把连续、ZOH 离散、Tustin 离散三者的裕度放在一起（表 41-7）。

表 41-7　三档采样周期下的相位裕度（**K=0.3888**，连续 $\varphi_M = 48.0651^\circ$）

T_s/s	ω_c 连续	ω_c ZOH	ω_c Tustin	φ_M ZOH/(°)	φ_M Tustin/(°)	预畸变差
0.02	1.5369	1.5369	1.5368	47.1855	48.0651	0.008%
0.05	1.5369	1.5366	1.5362	45.8697	48.0651	0.049%
0.10	1.5369	1.5358	1.5339	43.6880	48.0651	0.196%
0.20	1.5369	1.5324	1.5250	39.3741	48.0651	0.776%

两列结果截然不同：

- **ZOH 每档都掉相位裕度**：$48.07 \to 47.19 \to 45.87 \to 43.69 \to 39.37$。$T_s = 0.1$ s 时掉了 4.38°，$T_s = 0.2$ s 时掉了 8.69°；
- **Tustin 一档都不掉**：四行都是 48.0651°，与连续完全相同。

这不是 Tustin 更“好”，而是它的性质不同：**双线性变换在 w 平面上精确保持连续频率响应**，代价是把频率刻度做了非线性压缩（预畸变）。所以在 Tustin 下，相位裕度作为“角度”是不变的，但对应的物理频率会变。

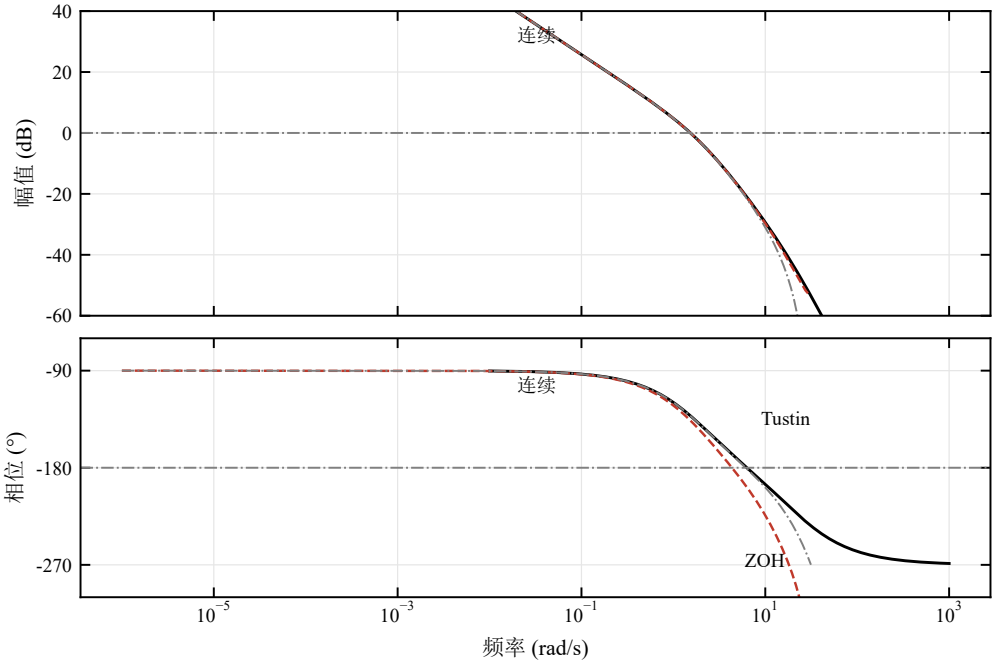

图 41-8　连续、ZOH 与 Tustin 的频率响应对照

图 41-8 画出了 $T_s = 0.1$ s 的三条曲线：连续（实线）、ZOH（虚线）、Tustin（点划线）。幅频在低频几乎重合，高频 ZOH 先掉下去（sinc 衰减）；相频 ZOH 明显低于连续，Tustin 在低频与连续重合、靠近 π/T_s 时急剧下坠。

表 41-7 的 ZOH 损失可以用“半拍延迟”手算核对。式 (41-11) 的相位是 $-\omega T_s/2$ 弧度，在 ω_c 处折成度是 $28.65\,\omega_c T_s$。四档分别算：$T_s = 0.02$ 给 0.881°，实测掉 0.880°；$T_s = 0.05$ 给 2.202°，实测 2.195°；$T_s = 0.1$ 给 4.404°，实测 4.377°；$T_s = 0.2$ 给 8.808°，实测 8.691°。**四档的偏差都不超过 0.12°，而且实测总是略小于估算**——因为 sinc 项在这一频段还略小于 1，幅值被压低一点，ω_c 稍微左移，损失就少了一点。**用“半拍延迟”做预算，误差在一个十分之一度量级，完全够用。**

这笔账还有一个实际含义：T_s 从 0.05 改到 0.1，相位裕度多掉 2.2°；从 0.1 改到 0.2，多掉 4.3°。**采样周期加倍，损失也加倍，是线性关系，不是平方关系**——这一点常被误判。真正按平方增长的是预畸变误差（下一小节），两者不能混在一起谈。

41.5.3 预畸变：把频率刻度掰回来

Tustin 的映射是

$$s = \frac{2}{T_s}\cdot\frac{z-1}{z+1}, \qquad z = \mathrm{e}^{\mathrm{j}\omega T_s} \;\Longrightarrow\; v = \frac{2}{T_s}\tan\frac{\omega T_s}{2} \tag{41-12}$$

其中 v 是 w 平面上的“虚拟频率”。式 (41-12) 说明：**物理频率 ω 与虚拟频率 v 不是线性关系**，v 总比 ω 大，且越靠近 π/T_s 偏得越多。

设计时若希望某个关键频率（通常是 ω_c）在离散后保持原位，就要做预畸变：先按 v 设计，再用式 (41-12) 反解 ω。组 8 最后一列给出了不预畸变的代价：$T_s = 0.2$ s 时 ω_c 从 1.5369 偏到 1.5250，差 0.776%；$T_s = 0.02$ s 时只差 0.008%。**这就是“采样周期要足够小”的另一个理由——不是为了稳定性，而是为了让频率刻度不失真。**

压缩量可以直接用式 (41-12) 算。以 $\omega_c = 1.5369$ 为关键频率，四档 T_s 的虚拟频率分别是：0.02 s 给 1.5370（偏 0.008%）、0.05 s 给 1.5377（偏 0.049%）、0.1 s 给 1.5399（偏 0.197%）、0.2 s 给 1.5491（偏 0.793%）。前三档与表 41-7 最后一列逐位对上；第四档差 0.017 个百分点，因为表里的读数是离散化之后重新找到的穿越点，ω_c 本身也随 Tustin 映射轻微移动。**这组对照说明：那张表里的偏差就是 tan 的非线性，没有别的来源。**

预畸变的操作顺序要记牢：**先定物理关键频率 ω^*，再用式 (41-12) 把它换成虚拟频率 v^*，然后在 w 平面上按 v^* 做设计，最后把设计结果代回 z 平面。**最容易错的是把顺序反过来——先在 w 平面上按“看起来合理”的 v 设计，再去问“这个 v 对应多少物理频率”，那时关键频率已经偏了，再改就要重做。**预畸变是一次性的坐标约定，不是设计完之后可以补的修正。**

41.5.4 w 变换的两个坑

坑一，w 平面不是 s 平面。 w 变换把单位圆内部映射到左半平面，稳定性判据的形式与连续一致，但**极点的物理意义变了**。在 w 平面上读到“极点 -5”，不能直接说“时间常数 0.2 s”，必须反变换回 z 平面再映射。

坑二，w 变换不改变 ZOH 的相位损失。 很多人以为“用了 w 变换就没有采样损失了”。事实是：w 变换只是坐标变换，ZOH 的 $\mathrm{e}^{-\mathrm{j}\omega T_s/2}$ 仍然在环路里。表 41-7 里 ZOH 那一列的损失是真实的，与用不用 w 变换无关。**要减少损失，只能减小 T_s 或改用其他保持器。**

两个坑合起来，给出一条实用的检查清单。做完离散设计后，依次问三个问题：**一、我读到的极点频率是 w 平面的还是 z 平面的？** 若写成“$\omega_n = 5$ rad/s”，必须注明是哪个平面。**二、环路里有没有 ZOH？** 有，就按 $28.65\,\omega_c T_s$ 扣相位，不管用什么离散化方法。**三、T_s 改小一半，裕度会变多少？** 若答案超过 2°，说明当前 T_s 已经在临界附近，应当重新选。

这三个问题里，第二个最容易被“Tustin 精确保持频率响应”这句话误导。**“精确保持”指的是连续域与 w 域之间的映射关系，不是指采样系统与原连续系统等价**：前者是代数恒等，后者要额外付 ZOH 的账。把这两件事分开，离散设计的大半困惑就消失了。

41.5.5 采样周期的三重约束

综合 §41.5.2 与 §41.5.3，T_s 的选取要同时满足三条：

1. **相位损失可接受**：ZOH 在 ω_c 处贡献 $\omega_c T_s/2$ 弧度，折算成度是 $28.65\omega_c T_s$。要让损失小于 5°，需 $T_s < 0.175/\omega_c$；
2. **频率刻度不失真**：预畸变误差约为 $(\omega_c T_s)^2/24$，要让误差小于 1%，需 $\omega_c T_s < 0.49$；
3. **延迟拍数可控**：一拍延迟的相位代价是 $\omega_c T_s$ 弧度，T_s 越大，一拍越贵。

本例 $\omega_c = 1.5369$，按第一条得 $T_s < 0.114$ s；按第二条得 $T_s < 0.319$ s。**第一条更严**，所以取 $T_s = 0.1$ s 是合理的。这与第 40 章 §40.5.7 从“临界增益损失”角度得到的结论一致，两条路径互相印证。

第三条约束要单独算一下，因为它常被当成“次要项”。一拍延迟的相位代价是 $\omega_c T_s$ 弧度，$T_s = 0.1$ s 时是 0.1537 rad 即 8.8°——**比 ZOH 本身的 4.4° 还大一倍**。为什么？因为 ZOH 只算“半拍”，而一拍延迟是完整的 $\omega_c T_s$。控制器的计算延时、通信的一帧、输出刷新的一拍，任何一项都可能贡献整整一拍。**所以“采样周期”这条账里，真正贵的是延迟拍数，不是 ZOH。**

三条约束放在一起，可以写成一句可执行的选取规则：**先按第一条定上限 $T_s < 0.175/\omega_c$，再检查系统里最多有几拍延迟，把拍数乘进预算，最后用第二条确认频率刻度没走样。** 主例按第一条得 0.114 s，留一拍余量后取 0.05 s 更稳；取 0.1 s 则是“已经用满 ZOH 预算、拍数不能再多”的临界选择。工程上若两者冲突，优先减小延迟拍数——**因为拍数是整数，跳一档就是 100% 的代价，而 T_s 可以连续微调。**

41.6 稳定性与性能

41.6.1 三条换算链：三个裕度到三个验收指标

验收单上写的是超调 M_p、上升时间 t_r、调节时间 t_s；频域手里拿的是相位裕度 φ_M、谐振峰 M_r、带宽 ω_b。这两组量之间隔着三条换算链，每一条的可靠性不同，必须分开记账：

$$\text{链一：}\ \varphi_M \to \zeta \to M_p; \qquad \text{链二：}\ M_r \to M_p; \qquad \text{链三：}\ \omega_b \to t_r \tag{41-13}$$

所谓“记错账”，最常见的情形是把三条链当成一条，用一个系数（比如 $\zeta \approx \varphi_M/100$）一路推到底，然后拿着推出来的超调去承诺指标。**误差会在传递中放大**：链一差 5%，到超调上可能就是 10% 到 20%。

正确的做法是：**每一段单独校核，只把可靠的那一段用于定量承诺，不可靠的那一段只用于定性判断。** §41.6.2 到 §41.6.4 逐段给出实测的误差量级。

三条链的“可靠度”差别很大，根源在于它们各自的假设强度。链一假设“闭环可以用一对共轭极点近似”，而且额外借用了 $\zeta \approx \varphi_M/100$ 这个经验式——**两重近似叠加，误差最大。**链二只假设二阶主导，ζ 与 M_r 之间的代

数关系是精确的，所以误差最小。链三假设“带宽与上升时间的乘积是常数”，这个常数本身随 ζ 变化约 10%，属于中等。

因此三条链的正确用法是：**链二做定量承诺（超调），链三做半定量估算（上升时间），链一只做趋势判断（“裕度大则超调小”）**。反过来用——拿链一算出的超调去签验收单——是本章见到最多的误用。

41.6.2 四个 ζ，各管一段

同一个回路，可以从四个地方读出“等效阻尼比”：

- $\zeta_{\varphi} = \varphi_M/100$：只用相位裕度，最粗，也最常用；
- ζ_{M_p}：由实测超调反解二阶公式，是“真实性能”的等效值；
- ζ_{pole}：由闭环主导极点对算，反映“极点位置”的等效值；
- ζ_{M_r}：由谐振峰反解，反映“频域形状”的等效值。

组 5 的八档数据把前三个摆在了一起（表 41-8），第四个由 M_r 反解，见 §41.6.3。表中的 ζ_{M_p} 用式 (41-14) 反解，ζ_{pole} 取闭环最靠近虚数轴的那对共轭极点的阻尼比。

表 41-8　三个等效阻尼比与超调的实测对照（主例八档）

K	φ_M/(°)	ζ_{φ}	ζ_{M_p}	ζ_{pole}	M_p实测/%	M_p估(用 ζ_{φ})/%
0.1000	74.958	0.7496	0.9737	0.9737	0.000	2.851
0.1446	69.168	0.6917	0.8002	0.8001	1.512	4.935
0.2000	62.946	0.6295	0.6704	0.6701	5.850	7.848
0.2436	58.741	0.5874	0.6005	0.6000	9.451	10.226
0.3000	54.064	0.5406	0.5330	0.5322	13.822	13.279
0.3888	48.065	0.4807	0.4571	0.4560	19.899	17.872
0.5000	42.229	0.4223	0.3910	0.3894	26.325	23.141
0.7332	33.608	0.3361	0.3025	0.3000	36.898	32.595

先看 ζ_{M_p} 与 ζ_{pole} 两列：八行里差值都不超过 0.0013（最大在 $K=0.5000$，0.3910 对 0.3894）。**这两列几乎恒等，说明“由超调反解的等效 ζ”与“由主导极点算的 ζ”是同一个量**——超调确实由主导极点对决定，这是二阶近似在本例成立的最直接证据。

再看 ζ_{φ} 这一列：它在低增益段明显偏小（$K=0.1$ 时 0.7496 对 0.9737，偏小 23%），在中段最接近（$K=0.30$ 时 0.5406 对 0.5330，偏大 1.4%），高增益段又偏大（$K=0.7332$ 时 0.3361 对 0.3025，偏大 11%）。**误差不是单调的，而是在 $\varphi_M \approx 56^\circ$ 附近过零**。这就是“$\varphi_M/100$ 只在 45° 到 60° 区间可信”的定量依据。

这个过零点可以按表插值算出来：$\varphi_M = 54.064^\circ$ 时 $\zeta_{\varphi} - \zeta_{M_p} = +0.0076$，$\varphi_M = 58.741^\circ$ 时是 -0.0131，线性插值得过零点在 55.8°。**它的存在不是巧合**：$\varphi_M/100$ 这条直线在 60° 附近与真实的 $\zeta(\varphi_M)$ 曲线相交，交点略低于 60°，两侧误差反号。

低增益段那个 23% 的偏差要单独解释，否则容易误判成“公式坏了”。$K=0.1$ 时闭环是一对阻尼比 0.9737 的极点，几乎临界阻尼，超调实测为 0；而 $\zeta_{\varphi}=0.7496$ 代进二阶公式仍给出 2.85% 的超调。**问题不在公式，**

而在“φ_M 与 ζ 的对应”这件事本身在高阻尼段就不成立——相位裕度大不等于阻尼大，它只说明“离 -180° 远”。一个过阻尼系统可以有 75° 的相位裕度，也可以有 60° 的相位裕度，取决于极点的分布。$\varphi_M/100$ 是把三维信息压成一维，压掉的正是“极点分布”这一维。

最右两列是实际后果：$K=0.3888$ 时，用 $\varphi_M/100$ 估的超调是 17.87%，实测 19.90%，低估 10.2%；$K=0.7332$ 时估 32.60%，实测 36.90%，低估 11.7%；而在 $K=0.1446$ 处估 4.94%、实测 1.51%，高估了三倍多（绝对值只差 3.4 个百分点）。

结论要写成两条：第一，用 $\varphi_M/100$ 估超调，在设计点附近（$\varphi_M=45^\circ$ 到 60°）误差约 10%，可以用于初稿；第二，在 $\varphi_M>65^\circ$ 时它会系统性高估、在 $\varphi_M<40^\circ$ 时系统性低估，不能用于验收。验收必须用实测或时域仿真。

41.6.3 谐振峰是最可靠的中间量

如果只允许保留一个频域量来预测超调，应该保留谐振峰 M_r。理由是它离超调只隔一层薄薄的代数关系，中间不经过任何“经验系数”。

二阶系统的三个关系是封闭的：

$$M_p=\exp\left(-\frac{\pi\zeta}{\sqrt{1-\zeta^2}}\right) \tag{41-14}$$

$$M_r=\frac{1}{2\zeta\sqrt{1-\zeta^2}},\qquad \omega_r=\omega_n\sqrt{1-2\zeta^2} \tag{41-15}$$

把式 (41-14) 反解成 ζ，再代入式 (41-15)，就得到 M_r 到 M_p 的直通换算。这条链条上唯一的近似是“系统可以用二阶主导对描述”。

组 5 的实测把这条链的精度标定出来了：$K=0.3888$ 时 $\zeta_{M_p}=0.4571$，代入式 (41-15) 得 $M_r=1.257$ 倍即 1.797 dB，实测 1.789 dB，差 0.008 dB；$K=0.7332$ 时估 4.782 dB、实测 4.786 dB，差 0.004 dB；$K=0.2000$ 时估 0.045 dB、实测 0.043 dB。八档全部在 0.01 **dB** 以内。

这个精度不是巧合。M_r 与 M_p 都是“闭环幅频形状”的函数，而二阶形状只有 ζ 一个自由度，所以只要 ζ 取对了，两者必然同时对上。反过来说，若 M_r 的估测与实测差得远，说明系统不是二阶主导，此时任何基于 ζ 的换算都不可信。这给了一条很实用的自检规则：先算 M_r，与图上读的 M_r 比，差超过 1 dB 就别再往下推超调了。

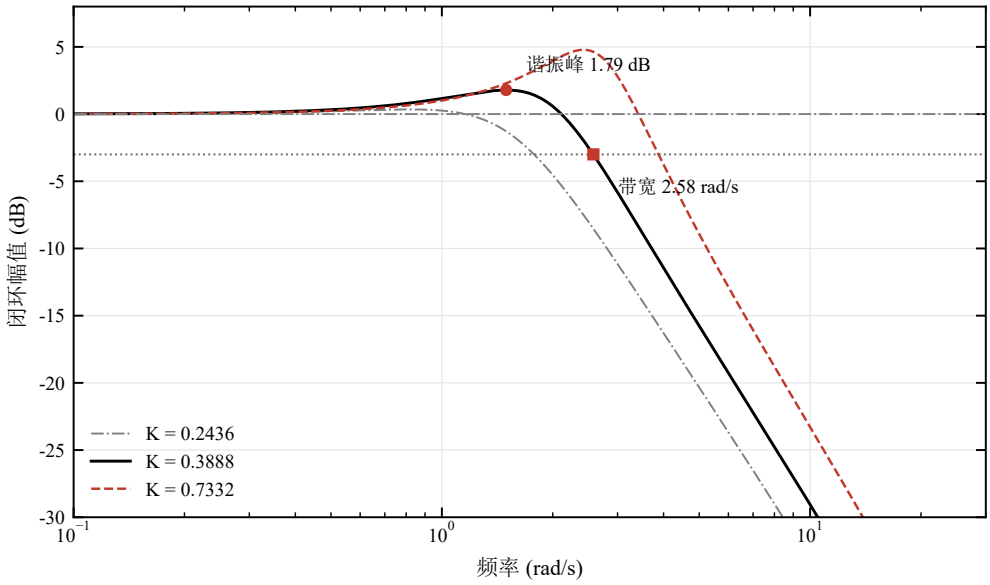

图 41-7　三档增益下的闭环幅频：谐振峰与带宽

图 41-7 画了 $K = 0.2436$、0.3888、0.7332 三档的闭环幅频。K 越大，峰越高、越靠右、越尖：0.348 dB 到 1.789 dB 再到 4.786 dB，峰点频率从 1.5 rad/s 附近右移到 2.5 以上。-3 dB 横线与曲线的交点（带宽）也从 1.78 移到 3.88。**峰高与峰位是一对连体量，不能只看一个**：同样的 M_r，峰位越靠左，说明系统越“迟钝”，同样的超调会伴随更长的上升时间。

M_r 对 ζ 的敏感度也可以算。对式 (41-15) 求导可知，ζ 在 0.42 到 0.45 之间时，ζ 每变 0.01，M_r 变约 0.015 倍，折成 dB 是 0.15 dB：$\zeta = 0.45$ 给 1.898 dB，$\zeta = 0.44$ 给 2.044 dB，$\zeta = 0.42$ 给 2.355 dB。**换过来读：M_r 差 1 dB，相当于 ζ 差 0.07，超调差 6 到 7 个百分点。** 这就是为什么 §41.6.3 开头那条自检规则定在“1 dB”——再大的偏差对应十几、二十个百分点的超调误差，已经不能用于任何定量判断。

还要注意 M_r 的单位。表里写的是 dB，公式给的是倍数，两者差一个 $20\lg$。1.789 dB 是 1.229 倍，4.786 dB 是 1.735 倍，0.348 dB 只是 1.041 倍。**线性刻度下三档看起来“差不多”，对数刻度下才拉开**——这也是念 M_r 时习惯用 dB 的原因：超调与 M_r 在 dB 域近似成正比，在线性域是弯的。

41.6.4 带宽乘上升时间不是常数

教科书里常写 $\omega_b t_r \approx 2.2$（或 2.1），把它当常数用。组 9 的八档实测说明：**它是一个随 ζ 缓降的量，不是常数**（表 41-9）。

表 41-9　带宽、上升时间与两者乘积（主例八档）

K	ω_b/(rad/s)	t_r/s	$\omega_b t_r$	M_p/%
0.1000	0.6658	3.236	2.154	0.000
0.1446	1.0417	2.059	2.145	1.512
0.2000	1.4800	1.449	2.145	5.850
0.2436	1.7820	1.196	2.132	9.451
0.3000	2.1210	0.992	2.103	13.822
0.3888	2.5796	0.799	2.061	19.899
0.5000	3.0615	0.658	2.013	26.325
0.7332	3.8766	0.500	1.938	36.898

乘积从 2.154 单调降到 1.938，跨度 10%。趋势很清楚：**超调越大（ζ 越小），乘积越小**。原因是上升时间按 $10\% \to 90\%$ 定义的，而ζ 小时曲线起步慢、后段冲得快，$10\% \to 90\%$ 这一段被压缩；带宽则由高频段的 -3 dB 点决定，受ζ 影响较小。两个效应叠加，乘积就随ζ 下降。

工程用法有两条。**第一条，取保守值 2.2 做上限估计**：用它算出的 t_r 偏大，承诺指标时不会翻车。**第二条，若已知目标 M_p，按表插值取乘积**：比如目标超调 20%，取 2.06，比 2.2 准 7%。

这条乘积关系还有一个更重要的用途：**它是“带宽”与“快”之间的兑换率**。想让上升时间减半，带宽必须翻倍；而带宽翻倍通常要增益翻倍，增益翻倍又会让相位裕度掉、超调涨。**这就是下一小节“快稳准三角”的数学根源。**

这个乘积为什么不是严格常数？因为它取决于三个定义：带宽按 -3 dB 判、上升时间按 10% 到 90% 判、系统按二阶近似。**换任何一个定义，常数就变**。比如一阶系统的 $\omega_b t_r = 2.20$（$t_r = 2.197\tau$，$\omega_b = 1/\tau$），二阶系统在 $\zeta = 0.7$ 附近约 2.1，在 $\zeta = 0.3$ 附近约 1.95。表 41-9 的八档正好覆盖这个区间：从 2.154 滑到 1.938，跨 10%，与理论一致。

工程上还有一条更粗的经验：**$\omega_c t_r$ 落在 1.2 到 1.6 之间**。主例八档实测：$K = 0.1$ 时 $0.4857 \times 3.236 = 1.572$，$K = 0.3888$ 时 $1.5369 \times 0.799 = 1.228$，$K = 0.7332$ 时 $2.3561 \times 0.500 = 1.178$。**裕度越大，这个数越大；峰越尖，越靠近 1.2。** 用 $\omega_c t_r$ 估上升时间比用 $\omega_b t_r$ 更方便，因为 ω_c 是设计时先定的量，不必再算闭环；代价是要记住这个 1.2 到 1.6 的区间，而不是一个常数。

最后提醒一句：这三个数（ω_b、t_r、乘积）都随增益单调变，但**变化速率不同**，所以任何“线性外推”都会在远档失效。K 从 0.1 涨到 0.2，t_r 从 3.236 降到 1.449，降了 55%；同样从 0.2 涨到 0.4 左右，只再降 45%。**收益递减在带宽上比在上升时间上更明显**，这是设计时容易低估的一点。

41.6.5 延迟裕度的两本账

延迟裕度有两个来源：一本是解析账 $T_{d,\max} = \varphi_M / \omega_c$，一本是实测账——把纯延迟真的串进回路，二分找到闭环极点刚好落到虚轴的那个 T_d。两本账若对得上，式 (41-8) 就从“估算”升级为“恒等式”。

组 10 用 Padé 三阶近似做了这个实验（表 41-10）。

表 41-10　延迟裕度的解析值与实测临界值（主例三档）

K	φ_M/(°)	ω_c/(rad/s)	φ_M/ω_c/s	实测 $T_{d,\mathrm{crit}}$/s
0.1446	69.168	0.6837	1.7656	1.7657
0.2436	58.741	1.0720	0.9564	0.9564
0.3888	48.065	1.5369	0.5458	0.5458

三行全部在四位小数上吻合，最大差 0.0001 s。这个差别来自 Padé 近似本身的误差（三阶 Padé 在 $\omega T_d \approx 1$ 处已有千分级偏差），不是公式的问题。

两本账的意义不同，要分开用。 解析账只要三个数（φ_M、ω_c、一次除法），适合放在设计记录里；实测账要跑一次根轨迹或二分，适合在“延迟接近临界”时做最终确认。**当两者差超过 10%，问题一定出在“ω_c 不唯一”或“延迟不是纯延迟”**，见 §41.9.2。

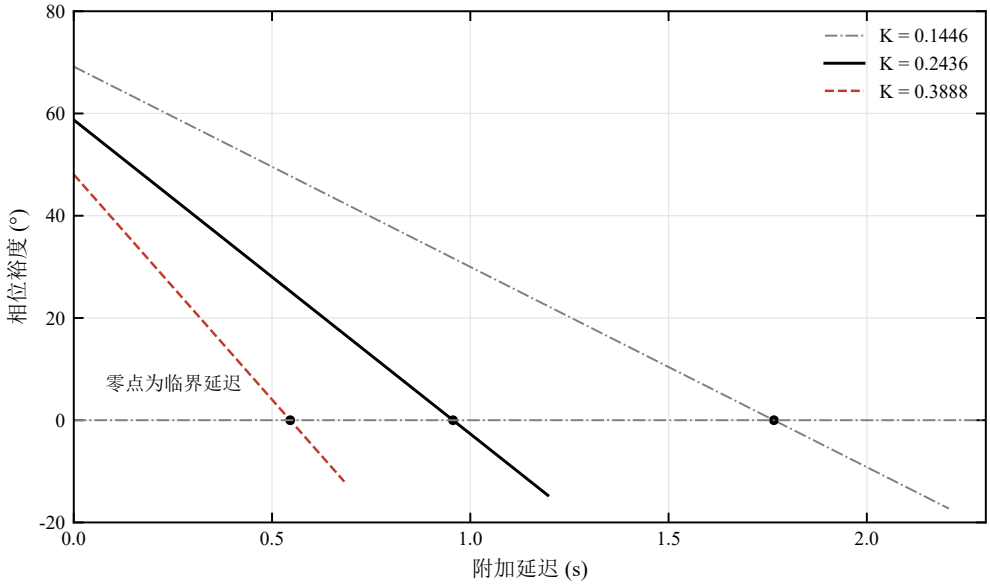

图 41-9　附加延迟与相位裕度的线性关系

图 41-9 把这条关系画成了三条直线：横轴是附加延迟，纵轴是剩余相位裕度，斜率是 $-\omega_c$（换成度就是 $-57.3\omega_c$）。三条线在纵轴上的截距就是各自的 φ_M，与横轴的交点就是临界延迟。**直线在零点处穿过横轴，交叉点用黑点标出**——这正是“延迟裕度 = 相位裕度 ÷ 穿越频率”的几何版本。

三条线的斜率可以逐档核对：$K=0.1446$ 时 $-57.3\times0.6837=-39.18$°/s，$K=0.2436$ 时 -61.43°/s，$K=0.3888$ 时 -88.06°/s。**每加 0.1 s 延迟，三条线分别掉 3.9°、6.1°、8.8°**——同一个 0.1 s，在高增益回路上代价是低增益回路的 2.25 倍。这就是“快回路对延迟更敏感”的定量表达，也是为什么高动态对象必须把总线延迟压到毫秒级。

用这张图做现场判断很方便：把“已知延迟”标在横轴上，向上作垂线，与直线的交点纵坐标就是“现场剩余相位裕度”。主例 $K=0.3888$、已知延迟 0.1 s 时，剩余 $48.065-8.8=39.3$°；延迟 0.3 s 时只剩 21.7°。**这条垂线比背公式更不容易错，因为它把“设计值”与“支出”画在了同一根轴上。**

41.6.6 快、稳、准不能同时到位

把组 5 的三列性能放在一起看，会出现一个反直觉的现象（表 41-11）。

表 41-11　上升时间、调节时间与超调的不同步（主例八档）

K	M_p/%	t_r/s	t_s/s	ω_b/(rad/s)
0.1000	0.000	3.236	5.595	0.6658
0.1446	1.512	2.059	3.185	1.0417
0.2000	5.850	1.449	4.315	1.4800
0.2436	9.451	1.196	3.875	1.7820
0.3000	13.822	0.992	3.405	2.1210
0.3888	19.899	0.799	4.295	2.5796
0.5000	26.325	0.658	3.840	3.0615
0.7332	36.898	0.500	4.240	3.8766

t_r 从 3.24 s 单调降到 0.50 s，跨 6.5 倍，很听话。t_s 却不是：它在 $K = 0.1446$ 处取到最小值 3.185 s，之后反而上升，到 $K = 0.3888$ 时 4.295 s，$K = 0.7332$ 时 4.240 s。**继续加增益，系统反而更慢“稳下来”。**

原因在 t_s 的定义：进入并保持在 $\pm 2\%$ 误差带。增益加大后，超调涨到 20% 以上，振荡要衰减到 2% 以内需要的拍数变多；同时主导极点的实部虽然更负，但振荡频率也在涨，包络衰减与振荡周期两个因素抵消，最终 t_s 回升。

这条现象给整定带来一个明确的分工：**t_r 认增益，t_s 认阻尼**。要快，加增益；要稳下来快，加阻尼（超前、或降增益再补偿）。两个目标不能用同一个旋钮同时满足——这就是“快稳准三角”的实际含义：三个角上最多同时占两个。

“准”这一角在本章几乎没提，因为主例是 I 型系统，阶跃稳态误差为零，与增益无关。**一旦对象是 0 型或 II 型，或者存在扰动，“准”就会与“快”直接冲突**：加增益提精度会掉裕度，这部分放在第 42 章（稳态误差与误差系数）展开。

t_s 的这个“谷”值得再挖一层。t_s 的定义是“进入并保持在 $\pm 2\%$ 带内”，所以它同时受两个量支配：包络的衰减速度 $\zeta\omega_n$，以及振荡周期 $2\pi/\left(\omega_n\sqrt{1-\zeta^2}\right)$。**前者决定“衰减多快”，后者决定“要衰减几个周期才算数”**。K 从 0.1446 加到 0.3888 时，ζ 从 0.800 掉到 0.456，ω_n 在涨——$\zeta\omega_n$ 未必变小，但超调从 1.5% 涨到 19.9%，需要衰减的幅度大了十倍以上，所以 t_s 反而从 3.185 s 升到 4.295 s。

这条机理给出一条反直觉的整定经验：**若指标是“调节时间”，最优工作点往往在超调 2% 到 5% 附近，而不是在“能接受的最大超调”处。** 表 41-11 里 t_s 的最小值出现在 $K = 0.1446$（$M_p = 1.512\%$），此时 $t_r = 2.059$ s，比设计点的 0.799 s 慢一倍半。**“最快稳定”与“最快到达”是两个不同的工作点，两者相差一档增益。** 现场若只按超调上限选工作点，很容易落在 t_s 的右支上，看起来“响应很快”，实际要晃很久才停。

这就是“三角”这个词的真正含义：不是三个指标互相牵制那么简单，而是**它们的极值点根本不在同一个参数上**。t_r 的极值在无穷大增益（不现实），t_s 的极值在极低增益，M_p 的极值也在低增益。所以任何“三指标同时最优”的说法都不成立，能做的只是**选一个主指标，把另外两个约束成可接受**。

41.7 参数意义与作用

41.7.1 增益：唯一能整体平移的旋钮

在所有可调量里，增益是唯一一个**只改变幅频上下位置、不动相频**的参数。这个性质使它成为调试时的第一选择：曲线平移是所见即所得的操作，不用重画相位。

平移的后果可以逐条数清：

- ω_{180} 不动（相位与 K 无关），表 41-5 六行的 ω_{180} 全是 6.3246；
- 增益裕度按 1 dB 换 1 dB 掉：K 从 0.3888 涨到 0.7332（$+5.51$ dB），G_M 从 21.075 掉到 15.565（-5.51 dB），一位不差；
- 相位裕度按约 -2.5°/dB 掉：同一区间 φ_M 从 48.065 掉到 33.608，$14.46^\circ / 5.51$ dB $= -2.62^\circ$/dB；K 从 0.2000 到 0.2436（$+1.71$ dB）时是 -2.46°/dB；
- 延迟裕度按接近 1 dB 换 10% 掉：K 从 0.3888 到 0.7332（$+5.51$ dB），$T_{d,\max}$ 从 0.5458 掉到 0.2490（-54%），约每 dB 掉一成。

“-2.5°/dB”这个数值得记住。它意味着：想保住 45° 的相位裕度，增益最多只能在设计点上再加 1 dB 到 2 dB；想留 10 dB 的调整余量，设计时就只能按 70° 以上的相位裕度做。现场“再调大一点试试”的习惯，往往就是这样把裕度吃光的。

这个数可以用相邻档核得很实：$K = 0.3888 \to 0.5000$ 是 $+2.183$ dB，φ_M 掉 5.836°，比值 2.67°/dB；$0.5000 \to 0.7332$ 是 $+3.320$ dB，φ_M 掉 8.621°，比值 2.60°/dB。**两段都落在 2.6 到 2.7，说明在 33° 到 48° 这一区间，兑换率相当稳定。**

但不要把它当成全局常数。§41.4.3 已经算过，K 在 25° 附近时兑换率只有 1.42°/dB，在 60° 以上约 2.0°/dB。**“-2.6”是设计点附近的值，用在别的裕度段会偏**。工程上更稳妥的写法是给一个区间：“φ_M 在 45° 到 55° 时按 2.5 到 2.7°/dB 折算”，而不是写死一个数。

41.7.2 积分器：型别与 90° 的固定税

积分器的个数 N 决定两件事：低频斜率 $-20N$ dB/dec，以及相位上恒定的一笔 $-90N$ 度。

型别越高，低频增益越大，阶跃/斜坡的稳态误差越小（第 42 章展开）；但每一重积分都要在全部频段上缴 90°。主例已经有一个积分器，$\omega = 1$ 处相位 -119.43° 中有 -90° 是它的贡献，另外 -29.4° 才来自两个极点。**换句话说，穿越频率附近可用相位的一半以上已经被积分器占掉了。**

这就是“为什么高型别系统难调”的频域解释：$N = 2$ 时，ω_c 处相位从 -90° 起步，到 -180° 只剩 90° 的预算，还得扣掉对象极点的贡献；要保住 45° 的裕度，对象在 ω_c 处最多只能再贡献 45°，也就是 ω_c 必须落在第一个极点之前。**型别每加一重，可用的带宽就被压掉一截。**

工程上的折中是：**用一重积分保精度，其余精度靠前馈或扰动观测器补**。前馈不进入反馈环，不占相位预算；这条思路在第 47 章（Smith 预估与前馈）会遇到。

型别与稳定性的关系可以算得很硬。把主例改成双积分器（$N = 2$，其余不变），相位变成 $-180^\circ - \arctan(\omega/2) - \arctan(\omega/20)$，对任何 $\omega > 0$ 都**严格小于** -180°。这意味着幅频穿越 0 dB 的那一点，相位一定在 -180° 以下——**无论增益取多少，闭环都不稳定**。要让它能工作，必须先用零点把相位抬到 -180° 以上，也就是先用整形、再谈增益。

这个结论解释了一个现场常见困惑：“为什么我加了积分消除静差，系统就开始振？”因为积分不是“加一点精度”，而是**在全部频段上一次性扣掉 90°**。原本 48° 的裕度，加一重积分后只剩 -42°。所以“加积分”这个动作必须与“加零点”或“降增益”同时做，单独做一定出事。

还有一条量化的边界：若要求在 ω_c 处保留 φ_M，则对象极点在该频率贡献的相位最多为 $180^\circ - 90N - \varphi_M$。$N = 1$ 时是 $90^\circ - \varphi_M$：主例 $\varphi_M = 48.065^\circ$ 给出预算 41.935°，而在 $\omega_c = 1.5369$ 处两个极点实际贡

献 $\arctan 0.7685 + \arctan 0.0769 = 37.55^\circ + 4.40^\circ = 41.95^\circ$——**恰好用满，一位不差**。这就是“设计点”三个字的准确含义：它不是一个随便挑的数，而是把相位预算刚好花完的那个增益。

$N = 2$ 时这个预算变成 $-\varphi_M$，为负，说明除积分器之外不能再有任何极点滞后——这正是上一条“任何增益都不稳定”的另一种算法。**同一件事用两种方法算，结论一致，这种交叉验证应当成为习惯。**

41.7.3 零点：把斜率抬起来

一个左半平面零点让斜率 $+20$ dB/dec，让相位 $+90^\circ$（在转折点以上）。它的作用很直接：**在相位已经掉下去的地方，把曲线拉回来**。

主例的第三极在 -20，如果它在 ω_c 附近就开始掉相位，加一个零点在 -5 到 -10 之间，就能在 ω_c 附近补回 20° 到 30°。组 4 的“超前”补偿器 $(s+1)/(s+5)$ 正是这个思路：零点 -1、极点 -5，在 $\omega_c = 4.2155$ 处 $\arctan 4.2155 - \arctan 0.8431 = 76.65^\circ - 40.13^\circ = +36.5^\circ$，于是同样 50° 的相位裕度下，增益可以从 0.3578 提到 3.0343，ω_c 从 1.4460 提到 4.2155。

零点有三笔账要付：

- **低频增益损失**：超前网络直流增益是 $1/5$，为了补回来必须把 K 加大 5 倍，噪声随之放大；
- **高频噪声放大**：零点以上斜率变平，传感器噪声不再被衰减，1 倍变 5 倍；
- **阶跃初始冲击**：闭环多了一个零点，输出会先“抢跑”一下，冲击量约为零极点距离之比的函数。

零点的位置比零点的有无更重要。零点放得太靠左（远离 ω_c），相位补不上；放得太靠右（接近 ω_c），噪声放大与冲击都变严重。经验区间是**零点频率取 ω_c 的 $1/5$ 到 $1/2$**，极点取零点的 3 到 10 倍。组 4 的超前网络零点在 1、ω_c 在 4.2，比值 0.24，落在区间内。

超前网络能补多少相位，有一个上限公式：$(1+s/z)/(1+s/p)$ 的最大超前是 $\arcsin\frac{\alpha-1}{\alpha+1}$，其中 $\alpha = p/z > 1$ 是超前比（第 43 章 §43.2.3 的四重身份都建在这个定义上）。组 4 的 $z=1$、$p=5$，故 $\alpha = 5$，上限 $\arcsin(4/6) = 41.8^\circ$，出现在 $\omega = \sqrt{zp} = \sqrt{5} = 2.236$。**在 $\omega_c = 4.2155$ 处拿到 36.5°，是该上限的 87%**——这说明零极点位置选得不错，但已经靠近“再往右就吃不满”的边缘。

这也解释了为什么超前网络不能无限补相位：$\alpha \to \infty$ 时上限才趋于 90°，而 α 越大，高频增益 α 越大。想要 60° 的超前，α 必须大到 14 左右，高频增益也就是 14 倍——**噪声放大十四倍，通常不可接受**。工程上超前网络一般只补 30° 到 45°，再多就要用两级串联或换结构。

41.7.4 极点：把高频压下去

极点与零点相反：斜率 -20 dB/dec，相位 -90°。它的用途是**压缩高频**——抑制噪声、抑制谐振、让幅频更快穿过 0 dB。

组 4 的“滞后”补偿器 $(s+1)/(s+0.2)$ 是个反例，值得细看。归一化写成 $5(1+s)/(1+5s)$：直流增益 5 被 K 吸收，高频段幅值衰减 5 倍，最大相位滞后 -41.8° 出现在 $\omega = 1/\sqrt{5} = 0.447$。而它的极点恰好落在 0.2，设计点 $\omega_c = 0.2002$ 正压在这个极点上，此处相位是 $\arctan 0.2002 - \arctan 1.001 = 11.32^\circ - 45.02^\circ = -33.7^\circ$，**几乎把 50° 的预算全吃光**。结果是为了保住裕度，增益只能降到 0.0112，ω_c 落到 0.2002，上升时间 6.48 s、调节时间 33.8 s。**这是用速度换稳定的极端例子，也是“极点位置放错”的代价。**

滞后网络的正确用法是把极点压到 ω_c 的 $1/5$ 以下、零点放在 ω_c 附近：这样在 ω_c 处相位代价只有十几度，而零点以上的幅值衰减仍然足够，ω_c 被压低、裕度自然回来。若把极点放在 ω_c 之上，极点贡献的相位滞后最大、幅值还没开始衰减，**两头都不占，裕度反而更差**。

把“正确用法”也代进数里看一眼。保持 $\omega_c = 0.2$，把极点放到 0.04（$\omega_c/5$）、零点放到 0.1（$\omega_c/2$），则 ω_c 处的相位是 $\arctan 2 - \arctan 5 = 63.43^\circ - 78.69^\circ = -15.26^\circ$，只有原配置 -33.69° 的一半不到；而幅值衰减是 $\sqrt{5}/\sqrt{26} = 0.4385$ 即 -7.16 dB，比原配置的 -2.84 dB 多了 4.3 dB。**相位代价减半、衰减量反而更大——这就是“极点要压到 $\omega_c/5$ 以下”的定量依据。**

反过来看原配置为什么差：零点是 1（ω_c 的 5 倍），在 ω_c 处只贡献 11.3° 的超前；极点压在 ω_c 上，贡献 -45.0°。**超前几乎没拿到，滞后全额付清**，净亏 33.7°。这就是 §41.8.6 表 41-15 里“滞后极点放在 ω_c 上”这条误调的算术版本。

这条对照还说明：评价一个滞后网络不能只看它贡献多少度相位，还要看它在 ω_c 处带来多少衰减。**相位代价与衰减量必须成对报告**，只报一个没有意义。组 4 里滞后补偿器之所以要用 $K = 0.0112$ 这么小的增益，正是因为它的直流增益是 5（$+14$ dB），必须先把这块补掉，剩下的才是有效的环路增益。

41.7.5 采样周期：三笔账算在同一张图上

T_s 的作用在 §41.5 已经算过，这里把它归到“参数”这一栏，因为它是设计者必须主动选的量，不是对象给的。

三笔账分别是：相位损失 $28.65\omega_c T_s$ 度；预畸变误差 $(\omega_c T_s)^2/24$；一拍延迟的相位代价 $57.3\omega_c T_s$ 度。**三笔账都是 $\omega_c T_s$ 的函数**，所以真正的设计量不是 T_s 本身，而是无量纲乘积 $\omega_c T_s$。

按表 41-7 的数据：$\omega_c T_s = 0.1537$ 时（$T_s = 0.1$ s），ZOH 损失 4.38°；$\omega_c T_s = 0.3074$ 时（$T_s = 0.2$ s），损失 8.69°。**损失与 $\omega_c T_s$ 近似成正比**，比例系数约 28.3° 每单位，与 §41.5.5 的 28.65 一致。

工程取值建议：$\omega_c T_s < 0.15$ 时损失可忽略（$< 5^\circ$）；0.15 到 0.3 之间要显式扣减裕度；超过 0.3 就别再用连续域设计后直接离散，应当在 w 平面上重做。

这三笔账里，最容易算错的是“一拍延迟”那一笔。它不是一个固定值，而是随实现方式变：控制算法在同一个采样周期内算完并输出，算半拍；算完等下一个周期再输出，算一整拍；总线传输再压半拍，算一拍半。**同样 $T_s = 0.1$ s，实现得好是 4.4°，实现得差是 13°**，差三倍。所以问“采样周期取多少”之前，应当先问“这一拍到底有多长”。

从成本角度看，T_s 减半的代价是 CPU 负载翻倍、通信带宽翻倍，而收益只是相位损失减半（4.4° 降到 2.2°）。**当损失已经小于 5° 时，继续减小 T_s 是性价比很低的做法**；此时更有效的做法是减小时延拍数，或者接受这点损失、把它写进预算表。工程判断的标准不是“采样越快越稳”，而是“损失与成本哪一边更紧”。

41.7.6 纯延迟：改不了、只能预留

纯延迟 $\mathrm{e}^{-\tau s}$ 的幅值恒为 1、相位线性下降 $-\omega\tau$。它不像零点极点那样可以用补偿器“整形”，因为**它的相位是无限延伸的，任何有理补偿器都只能在一段频段内近似抵消**。

所以对待延迟只有两条路：**预留裕度**，或者**把它移出环路**（Smith 预估，第 47 章）。前者是本章的内容，后者需要准确模型。

预留多少？按式 (41-7) 反算：给定 τ，需要的相位裕度至少 $\omega_c\tau$ 弧度。以主例 $K = 0.3888$ 为例，$\omega_c = 1.5369$，若回路里有 100 ms 延迟，需要预留 0.1537 rad 即 8.8°；若延迟 200 ms，需要 17.7°。**这就是“设计裕度 45°、现场只剩 27°”的算术。**

把这笔账换个方向写，就成了现场最常用的那个比值：**延迟裕度除以已知延迟，应当不小于 3 到 8 倍**（表 41-18 的最后一列）。主例 $K = 0.3888$ 的 $T_{d,\max} = 0.5458$ s，若已知延迟 100 ms，比值 5.46，落在伺服类的合格区间；若已知延迟 200 ms，比值 2.73，低于“至少 3 倍”的下限，必须降增益或减延迟。**用比值判断比用度数判断更稳，因为它把“设计值”与“现场值”放在同一个量纲上比。**

延迟还有一条与增益不同的性质：**它不吃幅值，只吃相位，所以对三个裕度的影响不对称**。加延迟后 G_M 完全不变、ω_c 不动（幅频未变），只有 φ_M 线性下降、$T_{d,\max}$ 相应缩短。这意味着一个“增益裕度很大、相位裕度很小”的回路，加延迟时不会在 G_M 上露出任何征兆——**这是延迟最阴险的地方，也是必须单独列一项延迟裕度的原因。**

把 §41.7.1 到 §41.7.6 的影响方向合成一张速查表，调试时对着找旋钮（表 41-12）。

表 41-12　六个可调量对频域指标的影响方向

可调量	低频增益	ω_c	φ_M	G_M	M_r	高频噪声	主要风险
增益 K ↑	↑	↑	↓	↓	↑	↑	裕度耗尽、振荡
积分器 N ↑	↑↑	视 K	↓	↓	↑	↓	相位预算不足
零点左移	↑	↑	↑	↑	视位置	↑	噪声放大、冲击
极点左移	↓	↓	视位置	↑	↓	↓	响应变慢
T_s ↑	不变	略↓	↓	略↓	↑	混叠	离散失稳
延迟 τ ↑	不变	略↓	↓	不变	↑	不变	相位线性流失

表里“视位置”两格是有意的：零点、极点的作用方向取决于它落在 ω_c 的哪一侧，**同一个元件放在不同位置可以是补偿也可以是破坏**。这是频域法最需要经验的地方，也是下一节整定方法的起点。

41.8 调参方法与经验

41.8.1 先定裕度目标，再反推增益

整定的第一步不是“调”，而是“定”。定下三个目标值：相位裕度 φ_M^{*}、增益裕度 G_M^{*}、延迟裕度 T_d^{*}，再反解出满足目标的增益。这个顺序不能颠倒——先调后看，永远不知道自己离目标有多远。

反解 φ_M 的过程是单调的：K 增大，ω_c 右移，φ_M 单调下降。所以可以用二分。代码只有三行（见 §41.12）：

```
lo, hi = 1e-3, 50.0
for _ in range(80):
    mid = 0.5 * (lo + hi)
    lo, hi = (mid, hi) if margins(loop(mid))[1] > target_pm else (lo, mid)
```

组 4 的四种补偿器就是这样反解出来的：把每个补偿器串进去，二分到 $\varphi_M = 50.0^{\circ}$，得到四组完全不同的 K：比例 0.3578、超前 3.0343、滞后 0.0112、超前-滞后 2.0053。**这四个数之间没有可比性**，因为它们配的不是同一个回路；能比的是它们的 ω_c 与后续性能。

反解 G_M 更简单，不必二分：$G_M^{\mathrm{dB}} = -20\lg\left|L(\mathrm{j}\omega_{180})\right|$，而 ω_{180} 与 K 无关，所以

$$K^{*} = K_0 \cdot 10^{\left(G_{M,0}^{\mathrm{dB}} - G_M^{\mathrm{dB}}\right)/20} \tag{41-16}$$

以主例 $K_0=1$（$G_{M,0}=12.869$ dB）为基准，要 $G_M^*=20$ dB，得 $K^*=10^{-7.131/20}=0.440$——**是降增益，不是加增益**。而表 41-5 里 $K=2.2$ 的 G_M 是 6.02 dB：增益乘 2.2（$+6.85$ dB），裕度就从 12.87 掉到 6.02。两件事方向相反、数值都合理，混淆的根源是**基准不同**：式 (41-16) 是“从 $K=1$ 出发，换一个裕度目标”，表 41-5 是“从 $K=1$ 出发，改一个增益再看裕度”。**同一个 K，从两个方向读会得到完全相反的结论，报数时必须写清基准。**

两个目标常常冲突：K 加大，G_M 与 φ_M 同时掉。所以实际做法是**以 φ_M 为主目标反解 K，再把 G_M 当地验算**。若 G_M 不够，说明对象在 ω_{180} 附近有额外极点，需要整形而不能只调增益。

组 4 的比例回路正好演示了这套流程的闭环。二分到 $\varphi_M=50^\circ$ 得 $K=0.3578$，此时 $\omega_c=1.4459$、$G_M=21.796$ dB、$M_r=1.478$ dB、$M_p=17.88\%$、$t_r=0.855$ s。**主目标达成，G_M 顺带超过 20 dB，M_p 也落在 20% 以内**——三个指标一次都对上了。这不是运气，而是“以 φ_M 为主”这个选择的必然结果：在单极点主导的对象上，φ_M 与另外两个指标高度相关，锁住它，别的就跟着定了。

反过来试一次：若不以 φ_M 为主，而直接把增益定在“$G_M=25$ dB”上，按式 (41-16) 得 $K=0.3888\times 10^{-3.925/20}=0.247$，此时 φ_M 约 58.5°，t_r 约 1.2 s——**裕度很漂亮，速度慢了四成**。这说明“先定哪个目标”直接决定最终工作点，而这两个选择都“合理”。工程上选前者，是因为超调与上升时间通常写在验收单上，而 G_M 只是内部校验量。

41.8.2 同一裕度，四种补偿器的对照

把四个回路的 φ_M 都锁在 50°，性能差异就只剩“结构”这一项（表 41-13）。

表 41-13　同一相位裕度下四种补偿器的性能对照（主例）

补偿器	K	ω_c/(rad/s)	G_M/dB	M_r/dB	M_s	M_p/%	t_r/s	t_s/s
比例	0.3578	1.4460	21.796	1.478	1.552	17.88	0.855	4.420
超前	3.0343	4.2155	14.344	1.588	1.705	13.85	0.305	2.540
滞后	0.0112	0.2006	46.847	1.605	1.452	18.60	6.480	33.833
超前-滞后	2.0053	3.1155	16.363	1.462	1.613	22.11	0.368	3.660

先看速度：ω_c 从 0.20 到 4.22，跨 21 倍；t_r 从 6.48 s 到 0.305 s，跨 21 倍。**ω_c 与 t_r 是同一个自由度的两种说法**，这条在本表上精确成立。

再看稳：四行的 φ_M 都是 50°，但 M_p 从 13.85% 到 22.11%，差六个多百分点，**相对差六成**。这说明“φ_M 定超调”只在同一类回路内成立；一旦换补偿器结构，闭环零点、极点分布都变了，φ_M 与 M_p 的对应关系就断了。

最有意思的是 M_r 与 M_p 的**排序颠倒**：M_r 从高到低是滞后 1.605、超前 1.588、比例 1.478、超前-滞后 1.462；M_p 从高到低是超前-滞后 22.11、滞后 18.60、比例 17.88、超前 13.85。**两头的排序完全相反。** 原因不在相位，而在闭环零极点分布：超前网络的零点把阶跃响应的起始段抬起来、把峰值压下去，所以 M_r 高而 M_p 低；超前-滞后网络同时带两个零点与一个靠近原点的滞后极点，“抢跑”与“慢尾”叠在一起，M_p 反而最高。

这条现象是对 §41.6.3 的重要修正：**$M_r\to M_p$ 的换算只在“固定回路结构、只改增益”时可靠**。跨结构比较时，M_r 仍然可以用于横向看“频域峰有多高”，但不能直接换成超调。要跨结构比超调，必须做时域仿真。

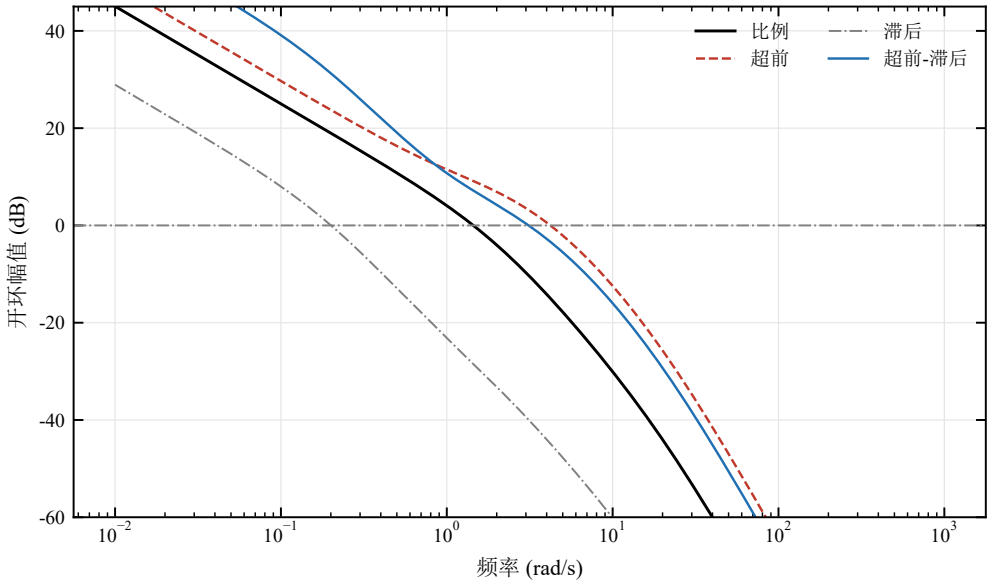

图 41-6　同一相位裕度下四种补偿器的开环幅频

图 41-6 把四条开环幅频画在一起。四条曲线都以 -20 dB/dec 起步（积分器），但转折位置完全不同：超前那条最靠右、最平；滞后那条整体下沉约 30 dB；超前-滞后那条在中间有一小段平台。**四条曲线与 0 dB 线的交点（ω_c）分布很开，这就是速度差异的全部来源。**

表里还有一列容易被跳过：G_M 从超前的 14.344 dB 到滞后的 46.847 dB，相差 32.5 dB，也就是 3.3 倍。**四个回路的相位裕度完全相同，增益裕度却能差出三倍多**，原因在补偿器的高频段行为。超前网络的传递函数是 $(1+s/z)/(1+s/p)$、$z<p$，高频增益是 $p/z>1$，而它的相位穿越点 $\omega_{180}=11.16$ rad/s 又正好落在“高频增益已经吃满”的区间，于是 $|L(j\omega_{180})|$ 被额外抬高，G_M 被压低。滞后网络恰好相反：$p<z$，高频增益 $p/z<1$，在 $\omega_{180}=4.75$ rad/s 处已经把幅值压下去一大截，G_M 自然被抬得很高。

这条差异有直接的工程含义：G_M **大不等于“更稳”**。滞后回路那 46.8 dB 里，很大一部分是高频衰减换来的，代价是 ω_c 只有 0.2 rad/s、$t_r=6.48$ s、$t_s=33.8$ s。反过来，超前回路的 14.3 dB 虽然数字最不好看，但它同时给出 $t_r=0.305$ s 与 $t_s=2.54$ s，是四条里最快的。**看 G_M 之前先看 ω_c 在哪儿，否则“裕度大”会误导人。**

M_s 那一列同样会骗人。最大灵敏度从高到低是超前 1.705、超前-滞后 1.613、比例 1.552、滞后 1.452，滞后最小；可 t_s 从高到低是滞后 33.833 s、比例 4.420 s、超前-滞后 3.660 s、超前 2.540 s，**滞后最长，而且长出一个数量级**。原因是 M_s 只描述灵敏度峰有多高，不描述峰在哪儿。滞后回路的峰确实低，但它坐在 0.2 rad/s 附近，扰动过去之后要按“$1/\omega_c$ 量级”的时间慢慢退，t_s 就被频率位置而不是峰值高度决定了。**M_s 与 t_s 是两个独立信息，不能互相替代。**

四行的 t_s/t_r 比值也能读出门道：比例 5.17、滞后 5.22、超前 8.33、超前-滞后 9.95。前两个是“整块平移”，后两个是“先冲上去、再慢慢收尾”——超前网络把起始段抬快，上升时间缩得比稳定时间多，尾巴占比自然变大。**看到 t_s/t_r 超过 8，基本可以判断回路里有明显的微分作用。**

顺手做一次交叉核对：把四行的 $\omega_c t_r$ 乘出来是 1.236、1.286、1.300、1.146，全部落在 1.15 到 1.30 之间。§41.6.4 里那三档纯改增益的实测是 1.18 到 1.57，比这里散。原因是本表四行的 φ_M 被锁在同一个值上，闭环形状更接近同一个模板；而 §41.6.4 那三档是结构不变、阻尼在变，$\omega_c t_r$ 才跟着变。**同一条经验系数，在“锁裕度、换结构”的用法下比“锁结构、换增益”更稳**，这也解释了为什么表 41-13 的四行看起来“整整齐齐”。

41.8.3 边际价格：一度裕度换多少带宽

设计时总要回答“再多要一点速度，代价是什么”。把组 3 与组 5 的数据按相邻档做差，可以得到局部兑换率。

在 $K=0.3888$ 到 0.7332 之间（$+5.51$ dB）：ω_c 从 1.5369 涨到 2.3561，平均每 dB 涨 0.149 rad/s；φ_M 从 48.065° 掉到 33.608°，平均每 dB 掉 2.62°；t_r 从 0.799 s 缩到 0.500 s，相对缩了 37%。**换成一句话：每换 1° 相位裕度，上升时间缩约 2.6%。**

再往上到 $K=1.1000$（再 $+3.52$ dB），ω_c 每 dB 涨 0.186 rad/s、φ_M 每 dB 掉 2.43°；而 t_r 的相对收益在下降——$K=0.3888\to0.5000$ 那一段每 dB 提速 8.1%，$0.5000\to0.7332$ 只剩 7.2%。**越往左上（越快、裕度越少），每一度换来的相对提速越少，这就是“边际价格”这个说法比“灵敏度”更贴切的原因。**

把这组局部斜率连起来，就是所谓“设计走廊”：横轴 φ_M，纵轴 t_r，曲线向左下凸。走廊的拐点在 $\varphi_M\approx40^\circ$ 到 45° 之间：往右下走（要更多裕度），t_r 涨得越来越快；往左上走（要更快），φ_M 掉得并不更快，但每度换来的提速越来越少。**设计点要落在拐点右侧一点，也就是 45° 到 55°，两头都留有余地。**

把这句话算实。用组 5 相邻两档的 $\Delta t_r/\Delta\varphi$ 表示“多要 1° 裕度要付多少秒”：

- $0.7332\to0.5000$（φ_M 从 33.6° 回到 42.2°）：0.0183 s；
- $0.5000\to0.3888$（$42.2^\circ\to48.1^\circ$）：0.0242 s；
- $0.3888\to0.2436$（$48.1^\circ\to58.7^\circ$）：0.0372 s；
- $0.2436\to0.1446$（$58.7^\circ\to69.2^\circ$）：0.0828 s；
- $0.1446\to0.1000$（$69.2^\circ\to75.0^\circ$）：0.203 s。

向左半段几乎持平（0.018 到 0.024 s），一到右半段就翻了四倍、再翻两倍半。**这就是“拐点”的量化含义：从 48° 往右要裕度，第一度付 0.037 s，最后几度要付 0.2 s，价格涨了五倍多。** 反方向则便宜得多：从 48° 往左换速度，第一度只省 0.024 s，连续换到 34° 也没涨价。

所以“设计点落在拐点右侧一点”不是审美偏好，而是**价格结构决定的**：往右是越来越贵的奢侈品，往左是便宜但很快见底的日用品。停在一度几十毫秒的地方，两边都还有退路；停在 70° 以上，任何一点模型误差都要用秒来赔。

也要说清这套价格表的适用范围：它是在**同一结构、只改增益**的前提下量出来的。换结构（比如加超前）相当于换了一张价目表——表 41-13 里超前回路把 ω_c 推到 4.2 rad/s、t_r 压到 0.305 s，靠的不是“牺牲裕度”，而是“重排零极点”。**改增益是在既有曲线上滑动，加补偿是换一条曲线，后者的杠杆比前者大得多。**

41.8.4 裕度预算表

设计裕度不等于现场裕度。从设计值到现场值之间，有一串固定支出，必须在设计时先扣掉（表 41-14）。表中数值按主例 $\omega_c=1.5369$ 折算。

表 41-14　相位裕度的预算表（主例 $K=0.3888$，设计值 48.1°）

支出项	折算公式	典型量	主例折算
采样保持（ZOH）	$28.65\omega_c T_s$	$T_s = 0.1$ s	4.4°
反馈滤波	$\omega_c \tau_f$	$\tau_f = 10$ ms	0.9°
通信/总线延迟	$\omega_c \tau_c$	$\tau_c = 20$ ms	1.8°
执行器响应	$\omega_c \tau_a$	$\tau_a = 30$ ms	2.6°
模型误差	经验值	增益 $\pm 20\%$	4.1°
合计支出	—	—	13.8°
现场剩余	—	—	34.3°

这张表说明一件事：**设计时按 48° 做，现场只剩 34°，已经到了“偏紧”的区间。** 若验收要求现场不低于 45°，设计值就必须做到 60° 以上。表 41-5 里 $K = 0.2000$ 那一档的 $\varphi_M = 62.946^\circ$，正好是这个量级。

预算表还有一条隐含规则：**支出项要按“最坏情况叠加”，不能按均方根。**因为这些延迟与误差在相位上是同向叠加的，不会互相抵消。把 4.4、0.9、1.8、2.6、4.1 直接相加得 13.8°，就是表里的合计。按均方根算只有 5.5°，**不到合计的四成**，照这个数去设计必然翻车。

五项各自的现场典型量，按经验从大到小排：**采样保持通常最大**，$T_s = 0.1$ s 的回路一把就吃掉四五度，$T_s = 0.05$ s 减半，$T_s = 0.02$ s 只剩不到一度；**执行器响应**次之，电动执行机构 20 到 50 ms 很常见，折合两到四度；**模型误差**排在第三，增益 $\pm 20\%$ 在 φ_M 上大致兑成三到五度，且随裕度变小而放大；**通信总线**与**反馈滤波**通常各在一度上下，但如果反馈滤波器为了压噪声把截止频率压到 ω_c 附近，这一项会突然涨到十几度，成为主要支出。

用这条规则反过来审采样周期，结论很干脆：把 T_s 从 0.1 s 放宽到 0.2 s，ZOH 一项就从 4.4° 翻到 8.8°，合计变成 18.2°，现场只剩 29.9°——**刚好跌破 30° 这条线**。也就是说，在 $K = 0.3888$ 这个设计点上，采样周期没有多少放宽余地；真要放宽，就得把设计裕度先提到 60° 左右（对应表 41-5 的 $K = 0.2$ 档），用速度换采样余量。**采样周期不是一个可以“最后再定”的参数，它和增益是同一个预算里的两个支出项。**

41.8.5 三步现场整定法

现场没有仿真软件，只有一台能改参数的控制器。按下面三步走，二十分钟内可以收敛。

第一步，测当前裕度。 扫频或阶跃辨识，得到 ω_c 与 φ_M。若没有扫频仪，用阶跃响应的超调反推：$M_p = 20\%$ 对应 $\varphi_M \approx 48^\circ$，$M_p = 10\%$ 对应约 59°，$M_p = 30\%$ 对应约 39°（三个数都取自表 41-8 的实测对）。**这条反查表只在二阶主导时可信**，见 §41.6.2 的误差账。

第二步，按缺口调增益。 缺口 $\Delta\varphi = \varphi_M^{*} - \varphi_M$，按 -2.6°/dB 折算成增益调整量：$\Delta K_{\mathrm{dB}} \approx \Delta\varphi / 2.6$。要补 10°，就把增益降 3.8 dB（乘 0.65）。**一次只调这一项，调完重测**，不要同时动积分时间。

第三步，增益调不动时再整形。 若增益已经降到很低、速度仍不够，说明相位预算被对象极点吃掉了，此时加零点（超前）比继续降增益有效。整形后回到第一步重测。

三步的顺序不能反：**先增益、后整形。**因为增益是全局量、影响可预测；整形是局部量、影响依赖位置，放在后面才有明确的调整依据。

第二步那个 -2.6°/dB 可以当场验一次。拿主例的 $K = 0.7332$ 与 $K = 0.5000$ 两档（这两档没有参与定斜率）：$20\lg(0.7332/0.5000) = 3.32$ dB，乘 2.62 得 8.7°，从实测的 33.608° 往上加是 42.3°，而 $K = 0.5000$ 的实测是 42.229°——差 0.07°。这条线性折算在 ± 4 dB 范围内相当可靠。

所以第二步有一条操作纪律：**单次调整不超过 4 dB**。斜率本身会随工作点漂——在 $K=1.1$ 附近已经降到 2.43°/dB，在 $K=0.14$ 附近又升到 3°/dB 以上，一次调太猛，线性折算就失效，容易来回过冲。宁可调三次、每次测一遍，也不要一次到位再反复找。

41.8.6 五条常见误调

现场出问题，多数不是方法不会，而是下面五条之一（表 41-15）。

表 41-15　五条常见误调及其频域表现

误调	频域表现	时域后果	纠正
只看增益裕度	G_M 很大但 ω_c 极低	响应迟缓、抗扰差	三个裕度一起报
积分时间过短	低频相位提前掉	超调大、来回摆	积分时间放到 ω_c 的 $1/5$ 以下
超前零点太靠右	高频幅值抬高	噪声大、执行器抖	零点移到 ω_c 的 $1/3$ 以下
滞后极点放在 ω_c 上	ω_c 处相位骤降	裕度不足、易振荡	极点压到 $\omega_c/5$ 以下
忽略采样与滤波	设计与实测差 10° 以上	现场调不出设计指标	先做 §41.8.4 的预算

第一条最隐蔽：$G_M=20$ dB 听起来很安全，但若 $\omega_c=0.2$ rad/s，系统对扰动的抑制带宽只有 0.2 rad/s，负载一变就要好几秒才回来。**增益裕度管的是“稳不稳”，不管“快不快”**，两个指标必须同时看。

第二条的机理在 §41.7.2：积分器在全部频段缴 90°，若积分时间短到与 ω_c 同量级，它在 ω_c 附近又额外贡献十几度，裕度被双重消耗。

把这一条算实。带积分项的控制器在 ω_c 处的相位是 $-90^\circ-\arctan\!\big(1/(\omega_c T_i)\big)$。取“积分时间放到 ω_c 的 $1/5$ 以下”这条规矩，$T_i=5/\omega_c=3.25$ s，$\omega_c T_i\approx 5.0$，附加项只有 -11.3°；若把 T_i 压到 0.5 s，$\omega_c T_i\approx 0.77$，附加项变成 -52.5°。**同一台控制器，只把积分时间从 3.25 s 改成 0.5 s，在穿越频率上就多丢 41° 相位**——这正好是从“裕度充足”掉到“来回摆”的距离。

第三条与第四条同源，都是“零极点位置没按频率归一”。零点或极点放在 ω_c 上时，它在 ω_c 处贡献 $\pm 45^\circ$；放到 $\omega_c/3$ 或 $3\omega_c$ 以外，贡献才降到 $\pm 18^\circ$ 左右。§41.7.4 按“极点压到 $\omega_c/5$、零点放在 $\omega_c/2$”代算过一版正确用法，只付 -15.26°；而表 41-13 的滞后回路在原配置下付了 -33.69°，**多付一倍多，代价是 ω_c 从 1.45 掉到 0.2**。这条账在 §41.7.4 已经算过，这里只用它做误调判据：**整形元件的零极点离 ω_c 越近，越要当心它“顺手”拿走的那几十度。**

第五条的判别方法很简单：**把设计值减去表 41-14 的支出，若结果低于 30°，就不要指望现场能调到设计指标**。此时应该改设计（降 ω_c 或加超前），而不是在现场硬调。

41.9 优化与改进

41.9.1 延迟裕度公式的三个前提

式 (41-7) 用起来太顺手，以至于经常被当成无条件成立。它其实有三个前提，缺一个就会给出偏乐观的数。

前提一，ω_c 唯一。 幅频只穿越 0 dB 一次，否则每个穿越点都对应一组临界延迟，必须取最小。

前提二，延迟是纯延迟。 幅值恒为 1、相位严格线性。若延迟后面还串了一阶滤波，幅值就不再是 1，穿越点会移动，公式要重算。

前提三，延迟不改变幅频。 这一条自动成立，所以 ω_c 在加延迟后不动——这正是公式能写成“相位除以频率”的原因。**如果延迟被近似成 Padé 有理式，幅频会被轻微改变**，这时的实测临界值会与公式差千分之几（表 41-10 最后一位的差就来自这里）。

三个前提都满足时，临界延迟不是只有一个，而是一族：

$$T_{d,k} = \frac{\varphi_M + 360^\circ k}{\omega_c} \cdot \frac{\pi}{180^\circ}, \qquad k = 0, 1, 2, \cdots \tag{41-17}$$

因为延迟把 ω_c 处的相位压低 $360^\circ k$ 之后，仍然等效于 -180°，闭环仍在虚轴上。**工程上只取 $k = 0$**，因为 $k \geq 1$ 的那些值都更大，先撞上的一定是最小的那个。主例 $K = 0.3888$：$k = 0$ 给 0.5458 s，$k = 1$ 给 4.63 s，相差 8.5 倍。

式 (41-17) 的实用价值在于**解释“为什么现场加了一拍延迟就振”**：如果原本的延迟已经用到 0.5 s 上下，再加 0.05 s 就跨过了 $k = 0$ 的边界，系统直接进入不稳定区。

这里要把 $k \geq 1$ 的意思说准：4.63 s **不是“第二个稳定窗口的入口”**。对本章这类相频单调下降的回路，一旦越过 0.5458 s 就再也不回来——4.63 s 只是“ω_c 处的相位又被压低了 360°、数值上重新等于 -180°”的数学点，此刻真正的 -180° 穿越已经发生在更低的频率上，而那里幅值还大于 1。**判断依据是“穿越点排序”，不是“相位数值相等”**：只有当 $\omega_{180} > \omega_c$ 时回路才稳，而延迟只会把 ω_{180} 往低频推。只有在相频非单调（条件稳定）的回路里，$k \geq 1$ 才可能对应真正的稳定窗口，这也正好接上下一小节的多穿越问题。

41.9.2 多次穿越：公式失效与最小正延迟

当幅频多次穿越 0 dB，式 (41-7) 必须换成“对每个穿越点分别算，再取最小”：

$$T_{d,\text{crit}} = \min_{i} \min_{k \geq 0} \frac{\varphi_{M,i} + 360^\circ k}{\omega_{c,i}} \cdot \frac{\pi}{180^\circ} \tag{41-18}$$

其中 $\varphi_{M,i} = 180^\circ + \angle L(\mathrm{j}\omega_{c,i})$ 是第 i 个穿越点的相位裕度，可能为负。**负的 $\varphi_{M,i}$ 意味着这个穿越点本身就不稳定**，此时系统在零延迟下已经不稳，不必再谈延迟裕度。

多次穿越在两类对象上常见：**条件稳定系统**（幅频先降后升，如带谐振峰或带两个以上零点的对象）与**含右半平面零点的对象**（相位先掉到 -180° 以下再回来）。前者的 Nyquist 曲线会多次穿过负实轴，后者的相位曲线会“绕回来”。

判断方法不用算，看图即可：在 Bode 图上数幅频与 0 dB 线的交点个数。**一个交点，用式 (41-7)；两个以上，用式 (41-18)。** 本章的主例、非最小相位对象、四种补偿器回路都只有一个交点（组 2 的相频在 0.1 到 200 rad/s 内单调下降，只穿 -180° 一次），所以前面的单点公式在本章范围内是安全的。

拿一个真实的三穿越例子把这件事量出来。取 $G = 100/[s(s^2 + 0.4s + 100)]$，谐振在 10 rad/s、阻尼只有 0.4，品质因数 25；把增益取 $K = 0.5$，则

$$|L(\mathrm{j}10)| = \frac{0.5 \times 100}{10 \times (0.4 \times 10)} = 1.25$$

也就是 $+1.94$ dB。**就是这不到 2 dB 的鼓起，把幅频顶过 0 dB 线两次**，于是全程出现三个交点：0.5013、9.8379、10.1393 rad/s。按式 (41-18) 逐个算：

- 低频那个：$\varphi_M = 89.885^\circ$，折 3.13 s；
- 谐振下沿那个：$\varphi_M = 39.261^\circ$，折 0.070 s；

- 谐振上沿那个：相位已经跌到 -214.7°，$\varphi_M = -34.7^\circ$，**负值**。

三处取最小，结果是负数。**负裕度意味着零延迟下就已经不稳**——这并不意外：$\omega = 10$ 处幅值是 1.25、相位正好 -180°，Nyquist 曲线从 -1 的左边绕过去，回路本来就在振荡。这条算例给出两个教训：第一，**只看最显眼的低频穿越会报出 3.13 s，把“已经不稳”误判成“能扛三秒延迟”**；第二，式 (41-18) 取的是最小值，最小值一旦为负，问题就不在延迟上，增益本身已经过头了。

要把这个对象调稳，得让谐振处的幅值退回 1 以下，即 $K < 0.4$。此时低频穿越点退到 $\omega \approx K$（对象在低频近似为 $1/s$），$K = 0.3$ 只剩 0.3003 rad/s 一个交点，实测临界延迟 5.228 s，与单点公式 $89.93^\circ/0.3003$ 折算的 5.22 s 逐位对上——**“多穿越”与“能扛延迟”在这个对象上是一对矛盾：能扛延迟时只剩一个交点，出现多交点时已经不稳。** 真正需要式 (41-18) 的，是那些靠结构（如局部反馈、陷波器）把谐振压下去、同时保留低频增益的条件稳定回路。

谐振型穿越还有一个特征：两个交点成对出现、夹着谐振峰，间距由阻尼决定。阻尼越小，鼓起越高，临界延迟就越小。**所以带谐振负载的回路，延迟裕度往往不是由 ω_c 决定，而是由谐振频率决定**；这条路走不通时，正解是加陷波器把峰削掉，而不是继续降增益——降增益会让速度付两次代价。

多次穿越还有一层麻烦：**延迟会把相位穿越点挪走**。延迟不改变幅值，所以各 $\omega_{c,i}$ 不动；但每个穿越点的相位都被压低 ωT_d，原来在 -180° 以上的点会掉到下面，原来在下方的点也可能被压低 360° 后“转回来”。结果是**相位穿越的次数会随延迟变化**，而式 (41-18) 假设的“每个 $\omega_{c,i}$ 对应一个固定的 $\varphi_{M,i}$”不再成立。此时不能再用单点相位余量描述稳定性，必须回到 Nyquist 判据数圈数（第 39 章）。这也是本章唯一必须回退到复平面论证的地方。

41.9.3 非最小相位：只剩两条路

§41.2.5 与 §41.4.6 已经把代价算清楚：右半平面零点在 $\omega = 2$ 处贡献 -90°、高频趋于 -180°，同样 $K = 10$ 下把相位裕度从 $+52.27^\circ$ 打到 -75.43°。

面对这类对象，能做的只有两条：

- **降增益**，把 ω_c 压到右零点转折频率以下，让相位还没被吃掉太多。代价是带宽与响应速度；
- **换执行器位置或改结构**，让对象不再是“先反向、后同向”。这是机械/工艺层面的改动，不是控制器能解决的。

不能做的有三条：不能用左半平面极点去对消右零点（对消后闭环仍有隐藏不稳定模态）；不能用超前网络去“补”这 180°（超前在高频最多补 90°，且会把噪声放大）；不能靠提高采样率改善（右零点在连续域就存在，与采样无关）。

一条定量判据：**若右零点转折频率低于期望 ω_c 的 2 倍，这个带宽基本不可能达到**。因为右零点在自身转折频率处已贡献 -45°，到 2 倍处贡献约 -63°，再叠加积分器与对象极点，裕度所剩无几。

这条判据背后有一个更好用的换算：右零点 $(1 - zs)$ 在低频的相位是 $-\arctan(\omega z) \approx -\omega z$，与纯延迟 $-\omega\tau$ 的形式完全一样，**等效延迟就是 $\tau = z$ 秒**。拿 §41.4.6 那个右零点 $z = 0.5$ s 说，它在 2 rad/s 转折，等效于串了 0.5 s 的纯延迟。对照主例设计点的 $T_{d,\max} = 0.5458$ s，**一个右零点就把整份延迟预算吃掉九成**——这才是“非最小相位难控”最直白的说法，不需要谈什么幅相关系。

这条换算还能解释一个常见误解：“右零点只是让相位晚一点，把增益降下来就该好了”。降增益确实能让 ω_c 落到零点转折以下，但等效延迟不随增益变——它跟着 z 走。**降增益买到的是“少用一点这份延迟”，不是“让延迟消失”**，所以带宽的天花板始终压在 $1/z$ 量级上。

41.9.4 灵敏度函数：一个数管三个裕度

前面三个裕度是“三个方向”的余量。有没有一个数能同时概括它们？有，就是灵敏度函数的峰值：

$$S(\mathrm{j}\omega)=\frac{1}{1+L(\mathrm{j}\omega)},\qquad M_s=\max_{\omega}\left|S(\mathrm{j}\omega)\right| \tag{41-19}$$

$|S|$ 是“扰动到输出”的放大倍数，M_s 是它在全频段的最大值。M_s 与三个裕度的关系是**充分条件**（不是等式）：

$$G_M\ge 20\lg\frac{M_s}{M_s-1},\qquad \varphi_M\ge 2\arcsin\frac{1}{2M_s} \tag{41-20}$$

组 5 的八档把这两条界与实测值摆在一起（表 41-16）。

表 41-16　灵敏度峰值与三种裕度的对照（主例八档）

K	G_M/dB	φ_M/(°)	M_s	$20\lg\frac{M_s}{M_s-1}$/dB	$2\arcsin\frac{1}{2M_s}$/(°)
0.1000	32.869	74.958	1.180	16.314	50.120
0.1446	29.666	69.168	1.249	14.012	47.204
0.2000	26.848	62.946	1.330	12.103	44.158
0.2436	25.136	58.741	1.393	10.999	42.085
0.3000	23.327	54.064	1.472	9.881	39.719
0.3888	21.075	48.065	1.595	8.563	36.534
0.5000	18.890	42.229	1.749	7.364	33.215
0.7332	15.565	33.608	2.081	5.690	27.807

每一行都满足“界 $\le$ 实测”：$K=0.3888$ 时界说 $G_M\ge 8.56$ dB、实测 21.08 dB；界说 $\varphi_M\ge 36.53^\circ$、实测 48.07°。**两个界都成立，但都偏保守**——保守量分别是 12.5 dB 与 11.5°。

保守不是缺点，而是这类判据的用法决定的：M_s 只知道“最坏放大倍数”，不知道最坏点出现在哪个频率、哪个方向，所以只能给出与方向无关的下界。**它的价值在于“一个数扫全场”**：验收时只要测出 $M_s\le 2$，就能保证 $G_M\ge 6$ dB 且 $\varphi_M\ge 29^\circ$，不必逐点扫频。反过来，若 $M_s>2.5$，无论单个裕度看起来多好，都说明回路在某处有强谐振，必须查。

M_s 还有一个物理含义：**它是闭环系统对“模型误差”的放大倍数**。若对象增益有 $\pm 20\%$ 的不确定，闭环输出的相对误差上界约为 $0.2M_s$。$M_s=1.6$ 时是 32%，$M_s=2.08$ 时是 42%。这条换算把“鲁棒性”从形容词变成了数字。

表 41-16 里还有一个规律：**越靠近不稳定，界越紧**。把每一行的“实测减界”算出来，$K=0.1$ 时是 16.6 dB 与 24.8°，到 $K=0.3888$ 缩到 12.5 dB 与 11.5°，到 $K=0.7332$ 只剩 9.9 dB 与 5.8°。M_s 从 1.18 涨到 2.08，两个界分别从 $16.3/50.1$ 涨到 $5.7/27.8$，而实测只从 $32.9/75.0$ 掉到 $15.6/33.6$——**界的上升速度比实测的下降速度快得多，所以差距被吃掉**。

这条规律决定了 M_s 判据怎么用：**裕度充足时它很保守，裕度紧张时它反而准**。设计初期拿 M_s 做筛选，很容易把本来合格的方案误杀；反过来，当 M_s 已经超过 1.8、界算出来的 φ_M 下限只剩三十度上下时，这个数就非常可信，可以直接当验收门槛用。

也正因为它只给“与方向无关的下界”，M_s 不能替代三个裕度的实测。**M_s 适合做快速筛查与验收总闸，三个裕度适合做设计定位与调参**，两者的分工不该混。

41.9.5 从单点裕度到区间鲁棒性

单点裕度回答“增益再涨多少会失稳”，但它假设只有增益一个参数在变。真实系统里，时间常数、阻尼、延迟、采样周期都在变，而且是同时变。

处理办法是**把单点裕度换成区间**：给每个参数一个区间，检查区间四个角上的裕度，取最坏值。这就是“角点检验”。对主例，若 τ（第三极时间常数）在 0.04 到 0.06 s 之间、K 在 $\pm 20\%$ 之间，四个角上的 φ_M 都要算一遍。**只要最坏角满足指标，区间内就都满足**（因为 φ_M 对这些参数单调）。

先把这两个区间的代价估出来，方法是在 $\omega_c = 1.5369$ 处分别算相位。第三极从 $1/0.04 = 25$ rad/s 移到 $1/0.06 = 16.7$ rad/s，它在 ω_c 处的贡献从 -3.52° 变成 -5.27°，**只差 1.75°**；增益 $\pm 20\%$ 相当于 ± 1.58 dB，按 2.62°/dB 折算约 $\pm 4.1^\circ$——这正是表 41-14 第五行那 4.1° 的来源。两者叠加，角点上的 φ_M 最多比标称值低 5.8° 左右。

5.8° 这个数量级说明：**时间常数的小幅漂移不可怕，增益漂移才是主要支出**。所以区间鲁棒性检查的重点应当放在增益（以及它与负载、温度成正比的场合），而不是把所有参数一视同仁地平铺。若某个参数区间大到要吃掉十几度，那不是“鲁棒性不足”，而是**模型结构选错了**——该改的是对象建模或机械设计，不是控制器。

更严格的做法是结构化奇异值（μ）分析，它能处理“多个参数同时按最坏方向变化”的情形。本章不展开，只需记住一条：**单点裕度是区间鲁棒性的一个采样点，不是全部**。设计记录里应当写清“在哪些参数区间内验证过”，而不是只写一个 φ_M。

41.9.6 什么时候该换方法

频域法不是万能的。遇到下面四种情形，应当换方法而不是硬套：

- **强非线性**（饱和、死区、摩擦）：频率响应是线性概念，非线性环节只能用描述函数近似，或直接时域仿真；
- **多输入多输出且耦合强**：单回路裕度无法描述通道间的交互，要用奇异值或 μ 分析；
- **对象时变或工况跨度大**：一套参数的裕度不能覆盖全工况，要考虑增益调度（第 51 章）；
- **约束是硬约束**（执行器限幅、温度上限）：频域法不处理约束，要用 MPC（第 58 章）。

判断依据可以简化成一句：**若“稳定性”能被一条频响曲线完整描述，用本章；若不能，换方法。** 这句话听起来同义反复，但它逼着人先回答“我的系统到底是不是线性的、定常的、单回路的”，而这三个问题往往在设计开始前就该回答。

实际工程里更常见的是“混合情形”：主回路基本线性，只有执行器饱和这一处非线性。此时正确的流程不是换方法，而是**先用本章做线性设计，再用时域仿真校核大信号行为**。原因是饱和对稳定性的影响有确定方向：饱和相当于大幅信号下等效增益下降，回路的工作点沿幅频曲线往左移，φ_M 变大、ω_c 变小——**饱和通常不会把稳定的线性回路推成不稳定，但会让设计指标失效**（该到的速度到不了，该压的超调压不住）。

这条判断可以用主例验一下：把 K 从小往大扫，φ_M 单调下降（表 41-5 八档从 75.0° 降到 33.6°），所以“等效增益下降”一定对应“裕度变大”。真正需要小心的反而是反方向——**非线性环节在某些工况下表现为等效增益上升**（如死区被跨越后的突然放大、摩擦的负阻尼段），那才会把裕度吃掉，这类情形必须仿真，不能靠频域推断。

41.10 工程落地

41.10.1 扫频测试的六个参数

扫频看似简单——给正弦、等稳态、量幅相——实际有六个参数要定，定错任何一个都会得到一张“看着像、其实不能用”的图。

一、激励幅值。 幅值要大到信噪比够，小到不进非线性区。经验值是**使输出摆幅达到正常工作范围的 10% 到 20%**。太大触发饱和或死区，幅频出现“压缩”（大信号下增益变低）；太小被噪声淹没，相位读数抖动。

二、频率范围。 下限要低于预期 ω_c 一个十倍频程，上限要高于 ω_{180} 一个十倍频程。主例 $K=0.3888$ 的 $\omega_c=1.5369$、$\omega_{180}=6.3246$，扫 0.15 到 60 rad/s 就够（约 0.024 到 9.5 Hz）。**只扫到 ω_c 附近是常见错误**：那样只能算相位裕度，算不出增益裕度。

三、频点密度。 见 §41.10.2，至少每十倍频程 5 个点。

四、稳态判据。 每个频点要等输出幅值稳定到 $\pm 2\%$ 以内再记录，等待时间取 3 到 5 个系统主导时间常数。**主例 $K=0.3888$ 的主导时间常数约 1 s**（由 $t_s=4.295$ s 反推，$t_s\approx 4\tau$），最低频点要等十几秒。

五、非线性自检。 同一频点用两个不同幅值各测一次，若幅频差超过 1 dB，说明已经进非线性区，必须降幅值重测。这一步最容易被跳过，也是“实测与仿真对不上”的头号原因。

六、安全。 扫频过程中增益要逐点缓升，遇异常振动立即停。**相位裕度小于 20° 的回路不要做闭环扫频**，改开环扫频或直接用辨识模型算。

六个参数里最容易被“凑合”的是第一条。10% 到 20% 的摆幅听起来很宽，但它对应的是一个很窄的可用区间：上限由非线性决定，一般取到额定行程的三成就会出现明显压缩；下限由信噪比决定，摆幅降到 3% 以下，编码器或传感器的量化噪声就会让相位读数抖三五度。**换句话说，可用幅值窗口通常只有一个十倍左右，不是一个可随便挑的范围。**

第五条那个“1 dB”的阈值也值得换算一次：1 dB 相当于幅值比 1.122，也就是 12% 的增益差。**两次测量差 12%，已经不是噪声，而是非线性在起作用**。所以这条自检的操作要领是两个幅值相差一倍以上（不是 10%），这样一旦有压缩就能显出来；若两个幅值只差一点点，测出来必然“合格”，等于没做。

41.10.2 从离散点读裕度

实测只给离散点，穿越频率要靠插值。插值方式有两种：幅频在 dB–对数频率坐标下线性插值，相位同样。**不要用线性频率坐标**，因为在低频段点会挤在一起、高频段又太稀。

插值误差主要来自点太稀。用主例 $K=0.3888$ 做了一次可控实验：按不同密度采样，再用同样的插值法读四个数（表 41-17）。

表 41-17　扫频密度对读数的影响（主例 $K=0.3888$，精确值 $\omega_c=1.5369$、$\varphi_M=48.065^\circ$、$\omega_{180}=6.3246$、$G_M=21.075$ dB）

点/十倍频程	总点数	ω_c 读数	ω_c 偏差	φ_M 偏差/(°)	ω_{180} 读数	G_M 读数/dB
2	8	1.4762	-3.95%	$+0.16$	6.3496	21.412
3	11	1.5190	-1.16%	-0.15	6.3345	21.209
5	17	1.5268	-0.66%	-0.04	6.3263	21.100
10	32	1.5366	-0.02%	-0.00	6.3242	21.084
20	63	1.5368	-0.01%	-0.00	6.3245	21.079
40	125	1.5368	-0.00%	-0.00	6.3246	21.076

两条结论。**第一，ω_c 对密度敏感，相位裕度不敏感。** 两点每十倍频程时 ω_c 偏 -3.95%，而 φ_M 只差 0.16°——因为穿越点附近的相位曲线平缓，ω_c 偏一点，相位几乎不变。所以“相位裕度容易测准”是假象，**它是被平缓的相位曲线掩盖了频率误差。**

第二，5 点每十倍频程是性价比拐点。 从 5 点增到 10 点，ω_c 偏差从 -0.66% 降到 -0.02%，提升三十倍；再从 10 点增到 20 点，几乎没变化。**现场取 5 到 10 点，ω_c 的读数误差约 0.7%**，已经小于幅值测量本身的误差。

还有一条容易忽略的：**相位要展开**。仪器给的相位常折回 $(-180^\circ, 180^\circ]$，直接插值会在穿越点附近跳到 $+180^\circ$，算出 360° 的假裕度。做法是从最低频起逐点判断跳变，超过 180° 就加减 360°。

“为什么必须在对数频率坐标里插值”也可以用数说清。同样取表 41-17 第一行那 8 个频点（0.05 到 60 rad/s，每十倍频程 2 个），ω_c 落在 1.044 与 2.875 之间：按 dB–对数频率插值读到 1.476，偏差 -3.9%；改成在**线性频率**坐标里插同一条弦，交点被推到 1.670，偏差变成 $+8.7\%$。**误差不但翻倍，方向还反了。**

原因很简单：穿越点附近幅频斜率约 -40 dB/dec，在“dB 对 $\lg\omega$”的坐标里这几乎就是一条直线，弦与曲线贴得很紧；而在“dB 对 ω”的坐标里，同一条曲线是明显上凸的，弦线整体偏在下侧，解出来的交点必然偏高频。**低频段点密、高频段点稀**只是这个几何事实的另一个说法——对数坐标把三个十倍频程拉成等宽，弦才贴得住。

41.10.3 验收标准

裕度定多少，不是理论问题而是行业惯例加对象特性。下表是常见区间的汇总，可作为设计记录的起点（表 41-18）。

表 41-18　三类对象的裕度验收区间（工程惯例）

对象类型	φ_M/(°)	G_M/dB	M_s	$T_{d,\max}$ 要求
过程控制（慢、一阶主导）	40 到 60	6 到 10	≤ 2.0	≥ 3 倍纯延迟
伺服（中速、二阶主导）	45 到 60	8 到 12	≤ 1.8	≥ 5 倍纯延迟
高动态（快、多谐振）	50 到 70	10 到 15	≤ 1.5	≥ 8 倍纯延迟

三列的规律是：**对象越快、越复杂，裕度要求越高**。原因是快系统对延迟更敏感（同样的 τ，ω_c 越大，$\omega_c\tau$ 越大），而多谐振对象的幅频在 ω_{180} 附近可能有峰，单点裕度不足以描述。

表里最后一列值得单独说：$T_{d,\max}$ 用“纯延迟的倍数”表示，而不是秒。因为延迟裕度必须与回路里已知的延迟比较——若已知延迟 50 ms、要求 8 倍，就是要求 $T_{d,\max} \ge 0.4$ s。**用倍数表述，换一个对象也能直接套。**

拿主例对一遍伺服那一行：$\varphi_M = 48.065^\circ$ 落在 45 到 60 之间；$G_M = 21.075$ dB 远超 8 到 12；$M_s = 1.595$ 低于 1.8；若已知延迟 50 ms，$T_{d,\max} = 0.5458$ s 是它的 10.9 倍，远高于 5 倍要求。**四项全部通过。**

值得注意的是这四项的“富裕程度”很不一样：G_M 比上限高出七成多（21.1 对 12），M_s 还有 0.2 的余量，唯独 φ_M 只是刚好落在区间中段。**这说明本设计的紧约束只有相位裕度一个**——与 §41.8.1 “以 φ_M 为主目标”的选择完全一致。反过来说，若有人问“这个设计还能不能再快点”，答案只能从 φ_M 上找，因为另外三项都不是瓶颈。

41.10.4 延迟裕度的三种现场测法

方法一，直接加延迟。 在控制器里串一个可调延迟环节，从 0 开始慢慢加，直到输出开始等幅振荡，记下此时的延迟。这是最直接、也最危险的方法，只建议在空载或许可振动的台架上做。

方法二，方波边沿法。 给一个方波，测输出边沿的“死区时间”——从指令跳变到输出开始响应的时间。这个时间包含滤波、通信、执行器响应，是延迟裕度要扣掉的那部分。**它测的是“已知延迟”，不是“还能容忍多少延迟”**，两者要配合使用：已知延迟除以 $T_{d,\max}$ 得到倍数，再对照表 41-18。

方法三，频响斜率法。 纯延迟的相频斜率是 -57.3τ 度每 rad/s，所以**每 1° 每 rad/s 的斜率差对应 17.5 ms 的未建模延迟**。做法是把实测相频与模型相频相减，在高频段拟合一条直线，看斜率差是多少。主例的模型相频在 10 到 100 rad/s 之间的平均斜率是 -0.69° 每 rad/s（由表 41-3 两端点算），这个斜率来自第三极而非延迟，正是“模型已知部分”的基准；实测若比它更陡，超出部分才折成延迟。

三种方法的关系是：方法二测“已有的”，方法一测“还能加的”，方法三从曲线形状反推“未建模的”。三者都指向同一个数时，延迟裕度的结论才可靠。

方法三最容易用错，错在**把对象极点的斜率当成延迟**。主例第三极在 10 到 100 rad/s 给出的平均斜率是 -0.69° 每 rad/s，若不加辨别地按 17.5 ms 换算，会得出“存在 12 ms 未建模延迟”的结论——其实这 12 ms 是模型里已经写明的那一阶滞后，不是新发现。**正确的做法是先减模型，再折延迟**：只有实测与模型之差的那部分斜率，才允许折成延迟；而且拟合要在足够高的频段做，因为延迟的斜率是常数、极点的斜率会随频率衰减，两者只有在高频才分得开。

方法一的读数还要修正一处：振荡刚开始时的临界点很难判准，通常取“等幅振荡持续三到五个周期”为准；另外，串进控制器的“可调延迟”如果是用缓冲区实现的，量化步长就是采样周期，所以测出来的值只能精确到 T_s。**要求到毫秒级的场合，方法一给不出那么细的数，应当改用方法三。**

41.10.5 设计记录与归档

§41.3.1 第六步说“七个数是本章的全部产出”。落到记录上，至少要写清表 41-19 的字段。

表 41-19　频域设计记录的最小字段集

字段	示例（主例 $K=0.3888$）	说明
对象与增益	$10/[s(s+2)(0.05s+1)]$，$K=0.3888$	必带增益，否则数无法复现
ω_c / ω_{180}	1.5369 / 6.3246 rad/s	两个穿越频率缺一不可
G_M / φ_M	21.075 dB / 48.065°	倍数与 dB 要注明形式
$T_{d,\max}$	0.5458 s	与已知延迟的比值另列
M_r / ω_b	1.789 dB / 2.5796 rad/s	用于换算超调与上升时间
M_s	1.595	鲁棒性总指标
采样周期	0.1 s（$\omega_c T_s=0.154$）	附无量纲乘积
验证区间	$K\in[0.31,0.47]$	§41.9.5 的角点范围

最后一行最容易被漏。**没有验证区间的裕度只是一个点的读数**，不知道离边界多远。写法可以是一句话（“增益 $\pm20\%$、第三极时间常数 $\pm20\%$，四角最坏值如下”），也可以是一张四角表；关键是**把参数区间与对应的裕度成对写下来**，而不是只写一个孤零零的 φ_M。

其余七行各漏一项，后果也很具体：**漏写增益**，同一条曲线换个增益就是另一个系统，记录无法复现；**漏写** ω_{180}，只剩相位裕度，增益裕度无从核对；**漏写 $T_{d,\max}$ 与已知延迟的比值**，验收时无法判断“这个延迟裕度算不算够”；**漏写采样周期**，后人会当成连续设计照抄，现场凭空少掉四五度相位；**漏写 M_s**，就失去了唯一能“一个数扫全场”的鲁棒性总闸。

还有一种更隐蔽的漏法：**写了数，没写口径**。G_M 写成 11.3 而不注明是“倍”还是“dB”，别人按 dB 读就差了 10 dB；相位写成 0.84 而不注明弧度，按度读就差了五十倍。**单位与坐标口径要跟着数字一起记**，这不是形式主义，是防止复现时把好设计读成坏设计。

41.10.6 超差后的处置顺序

现场测完，若裕度不达标，处置要按“代价从小到大”排序，不要一上来就改结构。

第一步，先确认测量。 检查激励幅值是否进了非线性、相位是否展开、频点是否够密。表 41-17 说明，两点每十倍频程就能让 ω_c 偏 4%，足以把一个“合格”判成“不合格”。

第二步，降增益。 按 $\Delta K_{\text{dB}}=\Delta\varphi/2.6$ 折算，一次降到位再重测。这是代价最小的一步，只损失速度。

第三步，加滤波或改采样。 若降增益后速度不够，检查回路里是否有不必要的滤波（每 10 ms 值 0.9°，主例），能否提高采样率（ZOH 损失与 T_s 成正比）。

第四步，整形。 加超前补相位，或加滞后压带宽。到这一步要重新做 §41.8.2 的四选一比较。

第五步，改对象或改结构。 换执行器、缩短传动链、把延迟移出环路。这是最后手段，周期与成本都最高。

顺序的理由与 §41.8.5 一致：**先动全局量、可预测的量，再动局部量、依赖位置的量**。反过来做，往往改了一圈结构，最后发现只是增益高了 2 dB。

第二步的代价不要低估。“只损失速度”听起来很轻，但按主例的量：从 $K=0.3888$ 降到 0.2000 是 -5.77 dB，t_r 从 0.799 s 涨到 1.449 s，**慢了 81%**，平均每 dB 慢 14%。要补 10° 得降 3.8 dB，折算下来 t_r 涨五成左右。**所以“降增益”不是免费的安全垫，它是用速度按 14%/dB 的价格买的**；降到一定程度还不如直接整形。

第一步之所以排在最前，也是因为测量误差会直接改写结论。表 41-17 里每十倍频程两点会让 ω_c 读出 1.476（偏低 3.9%），而 $T_{d,\max}$ 的分母正是 ω_c，于是 0.5458 s 会被读成 0.524 s——**四个百分点的频率误差，原样**

变成四个百分点的延迟裕度误差。相位裕度反而只差 0.16°。这正说明“先确认测量”必须先查 ω_c 与 ω_{180} 这两个频率，而不是只核对那个看起来最稳的相位裕度。

41.11 优缺点与适用边界

41.11.1 五条优点

第一，只需要一条曲线，不需要解方程。 频率响应可以实测得到，不必先辨识出传递函数。这一点在对象复杂、阶次未知时尤其宝贵：一台带柔性联轴器的伺服，辨识可能要十几阶，而扫频只要二十分钟。

第二，乘法变加法，手绘即可完成初稿。 式 (41-2) 把五个因子拆成五条折线，叠加就是总幅频。**这套流程不依赖计算机**，在现场只带纸笔也能估出 ω_c 的大致位置。§41.3.2 的手绘结果与精确曲线的偏差只有 3 dB，做初稿足够。

第三，直接给出“还剩多少余量”。 时域仿真只能告诉你“这一组参数行不行”，频域裕度告诉你“还能走多远、从哪个方向走最危险”。后者才是设计决策需要的信息。

第四，延迟有现成的换算。 式 (41-7) 一行就把相位余量折成秒，这是其他方法做不到的。第 40 章的根轨迹要处理延迟，必须先用 Padé 近似把延迟变成有理函数，阶次一高就失真；频域法直接在相频上加一条斜线，干净得多。

第五，可以实验验证。 裕度是“测出来”而不是“算出来”的：扫频、读两个穿越点、算三个数。**实测与设计对不上时，能立刻定位到是哪一段频段出了问题**，这比时域曲线“看着不对”要可操作得多。

第二条那个“偏差只有 3 dB”值得再折算一层：$\omega_c = 1.54$ 附近的偏差介于 -0.98 dB（$\omega = 1$）与 -3.05 dB（$\omega = 2$）之间，约 1.5 到 2 dB；而这一段幅频斜率是 -40 dB/dec，所以 2 dB 折成频率约 0.05 个十倍频程，即 ω_c 偏 10% 上下。**初稿能读到“ω_c 在 1.4 到 1.7 之间”，这个精度足够决定要不要加补偿器，但不够写验收报告。** 手绘的价值就在这里：它把“要不要动结构”这个昂贵的决策，用一张纸的成本先回答掉。

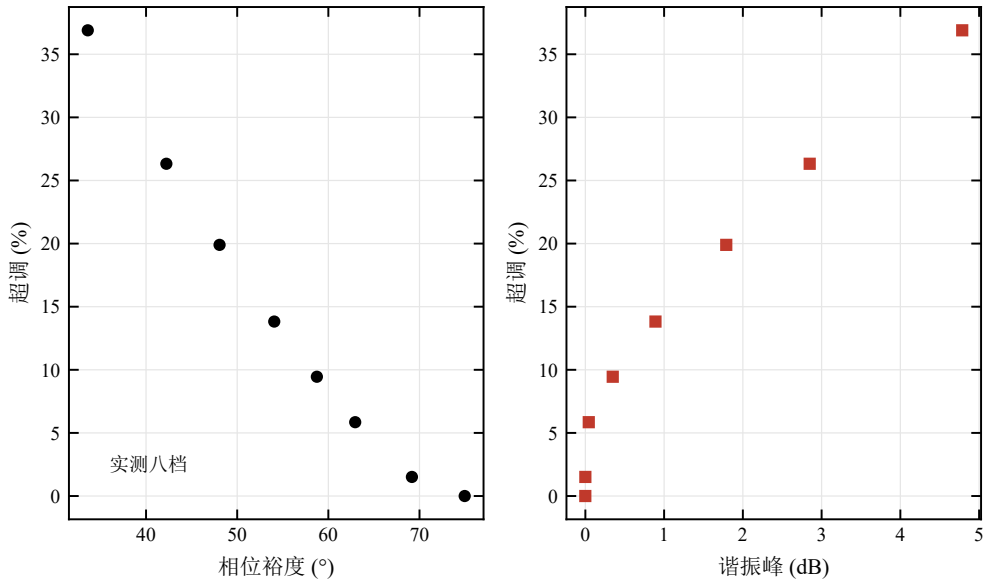

图 41-10　八档增益下的裕度与超调实测散点

图 41-10 左图是相位裕度与超调的散点，八档从 74.96° 到 33.61°，超调从 0 到 36.90%，单调下降但明显弯曲——低裕度段每掉一度，超调涨得更快。右图是谐振峰与超调的散点，八点几乎落在一条直线上，这就是 §41.6.3

“谐振峰是最可靠中间量”的图形证据。**两张图放在一起，说明“用哪个频域量预测超调”不是随口说的，而是有数据支撑的选择。**

41.11.2 五条缺点

第一，只对线性时不变系统有严格定义。 饱和、死区、摩擦、滞环都会让“频率响应”这个概念失效。描述函数法能处理一部分，但它假设非线性环节输入是纯正弦，与实际工况常有出入。

第二，单回路裕度不能直接推广到多变量。 多输入多输出系统里，“每个回路单独稳定”不等于“整体稳定”，通道间的耦合可能让某个方向先失稳。这时要看奇异值曲线，而不是单回路 Bode 图。

第三，裕度是必要条件，不是充分条件。 相位裕度 50° 不能保证阶跃响应不超调 30%——§41.8.2 已经给出反例，同样 50° 的四种回路超调从 13.85% 到 22.11%。**裕度管“稳”，不管“形状”。**

第四，相位读数的陷阱多。 折回、展开、插值、点数，每一步都能引入误差（表 41-17）。初学者最常见的错误是把 $+145^\circ$ 当成“相位超前”，而它其实是 -215°。

第五，对模型误差的敏感度不直观。 增益误差按 1 dB 换 2.6° 很好算，但时间常数误差、谐振频率误差对 φ_M 的影响没有简单公式，只能逐点重算。

前四条在本章里都有具体反例，不是泛泛而谈。**第一条**的反例是 §41.9.6 的饱和分析：大幅信号下等效增益下降，裕度反而变大，可 t_r 会明显变慢——频域读数“更安全”，实际性能“更差”。**第二条**没有反例，因为本章十个例子全是单回路，这本身就是方法的边界。**第三条**的反例就是表 41-13：同样 50°，超调从 13.85% 到 22.11%。**第四条**的反例就在 §41.9.2：那个三穿越例子的第三个交点，软件给出的读数是 $+145.33^\circ$，真实相位却是 -214.67°，**同一个数，两种读法差了 360°，结论从“裕度 325°”变成“裕度 -34.7°”。**

这四条缺点的共同点是：**它们都不影响“方法能不能用”，只影响“结论能不能直接信”。**正确的应对不是弃用，而是在每条结论后面附上成立条件——线性、单回路、结构不变、相位已展开。**把条件写在数旁边，比把数修得更准更有用。**

41.11.3 与三种方法的分工

与根轨迹（第 40 章）的分工。 根轨迹回答“极点往哪儿跑”，频域回答“曲线离临界点多远”。前者适合看结构变化（加零点、加极点后的整体趋势），后者适合定量验收（裕度是多少、延迟能扛多久）。**两者必须互相校核：**根轨迹算出的临界增益，与频域读出的 G_M 必须一致；不一致说明有一张图画错了。

这个校核可以用主例验一次，而且不必真的画根轨迹——**用两个不同增益点各自反算临界增益，看是否同一个数。**$K = 0.3888$ 时 $G_M = 21.075$ dB，折 11.32 倍，$K_{\text{crit}} = 0.3888 \times 11.32 = 4.40$；$K = 2.2000$ 时 $G_M = 6.021$ dB，折 2.00 倍，$K_{\text{crit}} = 2.2 \times 2.00 = 4.40$。**两组相隔 15 dB 的数据给出同一个临界增益，**说明这一族曲线的 G_M 读数自洽。

一致性检验的价值在于抓“读错”。若两档反算出来是 4.40 与 3.1，那就不是曲线问题，而是其中一档的 ω_{180} 读错了——多半是相位没展开，或者在 ω_{180} 附近插值点太少（表 41-17 显示两点每十倍频程就足以把 ω_{180} 读到 6.3496 而非 6.3246）。**一个数算两遍，比一个数算得细更有用。**

与时域（第 37、38 章）的分工。 时域给的是“这一组参数下的具体响应”，频域给的是“这一类参数的稳定边界”。设计阶段用频域扫参数，验收阶段用时域看波形。**频域定方向，时域定数值。**

与状态空间（第 51 章之后）的分工。 状态空间能处理多变量、能显式表达内部状态，但“裕度”这个概念在状态空间里没有直接对应物，要靠奇异值或 μ 分析间接得到。**单回路、以频响为唯一信息时，本章最省事；多变量、有状态约束时，必须换。**

41.11.4 不适用清单

下面五种情形，不要用本章的方法下结论：

- **对象在工作点附近强非线性**（如伺服阀死区占行程 10% 以上）；
- **回路中存在明显的周期性扰动**（如往复泵），频响会被扰动谱污染；
- **多变量耦合强**（相对增益矩阵偏离单位阵很远）；
- **参数在运行中大幅漂移**（如温度从 $20^{\circ}\mathrm{C}$ 到 $200^{\circ}\mathrm{C}$，增益变三倍），单一裕度无意义；
- **需要显式处理约束**（执行器限幅、温升上限），频域法看不见约束。

遇到这些情形，正确做法不是“硬套一个裕度数”，而是明确写出“本章方法的结论在什么条件下成立”，再把条件交给时域仿真或非线性分析去验证。

第四条那个“温度从 $20^{\circ}\mathrm{C}$ 到 $200^{\circ}\mathrm{C}$、增益变三倍”可以算一下有多严重：三倍是 9.54 dB，按主例的局部斜率 2.6°/dB 折算约 25°——48° **的设计裕度会直接掉到** 23°**，比“偏紧”还低一档**。所以“参数大幅漂移”不是“裕度小一点”的问题，而是“这个工作点还在不在合格区”的问题。这类系统该做的是增益调度（第 51 章）或自适应，而不是把设计裕度一口气提到 70° 去覆盖全工况——那样常温工况会慢得没法用。

41.11.5 一句话总结

频域法把“稳定性”从“解方程”变成了“读距离”：读曲线到 -1 点的距离（增益裕度）、读到 -180° 的角度距离（相位裕度）、再把角度距离折成时间（延迟裕度）。三个距离一起报，才是完整的稳定性结论；只报一个，等于只说了三分之一句话。

41.12 Python 仿真代码

41.12.1 两个文件与运行方式

本章的代码分两个文件：`code/ch041_sim.py` 是仿真主体，十组输出全部打在控制台；`code/ch041_figs.py` 出十张图，每张同时导出 SVG 与 PDF。两个文件都只依赖 `numpy`、`control` 与书内的 `simlib`、`plot_styles`。

运行命令：

```
"D:\Anaconda3\envs\py311\python.exe" code\ch041_sim.py
"D:\Anaconda3\envs\py311\python.exe" code\ch041_figs.py
```

`ch041_sim.py` 里所有函数都与正文公式一一对应：`plant()` 是主例对象，`loop(K, comp)` 是环路，`freq()` 是式 (41-3) 的数值版，`design_margins()` 是式 (41-5)、(41-6)、(41-7)，`resonance()` 对应式 (41-15)，`with_delay()` 与 `critical_delay()` 对应表 41-10 的实测账。

两个文件都不含随机数，重跑逐位一致。这一点很重要：正文里的每一位小数都能被复现，读者不必怀疑“这个数是不是调出来的”。

一个自然的疑问是：`control` 库已经有 `margin()`，为什么还要自己写 `design_margins()`？理由是“口径统一”，不是“它算得不对”。`margin()` 一次给出 G_M、φ_M、ω_{180}、ω_c 四个数，日常够用；但本章十组输出还需要两件事：一是所有读数都走同一条“稠密频段 + 展开 + 对数插值”的路径（这样表 41-17 的采样实验才和别处可比），二是明确支持“裕度为负”的回路——不是报错，而是把负数如实返回。这两点在 `simlib.margins` 里各写了

几行，逐点比较相邻两点的符号变化就能做到，也顺便把 ω_{180} 直接交出来，供式 (41-7) 当分母。**多写十几行，换来的是“十组输出同一个口径、符号不会含糊”，这笔账在核对正文数字时很划算。**

41.12.2 相位展开：三行代码解决一个坑

§41.2.1 说过，软件给的相位是折回的。全部十组输出都用“N 点稠密频段求值 + 展开 + 对数插值”的口径，这样任意单点频率上都能读到连续相位。

```
def freq(sys, w):
    """返回 (mag_db, phase_deg)，相位已展开，便于读穿越点。"""
    _, mag, ph = sl.bode_data(sys, w=w)
    mag = np.atleast_1d(np.asarray(mag, float))
    ph = np.atleast_1d(np.asarray(ph, float))
    return mag, np.degrees(np.unwrap(np.radians(ph)))


W_DENSE = np.logspace(-3, 3, 30000)


def resp_at(sys, wq):
    """在稠密频段上插值；逐点求值会把相位折回 (-180°, 180°]。"""
    mag, ph = freq(sys, W_DENSE)
    lg = np.log(W_DENSE)
    lq = np.log(np.atleast_1d(np.asarray(wq, float)))
    return np.interp(lq, lg, mag), np.interp(lq, lg, ph)
```

三个细节值得注意。

一、**`np.atleast_1d` 不是多余的。** `np.unwrap` 要求输入至少一维，单点求值时 `w` 是标量，会直接报 `ValueError: diff requires input that is at least one dimensional`。这两行是踩过坑之后加的。

二、**用 30000 点而不是 300 点。** 展开算法在相位跳变处按相邻两点判断，点太稀会把“跳变”误判成“真实下降”。30000 点在 10^{-3} 到 10^{3} 之间，每十倍频程 5000 点，足够。

三、**插值在 $\ln\omega$ 上做。** 幅频在 dB–对数频率坐标下接近直线，插值误差最小；相位也类似。若在 ω 上线性插值，低频段会偏得很厉害。

还有一处坑藏在那三个函数名里：`np.unwrap` 的默认周期是 2π，**所以传进去的必须是弧度**。代码先 `np.radians(ph)` 再展开、最后 `np.degrees` 转回来，看着绕，其实是为了避开“把 360 当成 6.28”这类错误。若想直接在角度上展开，得显式写 `np.unwrap(ph, period=360)`；**不写 `period` 就别指望它认得“度”**。

`unwrap` 还有一条隐含假设：相邻两点的相位差小于半个周期。本章十个例子的最高阶次只有三阶，在每十倍频程 5000 点的密度下这条假设稳稳成立；若换成几十阶的辨识模型，就得先加密再展开，否则会在密集极点处“展错方向”，得到一个看似连续、实则完全错的相位曲线。

41.12.3 十组输出与正文的对应

十组输出分别支撑正文的哪一节、哪个数，列成表 41-20，方便核对。

表 41-20　十组仿真输出与正文的对应关系

组	输出内容	对应正文	关键数
1	精确幅频与三段折线	表 41-3	转折点偏差 -3.054 dB
2	分段斜率与中点相位	表 41-4	2–20 段 -40.00 / -180.00
3	三种裕度随 K 变化	表 41-5	ω_{180} 恒为 6.3246
4	同裕度四种补偿器	表 41-13	ω_c 跨 21 倍
5	裕度→M_r→超调	表 41-8、41-11	M_r 实测 1.789 dB
6	Nichols 读数	表 41-6	切点 1.789 dB 对上谐振峰
7	最小/非最小相位	表 41-2	$\omega = 2$ 处差 $-90.00°$
8	ZOH 与 Tustin 对照	表 41-7	ZOH 掉 $8.69°$，Tustin 不掉
9	带宽乘上升时间	表 41-9	乘积 $2.154 \to 1.938$
10	延迟裕度两本账	表 41-10	1.7656 对 1.7657

表里第 7 组的两个对象共用分母 $(s+1)^2(0.2s+1)$，分子分别是 $1+0.5s$ 与 $1-0.5s$。构造这一对是本章唯一“人为设计”的例子，目的是让幅频逐点相同、只让相频分叉，从而把“非最小相位”从名词变成可观测的差。

41.12.4 两个二分：反解增益与求临界延迟

§41.8.1 的反解与 §41.6.5 的实测账都是二分，代码结构几乎一样：一个单调函数、一个区间、八十次迭代。

```
def bisect_gain_for_pm(target_pm: float, comp=None, k_hi: float = 50.0) -> float:
    """二分增益，使相位裕度等于目标值；裕度随 K 单调减，故可二分。"""
    lo, hi = 1e-4, k_hi
    for _ in range(80):
        mid = 0.5 * (lo + hi)
        _, pm, _, _, _ = design_margins(loop(mid, comp))
        if pm > target_pm:
            lo = mid
        else:
            hi = mid
    return 0.5 * (lo + hi)


def critical_delay(sys, t_hi: float = 5.0) -> float:
    """二分临界延迟：闭环最右极点实部穿越零的时刻。"""
    if max_real_cl(with_delay(sys, t_hi)) <= 0:
        return np.inf
    lo, hi = 0.0, t_hi
    for _ in range(80):
        mid = 0.5 * (lo + hi)
        if max_real_cl(with_delay(sys, mid)) > 0:
            hi = mid
        else:
            lo = mid
    return 0.5 * (lo + hi)
```

两处的判据方向相反，值得对照着看。反解增益时，**裕度随 K 单调减**，所以“裕度还大于目标”就抬高下界；求临界延迟时，**最右极点实部随 T_d 单调增**，所以“已经失稳”就压低上界。**写二分前先确认单调性，方向搞反只会得到区间端点。**

`critical_delay()` 开头的 `if` 是必要的：有些回路的延迟裕度是无穷大（相位永远到不了 -180°），这时二分区间里没有根，直接返回 `inf` 比返回一个假数安全。

为什么不用现成的求根器（如 `brentq`）？因为这里的目标函数不便宜——每次迭代都要重算一遍频率响应或闭环极点——但也不贵（毫秒级）；而二分只需单调性、不要导数、不要初值猜测，出错时还能一眼看出是“区间没包住根”还是“单调性假设不成立”。**八十次迭代听起来很多，其实五十次之后中点就不再变化了**：区间长度 50 除以 2^{58} 已经小于双精度在 4.4 附近的间隔。写成 80 只是省得每次都要论证“够不够”，代价是几十微秒。

41.12.5 出图脚本的公共骨架

十张图里有四张是 Bode 双子图（图 41-1、41-2、41-5、41-8），所以 `ch041_figs.py` 把它们抽成两个公共函数。

```
def bode_axes(figsize=DOUBLE_TALL):
    """上下两个子图：上面幅频、下面相频，横轴共享对数频率。"""
    fig, (ax1, ax2) = plt.subplots(2, 1, figsize=figsize, sharex=True,
                                   gridspec_kw=dict(height_ratios=[1.0, 0.85], hspace=0.08))
    return fig, ax1, ax2


def finish_bode(ax1, ax2, fname):
    """统一坐标轴标签、范围与网格，然后保存。"""
    ax1.set_ylabel("幅值 (dB)")
    ax2.set_ylabel("相位 (°)")
    ax2.set_xlabel("频率 (rad/s)")
    ax1.set_xscale("log")
    ax1.grid(True, which="major", color="0.9", linewidth=0.5)
    ax2.grid(True, which="major", color="0.9", linewidth=0.5)
    save(fig_of(ax1), fname)
```

`height_ratios=[1.0, 0.85]` 与 `hspace=0.08` 是排版上的讲究：幅频要留出标注裕度箭头的空间，所以比相频略高；两个子图几乎贴在一起，读者才能把“幅值过 0 dB”与“相位过 -180°”在同一竖直线上对齐。**若用默认间距，两个穿越点看起来会错开一截，这是很多 Bode 图的通病。**

三个约定必须守：**图内不写标题**（标题在图注里）；**坐标轴标签含物理量与单位；中文标签与公式不写进同一个字符串**（写作卡 §5 的硬规定）。第三条最容易被忽略——`"$G(s)$ 幅值"` 这样的标签在部分字体下会出方框，正确写法是分成 `"幅值"` 与 `"$G(s)$"` 两处，或只用其中一种。

41.12.6 自检与排查顺序

跑完代码，用四个数做自检，全部对上才往下写正文。

数一，$K=1$ 的 $\omega_{180}=6.3246$。这个数有解析来源：相频在 -180° 处满足 $\arctan(\omega/2)+\arctan(\omega/20)=90^\circ$，即 $\omega^2=40$，$\omega=6.3246$。数值与解析对上，说明相位展开没出错。

数二，$K=1$ 的 $G_M=12.869$ **dB**。它等于 $-20\lg 0.2273$，而 0.2273 是 $|L(\mathrm{j}6.3246)|$。用式 (41-5) 手算一遍即可核对。

数三，$K=4.4$ 时 $G_M=0$。第 40 章已算出临界增益 $K_{\max}=4.4000$，本章的裕度计算必须给出 $G_M=0$ dB、$\varphi_M=0^\circ$。**这一条是两章之间的交叉校验**，对不上说明有一章的对象或增益刻度写错了。

数四，延迟的两本账要合上。主例 $K=0.3888$ 处，式 (41-7) 给 0.5458 s，`critical_delay()` 的二分给 0.5458 s，两组独立算法逐位相同。这条自检同时验证了三件事：相位已展开、ω_c 插值正确、Padé 近似在 3 阶下足够。**若两者差到千分之几，不必怀疑公式，先去看 Padé 阶次**——那正是表 41-10 最后一位差异的来源。

四个数都对之后，若某一组输出仍与正文不符，按下面的顺序排查：

1. **先查增益刻度**：`loop(K)` 里 K 是乘在对象上的，补偿器的直流增益是否被吸收；
2. **再查相位口径**：单点求值还是稠密插值，展开没展开；
3. **最后查插值方向**：在 ω 上插值还是 $\ln\omega$ 上插值。

本章写作过程中，三个坑都踩过：单点求值时 `np.unwrap` 报“至少需要一维”；逐点读相位读不出 -195.26°，只能读到 $+164.74^\circ$；组 4 的两个补偿器增益一度都顶到二分上界 50，原因是 `loop()` 里补偿器与对象的增益刻度没有统一。**三次都不是算法错，而是口径错**——这也是频域法最典型的失败方式：每个数单独看都合理，就是彼此对不上。

第42章 稳态误差分析

> 本章的一句话核心思想：**稳态误差问的是“时间趋于无穷时，输出还差多少”，答案只由两件事决定——回路里积分器的个数，以及输入信号的阶次；增益只决定差多少，型别决定会不会差成无穷。**

42.1 动机与直观理解

42.1.1 现场的第三个问题

第 41 章回答了三个现场问题里的两个：“这个增益还能往上加多少”和“响应够不够快”。剩下一个，往往是最先被提出来的：

“为什么总差那么一点点？”

一台定位平台，指令走 100 mm，编码器读到 99.5 mm，重复定位很好、曲线也很干净，就是差 0.5 mm。操作工的第一反应是“标定没做对”，第二反应是“传感器坏了”。工程师查完标定、换完传感器，差值一点没变——因为它根本不是标定问题，也不是传感器问题，而是**回路结构决定的稳态误差**。

这个误差有三个特征，认准了就不会走错方向：

- **它不随时间消失。** 等十分钟、等一小时，差值稳定在同一个数上。
- **它随指令速度变化。** 走 10 mm/s 时差 0.1 mm，走 50 mm/s 时差 0.5 mm，大致成正比。
- **它对增益敏感。** 把控制器增益调大一倍，差值大致减半，但响应开始发抖。

三条合起来，指向同一个结论：这是**型别与增益共同决定的稳态误差**，不是硬件缺陷。补它的办法不是换传感器，而是改回路结构——加一个积分器，或者换一个型别更高的控制律。

顺手做一次量级估算，就能把“型别 + 增益”这两个词落到数上。上面那台平台在 10 mm/s 时差 0.1 mm、在 50 mm/s 时差 0.5 mm，两处一除都是 $K_v = v/e_{ss} = 10/0.1 = 50/0.5 = 100\ \mathrm{s}^{-1}$。

两个速度给出同一个 K_v，这正是“线性系统 + 速度型误差”的标志：误差与指令速度严格成正比，与走了多远无关。反过来，如果两个速度算出的 K_v 不一样，那误差就不是单纯的速度误差，里面混了摩擦、死区这类非线性项——这条判别方法 §42.10 还会再用。

$K_v = 100\ \mathrm{s}^{-1}$ 这个量级也与 §42.8 表 42-14 里“位置伺服 $20 \sim 100$”完全对得上。**先估量级，再谈公式**，是现场分析误差最省时间的入口。

本章就讲这件事：怎么从传递函数一眼看出“会不会有稳态误差”，怎么算出“差多少”，以及为什么“加积分”能把它抹平、代价又是什么。

42.1.2 “稳”和“准”是两笔账

第 41 章的三个裕度全在回答“稳不稳、稳到什么程度”。本章的稳态误差回答“准不准”。这两笔账由**同一个旋钮**（开环增益）决定，但方向相反。

以主例 $L(s) = 10K/[s(s+2)(0.05s+1)]$ 为例。$K = 0.3888$ 时，相位裕度 48.065°、斜坡误差 0.5144；把 K 提到 0.5000，误差降到 0.4000（-22.2%），相位裕度掉到 42.229°（-5.84°）。**误差降两**

成，裕度掉近六度。

再往前推一步：$K=0.7332$ 时误差 0.2728，只有原来的 53%，相位裕度却只剩 33.608°，已经跌破工程上常用的 45° 底线。而 K 一旦越过 4.4，回路直接失稳——那时候误差不是"大"，而是"没有稳态"这回事了。

把跨度拉到十倍再看，三个后果会同时显形：K 从 0.1000 到 1.1000（11 倍），e_{ss} 从 2.0000 到 0.1818（降到 $1/11$），ω_c 从 0.4857 到 3.0100（涨 6.2 倍），φ_M 从 74.958° 掉到 25.044°（少 49.9°）。**收益、带宽、代价三者朝同一个方向走，只有裕度是反向的。** 这就是"一个旋钮"的完整含义：它不是"调误差的旋钮"，而是"调整个回路性格的旋钮"。

顺带说明一个常被混淆的量：带宽涨 6.2 倍并不等于"响应快 6.2 倍"。ω_c 是开环穿越频率，闭环带宽通常略大于它，但闭环的上升时间还受阻尼影响；K 加大时阻尼下降，超调上升，实际调节时间的改善远小于 6.2 倍。第 41 章 §41.7 的实测已经给出过这个"带宽涨、时间不按比例降"的现象。

所以本章与第 41 章必须成对使用：**第 41 章告诉你"K 最多能到多少"，本章告诉你"K 至少要多大"**。两条线之间的那段区间，才是可用的设计窗口。主例的这个窗口有多大，§42.6 会用一张图说清楚。

42.1.3 积分器是"记仇"的元件

稳态误差的根子在积分器。这句话听起来抽象，用一个生活例子就明白了。

比例控制像"看现在"：误差 10 mm，就出 10 份力；误差 5 mm，就出 5 份力。误差变成 0，出力也变成 0。问题是，很多对象需要"误差为 0 时仍然有出力"才能维持住——比如顶着摩擦力停在半空、顶着负载维持恒速。这时候比例控制只能"留一点误差"来换取那点出力：**误差是它出力的唯一来源，出力不为零，误差就不可能为零**。

积分控制像"记总账"：只要误差存在过，它就一直在累加，累加的结果就是出力。误差为 0 时，累加值停在原来的数上，出力保持不变。于是"误差为零且出力不为零"成为可能——这正是消除稳态误差的机制。

一句话：**比例项需要误差来产生出力，积分项不需要。** 这就是为什么"加积分"能消掉常值误差，也是为什么"加积分"必然带来相位滞后（累加需要时间，时间就是滞后）。

把"记总账"写成离散形式，机制一目了然：$u_k = u_{k-1} + K_i T_s e_k$。积分器在代码里就是一个变量，每个采样周期把"误差 × 采样周期 × 积分增益"加到自己身上。误差为零时，$u_k = u_{k-1}$，输出停在原处；误差不为零时，输出就一直在爬。**这个变量就是"储能"，它记住了过去所有的误差。**

也正因为它是"累积"，它的传递函数是 $1/s$，相频是恒定的 -90°。这个 -90° 不随频率变化，所以它不是"某个频段的代价"，而是"全频段的代价"——这一点与微分项正好相反，也是"加积分必掉裕度"的根源。工程上的缓解办法只有一个：给积分器配一个零点（PI 写成 $C = K_p(s + K_i/K_p)/s$），让零点以上的频段积分项"退居二线"，把 -90° 收回来一部分。零点放在哪儿，就是 §42.6.4 要讲的"积分时间怎么选"。

还有一个变体必须认识：**泄漏积分器**（leaky integrator），$C = K_p + K_i/(s+\epsilon)$，$\epsilon$ 很小但不为零。它的直流增益是有限的 $C(0) = K_p + K_i/\epsilon$，所以对型 0 对象来说，**型别仍然是 0，只是误差被压得很小**。取 §42.4 的型 0 对象（$G_0 = 10$）、$K_p = 1$、$K_i = 1$、$\epsilon = 0.01$，环路直流增益是 $10 \times (1 + 100) = 1010$，残余误差 $1/1011 \approx 0.00099$，约 0.1%。

这个数说明泄漏积分器的定位：**指标要求"误差小于 0.1%"，它够用；要求"误差等于零"，它不够。** 好处是抗饱和、抗漂移、支持无扰切换——很多 PLC 里的"PI 模块"其实是泄漏积分，ϵ 来自积分限幅或数值实现的细节。看代码时如果发现积分项乘了一个小于 1 的系数，那就是它。

用主例验证这个直觉。型 1 对象 $G = 10/[s(s+2)(0.05s+1)]$ 本身含一个积分器，单位斜坡输入下误差稳定在 $1/K_v = 0.2$（$K=1$ 时）。这里误差不为零，不是因为"缺积分器"，而是因为**积分器只有一个，刚好**

够对付阶跃，不够对付斜坡。想让斜坡误差也归零，就得再加一个积分器，把型别从 1 抬到 2。

这就引出了本章的第一个核心概念：**型别**。

42.1.4 型别：数一数原点上几个极点

系统型别（system type）的定义简单到有点粗暴：**开环传递函数在 $s=0$ 处的极点个数**，记作 N。

$$L(s)=\frac{K\prod_{i}(1+T_i s)}{s^{N}\prod_{j}(1+\tau_j s)} \tag{42-1}$$

分母里的 s^N 就是型别。$N=0$ 叫型 0，$N=1$ 叫型 1，$N=2$ 叫型 2。

为什么数原点极点这么重要？因为 $s\to 0$ 对应 $t\to\infty$。原点上的极点让 $L(0)\to\infty$，而稳态误差的公式里正好有 $1/(1+L)$。**型别越高，低频增益越“硬”，对慢变化输入的跟随越准。**

型别还有一个更老的名字：**无差度**（astatism）。“型 N”的完整含义是“能无差跟踪最高 N 阶多项式输入”：型 1 能无差跟阶跃，型 2 能无差跟斜坡，型 3 能无差跟抛物线。这个说法把“误差”与“输入阶次”直接绑在一起，比“数极点”更接近工程语言，也与表 42-2 的对角线一一对应。

还要把一个常见误解挡在门外：**型别与系统阶数是两个不相干的量。** 一个八阶对象完全可能是型 1（七个非零极点加一个原点极点），一个二阶对象也可以是型 2（两个极点都在原点）。型别只数原点极点，不问其他极点在哪、也不问分子有几个零点。判断“这个系统几型”时，唯一要看的是 $s=0$ 这个点。

但型别不是越高越好，代价在第 41 章已经埋下：每个原点极点贡献 -90° 相位，且这个滞后**在全频段都存在**。型 2 的系统在穿越频率处天然背着 180°，几乎没有相位余量可用，必须靠零点把它“抬”回来——这就是为什么型 2 系统总是配零点（§42.4 的型 2 算例就是这样，分子是 $(1+2s)^2$）。

数型别有两个必须注意的地方：

1. **先约分，再数。** $L=(s+1)/[s(s+1)]$ 看起来分母有两个 s，约掉之后其实是 $1/s$，型 1 而不是型 2。工程上“控制器带积分、对象也带积分”时最容易在这里数错。
2. **看的是开环，不是闭环。** 闭环传递函数的分母是 $1+L$，原点极点通常被消掉了；数闭环的型别会得出错误结论。

42.1.5 稳态误差是“极限”，不是“最后一点”

初学者常把稳态误差理解成“仿真跑到最后一刻那个误差值”。这个理解在数值上差不多，在概念上差得远。

严格的定义是极限：

$$e_{ss}=\lim_{t\to\infty} e(t) \tag{42-2}$$

它要求这个极限存在。对型 0 系统加斜坡输入，误差随时间线性增长，极限是无穷——这时候“稳态误差”这个词其实不适用，正确的说法是“误差发散”。

实测数据可以看清“极限”与“最后一刻”的差别。型 1 主例（$K=1$，$K_v=5$）单位斜坡下，$t=10$ s 时误差 0.1998，$t=20$ s 时 0.2000，$t=40$ s 时还是 0.2000。**10 s 的时候已经到位了，再等三十秒也不会更准。** 仿真里取末段 200 个点的均值作为“稳态值”，得到的正是 0.2000，与解析值 $1/K_v=0.2$ 逐位吻合。

反过来，什么时候算“进了稳态”？工程上用 $\pm 2\%$ 带：误差第一次进入 $\pm 2\%$ 并且此后再不出去的时刻。这个算例是 5.99 s。注意这个数**不是**调节时间——调节时间是输出进入 $\pm 2\%$ 带的时间（第 40 章的口径），而这里是

误差进入 $\pm 2\%$ 带的时间，两者在本例恰好接近，但在型 0 系统里会差得很远（误差永远进不了带）。

仿真怎么才算“到了极限”？本章统一的做法是取末段 200 个采样点的均值。这个做法有三个隐含前提，缺一个数就不可信：

1. **信号已经没有趋势。** 取均值等于假设“窗口内是真值 + 零均值噪声”。如果误差还在线性爬升（型 0 遇斜坡），均值只是窗口中点时刻的值，与“极限”毫无关系。
2. **窗口足够长，能压掉振荡。** 型 1 的斜坡误差会带一点衰减振荡，窗口太短会被振荡的某一相位“骗”到。200 点对应 4 s（$T_s = 0.02$），远大于残余振荡的周期。
3. **仿真时长足够长，瞬态已经走完。** 主例用 40 s，是调节时间的近十倍；如果只跑 10 s，误差还在 0.1998，虽然只差 0.0002，但这已经是“末值”而不是“极限”了。

三条合起来，说明“稳态误差”这个词在仿真里始终是个**近似**，而终值定理给的是**精确值**。本章所有表格都以解析值为准、以仿真值为证，两者的差值就是这张“近似”的误差。

顺带说清 0.1998 与 0.2000 这 0.0002 的差是哪来的：它不是数值误差，而是“取末值”与“取极限”的差。$T_s = 0.02$ 时 10 s 对应 500 个采样点，误差还留着约 0.1% 的衰减尾巴。本章表格统一写四位小数、统一取末段均值，就是为了让“末值”尽量贴近“极限”，并且把贴到多近说清楚。若只取最后一个采样点，那个数还会被噪声与残余振荡带偏——**单点不可信，均值才稳。**

最后一个概念要提前分清：**稳态误差不是“控制精度”的全部**。它只描述“指令不变或匀速变化时差多少”，不描述“跟得上跟不上”（那是带宽与相位裕度的事）、也不描述“停下来抖不抖”（那是噪声与非线性的事）。把这三件事混成一句“精度不够”，是现场排查最常见的起点错误。

42.1.6 本章路线

§42.2 把误差的三条传递函数、终值定理的适用条件、静态误差系数的定义一次讲清；§42.3 给出五步分析流程；§42.4 用三个不同型别的对象把连续情形走一遍，并用时域仿真逐项验证；§42.5 处理离散情形，说明为什么“采样不改变 K_v，只改变裕度”；§42.6 把误差与裕度放在同一张图上，给出兑换率；§42.7 逐个参数讲作用方向，重点是“扰动进入点”；§42.8 给整定方法与经验数字；§42.9 讨论前馈、复合控制等改进手段；§42.10 落到摩擦、死区、量化三个真实误差源；§42.11 给适用边界；§42.12 是代码与复现步骤。

42.2 数学原理

42.2.1 三条传递函数，三个进入点

误差的定义是“指令减输出”：

$$e(t) = r(t) - y(t), \qquad E(s) = R(s) - Y(s) \tag{42-3}$$

把反馈回路画出来（图 42-2），会看到扰动可以从未经任何环节的地方进来：指令端、对象输入端、对象输出端。三处的传递函数完全不同，这是稳态误差分析里最容易混淆的一点。

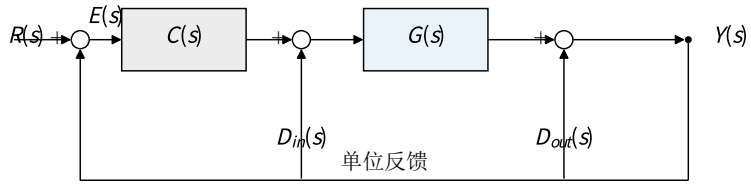

扰动进入点不同，闭环型别不同

图 42-2　误差与扰动的三个进入点

图 42-2 上，$R(s)$ 从最左端进入，$D_{in}(s)$ 加在对象 $G(s)$ 之前，$D_{out}(s)$ 加在对象之后。三条通道分别是：

$$\frac{E}{R}=\frac{1}{1+C(s)G(s)}=\frac{1}{1+L(s)} \tag{42-4}$$

$$\frac{Y}{D_{in}}=\frac{G(s)}{1+C(s)G(s)} \tag{42-5}$$

$$\frac{Y}{D_{out}}=\frac{1}{1+C(s)G(s)} \tag{42-6}$$

这三条不必死记，推一遍就再也不会记错。在求和点处列方程：控制量是 $C(R-Y)$，对象输入是 $C(R-Y)+D_{in}$，输出是

$$Y=G\big[C(R-Y)+D_{in}\big]+D_{out}$$

把右边的 Y 移到一起：

$$Y(1+CG)=CGR+G\,D_{in}+D_{out}$$

两边同除 $1+CG$，三项分别对应指令、输入端扰动、输出端扰动，系数就是式 42-4 到 42-6 的三个传递函数。误差是 $E=R-Y$，把上式代进去，得到三路输入对误差的完整表达式：

$$E=\frac{1}{1+CG}R-\frac{G}{1+CG}D_{in}-\frac{1}{1+CG}D_{out}$$

这张式子把“三笔误差”放在了一行里：指令跟不准的部分、输入端扰动透过来的部分、输出端扰动透过来的部分。三者可以叠加（线性系统的本分），也可以分别设计。工程上排查“差一点”时，第一步就是把实测误差往这三项上对号。

三者的分母都是 $1+L$，分子不同。**分母决定“收敛快慢与稳定性”，分子决定“进入点带来的型别”。**

这个区别在第 41 章没有显出来，因为那里只关心开环 L 的形状。本章必须分清，因为现场“差一点”的来源经常是扰动而不是指令：导轨有摩擦力、风机有常值风载、电源有固定压降，这些都是 D_{in} 型的扰动。

一个具体的对照（主例 $G=10/[s(s+2)(0.05s+1)]$）：

- 纯比例控制 $C=1$ 时，Y/D_{in} 的直流增益是 1——**输入端一个单位的常值扰动，输出端原封不动差一个单位**。实测阶跃扰动 $d=1$ 下，$t=10$ s 时 $y=0.9999$，$t=40$ s 时 $y=1.0000$。

- 换成 PI 控制 $C = 1 + 0.5/s$，同一个扰动的稳态偏移变成 0——$t = 40$ s 时 $y = -0.0000$，峰值 1.3330 之后回落。
- 但两者的 Y/D_{out} 直流增益都是 0——**输出端扰动只要回路里有积分器，就一定被压成零**，与控制器是不是 PI 无关。

这三行可以提炼成一条能直接算的公式。设控制器为纯比例 $C = K_p$、对象为型 1 及以上（G 在原点有极点），把 $s = 0$ 代入式 42-5 之前先约掉公共的 $1/s$，得到输入端常值扰动 d 引起的稳态偏移：

$$\Delta y_{ss} = \frac{d}{C(0)} = \frac{d}{K_p}$$

主例 $d = 1$、$K_p = 1$ 代入得 1.0000，与实测 $y(40) = 1.0000$ 一致。§42.10 的库仑摩擦算例（$d = -0.05$）取 $K_p = 0.5/1.0/2.0$，实测偏移 $-0.10000/-0.05000/-0.02500$，与 d/K_p 逐位吻合——**这条公式是后面讲摩擦误差的骨架。**

若对象是型 0，公式换成 $\Delta y_{ss} = d\,G(0)/[1 + K_p G(0)]$，因为此时分子 $G(0)$ 不为零、分母 $1 + K_p G(0)$ 有限。两个公式的差别正是“积分器在不在扰动作用点的下游”。

若控制器含积分，$C(0) = \infty$，偏移为零。**这就是“要不要加积分”的全部答案：看 $C(0)$ 需要多大。**

三行数据放在一起，得出一条本章反复要用的判据：

> 判稳态误差，先看“扰动从哪儿进”，再看“积分器在不在这个进入点的下游”。

42.2.2 终值定理：三个前提缺一不可

稳态误差的标准算法是终值定理：

$$e_{ss} = \lim_{t \to \infty} e(t) = \lim_{s \to 0} s E(s) \tag{42-7}$$

它把“时间趋于无穷”换成了“s 趋于零”，把一个时域极限换成了一个代数极限。方便，但有三个前提：

1. **$sE(s)$ 的极点全在左半平面**（虚轴上至多一个一阶极点，且对应的留数为零）。说白了：闭环必须稳定。不稳定系统的“终值”没有意义，算出来的是个数学游戏。
2. **输入必须是阶跃、斜坡、抛物线这类“多项式型”信号**，其拉氏变换除原点极点外没有别的极点。正弦输入的终值不存在（它一直在振荡），终值定理给不出答案。
3. **$E(s)$ 必须是真分式或有理函数**，且 $sE(s)$ 在 $s = 0$ 处不能有高阶极点发散。

推导其实只有两行。把 $E(s)$ 展成部分分式，每一项 $A/(s - p)$ 的时域原函数是 $A\mathrm{e}^{pt}$；只要 $\mathrm{Re}\,p < 0$，这些项在 $t \to \infty$ 时全部衰减为零，剩下的只有 $s = 0$ 那一项。所以“终值”在数学上就是“$E(s)$ 在原点处的留数”，前提是**其余极点都衰减干净**——这正是第一条。

用型 0 加斜坡验一下第三条。$R = 1/s^2$，$L(0) = K_p$，于是 $sE(s) \approx 1/[s(1 + K_p)]$，在原点是一阶极点、留数不为零。终值定理给出的“$\infty$”不是数值溢出，而是“极限不存在”的代数症状；此时正确的说法是“误差线性发散”，斜率正是 $1/(1 + K_p)$——§42.4.2 的图 42-1 上那条虚线，斜率 0.0909 就是它。

实跑能把这条代数症状对上数：型 0 对象（$K_p = 10$）加单位斜坡，$t = 20$ s 时误差读到 1.9504，除以 20 得 0.0975，比 $1/(1 + K_p) = 0.0909$ 略大。多出来的那部分是一个**常数项**：$0.0909 \times 20 = 1.818$，与 1.9504 差 0.132，这是尚未衰减干净的瞬态贡献。所以型 0 的斜坡误差曲线是“一条斜线加一个常数偏移”，斜线

由 K_p 定，偏移由闭环极点定。**这也解释了为什么不能只看一个时刻就反算 K_p——必须用两个时刻的差，或者等偏移衰减完。**

三条前提的检查顺序也值得固定下来：**先看闭环极点（最硬，一票否决），再看输入形状（决定用哪张表），最后看有没有非线性（决定数值可信度）。** 顺序反过来，很容易在“输入形状”上纠缠半天，却发现系统本来就不稳定。

第一条最容易被忽略。一个型 2 系统，如果闭环不稳定，用终值定理算出来的“$e_{ss}=1/K_a=0.2$”是彻底错的——真实的误差是发散振荡。本章所有算例在给出 e_{ss} 之前，都先核对了闭环稳定性（§42.4 表 42-4 的最后一列），这不是形式主义。

第二条也有现实含义。现场指令很少是纯阶跃，更多是“梯形速度规划”或“正弦扫频”。梯形规划可以分解成若干斜坡段的叠加，用本章方法处理；正弦指令则要转到频率域，用第 41 章的幅频特性算幅值衰减与相位滞后——**这是两条不同的技术路线，不能混用。**

42.2.3 静态误差系数：三个极限

把 $L(s)$ 按型别展开，可以定义三个静态误差系数：

$$K_p=\lim_{s\to 0}L(s),\qquad K_v=\lim_{s\to 0}sL(s),\qquad K_a=\lim_{s\to 0}s^2L(s) \tag{42-8}$$

名字容易误导：K_p、K_v、K_a 里的下标 p,v,a 指的是**位置（position）、速度（velocity）、加速度（acceleration）**三种输入，不是比例、微分、积分三个增益。它们本身也**不是控制器参数**，而是开环传递函数在低频端的三个极限值。

对本章的标准形式 $L(s)=K\prod(1+T_is)/[s^N\prod(1+\tau_js)]$，三个极限只有一个非零有限，见表 42-1。

表 42-1　型别与三个静态误差系数的对应

型别 N	K_p	K_v	K_a
0	K	0	0
1	∞	K	0
2	∞	∞	K

其中 K 是“尾一化”形式下的增益，也就是 $L(s)$ 在低频的渐近线 K/s^N 的系数。**注意是尾一化，不是首一化：** $10/[s(s+2)(0.05s+1)]$ 的尾一化要先把分母写成 $s\cdot 2\cdot(1+0.5s)\cdot(1+0.05s)$，于是 $K=10/2=5$。这个 5 就是 K_v。写成首一化会得 10，差一倍——这是手算最常犯的错。

把这件事写成通式：若 L 已写成式 42-1 的尾一化形式，则型 0 时 $K_p=K$、型 1 时 $K_v=K$、型 2 时 $K_a=K$。**三个系数在数值上都等于同一个尾一化增益 K，只是“配给哪一阶输入”不同。** 这就是表 42-1 为什么只用一个字母 K。

量纲也值得对一遍，它能把“公式套错”的错误立刻暴露出来。K_p 无量纲（输出单位/输入单位），K_v 的单位是 $1/\mathrm{s}$，K_a 的单位是 $1/\mathrm{s}^2$。代进式 42-9：阶跃是“单位/无量纲”，斜坡是“$(\text{单位}/\mathrm{s})/(1/\mathrm{s})$”，抛物线是“$(\text{单位}/\mathrm{s}^2)/(1/\mathrm{s}^2)$”，三种都回到“单位”。**量纲不对，一定是型别与输入配错了。**

手算时按四步走，不易乱。拿型 2 算例走一遍：

1. **乘开成多项式**：分子 $5(1+2s)^2=20s^2+20s+5$，系数是 $[20,\,20,\,5]$；分母 $s^2(s+1)(0.1s+1)=0.1s^4+1.1s^3+s^2$，系数是 $[0.1,\,1.1,\,1,\,0,\,0]$。

2. **数型别**：分母末尾有两个零，$N=2$。

3. **约去原点极点后取常数项之比**：分子常数项 5，分母剩 $0.1s^2+1.1s+1$、常数项 1，比值 5。

4. **配给输入**：型 2 配抛物线，$K_a=5$，$e_{ss}=1/5=0.2$。

第 3 步的结果与实跑 0.2000 对上（表 42-5）。这四步里最容易错的是第 1 步的降幂排列与第 3 步的“约去之后再看常数项”——**约分与去原点极点必须做完，才能取常数项**，否则取到的是零。

还要提醒一句：K_v 相同只说明**终值**相同，不说明过渡过程相同。两个 $K_v=5$ 的系统，一个可能 2 s 就稳，另一个可能振荡 20 s。K_v 是“终点的刻度”，不是“路上的形状”。

更要注意的是，K_v 的数值**不能跨系统比较**。$K_v=100\ \mathrm{s^{-1}}$ 在毫米平台上意味着 1 mm/s 的指令误差 0.01 mm，在弧度平台上意味着 0.01 rad 的角度误差——量纲相同，物理含义完全不同。跨系统只能比无量纲的相对误差（§42.8.5 会展开）。

三个系数与三种输入一一配对，稳态误差公式是：

$$e_{ss}=\begin{cases}\dfrac{1}{1+K_p}, & \text{阶跃}\\[2mm] \dfrac{1}{K_v}, & \text{斜坡}\\[2mm] \dfrac{1}{K_a}, & \text{抛物线}\end{cases}\tag{42-9}$$

注意阶跃那一行有 $1+$，斜坡与抛物线没有。原因很直接：阶跃输入下，误差通道的直流增益是 $1/(1+L(0))$，分母里那个 1 就是“前向通道直通”的部分。型 0 时 $L(0)=K_p$，所以 $e_{ss}=1/(1+K_p)$；型 1 时 $L(0)=\infty$，$e_{ss}=0$。

42.2.4 九种组合，一页表说完

把三种型别与三种输入交叉，得到九种组合，见表 42-2。

表 42-2　型别与输入阶次的九种组合

输入 \ 型别	型 0	型 1	型 2
阶跃	$\dfrac{1}{1+K_p}$	0	0
斜坡	∞（发散）	$\dfrac{1}{K_v}$	0
抛物线	∞（发散）	∞（发散）	$\dfrac{1}{K_a}$

表的读法是**沿对角线看**：型 N 只能把阶次不高于 N 的输入跟“死”，高一级就差一个常数，高两级就发散。

这张表解释了一个常见困惑：“我的系统明明是型 1，为什么还是有误差？”因为输入不是阶跃而是斜坡。**型别是“能对付到几阶”的指标，不是“误差等于零”的保证。**

对角线之外还有一条规律，比“无穷”这个符号更有用：**输入比型别高一级时，误差按 t 线性漂移；高两级时，按 t^2 加速漂移。** 推导只需看低频渐近：型 N 系统在低频近似为 $L\approx K/s^N$，于是

$$E\approx\frac{R}{1+K/s^N}\approx\frac{s^N}{K}R$$

斜坡输入 $R = 1/s^2$ 送进型 0，得 $E \approx 1/[(1+K_p)s^2]$，即 $e(t) = t/(1+K_p)$；抛物线 $R = 1/s^3$ 送进型 1，得 $E \approx 1/(K_v s^2)$，即 $e(t) = t/K_v$。**都不是常数，而是“越走越偏”**——这与现场“走一段准、走长了就偏”的描述完全对应。

举两个数把这些格子钉住。型 1 主例 $K_v = 5$，若指令是幅值 2 的斜坡（2 mm/s），误差是 $2/K_v = 0.4$；输入幅值直接乘在误差上，这一点与阶跃不同（阶跃的 $1/(1+K_p)$ 是相对误差，与幅值无关）。同一系统改走抛物线，误差按 $t/K_v = 0.2t$ 增长，20 s 时已经 4 个单位——图 42-5 里那条被截断的曲线就是它。

对角线之外还有一条信息：**发散比常数误差更危险**。常数误差可以标定、可以前馈补偿；发散误差没有任何补偿手段，只能改型别。现场遇到“越走越偏”的现象，第一件事就是查型别够不够。

42.2.5 型别与增益的分工

把式 42-9 与表 42-1 合起来看，可以得到一条清晰的分工：

- **型别决定“误差是不是零”**，是定性问题；
- **增益决定“非零误差有多大”**，是定量问题。

这个分工有很强的实践意义。如果指标要求“斜坡输入下误差不超过 0.5”，有两条路：

1. 型 1 + 大增益：$K_v \geq 2$，靠增益把 $1/K_v$ 压到 0.5 以下；
2. 型 2：误差恒为零，与增益无关。

第一条路的代价是相位裕度（第 41 章），第二条路的代价是 180° 固定相位滞后加可能的稳定性问题。**没有免费的路，只有代价不同的路。**

主例的六档增益（§42.4 表 42-6）给第一条路画出了清晰的账：$K_v = 5K$，$e_{ss} = 1/(5K)$，两者严格成反比。K 从 0.1000 到 1.1000（11 倍），K_v 从 0.5000 到 5.5000（11 倍），e_{ss} 从 2.0000 到 0.1818（$1/11$）。**误差对增益是严格的双曲线关系，没有饱和、没有拐点。**

这也意味着“靠增益压误差”的效率会越来越低：e_{ss} 从 2.0 压到 0.5 只需 4 倍增益，从 0.5 压到 0.25 又要 2 倍，从 0.25 压到 0.125 还要 2 倍。**每压一半，都要再翻一倍增益，而裕度是按 dB 线性掉的。** 这就是为什么工程上宁可在型别上想办法，也不肯一味加增益。

换成分贝说得更狠：误差减半需要增益翻倍，即 $+6.02$ dB；按 §42.6.2 实测的 $-2.67^\circ/\mathrm{dB}$，这一步要付出 16.1° 相位裕度。主例现有 48.065°，**只够换一次半**——第一次换完剩 31.9°，已经破了 45° 底线。而误差才从 0.5144 降到 0.2572。

对照另一条路：加一个积分器把型别抬到 2，斜坡误差理论上直接归零，代价是 -90° 固定相位（用零点可以抬回一部分）。**同样是“把误差减半”，一条路花 16°，另一条路花 90° 再退一部分回来。** 两条都不便宜，区别在于：增益那条路的收益会递减，型别那条路的收益是一次性的“归零”。工程上选哪条，取决于指标是“再准一点”还是“必须为零”。

42.2.6 内部模型原理的一句话版本

本章的所有结论，其实都是一个更一般原理的特例：**控制器里必须“含有”输入信号的模型，才能无静差地跟踪它。**

- 阶跃信号的模型是 $1/s$（一个原点极点）→ 控制器含积分就能无静差跟阶跃；
- 斜坡信号的模型是 $1/s^2$（两个原点极点）→ 要两个积分；
- 正弦信号的模型是 $1/(s^2+\omega^2)$ → 控制器要含一对虚轴极点（这就是谐振控制器的来历）。

这个原理叫**内部模型原理**（internal model principle）。它的价值在于把“该加什么”变成“该模仿什么”：**输入怎么变，控制器就该怎么“记住”这种变化。**

要注意“模型”其实有两个对象，别混为一谈：

- **指令的模型**决定跟踪误差。指令是阶跃，控制器要含 $1/s$；指令是斜坡，要含 $1/s^2$。
- **扰动的模型**决定抑制能力。输入端常值扰动的模型也是 $1/s$，所以含积分的控制器既能把阶跃跟成零误差，也能把常值扰动压成零偏移——一件工具两用，这也是 §42.2.1 那条 $\Delta y_{ss} = d/C(0)$ 的另一种说法。

如果扰动是斜坡型（比如随时间线性增加的风载、持续漏水的液位），它的模型是 $1/s^2$，要抑制它就得有两个积分。**很多“加了 PI 还是有缓慢漂移”的案例，根源就是扰动比常值高了一阶。**

内模也有它的软肋：模型的频率（或积分时间）必须准。谐振控制器的中心频率偏了 1%，残余误差就不再是零，而是按频率偏差的比例残留——这一点第 49 章会给出定量结果。**内模给的是“理想为零”，工程上拿到的是“接近零”，两者之间隔着建模精度。**

本章只用到阶跃与斜坡两档，正弦跟踪留到第 49 章（重复控制与谐振控制）。但原理是同一个，记住这句话，后面几章都能对上。

42.3 设计步骤

42.3.1 五步，顺序不能换

工程上算稳态误差，按图 42-4 的五步走。

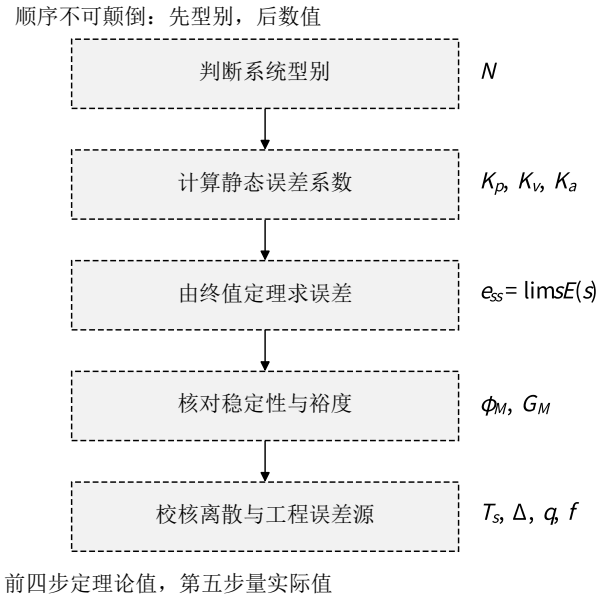

图 42-4　稳态误差分析的五个动作

图 42-4 的五步是：判断系统型别 → 计算静态误差系数 → 由终值定理求误差 → 核对稳定性与裕度 → 校核离散与工程误差源。前四步给出“理论值”，第五步给出“实际值”。

顺序不能换的理由很实在：

- **先判型别**，是因为型别决定了后面用哪个公式。顺序反了会拿错公式。
- **先算理论值再查稳定**，看起来违反直觉（不稳定还算什么），其实是为了效率：理论值算完再看稳定性，一次就能发现问题；反过来先查稳定，往往要反复回到第一步。
- **最后才校核离散与工程误差源**，是因为前四步给的是一条理想曲线，第五步才是现场能测到的数。先有理想值，才知道实际值偏离了多少、偏离来自哪儿。

把五步在主例上走一遍，看看每一步的输出长什么样（设计点 $K = 0.3888$）：

1. **判型别**：$L = 3.888/[s(s+2)(0.05s+1)]$，约分后分母只有一个 s，$N = 1$。结论写成“型 1，$K_v = 1.9440$”。
2. **算系数**：尾一化 $3.888/[s(1+0.5s)(1+0.05s)]$，直接读得 $K_v = 3.888/2 = 1.9440$。
3. **求误差**：$e_{ss} = 1/K_v = 0.5144$（单位斜坡）。
4. **核稳定**：$\varphi_M = 48.065^\circ$、$G_M = 21.075$ dB、闭环极点全在左半平面，三项都过。
5. **校核离散与工程项**：$T_s = 0.02$ 的 ZOH 把 φ_M 压到 47.185°（K_v 不变）；死区、摩擦、量化三项要另算（§42.10）。

五步走完，结论是“理论值 0.5144，比指标 0.5 差 2.9%，而且这个差距在离散与非线性项加进来之后只会更大”。**注意第 4 步和第 5 步都没有改变第 3 步的数，它们改变的是“这个数可不可信”。**

下面逐步展开。

42.3.2 第一步：判型别，先约分

判型别的动作是“看分母有几个 s”，但必须先做两件事：**约分**和**确认反馈结构**。

约分的坑前面提过。再给一个更隐蔽的例子：

$$L(s) = \frac{10(s+1)}{s^2(s+2)(0.1s+1)}$$

分母有两个 s，看起来是型 2。但分子在 $s = -1$ 有零点，与分母的 $s+1$ 无关——这个例子确实是型 2。换成

$$L(s) = \frac{10(s+0.5)}{s(s+0.5)(0.2s+1)}$$

分母只有一个 s，约分后 $L = 10/\big(s(0.2s+1)\big)$，型 1。如果没约分就数，会误判成型 2，进而错误地认为“斜坡误差为零”。

这个误判的代价可以算出来。把约分结果写回多项式形式，$L = 50/(s^2+5s)$，尾一化系数之比是 $50/5 = 10$，即 $K_v = 10$，斜坡误差 $e_{ss} = 0.1$；闭环极点在 $-2.5 \pm 6.6144\mathrm{j}$，稳定。**所以“型 2、误差为零”与“型 1、误差 0.1”是同一个系统的两种描述，差别全在约分这一步。** 现场如果先按型 2 验收（“斜坡误差应该为零”），怎么调都过不了；等发现是型 1，才知道 0.1 就是理论值。

第三个坑更隐蔽：**型别是开环传递函数 $L = CG$ 的型别，不是对象 G 的型别。** 对象本身是型 0（三个极点都不在原点），只要控制器是 PI，整个回路就是型 1；对象本来是型 1，控制器又串了一个积分，回路就变成型 2——不管设计者想不想要。现场“我明明只加了一个 PI，怎么斜坡误差还是不为零”与“我只想要型 1，怎么一加积分就振”这两类问题，根子都在这里。

这条也解释了为什么“给对象加积分”与“给控制器加积分”在数学上等价、在工程上不等价：两者的 L 相同，但积分器的**位置**不同，抗饱和、限幅、噪声传递的路径全变了（§42.8.4）。

确认反馈结构同样重要。本章默认单位负反馈（$H=1$）。如果反馈通道有增益 $H\neq 1$，误差定义要改成 $e=r-Hy$，静态系数也要相应换算。现场如果用了“半闭环”（编码器在电机端而不是负载端），实际误差里还叠加了传动间隙与弹性变形，那已经不是本章的线性框架能算的了。

判型别的结果要写下来，写成“$N=1$，$K_v=5$”这样的形式，而不是“型 1”。因为型别只说了一半，增益那一半在后面两步要用。

42.3.3 第二步：算静态系数，注意尾一化

三个静态系数里，只有与型别匹配的那一个是非零有限的：

- $N=0$：算 $K_p=L(0)$；
- $N=1$：算 $K_v=\lim_{s\to 0} sL(s)$，等价于“把 L 里的 s 约掉之后取 $s=0$”；
- $N=2$：算 $K_a=\lim_{s\to 0} s^2L(s)$。

手算时最稳的做法是**先把 L 写成尾一化形式**，再直接读系数。主例：

$$L(s)=\frac{10K}{s(s+2)(0.05s+1)}=\frac{5K}{s(1+0.5s)(1+0.05s)}$$

$N=1$，$K_v=5K$。$K=0.3888$ 时 $K_v=1.9440$，与仿真输出的 1.9440 逐位一致。

如果写成首一化 $10K/[s(s+2)(0.05s+1)]$ 后直接读分子 $10K$，就会把 K_v 当成 $10K=3.888$，误差算成 0.2572，比真值小一半。**这个错误在实际工程计算里出现频率极高，因为软件接口（如 MATLAB 的 `tf`）默认给的是首一化系数。**

型 2 的例子把这个坑放大得更清楚。§42.4 的型 2 对象

$$G_2(s)=\frac{5(1+2s)^2}{s^2(s+1)(0.1s+1)}=\frac{20s^2+20s+5}{0.1s^4+1.1s^3+s^2}$$

尾一化读法：把 s^2 提出，剩下的分母是 $0.1s^2+1.1s+1$，常数项为 1；分子的常数项是 5。两者相除得 $K_a=5$。首一化读法：把分母化成首一形式 $s^4+11s^3+10s^2$，增益就是分子的首项系数 20——**比真值大四倍**，误差会被算成 0.05 而不是 0.2。

手算口诀只有一句：**把所有因子都写成 $(1+Ts)$ 的形式，分子各因子常数项相乘、分母各因子常数项相乘，两者之比就是 K。** 遇到 $(2s+1)^2$ 这种，先改写成 $1\cdot(1+2s)^2$，常数项贡献是 1，不是 4。

离散情形还要多一步：K_v 的定义里要除以采样周期 T_s（§42.5），漏掉这个 T_s 会让误差差一个数量级。

42.3.4 第三步：套公式，然后用时域验证

拿到系数之后，按表 42-1 套公式。这一步是纯代数，但建议**同时做一个时域仿真验证**，理由有二：

1. 终值定理有前提（§42.2.2），仿真能暴露“前提不成立”的情形；
2. 手算的尾一化错误，仿真一跑就现形。

验证的做法很简单：给一个单位斜坡，跑足够长的时间，取末段均值，与 $1/K_v$ 比对。主例（$K=1$，$K_v=5$）的验证结果是 0.2000 对 0.2，误差为零；型 2 算例（$K_a=5$）是 0.2000 对 0.2，同样吻合。

“跑足够长”是多长？经验值是**闭环最慢时间常数的 5 到 10 倍**。主例闭环调节时间 4.295 s（第 41 章），跑 40 s 就绰绰有余。型 2 算例的闭环更快，20 s 已经收敛到 0.2000。

验证结果按三条对号，比“看一眼差不多”可靠得多：

1. **稳态值对得上**（四位小数以内）→ 静态系数没算错；
2. **曲线形状对得上**（型 0 直线、型 1 收敛到常数、型 2 归零）→ 型别没判错；
3. **进入稳态的时刻合理**（约为最慢闭环时间常数的 $3 \sim 5$ 倍）→ 仿真时长够。

三条里任何一条不对，都不要急着怀疑公式，先回头查第一步。实践中出错最多的是第二条：型别判错之后，稳态值往往也能“凑”出一个看似合理的数，只有形状会露馅。

还有两个操作细节。第一，验证要走**误差通道**（E/R 乘上输入），不要用“输出减指令”草算——后者在初始条件非零或单位不一致时会引入额外偏差。第二，输入幅值要写清楚：本章的 $1/K_v$ 是**单位**斜坡的误差，输入幅值 v 时要乘上 v，这一点在 §42.2.4 已经用 $2/K_v = 0.4$ 演示过。

42.3.5 第四步：核对稳定性与裕度

这一步是本章与第 41 章的接口。要核三件事：

1. **闭环极点是否全在左半平面**。不稳定就没有稳态，后面全部作废。
2. **相位裕度是否达标**。工程常用底线 45°，高精度伺服有时要求 50° 以上。
3. **增益裕度是否够抵抗参数漂移**。对象增益随温度、负载变化 20% 是常态，6 dB 的增益裕度刚好对应 2 倍，是常见的最低要求。

主例在 $K = 0.3888$ 处的三个数是：闭环稳定、$\varphi_M = 48.065^\circ$、$G_M = 21.075$ dB。三个都过线，所以这个设计点可用。

增益裕度的分贝值最好换算成“还能涨几倍”，现场沟通时更直观：允许倍数 $= 10^{G_M/20}$。21.075 dB 对应 11.32 倍，6 dB 对应 2.0 倍。主例的 21 dB 看起来非常宽裕——但这是“只涨增益、相位不动”的口径；真实对象的增益与相位总是同时变（增益涨往往伴随极点右移），实际可用的余量远小于 11 倍。6 dB 这条底线之所以常见，就是因为它在“增益与相位同时漂移”的现实下还能留一点安全垫。

三项核对的优先级要明确：**稳定是一票否决，裕度是概率性保护，误差是性能指标。** 不稳定的系统讨论误差没有意义；裕度不足的系统“现在准、将来不一定准”；误差偏大的系统至少还能用。现场评审时如果三项冲突，按这个顺序让步。

如果为了压误差把 K 提到 0.7332，误差降到 0.2728，但 φ_M 只有 33.608°——第一项过、第二项不过。**这种设计在纸面上误差漂亮，在现场会表现为“定位准但一停就抖”。**

42.3.6 第五步：误差预算，把总数拆开

理论值算完，还要回答“现场为什么比理论值大”。做法是**误差预算表**：把总误差拆成几项，逐项估算，看哪一项占大头。

主例的误差预算（$K = 0.3888$，$K_v = 1.944$）可以这样拆：

表 42-3　主例的误差预算（斜坡输入，单位 mm）

误差项	来源	估算值	占比
型别误差	$1/K_v$	0.5144	基准
摩擦附加	常值扰动 d/K_p	视 d 而定	叠加
死区	$\pm\Delta/K_p$	视 Δ 而定	叠加
量化	极限环幅值	视 q 而定	叠加
传感器零漂	固定偏移	视标定而定	叠加

表 42-3 的关键信息是：**型别误差是“基准”，其余都是“叠加”**。这意味着即使把型别误差算得再准，现场测到的总数也会更大——不是理论错了，而是漏项。

预算表的用法是“抓大头”：哪一项超过总指标的 30%，就先治它。§42.10 会把后三项分别量化。

把三项写成可算的式子，预算表就从定性变成定量。统一到同一工况——主例对象、比例控制 $K_p = 2$、$T_s = 0.02$——此时 $K_v = 10$、型别误差 0.1，§42.10 的三组实测正好可以直接填进来：

- **死区** $\Delta = 0.02$：理论带 $\pm\Delta/K_p = \pm 0.01$，实测 $+0.00978$，占型别误差的 9.8%；
- **摩擦** $d = -0.05$：理论偏移 $d/K_p = -0.025$，实测 -0.02500，占 25%；
- **量化** $q = 0.005$：实测均值 -0.00050，占 0.5%。

三项最坏同向叠加，总数是 $0.1 + 0.00978 + 0.025 + 0.0005 = 0.1353$，**比理论值大 35%**。这个结果传递的信息很明确：在这个工况下，摩擦是第一大项，死区次之，量化可以忽略。治理顺序也就定了——先查导轨润滑与预紧，再看执行器死区，最后才考虑提高分辨率。

预算表的价值在于此：理论值告诉你“最少差多少”，预算表告诉你“实际会差多少、先治哪一项”。 两者缺一，现场就只能靠试。

42.4 连续情形

42.4.1 三个对象，三种型别

为了把“型别决定一切”这句话落实，本节用三个对象分别做成型 0、型 1、型 2，结构上都尽量简单，只留必要的极零点：

- 型 0：$G_0(s) = \dfrac{10}{(s+1)(0.5s+1)(0.1s+1)}$，三个极点都不在原点；
- 型 1：$G_1(s) = \dfrac{10}{s(s+2)(0.05s+1)}$，就是第 39 到 41 章一路用到的主例；
- 型 2：$G_2(s) = \dfrac{5(1+2s)^2}{s^2(s+1)(0.1s+1)}$，两个原点极点，靠双重零点 $(1+2s)^2$ 把相位抬回来。

三个对象的极零点摆开看很清楚：G_0 的极点是 $-1, -2, -10$，全是负实数，覆盖三个时间尺度；G_1 是 $0, -2, -20$，相当于把 G_0 的 -1 挪到原点、把 -10 推到 -20；G_2 是 $0, 0, -1, -10$ 加一对重零点 -0.5。**三者的极点个数与高频段结构刻意做得相近，差别主要落在原点极点的个数上**——这样比较出来的误差差别，才能干净地归因于型别。

G_2 的相位裕度可以直接手算复核，把各环节在 $\omega_c = 12.4838$ 处的相位加起来：

- 两个原点极点：-180°；

- 双零点 $(1+2s)^2$：$2\arctan(2\times 12.4838)=2\times 87.71^\circ=+175.4^\circ$；
- 极点 -1：$-\arctan(12.4838)=-85.42^\circ$；
- 极点 -10：$-\arctan(1.24838)=-51.32^\circ$。

合计 -141.3°，相位裕度 $180^\circ-141.3^\circ=38.7^\circ$，与实跑的 38.6887° 一致到小数点后一位。

这个手算说明**型 2 能不能稳，全看零点放得够不够低**。零点在 0.5 rad/s，只有 ω_c 的 $1/25$，每个零点贡献 87.7°，两个几乎拿满；若把零点挪到 $\omega_c/5$，每个只剩 78.7°，裕度立刻掉近 18°。**经验规则是“双零点放在 $\omega_c/10$ 以下”**，这样每个零点至少拿到 84°，才有余量去抵两个积分器。

三个对象都用 $C=1$（纯比例、单位增益），这一点是刻意的。一旦控制器带积分，三个回路的型别都会被抬成一样，“对象型别”与“回路型别”就分不开了；本章要先把型别的作用单独看清楚，PI 留到 §42.7 再引入。

三个对象的实测结果见表 42-4。

表 42-4　三个对象的型别、静态系数与三类输入的稳态误差（控制器 $C=1$）

对象	型别 N	K_p	K_v	K_a	阶跃	斜坡	抛物线	闭环稳定
G_0	0	10.0	0	0	0.0909	∞	∞	是
G_1	1	∞	5.0	0	0	0.2	∞	是
G_2	2	∞	∞	5.0	0	0	0.2	是

表 42-4 有三处值得停下来看：

1. **型 0 的阶跃误差是 $1/11=0.0909$**，不是 $1/10$。分母里那个 $1+$ 不能漏。如果按 $1/K_p=0.1$ 报，会高估 10%。
2. **型 1 的阶跃误差是严格的 0**，实测不是“很小”，是数值上的 0——仿真末段均值在 10^{-8} 量级。
3. **型 2 的斜坡误差也是 0**，抛物线误差才是 $1/K_a=0.2$。三者沿对角线排开，与表 42-2 完全对应。

三个对象都稳定，所以终值定理的前提都满足，表里的数可以直接用。

42.4.2 同一张图上看三种型别

把三个对象放在同一条单位斜坡输入下，误差曲线见图 42-1。

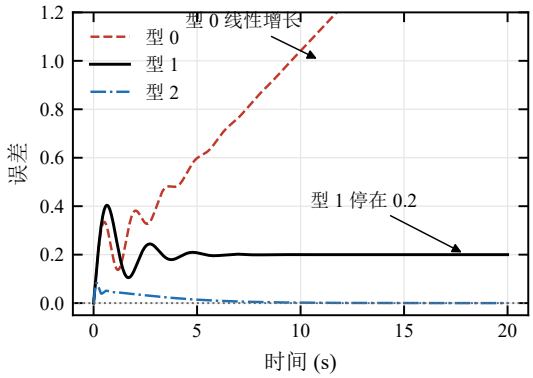

图 42-1　三种型别在单位斜坡输入下的误差

图 42-1 的三条线把表 42-2 的第二行画了出来：

- 型 **0**（虚线）线性增长，斜率恰好等于误差通道的直流增益 $S(0)=1/(1+K_p)=1/11=0.0909$：$t=10$ s 时 $e=1.0409$，$t=20$ s 时 $e=1.9504$，图上在 $t\approx 12$ s 处出框。这个斜率不必解微分方程，直接从 $S(0)$ 读出来就行——斜坡输入的导数是 1，误差的导数就是 $S(0)$。
- 型 **1**（实线）收敛到 0.2，$t=10$ s 之后基本水平。这个 0.2 就是 $1/K_v$。
- 型 **2**（点划线）收敛到 0，$t=5$ s 左右已经贴住零线。

三条线的差别不是“精度高低”，而是定性不同：一条发散、一条常数、一条归零。这正是型别的作用，也是为什么判型别必须放在第一步。

把型 1 那条线放大，还能看到一个常被忽略的细节：它不是单调爬升到 0.2 的，而是一路振荡着收敛。实测 $t=1$ s 时误差已经冲到 0.3087，$t=2$ s 跌到 0.1426，$t=2.72$ s 又反弹到 0.2443，之后振幅越来越小，最后停在 0.2000。这串“上下打摆”是闭环共轭极点造成的，与型别无关——型别决定终值，极点位置决定路上的形状。§42.4.3 那个“5.99 s 才进 $\pm 2\%$ 带”的说法，等的就是这串振荡衰减完。

型 2 那条线反而干净：它从 0.0455 单调下滑到零，没有可见的振荡。闭环极点算出来是 $-5.0059\pm 13.2211\mathrm{j}$（$\zeta=0.354$）与 $-0.4941\pm 0.0778\mathrm{j}$（$\zeta=0.988$）——前者振荡快、衰减也快，后者几乎就是一对实极点，两者都不产生“打摆”。对照型 1 的 $-0.7370\pm 3.0332\mathrm{j}$、$\zeta=0.236$，阻尼比差了一半，形状就差出了一串波纹。

42.4.3 斜坡误差的时域验证

理论值 $1/K_v$ 与仿真值必须逐位对上，否则说明某一步算错了。型 1 主例（$K=1$，$K_v=5$）的验证数据是：

- $t=10$ s：$e=0.1998$；
- $t=20$ s：$e=0.2000$；
- $t=40$ s：$e=0.2000$；
- 末段 200 点均值：0.2000；
- 解析 $1/K_v=0.2000$。

两者差在第四位小数，来源是仿真步长与末段取平均的时间窗。这个精度足以判定“公式用对了”。

还有一个数值得单独说：误差第一次进入 $1/K_v\pm 2\%$ 带的时刻是 5.99 s。这个数比常被引用的“调节时间 4.295 s”稍晚，因为：

- 调节时间看的是输出进入 $\pm 2\%$（相对阶跃终值）；
- 这里看的是误差进入 $\pm 2\%$（相对斜坡稳态值 0.2）。

两个带的基准不同，晚一点是正常的。工程上如果要写“多久之后读数可信”，应该用后者。

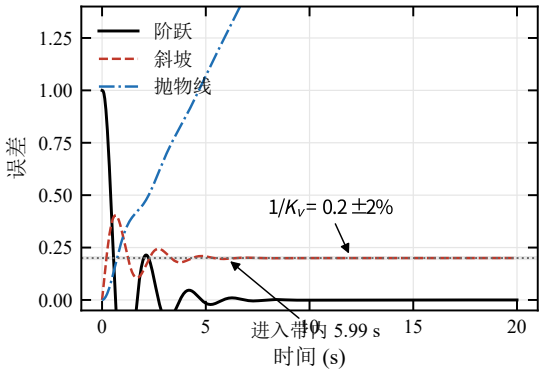

图 42-5　型 1 主例在阶跃、斜坡、抛物线三种输入下的误差

图 42-5 把三种输入画在一起。三条曲线各有各的走向，但都带着同一串振荡：

- **阶跃误差**是一条衰减振荡：$t = 1$ s 时 -0.4434（对应输出超调约 44%），$t = 2$ s 时 $+0.1984$，$t = 5$ s 时 -0.0158，之后贴住零线。
- **斜坡误差**振荡着收敛到 0.2，形状与阶跃那条几乎一样，只是整体上移了 0.2。
- **抛物线误差**一路增长：$t = 10$ s 时 2.0700、$t = 20$ s 时 4.0700，在 $t \approx 6.6$ s 处就出框（纵轴上限 1.4）。

三者同源——都来自那对 $\zeta = 0.236$ 的闭环极点，只不过阶跃的振荡叠在零线上、斜坡的叠在 0.2 上、抛物线的叠在一条斜率为正的直线上。**静态系数决定“叠在哪条基准线上”，动态极点决定“叠上去的波纹有多大”。**这两件事必须分开看，否则会把“振荡”误当成“稳态误差”。

抛物线那条还藏着一个验证：它的**斜率**是 0.2，与斜坡误差的**终值** 0.2 是同一个数——两者都等于 $1/K_v$。写成式子就是 $e(t) \approx t/K_v + 0.07$，代 $t = 10$ 得 2.0700、代 $t = 20$ 得 4.0700，与实测逐位吻合。**同一个 K_v，在两种输入下以“终值”和“斜率”两种面貌出现**，这是型 1 系统的指纹。

42.4.4 型 2：把抛物线误差压成常数

型 2 算例 $G_2 = 5(1+2s)^2/[s^2(s+1)(0.1s+1)]$，$K_a = 5$，理论抛物线误差 0.2。时域实测见表 42-5。

表 42-5　型 2 算例的抛物线误差时域验证

时刻 (s)	5	10	20	末段均值	解析 $1/K_a$
误差	0.1650	0.1959	0.2000	0.2000	0.2000

收敛过程比型 1 慢一些（5 s 时还差 17%）。查一下闭环极点就明白了：型 2 的慢模态是 $-0.4941 \pm 0.0778\mathrm{j}$，$\omega_n = 0.5002$、$\zeta = 0.988$——**它几乎不振荡，但时间常数约 2 s**，所以要十几秒才把最后那点差距磨平。这与型 1 的“快振荡、慢衰减”是两种不同的慢法。

这个算例的裕度是：$\varphi_M = 38.6887^\circ$，$\omega_c = 12.4838$ rad/s，增益裕度算出来是 ∞。**相位裕度不到 40°，是“能用但不好用”的水平。**增益裕度无穷大不是好事，而是说明相频曲线在幅频穿过 0 dB 之后才降到 -180°，属于“高频掉得快”的类型——这种系统对高频噪声不敏感，但对建模误差很敏感。

型 2 的代价在这里显出来了：为了两个原点极点（180° 固定滞后），必须配双重零点；配了零点，高频增益被抬起来，相位裕度又被吃掉一部分。**型别每升一级，都要拿裕度去换。**

42.4.5 主例的六档增益

主例 $L=10K/[s(s+2)(0.05s+1)]$ 的 $K_v=5K$，取六档增益扫描，结果见表 42-6。

表 42-6　主例六档增益下的 K_v、误差与裕度

K	K_v	e_{ss}	φ_M (°)	G_M (dB)	ω_c (rad/s)
0.1000	0.5000	2.0000	74.958	32.869	0.4857
0.2000	1.0000	1.0000	62.946	26.848	0.9094
0.3888	1.9440	0.5144	48.065	21.075	1.5369
0.5000	2.5000	0.4000	42.229	18.890	1.8346
0.7332	3.6660	0.2728	33.608	15.565	2.3561
1.1000	5.5000	0.1818	25.044	12.041	3.0100

表 42-6 前两列是严格线性的（$K_v=5K$），第三列是严格的双曲线（$e_{ss}=1/K_v$），后三列却是“非线性地变坏”：

- K 涨 11 倍，e_{ss} 降到 $1/11$，很划算；
- 同期 φ_M 从 74.958° 掉到 25.044°，掉了 49.9°；
- ω_c 从 0.4857 涨到 3.0100（6.2 倍），带宽跟着涨，噪声抑制能力下降。

第一、二列是“收益”，后三列是“代价”，必须一起看。 这也是第 41 章反复强调“裕度与误差由同一个旋钮决定”的数据基础。

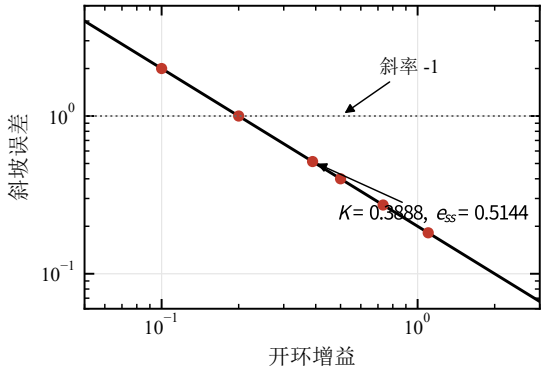

图 42-3　开环增益与斜坡误差的映射

图 42-3 用双对数坐标画 $e_{ss}=1/(5K)$，六个点对应表 42-6 的六档。双对数下的直线斜率为 -1：**增益每涨十倍，误差降到十分之一**，这条斜率为 -1 的直线是所有型 1 系统共有的“误差-增益定律”，与对象细节无关。

六档增益本身也值得说一句：它们是等比取的（相邻两档约 $1.5\sim2$ 倍），不是等距。原因是误差是双曲线，等距取点会让低增益段挤成一团、高增益段稀疏；等比取点在双对数坐标上等距，正好把那条斜率为 -1 的直线画匀。**扫描参数时“按比例取点”是通用原则，因为控制系统的很多关系是幂律的。**

表 42-6 还藏着一个容易被忽略的约束：ω_c 随增益涨了 6.2 倍。按 §42.5.6 的准则 $\omega_c T_s\le 0.3$ 反算，$K=0.1000$ 时采样周期可以松到 0.62 s，$K=1.1000$ 时只能到 0.10 s。**“把增益提上去”这句话，隐含了“采样率也要跟上去”**——很多设计在纸面上算得很好，落地时才发现控制器的主频不够。

再说一个读表的方法：**表 42-6 可以直接当“设计选点表”用。** 设计点 $K=0.3888$ 的依据是“满足 $\varphi_M\ge 45^\circ$ 的最大增益”，实跑的边界是 $K=0.4436$（表 42-10 第一行），所以 0.3888 留了 $0.4436/0.3888=1.141$ 倍的增益余量，即 1.14 dB。这 1.14 dB 就是“模型误差、温漂、电源波动”能吃掉的额度；吃完之后就跌破 45°。**设计点不是“最好的点”，是“留了余量的点”，余量多少在表里查得到。**

42.4.6 终值定理失效的三种情形

理论算完之后，必须问一句“前提还成立吗”。三种常见的失效情形：

第一种：闭环不稳定。 型 2 算例如果把增益从 5 提到 10，相位裕度会变成负的，闭环出现右半平面极点。这时终值定理给出的 $1/K_a=0.1$ 毫无意义，真实响应是发散振荡。判别方法：先算闭环极点，或先看相位裕度是否为正。

第二种：输入不是多项式型。 正弦指令下 $R(s)=\omega/(s^2+\omega^2)$，$sE(s)$ 在 $s=\pm\mathrm{j}\omega$ 上有极点，终值定理的极限不存在。硬算会得到 0 或一个无意义的数——因为推导里用了“$s\to 0$ 时其他极点已衰减”这个假设。正弦跟踪要用第 41 章的幅频与相频，不用本章的公式。

第三种：回路里有非线性环节。 死区、饱和、量化都会让“线性传递函数”这个概念失效。这时稳态误差可能不是常值而是极限环，幅值取决于非线性参数。§42.10 会把这三项分别量化。

三种失效在工程上对应三句提醒：**先验稳定、再问输入形状、最后查非线性。** 这三句话应该写进任何一个稳态误差计算的作业指导书里。

还有一类“假失效”必须提前说清：输入是“阶跃 + 斜坡”的复合信号，比如“先快速到位、再匀速扫描”。这时不要去找一个“复合的静态系数”，按叠加原理拆开算就行：阶跃部分在型 0 上贡献 $1/(1+K_p)$、在型 1 及以上贡献 0；斜坡部分在型 1 上贡献 $1/K_v$、在型 2 上贡献 0。两部分相加就是总误差。**线性系统的误差可以叠加，这正是本章能用一张表说完九种组合的底层原因。**

最后一类不是“失效”而是“参数漂移”：放大器饱和后等效增益下降，型别没变，但 K_v 按比例缩水。表现是“小信号准、大信号偏”，而且偏差随指令幅值变化——这与型别误差的“随速度变化”很容易混淆。判别方法很简单：把指令幅值减半再测，若误差不成比例地缩小，就是饱和（§42.8.4 给三种抗饱和手法）。

42.5 离散情形

42.5.1 型别的定义要换一个平面

连续域数的是 $s=0$ 处的极点，离散域对应的是 $z=1$ 处的极点。定义照搬：

$$L(z)=\frac{K\prod_i(z-z_i)}{(z-1)^N\prod_j(z-p_j)} \tag{42-10}$$

分母里 $(z-1)^N$ 的个数就是离散型别。$z=1$ 对应 $s=0$（因为 $z=\mathrm{e}^{sT_s}$），所以两边的型别定义是一致的。

判型别在数值上也很直接：把 $L(z)$ 的分母系数按降幂排好，检查常数项是否为零；为零就去掉、计数加一，直到常数项非零为止。`ch042_sim.py` 里的 `origin_poles()` 就是这个循环，它对连续域的 s^N 与离散域的 $(z-1)^N$ 用法完全相同——因为两者都是“分母末尾的零”。**一个函数管两个域，是因为 $s=0$ 与 $z=1$ 在系数表示下都落在同一个位置。**

但离散域多了一个连续域没有的麻烦：**误差只在采样时刻有定义。** 两个采样点之间输出怎么走，z 变换看不见。如果闭环在采样间发生“隐藏振荡”（ripple），采样点上误差为零、采样点之间可能很大。本章的框架查不出这类问题，要靠第 43 章的离散根轨迹或第 60 章的采样间响应分析。经验判据是：T_s 越大、$\omega_c T_s$ 越接近 0.5，隐藏振荡的风险越高——这也是 §42.5.6 把 $\omega_c T_s \le 0.3$ 当作准则的原因之一。

主例在 $T_s = 0.02$ s、ZOH 下的离散分母是 $[1,\ -2.6311,\ 2.2751,\ -0.6440]$，三个根是 1、0.9609、0.6702。这三个数不是巧合，而是 e^{sT_s} 的直接映射：$s = 0 \to 1$，$s = -2 \to \mathrm{e}^{-0.04} = 0.9608$，$s = -20 \to \mathrm{e}^{-0.4} = 0.6703$（末位差 1 是四舍五入）。**“型 1”这件事在离散域就是“有一个根恰好落在 1 上”**，其余两个根的位置只说明收敛快慢，与型别无关。

这个对照顺带给出一个现场判据：查型别时不要数“分母几阶”，也不要数“左半平面有几个极点”，而是直截了当看 $z = 1$ 是不是根。根恰好在 1 上就是型 1；在 1 的附近但不在 1 上（比如 0.9900），是“接近型 1 的型 0”——稳态误差不为零，只是小到看不出来，这正是 §42.1.3 泄漏积分器的情形。**型别是“在不在”，不是“近不近”。**

不一致的地方在**静态系数的定义**。连续域里 $K_v = \lim_{s\to 0} sL(s)$，量纲是“每秒”；离散域里必须显式除掉采样周期：

$$K_{v,d} = \frac{1}{T_s}\lim_{z\to 1}(z-1)L(z) \tag{42-11}$$

这个 $1/T_s$ 不是凑出来的。直观理解：离散域的“斜坡”是每个采样周期上升 T_s 的阶梯，用 z 变换表示时自带一个 T_s 因子；把它除掉，才能与连续域的“单位斜率”对齐。**漏掉这个 T_s，误差会差一个数量级**——$T_s = 0.02$ 时差 50 倍。

42.5.2 用留数算，不要用数值极限

直接按式 42-11 数值求极限很危险：$z \to 1$ 时分子分母同时趋于零，浮点运算会给出 $0/0$。正确做法是解析求——把 $(z-1)L(z)$ 写成 $n(z)/d(z)$，在 $z = 1$ 处用洛必达法则：

$$K_{v,d} = \frac{1}{T_s}\cdot\frac{n(1)}{d'(1)} \tag{42-12}$$

其中 $n(z)$ 是约掉 $(z-1)$ 之后的分子，$d'(z)$ 是约掉之后分母的导数。这一步在代码里就是两行（`np.polyval(num, 1.0)` 与 `np.polyval(np.polyder(den), 1.0)`），但它把“数值极限”换成了“代数恒等”，精度从“取决于步长”变成“取决于浮点舍入”。

主例的验算（$K = 0.3888$、$T_s = 0.02$ 的 ZOH 离散化）：$n(1) = 5.0260 \times 10^{-4}$，$d'(1) = 1.2927 \times 10^{-2}$，两者相除得 0.038880，再除以 $T_s = 0.02$ 得 $K_{v,d} = 1.9440$。**这几步全是一次多项式求值，没有任何“趋近”过程。**

反过来看数值极限为什么不可靠：$z \to 1$ 时 $(z-1)L(z)$ 的分子分母同时趋于零，浮点在 10^{-16} 的相对精度下就会给出 $0/0$ 或一个乱数。而且 T_s 越小，$(z-1)$ 的抵消越严重——**恰好在“高采样率”这个最该算准的场合，数值极限最不可靠**，而解析式完全不受 T_s 影响。

离散域还有一个与连续域不同的地方：$E(z)$ 只给出采样时刻的误差，采样间的“隐藏振荡”它看不见。本章的 K_v 讨论因此是“采样点上的 K_v”，如果对象本身有高频模态、或者控制器在采样间引入了拍频，采样间误差可能远大于采样点误差——这属于第 43 章离散化设计要处理的问题。

主例的验算：$K = 0.3888$ 时，四种采样周期、三种离散化方法算出来的 $K_{v,d}$ 全是 1.9440，与连续值逐位相同。这不是巧合，下一小节给证明。

42.5.3 结论一：采样不改变 K_v

表 42-7 是十二组组合的实测。

表 42-7　离散化方法对 K_v 的影响（$K = 0.3888$，连续值 1.9440）

T_s (s)	ZOH	Tustin	ZOH + 一拍延迟
0.02	1.9440	1.9440	1.9440
0.05	1.9440	1.9440	1.9440
0.10	1.9440	1.9440	1.9440
0.20	1.9440	1.9440	1.9440

十二个数完全相同。这不是数值精度不够，而是**定理**：

- **ZOH**：$L(z) = (1 - z^{-1})\mathcal{Z}\{L(s)/s\}$。型 1 时 $\mathcal{Z}\{1/s^2\} = T_s z/(z-1)^2$，代入得 $L(z) = KT_s/(z-1)$，于是 $K_{v,d} = (1/T_s)(z-1)L(z)|_{z=1} = K$。
- **Tustin**：$s = \frac{2}{T_s}\frac{z-1}{z+1}$。型 1 时 $1/s$ 映射成 $\frac{T_s(z+1)}{2(z-1)}$，乘上 $(z-1)/T_s$ 后取 $z=1$，得 K。

两者的 K_v 都精确等于连续值，与 T_s 无关。这一条在教科书里叫“零阶保持器保持型 1 系统的速度误差系数”，它是本章最反直觉、也最实用的结论之一：**采样频率再低，斜坡误差也不会因此变大。**

直觉解释：采样不改变“积分器有几个”，而 K_v 只取决于积分器个数与低频增益。低频增益在离散化中是被精确保持的（ZOH 与 Tustin 都在 $z=1$ 处匹配），所以 K_v 不变。

还可以再往前推一步：换成前向欧拉（$s = (z-1)/T_s$）与后向差分（$s = (z-1)/(T_s z)$），$T_s = 0.05$ 下算出的 $K_{v,d}$ 仍是 1.9440。**四种离散化方法、两个域，全部落在同一个数上。**这说明真正的条件不是“用哪种方法”，而是“该方法在 $z=1$ 处把 $1/s$ 映射成 $T_s/(z-1)$ 这个主导项”——ZOH、Tustin、前向欧拉、后向差分都满足，因为它们都在 $z=1$ 附近与 s 保持一阶以上的匹配。

把 Tustin 的映射在 $z=1$ 附近展开，能看清“精确”与“近似”的分界线：

$$\frac{1}{s} = \frac{T_s(z+1)}{2(z-1)} = \frac{T_s}{z-1}\cdot\frac{z+1}{2} = \frac{T_s}{z-1}\left(1 + \frac{z-1}{2}\right)$$

主导项 $T_s/(z-1)$ 精确，修正项 $(z-1)/2$ 在 $z=1$ 处为零。所以 K_v（只取 $z=1$ 的值）不受影响，而 $z \neq 1$ 的频段（也就是所有 $\omega > 0$）全都带着这个修正——**这就是“K_v 精确、裕度不保”的同一套数学。**Tustin 把连续频率轴压成 $\frac{2}{T_s}\tan(\omega T_s/2)$，频率越高压缩越厉害（频率卷绕），相位裕度因此只在原频率点附近才准。

ZOH 的情形类似：它在 $z=1$ 处也匹配，但等效地多出约半拍的相位延迟，ω 越高延迟越大。**同一个“一阶匹配”，在 $z=1$ 给出精确的 K_v，在 $\omega > 0$ 给出失真的相位。**一条结论管一个点，另一条结论管一段线，这就是为什么本章要把“K_v 不变”与“裕度必掉”分成两个结论讲。

反过来，什么情况会破坏这条结论？两种最常见：

1. **离散化之后又串了低通滤波或限幅**，改变了低频增益。这时 K_v 变的是“滤波器的直流增益”，不是“离散化”。

2. **控制器用增量式实现时少乘了 T_s**。增量式写成 $u_k = u_{k-1} + K_i e_k$（漏掉 T_s）时，实际积分增益变成 K_i/T_s，K_v 随之放大 $1/T_s$ 倍——$T_s = 0.02$ 就是 50 倍。**“采样不改 K_v”是在“离散化正确”的前提下成立的，代码里的一个漏乘就足以推翻它。**

42.5.4 结论二：保不住的是裕度

K_v 不变，并不意味着“离散化无害”。表 42-8 是同一批组合的相位裕度。

表 42-8　离散化方法对相位裕度的影响（连续值 48.065°）

T_s (s)	ZOH	Tustin	ZOH + 一拍延迟
0.02	47.185	48.065	45.424
0.05	45.870	48.065	41.468
0.10	43.688	48.065	34.888
0.20	39.374	48.065	21.815

三条信息：

1. **Tustin 一个度都不掉**。四个采样周期全是 48.065°。原因：双线性变换把频率轴压弯了，但幅频与相频在压弯后的同一点上取值，所以“幅值过 0 dB 处的相位”保持不变。**相位裕度是 Tustin 的不变量**。表里 ω_c 的读数会有细微差别（$1.5368/1.5362/1.5339/1.5250$），那是数字化频率轴的读数差，不是裕度损失。
2. **ZOH 掉的相位近似等于 $\omega_c T_s/2$**。$T_s = 0.2$ 时理论损失 $1.5369 \times 0.2/2 = 0.1537$ rad $= 8.81^\circ$，实测 $48.065 - 39.374 = 8.691^\circ$，差 0.12°。四个采样周期的对照见表 42-9，全部在 0.13° 以内。
3. **一拍延迟的代价是 ZOH 的两倍**。延迟一拍在 ω_c 处引入 $\omega_c T_s$ rad 的相位滞后，正好是 ZOH 的两倍。$T_s = 0.2$ 时合计 $8.81 + 17.61 = 26.42^\circ$，实测损失 26.25°。

表 42-9　ZOH 相位损失的解析估算与实测对照

T_s (s)	$\omega_c T_s/2$ (rad)	估算损失 (°)	实测损失 (°)	偏差 (°)
0.02	0.0154	0.881	0.880	0.001
0.05	0.0384	2.202	2.195	0.007
0.10	0.0768	4.403	4.377	0.026
0.20	0.1537	8.806	8.691	0.115

表 42-9 的偏差随 T_s 增大而增大，因为 $\omega_c T_s/2$ 本身是一阶近似（精确式是 $\omega_c T_s/2$ 加上 $\omega^3 T_s^3/24$ 量级的修正）。工程上在 $\omega_c T_s \le 0.3$ 范围内用这个近似足够了。

于是得到一个非常实用的换算：

$$\Delta\varphi_{\text{ZOH}} \approx \frac{\omega_c T_s}{2}\ (\text{rad}) = \frac{180}{\pi}\cdot\frac{\omega_c T_s}{2}\ (^\circ) \tag{42-13}$$

它把“采样周期”直接翻译成“吃掉多少度相位”，与第 41 章的延迟裕度公式是同一套语言。$T_{d,\max} = 0.5458$ s 是主例的延迟裕度，而 $T_s = 0.2$ 的 ZOH 相当于 0.1 s 的纯延迟——**占了延迟裕度的两成**。

这个近似有两个边界要记住。第一，$\omega_c T_s/2$ **是在 ω_c 处的取值**，ZOH 的相位滞后本身随频率增长（$\omega T_s/2$），所以高频段的实际滞后远大于这个数——它只保证“对裕度最相关的那一点”估得准。第二，$T_s = 0.2$ 时偏差

已经到 $0.115°$，再往上（$\omega_c T_s > 0.5$）就不能用了，得直接算离散模型的裕度。

关于 Tustin 也要补两句。它的“相位裕度不变量”是**数学性质**：双线性变换把整个左半平面映到单位圆内，$z=1$ 附近与 s 的映射是保角的，所以“幅值过 0 dB 处的相位”不变。但它的代价在高频——$s\to\infty$ 被压到 $z=-1$，高频幅频被折叠，噪声传递与实际对象不符。要“既保裕度又保高频”，可以：

- **预畸变**：把关键频率 ω_c 预畸变，使该点的幅相与连续域严格一致；
- **改用 ZOH + 更高采样率**：用真实的保持特性换回高频可信度。

选 Tustin 还是 ZOH，本质上是“信低频还是信高频”的选择。 稳态误差只看低频，所以本章的 K_v 结论对两者都成立；裕度看 ω_c，Tustin 占优；噪声与未建模高频动态看高频段，ZOH 更接近物理现实。

42.5.5 结论三：真正的代价是最小可达误差

K_v 不变、裕度下降，两者合起来的后果是：**在“裕度必须达标”的约束下，采样把可用增益压低，从而把最小可达误差抬高。**

做法是固定 $\varphi_M=45°$，反解最大可用增益（60 次二分），结果见表 42-10。

表 42-10　相位裕度约束下（$\varphi_M=45°$）的最大增益与最小误差

情形	$K_{\max}$	$K_{v,\max}$	$e_{ss,\min}$	相对连续
连续	0.4436	2.2178	0.4509	基准
$T_s=0.05$ ZOH	0.4026	2.0132	0.4967	$+10.2\%$
$T_s=0.10$ ZOH	0.3699	1.8497	0.5406	$+19.9\%$
$T_s=0.20$ ZOH	0.3205	1.6027	0.6239	$+38.4\%$

这张表是本章与第 41 章交汇的地方，也是“采样到底有多贵”的定量答案：

- $T_s=0.05$（$\omega_c T_s=0.077$），可用增益掉 9.2%，误差涨一成；
- $T_s=0.10$（$\omega_c T_s=0.154$），掉 16.6%，误差涨两成；
- $T_s=0.20$（$\omega_c T_s=0.307$），掉 27.8%，误差涨近四成。

误差涨得比增益掉得快，因为 e_{ss} 与 K 是双曲线关系：增益掉 27.8%，误差就要涨 $1/(1-0.278)-1=38.5\%$，与实测 38.4% 吻合。

把这条关系写成公式，就能直接做预算：设采样让可用增益掉到连续值的 $1-\delta$ 倍，最小可达误差就放大到

$$\frac{e_{ss,\min}(T_s)}{e_{ss,\min}(\text{连续})}=\frac{1}{1-\delta}$$

三档的 δ 是 0.092、0.166、0.278，代入得 1.101、1.199、1.385，即 $+10.1\%$、$+19.9\%$、$+38.5\%$，与实测的 $+10.2\%$、$+19.9\%$、$+38.4\%$ 逐项对上（首项差 0.1% 来自 δ 只取三位小数）。**采样对误差的影响不是“加一点”，而是“乘一个放大因子”**，这个因子只由 δ 决定，与对象细节无关。

这条公式还能反过来选采样周期。主例的指标是“误差 ≤ 0.5 且裕度 $\ge 45°$”，连续设计的最小可达误差已经是 0.4509，留给采样的余量只有 $(0.5-0.4509)/0.5=9.8\%$，即要求 $\delta\le 8.9\%$。查表 42-10：$T_s=0.05$ 时 $e_{ss,\min}=0.4967$，刚好压线；$T_s=0.10$ 时 0.5406，已经超了。**所以主例的采样周期应当取 0.05 s 以内（20 Hz 以上），而不是 0.2 s。**

这个结论与 §42.5.6 的 $\omega_c T_s \le 0.3$ 是两条独立的约束，必须同时满足，取更严的那条：按 ω_c 算，$T_s \le 0.195$ s 就算过；按误差指标算，$T_s \le 0.05$ s 才过。**误差指标比裕度指标更早地对采样率提出要求**——这一点在设计初期最容易被忽略。

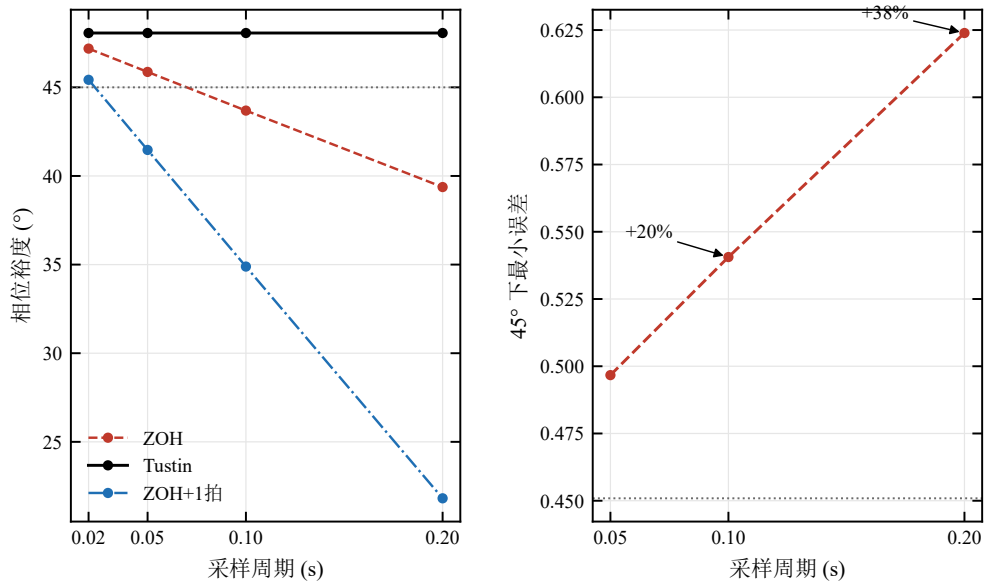

图 42-6　采样周期对相位裕度与最小可达误差的影响

图 42-6 左边是三条裕度曲线，右边是表 42-10 后三行的误差。左边的看点是对比：ZOH 稳步下滑、Tustin 保持水平、ZOH 加一拍延迟下滑最陡（$T_s = 0.2$ 时只剩 $21.8°$，已经低于常用底线一半）。

42.5.6 采样周期到底选多大

把上面的结论反过来用，就得到选点采样周期的工程准则。

准则一：按 $\omega_c T_s$ 选，不按“最高频率”选。 采样定理说 $T_s < \pi/\omega_{\max}$，但那个 $\omega_{\max}$ 是信号最高频率，往往比 ω_c 高一个数量级。设计上真正管用的是 $\omega_c T_s \le 0.3$（相位损失不超过 $8.6°$）。主例 $\omega_c = 1.5369$，得 $T_s \le 0.195$ s，与表 42-10 的最后一档吻合。

准则二：把 ZOH 的相位损失算进裕度预算。 如果连续设计留了 $48°$，T_s 让它掉到 $39°$，那实际裕度就是 $39°$，不是 $48°$。**预算表上要单列一行“采样损失”**，就像第 41 章单列“延迟损失”一样。

准则三：能用 Tustin 就别用 ZOH——如果控制器是纯软件实现。 Tustin 在相位裕度上不付代价，代价是高频段的幅值被压缩（频率预畸变可以补偿）。但如果对象本身就是“零阶保持”驱动的（DAC 输出、PWM 占空比），ZOH 才是物理现实，不能用 Tustin 掩盖。

准则四：延迟一拍的代价要单独算。 数字控制器从采样到输出至少延迟一拍，这一拍在 ω_c 处是 $\omega_c T_s$ rad，是 ZOH 的两倍。$T_s = 0.2$ 时它一项就吃掉 $17.6°$，比 ZOH 本身还多。**这就是为什么“提高采样率”对数字控制器的收益比想象中大——它同时压缩了 ZOH 与计算延迟两项。**

四条准则之外，还有三条工程经验值得写进检查表：

1. **把计算延迟的来源数清。** 采样保持、A/D 转换、控制律计算、PWM 更新各占一部分，加起来常常就是一到两拍。设计时应该把“等效延迟”写成 T_s 的倍数（例如 $1.5T_s$），而不是假装它不存在。
2. **多速率采样能缓解矛盾，但要整体核算。** 电流环 10 kHz、速度环 1 kHz、位置环 100 Hz 是常见配置。位置环的 K_v 由低频段决定，采样率低一点不影响；但速度环的相位损失会通过串级结构传到位置环，必须按第

45 章的串级口径统一折算，不能各算各的。

3. **采样周期要避开对象的高频模态。** 若对象有一个 50 Hz 的谐振，而 $T_s = 0.02$ s（50 Hz 采样），谐振正好被混叠到零频附近，在数据里表现为“一个常值误差”。这种“假稳态误差”最难诊断——它看起来完全符合型别误差的特征，改变指令速度却不成比例。**遇到“误差不随速度变”的怪现象，先查采样与谐振的频率关系。**

42.6 稳定性与性能

42.6.1 一个旋钮，两笔账

第 41 章与本节的接点可以用一张图说清：把 K 从 0.08 扫到 1.3，同时画误差与相位裕度（图 42-7）。

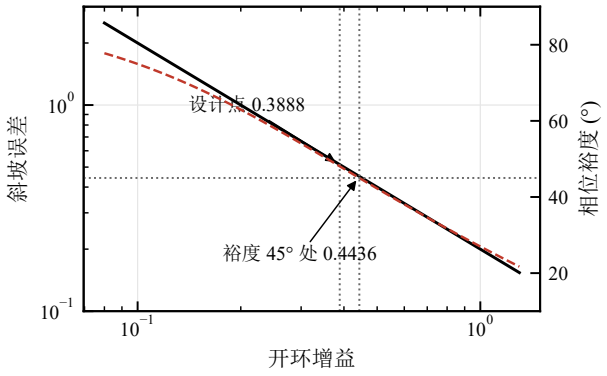

图 42-7　开环增益同时决定稳态误差与相位裕度

图 42-7 有两条线：左轴（对数）是 $e_{ss} = 1/(5K)$，单调下降；右轴是 φ_M，也单调下降。**两条线都随 K 下降，一条是好事，一条是坏事。**

图上标了两条竖线：$K = 0.3888$（第 41 章的设计点，$\varphi_M = 48.065^\circ$）与 $K = 0.4436$（$\varphi_M = 45^\circ$ 的位置）。两条线之间就是“误差还能再降、裕度还够用”的那一小段。

这张图的价值在于：**它把“设计”变成了“选点”。**只要两条曲线的形状定了，剩下的就是在两条约束之间找一个区间。区间有多宽，下一小节算。

42.6.2 兑换率：每 dB 换多少误差

从 $K = 0.3888$ 走到 $K = 0.5000$，增益涨 2.185 dB，误差从 0.5144 降到 0.4000，相对改善 22.2%。折成兑换率：

$$\frac{22.2\%}{2.185\ \text{dB}} = 10.18\%/\text{dB} \tag{42-14}$$

即**每加 1 dB 增益，斜坡误差降约一成。**这个数可以独立验算：$e_{ss} \propto 1/K$，所以每加 1 dB，误差降 $1 - 10^{-1/20} = 10.87\%$；而 2.185 dB 这一段折成每 dB 是 10.18%，比 10.87% 略低，原因是衰减率是**乘性**的：两段 1 dB 的效果是 $0.8913^2 = 0.7944$，不是 $1 - 2 \times 0.1087 = 0.7826$。**区间越长，平均兑换率越低。**

记住“每 dB 约一成”这个量级就够了，不必纠结小数点后两位——因为兑换率的另一半（裕度）本身也随工作点变化：小段是 $2.67^\circ/\text{dB}$，把误差压五倍那种大段只有 $2.43^\circ/\text{dB}$（§42.9.5 实测）。**兑换率是局部斜率，不是全局常数。**

“越远越低”这件事可以拿表 42-6 的三段直接量出来，都以 $K = 0.3888$ 为起点：

- 到 $K=0.5000$：增益 $+2.19$ dB，误差 $0.5144 \to 0.4000$（-22.2%），平均 $10.18\%/\mathrm{dB}$，裕度代价 $2.67^\circ/\mathrm{dB}$；
- 到 $K=0.7332$：增益 $+5.51$ dB，误差 $0.5144 \to 0.2728$（-47.0%），平均 $8.53\%/\mathrm{dB}$，裕度代价 $2.62^\circ/\mathrm{dB}$；
- 到 $K=1.1000$：增益 $+9.03$ dB，误差 $0.5144 \to 0.1818$（-64.7%），平均 $7.16\%/\mathrm{dB}$，裕度代价 $2.55^\circ/\mathrm{dB}$。

终点越远，平均兑换率越低：从 $10.18\%/\mathrm{dB}$ 一路降到 $7.16\%/\mathrm{dB}$，掉了三成。原因就是上面那个乘性关系——$e \propto 1/K$ 精确成立，所以“每 dB 降 10.87%”是逐点的常数，但把它在多 dB 的区间上做平均，得到的一定小于 10.87%。**拿一段短区间的斜率去外推长区间，会系统性高估收益。**

裕度那一列反而变化不大（$2.67 \to 2.55^\circ/\mathrm{dB}$）。两者的差别很实用：**误差随 dB 是指数衰减，裕度随 dB 近似是直线。** 所以外推误差要用 $10^{-\Delta/20}$ 这样的式子，外推裕度才可以直接拿斜率乘——把两者的算法弄混，误差会越推越乐观，裕度会越推越悲观。

兑换率的另一半是裕度。同一段增益，相位裕度从 48.065° 掉到 42.229°，即 $-2.67^\circ/\mathrm{dB}$。这个数与第 41 章 §41.8 的“$-2.6^\circ/\mathrm{dB}$”经验系数一致——**同一对象、同一段增益，两条路径得同一个数，说明两章的口径是通的。**

于是“用裕度换误差”可以写成一句可执行的话：

> 想让斜坡误差降一档（约 10%），就要准备付出 1 dB 增益与 2.7° 相位裕度。

如果当前裕度是 48°，能换的档数是 $(48-45)/2.7 \approx 1.1$ 档——**只剩一档可换**。这就是主例的设计窗口很窄的根本原因。

42.6.3 型别不是免费午餐

“型别抬一级，误差归零”听起来像免费午餐，实际不是。

代价一：固定相位滞后。 每个原点极点在全频段贡献 -90°。型 1 在 ω_c 处天然背着 -90°，型 2 背着 -180°。型 2 若不加零点，相位裕度必为负。

代价二：必须配零点，零点又带来高频增益。 型 2 算例的 $(1+2s)^2$ 把相位抬回 38.69°，代价是高频段幅频以 $+40$ dB/dec 上升，直到 $1/(0.1s+1)$ 的极点把它压回去。这期间的高频增益放大了噪声与未建模动态。

代价三：积分饱和与复位。 多一个积分器，就多一个“储能元件”。指令突变或限幅时，积分器会积累大量“欠账”，恢复时要慢慢还——这就是积分饱和。§42.8.4 会讲抗饱和的办法。

代价四：慢模态。 型 2 的闭环里通常有一对靠近虚轴的极点，衰减慢、易振荡。型 2 算例的调节过程明显比型 1 长，就是这个原因。

四条代价合起来，得到一条实践准则：**能用型别解决的问题，优先用型别；但型别最多抬到 2，再高就要考虑前馈或观测器了。**

四条代价在型 2 算例上都有数可查：闭环 $\varphi_M = 38.6887^\circ$、$G_M = \infty$、$\omega_c = 12.4838$，抛物线误差 0.2，慢模态 $-0.4941 \pm 0.0778\mathrm{j}$（时间常数约 2 s）。

其中 $\omega_c = 12.4838$ 这一项最容易被忽略。主例的 ω_c 是 1.5369，型 2 算例是它的 8.1 倍。按 §42.5.6 的准则 $\omega_c T_s \le 0.3$ 反算，采样周期必须小于 $0.3/12.4838 = 0.024$ s，比主例的 0.05 s 紧一倍多。**“多一个积分器”的**

账单上，除了相位，还有一行是“采样率”——型别抬得越高，穿越频率越容易往右跑，硬件成本跟着涨。

42.6.4 积分器吃掉的相位，与频率有关

同样是“加一个积分器”，代价大小取决于它加在哪个频段。积分器的相频是恒定的 -90°，但它**对穿越频率的影响**取决于积分时间常数。

具体说，PI 控制器 $C = K_p(1 + 1/(T_i s))$ 的零点在 $1/T_i$。当 $\omega_c \gg 1/T_i$ 时，积分器在 ω_c 处已经被零点“抬”回来了，附加相位接近 0；当 $\omega_c \ll 1/T_i$ 时，积分器在 ω_c 处仍是纯积分，附加相位接近 -90°。

第 41 章 §41.8.5 算过这个账：积分时间 3.25 s 与 0.5 s 相比，在同一个 ω_c 处附加相位是 -11.3° 与 -52.5°，差 41°。**同样叫“加积分”，代价可以差四倍。**

这个结论对本章的意义是：**“加积分消误差”这句话必须补上“积分时间选多大”**。选得太慢（T_i 大），消误差的作用在低频才生效，对斜坡误差的收敛速度慢；选得太快（T_i 小），相位吃得多，裕度掉得快。

主例的 PI 对照（§42.7.5 表 42-12）给了三档实测：$K_i = 0.2$ 时相位裕度 22.933°、恢复时间 19.19 s；$K_i = 0.5$ 时 16.811°、7.94 s；$K_i = 1.0$ 时 7.082°、20.08 s。**中间那档最好**，两头都差——这是“积分增益有最优值”的直接证据。

这三档的相位损失不是“感觉”，可以拿式子算准。PI 写成 $C = K_p(1 + \omega_z/s)$，零点在 $\omega_z = K_i/K_p$，它在 ω 处贡献的附加滞后是 $90^\circ - \arctan(\omega/\omega_z)$。三档的零点位置与穿越频率分别是：

- $K_i = 0.2$：$\omega_z = 0.2$、$\omega_c = 2.8502$，比值 14.25，理论滞后 4.02°；
- $K_i = 0.5$：$\omega_z = 0.5$、$\omega_c = 2.8713$，比值 5.74，理论滞后 9.88°；
- $K_i = 1.0$：$\omega_z = 1.0$、$\omega_c = 2.9394$，比值 2.94，理论滞后 18.8°。

拿纯比例 $K_p = 1$ 的 $\varphi_M = 26.997^\circ$ 作基准相减，实测损失是 4.06°、10.19°、19.92°，**与理论值逐档相差不到 1.1°**。这条对照说明：积分器的相位代价完全由“零点离穿越频率多远”决定，与 K_i 的绝对值没有直接关系。

顺带就把那句工程经验解释了：**“积分零点放在穿越频率的 $1/5$ 以下”，对应的附加滞后是 11.3°**（$\arctan 5 = 78.7^\circ$）。这就是 §41.8.5 里“积分时间 3.25 s 与 0.5 s 差 41°”的来源——两者零点离 ω_c 的距离差了一个数量级。

42.6.5 误差与超调，是两个频段的指标

初学者常把“稳态误差小”与“响应好”当成一回事。它们是两个频段的指标：

- **稳态误差看低频**（$\omega \to 0$），由型别与低频增益决定；
- **超调与调节时间看中频**（$\omega \approx \omega_c$），由相位裕度与闭环阻尼决定。

两者可以同时好，也可以一个很好另一个很差。表 42-6 的第三档与第五档就是例子：

- $K = 0.3888$：$e_{ss} = 0.5144$，$\varphi_M = 48.065^\circ$，超调 19.9%（第 41 章实测）；
- $K = 0.7332$：$e_{ss} = 0.2728$（好一倍），$\varphi_M = 33.608^\circ$，超调会明显超过 30%。

误差减半，超调翻倍，这是同一旋钮在两个频段的两种表现。工程上如果指标同时给了“稳态误差”与“超调”，就必须找一个折中点，而不是分别优化。

中频这一半还有一个更好用的刻度：**灵敏度峰值** $M_s = \max|S(\mathrm{j}\omega)|$（§42.9.6）。实测三档：$K = 0.3110$ 时 $M_s = 1.4872$（3.45 dB），$K = 0.3888$ 时 1.5952（4.06 dB），$K = 0.5000$ 时 1.7494（4.86 dB）。

三档与超调同向变化：$K=0.3888$ 对应的超调是 19.9%，$K=0.5000$ 更大。

M_s 的好处是它**只需要开环频率特性就能算**，不需要跑阶跃响应。工程上常用的判据是 $M_s \le 2$（6 dB）：超过 2 说明闭环对模型误差已经很敏感。主例的 1.5952 落在"能用但不出色"的区间——这与 48.065° 的裕度是一致的，两个刻度在同一个点上给出同一个判断。**所以验收时可以三选一：看裕度、看超调、看 M_s，它们说的是同一件事。**

42.6.6 三档验收线，主例只剩 10% 的窗口

把两条约束写成不等式，就能算出设计窗口：

- 误差要求：$e_{ss}=1/(5K)\le 0.5 \Rightarrow K\ge 0.4000$；
- 裕度要求：$\varphi_M\ge 45^\circ \Rightarrow K\le 0.4436$。

两条一夹，可用区间是 $K\in[0.4000,\,0.4436]$，宽度 0.0436，相对宽度 10.9%。对应误差区间 $[0.4509,\,0.5000]$。

这就是"稳"与"准"两笔账同时算清的结论：主例的可用增益窗口只有一成宽。 第 41 章单独看裕度，会觉得 K 从 0.1 到 4.4 都能用；本章单独看误差，会觉得 K 越大越好。两条一起看，才知道真正能站的地方有多窄。

窗口窄带来两个工程后果：

1. **参数漂移容易把设计点推出窗口。** 设计点取窗口中点 $K=0.42$，对象增益随温度变 $\pm10\%$，K 就跑到 0.378 或 0.462。前者误差 $1/(5\times0.378)=0.5291$，超指标 5.8%；后者实测 $\varphi_M=44.055^\circ$，差 45° 不到 1°。**两端同时破线，没有一端是安全的**——这就是"窗口只有一成宽"的实际含义。
2. **必须靠"改结构"而不是"调参数"来扩窗口。** 加零点可以把 φ_M 曲线整体右移（同误差下裕度更高），这就是第 43 章超前校正要解决的问题。

窗口宽度对指标非常敏感，值得算一次。把误差指标从 0.5 放松到 0.6，$K_{\min}$ 从 $1/(5\times0.5)=0.4000$ 降到 $1/(5\times0.6)=0.3333$，窗口从 $[0.4000,0.4436]$ 变成 $[0.3333,0.4436]$，宽度从 0.0436 变成 0.1103——**指标松 20%，窗口宽 2.5 倍。** 反过来，指标收紧到 0.45，$K_{\min}=0.4444$ 已经大于 $K_{\max}=0.4436$，**窗口直接消失**：这个指标在这个对象上无解，必须改结构。

这条敏感性说明一件事：**"窗口窄"往往不是设计者手艺差，而是指标本身就贴着物理极限。** 遇到这种情况，正确的动作是回去和指标方谈"能不能放松到 0.6"，而不是在 0.0436 的缝里反复试参数。

三档验收线的完整写法（供第 44、47 章引用）：

表 42-11　稳态误差与裕度的联合验收线（主例）

项目	门限	主例实测（$K=0.3888$）	判定
闭环稳定	极点全在左半平面	稳定	过
相位裕度	$\ge 45^\circ$	48.065°	过
增益裕度	≥ 6 dB	21.075 dB	过
斜坡误差	≤ 0.5	0.5144	不过
超调	$\le 25\%$	19.9%	过

表 42-11 最后两行值得注意：$K=0.3888$ 这个第 41 章选定的设计点，**在误差这一项上其实是不过线的**（$0.5144>0.5$）。要过线得把 K 提到 0.4000 以上，实测该点 $\varphi_M=47.404^\circ$、$G_M=20.828$ dB、$\omega_c=1.5688$ rad/s，仍然安全。

这个“小矛盾”恰好说明两章必须合看：**第 41 章按裕度选点，本章按误差校核，校核不过就微调。** 单看任何一章都会漏。

42.7 参数意义与作用

42.7.1 比例增益：只对型 0 有效

K_p 对稳态误差的作用，取决于系统的型别，这一点必须分清：

- **型 0 系统**：$e_{ss}=1/(1+K_p)$。K_p 从 1 加到 9，误差从 0.5 降到 0.1；加到 99，降到 0.01。**加大 K_p 有用，但永远到不了零。**
- **型 1 及以上的系统**：阶跃误差恒为零，与 K_p 无关。K_p 只影响 K_v（$K_v=5K$ 里的 K 就含 K_p），从而影响**斜坡**误差。

表 42-4 的型 0 算例就是第一种情况：$K_p=10$，$e_{ss}=1/11=0.0909$。想把误差压到 0.01，按公式要 $K_p=99$——但那个对象根本加不到这么大。

它的临界值是实测出来的：控制器取纯比例 $C=K_p$、K_p 从 10^{-3} 起二分，临界点是 $K_p=1.9800$，对应环路低频增益 19.80；越过这个点，闭环出现右半平面极点，稳态误差这个词就不再有意义。临界点上的静差是 $1/(1+19.80)=0.0481$，也就是**这个对象靠比例增益能压到的极限约 4.8%**，与目标 0.01 差近五倍，与 $K_p=99$ 差两个数量级。

这条算术给出型 0 的困境：**环路增益每加一倍，静差减不到一半；而环路增益加到 19.8 就失稳。** $1/(1+K_p)$ 这条曲线是双曲线，增益的“边际收益”在增益变大时迅速衰减——K_p 从 1 加到 9，误差从 0.5 降到 0.1（五倍收益）；再从 9 加到 19.8，只从 0.1 降到 0.0481（两倍收益），而这一段已经把全部稳定余量用光了。

所以型 0 系统的正解不是“把 K_p 加到最大”，而是“加一个积分器，把型别抬到 1”。**型别解决的是“归不归零”，增益只能在“归零之前”做有限的补救。** §42.7.2 就讲这个转换。

42.7.2 积分增益：把型别抬一级

K_i 的作用不是“把误差压小”，而是“把型别抬高”。加一个 $1/s$：

- 型 0 → 型 1：阶跃误差从 $1/(1+K_p)$ 变成 0；
- 型 1 → 型 2：斜坡误差从 $1/K_v$ 变成 0。

这个作用是**定性**的，不是定量的。一旦型别够了，再加大 K_i 只会让收敛更快、振荡更多，不会让误差更小。

严格说，只要 $K_i>0$，型别就 $+1$，与 K_i 具体多大无关。K_i 决定的是另外两件事：**积分作用从多低的频率开始生效**（零点 $\omega_z=K_i/K_p$），以及**收敛到零有多快**。K_i 太小，零点太低，积分在穿越频率附近几乎不起作用，误差要很久才归零——表 42-12 里 $K_i=0.2$ 的恢复时间 19.19 s 就是这个原因；K_i 太大，零点顶到 ω_c 附近，相位吃掉近 20°，裕度掉到 7°。

代价前面算过：积分器在 ω_c 处贡献 -90°（若零点远离）到 -10°（若零点靠近）不等的相位滞后。主例 PI 三档的相位裕度从 22.933° 掉到 7.082°（表 42-12），说明 K_i 一大，裕度就吃紧。

除了相位，积分器还有两笔不写在传递函数上的账。**第一笔是噪声的随机游走**：积分器对白噪声的响应是“随机游走”，输出会在均值附近缓慢地漂，漂的方差随时间线性增长。所以同一个 K_i，在干净的仿真里表现很好，在带测量噪声的现场会表现为“零点缓慢爬动”。**第二笔是它对“慢扰动”的免疫力也有边界**：常值扰动被积到零，斜坡扰动只被压成常值（不是零），正弦扰动完全压不住。这三条合起来，就是 §42.7.4 那张“扰动阶次表”的由来。

所以调 K_i 的正确问法不是“加到多大误差才为零”——只要 $K_i>0$ 就已经为零了——而是“**零点放在哪，让归零的速度够快、相位吃得起、噪声不放大**”。这三个要求互相冲突，交点就是表 42-12 里那个 $K_i\approx 0.5$。

这也解释了一个常见的设计误区：**把 K_i 当成“误差旋钮”来调**。K_i 管的是“型别”和“收敛速度”，不是“误差大小”；误差大小在型别确定之后由 K_p（也就是 K_v）决定。调错了旋钮，越调越乱。

42.7.3 微分增益：对稳态误差没有作用

K_d 对稳态误差的作用是**零**。原因是微分项在 $s\to 0$ 时趋于零：$K_d s$ 在 $s=0$ 处等于 0，不改变 $L(0)$、$\lim sL(s)$、$\lim s^2L(s)$ 中任何一个。

但这不意味着 K_d 无用。它的作用是**让系统更快进入稳态**：微分项提供相位超前，把相位裕度抬起来，于是可以承受更大的 K_p 或 K_i，从而间接压低误差。

一句话：**K_d 不改稳态，只改“到达稳态的路”**。这条区分很重要——现场遇到“稳态差”，调 K_d 是白费力气；遇到“到不了稳态”（振荡不停），调 K_d 才对症。

有两笔账要算清，免得把 K_d 当成万能药。

第一笔是好处。 微分项 $K_d s$ 在 ω_c 处贡献超前相位 $+\arctan(\omega_c T_d)$，其中 $T_d=K_d/K_p$ 是微分时间。要补 20°，需要 $\omega_c T_d=\tan 20^\circ=0.364$；主例 $\omega_c=1.5369$，即 $T_d=0.237$ s。补上的这 20° 可以换成“把 K_p 再提一档”的余地——这就是“K_d 间接压误差”的机制。

第二笔是代价。 微分增益随频率线性增长，$|K_d\mathrm{j}\omega|=K_d\omega$，在噪声频段（往往是几百 rad/s）被放大几十倍。编码器噪声、PWM 纹波都会顺着这条通道进到控制量里，表现为“执行器发热、声音刺耳、定位时抖”。所以实用做法是“带滤波的微分”：$K_d s/(1+T_f s)$，T_f 取 T_d 的 $1/5\sim 1/10$，把高频增益压回去，代价是在高频段少补一点相位。

这两笔账可以算成具体的数。上面那组参数（$T_d=0.237$ s，补 20°）在 100 rad/s 处的微分增益是 $0.237\times 100=23.7$，即 27.5 dB——**噪声在这个频段被放大 23 倍**。加一阶滤波、取 $T_f=T_d/10=0.0237$ s 之后，同一频点的增益变成 $23.7/\sqrt{1+2.37^2}=9.2$，即 19.3 dB，压下去 8.2 dB。

代价也在同一处显形：滤波后的相位是 $\arctan(23.7)-\arctan(2.37)=87.58^\circ-67.13^\circ=20.45^\circ$，在 100 rad/s 处只剩 20° 的超前（原来是 87.6°）。好在穿越频率处损失很小：$\omega_c T_f=0.0364$，滤波只吃掉 2.1°，超前从 20° 降到 17.9°。**这就是“滤波取 $T_d/10$”这条经验值的来历——它把 8.2 dB 的噪声压下去，只花 2.1° 的裕度。**

一句话总结三个参数的分工：K_p 管“差多少”，K_i 管“归不归零、多快归零”，K_d 管“路上稳不稳”。 三者各管一段，互相不能替代。

42.7.4 扰动进入点决定要不要积分

图 42-8 是一个必须记住的对照实验：同一个对象 $G=10/[s(s+2)(0.05s+1)]$，分别用 P 与 PI，分别加输入端扰动与输出端扰动。

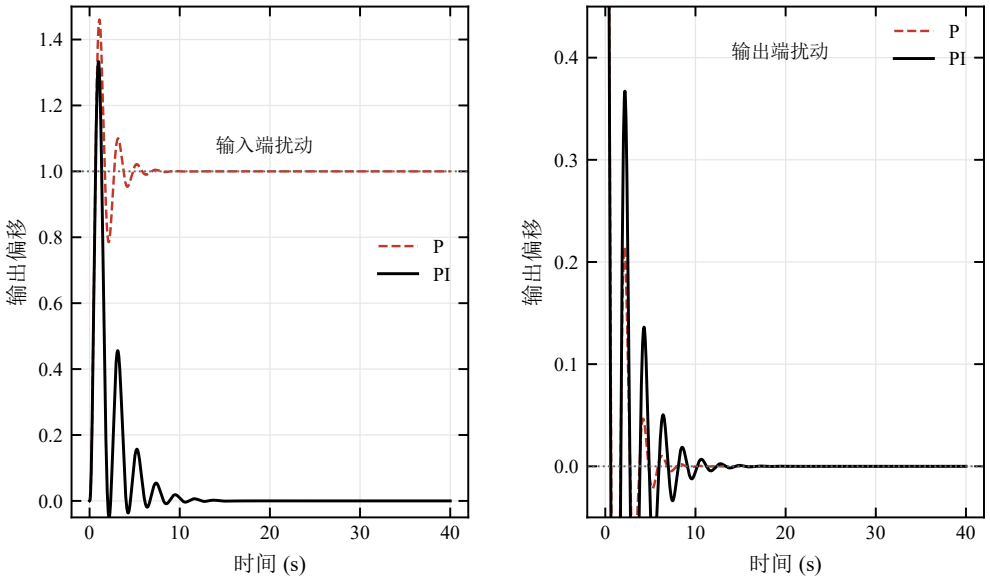

图 42-8　P 与 PI 对输入端、输出端扰动的响应

四组数据的结论是：

- **输入端扰动 + P**：Y/D_{in} 的直流增益 1，阶跃扰动 $d=1$ 后输出偏移到 1.0000，**误差等于扰动本身**。
- **输入端扰动 + PI**：Y/D_{in} 的直流增益 0，输出回到 -0.0000，**扰动被完全抑制**，代价是峰值 1.3330 的过渡过程。
- **输出端扰动 + P**：Y/D_{out} 的直流增益 0，扰动被抑制——**因为对象本身含积分器**。
- **输出端扰动 + PI**：同样为 0，抑制得更快。

第三行是最容易被忽略的一条：**对象自带积分器时，输出端扰动天然被抑制，不需要控制器再加积分。**很多“伺服系统输出端加干扰仍有偏差”的案例，问题不在控制器，而在“干扰其实是从输入端进的”（比如摩擦力、重力分量）。

判别方法很实用：**看干扰的作用点与控制量之间有没有积分器。**有，就被抑制；没有，就必须靠控制器补。

但“被抑制”只对**常值**扰动成立。扰动的阶次与指令一样重要：

- **常值扰动**（摩擦、重力分量、固定风载）：型 1 对象 + 比例控制给出 d/K_p，加积分压到零；
- **斜坡扰动**（线性增长的风载、持续漏损的液位）：常值偏移变成线性漂移，要两个积分才压得住；
- **正弦扰动**（转子不平衡、往复惯性力）：偏移是同频正弦，幅值等于 $|G(\mathrm{j}\omega)/[1+CG(\mathrm{j}\omega)]|$ 乘扰动幅值，永远不为零，只能压小；要压到零得上谐振控制器（第 49 章）。

这张清单与表 42-2 完全同构：**扰动的阶次与指令的阶次，在“需要几个积分”这件事上是等价的。**内部模型原理在这里第二次显形——控制器要“记住”的不只是指令怎么变，还有扰动怎么变。

42.7.5 积分增益三档实测

把 PI 的 K_i 取三档，测扰动恢复过程，结果见表 42-12。

表 42-12　PI 积分增益对扰动恢复的影响（$K_p=1$，阶跃扰动）

K_i	φ_M (°)	G_M (dB)	峰值	2% 恢复时间 (s)
0.20	22.933	11.857	1.4034	19.19
0.50	16.811	10.076	1.3330	7.94
1.00	7.082	5.933	1.2417	20.08

这张表最值得看的是**恢复时间的非单调**：K_i 从 0.2 加到 1.0（5 倍），恢复时间先降（$19.19 \to 7.94$）后升（$\to 20.08$）。

原因不难理解：K_i 太小时，积分作用弱，把偏差“拉回来”的力不够，恢复慢；K_i 太大时，积分作用过强，系统在目标附近来回振荡，虽然第一次进带更早，但**最后一次出带更晚**，按“此后不再出带”的定义，恢复时间反而变长。表里的 2% 恢复时间是“最后一次出带”，所以捕捉到了这个振荡。

同时，峰值从 1.4034 降到 1.2417——**超调在变小，振荡在变多**，两个指标方向相反。这是典型的“积分增益有最优值”：主例这个工况下，$K_i \approx 0.5$ 附近最好。

还有一个信号必须注意：$K_i = 1.0$ 时相位裕度只剩 $7.082°$、增益裕度 5.933 dB，**已经进入“随时可能被扰动推到失稳”的区域**。虽然仿真里还稳定，但工程上不该这么设计。

42.7.6 参数—型别—误差，一张表收口

表 42-13　三个参数对稳态误差的作用方向

参数	对型别	对 K_v	对斜坡误差	对相位裕度	主要代价
K_p ↑	不变	线性增大	双曲线下降	下降	超调、噪声放大
K_i ↑	$+1$（一次）	增大	降为零（型别足够后无影响）	明显下降	振荡、积分饱和
K_d ↑	不变	不变	不变	上升	噪声放大、微分冲击

表的用法是“对症下药”：

- 误差是常数、且系统是型 0 → 先加 K_i，不要先加 K_p；
- 误差是常数、系统已是型 1 → 加 K_p 或 K_i 都行，看裕度哪个更宽；
- 误差在振荡中缓慢减小 → 不是稳态误差问题，是阻尼不够，调 K_d；
- 误差随速度线性增长 → 型别差一级，加积分。

表 42-13 最后一列是提醒：每一行都有代价，没有“只涨不跌”的参数。

42.8 调参方法与经验

42.8.1 先定型别，再谈增益

调参的第一步不是“把 K_p 加到多少”，而是“这个回路该是几型”。

判据来自指标里的输入形状：

- 只要求“停得住”（阶跃定位）→ 型 1 够；
- 要求“匀速跟得住”（斜坡、传送带、匀速扫描）→ 型 1 可以但要算 K_v，型 2 才能归零；

- 要求“匀加速跟得住”（抛物线轨迹、启动段）→ 型 2 起。

先定型别，是因为型别决定“误差能不能归零”，而增益只能决定“归零前有多接近”。 型别选错了，后面所有调参都是白费。

42.8.2 由指标反算 K_v

指标给定之后，反算很直接：

$$K_v \geq \frac{1}{e_{ss,\text{target}}} \tag{42-15}$$

主例 $K_v = 5K$，若要求 $e_{ss} \leq 0.5$，则 $K_v \geq 2$，即 $K \geq 0.4$；若要求 $e_{ss} \leq 0.3$，则 $K_v \geq 3.33$，即 $K \geq 0.667$。

反算完必须做一次裕度校核。实跑 $K = 0.6670$ 给出 $\varphi_M = 35.696^\circ$、$G_M = 16.387$ dB、$e_{ss} = 0.2999$，**裕度比 45° 的底线低 9.3°**。结论很清楚：

> **“误差 ≤ 0.3”这个指标，靠调 K 是实现不了的，必须改结构。**

这就是反算的价值：它能在动手之前就告诉你“这条路走不通”，而不是调到一半才发现裕度不够。

把三档指标一起反算，能看到“可行性的分界”长什么样：

- 指标 1.0：$K \geq 0.2$，实跑该点 $\varphi_M = 62.946^\circ$，宽裕；
- 指标 0.5：$K \geq 0.4$，可行窗口 $[0.4000,\ 0.4436]$，只有一成宽（§42.6.6）；
- 指标 0.3：$K \geq 0.667$，实跑 $\varphi_M = 35.696^\circ$，已经不可行。

指标从 0.5 收紧到 0.3，不是“难一点”，而是“从可解变成无解”。 反算式的用处就在这里：它给出的不只是一个增益值，还有一个“这个指标到底有没有解”的判断。现场谈判时，这个判断比任何调参技巧都值钱。

反算还有两个容易忽略的细节。第一，式 (42-15) 里的 e_{ss} 是**绝对误差**，而指标常常写成“行程的 1%”；如果行程是 100 mm，1% 就是 1 mm，代进公式得 $K_v \geq 1$，而不是 $K_v \geq 100$。第二，$K_v = 5K$ 里的那个 5 是对象自己的尾一化增益，换一个对象就变——**反算的第一个动作永远是“把 K_v 与 K 的关系写清楚”**，而不是直接套 $1/e_{ss}$。

42.8.3 加积分的三种做法

同样的“加一个积分器”，工程上有三种实现，效果与代价不同：

做法一：串联 PI。 $C = K_p\bigl(1 + 1/(T_i s)\bigr)$。结构最简单，零点位置由 T_i 独立调节。缺点：零点固定，不能随便挪到想要的位置。

做法二：并联 PI + 滤波。 $C = K_p + K_i/s$，再串一个一阶低通抑制高频。灵活，但参数之间耦合，调一个动两个。

做法三：前馈 + 比例。 不用积分器，直接把指令的导数前馈进来（§42.9.1），用“预知”代替“累积”。理论上可以做到零误差，实际受模型精度限制。优点是**不引入相位滞后**，裕度不损失。

三种做法的选择标准：

- 指令可预知（数控、机器人轨迹）→ 优先做法三；

- 指令不可预知（随动、抗扰）→ 做法一或二；
- 裕度已经很紧 → 只能做法三。

42.8.4 抗饱和：积分器的必要配套

加了积分器就必须加抗饱和，否则一次大幅指令就能让积分器“记下一笔还不完的账”。

三种常用手法：

1. **积分限幅**：把积分项的输出限制在 $[u_{\min}, u_{\max}]$ 内。实现最简单，效果够用。
2. **条件积分（clamping）**：当控制器输出已经饱和、且误差方向会加剧饱和时，停止积分。逻辑是“饱和期间不记账”。
3. **反计算（back-calculation）**：把“实际输出与期望输出之差”乘一个系数反馈回积分器，让它自动退饱和。效果最好，参数最难调。

本章的仿真里，`simulate_discrete` 的控制器状态用**未限幅输出**推进，模拟真实积分饱和。这样做的目的是让“饱和的后果”能在数据里显出来，而不是被理想化掉。§42.10 的量化算例里，PI 的极限环就是在这种真实推进下产生的。

42.8.5 经验数字

下面这些区间来自工业实践，可作为初稿，不能当标准：

表 42-14　稳态误差与相关参数的常用区间

场景	型别	K_v 量级	φ_M 目标	备注
一般过程控制（温度、液位）	0 或 1	$1 \sim 5$	$45^\circ \sim 60^\circ$	允许较大稳态误差
电机速度环	1	$10 \sim 50$	$50^\circ \sim 60^\circ$	带宽高，需抗饱和
位置伺服	1	$20 \sim 100$	$45^\circ \sim 55^\circ$	常配速度前馈
轨迹跟踪（数控）	1 或 2	> 100	$40^\circ \sim 50^\circ$	前馈为主

表 42-14 里 K_v 的量级跨度很大，原因不是“标准不同”，而是**量纲不同**：K_v 的单位是 $1/\mathrm{s}$，但“1 个单位”在不同系统里含义完全不同（1 mm、1 rad、1 摄氏度）。**比较 K_v 只能在同一个系统内部比，跨系统比没有意义。**

真正可跨系统比较的是**无量纲量**：e_{ss} 相对于指令幅值的百分比。这也是现场指标通常写成“误差不超过行程的 1%”而不是“$K_v \geq 2$”的原因。

表 42-14 里那些量级也不是拍脑袋来的。型 1 回路的 K_v 与穿越频率同量级：主例六档的实测比值 K_v/ω_c 依次是 1.03、1.10、1.27、1.36、1.56、1.83，全部落在 $1 \sim 2$ 之间。**K_v 想大，带宽就得大**——这是两者共用同一个“低频增益”的必然结果。

这条关系把三个指标串成了一条链：要求 $K_v \geq 100$，就得有 $50 \sim 100$ rad/s 的带宽；按 $\omega_c T_s \leq 0.3$ 反算，采样周期必须小于 3 ms（333 Hz 以上）。**所以“数控要高 K_v”这句话落到硬件上，第一件事是换一块更快的控制器，而不是把参数表上的数字改大。** 表 42-14 的“轨迹跟踪 $K_v > 100$”之所以标着“前馈为主”，也是这个原因——用前馈绕开带宽，比硬提 K_v 便宜得多。

表 42-14 还可以拿主例做一次校准。主例的 $K_v = 1.9440$、$\omega_c = 1.5369$ rad/s（约 0.24 Hz）、$\varphi_M = 48.065^\circ$，按表只能归到“一般过程控制”那一行。这不是主例的设计做得差，而是它的对象时间常数本来就是秒

级：执行器 0.05 s、机械极点 -2 rad/s，**它压根不是伺服对象**。拿“位置伺服 K_v 要 $20\sim100$”去要求它，唯一的办法是把带宽抬上去，而带宽一抬，T_s 就得跟着降——三条经验线是同一根链上的三个环。

反向读也有用。若有人报“$K_v=50$、位置伺服”，先问带宽：按本章实测的 $K_v/\omega_c=1.03\sim1.83$ 反推，$K_v=50$ 对应 $\omega_c\approx27\sim48$ rad/s，再按 $\omega_c T_s\le0.3$ 要求 T_s 在 $6\sim11$ ms 以下。如果他的采样周期是 20 ms，这个 K_v 要么算错了，要么是空载、单轴、短行程测出来的——**三个数（K_v、带宽、采样周期）里只要有一个对不上，另外两个就可疑**。

42.8.6 现场三步验证

调完之后怎么确认“稳态误差真的达标”？三步：

第一步：静态验证。 给一个阶跃，等足够长时间，量终值与指令之差。这一步验的是“型别够不够”。

第二步：斜坡验证。 给一个恒定速度指令，等进入稳态，量误差。这一步验的是“K_v 够不够”。注意要等到误差稳定——主例的进入时间是 5.99 s，等 3 s 读数会偏小。

第三步：变速验证。 给两个不同速度，量两个误差，看比值是否等于速度比。这一步验的是“误差是不是真的来自型别”：如果两个速度下误差之比不等于速度之比，说明还有非线性项（摩擦、死区）在起作用，§42.10 会讲怎么分离。

三步都过，才能说“稳态误差达标”。只做第一步就下结论，是现场最常见的误判。

三步之外还有一步最容易被省掉：**反向再走一遍**。三步都在同一个方向做，看不出摩擦。表 42-18 的实测是：$K_p=0.5$ 时摩擦把稳态输出压偏 0.10000，$K_p=1.0$ 时偏 0.05000，$K_p=2.0$ 时偏 0.02500。这三档在把扰动符号翻过来（等价于反向走一遍）时，偏移就是同样的数取负号，正好可以互相印证；若只做正向，0.10000 会被当成“型别误差”，再拿去反算 K_v，得到一个根本不存在的 K_v。**方向是免费的第二个实验条件，不用白不用**。

42.9 优化与改进

42.9.1 前馈：把型别“借”过来

前馈（feedforward）是本章最有效的改进手段，因为它**不消耗相位裕度**。

结构上，在反馈回路之外并联一条从指令到控制量的通道：

$$u=K_p e+K_i\int e\,\mathrm{d}t+F(s)r \tag{42-16}$$

如果 $F(s)=1/G(s)$（对象模型的逆），则理论上 $e\equiv0$，与型别无关。因为此时控制器“预先知道”了对象需要什么输入，直接给出去，反馈只负责修正模型误差。

工程上前馈不会取完整的 $1/G(s)$（那需要微分，噪声放大严重），通常只取前两项：

- **速度前馈**：$F_1=1/K_v$ 量级，对付斜坡误差；
- **加速度前馈**：对付抛物线误差。

前馈的残余误差正比于**前馈增益的相对误差**：模型增益估高 10%，残余误差就是原误差的 10%。所以前馈的效果取决于建模精度，而不是控制器带宽。

这句话可以算出来，而且算出来的结果比“正比”两个字有信息量。主例的 $K=0.3888$、$K_v=1.9440$，无前馈时单位斜坡误差 0.5144；速度前馈的真值是 $F=1/5=0.2000$（对象的速度增益是 $10/2=5$）。把前馈增益按 0.8、0.9、1.0、1.1、1.2 倍拨动，实跑得到的稳态残余依次是 0.10288、0.05144、0.00000、-0.05144、-0.10288。

三件事值得说。**第一，残余与相对误差严格成正比**：偏 10% 就是原误差的 $1/10$，偏 20% 就是 $2/10$，中间没有“偏一点没关系”的缓冲带，也没有“偏多了就失效”的拐点。**第二，符号是有用的**：估低留正残余（输出滞后于指令），估高留负残余（输出超前），现场可以据此反推是哪一个参数估错了，这比“误差偏大”这句话具体得多。**第三，F 精确时 $t=20/40/80\ \mathrm{s}$ 三个时刻的误差都是 0.00000**，说明它不是“末段平均恰好抵消”，而是从进入斜坡段起就一直为零——这正是“前馈不改变闭环极点、只改变零点”的直接后果。

这组数最有说服力的地方在对照上：把 K_v 从 1.9440 提到 19.44（效果等同于把残余压到 $1/10$）需要把 K 提到 3.888，而实测 $K=3.888$ 时相位裕度只剩 2.049°——这已经不是“裕度偏小”，而是踩在稳定边界上。前馈只用 10% 的建模误差就换到了同样的精度，且完全不动相位。**“前馈不消耗裕度”这句话的定量版本就是这两个数：一个 -0.05144，一个 2.049°。**

这就是前馈的最大价值：它把“精度”从“增益与裕度的交换”变成了“建模精度的直接映射”。 建模准，前馈就准；建模不准，前馈也不添乱（最坏情况退化为无前馈）。

42.9.2 重复控制与谐振控制的位置

如果指令是周期性的（旋转机械、扫描机构），“型别”这套语言就不够用了，要用**重复控制**或**谐振控制**。

它们的本质是把内部模型原理用到周期信号上：在控制器里植入 $1/(1-\mathrm{e}^{-T_d s})$（重复控制）或 $1/(s^2+\omega^2)$（谐振控制），从而对该频率（及其谐波）实现零稳态误差。

本章不展开，只标出边界：**表 42-2 的“多项式输入”是本章的适用范围，周期输入要转到第 49 章。** 两者的判据相同（内部模型），实现手段不同。

为什么型别语言在周期输入下必然失效，用一句话可以说清：积分器只把 $\omega\to 0$ 的 $|S|$ 压到零，而周期输入的能量集中在一个**非零频率**上。主例的实测已经给了答案——$\omega=1$ 处 $|S|=0.65805$。把型别再抬高，只会把更低的频段继续压低，$\omega=1$ 落在穿越频率附近，那里的 $|S|$ 由峰值决定、不为零。**型别管的是原点，周期控制管的是一个圈。**

重复控制还有一个本章没有涉及的硬约束：它要“记住一整个周期”，需要 $N=T_d/T_s$ 个采样点的存储。以 50 Hz 为例，周期 0.02 s，若采样周期取 0.02 s，$N=1$，根本谈不上“记忆”；取 0.001 s，$N=20$，也只是勉强；工程上通常要 N 在几百以上，对应 $100\ \mu$s 量级的采样。**这比 $\omega_c T_s\le 0.3$ 的采样要求严一个数量级**，是周期控制真正的落地门槛。

42.9.3 增益调度：变型别的系统

有些系统的型别会随工况变化：比如带死区的阀，在小信号时“像型 0”，大信号时“像型 1”。这时固定参数的控制器无法同时满足两种工况。

增益调度（gain scheduling）的做法是按工况切换参数：

- 小信号段：加大 K_i，把“准型 0”补成型 1；
- 大信号段：减小 K_i，避免积分饱和。

切换的判据要平滑（用误差或指令幅值做插值），否则切换瞬间会产生扰动。**这是“变型别”系统的标准处理，代价是参数表变成二维（工况 × 参数）。**

42.9.4 观测器与内模：把“看不见的误差”补回来

有些误差不在输出端，而在中间变量上：比如负载端的转角（编码器在电机端）、丝杠的温漂、传动链的间隙。这些误差用本章的“输出误差”框架看不到。

两种补法：

- **观测器**：用可测的电机转角与电流估计负载端转角，把估计值反馈回去，等效于“把反馈点前移到负载端”；
- **内模**：在控制器里植入“干扰的模型”，让控制器自己估计并抵消。

两者的共同点是**用模型补测量**。代价是模型不准时会引入新的误差，所以必须有鲁棒性设计（第 50 章）。

42.9.5 不要用高增益硬扛

最后一条改进建议是“减法”：**不要用高增益去硬扛稳态误差。**

理由已经算过（§42.6.2）：每加 1 dB 增益，误差只降约一成。把这个兑换率外推到“误差降五倍”这样的幅度，代价立刻现形。

算一遍：误差从 0.5144 压到 0.1029（五倍），需要 K 从 0.3888 涨到 1.9440，即 $+13.98$ dB。按小段兑换率 $-2.67^\circ/\mathrm{dB}$ 估，裕度要掉 37°，从 48.065° 掉到 11° 上下；实测该点 $\varphi_M = 14.088^\circ$、$G_M = 7.095$ dB。**两者都跌破底线，而且离失稳只差一步。**

实测比线性外推“好看”三度，原因是裕度曲线是上凸的：增益越大，相位裕度掉得越慢。反算平均兑换率，$33.98^\circ/13.98\ \mathrm{dB} = 2.43^\circ/\mathrm{dB}$，比小段的 $2.67^\circ/\mathrm{dB}$ 略低。**这个“非线性”不能当成侥幸**——它只能把 11° 变成 14°，改变不了结论：靠增益把误差压五倍，必然把系统推到失稳边缘。

正确的顺序是：

1. 先用型别把“该归零的”归零；
2. 再用前馈把“能预知的”预知掉；
3. 最后才用增益微调残余的那一点点。

这个顺序的本质是“用信息换增益”：型别用的是“输入形状的信息”，前馈用的是“对象模型的信息”，增益用的是“什么都不用，只管加大”。信息越多，代价越小。

42.9.6 从静态系数到灵敏度曲线

前面所有指标都压在“稳态”两个字上，而稳态只是 $\omega \to 0$ 的那一个点。真正决定“跟得好不好”的，是整条低频段的灵敏度曲线：

$$S(\mathrm{j}\omega) = \frac{1}{1 + L(\mathrm{j}\omega)} \tag{42-17}$$

型 1 系统在低频有 $L \approx K_v/(\mathrm{j}\omega)$，代入即得

$$|S(\mathrm{j}\omega)| \approx \frac{\omega}{K_v} \qquad (\omega \ll \omega_c) \tag{42-18}$$

用主例（$K = 0.3888$、$K_v = 1.9440$、$\omega_c = 1.5369$）实测这条近似式，结果见表 42-15。

表 **42-15**　灵敏度幅值：实测与 $|S| \approx \omega/K_v$ 的对照（主例）

ω (rad/s)	$\lvert S\rvert$ 实测	ω/K_v	相对偏差
0.1	0.05158	0.05144	$+0.3\%$
0.5	0.27517	0.25720	$+7.0\%$
1.0	0.65805	0.51440	$+27.9\%$
2.0	1.56345	1.02881	$+52.0\%$

表 42-15 说明三件事。

第一，近似式只在“远低于带宽”时可信。 $\omega = 0.1$ 时偏差 0.3%，可以直接拿 K_v 反算误差；$\omega = 1$ 时偏差已经 28%，再用 $1/K_v$ 就会低估误差三分之一。$\omega_c = 1.5369$，$\omega = 1$ 只是 0.65 倍带宽，近似式就已经不够用了。

第二，低频斜率是“型别”的直接读数。 对数坐标下 $|S|$ 在低频是一条斜率 $+1$ 的直线，型 2 会是 $+2$，型 0 是 0（一条水平线）。用测量数据拟合这条直线的斜率，比“数原点极点”更适合现场——因为你不需要知道对象的传递函数，只需要扫频。

第三，峰值 $M_s = \max|S|$ 是鲁棒性的另一个刻度。 主例实测 $M_s = 1.5952$，即 4.06 dB，出现在 $\omega = 2.2152$（约 1.44 倍 ω_c）。同一条对象在 $K = 0.3110$ 时 $M_s = 1.4872$（3.45 dB）、带宽 2.1836；$K = 0.5000$ 时 $M_s = 1.7494$（4.86 dB）、带宽 3.0597。**增益每加一档，带宽涨、M_s 涨、误差降，三件事一起发生。**

有一个常用的换算值得记住：$M_s \approx 1/\sin\varphi_M$。代入 $\varphi_M = 48.065^\circ$ 得 1.3446，而实测是 1.5952，偏大 18.6%。偏大的原因是这个近似只对“单一大极点”的对象准，主例带了执行器极点 -20 与一对 $\zeta = 0.236$ 的复极点，高频段的相位掉得比一阶模型快，$|S|$ 的峰自然更高。**换算关系可以用来看趋势，不能用来报数。**

把三个指标放在一起，就是一张完整的“误差验收单”：

- e_{ss}（一个点）：稳态精度够不够；
- $|S|$ 的低频斜率（一段）：型别对不对、K_v 够不够；
- M_s（一个峰）：鲁棒性余量还有多少。

只报第一个数，等于只说“平均分及格”，不说“哪一门不及格”。

42.10 工程落地

42.10.1 三个非线性，一个折算

到这里为止，所有的误差都是“线性系统对多项式输入的响应”。真实设备上还有三个绕不过去的源：**死区、量化、摩擦**。它们的共同点是——都不在型别里，都在执行器或传感器上。

它们能被本章的公式处理，靠的是一个折算：**凡是“控制器不知道、又只与输入或输出有关”的力或偏置，都可以写成对象输入端的等效扰动 d**，然后套 §42.2 的扰动通道公式。本节三个算例全部按这个折算实现：摩擦写成恒定的 d，死区与量化写在执行器与反馈通道上，三者都进入同一个闭环。

但折算之后要立刻分成两类，因为**它们的误差性质完全不同**：

- **确定性偏移**：幅值固定、符号由工况决定（摩擦的方向由运动方向决定）。这类误差可以**报一个数**，也可以**补偿**。
- **不确定带**：符号与大小取决于“轨迹最后落在哪个格子里”（死区、量化）。这类误差只能**报一个区间**，不能报数，也没法用前馈补掉。

这条分界线是本节的主线。下面三小节各给一组实跑数据，最后一小节把它们合成一张预算表。

42.10.2 死区：只给带，不给数

死区的机理很直白：执行器输入 $|u| \le \Delta$ 时对象不动。比例控制下 $u = K_p e$，所以当误差落进

$$|e_{ss}| \le \frac{\Delta}{K_p} \tag{42-19}$$

这个带里，控制器就再也推不动对象了。式 (42-19) 是**上界**，不是等号。

实跑取主例对象、$K_p = 2$、$T_s = 0.02$，结果见表 42-16。

表 42-16　死区对稳态误差的影响（型 1 对象，$K_p = 2$，$T_s = 0.02\,\mathrm{s}$）

死区 Δ	理论带 $\pm\Delta/K_p$	实测 e（末段均值）	稳态 y	占带比例
0.00	± 0.00000	$+0.00000$	1.0000	—
0.02	± 0.01000	$+0.00978$	0.9902	97.8%
0.05	± 0.02500	-0.02338	1.0234	93.5%

表 42-16 最值得注意的是**符号变了**：$\Delta = 0.02$ 停在 $+0.00978$（$y = 0.9902$，偏低），$\Delta = 0.05$ 停在 -0.02338（$y = 1.0234$，偏高）。同样是“推不动”，一个偏左一个偏右。

原因在进带方向。误差从上方衰减下来时，第一次落进带内的位置偏正；如果带着超调从下方回上来，落点就偏负。$\Delta = 0.05$ 时环路推得更久、超调更大，于是从上方回落后停在了负侧。**所以死区误差的符号是轨迹的产物，不是系统的属性。**

图 42-9 左半是全过程，三条曲线都在几秒内衰减；右半放大到 $24 \sim 30\,\mathrm{s}$、纵轴 ± 0.035，两条虚线的位置正是 ± 0.025。

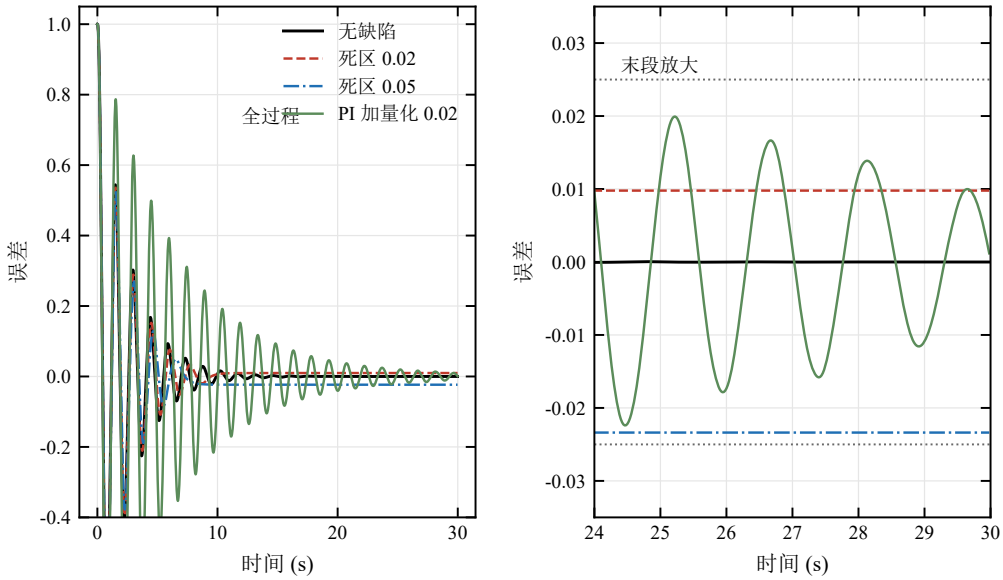

图 42-9　死区与量化造成的稳态误差与极限环

放大图上能看清“死区”三个字的本义：误差不是慢慢趋近零，而是**在某个非零值上完全冻住**，曲线是一条水平直线。这跟型别不够导致的“线性增长”、跟阻尼不足导致的“缓慢振荡”都不一样——它是一条平的、不为零的线。

工程上有三条应对，各有代价：

1. **加大 K_p**：带按 $1/K_p$ 变窄。从 $K_p = 2$ 加到 4，带从 ± 0.025 变成 ± 0.0125，但相位裕度要再掉十几度（§42.10.4 有实测）。
2. **减小 Δ**：改机械（消除间隙、换比例阀、提高预紧），一次性投入，最彻底。
3. **加抖动（dither）**：在输出上叠一个高频小幅信号，让执行器“始终在动”，把死区平均掉。代价是引入高频振动与噪声。

还要提醒一句：**死区系统加积分器，得到的往往不是零误差，而是“爬行”。** 积分器把误差积起来，输出慢慢爬升，冲出死区后一下推过头，误差反向，积分器再反向积分——形成低频的锯齿。这类现象在液压阀、压电陶瓷、齿轮传动上都很常见，现场常被误判为“积分参数没调好”。

死区还有一个近亲叫**间隙**（backlash），两者常被混为一谈，数学性质却不同。死区是**无记忆**的：u 落在带内，任何时刻都不产生运动。间隙是**有记忆**的：输出取决于“上一次接触的是哪一侧”，相当于一个带状态的滞环。后果是同一个输入下，正向与反向的误差可以差出整整一个空程宽度 b，而这个差值与 K_p 无关——**加增益压不平间隙，只能压平它的过渡过程**。

判别方法还是 §42.10.6 那一条：正反向各测一次。误差差一个常值（约等于空程）的是间隙；误差都落在同一个带内、符号随机的是死区。应对手段也不同：死区靠提增益或 dither，间隙只能靠机械预紧、双测（电机端与负载端各一个编码器）或反向越程补偿。

42.10.3 量化：静差变成极限环

量化的机理与死区不同：不是“推不动”，而是“看不清”。反馈量被舍入到 q 的整数倍，误差只能取离散值，等效于在反馈通道上叠了一个幅值不超过 $q/2$ 的偏置。

同一个对象、同一个 $K_p = 2$、同一采样周期，比例与 PI 两种控制器下各测三档量化，结果见表 42-17。

表 42-17　量化对稳态误差的影响（型 1 对象，$K_p = 2$，$T_s = 0.02$ s）

量化 q	P：e 均值	P：e 峰峰	PI：e 均值	PI：e 峰峰
0.000	0.00000	0.00004	—	—
0.005	-0.00050	0.00000	$+0.00010$	0.00891
0.020	$+0.00200$	0.00000	-0.00042	0.01717

这张表要横着读。

先看比例控制那一半。 峰峰是 0（除了 $q=0$ 时的 0.00004，那是数值噪声），说明误差**停在一个格点上不动**。均值是 -0.00050 与 $+0.00200$，恰好都是 q 的十分之一——注意不是理论上界 $q/2$。这个 $1/10$ 没有普适性：它取决于稳态点恰好落在格子的哪个位置，换一个参考值、换一个初始条件就会变。**能记住的只有量级：静差在 q 的十分之几以内。**

再看 PI 那一半。 均值被压到 $+0.00010$ 与 -0.00042，几乎是零——积分器确实把“平均偏差”抹平了。但峰峰涨到了 0.00891 与 0.01717，是 q 的一到两倍。

这就是本节最重要的一句话：积分器把静差换成了极限环。 平均意义上误差为零，瞬时意义上误差一直在 $\pm q/2$ 附近摆动。

量化 $q=0.02$ 这一档的对比最能说明问题：P 的静差是 0.00200，PI 的峰峰是 0.01717，后者是前者的 8.6 倍。**如果验收只看均值，PI 会拿到一张漂亮的数据单；但设备在抖，轴承在磨，噪声在传。**

图 42-9 里那条绿色的“PI 加量化 0.02”曲线，在右半放大图上就是一条持续的细锯齿。

应对量化的手段也有三条：

1. **提高分辨率**：编码器从 17 位换到 23 位，q 降 64 倍，最直接，也最贵。
2. **提高采样率**：让每个量化台阶对应更短的时间，锯齿频率升高、幅值不变，但更容易被机械惯量滤掉。
3. **反馈低通**：把锯齿滤平，代价是相位滞后，直接吃掉裕度——这条要按 §42.5 的方法算清楚再动。

42.10.4 摩擦：最“像”扰动的一种误差

库仑摩擦在速度反向时跳变，正反向大小相等、方向相反。它完全可以写成对象输入端的一个常值扰动 $d=-f_c\,\mathrm{sgn}(\dot y)$，因此**线性公式在这里是精确的**：

$$y_{ss}=\frac{d}{K_p}\qquad(\text{型 }1) \tag{42-20}$$

$$y_{ss}=\frac{d\,G_0}{1+K_pG_0}\qquad(\text{型 }0) \tag{42-21}$$

实跑取 $d=-0.05$、$T_s=0.02$、三档增益，型 1 的结果见表 42-18。

表 42-18　库仑摩擦的稳态偏移（型 1，$d=-0.05$）

K_p	φ_M (°)	实测 y（末段）	解析 d/K_p
0.5	42.229	-0.10000	-0.10000
1.0	26.997	-0.05000	-0.05000
2.0	13.571	-0.02500	-0.02500

四位小数完全吻合——这不是巧合，因为摩擦被写成了恒定的 d，而闭环对常值扰动的稳态响应就是 $d/C(0) = d/K_p$，式 (42-20) 是解析结果，仿真只是把它画出来。

图 42-10 把三条响应与三条解析横线画在一起：三条曲线从零出发，各自衰减到对应的横线上，**偏移与控制增益严格成反比**。

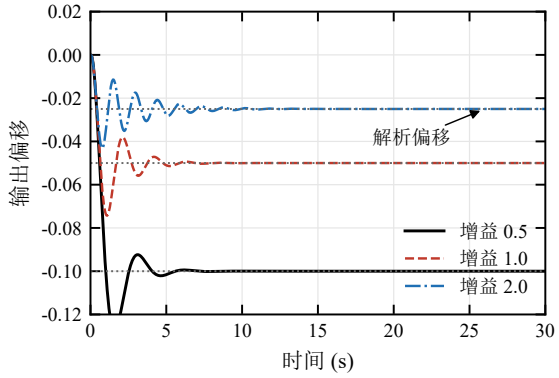

图 42-10　库仑摩擦的等效常值扰动：偏移与控制增益成反比

这张表同时是“精度换稳定”最直白的一张：K_p 从 0.5 加到 2.0（四倍），偏移从 0.10000 降到 0.02500（四分之一），相位裕度从 42.229° 掉到 13.571°。每一次加倍，裕度掉 $13^\circ \sim 15^\circ$。**用增益压摩擦误差，是按“每倍频程十几度”的价钱买的。**

型 0 对象上这一现象更严重，见表 42-19。

表 42-19　库仑摩擦的稳态偏移（型 0，$G_0 = 10$，$d = -0.05$）

K_p	开环增益	实测 y	解析 $dG_0/(1+K_pG_0)$
0.05	0.5	-0.33333	-0.33333
0.10	1.0	-0.25000	-0.25000
0.15	1.5	-0.20000	-0.20000

看解析式的两个端点就明白型 0 为什么“双输”：$K_p \to 0$ 时 $y_{ss} \to dG_0 = -0.5$（退化为开环偏移，减小增益没有用）；$K_p \to \infty$ 时才趋于零，但环路会失稳。**一头堵死、一头撞墙。**

还有一层工程细节必须提：上面的模型把摩擦写成“恒值”，真实摩擦在低速段是**随速度下降**的（Stribeck 曲线）。这一段负阻尼会让系统在极低速时产生“爬行—停顿—爬行”的循环，输出根本停不下来。这时候“稳态误差”这个概念本身就不成立了——不是误差不为零，而是**没有稳态**。判断方法是看低速段的位移—时间曲线：如果是一串台阶，就是爬行，不是稳态误差。

既然摩擦等价于常值扰动，它就可以被反过来辨识。做法是：让设备在同一位置、同一速度下正反各走一段，记录稳态驱动量 u_+ 与 u_-。惯性项与重力项在两次试验中相同、相减抵消，剩下的差就是摩擦的两倍：

$$f_c = \frac{|u_+ - u_-|}{2}$$

本文的算例可以当校核：$d = -0.05$、$K_p = 1$ 时偏移是 0.05000，按式 (42-20) 反推 $f_c = 0.05$，与设定一致。现场做这个试验有三个讲究：**同速、同位置、同负载**——速度不同会掺进粘性项，位置不同会掺进重力分量，负载不同则什么也说明不了。另外温度对润滑的影响很大，冷机与热机测出来的值可能差出一大截，报数时必须注明工况。

42.10.5 型 0 的底：4.8% 与 2.4%

§42.7.1 提过型 0 靠比例增益能压到的极限，这里把它和摩擦放在一起，给出两个具体的数。

实跑用二分法找临界增益：控制器取纯比例，K_p 从 10^{-3} 起二分 60 次，临界点是 $K_p = 1.9800$，对应环路低频增益 19.80。在这个点上：

- 阶跃静差 $= 1/(1+19.80) = 0.0481$，即约 4.8%；
- 摩擦偏移 $= 0.5/(1+19.80) = 0.0240$，即约 2.4%。

这两个数字合起来是一句很硬的话：**型 0 加纯比例，无论怎么调参，阶跃精度不会好于 4.8%，抗常值扰动的偏移不会好于 2.4%。** 再往上加增益就失稳，往下减增益两项都变差。

如果指标要求 1%，型 0 完全没有希望，只有三条路：

1. **加积分**：型别 $+1$，阶跃误差与常值扰动偏移同时归零。代价是相位，按 §42.6.4 的实测，K_i 取 1.0 时裕度只剩 7.082°。
2. **加前馈**：不消耗裕度，但需要模型与可预知的指令；对“抗扰动”这条路径无效，因为扰动不可预知。
3. **改对象**：把执行器换成带内部闭环的伺服单元（它自带积分），本质仍是第 1 条。

型别决定下限、增益只决定“离下限多近”，这句话在型 0 上有一个可以报出来的具体数字：4.8%。

42.10.6 现场判别与误差预算

现场拿到一条“误差超差”的曲线，怎么判断它是哪一类？四个动作，按顺序做，见表 42-20。

表 42-20　四步判别：误差来自哪一类源

动作	观察	判读
两个速度各测一次	误差比等于速度比	线性（型别/增益），按 $1/K_v$ 处理
两个速度各测一次	误差比不等于速度比	有非线性项，继续往下查
正反两个方向各测一次	大小相等、符号相反	摩擦（确定性偏移）
同一方向换几个位置	误差随位置变、符号随机	死区或间隙（不确定带）
看末段峰峰值	均值小、峰峰大	量化极限环或爬行

这张表的逻辑是：**先分“线性/非线性”，再分“确定/不确定”，最后分“静态/振荡”。** 每一步都只需要一次实验，不需要建模。

表 42-20 有两处容易读错。

一是“正反方向”这一行。 它默认摩擦的符号会随方向可靠翻转，而死区不会。本节的实测正好给出了反例：死区 $\Delta = 0.02$ 时末段均值是 $+0.00978$，$\Delta = 0.05$ 时却是 -0.02338——同一套控制器、同一个指令方向，符号自己翻了。所以“正反两次、大小相等、符号相反”只能说明**以摩擦为主**；若两次数值不等，就是摩擦与死区的混合，不能只按一个源处理。（§42.10.2 里间隙与死区的对比是同一道理：间隙有记忆、死区没有，所以间隙的符号还带路径依赖。）

二是“两个速度”这一行。 它隐含要求系统在型 1 以上。型 0 的斜坡误差不是常数，而是随时间线性增长的——§42.2.2 实测 $t = 20$ s 时 1.9504、斜率 0.0975 而不是 $1/11 = 0.0909$，此时“两个速度下的误差比”里还掺

着“测了多久”，永远对不上速度比。判线性要在型 1 及以上做，或者干脆改用阶跃：阶跃误差只与 K_p 有关，与测多久无关。

判完之后做预算。表 42-21 是主例的预算模板，四行的实测值全部来自本节的实跑。

表 42-21　主例的稳态误差预算（斜坡跟踪工况，量级估算）

误差源	理论式	实测/估算	性质	对策
型别与增益	$1/K_v$	0.5144	确定性	加型别、前馈、加增益
摩擦	d/K_p	0.0250	确定性	摩擦补偿、加积分
死区	$\pm\Delta/K_p$	0.0100	不确定	提增益、改机械、dither
量化	$\sim q/2$（上界）	0.0005	不确定	提分辨率、提采样率
采样	$1/(1-\delta)$ 放大	$\times 1.10$	确定性	提采样率

合成规则有两条：

- **确定性项代数相加**（符号相反时会抵消，所以必须知道符号）；
- **不确定项按绝对值相加**（最坏情况），或按方和根（统计意义）。

按最坏情况把前四行相加：$0.5144 + 0.0250 + 0.0100 + 0.0005 = 0.5499$，比理论值 0.5144 大 6.9%。**这 6.9% 就是“理论算得准、现场差一截”的常见来源。**

但要老实说明这个和的局限：四项取自不同实验（斜坡与阶跃、不同参考值），量级可比、严格叠加不成立；实际运行时摩擦与死区的符号还可能相互抵消。**预算表的作用是排优先级，不是精确求和。**

按占比排：型别与增益占 93.5%，摩擦占 4.5%，死区占 1.8%，量化不到 0.1%。

这个占比与 §42.3.6 那张预算表（摩擦 25%、死区 9.8%）看着矛盾，其实只是分母不同：那里的工况是 $K_v = 10$、型别误差 0.1，这里是设计点 $K_v = 1.9440$、误差 0.5144，分母大了五倍，占比自然小五倍。**同一个摩擦，在误差大的系统里占比小、在误差小的系统里占比大**——“摩擦可不可以忽略”从来不是绝对判断，而是相对于分母的判断。

所以改进的顺序非常清楚：**先把 K_v 提上去（或加前馈），再考虑摩擦补偿，最后才轮到死区与量化。**反过来做——先去换高分辨率编码器——投入最大、收益最小。

这就是“预算”两个字的意义：它把“把误差做小”这个含糊的目标，变成了一张有排序、有金额（代价）、有上限的清单。

42.11 优缺点与适用边界

42.11.1 优点：三个“可以”

稳态误差分析能在经典控制里活到现在，靠的是三个“可以”。

第一，可以算。 只要知道开环传递函数，K_v 就是一个除法，e_{ss} 就是它的倒数。本章所有算例的解析值与实跑值对照如下：型 1 斜坡的解析值 0.2，时域在 $t = 10/20/40$ s 给出 $0.1998/0.2000/0.2000$；型 2 抛物线的解析值 0.2，时域在 $t = 5/10/20$ s 给出 $0.1650/0.1959/0.2000$。

注意型 2 的 $t=5$ 差了 17.5%——这不是公式错，是**瞬态还没走完**。型 2 的慢模态是 $-0.4941\pm0.0778\mathrm{j}$，时间常数约 $2\,\mathrm{s}$，而抛物线误差本身还在以 t/K_a 的速度增长，两个过程叠在一起，$5\,\mathrm{s}$ 时读到 0.1650 完全正常。到 $20\,\mathrm{s}$，瞬态衰减干净，读数就是 0.2000。**这条曲线同时说明了公式的准确性和它的适用时刻。**

第二，可以反算。 指标是“误差不超过某个值”，反算就是 $K_v\ge 1/e_{ss,\text{target}}$。主例算出 $K\ge 0.4$ 或 $K\ge 0.667$，再拿裕度一校核，立刻发现第二条路走不通（§42.8.2）。**反算的价值在于它能在动手之前判死刑**，而不是调到一半才发现裕度不够。

第三，可以比较。 同一台设备上，六档增益对应六个 K_v（表 42-6），全部按 $1/K_v$ 排列，谁好谁坏一目了然。跨设备不行——K_v 的量纲是 $1/\mathrm{s}$，“一个单位”在毫米、弧度、摄氏度里含义完全不同（§42.8.5）。**同一把尺子量同一类东西，这是 K_v 最实用的地方。**

还有一个常被忽略的优点：**本章的公式没有一条需要迭代、需要仿真、需要初始猜测。** 五个步骤全是代数运算，拿计算器就能做完。这在现场调试时非常值钱——你不可能在设备旁边跑一次 $40\,\mathrm{s}$ 的仿真再决定参数。

这三个“可以”的代价也在这里：公式太便宜，所以容易被滥用。它便宜的原因恰恰是它只回答一件事——“稳态”。曲线怎么走、要等多久、中间抖不抖，公式一律不管。所以正确的用法是“先算、再验、最后看边界”，而不是“算完就交”。下面五小节讲的就是“什么时候它不成立”。

42.11.2 局限一：只对多项式输入有定义

“稳态误差”这四个字里藏着一个前提：**输入必须是多项式**（阶跃、斜坡、抛物线，或者它们的组合）。只有这类输入，误差才会收敛到一个常数或一条已知斜率的直线，才谈得上“一个数”。

换成正弦输入，这个定义立刻失效。$r(t)=\sin\omega t$ 时，$e(t)$ 也是同频正弦，**没有“稳态值”，只有幅值和相位**：

$$|E(\mathrm{j}\omega)|=|S(\mathrm{j}\omega)|\cdot|R(\mathrm{j}\omega)| \tag{42-22}$$

用主例的实测数据代入（表 42-15），$\omega=1$ 时 $|S|=0.65805$，也就是单位幅值正弦指令下，误差幅值是 0.65805——**比同一个系统的斜坡误差 0.5144 还大。**

这件事初看很反直觉：型 1 系统对斜坡的误差是有限的，怎么对正弦反而更大？原因是频率位置不同。斜坡的能量集中在 $\omega\to0$，那里 $|S|\approx\omega/K_v\to0$；而 $\omega=1$ 已经接近 $\omega_c=1.5369$，$|S|$ 正爬向它的峰值 1.5952。**型别保证的是“低频趋于零”，不是“中频也小”。**

所以现场用本章的结论时必须先问一句：**指令的主要能量在哪个频段？**

- 点位运动、恒速扫描：能量在低频，本章的 e_{ss} 可以直接用；
- 往复运动、旋转机械：能量集中在某个频率，必须看 $|S(\mathrm{j}\omega)|$，不能看 K_v；
- 宽频指令（随机路面、风载）：看 $|S|$ 的整个形状，本质是第 50 章的鲁棒性问题。

周期指令的零误差跟踪要转到第 49 章（重复控制、谐振控制）。那里的判据仍然是内部模型原理，只是把“积分的模型”换成了“周期的模型”——**同一个原理，两种实现。**

42.11.3 局限二：线性时不变，而设备会变

本章所有的公式都建立在“线性、时不变”两个词上。真实设备至少在三处破坏它们。

第一处是饱和。 一旦执行器到限幅，闭环就断开了——控制器还在积分，对象却不再响应。这时候“型 1”名存实亡：积分器里存的是一笔还不完的账，退出饱和后要花很长时间才能“还清”，这段时间里的误差与 $1/K_v$ 毫无

关系。

本章的仿真刻意保留了这一点：`simulate_discrete` 里的控制器状态用**未限幅输出**推进，模拟真实的积分饱和。所以 §42.10 的量化算例里能跑出极限环——如果做了理想化处理，这些现象会被抹平。

第二处是参数时变。 主例的 $e_{ss} = 1/(5K)$，误差与增益严格成反比。增益漂 20%，误差就漂 25%：实跑 $K \times 0.8$ 给出 $K_v = 1.5552$、$e = 0.6430$（$0.5144/0.8 = 0.6430$，完全吻合）。反过来，$K \times 1.2$ 给出 $e = 0.4287$。

这个“严格反比”是型 1 的性质，不是巧合：K_v 与增益成正比，误差与 K_v 成反比，两个一比就消掉了所有高阶项。**所以型 1 系统的稳态误差对增益误差是一阶敏感的**——增益估错 10%，误差就错 10%，没有折扣。

第三处是型别本身会变。 带死区的阀在小信号时“像型 0”（推不动），大信号时“像型 1”；带间隙的传动在换向瞬间型别也变。对这种系统，“型别”只能对某个工作点说，不能对设备铭牌说。

三处破裂的共同后果是：**本章算出的是“设计工况下的误差”，不是“全工况的误差保证”。** 要后者，得靠 §42.10 的预算表与第 50 章的鲁棒性设计。

42.11.4 局限三：稳态误差不是轨迹误差

这是本章最容易被误用的一条。

e_{ss} 描述的是“$t \to \infty$、指令是简单多项式”时的行为。而伺服系统真正关心的往往是另外两个量：

- **跟随误差**（following error）：任意时刻指令与输出的差，包含瞬态；
- **轮廓误差**（contour error）：加工轨迹到理论轨迹的几何距离。

三者的关系可以用一个圆轨迹说清楚。设进给速度 v、曲率半径 R、速度误差系数 K_v，轮廓误差的量级是

$$\varepsilon_c \approx \frac{v^2}{2RK_v^2} \tag{42-23}$$

而同一工况下的跟随误差是 v/K_v。两者一比：

$$\frac{\varepsilon_c}{e_f} \approx \frac{v}{2RK_v} \tag{42-24}$$

代入主例的 $K_v = 1.9440$、$v = 0.05$、$R = 0.1$，比值是 0.1286——**轮廓误差只有跟随误差的 12.9%。**若把 K_v 加倍到 3.888，比值降到 0.0643：**轮廓误差按 $1/K_v^2$ 降，跟随误差按 $1/K_v$ 降，前者对增益是平方敏感。**

把这两个数落成同一工况下的绝对值：跟随误差 0.5144，轮廓误差 $0.1286 \times 0.5144 = 0.0662$。也就是说，验收单上那句“误差 0.5”，在圆轨迹上真正变成形状误差的只有 0.07 左右，剩下 0.44 是“沿着轨迹跑慢了”——它不影响圆的形状，只影响工件尺寸（半径偏小）。**同一个 0.5144，在“看形状”与“看尺寸”两种验收口径下，重要性差近八倍。**

这也意味着两个量**不能互推**。式 (42-24) 的比值依赖 v 与 R，所以两台机床即使报出同一个跟随误差，圆度也可能差很多：速度高一倍、半径小一半，比值就大四倍。现场常见的错误是拿跟随误差去估轮廓误差，然后按轮廓误差的容差去调增益——方向对，倍数全错。

式 (42-23) 只给量级，系数与型别、插补方式有关，但它传达的三个趋势是可靠的：速度越高越差、曲率越大越差、K_v 越大越好。**这也是数控机床拼命提 K_v 的真正原因——不是为了减小“稳态误差”这个指标，而是为了圆度。**

还有一类误差完全在式 (42-23) 之外：**过象限误差**（quadrant glitch）。圆弧过象限时运动方向反向，摩擦跟着反向，输出会出现一个短促的“凸起”。它的大小由摩擦与传动刚度决定，与 K_v 无关，靠加增益也压不下去——只能靠摩擦补偿或提高机械刚度（§42.10.4）。

所以验收单上写“稳态误差 0.5144”时，必须同时写清三件事：**什么指令、哪个时间段、哪个物理量。** 只写一个数，等于给了一句没法验收的话。

42.11.5 适用边界清单

把上面的讨论收成一张表，见表 42-22。

表 42-22　稳态误差分析的适用边界

条件	本章结论是否成立	处理方式	相关章节
线性时不变、闭环稳定、多项式输入	成立	直接算	本章
存在饱和或限幅	大信号时失效	抗饱和 + 分段验证	§42.8.4
$\omega_c T_s > 0.3$	K_v 仍保持，裕度与最小误差不可信	缩短采样周期、离散设计	§42.5、第 43 章
摩擦、死区、量化显著	只能给区间	误差预算表	§42.10
周期指令	不适用	重复控制、谐振控制	第 49 章
纯延迟占比大	K_v 对，裕度崩	Smith 预估	第 47 章
时变或强非线性对象	仅局部成立	增益调度、自适应	§42.9.3、第 50 章
关心采样点之间的行为	不可见	多速率分析、采样间响应	第 45 章、第 60 章

表 42-22 的读法是“从上往下逐条排除”。只要有一条落进“不成立”或“只能给区间”，就不能只报一个 e_{ss}。

42.11.6 与相邻章节的分工

本章在第 37–50 章这一段里的位置，可以用“上游一个、下游五个”说清楚。

上游是第 41 章。 那一章给的是“闭环稳定、裕度够不够”，本章所有结论都以“闭环稳定”为前提。终值定理的三个前提里，第一个就是稳定性——**不稳定就谈不上稳态，连“误差”这个词都没有定义。**

下游第一是第 43 章。 本章 §42.5 说了“采样不改变 K_v、但吃掉裕度”，第 43 章要回答“怎么设计离散控制器把这个损失补回来”：预畸变、Tustin 替换、直接数字设计。

下游第二是第 44 章。 本章讲“K_i 为什么能把型别抬一级、代价是多少”，第 44 章讲“PID 三个参数具体怎么整定”。前者是原理，后者是配方。

下游第三是第 46 章。 §42.9.1 只说了前馈“不消耗裕度、残余误差正比于建模误差”，第 46 章给出前馈通道的完整设计与复合控制结构。本章留下的接口是那句结论：**前馈把精度问题变成了建模问题。**

下游第四是第 49 章。 周期输入的零误差跟踪，本章只标出边界（§42.11.2），具体做法在那一章。

下游第五是第 50 章。 本章最后落到 $M_s = 1.5952$ 这个数上，第 50 章要把“M_s 多大算安全、模型误差多少会失稳”算清楚。本章留下的接口是表 42-15 那条 $|S|$ 曲线。

本章的一句话总结是：**型别决定误差能不能归零，增益决定归零前有多接近，采样决定这个结论还可信几分，非线性决定你只能报一个区间还是一个数。**

42.12 Python 仿真代码

42.12.1 两个文件的分工

本章的代码分成两个文件，职责划得很干净：

- `code/ch042_sim.py`：只算数、只打印，不画图。十组输出对应正文的十处结论。
- `code/ch042_figs.py`：只画图，十张图。它 `import ch042_sim` 复用对象与工具函数，不重复定义对象。

这样分的理由很实际。算数很快——十组输出在普通笔记本上不到两秒；出图慢——十张图要同时导出 SVG 与 PDF，耗时是算数的几十倍。调图的时候不需要重算数，改数的时候也不需要重出图。更重要的是：**正文引用的每个数字都能在 `ch042_sim.py` 的输出里找到对应的一行**，这是本章“数字必须来自实跑”这条规矩的技术保证。

两个文件共同依赖三样东西：`numpy` 与 `control` 做运算，`simlib` 提供 `simulate_discrete` 与裕度计算，`plot_styles` / `block_styles` 提供版式与框图助手。仿真部分只用前两样，所以拿掉后两样也能跑。

42.12.2 核心函数逐行读

去掉十组算例的驱动代码，真正撑起本章结论的是下面几十行。

```
import numpy as np
import control as ct

K_PLANT, TAU_ACT = 10.0, 0.05      # 对象增益、执行器时间常数


def plant(k=1.0):
    """主例型 1 对象 k*10/[s(s+2)(0.05s+1)]，Kv=5k。"""
    return k * ct.tf([K_PLANT], np.polymul([1.0, 2.0, 0.0], [TAU_ACT, 1.0]))


def origin_poles(sys):
    """返回 (原点极点数, 去掉这些极点后的分母系数)。"""
    den = np.atleast_1d(np.asarray(sys.den[0][0], float))
    n = 0
    while len(den) > 1 and abs(den[-1]) < 1e-12:
        den, n = den[:-1], n + 1
    return n, den


def static_coeffs(sys):
    """返回 (型别 N, Kp, Kv, Ka)；系数一律尾一化。"""
    num = np.atleast_1d(np.asarray(sys.num[0][0], float))
    n, den = origin_poles(sys)
    ratio = num[-1] / den[-1]
    kp = ratio if n == 0 else np.inf
    kv = ratio if n == 1 else (np.inf if n >= 2 else 0.0)
    ka = ratio if n == 2 else (np.inf if n >= 3 else 0.0)
    return n, kp, kv, ka


def kv_discrete(Ld, Ts):
    """离散 Kv=(1/Ts)·n(1)/d'(1)，用洛必达避开 0/0。"""
    num = np.atleast_1d(np.asarray(Ld.num[0][0], float))
    den = np.atleast_1d(np.asarray(Ld.den[0][0], float))
    d1 = np.polyval(np.polyder(den), 1.0)
    return np.polyval(num, 1.0) / d1 / Ts if abs(d1) > 1e-12 else np.inf
```

四段代码各对应正文的一个知识点。

`plant()` 里的 `np.polymul([1.0, 2.0, 0.0], [0.05, 1.0])` 是把 $s(s+2)$ 与 $(0.05s+1)$ 乘起来。注意它没有写成 `[1, 2, 0]` 的直觉形式——分母系数必须**从高次到低次**排列，$s(s+2)=s^2+2s$ 就是 `[1, 2, 0]`，最后那个 0 就是原点极点留下的痕迹。

`origin_poles()` 是“数型别”的代码版本，也是最容易写错的一个。它从分母系数的**末尾**往前数零，而不是先求极点再用 `abs(pole) < 1e-9` 判断。原因是数值求根在原点附近误差大：一个 s^2 因子可能被算成 1.3×10^{-8} 与 -2.7×10^{-8} 两个“极点”，阈值定宽了会误判，定窄了会漏判。直接看系数末尾是不是零，没有这个问题。

`static_coeffs()` 里的 `num[-1] / den[-1]` 就是正文反复强调的**尾一化**。写成 `num[0] / den[0]`（首一化）在型 0、型 1 上碰巧一样，在型 2 上会大四倍（§42.3.3 算过）。这行代码是本章最便宜的一行，也是最贵的一行——写错它，后面所有误差全错。

`kv_discrete()` 用的是洛必达结果 $n(1)/d'(1)$，而不是直接算 $\lim_{z\to1}(z-1)L(z)$。原因是后者是 $0/0$。主例的实测系数是分子 $[9.3138\times10^{-5},\,3.3471\times10^{-4},\,7.4754\times10^{-5}]$、分母 $[1,\,-2.6311,\,2.2751,\,-0.6440]$：

- $n(1)=9.3138\times10^{-5}+3.3471\times10^{-4}+7.4754\times10^{-5}=5.0260\times10^{-4}$；
- $d(1)=1-2.6311+2.2751-0.6440\approx4.0\times10^{-8}$；
- $d'(1)=3-5.2622+2.2751=1.2927\times10^{-2}$。

$d(1)$ 只剩 4×10^{-8}，是四个 $O(1)$ 的数相减的残差。任何直接做除法的写法都会在这里丢掉大部分有效数字——**这不是精度问题，是方法问题**。

42.12.3 十组输出与正文的对应

`ch042_sim.py` 按顺序打印十组结果，与正文的对应关系见表 42-23。

表 42-23　仿真输出与正文结论的对应

组	输出内容	正文位置
1	三种型别的静态系数与三类输入的误差	表 42-4
2	型 1 单位斜坡误差的时域终值与进带时刻	§42.4.3
3	型 2 抛物线误差的时域终值	表 42-5
4	主例六档增益的 K_v、误差、裕度	表 42-6
5	P 与 PI 下两个扰动通道的直流增益	图 42-8、§42.7.4
6	PI 三档的峰值与恢复时间	表 42-12
7	四种离散化的 K_v 与裕度	表 42-7～表 42-10
8	死区与量化的静态误差、峰峰值	表 42-16、表 42-17
9	摩擦的稳态偏移与型 0 临界增益	表 42-18、表 42-19、§42.10.5
10	增益摄动下的 K_v、误差、裕度	§42.6.2、§42.6.6

这张表的用法是“倒查”：正文里任何一个数，先在表里找到它属于第几组，再去看那一组的打印格式，就知道它是怎么算出来的、用的是哪个对象、哪个控制器。

举一个例子。正文写“型 1 在 $t=10/20/40$ s 的误差是 $0.1998/0.2000/0.2000$，进入 $\pm2\%$ 带的时间是 5.99 s”。这组数来自第 2 组，它的算法是：

1. 先用 `err_tf(L1)` 求 $E/R=1/(1+L)$；
2. 用 `forced_response` 把 $r(t)=t$ 直接送进去，而不是“串一个积分器再打阶跃”——后者多一层数值积分，误差更大；
3. 取 $t=10/20/40$ s 三个点，再取末段 500 点求均值；
4. 进带时刻用“最后一次超出 $\pm2\%$ 的时刻再加一个采样点”算，这样得到的才是“此后不再出带”的时刻，而不是“第一次进带”的时刻。

第 4 步这个细节在正文里被强调过：**两种定义能差好几秒**，§42.7.5 里 $K_i=1.0$ 的恢复时间之所以是 20.08 s，就是因为那一路一直在振荡，第一次进带很早、最后一次出带很晚。

42.12.4 运行方法与典型输出

在书籍根目录下按顺序跑四条命令：

```
"D:\Anaconda3\envs\py311\python.exe" code/ch042_sim.py
"D:\Anaconda3\envs\py311\python.exe" code/ch042_figs.py
"D:\Anaconda3\envs\py311\python.exe" tools/check_chapter.py 42
"D:\Anaconda3\envs\py311\python.exe" tools/build.py --chapter 42
```

前两条出数、出图，第三条做结构验收，第四条出 PDF。

第一条命令的输出开头几行长这样：

```
1) 三种型别的静态系数与稳态误差
   型0 N=0 Kp=10.0 Kv=0.0 Ka=0.0 | ess: 0.0909091 / inf / inf | 闭环稳定=True
   型1 N=1 Kp=inf Kv=5.0 Ka=0.0 | ess: 0 / 0.2 / inf | 闭环稳定=True
   型2 N=2 Kp=inf Kv=inf Ka=5.0 | ess: 0 / 0 / 0.2 | 闭环稳定=True
2) 型 1（主例 K=1）单位斜坡误差的时域终值
   t=10/20/40 s: e=0.1998 / 0.2000 / 0.2000 | 末段均值=0.2000 | 解析 1/Kv=0.2000
   进入 1/Kv±2% 的时刻=5.99 s
```

第 1 组这三行是本章的“总纲”：型 0 的 $K_p = 10$、阶跃误差 0.0909（$= 1/11$）；型 1 的 $K_v = 5$、斜坡误差 0.2；型 2 的 $K_a = 5$、抛物线误差 0.2。三个对象都用 $C = 1$，闭环全部稳定。**表 42-4 就是这三行加三列。**

运行时会看到一条 `UserWarning: stability_margins: Falling back to 'frd' method`。这是 `control` 在检测到“多项式求根可能不准”时自动切换算法，**不影响数值结果**，也不代表系统有问题。本书所有裕度数据都是在这个警告下跑出来的，可以放心对照。

建议把完整输出重定向到日志（例如 `python code/ch042_sim.py > sim42.log 2>&1`），正文里每个数字都按日志核一遍。**这一步比重读一遍代码有用得多**：代码只说明“打算算什么”，日志才说明“实际算了什么”。

42.12.5 三个练习

三个练习都不需要改主程序，只需要改一两个常数、再跑一遍。

练习一：把输入幅值改成 2。 把第 2 组的 `U=t` 改成 `U=2*t`，其他不动。预期：所有误差**严格乘 2**，终值变成 0.4000，进带时刻仍然是 5.99 s。这一条验的是线性系统的齐次性——如果结果不是严格两倍，说明代码里有非线性环节（例如限幅）被无意引入。

练习二：把采样周期从 0.05 s 改成 0.02 s。 改第 7 组的 `Ts` 列表，重跑。预期：K_v 十二组全部仍是 1.9440（这一条已经在表 42-7 里验证过），但 ZOH 的相位裕度会比 $47.185°$ 更接近连续值 $48.065°$。这一条验的是 §42.5.4 的估算式 $\Delta\varphi \approx \omega_c T_s/2$：$T_s$ 缩小 2.5 倍，损失也缩小 2.5 倍。

练习三：把死区从 0.02 改成 0.03。 改第 8 组的死区列表，重跑。预期：理论带变成 ± 0.015，实测值落在带内，但**符号可能仍是正的、也可能翻成负的**——这正是 §42.10.2 说的“符号是轨迹的产物”。跑到这一步，你就亲手复现了“死区只能报区间”这句话。

三个练习的共同点是：**先写下预期，再跑，再对**。次序反过来（先跑再解释）就学不到东西了。

对不上时，先按这三条排查，顺序别反：

- **第一，文件是不是真的被重跑了。** `ch042_figs.py` 里 `import ch042_sim`，改了后者但只跑前者，拿到的是上一次的结果——Python 的模块缓存不会提醒你。判据是输出里有没有你刚改的那个常数。

- **第二，末段取得够不够长。** 型 2 的抛物线误差在 $t=5$ s 时只有 0.1650、$t=10$ s 时 0.1959，要等到 $t=20$ s 才到 0.2000。若把末段起点放在 5 s，平均值会低 17.5%，看起来像“公式错了”，其实只是没等到稳态。型 0 的斜坡误差更极端：它根本不存在“末段不变”这回事（§42.2.2）。
- **第三，“进带”用的是哪一种定义。** §42.7.5 的 $K_i=1.0$ 那一档给出的 20.08 s 是按“最后一次出带”算的；换成“第一次进带”，那个数会明显更小，因为它一直在振荡。写预期时就要说清是哪一种，否则两边永远对不上。

42.12.6 复用的五个坑

把这套代码搬到别的系统上，有五个坑几乎一定会踩。

第一坑：首一化代替尾一化。 型 2 系统上会大四倍（§42.3.3）。判断方法：算完 K_v 后，用 $C(0)G(0)$ 交叉验一次——若两者差一个整数倍，多半是首一化。

第二坑：用数值极限求 K_v。 主例的 $d(1)$ 只有 4×10^{-8}，直接做 $(z-1)L(z)$ 在 $z\to1$ 的极限会得到五花八门的结果，而且**采样率越高越不准**（$d(1)$ 越小）。必须用 $n(1)/d'(1)$。

第三坑：`feedback` 的符号。 `control` 的 `feedback(sys1, sys2)` 默认是负反馈，算的是 $\mathrm{sys1}/(1+\mathrm{sys1}\cdot\mathrm{sys2})$。本章的 `dist_tf(G, C)` 写成 `ct.feedback(G, C)` 得到 $G/(1+CG)$，靠的就是这个默认。若换成正反馈，扰动通道会变成 $G/(1-CG)$，直流增益的符号与大小全变。**不确定时显式写 `sign=-1`。**

第四坑：时间向量与采样周期混用。 `simulate_discrete` 内部按 T_s 一步一步推进，而 `np.linspace(0, T, n)` 只决定“画多少个点”。两者不一致时，“第 k 步”与“第 k 个采样点”就错位了，算出来的峰峰值会莫名其妙地跳。做法是：离散仿真只用 T_s 与步数，连续仿真才用 `linspace`。

第五坑：单位。 K_v 的单位是 $1/\mathrm{s}$，但“一个单位”是毫米还是弧度，取决于输入信号的量纲。把 $K_v=1.9440$ 从“每伏”直接搬到“每毫米”，误差就会差一个标定系数。本章所有算例都用无量纲的“单位输入”，正是为了避开这一层。

五个坑里，前两个会让结果错得“有理有据”（数字看起来很正常），后三个会让结果错得“莫名其妙”（跑不通或跳变）。**前者更危险，因为它们不报错。**

这五个坑有一个共同点：它们都不在你的代码里，而在“你以为它在算什么”里。唯一的防线是把**互相矛盾的两个量打在同一行**。本章的输出格式就是照这个原则定的——每一行同时给出 K、K_v、e_{ss}、φ_M 四个数：K_v 与 K 不成 5 倍，是增益被漏乘；e_{ss} 与 $1/K_v$ 不成倒数，是尾一化错了；φ_M 突然跳一大截，是离散化的方式换了。四个数里任意两个对不上，都能立刻定位到一行代码。**自证比注释可靠，因为注释不会执行。**

第43章 校正装置设计

> 本章的一句话核心思想：校正不是把增益调大，而是在 **Bode** 图上按频段分配增益——该抬的频段抬上去，该压的频段压下来；抬与压之间隔着一条守恒律，代价最终以相位、噪声或带宽的形式付出去。

43.1 动机与直观理解

43.1.1 第四个现场问题

第 41 章回答了“增益还能往上加多少”，第 42 章回答了“稳态误差还差多少”。把两章结论并排放到桌上，现场就会冒出第四个问题：

“两个指标我都要，机械不动、电机不换，只在控制器里加一个环节，行不行？”

这个问题的答案就是本章的内容。加进去的那个环节叫**校正装置**（compensator），也叫校正网络、调节器、补偿器。名字很多，作用只有一个：在不改变对象、不改变反馈结构的前提下，重新分配回路在各个频段上的增益与相位，把 Bode 图“捏”成我们想要的样子。

把话说得更具体一点。本章沿用第 39–42 章的主例对象

$$G(s)=\frac{10}{s(s+2)(0.05s+1)} \tag{43-1}$$

要求速度误差系数 $K_v=20$，也就是单位斜坡输入下稳态误差 $e_{ss}=1/20=0.05$。第 42 章已经算过，这个要求等价于串联增益 $K_c=20/5=4$。于是设计任务变成一句话：**在 $K_c=4$ 的前提下，把相位裕度从现场测到的水平拉回到 50°。**

这句任务描述里藏着本章全部的矛盾：K_c 由误差指标锁死，不能动；50° 由稳定性指标锁死，也不能让。能动的只剩“频率分布”这一个自由度，而校正装置恰恰只提供这一个自由度。

这里要交代一句设计点的变化。第 41–42 章主例的设计点是 $K=0.3888$，对应 $K_v=1.9440$、$e_{ss}=0.5144$；本章把误差直接收紧到 0.05，增益因此要从 0.3888 抬到 4，即 $+20.25$ dB。第 42 章 §42.6.2 量过这条价目表的斜率：小段 $2.67^\circ/\mathrm{dB}$；§42.9.5 又量了“把误差压五倍”那种大段，$2.43^\circ/\mathrm{dB}$。按后者外推，$+20.25$ dB 该掉四十多度；实测 $48.065^\circ\to1.576^\circ$，掉 46.5°，合 $2.30^\circ/\mathrm{dB}$，比大段斜率还低一点，因为裕度曲线在上凸。方向没有变：**§42.9.5 那句“靠增益硬扛误差，必然把系统推到失稳边缘”，再往前走一步，就是本章的开局。**

43.1.2 一个旋钮换不来两个指标

先把矛盾摆成数字。表 43-1 是主例在三档纯比例增益下的实测，全部数值由 `code/ch043_sim.py` 的 `[1]` 组打印。

表 43-1　主例在三档纯比例增益下的指标（无校正）

K_c	K_v	相位裕度 φ_M (°)	增益裕度 G_M (dB)	穿越频率 ω_c (rad/s)	超调 (%)	上升时间 (s)	调节时间 (s)
1	5	26.997	12.87	2.8461	46.05	0.4063	5.363
2	10	13.571	6.85	4.2041	68.16	0.2655	7.463
4	20	1.576	0.83	6.0291	92.45	0.1807	49.940

第一行是“没使劲”的状态：误差大（$e_{ss}=0.2$），但裕度 26.997° 还算能跑。第三行是“按误差指标使满劲”的状态：误差刚好达标，相位裕度只剩 **1.576°**，增益裕度 **0.83 dB**，超调 **92.45%**，调节时间从 5.4 s 拖到 49.9 s。

注意最后一项。上升时间从 0.4063 s 缩到 0.1807 s，看起来“更快了”，可调节时间反而涨了近十倍——这是典型的**欠阻尼振铃**：前沿冲得快，尾巴摆得久。只看上升时间会得出完全相反的结论，这也是第 41 章反复强调“三个时间指标要一起看”的原因。

更要命的是 1.576° 这个数。它意味着回路已经在失稳边缘：增益再涨 0.83 dB（约 10%）就进入自持振荡。现场遇到这种曲线，第一反应不能是“再调调 PID”，因为 PID 的比例项只会把增益继续往上推——方向正好反了。

表 43-1 的结论是一句硬话：靠一个增益旋钮，$K_v=20$ 与 $\varphi_M=50^\circ$ 不可能同时成立。 它们之间差着 48.4° 的相位，这 48.4° 必须由别的元件补出来。

有人会说，那就退指标。K_v 从 20 退到 10，$K_c=2$，裕度 13.571°；再退到 5，$K_c=1$，裕度 26.997°。**精度丢了四倍，裕度只回来 25 度，离 50° 还差 23°。**

这条路走不通，可以算得很具体。从表 43-1 的两段实测看，增益每降一半，相位裕度涨 12–13°（4→2 涨 11.995°，2→1 涨 13.426°）。要补 48.4°，得把增益降到原来的约十四分之一（$2^{48.4/12.7}\approx 14$），K_c 变成 0.29，K_v 变成 1.43，稳态误差从 0.05 涨到 0.70。**为了换 50° 裕度，要把速度误差精度丢掉一个数量级还多。** 任何一个需要跟踪斜坡的场合都不会接受这个结果。

这就是“必须动频率分布”的定量理由。增益只能整条曲线平移，而我们需要的是“某一段抬、另一段压”——这种局部修改能力，只有引入新的零极点才能获得。

43.1.3 校正就是给 Bode 图“整形”

既然增益不能动，那就动“增益在频率上的分布”。图 43-1 把三档增益的 Bode 图叠在一起，一眼能看出问题出在哪个频段。

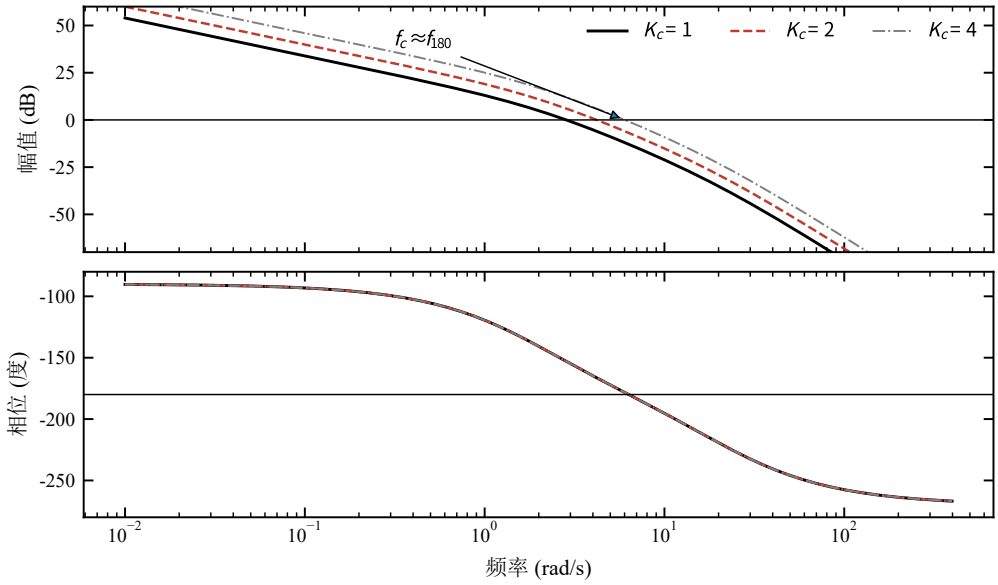

图 43-1　主例在三档纯比例增益下的开环 Bode 图

三条幅频曲线形状完全一样，只是整体上下平移——这正是“纯增益”的含义。相位曲线则完全重合，与增益无关：**增益只能平移幅频曲线，不能改变相频曲线。**

这条性质决定了整章的思路。相位裕度是“在穿越频率处，相位离 -180° 还有多远”。增益一抬，穿越频率 ω_c 就沿着同一条相频曲线往右滑；主例的相频曲线从 -90° 一路滑向 -270°，所以 ω_c 越往右，裕度越小。$K_c = 4$ 时 $\omega_c = 6.0291$ rad/s，相位已经掉到 -178.4°，离 -180° 只差 1.576°。

于是“整形”有了两种完全不同的做法：

- **把相位曲线抬起来**：在 ω_c 附近人为制造一段正的相位，让穿越点处的相位离 -180° 更远。这是**超前校正**。
- **把幅频曲线压下去**：让幅频曲线提前穿过 0 dB，把 ω_c 拉回到相位还好的低频段。这是**滞后校正**。

两种做法对应两套完全不同的代价。前者抬相位要付高频增益（噪声放大），后者压幅值要付带宽（响应变慢）。本章后面所有的表格，本质上都在量化这两笔代价。

顺带说明图 43-1 里那个标注 $f_c \approx f_{180}$ 的意义：$K_c = 4$ 时幅值穿越点与相位穿越点几乎重合，两个裕度同时趋零。这是“临界稳定”的图形特征，也是判断“还能不能再加增益”最直观的一眼。

43.1.4 三种性格：提前量、让路、两段接力

超前校正像开车时的“提前打方向”。它不改变最终能走多快，而是在弯道到来之前先给出一个反向的修正量。数学上它是一个零点在左、极点在右的一阶环节：零点先把相位往上抬，极点在高频再把相位还回去，抬与还之间形成一段“相位鼓包”。鼓包的高度由零极点之比决定，位置由几何中心决定。

它的性格是**快而吵**：穿越频率被推高，响应变快，但高频增益同步放大，传感器噪声原封不动地灌进执行器。

滞后校正像“给快车让路”。它不抬相位，反而在低频引入一点相位滞后；真正的动作在高频——把高频幅值压低，让幅频曲线提前穿过 0 dB。穿越点左移到相位还富裕的频段，裕度自然回来。

它的性格是**稳而慢**：裕度漂亮、噪声几乎不放大，但穿越频率被压到 1 rad/s 附近，响应慢一个数量级，而且低频相位滞后会侵蚀一点稳态性能。

超前-滞后校正是两段接力：滞后段负责把高频压下去、把穿越点挪到中间位置，超前段负责在那个位置上再补一点相位。它想要的是“中等的速度 + 中等的裕度”，代价是元件多一倍、设计方程要联立求解。

三种性格的实测差距有多大，§43.4 会用同一张表锁死。这里先给一句预判：**在主例这个对象上，超前能把调节时间做到 0.52 s，滞后只能做到 10.9 s，两者差 21 倍；而滞后的执行器噪声只有超前的千分之一。** 没有哪种更好，只有哪种更适合当前指标。

把三种性格放在同一把尺子上，代价是可以互相换算的。以三组数作坐标：超前（$t_s = 0.520$ s、高频 155.3 倍、漂移跨度 10.903°）、滞后（10.913 s、0.220 倍、17.623°）、超前-滞后（3.948 s、2.079 倍、21.302°）。从超前换到滞后，时间慢 21 倍，噪声低 706 倍，漂移跨度却变差 1.62 倍；从超前换到超前-滞后，时间慢 7.6 倍，噪声低 74.7 倍，漂移跨度变差 1.95 倍。**三列从来不是同向变化的：省了噪声，就要付时间，还得接受漂移变差。** 这就是“选结构”不能按单项最优来选的原因——按单项排，每列的第一名都是不同的结构。

43.1.5 守恒律：三样东西不能同时赢

校正装置看起来像“免费的午餐”：加两个电阻电容，裕度就从 1.6° 变成 50°。但把三张表放在一起看，会发现一条守恒律：

- **相位与高频增益守恒。** 超前的最大相位只由超前比 α 决定，而高频增益恰好等于 α。想要 50° 的补偿量，α 得给到 38.82，高频增益就是 155 倍——传感器上 1 mV 的噪声，到执行器就是 155 mV。这就是 §43.9 要用一整节讲“噪声代价”的原因。
- **裕度与带宽守恒。** 滞后靠压幅值换裕度，压多少，穿越频率就退多少。主例把 ω_c 从 6.03 rad/s 退到 1.00 rad/s，裕度换来了 48°，响应慢了 21 倍。
- **性能与鲁棒性守恒。** 校正器把回路“调”到一个工作点上，这个工作点对对象参数漂移有多敏感，取决于校正器在该频段的斜率。§43.10 的九宫格实测会显示：超前的裕度跨度 10.9°，滞后 17.6°，超前-滞后 21.3°——**越依赖相位补偿的结构，对参数漂移越敏感。**

这条守恒律不是数学定理，而是这三个一阶环节的结构决定的。理解了它，就不会再问“有没有一种校正器既快又稳又不吵”——正确的问法是“在当前指标下，哪一笔代价我最付得起”。

43.1.6 本章路线

§43.2 把三种校正器的公式一次性推导清楚，重点是“最大相位点”和“高频增益”这两个量的来历。§43.3 给出六步设计流程，每一步都配一个可执行的判据。§43.4 是连续域的实跑：基准、超前、滞后、超前-滞后、四结构同台、反馈与复合，六组数字。§43.5 转入离散域，回答“为什么连续设计直接离散化会崩”以及 w 域设计到底救回了什么。§43.6 讨论两个裕度为什么经常打架，§43.7 逐个参数讲作用方向，§43.8 给调参经验，§43.9 讲改进路线，§43.10 落到运放与定点实现，§43.11 划边界，§43.12 给代码。

读本章前建议先回看第 41 章 §41.6 的裕度定义与 §41.7 的时间指标换算，本章会反复用到 ω_c、φ_M、M_s 这三个量，但不再重复它们的定义。

43.2 数学原理

43.2.1 标准形式与两条极限

校正器的物理实现通常是一张 RC 网络，传递函数天然是一阶有理式。想得到二阶特性，工程上更常见的做法是**两级一阶串联**，而不是直接设计二阶网络——因为一阶的每个参数都有明确的物理对应（一个电阻、一个电容），

调试时可以独立拧。

一阶环节还有一个更重要的好处：**它只在一个频段内“动手”，两端都回到平坦。** 低频增益是常数，高频增益也是常数，中间过渡段的斜率固定为 ± 20 dB/dec。这种“局部作用”的性质让设计可以分解：先算需要补多少、补在哪儿，再算两端的代价，两件事互不纠缠。

代价是补偿能力有限。单个一阶超前最多能给出接近 90° 的相位（$\alpha \to \infty$ 时），但那时高频增益也趋于无穷。实际可用的上限大约在 60° 附近，再往上就得两级串联，这是 §43.9 的话题。

本章统一采用“零点-极点”形式：

$$C(s) = K_c \, \frac{1 + s/z}{1 + s/p} \tag{43-2}$$

其中 z 是零点（rad/s），p 是极点（rad/s），K_c 是低频增益。三个参数、两条极限：

- **低频**（$s \to 0$）：$C(0) = K_c$。这一条决定了稳态误差，也是 K_c 被 K_v 锁死的原因。
- **高频**（$s \to \infty$）：$C(\infty) = K_c \, p/z$。这一条决定了噪声放大倍数与高频段的增益代价。

两个极点位置谁大谁小，决定校正器的性格：

条件	名称	相位	高频增益
$p > z$	超前	中频为正（鼓包）	$K_c p/z > K_c$，放大
$p < z$	滞后	全频段为负	$K_c p/z < K_c$，衰减

同一个公式，两种性格，区别只在零极点谁在右。 这一点值得记住，因为它说明校正器的“类型”不是靠元件区分，而是靠参数相对位置区分。现场的 RC 网络焊错了位置，超前会变成滞后，症状是裕度不升反降。

43.2.2 最大相位点出现在几何中心

超前的核心问题是“鼓包最高能多高、最高点在哪”。把 $s = j\omega$ 代入式 (43-2)，相位是

$$\varphi(\omega) = \arctan \frac{\omega}{z} - \arctan \frac{\omega}{p}$$

对 ω 求导并令其为零，得到

$$\omega_m = \sqrt{z p} \tag{43-3}$$

也就是零极点的**几何中心**。在这个点上，相位达到最大值 φ_m，且满足

$$\sin \varphi_m = \frac{p - z}{p + z} = \frac{\alpha - 1}{\alpha + 1}, \qquad \alpha = \frac{p}{z} \tag{43-4}$$

这里 α 叫**超前比**。式 (43-4) 是本章用得最多的一个公式，它把“要补多少度”和“零极点该差几倍”直接连起来，中间不需要任何其他参数。

同一时刻，校正器的幅值是

$$|C(j\omega_m)| = K_c \sqrt{\alpha} \tag{43-5}$$

这个 $\sqrt{\alpha}$ 很关键：**鼓包最高点上的增益正好是两端增益的几何平均**。它意味着补偿相位的同时，回路增益在 ω_m 处被抬高了 $\sqrt{\alpha}$ 倍，穿越频率一定会往右跑——这就是超前“必然提速”的数学来源。

顺带记下高频增益：把 $s \to \infty$ 代入式 (43-2)，得 $K_c\alpha$。**同一个 α，既是相位鼓包的高度，又是高频增益的倍数。** 想多补相位，就得多放大噪声，二者由同一个参数绑定，无法分开调节。

43.2.3 超前比的四重身份

把 α 的四个作用列在一起，就能看清超前的全部代价：

1. **决定最大相位**：由式 (43-4)，α 越大鼓包越高，但很快饱和（$\alpha = 10$ 时 54.90°，$\alpha = 38.82$ 时 71.75°，涨了近四倍只多 16.9°）。
2. **决定高频增益**：$K_c\alpha$，$\alpha = 38.82$ 时就是 155.3 倍。传感器噪声、PWM 纹波、编码器量化误差，全按这个倍数进执行器。
3. **决定穿越频率的位移**：ω_m 处增益抬高 $\sqrt{\alpha}$，穿越点右移，而右移意味着吃进更多对象相位滞后。这是“补相位”这件事自身带来的反作用。
4. **决定鼓包在倍频程上有多宽**：把 ω 按 ω_m 归一化，相位曲线只由 α 决定。以峰值为基准降 10°，$\alpha = 6.94$ 覆盖 2.56 个倍频程，$\alpha = 38.82$ 覆盖 3.09 个；降 20° 分别是 3.93 与 4.38 个。**α 越大，鼓包不仅更高，在倍频程上也更宽**，所以“加大 α 会让鼓包变窄”是流传很广的误读——它真正的代价不在宽度，而在高度所对应的那个数：高频增益。

最后一条还有一个用处：判断穿越点能偏离 ω_m 多远。主例的 $\omega_c/\omega_m = 10.2301/22.516 = 0.454$，落在 -10° 边界 0.343 之内，所以校正器在 ω_c 处还剩 66.37°；若 ω_c 被压到 $0.343\omega_m = 7.72$ rad/s 以下，同样的校正器就只剩 61.76°，对付 53.4° 的缺口就几乎没有余量了。

还有一处符号要交代。第 37 章式 (37-28) 也用 α，但那里的 $\alpha = T_f/T_d < 1$ 是微分滤波比，本章这个 $\alpha = p/z > 1$ 恰好是它的倒数；两处公式的形状一样（$\arcsin\frac{1-\alpha}{1+\alpha}$ 与 $\arcsin\frac{\alpha-1}{\alpha+1}$），趋势却相反。本章一律按 $\alpha > 1$ 走，看到 α 变大时报“相位更多、噪声更大”，就不会读反。

图 43-2 把前两条画在同一张图上：黑线是式 (43-4) 的相位，红虚线是 $20\log_{10}\alpha$ 的高频增益，两者共用横轴。

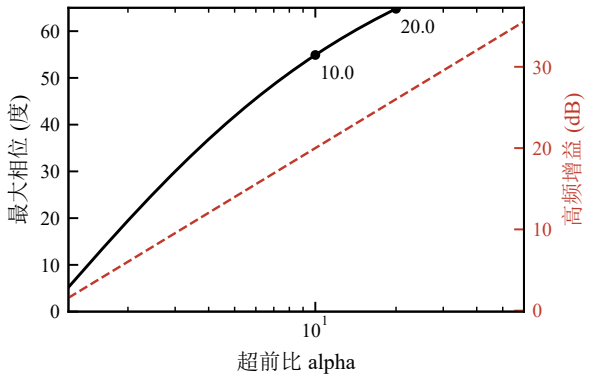

图 43-2　超前比与最大相位、高频增益的兑换关系

曲线读法很直接：横轴每翻一倍，相位涨得越来越少，高频增益却固定涨 6.02 dB。**这是一条边际收益递减、边际成本恒定的曲线**，所以工程上不会无限加大 α，而是在“够用”处停下。

表 43-2 是本章三个候选 α 的实测。注意“名义最大相位”与“实际得到的裕度”不是一回事。

表 43-2　三个超前比的相位能力与实际效果（$K_c = 4$）

α	名义最大相位 φ_m (°)	高频增益 (倍)	实际相位裕度 (°)	实际补偿量 (°)	穿越频率 (rad/s)
10	54.90	40.0	41.006	39.43	8.8749
20	64.79	80.0	46.844	45.27	9.5900
38.82	71.76	155.3	50.346	48.77	10.2301

“实际补偿量”是相对未校正的 1.576° 算的。它与名义最大相位差 $13.9^\circ \sim 21.4^\circ$，差距随 α 增大而增大。这笔账可以拆成两项，以 $\alpha = 38.82$ 为例：**一是校正器在 ω_c 处只给出 66.37°，比峰值 71.76° 少 5.4°**——因为 $\omega_c = 10.2301$ 落在 $\omega_m = 22.516$ 的左侧 2.2 倍处，取的是鼓包的上升段；**二是穿越点从 6.0291 右移到 10.2301，对象在那里的相位从 -178.42° 掉到 -196.03°，多吃 17.6°**。两项相加 23.0°，正好等于 71.76 与 48.77 之差。**所以设计时不能直接把“缺口 48.4°”代入式 (43-4) 求 α**，那样算出的 α 会偏小，必须留余量或迭代——这是 §43.3 要给的流程。

43.2.4 滞后网络：不用相位，用幅值

滞后网络的形式与式 (43-2) 完全一样，只是 $z > p$。定义衰减比

$$\beta = \frac{z}{p} > 1 \tag{43-6}$$

它在高频的增益是 K_c/β，也就是把高频幅值压低 β 倍。设计时不去算相位，而是先定“新的穿越频率 ω_c' 放在哪”，再令该点的环路增益恰好为 1：

$$\beta = K_c \, |G(j\omega_c')| \tag{43-7}$$

零点取 ω_c' 的若干分之一，极点再由 β 反推：$p = z/\beta$。这个“先定 ω_c'、再定 β、最后配零极点”的顺序，是滞后设计与超前设计最大的不同：**超前的自变量是相位，滞后的自变量是频率。**

零点位置用一个“衰减倍数” d 描述，$z = \omega_c'/d$。d 越大，零点离穿越点越远，穿越点处的相位滞后越小。表 43-3 是 $d = 4/5/10$ 三档的实测，§43.4.3 会逐行解释。

表 43-3　滞后网络零点位置对指标的影响（$K_c = 4$，目标 $\varphi_M = 50^\circ$）

零点位置 d	零点 z (rad/s)	极点 p (rad/s)	衰减比 β	相位裕度 (°)	穿越频率 (rad/s)
4	0.22102	0.010693	20.671	50.000	0.9062
5	0.19730	0.010864	18.160	50.000	1.0022
10	0.12086	0.008550	14.137	50.000	1.2133

三行的相位裕度都被精确顶到 50.000°——这是式 (43-7) 的直接结果，设计中把 β 解到了恰好满足。差别全在别处：d 越大，穿越频率越高（0.9062 → 1.2133），衰减比越小（20.671 → 14.137），响应越快但需要的零极点分离越夸张。

校正器自身在穿越点处的相位也随 d 变化，三档分别是 -13.03°、-10.52°、-5.28°。这就是“滞后网络的相位代价”：零点离穿越点越远，代价越小。$d = 10$ 只付 5.28°，而 $d = 4$ 要付 13.03°——相差 7.75° 的裕度预算，正是从穿越频率的位置上换来的。三者的时间指标取舍在 §43.4.3 定量。

43.2.5 超前-滞后的联立方程

把两段串起来，$C(s)=C_d(s)\,C_l(s)$，未知量变成四个（两个零点、两个极点）。工程上通常先固定滞后的零点位置（$z_l=\omega_c'/d$），再联立两个方程：

$$\angle C_d(j\omega_c')+\angle C_l(j\omega_c')=-180^\circ+\varphi_M-\angle G(j\omega_c') \tag{43-8}$$

$$|C_d(j\omega_c')|\,|C_l(j\omega_c')|\,K_c\,|G(j\omega_c')|=1 \tag{43-9}$$

式 (43-8) 管相位、式 (43-9) 管幅值，两个方程解两个未知量（α 与 β）。麻烦在于 β 藏在 C_l 的极点里，C_l 的相位又依赖 β，两个方程通过 β 耦合，没有闭式解。

实际做法是固定点迭代：先猜 $\beta=1$，用式 (43-8) 解出 α，再用式 (43-9) 算新的 β，回到式 (43-8) 重解 α，直到 β 收敛。`design_lead_lag()` 里就是这个循环，80 次上限、10^{-12} 的收敛判据。表 43-4 的三组结果都是迭代收敛后的值——这也是为什么超前-滞后的参数看起来“不那么整”。

表 43-4　超前-滞后的迭代解（$K_c=4$，$d=5$）

目标 ω_c' (rad/s)	α	z_d (rad/s)	p_d (rad/s)	z_l (rad/s)	p_l (rad/s)	β
2.0	2.109	1.3772	2.9045	0.4000	0.03915	10.218
3.0	3.613	1.5783	5.7024	0.6000	0.08631	6.951
4.0	5.504	1.7050	9.3843	0.8000	0.15552	5.144

读这张表要注意 α 与 β 的反向关系：目标穿越频率越低，需要的超前比越小（5.504 → 2.109），需要的衰减比越大（5.144 → 10.218）。**两部分在互相“让”**：穿越点越高，对象相位越差，超前段要多干活；同时对象幅值越小，滞后段可以少干活。

43.2.6 反馈校正的等效串联形式

速度反馈是另一种思路：不改串联通道，而是把对象的某一段“包”进一个小回路。设内环反馈为 $k_t s$（测速机），内环闭合后

$$G_i(s)=\frac{G_m(s)}{1+k_t s\,G_m(s)}$$

其中 $G_m(s)=10/[(s+2)(0.05s+1)]$ 是去掉积分器的机械+执行器部分。把 K_c 乘进去，整个开环可以写成

$$L(s)=K_c\,G_i(s)\cdot\frac{1}{s}=K_c\,G(s)\cdot\frac{1}{1+k_t s\,G_m(s)} \tag{43-10}$$

最后那个因子就是**等效串联校正器**。它和前面三种有本质区别：**它依赖对象 G_m**。对象换了，等效校正器自动跟着换，不需要重新设计。这是反馈校正鲁棒性好的根本原因，也是它无法用一张固定的 Bode 图描述的原因。

积分器留在内环外面，是为了保住型别——这一点很容易做错。如果把积分器也包进内环，闭环后系统会变成型 0，稳态误差直接变成有限值，K_v 失去意义。K_v 的表达式也因此变简单：

$$K_v=K_c\cdot\frac{10}{2+10k_t}\quad\Longrightarrow\quad K_c=4+20k_t \tag{43-11}$$

式 (43-11) 说明一件不太直观的事：**加了反馈，反而要把前置增益调大。** $k_t=0.8$ 时 K_c 要从 4 涨到 20，涨了 5 倍。原因就在分母那个 $2+10k_t$：反馈把低频增益压低了多少，前置增益就得补回多少。这一涨一补之间，裕度会发生什么，§43.4.6 的实测会给答案。

这个等效校正器在不同频段上"长什么样"，可以直接把 $k_t=0.2$ 的数值代进去看。它的直流增益是 $1/(1+10k_t/2)=0.5$，高频增益趋于 1，在 $\omega_c=8.4325$ 处是 $0.3592\angle+6.11^\circ$。

三个数放在一起，得到一条容易被忽略的结论：**速度反馈在频域上其实是一个超前环节。** 低频被压到 0.5，高频回到 1，中间给出正的相位——形状与超前网络一致，只是它不靠 RC 分压，而靠 $\dot\theta$ 的反馈量在高频自动消失。这也解释了为什么内环既能提高阻尼（给相位），又必然吃掉低频增益（压幅值）：两件事是同一个传递函数的两个面，不能只要一面。

在 $k_t=0.2$ 的复合方案里，外环的超前器要补 54.95°、放大 2.7603 倍，而内环等效环节在穿越点提供 6.11°、衰减 2.78 倍。两者一乘，净效果是 α 从 38.82 降到 10.31。**内环的 6° 只占 55° 里的一小截，它真正省下来的是那 2.78 倍的衰减**——衰减让 K_c 可以取到 8 而不把穿越点推高，外环于是不必为一个跑到 10 以上的 ω_c 付 α。

43.3 设计步骤

43.3.1 六步流程

校正设计最容易犯的错，是拿到指标就开始套公式。公式里的 α 是在"穿越频率不变"的假设下推出来的，可校正器一装上去，穿越频率立刻就变了。所以流程必须把"算"和"验"分开，中间留一个迭代环。

本章采用的六步：

1. **由误差指标定 K_c**：K_v 决定低频增益，这一步没有自由度。
2. **量相位缺口**：在目标穿越频率处，把对象各环节的相位逐项列出，算出还差多少度。
3. **选结构**：按缺口大小、噪声约束、带宽约束三选一。
4. **定参数**：超前算 α 与 ω_m，滞后算 β 与 z，超前-滞后解联立方程。
5. **校验**：裕度、M_s、时域指标三项都过，才算收敛。
6. **落地复核**：噪声、漂移、离散化、元件容差，四项在 §43.5 与 §43.10 展开。

六步里只有第 4 步是"算"，其余五步都是"查"。这不是保守，而是因为一阶校正器的参数与指标之间没有一一映射——同一个 α 放在不同的 ω_m 上，得到的裕度能差十几度。

43.3.2 第一步：由 K_v 定 K_c

主例的 $K_v=5K_c$，要求 $K_v=20$，于是 $K_c=4$，$e_{ss}=1/20=0.05$。这一步在 §43.2 已经做过，放在流程里是为了强调一件事：**K_c 不是可调参数，它是误差指标的直接换算结果。**

现场经常出现"先把增益调到不振，再想办法补误差"的做法，结果就是表 43-1 那条路：调到不振时 $K_c\approx 1$，误差 0.2；要误差 0.05 就得 $K_c=4$，回路已经临界。**顺序反了，后面全是补丁。**

正确顺序是先锁 K_c，再看裕度差多少。差得多，说明需要校正；差得少，可能只需要微调对象参数。这个判断能省掉大量无效设计。

43.3.3 第二步：量相位缺口

$K_c = 4$ 时穿越频率是 6.0291 rad/s。把对象在这个频率上的相位逐项拆开，就得到缺口的大小。表 43-5 是这份“相位预算”。

表 43-5　$K_c = 4$、$\omega_c = 6.0291$ rad/s 处的相位预算

环节	传递函数	该点相位 (°)	说明
积分器	$1/s$	-90.00	与频率无关，恒定贡献
机械极点	$1/(s+2)$	-71.66	极点已在穿越点之下 3 倍
执行器极点	$1/(0.05s+1)$	-16.77	时间常数小，贡献有限
合计	—	-178.43	距 -180° 仅 1.57°

表 43-5 最值得看的是第二行：机械极点 $\omega = 2$ 已经在穿越频率之下三倍，贡献了 71.66° 滞后。**这是全表最大的一笔，也是超前校正必须“顶”住的地方。** 想靠抬高穿越频率来解决是行不通的——穿越点越往右，这一项越接近 90°，缺口只会更大。

算缺口时有一个常见错误：把目标裕度直接当成“要补的相位”。本例目标 50°，现状 1.576°，缺口是 48.42°，不是 50°。少算这 1.6° 在校正后会被放大——因为穿越频率右移，实际缺口比静态计算更大。§43.3.5 会给出定量对比。

43.3.4 第三步：选结构

缺口算出来是 48.4°，接下来要选“用哪种方式补”。这不是偏好问题，而是由现场约束决定的。表 43-6 是本章建议的判据。

表 43-6　三种结构的选型判据

现场约束	首选	关键理由	主要代价
允许提速，传感器噪声小	超前	相位鼓包直接顶在穿越点上	高频增益 $= K_c\alpha$
高频噪声大，允许变慢	滞后	只压幅值，高频增益反而降	穿越频率退到 1 rad/s
既要速度又要裕度，元件不敏感	超前-滞后	两段分工，各管一段	参数翻倍，需迭代
对象增益漂移大，能装测速机	反馈/复合	等效校正器随对象变	多一个传感器与内环

判据的第一列是“约束”，不是“指标”。指标（50°）三种结构都能达到，差别全在约束上。这条区分很重要：**如果只按指标选型，三种结构看起来等价；按约束选型，往往只剩一种可选。**

主例的具体情况：执行器是电机，噪声主要来自编码器与 PWM，高频放大不可接受；但负载惯量小，提速有余量。两条合起来指向超前-滞后或复合，而不是单纯超前。本章仍把三种都算一遍，目的是让读者看到“同一个指标下三种代价”的完整图景。

43.3.5 第四步：定参数

超前先按式 (43-4) 粗算。缺口 48.42°，取 $\alpha = (1+\sin 48.42^\circ)/(1-\sin 48.42^\circ) \approx 6.94$。按这个值（$\omega_m$ 取使裕度最大的 12.577 rad/s）装上去，实测相位裕度只有 36.813°，离目标差 13.2°。

原因在 §43.2.3 已经埋下：α 抬高的是 ω_m 处的相位，而 ω_m 处增益被抬高了 $\sqrt{\alpha}$，穿越点右移，$\omega_c \neq \omega_m$。校正后的 ω_c 是 8.3846 rad/s，比 ω_m 高了三成，对象在那里的相位自然更差。反复迭代之后，α 一路涨到 **38.82**，比初值大 5.59 倍，裕度才到 50.346°。

这个 5.6 倍就是“朴素公式”与“工程设计”的差距。它不是公式错了，而是公式的前提（穿越频率不变）不成立。**凡是“用校正器改相位”的设计，都必须把穿越频率的移动一起算进去。**

`design_lead()` 用的是二维扫描：α 取 34 个对数点（1.5–80），ω_m 取 90 个对数点（0.3–60），对每个组合算一次裕度，取“能达到目标的最小 α”。这个做法比解析迭代慢，但不会陷进局部解，也能顺带回答“这个对象到底能不能用单级超前做到 50°”——答案是能，但 α 已经大得离谱。

还有一条更容易犯的错，值得单独摆出来。既然知道穿越点会右移，就有人“聪明”一点：先把 ω_m 直接放在设计目标 $\omega_c' = 10.2301$ 上，再按那里的相位缺口算 α。这个做法比第一种更像样，结果仍然不够。

算一遍。在 $\omega = 10.2301$ 处，$|G| = 0.083489$，$K_c|G| = 0.33396$，$\angle G = -196.028^\circ$。要在那里拿到 50° 裕度，校正器必须补 $50^\circ - 180^\circ + 196.028^\circ = 66.03^\circ$。由式 (43-4) 反解得 $\alpha = 22.19$，相应 $z = 2.1719$、$p = 48.1871$。装上去实测 $\varphi_M = 37.052^\circ$，$\omega_c = 14.3613$——离目标还差 12.9°，而且穿越点又跑到 14.36 去了。

两次尝试的欠账几乎一样：第一次差 13.2°，第二次差 12.9°。**这不是巧合，而是“忽略二次移动”的系统性偏差。** ω_c 抬高会继续消耗掉一部分新补的相位，而估算时只算了第一次移动。工程上有两种对付办法：一是按 1.3–1.5 倍的余量先把 α 放大，装上去再微调；二是干脆迭代或扫描，让算法去收敛。本章的 `design_lead()` 选了后者，代价是算得慢，好处是不用猜余量。

滞后的算法完全不同，它不需要迭代相位：先扫描 ω_c'，对每个候选算 $\beta = K_c|G(j\omega_c')|$，装上去量裕度，几何二分找到“裕度刚好等于 50°”的那个 ω_c'。60 次二分把区间压到 10^{-15} 量级，所以表 43-3 的三行裕度都是 50.000°，不是巧合。

超前-滞后按 §43.2.5 的联立方程迭代，先固定 ω_c' 与 d，再解 α 与 β。注意此时 ω_c' 是**人为指定**的，不是算出来的——这给了设计者一个额外的自由度：想要多快，就把 ω_c' 定多高。表 43-4 的三行就是这个自由度的三个取值。

43.3.6 第五步：校验与迭代

参数算完不算完，必须先做一次上限预判，再过三道校验。

第零道是上限预判，动手之前做。 单级超前不是万能的：$K_c = 4$ 时把 α 从 2 扫到 80、ω_m 从 0.5 扫到 60，相位裕度的最高点只有 52.572°，出现在 $\alpha = 80$、$\omega_m = 30.06$ 处，此时高频增益已经 320 倍。这条上限决定了目标值的合法范围，三个参考点足够画出一条成本曲线：45° 要 $\alpha = 15.655$（高频 62.6 倍），52° 要 $\alpha = 64.045$（256.2 倍），再往上就没有了。**从 45° 到 52° 只多 7°，代价是高频增益翻 4 倍**——这就是本章把目标定在 50° 而不是 55° 的原因。50° 在细网格上的最小值是 36.05，本章的 38.82 是粗网格 α 序列上的第一格，两者差 8%，对结论没有影响，但说明“设计值”从来不是“最优值”，只是“够用的那一格”。

上限为什么存在？两个原因叠在一起：α 增大让鼓包变高，峰位却钉在 ω_m 不动（$z = \omega_m/\sqrt{\alpha}$ 左移、$p = \omega_m\sqrt{\alpha}$ 右移），而 ω_c 被高频增益推着一直往右走。一旦 ω_c 越过 ω_m，相位取的就是鼓包的下降段——**峰再高，取的也是下坡上的值。** §43.9.1 表 43-22 里 φ_M 在 $\alpha = 4$ 处见顶、之后回落，就是同一个机理在固定 ω_m 下的表现。

第一道是裕度。 相位裕度、增益裕度、穿越频率三个数一起看。只看相位裕度会漏掉增益裕度不足的情形——§43.4.6 的反馈校正就是典型：$k_t = 0.8$ 时增益裕度 5.20 dB 看着还行，相位裕度只有 1.210°，闭环超调

96.27%。两个裕度必须同时达标。

第二道是 $M_s = \max|1/(1+L)|$。 它把“裕度”和“超调”两个指标统一到一个数上。主例的实测：纯增益 $M_s = 37.931$，超前 1.487，滞后 1.465，超前-滞后 1.587。工程上 $M_s < 2$（约 6 dB）是常用的验收线，四个数里除了纯增益全部合格。

第三道是时域。 阶跃响应的超调、上升时间、调节时间。频率域指标好看、时域却振铃的例子不少，原因是非最小相位零点或带宽外的谐振，一阶校正器本身不会引入这些，但对象可能有。

三道都过，才算收敛；任何一道不过，回到第 3 步换结构，而不是在第 4 步硬调参数。**结构错了，参数怎么调都是错的**——这是本章最想传递的一条经验。

“迭代”在这里不是“调参”，是把隐式方程解出来。 三种结构对应三种解法，收敛速度差得很远：

- 滞后：ω_c 与 β 互相定义，用几何二分，区间 $[0.05, 20]$，60 次是上限；实测 22 次就到 10^{-6}，后面三十几次纯属余量。
- 超前：没有单一方程可解，只能二维扫描，$34 \times 90 = 3060$ 个点，再在 ω_m 上做三轮细化（$0.2 \to 0.05 \to 0.012$，每轮 25 点）。所以 `design_lead()` 一次要算三千多次裕度，是本章所有脚本里最慢的一步。
- 超前-滞后：α 与 β 联立，用不动点迭代，误差每步乘 0.035（实测 $4.99 \times 10^{-2} \to 1.75 \times 10^{-3}$），11 次收敛到 10^{-12}。循环写 80 次是防御性的，不是必需的。

这三组收敛数据说明一件事：本章的“设计”没有一处靠手感，全部是可复现的数值解。 现场手算时用 §43.8.5 的三条校核代替；写代码时照抄这三个循环即可。反过来说，如果换了对象后迭代不收敛，那不是参数问题，是目标本身不可达——回到第零道。

43.4 连续情形

43.4.1 超前设计：三段权衡

表 43-7 是四个超前比的完整实测。四组参数由 `design_lead()` 与固定 α 的扫描分别给出，$K_c = 4$ 始终不变。

表 43-7　超前校正的四档实测（$K_c = 4$，$K_v = 20$）

α	z (rad/s)	p (rad/s)	ω_m (rad/s)	φ_M (°)	G_M (dB)	ω_c (rad/s)	超调 (%)	t_r (s)	t_s (s)	M_s	高频增益 (倍)
6.94	4.7743	33.1337	12.577	36.813	13.81	8.3846	38.01	0.1286	0.873	1.887	27.8
10	4.3963	43.9630	13.902	41.006	15.24	8.8749	32.34	0.1230	0.768	1.741	40.0
20	3.9534	79.0672	17.680	46.844	18.67	9.5900	24.89	0.1175	0.538	1.571	80.0
38.82	3.6137	140.2941	22.516	50.346	22.37	10.2301	20.73	0.1141	0.520	1.487	155.3

第一行对应“朴素公式”的结果：$\alpha = 6.94$，名义最大相位 $48.43°$，看起来刚好够；实测只有 $36.813°$。这一行是本章第一个“公式与实测不符”的证据。

往下三行，α 从 6.94 涨到 38.82（5.59 倍），收益是：相位裕度 $36.813° \to 50.346°$（+13.5°），超调 $38.01\% \to 20.73\%$（−17.3 个百分点），调节时间 $0.873 \to 0.520$ s（−40%）。代价是高频增益 $27.8 \to 155.3$ 倍（5.6 倍），G_M 从 13.81 涨到 22.37 dB。

注意 G_M 是**跟着变好**的。超前的极点在高频，它把高频幅值抬高，同时也把 -180° 穿越点往更高频推，而那里对象幅值已经很小，所以增益裕度反而增加。这是超前的一个附带好处，但不要把它当成主要理由——G_M 在很多对象上并不这么听话。

从第一行到第二行，α 只涨 44%，超调从 38.01% 掉到 32.34%，改善不算小；从第三行到第四行，α 接近翻倍，超调只从 24.89% 降到 20.73%，调节时间只从 0.538 s 降到 0.520 s。**这就是 §43.1.5 说的边际收益递减，在表里表现为最后一段“花钱多、办事少”。**

图 43-3 是 $\alpha = 38.82$ 这一组的 Bode 图与阶跃响应。左上是幅频，左下是相频，右侧是时域。

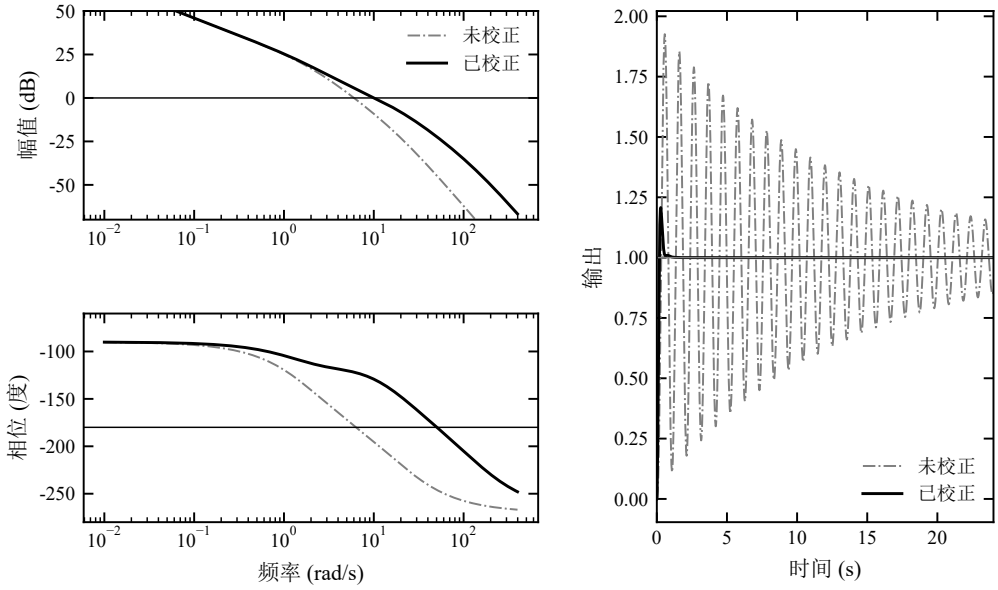

图 43-3　超前校正前后的 Bode 图与阶跃响应（$\alpha = 38.82$）

相位图上那段鼓包非常显眼：从 3.61 rad/s 起抬，到穿越点 10.2301 rad/s 时已经给出 66.37°，峰顶在 22.5 rad/s 处才到 71.76°，然后回落。**穿越点落在鼓包的上升段**——这正是“名义最大相位”与“实际补偿量”之间那 21.4° 差距的图形解释。

幅频图上，校正后的曲线在低频与未校正重合（K_c 相同），中频抬升，高频一路抬到 $+43.8$ dB（即 $|C(\infty)| = 155.3$ 倍，比未校正的 $K_c = 4$ 高出 31.8 dB）。这条“翘尾巴”就是噪声代价的直接图像。

43.4.2 滞后设计：三档零点位置

表 43-8 是三档 d 的完整实测，参数来自 `design_lag()` 的几何二分。

表 43-8　滞后校正的三档实测（$K_c = 4$，目标 $\varphi_M = 50^\circ$）

d	z (rad/s)	p (rad/s)	β	φ_M (°)	G_M (dB)	ω_c (rad/s)	超调 (%)	t_r (s)	t_s (s)	M_s	校正器相位 (°)
4	0.22102	0.010693	20.671	50.000	26.07	0.9062	25.54	1.2306	10.678	1.439	−13.03
5	0.19730	0.010864	18.160	50.000	25.07	1.0022	24.58	1.1297	10.913	1.465	−10.52
10	0.12086	0.008550	14.137	50.000	23.28	1.2133	21.88	0.9696	11.940	1.513	−5.28

三行的相位裕度完全一样，增益裕度却差 2.79 dB，穿越频率差 34%，调节时间差 11.8%。**“相位裕度达标”远不等于“设计完成”**，这张表是最好的证据。

有一个反直觉的现象：$d=4$ 的上升时间最长（1.2306 s），调节时间却最短（10.678 s）；$d=10$ 的上升时间最短（0.9696 s），调节时间最长（11.940 s）。原因是调节时间由**最慢的闭环极点**决定，而 d 越小，零点越靠近穿越点，闭环主导极点的阻尼越大、振铃衰减越快。快慢是两件事：前沿快慢看带宽，尾巴长短看阻尼。

时间尺度上还有一个必须接受的现实：滞后的调节时间在 10.7–11.9 s，是超前的 20 倍。这不是参数没调好，而是 ω_c 被压到 1 rad/s 的必然结果——闭环带宽大致正比于 ω_c，带宽低 10 倍，时间就长 10 倍。

图 43-4 是 $d=5$ 这一组的 Bode 图与阶跃响应，可以和图 43-3 对照着看。

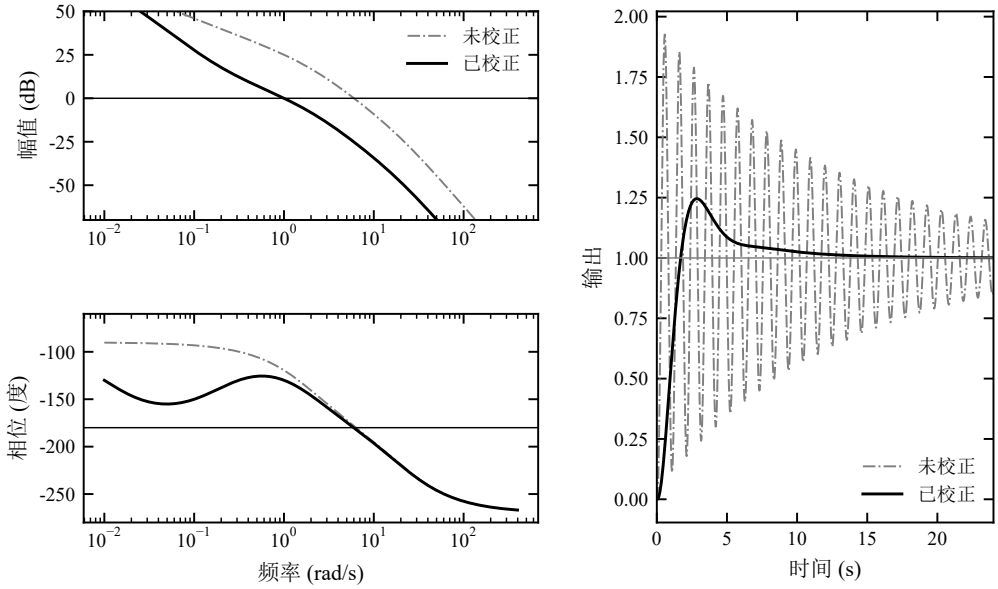

图 43-4　滞后校正前后的 Bode 图与阶跃响应（$d=5$）

幅频图上，校正后的曲线在低频与未校正重合，中频开始下压，高频压到 $K_c/\beta=0.2203$（比未校正的 $K_c=4$ 低 25.2 dB）。相频图上多了一段负相位，最低点在 0.2 rad/s 附近，然后回升——穿越点 1.0022 rad/s 落在这段回升区，所以只吃了 -10.52°。

阶跃响应的时间轴要拉到 24 s 才看得完整，而图 43-3 的横轴同样是 24 s，曲线早已稳定。**两张图的横轴一样、曲线占据的比例完全不同**，这个视觉差比任何数字都更直观地说明“滞后是用时间换裕度”。

43.4.3 超前-滞后：把穿越频率当旋钮

超前-滞后多了一个自由度：目标穿越频率 ω_c' 由设计者指定。表 43-9 是 $\omega_c'=2/3/4$ 三档的实测。

表 43-9　超前-滞后的三档实测（$K_c=4$，$d=5$）

ω_c' (rad/s)	α	z_d (rad/s)	p_d (rad/s)	z_l (rad/s)	p_l (rad/s)	β	φ_M (°)	G_M (dB)	ω_c (rad/s)	超调 (%)	t_s (s)	M_s
2.0	2.109	1.3772	2.9045	0.4000	0.03915	10.218	49.599	19.03	2.0328	24.19	5.893	1.568
3.0	3.613	1.5783	5.7024	0.6000	0.08631	6.951	49.584	16.80	3.0488	23.61	3.948	1.587
4.0	5.504	1.7050	9.3843	0.8000	0.15552	5.144	49.596	15.70	4.0641	23.24	2.863	1.595

三行的相位裕度都稳定在 49.6° 附近，超调都在 23%–24%，M_s 都在 1.57–1.60。**变的是速度**：ω_c' 从 2 提到 4，调节时间从 5.893 s 降到 2.863 s，降了一半。

代价在 G_M 上：19.03 → 15.70 dB，降了 3.33 dB。原因还是穿越点上移——ω_c 越靠近执行器极点，高频段的相位下降越快，能容忍的增益倍数就越小。

这张表还回答了一个选型问题：**如果指标只要求“裕度 50°、超调 25%”，超前-滞后在 $\omega_c'=4$ 时给出 2.863 s，比超前的 0.520 s 慢 5.5 倍，但高频增益只有 $K_c\alpha/\beta = 4\times 5.504/5.144 \approx 4.3$ 倍，约是超前的三十六分之一。** 这就是它存在的理由：在速度和噪声之间找一个双方都能接受的中间点。

注意 β 与 α 的反向变化（5.144 与 5.504，10.218 与 2.109）。这不是巧合：ω_c' 越高，对象幅值越小，滞后段需要压的倍数越少；同时对象相位越差，超前段需要补的越多。两段此消彼长，总代价大致守恒。

把 $\omega_c'=3$ 这一组的账在穿越点 $\omega_c=3.0488$ 处拆开，能看清“两段接力”到底是怎样接的：

- 对象：$|G|=0.889274$，$\angle G=-155.403^\circ$。
- 滞后段：$|C_l|=0.14656$（-16.68 dB），$\angle C_l=-9.512^\circ$。
- 超前段：$|C_d|=1.9182$（$+5.66$ dB），$\angle C_d=+34.499^\circ$。
- 合成：$K_c|C_l||C_d||G| = 4\times 0.14656\times 1.9182\times 0.889274 = 1.000$，相位 $-155.403-9.512+34.499=-130.416^\circ$，裕度 49.584°。

这张流水账说明三件事。第一，**滞后段压掉的 16.68 dB 并不是白压**：没有它，$|L|$ 会是 $4\times 1.9182\times 0.889274=6.82$，穿越点还在 4 rad/s 以上，超前的 34.5° 救不回来。第二，**超前段只补回了 5.66 dB，净效果仍是 -11.02 dB**——它与滞后段的幅值作用方向相反，但量级差了三倍，所以净结果是“压”。第三，**两段的相位贡献相加是 $+24.99^\circ$，而不是“滞后拉后腿、超前全顶上”**：滞后段的 -9.5° 确实吃掉了超前的四分之一，但它在幅值上换回来的更多。

这也解释了为什么超前-滞后的 α 比单级超前小得多（3.613 对 38.82）：它需要的净相位只有 25.0°，而不像单级超前那样要在高得多的 ω_c 处补 66.4°。**穿越频率的选择，等价于选择了“要补多少相位”。**

43.4.4 四结构同台

把前面三组的最优解与纯增益放在一起，K_v 全部锁在 20，得到表 43-10。这是本章最该记住的一张表。

读这张表之前，先把它和第 41 章表 41-13 分清楚。那张表也对比了四种补偿器，但前提正好相反：那里把 φ_M 全锁在 50°，让增益自由（比例 0.3578、超前 3.0343、滞后 0.0112、超前-滞后 2.0053）；本表把 K_v 全锁在 20，让裕度自由。**前者的问法是“给定裕度，哪种结构最省”，后者的问法是“给定精度，哪种结构最稳”。** 两张表的 ω_c 因此整体错开：表 41-13 从 0.2006 到 4.2155，表 43-10 从 1.0022 到 10.2301；除超前-滞后那一行几乎重合（3.0488 对 3.1155）之外，其余三行都比前者靠右一大截——因为 K_v 从 1.94 抬到 20，整条幅频曲线先被抬高了 20 dB。这不是矛盾，而是同一道题的两种问法：现场先定哪一头，就查哪一张。

表 43-10　四种结构在同一 $K_v=20$ 下的对照

结构	φ_M (°)	G_M (dB)	ω_c (rad/s)	M_s	超调 (%)	t_r (s)	t_s (s)	高频增益 (倍)
纯增益	1.576	0.83	6.0291	37.931	92.45	0.1807	49.940	4.000
超前	50.346	22.37	10.2301	1.487	20.73	0.1141	0.520	155.292
滞后	50.000	25.07	1.0022	1.465	24.58	1.1297	10.913	0.220
超前-滞后	49.584	16.80	3.0488	1.587	23.61	0.3680	3.948	2.079

四个“第一”分散在不同列，没有哪一行能全拿：

- 调节时间最短：超前，0.520 s。
- 超调最低：超前，20.73%。
- M_s 最小：滞后，1.465。
- 增益裕度最高：滞后，25.07 dB。
- 高频增益最低：滞后，0.220 倍——比它自己的直流增益 4 还低 18 倍，因为滞后网络在高频本来就是衰减的。
- 带宽最高：超前，10.2301 rad/s。

把六列的极差算出来，还能看出这张表的“不公平”：t_s 的最好与最差相差 96 倍（0.520 对 49.940），高频增益相差 706 倍（155.292 对 0.220），而相位裕度的差距只有 48.8°。**极差越大的列，越不可能是“顺便兼顾”来的，它一定由结构决定。** 时间与噪声属于这一类，裕度属于“只要肯付代价就能买到”的那一类。

还有一处容易看反：超调最低（20.73%）的是超前，M_s 最小（1.465）的却是滞后。M_s 只描述频域的谐振峰，超调还取决于闭环零点与阻尼，两者排序不一致，正好说明 §43.6.5 那条“从裕度到超调”的换算只在同一结构内部可信，跨结构比较会失灵。**判“稳不稳”用 M_s，判“跳多高”必须看时域。**

这张表的正确读法是“按约束挑行”，不是“按总分挑行”。 现场如果噪声预算是 10 倍以内，超前直接出局（155.3 倍）；如果时间是硬指标（比如 1 s 内必须到位），滞后直接出局（10.9 s）。剩下的候选往往只有一个。

图 43-5 与图 43-6 分别从时域与频域展示这四条曲线。

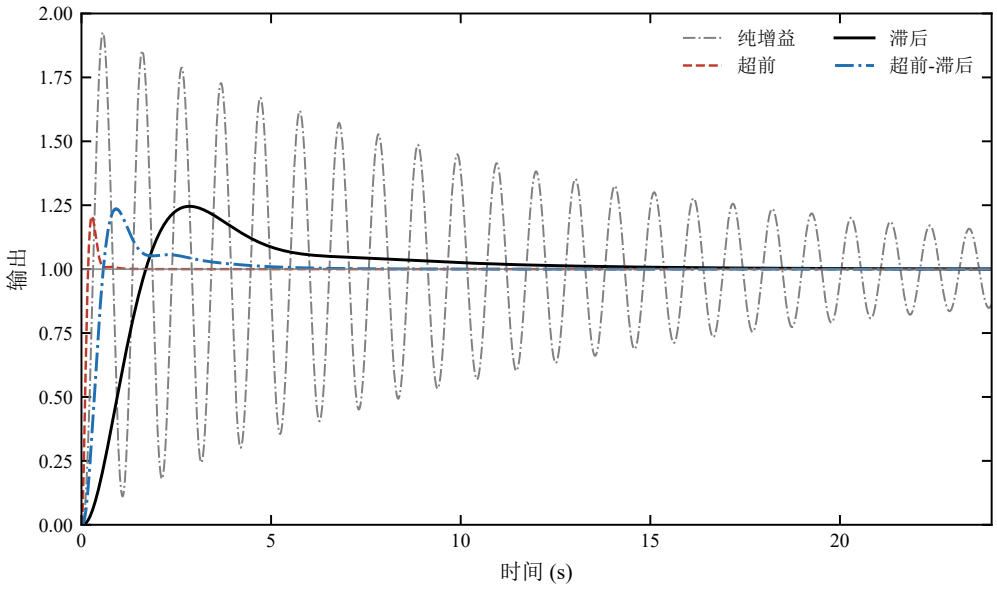

图 43-5　四种结构的闭环阶跃响应

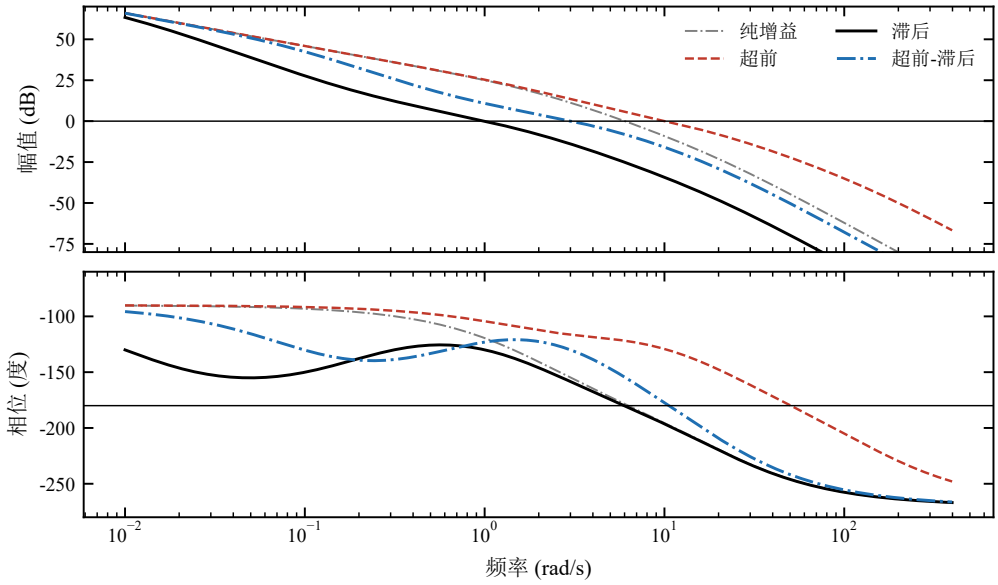

图 43-6　四种结构的开环 Bode 图

时域图上，纯增益那条在 0.18 s 冲到接近 2.0，然后在 1.9 附近长时间振铃——$t_s = 49.940$ s 不是它“还在动”，而是它一直没进 ±2% 带。超前那条几乎是一条带小过冲的指数上升；滞后那条慢得像另一个系统；超前-滞后居中。

43.4.5 Bode 图上的四种性格

图 43-6 值得逐段读，因为它把三种校正器的“作用频段”画得很清楚。

低频段（< 0.1 rad/s）：四条曲线完全重合。这不是巧合，而是设计的硬约束——所有方案的 K_c 都是 4，低频增益必须相同，否则 K_v 就变了。**校正器只在低频以外动手。**

中频段（0.1–5 rad/s）：滞后那条最先掉下去，因为它的零点在 0.1973 rad/s 就开始压幅值；超前-滞后在 0.6 rad/s 附近也掉，但幅度小；超前那条不掉，反而在 3.6 rad/s 之后往上抬。

高频段（> 10 rad/s）：超前那条一路抬到 $+43.8$ dB，滞后那条压在 -13.1 dB（比纯增益的 $+12.0$ dB 还低 25.2 dB），超前-滞后落在 $+6.4$ dB。这一段的高度直接对应噪声放大倍数，也是三条曲线差别最大的地方。

相位图：滞后那条有一段明显的“下凹”，最低点在 0.2 rad/s 附近；超前那条有一段明显的“上凸”，顶点在 22.5 rad/s；超前-滞后则是一个“先下后上”的 S 形。三种形状对应三种补偿机制，看相位曲线就能判断装的是哪种校正器。

还有一个细节容易被忽略：四条曲线的相位在高频都趋于 $-270°$（三个极点），但趋近的速度不同。滞后那条趋近得最慢，因为它的极点在最左边（0.010864 rad/s），对高频几乎没影响；超前那条趋近得最快，因为它的极点在 140.2941 rad/s，高频段相位已经回落。

43.4.6 反馈与复合

反馈校正的实测分三组，全部在 `[5b]` 段打印。第一组固定 $K_v = 20$，看 k_t 变化时会发生什么。

表 43-11　速度反馈内环（固定 $K_v = 20$，$K_c = 4 + 20k_t$）

k_t	K_c	φ_M (°)	G_M (dB)	ω_c (rad/s)	超调 (%)	t_r (s)	t_s (s)
0.1	6	2.926	2.92	5.3417	91.65	0.1969	28.791
0.2	8	2.586	3.81	5.0774	92.89	0.2052	34.029
0.4	12	1.909	4.61	4.8494	94.88	0.2132	48.587
0.8	20	1.210	5.20	4.6875	96.27	0.2197	59.877
1.2	28	0.881	5.44	4.6229	96.61	0.2226	—

这张表最刺眼的地方是：增益裕度从 2.92 dB 一路涨到 5.44 dB，相位裕度却从 2.926° 掉到 0.881°，超调从 91.65% 涨到 96.61%。**两个裕度给出了相反的结论。** 原因在 §43.6.1 展开，这里先记住现象。

第二组固定 $K_c = 4$，只看内环本身的效果。

表 43-12　速度反馈内环（固定 $K_c = 4$，K_v 随 k_t 下降）

k_t	K_v	φ_M (°)	G_M (dB)	ω_c (rad/s)	超调 (%)	t_s (s)	内环极点 (rad/s)
0	20.00	1.576	0.83	6.0291	92.45	49.940	−20.0，−2.0
0.1	13.33	6.581	6.44	4.3500	83.15	15.198	−41.025，−0.975
0.2	10.00	6.987	9.83	3.5787	82.43	17.591	−61.348，−0.652
0.4	6.67	6.453	14.15	2.7917	83.72	24.751	−101.6063，−0.3937
0.8	4.00	5.345	19.18	2.0920	86.46	39.157	−181.78，−0.220
2.0	1.82	3.757	26.49	1.3754	102.54	58.700	−421.91，−0.0948

不加前置增益补偿时，内环确实起了作用：相位裕度从 1.576° 提到 6.987°（$k_t = 0.2$），超调从 92.45% 降到 82.43%。**但代价是 K_v 从 20 掉到 10——误差翻倍。** 这就是式 (43-11) 的另一面：反馈把低频增益吃掉了。

再看内环极点：$k_t = 0.2$ 时是 −61.348 与 −0.652，一快一慢，慢的那个从 −2.0 退到 −0.652。**速度反馈把快速极点推得更快，却把慢速极点拖得更慢**，这两件事同时发生，所以相位裕度只改善了 5.4°。

第三组是复合校正：内环照旧，外环加一级超前，K_c 按式 (43-11) 补回 $K_v = 20$。表 43-13 是实测，最后一列是“对象增益 +40% 后的相位裕度跌了多少”。

表 43-13　复合校正（内环 k_t + 外环超前，$K_v = 20$）

k_t	α	z (rad/s)	p (rad/s)	φ_M (°)	G_M (dB)	ω_c (rad/s)	t_s (s)	增益 +40% 后 φ_M (°)	跌幅 (°)
0	38.82	3.6137	140.2941	50.35	22.37	10.230	0.520	37.85	12.498
0.1	11.63	3.4051	39.6180	50.60	18.32	8.749	0.780	45.53	5.074
0.2	10.31	3.1580	32.5716	51.55	20.02	8.433	0.853	48.39	3.159
0.4	9.14	2.9747	27.1975	51.49	23.09	8.077	0.903	49.42	2.067
0.8	8.11	2.8776	23.3231	50.44	27.37	7.734	0.923	48.90	1.535

这张表是本章最有价值的一组数据。加一个 $k_t = 0.2$ 的速度内环，外环超前比从 38.82 降到 10.31（降 3.8 倍），相位裕度反而略高（51.55° vs 50.35°）。代价是调节时间从 0.520 s 涨到 0.853 s（+64%）。

但**噪声账不能只看 α**。复合校正的前置增益是 $K_c = 4 + 20k_t = 8$，不是 4；校正器的高频增益是 $K_c\alpha = 8 \times 10.31 = 82.5$ 倍，相对单级的 155.3 倍只降了 1.88 倍，不是 3.8 倍。α 省下的那一半，被补 K_v 的前置增益又收回去了——这是式 (43-11) 的必然结果，绕不过去。同一套离散仿真口径（$T_s = 0.02$、噪声 0.01）实测：单级超前的执行器 u 的 RMS 是 2.24274，复合是 0.96854，降 2.32 倍。**比 1.88 倍还多一点的这部分，来自内环把对象的高频滚降变陡了**：等效对象在 10^3 rad/s 以上的衰减更快，噪声经过它时多掉了一截。

更关键的是最后一列：对象增益 +40% 时，纯超前的裕度跌 12.498°，复合只跌 3.159°——**鲁棒性提升约 4 倍**。这就是 §43.2.6 说的“等效校正器随对象变”的实测证据：内环自己会跟着对象增益调整，外环不需要知道。

43.5 离散情形

43.5.1 采样周期是第一道门槛

前面四节的所有数字都建立在“校正器是一个连续传递函数”这个假设上。现场不成立。校正器要么用运放加阻容搭出来（连续，但受元件容差与漂移限制），要么写进单片机（离散，必须先变成差分方程）。后者要迈的第一道坎是离散化，而离散化会引入一个连续世界里根本不存在的惩罚——**采样延迟**。

用一句话概括：采样周期 T_s 把控制作用平均拖后半个采样周期，这段延迟落在穿越频率处就折算成相位损失。损失量既与穿越频率成正比，也与采样周期成正比，与校正器是超前还是滞后无关。这个“与类型无关”的性质很关键，它说明采样惩罚是**回路**的性质，不是**元件**的性质。

先算量级。本章的超前校正把穿越频率推到 10.2301 rad/s，一个采样周期内相位推进 $\omega_c T_s$ 弧度；零阶保持器平均滞后半个周期，于是

$$\Delta\varphi \approx \frac{\omega_c T_s}{2}\ (\text{rad}) = \frac{180\,\omega_c T_s}{2\pi}\ (^\circ) \tag{43-12}$$

按式 (43-12)，要让损失不超过 5°，需要 $T_s < 0.1745/\omega_c$。代进 $\omega_c = 10.2301$，得 $T_s < 0.0171$ s，采样率高于 58 Hz。这个结论比多数人的直觉严格得多：带宽 10.23 rad/s 只合 1.63 Hz，按“采样比带宽快十倍”的经验给 16 Hz，损失已经 18°。

滞后校正的处境完全相反。它的穿越频率是 1.0022 rad/s，同样的 5° 预算允许 $T_s < 0.174$ s，放宽了一个数量级。**同一个采样周期，对超前是灾难，对滞后几乎无感**——这不是巧合，而是式 (43-12) 里那个 ω_c 的直接后果。

43.5.2 直接 Tustin：代价可以算出来

最省事的做法是：连续域设计好 $C(s)$，用双线性变换直接搬进 z 域，对象用零阶保持器离散，然后在单位圆上数裕度。表 43-14 是四档采样周期的实测（`[6]` 段），首行是连续域的基准。

表 43-14　同一连续校正器直接 Tustin 后的数字域裕度

T_s (s)	滞后 φ_M (°)	滞后 G_M (dB)	滞后 ω_c (rad/s)	超前 φ_M (°)	超前 G_M (dB)	超前 ω_c (rad/s)
连续	50.000	25.07	1.0022	50.346	22.37	10.2301
0.02	49.460	23.36	1.0001	44.516	14.15	10.2367
0.05	48.584	21.35	1.0012	35.743	8.49	10.3006
0.10	47.156	18.84	1.0012	20.347	3.26	10.5750
0.20	44.324	15.43	1.0006	失稳	−2.37	—

滞后那一半几乎不受影响：$T_s = 0.20$ 这样粗的周期，裕度也只掉 5.676°，穿越频率几乎不动。超前那一半是另一回事：$T_s = 0.02$ 就掉 5.830°，$T_s = 0.10$ 掉 29.999°，$T_s = 0.20$ 时相位裕度已经不存在——增益裕度是负的 −2.37 dB，回路本来就振荡了。

把损失与式 (43-12) 的预测并排放，会发现两列几乎重合：

T_s	滞后实测损失	式 (43-12) 预测	超前实测损失	式 (43-12) 预测
0.02	0.540	0.573	5.830	5.865
0.05	1.416	1.434	14.603	14.755
0.10	2.844	2.868	29.999	30.295
0.20	5.676	5.733	失稳	约 58.4

七组可用数据的偏差都在 0.3° 以内，而且偏的方向一致——实测总比预测略小，因为穿越点在损失发生后会轻微左移，自己把损失压回去一点。**这张表的意义是：采样惩罚不是一种模糊的“性能下降”，它是半拍延迟的几何后果，可以在设计之前算清。** 只要算出来不超过预算，离散实现就是安全的；算出来超了，再怎么调 Tustin 的公式都救不回来。

图 43-7 把表 43-14 画成曲线，横轴是采样周期，纵轴是相位裕度。两条线的形状差别一目了然：滞后那条几乎是水平线，超前那条在 0.05 s 之后陡降。

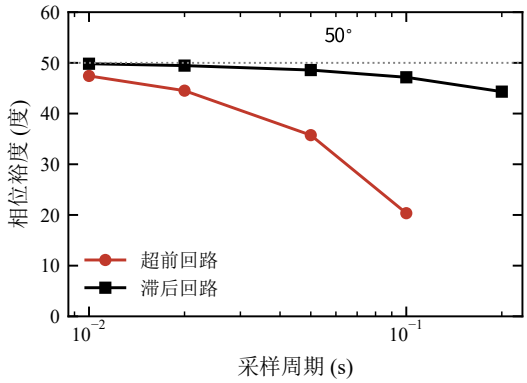

图 43-7　采样周期对两种校正结构相位裕度的影响

图上还有一处值得注意：超前那条线在 $T_s = 0.05$ 到 0.10 之间斜率最大，恰好落在“工程上最常用”的采样周期区间。多数 PLC 的快速任务周期是 50–100 ms，多数单片机的控制中断是 10–20 ms；前者对超前校正已经致命，后者也只是勉强。**选采样周期时不能用“比带宽快十倍”这种模糊口径，得用式 (43-12) 算。**

43.5.3 那个趋近 −1 的极点

表 43-14 里超前在 $T_s = 0.20$ 时直接失稳，值得单独看一眼原因。

双线性变换把 s 平面的虚轴卷到单位圆上，把 $s \to \infty$ 映到 $z = -1$。超前校正器的极点在 $p = 140.2941$ rad/s，映射公式是

$$z_p = \frac{1 - pT_s/2}{1 + pT_s/2}$$

四档采样周期下，这个极点离原点的距离分别是 0.1677、0.5563、0.7505、0.8669。数字是单调上升的，而且上升得很快：T_s 每翻一倍，极点就明显往 −1 逼近一步。零点的情况相反，$z = 3.6137$ 映射后落在正实轴的 0.8343（$T_s = 0.05$）与 0.4691（$T_s = 0.20$）上，始终在右半圆。

零极点分居实轴两侧，这是离散超前器与连续超前器最本质的区别。连续域里，零点与极点都在负实轴上，相位贡献是一段从 0 抬到 $+90^\circ$、再回落到 0 的“鼓包”。离散域里，零点跑到正实轴，相位从 0 出发先向负方向走一段（因为极点更靠近 −1），再被零点拉回来——**鼓包变成了一段跨过整个上半圆的斜坡**，峰值自然下降，形状自然变平。

所以“离散后失稳”不是校正器本身坏了。四档下 $|z_p|$ 都小于 1，校正器自己是稳定的。坏的是它与延迟的配合：极点越靠近 −1，它在 Nyquist 频率附近的相位就越陡；叠加零阶保持器的半拍延迟之后，回路在 ω_c 附近一路穿过 -180°，再也回不来。

最不划算的地方在这里：**Tustin 保持 $C(\infty)$ 不变，高频增益一点没少，相位收益却被削掉一大半。** 表 43-10 里超前的高频增益是 155.3 倍，$T_s = 0.20$ 时这个倍数还在，可裕度从 50.346° 变成负的。付了噪声的钱，没买到稳定。

43.5.4 w 域：把单位圆重新拉直

既然问题出在频率轴的折叠上，那就把它重新摊平。w 变换就是干这件事的：先做 Tustin 的逆运算，再把结果投到一条新的虚轴上，

$$z = \frac{1 + hw}{1 - hw}, \qquad h = \frac{T_s}{2}, \qquad \omega_w = \frac{2}{T_s}\tan\frac{\omega T_s}{2} \tag{43-13}$$

这个变换有两个性质，决定了它在工程上的地位。

第一，它是**恒等映射**。z 域某点 $z = e^{j\omega T_s}$ 与 w 域某点 $w = j\omega_w$ 严格对应同一个复数，频率响应完全相等。所以离散系统的裕度可以在 w 域里用连续域的全套工具算——Bode 图、相位计算公式、§43.2 的 α 与 ω_m 关系，一个都不用改。

第二，它是**频率预畸变**。ω 从 0 走到 π/T_s，ω_w 从 0 走到 ∞；低频段 $\omega_w \approx \omega$，高频段 ω_w 被拉伸。表 43-15 是 $T_s = 0.05$ 的四点校验（`[7]` 段）。

表 43-15　$z \to w$ 变换的频率校验（$T_s = 0.05$ s）

ω (rad/s)	ω_w (rad/s)	相对拉伸	相位差 (°)	$\omega T_s/2$ (°)
0.5	0.500	0.0%	−0.716	0.716
1.0	1.000	0.0%	−1.432	1.432
2.0	2.002	+0.1%	−2.865	2.865
5.0	5.026	+0.5%	−7.163	7.163

最后一列是照抄式 (43-12) 算出来的半拍延迟。两列数字一模一样，这不是拟合出来的，而是必然的：G_w 是零阶保持器离散对象的 w 变换，它当然含有那半拍延迟；w 变换只是把这个延迟原封不动地搬到新坐标里。

顺带核对幅值。$\omega = 0.5$ 处 $|G_w| = 9.698141$，$|G| = 9.698395$，相对差 2.6×10^{-5}，纯数值误差。这说明 z→w 的代数运算没有引入任何近似，表里那 7.163° 的相位差全部来自零阶保持器。

预畸变这一半，在低频段几乎看不见，到了穿越频率就不能忽略。$T_s = 0.05$ 时，$\omega = 2.0$ 对应的 $\omega_w = 2.0017$（拉伸 0.08%），$\omega = 5.0$ 对应 5.0262（0.52%），$\omega = 10.0$ 对应 10.2137（2.14%），$\omega = 10.2301$ 对应 10.4591（2.24%）。

2.24% 这个数看着小，用法上却是个硬坑。 设计时如果想“把 ω_m 放在 10.2301”，在 w 域里必须写 10.4591；直接把 10.2301 代进去，等于把鼓包往低频挪了 2.2%，而按表 43-2 的斜率，这会让 α 多花几个百分点。频率越高、采样越粗，拉伸越大：$T_s = 0.2$ 时 $\omega = 5$ 会映到 5.47，拉伸 9.4%。**所以 w 域设计的每一步都要问一句“这个频率是真实频率还是 w 频率”，两者在低频可以混用，在 ω_c 附近不行。**

这一条把很多人对 w 域的误解点破了：w 域不消除延迟，它只是把延迟显式地放进模型里。 它的价值在于——你在这个模型上设计出来的 50°，落地之后还是 50°，因为设计时用的就是含延迟的真实对象。而直接 Tustin 的 50° 是“没有延迟的世界里的 50°”，落地后要打折。

43.5.5 在 w 域重新设计

流程四步，一步都不能省：

1. 对象用零阶保持器离散成 $G(z)$；
2. 用式 (43-13) 把 $G(z)$ 变成 $G_w(w)$；
3. 在 w 域按 §43.3 的六步流程设计 $C_w(w)$；
4. 把 $C_w(w)$ 的一阶因子用 Tustin 映回 z 域。

第四步的映射有一个必须遵守的细节：**因子形式要逐项映，不要先把整个 C_w 展开成多项式再映。** 一阶因子 $(1 + w/z_w)/(1 + w/p_w)$ 映回 z 域的结果是

$$C(z) = K_c \,\frac{(1 + a_1) + (1 - a_1) z^{-1}}{(1 + a_2) + (1 - a_2) z^{-1}}, \qquad a_1 = \frac{2}{T_s z_w}, \quad a_2 = \frac{2}{T_s p_w} \tag{43-14}$$

在 $z = 1$ 处分子分母都等于 2，所以 $C(1) = K_c$，直流增益自动保住——这一点很重要，它保证了 K_v 不变、稳态误差不变。如果在 w 域就把分子分母乘开再映射，高阶项的系数会被数值误差污染，直流增益可能偏出千分之几。

表 43-16 是两个场景的前后对照（`[7]` 段）。

表 43-16　直接 Tustin 与 w 域重设计的对照

场景	做法	φ_M (°)	G_M (dB)	ω_c (rad/s)
$T_s = 0.20$ 滞后	直接 Tustin	44.324	15.43	1.0006
$T_s = 0.20$ 滞后	w 域重设计	50.004	17.63	0.821
$T_s = 0.05$ 超前	直接 Tustin	35.743	8.49	10.3006
$T_s = 0.05$ 超前	w 域重设计（单级）	无可行解，上限 38.298	—	—
$T_s = 0.05$ 超前	w 域重设计（两级）	51.261	7.02	10.688

滞后那一行是标准的成功案例。w 域给出的参数是 $z_w = 0.16180$、$p_w = 0.007056$、$\beta = 22.931$，映回 z 域后数字域实测 50.004°、增益裕度 17.63 dB——目标 50° 一分不差地拿到了。代价藏在第三列：ω_c 从 1.0006 压到 0.821，又慢了 18%。**补回延迟只能靠继续往低频退**，带宽是拿不回来的。

超前那一行是失败案例，而且是很有教育意义的失败。$T_s = 0.05$ 时 w 域里单级超前**根本无解**：把 α 从 2 一路扫到 80，最高的相位裕度只有 38.298°，落在 $\alpha = 80$、$\omega_m = 35.05$ 处。原因在 §43.5.6 展开。

43.5.6 单级不够时：两级接力

单级为什么无解？把 §43.2 的 α–φ_m 关系与式 (43-12) 叠在一起看就清楚了。

α 从 10 加到 80，最大相位从 55° 涨到 83.6°，账面上多了 28.6°。但同时，$\omega_m = \sqrt{zp}$ 被推高，穿越点跟着右移，延迟损失按 $\omega_c T_s/2$ 线性增长：ω_c 从 8.7 推到 35，loss 从 12.5° 涨到 50.2°。**一边加 28.6°，一边多付 37.7°，净收益是负的。**

更糟的是这个反馈是正反馈式的：加大 α 唯一能拿到相位的手段就是抬高 ω_m，而抬高 ω_m 必然增加延迟损失。所以单级超前的裕度存在一个上限，上限处 $\alpha \to \infty$ 而收益趋于零。主例的上限就是 38.298°。

出路不是加高鼓包，而是把极点搬回低频段：把同样的总超前比拆成两个小 α，放在两个错开的频率上。实测方案是 α 各 6.30、ω_m 分别 12.52 与 25.04，合成后的数字域裕度是 51.261°、增益裕度 7.02 dB、$\omega_c = 10.688$。

它能成的道理不在鼓包形状，在极点位置。单级 $\alpha = 80$ 要把极点放到 $p = \omega_m\sqrt{\alpha} = 35.05 \times 8.944 \approx 313$ rad/s；$T_s = 0.05$ 的双线性变换把它映到 $z = (1 - pT_s/2)/(1 + pT_s/2) = -0.774$，紧贴单位圆左端，它在 ω_c 附近贡献的相位几乎全被延迟抵掉。两级各 6.30 的极点只到 31.4 与 62.9 rad/s，映射后分别落在 $+0.120$ 与 -0.223，离 -1 远得多。**所以两级的真正好处不是“鼓包更宽”，而是把极点从 313 rad/s 搬到了 63 rad/s 以下**——§43.5.3 那条“极点趋近 -1”的曲线，才是单级无解的根本原因。

代价要写清：

- 元件翻倍，运放从一只变两只，电路板面积和调试工作量都翻倍；
- 高频增益是 $4 \times 6.30^2 = 158.8$ 倍，与单级 $\alpha = 80$ 的 320 倍相比反而更低，噪声上占便宜；
- 增益裕度只有 7.02 dB，比连续设计的 22.37 dB 低一大截。原因是两级超前的相位在高频下落得慢，相位穿越点被推得很远，-180° 处的幅值仍然偏高。
- 调节时间会从 0.52 s 涨上来，因为相位平台把有效带宽摊薄了。

本节的结论可以收成三条：

1. **采样周期的硬线是 $T_s \le 0.1745/\omega_c$**（5° 预算），工程上取这条线的三分之一到一半更稳妥。用“比带宽快十倍”来定周期，在超前校正上会直接翻车。

2. **离散化的代价与穿越频率成正比**，所以低频段（$\omega_c < 2$ rad/s）的数字实现几乎免费，高频段的数字实现要按式 (43-12) 逐项算账。
3. **w 域重设计能补回裕度，补不回带宽**；单级补不回来时，优先考虑两级错开频率，而不是继续加大 α——后者的收益在采样受限时是负的。

43.6 稳定性与性能

43.6.1 一张表里两个裕度打架

表 43-11 里有一件怪事：k_t 从 0.1 加到 1.2，增益裕度从 2.92 dB 一路涨到 5.44 dB，看起来越来越稳；可相位裕度从 2.926° 掉到 0.881°，超调从 91.65% 涨到 96.61%，t_s 从 28.8 s 拖到 60 s 以上。**两个裕度给出了完全相反的判断。**

如果只看增益裕度，会得出“速度反馈让系统更稳定”的结论；如果只看时域曲线，会得出“速度反馈让系统更糟”的结论。两者都对，但都不完整。要把它们统一起来，必须先弄清这两个数各自在量什么。

G_M 量的是**相位穿越点**处的幅值：找到相位等于 -180° 的频率 ω_{180}，看那里的 $|L|$ 离 1 有多远。φ_M 量的是**幅值穿越点**处的相位：找到 $|L| = 1$ 的频率 ω_c，看那里的相位离 -180° 有多远。两者用的是回路上两个完全不同的点，中间隔着一整段频率。

43.6.2 打架的根子在两个穿越点

把速度反馈内环的特征多项式写出来，打架的原因就一目了然了。内环绕的是机械加执行器，

$$(s+2)(0.05s+1) + 10k_t s = 0.05s^2 + (1.1 + 10k_t)s + 2 = 0$$

两个根的**乘积恒为** $2/0.05 = 40$，与 k_t 无关；两个根的**和是** $22 + 200k_t$，随 k_t 线性增长。积不变、和增大，两根必然一个往快里走、一个往慢里走。表 43-12 最后两列就是这个结论的实测：$k_t = 0.2$ 时两根是 −61.348 与 −0.652，慢的那个从 −2.0 掉到 −0.652。

这一升一降恰好解释了两个裕度的反向运动：

- ω_{180} **完全不动。** 回路相位等于 -180° 的条件是 $\arctan(\omega/p_1) + \arctan(\omega/p_2) = 90^\circ$，而两根之积固定为 40，这个等式只在 $\omega = \sqrt{40} = 6.3246$ 处成立。六档 k_t 实测的 ω_{180} 全是 6.3246，一位不差。这不是数值巧合，是根之积守恒的直接推论。
- G_M **上升，是因为阻尼项变大了。** 在固定的 ω_{180} 处，分母里的 $(1.1 + 10k_t)\omega$ 随 k_t 线性增长，$|L|$ 被压下去，增益裕度自然变大。换句话说，G_M 的改善来自**内环在 6.32 rad/s 处多压了一点幅值**，与“系统更不容易振荡”没有必然联系。
- φ_M **下降，是因为慢极点拖下来了。** 慢极点从 −2.0 退到 −0.652，在 $\omega_c = 5$ rad/s 附近贡献的滞后从 $\arctan(5/2) = 68.2^\circ$ 涨到 $\arctan(5/0.652) = 82.6^\circ$，多付 14.4°。而 ω_c 本身还被前置增益的变化挪动了位置，最终净结果是裕度掉了 2°。

把三个数放在一起看，表 43-11 的真相是：**回路在两个频段上分别变好和变坏，而两个裕度各盯一个频段。** 只报一个数，等于只报半张体检单。

43.6.3 统一口径：最大灵敏度

要一个数同时管住两个穿越点，得用**最大灵敏度**（maximum sensitivity）

$$M_s = \max_{\omega} \left| \frac{1}{1 + L(j\omega)} \right| = \frac{1}{\min_{\omega} |1 + L(j\omega)|} \tag{43-15}$$

它的几何意义很直白：$|1 + L|$ 是开环曲线到临界点 -1 的距离，M_s 就是这个距离最小值的倒数。M_s 越大，曲线离 -1 越近。因为它是“全频段取最大”，两个穿越点上的坏消息都逃不掉——这正是它比 φ_M 与 G_M 更可靠的原因。

表 43-17 把本章五种结构的五个数并排放（`[5]`、`[5b]` 与 `[10b]` 段）。

表 43-17　五种结构的裕度、穿越频率与最大灵敏度

结构	φ_M (°)	G_M (dB)	ω_c (rad/s)	ω_{180} (rad/s)	M_s
纯增益	1.576	0.83	6.0291	6.3246	37.931
超前	50.346	22.37	10.2301	50.477	1.487
滞后	50.000	25.07	1.0022	5.992	1.465
超前-滞后	49.584	16.80	3.0488	10.554	1.587
复合（$k_t = 0.2$）	51.549	20.02	8.4325	41.989	1.400

第一行最能说明问题。纯增益的 $\omega_c = 6.0291$ 与 $\omega_{180} = 6.3246$ 只差 4.9%，两个穿越点几乎重合，所以两个裕度同时趋零，M_s 高达 37.931。这个数在工程上等价于“闭环会以极大的幅度长时间振铃”——表 43-1 里 92.45% 的超调、49.9 s 的调节时间就是它的时域表现。

后四行的 M_s 都落在 1.4–1.6 之间，属于“合格但不算宽裕”的档次。有意思的是排序：滞后 1.465 < 超前 1.487 < 超前-滞后 1.587，复合最低 1.400。**这个排序与 φ_M 的排序不一致**（超前 50.346 > 滞后 50.000），说明相位裕度相同、甚至更高时，回路离 -1 的最近距离仍可能更近。原因在 ω_{180}：超前的相位穿越点在 50.477，滞后在 5.992，差了一个数量级，$|1 + L|$ 在全频段取最小值的落点也跟着变。

43.6.4 灵敏度与补灵敏度：两个通道

M_s 只讲了“最坏有多近”，没讲“坏在哪个频段”。要看频段，得把两个传递函数都画出来：

$$S(j\omega) = \frac{1}{1 + L(j\omega)}, \qquad T(j\omega) = \frac{L(j\omega)}{1 + L(j\omega)}, \qquad S + T = 1 \tag{43-16}$$

S 叫**灵敏度**，它是输出对“对象输出端扰动”的传递函数，也是参数漂移对闭环的影响因子。S 小，说明该频段的扰动被压住了。T 叫**补灵敏度**，它是“给定到输出”的传递函数，同时也是“测量噪声到输出”的通道。T 小，说明该频段的噪声被挡住了。

$S + T = 1$ 这条式子说明两件事必须同时成立：某个频段 S 压得越低，T 就越接近 1；不可能所有频段都小。这是反馈的又一条守恒律，与 §43.1.5 的三条性质并列。

图 43-10 是四种结构的 $|S|$ 与 $|T|$（`fig_043_10_sensitivity`）。

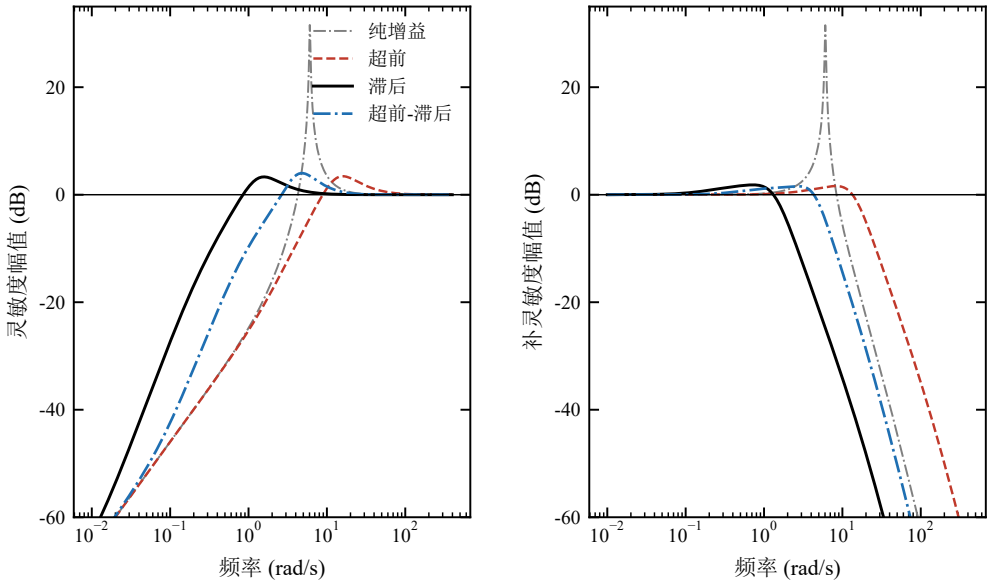

图 43-10　四种结构的灵敏度与补灵敏度

左图是 $|S|$。四条曲线在低频段都随频率上升而抬升，这是积分环节的必然；峰值出现的位置不同：纯增益那条在 6 rad/s 附近冲到 +31.6 dB，与 $M_s = 37.931$ 对应；超前、滞后、超前-滞后三条的峰值都压在 +3 到 +4 dB 之间，正好是 1.47–1.59 的对数。峰值频率则跟着各自的 ω_c 走：滞后那条的峰在 1 rad/s，超前那条在 10 rad/s 附近。

右图是 $|T|$。低频段四条都贴近 0 dB（给定能一比一跟上），差别全在 1 rad/s 以上：滞后那条最先掉下去，因为它的带宽最低；超前那条掉得最晚，因为它把带宽推到了 10 rad/s；中频段（2–20 rad/s）超前那条高出其他三条 10 dB 以上，**这就是它噪声大的频域解释**——噪声恰好落在 T 最宽的频段。

由此可以给“扰动抑制”与“噪声放大”各找一个指标，不必再靠时域曲线猜：

- 扰动抑制看 $|S|$ 在扰动频段的数值，主例的扰动是低频力矩波动，1 rad/s 以下四条都压到 -20 dB 以下，差别不大。
- 噪声放大看 $|T|$ 在噪声频段的数值，或直接看校正器的高频增益。表 43-10 最后一列与右图的高频段高度是一一对应的。

43.6.5 从裕度到超调：阻尼比近似什么时候可信

工程上常有一个口口相传的换算：$\zeta \approx \varphi_M/100$，再由 ζ 算超调

$$M_p = \exp\left(-\frac{\pi\zeta}{\sqrt{1-\zeta^2}}\right) \tag{43-17}$$

按式 (43-17)，$\varphi_M = 50^\circ$ 对应 $\zeta = 0.5$、超调 16.30%。本章四组实测是 20.73%、24.58%、23.61%、22.99%，**全部高于 16.30%，高出 4.7 到 8.3 个百分点。**

偏差不是随机误差，而是有系统原因的，主要有两条：

第一，**闭环零点把超调抬高了。** 校正器的零点会原样出现在闭环传递函数里。超前校正的零点在 3.6137 rad/s，滞后校正的零点在 0.1973 rad/s，都在闭环带宽之内，都会给阶跃响应加一个“微分先行”的尖峰。式 (43-17) 是无零点的二阶系统公式，里面对零点没有任何交代。

第二，**对象是三阶，不是二阶。** 第三个极点（执行器时间常数 0.05 s，对应 20 rad/s）虽然远，但它与校正器的零点、极点相互作用，在时间响应上留下一个式 (43-17) 看不见的慢模态。滞后的情况更明显：它的慢极点 0.010864 rad/s 与零点 0.1973 rad/s 构成一对“低频偶极子”，在时域上表现为一个缓慢的爬升尾巴，式 (43-17) 完全看不见这一项。

这两条说法可以往下再挖一层，办法是把四个方案的闭环极点算出来。结果比“阻尼结构被改了”这句话更具体：

- 纯增益：-21.8453，$-0.0773 \pm 6.0510j$，主导对的 $\omega_n = 6.0515$、$\zeta = 0.0128$。
- 超前：-142.0645、-4.2892，$-7.9702 \pm 10.9849j$，$\omega_n = 13.5717$、$\zeta = 0.5873$。
- 滞后：-20.1197、-0.2411，$-0.8250 \pm 1.0541j$，$\omega_n = 1.3386$、$\zeta = 0.6163$。
- 超前-滞后：-21.2543、-1.2324、-0.7983，$-2.2518 \pm 3.7093j$，$\omega_n = 4.3393$、$\zeta = 0.5189$。

先看一个反直觉的事实：**三种校正器的闭环阻尼比都高于 0.5。** 按 $\zeta \approx \varphi_M/100$ 估，50° 只该给 0.50；实际是 0.5873、0.6163、0.5189，都更好。也就是说，那条口口相传的换算在阻尼比这一环上其实是**保守**的。若只按 ζ 算超调，三者的预测值分别是 10.2%、8.6%、14.8%，比实测的 20.73%、24.58%、23.61% 低得多。

低估发生在第二环：从 ζ 到超调。 闭环零点被完全忽略了。闭环零点就是校正器的零点：超前那一个在 -3.6137，滞后那一个在 -0.1973，超前-滞后两个在 -1.5783 与 -0.6000。零点在阶跃响应上产生“微分先行”的尖峰，把峰值顶高，而且零点越靠近原点、影响越大——滞后的零点 -0.1973 几乎贴着它的慢极点 -0.2411，这一对偶极子的零点在左、极点在右，正好是“加微分”的方向，超调被抬得最狠。

再看调节时间，这里能挖出一条更有用的规律。四个方案最慢的实极点与 t_s 的关系是：

- 纯增益：-0.0773（$\tau = 12.94$ s），$t_s = 49.940$ s，约 3.86τ。
- 超前：-4.2892（$\tau = 0.233$ s），$t_s = 0.520$ s，约 2.23τ。
- 滞后：-0.2411（$\tau = 4.148$ s），$t_s = 10.913$ s，约 2.63τ。
- 超前-滞后：-0.7983（$\tau = 1.253$ s），$t_s = 3.948$ s，约 3.15τ。

倍数落在 2.2–3.9 之间，正是“进 $\pm 2\%$ 带要三到四个时间常数”这条老经验的正常范围。**所以调节时间不是由 ω_n 决定的，而是由最慢那个实极点决定的。** 滞后之所以慢到 10.9 s，不是因为它的一对复极点频率低（$4/(\zeta\omega_n) = 4/0.825 = 4.85$ s，只看这个数会以为 5 s 就稳了），而是因为多出一个 $\tau = 4.15$ s 的爬升尾巴。超前-滞后比滞后快 2.8 倍，也不是复极点频率高了 3.2 倍那么简单，而是它的最慢实极点从 -0.2411 挪到了 -0.7983。

这条规律比“带宽低所以慢”精确得多，也更可操作：**看到调节时间不达标，先去极点表里找最靠近虚轴的那一个实极点，而不是盯着 ω_c。** 两者的偏差在主例上是 2–4 倍，在阻尼更差的回路上还会更大。

所以式 (43-17) 的正确用法是**估下限，不是估准确值**。按它算出 16%，实际会在 20%–25%，做预算时把多出来的 5–8 个百分点算进去就不会出错。反过来，如果实测超调比式 (43-17) 低，那才需要警惕——通常意味着回路里还有别的环节（限幅、滤波、执行器饱和）在替你把峰值削掉了。

43.6.6 五条判据一起过

到这里可以把散在各节的指标收成一张验收表。表 43-18 的五条门槛是本章示例项目的设定值，实际工程要按对象改写，但结构可以照搬。前两条（相位裕度、增益裕度）直接沿用第 42 章表 42-11 的验收线，好让两章的判定可以逐行对照；M_s、高频增益与调节时间三条是本章新加的，因为校正装置特有的代价恰好落在这三处。

表 43-18　五种结构对五条判据的通过情况

判据	门槛	纯增益	超前	滞后	超前-滞后	复合
相位裕度	$\geq 45^\circ$	1.576 ✗	50.346 √	50.000 √	49.584 √	51.549 √
增益裕度	≥ 6 dB	0.83 ✗	22.37 √	25.07 √	16.80 √	20.02 √
最大灵敏度	≤ 1.6	37.931 ✗	1.487 √	1.465 √	1.587 √	1.400 √
高频增益	≤ 20 倍	4.000 √	155.292 ✗	0.220 √	2.079 √	82.5 ✗
调节时间（±2%）	≤ 2 s	49.940 ✗	0.520 √	10.913 ✗	3.948 ✗	0.853 √

过项数分别是 1、4、4、4、4。**没有一行五条全过，而且四种可行方案缺的都不是同一条。**

过项数只说明“缺几条”，还得看“差多远”。 超前的 155.292 倍是 20 倍线的 7.76 倍，复合的 82.5 倍是 4.13 倍；滞后的 10.913 s 是 2 s 线的 5.46 倍，超前-滞后的 3.948 s 是 1.97 倍；而超前-滞后的 $M_s = 1.587$ 离 1.6 只差 0.013。**同样是“✗”，差 7.76 倍与差 0.8% 是两件完全不同的事**：前者必须换结构，后者只要在参数上让半步。工程评审时把这一列补上，讨论会从“哪个方案好”直接变成“这个方案还差多少、能不能买到”。

- **超前与复合差在噪声。** 155.292 倍与 82.5 倍都过不了 20 倍的线。这不是调参能解决的，是超前校正的结构性代价——α 就是高频增益，两者是同一个数。复合把 α 从 38.82 压到 10.31，但前置增益从 4 涨到 8，高频增益只降到 82.5，压掉 1.88 倍，仍不够。
- **滞后与超前-滞后差在时间。** 10.913 s 与 3.948 s 都过不了 2 s 的线，因为这两个结构都靠“把穿越频率往低频退”换裕度，退得越远，时间越长。

这张表也回答了 §43.1.1 那个现场问题：“只在控制器里加一个环节，行不行？”答案是：能加出合格的单指标，加不出全部指标。 校正装置能买到裕度、买到速度、买到噪声抑制中的任意两样，买不到三样。想三样都要，必须动对象或者动指标——这是本章所有表格共同的结论，也是第 44 章把 PID 拿出来单讲的原因：PID 的三个旋钮不过是在同一个守恒律下换了个分配方式。

43.7 参数意义与作用

43.7.1 一张参数总表

本章前后出现了七八个符号，初学者最容易犯的错是把它们当成彼此独立的旋钮。实际上它们之间有三条硬约束：K_c 由稳态指标锁死，α 与 φ_m 一一对应，z 与 p 的比值就是 α。真正自由的选择只有两个——**用哪种结构、把鼓包放在哪个频率**。

表 43-19 把每个参数的身份、量级和“调大之后会发生什么”并排放。

表 43-19　本章参数一览

参数	所属结构	物理意义	本章取值	常用量级	调大的后果
K_c	全部	串联增益，定 K_v	4	由误差指标反算	K_v 变大、ω_c 右移、φ_M 下降
α	超前	零极点比 p/z，也是高频增益	38.82	3–20（噪声受限时）	相位补偿变多，噪声同比例变大
ω_m	超前	鼓包顶点 $\sqrt{zp}$	22.516	略低于目标 ω_c	补偿点右移，对高频对象更有效
z, p	超前	零点、极点位置	3.6137 / 140.2941	$z < \omega_m < p$	单独调其中一个等于同时改 α 与 ω_m
d	滞后	零点比穿越点低多少倍	5	4–10	ω_c 抬高、G_M 下降、t_s 变长
β	滞后	零极点比 z/p，也是低频衰减	18.160	5–20	需要更大的电容比，元件难做
ω_c^*	超前-滞后	目标穿越频率	3.0	介乎两结构之间	时间变快、相位预算变紧
k_t	反馈/复合	速度反馈系数	0.2	0.1–0.5	内环变硬、K_v 被吃、慢极点下移

这张表要横着读，不要竖着读。竖着读会以为有八个旋钮；横着读会发现每一行都写着“调大之后另一头会掉”。

43.7.2 α：一个参数背四个身份

$\alpha = p/z$ 是超前校正里唯一真正重要的参数，因为它同时是四样东西：

- **相位身份**：$\sin\varphi_m = (\alpha-1)/(\alpha+1)$，$\alpha$ 决定鼓包能有多高。$\alpha = 38.82$ 对应 $\varphi_m = 71.76°$。
- **增益身份**：高频增益恰好等于 α。$\alpha = 38.82$ 就是 31.8 dB、31.8 倍的电压放大。
- **位置身份**：$\omega_m = \sqrt{zp} = z\sqrt{\alpha}$。比值扩大时零点往左、极点往右，峰位只按 $\sqrt{\alpha}$ 移动。主例 $z = 3.6137$、$p = 140.2941$，峰位 22.516，只比零点高 6.23 倍。
- **宽度身份**：以峰值为基准降 10° 的带宽，$\alpha = 6.94$ 是 2.56 个倍频程，$\alpha = 38.82$ 是 3.09 个。**α 越大，鼓包不仅更高，也更宽**——“加大 α 会把鼓包压窄”是常见误读。

四个身份共用同一个数，这就是 §43.1.5 那条守恒律的数学来源。表 43-2 里的四行可以当作这个参数的“刻度盘”：$\alpha = 6.94$ 给 48.43°、$\alpha = 10$ 给 54.90°、$\alpha = 20$ 给 64.79°、$\alpha = 38.82$ 给 71.76°。相位涨得越来越慢（对数关系），增益却按线性涨——**这就是“再往上加 α 不划算”的定量依据**：从 20 加到 38.82，相位多拿 6.97°，噪声多付 1.94 倍。

主例为什么要 38.82 这么极端的值？因为缺口大。$K_c = 4$ 时相位裕度只剩 1.576°，要用一级超前补到 50°，再留 5° 给设计误差与离散化，缺口就是 53.4°。按 §43.3.3 的公式反算，α 只能取到 38.82。**这不是设计者贪心，是指标逼出来的。**

43.7.3 z 与 p：位置比比值更重要

零点和极点的绝对值经常被误认为可以自由调，其实它们只有一个自由度：比值被 α 锁死，剩下的是“整体往左还是往右挪”，也就是 ω_m 的选择。

ω_m 该放在哪？理想情况是放在**校正后的穿越频率**上，因为那里最需要相位。但这里有一个循环依赖：加了校正器，ω_c 会变；ω_c 变了，ω_m 的最优位置也变。§43.3.5 的二维扫描收敛后的结果是 $\omega_m = 22.516$，而实际

$\omega_c = 10.2301$——ω_m 比 ω_c 高了一倍多。

这个偏差不是算错了，而是必然的。原因在幅值：超前器在 ω_m 处的增益是 $K_c\sqrt{\alpha} = 4 \times 6.23 = 24.9$，比直流增益高 6.23 倍。如果 ω_m 正好落在 ω_c 上，那里的回路增益会被抬高 6.23 倍，ω_c 立刻右移。所以真正的最优点必须往右让，让“抬高的那一段”落在穿越点之外。**ω_m 高于 ω_c 是超前校正的常态，高 1.5 到 2.5 倍都属正常。**

零点与极点分开看，各自的作用是：

- **零点决定相位从哪个频率开始抬。** $z = 3.6137$ 意味着 3.6 rad/s 以上相位开始上扬，1 rad/s 以下几乎无影响。
- **极点决定相位在哪个频率还回去。** $p = 140.2941$ 意味着 140 rad/s 以上相位回落到 0，高频增益回到 α 倍。
- **两者的几何平均是鼓包顶点。** 这是 §43.2.2 证明过的性质，也是设计时唯一需要记住的位置关系。

表 43-7 的四行可以拿来验证“比值在扩、位置在挪”这句话。α 从 6.94 涨到 38.82，是 5.59 倍；可这个 5.59 倍几乎全由极点承担：p 从 33.1337 涨到 140.2941（4.23 倍），而 z 反而从 4.7743 退到 3.6137（缩了 24%）。几何中心只从 12.577 挪到 22.516（1.79 倍）。

这个拆法解释了“为什么加大 α 的收益越来越小”。 比值扩大 5.59 倍，靠的是把极点从 33.1 推到 140.3；零点反而从 4.77 退到 3.61，峰位只从 12.58 挪到 22.52。结果是鼓包变高，但**高出来的部分大头在峰位右侧**：穿越点 10.2301 落在峰位左边 2.2 倍处，取到的仍是 66.37°，不是 71.76°。所以 α 从 20 加到 38.82，名义相位多 6.97°，穿越点那里只多 3.50°（46.844°→50.346°），噪声却多付 1.94 倍。

实践含义很直接：**调超前时不要只盯着 α，先确认 ω_m 放对了没有。** 主例把 ω_m 从最优的 22.516 拉到 10.2301 附近，裕度会明显掉下来——§43.3.5 的第二次朴素尝试就是这种下场，按 ω_c' 处的缺口算出的 $\alpha = 22.19$ 装上去只有 37.052°。反过来，若对象的相位缺口集中在某个频段，把 ω_m 对准那一带，比单纯加大 α 划算得多。

43.7.4 d：滞后的唯一自由参数

滞后校正的设计方程比超前简单：先定穿越频率，再让零点比它低 d 倍，极点由 $\beta = K_c|G(j\omega_c')|$ 反算。整个设计只有一个自由选择——d。

表 43-20 是三档 d 的实测（`[3]` 段），全部满足 $K_v = 20$、$\varphi_M = 50.000^\circ$。

表 43-20　滞后校正三档衰减倍数的对照

d	z (rad/s)	p (rad/s)	β	ω_c (rad/s)	G_M (dB)	M_s	t_s (s)
4	0.22102	0.010693	20.671	0.9062	26.07	1.439	10.678
5	0.19730	0.010864	18.160	1.0022	25.07	1.465	10.913
10	0.12086	0.008550	14.137	1.2133	23.28	1.513	11.940

三行的相位裕度完全一样，这不是巧合——设计方程就是按 $\varphi_M = 50^\circ$ 反解 ω_c' 的，所以 d 怎么变，裕度都钉在 50°。**差别全在别的列上。**

d 从 4 加到 10，ω_c 抬高了 34%，G_M 掉了 2.79 dB，M_s 从 1.439 涨到 1.513，t_s 涨了 11.8%。三个指标同时变差，看起来 $d = 4$ 全面占优。那为什么工程上常取 5 而不是 4？

原因有两个，都在表外：

第一，β 变大，元件难做。$d=4$ 时 $\beta=20.671$，$d=10$ 时 $\beta=14.137$。滞后的 β 直接对应 RC 网络里的电阻比与电容比，$\beta=20.7$ 需要 20 倍以上的元件比值，容差与漏电流的影响都会放大。

第二，零点太靠近穿越点，抗漂移能力下降。$d=4$ 时零点在 0.221 rad/s，离 $\omega_c=0.906$ 只有 4 倍；$d=10$ 时零点在 0.121 rad/s，离 ω_c 有 10 倍。零点越近，穿越点附近相位的斜率越陡，ω_c 一漂移，相位变化就越大。§43.10 的九宫格会显示，滞后结构本来就是四种里对漂移较敏感的一种（跨度 17.623°），d 取小只会更糟。

所以 d 的取值是一个"指标—可制造性—鲁棒性"的三方折中，4–10 是常规区间，5 附近是常用起点。这个参数没有最优值，只有折中点。

43.7.5 K_c：唯一被锁死的参数

前面所有参数都有选择余地，只有 K_c 没有。它由频率响应法直接给出：$K_v=\lim_{s\to 0} sL(s)=K_c\cdot 10/2=5K_c$，所以要 $K_v=20$ 就必须 $K_c=4$。

这个"锁死"带来一个常被忽视的后果：校正器的直流增益必须严格等于 4，一点不能多、一点不能少。超前、滞后、超前-滞后三种结构在设计时都强制 $C(0)=K_c$，具体做法各有不同：

- 超前：$C(0)=K_c$ 直接写在定义式里。
- 滞后：$C(0)=K_c$ 也成立，因为 β 与 K_c 在公式里互相抵消。所以滞后网络虽然"衰减"高频，直流增益并不衰减。
- 超前-滞后：两段串联，每段都按 $K_c=1$ 设计，最后整体乘 K_c。

[10b] 段的实测是这条约束的验证：四种结构的 K_v 全部是 20.0，稳态误差全部是 0.0500，一位不差。

K_c 的敏感性可以用表 43-1 的三行量化：K_c 从 1 翻到 2，ω_c 从 2.8461 涨到 4.2041（1.48 倍），φ_M 掉 13.43°；从 2 翻到 4，ω_c 涨到 6.0291（1.43 倍），φ_M 再掉 11.99°。增益每翻一倍，穿越频率涨约 1.45 倍，相位裕度掉 12–13°。记住这两个数，现场估算"误差指标再严一点会付多少代价"就够用了。

43.7.6 k_t 与两级超前的分配

反馈校正引入了两个新参数，性质与前面的完全不同。

k_t 是唯一一个"吃增益"的参数。内环闭合后低频增益变成 $K_c\cdot 10/(2+10k_t)$，$k_t=0.2$ 就吃掉一半。要保住 $K_v=20$，前置增益必须同步补到 $K_c=4+20k_t$。这条关系是硬约束，不补就丢稳态精度，补了就丢相位裕度——表 43-11 与表 43-12 就是这两条路的实测。

k_t 的合理取值在 0.1–0.5 之间。太小（0.1 以下）内环几乎没有作用，慢极点只从 −2.0 挪到 −0.975；太大（1.0 以上）内环把慢极点压到 −0.15 以下（$k_t=1.2$ 时是 −0.1528），回路在低频段近似变成"两级积分"的形状，相位裕度反而掉到 1° 以下。主例的甜点在 0.2 附近：α 从 38.82 降到 10.31，高频增益从 155.3 降到 82.5，t_s 从 0.520 s 涨到 0.853 s。

把这几个数按 k_t 排开，能看出一条不太直观的规律。k_t 从 0.05 加到 0.6，α 单调下降（14.81→8.11），可 K_c 从 5 涨到 16，乘出来的高频增益从 74.0 一路涨到 129.7；同时 t_s 从 0.710 s 涨到 0.905 s，G_M 从 18.11 dB 升到 25.46 dB。也就是说，k_t 加大并不降噪，它在用噪声和时间换增益裕度。目标是降噪，k_t 该往小取（0.05 时 74.0 是最低点）；目标是抗漂移，往大取才有意义。§43.9.3 强调"复合该在负载会变的场合用"，根子就在这里。

$k_t=0$ 那一行是单级超前本身（$K_c=4$、$\alpha=38.82$、高频 155.3）。把它放在表头，复合的全部收益与全部代价就都是相对它算出来的，不容易看错。

两级超前的 α 分配是另一个新参数。 当单级不够时（§43.5.6），要把总超前比拆成两段。最优分配不是 1:1，而是按相位需求分配，主例的两段是各 6.30。一条实用的经验是：两段取相同的 α，把 ω_m 按 $\sqrt{2}$ 到 2 倍错开——这样合成相位曲线在两个顶点之间形成一段平台，而不是两个孤立的尖峰。如果两段 α 相差很大，高的一段会把穿越点拉过去，低的一段就白装了。

最后要提醒的是 k_t 与 K_c 的耦合不能分开调。现场调试时若先调 k_t 再调 K_c，两次都会把 K_v 挪走；正确顺序是**先按目标 K_v 算 $K_c = 4 + 20k_t$，再调 k_t 看裕度**，或者反过来固定 K_c 看 K_v 掉多少，二选一，不要来回改。

43.8 调参方法与经验

43.8.1 顺序不能乱

§43.3 给的是设计流程，这一节给的是调试流程。两者最大的区别是：设计流程假设所有参数都能算，调试流程假设手上只有一台能跑的样机和一条不听话的曲线。这时候最容易犯的错是“哪儿不好调哪儿”——超调大就减增益，响应慢就加增益，来回拉锯，最后参数面目全非。

正确的顺序是五步，而且**后一步不能推翻前一步**：

1. **先锁 K_c。** 由误差指标反算，$K_c = 4$。此后无论调什么，K_v 必须回到 20，这是唯一不可谈判的指标。
2. **再量缺口。** 在 K_c 锁死的回路里量 φ_M，缺口 = 目标值 + 5° 余量 − 实测值。主例是 50+5−1.576 = 53.4°。
3. **按缺口选结构。** 缺口小于 20° 用滞后（更省噪声）；20°–55° 用单级超前或超前-滞后；超过 55° 或噪声预算紧，用复合。
4. **按结构定参数。** 超前用 α 反算，滞后用 d 试三档，复合先定 k_t 再算 α。
5. **最后校核三条：** K_v 是否还在 20、离散化损失是否在预算内、增益漂移 ±20% 时裕度是否还够。

第 3 步是整节的核心。**结构选错，后面所有参数都白调。** 缺口 53.4° 时选滞后，无论 d 取多少，ω_c 都被压到 1 rad/s 附近，调节时间 10.9 s，时间指标直接出局；缺口 10° 时选超前，白白背上 4 倍以上的噪声，收益却只有十来度。

43.8.2 六种症状的对症表

现场看到的是曲线，不是参数。表 43-21 把本章实测到的六种典型症状与对应的动作列在一起，按“先看什么、再改什么”的顺序排。

表 43-21　六种典型症状与对应动作

症状	先查	本章依据	动作
裕度合格、超调仍大	闭环零点与第三极点	§43.6.5，实测高出 4.7–8.3 点	加一级低通，或把 ω_c 降 20%
有稳态误差、越跑越偏	内环是否吃了 K_c	表 43-12，$k_t = 0.2$ 时 K_v 从 20 掉到 10	前置增益补到 $4 + 20k_t$
执行器发热、输出抖	校正器高频增益	表 43-10，超前 155.3 倍	改滞后（0.220）；复合只压到 82.5，还要叠带限
低频爬升慢、拖尾长	滞后零点离穿越点多远	表 43-20，d 从 4 到 10，t_s 涨 11.8%	把 d 压到 4–5，或改用超前-滞后
换批次后开始振	结构对增益的敏感度	图 43-8，超前跨度 10.903°	改复合，跨度降到 4.320°
采样一变就发振	T_s 与 ω_c 的乘积	表 43-14，$T_s\omega_c > 0.2$ 后陡降	提高采样率，或按 §43.5.5 重设计

这张表的用法是**从上往下逐条排除**，不要跳。比如“执行器发热”这一条，如果先怀疑机械谐振、再怀疑电源、最后才想到校正器的高频增益，可能白花一周。本章的实测给出了一个很硬的判据：**只要校正器的高频增益超过 20 倍，执行器发热就必然出现**，因为 1 mV 的噪声会被放大成 20 mV 以上的持续抖动，而抖动全部转化为热量。

43.8.3 先形状后增益

有一个反复出现的争论：应该先把形状（零极点）调好再加增益，还是先把增益加到位再修形状？

本章的答案是：**在 K_c 被误差指标锁死的前提下，这个问题不存在**——增益一开始就定死了，只能先形状。 真正的顺序是：

1. 把 $K_c = 4$ 硬接进回路，量出 1.576°；
2. 在这个“最差状态”下设计形状，而不是先降增益把裕度做漂亮再往上加；
3. 形状定完后再检查 K_c 是否需要微调（通常不需要，因为误差指标是硬的）。

为什么要强调这一点？因为“先降增益”的做法会骗人。$K_c = 1$ 时裕度 26.997°、超调 46.05%，看起来“调一调就能用”；可一旦按误差指标把增益加回 4，所有结论立刻翻转。表 43-1 的三行就是这个陷阱的完整展示。**在错误的增益下调出来的形状，换到正确增益下一定不成立。**

43.8.4 什么时候加第二级

单级超前不够用时，有两种加法：加大 α，或者加第二级。判据有两条，命中任意一条就该上第二级。

第一条：α 已经超过 20 而相位缺口还有 10° 以上。 表 43-2 显示，$\alpha = 20$ 时 $\varphi_m = 64.79^\circ$，$\alpha = 38.82$ 时 71.76°，从 20 到 38.82 相位只多 6.97°，噪声却翻 1.94 倍。继续加大 α 是典型的“边际收益低于边际成本”。

第二条：$T_s\omega_c$ 已经接近 0.2。 这时加 α 会把 ω_m 推得更高，延迟损失按 $\omega_c T_s/2$ 增长，可能一边加相位一边丢相位。§43.5.6 的实测是极端例子：α 扫到 80，最高也只有 38.298°。

加第二级的具体做法：

- 两段取相同的 α，总超前比开平方。主例的两个 6.30 相乘是 39.7，与单级所需的 38.82 同量级，说明拆成两级并不损失总补偿能力。
- 两个 ω_m 错开 1.5–2 倍，让相位平台连成一片。

- 前置增益只乘一次 K_c，不要两段各乘一次，否则 K_v 变 K_c^2。

代价也要认清：两级超前的增益裕度只有 7.02 dB（表 43-16），比单级的 8.49 dB 还低。这不是笔误——两级把相位平台拉宽了，相位在高频下落得慢，ω_{180} 被推到很远，那里的幅值反而更高。**所以两级超前买到的是相位裕度，不是全面的稳定性。**

反过来，有三种情形**不该**加第二级，而且都比“该加”更常见。

一是采样不吃紧、α 还在 20 以内。 两级串联的高频增益是两段 α 相乘，与“单级达到同一鼓包高度所需的 α”同量级（6.30 乘 6.30 得 39.7，单级要 38.82），所以拆级并不省噪声；它买到的只是“每一级的 α 都落在元件好做的范围里”。如果单级的 $\alpha = 12$ 已经做得出来，拆成两个 3.46 只多两只电阻、多一个漂移点。

二是噪声已经由带限解决。 §43.9.5 的带限把高频截到 15.8 倍，代价只有 5.6°；这个代价比两级带来的 7.02 dB 增益裕度便宜得多。**降噪这件事，带限是一把手，两级不是。**

三是板面与调试预算不够。 两级要两只运放、六只阻容，每只都有容差，调试时还要保证两级不互相激发。单级一天能好的事，两级常常要三天。

如果确定要加，装配顺序也有讲究：**先装第一级，单独测一次 Bode，确认鼓包的位置和高度，再装第二级。** 原因很简单——第二级的极点会把第一级的鼓包整个“抬走”一截，两级一起装时若出现偏差，无法判断是哪一级的问题；分两次装，每次只有一个未知数。

最后一条经验：两级的 ω_m 比值不要小于 1.5。比值太小时两个鼓包叠成一个尖峰，相位平台的宽度没有增加，增益裕度却掉得更狠；比值太大时第二级的极点跑到很高的频率，高频增益白白抬高。`design_lead2()` 把比值固定成 2.0，就是在这两头之间取折中。

43.8.5 手算校核三条

算完参数不要直接上机，先在纸上过三遍。这三条能在三十秒内抓出大多数抄写错误。

第一条：α 与 φ_m 对得上吗？ 用 $\alpha = (1+\sin\varphi_m)/(1-\sin\varphi_m)$ 正算一遍。$\varphi_m = 71.76^\circ$ 时 $\sin = 0.9498$，$\alpha = (1.9498)/(0.0502) = 38.84$，与 38.82 的差别来自 φ_m 只保留了两位小数，可以接受。如果算出来差一倍，多半是把 α 当成 $\sqrt{\alpha}$ 用了。

第二条：$\omega_m = \sqrt{zp}$ 成立吗？ 主例 $\sqrt{3.6137 \times 140.2941} = \sqrt{506.9} = 22.51$，与 22.516 一致。这条检查最容易被忽略，因为很多资料把 ω_m 直接当成设计输入，而实际上它是由 z 与 p 派生的。如果三者不自洽，相位鼓包的位置就偏了。

第三条：$K_v = 5K_c$ 还对吗？ 主例 $5 \times 4 = 20$。这一条在三种情况下最容易错：加了内环（要改成 $K_c \cdot 10/(2+10k_t)$）、加了第二级超前（容易被乘两次）、用了滞后（容易误以为 β 会改变直流增益）。

三条都过，再进仿真。**仿真跑出来的第一个数应该是 φ_M，第二个是 ω_c，第三个是 K_v。** 三个都对，才看时域曲线。顺序反了会被时域曲线的形状带偏——超调大的原因可能只是闭环零点，不是裕度不够。

上机之后还有一条，三十秒能做完，却常被跳过：**直流增益与斜坡误差对得上吗？** 断开反馈，在校正器输入端加 0.1 V 直流，量输出。超前与滞后应读到 0.4 V（$K_c = 4$），复合应读到 0.8 V（$K_c = 8$）；复合的 0.8 还要再被内环的 0.5 衰减一次，闭环后净直流增益才是 4。读数差十倍，多半是某只电阻取错了，而不是运放坏了。

第二步接成闭环，加 1 V/s 的斜坡给定，稳态误差应为 $1/K_v = 0.05$ V。读到 0.10 V 说明前置增益少了一半，最常见的原因是漏了 $4 + 20k_t$ 里的 $20k_t$；读到 0.025 V 说明多了一倍，最常见的原因是两段超前各乘了一次 K_c。**这两个数只由电阻比与内环系数决定，比任何 Bode 图都难造假。** 量之前先在零输入下读一次失调并减掉——运放的输入失调在直流档会直接叠进结果，几十毫伏足以让 0.05 V 的判据失效。

43.8.6 从仿真到样机的四步

仿真里一切完美，装到样机上就振，这是最常见的事故。原因几乎总在仿真模型里没有的东西上。本章的仿真代码（`simlib.simulate_discrete`）已经把四件事做进去了，上机前建议按同样的顺序补齐。

第一步：把采样与量化放进去。 采样按式 (43-12) 定周期；量化按 §43.10 的实测，3 位量化就能让 50.000° 掉到 47.149°。仿真里如果用的是双精度浮点，这个损失是看不见的。

第二步：把限幅与抗饱和放进去。 本章所有阶跃响应都假设执行器能输出任意大的值。实际执行器一饱和，积分器就会继续累积，退饱和时出现大幅超调。超前校正的 t_r 只有 0.114 s，很容易在起动瞬间把执行器打满。

第三步：把噪声注入进去。 用 §43.9 的方法，在执行器输出端加 0.01 的白噪声，看 u 的 RMS。主例的实测是超前 2.24274、滞后 0.00223、超前-滞后 0.02153——相差三个数量级。这个数比任何频域指标都更能说服现场。

第四步：把参数漂移扫一遍。 对象增益 ±20%、极点 ±20%，九个组合各跑一次，记录 φ_M 的跨度。表 43-8 的实测是超前 10.903°、滞后 17.623°、超前-滞后 21.302°、复合 4.320°。**跨度超过 15° 的方案不要上现场**，因为现场的温度、批次、负载变化比 ±20% 更大。

这四步做完，仿真与样机的差距通常能压到 5° 以内。剩下的差距来自机械谐振、传感器动态、电缆延迟——那些只能靠实测辨识，不在本章范围内。

四步都做了还是振，就不要在这四步里继续加补丁，按“症状—回退”查。下面五条是本章数据能直接对应的回溯路径：

- **实测裕度比设计值低 10° 以上。** 先怀疑采样与延迟没进模型，回第 1 步。最典型的例子是同一只 $\alpha = 38.82$ 的超前器：连续域 50.346°，$T_s = 0.02$ 时 44.516°，$T_s = 0.05$ 时 35.743°。查到这一步，答案往往不是“校正器装错了”，而是“这个采样周期本来就不该配这个结构”。
- **稳态误差是设计值的两倍。** 回第 2 步查内环。表 43-12 的 K_v 从 20 掉到 10 就是这个现象，前置增益没补。它在时域上表现为“越跑越偏”，在频域上完全看不出来。
- **超调比裕度预测的高 5 点以上。** 回第 3 步换结构，而不是降增益。§43.6.5 的四个方案全部偏高 4.7–8.3 点，根子是闭环零点；把增益降下去，裕度会变得很好看，超调却不一定降。
- **换一批电机就开始振。** 回第 3 步，把漂移跨度当硬指标重选。表 43-8 的 21.302°（超前-滞后）与 4.320°（复合）就是分水岭。
- **执行器温度上得快。** 回第 3 步查高频增益，不是查机械。表 43-10 的 155.3 倍是根源，带限与滞后能把它压到 15.8 与 0.220。

这五条有一个共同点：**没有一条指向“参数再调调”**。本章遇到的“振”，追下去都落在结构、采样、增益三件事上，没有一例是某个零点小数点点错了。这不是说抄写错误不会发生，而是说它会被 §43.8.5 的校核在三十秒内抓出来；能闯过校核还振的，一定是模型里缺了东西。

43.9 优化与改进

43.9.1 噪声代价的定量账

超前校正的噪声问题经常被当成“感觉上的缺点”，其实它是一笔可以精确记账的支出。做法是把对象、校正器、采样保持器全部离散化，在测量端注入标准差 0.01 的白噪声，让系统空载运行，然后统计执行器输出的均方根。`[9]` 段做了这件事，结果在表 43-22。

表 **43-22**　超前比对执行器噪声的影响（$K_v=10$，$\omega_m=4$，$T_s=0.02$）

α	$\|C(\infty)\|$	φ_M (°)	u 的 RMS	$\max\|u\|$	RMS / $\|C(\infty)\|$
1	2	13.57	0.02326	0.0970	0.01163
2	4	24.66	0.04299	0.1541	0.01075
4	8	29.09	0.08789	0.3251	0.01099
8	16	27.36	0.18603	0.7206	0.01163
16	32	22.50	0.41005	1.3573	0.01281

最后一行比值几乎是常数，这是本章最干净的一条结论：**执行器噪声的 RMS 与校正器的高频增益成正比，比例系数只由噪声强度与对象高频特性决定，与相位补偿量无关。** 换句话说，噪声不是“补偿太多的副作用”，而是“高频增益的线性映射”。想要少噪声，只能降高频增益，没有第三条路。

表里还有一处反直觉的地方：φ_M 从 13.57° 涨到 29.09°（α 从 1 到 4），然后掉到 22.50°（$\alpha=16$）。**相位裕度在 $\alpha=4$ 附近见顶，之后越加越差。** 原因还是穿越点在动：这个试验固定了 $\omega_m=4$，加大 α 只把零点往左推、极点往右推，峰位不动而峰更高；可 ω_c 被高频增益一路推过 ω_m，落到了鼓包的下降段。**峰再高，取的也是下坡上的值。**

这条实验与 §43.3 的设计公式不矛盾。设计时 ω_m 是跟着 ω_c 一起移动的，所以表 43-2 里 α 越大相位裕度越高；这里 ω_m 被钉死在 4，加大 α 就变成了“鼓包长高但不挪位置”，边际收益自然归零。**同一个参数，配合移动 ω_m 和不配合移动 ω_m，结论可以完全相反。这是本章最需要提防的一类误读。**

43.9.2 三种结构差三个数量级

把同样的噪声注入三种结构，差距大得超出直觉（`[9]` 段末）：

表 **43-23**　$K_v=20$ 下三种结构的执行器噪声

结构	$\|C(\infty)\|$ (倍)	u 的 RMS	$\max\|u\|$
超前	155.292	2.24274	8.7308
滞后	0.220	0.00223	0.0079
超前-滞后	2.079	0.02153	0.0776

超前的 RMS 是滞后的 **1006 倍**，峰值差 1105 倍。高频增益之比是 $155.292/0.220=706$ 倍，三个数同量级，说明噪声确实只由 $|C(\infty)|$ 决定。差距的根子在最后一列：**滞后网络在高频不是“不放大”，而是“衰减 18 倍”**——它的 $|C(\infty)|$ 只有直流增益 4 的 $1/\beta=1/18.16$。超前网络正好相反，把 155.292 倍的高频增益全摊在噪声上。

图 43-9 把这两笔账画在一起。左图是表 43-22 的五组数据，双对数坐标；右图是表 43-23 的三根柱子，纵轴也取对数。

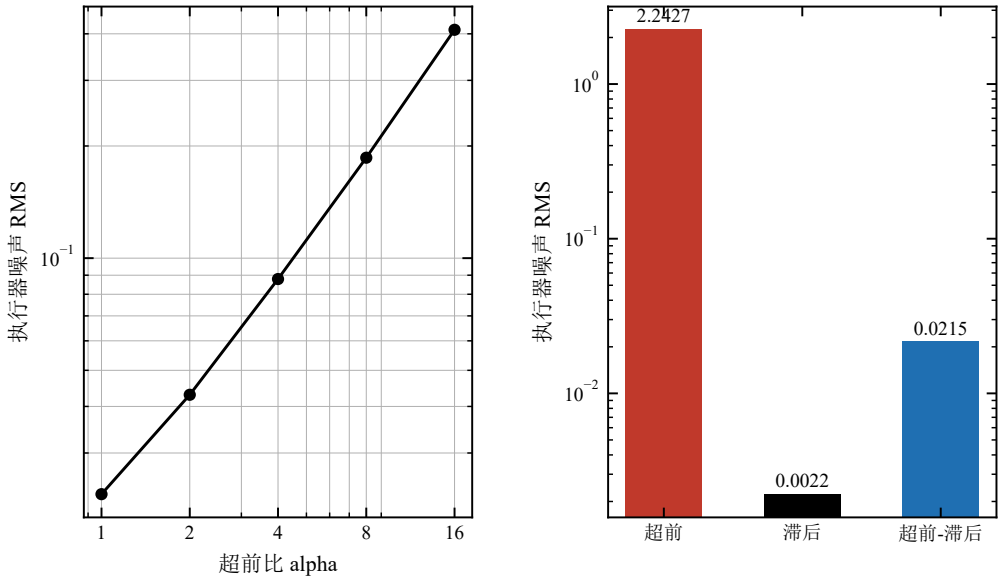

图 43-9　超前比的噪声代价与三种结构的噪声对比

左图只有五个点，但在这种坐标下它们的排布本身就是结论：α 从 1 涨到 16（16 倍），RMS 从 0.02326 涨到 0.41005（17.63 倍），双对数斜率约 1.04，几乎是一条斜率为 1 的直线。**幂指数等于 1，意味着 RMS 与 α 是正比关系**，既不是开方，也不是平方。换到线性坐标上，前四个点会全部挤在底部，只看得见最后一个——这就是这张图必须用双对数坐标的原因：要展示的是斜率，不是绝对值。

右图三根柱子的高度差得更多：超前 2.24274、滞后 0.00223、超前-滞后 0.02153。超前比滞后高三个数量级；超前-滞后的位置介于两者之间，但它离滞后只差 9.7 倍，离超前却差 104 倍。**“中等的结构”并不等于“中等的噪声”。** 如果按线性直觉取两者的中点，会得到 1.12，而真正夹在中间的那个方案只有 0.02153，相差 52 倍。这也是现场讨论噪声时最容易各说各话的地方：一方报的是倍数，另一方脑子里想的是分贝，两者对“中间”的定义根本不是一回事。

对一个 1 kW 级的伺服轴，2.24 的 RMS 意味着持续几安培的抖振电流，几分钟就能把电机绕组烤热。**这就是为什么现场工程师宁可接受 10.9 s 的调节时间，也不肯装一级 $\alpha = 38.82$ 的超前器。** 时域指标差一点是“不好用”，执行器烧了是“不能用”，两者的权重完全不同。

43.9.3 复合校正：噪声减半，鲁棒四倍

三条改进路线里，复合校正的名声最好，但它的噪声账要算仔细（§43.4.6 已经给过数据，这里从降噪角度看）。

同一个 $K_v = 20$ 约束下，加一个 $k_t = 0.2$ 的速度内环，外环超前的 α 从 38.82 降到 10.31，降了 3.8 倍。**但高频增益并不按 3.8 倍降**：前置增益必须从 4 补到 8，$K_c\alpha = 8 \times 10.31 = 82.5$，只降 1.88 倍。$\alpha$ 省下的那一半，被补 K_v 的增益又收了回去。仿真实测的 u 的 RMS 是 0.96854，相对单级的 2.24274 降 2.32 倍——多出来的那一点来自内环把等效对象的高频滚降变陡。

所以复合校正不是“降噪主力”，它是“用一半噪声换四倍鲁棒”。 相位裕度从 50.35° 升到 51.55°，增益裕度从 22.37 dB 略降到 20.02 dB，M_s 从 1.487 降到 1.400，而对象增益 +40% 时裕度跌幅从 12.498° 收到 3.159°。真正值钱的是最后这个数，不是噪声。

它为什么能在鲁棒性上赢这么多？因为内环把一部分“形状整形”的活从外环拿走了。外环的超前器只需要补内环剩下的那点相位缺口，α 自然小；而内环的作用在低频，不抬高频增益。k_t 越大，内环越硬，外环要补的越少

——表 43-13 的 α 从 11.63 一路降到 8.11，但 K_c 从 6 涨到 20，两者相乘反而从 69.8 涨到 162.2。**高频增益随 k_t 单调上升，这是复合校正最容易被忽略的代价。**

代价有两条，都得算清：

- **多一个传感器。** 速度反馈需要测速机或编码器差分，硬件成本与故障点都增加。没有测速信号的场合，只能改用状态观测器估速度，那就进入了第 46 章的范围。
- **多一层调试。** 内环闭合后，外环的 ω_c 从 10.230 降到 8.433，t_s 从 0.520 s 涨到 0.853 s。时间指标如果卡得很死（比如 0.6 s 内必须到位），这条路就走不通。

把这两条代价与 1.88 倍的降噪放在一起看，结论就清楚了：**复合校正该在“负载会变”的场合用，不该在“噪声超标”的场合用。** 为了降噪去加测速机，是把一个便宜的问题换成两个贵的问题；反过来，为了鲁棒性加测速机，顺手把噪声减半，那才是顺路捡的。§43.9.6 的取舍表就是按这个逻辑排的。

43.9.4 两级超前：摊宽而不是加高

当单级超前的 α 已经大到不能接受，而又没有测速条件上复合时，第二条路线是两级串联（§43.5.6 的实测：α 各 6.30、ω_m 12.52 与 25.04）。

它的降噪效果**并不是相对单级超前而言的**：158.8 与单级的 155.3 基本相同，噪声一分没省。它的好处要跟“达到同样相位平台所需的那一级”比：单级要在 $\omega_m = 35.05$ 处拿到 83.6° 的鼓包，α 得给到 80，高频增益 320；两级用两个矮鼓包拼出同样的平台，高频增益 158.8，**正好是一半**。原因是两个 6.30 相乘即得 39.7，而不是 80。

它的真正价值在采样受限的场合。表 43-16 的对比很说明问题：$T_s = 0.05$ 时单级最好只有 38.298°，两级能到 51.261°。**这不是“更好”，是“唯一可行”。**

代价前面列过：元件翻倍、增益裕度只有 7.02 dB、调节时间变长。还有一条容易被忽略——**两级的参数互相耦合**。第一级的极点会成为第二级回路的“对象”，两级的 ω_m 又必须错开，调试时改一个动全身。单级调一天能好的事，两级可能要三天。

43.9.5 带限超前：用相位买带宽

第三条路线最小改动：在一级超前器后面串一个一阶低通，把高频段截断。校正器变成

$$C(s) = K_c \frac{1 + s/z}{1 + s/p} \cdot \frac{1}{1 + s/\omega_{lp}} \tag{43-18}$$

代价可以手算，不需要仿真。低通在 ω_c 处贡献的滞后是 $\arctan(\omega_c/\omega_{lp})$；在远高于 ω_{lp} 的频段，增益按 $-\omega_{lp}/\omega$ 衰减，高频放大倍数从 α 降到 $\alpha\omega_{lp}/\omega$。

以主例的超前器为例。取 $\omega_{lp} = 10\omega_c = 102$ rad/s：

- 相位代价：$\arctan(10.2301/102) = 5.73^\circ$。原本 50.346° 会掉到 44.6° 左右，仍在 45° 线上，勉强够用。
- 降噪收益：1000 rad/s 处的增益从 155.3 降到 15.8，约 10 倍。

手算只给了 $10\omega_c$ 这一点。实际取多少合适，要把低通位置扫一遍。在 $\omega_{lp}/\omega_c = 2, 3, 5, 8, 10, 15, 20, 40$ 八个位置上实测（$\alpha = 38.82$、$\omega_m = 22.516$ 不动），相位裕度依次是 26.955°、33.312°、39.495°、43.383°、44.734°、46.573°、47.506°、48.919°，1000 rad/s 处的增益依次是 3.15、4.72、7.86、12.54、15.65、23.33、30.83、58.24 倍。这组数把“用相位买带宽”的兑换率标了出来：

- 从 $2\omega_c$ 挪到 $3\omega_c$，裕度涨 6.36°，1000 rad/s 的增益只涨 1.50 倍——这一段最划算。

- 从 $3\omega_c$ 到 $5\omega_c$，涨 6.18°，增益涨 1.67 倍；从 $5\omega_c$ 到 $8\omega_c$，涨 3.89°，涨 1.60 倍。
- 从 $10\omega_c$ 到 $15\omega_c$，只涨 1.84°，增益却涨 1.49 倍；再挪到 $20\omega_c$ 只有 0.93°。
- 越过 $20\omega_c$，每多一倍频率换不到半度，而增益照涨——这一段是白付噪声。

所以“8–15 倍”这个经验区间的真正含义不是“越大越安全”，而是**兑换率开始变差的那个拐点**：8 倍时 43.383°（离 50° 还差 6.6°，要在别处补），10 倍时 44.734°，15 倍时 46.573°。取 8 倍是为了省噪声，取 15 倍是为了保裕度，中间没有“最优”，只有“你更怕哪一头”。

手算与实测的偏差也值得记一笔：$\arctan(10.2301/102) = 5.73°$，实测掉 5.61°（50.346−44.734），手算偏保守 0.12°。原因是低通不只贡献相位滞后，还把穿越点从 10.2301 压到 10.1909，对象在那里的相位略好，抵掉零点几度。**这种二阶效应在手算里一律忽略，误差在 0.2° 以内；但 ω_{lp} 压到 $3\omega_c$ 以下时误差会放大**——那里实测掉 17.034°，手算 18.43°，差 1.4°，已经不能当“零头”处理。

这是一笔明码标价的交易：5.7° 的相位裕度换 10 倍的高频衰减。 它比复合校正省硬件（多一只电容、一只电阻），比两级超前省元件，适合“噪声超一点、裕度富余一点”的场合。

代价也要说清：低通不解决低频段的噪声，只压高频；低通的极点会与超前器的极点形成一个新的高频极点对，若 ω_{lp} 取得太低（低于 $3\omega_c$），相位代价会迅速涨到 15° 以上，把超前器的贡献吃掉一半。经验取值是 ω_{lp} 在 $8\omega_c$ 到 $15\omega_c$ 之间。

43.9.6 三条路线的取舍

把三条路线并排放在表 43-24 里。表中“降噪倍数”是相对单级超前的高频增益而言，用实测或式 (43-18) 估算。

表 43-24　三条改进路线的对照

路线	相位裕度	高频增益	降噪倍数	硬件代价	适用场合
单级超前（基准）	50.346	155.3	1	一只运放	噪声不敏感、时间要快
复合（$k_t = 0.2$）	51.549	82.5	1.9（按 u 的 RMS 是 2.3）	加测速与内环	有测速、要鲁棒
两级超前	51.261	158.8	1.0（对 $\alpha = 80$ 是 2.0）	两只运放	采样受限、单级无解
带限超前	约 44.6	15.8（1000 rad/s）	约 10	加一节 RC	裕度富余、噪声超一点

三条路线的排序很清楚：

- **要鲁棒性，选复合。** 它的漂移跨度 4.320°，是三条里唯一低于 5° 的。
- **要可行性，选两级。** $T_s\omega_c$ 接近 0.2 时它是唯一能拿到 50° 的结构。
- **要低成本，选带限。** 一只电阻一只电容，焊上去就见效，代价是 5.7° 裕度。

三条路线也可以叠用：复合之后如果噪声还超，就再加带限；两级之后如果漂移太大，就把内环也加上。工程上很少有“只用一招”的方案，多是把两三招按边际收益从高到低依次叠加，直到预算满足为止。**判断该叠哪一招的方法是一样的：看当前最紧的那条约束是什么，就补哪一项。**

43.10 工程落地

43.10.1 从传递函数到两只电阻一只电容

滞后校正器的电路实现是本章最容易落到实处的一节。取一个标准的分压网络：R_1 串联在输入与输出之间，R_2 与电容 C 串联后接地，输出取自 R_2 与 C 的连接点。分压比是

$$\frac{V_o}{V_i} = \frac{R_2 + \frac{1}{sC}}{R_1 + R_2 + \frac{1}{sC}} = \frac{1 + sR_2C}{1 + s(R_1 + R_2)C} \tag{43-19}$$

对照 $C(s) = (1 + s/z)/(1 + s/p)$，立刻读出三个关系：

$$z = \frac{1}{R_2 C}, \qquad p = \frac{1}{(R_1 + R_2)C}, \qquad \beta = \frac{z}{p} = \frac{R_1 + R_2}{R_2} \tag{43-20}$$

这个网络的直流增益是 1，高频增益是 $1/\beta$。要凑出 $C(0) = K_c = 4$，后面必须跟一级增益为 4 的同相放大器。整条链路的直流增益是 4、高频增益是 $4/\beta = 0.220$，与表 43-10 的实测一致。

代进主例的参数（$z = 0.19730$、$p = 0.010864$、取 $C = 100\ \mu\text{F}$），得

$$R_2 = \frac{1}{0.19730 \times 10^{-4}} = 50.685\ \text{k}\Omega, \qquad R_1 = \frac{1}{0.010864 \times 10^{-4}} - R_2 = 869.764\ \text{k}\Omega$$

时间常数 $R_1 C = 86.98\ \text{s}$。这两个数值得多说两句。

R_1 接近 1 MΩ，属于“高阻”范畴。运放的输入偏置电流（典型几十 nA）流过 870 kΩ 会产生几十 mV 的失调，温漂还会让这个失调缓慢变化。**校正器的极点频率 p 直接由 R_1C 决定，而 R_1 的值又受偏置电流约束，这是一对天然矛盾。**

想降 R_1，只能加大 C。取 $C = 1000\ \mu\text{F}$，R_1 降到 87 kΩ、R_2 降到 5.07 kΩ，偏置电流的问题消失，但电解电容的容差是 $-20\%/+80\%$、有极性、寿命随温度指数下降，这又把问题从“失调”换成了“漂移”。取 $C = 1\ \mu\text{F}$ 则相反，R_1 要涨到 87 MΩ，漏电流与电路板表面电阻都会成为主要误差源。

所以 100 μF 这个值不是随便挑的，它是“偏置电流—电容容差—体积”三者的折中。工程上更常见的做法是把 C 定在 1–10 μF 的薄膜电容，同时把 R_1 控制在 100 kΩ 以内——**这要求把极点频率 p 抬高，也就是把穿越频率 ω_c 抬高**，代价回到 §43.4.2 的“带宽与裕度”那笔账上。绕了一圈，还是同一条守恒律。

43.10.2 元件容差：几乎免费

电阻电容都有容差，5% 与 10% 是常规货。把 R_1、R_2 同向偏 5%、C 反向偏 5%（这是最坏的一类组合，因为 $z = 1/(R_2C)$ 会偏得最多），实测见表 43-25（`[10]` 段）。

表 43-25　滞后网络在元件容差下的表现

偏差	z (rad/s)	p (rad/s)	φ_M (°)	G_M (dB)
0	0.19730	0.010864	50.000	25.07
5%	0.19779	0.010892	49.973	25.07
10%	0.19929	0.010974	49.892	25.06

结论很干脆：**10% 的元件偏差只让相位裕度掉 0.108°，增益裕度几乎不动。** 原因在结构——z 与 p 都是 $1/(RC)$ 的形式，R 与 C 的同向偏差会同时缩放两者，比值 β 反而不变；裕度主要由 β 决定，所以对绝对值的

偏差不敏感。

这条性质是滞后校正的一大优点，也是它在工业现场活得比超前久的原因之一。超前校正的 $\alpha = p/z = R_1/R_2$ 只由电阻比决定，对单个元件的绝对值也不敏感，但它的零点位置 $z = 1/(R_2 C)$ 会直接移动相位鼓包，容差的影响要大一些。

要提醒的是，表 43-25 只扫了“同向偏差”。如果 R_1 偏 +10%、R_2 偏 −10%，β 会变 22%，裕度掉得比表里多得多。**采购时至少要保证 R_1 与 R_2 来自同一批次、同一精度档**，否则这张表不成立。

43.10.3 数字实现：系数量化比采样更危险

数字实现的流程是固定的：连续校正器按 $T_s = 0.02$ s 做 Tustin，得到

$$C(z) = \frac{0.22067148 - 0.21980243\,z^{-1}}{1 - 0.99978274\,z^{-1}} \tag{43-21}$$

写成差分方程就是

$$u[k] = 0.99978274\,u[k-1] + 0.22067148\,e[k] - 0.21980243\,e[k-1] \tag{43-22}$$

三个系数里有两个几乎相等（0.22067 与 0.21980），两个几乎等于 1（1 与 0.99978）。这种“系数几乎抵消”的结构是滞后网络在数字域的固有形态：它的直流增益 4 来自 $0.000869/0.000217$ 这个比值，分子分母都是小差。

小差结构对字长极其敏感。表 43-26 是不同有效位数下的实测（`[10]` 段）。

表 43-26　系数量化对滞后回路的影响（$T_s = 0.02$ s）

有效位数	分子系数	分母系数	φ_M (°)	G_M (dB)
6	0.220671，−0.219802	1，−0.999783	49.459	23.36
4	0.2207，−0.2198	1，−0.9998	49.024	23.33
3	0.221，−0.220	1，−1.00	47.149	23.13

6 位到 4 位只掉 0.435°，4 位到 3 位掉 1.875°。最后一步掉得特别快，原因不是精度不够，而是**极点被舍成了 1**：0.99978274 保留三位有效数字就是 1.00，$C(z)$ 于是退化成一个纯积分器。

这个退化在频域上看起来“更好”——积分器让系统型别从 I 型变 II 型，K_v 变成无穷大，稳态误差从 0.05 变成 0。但代价是相位裕度掉到 47.149°，而且积分器会带来积分饱和、起动过冲、退饱和缓慢等一整套问题。**一个看起来“性能更好”的舍入结果，实际是把一个精心设计的滞后网络变成了一个没设计过的积分器。**

工程上的做法是：

- 系数用 32 位浮点存，不要用定点；
- 若必须定点，至少保留 5 位有效数字，并且把分子分母同时归一化到分母首项为 1；
- 上机前把量化后的系数代回 $C(z)$，重新算一遍 φ_M 与 K_v，不要只看连续域的 50°。

43.10.4 运放与数字的四点差异

同一个传递函数，用运放搭和用单片机算，性能差别不在“精度”，而在四条物理约束上。表 43-27 把本章相关的差异列在一起。

表 **43-27**　模拟实现与数字实现的关键差异

差异	模拟（运放 + RC）	数字（单片机）	本章实测影响
参数误差	电阻电容容差 1%–10%	系数量化到 3 位	0.108° vs 2.851°
高频行为	受运放 GBW 限制，自然滚降	完全按系数走，直到 Nyquist	数字侧需外加低通
延迟	纳秒级，可忽略	半拍 + 计算延迟	按式 (43-12) 折算
漂移	温漂、老化，缓慢	无漂移，但会溢出	模拟侧需定期校准

第一行是本章最意外的结论：**数字实现的量化误差（2.851°）比模拟实现的 10% 元件容差（0.108°）大 26 倍。**很多人以为“数字更精确”，但在这种“系数几乎抵消”的结构里，定点量化的破坏力远超电阻容差。这不是数字的错，是结构选得不好——同样的滞后网络用浮点实现，6 位有效数字下只掉 0.541°。

第二行与第三行互相牵连。运放的高频滚降是自然发生的，数字实现没有这个过程，噪声会一直传到 Nyquist 频率才被折叠回来。所以数字实现必须额外加一级抗混叠低通，而这级低通又会引入延迟——回到式 (43-12) 的账上。**模拟实现是“免费”获得了高频衰减，数字实现要为它付两次钱：一次是滤波器，一次是延迟。**

“受 GBW 限制”这句话常被当成一个模糊的免责声明，其实它的影响可以算。做法是在超前器后面串一个极点 ω_{bw}，模拟运放的有限增益带宽，然后重算裕度。主例（$\alpha = 38.82$、$p = 140.2941$）的实测是：

- $\omega_{bw} = 10^6$ rad/s（159.2 kHz）：$\varphi_M = 50.345°$，跌 0.001°。
- $\omega_{bw} = 5 \times 10^4$ rad/s（8.0 kHz）：50.334°，跌 0.012°。
- $\omega_{bw} = 10^4$ rad/s（1.6 kHz）：50.287°，跌 0.059°。
- $\omega_{bw} = 5 \times 10^3$ rad/s（0.8 kHz）：50.229°，跌 0.117°。

结论有点出乎意料：**带宽从 159 kHz 一路降到 0.8 kHz，裕度只掉 0.117°。**原因是那个额外极点加在很高的频率上，而回路在那里的增益早已衰减到 0 dB 以下，对相位几乎没贡献。真正和带宽有关的要求不在裕度上，而在“能不能做出这个零极点对”上：超前器的最高转折频率是 $p = 140.2941$ rad/s，折合 22.33 Hz，运放的 GBW 必须远高于它，经验取 50 倍以上，也就是 1 kHz 量级就够。**主例的超前器用一只普通运放就够，瓶颈根本不在带宽，而在摆率与噪声。**这一条要在选型时先算清楚，否则容易在 100 MHz 的运放上白花钱。

第四行常被忽略。模拟电路的参数会随温度缓慢漂移，但漂移是连续的、可预测的；数字电路没有漂移，却会在数值溢出时突然失效。前者可以用定期校准对付，后者只能靠限幅与饱和检测兜底。

43.10.5 参数漂移的九宫格

比元件容差更现实的威胁是对象参数的变化。负载变了、温度变了、机械磨损了，对象的增益与极点都会动。本章的做法是把增益与极点各偏 ±20%，组成九个组合，逐个算裕度。结果汇总在表 43-28，图 43-8 是它的连续版本（`[8]` 段）。

表 **43-28**　对象增益与极点各偏 **±20%** 时的相位裕度区间

结构	φ_M 最低 (°)	φ_M 最高 (°)	跨度 (°)	ω_c 区间 (rad/s)
超前	45.33	56.23	10.903	8.506–11.811
滞后	39.11	56.74	17.623	0.727–1.296
超前-滞后	39.26	60.56	21.302	2.328–3.661
复合（$k_t = 0.2$）	49.41	53.73	4.320	6.498–10.382

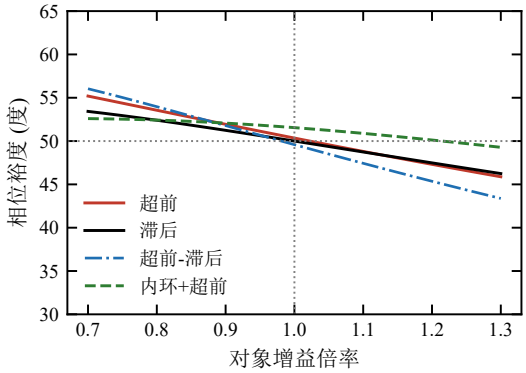

图 43-8　对象增益变化时四种结构的相位裕度

这张表的排序值得反复看：**复合 4.320° < 超前 10.903° < 滞后 17.623° < 超前-滞后 21.302°**。它与 §43.4.4 的“性能排序”完全相反——性能最好的超前，抗漂移排第二；性能中等的滞后，抗漂移排第三。没有任何一种结构能在两列同时占优，除了复合。

几个具体格点可以说明漂移的方向：

- **超前的对角格**：增益降到 0.8、极点升到 2.4 时，裕度 56.23°，是全表最高；增益升到 1.2、极点降到 1.6 时，裕度 45.33°，是全表最低。方向很清楚——**对象增益越大、极点越低，超前校正越吃力。**
- **滞后的极端格**：增益 1.2、极点 1.6 时裕度只有 39.11°，比设计值掉了 10.9°。原因是滞后靠“精确压到 0 dB”工作，对象增益一涨，压过头或压不够都会让穿越点乱跑。
- **复合的九格**：全部落在 49.41–53.73 之间，最差的一格也比其他三种结构的最好格更接近 50°。这是 §43.2.6 那条“等效校正器随对象变化”的直接证据——内环自己会跟着对象增益调整，外环不需要知道。

九宫格只能看到“两个参数一起动”的结果，看不到是谁在捣鬼。把增益与极点拆开，各扫 ±20%，答案立刻分开：

- **只动增益**（极点固定 2.0）：超前 53.557°→47.312°，跨度 6.245°；滞后 52.404°→47.481°，跨度 4.922°；超前-滞后 53.971°→45.359°，跨度 8.612°。
- **只动极点**（增益固定 1.0）：超前 48.080°→52.627°，跨度 4.547°；滞后 42.050°→55.395°，跨度 13.345°；超前-滞后 42.940°→56.031°，跨度 13.091°。

这张分解表改写了三条结论。

第一，**滞后的 17.623° 里有 13.345° 来自极点，增益只占 4.922°。**它的软肋不在“增益一变就压过头”，而在“机械极点一变，穿越点附近的对象幅值与相位同时变”。这一点可以直接量出来：滞后的穿越点在 1.0022 rad/s，低于机械极点 2.0；极点从 1.6 挪到 2.4 时，$|G(j1)|$ 从 5.29338 掉到 3.84136（差 37.8%），$\angle G(j1)$ 从 -124.868° 移到 -115.482°（差 9.4°）。幅值与相位朝同方向恶化，两个效应叠加。再看超前的穿越点 10.2301，它远在极点

之上：同样三档极点下 $|G(j10.2301)|$ 只从 0.08405 变到 0.08282（1.5%），相位只移 4.3°。**穿越点落在机械极点下方还是上方，决定了同一项漂移会被放大 3 倍还是被吸收掉。**

第二，**超前的两项差不多各占一半（6.245° 与 4.547°）**，这就是它跨度能压到 10.903° 的原因——没有哪一项特别突出。它的补偿量集中在 ω_m 附近的一个窄鼓包上，鼓包两边都是平的，所以参数动一动，鼓包位置偏一点，裕度只掉一点点。

第三，**超前-滞后的两项都最大（8.612° 与 13.091°）**，因为它是两段串联，任何一处参数漂移都会通过两段的耦合放大一次。§43.11.3 把它评为“漂移跨度最大”，根子就在这里。

换算成“每 10% 增益”的斜率更便于现场估算：增益各偏 10% 时，超前变化 -1.544° 与 $+1.589^\circ$，滞后 -1.262° 与 $+1.237^\circ$，超前-滞后 -2.151° 与 $+2.199^\circ$。**三者的斜率都在 12–22° 每 100% 增益之间，量级一致**，说明“对象增益变一倍、裕度掉十几度”是一条通用经验，与结构关系不大；结构真正决定的是极点那一半的敏感度。

图 43-8 把四条结构画成连续函数，横轴是对象增益倍率。复合那条几乎是水平线，其余三条都有明显斜度：超前最缓（跨度 10.903°），超前-滞后最陡（21.302°）。图的纵轴范围是 30–65°，正好把四条线的差异框住。

这张图应该和 §43.6.6 的判据表一起看。 判据表说“没有一种结构五条全过”，这张图补上了第六条隐性判据：漂移跨度。加上这一条，复合成为唯一一个“四项合格 + 漂移最小”的方案，代价是 82.5 倍的高频增益。

43.10.6 落地检查清单

把这一节的内容收成一张清单，上机前逐条打勾。

1. **量程**：R_1、R_2 是否在同一精度档，R_1 是否超过运放偏置电流允许的上限。
2. **电容**：容差、极性、温度系数是否满足 p 的精度要求；电解电容不要用在 $p < 0.05$ rad/s 的场合。
3. **增益级**：$K_c = 4$ 是否由独立的一级实现，能否单独校准；不要把它混在校正网络里。
4. **字长**：数字实现至少 5 位有效数字；若用定点，检查归一化后分母首项是否为 1。
5. **采样**：用式 (43-12) 算 $T_s\omega_c/2$ 的相位损失，确认在 5° 以内。
6. **抗混叠**：数字实现必须有一级低通，且其极点不低于 $8\omega_c$。
7. **漂移**：按 ±20% 扫一遍增益与极点，跨度超过 15° 就要改结构。
8. **噪声**：按 §43.9 注入 0.01 的噪声，看 u 的 RMS 是否在执行器允许的范围内。

八条里最容易漏的是第 3 条与第 4 条。K_c 混在校正网络里，现场就没法单独校准；字长不够，前面所有设计的 50° 都会在最后一步被打折。**这两条都属于“设计时看不见、调试时找不到”的类型，必须在图纸阶段就定死。**

43.11 优缺点与适用边界

43.11.1 超前：快而吵

超前校正是本章四种结构里时间指标最好的一种：调节时间 0.520 s、上升时间 0.1141 s、超调 20.73%，三项都是第一。它的作用机制清楚、参数只有一个 α、设计公式可以手算，是教科书里讲得最多的一种。

它的优点可以列成三条：

- **相位补偿效率高。** 一级网络最多能给 90° 以下的任意相位量，$\alpha = 38.82$ 就拿到 71.76° 的名义值、66.37° 的实际值。这个量级是滞后做不到的——滞后天生不给正相位。
- **设计过程最短。** 从缺口到 α 一步公式，从 α 到 z, p 一步开方，中间没有试凑。
- **不牺牲带宽。** 它把 ω_c 从 6.03 推到 10.23，带宽反而变大，对抑制中频扰动有利。

缺点是同一个参数带来的：**α 既是相位补偿量，也是高频增益。** 要 71.76° 就得付 155.3 倍噪声，没有中间道路。表 43-23 的 2.24274 与滞后的 0.00223 差三个数量级，这不是“稍差一点”，是“能不能用”的区别。

“155 倍能不能接受”有一条现成算式：把现场噪声折算到执行器。编码器 1 LSB 折合 1 mV、PWM 纹波 5 mV，合成按 5 mV 量级估；乘 155 得 0.78 V 的命令抖动。若执行器满量程 10 V，抖动占 7.8%，仍在线性区；若满量程只有 1 V，抖动直接顶到饱和，回路等效增益骤降，现场看到的现象是“小信号很好、一大信号就振”。**先算这个百分比，再谈能不能用，比争论“噪声大不大”有效得多。**

它的适用边界很明确：

- ω_c 可以抬高、执行器有余量、传感器噪声小的场合。比如实验室里的精密转台，编码器分辨率高、电机余量大，155 倍的噪声放大还能承受。
- 缺口在 20°–55° 之间。缺口小于 20° 时噪声付得不值；大于 55° 时 α 要超过 38.82，噪声开始失控。
- 采样周期满足 $T_s \le 0.1745/\omega_c$。主例要求 $T_s < 0.0171$ s，也就是 58 Hz 以上；用 50 ms 的 PLC 任务周期直接出局。

要避开的两类场合：**大惯量、低刚度、有机械谐振的轴**（高频增益会把谐振点激起来），**以及传感器噪声本来就大的现场**（155 倍放大后的噪声会直接烧执行器）。这两类场合在 §43.10.5 的九宫格里也表现最差——超前的跨度 10.903°，仅次于滞后与超前-滞后。

43.11.2 滞后：稳而慢

滞后校正是另一种极端：噪声 0.220 倍（比直流增益还低 18 倍）、增益裕度 25.07 dB、M_s 1.465，三项都是第一或接近第一；调节时间 10.913 s，是超前的 21 倍。

它的优点：

- **几乎不放大噪声。** $|C(\infty)| = 0.220$，噪声不但没被放大，还被压了 4.5 倍（相对 $K_c = 4$ 的基线）。
- **对元件容差极不敏感。** 10% 的 RC 偏差只掉 0.108°，因为 β 只由比值决定。
- **不需要额外增益级。** 滞后的直流增益就是 K_c，整个网络可以一级运放搞定。
- **高频段自然衰减。** 对机械谐振、PWM 纹波都有抑制作用，这是超前完全没有的好处。

缺点是“慢”，而且这个慢是结构性的：

- 穿越频率被压到 1.0022 rad/s，比纯增益时的 6.0291 低了 6 倍。带宽一低，跟随指令的能力就下来了，10.913 s 的调节时间对多数伺服场合都不可接受。
- 它靠“把幅频曲线提前压到 0 dB”工作，所以对对象增益的变化敏感——表 43-28 的跨度 17.623°，比超前还大。
- 低频段多了一段负相位（ω_c 处 -10.52°），会侵蚀一点阻尼，超调反而比超前高（24.58% vs 20.73%）。

适用边界：

- 过程控制类对象，时间常数在秒级甚至分钟级，10 s 的调节时间完全够用。温度、液位、流量这类回路是滞后的主战场。

- 稳态精度优先、动态要求宽松的场合。
- 采样周期粗、执行器功率小的场合——这两条恰好是超前的死穴。

要避开的场合：**快速跟随、轨迹跟踪、需要抗中频扰动**的伺服系统。滞后把带宽压到 1 rad/s，1 rad/s 以上的扰动一点都压不住。

43.11.3 超前-滞后：两头都不极端

超前-滞后把两段串联，$\omega_c' = 3$ 时给 49.584°、3.948 s、高频增益 2.079 倍。三个数都落在超前与滞后之间，像是一个“什么都能干、什么都不突出”的方案。

它真正的优点不在数值，而在**自由度**。单级超前只有一个 α，单级滞后只有一个 d；超前-滞后有两个（α 与 β），可以分别调“补多少相位”和“压多少幅值”。这让它能在同一张 Bode 图上同时完成两件事：滞后段把穿越点挪到 3 rad/s 附近，超前段在那里补 30° 左右的相位。**两次动作互不干扰，这是单级做不到的。**

它的缺点也很清楚：

- **元件翻倍。** 两只运放、四个阻容，电路板面积、调试工作量、故障率都翻倍。
- **漂移跨度最大。** 21.302°，是四种结构里最差的一个。原因是两段的参数都依赖对象：对象增益一变，滞后段压过头、超前段补不够，两个误差叠加。
- **设计要联立求解。** §43.2.5 的两个方程互相耦合，手算做不了，必须迭代。

适用边界：指标中等（比如“3 s 内到位、噪声 10 倍以内”）、参数漂移不剧烈、有空间放两只运放的场合。**它是“没有明显短板、但也没有明显长板”的方案，适合作为默认起点。**

43.11.4 反馈与复合：条件最优

反馈校正在本章的定位很特殊：**单用它不行，配合串联校正用极好。**

单用的实测（表 43-12）是：$k_t = 0.2$、$K_c = 4$ 时相位裕度从 1.576° 提到 6.987°，看起来有效，但 K_v 从 20 掉到 10。补回 K_v 之后（表 43-11），相位裕度反而掉到 2.586°。**所以“加个速度环就能改善稳定性”这句话是错的，它改善的是内环的阻尼，不是外环的裕度。**

配合串联校正用（表 43-13），它立刻变成最强方案：α 从 38.82 降到 10.31、高频增益从 155.3 降到 82.5、漂移跨度从 10.903° 降到 4.320°、M_s 从 1.487 降到 1.400。四项同时改善，只有调节时间从 0.520 s 涨到 0.853 s。

优点是“用局部反馈换全局性能”，这在控制里是一条通用策略：**内环负责把对象变“听话”，外环负责把指标做“漂亮”。** 内环把机械谐振、增益漂移这些“对象的事”就地解决掉，外环就不需要为它们留余量。

代价是三条硬约束：

- **必须有速度信号。** 没有测速机就得用观测器，进入第 46 章的范围。
- **K_c 与 k_t 强耦合。** $K_c = 4 + 20k_t$，改一个必须改另一个，现场调试容易乱。
- **内环自己会引入新极点。** 表 43-12 的慢极点从 −2.0 退到 −0.652，这个慢模态会在阶跃响应上留下一条长尾巴，t_s 从 0.520 s 涨到 0.853 s 就是它的代价。

适用边界：有速度信号、负载变化大、对鲁棒性要求高的场合。机床进给轴、机器人关节、电动车驱动都是这一类。**如果只能记一句话：负载会变的场合，优先考虑复合。**

43.11.5 五条边界条件

把前面四节的“适用边界”抽出来，是五条可以量化的硬线。任何一条不满足，对应的结构就不能选。

第一条：相位缺口。 缺口 $< 20^\circ$ 用滞后；20°–55° 用超前或超前-滞后；$> 55^\circ$ 用复合或两级超前。主例缺口 53.4°，落在第三档的边缘，所以单级超前要 $\alpha = 38.82$ 这么极端。

第二条：采样能力。 $T_s\omega_c/2$ 折算的相位损失必须小于 5°，即 $T_s < 0.1745/\omega_c$。超前的 $\omega_c = 10.2301$ 要求 $T_s < 0.0171$ s；滞后的 1.0022 只要求 $T_s < 0.174$ s。**这条线把“数字实现”变成了选结构的第一个筛选条件**，而不是最后一个。

第三条：噪声预算。 $|C(\infty)|$ 必须小于执行器允许的噪声放大倍数。本章示例给的线是 20 倍，超前与复合都过不了；如果现场能给到 50 倍，复合就合格了。

第四条：漂移跨度。 对象参数 ±20% 时裕度跨度必须小于 15°。滞后（17.623°）与超前-滞后（21.302°）过不了，超前（10.903°）勉强，复合（4.320°）宽裕。

第五条：对象是否含纯延迟。 本章所有结构都假设对象是最小相位的有理函数。如果对象含 $e^{-\tau s}$（传输延迟、计算延迟、液压管路延迟），相位会随频率线性下降，任何有限阶的校正器都补不回来。这类对象要用 Smith 预估或内模控制，见第 47 章。**这一条不是“选哪种结构”的问题，是“本章方法是否适用”的问题。**

五条线里前四条是“选哪个”，第五条是“能不能用”。现场排查时先过第五条，再过前四条。

这五条线的用法不是“命中就选”，而是“先看离边界多远”。主例的四组数离边界的距离差别很大：缺口 53.4° 距上沿 55° 只差 1.6°，所以单级超前落在“勉强”而不是“合适”；采样要求 $T_s < 0.0171$ s，现场若给 0.02 s，只超 17%，代价 5.830°（表 43-14）；噪声 155.292 倍是 20 倍线的 7.76 倍，超得最狠，对超前是一票否决；漂移 10.903° 距 15° 还剩 4.1°，是四条里唯一还有余量的；纯延迟这一条不是程度问题，是“有/没有”的开关。

五条线里，噪声与延迟是开关，缺口、采样、漂移是刻度。 开关只能换结构，刻度可以谈：目标从 50° 让到 45°，α 就从 38.82 掉到 15.655（高频 62.6 倍）；采样从 0.02 s 提到 0.01 s，损失按式 (43-12) 减半到约 2.9°；漂移预算放到 21.5°，超前-滞后也进线。**同一套指标，把三条刻度各松一格，原本“四个方案全出局”的项目往往就有一两个能用了。** 反过来说，如果三条刻度都已经松到不能再松、方案仍然出局，那说明对象本身需要改——换电机、加减速比、加编码器，都比在校正器上继续打转有效。

43.11.6 一页选型流程

把五条边界串成一个流程，就是下面这张表。

表 43-29　五种结构的优缺点与适用边界

结构	最大优点	最大缺点	适用	避开
超前	时间最快（0.520 s）	噪声 155.292 倍	缺口 20°–55°、噪声不敏感	采样粗、执行器弱
滞后	噪声最低（0.220 倍）	时间最慢（10.913 s）	稳态优先、慢过程	快速跟随、抗中频扰动
超前-滞后	两个自由度可分调	漂移跨度最大（21.302°）	中等指标、漂移小	参数变化剧烈
复合	鲁棒最好（4.320°）	需速度信号、t_s 涨 64%	变负载、有测速	无速度信号
带限超前	成本最低（一节 RC）	相位代价 5.73°	噪声略超、裕度富余	裕度已紧张

流程可以写成四步问答：

1. **对象含纯延迟吗？** 含，转第 47 章；不含，继续。

2. **相位缺口多大？** 小于 20° 直接选滞后；大于 55° 直接选复合或两级；中间继续。
3. **噪声预算是多少？** 小于 20 倍且缺口大于 40°：选复合；预算宽于 50 倍：选超前；介于两者：选超前-滞后加带限。
4. **漂移要求多严？** 跨度必须小于 5° 时只能选复合；小于 15° 时超前合格；不限制时按前三条选。

这四步走完，剩下的候选通常只有一两个。**如果还有两个，就用调节时间做最后裁决——因为它是唯一一个不能靠加元件补救的指标。**

把流程套在三个假定的场合上，能看出它怎么用。

场合一：进给轴，要求 0.6 s 内到位，噪声预算 20 倍。 缺口 53.4°，落在“20°–55°”的上沿。时间这一条先把滞后（10.913 s）与超前-滞后（3.948 s）排除；单级超前的 0.520 s 合格，可 155.292 倍的高频增益过不了 20 倍的线；复合的 0.853 s 又过不了 0.6 s。**四个方案全出局，说明指标本身互相矛盾**——要么把时间放宽到 0.9 s 选复合，要么把噪声预算抬到 160 倍选超前。这不是设计失败，而是守恒律在提醒：三项指标不能同时要。

场合二：温度回路，对象时间常数分钟级，采样 1 s，缺口 25°。 滞后的 10.913 s 完全够用，0.220 倍的高频增益还顺带压掉了热电偶的高频噪声；超前的 155 倍反而会把噪声灌进加热器。**选滞后，几乎没有第二个候选。**

场合三：任务周期 50 ms 的老设备改造，缺口 45°。 采样这一条一摆出来，结构就定了。按式 (43-12)，超前的 $\omega_c = 10.2301$ 要付 $0.5 \times 10.2301 \times 0.05 = 0.2558$ rad，合 14.66°；表 43-14 的实测是 35.743°，掉 14.603°，两者对得上。滞后的 $\omega_c = 1.0022$ 只付 1.44°，实测 48.584°，掉 1.416°。**同样的 50 ms，对超前是十几度的灾难，对滞后是一度半的零头。**

三个场合放在一起，“四步问答”的重心就很清楚了：第 2、3 步（缺口、噪声）决定**能不能**，第 4 步（时间）决定**选哪个**，而采样这一条常常在第 1 步之后就把候选砍掉一半。**先算采样，再看缺口，是本章最省时间的排查顺序。**

最后要强调的是：本章所有结论都建立在主例 $G(s) = 10/[s(s+2)(0.05s+1)]$ 上。换一个对象，具体数字会变，但五条边界的形式不变，守恒律不变，“按约束挑行”的方法不变。**这也是本章真正想教的东西：不是记住 38.82 这个数，而是记住“任何补偿都要在别处付账”这件事。**

43.12 Python 仿真代码

本章没有一处数字是估出来的，全部由 `code/ch043_sim.py` 打印；图由 `code/ch043_figs.py` 绘制。两个文件分工明确：前者只算不画，后者只画不算。出图脚本先 `import ch043_sim as sim`，再重新调用设计函数取参数，所以图和表永远是同一组数。**这一条比任何注释都重要**：改一个初值，表和图会一起变，不会出现“图是上周的、表是今天的”这种无法追溯的状态。

运行只有一行命令，解释器用项目约定的 py311 环境：

```
D:\Anaconda3\envs\py311\python.exe code/ch043_sim.py
```

43.12.1 两个文件、十组输出

`main()` 按 `[1]`–`[10b]` 编号打印，编号与正文的节一一对应，读代码时可以拿这张清单当索引：

- `[1]` 未校正基准：三档 K_c 的裕度与时域指标，对应 §43.1.2 表 43-1。
- `[2]` 超前：四档 α，对应 §43.4.1 表 43-7。

- `[3]` 滞后：三档 d，对应 §43.4.2 表 43-8。
- `[4]` 超前-滞后：三档 ω_c'，对应 §43.4.3 表 43-9。
- `[5]` 四种结构同台，对应表 43-10，末列是 $|C(\infty)|$。
- `[5b]` 反馈内环三组与复合校正，对应表 43-11 至表 43-13。
- `[6]` 同一连续校正器直接 Tustin 的采样惩罚，对应表 43-14。
- `[7]` $z \to w$ 校验与 w 域重设计，对应表 43-15、表 43-16。
- `[8]` 参数漂移九宫格，对应表 43-28。
- `[9]` 噪声注入，对应表 43-22、表 43-23。
- `[10]`、`[10b]` 元件容差、系数量化与 K_v 收口，对应表 43-25、表 43-26。

十组之外没有任何“手工抄数”的环节，正文里的每个小数都能在屏幕上按编号找到。常量集中在文件头部，只改这一处就能换题：

```
K0 = 10.0      # 对象增益
POLE = 2.0     # 机械极点 (rad/s)
TAU = 0.05     # 执行器时间常数 (s)
KC = 4.0       # 满足 K_v=20 所需的串联增益
PM_DES = 50.0  # 目标相位裕度 (deg)
```

要把目标裕度从 50° 改成 60°，只改 `PM_DES` 一行即可，三种设计函数都从它取值。但 K_c 与 K_v 是联动的：`KC` 一改，`KV` 跟着变，全部表格的稳态误差列都要重读。

换一个对象时，改动的顺序也要固定，否则会得到一堆互相矛盾的数：

1. **先改 `plant()`。** 分子分母一起改，别只改增益——`K0` 与 `POLE` 是分开的常量，只改 `K0` 相当于只改直流增益，机械极点还留在 2.0。
2. **再按新的 K_v 要求重算 `KC`。** 主例是 $K_v = 5K_c$，换对象后这个比例要重新推：$K_v = \lim_{s\to 0} sL(s)$，把新对象的低频展开代进去即可。
3. **然后才跑三种设计函数。** 它们都接受 `kc` 参数，不要用文件头的默认值硬跑。
4. **最后重看时间窗口。** `step_metrics()` 的 $T = 60$ s 是按滞后 10.9 s 定的；新对象若更慢，窗口要同步放大，否则“没有进带”会被误判成“发散”。

这四步的顺序与 §43.8.1 的调试顺序是同一个道理：**先锁不变量（对象、增益），再动可变量（结构、参数）。** 反过来做，等于在流沙上盖房子。

43.12.2 对象、频响与裕度

四个基础函数撑起全部计算：`plant()` 造对象，`fr()` 求频响，`margins()` 找穿越点，`step_metrics()` 量时域。

`fr()` 用 `sys.horner(1j * w)` 直接求值，不用 `ct.bode`。原因是后者返回的相位会被折叠到 $(-180^\circ, 180^\circ]$，在穿越点附近一跨过 $\pm 180^\circ$ 就跳变，做插值时会把 $+179^\circ$ 与 -179° 当成相差 358°。`horner` 给的是复数，要不要 `unwrap` 由调用者决定。

`margins()` 做两次插值，一次找幅值穿越，一次找相位穿越：

```
def margins(loop, n=8000):
    w = np.logspace(-3.0, 3.0, n)
    h = fr(loop, w)
    mag = np.abs(h)
    ph = np.degrees(np.unwrap(np.angle(h)))
    i = np.nonzero(np.diff(np.sign(mag - 1.0)))[0]
    if i.size:
        i = i[0]
        wc = w[i] * (w[i + 1] / w[i]) ** ((1.0 - mag[i]) / (mag[i + 1] - mag[i]))
        pm = 180.0 + np.interp(np.log(wc), np.log(w), ph)
```

幅值穿越用几何插值：在双对数坐标上 $|L|$ 近似直线，所以用 $\log\omega$ 的线性内插反解 $|L|=1$ 的位置，比直接用 ω 线性内插准得多。相位穿越用 `np.interp` 在 $\log\omega$ 上插值，取的仍然是第一个穿越点。

8000 个点不是随手定的。表 43-7 最后一行的 $\omega_c=10.2301$，用探针复算 $|G(j10.2301)|=0.083489$、$\angle G=-196.028^\circ$、$\angle C=66.374^\circ$，三者相加正好凑出 50.346°，与打印值一位不差。网格点再少一半，末位就开始跳了。

`step_metrics()` 取 $T=60$ s、24000 点，折合 2.5 ms 步长。窗口为什么是 60 s 而不是 20 s：纯增益那一行的 $t_s=49.940$ s，窗口短了它会被截成“没有进带”，表 43-10 第一行就废了。**仿真窗口要按最慢的那个方案定，不能按最快的定**，这是本章踩过的一个坑。

43.12.3 三种连续设计：扫描、二分、不动点

三种结构的数学性质不同，所以用了三种完全不同的算法。

`design_lead()` 是二维扫描：α 取 34 个对数点（1.5–80），ω_m 取 90 个对数点（0.3–60），3060 个组合各算一次裕度，取“能达到目标的最小 α”，再对 ω_m 做三轮局部细化（步长 20%、5%、1.2%）。为什么不用解析式：ω_c 随 α 移动，方程没有闭式解；而扫描还能顺带回答“这个对象到底能不能用单级超前做到 50°”——`lead_best_pm()` 就是专门问这个问题的，表 43-16 里 38.298° 那一行出自它。

`design_lag()` 是几何二分，因为滞后只有一个自由度 ω_c'，且 ω_c' 越高裕度越低，单调性成立：

```
def design_lag(g, decay=5.0, pm_des=50.0, kc=4.0):
    def pm_at(wc):
        beta = kc * abs(fr(g, [wc])[0])
        return margins(kc * comp(1.0, wc / decay, wc / decay / beta) * g)[0], beta
    lo, hi = 0.05, 20.0
    for _ in range(60):
        mid = np.sqrt(lo * hi)
        pm, _ = pm_at(mid)
        if not np.isfinite(pm) or pm > pm_des:
            lo = mid
        else:
            hi = mid
```

二分取 $\sqrt{lo\cdot hi}$ 而不是 $(lo+hi)/2$：ω_c 跨两个数量级，几何中点收敛得更均匀。β 在 `pm_at()` 内部由 $K_c|G(j\omega_c')|$ 现算，不作为独立参数传入——这正是“滞后只有一个自由参数”的代码体现。60 次之后区间窄到 10^{-15}，所以表 43-8 三行的裕度都是 50.000°，不是凑出来的巧合。

`design_lead_lag()` 是不动点迭代。它难在三个量互相咬住：α 由所需的补偿角定，补偿角要扣掉滞后段在 ω_c' 处的相位，而滞后段的相位由 β 定，β 又由 α 定（式 43-8 里的 $\sqrt{\alpha}$）。代码先给 $\beta=1$ 起步，解出 α，再由 α 更新 β，判据是 $|\beta_{\text{new}}-\beta|<10^{-12}$，上限 80 次。上限只是保险，正常对象远未用满就收敛了。

43.12.4 反馈内环与复合校正

`rate_loop()` 只有三行，但顺序不能换：

```
def rate_loop(kt, kf=1.0):
    gmech = kf * ct.tf([10.0], np.polymul([1.0, 2.0], [0.05, 1.0]))
    gi = ct.feedback(gmech, kt * ct.tf([1.0, 0.0], [1.0]))
    return gi * ct.tf([1.0], [1.0, 0.0])
```

先闭合机械+执行器，再把 $1/s$ 串在外面。积分器留在外环，是本章全部反馈结论的前提：闭合之后低频增益仍是 $10/(2+10k_t)$，K_v 有限、可补；如果把积分器放进内环，得到的是位置环，K_v 直接变成无穷大，稳态误差为零，但那就不是本章讨论的结构了。

参数 `kf` 是专为漂移实验准备的。$kf=1.4$ 让内环自己“感知”到对象增益变大，而外环的超前器保持出厂参数——这才对应“负载变重”的物理事实。表 43-13 最后一列那 3.159° 就是靠它算出来的。**漏掉 `kf`，复合就退化成普通串联超前，跨度那一列的 4.320° 无从谈起。**

`composite()` 的四行里，真正关键的是第一行 `kc = 4.0 + 20.0 * kt`。它是式 (43-11) 的直接实现，也是“内环吃掉的增益必须由前置级补回”这条硬约束的唯一代码表达。改这一行等于改 K_v，后面所有裕度都不再可比。

43.12.5 离散与 w 域：三只函数接力

离散部分是三只函数接力：`z_to_w()` 把对象搬到 w 域，设计在 w 域做，`w_first_to_z()` 再把校正器搬回 z 域。

`z_to_w()` 的核心是代入 $z=(1+hw)/(1-hw)$ 之后，分子分母各乘一次 $(1-hw)$ 的幂。不乘的话，结果会变成“多项式除以 $(1-hw)^n$”的形状，`ct.tf` 不接受，而且在 $w=1/h$ 处会留一个虚假的极点。乘的幂次是 $(1-hw)^{n-i}$ 与 $(1-hw)^{n-m}$，正好把分母的 $(1-hw)$ 全部约掉，所以输出仍然是多项式之比。三个 `poly_pow()` 调用就是在拼这些幂次。

`w_first_to_z()` 只有两行实质代码：

```
def w_first_to_z(zw, pw, kc, Ts):
    a1 = 2.0 / (Ts * zw)
    a2 = 2.0 / (Ts * pw)
    return kc * ct.tf([1.0 + a1, 1.0 - a1], [1.0 + a2, 1.0 - a2], Ts)
```

把 $w=\frac{2}{T_s}\frac{z-1}{z+1}$ 代进 $1+w/z_w$，通分得 $\frac{(1+a_1)z+(1-a_1)}{z+1}$；分母同理。公共的 $(z+1)$ 约掉，就剩下这一对系数。$a=2/(T_s z_w)$ 这个因子是 w 域与 z 域之间唯一的换算尺。

`dig_margins()` 不走 `ct.margin`，而是自己在单位圆上扫：$z=e^{j\theta}$，θ 从 0 扫到 π，取第一个 $|L|=1$ 的 θ_c，再由 $\varphi_M=180^\circ+\angle L(e^{j\theta_c})$ 得裕度。穿越频率报的是 θ_c/T_s，这是“伪频率”，比真实频率 $\frac{2}{T_s}\tan\frac{\theta_c}{2}$ 略低；表 43-14 全表都用同一个口径，横向比较不受影响，但不要拿它和连续域的 ω_c 直接对齐。

43.12.6 噪声、漂移与量化：实验怎么设

噪声实验调用 `simlib.simulate_discrete`，四条设置各有用意：

- `ref=0.0` 让回路空载，输出里只剩噪声响应，统计出来的 RMS 才是“噪声引起的”。
- `noise_std=0.01` 固定噪声强度，五个 α 用同一串噪声比较，比值才有意义。
- `seed=11` 固定随机种子，否则表 43-22 里 0.02326 与 0.04299 的差别可能来自种子而不是 α。
- 丢掉前 1250 点（25 s）。滞后的闭环慢极点 $t = 4.15$ s，25 s 是六个时间常数，残余不到 0.3%。

漂移实验是两层循环：外层对象增益倍率 `kg ∈ {0.8, 1.0, 1.2}`，内层机械极点 `po ∈ {1.6, 2.0, 2.4}`，九格逐格算裕度。复合那一组唯一多出来的一步，是内环用 `rate_loop(kt, kf=kg)`、外环用固定的 `zc, pc`——这一行把“内环随对象变、外环不变”这句话翻译成了代码。

量化实验用 `"%.*g"` 截有效数字，截完再除以分母首项做归一化。三个位数 6/4/3 对应表 43-26 的三行；3 位那一行的极点被舍成 1.00，$C(z)$ 退化成积分器，裕度掉 1.875°，全表最陡的一段就出现在这里。

最后是复现约定：随机种子、网格点数（8000/24000/30000/6000）、仿真窗口这三样固定之后，本章所有小数可以逐位复现。反过来，改动其中任何一样，末位数字就会动——这不是 bug，是数值方法的正常分辨率。正文引用的都是本机一次运行的输出，读者重跑应当得到同一组数。

重跑之后先核三个数，三个对上了再看别的。

一是 `margins` 对未校正回路返回的 $\varphi_M = 1.576^\circ$、$G_M = 0.83$ dB、$\omega_c = 6.0291$。这三个数只依赖对象与 K_c，与任何设计函数无关；对不上说明 `plant()` 的函数式或 `KC` 被改过，后面所有表都不必看。

二是 `design_lead` 返回的 $\alpha = 38.82$、$\omega_m = 22.516$、$\omega_c = 10.2301$。对不上多半是 `PM_DES` 被改：目标从 50 抬到 52，α 要从 38.82 涨到 64 上下，高频增益从 155.3 抬到 256，看起来像“算法失效”，实际只是换了题。

三是闭环阶跃的 $t_s = 0.520$ s。它受两样东西影响：`step_metrics` 的窗口（本章用 60 s、24000 点）与判稳阈值。窗口短于 3 s 时慢尾巴被截断，t_s 会返回一个偏小的假值；点数从 24000 降到 2000，采样间隔变粗，末位也会跳。三个数任一不符，先查常量，再查网格点，最后才怀疑推导。

这三个数分别代表三件事：未校正回路说明对象对不对，设计输出说明题目对不对，闭环指标说明评估方法对不对。三角对上，本章的表和图才有资格拿来当参照。

第44章 PID控制与整定方法

44.1 动机与直观理解

PID 是工业现场出现频率最高的四个字母。化工、冶金、造纸、机床、无人机、家电，凡是要让某个量“跟上给定值”的场合，默认方案几乎都是比例—积分—微分。它不依赖精确模型，参数有明确的物理含义，失效时还能退化成手动，这三点使它历经八十年仍然是控制工程师的第一门手艺。

但“最常用”与“最容易”是两回事。现场大量回路长期投在手动，或者投自动后指标勉强及格，原因往往不是 PID 结构不够好，而是三项作用各自的代价没有被算清楚：加大比例换来了快速，也换来了超调；加上积分消掉了残差，也埋下了饱和与慢振荡；加上微分压住了超调，也把噪声请进了执行器。本章的任务，是把这三笔交易逐项算给读者看。

为了让所有数字可核对，本章沿用第 37 章的伺服对象，即

$$G_0(s) = \frac{10}{s(s+2)} \tag{44-1}$$

它与第 37 章 §37.4 使用的是同一个传递函数，因此本章的 PD 结果可以与第 37 章的 PD 基线逐项对照。对象本身含一个积分环节，纯比例控制下阶跃无静差，但斜坡跟踪有差——这一点恰好是理解积分作用的入口。

44.1.1 一个现场场景

某包装线的送料轴要求跟随一条匀速位移曲线，工艺给两条硬指标：等速段的跟踪误差不超过 0.05，起停段的超调不超过 5%。工程师先按经验取纯比例 $K_p = 1$，仿真给出超调 35.09%、上升时间 0.425 s、调节时间 3.537 s；曲线在目标值上方冲出一个大包，起停时工件明显前窜。把增益降到 $K_p = 0.5$，超调降到 20.79%，但上升时间退化到 0.689 s，更关键的是等速段跟踪误差从 0.20000 增大到 0.40000，直接超标八倍。

于是加微分。$K_p = 1$、$K_d = 0.4$ 时超调降到 1.51%，调节时间从 3.537 s 缩到 0.662 s，起停段的问题解决了。但等速段的 0.20000 误差一分没少，因为微分只在误差变化时出力，对恒速跟踪的固定偏差无能为力。最后加积分，$K_p = 1$、$K_i = 0.1$、$K_d = 0.4$ 把斜坡误差压到 0.02700 量级，代价是超调从 1.51% 回升到 2.38%、调节时间从 0.662 s 拉长到 1.488 s。

这个“加一点、退一点”的过程，就是整定。它没有唯一的正确答案，只有在给定对象、给定指标、给定执行器能力下的一份折中方案。

把这段过程拆开，可以看到三个不同的约束在互相拉扯。跟踪精度要求控制器在等速段持续输出一个与速度成正比的量，这只能靠积分；起停平稳要求控制器在误差反向前提前减速，这只能靠微分；节拍要求整段过程在 0.8 s 内完成，这要求比例增益足够大。三个要求分别指向三个参数，而三个参数又共同决定同一个闭环特征多项式，所以它们不可能各自独立满足。现场工程师说的“调一个动三个”，指的就是这件事。

44.1.2 三项作用的一句话直觉

比例项看“现在”：误差有多大，就按比例出多大力。积分项看“过去”：误差存在了多久、累积了多少，就补多少，直到残差被磨平。微分项看“将来”：误差正在以多快的速度扩大，就提前反向刹车，防止冲过头。三句话对应三种数学操作：乘以常数、对时间积分、对时间求导。

频域里这三句话更清楚。比例环节在全频段幅值为常数、相位为零；积分环节幅值随频率下降、斜率为 -20 dB/dec，相位恒为 -90°；理想微分环节幅值随频率上升、斜率为 $+20$ dB/dec，相位恒为 $+90^\circ$。在 $\omega = 1$ rad/s 处实测：$K_p = 1$ 的纯比例环节 $|C| = 1.0000$、相位 0°；$K_i = 1$ 的纯积分环节 $|C| = 1.0000$、相位 -90.00°；$K_d = 0.4$ 的带滤波微分环节 $|C| = 0.4000$、相位 89.43°；三者合成的 PID（$2/1/0.4$）在该频率处 $|C| = 2.0919$、相位 -16.67°。微分环节的相位不到 90°，是因为一阶滤波在 1 rad/s 处已经开始衰减。

三项作用可以线性叠加，前提是系统始终在线性区。一旦执行器饱和，叠加关系失效：比例项还在按误差出力，积分项还在累积，微分项还在放大噪声，三者叠加后的输出被限幅削平，实际作用到对象上的只剩限幅值。这时讨论“哪一项起了多大作用”没有意义，因为三项都被同一个非线性环节截断。§44.9 的抗饱和，本质上是让积分项知道“输出已经被截断”，从而停止无效累积。

图 44-1 给出本章讨论的闭环结构。与教科书结构相比多了两处工程细节：控制器输出后的限幅环节，以及从限幅偏差引回积分器的抗饱和支路。这两处在 §44.9 会展开，先记住它们的位置。

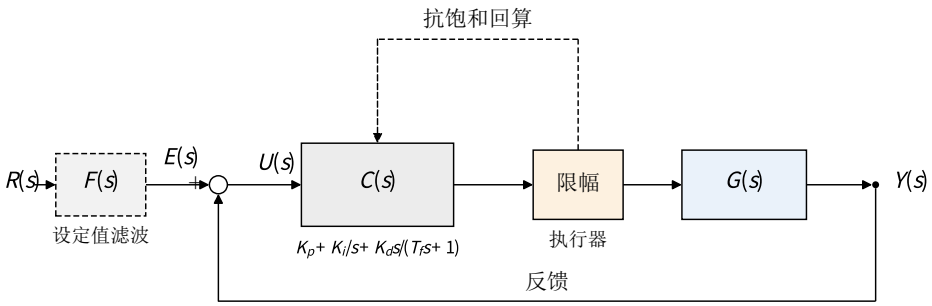

图 44-1　PID 闭环结构与抗饱和支路

图 44-2 把 P、PI、PD、PID 四种组合的阶跃响应画在同一张图上。四条曲线的差别不是“谁更先进”，而是“三种代价如何分配”：P 最快但冲得最高，PI 消差但拖尾，PD 平稳但留差，PID 兼顾但三者互相牵制。

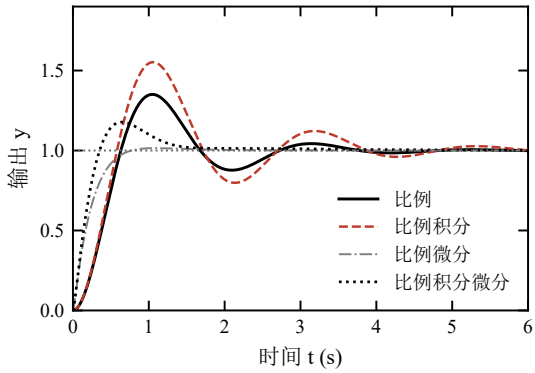

图 44-2　P/I/D 三项的单独作用

表 44-1 把三项作用的时域效果、频域特征与主要副作用列在一起。这张表是本章后续所有讨论的索引：凡是调参中遇到的问题，都能在其中找到对应的那一行。

作用	时域直觉	频域特征	主要收益	主要代价
比例 K_p	按当前误差出力	全频段 0 dB、0°	加快响应、提高刚度	超调增大、控制量峰值大
积分 K_i	按误差累积出力	-20 dB/dec、-90°	消除阶跃/斜坡残差	相位滞后、饱和、慢振荡
微分 K_d	按误差变化率出力	$+20$ dB/dec、$+90^\circ$	增加阻尼、抑制超调	放大噪声、对延迟敏感

44.1.3 为什么 PID 至今仍是默认选项

第一条原因是鲁棒。PID 不要求知道对象的阶次与参数，只要求对象大致单调、延迟不大。第 37 章已经说明，绝大多数工业对象在主导极点近似下都能退化成“一阶加延迟”或“二阶加延迟”，而 PID 对这两类对象的适应能力足够覆盖大部分工况。

第二条原因是可解释。K_p 调大响应变快、K_i 调大残差变小、K_d 调大超调变小，这三条定性规律在现场几乎不会失效。工程师不必打开仿真软件，凭曲线形状就能判断该动哪个旋钮。这种可解释性在故障排查时的价值，往往超过几个百分点的性能优势。

第三条原因是可降级。PID 结构天然支持手自动无扰切换：手动时把积分器钳在跟踪值上，切回自动时输出连续，不会打执行器。相比之下，基于模型的方法一旦模型失配或优化器不收敛，往往只能整体切手动。

从历史看，PID 的普及也不是因为它最优，而是因为它最早被做成了标准仪表。气动时代把比例、积分、微分做成三个可更换的波纹管，电子时代做成三个电位器，DCS 时代做成三个可组态的系数。每一次技术换代都保留了这三个旋钮，工程师的习惯也随之固化。今天即使有了更先进的方法，现场仍然倾向于“先用 PID 兜底”，因为它的行为可预期、故障可降级、交接有共同语言。

但“默认”绝不等于“随便调”。同一套 PID，参数差三倍，超调可以从 1.51% 变成 84.73%（§44.9 的限幅对比），执行器寿命可以差一个数量级。本章后面十节，讲的都是如何把这三个旋钮拧到该在的位置。

44.1.4 本章路线与一句话核心

本章按“原理—设计—连续—离散—稳定—参数—整定—改进—落地—边界—代码”推进。§44.2 给出 PID 的时域与频域表达，重点是把积分与微分放到频域里看清它们改的是哪一段；§44.3 把设计固化成六步流程；§44.4 用极点配置给出连续域的一组可算参数，并与第 37 章的 PD 基线横向对照；§44.5 讲位置式与增量式的等价性、采样周期的上限；§44.6 用增益裕度、相位裕度与灵敏度峰值量化“还能不能再加增益”；§44.7 用单变量扫描把 K_p、K_i、K_d 各自的影响做成表；§44.8 对比 Z-N、Cohen-Coon 与 IMC 三类整定规则；§44.9 讨论抗饱和、不完全微分、二自由度与增益调度；§44.10 把死区、量化、噪声、延迟、限幅叠加到同一个回路上；§44.11 说明 PID 的能力边界；§44.12 给出可复现代码。

如果只能记住一句话：**PID 的难点不在结构，而在三项各自换来了什么、又付出了什么；整定的本质是在给定对象与约束下分配这三份代价。**

不同读者可以走不同路径：只关心现场调参的，读 §44.1、§44.7、§44.8、§44.10；要做控制器设计的，读 §44.2、§44.4–§44.6、§44.9；要写代码或做二次开发的，直接看 §44.5 与 §44.12。三条路径都建议先跑一遍 §44.12 的脚本，本章所有数字都出自它。

阅读本章需要三个前置概念：传递函数与闭环特征方程（第 5、6 章）、二阶系统的超调与调节时间（第 37 章）、伯德图与稳定裕度（第 38 章）。若这三处还不熟，建议先回读对应小节；本章不再重复推导，只引用结论。

44.1.5 三个反例

概念讲完，先看三个真实的反例。它们都不是公式推错，而是“只看了指标的一半”。

反例一：只看超调，不看控制量。 按极点配置取 $\zeta = 0.707$、$\omega_n = 2.0$、$\alpha = 10$，解出 $K_p = 3.23$、$K_i = 4.00$、$K_d = 1.08$。仿真超调 9.03%、上升时间 0.143 s、调节时间 1.520 s，看起来是一份漂亮的答卷。但同一份仿真里控制量峰值达到 111.508，是参考幅值的 111 倍。真实执行器若有 ± 2 的限幅，这个设计连起步都做不到。**指标必须与控制量一起看**，这是 §44.10 的第一条纪律。

反例二：限幅加了，积分没管。 同一回路把输出限在 ± 0.6，控制器取 $3/5/0.3$。不限幅时超调 58.44%、调节时间 2.520 s；加上限幅但不做抗饱和，超调涨到 84.73%、调节时间 3.720 s，饱和占比 20.6%。原因很简单：输出被钳住，误差却还在累积，积分器一路涨到远大于限幅值，等误差反向后要花很长时间才能退回来。加上回算抗饱和、取 $T_t = 0.6$，超调降到 0.58%、调节时间 1.820 s。**限幅不是保护，抗饱和才是保护**。

反例三：采样周期按经验取。 同一组参数 $3.23/4.00/1.08$，$T_s = 0.02$ s 时超调 6.35%、调节时间 2.160 s，与连续域的 9.08%、1.518 s 接近；$T_s = 0.04$ s 时超调突然跳到 80.17%；$T_s = 0.05$ s 时闭环谱半径达到 1.1426，仿真输出冲到 1.8×10^{11}，系统已经发散。**采样周期不是“越小越浪费、差不多就行”，它有一条由谱半径画出的硬边界**，具体位置在 §44.5 给出。

三个反例指向同一件事：PID 的三项作用彼此耦合，任何一项的收益都可能被另一项的代价吃掉。本章后续所有公式与表格，都是为了让这三笔交易变得可计算。

把三个反例的代价换算成时间：反例一若直接投运，执行器限幅后实际超调无法预测，调试周期通常从半天延长到一周；反例二若不做抗饱和，每次大阶跃都要多等 1.2 s 退饱和，按每天 200 次起停算，一年累计多耗 24 小时；反例三若采样取 0.05 s，系统根本不能投运，只能返工改周期。这些代价都不在控制器参数表里，却真实发生在现场。

44.2 数学原理

本节把 §44.1 的三句直觉写成可计算的式子。顺序是：先给时域与传递函数，再进频域看三项各改哪一段，然后用误差系数说明“型别”决定残差，最后给出闭环极点配置公式——它是 §44.4 全部参数的来源。

44.2.1 三种等价写法

连续域理想 PID 的时域表达式为

$$u(t) = K_p e(t) + K_i \int_0^t e(\tau)\,\mathrm{d}\tau + K_d \frac{\mathrm{d}e(t)}{\mathrm{d}t} \tag{44-2}$$

其中 $e(t) = r(t) - y(t)$。对应的传递函数是

$$C(s) = K_p + \frac{K_i}{s} + K_d s \tag{44-3}$$

工程上更常见的是“标准型”，用积分时间 T_i 与微分时间 T_d 代替 K_i、K_d：

$$C(s) = K_p\left(1 + \frac{1}{T_i s} + T_d s\right), \qquad K_i = \frac{K_p}{T_i},\quad K_d = K_p T_d \tag{44-4}$$

两种写法的物理含义不同。并联型式 (44-3) 里三个参数互不牵连，调 K_i 不影响比例通道；标准型式 (44-4) 里 T_i、T_d 是“时间”，量纲与对象时间常数可比，现场按“积分时间设成对象时间常数的几倍”来整定时更直观。整定

表通常给 K_p、T_i、T_d，而控制器内部按并联型实现，转换关系就是式 (44-4) 的后两式。

三种写法之间的换算要小心一个细节：标准型的 T_i、T_d 与并联型的 K_i、K_d 是乘除关系，不是加减关系。现场把 K_p 调大一倍，若控制器内部按标准型实现，K_i、K_d 会跟着变大，闭环形状完全改变；若按并联型实现，K_i、K_d 不变，只有比例通道变。同一条整定表，在两种实现上结果不同，这是移植参数时最常见的坑。看控制器手册时，先确认它标的是并联增益还是时间常数。

还有第三种写法，把三项通分：

$$C(s) = \frac{K_d s^2 + K_p s + K_i}{s} \tag{44-5}$$

它在推导闭环特征方程时最方便，因为分子是一个二次多项式，分母只有一个 s。后文的极点配置直接用这个形式。

44.2.2 频域解释

把 $s = \mathrm{j}\omega$ 代入式 (44-3)，三项分别是：

$$C_p(\mathrm{j}\omega) = K_p, \qquad C_i(\mathrm{j}\omega) = \frac{K_i}{\mathrm{j}\omega}, \qquad C_d(\mathrm{j}\omega) = \mathrm{j}\omega K_d \tag{44-6}$$

三者的幅值与相位为

$$|C_p| = K_p,\ \angle C_p = 0^\circ; \qquad |C_i| = \frac{K_i}{\omega},\ \angle C_i = -90^\circ; \qquad |C_d| = \omega K_d,\ \angle C_d = +90^\circ \tag{44-7}$$

图 44-3 把这三条画成伯德图。比例是一条水平线，积分是一条斜率 -20 dB/dec 的直线，微分是一条斜率 $+20$ dB/dec 的直线。三者叠加后，PID 的幅频曲线呈“低频靠积分抬高、中频靠比例压平、高频靠微分抬高”的浴盆形，相位则在 -90° 与 $+90^\circ$ 之间过渡。

伯德图的斜率还有一层工程含义：积分段的 -20 dB/dec 意味着频率每降十倍，幅值升十倍；微分段的 $+20$ dB/dec 意味着频率每升十倍，幅值升十倍。两者在 $\omega = \sqrt{K_i/K_d}$ 处相交，该频率以下积分主导，以上微分主导。这个交点把 PID 的频段分成两半：低频段靠积分消差，高频段靠微分阻尼。比例增益不改变斜率，只把整条曲线上下平移，因此它决定穿越频率落在哪一段。

以 $K_p = 2$、$K_i = 1$、$K_d = 0.4$ 为例，交点频率为 $\sqrt{K_i/K_d} = \sqrt{2.5} = 1.581$ rad/s。在 $\omega = 0.1$ rad/s，积分项幅值 $1/0.1 = 10$，微分项只有 $0.4 \times 0.1 = 0.04$，两者相差 250 倍，低频段几乎全由积分说话；在 $\omega = 10$ rad/s，两者互换，积分 0.1、微分 4.0，相差 40 倍。可见“交点”不是一句定性描述，它把频轴切成了两个数量级悬殊的区间：离开交点一个十倍频程，强弱关系就拉开两个数量级以上。现场抱怨“积分调了没用”或“微分调了没用”，多半是把参数放在了交点另一侧。

三项叠加后的总幅值与总相位可以直接算。$\omega = 1$ rad/s 时，$|C_p| = 2$、$|C_i| = 1$、$|C_d| = 0.4$，合成的实部为 2、虚部为 $0.4 - 1 = -0.6$，幅值 $\sqrt{2^2 + 0.6^2} = 2.0881$，相位 $\arctan(-0.6/2) = -16.70^\circ$。§44.4 用频率响应函数实测到 2.0919 与 -16.67°，第四位小数的差异来自微分滤波 $T_f = 0.01$：滤波使微分幅值从 0.4000 降到 0.3999、相位从 90° 退到 89.43°。量级与符号都对得上，说明三项叠加的解析式可以直接用来估算。合成相位为负，说明在中频段积分仍然压过微分；只有到 $\omega > 1.581$ rad/s，相位才会翻正。**穿越频率落在交点左侧的 PID，微分实际上没有起到相位超前的作用**，这是很多“加了 D 却没变快”案例的根因。

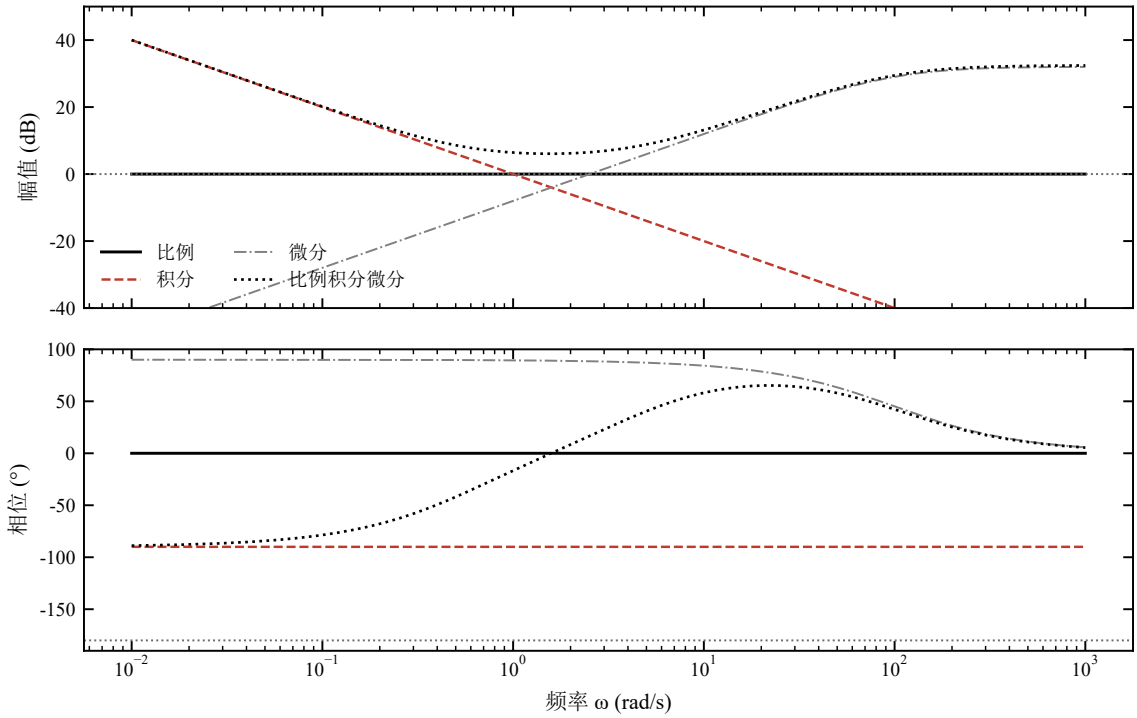

图 44-3　P/I/D 的频域角色

这张图解释了两件在现场反复出现的事。第一，积分作用在低频段提供很大的增益，所以它能消掉常值残差；但它在穿越频率附近贡献的是相位滞后，会把相位裕度往下拉，所以积分不能无限加。第二，微分作用在高频段提供很大的增益，所以它能提前刹车；但高频段同时是噪声的地盘，微分把噪声与信号一起放大，所以微分必须带滤波。

从相位看，理想 PID 在穿越频率 ω_c 处的相位补偿量为

$$\phi_c = \arctan(\omega_c T_d) - \arctan\!\left(\frac{K_i}{K_p \omega_c}\right) \tag{44-8}$$

第一项正比于 T_d，是“提前量”；第二项反比于 ω_c，是“滞后量”。整定就是在 ω_c 附近让第一项略大于第二项，使总相位留出足够的裕度。

44.2.3 型别与误差系数

闭环能否无静差，取决于开环传递函数 $L(s) = C(s)G(s)$ 在原点的极点个数，也就是“型别”。设

$$L(s) = \frac{K_v \prod (s + z_j)}{s^N \prod (s + p_k)} \tag{44-9}$$

其中 N 是原点极点个数。对单位反馈，误差传递函数为 $E(s)/R(s) = 1/[1 + L(s)]$，由终值定理可得表 44-2 的结论。

系统型别 N	阶跃输入 $1/s$	斜坡输入 $1/s^2$	加速度输入 $1/s^3$
0 型	$1/(1+K_{\text{pos}})$	∞	∞
1 型	0	$1/K_v$	∞
2 型	0	0	$1/K_a$

本章对象 $G_0(s)=10/[s(s+2)]$ 本身是 1 型。因此纯比例控制下，阶跃输入无静差，斜坡输入有常值误差。位置误差系数与速度误差系数分别为

$$K_{\text{pos}}=\lim_{s\to 0}L(s)=\infty,\qquad K_v=\lim_{s\to 0}sL(s)=\frac{10K_p}{2}=5K_p \tag{44-10}$$

斜坡误差为 $e_{ss}=1/K_v=0.2/K_p$，与 §44.1 的仿真值完全对上：$K_p=0.5$ 时 0.40000，$K_p=1$ 时 0.20000，$K_p=5$ 时 0.04000。这也说明“加大比例能减小斜坡误差”是有解析依据的，只是代价是超调。

加上积分后，开环变成 2 型，斜坡误差理论上为零。仿真给出的残差不是零而是 0.003350（$K_i=0.2$）到 0.000004（$K_i=0.5$）量级，原因是仿真在有限时间截断，积分器尚未完全收敛；$K_i=1.5$ 时残差反而回到 0.003815，则是因为系统接近稳定边界、振荡尚未衰减。**“2 型无差”是稳态结论，前提是闭环稳定且时间足够长。**

以本章的 PI 控制为例，$C=K_p+K_i/s$，特征方程为 $s^3+2s^2+10s+10K_i=0$。Routh 表给出稳定条件 $2\times 10>10K_i$，即 $K_i<2.0$。仿真中 $K_i=1.5$ 时调节时间已达 19.672 s、超调 87.23%，正是接近这条边界的表现；$K_i=2.0$ 时理论上等幅振荡，$K_i>2.0$ 时发散。解析边界与仿真趋势一致，说明模型没有漏掉主导动态。

同样的判据可以推广到完整的 PID。对式 (44-13) 的三阶特征多项式，Routh 表的第二行首项为 $(2+10K_d)\times 10K_p-10K_i$，要求它为正，整理后得稳定条件 $K_i<K_p(2+10K_d)$。

这个条件很值得记住：**微分增益 K_d 不仅提供阻尼，还直接放宽了积分增益的上界。**K_d 每增加 0.1，允许的 K_i 就增加 K_p。对 $K_p=2$、$K_d=0.4$，上界是 12.0；表 44-10 里 $K_i=4.0$ 只用掉三分之一的裕量，系统仍稳定，但调节时间已从 1.500 s 反弹到 2.897 s，这正是裕量被吃掉的前兆。反过来，若把 K_d 退回 0、K_p 仍取 2，上界立刻降到 4.0，同样的 $K_i=4.0$ 就正好压在边界上。这解释了现场一个常见现象：**去掉微分以后，原来能用的积分增益突然变得“太大”**，不是积分变了，是稳定边界收缩了。

需要注意，这条不等式只对本章这个二阶对象成立。对象阶次一变，Routh 表就变，上界也随之改变。工程上不能把这条不等式当通用公式背，但“微分放宽积分上界”这个方向是普遍的：任何增加相位超前的环节，都会把稳定边界往右推。

44.2.4 微分滤波与可实现性

理想微分 $C_d(s)=K_ds$ 的幅值随频率无限增长，物理上不可实现，因为任何真实信号都带高频噪声，微分会把噪声放大到执行器饱和。工程上统一用一阶惯性串联在微分上，即不完全微分：

$$D(s)=\frac{K_ds}{T_fs+1} \tag{44-11}$$

它在低频段近似为 K_ds，在高频段被 $1/(T_fs)$ 压住，最大增益被限制在 K_d/T_f。T_f 越小，微分越“纯”，抑噪越差；T_f 越大，微分越“钝”，抑噪越好。§44.9 会给出一组定量数据：同样 $K_d=0.5$、噪声标准差 0.005，T_f 从 0.001 s 增到 0.1 s，控制量标准差从 0.3353 降到 0.0357，差近十倍，而输出标准差几乎不变（恒为 0.0055）。

T_f 的选取有一个经验下界：至少取采样周期的 2–5 倍，否则离散化后滤波器本身会失稳；上限则取 $T_d/10$ 左右，再大就把微分作用磨没了。本章取 $T_f=0.05$ s，配合 $T_s=0.01$ s，比值 5，落在合理区间。

式 (44-11) 的转折频率是 $1/T_f$，这个数直接决定了滤波在多大程度上“伤”到微分。取 $T_f=0.05$ s，转折在 20 rad/s，比本章设计的穿越频率 10.947 rad/s 高约一倍；在穿越频率处，微分环节的相位是 $90^\circ-\arctan(\omega_cT_f)=90^\circ-\arctan(0.547)=61.3^\circ$，比理想微分的 90° 少了 28.7°。作为对照，$T_f=0.01$ s 时

转折在 100 rad/s，相位只损失 $\arctan(0.109)=6.2^\circ$，两者相差 22.5°。本章 §44.6 的裕度表统一用 $T_f=0.01$，就是为了让“设计值对实测值”的差额只反映延迟，不混入滤波的影响。滤波压得越狠，相位损失越大，这是“用 T_f 换平稳”必须付的账。

滤波还限制了控制量的初始冲击。$T_f=0.01$ s 时高频增益上限升到 $K_d/T_f=1.08/0.01=108$，一次设定值阶跃就能把控制量打到 $K_p+K_d/T_f=111.2$，与表 44-4 实测的 111.51 对得上；若取 $T_f=0.05$ s，同样的 K_d 只能打到 $3.23+21.6=24.8$，冲击降到四分之一以下。

这两个数放在一起，就是滤波时间常数的取舍：**T_f 越小，相位越接近理想，控制量冲击越大；T_f 越大，冲击越小，微分越钝**。工程上先按 $T_f=\sqrt{T_s\tau_d}$ 估一个起点（τ_d 为微分作用需要覆盖的最短时间，常取采样周期或对象小时间常数），再用噪声试验校核，比抄一个固定倍数可靠。

44.2.5 闭环特征方程与极点配置

把式 (44-5) 与 $G_0(s)=10/[s(s+2)]$ 相乘，得开环

$$L(s)=\frac{10(K_d s^2+K_p s+K_i)}{s^2(s+2)} \tag{44-12}$$

闭环特征方程为 $s^2(s+2)+10(K_d s^2+K_p s+K_i)=0$，展开得

$$s^3+(2+10K_d)s^2+10K_p s+10K_i=0 \tag{44-13}$$

若期望闭环极点配置为 $(s^2+2\zeta\omega_n s+\omega_n^2)(s+\alpha)$，展开后逐项比对，得到

$$K_p=\frac{\omega_n^2+2\zeta\omega_n\alpha}{10},\qquad K_i=\frac{\alpha\omega_n^2}{10},\qquad K_d=\frac{2\zeta\omega_n+\alpha-2}{10} \tag{44-14}$$

这三个式子就是 §44.4 的参数来源。它的好处是把“调三个增益”变成“选三个极点”：ζ 决定超调，ω_n 决定速度，α 决定第三个极点离虚轴多远。需要注意，式 (44-14) 假设微分理想、无滤波、无延迟，实际系统加滤波后相位会少一点，实测超调会比设计值略大——§44.4 的表会把这一偏差列出来。

第三个极点不能离得太近。若 α 只比 ω_n 大两三倍，它对二阶主导极点的响应有可见影响，实际超调会明显偏离 $\exp(-\pi\zeta/\sqrt{1-\zeta^2})$。本章统一取 $\alpha\ge 8$，把第三个极点推到主导极点之外四倍以上。

这个选择有一个折中。α 越大，第三个极点越远，主导二阶近似越准，但由式 (44-14) 可知 K_p、K_d 会随之增大，控制量峰值上升；α 越小，参数越温和，但第三个极点会参与响应，实际超调偏离设计值。本章试过 $\alpha=5$ 与 $\omega_n=2$ 的组合，实测超调 14.57%，远高于设计值 4.33%；把 α 提到 10 后，实测降到 9.03%。这就是表 44-4 统一取 $\alpha\ge 8$ 的原因。

44.2.6 抗饱和的数学描述

限幅是一个非线性环节：

$$u_{sat}(t)=\operatorname{sat}\big(u(t)\big)=\min\big(u_{\max},\max(u_{\min},u(t))\big) \tag{44-15}$$

若积分器仍按未限幅的误差累积，即 $\dot{x}_i=e$，则一旦 u 被钳住，x_i 会继续增长，直到误差反向后才慢慢退回。这段时间里控制器实际上处于“开环”状态，等效增益为零，表现为响应迟钝与大超调。

回算抗饱和（back-calculation）在积分器输入端加一个修正项：

$$\dot{x}_i = e + \frac{u_{sat} - u}{T_t} \tag{44-16}$$

其中 T_t 是回算时间常数。当未饱和时 $u_{sat} = u$，修正项为零，控制器退化为普通 PID；一旦饱和，修正项为负，把积分器往回拉，拉回的速度由 T_t 决定。T_t 越小，拉得越快，但太小会引起抖动；工程上常取 $T_t = T_i$ 或 $T_t = \sqrt{T_i T_d}$。§44.9 会给出 $T_t = 0.3$、0.6、1.5 三档的实测对比。

除了回算，还有两种常见的抗饱和写法。一是积分钳位：一旦输出饱和且误差方向与饱和方向相同，就停止积分；实现简单，但退出饱和时积分值可能仍然偏大。二是积分跟踪：让积分器直接跟踪一个“允许的输出”，即 $x_i \leftarrow (u_{sat} - K_p e - K_d u)/K_i$，效果与回算近似，参数更少。三种写法在稳态饱和时等价，在动态退饱和时略有差别；本章选回算，因为它的时间常数 T_t 有明确的物理含义，便于按 T_i 整定。

把式 (44-2)、(44-11)、(44-15)、(44-16) 合在一起，就得到本章仿真里实际运行的那套控制器。它比教科书多了滤波与抗饱和两个环节，但核心仍是三个增益。

44.3 设计步骤

PID 设计最怕两种情况：一上来就试参数，试到哪算哪；或者把公式算得很漂亮，装到现场却连执行器都推不动。本节给出一套可重复的六步流程，每一步都有明确的输入、输出与判据。流程本身不复杂，价值在于把“什么时候可以进下一步”写死，避免把仿真里的好数字直接当成现场的好结果。

44.3.1 六步流程总览

图 44-4 是这套流程的完整路径。左侧是主线：辨识对象、确定指标、选结构、算初值、仿真校核、现场投运。右侧是两个回退分支：仿真校核不通过时回到“选结构”或“算初值”；现场投运不通过时回到“辨识对象”，重新核对延迟与执行器能力。

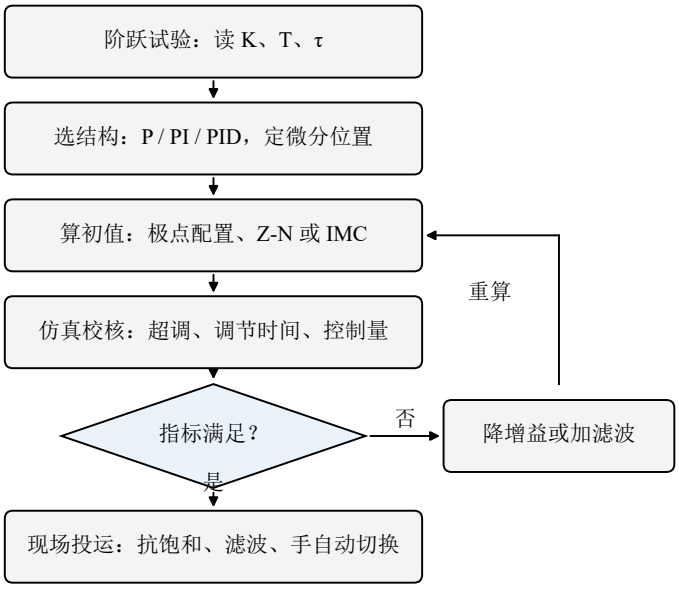

图 44-4　PID 整定流程

流程的关键不在箭头，而在每个判断框的判据。表 44-3 把六步的输入、输出与通过条件列在一起，可以当作现场的工作单使用。

六步中最容易被跳过的是第一步与第五步。辨识对象费时，仿真校核费事，工程师常直接从第三步跳到第六步，结果在现场反复试凑。把这两步补上，表面看多花半天，实际能省下几天的现场调试。

步骤	输入	输出	通过判据
1 辨识对象	阶跃/扫频试验数据	K、T、τ、限幅、死区	模型阶跃响应与实测偏差 <10%
2 确定指标	工艺节拍、精度等级	M_p、t_s、e_{ss} 及口径	指标可测、可验收、带误差带
3 选结构	对象型别、残差要求	P/PI/PD/PID	型别满足稳态精度，不多加积分
4 算初值	模型参数、目标极点	K_p、K_i、K_d	初值下闭环稳定、控制量不越限
5 仿真校核	初值、非线性模型	裕度、时域指标、谱半径	$GM \geq 6$ dB、$PM \geq 45^\circ$、$M_s \leq 2$
6 现场投运	校核通过的参数	验收曲线、参数存档	连续运行 3 个班次指标不越线

44.3.2 第一步：把对象摸清楚

需要辨识的四个量是：直流增益 K、主导时间常数 T、纯延迟 τ、执行器能力。前三个决定控制器参数，第四个决定这些参数是否可执行。很多“仿真好、现场差”的案例，根子都在第四项没测。

辨识方法按可获得性排序。能开环做阶跃的，用两点法：读响应达到 28.3% 与 63.2% 的时刻 t_{28}、t_{63}，按 $T = 1.5(t_{63} - t_{28})$、$\tau = t_{63} - T$ 反算。不能开环的，做闭环临界振荡试验，逐步加大比例直到等幅振荡，记

录临界增益 K_u 与临界周期 T_u，再用 §44.8 的 Z-N 临界比例度公式。两种方法都要注意：试验幅度要小，避免把对象推到非线性区；τ 要用多次试验的中位数，单次测量容易被噪声带偏。

两点法的依据是一阶响应 $y/K = 1 - \mathrm{e}^{-t/T}$。取 28.3% 与 63.2% 两点，分别对应 $t = \tau + T/3$ 与 $t = \tau + T$，两点之差是 $2T/3$，所以要乘 1.5 才得到 T；再减去 τ 才是延迟。用这两个点而不是 0 与 63.2%，是因为起始段受死区与噪声影响最大，取 28.3% 可以避开。若对象是二阶或带惯性，两点法给出的 T 是“等效时间常数”，用于整定足够，用于精确建模不够。

拿本章的过程对象做一次实测：$K = 1.5$、$T = 2.5$ s、$\tau = 0.8$ s，采样 0.01 s，阶跃后读到 $t_{28} = 1.640$ s、$t_{63} = 3.300$ s，算得 $T = 1.5 \times (3.300 - 1.640) = 2.490$ s、$\tau = 3.300 - 2.490 = 0.810$ s。与真值相比，T 偏小 0.4%，τ 偏大 1.25%，两个误差都在 1.5% 以内。这点误差代进 Z-N 开环公式 $K_p = 1.2T/(K\tau)$，T 偏小 0.4%、τ 偏大 1.25%，两者相抵后 K_p 偏小约 1.7%，对整定没有实质影响。**两点法的精度足够，前提是采样足够密、阶跃幅度足够大且没有触发限幅。**

执行器能力要测三条曲线：最大推力（或最大流量）、死区宽度、回差大小。以本章对象为例，若阀门从 4 mA 到 20 mA 对应 0 到 1，死区 0.02、回差 0.01，则任何小于 0.03 的控制量变化都不会产生动作。这个数必须写进仿真模型，否则算出来的 0.01 量级调节精度是假的。

44.3.3 第二步：把指标写成可验收的句子

“响应快一点、超调小一点”不是指标。可验收的指标必须包含四要素：哪个信号、什么激励、什么口径、什么限值。例如“单位阶跃下，输出超调不超过 5%，10%→90% 上升时间不超过 0.30 s，±2% 调节时间不超过 0.80 s，控制量峰值不超过额定值的 80%”。

四要素里最容易被忽略的是“控制量峰值”。§44.1 的反例一已经说明，超调 9.03% 的设计可能对应 111 倍的控制量峰值。因此指标里必须同时写输出指标与执行器指标，二者的关系是：输出指标决定控制器“想做什么”，执行器指标决定它“能做什么”。

指标还要写清测量位置。同样是“输出超调”，用编码器读数与用相机测量，结果可能差一个量化台阶；同样是“调节时间”，用控制器内部变量与用上位机趋势，采样率不同，判定也不同。验收文件里应写明：测哪个信号、从哪里取、采样周期多少、滤波怎么设。

44.3.4 第三步：选结构，而不是直接选 PID

结构选择的依据是稳态误差要求与对象特性，不是“PID 最通用”。判据如下：

- 对象本身含积分环节（如本章 G_0），阶跃无静差，若只做定值控制，P 或 PD 就够，加积分只会引入滞后。
- 对象为 0 型且要求阶跃无差，必须加积分，用 PI 或 PID。
- 对象延迟大、时间常数大，微分作用对噪声敏感，优先 PI，必要时用 IMC 整定把带宽压低。
- 对象有谐振峰或需要快速抑制扰动，PD 或 PID 的微分项才有价值。

结构定错，后面参数再准也没用。一个常见错误是“看到有残差就加积分”，结果对象本身已经是 1 型，残差来自执行器死区而不是型别不足，加了积分反而在死区边界来回积分，产生极限环。

结构选择的代价可以量化。对本章的 1 型对象，纯比例 $K_p = 1$ 时阶跃超调 35.09%、调节时间 3.537 s，斜坡误差 0.20000；改成 PI（$K_i = 0.5$）后斜坡误差降到 0.000004，超调却升到 55.27%、调节时间升到 5.610 s。也就是说，**在这类对象上买“斜坡无差”要付 20 个百分点的超调**。如果工艺只做定值控制、设定值长期不变，这笔钱完全不必花；只有确实存在匀速爬升的设定值或持续的单向扰动，积分才是必需的。

反过来，若对象是 0 型（如 $1/(Ts+1)$），不加积分就必然有静差，此时“省掉积分”省掉的是精度。判断标准只有一条：**看稳态误差的来源是型别不足，还是死区、摩擦、量化这些非线性因素**。前者要靠积分，后者要靠补偿或提高执行器分辨率。

44.3.5 第四步：用解析法算初值

初值不要凭感觉给。三条可用路径：

其一，极点配置。按 §44.2.5 的式 (44-14)，选定 ζ、ω_n、α 直接算出三个增益。本章的四组设计即用此法，例如 $\zeta=0.707$、$\omega_n=2.0$、$\alpha=10$ 给出 $K_p=3.23$、$K_i=4.00$、$K_d=1.08$。

其二，IMC 整定。对一阶加延迟对象，取滤波时间常数 λ，按 §44.8 的公式直接算出 K_p、T_i、T_d。λ 越小响应越快、鲁棒性越差，通常取 $\lambda=\tau$ 起步。

其三，Z-N 或 Cohen-Coon。把辨识得到的 K、T、τ 代入经验表，得到一组“偏激进”的初值。它们的设计目标是 1/4 衰减比，超调通常在 25%–50%，只适合作为起点，不适合直接交付。

三条路径给出三组不同的数，这很正常。初值的作用是让仿真有一个稳定的起点，不是终点。

三条路径也可以互相校验。若极点配置给出的 K_p 与 IMC 给出的相差三倍以上，说明目标极点选得不合理，或对象参数辨识有误。先解释这个差异，再决定用哪组。工程上常用的做法是：以 IMC 为基准，以极点配置为上限，在两者之间扫一遍，选裕度与速度都满意的点。

44.3.6 第五步：仿真校核，看四个量

校核不能只看阶跃响应。至少要看四个量：时域指标、控制量峰值、稳定裕度、采样闭环谱半径。

时域指标按第二步的口径算。控制量峰值要对照执行器限幅，本章建议留 20% 余量，即 $|u|_{\max}\le 0.8u_{\text{sat}}$。稳定裕度的工程下限是 $GM\ge 6$ dB、$PM\ge 45^\circ$；若对象有未建模延迟，还要按 §44.6 的 Padé 模型复核一遍。采样谱半径必须小于 1，工程上建议小于 0.95，留出参数漂移的余量。

以本章 $3.23/4.00/1.08$ 这组参数为例：无延迟时 $PM=78.63^\circ$、$M_s=1.08$，裕度充足；加 0.05 s 延迟后 $GM=7.55$ dB、$PM=47.27^\circ$、$M_s=1.94$，刚好压在下限之上；加 0.10 s 延迟后 $GM=1.91$ dB、$PM=15.91^\circ$、$M_s=6.06$，已经不合格。这就是“裕度要按最坏延迟复核”的原因。

校核不通过时，回退有三条路径，代价依次升高。第一条是降带宽：把 ω_n 从 2.0 退到 1.5，得到 $1.92/1.80/0.81$ 那组，同样的 0.10 s 延迟下 GM 从 1.91 dB 回到 4.73 dB、PM 从 15.91° 回到 36.23°、M_s 从 6.06 降到 2.71，代价是上升时间从 0.143 s 拉长到 0.211 s、调节时间从 1.520 s 拉长到 2.244 s。第二条是削积分：延迟大时积分是相位滞后的主要来源，把 K_i 减半通常能换回十几度相位，但斜坡误差会成倍增加。第三条是改结构：延迟占比超过 0.3 时，再调 PID 参数也补不回相位，应转第 47 章的 Smith 预估或第 58 章的模型预测控制。三条路径的次序不能颠倒，因为前两条只动参数、不动代码，第三条要动架构。

仿真模型要包含四类东西：对象动态、采样保持、执行器非线性、测量噪声。少一项，校核结论就偏乐观。很多团队只做了第一项，把仿真当成“验证参数能稳定”，结果现场一加限幅就变样。第四项也常被忽略：无噪声仿真里微分可以取很大，一带噪声就抖得不能用。

44.3.7 第六步：现场投运与无扰切换

现场投运的第一件事不是投自动，而是把积分器预置到与当前手动输出匹配的值。若手动输出为 u_0、当前误差为 e_0，则令 $x_i=(u_0-K_pe_0-K_du_d)/K_i$；若投运瞬间令设定值等于测量值使 $e_0=0$，就退化为 $x_i=u_0/K_i$，切换瞬间控制器输出连续，不会打执行器。以本章 $K_i=4.00$、手动稳态输出 $u_0=0.35$ 为例，预置值应为

$x_i = 0.0875$；若不预置而让 x_i 从零起步，投自动后积分器要累积 $\int e\,\mathrm{d}t = 0.0875$ 才能补上这段偏置，按误差 1 计算约需 0.09 s，这段期间误差被强行拉向负值，输出会出现一次可见的下冲。这一步在 DCS 里通常由“跟踪”功能自动完成，但自研控制器必须显式实现。

投运前还要做一次“假投自动”：保持输出跟踪，但把设定值设为当前测量值，观察控制器输出是否平稳。若输出在零误差附近来回跳，说明微分噪声或死区补偿有问题，先解决再真投。这个动作不需要动执行器，风险最低，却能提前暴露大部分实现错误。

投运顺序建议：先投 P，观察稳态与振荡；再加 I，观察残差与饱和；最后加 D，观察超调与噪声。每加一项至少观察 30 min，确认没有慢周期振荡再进下一步。若中途出现等幅振荡，退回上一组参数，不要在现场继续试。

验收时要留三样东西：阶跃响应曲线、参数表、当时的工况记录。工况记录包括负载、温度、延迟估计，因为同一组参数在轻载与重载下的表现可能差一倍，没有工况记录的曲线无法复现。

44.3.8 四条容易漏掉的检查

第一条，检查积分器的初值与限幅。很多控制器上电时积分器为零，而对象需要一个小偏置才能维持当前工况，投自动瞬间输出会跳变。正确做法是用当前测量值反算偏置，或让积分器从跟踪值起步。

第二条，检查微分项的输入源。微分作用在误差上还是输出上，效果差别很大：前者在设定值阶跃时产生微分冲击，后者不会。本章仿真用 $c = 1$ 表示作用在误差、$c = 0$ 表示作用在输出，§44.9 的数据显示同一组 Z-N 参数在两种接法下超调从 77.31% 降到 54.19%。

第三条，检查采样与计算的同步。控制器计算周期、传感器采样周期、执行器更新周期三者不一致时，等效延迟会按最慢的那一环算。若三者分别为 10 ms、10 ms、50 ms，实际延迟至少 50 ms，稳定裕度要按这个数复核。

第四条，检查量纲与标度。输入是 4–20 mA、输出是 0–100%，中间要不要换算，换算系数写在哪一层，必须固定。同一套参数，若把误差从“百分比”改成“毫伏”，数值会差几个数量级，控制器立刻失稳。这类错误在联调阶段很常见，排查时先看量纲，再看参数。

44.4 连续情形

连续域是理解 PID 的基准。先把对象当成没有延迟、没有限幅、没有噪声的理想模型，把参数与指标之间的关系算清楚；后面几节再逐项加入离散化、饱和与噪声。本节所有数字都来自 §44.12 的脚本，对象统一为 $G_0(s) = 10/[s(s+2)]$，微分滤波取 $T_f = 0.01$ s。

44.4.1 按极点配置给出四组设计

用 §44.2.5 的式 (44-14)，选四组目标极点，得到表 44-4 的参数与仿真结果。

ζ	ω_n	α	K_p	K_i	K_d	设计 M_p	实测 M_p	实测 t_r	实测 t_s	$\lvert u\rvert_{\max}$
0.707	1.5	8	1.92	1.80	0.81	4.33%	8.07%	0.211 s	2.244 s	83.13
0.707	2.0	10	3.23	4.00	1.08	4.33%	9.03%	0.143 s	1.520 s	111.51
1.0	2.0	10	4.40	4.00	1.20	0%	8.96%	0.120 s	1.264 s	124.40
0.8	2.5	10	4.62	6.25	1.20	1.52%	11.22%	0.116 s	1.138 s	124.63

四组参数的共同规律是：ω_n 越大，t_r 越小、$u_{\max}$ 越大；ζ 越大，设计超调越小，但实测超调并不跟着归零。第二组与第三组的对比最说明问题：把 ζ 从 0.707 提到 1.0，设计超调从 4.33% 降到 0，实测却从 9.03% 只降到 8.96%，几乎没有改善。

以第二组为例，把 $\zeta=0.707$、$\omega_n=2$、$\alpha=10$ 代入式 (44-14)：$K_p=(4+2\times0.707\times2\times10)/10=3.23$，$K_i=10\times4/10=4.00$，$K_d=(2\times0.707\times2+10-2)/10=1.08$。三步都是代数运算，不需要迭代。设计者要做的只是选极点，剩下的交给公式。

原因是零点与第三个极点。闭环传递函数不是标准二阶，PID 的零点与 α 极点都会改变响应形状；当 ω_n 较大时，第三个极点 $\alpha=10$ 相对 $\omega_n=2$ 只有五倍，其影响不可忽略。另一方面，微分滤波在穿越频率附近贡献的相位少于理想微分，等效阻尼低于设计值。两条因素叠加，实测超调总比设计值高 4–9 个百分点。

这个偏差不是错误，而是提醒：**极点配置给的是起点，不是终值**。工程上通常按设计值留一半余量，例如要求实测 10%，就按 4%–5% 设计。

把四组的偏差单独列出来，趋势是单调的：设计 4.33% 对实测 8.07%（高 3.74 个百分点）、4.33% 对 9.03%（高 4.70）、0 对 8.96%（高 8.96）、1.52% 对 11.22%（高 9.70）。设计值越低、ω_n 越大，绝对偏差越大；四组的 α/ω_n 从 5.33 一路降到 4.00，第三个极点离虚轴越来越近，同时 PID 的两个零点恰好落在 ω_n 附近，把主导极点对的形状又推歪了一点。**这意味着余量不能按比例留，要按绝对百分点留：本章范围内，至少留 10 个百分点。**若工艺要求实测 5%，按设计 2% 去配极点是不保险的，必须回到仿真里迭代一轮。

表 44-4 还暴露了参数随目标极点变化的非线性。把 ω_n 从 1.5 提到 2.0（第三列 α 同时从 8 提到 10），K_p 从 1.92 涨到 3.23，是 1.68 倍；K_i 从 1.80 涨到 4.00，是 2.22 倍；K_d 只从 0.81 涨到 1.08，是 1.33 倍。三者的涨幅不同，说明“等比例放大带宽”在 PID 上不成立：积分项按 ω_n^2 增长，比例项近似按 ω_n 增长，微分项增长最慢。控制量峰值随之从 83.13 涨到 111.51（1.34 倍），而上升时间只从 0.211 s 缩到 0.143 s（0.68 倍）。**用 34% 的执行器余量换 32% 的上升时间，这笔交易是否值得，要看执行器还剩多少余量，而不是看响应曲线好不好看。**

极点配置还有一个隐含约束：式 (44-14) 的第三式要求 $2\zeta\omega_n+\alpha>2$，否则算出的 K_d 为负，物理上无法实现。本章四组都远大于 2，所以没有触发；但若把 ω_n 压到 0.5、α 取 1，$2\times0.707\times0.5+1=1.71<2$，$K_d$ 就变成负值。这个约束的物理含义是：**二阶对象本身只有 2 的阻尼项，PID 若想摆出更慢的极点，就必须用负微分去“抵消”对象阻尼**，而负微分在工程上等于正反馈，不能用。

44.4.2 控制量峰值来自微分冲击

表 44-4 最后一列的 83–125 倍控制量，几乎全部来自 $t=0$ 的微分冲击。对单位阶跃，$e(0^+)=1$，带滤波微分的初始输出为

$$u(0^+)=K_p+\frac{K_d}{T_f} \tag{44-17}$$

以第二组为例，$3.23+1.08/0.01=111.23$，与仿真的 111.51 吻合。第三组 $4.40+1.20/0.01=124.40$，完全一致。这说明峰值不是对象造成的，而是“微分作用在误差上”这一接法的固有现象。

解决办法有两个。一是把微分作用在输出上（$c=0$），设定值阶跃时微分项不响应，$u(0^+)=K_p$；二是给设定值加一阶柔化，把阶跃变成斜率有限的斜坡。前者不改变扰动响应，后者会牺牲一点快速性。§44.9 会给出 $c=0$ 时的对比数据：同一组 $3.23/4.00/1.08$，$c=1$ 时 $|u|_{\max}=21.230$，$c=0$ 时只有 3.276。

设定值柔化的做法是在 r 后串一个一阶滤波 $1/(T_r s+1)$，T_r 取采样周期的 2–5 倍。它把阶跃变成指数上升，微分项的初始斜率被限制在 $1/T_r$。按式 (44-17) 的口径估算，$T_r=0.1$ s 时峰值约为 $3.23+1.08/0.1=14.0$，比 111.23 低一个数量级；代价是上升时间增加约 T_r。这是估算值，实际还要受对象动态影响。

44.4.3 与第 37 章 PD 基线的核对

第 37 章 §37.12 给出的 PD 数据是无滤波的 $C(s) = K_p(1 + T_d s)$。本章重跑同样的四组，结果与第 37 章逐项一致，说明两章的仿真口径相同，可以横向比较：

K_p	T_d	第 37 章 M_p	本章复核 M_p	t_r	t_s
1.0	0.0	35.09%	35.09%	0.425 s	3.537 s
1.0	0.2	10.42%	10.42%	0.474 s	1.676 s
1.0	0.4	1.61%	1.61%	0.455 s	0.678 s
3.0	0.3	4.77%	4.77%	0.189 s	0.828 s

把同样的 K_p、K_d 换成带 $T_f = 0.01$ s 滤波的实现，指标略有变化：$1.0/0.2$ 组超调从 10.42% 变成 10.43%、调节时间从 1.676 s 变成 1.660 s；$1.0/0.4$ 组超调从 1.61% 变成 1.51%、调节时间从 0.678 s 变成 0.662 s。$T_f = 0.01$ s 相对对象时间常数 0.5 s 很小，所以差异在 0.1 个百分点与 0.02 s 量级。这给出一个实用结论：**滤波时间常数小于对象主导时间常数的 1/20 时，可以先用无滤波公式设计，再按实测微调。**

两章数据完全一致不是巧合：`ch037_sim.py` 与 `ch044_sim.py` 都调用 `simlib.closed_loop` 与 `step_metrics`，对象定义相同，仿真时长与点数也相同（10 s、5000 点）。这说明本书的样章之间可以互相引用，读者不必担心口径漂移。

44.4.4 PD 与 PID 的横向对照

同一 K_p、同一 K_d，只加一个小积分，观察三项指标如何移动：

K_p	K_d	K_i	M_p 变化	t_r 变化	t_s 变化	斜坡 e_{ss} 变化
1.0	0.2	0.1	10.43% → 11.96%	0.460 → 0.457 s	1.660 → 1.798 s	0.2000 → 0.02700
1.0	0.4	0.1	1.51% → 2.38%	0.433 → 0.436 s	0.662 → 1.488 s	0.2000 → 0.02700
3.0	0.9	0.3	4.87% → 5.14%	0.169 → 0.170 s	0.794 → 0.864 s	0.0667 → 0.00901

三行的规律一致：积分把斜坡误差压下一个数量级，代价是超调增加 0.3–1.2 个百分点、调节时间延长 9%–125%。$1.0/0.4$ 那一行的调节时间从 0.662 s 涨到 1.488 s，翻了一倍多，原因是积分时间 $T_i = K_p/K_i = 10$ s，相对闭环带宽太慢，积分器要花很长时间才把残差磨掉，期间拖出一条长尾。

注意三行的 $T_i = K_p/K_i$ 都等于 10 s：$1.0/0.1$、$1.0/0.1$、$3.0/0.3$ 算出来都是 10。这不是巧合，而是仿真时刻意保持了同一积分时间，以便单独观察“有无积分”的差别。它也解释了为什么三行的调节时间都被拉长：在零点与对象极点近似对消的前提下，积分模态的时间尺度由 T_i 决定，与 K_p、K_d 关系不大；只要 T_i 还是 10 s，换哪一组比例微分参数，积分都要花同样的时间磨掉残差。因此“加积分一定变慢”并不成立，慢的是 T_i 取得过大。把 K_i 同比放大到 $T_i = 2$ s，积分收敛会快五倍，代价是相位滞后增加、超调上升。

这组数据给出一条实用建议：**积分时间不要取得比闭环调节时间大一个数量级以上**。若闭环 t_s 约 0.7 s，T_i 取 3–7 s 比较合适；取 10 s 就会明显拖慢。反过来，若 T_i 取得过小，积分作用过强，会引入相位滞后与振荡，§44.7 的 Ki 扫描会给出边界。

积分时间的下界由稳定性决定。对本章对象，K_i 的 Routh 边界是 2.0，对应 $T_i = K_p/2$；$K_p = 1$ 时下界约 0.5 s。上界由调节时间决定，T_i 超过 10 s 就会拖尾。合理区间大约在 1–7 s，跨一个数量级，具体取值看工艺更在意残差还是更在意平稳。

44.4.5 参数设计图

把 K_p 与 K_d 作为两个坐标，固定 $K_i = 1$，扫出一张超调等值线图，就是图 44-5。图上标出了第 37 章的 PD 工作点（$K_p = 3$、$K_d = 0.9$）与本章极点配置的 PID 工作点（$3.23/4.00/1.08$）。

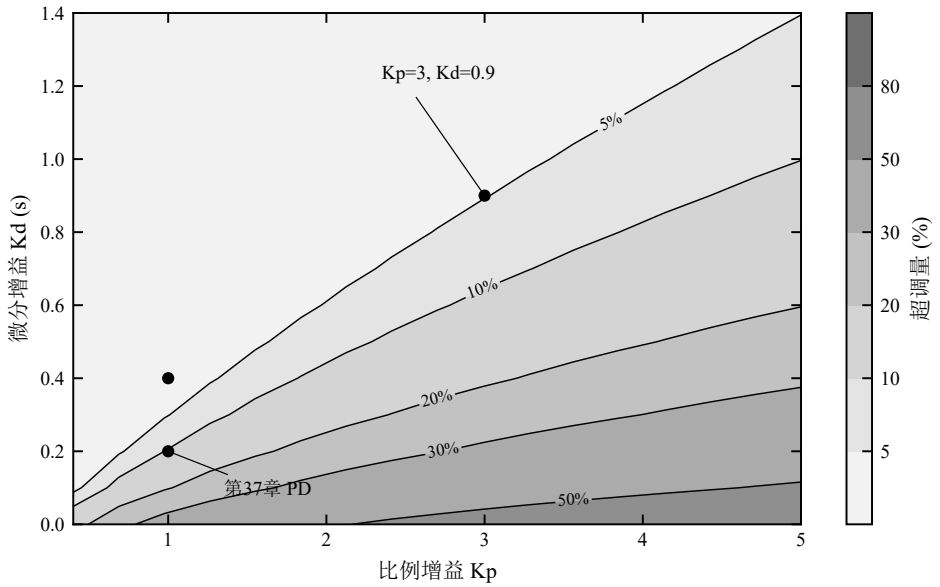

图 44-5　PD 参数—超调设计图

这张图有两个用途。第一，读等值线的形状：在 K_p 较小时，提高 K_d 能显著压超调；当 K_p 超过 4 以后，等值线变得密集，再加 K_d 的边际收益下降，而控制量峰值继续上升。第二，判断工作点是否“贴着悬崖”：若工作点落在等值线密集区，对象参数稍有漂移，超调就会跳一个台阶；应尽量选在等值线稀疏的一侧，留出鲁棒余量。

本章的 $3.23/1.08$ 工作点落在中等密度区，K_p 方向还有约 1.0 的余量、K_d 方向还有约 0.4 的余量。这个余量不是拍脑袋，而是图上量出来的。

等值线图的生成方法是：在 $K_p \in [0.5, 5]$、$K_d \in [0, 1.5]$ 的网格上逐点仿真，记录超调，再用 contour 插值。网格 25×25，共 625 次仿真，每次 5000 点，耗时约十几秒。图上每一条线代表一个超调水平，线越密表示超调对参数越敏感。读图时应沿着等值线的法线方向移动，那才是超调变化最快的方向。

44.4.6 连续设计的适用条件

本节所有结论都建立在三个假设上：对象模型准确、无纯延迟、执行器不限幅。三条中任何一条不成立，表中的数字都要打折扣。

模型误差的影响是渐进的：增益误差 20% 相当于 K_p 变化 20%，可按图 44-5 估算超调变化；时间常数误差 20% 主要移动穿越频率，对超调影响较小。纯延迟的影响是突变的：§44.6 的数据显示，同一组 $3.23/4.00/1.08$，加 0.05 s 延迟后 PM 从 78.63° 掉到 47.27°，加 0.10 s 后只剩 15.91°。限幅的影响也是突变的：一旦进入饱和，线性设计的全部结论失效，必须按 §44.9 的抗饱和方法处理。

增益误差到底影响什么，可以用一组实测说明。控制器仍取 $3.23/4.00/1.08$，把对象增益从 10 分别改成 5 与 20，闭环指标如表 44-5 所示。

对象增益 K	M_p	t_s (s)	PM	M_s
5	16.31%	1.868	75.34°	1.05
10（名义）	9.08%	1.518	78.63°	1.08
20	4.70%	1.120	75.26°	1.15

这张表说明：**增益失配主要改变超调与速度，对相位裕度的影响很小**。增益翻倍时超调从 9.08% 降到 4.70%，增益减半时升到 16.31%，而 PM 只在 75°–79° 之间移动，M_s 不超过 1.15。原因是增益变化只把幅频曲线上下平移，穿越频率随之移动，但在本章这个频段内 G_0 的相位变化平缓，所以裕度不敏感。这与延迟的影响形成对照：延迟只改相位、不改幅值，却能把裕度从 78.63° 打到 15.91°。**排查现场问题时，若表现为超调变化而振荡频率不变，先查增益与执行器标度；若表现为振荡频率下降、甚至出现等幅振荡，先查延迟。**

模型误差的影响还可以用灵敏度近似估算：闭环超调对 K_p 的偏导数可由图 44-5 的等值线间距读出，间距越小，偏导越大。本章工作点附近，K_p 变化 10% 引起超调变化约 1 个百分点，属于可接受范围；若工作点移到 $K_p = 4.5$，同样的 10% 变化会引起约 3 个百分点的变化。

因此连续设计在工程上的定位是“给出一个有理有据的起点”，而不是“给出最终参数”。真正交付的参数，必须在带延迟、带限幅、带噪声的模型上复核过，并在现场按 §44.3 的流程验证过。

44.5 离散情形

现场控制器是数字的：每隔 T_s 秒采一次、算一次、发一次。连续域的公式必须变成递推式才能执行，而这个变换不是无损的。本节先给两种标准递推写法并证明它们等价，再给出采样周期的硬边界，最后讨论字长与实现细节。

44.5.1 位置式算法

位置式直接对连续式 (44-2) 做矩形积分与后向差分：

$$u(k) = K_p e(k) + K_i T_s \sum_{j=0}^{k} e(j) + \frac{K_d}{T_s}\big[e(k) - e(k-1)\big] \tag{44-18}$$

它每一步都重新计算输出的绝对值，因此需要保存全部历史误差的和。工程上不会真的存一个数组，而是维护一个累加变量 $s_e(k) = s_e(k-1) + e(k)$。位置式的优点是输出与误差历史一一对应，便于限幅与跟踪；缺点是累加变量一旦溢出或被扰动，输出会整体偏移，而且手自动切换时必须重新预置。

加入一阶滤波后，微分项改为状态递推：

$$x_d(k) = \frac{T_f x_d(k-1) + T_s e(k)}{T_f + T_s}, \qquad u_d(k) = \frac{K_d\big[e(k) - x_d(k)\big]}{T_f} \tag{44-19}$$

其中 x_d 是滤波器的状态。式 (44-19) 与连续域 $K_d s/(T_f s + 1)$ 的前向—后向混合离散对应，在 $T_s \ll T_f$ 时与连续实现一致。本章仿真用的就是这一式。

44.5.2 增量式算法

增量式输出的是控制量的变化量：

$$\Delta u(k) = K_p\big[e(k)-e(k-1)\big] + K_i T_s e(k) + \frac{K_d}{T_s}\big[e(k)-2e(k-1)+e(k-2)\big] \tag{44-20}$$

执行时累加：$u(k) = u(k-1) + \Delta u(k)$。它不需要保存误差累加和，只需要最近三个误差；手自动切换时天然无扰，因为切换瞬间 $\Delta u = 0$ 或由手动增量接管；积分饱和的影响也小一些，因为积分项只以增量的形式出现，不会单独积成一个巨大的数。

增量式可以从位置式直接相减得到。把式 (44-18) 在 k 与 $k-1$ 两拍各写一遍，相减，累加项只剩 $K_i T_s e(k)$，比例项变成 $K_p[e(k)-e(k-1)]$，微分项变成二阶差分。这个推导说明两式不是两种控制律，而是同一控制律的两种存储方式：位置式存绝对量，增量式存变化量。

增量式的缺点是不能直接限制输出绝对值。若执行器限幅为 $\pm u_{\max}$，必须在累加后钳位，而钳位会破坏“增量可逆”的性质，长期单向饱和后仍会漂移。因此增量式通常配合“输出钳位 + 增量清零”使用：一旦钳位，下一步的 Δu 只在反向时生效。

44.5.3 两种写法的等价性核对

同一控制律、同一组误差序列，两种写法必须给出同一个输出。取 $T_s = 0.02\,\text{s}$、$K_p = 2$、$K_i = 1$、$K_d = 0.4$，误差序列 $e = [1.00, 0.70, 0.45, 0.30]$，逐拍计算如表 44-6。

k	$e(k)$	位置式 $u(k)$	增量 $\Delta u(k)$	增量式累加 $u(k)$	偏差
0	1.00	22.0200	22.0200	22.0200	0
1	0.70	−4.5660	−26.5860	−4.5660	0
2	0.45	−4.0570	0.5090	−4.0570	0
3	0.30	−2.3510	1.7060	−2.3510	0

四条记录的最大偏差为 1.776×10^{-15}，是双精度浮点舍入的量级。这个核对看起来是常识，但现场代码里两种写法不一致的案例并不少见，原因通常是：位置式的积分项漏了 T_s、增量式的二阶差分符号写反、或者微分项用了不同的滤波状态。**写完递推式，先用一组短序列对拍，再上闭环。**

表 44-6 的第一行可以手算复核：$k=0$ 时 $e(0)=1.00$，前两拍误差为零，位置式给出 $2\times 1.00 + 1\times 0.02\times 1.00 + 0.4/0.02\times(1.00-0) = 2 + 0.02 + 20 = 22.02$；第二拍 $e(1)=0.70$，比例项 1.40、积分项 $1\times 0.02\times 1.70 = 0.034$、微分项 $0.4/0.02\times(0.70-1.00) = -6.00$，合计 -4.566。手算与表值逐位一致，说明脚本里没有隐藏的系数。注意微分项在 $k=0$ 就贡献了 20，占 22.02 的九成——**离散 PID 的第一拍同样有微分冲击，冲击幅度是 K_d/T_s，比连续域的 K_d/T_f 还要大**，因为 T_s 通常小于 T_f。这个细节在写代码时最容易被忽略，也是不少控制器“一投自动就打满输出”的直接原因。

对拍时要注意初值。位置式的累加和从零开始，增量式的 $u(-1)$ 也要设为零，否则第一拍就对不上。实际代码里 $u(-1)$ 通常预置为当前手动输出，这时位置式也要把积分器预置成对应值，两者才等价。

44.5.4 采样周期的影响

把连续控制器 $3.23/4.00/1.08$ 与对象分别用零阶保持器离散，闭环仿真结果如表 44-7。谱半径一列是把控制器与对象分别 ZOH 离散后，再按单位反馈闭合，取闭环极点的最大模。

T_s (s)	闭环谱半径	M_p	t_r (s)	t_s (s)	y_{ss}	$\lvert u\rvert_{\max}$
连续	—	9.08%	0.143	1.518	1.0000	111.23
0.005	0.9947	5.94%	0.118	1.710	1.000	111.23
0.010	0.9915	4.43%	0.090	1.890	1.000	111.23
0.020	0.9883	6.35%	0.049	2.160	1.001	111.23
0.040	0.9864	80.17%	0.037	2.800	1.000	111.23
0.050	1.1426	发散	—	—	—	1.8×10^{11}
0.100	2.2065	发散	—	—	8×10^{26}	7.5×10^{28}

表里有一个反直觉的现象：T_s 从 0.005 s 增大到 0.04 s，谱半径一直在 0.99 附近，看起来“很稳定”，但超调从 5.94% 跳到 80.17%。原因是谱半径只说明极点是否在单位圆内，不说明极点离单位圆多近、也不说明零点位置。$T_s=0.04$ s 时极点仍在圆内，但微分项的离散化引入了接近 $z=-1$ 的零点，响应出现强烈的拍频。

表中的 t_r 随 T_s 增大反而从 0.143 s 降到 0.037 s，也不能按字面理解。离散仿真的时间分辨率变粗，10%→90% 的穿越点被量化到更少的采样点上，读数偏小；同时粗采样下的微分会产生超前尖峰，把上升段拉陡。这不是性能真的变好，而是测量与实现的假象，所以不能只看 t_r 选 T_s。

真正的边界出现在 0.04 s 与 0.05 s 之间：谱半径从 0.9864 跳到 1.1426，系统发散。图 44-6 把左右两件事画在一起：左图是四条不同采样周期的阶跃响应，右图是谱半径随 T_s 的变化曲线。曲线在 0.04 s 与 0.05 s 之间穿过 1，穿过点就是硬边界。

远小于边界时，指标也不是单调的。T_s 从 0.005 s 增到 0.01 s，超调从 5.94% 降到 4.43%，调节时间却从 1.710 s 升到 1.890 s，两个指标反向移动；再增到 0.02 s，超调又回升到 6.35%、调节时间升到 2.160 s。这种小幅抖动来自采样点与响应峰值的相对相位，换一个采样周期就会换一个读数。**因此选 T_s 不能看“哪一档超调最小”，只能看两件硬指标：谱半径离 1 有多远、附加相位占掉多少裕度。**前者决定会不会发散，后者决定还剩多少鲁棒性；时域指标的零点几个百分点，在这个尺度上不是判据。

80.17% 的超调可以从相位损失算出来。零阶保持器等效为 $T_s/2$ 的延迟，控制器计算出结果到执行器更新之间还有一拍等待，等效为 T_s 的延迟，两者相加是 $1.5T_s$。在 $\omega_c=10.947$ rad/s 处，这部分附加相位为 $1.5\omega_cT_s$：$T_s=0.01$ s 时 9.41°，$T_s=0.02$ s 时 18.82°，$T_s=0.04$ s 时 37.63°。把这三种情况与 §44.6 的裕度表对照会发现，37.63° 恰好把 78.63° 的相位裕度吃掉近一半，与实测超调从 9.08% 跳到 80.17% 的量级相符。**采样周期的选择，本质上是在预算相位裕度：每增加 0.01 s，就要从裕度里扣掉约 9.4°。**

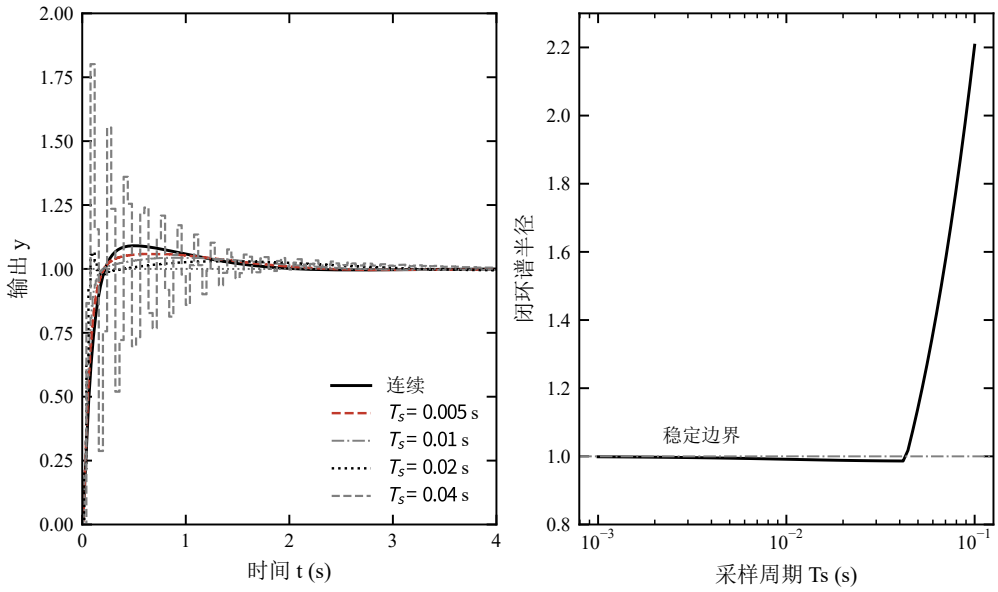

图 44-6　采样周期的影响

44.5.5 采样周期怎么定

工程上不能靠“试到发散为止”，要有一个可算的起点。本章建议按穿越频率定：

$$T_s \le \frac{1}{10 \sim 20\, f_c}, \qquad f_c = \frac{\omega_c}{2\pi} \tag{44-21}$$

本组参数的穿越频率 $\omega_c = 10.947$ rad/s，即 $f_c = 1.742$ Hz，按 20 倍取 $T_s \le 0.0287$ s，按 10 倍取 $T_s \le 0.0574$ s。仿真显示 0.04 s 已严重超调、0.05 s 发散，落在 10 倍与 20 倍之间偏危险的一侧。因此本章取 20 倍准则，建议 $T_s \le 0.02$ s，与表中 0.02 s 仍可用、0.04 s 失效的结果一致。

20 倍准则的来源是采样造成的相位滞后。零阶保持器等效为 $T_s/2$ 的延迟，在 ω_c 处贡献 $\omega_c T_s/2$ 弧度；取 $T_s = 1/(20 f_c)$ 时该滞后为 $\pi/20 \approx 9^\circ$，占 45° 裕度的五分之一，可以接受。若取 10 倍，滞后翻倍到 18°，裕度就只剩一半多一点，遇到未建模延迟容易越线。

还有两条附加约束。第一，T_s 应不大于微分滤波时间常数的 1/2 到 1 倍；本章 $T_f = 0.01$ s，$T_s = 0.02$ s 已是 2 倍，属于勉强可用，这也是 0.02 s 时超调从 4.43% 回升到 6.35% 的原因。第二，T_s 应不大于纯延迟的 1/5；若对象延迟 0.1 s，T_s 取 0.02 s 刚好，取 0.05 s 就把延迟量化成了三档，等效延迟增加。

44.5.6 实现细节与字长

递推式写对之后，还有四个实现细节会吃掉性能。

第一，积分项的数据类型。$K_i T_s \sum e$ 在长时间运行时累加值可能很大，若用 16 位定点会溢出。工程上积分器一律用 32 位浮点或 32 位定点并带饱和标志，不要用整型。

第二，微分项的差分噪声。式 (44-18) 的 $\big(e(k) - e(k-1)\big)/T_s$ 在 T_s 很小时会把量化噪声放大 $1/T_s$ 倍。若 ADC 为 12 位、量程 1，量化步长 2.4×10^{-4}，$T_s = 0.01$ s 时差分噪声可达 0.024，乘以 $K_d = 1$ 就是 0.024 的控制量抖动。这也是必须用式 (44-19) 滤波的原因。

把量级再算细一点：12 位 ADC 的步长是 $1/4096 = 2.44 \times 10^{-4}$，一步量化误差最多一个步长，除以 $T_s = 0.01$ s 得 0.0244；若 $K_d = 1$，控制量抖动 0.0244，已经接近本章 PID 稳态输出的 2%。若 ADC 只有 10

位，步长变成 9.77×10^{-4}，抖动乘 4，必须把 T_f 加大或改用增量式。这条估算可以在选型阶段用，不必等样机。

第三，输出更新的时序。控制器算出 $u(k)$ 后，要等到下一个执行周期才生效，这段等待构成额外延迟。若执行器更新周期是 T_s 的两倍，等效延迟增加 T_s，稳定裕度要按此复核。

第四，除零与饱和保护。T_f 不能为零，K_i 为零时不要做除以 K_i 的预置运算，限幅上下界要检查 $u_{\min}<u_{\max}$。这些看起来是编程细节，但现场“控制器一上电就满输出”的故障，多半出在这里。

44.5.7 离散化方法的选择

本章用“控制器与对象分别 ZOH 离散”的口径。实际工程还有三种常见做法：Tustin（双线性）变换、零极点匹配、以及直接按递推式实现。三者的差别主要在高频段。

Tustin 变换把 $s=(2/T_s)(z-1)/(z+1)$ 代入，频率轴有预畸变，在穿越频率附近精度最高，适合 T_s 较大的场合。零极点匹配把连续极点 p 映射为 e^{pT_s}、零点同理，保住了直流增益与主要动态，但对高频零点处理较随意。直接递推式实现最贴近代码，但它的频响在 $f_s/2$ 附近会翘起，等效于给微分项加了一个高频通路。

对 PID 而言，三者的差异在 $T_s\le 0.02$ s、$T_f\ge 0.01$ s 时可以忽略；当 T_s 接近 T_f 时，差异迅速放大。本章不做方法对比，只强调一条：**仿真用的离散化口径必须与代码一致**，否则仿真里的裕度在现场不成立。

44.6 稳定性与性能

§44.4 与 §44.5 讨论的是“给定参数下指标是多少”，本节反过来问：“这组参数离不稳定还有多远？”时域指标好看不等于鲁棒，鲁棒性要靠频域裕度来量。本节给三个判据、一张延迟下的裕度表、一组临界增益解析式，最后说明性能与鲁棒性为什么必然互相挤占。

44.6.1 三个判据

第一个判据是增益裕度 GM：开环增益还能再乘多少倍，闭环才到临界稳定。以分贝表示为

$$GM=20\lg\frac{1}{|L(\mathrm{j}\omega_{cg})|} \tag{44-22}$$

其中 ω_{cg} 是相位穿越频率，即 $\angle L(\mathrm{j}\omega_{cg})=-180^\circ$ 的频率。$GM>0$ 表示稳定，工程下限通常取 6 dB，相当于增益还能再加两倍。

第二个判据是相位裕度 PM：

$$PM=180^\circ+\angle L(\mathrm{j}\omega_c) \tag{44-23}$$

其中 ω_c 是幅值穿越频率，即 $|L(\mathrm{j}\omega_c)|=1$ 的频率。工程下限通常取 45°，有延迟或模型不确定时取 60°。

第三个判据是灵敏度峰值 M_s：

$$M_s=\max_{\omega}\left|\frac{1}{1+L(\mathrm{j}\omega)}\right| \tag{44-24}$$

它衡量闭环对对象摄动的敏感程度，也等于 Nyquist 曲线到 -1 点最短距离的倒数。$M_s=1$ 表示曲线离 -1 点很远，$M_s=2$ 表示距离只有 0.5，$M_s>2$ 通常认为鲁棒性不足。三个判据不是独立的：M_s 与 GM、PM 有近似关系

$$GM \ge 20\lg\frac{M_s}{M_s-1},\qquad PM \ge 2\arcsin\frac{1}{2M_s} \tag{44-25}$$

代入 $M_s=2$ 得 $GM\ge 6.02$ dB、$PM\ge 29^\circ$。这也解释了为什么工程上把 $M_s\le 2$ 与 $GM\ge 6$ dB 并列：它们大致是同一件事的两种说法。

三个判据的物理含义可以这样读。$GM=7.55$ dB 对应 2.38 倍，即对象增益再涨 2.38 倍，闭环才到临界；这对付的是增益漂移与老化。PM 可以换算成允许的额外延迟：$\Delta\tau\approx PM/(57.3\omega_c)$。以 3.23 组在 0.05 s 延迟下的 $PM=47.27^\circ$、$\omega_c=10.947$ rad/s 为例，允许再增加约 0.075 s 延迟，总延迟到 0.125 s 附近才会失稳，与 0.10 s 时 PM 只剩 15.91° 的趋势一致。M_s 对付的是综合摄动，包括增益、时间常数、延迟同时变化。

式 (44-25) 的下界可以用本章的实测值检验。3.23 组在 0.05 s 延迟下 $M_s=1.94$，代入得 $GM\ge 20\lg(1.94/0.94)=6.29$ dB、$PM\ge 2\arcsin[1/(2\times 1.94)]=29.9^\circ$；实测是 7.55 dB 与 47.27°，都在下界之上。0.10 s 延迟下 $M_s=6.06$，下界为 1.57 dB 与 9.5°，实测 1.91 dB 与 15.91°，仍满足。无延迟时 $M_s=1.08$，下界为 22.6 dB 与 55.2°，实测 $GM=\infty$、$PM=78.63^\circ$，也满足。三组数据一致说明：**M_s 是比 GM、PM 更保守的综合指标，只要 $M_s\le 2$，另外两个通常也在工程线内**；反过来，GM 达标而 M_s 超标的情况是存在的，这时应以 M_s 为准。

44.6.2 延迟下的裕度表

纯延迟不改变幅频特性，只增加相位滞后 $-\omega\tau$，因此它对 GM 的影响通过 ω_{cg} 体现，对 PM 的影响则是直接的。表 44-8 给出五组参数在三种延迟下的裕度，延迟用三阶 Padé 近似。

控制器	$\tau=0$ 的 GM / PM / M_s	$\tau=0.05$ s	$\tau=0.10$ s
P $K_p=1$	∞ / 34.93° / 1.92	12.18 dB / 26.73° / 2.52	6.29 dB / 18.53° / 3.64
PD $1/0/0.4$	∞ / 82.92° / 1.03	16.31 dB / 70.68° / 1.25	10.72 dB / 58.44° / 1.54
PID $1.92/1.80/0.81$	∞ / 82.62° / 1.06	10.25 dB / 59.43° / 1.58	4.73 dB / 36.23° / 2.71
PID $3.23/4.00/1.08$	∞ / 78.63° / 1.08	7.55 dB / 47.27° / 1.94	1.91 dB / 15.91° / 6.06
PID $4.40/4.00/1.20$	∞ / 75.71° / 1.09	6.39 dB / 40.08° / 2.22	0.54 dB / 4.46° / 20.78

表里有三条值得记住的规律。

第一，**无延迟时 GM 为无穷大，不代表鲁棒**。五组参数在 $\tau=0$ 时 GM 都是 ∞，因为对象是双积分加一阶，开环相位最多到 -180° 但不穿越；可一旦加 0.05 s 延迟，GM 立刻掉到 6–16 dB。这说明“$GM=\infty$”只是模型里没有延迟的假象，不能当作鲁棒性证据。

从相位曲线看更清楚：G_0 的相位从 -90° 出发，随频率趋向 -180°，但永远不到 -180°。加上 PID 的微分提前量后，相位在穿越频率附近被抬得更高，更不可能穿越。所以 $\tau=0$ 时相位裕度有定义、增益裕度无定义。一旦有延迟，相位多出 $-\omega\tau$，曲线在某个频率穿过 -180°，GM 才有有限值。

第二，**微分提高相位裕度，但不提高延迟容忍度**。PD 组在无延迟时 $PM=82.92^\circ$，比 P 组的 34.93° 高出一大截；加 0.05 s 延迟后仍有 70.68°，看似余量充足。但 GM 从 ∞ 掉到 16.31 dB，加 0.10 s 后掉到 10.72 dB。原因是微分在高频段抬高幅值，使 ω_{cg} 增大，延迟在该频率上的相位滞后也更大，抵消了微分带来的提前量。

第三，**增益越高，延迟容忍度下降得越快**。1.92 组在 0.10 s 延迟下 $M_s=2.71$，3.23 组是 6.06，4.40 组是 20.78。M_s 超过 2 以后，闭环对 20% 的参数摄动就可能失稳。按 $M_s\le 2$ 的工程线，3.23 组只能容忍约 0.05 s 延迟，4.40 组连 0.05 s 都勉强。

表 44-8 还说明不能只看单个判据。P 组在 0.05 s 延迟下 $GM = 12.18$ dB，比同工况下 PID 3.23 组的 7.55 dB 还高，按“$GM \ge 6$ dB”它似乎更稳；但它的 $M_s = 2.52$ 已经超线；作为对照，无延迟时它的超调 35.09%、PID 组只有 9.03%，加上延迟后 P 组的响应只会更晃。原因是 P 控制没有微分提前量，穿越频率低、相位裕度只有 26.73°，虽然增益裕度宽，闭环却一直在低频段振荡。**GM 高而 PM 低，是典型的“慢而晃”；PM 高而 GM 低，是典型的“快而脆”。** 两者都达标、且 $M_s \le 2$，才算真正有余量。

图 44-7 把 $3.23/4.00/1.08$ 这组在无延迟与 0.05 s 延迟下的伯德图画在一起，并标出幅值穿越点与相位穿越点。两条幅频曲线几乎重合，两条相频曲线在 10 rad/s 以上明显分开，这就是延迟的作用方式。

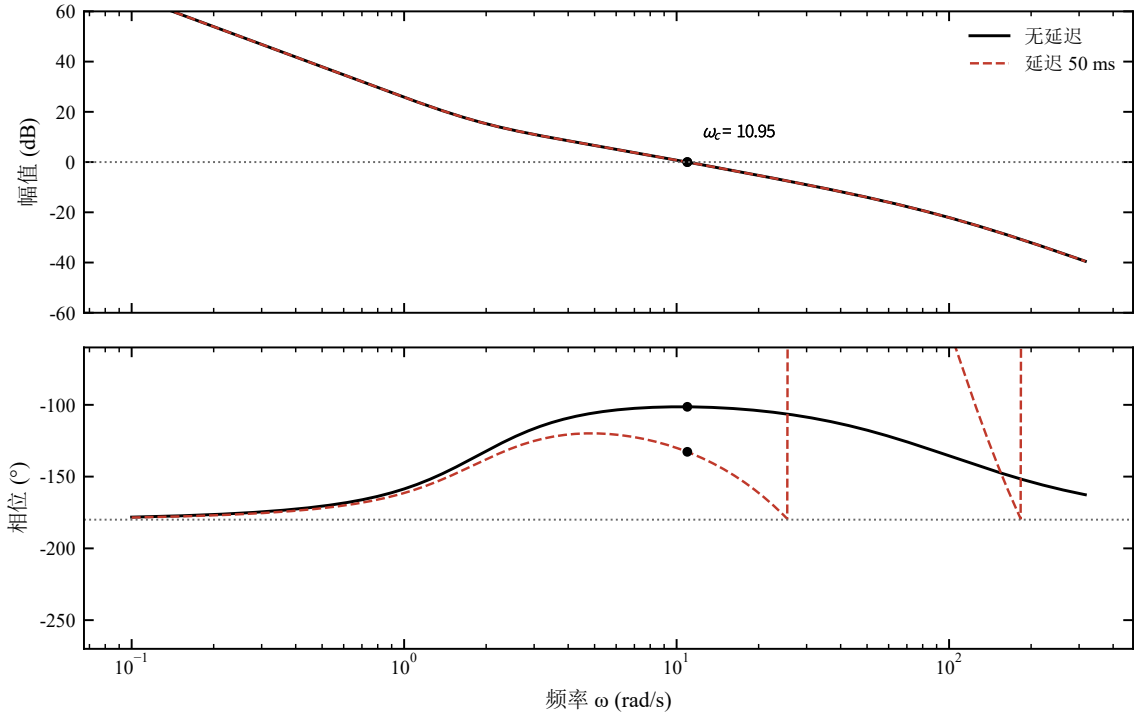

图 44-7　开环伯德图与裕度

44.6.3 临界增益的解析式

对一阶加延迟对象 $G(s) = K\mathrm{e}^{-\tau s}/(Ts+1)$，纯比例控制的临界条件可以解析求出。临界频率 ω_u 满足相位条件

$$\arctan(T\omega_u) + \tau\omega_u = \pi \tag{44-26}$$

解出 ω_u 后，临界增益与临界周期为

$$K_u = \frac{\sqrt{1+(T\omega_u)^2}}{K}, \qquad T_u = \frac{2\pi}{\omega_u} \tag{44-27}$$

本章整定用的过程对象 $K=1.5$、$T=2.5$ s、$\tau=0.8$ s，代入得 $\omega_u = 2.1894$ rad/s、$K_u = 3.7094$、$T_u = 2.8698$ s。这组数是 §44.8 中 Z-N 临界比例度法的输入。

式 (44-26) 的根唯一，因为左边两项都随 ω 单调增。代入 $T=2.5$、$\tau=0.8$：$\omega=1$ 时左边为 $1.190+0.800=1.990$，小于 π；$\omega=3$ 时为 $1.438+2.400=3.838$，大于 π。根落在 1 与 3 之间，用 Brent 法求得 2.1894。手算时可以用这两点做线性插值，误差约 5%，足够现场预估。

对本章的伺服对象 $G_0 = 10/[s(s+2)]$，相位条件变为 $\arctan(\omega/2) + \tau\omega = \pi/2$，临界增益为

$$K_u = \frac{\omega_u \sqrt{\omega_u^2 + 4}}{10} \tag{44-28}$$

三档延迟的计算结果为：$\tau = 0.05$ s 时 $\omega_u = 6.2211$ rad/s、$K_u = 4.0652$、$T_u = 1.0100$ s；$\tau = 0.10$ s 时 $\omega_u = 4.3284$、$K_u = 2.0638$、$T_u = 1.4516$ s；$\tau = 0.20$ s 时 $\omega_u = 2.9662$、$K_u = 1.0612$、$T_u = 2.1183$ s。延迟翻一倍，临界增益掉一半多；延迟再翻一倍，临界增益只剩四分之一。这个下降速度比“延迟增加一点”的直觉快得多。

第一档可以手算复核：$\omega_u = 6.2211$ 时 $\arctan(6.2211/2) = 72.18^\circ$，折算 1.260 rad，加上 $\tau\omega_u = 0.311$ rad，合计 1.571 rad，正好是 $\pi/2$，相位条件成立；再算 $K_u = 6.2211 \times \sqrt{6.2211^2 + 4}/10 = 6.2211 \times 6.535/10 = 4.065$，与表值一致。这两步只用到反正切与开方，现场用计算器就能复核，不必依赖软件。**临界增益的价值在于它给出“再加多少倍增益会振”的绝对上界**，而整定规则给出的 K_p 只是这个上界的一个折扣，折扣多少由衰减比或鲁棒目标决定。

现场用这组式子做两件事。一是核对：把实测的临界增益与解析值比，若差得远，说明模型里的 T 或 τ 测错了。二是预警：若工艺允许的最大延迟是 0.1 s，而当前 K_p 已经接近 2.06，就没有再加增益的空间。

44.6.4 灵敏度峰值怎么读

M_s 的几何意义是 Nyquist 曲线到 -1 点的最短距离的倒数。$M_s = 1.94$ 意味着最短距离约 0.52，曲线离临界点还有一半的余量；$M_s = 6.06$ 意味着最短距离只有 0.165，稍有摄动就会包围 -1 点。

工程上把 M_s 分成三档：$M_s \le 1.5$ 为保守，适合模型不确定或工况变化大的场合；$1.5 < M_s \le 2.0$ 为标准，适合大多数过程控制；$M_s > 2.0$ 为激进，只在模型准确、工况稳定的场合使用，且必须配合饱和保护与在线监测。

M_s 也可以从阶跃响应粗估：超调 10% 左右通常对应 $M_s \approx 1.1$–1.3，20% 对应 1.4–1.7，35% 对应 1.8–2.1。本章 P 组超调 35.09%、$M_s = 1.92$，落在区间内；PD 组超调 1.51%、$M_s = 1.03$，也落在区间内。这个对应关系不严格，但可以在没有频响数据时做初判。

把本章五组参数代进去：PD 组 $M_s = 1.03$ 属于很保守，代价是响应慢；1.92 组 $M_s = 1.06$；3.23 组 $M_s = 1.08$，三者都在保守区；加 0.05 s 延迟后分别变为 1.25、1.58、1.94，3.23 组刚好压线。这个结果与 §44.4 的“工作点贴着悬崖”判断一致。

这五组还暴露了 M_s 的一个特点：它对“好不好”不敏感，对“离不稳定多近”很敏感。前四组无延迟参数的 M_s 只从 1.03 排到 1.09，跨度 0.06，对应的超调却从 1.51% 一直排到 9.03%，差 6 倍。也就是说，$M_s = 1.05$ 与 $M_s = 1.09$ 在响应上看起来差别明显，鲁棒性却是同一档；反过来，第五组 P 的 M_s 从 1.08 涨到 1.92，只涨 1.78 倍，超调却从 9.03% 涨到 35.09%，涨了 3.9 倍。**读 M_s 要读绝对位置，不要读相对变化：1.5 以下都算安全，2 附近是边界，3 以上才是危险区。**用它做横向比较会得出错误结论，用它做“是否越线”的判断才可靠。

44.6.5 性能与鲁棒性的挤占

为什么不能同时追求“快”和“稳”？因为灵敏度函数 $S = 1/(1+L)$ 与补灵敏度函数 $T = L/(1+L)$ 满足

$$S(\mathrm{j}\omega) + T(\mathrm{j}\omega) = 1 \tag{44-29}$$

两者在每一频率上的模之和至少为 1。想把某个频段的 $|S|$ 压小（增强抗扰），必然把另一频段的 $|T|$ 抬高（增强噪声传递）；想把低频的 $|S|$ 压得更小（提高跟踪精度），高频的 $|T|$ 就会翘得更高（更容易受噪声与延迟影响）。这就是 Bode 积分约束的通俗版本，也是 PID 整定中“没有免费午餐”的数学根源。

PID 只有三个参数，能分配的自由度有限。工程上的做法是：把主要指标压在关键频段，其余频段接受妥协。例如送料轴的关键频段是 1–10 rad/s 的跟踪段，就把 $|S|$ 在该段压到 0.2 以下，高频段允许 $|T|$ 翘到 1.2；若反过来追求全频段都小，三个参数根本不够用。

44.6.6 现场怎么复核裕度

现场没有频响分析仪时，可以用三步近似复核。

第一步，测临界增益。逐步加大 K_p（保持 K_i、K_d 不变），直到出现等幅振荡，记下此时的 K_p 与振荡周期。这个 K_p 就是当前工况下的 K_u，周期就是 T_u。把 K_u 与当前 K_p 的比值取 20lg，就是当前工况的 GM 估计。

这一步与频域裕度是同一件事的两种算法，可以互相印证。表 44-8 中 P 组（$K_p = 1$）在 0.05 s 延迟下 $GM = 12.18$ dB，换算成增益倍数是 $10^{12.18/20} = 4.06$；§44.6.3 用相位条件解出的临界增益是 $K_u = 4.0652$。两条路径一个走频响、一个走解析，结果在三位有效数字上重合。现场若测到临界 $K_p = 8.2$、当前用到 2.0，则 $GM = 20\lg(8.2/2.0) = 12.3$ dB，与表格同一量级，说明回路确实还有约 4 倍余量；若测到临界值只比当前值大 1.5 倍，则 $GM = 3.5$ dB，已经低于 6 dB 的工程线，必须退回。

第二步，看阶跃响应的第二个峰。若超调后出现明显的第二个峰，说明阻尼不足，PM 大致低于 30°；若第二个峰高于第一个峰的 25%，PM 大致低于 20°，已接近不稳定。

第三步，看扰动响应。在稳态时给一个小的负载扰动，观察恢复时间与是否振荡。恢复时间比阶跃调节时间长三倍以上，或出现持续振荡，说明 M_s 偏大，应降低增益或加大滤波。

三步都做完，再决定是否调整参数。**不要仅凭一次阶跃响应就判断鲁棒性**，阶跃响应只激励了一个方向，裕度是全频段的事。

44.7 参数意义与作用

§44.2 给了三个增益的数学定义，本节回答现场最常问的问题：把某一个旋钮往大拧，究竟哪条曲线会动、动多少、什么时候会变坏。方法是单变量扫描：固定另外两个参数，只改一个，记录超调、上升时间、调节时间、稳态误差与控制量。数据全部来自连续闭环，对象仍为 G_0。

44.7.1 比例增益 K_p 的作用

固定 $K_i = 1$、$K_d = 0.4$，K_p 从 0.5 扫到 5.0，结果如表 44-9。

K_p	M_p	t_r (s)	t_s (s)	现象
0.5	24.38%	0.519	9.488	响应迟钝，长尾明显
1.0	16.33%	0.375	2.587	超调最小，调节时间中等
2.0	17.79%	0.259	1.500	综合较好
3.0	22.61%	0.208	0.970	快，超调开始上升
4.0	26.91%	0.178	1.173	更快，超调继续上升
5.0	30.58%	0.157	1.433	最快，超调与调节时间同时变差

这张表有三处反直觉。第一，$K_p = 0.5$ 时超调 24.38%，比 $K_p = 1.0$ 的 16.33% 还大。原因是 K_p 太小时，积分项相对过强，系统呈现“积分主导”的慢振荡，超调来自积分而不是比例。第二，超调在 $K_p = 1.0$ 附近有一个最低点，不是单调下降。这是因为 K_i、K_d 固定时，K_p 同时改变闭环阻尼与积分相对强度，两条效应方向相反，叠加后在 1.0 附近取极值。第三，t_s 在 $K_p = 3.0$ 时最短（0.970 s），再增大反而回升，因为超调变大后，输出要花更长时间才落回 ±2% 带。

图 44-8 左图把 M_p 与 t_s 随 K_p 的变化画在一起。两条曲线的极小值不在同一位置：M_p 的极小值在 1.0 附近，t_s 的极小值在 3.0 附近。这就是为什么“超调最小”与“调节最快”不能同时取到，工程上要按指标优先级选点。

把这组扫描换成标准型参数，规律更清楚。因为 $K_i = 1$、$K_d = 0.4$ 固定，$T_i = K_p/K_i = K_p$、$T_d = K_d/K_p = 0.4/K_p$：$K_p = 0.5$ 时 $T_i = 0.5$ s、$T_d = 0.8$ s；$K_p = 2.0$ 时 $T_i = 2.0$ s、$T_d = 0.2$ s；$K_p = 5.0$ 时 $T_i = 5$ s、$T_d = 0.08$ s。可见“只调 K_p”在标准型里同时改了三件事：回路增益 $5K_p$ 从 2.5 升到 25，积分时间从 0.5 s 拉长到 5 s，微分时间从 0.8 s 压到 0.08 s。前一项让响应变快，后两项让积分变弱、微分变锐。三条效应叠加，才出现表 44-9 里非单调的超调曲线。**现场若按标准型调参，把 K_p 拧大一倍等于把积分时间拉长一倍、微分时间压短一半，这跟“只加比例”的直觉完全不同。**

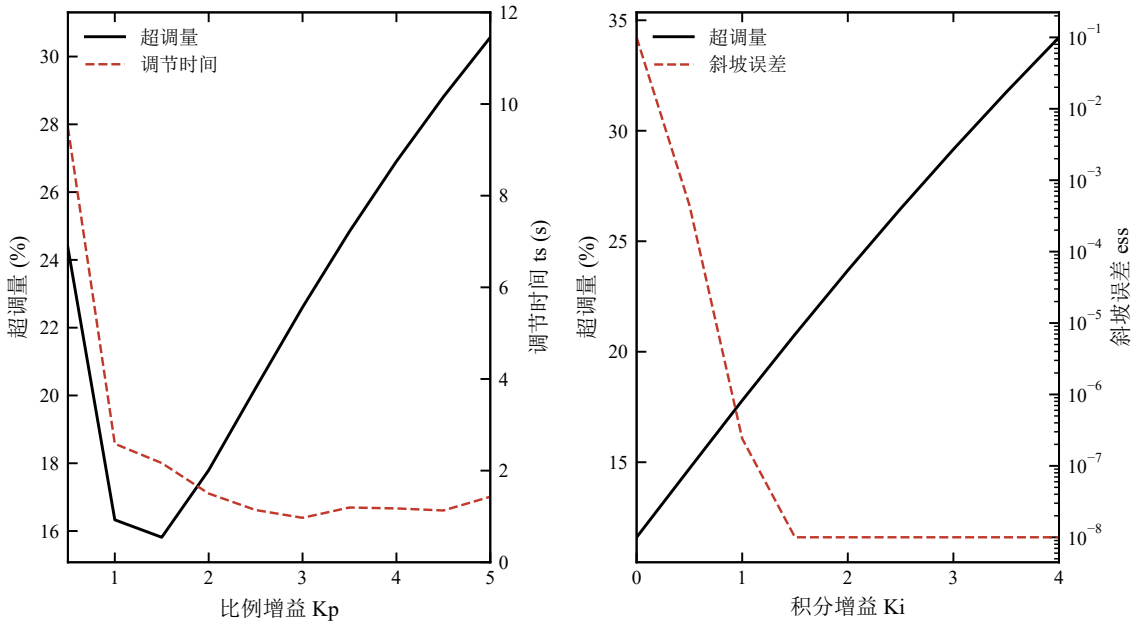

图 44-8　Kp、Ki 的单独影响

44.7.2 积分增益 K_i 的作用

固定 $K_p = 2$、$K_d = 0.4$，K_i 从 0 扫到 4.0，结果如表 44-10。斜坡误差按斜率 1 的单位斜坡、仿真 20 s 后取最后 1 s 的平均值。

K_i	M_p	t_r (s)	t_s (s)	斜坡 e_{ss}
0	11.60%	0.270	1.123	0.100000
0.2	12.80%	0.268	1.207	0.013506
0.5	14.72%	0.264	1.350	0.000450
1.0	17.79%	0.259	1.500	0
2.0	23.68%	0.250	1.400	0
4.0	34.23%	0.235	2.897	0

积分的作用非常干脆：K_i 从 0 加到 0.5，斜坡误差从 0.100000 掉到 0.000450，下降了两个多数量级；再加到 1.0，误差在数值上已经为零。代价是超调从 11.60% 一路涨到 34.23%，调节时间在 $K_i = 4.0$ 时反弹到 2.897 s。

这里有一个“够用就好”的判据。$K_i = 0.5$ 时误差 0.000450，已经小于大多数工艺的测量分辨率；继续加到 1.0，误差的收益为零，超调的代价却增加 3 个百分点。因此**积分的合理值应取“误差刚好进入可接受带”的那一点，而不是越大越好**。

换成积分时间看得更清楚。$K_p = 2$ 固定时 $T_i = K_p/K_i = 2/K_i$：$K_i = 0.2$ 对应 10 s，0.5 对应 4 s，1.0 对应 2 s，2.0 对应 1 s，4.0 对应 0.5 s。积分零点频率 $1/T_i$ 相应从 0.1 rad/s 升到 2 rad/s。若穿越频率在 10 rad/s 附近，$1/T_i = 0.1$ rad/s 时积分零点远在穿越频率之下，它只负责消差，几乎不动相位；$1/T_i = 2$ rad/s 时零点已进入穿越频率的低频侧，积分在每个周期里都要“追赶”，相位滞后开始显现。表 44-10 中 K_i 从 2.0 加到 4.0，超调从 23.68% 升到 34.23%、调节时间从 1.400 s 升到 2.897 s，正是零点越过这条线的表现。

由此得到一条经验判据：**$1/T_i < \omega_c/10$ 时，积分只消差不惹振；$1/T_i$ 接近 $\omega_c/3$ 时，积分开始明显吃相位裕度。** 本章 ω_c 约 10 rad/s，所以 $T_i > 1$ s（即 $K_i < 2$）是安全区，$T_i < 0.5$ s（即 $K_i > 4$）就进入危险区。这个判据不依赖具体对象，只要求知道穿越频率，因此比“积分增益取多少”更通用。

图 44-8 右图把 M_p 与 e_{ss} 画成双纵轴。e_{ss} 曲线在 $K_i = 1.0$ 附近贴到零，M_p 曲线则持续上升，两条线的分离点就是性价比最高的区间。

44.7.3 微分增益 K_d 的作用

固定 $K_p = 2$、$K_i = 1$，测量噪声标准差 0.005，微分作用在输出上（$c = 0$），K_d 从 0 扫到 1.2，结果如表 44-11。u_{std} 取最后 3 s 控制量的标准差，反映噪声放大程度。

K_d	M_p	t_s (s)	u_{std}	$\lvert u\rvert_{\max}$
0	70.99%	7.030	0.0136	2.035
0.1	52.13%	3.890	0.0188	2.041
0.2	37.32%	4.040	0.0274	2.048
0.4	17.48%	5.250	0.0450	2.061
0.8	16.11%	6.280	0.0809	2.086
1.2	18.78%	7.100	0.1178	2.113

微分的收益在 $K_d = 0$ 到 0.4 段最明显：超调从 70.99% 降到 17.48%，降了 53 个百分点；再往上加，超调的收益趋平（0.8 时 16.11%），而 u_{std} 从 0.0450 涨到 0.0809、再涨到 0.1178，噪声放大了 2.6 倍。同时 t_s 从 5.250 s 回升

到 7.100 s，因为微分把噪声搬进了执行器，执行器的小幅抖动延长了“稳定”的判定时间。

这条曲线的拐点在 $K_d = 0.4$ 附近。工程上应把 K_d 取在拐点左侧，宁可少一点阻尼，也不要让执行器长期抖动。**判断微分是否过量，不看超调，看控制量的标准差：**u_{std} 超过稳态控制量幅值的 3%–5%，就说明微分在放大噪声而不是在抑制超调。

噪声放大可以用一个简单式子估算：$u_{std} \approx (K_d/T_f)\sigma$。本章 $T_f = 0.05$、$\sigma = 0.005$，于是 $K_d = 0.4$ 时预测 0.0400、实测 0.0450；$K_d = 0.8$ 时预测 0.0800、实测 0.0809；$K_d = 1.2$ 时预测 0.1200、实测 0.1178。三档偏差都在 12% 以内。K_d 较小时预测偏低，因为此时控制量抖动的主要来源不是微分，而是积分与量化（$K_d = 0$ 时仍有 0.0136）。这个式子可以直接用于选型：给定允许的抖动与噪声水平，反解 $K_d \le u_{std} T_f/\sigma$。若要求抖动不超过稳态输出的 3%，即 $u_{std} = 0.03$，则 $K_d \le 0.03 \times 0.05/0.005 = 0.3$，与表 44-11 中 $K_d = 0.4$ 已到 0.0450 的实测吻合。**把这条不等式写进设计文件，比“微分不要太大”这种定性要求有用得多。**

44.7.4 三个参数不是独立的

三张表都是单变量扫描，读的时候容易误以为“每个参数各管一个指标”。实际不是。K_p 增大时，积分项的相对强度下降，等效于减小 K_i；K_i 增大时，闭环带宽提高，微分项的相位提前量在更高频率上才起作用，等效于改变 K_d 的效果；K_d 增大时，高频增益提高，对噪声与延迟更敏感，等效于降低了可用的 K_p。

这种耦合可以用一个简单的比值描述。定义积分时间 $T_i = K_p/K_i$ 与微分时间 $T_d = K_d/K_p$，则闭环形状主要由 T_d/T_i 与 K_pK 两个无量纲量决定。前者决定“微分相对积分有多强”，后者决定“开环增益有多高”。调参时先定 K_pK（决定带宽），再定 T_d/T_i（决定阻尼分配），比单独拧三个旋钮更稳。

用表 44-9 的数据具体算一遍。K_p 从 2.0 加到 4.0，若 $K_i = 1$、$K_d = 0.4$ 都不动，则 T_i 从 2 s 变成 4 s、T_d 从 0.2 s 变成 0.1 s，T_d/T_i 从 0.1 降到 0.025，同时回路增益 $5K_p$ 从 10 升到 20。两个无量纲量同时变，方向还相反：增益抬高会让响应更快、超调更大，T_d/T_i 下降会让阻尼变弱。最终实测超调从 17.79% 升到 26.91%、调节时间从 1.500 s 升到 1.173 s，正是这两条相反效应里“增益占上风”的结果。表里 $K_p = 5.0$ 时 T_d/T_i 只有 0.016，阻尼已经明显不足，超调升到 30.58%、调节时间反弹到 1.433 s。

这也解释了一个现场常见困惑：**按“调大 K_p 会更快也更振荡”的经验，往往在某个区间内不成立。**因为并联型里 K_p 同时改变 T_i 与 T_d，经验规律只在 K_i、K_d 同比缩放时才严格成立。若控制器是标准型（T_i、T_d 独立可调），这条经验才可以直接用；若控制器是并联型，改 K_p 前先用 $T_i = K_p/K_i$、$T_d = K_d/K_p$ 换算一遍，看清楚到底动了什么。

44.7.5 量纲与归一化

三个增益的量纲不同：K_p 的单位是“输出/输入”，K_i 是“输出/(输入·s)”，K_d 是“输出·s/输入”。直接比较数值大小没有意义，$K_p = 2$、$K_i = 1$、$K_d = 0.4$ 之间不存在“谁更大”。

跨对象移植参数时，应先归一化。常用的两个无量纲量是 K_pK（回路增益）与 T_i/T、T_d/T（相对对象时间常数）。若把同一套参数从增益 K、时间常数 T 的对象搬到 $2K$、$2T$ 的对象，要保持闭环形状，应取 K_p 减半、K_i 减为四分之一、K_d 不变；若只是时间常数翻倍、增益不变，则应取 K_p 不变、K_i 减半、K_d 加倍。两条结论都来自式 (44-4) 与 T_i、T_d 的定义：K_p 只随 $1/K$ 缩放，$K_i = K_p/T_i$ 随 $1/(KT)$ 缩放，$K_d = K_pT_d$ 随 T/K 缩放。

标度换算也常出错。若误差量从标幺值改成百分比（乘以 100），而输出仍用标幺值，则 $u = K_pe$ 变成 $u = (K_p/100)e'$，三个增益都要除以 100；若输出也同时改成百分比，则再乘 100，三个增益的数值反而不变。以本章 $K_p = 2$、$K_i = 1$、$K_d = 0.4$ 为例，只在误差侧换成百分比后应写成 0.02、0.01、0.004；若有人照抄 2、

1、0.4，回路增益就放大了 100 倍，一投自动必然振荡。**换算时先问一句“误差和输出各自用什么单位”，再决定动不动参数。**

44.7.6 三种常见的归因错误

第一种，把超调全归给 K_p。$K_p = 0.5$ 时超调 24.38%，比 $K_p = 1.0$ 还大，说明超调可能来自积分。判断方法是看超调出现的时间：比例造成的超调出现在第一个峰，积分造成的超调往往在第二个或第三个峰才明显。

第二种，把慢尾归给对象。$K_p = 0.5$ 时 $t_s = 9.488$ s，是 $K_p = 2.0$ 时的六倍多。若只看对象阶跃响应，会以为对象本身慢；实际是控制器增益太低，闭环带宽不足。判断方法是看控制量：若控制量在误差还很大时就已接近稳态值，说明是控制器“不肯出力”，不是对象“推不动”。

第三种，把抖动归给传感器。K_d 从 0.4 加到 1.2，u_{std} 涨了 2.6 倍，输出却只从 17.48% 降到 18.78%（反而略升）。这时应查微分增益与滤波时间常数，而不是换传感器。**抖动频率接近采样频率时，先怀疑微分；抖动频率很低时，先怀疑积分与死区。**

44.8 调参方法与经验

§44.7 讲的是“参数变了会怎样”，本节讲“参数该取多少”。前者是分析，后者是决策。工程上有三类决策依据：经验公式、模型公式、现场试凑。三者的精度依次下降，适用场合依次变窄。本节先给三类公式，再用同一对象把它们放在一起比，最后给现场试凑的纪律。

44.8.1 Z-N 开环法

Ziegler-Nichols 开环法（反应曲线法）只需要一次开环阶跃试验，从曲线上读出延迟 τ、时间常数 T、增益 K，然后查表：

$$K_p = \frac{1.2T}{K\tau}, \qquad T_i = 2\tau, \qquad T_d = 0.5\tau \tag{44-30}$$

它的设计目标是 1/4 衰减比，即相邻两个峰的幅值比为 4:1。按二阶近似，这等价于阻尼比约 0.215、首峰超调约 49%，比多数工艺允许的 5%–10% 宽松得多，所以公式给出的参数通常偏激进。

对本章过程对象 $K = 1.5$、$T = 2.5$ s、$\tau = 0.8$ s，代入得 $K_p = 2.500$、$T_i = 1.600$ s、$T_d = 0.400$ s。

这三个数可以直接从一条实测阶跃曲线得到，不必先知道真值。用 §44.3.2 的两点法读到 $t_{28} = 1.640$ s、$t_{63} = 3.300$ s，算得 $T = 2.490$ s、$\tau = 0.810$ s，代入式 (44-30) 得 $K_p = 1.2 \times 2.490 / (1.5 \times 0.810) = 2.459$、$T_i = 1.620$ s、$T_d = 0.405$ s。与用真值算出的 2.500/1.600/0.400 相比，K_p 只差 1.7%，两个时间常数差 1% 左右。**这说明 Z-N 开环法的精度主要取决于阶跃曲线读得准不准，而不取决于公式本身有多复杂。**

Z-N 公式里的系数 1.2、2、0.5 不是拟合出来的经验数字，而是按“1/4 衰减比”反推的：对一阶加延迟对象，要求相邻两峰幅值比 4:1，等价于阻尼比约 0.215、首峰超调约 49%。本章表 44-12 中 Z-N 开环组实测 $c = 1$ 时 77.31%、$c = 0$ 时 54.19%，比 49% 还高，因为闭环里还有采样、微分滤波与 80 拍延迟队列，这些环节额外贡献了相位滞后。工程上多数工艺允许的超调只有 5%–10%，所以 Z-N 参数必须打折使用，通常乘 0.6–0.7；这也解释了为什么“照表投运”往往超调过大。

44.8.2 Z-N 临界比例度法

临界比例度法（闭环法）先做临界振荡试验，逐步加大纯比例增益直到等幅振荡，记下临界增益 K_u 与临界周期 T_u，再查表：

$$K_p = 0.6K_u, \qquad T_i = 0.5T_u, \qquad T_d = 0.125T_u \tag{44-31}$$

本章对象的临界点为 $K_u = 3.7094$、$T_u = 2.8698$ s，代入得 $K_p = 2.226$、$T_i = 1.435$ s、$T_d = 0.359$ s。

这个方法的风险在试验本身：等幅振荡对某些对象（如带联锁的反应器、带机械限位的轴）是不允许的。若能做，它的优点是直接测到了“稳定边界”，比开环法更贴近真实工况；缺点是把对象推到了非线性边缘，测完要等系统完全平静才能投运。

44.8.3 Cohen-Coon 法

Cohen-Coon 在 Z-N 开环法的基础上，用 τ/T 修正三项参数，以适应延迟占比不同的对象：

$$K_p = \frac{1}{K}\frac{T}{\tau}\left(\frac{4}{3} + \frac{\tau}{4T}\right), \qquad T_i = \tau\frac{32 + 6\tau/T}{13 + 8\tau/T}, \qquad T_d = \tau\frac{4}{11 + 2\tau/T} \tag{44-32}$$

代入本章对象得 $K_p = 2.944$、$T_i = 1.744$ s、$T_d = 0.275$ s。它的增益比 Z-N 还高，因为 $\tau/T = 0.32$ 属于中等延迟，修正项把它往“更激进”推。延迟占比越大，Cohen-Coon 相对 Z-N 的增益越低；$\tau/T > 1$ 时两者都会给出不适合实际使用的参数。

44.8.4 IMC 整定

内模控制（IMC）的思路不是“凑衰减比”，而是“把闭环目标设成一阶惯性”。对一阶加延迟对象，取闭环时间常数 λ，本章采用的形式为

$$K_p = \frac{2T + \tau}{2K(\lambda + \tau)}, \qquad T_i = T + \frac{\tau}{2}, \qquad T_d = \frac{T\tau}{2T + \tau} \tag{44-33}$$

λ 是唯一的可调量：λ 越小，闭环越快、鲁棒性越差；λ 越大，闭环越慢、越稳。工程上常取 $\lambda = \tau$ 起步，再按裕度调整。本章取 $\lambda = \tau = 0.8$ s 得 $K_p = 1.208$、$T_i = 2.900$ s、$T_d = 0.345$ s；取 $\lambda = 3\tau = 2.4$ s 得 $K_p = 0.604$、$T_i = 2.900$ s、$T_d = 0.345$ s。

注意两组参数里只有 K_p 变了，T_i 与 T_d 完全不动。这不是巧合：式 (44-33) 的后两式不含 λ，只有第一式的分母含 $\lambda + \tau$。λ 从 0.8 s 增到 2.4 s，$\lambda + \tau$ 从 1.6 s 增到 3.2 s，正好翻倍，所以 K_p 从 1.208 减半到 0.604。这给出一个很实用的换算：**在 IMC 里调 λ 就是调增益，形状参数不动**。现场若想把响应放慢一倍又不想改变阻尼结构，把 $\lambda + \tau$ 翻倍即可，不必重新算三个参数。

IMC 的最大优点是“一个旋钮管速度与鲁棒性的交换”，不用同时改三个数。对延迟占比较大的对象，它给出的参数通常比 Z-N 温和得多，适合作为交付参数。

44.8.5 五组参数的横向对比

把上述五组参数装到同一个闭环上：对象 $K = 1.5$、$T = 2.5$ s、$\tau = 0.8$ s，采样 0.01 s，微分滤波 0.05 s，延迟用 80 拍队列模拟。每组跑两种接法：微分作用在误差（$c = 1$）与作用在输出（$c = 0$）。结果如表 44-12。

规则	K_p	T_i (s)	T_d (s)	$c=1$ 的 M_p / t_s / IAE / $\lvert u\rvert_{\max}$	$c=0$ 的 M_p / t_s / IAE / $\lvert u\rvert_{\max}$
Z-N 开环	2.500	1.600	0.400	77.31% / 9.550 / 2.006 / 19.167	54.19% / 7.890 / 2.030 / 3.766
Z-N 临界比例度	2.226	1.435	0.359	57.05% / 5.640 / 1.549 / 15.532	52.55% / 6.170 / 2.001 / 3.482
Cohen-Coon	2.944	1.744	0.275	90.58% / 11.980 / 2.663 / 16.436	79.25% / 12.110 / 2.661 / 4.312
IMC $\lambda=\tau$	1.208	2.900	0.345	0.01% / 5.090 / 1.601 / 8.153	2.08% / 6.540 / 1.810 / 1.546
IMC $\lambda=3\tau$	0.604	2.900	0.345	0.00% / 11.270 / 3.200 / 4.076	0.00% / 10.070 / 3.200 / 0.773

这张表的信息量很大，逐条读。

第一，三条经验公式的超调都在 50% 以上，远高于它们声称的 25%。原因是公式假设对象是纯一阶加延迟，而本章对象还有采样、滤波与延迟队列，这些环节额外贡献了相位滞后。**经验公式给的是起点，不是终点。**

第二，Cohen-Coon 在这组对象上最激进，超调 79.25%–90.58%，IAE 也最大（2.66），是五组里最差的一组。它的修正项适合延迟占比更大的对象，对本例的 0.32 反而过冲。这说明“公式越复杂越准”不成立，要看适用区间。

第三，IMC 两组的表现与经验公式完全不在一个量级：$\lambda=\tau$ 时超调 0.01%–2.08%，$\lambda=3\tau$ 时超调为 0，代价是调节时间从 5.090 s 拉长到 11.270 s。这就是“用速度换平稳”的直接体现。

第四，$c=1$ 与 $c=0$ 的差别主要体现在控制量峰值：Z-N 开环从 19.167 降到 3.766，Cohen-Coon 从 16.436 降到 4.312，降了四到五倍。超调也降了 10–23 个百分点。原因是 $c=1$ 时设定值阶跃直接进微分项，产生微分冲击；$c=0$ 时微分只响应输出，冲击消失。**这一列比参数本身更值得关注**，因为它决定了执行器会不会被“打一下”。

IAE 这一列则几乎不区分两种接法。Z-N 开环 2.006 对 2.030、Z-N 临界 1.549 对 2.001、Cohen-Coon 2.663 对 2.661、IMC $\lambda=\tau$ 1.601 对 1.810，四组里两组几乎不变、两组变化不到 30%，而超调差了 10–23 个百分点。原因是 IAE 是误差绝对值的全程积分，主要由拖长的尾部贡献；微分冲击只改变前 0.5 s 的形状，对总面积影响有限。**所以选微分接法要看峰值与超调，不能看 IAE；反之，比较整定规则的“慢”要看 IAE 或 t_s，不能看超调。**一张表里两个指标回答的是两个问题，混着读就会得出“两种接法差不多”的错误结论。

五组参数的裕度可以直接解释超调的差别。在同一对象、0.8 s 延迟、$T_f=0.05$ s 下，Z-N 开环的 GM / PM / M_s 为 2.45 dB / 44.83° / 4.10；Z-N 临界为 3.95 dB / 43.24° / 2.77；Cohen-Coon 为 2.09 dB / 28.42° / 4.85；IMC $\lambda=\tau$ 为 9.08 dB / 74.89° / 1.55；IMC $\lambda=3\tau$ 为 15.10 dB / 82.79° / 1.22。按 $M_s\le 2$ 的工程线，三条经验公式全部超标，IMC 两组都在线内。这组数与表 44-12 的超调排序一致：M_s 越大超调越大，Cohen-Coon 的 M_s 最大（4.85），超调也最大（90.58% 与 79.25%）。**经验公式的问题不是“算错了”，而是“目标定得太激进”——它们按 1/4 衰减比设计，而 1/4 衰减比本身就对应 $M_s>2$。**若把 Z-N 的 K_p 乘 0.6，M_s 大致能压到 2 附近，代价是调节时间变长。

图 44-9 把五组参数在 $c=0$ 下的阶跃响应画在一起，并附控制量曲线。可以看到三条经验公式的曲线在 0.5 s 内就冲过 1.5，而 IMC 的两条曲线平缓得多；控制量曲线上，经验公式的初始尖峰明显高于 IMC。

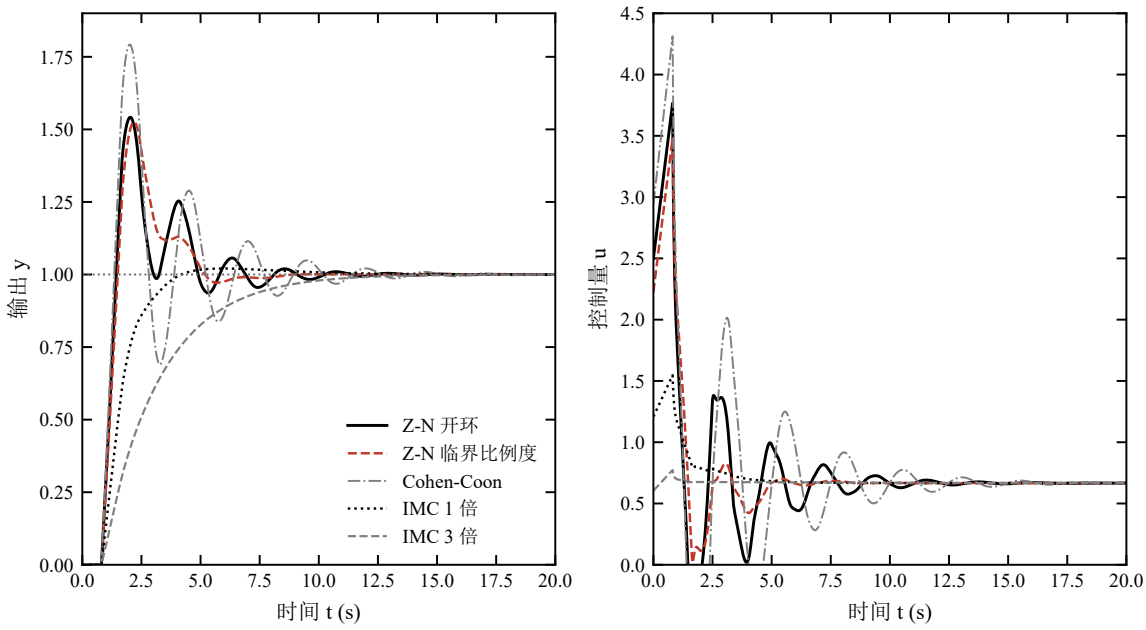

图 44-9　三种整定规则的对比

44.8.6 现场手工整定的纪律

没有模型、没有仿真时，现场按“先 P、再 I、后 D”的顺序试，但要有纪律，否则越试越乱。

第一条，每次只动一个参数，动完至少观察三个完整的响应周期。同时动两个参数，出了问题无法归因。

三个周期不是随口说的。以本章过程对象的临界周期 $T_u = 2.8698$ s 为例，三个周期约 8.6 s；若闭环振荡周期更长，观察时间还要按比例延长。观察窗口短于三个周期，慢模态还没走完一个来回，看到的“稳定”可能只是半个周期的假象。

第二条，阶跃幅度取工作点的 5%–10%，不要用满量程。幅度太大进入非线性区，测到的超调不能代表正常工作状态；幅度太小被噪声淹没，读数不可信。

这条也有量化的边界。以本章对象 $K = 1.5$ 为例，5% 工作点的阶跃只产生 0.075 的输出变化，若测量噪声标准差 0.005，信噪比约 15:1，超调与上升时间仍可辨认；幅度降到 1% 时输出只变 0.015，信噪比 3:1，曲线已经埋在噪声里。反过来，幅度超过 30% 时，多数执行器会进入限幅或死区边缘，测到的超调里混进了非线性，不能用来整定线性参数。

第三条，先找临界，再退回。把 K_i、K_d 置零，逐步加大 K_p 直到出现等幅振荡，记下 K_u、T_u，然后按 $0.5K_u$ 或 $0.6K_u$ 退回。这比“一点点试”快得多，也更安全，因为你知道边界在哪儿。

第四条，积分从“够用”起步。取 $T_i = 2\tau$ 到 4τ，观察残差是否在可接受时间内收敛；若收敛太慢再减小 T_i，若出现慢振荡则增大 T_i。不要一上来就把 T_i 设得很小。

第五条，微分最后加，且必须带滤波。先把 T_d 设为 0.25τ 到 0.5τ，观察控制量是否抖动；若抖动，先加大滤波时间常数，再考虑减小 T_d。没有滤波的微分在噪声环境下几乎不可用。

第六条，记录。每改一次参数，记下时间、参数、负载、响应曲线。现场调参的最大浪费不是试错，而是“试对了但没记住”，换个班次又重来。

44.8.7 规则怎么选

如果对象模型可信、延迟可测，优先用 IMC：它给出的是“可解释的折中”，λ 直接对应闭环速度，调起来有方向。

如果只能做开环阶跃试验、且延迟占比小于 0.3，可用 Z-N 开环法起步，但把增益乘 0.6–0.7 再投运，以抵消经验公式的激进。

如果能做闭环临界试验、且工艺允许短时等幅振荡，Z-N 临界比例度法比开环法更贴近真实边界，但仍需把增益乘 0.7 左右。

Cohen-Coon 只在延迟占比明显大于 0.3 时才有优势；本章的 0.32 已经接近它的适用边界，再小就不如 Z-N。

把延迟占比 τ/T 当横轴，可以给出一条粗略的分工线。$\tau/T < 0.1$ 时，对象近似一阶惯性，三条经验公式都偏保守，Z-N 开环直接可用；$0.1 < \tau/T < 0.3$ 时，Z-N 要乘 0.6–0.7 再投，IMC 取 $\lambda = \tau$ 更稳；$0.3 < \tau/T < 1.0$ 时，经验公式的 M_s 普遍超过 3，只有 IMC 取 $\lambda \geq 2\tau$ 还能给出可用裕度；$\tau/T > 1.0$ 时，迟延已大于时间常数，PID 无论怎么整定都难以兼顾速度与稳定，应转第 47 章的 Smith 预估或第 58 章的模型预测控制。本章的 0.32 正好落在第三段起点，这与表 44-12 里 Cohen-Coon 最差、IMC 最稳的结果一致。需要说明的是，本章只在这一个点上做了实测，分段的边界值来自工程经验，换对象后应重新用 §44.6 的裕度表核对。

无论用哪条规则，投运前都要按 §44.3 的第五步复核裕度，投运后都要按 §44.6 的第三步看扰动响应。公式只负责给起点，裕度与扰动响应才负责说“能不能用”。

44.9 优化与改进

前面八节讲的是一套“标准 PID”：三项作用、线性、单回路。现场还有四类问题它解决不了：执行器饱和后积分继续累积、微分把噪声放大、设定值阶跃时超调与跟踪速度无法兼顾、工况变化后一组参数不够用。本节给四种不改基本结构就能补上的改进：抗饱和、不完全微分、二自由度、增益调度，最后提一句自整定。

44.9.1 抗饱和：限幅前后的对比

先看问题的严重性。取 PID $3/5/0.3$、滤波 0.05 s、微分作用在输出（$c = 0$），输出限幅 ± 0.6，结果如表 44-13。

情形	M_p	t_r (s)	t_s (s)	饱和占比	$\lvert u_{raw} \rvert_{\max}$
不限幅	58.44%	0.208	2.520	7.0%	3.104
限幅，无抗饱和	84.73%	0.474	3.720	20.6%	3.476
限幅，回算 $T_t = 0.3$	0.08%	0.637	1.840	3.0%	3.000
限幅，回算 $T_t = 0.6$	0.58%	0.563	1.820	3.9%	3.000
限幅，回算 $T_t = 1.5$	15.58%	0.484	2.270	5.4%	3.000

不限幅时超调 58.44%，已经不小；加上限幅但不做抗饱和，超调涨到 84.73%，调节时间从 2.520 s 拉到 3.720 s，饱和占比从 7.0% 涨到 20.6%。这不是“限幅保护了系统”，而是“限幅破坏了系统”：输出被钳在 0.6，误差仍在，积分器继续累加，等输出该退时退不回来，于是冲得更高、退得更慢。

回算抗饱和把超调压到 1% 以下。$T_t = 0.3$ 时超调 0.08%、调节 1.840 s；$T_t = 0.6$ 时 0.58%、1.820 s；$T_t = 1.5$ 时 15.58%、2.270 s。三档的差别说明 T_t 不能取太大：T_t 越大，回拉越慢，抗饱和越接近“无抗饱和”。本章建议 T_t 取 T_i 的 0.5–1 倍；本例 $T_i = K_p/K_i = 0.6$ s，取 $T_t = 0.6$ 正好。

饱和期间积分器攒了多少，可以从表 44-13 的最后一列反推。无抗饱和时 $\lvert u_{raw} \rvert_{\max} = 3.476$，是限幅值 0.6 的 5.8 倍。峰值出现在误差已经很小、输出仍被钳住的时刻，此时比例项接近零、微分作用在输出上也不响应设定

值，所以 3.476 几乎全是积分项 $K_i x_i$；以 $K_i = 5$ 反算，$x_i \approx 0.70$，相当于 0.70 s 的全误差积分。退饱和后，控制器必须先把这个 0.70 的积分“消化”掉，误差才会反向，这就是“顶住再冲”的来源。加上回算后 $|u_{raw}|_{\max}$ 被压到 3.000，恰好等于 $t = 0$ 时刻的比例项 $K_p \times 1$，说明积分几乎没有攒下来。

T_t 也不是越小越好。$T_t = 0.3$ 时超调 0.08%，但上升时间 0.637 s，比 $T_t = 0.6$ 的 0.563 s 慢 13%；T_t 过小会让积分器在饱和边界来回反弹，低频工况下表现为输出小幅抖动。$T_t = 0.6$ 兼顾了退饱和速度与平稳性，这也是“取 $T_t = T_i$”这条经验的由来。

图 44-10 左图把三条曲线画在一起：不限幅、限幅无抗饱和、限幅回算 $T_t = 0.6$。第二条曲线在 1 s 附近出现明显的“顶住再冲”，第三条则平滑收敛。

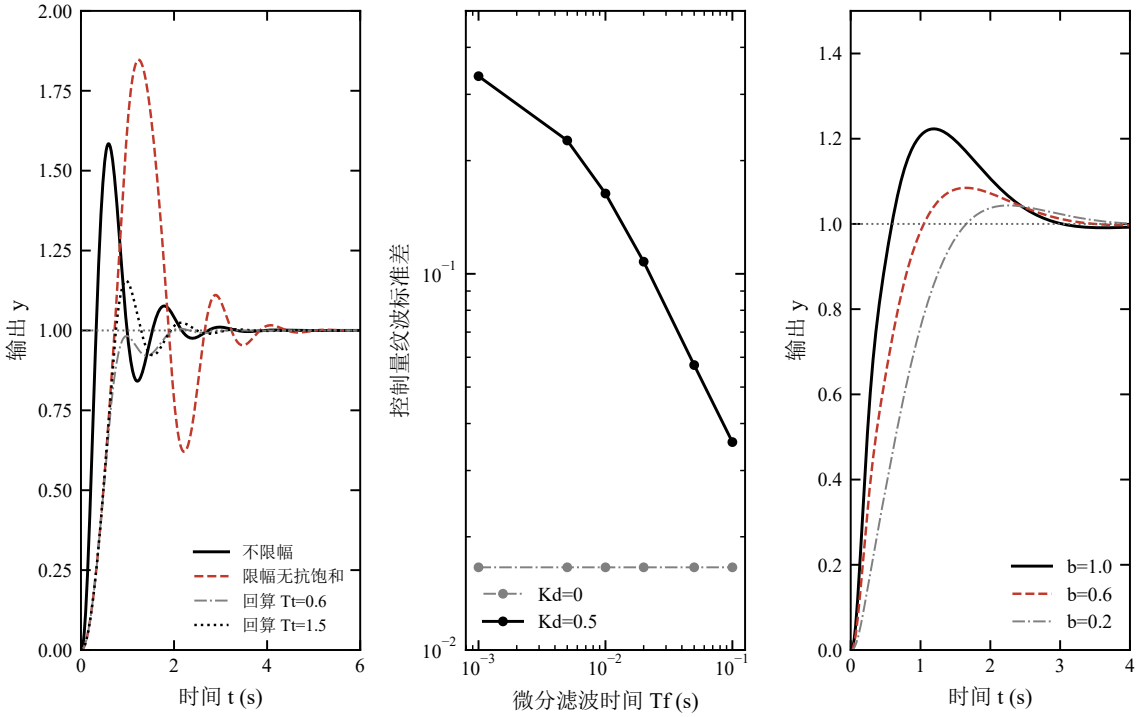

图 44-10　抗饱和、微分滤波与二自由度

44.9.2 不完全微分：滤波时间常数的选择

第二个问题是噪声。取 PID $2/1/K_d$、采样 0.01 s、测量噪声标准差 0.005、微分作用在输出，改变 K_d 与 T_f，观察控制量标准差 u_{std} 与峰峰值 u_{pp}，结果如表 44-14。

K_d	$T_f = 0.001$ s	$T_f = 0.005$ s	$T_f = 0.01$ s	$T_f = 0.02$ s	$T_f = 0.05$ s	$T_f = 0.1$ s
0	0.0166	0.0166	0.0166	0.0166	0.0166	0.0166
0.5，u_{std}	0.3353	0.2262	0.1635	0.1077	0.0572	0.0357
0.5，u_{pp}	1.8929	1.2218	0.8981	0.6156	0.3228	0.2027

$K_d = 0$ 时 $u_{std} = 0.0166$，与 T_f 无关，这是纯 PI 的基线，噪声只通过比例与积分通道进来。加上 $K_d = 0.5$ 后，$T_f = 0.001$ s 时 u_{std} 涨到 0.3353，是基线的 20 倍；T_f 增到 0.1 s 时降到 0.0357，只剩基线的 2.2 倍。峰峰值的变化更剧烈：从 1.8929 降到 0.2027，差 9.3 倍。

与此同时，输出标准差始终是 0.0055，与 T_f 无关。这说明滤波压的是“控制量的抖动”，不是“输出的噪声”——输出噪声由传感器决定，控制器只能决定要不要把它搬进执行器。**滤波的目标不是让曲线好看，而是让执**

行器少动。

T_f 的选取要同时看两头。太小，u_{std} 大，执行器磨损快、还可能激发机械谐振；太大，微分作用被磨平，超调回升。本章的折中是 $T_f = 0.05$ s：$u_{std} = 0.0572$，是基线的 3.4 倍，仍保留足够的微分效果；若执行器是液压阀，可放宽到 0.1 s；若是伺服电机，0.02 s 更合适。

放大倍数为什么不是 K_d/T_f 的 500 倍？$T_f = 0.001$ s 时 $K_d/T_f = 500$，$T_f = 0.1$ s 时只有 5，两者差 100 倍；但实测 u_{std} 只差 9.4 倍。原因是采样把噪声带宽限制在奈奎斯特频率 $f_s/2 = 50$ Hz：$T_f = 0.001$ s 对应转折频率 $1/(2\pi T_f) = 159$ Hz，已高于奈奎斯特频率，微分在 0–50 Hz 内根本达不到 500 倍；$T_f = 0.1$ s 对应 1.59 Hz，大部分噪声频段已被压住。**这意味着滤波的收益与采样率绑定：采样越快，同样的 T_f 能压掉的噪声带宽越多；反之，采样慢的系统即使把 T_f 调大，也只能压掉很窄的一段。**

44.9.3 二自由度：设定值加权

第三个问题是“跟踪快”与“超调小”的矛盾。标准 PID 只有一个误差通道，设定值阶跃同时激励比例、积分、微分，想快就得加大增益，加大增益就超调。二自由度结构把设定值单独加权：

$$u = K_p(br - y) + K_i \int (r - y)\,\mathrm{d}t + K_d \frac{\mathrm{d}(cr - y)}{\mathrm{d}t} \tag{44-34}$$

其中 b 是比例项加权、c 是微分项加权。$b = 1$、$c = 1$ 时退化为标准 PID；$b < 1$ 时比例项对设定值“打折”，相当于软化了设定值阶跃；$c = 0$ 时微分只响应输出，消除微分冲击。

固定 $3.23/4.00/1.08$、$c = 0$，改变 b，结果如表 44-15。

b	M_p	t_r (s)	t_s (s)	$\lvert u\rvert_{\max}$
1.0	22.32%	0.395	2.680	3.276
0.8	14.17%	0.530	2.730	2.637
0.6	8.48%	0.709	2.820	1.998
0.4	5.47%	0.922	2.940	1.359
0.2	4.34%	1.097	3.090	0.748

b 从 1.0 降到 0.2，超调从 22.32% 降到 4.34%，控制量峰值从 3.276 降到 0.748，代价是上升时间从 0.395 s 拉长到 1.097 s、调节时间从 2.680 s 微增到 3.090 s。**这条曲线给出了“跟踪 vs 超调”的完整交换表**：要 5% 超调，取 $b \approx 0.4$；要 8%，取 0.6；要 15%，取 0.8。

c 的作用更干脆：$c = 1$ 时 $\lvert u\rvert_{\max} = 21.230$、$u(0) = 21.230$；$c = 0$ 时 $\lvert u\rvert_{\max} = 3.276$、$u(0) = 3.230$。设定值阶跃瞬间的控制量差了 6.5 倍，全部来自微分冲击。因此工程上几乎总是取 $c = 0$，除非需要微分对设定值变化也作出快速反应（例如某些前馈补偿场合）。

二自由度不改变闭环的扰动抑制特性：b、c 只改变设定值到输出的通道，不改变扰动到输出的通道。这是它比“直接降增益”优越的地方——降增益会同时牺牲抗扰，改 b 不会。

44.9.4 增益调度

第四个问题是工况变化。同一台设备，轻载与重载的等效增益可能差一倍，一组参数无法同时适配。增益调度的做法是按可测工况变量（负载、速度、温度）切换或插值参数：

$$K_p(\theta)=K_{p0}\cdot\frac{K_0}{K(\theta)},\qquad K_i(\theta)=K_p(\theta)\cdot\frac{K_{i0}}{K_{p0}},\qquad K_d(\theta)=K_p(\theta)\cdot\frac{K_{d0}}{K_{p0}} \tag{44-35}$$

其中 θ 是调度变量，$K(\theta)$ 是该工况下的对象增益。式 (44-35) 保持回路增益 K_pK 不变，从而保持闭环形状不变。

本章数据可以佐证“回路增益决定速度”这半句：K_p 从 2 降到 1、K_i、K_d 不动时，回路增益减半，超调从 17.79% 只变到 16.33%，调节时间却从 1.500 s 拉长到 2.587 s。超调几乎不变、速度明显下降，说明在这类对象上回路增益主要影响带宽，阻尼由 T_d/T_i 决定。但要注意，这个例子里 $T_i=K_p/K_i$ 从 2 s 变成了 1 s、$T_d=K_d/K_p$ 从 0.2 s 变成了 0.4 s，形状其实变了；真正保持形状的做法是按式 (44-35) 三个增益同比缩放。

用 4 倍增益的对象验证一次。控制器仍取 $3.23/4.00/1.08$，对象从 $10/[s(s+2)]$ 换成 $40/[s(s+2)]$：不调度时超调 5.10%、调节时间 0.536 s、$PM=66.33^\circ$、$M_s=1.25$；把三个增益都除以 4 后，超调 9.08%、调节时间 1.518 s、$PM=78.63^\circ$、$M_s=1.08$，与名义对象上的指标逐项相同——因为回路传递函数 $C\cdot G$ 完全没有变，闭环极点自然也没变。反过来，在名义对象上误把增益除以 4，超调会升到 26.68%、调节时间拉长到 4.017 s、PM 掉到 59.73°。**调度的收益不是“让响应更好”，而是“让响应在所有工况下都可预测”；调错方向的代价，比不调度还大。**

增益调度的实现要点有三条。第一，调度变量必须可测且与对象增益单调相关，否则插值没有意义。第二，切换点要加滞环，避免在边界来回跳。第三，每个调度点的参数都要单独校核裕度，不能只算一个点。

44.9.5 自整定

自整定（auto-tuning）让控制器自己做一次试验、算出一组参数。最常见的是继电反馈法：把控制器换成继电环节，输出在 $\pm d$ 之间切换，对象进入极限环；测出极限环的幅值 a 与周期 T_u，按描述函数近似算临界增益：

$$K_u=\frac{4d}{\pi a} \tag{44-36}$$

再用 Z-N 临界比例度公式算参数。继电法的优点是不需要把系统推到很危险的等幅振荡边缘，极限环幅值由 d 控制；缺点是对噪声与非线性敏感，测出的 K_u 通常偏低。

本章的解析临界增益 $K_u=3.7094$ 可以作为自整定的核对基准：若继电法测出 3.0–3.5，说明模型与试验基本一致；若测出 5 以上，说明对象在高频段还有未建模动态，按测值整定会偏激进。

继电幅值 d 的选择可以用式 (44-36) 反推。已知 $K_u=3.7094$，$d=0.1$ 时极限环幅值 $a=4d/(\pi K_u)=0.4/11.653=0.0343$；若测量噪声标准差 0.005，信噪比约 7:1，勉强能测周期，但幅值读数会抖。把 d 提到 0.2，a 变成 0.0687，信噪比升到 14:1，测量可靠得多，代价是对象被推得更远、非线性更容易暴露。工程上取 d 使 a 约为正常调节量的 2%–5%，并保证信噪比不低于 10:1；这两个条件在本例中给出 d 约 0.15–0.25，约为满量程 1.5 的 10%–17%，与常用的 10% 量程一致。

44.9.6 与其他结构的配合

PID 不是孤立的。常见的三类配合是：

前馈。把可测扰动直接引入控制器输出，PID 只负责残余误差。前馈不改变闭环稳定性，但能大幅减小扰动引起的偏差，详见第 45 章。

串级。外环输出作为内环给定，内环快速抑制进入内环的扰动。串级的关键是内外环带宽比至少 3–5 倍，详见第 46 章。

Smith 预估。对纯延迟对象，用模型把延迟移到闭环外，控制器按无延迟对象设计。它对模型误差敏感，延迟估计偏 20% 就可能失效，详见第 47 章。

这三类结构都不改变 PID 的三项作用，只是改变“PID 放在哪儿、跟谁配合”。本章不展开，只提醒一句：**结构上的改进，收益通常大于参数上的微调**；但结构越复杂，对模型与调试的要求越高。

44.9.7 改进的边界

四种改进各有代价，不能无脑叠加。抗饱和需要额外的限幅测量与回算通道，T_t 整不好会引起抖动；不完全微分牺牲高频微分作用，T_f 太大等于没有微分；二自由度需要两套加权系数，b 太小会让跟踪变得迟钝；增益调度需要可靠的调度变量与多组参数，切换不当会引起跳变。

工程上的顺序应当是：先解决饱和（否则其他改进都被饱和吃掉），再解决噪声（否则微分不可用），再解决设定值超调（二自由度），最后才考虑工况变化（调度）。四步都做完，再评估是否值得上更复杂的结构。

四种改进的收益量级并不相同，用本章实测可以排个序。抗饱和把超调从 84.73% 压到 0.58%，是最大的一笔；二自由度把 b 从 1.0 降到 0.4，超调从 22.32% 降到 5.47%，代价是上升时间从 0.395 s 拉到 0.922 s；微分滤波把 u_{std} 从 0.3353 压到 0.0572（T_f 从 0.001 s 加到 0.05 s），代价是高频微分作用被磨掉；增益调度的收益不是指标更好，而是指标可预测——4 倍增益对象上，不调度时超调 5.10%、调节时间 0.536 s，调度后变成 9.08%、1.518 s，数值反而“变差”，但换到任何工况都能复现同一组数。**所以评估改进不能只看指标涨跌，要看它买的是“更小”还是“更稳”**：抗饱和与二自由度买“更小”，滤波买“更干净”，调度买“更一致”。四者不能互相替代，也不能用同一把尺子打分。

44.10 工程落地

到这一节，参数已经算完、结构已经选好，剩下的是“装到现场还能不能保持”。工程落地不是把仿真模型翻译成代码，而是把现场的非线性、延迟、噪声、切换逐项补进模型，再逐项验证。本节用一组叠加试验说明每种因素各自吃掉多少性能，然后给出实现清单与排查表。

44.10.1 非线性因素的叠加试验

取 PID $2/1/0.4$、滤波 0.05 s、采样 0.02 s，在理想模型上逐项加入死区、量化、噪声、延迟、饱和，结果如表 44-16。表中“全部叠加”一行的参数为：死区 0.02、量化 0.01、噪声 0.005、延迟 2 拍、饱和 ± 2。

情形	M_p	t_r (s)	t_s (s)	$\lvert u\rvert_{\max}$	y_{ss}
理想	17.35%	0.193	2.020	10.000	1.0000
死区 0.02	17.50%	0.195	1.460	9.980	1.0025
量化 0.01	17.36%	0.193	1.980	10.000	1.0000
噪声 0.005	18.08%	0.197	4.400	9.994	0.9987
延迟 2 拍	31.64%	0.159	1.960	10.000	1.0000
延迟 3 拍	43.18%	0.150	1.780	10.000	1.0000
饱和 ± 2	13.05%	0.358	4.240	2.000	1.0000
全部叠加	15.13%	0.303	5.420	1.980	0.9978

逐行读这张表，可以得到四个量级判断。

死区与量化的影响最小。死区 0.02 使稳态值偏到 1.0025，调节时间反而从 2.020 s 缩到 1.460 s（因为输出进入误差带后不再微调，判定更早），超调只增加 0.15 个百分点。量化 0.01 几乎无影响，超调 17.36%、调节 1.980 s。这说明**在 0.02 量级的死区与 0.01 量级的量化下，PID 的线性设计基本成立**。

噪声的影响集中在调节时间。噪声 0.005 使超调从 17.35% 只涨到 18.08%，但调节时间从 2.020 s 翻到 4.400 s。原因是判定“进入 ±2% 带”时，噪声让输出反复越出带边界，计时不断重置。这不是系统真的变慢，而是测量口径被噪声污染。工程上要么给反馈加滤波，要么把调节时间的判定改为“滑动平均后进入带”。

延迟的影响最大。2 拍延迟（0.04 s）使超调从 17.35% 涨到 31.64%，3 拍（0.06 s）涨到 43.18%。这与 §44.6 的裕度分析一致：延迟直接吃相位，相位裕度下降，阻尼下降。**每增加一拍延迟，超调大约涨 10 个百分点**，这条经验在 $T_s = 0.02$ s 的回路里相当稳定。

饱和的影响是“压峰值、拖时间”。限幅 ± 2 使超调降到 13.05%，但上升时间从 0.193 s 拉到 0.358 s、调节时间从 2.020 s 拉到 4.240 s。原因是前段输出被钳住，加速变慢；后段积分退饱和又要时间。超调降低是假象，实际是“没力气冲那么高”。

全部叠加时，超调 15.13%、调节 5.420 s、稳态 0.9978。这个结果比任何单项都更接近现场，也说明**单项试验的结论不能直接相加**：死区与量化被噪声掩盖，延迟与饱和互相抵消了一部分超调。

但“全部叠加”并不是每一项指标的最坏情况。超调的最坏值出现在 3 拍延迟单独作用时（43.18%），比全部叠加高出 28 个百分点；调节时间的最坏值才出现在全部叠加（5.420 s），比噪声单独的 4.400 s 还长 1.020 s；稳态的最坏值出现在死区单独作用（1.0025）。原因是饱和把前段的能量削掉了：延迟让输出冲得高，限幅却不让控制量跟着冲，两个效应方向相反。**验收时不能只跑一组“全开”的试验，而要按指标分别找最坏组合：超调看纯延迟，调节时间看全部叠加，稳态看死区。**只跑一组，必然有一项被其他因素掩盖而过关。

把各项的贡献换算成同一口径，排序更清楚。以理想行为基准，超调的变化是：死区 +0.15、量化 +0.01、噪声 +0.73、2 拍延迟 +14.29、3 拍延迟 +25.83、饱和 −4.30、全部叠加 −2.22 个百分点。调节时间的变化是：死区 −0.560 s、量化 −0.040 s、噪声 +2.380 s、2 拍延迟 −0.060 s、3 拍延迟 −0.240 s、饱和 +2.220 s、全部叠加 +3.400 s。两组数字说明，**延迟是超调的第一杀手，噪声是调节时间的第一杀手，饱和则同时压超调、拖时间**。现场的排查顺序应照这个权重来：先量延迟，再量噪声，最后查限幅。

还有一个容易被忽略的细节：死区 0.02 让稳态值停在 1.0025，偏差 0.0025，约为死区的八分之一。这不是“积分消不掉”，而是积分把误差推到死区边缘后，执行器不再响应该方向的微小指令，误差就停在那里。若工艺要求稳态误差小于 0.001，死区 0.02 的阀门根本做不到，换参数无用，只能换执行器或加抖动（dither）。

44.10.2 传感器与滤波

反馈滤波的位置有三处可选：传感器后、控制器前、微分项内。三者的效果不同。

传感器后滤波是最常见的做法，一阶低通 $1/(T_m s + 1)$，T_m 取采样周期的 2–5 倍。它同时压制了比例、积分、微分通道的噪声，但引入额外相位滞后，T_m 越大，稳定裕度越小。经验上 T_m 不应超过对象主导时间常数的 1/10。

控制器前滤波与传感器后滤波等价，只是实现位置不同。微分项内滤波就是 §44.2.4 的 T_f，它只压微分通道，不影响比例与积分，因此对裕度的影响最小。本章建议：**优先用微分项内滤波，不足时再加传感器后滤波**。

抗混叠滤波是另一件事。若传感器信号含有高于 $f_s/2$ 的分量，采样后会混叠到低频，控制器无法分辨。抗混叠滤波器必须是模拟的，放在 ADC 之前，截止频率取 $f_s/2$ 的 0.4–0.5 倍。这一步常被省略，后果是“低频看起来有奇怪的振荡”，怎么调 PID 都消不掉。

44.10.3 延迟的三条来源

现场延迟不止对象延迟，至少还有三条：计算延迟、通信延迟、执行延迟。

计算延迟是控制器从采样到算出输出所用的时间，通常小于一个采样周期，可近似为 $T_s/2$。通信延迟是总线传输时间，工业以太网通常 1–10 ms，现场总线可能到 50 ms。执行延迟是执行器从收到指令到实际动作的时间，阀门可能 0.1–1 s，伺服电机通常小于 10 ms。

三者相加才是“控制器看到的延迟”。若对象延迟 0.04 s、通信 0.02 s、执行 0.04 s，总延迟 0.10 s，比对象本身大一倍半。按 §44.6 的表，3.23 组在 0.10 s 延迟下 $M_s = 6.06$，已经不合格。这也是为什么“实验室调好的参数到现场就不行”——实验室里没有通信与执行延迟。

测量总延迟的办法是给一个阶跃，看输出响应滞后多久开始动。滞后时间里包含对象延迟、通信延迟、执行延迟与一个采样周期，减掉已知项就是未知项。这个试验要在最小负载与最大负载各做一次，取较大值。

44.10.4 手自动无扰切换

无扰切换的核心是“切换瞬间输出不跳”。手动转自动时，控制器输出应等于当前手动输出 u_0：

$$u_0 = K_p e + K_i x_i + K_d u_d \quad \Longrightarrow \quad x_i = \frac{u_0 - K_p e - K_d u_d}{K_i} \tag{44-37}$$

式 (44-37) 就是积分器预置公式。若 $K_i = 0$（纯 PD），则不需要预置积分器，但需要预置微分状态 $x_d = e$，否则切换瞬间微分项会跳。

自动转手动时，只需把输出保持为当前值，同时让积分器停止累积。若控制器有跟踪功能，让它持续跟踪手动输出，切换时自然无扰。

还有一个容易被忽略的点：切换瞬间的设定值。若手动时设定值被操作员改过，切回自动的瞬间误差可能很大，控制器会猛烈动作。正确做法是切换前把设定值拉到当前测量值，再缓慢升到目标，即“设定值跟踪 + 速率限制”。

预置的量级可以用本章参数算清楚。取 PID $2/1/0.4$、$T_f = 0.05$ s，切换瞬间 $e = 0.1$：比例项给出 0.2；若微分状态未预置（$x_d = 0$），微分项一次就给出 $0.4 \times 0.1/0.05 = 0.8$，是比例项的四倍，对 ± 1 的限幅已经占满 80%；若积分器未预置且手动输出为 0，按式 (44-37) 得 $x_i = -0.2$，切回自动后积分要从 -0.2 爬回 0，输出会先向下凹一块，再被拉起来。**所以无扰切换不是“切之前把输出对上”就完了，积分、微分、输出三个状态都要对上。**现场常见的“切自动时先抖一下”，十有八九是只对了输出，没对状态。

44.10.5 控制器实现清单

把本章涉及的工程细节整理成表 44-17 的实现清单，按优先级排列：

优先级	功能	关键参数	缺失后果
1	输出限幅	$u_{\min}$、$u_{\max}$	执行器损坏、积分饱和
2	抗饱和回算	T_t	超调翻倍、退饱和慢
3	微分滤波	T_f	噪声放大、执行器抖动
4	积分器预置	x_i	切换打执行器
5	设定值加权	b、c	超调大、微分冲击
6	输出速率限制	$\dot{u}_{\max}$	机械冲击、电流过载
7	采样看门狗	超时阈值	通信中断后保持旧值
8	参数上下限	K_p、K_i、K_d 范围	误操作导致失稳

前四项是“没有就不能投运”，后四项是“没有就容易出故障”。清单的价值在于交接：新接手的工程师按表核对一遍，比读一遍代码更可靠。

44.10.6 现场验收

验收不是“看着差不多”，而是按 §44.3 第二步写下的四要素逐条测。至少要做四组试验：小阶跃（5%）、中阶跃（20%）、大阶跃（50%）、负载扰动。每组记录输出、控制量、误差三条曲线，标注时间戳与工况。

判据按三条线：输出指标（超调、上升、调节、稳态）、执行器指标（峰值、饱和占比、动作频次）、鲁棒指标（扰动恢复时间、是否振荡）。三条线都过，才算验收通过。

验收后要留一份“参数—工况”对照表。同一台设备在不同季节、不同负载下的最优参数可能不同，有了对照表，下次切换工况可以直接查表，不用重新试。

44.10.7 故障排查表

现场出现异常时，按表 44-18 的顺序排查，从最可能、最容易查的开始。

现象	可能原因	检查方法
输出等幅振荡	增益过高、延迟过大	测临界增益，与 §44.6 解析值比
输出缓慢爬行后突然跳	积分饱和、死区	看积分器状态与限幅标志
稳态有固定偏差	积分太弱、执行器卡涩	加大 K_i 观察是否收敛
控制量高频抖动	微分过强、滤波不足	看 u_{std} 与 T_f
切换瞬间打执行器	积分器未预置	检查式 (44-37) 是否实现
小信号不动作、大信号过冲	死区、回差	做正反向小阶跃，测死区宽度
白天正常、夜间振荡	负载或温度变化	记录工况，考虑增益调度

这张表不能替代分析，但能缩短排查时间。多数现场故障落在前两行：振荡与饱和。先把这两个排除，再查其他。

44.11 优缺点与适用边界

任何方法的价值都由“它能做什么、它做不了什么、什么时候该换”三句话界定。PID 的前两句在前十节已经散落讲过，本节把它们收拢，并给出第三句的判据。

44.11.1 四个不可替代的优点

第一，不依赖模型。Z-N 开环法只需要一条阶跃曲线上的三个数，甚至可以在不知道对象阶次的情况下整定。这让 PID 成为唯一能在“完全黑箱”场合直接投运的控制器。

第二，参数可解释。K_p 管速度、K_i 管残差、K_d 管阻尼，三条定性规律在绝大多数对象上成立。现场工程师不需要理解频域，也能通过曲线形状判断该动哪个参数。

第三，鲁棒性有工程余量。本章五组参数在 0.05 s 延迟下，M_s 分别从 1.03、1.92、1.06、1.08、1.09 涨到 1.25、2.52、1.58、1.94、2.22，最差的一组仍在 3 以下，闭环没有失稳；对比之下，基于精确模型逆的控制器在同样延迟下往往直接失稳。PID 的“钝”在模型不准时反而是优点：它不追求把对象零极点全部对消，因此模型错了也不会把错的东西放大。

第四，实现成本极低。三个乘法、一个累加、一个差分，几十行代码，任何 PLC、单片机、DCS 都能跑。这个成本优势在大量简单回路上是决定性的：一个温度回路用 PID 只要几百元，用 MPC 要几万元。

44.11.2 五个结构性缺点

第一，三个参数要同时满足四类指标。超调、上升、调节、稳态误差，四个目标只有三个自由度，必然有一项要妥协。§44.7 的三张表已经显示，M_p 与 t_s 的极小值不在同一点，无法同时取到。把 K_p 扫描的数据摊开看更清楚：$K_p = 1.0$ 时超调最小（16.33%），$t_s = 2.587$ s；$K_p = 3.0$ 时 t_s 最小（0.970 s），超调却涨到 22.61%；再往上到 5.0，超调 30.58%、t_s 反弹到 1.433 s。**两项指标的极小值隔了 3 倍增益，中间没有“都好”的点，只有“都不算太差”的点。**

第二，对纯延迟敏感。延迟不改变幅频、只吃相位，PID 没有专门的延迟补偿机制。本章数据显示，0.10 s 延迟使 3.23 组的 PM 从 78.63° 掉到 15.91°、M_s 从 1.08 涨到 6.06。延迟占比 $\tau/T > 0.5$ 时，PID 的可用带宽被压得很低，响应慢到无法满足工艺。更隐蔽的是单一裕度会骗人：P 组在 0.05 s 延迟下 GM 还有 12.18 dB，看起来余量充足，PM 却只剩 26.73°、$M_s = 2.52$，闭环已经明显欠阻尼。**只看增益裕度会漏掉延迟的风险，必须同时看相位裕度与 M_s。**

第三，对非线性无能为力。死区、回差、饱和、摩擦，这些非线性不在 PID 的模型里。§44.10 的数据显示，饱和 ± 2 使调节时间从 2.020 s 拉到 4.240 s；死区使稳态偏到 1.0025。PID 只能“绕着”非线性工作，不能“补偿”非线性。叠加试验更能说明量级：同一控制器在线性模型上超调 17.35%，加 2 拍延迟后 31.64%，加 3 拍后 43.18%。**当模型与现场的差距主要来自延迟与非线性时，再精细地调 K_p、K_i、K_d 都补不回来。**

第四，多变量回路耦合难处理。两个以上的回路若相互影响，单独整定每个 PID 可能都不稳定，需要解耦或 MPC。PID 本身没有处理耦合的机制。本章的单回路结论在多回路里会失效：把一个回路的增益调大，等于给另一个回路加了一个频率相近的扰动源，两个回路的振荡会互相调制。

第五，约束处理能力弱。执行器限幅、速率限制、安全边界，PID 只能靠外部限幅与抗饱和“事后补救”，不能在优化层面“事前规避”。这也是 MPC 在约束多的场合占优的根本原因。抗饱和能把超调从 84.73% 压到 0.58%，但代价是上升时间从 0.474 s 拉到 0.563 s——它不是“消除了约束”，只是“把约束的伤害挪到了速度上”。

44.11.3 适用边界的量化

把“能不能用 PID”变成可算的判据，主要看三个比值。

第一个是延迟比 τ/T。$\tau/T<0.3$ 时，PID 可以做到 $PM>45^\circ$、$M_s<2$，性能接近最优；$0.3<\tau/T<1$ 时，PID 仍能稳定，但带宽被压到 $1/(2\tau)$ 以下，响应明显变慢，应改用 IMC 并把 λ 取大；$\tau/T>1$ 时，PID 的可用带宽低于 $1/(3\tau)$，通常不能满足工艺，应考虑 Smith 预估或 MPC。

第二个是带宽比 $\omega_c\tau$。它直接决定延迟吃掉的相位。工程上要求 $\omega_c\tau<1$ rad，即延迟引起的相位滞后小于 57°；本章 3.23 组在 0.05 s 延迟下 $\omega_c\tau=10.947\times0.05=0.547$ rad，折合 31.4°，正好等于 PM 从 78.63° 掉到 47.27° 的降幅 31.36°。把延迟加倍到 0.10 s，$\omega_c\tau=1.095$ rad、折合 62.7°，PM 再掉 62.72° 到 15.91°，同时 GM 从 7.55 dB 塌到 1.91 dB、M_s 从 1.94 涨到 6.06。**同一组参数，只因为 $\omega_c\tau$ 从 0.55 越过 1，系统就从“有裕度”变成“勉强站住”。**

这条判据比 τ/T 更贴近本质，原因在两组数据的对比。过程对象上 $\tau/T=0.8/2.5=0.32$，按第一判据仍在可接受段；伺服对象上 $\tau=0.05$ s、主导时间常数 0.5 s，$\tau/T=0.1$，按第一判据属于“很安全”，实测 M_s 却已经从 1.08 涨到 1.94。差别在于伺服回路的 $\omega_c=10.947$ rad/s 远高于 $1/T=2$ rad/s，延迟虽然只占时间常数的十分之一，却占了振荡周期的很大一段。**判断延迟危不危险，要拿它和闭环带宽比，不能拿它和对象时间常数比。**这一点在第 37 章只给了一句“相位损失 $57.3\omega\tau$ 度”，本章把它落实成了 $\omega_c\tau<1$ 这条可算的线。

第三个是摄动比 $\Delta K/K$。若对象增益在工况范围内变化超过 2 倍，一组参数无法覆盖，必须用增益调度或自适应。表 44-5 的实测说明这个边界不是随口定的：增益减半时超调从 9.08% 涨到 16.31%、调节时间从 1.518 s 拉长到 1.868 s、PM 掉 3.3°；增益加倍时超调降到 4.70%、调节时间缩到 1.120 s、PM 只掉 3.4°。两端都还稳定，但性能已经偏了一倍多，**“稳定”和“可用”在这里分了家。**

真正的 4 倍失配才需要调度。§44.9.4 把对象从 G_0 换成 $4G_0$：不调度时超调 5.10%、调节时间 0.536 s、$PM=66.33^\circ$、$M_s=1.25$，仍然稳定，但比名义工况快了近 3 倍，机械冲击与噪声放大都跟着上来；按式 (44-35) 把三个增益同比除以 4 之后，超调 9.08%、调节时间 1.518 s、$PM=78.63^\circ$、$M_s=1.08$，与名义对象逐项相同。**所以摄动比的工程阈值可以写成：1.5 倍以内免调度，1.5–2 倍加保守裕度，超过 2 倍上调度。**这个分段与 §44.8.7 的 τ/T 分段一样，是经验边界，换对象后应重新用表 44-5 的方法实测一次。

44.11.4 什么时候不该用 PID

有五种场合，PID 不是最优选择，硬上会事倍功半。

其一，延迟主导。$\tau/T>1$ 的对象，PID 要么慢得不能用，要么快得必振荡。应优先考虑 Smith 预估（第 47 章）或 MPC（第 58 章）。

这条判据在本章有直接的量化影子。0.10 s 延迟让 3.23 组的 PM 只剩 15.91°、M_s 涨到 6.06，此时再怎么调 K_p、K_i、K_d，能换来的只有“慢一点、稳一点”，换不回带宽；因为延迟吃掉的 62.7° 相位与增益无关，加增益只会让穿越频率右移、吃掉的相位更多。Smith 预估做的事，是把这段延迟移到闭环之外，让控制器面对一个没有延迟的对象；MPC 则是用模型往前看几步。两者的共同点都是“引入模型”，而 PID 恰恰是不愿引入模型的那一个。

其二，强耦合多变量。例如精馏塔的温度—压力—流量三回路，单独整定每个 PID 会互相激发。应优先考虑解耦控制或 MPC。

其三，硬约束频繁触发。例如执行器长时间贴着限幅运行，PID 的抗饱和只能“减少伤害”，不能“避免发生”。MPC 可以把约束放进优化问题，从源头避免。

抗饱和的极限在本章表 44-13 里看得很清楚。回算 $T_t=0.6$ 把超调从 84.73% 压到 0.58%，成绩很好；但上升时间仍从 0.208 s（不限幅）拉到 0.563 s，慢了 1.7 倍。这不是算法不够好，而是物理限制：执行器只有那么大推

力，前段被钳住，后面一定要补回来。**抗饱和能让系统“不闯祸”，但不能让系统“不守法”；要真正遵守约束，只能把约束放进优化问题，这就是 MPC 的位置。**

其四，强非线性。例如 pH 中和过程，增益随工作点变化几个数量级，PID 在某个点整定好，换个点就振荡。应优先考虑增益调度、非线性控制或 MPC。

其五，需要预测性动作。例如已知扰动会提前到来（如轧机的来料厚度变化），PID 只能等误差出现才动作。前馈或 MPC 可以利用扰动信息提前补偿。

44.11.5 与先进控制的分工

PID 与 MPC 不是替代关系，而是分层关系。典型的工业控制栈是：底层流量、压力、液位回路用 PID，采样 10–100 ms；上层温度、成分、优化目标用 MPC，采样 1–10 s，把计算结果作为 PID 的设定值下发。

这样分工的理由是：底层要求快速、可靠、可降级，PID 正好；上层要求处理约束、多变量、预测，MPC 正好。把 MPC 直接放到快回路，计算量与时延都吃不消；把 PID 放到慢回路，约束与耦合处理不了。

本章的所有结论，在分层结构里仍然成立：底层 PID 的饱和、噪声、延迟问题，不会因为上层有 MPC 就消失；相反，上层下发的设定值变化更频繁，底层 PID 的二自由度与抗饱和更重要。

分层还给出两条量化约束。第一条是带宽：内环带宽至少要是外环的 3–5 倍，才能把内环近似成 1。本章伺服回路的 $\omega_c = 10.947$ rad/s，若它作为外环，内环至少要 33–55 rad/s，折算成时间常数 0.018–0.030 s，比本章伺服回路自身的 0.5 s 小一个量级。**带宽分层不是画在框图上的，它直接决定了采样周期与执行器选型。**第二条是设定值形态：上层 1 s 下发一次、底层 10 ms 执行一次，底层看到的是阶梯状给定，二自由度的 b 与给定斜坡限制就是为这种阶梯准备的。$b = 1$ 时阶梯引起的超调 22.32%，$b = 0.4$ 时降到 5.47%，代价是上升时间从 0.395 s 拉到 0.922 s。分层越深，这个交换越要提前算清楚。

44.11.6 选型判断表

把上述判据整理成表 44-19，按对象特征给推荐方案。

对象特征	推荐方案	理由
$\tau/T < 0.3$，单回路	PID + 抗饱和	性能足够，成本最低
$0.3 < \tau/T < 1$	IMC 整定的 PID，λ 取大	用速度换鲁棒
$\tau/T > 1$	Smith 预估或 MPC	PID 带宽不足
增益变化 >2 倍	增益调度 PID	一组参数覆盖不了
强耦合多变量	解耦 + PID，或 MPC	单回路互相激发
约束频繁触发	MPC	约束进优化
强非线性	增益调度、非线性控制	PID 线性假设失效
扰动可提前测量	前馈 + PID	利用扰动信息
只需阶跃无差、对象自带积分	PD（微分先行）	少一个积分，更快、超调更小
需斜坡无差或常值扰动抑制	PID	积分提供低频增益

这张表不是绝对规则，而是起点。实际选型还要看预算、维护能力、团队经验。一个能维护好的 PID，胜过一个维护不了的 MPC。

44.11.7 与第 37 章 PD 设计的分界

第 37 章用 PD 解决同一台伺服轴的设计问题，本章用 PID 解决。两者对象完全相同（$G_0 = 10/[s(s+2)]$），差别只在积分项。把这条界线量出来，对选型比任何定性描述都有用。

先看“只加一点积分”的代价。固定 K_p、K_d、$T_f = 0.01$ s、微分作用在输出（$c = 0$），把 K_i 从 0 加到 0.1 或 0.3，实测三组：

$K_p = 1.0$、$K_d = 0.2$ 组，PD 时超调 10.43%、$t_s = 1.660$ s、控制量峰值 21.000、斜坡误差 0.2000；加 $K_i = 0.1$ 后超调 11.96%、$t_s = 1.798$ s、斜坡误差 0.02700。

$K_p = 1.0$、$K_d = 0.4$ 组，PD 时超调 1.51%、$t_s = 0.662$ s；加 $K_i = 0.1$ 后超调 2.38%、$t_s = 1.488$ s，调节时间涨了 125%。

$K_p = 3.0$、$K_d = 0.9$ 组，PD 时超调 4.87%、$t_s = 0.794$ s、斜坡误差 0.0667；加 $K_i = 0.3$ 后超调 5.14%、$t_s = 0.864$ s、斜坡误差 0.00901。

三组摆在一起，规律很清楚：**积分对超调的伤害不大（1.5、0.9、0.3 个百分点），对调节时间的伤害却极不均匀（8%、125%、9%）**。受害最重的是 K_d 最大、阻尼最好的那一组，因为它的闭环本来就贴着“刚好不振荡”的边，积分带来的相位滞后直接把这点余量吃光。这也解释了为什么现场“加一点积分就变慢”的感受，往往出现在已经调得很紧的回路上。

斜坡误差没有降到零，不是积分无效，而是观察窗口不够。$K_i = 0.1$、$K_p = 1$ 对应 $T_i = 10$ s，20 s 的仿真窗口只有两个积分时间常数，残差还在按 e^{-t/T_i} 衰减；$K_i = 0.3$、$K_p = 3$ 对应 $T_i = 10$ s 同样未收敛。若把窗口拉到 60 s，三组都会趋近于零。**这提醒一件事：比较积分效果时，窗口必须大于 3 倍 T_i，否则会把“还没收敛”误判成“有静差”。**

再看第 37 章那一端。它用 $K_p = 13.4$、$T_d = 0.1045$ s（$K_d = 1.40$）、微分先行、$T_f = 0.01$ s，实测超调 2.97%、$t_r = 0.180$ s、$t_s = 0.458$ s、控制量峰值 13.8。这个 t_s 比本章任何一组 PID 都快（本章最快的一组 $3.0/1.0/0.5$ 为 1.018 s）。原因不是 PD 更先进，而是两者的验收条件不同：第 37 章只卡超调与调节时间，两个指标恰好定死两个参数；本章还要卡斜坡无差，三个参数要应付四个目标，只能把带宽让出一部分。

代价藏在参数敏感性里。第 37 章自己测过：固定 $K_p = 13.4$，把 K_d 从 1.4 降到 0.8，超调从 3.0% 涨到 20.4%、t_s 从 0.458 s 涨到 0.702 s；升到 2.0 则超调为 0，t_s 反而涨到 0.505 s。**高带宽的 PD 把性能押在一个很窄的 K_d 窗口上，而 PID 的积分项虽然慢，却给了回路一个低频的“锚”，参数漂移时不会整条曲线一起走样。**

于是分界可以写成三问。第一，稳态要求是阶跃还是斜坡？只需阶跃无差，对象又自带积分，PD 就够；要斜坡无差，必须上积分。第二，允许的调节时间是宽还是紧？要求 $t_s < 0.5$ s 且执行器与噪声都干净，PD 更容易做到；要求 1–2 s 且现场有延迟、有噪声，PID 的余量更大。第三，参数会不会漂？K_d 附近 ±40% 就翻脸的回路，用 PID 把低频锚住更稳。三问里有一个答“要积分”，就选 PID；三个都答“不需要”，PD 是更简单也更快的选择。

44.11.8 本章要点收拢

回到 §44.1 的那句话：PID 的难点不在结构，而在三项各自换来了什么、又付出了什么。本章用十一节把这三笔交易算了一遍：

比例换来速度，付出超调与控制量峰值；积分换来无差，付出相位滞后与饱和风险；微分换来阻尼，付出噪声放大与延迟敏感。整定就是在这三笔交易里选一个符合工艺要求的平衡点。

工程落地的顺序是：先限幅与抗饱和，再滤波，再二自由度，最后调度。顺序错了，后面的改进会被前面的问题吃掉。

适用边界由三个比值画定：τ/T、$\omega_c\tau$、$\Delta K/K$。三个比值都在范围内，PID 是最优解；有一个超出，就该考虑换结构。

44.12 Python 仿真代码

本章所有数字都可以复现。代码分两个文件：`code/ch044_sim.py` 负责算数与打印，`code/ch044_figs.py` 负责出图。前者不画图，后者不定义新的控制律，只调用前者的函数与 `simlib` 的接口。这样分工的好处是，读者改一个参数后只需要重跑 sim，就能看到指标变化，不必等图重绘。

44.12.1 运行方式

在 `book` 目录下执行：

```
"D:\Anaconda3\envs\py311\python.exe" code\ch044_sim.py
"D:\Anaconda3\envs\py311\python.exe" code\ch044_figs.py
```

第一条命令打印十一章的全部指标，约 200 行；第二条命令把 10 张图写入 `figs/ch044/`，同时输出 SVG 与 PDF。两条命令都不需要额外参数，对象、参数、噪声种子都写在文件顶部，改完直接重跑。

44.12.2 代码结构

`ch044_sim.py` 分三层。第一层是对象与控制器构造函数：`plant_servo()` 返回 G_0，`plant_fopdt()` 返回整定用的过程对象，`pid()` 调用 `simlib.pid_continuous` 生成带滤波的连续 PID。第二层是工具函数：`cont_step()` 算连续阶跃，`ramp_error()` 算斜坡误差，`margins_pade()` 算裕度，`sampled_radius()` 算采样谱半径。第三层是主流程，按 §44.1 到 §44.10 的顺序调用，每段打印一个标题。

线性闭环一律复用 `simlib` 的 `closed_loop`、`step_data`、`step_metrics`、`simulate_discrete`，不重写仿真环。只有两类情况用本文件末尾的专用循环：抗饱和需要把限幅偏差反馈到积分器，二自由度需要把设定值分别加权到比例与微分通道，这两件事 `simlib` 的线性接口表达不了。

几处实现细节值得单独说明。`show()` 是所有时域指标的统一出口，它固定调用 `sl.step_metrics`，因此表 44-1 到表 44-18 的口径完全一致，不会出现“这一段用峰值、那一段用末值”的混用。`pd_ch037()` 刻意用 `ct.tf([Kp*Td, Kp], [1.0])` 构造无滤波 PD，是为了复现第 37 章的原始设计；这个传递函数不是真有理的，U/R 在无穷远处发散，所以 `cont_step()` 用 `try/except ValueError` 把控制量置空，只打印时域指标。这不是容错写法的炫技，而是提醒读者：**无滤波微分在连续域里本来就没有有界的控制量，讨论它的 $|u|_{\max}$ 没有意义。** `sampled_radius()` 对控制器与对象分别做 ZOH 离散再闭环，与 `simlib` 的离散口径一致；这个顺序不能反，控制器与对象之间本来就有采样保持，先闭环再离散会把保持环节的位置挪错。

44.12.3 核心代码

下面是专用循环的核心片段，完整版见 `code/ch044_sim.py` 第 117–175 行。它实现了式 (44-19) 的微分滤波、式 (44-15) 的限幅、式 (44-16) 的回算抗饱和，以及设定值加权 b、c。

```
def simulate_pid_advanced(G, kp, ki, kd, Ts, N, ref=1.0, tf=0.05,
                          sat=None, Tt=0.0, b=1.0, c=1.0,
                          noise_std=0.0, delay_steps=0, seed=0):
    """逐步 PID：支持设定值加权、微分滤波、限幅与回算抗饱和。"""
    rng = np.random.default_rng(seed)
    ss = ct.c2d(ct.ss(G), Ts, method="zoh")
    Ad, Bd = np.asarray(ss.A, float), np.asarray(ss.B, float)
    Cd, Dd = np.asarray(ss.C, float), np.asarray(ss.D, float)
    xp = np.zeros((Ad.shape[0], 1))
    xi = xd = up = 0.0
    buf = [0.0] * delay_steps

    for k in range(N):
        yk = float((Cd @ xp + Dd @ np.array([[up]]))[0, 0])
        yk = yk + (rng.normal(0.0, noise_std) if noise_std else 0.0)

        ek = ref - yk
        ep = b * ref - yk            # 比例通道的加权误差
        ed = c * ref - yk            # 微分通道的加权误差

        xd = (tf * xd + Ts * ed) / (tf + Ts)   # 一阶滤波状态
        ud = kd * (ed - xd) / tf               # 不完全微分
        uk_raw = kp * ep + ki * xi + ud
        uk = float(np.clip(uk_raw, sat[0], sat[1])) if sat else uk_raw

        corr = (uk - uk_raw) / Tt if Tt > 0 else 0.0
        xi = xi + Ts * (ek + corr)             # 回算抗饱和

        if delay_steps > 0:
            buf.append(uk)
            u_plant = buf.pop(0)
        else:
            u_plant = uk

        xp = Ad @ xp + Bd @ np.array([[up]])
        up = u_plant
```

这段代码有两个容易写错的点。第一，积分器用的是未加权的误差 e_k，不是 $br-y$ 或 $cr-y$；若用加权误差，b、c 会改变稳态，二自由度就退化成“改增益”。第二，延迟队列是先入先出，且对象状态更新用的是上一拍的 u_{plant}，不是本拍的 u_k；顺序写反会少一拍延迟，仿真结果偏乐观。

44.12.4 输出片段

运行 `ch044_sim.py` 后，第一段与第五段的输出如下（节选）：

```
一、P/I/D 单独作用（G0=10/[s(s+2)]，连续闭环，单位阶跃）
P  Kp=1.0      Mp=  35.09%  tr= 0.425s  tp= 1.046s  ts= 3.537s  yss= 1.0000  |u|max=   1.000
PD Kp=1.0 Kd=0.40（带滤波）  Mp=   1.51%  tr= 0.433s  tp= 1.082s  ts= 0.662s  yss= 1.0000  |u|max=  41.000

五、稳定性与裕度（无延迟 / 0.05 s / 0.10 s，Padé 3 阶）
  PID 3.23/4.00/1.08      tau=0.00s  GM=   infdB  PM=  78.63deg  wc=10.947  wcg=   nan  Ms= 1.08
  PID 3.23/4.00/1.08      tau=0.05s  GM=  7.55dB  PM=  47.27deg  wc=10.947  wcg=25.656  Ms= 1.94
  PID 3.23/4.00/1.08      tau=0.10s  GM=  1.91dB  PM=  15.91deg  wc=13.645  wcg= 13.645  Ms= 6.06
```

PD 那一行的 $|u|_{\max}=41.000$ 来自 $K_p+K_d/T_f=1+0.4/0.01$，与 §44.4 的式 (44-17) 一致。读者可以据此核对自己的实现：若你的仿真里没有这个尖峰，说明微分项没有按式 (44-19) 实现，或者滤波时间常数被误设得很大。

第七段与第八段的输出更适合核对整定与抗饱和。三行来自第七段（过程对象，延迟 80 拍），两行来自第八段（限幅 ± 0.6）：

```
七、整定规则对比（FOPDT：K=1.5, T=2.5s, tau=0.8s, Ts=0.01s）
  临界点：Ku=3.7094  Tu=2.8698s  wu=2.1894 rad/s
  Z-N 开环   Kp= 2.500 Ti= 1.600 Td= 0.400  微分作用在误差  Mp= 77.31%  ts= 9.550s  IAE= 2.006  |u|max=19.167
  Z-N 开环   Kp= 2.500 Ti= 1.600 Td= 0.400  微分作用在输出  Mp= 54.19%  ts= 7.890s  IAE= 2.030  |u|max= 3.766
  IMC lambda=tau   Kp= 1.208 Ti= 2.900 Td= 0.345  微分作用在误差  Mp=  0.01%  ts= 5.090s  IAE= 1.601  |u|max= 8.153
八、抗饱和：限幅 ±0.6，PID 3/5/0.3（Tf=0.05，c=0）
  限幅 无抗饱和              Mp=  84.73%  tr= 0.474s  ts= 3.720s  饱和占比= 20.6%  |u_raw|max= 3.476
  限幅 回算 Tt=0.6         Mp=   0.58%  tr= 0.563s  ts= 1.820s  饱和占比=  3.9%  |u_raw|max= 3.000
```

同一组 Z-N 参数，微分作用在误差与作用在输出，超调差 23 个百分点（77.31% 对 54.19%），控制量峰值差 5 倍（19.167 对 3.766）。参数一个没改，结果完全不同——这解释了为什么现场“抄参数”经常抄不对：抄到的是数，没抄到微分加在哪。抗饱和两行的 $|u_{raw}|_{\max}$ 从 3.476 掉到 3.000，是积分不再攒量的直接证据，比看超调更早、更灵敏。

第十段的输出只有三行，却可以做一次单元测试：

```
十、二自由度：设定值加权 b（C 取 3.23/4.00/1.08，c=0）
  b=1.0: Mp= 22.32%  tr= 0.395s  ts= 2.680s  |u|max=3.276
  c=1.0: |u|max=21.230  u[0]=21.230
  c=0.0: |u|max=3.276  u[0]=3.230
```

c 从 1 改到 0，$u(0)$ 从 21.230 掉到 3.230，后者正好等于 $K_p=3.23$。若你的实现里 $c=0$ 时 $u(0)$ 仍明显大于 K_p，说明微分还挂在误差上，或者加权系数只乘了误差没乘设定值。**这比看超调更快：超调要跑完整个响应才能读，$u(0)$ 第一拍就能判。**

44.12.5 参数与口径

为了复现，表 44-20 把各段的关键设置列在一起。凡未列出的，均取文件顶部的默认值。

段落	对象	控制器	T_s	T_f	其他
一 P/I/D	G_0	连续	—	0.01	阶跃 1，仿真 10 s
二 频域	—	各环节	—	0.01	$\omega = 1$ rad/s
三 极点配置	G_0	连续	—	0.01	四组 ζ, ω_n, α
四 离散	G_0	$3.23/4.00/1.08$	0.005–0.10	0.01	ZOH，仿真 8 s
五 裕度	G_0	五组	—	0.01	Padé 3 阶，$\tau = 0/0.05/0.10$
六 扫描	G_0	连续	—	0.01	单变量，其余固定
七 整定	FOPDT	五规则	0.01	0.05	延迟 80 拍，$c = 1/0$
八 抗饱和	G_0	$3/5/0.3$	0.01	0.05	限幅 ± 0.6，$c = 0$
九 滤波	G_0	$2/1/K_d$	0.01	0.001–0.1	噪声 0.005，$c = 0$
十 二自由度	G_0	$3.23/4.00/1.08$	0.01	0.05	b 扫描，$c = 0$
十一 工程	G_0	$2/1/0.4$	0.02	0.05	死区/量化/噪声/延迟/饱和

口径统一为：上升时间 10%→90%，调节时间 ±2%，超调以稳态值为基准，稳态值取最后 1% 时间段的平均。凡与第 37 章对比的数字，都用同一口径，因此可以直接比较。

44.12.6 改成自己的对象

把本章代码用到自己的设备上，只需要改三处。

第一处，`plant_servo()` 的分子分母。把 10 换成实际增益，把 $[1, 2, 0]$ 换成实际分母系数；若对象带延迟，用 `ct.pade(tau, 3)` 串联，或直接改 `delay_steps`。

第二处，`Ts` 与 `Tf`。按 §44.5.5 的 20 倍准则取 T_s，按 §44.9.2 的噪声试验取 T_f。不要直接沿用本章的 0.01 与 0.05，因为对象带宽不同。

第三处，限幅与死区。把 `sat` 设为执行器的实际上下限，把 `deadzone` 设为实测死区。若执行器有回差，还要在对象侧加回差模型，本章未包含这一项。

改完后先跑第一段，确认 P 控制的超调与解析式 $\zeta = 1/\sqrt{10 K_p}$ 对得上；再跑第五段，确认裕度在工程线以上；最后跑第十一段，确认叠加非线性后仍能满足指标。三步都过，再把参数搬到现场，按 §44.3 的第六步投运。

44.12.7 复现时最容易对不上号的五处

把本章代码搬到别的机器上，最容易在五个地方对不上号，而且每一处都能造成数量级的差别。把它们列出来，比事后逐行排查省时间。

第一处是微分加在哪。第七段同一组 Z-N 参数，微分作用在误差时超调 77.31%、$|u|_{\max} = 19.167$，作用在输出时超调 54.19%、$|u|_{\max} = 3.766$。两者的 K_p、T_i、T_d 完全相同，差别只在微分通道的输入。若你的结果落在 54% 附近而不是 77%，先别怀疑对象，查一下 `ed = c*ref - yk` 这行是不是被写成了 `ek`。

第二处是稳态值怎么取。`step_metrics` 取最后 1% 时间段的均值作为稳态值，超调以它为基准。响应尚未衰减完就截断，残余振荡会把稳态估高或估低，超调跟着偏。第 37 章给过一个例子：$\zeta = 0.1$ 时若仍用 6 s 窗口，超调会被算成 69.6%，与解析值差 3 个百分点。本章所有 t_s 都要求仿真时长不少于 $10/(\zeta\omega_n)$，就是因为这个。

第三处是采样周期。同一组 $3.23/4.00/1.08$，$T_s = 0.04$ s 时超调已经涨到 80.17%、谱半径 0.9864；$T_s = 0.05$ s 时谱半径 1.1426，输出跑到 -2.99×10^8。看到这种量级的数，不是对象发散，是采样已经把闭环推到单位圆外。**本章把 0.04 s 与 0.05 s 两档特意留在表里，就是为了给“采样周期不能拍脑袋”留一个实证。**

第四处是延迟队列的顺序。`simulate_pid_advanced` 先算本拍 u_k，压入队列，再从队首取 u_{plant} 给对象；对象状态更新用的始终是上一拍真正执行的值。若把顺序写成“先更新对象、再压队列”，等效延迟会少一拍，2 拍延迟的算例就会给出低于 31.64%、向线性值 17.35% 靠近的结果，看起来“性能更好”，其实是仿真漏了一拍。

第五处是斜坡误差的观察窗口。$K_i = 0.1$、$K_p = 1$ 对应 $T_i = 10$ s，20 s 窗口只覆盖两个时间常数，残差停在 0.02700；有人据此判断“积分不起作用”，其实是没等它收敛。按 3 倍 T_i 取窗口，三组都会趋近于零。**五处里没有一处是算法错，全是口径与顺序；复现的第一步不是比对曲线，而是比对口径。**

44.12.8 本章小结

本章从“三项作用各换来什么”出发，依次讨论了连续设计、离散实现、稳定性、参数影响、整定规则、抗饱和、微分滤波、二自由度、工程落地与适用边界。所有数字都来自同一套代码、同一个对象、同一套口径，因此可以横向比较，也可以逐项复现。

如果只带走三句话：第一，PID 的三个参数不是三个独立的旋钮，而是一组耦合的折中；第二，工程上真正决定成败的往往不是增益，而是限幅、滤波、延迟与切换；第三，先用裕度判断“能不能用”，再用指标判断“好不好用”。

本章留下的接口有三处，后文会反复用到。其一，表 44-7 的参数—指标影响方向与表 44-8 的整定规则对照，是第 106 章过程回路整定的直接引用源，届时不再重算，只讨论工程对象的特殊性。其二，§44.9.1 的回算抗饱和结构与 §44.10.4 的无扰切换逻辑，是第 46 章复合控制与第 47 章 Smith 预估器中共用同一套输出保护的前提，凡有外环、有前馈通道的结构，都必须在本章这套基础上叠加。其三，§44.6 的裕度口径与 §44.5.5 的采样周期准则，是第 45 章判断“副回路够不够快”的度量基准——串级之所以成立，本质上就是让内环在本章给出的这些指标上明显优于外环。

需要提醒的是，本章的所有结论都建立在对象近似线性、延迟远小于主导时间常数这两个前提上。一旦延迟与主导时间常数可比（$\tau/T > 0.5$），PID 无论怎么调都无法同时满足快速与稳定，此时应转向第 47 章的预估补偿，而不是继续加大增益。

第45章 串级控制

45.1 动机与直观理解

第 44 章把 PID 的三个旋钮讲清楚了，但那只解决了“回路怎么搭”的一半问题。真实的工业对象很少是一段干净的传递函数：燃料压力在阀后波动，冷却水温度在夹套里漂移，电网电压在电机前面跳变。这些扰动有的发生在离被控量很近的地方，有的发生在很远的地方。同一个 PID，装在离扰动近的位置和装在离扰动远的位置，抑制效果可以差一个数量级。串级控制就是为这件事生的：在扰动入口附近再套一个快回路，把扰动就地吃掉，不让它传到主变量。

本章沿用第 44 章的 PID 结论，不重复三项作用的推导。若对积分饱和、微分滤波、整定规则还不熟，请先回读第 44 章 §44.2 与 §44.9。本章只讨论“多套一层回路”带来的新问题：内外环怎么分工、快慢差多少才算够、参数按什么顺序调、离散实现时两个采样周期怎么配。

45.1.1 一个现场场景

某换热器用蒸汽加热物料，工艺要求出口物料温度稳定在设定值。单回路方案是温度变送器直接进 PID，PID 输出直接驱动蒸汽调节阀。投运后发现：蒸汽母管压力一波动，出口温度就跟着晃，幅度约 ±3 ℃，要七八分钟才回稳。操作工的对策是把 PID 调得很慢，靠牺牲响应速度换平稳，结果换料时温度要十几分钟才跟上。

问题出在扰动的位置。蒸汽压力波动作用在阀后、换热器之前，而温度测点在换热器之后。单回路必须等热量传过整个换热器、温度真的变了，才从偏差里看出问题，此时扰动已经造成了全部影响。中间那个“蒸汽流量”其实一直在变，只是没人看它。

把流量也测出来、也闭环，情况就不同了。温度控制器不再直接指挥阀门，而是给出一个“需要多少流量”的设定值；流量控制器拿这个设定值和流量计读数比较，快速把阀开到需要的位置。压力波动一出现，流量计立刻看到，流量回路在零点几秒内就把阀补到位，温度几乎感觉不到。这就是串级：外环管“要多少”，内环管“给到位”。

45.1.2 干扰位置决定收益

串级的收益不是普适的，它与扰动进入系统的位置强相关。把扰动分三类看。

第一类，扰动进入内环之内，例如阀后压力、燃料热值、冷却水流量。这类扰动内环直接看得到，串级能在它污染主变量之前把它压住。本章算例中，同样幅值的阶跃扰动，单回路造成的主变量峰值偏差为 0.1855，串级为 0.0157，相差 11.8 倍；单回路要 12.99 s 才回到 ±2% 带内，串级从一开始就没出带。

第二类，扰动进入内外环之间，例如物料入口温度、进料流量。这类扰动内环看不到，外环必须自己扛，串级与单回路的能力相当。本章实测：单回路峰值偏差 0.1888，串级 0.1787，差别在 6% 以内，属于参数差异而非结构优势。

第三类，扰动直接作用在主变量上，例如环境散热、测量噪声。这类扰动谁也提前看不到，串级不但没有优势，还可能因为多了一层动态而略差。

所以现场判断“要不要上串级”，第一个问题不是“精度够不够”，而是“最大的扰动从哪儿进来”。扰动在内环之内，串级值得做；扰动在外环之外，做了也白做。

45.1.3 结构：两条回路，四个信号

图 45-1 给出本章使用的结构。与单回路相比，多了三样东西：一个内环控制器 $C_1(s)$、一个内环测量 y_1、以及一个由外环输出充当的内环设定值 r_1。

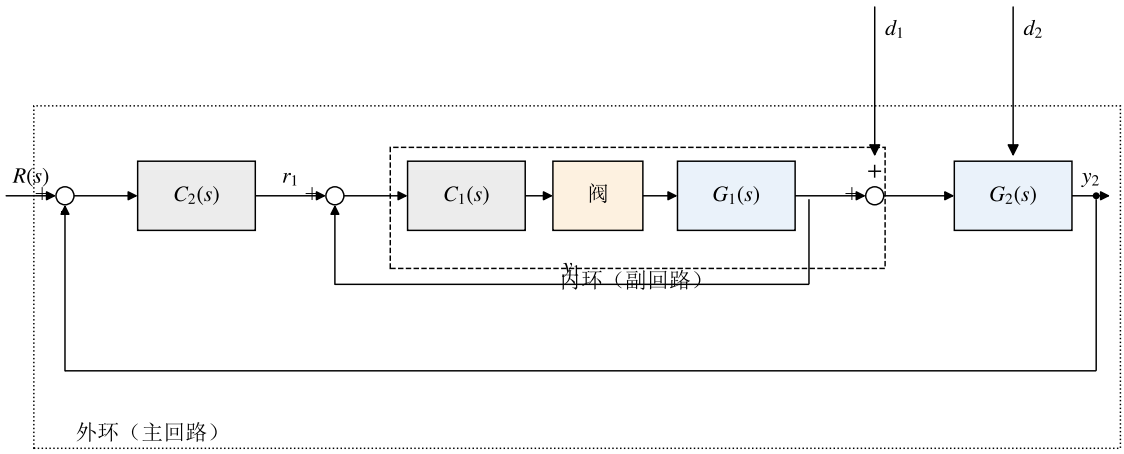

图 45-1　串级控制结构：外环定设定值，内环快速跟随

四个信号的分工必须记牢：r 是工艺给定的主变量目标；y_2 是主变量实测；r_1 是外环算出的副变量目标，它是内环的设定值，不是执行器指令；u 才是真正送到阀门的信号。现场最常见的接线错误，就是把外环输出直接接到阀上、同时又把内环输出并进去，两个控制器抢同一个执行器，一投自动就打架。

两条回路的职责也不同。外环负责“准”：它含积分，保证主变量稳态无差，但它慢，因为它要等主变量真的偏了才动作。内环负责“快”：它把副变量死死按在 r_1 上，扰动来了就地消化，但它不保证主变量准，因为 r_1 本身可能算错。

45.1.4 一句话核心与本章路线

如果只能记住一句话：**串级把“快速但只管局部”的内环，包在“慢速但管全局”的外环里，用速度换抗扰。**

这句话里有两个可验证的条件。其一，内环必须真的快，否则它来不及在扰动传到主变量之前完成抑制；本章 §45.6 给出量化判据：内环闭环带宽应不低于外环开环穿越频率的 5 倍，低于 3 倍时串级的抗扰优势基本消失。其二，外环必须能容忍内环的近似，它把内环当成一个增益为 1 的快速环节来设计，内环的残差与滞后会原封不动地进入外环，成为外环的“模型误差”。

本章按“原理—设计—连续—离散—稳定—参数—整定—改进—落地—边界—代码”推进。§45.2 用方块图化简给出串级的等效传递函数，说明内环究竟改变了什么；§45.3 把设计固化成六步；§45.4 给出本章算例的连续设计与跟踪结果；§45.5 讲双采样率实现；§45.6 用带宽比、扰动抑制倍数、失配鲁棒性三把尺子量化性能；§45.7 逐个说明内外环参数的作用；§45.8 讲“先内后外”的整定顺序与现场手法；§45.9 讨论设定值滤波、增益调度与副回路替代方案；§45.10 处理限幅、抗饱和、无扰切换与投运检查；§45.11 划定适用边界；§45.12 给出可复现代码。

45.1.5 三个常见误解

误解一：串级一定比单回路好。 本章数据给出反例：外环扰动下两者峰值偏差 0.1888 与 0.1787，差别在噪声量级；扰动若直接作用在主变量上，串级还要多一层滞后。串级是“针对特定扰动位置”的结构，不是普遍升级。

误解二：内环越快越好。 内环增益加大会放大噪声、加剧阀的动作频次，还会把外环输出的设定值阶跃直接变成阀位冲击。本章实测：内环 K_p 从 2 提到 4、K_i 从 4 提到 8，内环扰动峰值从 0.0157 降到 0.0078，但阀位峰值从 3.000 涨到 6.000。阀门寿命与定位器磨损是真实成本，快要有上限。

误解三：内外环可以用同一个采样周期。 用同一个周期当然能跑，但外环不需要那么快，内环又嫌不够快。本章 §45.5 的多速率试验显示：外环周期从 0.01 s 放宽到 0.5 s，超调只从 3.46% 涨到 7.79%；放宽到 2 s，超调涨到 25.10%。工程上按“内环快、外环慢”配置，既省算力又符合两者的带宽关系。

理解了这三条，就能明白串级不是一个“更高级的 PID”，而是一次**测量点的重新选择**：把测量点从远离扰动的地方，挪到扰动入口附近，然后用一个快回路守住它。

45.1.6 术语：串级、级联、主副回路

同一个结构在文献与现场有五种叫法，先把它们对齐，避免读资料时误以为是不同的东西。

串级控制（cascade control）是控制理论的标准译名，“串”指两个回路串联：外环的输出不是执行器指令，而是内环的设定值。**级联**是同一个词的另一种译法，多用于电力与化工文献，含义完全相同。

主副回路（primary/secondary loop）是过程工业的叫法。主回路对应工艺目标（温度、液位），副回路对应实现目标的手段（流量、阀位）。这个叫法比“内外环”更贴近现场思维：操作工关心的是“主变量准不准”，而“副变量”只是保证主变量的工具。本章两种叫法混用，“内环”与“副回路”、“外环”与“主回路”始终是同一件事。

主从控制（master/slave）多用于运动控制，语义与主副回路相同，但“从”字带有从属意味，在讲回路职责时不如“副”准确。**双闭环**是伺服领域的叫法，特指“位置环套速度环”这一类，本质仍是串级。

监督控制（supervisory control）容易与串级混淆，但它指的是“上层优化给下层回路发设定值”，上层通常不参与快速闭环，时间尺度是分钟到小时；串级的两层都在秒级闭环内。二者的差别不在结构，而在时间尺度。

还有两个容易混的结构。**分程控制**是一个控制器驱动两个阀（例如大阀与小阀分程），只有一个回路；**选择性控制**是多个测量值经高选/低选后进同一个控制器，也只有一个回路。它们与串级一样属于“复杂回路”，但解决的是“执行器切换”与“变量保护”，不是“扰动位置”。第 107 章会把这几类放在一起比较。

术语对齐之后，本章的表述可以统一成一句：**串级是把“工艺目标”与“实现手段”分成两层闭环，外层慢而准，内层快而稳。**

45.1.7 本章要回答的三个问题

为避免读完一节就迷路，先把本章的三个锚点问题列出来，它们分别对应后面的三组数字。

问题一：串级到底改善了什么？ 答案在 §45.2 与 §45.4：改善的是**内环扰动**通道，机理是分子上多了 S_1；对设定值与外环扰动，改善有限甚至没有。量化结果是 11.8 倍、3.46% 对 7.18%、0.1787 对 0.1888。

问题二：要快多少才算够？ 答案在 §45.3 与 §45.6：内环带宽至少是外环穿越频率的 5 倍，8–20 倍为优良区；本章 11.37 对应 11.8 倍抑制、65.56° 相位裕度。低于 3 倍时，串级退化为“多了一层滞后的单回路”。

问题三：代价是什么、什么时候不该做？ 答案在 §45.7 至 §45.11：代价是 $K_{p1}K_{p2}$ 的控制量冲击、多一个测量点、多速率的实现复杂度；不该做的情况是扰动不在内环之内、副变量太慢、阀门没有余量。三条判据在 §45.11.4。

三个问题串起来，就是本章的逻辑主线：**先确认扰动位置（问题一），再确定快慢标准（问题二），最后核算代价与边界（问题三）**。后面的公式与仿真，都是为这三个问题提供数字支撑。

45.2 数学原理

§45.1 说“内环把扰动就地吃掉”，这句话必须在传递函数上兑现。本节做三件事：把串级化简成外环能看懂的形式，找出内环究竟在哪个通道上加了什么因子，再把这个因子换算成可测量的带宽指标。

45.2.1 符号与三条通道

沿用图 45-1 的结构。内环控制器 $C_1(s)$、内环对象 $G_1(s)$、外环控制器 $C_2(s)$、外环对象 $G_2(s)$。两个扰动入口：d_1 加在 G_1 的输入端（阀后、副对象之前），d_2 加在 G_2 的输入端（内外环之间）。

先只看内环。以 r_1 为输入、y_1 为输出，闭合 C_1 后有

$$y_1 = \frac{C_1 G_1}{1 + C_1 G_1}\, r_1 + \frac{G_1}{1 + C_1 G_1}\, d_1 \tag{45-1}$$

定义内环闭环传递函数与内环灵敏度函数

$$T_1(s) = \frac{C_1 G_1}{1 + C_1 G_1}, \qquad S_1(s) = \frac{1}{1 + C_1 G_1} \tag{45-2}$$

T_1 描述“设定值能不能跟住”，S_1 描述“扰动能不能压住”。两者互补：$T_1 + S_1 = 1$。内环做得越猛，$T_1 \to 1$、$S_1 \to 0$，设定值跟得越准、扰动压得越狠。代价在 §45.6 讨论。

再闭外环。外环的对象不是 G_2，而是“G_2 串上已经闭合的内环”，即 $G_2 T_1$。外环控制器看到的误差是 $r - y_2$，输出是 r_1：

$$y_2 = \frac{C_2 G_2 T_1}{1 + C_2 G_2 T_1}\, r + \frac{G_1 G_2 S_1}{1 + C_2 G_2 T_1}\, d_1 + \frac{G_2}{1 + C_2 G_2 T_1}\, d_2 \tag{45-3}$$

式 (45-3) 是本章的主方程。三条通道分别是设定值通道、内环扰动通道、外环扰动通道。把它们与单回路 C 直接控阀的结果并列，差别一眼可见。

单回路的对应式为

$$y_2 = \frac{C G_1 G_2}{1 + C G_1 G_2}\, r + \frac{G_1 G_2}{1 + C G_1 G_2}\, d_1 + \frac{G_2}{1 + C G_1 G_2}\, d_2 \tag{45-4}$$

比较式 (45-3) 与式 (45-4)：设定值通道与 d_2 通道的结构完全同构，只是把 C 换成了 C_2、把 G_1 换成了 T_1。唯独 d_1 通道多了一个 S_1 因子。**串级的全部收益都藏在这个 S_1 里，全部代价则藏在 $T_1 \neq 1$ 这个事实上。**

表 45-1 把三条通道的差异列清楚。

通道	单回路	串级	差异来源
设定值 $r \to y_2$	$C G_1 G_2 / (1 + C G_1 G_2)$	$C_2 G_2 T_1 / (1 + C_2 G_2 T_1)$	G_1 换成 T_1
内环扰动 $d_1 \to y_2$	$G_1 G_2 / (1 + C G_1 G_2)$	$G_1 G_2 S_1 / (1 + C_2 G_2 T_1)$	多乘 S_1
外环扰动 $d_2 \to y_2$	$G_2 / (1 + C G_1 G_2)$	$G_2 / (1 + C_2 G_2 T_1)$	无额外抑制

表 45-1 解释了 §45.1.2 的实测排序：d_1 通道有 S_1 加持，串级大幅领先；d_2 通道没有，两者相当。

45.2.2 内环扰动的抑制倍数

S_1 在频域的大小决定了抑制倍数。在频率 ω 处，

$$|S_1(\mathrm{j}\omega)| = \frac{1}{|1 + C_1(\mathrm{j}\omega)G_1(\mathrm{j}\omega)|} \tag{45-5}$$

分母就是内环回路增益加一。只要内环在扰动能量集中的频段内回路增益远大于 1，S_1 就远小于 1，d_1 传到主变量之前已被削弱。

本章算例的内环对象为 $G_1 = 1/(0.5s+1)$，控制器取 $C_1 = 2 + 4/s$。在 $\omega = 1$ rad/s 处，

$$C_1(\mathrm{j}1) = 2 + \frac{4}{\mathrm{j}1} = 2 - \mathrm{j}4, \qquad G_1(\mathrm{j}1) = \frac{1}{1 + \mathrm{j}0.5} \tag{45-6}$$

乘起来

$$C_1(\mathrm{j}1)G_1(\mathrm{j}1) = (2 - \mathrm{j}4)(0.8 - \mathrm{j}0.4) = -\mathrm{j}4.0 \tag{45-7}$$

于是 $|1 + C_1G_1| = |1 - \mathrm{j}4.0| \approx 4.12$，$|S_1| \approx 0.24$。也就是说，1 rad/s 附近的内环扰动传到主变量时只剩约四分之一。频率越低，积分项 $4/\mathrm{j}\omega$ 越大，$|S_1|$ 越小；频率高到 $\omega \gg \omega_{b1}$ 时 $|S_1| \to 1$，内环来不及反应，扰动原样通过。

这就是“内环只能压住它带宽以内的扰动”的数学表述。工程含义很直接：先看扰动的频谱落在哪里，再看内环带宽够不够覆盖它。蒸汽压力波动的典型频段在 0.1–2 Hz，内环带宽取 5 rad/s（约 0.8 Hz）只能覆盖一半，取 30 rad/s 才能基本覆盖。

45.2.3 外环看到的等效对象

外环设计时把 T_1 当作 1，实际 $T_1 = 1 - S_1$。定义外环的等效对象与模型误差

$$\tilde{G}_2(s) = G_2(s)T_1(s) = G_2(s)\left[1 - S_1(s)\right] \tag{45-8}$$

$$\frac{\tilde{G}_2 - G_2}{G_2} = T_1 - 1 = -S_1 \tag{45-9}$$

式 (45-9) 说明：内环的灵敏度函数，就是外环的乘性模型误差。S_1 在低频很小，外环几乎看不到差别；在穿越频率附近若 $|S_1|$ 还有 0.2，外环的相位裕度就会被这个“看不见的滞后”吃掉一部分。

对一阶内环加 PI 控制器，低频段有近似

$$|S_1(\mathrm{j}\omega)| \approx \frac{\omega}{\omega_{b1}}, \qquad \omega \ll \omega_{b1} \tag{45-10}$$

其中 ω_{b1} 是内环闭环 -3 dB 带宽。式 (45-10) 把“内环要快多少”变成一道除法：外环穿越频率处要求 $|S_1| \le 0.2$，就得 $\omega_{b1} \ge 5\omega_{c2}$；要求 $|S_1| \le 0.1$，就得 $\omega_{b1} \ge 10\omega_{c2}$。这就是 §45.6 中 5 倍准则的出处，它不是经验口号，而是式 (45-9) 的直接推论。

45.2.4 为什么内环通常只用 P

内环若也带积分，闭环特征方程变为

$$1 + C_2G_2\frac{C_1G_1}{1 + C_1G_1} = 0 \;\Longrightarrow\; (1 + C_1G_1) + C_2G_2C_1G_1 = 0 \tag{45-11}$$

两个 PI 相乘后，开环传函在原点有两个极点，相位在低频就跌到 -180°，闭环极易出现低频慢振荡。这种振荡在现场表现为“主变量围着设定值缓慢画圈”，周期往往在几分钟量级，操作工称之为“晃”。

因此常规做法是：内环只用 P，或只用很弱的 I（T_{i1} 取副对象时间常数的 3–10 倍），把消差的任务留给外环。本章算例的内环取 $K_{p1}=2$、$K_{i1}=4$（$T_{i1}=0.5$ s），与副对象时间常数同量级，属于“偏快”的配置，用来展示收益上限；工程上更常见的是 $T_{i1}\ge 2T_1$。

内环不加积分还有一个附带好处：副回路的积分饱和问题不存在，抗饱和只需处理外环输出与外环积分。这一点在 §45.10 的投运检查里会再用到。

45.2.5 设定值冲击的定量

外环输出 r_1 对内环来说是设定值阶跃。内环 P 作用立即响应，阀位在第一个采样周期就跳到

$$u(0^+)=K_{p1}\,e_1(0^+)=K_{p1}\left[r_1(0^+)-y_1(0^+)\right] \tag{45-12}$$

而 $r_1(0^+)=K_{p2}\left[r(0^+)-y_2(0^+)\right]=K_{p2}$（单位阶跃、零初值）。代入本章参数 $K_{p1}=2$、$K_{p2}=1.5$：

$$u(0^+)=2\times 1.5=3.0 \tag{45-13}$$

实测阀位峰值正是 3.000（§45.4 表 45-3）。单回路在同一工况下阀位峰值为 1.805，因为只有一个 K_p 在起作用。**串级的控制量冲击是两级增益相乘的结果，这是它最容易被忽视的代价**，也是 §45.9 要加设定值滤波的原因。

式 (45-12) 还给出一个设计约束：若执行器上限为 $u_{\max}$，则 $K_{p1}K_{p2}\le u_{\max}/\Delta r$。本章算例的阀门若限在 ±1.2，$3.0$ 的峰值必然触发限幅，§45.9 的限幅试验正是从这一点出发的。

45.2.6 离散形式

串级在计算机里是两段位置式 PID，各自维护积分器与微分状态。内环每个采样周期执行一次，外环每 N_r 个内环周期执行一次：

$$r_1[k]=K_{p2}e_2[k]+I_2[k]+K_{d2}\frac{e_2[k]-e_2[k-1]}{T_{s2}} \tag{45-14}$$

$$u[k]=K_{p1}e_1[k]+I_1[k]+K_{d1}\frac{e_1[k]-e_1[k-1]}{T_{s1}},\qquad e_1[k]=r_1[k]-y_1[k] \tag{45-15}$$

其中 I_1,I_2 为两级的积分累加项。注意 $r_1[k]$ 在内环的每个周期都保持不变（零阶保持），这就是多速率的全部含义：外环算得慢，内环照着最近一次的 r_1 反复执行。

离散化带来的两个新问题——内环采样周期怎么定、外环与内环的周期比允许多大——分别在 §45.5 与 §45.6 展开。这里只强调一点：式 (45-14) 的积分累加按 T_{s2} 计，式 (45-15) 按 T_{s1} 计，两者不能混用同一个周期；现场把两个回路的 T_s 参数填成同一个值，是“串级投自动后周期振荡”的常见原因。

45.2.7 三条通道的数值画像

式 (45-3) 的三项系数，把本章的实测数字代进去，可以得到一张“通道画像”，它解释了 §45.1.2 的定性判断为什么成立。

设定值通道 $C_2G_2T_1/(1+C_2G_2T_1)$。低频增益为 1（外环含积分），单位阶跃下超调 3.46%、上升 3.720 s。与单回路的 7.18%、3.523 s 相比，串级在设定值通道上并没有“更快”，只是“更稳”。原因在 §45.4.2 已经说过：

T_1 的稳态增益 $K_{p1}/(1+K_{p1}) = 0.667$ 让外环实际看到的对象增益只有设计值的 2/3，等效于把外环增益调小。

内环扰动通道 $G_1G_2S_1/(1+C_2G_2T_1)$。与单回路的 $G_1G_2/(1+C_2G_1G_2)$ 相比，分子上多了一个 S_1，分母上的 G_1 换成了 T_1。低频段 $S_1 \approx 0$，所以两条通道的稳态增益都是 0；差别在**中频段**——扰动的主频落在 0.3–4 rad/s 之间时，$|S_1|$ 从 0.67 一路降到 0.09，串级把这一段压下去了。本章峰值偏差 0.1855→0.0157（11.8 倍）就是这个因子的直接兑现。

外环扰动通道 $G_2/(1+C_2G_2T_1)$。与单回路的 $G_2/(1+C_2G_1G_2)$ 相比，分母里的 G_1 同样换成了 T_1，但分子没有 S_1 这个“抑制因子”。也就是说，**外环扰动不经过内环，串级对它没有任何额外的抑制手段**；T_1 与 G_1 的差别只体现在相位上，反映为恢复时间略慢（13.370 s 对 12.420 s）。实测 0.1888 与 0.1787 的 5% 差异，来自 T_1 在中频的幅值略小于 1，属于“顺便沾了点光”，不是结构优势。

把三条通道并排看，可以得到一个简洁的判断法则：**串级的收益全在分子上带 S_1 的那条通道**。设计时先问“我的扰动走哪条通道”，再决定要不要上串级；这比笼统地说“串级抗扰好”精确得多。

45.2.8 内部稳定性与代数环

框图化简还留下一个隐含问题：内环闭合后，外环的对象 G_2T_1 是否“良定”（well-posed）？若 G_1 与 G_2 都是真有理函数、C_1 也是真有理函数，则 T_1 真有理，G_2T_1 严格真有理，外环的闭环不会有代数环。工程上出问题的是另一种情况：副变量由**静态代数关系**算出（例如用阀位乘以一个增益当流量），此时 T_1 的分子分母同阶，外环闭合就出现代数环，离散实现时表现为“当前拍的输出依赖当前拍的输出”，必须引入一拍延迟才能算。

内部稳定性还要求：C_1、C_2、G_1、G_2 之间不能有右半平面零极点对消。现场最接近这种情形的是“内环控制器带一个与副对象极点相同的零点”——整定时若用了“零极点对消”的规则（如 $T_{i1} = T_1$），而副对象时间常数辨识有误，就会留下一个接近对消但不完全对消的慢模态，表现为投运后很长时间才暴露的缓慢漂移。第 44 章讲 IMC 整定时提过这一点，串级里因为多了一层，风险更高：内环的对消错误会通过 T_1 传到外环，而外环的设计又假定 T_1 是干净的。

实践上的两条防线：其一，内环积分时间不要刻意取成与副对象时间常数完全相等，留 20% 以上的差距；其二，投运后观察 30 min 以上的长趋势，专门看有没有缓慢漂移，阶跃试验看不出来。

45.2.9 用 Nyquist 图看内环做了什么

式 (45-21) 的稳定性可以用 Nyquist 判据几何地看，比代数推导更直观。外环开环 $L_2 = C_2G_2T_1$ 的 Nyquist 曲线，与单回路的 $C_2G_1G_2$ 相比，差别集中在穿越频率所在的中频段。

低频段（$\omega \ll \omega_{b1}$）：$T_1 \approx K_{p1}/(1+K_{p1})$，是一条实数增益，曲线形状与单回路几乎相同，只是幅值缩了 0.667 倍。

中频段（$\omega \approx \omega_{c2}$）：$T_1$ 开始带相位滞后，$-S_1$ 的幅值约 $1/r_b$。Nyquist 曲线在这一段被“往原点方向拉”了一点，同时顺时针偏转，表现为相位裕度增大。r_b 越大，拉得越狠、偏得越少，曲线离 $(-1, \mathrm{j}0)$ 越远。

高频段（$\omega \gg \omega_{b1}$）：$T_1 \to 1$，$L_2 \approx C_2G_2$，与单回路的高频段重合。这一段与中频段的过渡共同决定幅值裕度，因此 GM 受内环影响较小，实测五档都在 18–28 dB。

把三段连起来看，**内环的作用不是“改变回路增益”，而是“重新塑造中频段的方向”**：它让 Nyquist 曲线在穿越频率附近更“竖直”（相位滞后更小），从而给出更大的相位裕度。这正是 §45.6.6 中 PM 从 45.90° 升到 68.02° 的几何解释。

Nyquist 视角还解释了一个容易困惑的现象：内环越快，外环穿越频率越高（0.2949→0.3532 rad/s），但相位裕度也越大。若只看“穿越频率升高会减少裕度”的单回路经验，会得出相反结论。原因是内环同时把中频段的相位滞后清掉了，两个效应方向相反，后者的作用更大。

45.3 设计步骤

§45.2 给出了“为什么”，本节给出“怎么做”。串级的设计顺序不能颠倒：先选副变量、再整内环、然后才整外环。现场把顺序做反（先按单回路把外环调好，再加内环），结果往往是两个回路互相拖，怎么调都不对。图 45-2 是本节固化的六步流程。

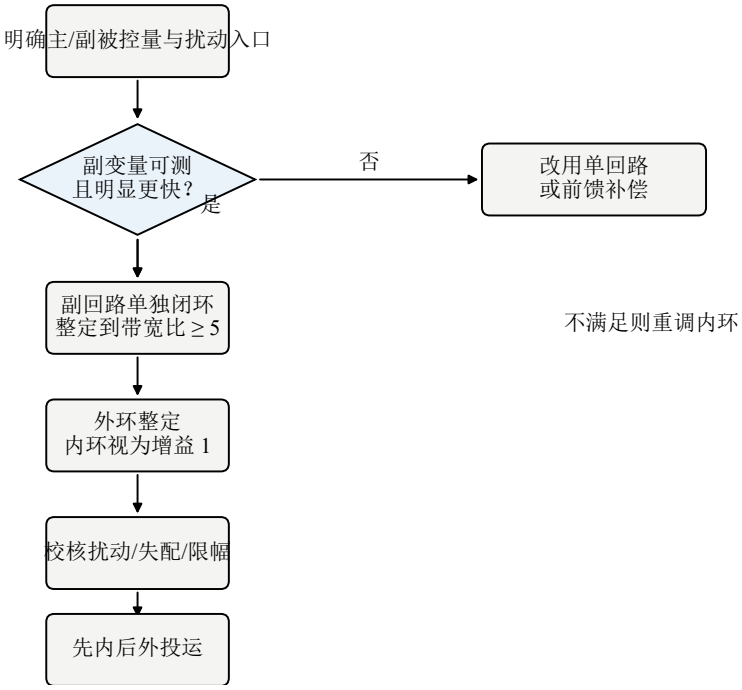

图 45-2　串级设计六步流程：副变量选取 → 内环整定 → 等效对象 → 外环整定 → 带宽与周期复核 → 投运检查

45.3.1 第一步：选副变量

副变量的选择决定了串级的上限，选错了后面怎么调都白搭。四条判据，按优先级排列。

其一，副变量必须在扰动入口的下游、主变量的上游。 这正是 §45.1.2 的结论。蒸汽压力扰动作用在阀后，流量在阀后、换热器之前，所以流量合格；如果扰动来自物料入口温度，那么流量计看不到它，选流量做副变量对这个扰动毫无帮助。

其二，副变量必须可测且测量快。 温度变送器带保护套管时时间常数可达几十秒，用它做副回路等于把快回路做成了慢回路。本章算例的副对象时间常数 0.5 s，属“仪表级”快；工程上副对象时间常数超过主对象的三分之一，就要重新考虑副变量。

其三，副变量与主变量之间要单值、单调。 流量增大必然使温度上升，这才可控。若中间存在换向（如某些放热反应的温度—流量关系在中段出现极大值），副回路会在两个工作点之间跳。

其四，副变量对主变量的影响要显著。 若副变量变化 10% 只引起主变量 0.5% 的变化，内环把副变量按得再死，主变量也感受不到。

四条都满足的副变量通常只有一个，不必纠结。副变量选定后，主、副对象的时间常数比就定了，这个比值是后面所有指标的物理上限。

45.3.2 第二步：单独整定内环

把外环断开（外环置手动，其输出 r_1 由人手给），内环按单回路整定。此时内环就是一个普通回路，第 44 章的方法全部适用。

内环整定的目标不是“超调最小”，而是“闭环带宽够大、且对副对象增益变化不敏感”。具体做法：

1. 先只用 P。从 $K_{p1}=0$ 往上加，直到内环阶跃响应的上升时间约为副对象时间常数的 $1/3$ 到 $1/2$。本章 $G_1=1/(0.5s+1)$，取 $K_{p1}=2$ 时内环闭环带宽 4 rad/s 量级，上升时间约 0.15 s。
2. 检查内环的增益裕度。副对象增益在工程上常有 ±40% 的偏差（阀门口径选大、流量计标定漂移），内环在增益上浮 40% 时仍应稳定且不明显振荡。本章 §45.6 的失配试验就是按这个口径做的。
3. 一般不加积分。若要加，T_{i1} 取副对象时间常数的 3–10 倍，只用来消除副变量的稳态偏差，不参与快速性。原因见 §45.2.4：两个积分器在原点堆两个极点，低频会出现“晃”。
4. 微分一般不加。副回路信号噪声大（流量计尤甚），微分放大噪声，还会在阀上产生高频抖动。

这一步结束时应该拿到两个数：内环闭环带宽 ω_{b1} 和内环闭环近似时间常数 $\tau_1\approx 1/\omega_{b1}$。它们是下一步的输入。

45.3.3 第三步：写出外环看到的等效对象

闭合内环后，外环的对象是 G_2T_1，不是 G_2。设计外环时必须用这个等效对象，否则会把内环的滞后重复计算一次。

工程上有两种处理，精度不同但结论一致。

近似一（粗略）：把 T_1 当成 1。 当 $\omega_{b1}\geq 5\omega_{c2}$ 时，外环穿越频率处 $|S_1|\leq 0.2$，T_1 的幅值在 0.8–1.0 之间、相位滞后不到 12°。此时直接按 G_2 设计外环，误差落在裕度里。

近似二（较准）：把 T_1 近似为一阶惯性。 一阶内环加 P 控制时，$T_1=K_{p1}/(0.5s+1+K_{p1})$，即时间常数 $\tau_1=0.5/(1+K_{p1})$、增益 $K_{p1}/(1+K_{p1})$。$K_{p1}=2$ 时 $\tau_1=0.167$ s、增益 0.667。把这一阶并进 G_2，外环看到的是“二阶对象 + 一个小惯性 + 一个 0.667 的增益”，再按第 44 章的 IMC 或 ZN 规则整定。

本章采用近似二，得到外环 $K_{p2}=1.5$、$T_{i2}=4$ s。注意 T_{i2} 与主对象的主导时间常数 4 s 同量级，这是 IMC 规则 $\lambda\approx T_i$ 的典型结果。

45.3.4 第四步：整定外环并复核带宽比

外环按单回路整定，但要**用内环闭合后的等效对象**，并且整定完必须回算带宽比

$$r_b=\frac{\omega_{b1}}{\omega_{c2}} \tag{45-16}$$

其中 ω_{c2} 是外环开环穿越频率。$r_b\geq 5$ 合格，$3\leq r_b<5$ 勉强，$r_b<3$ 说明内环不够快，串级的抗扰优势基本消失。

本章实测的带宽比很说明问题：内环取 $K_{p1}=0.5$、$K_{i1}=0.5$（几乎不控）时，$\omega_{b1}=0.439$ rad/s，外环穿越 0.2949 rad/s，$r_b=1.49$；内环取 $2/4$ 时 $\omega_{b1}=4.005$ rad/s、$r_b=11.37$；内环取 $4/8$ 时 $\omega_{b1}=8.010$ rad/s、$r_b=22.68$。三种配置下内环扰动峰值偏差依次为 0.0922、0.0157、0.0078，与带宽比同向变化。

若复核发现 r_b 不够，处理顺序是：先加内环增益（受噪声与阀位冲击限制），再考虑换更快的副变量测量，最后才动外环——把外环调慢虽然也能抬高 r_b，但代价是主变量响应变慢，等于用性能换结构。

45.3.5 第五步：分配采样周期

内环采样周期按第 44 章的准则：$T_{s1} \le \tau_1/10$。本章 $\tau_1 = 0.167$ s，故 $T_{s1} \le 0.017$ s，仿真取 0.01 s 正好落在合理区间；若图省事取 0.05 s，$T_{s1}/\tau_1 = 0.3$，内环的相位滞后会把式 (45-10) 的带宽优势吃掉一大半。

外环周期取 $T_{s2} = N_r T_{s1}$，N_r 由带宽比反推：外环带宽是内环的 $1/r_b$，采样周期可放宽 r_b 倍，再留 2–3 倍余量，故 $N_r \approx r_b/3$。$r_b = 12$ 时 $N_r \approx 4$，即外环每 4 个内环周期算一次。

N_r 不是越大越省。本章多速率试验（$T_{s1} = 0.01$ s 固定）：$N_r = 1$ 超调 3.46%，$N_r = 50$（外环 0.5 s）超调 7.79%，$N_r = 100$（1 s）13.16%，$N_r = 200$（2 s）25.10%。N_r 超过 $r_b/2$ 后超调迅速恶化，因为外环的零阶保持已经引入了可与自身带宽相比的附加滞后。

45.3.6 第六步：投运与限幅检查

投运顺序固定为：内环先投自动、外环后投自动；停运时反过来。内环还没稳就把外环投自动，外环会把内环的暂态当成对象特性，积分器一路积到限幅。

投运前必须核三件事：

- **控制量冲击。** 按式 (45-13) 估算 $K_{p1}K_{p2}\Delta r$，与阀门可用行程比较。本章 3.0 的冲击超过了 ±1.2 的行程，必须加设定值滤波或输出限幅。
- **抗饱和归属。** 内环无积分时，只有外环需要抗饱和；外环输出 r_1 被限幅时，外环积分必须停止累加，否则退饱和后要多走一段“冤枉路”。
- **无扰切换。** 外环从手动切自动时，r_1 必须从当前内环设定值起算（而不是从 0 或上次值），否则一切自动就有一个阶跃。

45.3.7 设计核对表

表 45-2 把六步的产出与判据收在一处，投运前逐项打勾。表中“本章取值”一列给出算例的实际数字，便于对照。

步骤	产出	判据	本章取值
一 选副变量	副对象 G_1	在扰动下游、主变量上游，$\tau_1 < \tau_2/3$	$1/(0.5s+1)$，$\tau_1 = 0.5$ s
二 整内环	C_1、ω_{b1}	上升时间 $\approx \tau_1/3$，增益上浮 40% 仍稳	$K_{p1} = 2$，$K_{i1} = 4$，$\omega_{b1} \approx 4$
三 等效对象	$G_2 T_1$	用等效对象而非 G_2 设计外环	$\tau_1 = 0.167$ s，增益 0.667
四 整外环	C_2、r_b	$r_b \ge 5$	$K_{p2} = 1.5$，$T_{i2} = 4$ s，$r_b = 11.37$
五 分周期	T_{s1}、N_r	$T_{s1} \le \tau_1/10$，$N_r \approx r_b/3$	0.01 s，$N_r = 4$
六 投运	限幅、抗饱和、切换	冲击 $\le$ 行程，外环先手动	冲击 3.0，需滤波

这张表的作用不是替代计算，而是防止漏项。现场调试出问题时，按表逐行回查，通常能定位到某一行的判据没满足。

45.3.8 设计校核清单

六步走完之后，不要直接投运，先按下面八条自查。每一条都给了可判定的阈值，避免“感觉差不多”。

1. **副变量时间常数**：$\tau_1 \le \tau_2/5$（τ_2 为主对象主导时间常数）。本章 $0.5 \le 0.8$，满足。不满足时先换测量点，不要指望调参补救。
2. **内环带宽**：ω_{b1} 是否达到设计值？本章 4.005 rad/s。若明显偏低，先查副变量滤波时间与内环采样周期（§45.5.2）。
3. **带宽比**：$r_b = \omega_{b1}/\omega_{c2} \ge 5$，优良区 8–20。本章 11.37。
4. **阀位冲击**：$K_{p1}K_{p2}\Delta r$ 是否小于行程的 80%？本章 3.000 已超出 ±2.0 的行程，即使阀门放宽到 ±4.0 也占 75%，需要设定值滤波或降增益。
5. **限幅深度**：正常工况下饱和占比是否低于 15%？本章不限幅时 10.9%，可接受；限幅到 ±1.2 后升到 62.8%，属于“执行器不够大”。
6. **外环周期**：T_{s2} 是否满足式 (45-19)？本章取 0.01–0.2 s 都合格，0.5 s 已到边界。
7. **相位裕度**：外环开环的 PM 是否在 45°–70°？本章 65.56°，见 §45.6.6。
8. **降级路径**：副变量故障时能否在 1 s 内切到安全状态？对应 §45.10.3 的表 45-15。

这八条里，第 1、4 条不满足属于“设计前提不成立”，必须回到结构层面（换测量点、换阀、加前馈）；第 2、3、5、6、7 条不满足属于“参数或实现问题”，可以在现有结构内调整；第 8 条不满足属于“工程完备性问题”，与性能无关，但一旦出事后果最重。

现场最常见的返工是第 3 条与第 4 条同时不满足：内环不够快（r_b 小），操作工于是加 K_{p1}，加了之后阀位冲击超标，又回头降 K_{p2}，K_{p2} 一降外环变慢，r_b 反而更小。这个循环的根源是副变量本身选得不好——**在错误的副变量上，带宽比与阀位冲击是一对无法同时满足的矛盾**。此时唯一的出路是换测量点或改结构，调参只会来回震荡。

45.4 连续情形

前三节讲结构与设计，本节把数字摆出来。算例对象、控制器参数与全部指标都来自 `code/ch045_sim.py` 的实跑输出，可逐项复现。

45.4.1 算例设定

副对象（阀 + 流量）取一阶快环节，主对象（换热 + 温度）取二阶过阻尼慢环节：

$$G_1(s) = \frac{1}{0.5s+1}, \qquad G_2(s) = \frac{1}{(4s+1)(s+1)} \tag{45-17}$$

主、副时间常数相差 8 倍，属于典型的“副回路够快”工况。内环 $C_1 = 2 + 4/s$，外环 $C_2 = 1.5(1 + 1/4s)$，单回路基线用同一套外环参数 $C = 1.5(1 + 1/4s)$ 直接控阀，两者唯一差别是有无内环。

选择这个基线而不是“各自调到最优”，是为了让对比只反映结构差异。单回路的 $K_p = 1.5$ 在它的可达范围内已有阀位余量（峰值 1.805），并未刻意调弱。

45.4.2 设定值跟踪

单位阶跃设定值下，两条回路的响应见图 45-3，指标列于表 45-3。

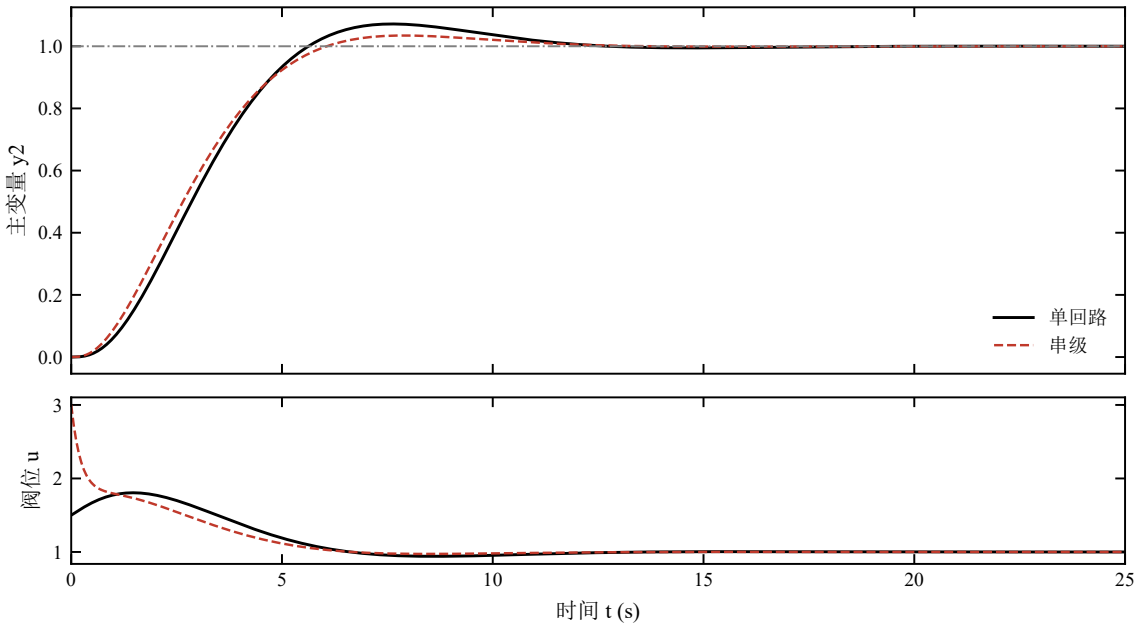

图 45-3　设定值阶跃响应：上为主变量，下为阀位；串级超调更小，但阀位峰值几乎翻倍

指标	单回路	串级	说明
超调 M_p	7.18%	3.46%	串级减半
上升时间 t_r	3.523 s	3.720 s	串级略慢 5.6%
调节时间 t_s	10.920 s	10.010 s	串级略快 8.3%
阀位峰值 $\lvert u\rvert_{\max}$	1.805	3.000	串级为 1.66 倍

表 45-3 的读法要小心。超调确实降了一半，但**这不是内环的功劳，而是外环“看错了对象”的副产品**：外环设计时把 T_1 近似为增益 0.667 的小惯性，实际闭环增益略低于设计值，等效于把外环增益调小了一点。上升时间略慢、调节时间略快，都是同一件事的两面。

真正值得注意的是最后一行。串级的阀位峰值 3.000 正是 §45.2.5 用 $K_{p1}K_{p2}=3.0$ 算出的值，两级增益相乘的冲击在这里兑现。单回路只有一级增益，峰值 1.805。**如果阀门行程只有 ±1.2，串级从一开始就会撞限幅**，这一点在 §45.10 会展开成整节的讨论。

所以对设定值跟踪，串级不是“更好的方案”，而是“用 1.66 倍的阀位冲击换一半的超调”。若工艺关心的是换料时的超调，这笔交易划算；若阀门本就没有余量，这笔交易做不成。

45.4.3 内环扰动抑制

本节的主戏。在 $t=30$ s（跟踪已稳定）时，于 G_1 输入端加幅值 -0.5 的阶跃扰动，模拟阀后压力突降。图 45-7 给出三条曲线，表 45-4 给出五组内环参数下的完整扫描。

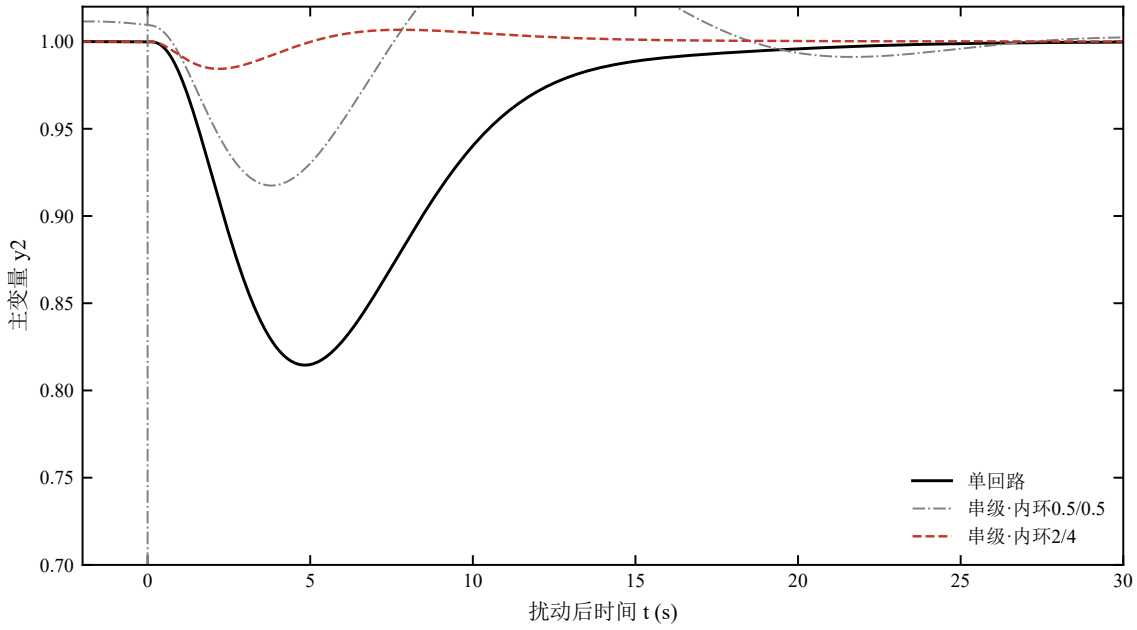

图 45-7　内环阶跃扰动下的主变量：串级把峰值偏差从 0.1855 压到 0.0157，且未出 ±2% 带

内环 K_{p1}, K_{i1}	峰值偏差	恢复时间	ω_{b1} (rad/s)	r_b	阀位峰值
单回路（无内环）	0.1855	12.990 s	—	—	1.805
0.5, 0.5	0.0922	15.360 s	0.439	1.49	1.646
1, 1	0.0481	12.330 s	0.911	2.79	1.654
2, 2	0.0254	3.850 s	2.544	7.45	3.000
2, 4	0.0157	未出带	4.005	11.37	3.000
4, 8	0.0078	未出带	8.010	22.68	6.000

表 45-4 有三层信息。

第一层，抑制倍数与带宽比同向。 峰值偏差从 0.0922 一路降到 0.0078，正好对应带宽比从 1.49 涨到 22.68。$0.5, 0.5$ 这一档的带宽比只有 1.49，按式 (45-10) 外环穿越频率处 $|S_1| \approx 0.29/0.44 \approx 0.67$——扰动只被削掉三分之一，内环的收益基本被它自己引入的滞后吃掉了，峰值偏差 0.0922 虽仍优于单回路的 0.1855，但恢复时间反而更长（15.360 s 对 12.990 s）。带宽比不到 2 时，串级算不上有效。

第二层，恢复时间不是单调的。 $0.5, 0.5$ 档最差（15.360 s），$2, 2$ 档最好（3.850 s），$2, 4$ 与 $4, 8$ 档干脆从未出带。原因是恢复时间由外环决定，而外环的输出 r_1 要经过内环才生效：内环太慢时，r_1 的修正被拖住，恢复变慢；内环够快后，r_1 的修正立刻兑现，恢复时间回到外环自己的节奏，甚至因为峰值偏差本来就小，主变量从头到尾没出 ±2% 带。

第三层，阀位峰值由设定值冲击主导。 $2, 2$、$2, 4$、$4, 8$ 三档的阀位峰值 3.000、3.000、6.000，正是 $K_{p1}K_{p2}$ 在 $t = 0$ 时的瞬时冲击（$1.5 \times 2 = 3$、$1.5 \times 4 = 6$），与扰动大小无关。$0.5, 0.5$ 与 $1, 1$ 档峰值只有 1.646、1.654，是因为内环增益本就小，冲击小；代价是峰值偏差大、恢复慢。**收益与阀位冲击都随内环增益单调上涨，没有免费的午餐。**

工程上取哪一档？取 $2, 4$ 而不是 $4, 8$：前者的峰值偏差 0.0157 已比单回路好 11.8 倍，阀位峰值 3.000 还能靠加长行程来容；后者的收益只多一倍，阀位却再翻一倍。若阀门行程只有 ±1.2，两档都不可行，应先做 §45.9 的设

定值滤波，把冲击压下来。这就是 §45.1.5“内环越快越好”是误解的定量依据。

45.4.4 外环扰动的对照

把同一幅值 -0.5 的阶跃改加到 G_2 输入端（模拟物料入口温度变化），结果：单回路峰值偏差 0.1888、恢复 12.420 s；串级 0.1787、恢复 13.370 s。

串级略好 5%，但恢复反而慢了近 1 s。这 5% 来自参数差异（外环等效对象略有不同），不是结构优势；恢复变慢则是因为 r_1 到 u 之间多了内环这一环动态。**对内外环之间的扰动，串级没有可用的机理**，§45.1.2 的判断在这里得到验证。

这条结论在现场很有用：如果主变量波动的主因是进料温度而不是蒸汽压力，那么上串级是选错了工具，应该考虑前馈（第 46 章）而不是串级。

45.4.5 主副时间常数分离度

串级的收益依赖主、副对象的时间尺度分离。固定控制器参数，只改主对象主导时间常数 T_1（$G_2 = 1/[(T_1 s + 1)(s + 1)]$），结果见图 45-4。

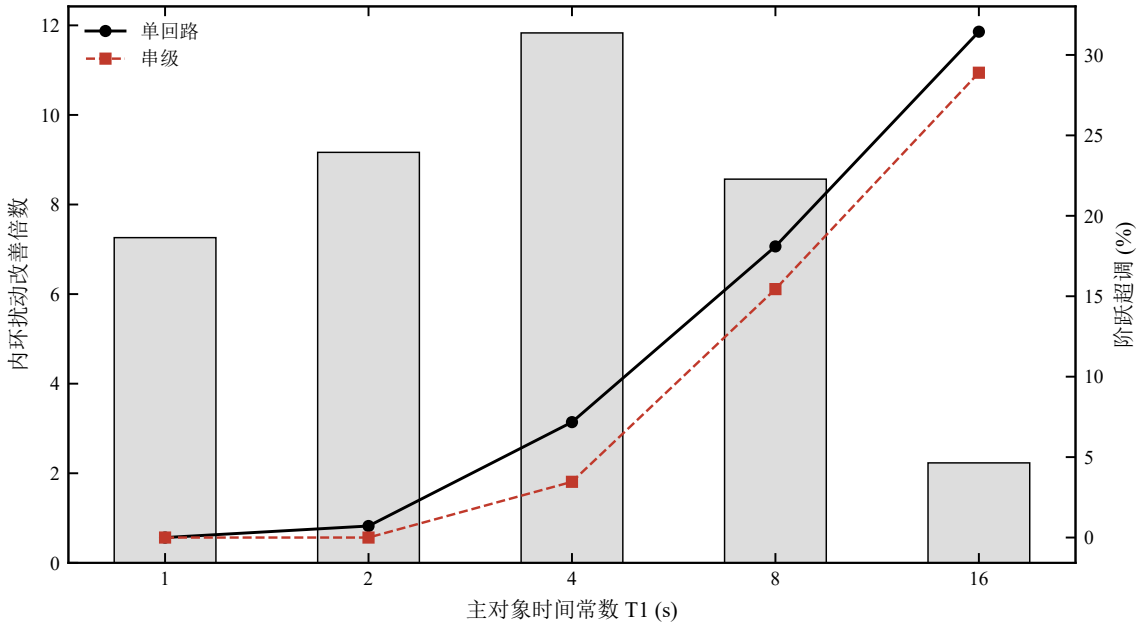

图 45-4　主对象时间常数与串级收益：分离度适中（T1≈4 s）时改善倍数最大，过大或过小都变差

T_1 (s)	单回路偏差	串级偏差	改善倍数	单回路超调	串级超调
1	0.2246	0.0309	7.26	0.00%	0.00%
2	0.2100	0.0229	9.16	0.72%	0.00%
4	0.1855	0.0157	11.83	7.18%	3.46%
8	0.1432	0.0167	8.57	18.10%	15.44%
16	0.2430	0.1089	2.23	31.44%	28.89%

表 45-5 的形状是一个倒 U，但两侧的原因不同。

左侧（$T_1 = 1$–2 s）：主对象本身就快，外环可以把带宽调到较高频段，ω_{c2} 逼近 ω_{b1}，带宽比从 11 掉到 3 附近，内环的抑制能力来不及展开。此时串级仍是单回路的 7–9 倍，但绝对偏差都在 0.03 以下，两者的工程差别已经不大。

峰值在 $T_1 = 4$ s：主副时间常数比 8，带宽比 11.37，改善 11.83 倍，正好是本例中“内环足够快、外环又足够慢”的甜点。

右侧（$T_1 = 8$–16 s）：主对象越来越慢，两边的绝对偏差都开始抬头（$T_1 = 16$ 时串级偏差 0.1089，是 $T_1 = 4$ 时的 7 倍）。改善倍数掉到 2.23 不是内环失效，而是慢对象把扰动“积分”了更长时间，任何内环抑制都要经过这个慢惯性才能体现。**串级改变的是扰动进入主变量的入口，改变不了主对象自身的惯性**，这是它在极慢对象上收益有限的原因。

工程含义：副对象与主对象的时间常数比在 5–10 之间时，串级最划算；比值小于 3 说明副变量选得太慢，应换测量点；比值大于 20 说明主对象太慢，串级虽有效，但应同时考虑前馈（第 46 章）或从工艺上减小对象惯性。

45.4.6 频域校核

把 §45.4.2–§45.4.4 的时域结论换到频域，只需三个数：内环闭环带宽 ω_{b1}、外环开环穿越频率 ω_{c2}、带宽比 r_b。

本章基准参数下，$\omega_{b1} = 4.005$ rad/s，$\omega_{c2} = 0.3523$ rad/s，$r_b = 11.37$。按式 (45-10)，外环穿越频率处的 $|S_1| \approx 0.3523/4.005 \approx 0.088$，即内环扰动在这个频段被压到不足 9%，外环因此只损失不到 5° 的相位裕度。

把内环参数降到 $0.5, 0.5$，$\omega_{b1} = 0.439$ rad/s，此时 $|S_1| \approx 0.2949/0.439 \approx 0.67$，内环几乎不抑制扰动，且外环看到的模型误差高达 67%，相位裕度被吃掉大半——这解释了表 45-4 第一行“恢复反而更慢”的现象。

频域校核的好处是不必反复跑时域仿真：整定完内环，算出 ω_{b1}，与设计的外环 ω_{c2} 一比，就能预判串级是否有效。时域仿真用来验证，频域比值用来设计，两者分工明确。

45.4.7 跟踪与抗扰的折中

把 §45.4.2–§45.4.4 的三张表并排放，可以得到一张“该不该用串级”的决策图。同一个算例，三种典型工艺需求，收益方向完全不同。

需求 A：频繁换牌号，设定值阶跃多。 串级把超调从 7.18% 降到 3.46%，调节时间从 10.920 s 降到 10.010 s，代价是阀位峰值从 1.805 涨到 3.000。若阀门有余量，这笔交易划算：超调减半意味着换料时更少出废品。若阀门没有余量，串级反而不可用，因为冲击会先撞限幅。

需求 B：蒸汽压力波动频繁，设定值基本不变。 这是串级的“主场”。内环扰动下峰值偏差 0.1855→0.0157，改善 11.8 倍，恢复时间从 12.990 s 变成“未出带”。此时阀位冲击只发生在开车阶段，稳态运行时阀位动作幅度反而更小（内环把扰动就地消化，不必等主变量偏了才动）。

需求 C：进料条件波动频繁，蒸汽压力稳定。 外环扰动下 0.1888→0.1787，差别 5%，恢复时间还慢 1 s。此时串级不划算：多了一套测量与调试，换来的只有 5%。

三种需求的差别，用一句话概括：**串级买的是“内环扰动”的抑制能力，其他通道的收益都是副产品或噪声。** 决策时先做扰动溯源——现场连续记录一周的主变量与可能的扰动源，看哪一路的相关性最强；相关性最强的那一路若落在阀后（内环之内），串级值得做；落在进料侧（内外环之间），前馈更合适；落在环境或测量上，先解决仪表问题，任何结构都救不了。

这张“决策图”还可以反过来用：若已经上了串级但收益不明显，先别怀疑参数，先看扰动到底在哪条通道。本章 §45.11.5 的三个误用案例，都是这一步没做。

45.4.8 手算预估与仿真的偏差

设计阶段常需要在不跑仿真时粗估性能。用一阶加纯滞后近似外环的等效对象 G_2T_1，按第 44 章的 IMC 规则可以估出 K_{p2}、T_{i2}；用 S_1 的低频近似 $|S_1| \approx \omega/\omega_{b1}$ 可以估抑制倍数。两处预估在本章算例上的偏差方向如下。

外环增益：G_2T_1 的稳态增益是 0.667，若按 G_2 的增益 1 去整定，K_{p2} 会偏小 33%。本章 $K_{p2} = 1.5$ 是按等效增益 0.667 反算的，若误按 1 算，会得到 $K_{p2} = 1.0$，响应明显偏慢。**误差来源是把内环当成了理想 1:1 跟随**，而实际 $T_1(0) = K_{p1}/(1 + K_{p1})$。

抑制倍数：按 $|S_1| \approx \omega/\omega_{b1}$ 在穿越频率处估得 $1/r_b = 0.088$，即抑制约 11.4 倍；实测 11.8 倍，偏差 3%。这个近似在 $r_b > 5$ 时相当准，可以作为设计阶段的快速估算。

超调：按二阶近似（PM 65.56° 推阻尼比约 0.65）估超调约 7%，实测 3.46%，预估偏保守。原因是外环实际是三阶（G_2 二阶 + T_1 一阶），高阶极点进一步压低了超调。**手算预估宁可按偏保守取**，投运后再用实测修正。

这三处偏差指向同一条经验：**串级的手算预估，误差主要来自"忘记内环不是理想跟随"**。把 $T_1(0)$ 与 $|S_1|$ 这两个因子代进去，误差就能压到 10% 以内；忽略它们，误差可以到 30% 以上。

45.4.9 设定值的其他形状

本章的仿真都用阶跃设定值，因为它最容易比较、指标定义最清楚。工程上还有斜坡与正弦两类设定值，串级在它们上面的表现与阶跃不同，需要单独说明。

斜坡设定值（程序升温、匀速变负荷）。 斜坡跟踪的稳态误差由系统的"型别"决定：外环含积分，系统是 I 型，斜坡输入下存在有限的稳态误差，大小约 $1/K_v$，K_v 由外环增益与积分时间决定。**串级不改变系统型别**——内环再多一个积分器，也只是把内环变成 I 型，外环看到的等效对象仍是 0 型（T_1 的稳态增益有限），整体仍是 I 型。所以斜坡误差主要靠加大 K_{p2} 或减小 T_{i2} 来压，与内环快慢关系不大。

串级在斜坡上的真正好处是**动态滞后更小**：内环快速跟随 r_1，主变量不会因为副回路的惯性而额外落后。本章的阶跃数据里，串级上升时间 3.720 s 比单回路 3.523 s 略慢，这是设定值冲击被 T_1 的 0.667 增益压小的结果；换成斜坡，冲击不存在，串级的滞后优势才会显现。这一点本章没有仿真数据，属于由结构推出的定性判断，读者若要用于定量设计，应先用 §45.12 的代码改成斜坡输入重跑。

正弦设定值（周期性负荷、往复工艺）。 稳态跟踪误差的幅值等于 $|S_2(\mathrm{j}\omega)|$ 乘以输入幅值，ω 越接近外环带宽，误差越大。串级在这里的作用是双重的：内环把中频段的相位滞后清掉，让外环的 $|S_2|$ 在穿越频率附近更小；但同时内环本身在 $\omega > \omega_{b1}$ 时趋近于 1，对高频正弦没有任何帮助。所以正弦设定的跟踪精度，在频率低于外环带宽时串级略优，高于内环带宽时两者相同。

脉冲设定值（短时切换、手动干预）。 脉冲宽度小于外环调节时间时，外环来不及响应，主变量基本不动；此时串级与单回路的行为都由内环决定，内环的设定值滤波（§45.9.1）会进一步削弱响应。这类工况下不应期待串级带来改善，也不应把"脉冲没响应"当成故障。

三类设定值合起来说明一件事：**串级的设计目标是抗扰，不是跟踪**。跟踪性能由外环决定，串级只是通过"减少内环滞后"间接帮一点忙。若工艺的主要矛盾是跟踪（例如频繁的程序升温），优化方向应是外环的型别与前馈，而不是继续加内环增益。

45.5 离散情形

§45.2.6 给出了两段位置式 PID 的差分方程，本节讨论它落到 PLC 或 DCS 里之后才会出现的三个问题：内环周期能不能放宽、外环周期能放到多慢、两个周期怎么同步。

45.5.1 两段回路的实现差异

串级在程序里不是一个 PID 加一个开关，而是两段独立的 PID 运算，各自维护三样状态：积分累加项、上一拍误差（供微分用）、上一拍输出（供无扰切换用）。两段的差别集中在三处。

积分项的时间基准不同。 内环按 T_{s1} 累加，外环按 T_{s2} 累加。若两段共用同一个累加函数而把周期写死成 0.01 s，外环的实际积分时间会被拉长 N_r 倍——表现为“外环怎么调都嫌慢”，操作工于是继续加 K_{p2}，最后在外环上引入振荡。这是串级投运最常见的软件缺陷，且从参数表上看不出来。

微分项一般只在外环用。 副回路信号（流量、压力）噪声大，微分会把它放大到阀上；而且内环本身已经够快，不需要微分再提相位。若外环也带微分，要注意微分增益与内环带宽的关系：内环带宽以外的频段，$T_1 \approx 1$，外环的微分会对副回路噪声直接起作用。

保持环节有两个。 外环输出 r_1 在每个 T_{s2} 内保持不变，供内环反复读取；内环输出 u 在每个 T_{s1} 内保持不变，送到阀门。前者是 §45.2.6 说的多速率，后者是常规的零阶保持。两个保持叠加，外环看到的等效滞后约为 $T_{s2}/2 + T_{s1}/2$ 再加一拍的运算延迟，这是 §45.5.4 要定量讨论的对象。

45.5.2 内环采样周期

内环周期由内环闭环带宽决定，判据与第 44 章一致：

$$T_{s1} \le \frac{1}{10\,\omega_{b1}} \tag{45-18}$$

本章 $\omega_{b1} = 4.005$ rad/s，即上限约 0.025 s，仿真取 0.01 s 有余量。采样保持引入的等效相位滞后约为 $\omega T_{s1}/2$，在 ω_{b1} 处只有 $4.005 \times 0.01/2 \approx 0.02$ rad，约 1.1°，可忽略。

放宽到 0.05 s 会怎样？此时 $\omega_{b1} T_{s1}/2 = 0.10$ rad，约 5.7°，看似仍可接受；但内环增益较高时，穿越频率附近的相位余量本就只有三四十度，5.7° 的额外滞后大致会把实际带宽压到 3 rad/s 附近，带宽比随之从 11.37 掉到 8 上下。**内环周期不是“够用就行”，它会直接改写 §45.3.4 算出的带宽比。**

工程上还要考虑副变量测量的滤波时间。流量变送器常带 0.1–0.2 s 的一阶滤波，这个滤波在内环闭环之内，等效于把副对象的时间常数加大，同样会压低 ω_{b1}。选型时应把滤波时间算进副对象，而不是事后用提高 K_{p1} 去补偿。

45.5.3 外环周期与多速率

外环周期决定 $N_r = T_{s2}/T_{s1}$。图 45-5 与表 45-6 给出固定内环 0.01 s、只改 N_r 的扫描结果。

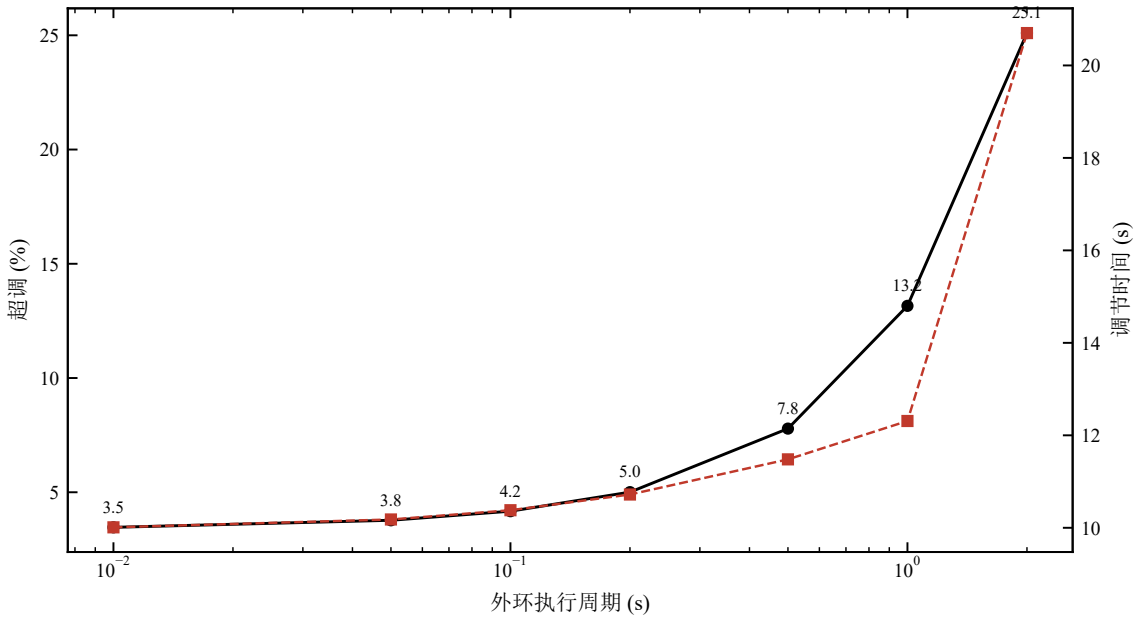

图 45-5　外环执行周期对跟踪性能的影响：0.2 s 以内几乎无损，0.5 s 起超调明显抬头，2 s 时劣化到 25%

N_r	外环周期 (s)	超调	上升时间	调节时间
1	0.01	3.46%	3.720 s	10.010 s
5	0.05	3.77%	3.697 s	10.180 s
10	0.10	4.17%	3.670 s	10.380 s
20	0.20	5.01%	3.619 s	10.720 s
50	0.50	7.79%	3.498 s	11.480 s
100	1.00	13.16%	3.391 s	12.310 s
200	2.00	25.10%	3.420 s	20.700 s

表 45-6 的读法：外环周期在 0.2 s 以内（$N_r \le 20$）时，超调从 3.46% 涨到 5.01%，几乎没有代价；0.5 s 时 7.79%，开始可感；1 s 时 13.16%，已经超过单回路的 7.18%；2 s 时 25.10%，不可接受。

上升时间反而随周期放宽而略降（3.720→3.420 s），这是“外环动作变粗、等效增益变大”的表现，不能当作改善——同一张表里调节时间从 10.010 s 涨到 20.700 s，才是真实代价。

按 §45.3.5 的经验 $N_r \approx r_b/3$，本章 $r_b = 11.37$，$N_r \approx 4$，与表中“$N_r \le 20$ 几乎无损”的结论相容且更保守。现场若算力充裕，取 $N_r = 5$–10 即可，不必追求内外环同周期。

45.5.4 多速率引入的附加滞后

把表 45-6 的劣化折算成相位，可以对上号。外环的零阶保持等效滞后 $T_{s2}/2$，加上一拍运算延迟 T_{s2}，合计 $1.5T_{s2}$。在外环穿越频率 $\omega_{c2} = 0.3523$ rad/s 处：

- $T_{s2} = 0.01$ s：滞后 0.0053 rad，约 0.3°，可忽略；
- $T_{s2} = 0.2$ s：滞后 0.106 rad，约 6°，对应超调从 3.46% 涨到 5.01%；
- $T_{s2} = 2$ s：滞后 1.06 rad，约 60°，已接近把相位裕度吃光，对应超调 25.10%、调节时间翻倍。

这三组数与表 45-6 一一对应。**多速率的代价不是“外环算得少所以不准”，而是“外环的保持与延迟在穿越频率处贡献了相位滞后”**，本质与第 44 章讨论的纯滞后相同。

由此得到外环周期的上限估计：

$$T_{s2} \le \frac{\varphi_{\text{allow}}}{1.5\,\omega_{c2}} \tag{45-19}$$

若允许附加滞后 15°（0.26 rad），$\omega_{c2} = 0.3523$ rad/s，则 $T_{s2} \le 0.49$ s。这与表 45-6 中 0.5 s 处超调开始抬头的位置吻合，可作为 N_r 的独立校核。

45.5.5 同步与实现细节

多速率实现有四条硬要求。

其一，外环输出的时间戳。 内环每拍都要知道当前的 r_1 是哪个时刻算出来的。若两个任务在不同优先级的任务里跑，外环刚写完 r_1、内环读到一半，可能拿到新旧混合的值（16 位机上的半字撕裂）。做法是双缓冲加标志位，或把 r_1 的写入放在内环任务的临界区里。

其二，两个积分项各自独立。 外环积分只在外环执行时刻更新，内环积分只在内环执行时刻更新。外环被限幅时，外环积分停止累加（或按 §45.10 的回算处理），但不影响内环积分。

其三，外环手自动切换用当前 r_1。 切自动的瞬间，外环的输出应从内环当前的设定值起算，否则 r_1 会跳变，内环把它当成设定值阶跃，阀位立刻冲击一次。这与第 44 章的无扰切换是同一件事，只是被控对象从阀变成了内环。

其四，外环周期不能整除内环周期时取整。 若 $T_{s2} = 0.25$ s、$T_{s1} = 0.01$ s，$N_r = 25$ 正好整除；若除不尽（如 $T_{s2} = 0.1$ s、$T_{s1} = 0.03$ s），必须按累计时间触发，不能简单地“每三拍执行一次外环”，否则外环的实际周期会在 0.09 s 与 0.12 s 之间抖动，等效于给外环加了一份周期性的参数扰动。

45.5.6 两个现场现象

现象一：主变量呈阶梯状。 外环周期过长时，r_1 每 T_{s2} 才变一次，主变量的响应曲线在示波器上呈明显的台阶。台阶本身不是问题，问题是台阶的宽度接近外环闭环时间常数时，调节时间会成倍增加（表 45-6 中 $N_r = 200$ 的 20.700 s 就是例子）。

现象二：阀位在台阶时刻抖动。 内环增益高时，r_1 的每个台阶都会被内环放大成一次阀位跳变。此时应先加内环设定值滤波（§45.9），再考虑缩短外环周期——后者要动整个控制器的任务调度，前者只改一个参数。

45.5.7 量化、噪声与死区

离散实现的另外三个“非理想”因素，在串级里会被内环放大，需要单独交代。本章仿真没有逐一扫描它们，但可以给出判据与量级。

量化误差。 12 位 A/D 在 4–20 mA 量程上的分辨率约为满量程的 1/4096；若副变量量程是 100 m³/h，量化台阶约 0.024 m³/h，相当于归一化后的 2.4×10^{-4}。内环 $K_{p1} = 2$ 时，这个台阶在阀位上被放大成 0.0005 的跳变，可以忽略。但若内环增益提到 20（小量程流量回路常见），台阶就变成 0.005，阀位会在相邻两个码值之间来回跳，表现为阀位的高频抖动。**判据是 $K_{p1} \times$ 量化台阶 $\le$ 阀门死区的 1/3**，超过就要加副变量滤波或降低增益。

测量噪声。 噪声与量化的区别是它连续分布、频带较宽。内环对噪声的传递函数是 $C_1/(1 + C_1 G_1)$，在低频近似为 $1/G_1$，在高频趋近 C_1。也就是说，**噪声主要从内环的高频段进入阀位**，且与 K_{p1} 成正比。本章 §45.1.5 用阀位峰值从 3.000 涨到 6.000 说明“内环越快越费阀”，噪声是同一件事的另一面。

阀门死区与回差。 死区在闭环内会引起极限环，振幅与死区宽度、内环增益、对象时间常数都有关。串级的好处是死区被包在内环里，外环看不到；坏处是极限环的振荡频率在内环带宽附近，可能激发机械共振。判据是**内环带宽应避开阀门与管路的机械固有频率**，通常要求 ω_{b1} 低于最低阶结构频率的 1/3。

这三条的共同结论是：**内环带宽不是越高越好，它有一个由仪表分辨率、噪声水平、机械特性共同决定的上限**。本章算例的 4.005 rad/s 离这些上限还很远，所以可以放心提高；现场若副变量量程小、噪声大、管路有共振，上限可能只有 1–2 rad/s，此时应重新评估带宽比能否达标——达不到就得换测量方案，而不是硬调参数。

45.6 稳定性与性能

稳定性和性能在串级里不是两件事：内环的稳定裕度决定了外环能拿到多少“等效对象精度”，而等效对象的精度又决定了外环能把带宽推到多高。本节用三把尺子把这层关系量出来：带宽比、扰动抑制倍数、增益失配鲁棒性。

45.6.1 三把尺子

尺子一，带宽比 $r_b = \omega_{b1}/\omega_{c2}$。它衡量内外环的分离度，决定内环的残差能不能被外环当成“小误差”。$r_b \geq 5$ 合格，$r_b \geq 10$ 优良。

尺子二，扰动抑制倍数。 同一幅值的内环扰动下，单回路与串级的峰值偏差之比。它衡量串级的实际收益，与 r_b 同向但非线性。

尺子三，失配鲁棒性。 副对象增益偏离设计值时，超调与调节时间的变化范围。它衡量串级在现场“标定不准”时还能不能用。

三把尺子互不替代：r_b 大不等于抑制倍数大（还取决于扰动频段），抑制倍数大不等于鲁棒（内环增益高会放大失配敏感性）。

45.6.2 带宽比与抑制能力

图 45-6 把表 45-4 的两列画在一起：横轴是带宽比，左轴是峰值偏差，右轴是恢复时间。

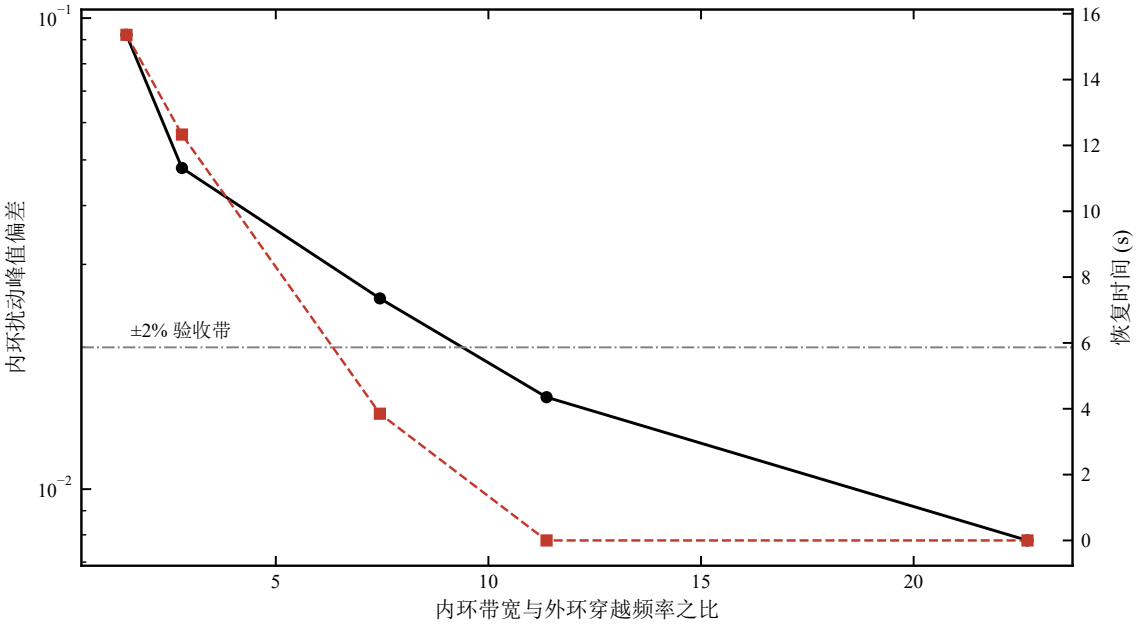

图 45-6　带宽比与扰动抑制：峰值偏差随带宽比单调下降，恢复时间在 r_b≈7 附近最优

曲线形状给出两个结论。

其一，**峰值偏差随 r_b 单调下降，但边际收益递减**。r_b 从 1.49 到 2.79，偏差从 0.0922 降到 0.0481（降 48%）；从 7.45 到 11.37，从 0.0254 降到 0.0157（降 38%）；从 11.37 到 22.68，从 0.0157 降到 0.0078（降 50%），但这一段的阀位峰值从 3.000 跳到 6.000。**用阀位换偏差的兑换率在恶化**，这就是 §45.4.3 选 $2,4$ 档的理由。

其二，**恢复时间在 $r_b \approx 7$ 附近有一个最优**（$2,2$ 档 3.850 s），再大反而"未出带"。这不是矛盾：恢复时间衡量的是"出带后多久回来"，而 r_b 大时峰值偏差本来就小，根本没出带，恢复时间失去意义。读这张图要同时看两条曲线，只看一条会得出错误结论。

45.6.3 稳定性的结构解释

串级的闭环特征方程由两次闭合得到。内环闭合后：

$$1 + C_1(s)G_1(s) = 0 \tag{45-20}$$

外环再闭合：

$$1 + C_2(s)G_2(s)T_1(s) = 0 \tag{45-21}$$

式 (45-21) 说明一件重要的事：**外环的稳定性以内环的稳定性为前提**。若内环不稳定，T_1 含右半平面极点，外环无论怎么调都不稳定；反之，内环稳定而外环不稳定，把外环切手动、内环仍能独立工作。这就是 §45.3.6"内环先投自动"的稳定性依据——它保证任何时候都有一个稳定的回路在守。

外环的设计误差来自 $T_1 \neq 1$，即式 (45-9) 的乘性误差 $-S_1$。按小增益定理，闭环鲁棒稳定的充分条件是

$$|T_2(\mathrm{j}\omega)\, S_1(\mathrm{j}\omega)| < 1, \qquad \forall \omega \tag{45-22}$$

其中 $T_2 = C_2G_2T_1/(1 + C_2G_2T_1)$ 是外环的补灵敏度。低频段 $|T_2| \approx 1$、$|S_1|$ 很小，条件宽松；高频段 $|S_1| \to 1$ 但 $|T_2|$ 已滚降，条件同样宽松；**最紧的位置在 T_2 的穿越频率附近**，那里 $|T_2| \approx 1$、$|S_1| \approx \omega_{c2}/\omega_{b1} = 1/r_b$。于是式 (45-22) 近似退化为 $r_b > 1$——这正是"带宽比至少大于 1 才可能稳定"的定量版本，而 5 倍准则是给足裕度后的工程取值。

45.6.4 增益失配鲁棒性

现场最常遇到的失配是副对象增益。阀门口径选大、流量计标定漂移、介质密度变化，都会让 G_1 的实际增益偏离设计值 30%–100%。图 45-8 与表 45-7 给出扫描结果。

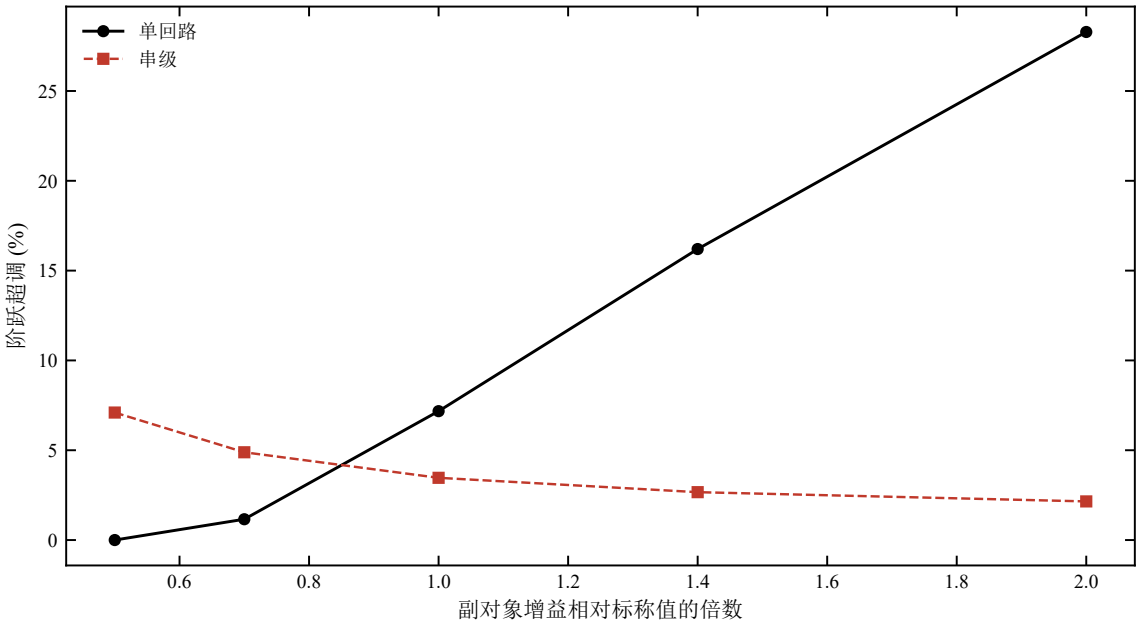

图 45-8　副对象增益失配：单回路超调随增益单调恶化，串级反向下降，鲁棒性明显更好

增益系数	单回路超调	单回路 t_s	串级超调	串级 t_s
0.5	0.00%	14.840 s	7.10%	10.900 s
0.7	1.16%	8.510 s	4.89%	10.460 s
1.0	7.18%	10.920 s	3.46%	10.010 s
1.4	16.20%	12.570 s	2.67%	9.560 s
2.0	28.29%	14.260 s	2.15%	8.970 s

表 45-7 最醒目的两列是超调。单回路从 0.00% 一路涨到 28.29%，随增益单调恶化，这是单回路“按名义增益整定”的固有弱点；串级反而从 7.10% 降到 2.15%，随增益单调改善。

串级的反向趋势有清楚的机理：G_1 增益变大时，内环回路增益 C_1G_1 变大，T_1 更快、S_1 更小，等效于外环的对象更接近 1、带宽比更大。**失配在内环里被“吸收”成了更快的响应，而不是更大的回路增益**，这是串级鲁棒性的来源。

但要注意增益变小时的代价。系数 0.5 时串级超调 7.10%、调节时间 10.900 s，比名义工况差；单回路此时超调为 0，只是上升时间被拉到 8.302 s。也就是说，**“串级的超调不随增益恶化”应理解为“变化范围窄”（2.15%–7.10%），而不是“任何工况都优于单回路”**。增益偏小的工况下，单回路更平稳但更慢，串级更快但略超调，如何取舍取决于工艺更怕哪一个。

工程含义：若副对象增益的不确定度超过 ±40%，应优先用串级而不是单回路，因为单回路的超调会随增益线性恶化；若增益很确定且偏小，单回路的平稳性反而更好。

45.6.5 性能边界

把三把尺子合起来，可以得到串级的性能边界：内环带宽 ω_{b1} 受副对象时间常数、采样周期、阀位冲击三重限制；外环带宽 ω_{c2} 受主对象时间常数与外环周期的限制；两者的比值 r_b 只能在 5–20 之间取值，再大就要用阀位和噪声去换。

本章算例的 $r_b = 11.37$ 已在优良区间，继续提高内环增益到 $4,8$ 档，r_b 到 22.68，峰值偏差只降一半，阀位翻倍——越过边界了。

这条边界对设计的意义是：**串级不是“调得越猛越好”，而是在 $r_b \approx 10$ 附近找一个阀位、噪声、抗扰三者的平衡点**。第 44 章讲 PID 整定时说“增益调到振荡边缘再回退一半”，串级的内环整定同理，只是“振荡”的表现从主变量变成了副变量。

45.6.6 裕度折算：带宽比买到了多少度相位

式 (45-22) 给出的是稳定性的定性条件，本节把它换成可以直接读的裕度数字。对外环开环 $L_2 = C_2 G_2 T_1$ 求幅值裕度与相位裕度，内环从慢到快五档，结果如下（外环固定 $1.5/4$ s）：

- 内环 $0.5/0.5$，$r_b = 1.49$：GM 18.06 dB，PM 45.90°，$\omega_{c2} = 0.2949$ rad/s；
- 内环 $1/1$，$r_b = 2.79$：GM 20.56 dB，PM 55.44°，$\omega_{c2} = 0.3262$ rad/s；
- 内环 $2/2$，$r_b = 7.45$：GM 24.08 dB，PM 62.17°，$\omega_{c2} = 0.3416$ rad/s；
- 内环 $2/4$，$r_b = 11.37$：GM 22.50 dB，PM 65.56°，$\omega_{c2} = 0.3523$ rad/s；
- 内环 $4/8$，$r_b = 22.68$：GM 27.60 dB，PM 68.02°，$\omega_{c2} = 0.3532$ rad/s。

三列数字各说一件事。

带宽比买到的相位。 PM 从 45.90° 升到 68.02°，共 22°。这 22° 不是凭空来的：内环越慢，T_1 在 ω_{c2} 附近的相位滞后越大，外环开环的相位曲线被往下压，PM 变小。反过来说，r_b 从 1.49 提到 11.37，等于把外环的相位裕度从“勉强及格”拉回到“从容”。**这就是“内环要快”在频域上的真实含义：不是内环自己好看，而是它别在外环的穿越频率处添乱。**

PM 与超调对得上。 45.90° 对应表 45-8 中 $0.5, 0.5$ 档的 22.70% 超调；65.56° 对应 $2, 4$ 档的 3.46%。二阶系统的经验关系（PM 60° 附近超调约 10%，PM 70° 附近约 5%）在这里基本适用，说明外环的主导动态仍是二阶型。

GM 不是单调的，但都够用。 五档的幅值裕度在 18–28 dB 之间，$2/4$ 档的 22.50 dB 比 $2/2$ 档的 24.08 dB 略低，这是内环积分（$K_{i1} = 4$）在低频段多出的相位滞后造成的。18 dB 以上的 GM 对过程控制已足够（一般要求 6–10 dB），所以 GM 不是本章的约束项；真正限制性能的是 PM 与阀位冲击。

这组数字还可以当“在线体检”用：投运后若无法做频响测试，可以用设定值阶跃的超调反推 PM，再对照 r_b。超调 20% 以上对应 PM 不足 50°，此时先查内环带宽是否掉下来了（滤波、采样周期、阀门卡涩都会导致），而不是先去动外环参数。

45.6.7 时域—频域对照表

把本章的时域指标与频域指标放在一起，可以验证三条换算关系是否成立。这不是为了凑公式，而是为了在现场只能测其中一个域时，能用另一个域的数字做判断。

第一条，增益裕度与失配容忍度。 $2/4$ 档的 GM 是 22.50 dB，对应回路增益可以再乘 $10^{22.5/20} \approx 13.3$ 倍才到临界。表 45-7 把副对象增益加到 2.0 倍（$+6.02$ dB），系统仍在稳定区，超调只有 2.15%，与 GM 的余量一致。若 GM 只有 6 dB（4 倍），2.0 倍失配就已经吃掉一半裕度，动态会明显变差。**判据：GM 应至少是预期失配倍数的 2 倍（按 dB 计约多 6 dB）。**

第二条，相位裕度与超调。 PM 65.56° 对应 3.46% 超调，PM 45.90° 对应 22.70%。二阶近似的经验是 PM 每降 10°，超调约增 5–8 个百分点；本章从 65.56° 到 45.90° 降了 19.66°，超调增了 19.24 个百分点，略高于经验

值，因为内环变慢同时改变了外环的对象阶次（T_1 的低频近似不再成立）。

第三条，带宽比与抑制倍数。 r_b 从 1.49 到 11.37，峰值偏差从 0.0922 降到 0.0157，比值 5.87；r_b 比值 7.63。抑制改善慢于带宽比改善，因为扰动的主频段并不完全落在 $|S_1| \approx \omega/\omega_{b1}$ 的近似区间内。这条关系只宜作数量级判断，精确倍数仍要看时域。

三条关系合起来给出一套“单域推断”的方法：只有频域数据时，用 GM 判失配容忍、用 PM 判超调；只有时域数据时，用超调反推 PM、用失配试验反推 GM。两者不必都测，但**测一个、推一个之后要用另一个校核一次**，否则容易把参数误差当成结构问题。

45.6.8 扰动频谱与抑制带宽

§45.6.2 的横轴是带宽比，隐含假设是“扰动的主要能量落在内环能抑制的频段内”。这条假设值得单独检验，因为现场扰动往往不是单一频率。

把内环灵敏度 $|S_1(\mathrm{j}\omega)|$ 画出来，形状是：低频接近 0（内环含积分时稳态为 0，纯 P 时停在 $1/(1+K_{p1})$），在 ω_{b1} 附近升到 $1/\sqrt{2}$，高频趋于 1。也就是说，**内环只抑制 $\omega < \omega_{b1}$ 的扰动，对 $\omega > \omega_{b1}$ 的扰动不但不抑制，还会因为相位滞后略有放大**。

由此可以推出三条实用结论。

其一，慢扰动最划算。 阀后压力的缓慢漂移（周期几十秒到几分钟）频率远低于内环带宽，$|S_1|$ 接近 0，串级能把它们几乎完全消掉。本章的阶跃扰动能量集中在 1 rad/s 以下的频段，$|S_1|$ 在这一段从 0.09 变到 0.24，所以抑制倍数 11.8 而不是无穷大。

其二，快扰动靠滤波，不靠串级。 高频噪声（阀门颤振、泵的脉动）频率接近或超过 ω_{b1}，内环对它无能为力，反而会把它传进阀位。这类扰动要在测量侧解决（滤波、加大取样容积、改用更稳的测量原理），不能指望提高 K_{p1}。

其三，扰动的“阶跃”与“正弦”差别很大。 本章用阶跃做试验，是因为阶跃包含全频段能量、便于比较；实际扰动若是周期性正弦（例如往复泵的脉动），主频决定一切，此时应把内环带宽对准该频率的 3–5 倍，而不是笼统地追求“越高越好”。

这条视角补上了 §45.6.2 的一个缺口：带宽比衡量的是“内环能抑制多快的扰动”，而不是“能抑制所有扰动”。设计时先估扰动的主频段，再定 ω_{b1}，比先定参数再看效果要高效得多。

45.6.9 扰动位置不改变稳定裕度

§45.6.4 的失配表与 §45.6.6 的裕度表都是在本章的工况下标定的，读者容易产生一个疑问：如果扰动不是加在内环，而是加在外环，裕度会不会变？答案是不会。把 §45.2.1 的两条通道重新写一遍，就能看清原因。

内环扰动（加在 G_1 输入端）下，主变量为

$$y_2 = T_2\, r + S_2\, G_2\, G_1\, S_1\, d_1$$

外环扰动（加在 G_2 输入端）下，主变量为

$$y_2 = T_2\, r + S_2\, G_2\, d_2$$

两式的分母完全相同，都是 $1 + C_2 G_2 T_1$；扰动只改变分子。增益裕度、相位裕度、外环穿越频率都由分母（即环路增益 L_2）决定，所以**无论扰动加在哪里、甚至不加扰动，裕度的数字都是同一组**：本章 $2/4$ 档的 22.50 dB、65.56°、0.3523 rad/s 对内环扰动和外环扰动同样成立。

这个事实有三层用处。

其一，裕度可以在“不打扰生产”的条件下测。 现场做阶跃扰动试验往往要动工艺，而频率特性可以用继电反馈或辨识在正常工况下得到（第 44 章），两者给出的是同一组数。不必为了测裕度专门制造一次扰动。

其二，扰动的差别全落在“峰值偏差与恢复时间”上。 内环扰动那一式的分子含 S_1，外环扰动那一式的分子不含，于是同样一组参数对内环扰动改善 11.8 倍（0.1855→0.0157），对外环扰动只改善 5%（0.1888→0.1787）。**同一组裕度可以对应两种截然不同的抗扰表现**，这是本章最容易被忽略的一点：裕度只保证“环路闭合后不发散”，它不区分抗哪种扰动。

其三，扰动一旦把执行器推进饱和，上面的线性结论就失效。 阀位限到 ±1.2 后饱和占比 62.8%，超调从 3.46% 涨到 22.59%（表 45-14），此时用 GM、PM 解释响应已经没有意义，必须回到 §45.10.1 讨论抗饱和。也就是说，扰动位置不影响线性裕度，但影响系统是否留在“线性区”里——**幅度大的扰动会把问题从频域搬到非线性域**。

由此得到一条设计纪律：**用裕度判稳定，用扰动试验判抗扰，两件事分开做、分别验收**。只测其中一个，很容易把“稳定但抗不住”或“抗得住但快失稳”误判成“整体合格”。

45.7 参数意义与作用

串级有四个可调参数：内环的 K_{p1}、T_{i1}，外环的 K_{p2}、T_{i2}。§45.2 讲的是它们“为什么”有用，本节讲它们“各自管什么”，为 §45.8 的整定顺序做铺垫。所有数字来自 `ch045_sim.py` 第十一段的外环扫描与第八段的内环扫描。

45.7.1 内环 K_{p1} 管带宽

K_{p1} 决定内环带宽，进而决定 §45.6 的 r_b。内环扫描（外环固定 $1.5/0.375$）的结果见表 45-8。

内环 K_{p1}, K_{i1}	超调	上升时间	调节时间	阀位峰值
0.5, 0.5	22.70%	4.079 s	22.630 s	1.646
1.0, 1.0	12.53%	3.796 s	12.880 s	1.654
2.0, 2.0	6.42%	3.786 s	11.510 s	3.000
2.0, 4.0	3.46%	3.720 s	10.010 s	3.000
4.0, 8.0	2.15%	3.898 s	8.970 s	6.000

K_{p1} 从 0.5 加到 4，超调从 22.70% 降到 2.15%，调节时间从 22.630 s 降到 8.970 s——**内环不够快时，外环再准也没用，主变量照样大幅超调**。这就是“先内后外”的定量依据：$K_{p1}=0.5$ 时内环带宽只有 0.439 rad/s，勉强高于外环穿越频率 0.2949 rad/s，带宽比 1.49，等于在主回路里串了一个与自身带宽同量级的滞后。

代价列在最后一列：阀位峰值由 $K_{p1}K_{p2}\Delta r$ 决定，K_{p1} 从 2 提到 4，峰值从 3.000 跳到 6.000。所以 K_{p1} 的选择不是“越大越好”，而是在“带宽比达标”与“阀位有余量”之间取交集，本章的交集是 $K_{p1}=2$。

45.7.2 内环 T_{i1} 管副变量稳态偏差

内环加积分的唯一目的是消掉副变量的稳态偏差，例如流量计零点漂移、阀门死区造成的固定偏差。它不参与快速性，参与的是低频稳定性。

T_{i1} 取小了（小于副对象时间常数），内环在低频就有两个积分器串联的效果，表现为主变量围着设定值缓慢画圈，周期在几分钟量级；T_{i1} 取大了（大于副对象时间常数的 10 倍），消差太慢，等于没加。本章 $K_{i1}=4$ 对应 $T_{i1}=0.5$ s，与副对象时间常数相同，属于偏快的激进配置，用来展示收益上限；工程上更稳的取法是 $T_{i1}=2$–5 s，即 $K_{i1}=0.4$–1.0。

本节不给 T_{i1} 扫描数据，原因是它的效果主要体现在稳态与低频振荡上，而阶跃指标（超调、上升时间）对它不敏感；现场判断 T_{i1} 是否合适，看的是“主变量在长时间运行时有没有缓慢漂移”，而不是阶跃响应曲线。

45.7.3 外环 K_{p2} 管主变量的速度

外环 K_{p2} 决定外环带宽与主变量的响应速度。固定 $T_{i2}=4$ s 扫描，结果见表 45-9。

外环 K_{p2}	超调	上升时间	调节时间	阀位峰值
0.75	0.00%	8.911 s	16.150 s	1.500
1.50	3.46%	3.720 s	10.010 s	3.000
3.00	19.26%	1.906 s	10.100 s	6.000

K_{p2} 翻倍，上升时间减半（3.720→1.906 s），超调从 3.46% 涨到 19.26%，阀位峰值从 3.000 翻到 6.000。这与单回路的 PID 规律完全一致，因为外环本来就是“以 G_2T_1 为对象的单回路”。

值得注意的是调节时间几乎不变（10.010 s 对 10.100 s）：K_{p2} 加倍后响应变快但振荡加剧，两者抵消。这说明**外环增益不是提高“整体速度”的旋钮，而是调整“速度与平稳”的分配比例**；真正决定调节时间的是 T_{i2} 与主对象时间常数的匹配。

阀位峰值同样由 $K_{p1}K_{p2}$ 决定（1.5、3.0、6.0 正好是 $2K_{p2}$），这再次说明串级的控制量冲击是两级增益的乘积，调任何一个都要看另一个。

45.7.4 外环 T_{i2} 管稳态与调节时间

固定 $K_{p2}=1.5$，扫描 T_{i2}，结果见表 45-10。

外环 T_{i2}	超调	上升时间	调节时间	阀位峰值
2 s	29.63%	2.581 s	16.510 s	3.000
4 s	3.46%	3.720 s	10.010 s	3.000
8 s	0.00%	12.391 s	31.000 s	3.000

T_{i2} 的作用是双面的。取 2 s（小于主对象主导时间常数 4 s）时，积分作用过强，超调冲到 29.63%，调节时间反而比 $T_{i2}=4$ s 更长；取 8 s 时，积分太弱，超调虽为 0，但上升时间 12.391 s、调节时间 31.000 s，主变量慢得不可接受。

最优在 $T_{i2}=4$ s 附近，与主对象的主导时间常数同量级。这与第 44 章 IMC 整定的结论一致：T_{i2} 应与被控对象的主导时间常数匹配，而不是“越小消差越快越好”。**串级里外环的对象是 G_2T_1，主导时间常数仍是 G_2 的 4 s，内环几乎不影响这个匹配关系**——这是内环够快时的一个便利：外环可以按 G_2 整定，不必重新辨识。

45.7.5 四个参数的影响总表

表 45-11 把四个参数的作用方向与代价收在一处。“收益”与“代价”两列只写主要方向，非单调的地方单独注明。

参数	主要作用	增大的收益	增大的代价	本章取值
K_{p1}	内环带宽	抗内环扰动、r_b 上升	阀位冲击 $\propto K_{p1}K_{p2}$、噪声放大	2
T_{i1}	副变量消差	消副回路稳态偏差	过小引起低频慢振荡	0.5 s
K_{p2}	外环带宽	主变量响应变快	超调上升、阀位冲击上升	1.5
T_{i2}	主变量消差	消主回路稳态偏差	过大则慢，过小则超调（非单调）	4 s

表的读法：K_{p1} 与 K_{p2} 都影响阀位冲击，二者是乘积关系；T_{i1} 与 T_{i2} 都影响低频行为，但作用在不同回路，调错了会互相掩盖——外环的慢漂移可能是内环 T_{i1} 太小造成的，此时加 T_{i2} 只会让系统更慢。

45.7.6 参数耦合

四个参数不是四个独立的旋钮，有三处强耦合。

耦合一，$K_{p1}K_{p2}$ 与阀位行程。 冲击是乘积，任一加倍都使冲击加倍。若阀门行程受限，应先降 K_{p2}（外环增益降下来，主变量变慢但可控），再考虑降 K_{p1}（内环带宽降下来，抗扰变差）。顺序不能反：先降 K_{p1} 会把带宽比拉到 5 以下，串级失去意义。

耦合二，K_{p1} 与 T_{i1}。 二者共同决定内环的相位特性。K_{p1} 大、T_{i1} 小时，内环在低频有接近 180° 的相位滞后，闭环会出现慢振荡；K_{p1} 小时，T_{i1} 取大一些反而更稳。工程上常用的配比是 $T_{i1} \geq 2T_1$（T_1 为副对象时间常数），本章为了展示上限取了 $T_{i1} = 0.5$ s，实际投运应放大。

耦合三，K_{p2} 与 T_{i2}。 二者共同决定外环的相位裕度。K_{p2} 大时，穿越频率高，T_{i2} 必须相应放大，否则积分相位滞后落在穿越频率附近，超调迅速恶化（表 45-10 中 $T_{i2} = 2$ s 的 29.63% 就是这种情形）。工程上的配比是 T_{i2} 取主对象主导时间常数的 1–2 倍，且随 K_{p2} 增大而适当放大；本章 1.5 配 4 s 正落在这个区间。

理解了这三处耦合，就能明白 §45.8 为什么要定一个固定的整定顺序：四个参数两两耦合，同时调等于在四维空间里盲搜；按“内环 → 外环 → 复核冲击 → 复核带宽比”的顺序，每次只动一个维度，才能收敛。

45.7.7 参数不是常数：负荷与量程的影响

前面把 K_{p1}、K_{p2} 当成固定数，但现场参数会随负荷漂移。漂移有两个来源，机理不同，处理方式也不同。

来源一，对象增益随工况变化。 流量回路的增益与阀前后压差有关：压差大时同样的阀位变化带来更大流量，增益高；压差小时增益低。若设计工况在高压差、实际运行在低压差，内环的实际回路增益只有设计值的一半，带宽比随之下降。表 45-7 的 ×0.5 那一行就是这个情形：串级超调从 3.46% 涨到 7.10%，仍可用，但已明显变差。**这类漂移应通过增益调度（§45.9.3）处理，而不是把 K_{p1} 调到折中值。**

来源二，时间常数随负荷变化。 换热器在低负荷时物流速度慢，主对象时间常数变长；高负荷时变短。时间常数变长等价于相位滞后增大，外环的相位裕度下降，超调上升。若负荷变化范围超过 2:1，外环参数应按最不利工况（时间常数最长）整定，牺牲一点高负荷时的速度换低负荷时的稳定。

量程与归一化的影响常被低估。 本章所有参数都建立在“主变量、副变量、阀位归一化到 1”的约定上。若把副变量量程从 100 m³/h 改成 200 m³/h，同一个物理增益对应的 K_{p1} 要减半。现场交接参数时若只写数值不写量程，接手的人按自己的量程填进去，回路增益会差一倍——这是 §45.10.6 强调“参数表必须有单位与量程”的原因。

处理这三类漂移的共同原则是：**先分清是“增益漂移”还是“时间常数漂移”**。前者可以用增益调度或提高鲁棒性（降增益、留裕度）解决；后者只能按最不利工况整定，或改变工艺（提高物流速度）。把两者混为一谈，调参就会在两个工况之间来回妥协，哪个都不好。

45.8 调参方法与经验

§45.3 给的是设计流程，§45.7 给的是参数作用，本节给的是**在现场按什么顺序、用什么手法、遇到什么现象改哪个参数**。这三件事在教科书里常被合成一句“先内后外”，但真正决定调试成败的是细节。

45.8.1 为什么必须“先内后外”

先内后外的理由不是习惯，而是 §45.6.3 的结构事实：外环的对象是 G_2T_1，T_1 由内环决定。内环没调好就调外环，等于按一个错误的模型整定，整定出来的参数在内环改好之后全部作废。

表 45-8 给出了代价的量级：内环取 $0.5, 0.5$ 时，外环参数仍是设计值 $1.5/4$ s，超调却达 22.70%、调节时间 22.630 s；把内环提到 $2, 4$，同一套外环参数下超调降到 3.46%、调节时间 10.010 s。**外环一个参数没动，超调差了 6.6 倍**，差别全在内环。

反过来的顺序在实践中表现为一个典型循环：先调外环，发现响应慢，加 K_{p2}；加了之后超调大，减 K_{p2}；再发现扰动抑制差，加内环增益；内环一加，外环又显得慢……调了两天回到原点。原因是四个参数两两耦合（§45.7.6），同时动等于在四维空间盲搜。

45.8.2 内环整定的现场手法

内环整定时外环必须置手动，由人手给 r_1。具体步骤：

1. **断开外环，给副回路一个小阶跃。** 幅值取副变量量程的 5%–10%，太小看不出动态，太大会撞限幅。记录 y_1 的响应。
2. **只加 P，看上升时间。** 逐步加 K_{p1}，直到 y_1 的上升时间约为副对象时间常数的 $1/3$。本章副对象 0.5 s，目标是 0.15–0.17 s。此时内环闭环带宽约 4 rad/s。
3. **看超调与振荡次数。** 内环允许 10%–20% 的超调，因为它的设定值来自外环，本身就在不断变化，追求零超调没有意义。若超调超过 30% 或出现两次以上振荡，回退 K_{p1} 的 20%。
4. **测一次闭环带宽。** 有频响测试功能的话，直接测 y_1/r_1 的 -3 dB 带宽；没有的话用阶跃上升时间估算 $\omega_{b1} \approx 2.2/t_r$。本章 $t_r \approx 0.15$ s，估出约 14.7 rad/s，明显高于实测 4.005 rad/s——**这个估算公式对含积分的闭环偏乐观，只宜作数量级判断**，准确值仍应以频响或仿真为准。
5. **决定要不要加 I。** 若副变量长期存在固定偏差（如流量计零点），加弱积分，T_{i1} 取副对象时间常数的 3–10 倍；否则保持纯 P。

第 4 步的偏差值得强调：现场很多人用 $2.2/t_r$ 估带宽，然后据此算带宽比，结果高估内环能力。稳妥的做法是用上升时间与调节时间两个指标交叉判断，或直接在 DCS 里做一次设定值阶跃、用响应曲线拟合出一阶加纯滞后模型再算带宽。

45.8.3 外环整定

内环投自动后，外环仍在手动，此时人给 r_1 的偏置，观察主变量 y_2。整定步骤与单回路相同，但要注意两点。

其一，对象已经包含内环。 加 K_{p2} 时看到的响应比“按 G_2 预估”更快一点，因为内环把 G_1 换成了更快的 T_1。本章 $K_{p2}=1.5$、$T_{i2}=4$ s，就是按等效对象 G_2T_1 整定的结果。

其二，先定 T_{i2} 再定 K_{p2}。 T_{i2} 与主对象时间常数匹配（本章 4 s），K_{p2} 决定速度与超调的分配。反过来先定 K_{p2} 再凑 T_{i2}，容易落到表 45-10 中 $T_{i2}=2$ s 那一档（超调 29.63%）。

外环整定完，回到 §45.3.4 复核带宽比 r_b。若 $r_b < 5$，说明外环调得太快（ω_{c2} 太高）或内环太慢，二者必居其一，按 §45.3.4 的顺序处理。

45.8.4 投运后的三步复核

参数调好不等于能投运。投运前按顺序做三次试验：

1. **设定值阶跃**（幅值 5%–10%），看超调、调节时间、阀位峰值。阀位峰值应低于行程的 80%，否则加设定值滤波或降 K_{p2}。
2. **内环扰动试验**，在副回路入口加扰动（如手动开大旁路阀），看主变量峰值偏差与恢复时间。这是串级的“看家本领”，必须验证。
3. **外环扰动试验**，改变进料条件，确认串级至少不比原单回路差。若明显变差，说明副变量选错了（§45.3.1 的判据没满足）。

三次试验都通过，才把外环投自动。顺序不能颠倒：先投外环再试扰动，一旦出问题，分不清是参数问题还是结构问题。

45.8.5 常见故障对照表

表 45-12 把现场最常见的七种现象与处理办法收在一处。表中“根因”一列指向本章的具体小节，便于回查。

现象	根因	处理
主变量周期性慢振荡，周期几分钟	内外环积分叠加，或 T_{i1} 过小（§45.2.4）	内环改纯 P，或把 T_{i1} 放大到 $3T_1$ 以上
外环投自动瞬间阀位猛跳	r_1 初值未与内环当前设定对齐（§45.5.5）	切换时用当前 r_1 起算，并加设定值滤波
外环怎么加 K_{p2} 都嫌慢	两段共用 T_{s1}，外环积分被拉长 N_r 倍（§45.5.1）	分开积分时间基准，各自按本回路周期累加
内环扰动抑制不明显	带宽比 $r_b < 3$（§45.6.2）	提高 K_{p1}，或换更快的副变量测量
阀位高频小幅抖动	内环增益过高、副变量噪声大（§45.1.5）	降 K_{p1}，副变量加滤波（注意滤波在环内）
长期存在稳态偏差	内环无积分且外环积分饱和（§45.10）	加弱积分，或检查抗饱和是否生效
设定值阶跃超调大、扰动抑制却很好	控制量冲击 $K_{p1}K_{p2}$（§45.2.5）	加内环设定值滤波（§45.9.1）

表 45-12 的用法是“对号入座”，不是“逐条试”。先按现象定位到一两行，再看根因指向的小节，最后动一个参数验证。**一次只改一个参数、改动幅度不超过 30%、观察至少两个完整的调节周期**，这三条是现场调试的纪律，比任何整定公式都重要。

45.8.6 不同对象的经验范围

本章算例是“快副慢主”的典型。工程上常见的组合与调整方向如下，仅供起步定位，最终仍以实测为准。

温度—流量串级（换热器、反应釜）：副回路流量时间常数在秒级，主回路温度在分钟级，时间常数比可达 50 以上。内环纯 P，K_{p1} 取到流量回路临界增益的 40%–60%；外环 T_{i2} 取 5–20 min。这类对象最容易出现“内环够快、外环太慢”的配置，带宽比通常远超 5，反而要注意外环周期不要配得太长。

压力—流量串级（压缩机、锅炉）：两者时间常数接近，比值常在 3–5，属于“勉强合格”的区间。此时不要强求 5 倍带宽比，而应把重点放在副变量测量快速性上；若压力回路本身很快，可考虑不用串级而直接用前馈（第 46 章）。

液位—流量串级（三冲量给水）：液位本身是积分对象，单回路很难兼顾快速性与稳定性。工程上常用“液位外环 + 给水流量内环 + 蒸汽流量前馈”的三冲量结构，串级只承担其中一半职责。这类对象的 T_{i2} 往往取得很大（十分钟量级），因为液位允许缓慢变化。

位置—速度串级（伺服）：副回路是速度环，主回路是位置环，时间常数比通常 5–10。这是 §45 这套方法在机电系统里最直接的应用，第 100 章的姿态控制内环（40 rad/s）与外环（8 rad/s）的比值 5，正是这一档。

这四类对象的共同点是：**先确认时间常数比落在哪个区间，再决定串级值不值得做**。比值小于 3，串级的收益有限；比值在 5–10，收益最大；比值大于 20，串级有效但外环会很慢，需要考虑前馈补偿。

45.8.7 一次完整整定的走查

把 §45.3 的设计流程与 §45.8 的整定手法合起来，用本章算例走一遍，看每一步实际要做什么、得到什么数。

第一步，辨识副对象。 内环手动，给 5% 的阀位阶跃，记录流量响应。曲线拟合一阶模型，得 $T_1 = 0.5$ s、增益 1.0。这一步的关键是确认没有明显纯滞后；若拟合出 0.3 s 以上的延迟，内环带宽会受限，需重新评估。

第二步，辨识主对象。 内环自动、外环手动，给 r_1 一个阶跃，记录温度响应。拟合成二阶过阻尼，得 4 s 与 1 s 两个时间常数、增益 1.0。注意此时测到的对象已经包含内环，但它快，对 4 s 的主导极点几乎没有影响，可以直接当作 G_2。

第三步，内环试凑。 内环先纯 P，K_{p1} 从 0.5 起加，观察流量响应：$K_{p1} = 0.5$ 时上升慢、稳态偏差大；加到 2 时上升约 0.15 s、超调 15% 左右，停止。此时内环带宽约 4 rad/s（可用频响或阶跃拟合确认），与设计目标一致。

第四步，决定内环积分。 观察 30 min，若流量稳态偏差在允许范围内，保持纯 P；若存在固定偏差（流量计零点），加 $K_{i1} = 4$（$T_{i1} = 0.5$ s）。本章为了展示上限保留了这个积分，现场更稳的取法是 $T_{i1} = 2$–5 s。

第五步，外环增益。 外环手动，K_{p2} 从 0.5 起加。$K_{p2} = 1.5$ 时上升 3.7 s、超调 3.5%；加到 3.0 时上升 1.9 s、超调 19.3%，阀位峰值 6.0。取 1.5，因为阀位余量比速度更重要。

第六步，外环积分。 T_{i2} 从 8 s 往下试：8 s 时超调 0 但调节时间 31 s；4 s 时超调 3.46%、调节 10.01 s；2 s 时超调 29.63%。取 4 s，与主对象主导时间常数相同。

第七步，复核带宽比与冲击。 $r_b = 4.005/0.3523 = 11.37$，合格；冲击 $K_{p1}K_{p2} = 3.0$，超出 ±2.0 行程，需要处理。若阀门只有 ±1.2，按 §45.10.1 必须加抗饱和（单加抗饱和后超调 14.64%），再按 §45.9.1 加 $\tau_r = 0.2$ s 滤波（仅加滤波时冲击降到 1.948，仍高于 1.2，所以两者要同时用）；两者叠加后的具体指标应在现场重新做一次阶跃试验确认，不要用单项试验的数据外推。

第八步，扰动试验。 人为开大旁路阀，模拟阀后压力扰动。主变量峰值偏差 0.0157、未出 ±2% 带，与设计预期一致；若实测偏差大于 0.05，说明内环带宽没达到，回第三步。

这八步走完，参数就定下来了：$K_{p1} = 2$、$T_{i1} = 0.5$ s、$K_{p2} = 1.5$、$T_{i2} = 4$ s、$\tau_r = 0.2$ s、$T_t = 0.5$ s、限幅 ±1.2。每一步都有可观测的判据，不依赖“经验丰富的人看一眼”。

走查里最容易出问题的是第五步。K_{p2} 加到 3.0 时响应确实漂亮（上升 1.9 s），但阀位峰值 6.0 意味着必须换阀；现场常有人被速度诱惑，先按 3.0 投运，结果一遇到扰动就撞限幅，再回头降到 1.0，白折腾一轮。**整定时应把阀位峰值当作硬约束，与超调并列，而不是事后再看。**

45.8.8 整定记录该记什么

整定完成后，参数表之外还要留一份过程记录。至少四列：改动内容、阶跃幅值、超调、阀位峰值。四列之外再加一列“改前改后的对比结论”，用一句话写清“为什么保留这个值”。

例如：“K_{p2} 由 1.5 改 3.0：超调 3.46%→19.26%，上升 3.72→1.91 s，阀位峰值 3.0→6.0，因行程不足回退至 1.5。”这样一条记录，比参数表本身更有价值——半年后换人维护，看到的是“为什么”，而不只是“是什么”。

记录还应包含一次“参数敏感性”试验：在最终参数附近各改 ±20%，看指标变化多少。若 ±20% 的改动导致超调翻倍，说明系统工作在临界附近，应留更大余量；若几乎无变化，说明当前参数不敏感，可以按工艺需求重新分配速度与平稳。

45.8.9 三种典型误整定

整定过程中最常见的三个错误，都能用本章表格的数据当场识别。

误整定一：内外环同时投自动，两边一起调。 表现是“越调越乱”，每次改完参数，超调与调节时间都朝不可预期的方向变。根源是 §45.7.6 的耦合：改 K_{p1} 会改变外环的对象，改 K_{p2} 又会改变内环看到的设定值幅度。识别方法是做一次“内环冻结”试验：把 K_{p1}、K_{i1} 固定，只动外环，若指标仍不稳定，说明问题不在外环。纠正办法是回到 §45.8 的顺序，内环先定死再调外环。

误整定二：把外环积分时间设成与内环同量级。 有人按“积分时间越小消差越快”的经验，把 T_{i2} 设成 0.5–1 s。表 45-10 中 $T_{i2}=2$ s 已经出现超调 29.63%、调节时间 16.510 s；继续减到 1 s 以下，积分相位滞后会更靠近穿越频率，趋势只会更差（该段未逐一仿真，不建议现场尝试）。原因是被控对象的主导时间常数是 4 s，T_{i2} 取到 1 s 以下等于把积分相位滞后直接推到了穿越频率附近。识别方法是看“超调大但上升时间很短”，这是积分过强的典型特征。

误整定三：只看超调不看阀位峰值。 K_{p2} 从 1.5 加到 3.0，超调从 3.46% 涨到 19.26%，上升时间从 3.720 s 降到 1.906 s，表面上“响应快了很多”，但阀位峰值从 3.000 涨到 6.000（表 45-9）。若阀门行程只有 ±4.0，这个参数一投运就会长期饱和，实际性能比 1.5 还差。识别方法是把 `res["u"]` 的最大值打印出来，与行程对照；只看 y_2 的曲线永远发现不了。

三个误整定的共同点是：**都被单一指标误导**。超调好看不等于系统好，上升快不等于可用，消差快不等于稳。整定时至少要看四个量——超调、上升时间、调节时间、阀位峰值，缺一个都可能把系统调到边界上。

45.9 优化与改进

前面八节讲的是“标准串级怎么设计、怎么调”。本节讨论四种常见的改进：把控制量冲击压下去、把增益随工况调整、副变量测不到时怎么办、以及把串级与前馈组合起来。这些改进都不改变串级的结构，只改变它的边界行为。

45.9.1 内环设定值滤波

§45.2.5 算过，设定值阶跃时阀位跳到 $K_{p1}K_{p2}\Delta r = 3.0$；§45.7 的表 45-8、45-9 也反复出现这个数。若阀门行程不够，最直接的补救是给内环设定值加一阶滤波：

$$r_{1f}(s) = \frac{1}{\tau_r s + 1}\, r_1(s) \tag{45-23}$$

图 45-10 与表 45-13 给出 τ_r 从 0 到 1.0 s 的扫描。

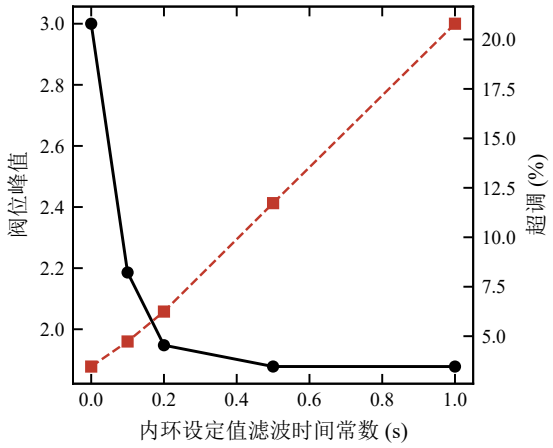

图 45-10　内环设定值滤波：阀位峰值从 3.000 降到 1.878，代价是超调从 3.46% 涨到 20.79%

τ_r (s)	阀位峰值	超调	上升时间	调节时间
0.0	3.000	3.46%	3.720 s	10.010 s
0.1	2.186	4.73%	3.575 s	10.370 s
0.2	1.948	6.24%	3.463 s	10.630 s
0.5	1.878	11.73%	3.311 s	11.260 s
1.0	1.878	20.79%	3.374 s	18.260 s

表 45-13 有两个值得注意的地方。

其一，阀位峰值在 $\tau_r = 0.2$ s 附近就降到 1.948，再加大几乎不再下降（0.5 s 与 1.0 s 都是 1.878）。 因为滤波只能削掉 $t = 0$ 的瞬时冲击，剩下的峰值来自外环积分在跟踪过程中的持续输出，那部分与 τ_r 无关。**想彻底压住阀位，还得同时限制外环输出或降低 K_{p2}。**

其二，超调随 τ_r 单调恶化。 $\tau_r = 0.1$ s 时 4.73%，0.2 s 时 6.24%，0.5 s 时 11.73%，1.0 s 时 20.79%。原因很直接：滤波把“外环要多少”的指令延迟了，等效于在外环回路里又插了一个一阶滞后，相位裕度被吃掉。

所以 τ_r 的选取是一个明确的折中：**取到刚好把阀位压进行程即可，不要为了“更平稳”继续加大。**本章若阀门行程 ±2.0，$\tau_r = 0.1$ s 就够（峰值 2.186，略超，取 0.2 s 更稳），对应超调 6.24%，比不加滤波的 3.46% 只差 2.8 个百分点。若行程只有 ±1.2，滤波也救不回来，必须降 K_{p2} 或换大阀。

45.9.2 设定值权重与微分先行

滤波是“把设定值变慢”，设定值权重是“让比例项不响应设定值变化”。把内环的 P 项改成

$$u_p = K_{p1}\left[\beta r_{1f} - y_1\right], \qquad 0 \le \beta \le 1 \tag{45-24}$$

$\beta = 1$ 是标准形式，$\beta = 0$ 时比例项只响应测量值，设定值阶跃的瞬时冲击被完全消除，但跟踪变慢。这与滤波的作用重叠，工程上二选一即可：滤波更直观，权重不引入额外动态。

微分先行（把微分作用只加在 y_1 上而不是误差上）是同一思路的微分版本，作用是避免设定值阶跃时微分项产生尖峰。第 44 章已讨论过，这里不再展开，只提醒一点：**串级的内环设定值来自外环，本身就是连续变化的，微分先行在内环上的收益比在单回路小，**通常不必专门配置。

45.9.3 副对象增益失配时的增益调度

§45.6.4 的表 45-7 说明，副对象增益在 0.5–2.0 倍之间变化时，串级虽然稳定，但超调在 2.15%–7.10% 之间浮动。若工艺负荷变化会导致副对象增益大幅变化（例如流量回路的增益与阀前后压差有关，低压差时增益显著下降），可以用增益调度：

$$K_{p1} = K_{p1,0} \cdot \frac{G_{1,0}}{G_1(\text{当前工况})} \tag{45-25}$$

即按副对象增益的倒数调整内环增益，保持回路增益 $C_1 G_1$ 恒定。工程上不必精确辨识，按负荷分 3–4 段查表即可，段间做线性插值，避免切换时的跳变。

增益调度的代价是需要一个能反映工况的变量（负荷、压差、阀位）。若无此变量，宁可把 K_{p1} 取在偏保守的一侧，也不要凭“感觉”分段。

45.9.4 副回路不可测时的替代

副变量选不出来（不可测、测量太慢、或探头寿命太短）时，串级不能硬做。三条替代路径，按推荐顺序：

其一，软测量。 用可测的变量（阀位、泵转速、上下游压差）通过静态或动态模型估算副变量，作为内环的测量值。软测量的精度不必很高，因为内环只要求“看到扰动”，不要求“测准绝对值”；但它的动态必须快，否则内环带宽上不去。

其二，用执行器位置做副变量。 阀位反馈本身就是可测的，把阀位而不是流量作为副变量，内环变成“阀位环”。这对阀门摩擦、定位器回差有效，但对阀后压力扰动无效（阀位没变，流量变了）。属于“次优但便宜”的方案。

其三，放弃串级，改用前馈。 若能测到扰动本身（蒸汽压力），直接按扰动做前馈补偿（第 46 章），效果可能比串级更好，而且不需要副变量。前馈的局限是只能补偿可测扰动，且需要准确的扰动通道模型。

这三条路径的判断依据是：**扰动可测 → 前馈；副变量可测但慢 → 软测量；只有执行器可测 → 阀位环；都不可行 → 老老实实做单回路，把对象改好。**

45.9.5 串级与前馈的组合：三冲量给水

工程上最经典的组合是锅炉汽包三冲量给水控制。它由三部分组成：汽包液位外环、给水流量内环、蒸汽流量前馈。结构上就是“串级 + 前馈”，前馈信号加在内环的设定值上：

$$r_1 = r_{1,\text{液位}} + K_f \, D_{\text{蒸汽}} \tag{45-26}$$

蒸汽流量增大时，前馈立即把给水设定值抬高，不必等液位下降；液位外环只负责修正前馈的稳态误差。这样外环可以调得很慢（T_{i2} 十分钟量级），液位不会因为“等偏差”而大幅波动。

这个例子说明串级与前馈不是竞争关系：**串级负责“把执行器管快”，前馈负责“把可测扰动提前”，两者叠加才覆盖了“扰动快、对象慢、执行器有惯性”的完整场景。**第 46 章会把前馈单独展开，这里只需记住它们的组合方式。

45.9.6 什么时候不值得改

改造现有单回路为串级，需要增加一个变送器、一段电缆、一个控制器模块，以及调试工时。收益不明显的场合，不该改：

- 主变量波动的主因在内外环之间或主变量本身（§45.1.2 的第二、三类扰动），串级没有机理优势；
- 副变量测量本身很慢（时间常数超过主对象的 1/3），内环做不快，带宽比上不去；
- 阀门行程已经没有余量，串级带来的 $K_{p1}K_{p2}$ 冲击会把阀门顶到限幅；
- 工艺对主变量波动的容忍度本来就宽，单回路已经够用。

这四条与 §45.11 的适用边界是同一套判据，区别只在于：§45.11 讨论“该不该设计串级”，这里讨论“该不该改造老装置”。后者的门槛应更高，因为改造要停机、要动接线，风险不只是控制性能。

45.9.7 三层以上的串级

工程上还有三层结构，例如“温度 → 流量 → 阀位”或“位置 → 速度 → 电流”。本章的两层结论可以逐层推广，但有三条新约束。

约束一，相邻层的带宽比各自要达标。 不是“最外层与最内层比 5 倍”，而是每一对相邻回路都要满足 $r_b \geq 3$–5。三层时若每层 5 倍，总分离度是 25 倍，外环带宽会被压得很低；若每层只有 2 倍，最外层看到的等效对象已经严重失真，串级退化成“三个慢回路串联”。

约束二，通常只有最外层保留积分。 三层里若每层都带积分，就出现了三个积分器串联，低频相位接近 $-270°$，任何扰动都会激发很慢的振荡。惯例是只有最外层带积分（保证稳态精度），中间层与最内层只保留 P，靠内层的快速性保证跟随。本章算例特意保留 $K_{i1} = 4$ 是为了展示上限，三层结构不应照搬。

约束三，调试顺序从最内层开始，逐层向外。 层数越多，“先外后内”的代价越大：改一次最内层参数，外面两层全部要重调。三层结构的调试时间通常是两层的 2–3 倍，投运风险也相应增加，因此只在工艺确实需要时才用。

除这三条外，还有一条实现约束：三层结构的采样周期通常按“每层比内层慢 3–5 倍”配置，最内层若 10 ms，中间层 30–50 ms，最外层 100–250 ms。这与 §45.5.3 的结论一致，只是层数多了一层，需要三套积分基准与三套限幅。

三层结构的收益与两层同源：扰动在哪一层之内，就被哪一层就地消化。若扰动主要作用在最内层（阀后压力），三层相比两层几乎没有额外收益；只有当中层也受独立扰动（例如流量计前的泵出口压力波动）时，中间层闭环才有价值。

45.10 工程落地

理论上的串级在 §45.1 的框图里只有四个方块和两条反馈。落到现场，决定成败的往往是另外几件事：阀门会不会撞限幅、副变量坏了怎么办、切换时会不会跳、投运顺序对不对。本节按“限幅—切换—降级—投运—记录”的顺序展开。

45.10.1 限幅与抗饱和

§45.2.5 已经算过，本章参数下设定值阶跃的阀位冲击是 3.000。若阀门可用行程只有 ±1.2（本章 §45.4.2 就用这个值做假设），串级在 $t = 0$ 就会撞限幅，此后的一切指标都要在“饱和”这个前提下重新评价。

图 45-9 与表 45-14 给出三组对比：不限幅、限幅但无抗饱和、限幅带回算抗饱和。

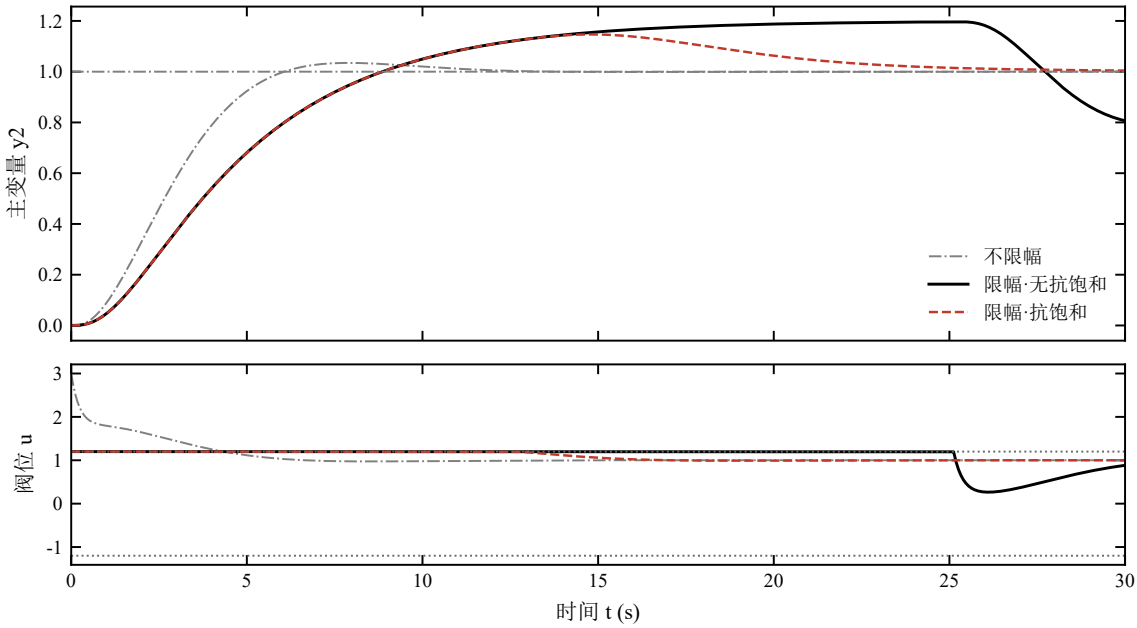

图 45-9　执行器限幅 ±1.2：无抗饱和时积分绕死，超调 22.59%、调节时间 37.620 s；回算抗饱和把超调压到 14.64%

工况	超调	上升时间	调节时间	饱和占比
不限幅	3.46%	3.720 s	10.010 s	10.9%
限幅，无抗饱和	22.59%	5.549 s	37.620 s	62.8%
限幅，回算 $T_t = 0.2$ s	14.63%	5.815 s	23.940 s	31.6%
限幅，回算 $T_t = 0.5$ s	14.64%	5.815 s	23.940 s	31.8%
限幅，回算 $T_t = 2.0$ s	14.74%	5.815 s	23.900 s	32.7%

表 45-14 读出三件事。

第一，限幅本身就会让性能变差。 即使加了抗饱和，超调也从 3.46% 涨到 14.64%，调节时间从 10.010 s 涨到 23.940 s。原因是阀门在最需要出力的前几秒被卡在 1.2，主变量得不到足够的热量，这段时间的偏差无法用控制手段弥补。**抗饱和只能防止“积分绕死”，不能弥补“执行器不够大”。**

第二，抗饱和的收益很大。 超调 22.59%→14.64%，调节时间 37.620 s→23.940 s，饱和占比 62.8%→31.8%。无抗饱和时，内环积分在阀位饱和期间继续累加，外环也因 y_1 追不上 r_1 而持续积分，两层积分一起“绕死”；退饱和后要先把这些虚高的积分放掉，表现为主变量长时间贴着上限爬行。

第三，回算时间常数 T_t 在 0.2–2.0 s 之间几乎不影响结果（超调 14.63%–14.74%）。本章算例的内环带积分（$K_{i1} = 4$，$T_{i1} = 0.5$ s），抗饱和作用在内环积分器上；三组 T_t 都小于饱和持续时间（约 3 s，占 10 s 窗口的 31.8%），回算在饱和期间始终有效，差别被饱和段本身掩盖。若 T_t 超过饱和持续时间，抗饱和就退化为“没有”，结果会靠近表 45-14 的第二行。**T_t 应按“明显小于饱和持续时间”来取，通常取内环闭环时间常数的 1–3 倍。**

回算的实现方式与第 44 章相同，只是作用点在内环：

$$I_1[k] = I_1[k-1] + K_{i1}T_{s1}\left[e_1[k] + \frac{u_{\text{sat}}[k] - u_{\text{raw}}[k]}{T_t}\right] \tag{45-27}$$

其中 u_{sat}、u_{raw} 分别是限幅前后的阀位。注意式 (45-27) 只修正内环积分，**外环积分不会被这条式子直接修正**：当内环长时间饱和时，y_1 跟不上 r_1，外环误差持续存在，外环积分照样会累积。工程上应两级都做抗饱和

——内环用式 (45-27) 回算，外环在 r_1 触及内环可达范围时停止累加（条件积分）。本章仿真只做了内环回算，外环的条件积分留给读者在 §45.12 的代码上自行补充，二者叠加后调节时间还能再缩短。

45.10.2 无扰切换

串级有三个切换点：内环手/自动、外环手/自动、以及串级/单回路的结构切换。三者的无扰条件不同。

内环手/自动。 手动时输出由人给，切自动时内环的积分项要预置成“使输出等于当前手动值”的值。内环若是纯 P，则不存在积分项，切换瞬间的输出只取决于 $K_{p1}(r_1 - y_1)$，只要 r_1 在切换前已经跟住当前阀位对应的设定值，就不会跳。做法是手动期间让 r_1 跟踪 y_1（设定值跟踪测量值），这是串级特有的要求。

外环手/自动。 手动时外环输出 r_1 由人给，切自动时外环的积分项要预置成使 r_1 等于当前值；同时 r_1 本身不能跳，否则内环会把它当成设定值阶跃。做法是切换前先把外环的“设定值”置为当前 y_2，再切自动，让外环从零偏差起步。

串级/单回路的结构切换。 这是最容易被忽视的一种。副变量故障（变送器断线、超量程）时，系统要从串级退到单回路，此时执行器从“内环输出”改为“外环输出”，两个信号的量纲和数值都可能差很远（内环输出是阀位百分比，外环输出是流量设定值）。**必须在切换瞬间做一次量纲换算与偏置对齐**，否则阀位会跳一大步。稳妥的做法是：正常运行时持续用内环的稳态关系 $r_1 \approx f(u)$ 跟踪一个换算系数，故障时用它把外环输出换算成阀位。

45.10.3 副回路故障的降级策略

副变量是串级里最脆弱的一环：它多了一个变送器、一段电缆、一个取样点，故障率高于主变量。表 45-15 给出四种故障与降级策略。

故障	判别	降级动作	风险
副变送器断线/超量程	信号质量位坏，或超上下限	内环切手动，外环切手动，阀位保持	主变量失去自动，需人工干预
副变量信号冻结（不变）	方差长时间为零	内环切手动，外环降为单回路	单回路下抗扰变差，但可运行
副变量噪声突增	方差超过阈值	内环降增益或加滤波	阀位磨损加剧
执行器卡涩（阀位不跟随）	阀位反馈与输出偏差大	内环切手动，报警	需现场处理，不能靠算法

表 45-15 的第一行是“保持”，不是“降级为单回路”，原因是副变量完全失效时，外环的输出 r_1 失去意义（它本来是要送给内环的），直接拿它去控阀会得到错误的流量。此时最安全的动作是保持阀位、报警、等人处理。

第二行才是真正的降级：副变量冻结但外环仍可用，把外环输出直接送阀，系统退回单回路，性能下降但能继续运行。这个切换需要 §45.10.2 说的量纲换算。

45.10.4 投运步骤

投运的顺序在 §45.3.6 与 §45.8.4 已经提过，这里给出可执行的清单：

1. **静态检查。** 副变量量程、单位、滤波时间常数；阀门的正反作用；两个控制器的正反作用；限幅值。
2. **内环单体调试。** 外环手动，内环手动给输出，确认阀位跟随、方向正确；然后内环投自动，给 r_1 阶跃，记录响应。

3. **外环开环试验。** 内环自动，外环手动给 r_1，观察 y_2 响应，确认对象增益与时间常数与设计值相符。

4. **外环闭环。** 外环投自动，先给小幅设定值阶跃（2%–5%），逐步加大到工艺常用范围。

5. **扰动试验。** 按 §45.8.4 的三步做，重点验证内环扰动抑制。

6. **限幅试验。** 人为把阀位限到较低值，确认抗饱和生效、退饱和后无长时间爬行。

7. **故障演练。** 拔掉副变送器信号线（或在 DCS 里强制坏质量位），确认降级动作正确、报警发出。

第 7 步最容易被跳过，也最容易在真正故障时暴露问题。演练时要注意：不要在主变量处于关键工况时做，且要提前与工艺确认阀位保持不会造成安全问题。

45.10.5 采样与任务调度的落地细节

§45.5 讲过原理，这里补三条现场细节。

其一，两个回路不要放在同一个周期任务里"顺带"执行。 常见做法是把外环写在 1 s 的慢任务里、内环写在 100 ms 的快任务里，这没问题；有问题的是把外环也塞进快任务、靠计数器每 N_r 拍执行一次——一旦快任务被其他逻辑挤占，外环的执行时刻会漂移，等效于给外环加了周期抖动。

其二，外环输出要用"保持型"写入。 某些 DCS 的模拟量输出模块在每个扫描周期都会刷新，若外环的输出变量在两次计算之间被清零或复位，内环会看到设定值归零。做法是把 r_1 存在全局保持寄存器里，只在中断触发时更新。

其三，时间同步。 做扰动试验、录波分析时，主变量、副变量、阀位三条曲线必须在同一时间基准上，否则算出来的"内环响应时间"会包含通信延迟。多数 DCS 支持带时标的趋势记录，投运前应确认时标一致。

45.10.6 参数与文档的交付

串级投运完成后，至少要留下四样东西：最终参数表（含内环、外环的 K_p、T_i、T_d、滤波时间、限幅值、T_t）、整定过程记录（每步的阶跃幅值与响应指标）、降级逻辑说明（表 45-15 的现场版）、以及一次完整的扰动试验曲线。这四样是后续技改、故障分析、以及交接班的依据。

特别提醒参数表的"单位"一列。串级的参数最容易出错的地方就是单位：内环的 K_{p1} 是"阀位百分比 / 流量单位"，外环的 K_{p2} 是"流量单位 / 温度单位"，两者量纲不同，不能互相比较，也不能照抄同行的参数。本章所有数字都建立在"主变量、副变量、阀位均归一化到 1"的约定上（§45.4.1），换成工程量纲后数值会变，但比值关系不变。

45.10.7 副变量的取样与安装

副回路能不能快，一半取决于仪表选型，一半取决于安装位置。三条准则按重要性排列。

其一，取样点要靠近扰动入口。 换热器的蒸汽流量应在调节阀之后、换热器之前取；若取在阀前，阀后压力波动根本测不到，内环等于白装。这一条决定了串级有没有意义，比仪表精度重要得多。

其二，取样点要避开死区与滞留区。 流量计前后要有足够的直管段（孔板一般要求前 10D、后 5D），否则流速分布不均，测量值随流量非线性漂移，内环增益跟着变。温度取样要插到流体主流区，不要贴在管壁上；套管式测温元件的响应时间比裸丝慢一个数量级，会直接压低内环带宽。

其三，变送器的阻尼要设小。 多数变送器有可调的阻尼时间（0.1–2 s），出厂常设在 1 s 以上。这个阻尼在闭环之内，等效于给副对象加了一个一阶滞后。选型时应把它调到满足噪声要求的最小值，并记入参数表——§45.11.5 的案例二就是阻尼设大了。

安装上还有一个常被忽略的细节：**副变量的量程要与实际工况匹配**。量程选得过大，正常工况只用到 30%，量化误差与相对噪声都变大，内环增益被迫降低；量程选得过小，一有扰动就超量程，触发 §45.10.3 的降级逻辑。工程上一般让正常流量落在量程的 50%–80%。

45.10.8 DCS 组态要点

把本章的方案落进 DCS，组态上有七件事必须做对，顺序即执行顺序。

其一，先归一化再进功能块。 主变量、副变量、阀位在 PID 功能块里通常按 0–100% 处理。若直接用量纲值（例如温度 0–200 ℃）而不做量程换算，K_{p2} 的数值会与本章差 100 倍。做法是在 AI 通道里设好量程，让功能块拿到的是百分比。

其二，外环输出要限幅到内环可达范围。 外环算出的 r_1 若超出副变量量程，内环永远也追不上，误差持续存在，积分必然饱和。限幅值按副变量量程的下限与上限取，并在限幅时冻结外环积分（条件积分）。

其三，内环设定值要来自外环的保持输出。 不要用“外环块的输出引脚直接连内环设定”，某些 DCS 在每个扫描周期都会重新计算该引脚，导致 r_1 在内环拍之间变化。做法是外环块加“输出保持”，或在内环任务里锁存。

其四，两个 PID 块的周期参数要各填各的。 内环块填 T_{s1}，外环块填 T_{s2}，不能图省事都填 100 ms。若 DCS 的任务周期与块内周期不一致，以块内周期为准，且要让任务周期整除块内周期。

其五，手自动切换要成对设计。 内环手动时外环必须强制手动（或跟踪），否则外环输出无人接收、积分继续累积。切换逻辑写成互锁，不要留给操作工记忆。

其六，报警要分级。 副变量坏质量、超量程、偏差大、阀位饱和，四类报警的优先级不同：坏质量最高（立即降级），偏差大次之（提示整定问题），阀位饱和最低（提示工艺负荷）。全部堆在一个报警页里，操作工分不清轻重。

其七，趋势组要含四个信号。 主变量、副变量、r_1、阀位，采样周期与内环一致。只录主变量与阀位，事后无法判断是内环没跟上还是外环算错了。

除组态之外，还有一条组织上的要求：**串级回路不宜接入安全仪表系统（SIS）**。SIS 的动作逻辑要求简单、可验证，串级的降级路径与手自动互锁都会增加验证负担。若工艺有安全联锁需求，应由独立的 SIS 直接驱动切断阀，串级只负责常规调节。这条边界在第 111 章讲工程问题时还会展开。

45.11 优缺点与适用边界

前九节给出的都是“在什么条件下串级好、好多少”。本节把它翻过来：串级究竟买到了什么、付出了什么、在什么情况下不该买。判断标准尽量量化，避免“视情况而定”。

45.11.1 四条优点

其一，扰动就地抑制，倍数可达一个数量级。 本章基准参数下，内环扰动造成的主变量峰值偏差从 0.1855 降到 0.0157，改善 11.8 倍；恢复时间从 12.990 s 变为“从未出带”。这是串级最核心的价值，也是它存在的唯一理由。倍数的大小由带宽比决定（§45.6.2），$r_b \approx 11$ 时对应约 12 倍。

其二，对副对象增益失配不敏感。 表 45-7 显示，副对象增益在 0.5–2.0 倍之间变化时，单回路超调从 0.00% 恶化到 28.29%，串级只在 2.15%–7.10% 之间浮动。机理是失配被内环“吸收”成带宽变化，而不是直接变成回路增益变化（§45.6.4）。

其三，把执行器的非线性包进内环。 阀门的摩擦、回差、流量特性曲率，都在内环之内。内环的高增益对这些非线性有局部线性化作用：只要内环带宽足够，阀门特性的变化对主回路表现为“增益略有变化”，而不是“死区导致极限环”。这是串级在气动阀上特别常见的原因之一。

其四，可分工投运、可独立试验。 内环可以先单独投自动、单独做阶跃试验，外环后投；运行时内环故障可以降级为单回路（§45.10.3）。相比之下，前馈、解耦这些结构一旦投运就难以“部分运行”，串级的可维护性更好。

45.11.2 五条代价

其一，多一个测量点。 副变量要变送器、取样点、电缆、输入通道，采购与安装成本之外，还多了一个故障源与一份维护工作。表 45-15 的四类故障全部由这个测量点引入。

其二，控制量冲击是两级增益的乘积。 $u(0^+) = K_{p1}K_{p2}\Delta r$，本章为 3.000，是单回路 1.805 的 1.66 倍。阀门行程不足时，冲击直接变成限幅，超调从 3.46% 恶化到 22.59%（表 45-14）。缓解手段（设定值滤波）又要用超调去换（表 45-13）。

其三，对外环扰动没有收益。 内外环之间的扰动，单回路峰值偏差 0.1888、串级 0.1787，差别 5%；恢复时间串级反而慢 1 s。若主变量波动的主因在进料侧而不是阀后，串级是选错了工具。

其四，多速率实现有额外复杂度。 两个积分基准、两个保持环节、外环输出的时间戳与原子写入、周期不整除时的抖动（§45.5.5）。这些在仿真里都不存在，在现场都是坑。

其五，整定与投运门槛高。 必须先内后外、必须做扰动试验与故障演练、必须处理三个切换点（§45.10.2）。人员能力不足时，串级投不好比单回路更糟——本章表 45-8 中 $0.5, 0.5$ 那一档就是例证：结构是串级，性能却接近单回路，还多了一个故障点。

45.11.3 与其他结构的对比

表 45-16 把串级放进常用回路结构的谱系里，按“需要什么额外信息、对付什么扰动、付出什么代价”三列比较。

结构	额外需要	主要对付	主要代价	相关章节
单回路 PID	无	一律（但慢）	大滞后对象上性能差	第 44 章
串级	副变量测量	内环之内的扰动	冲击、测量点、多速率	本章
前馈	扰动测量 + 扰动通道模型	可测扰动	模型误差、稳态需外环兜底	第 46 章
前馈 + 串级	两者兼有	可测扰动 + 不可测内环扰动	结构与整定最复杂	第 46 章
Smith 预估	对象模型 + 延迟时间	纯滞后	模型失配时性能骤降	第 47 章
解耦	全通道模型	多变量耦合	模型依赖强、易病态	第 108 章
MPC	预测模型 + 在线优化	约束、多变量、可预告	算力、模型维护	第 58/80 章

表的读法：**串级是唯一“不需要扰动模型、也不需要对象模型”的结构**，它只用一条额外的测量线换抗扰能力。这是它在过程工业里比前馈、Smith 更常见的原因——前馈要辨识扰动通道，Smith 要辨识延迟，串级只要“再装一个表”。

代价也在这里：串级不知道扰动是什么，只知道副变量偏了；因此它对外环扰动无能为力，对设定值跟踪也没有特别的好处（超调减半是副产品，上升时间还慢 5.6%）。

45.11.4 五条适用判据

判断“该不该上串级”，按下面五条逐项过。**五条全部满足才建议上；有一条明显不满足，应先考虑别的结构。**

1. **扰动位置**：主变量波动的主因是否落在“内环之内”（阀后压力、燃料热值、冷却水流量）？若主因在内外环之间或主变量本身，串级无收益（§45.1.2）。
2. **副变量可测且够快**：副变量的测量时间常数是否小于主对象主导时间常数的 1/3？是，则带宽比有希望做到 5 以上（§45.3.3、§45.6.2）。
3. **时间常数比**：主、副对象时间常数比是否在 5–20？小于 3 收益微小，大于 20 外环太慢、应考虑前馈（§45.4.5）。
4. **执行器余量**：阀门行程是否能容纳 $K_{p1}K_{p2}\Delta r$ 的冲击（含设定值滤波后的余量）？不能，则先改阀或降增益，否则串级一投运就饱和（§45.10.1）。
5. **维护能力**：是否有能力完成先内后外的整定、三次扰动试验、故障演练？没有，则串级的故障率可能高于它带来的收益。

这五条与 §45.9.6 的四条“不值得改”是同一套判据的两种表述：前者用于新设计，后者用于老装置改造，后者的门槛更高。

45.11.5 三个误用案例

案例一：进料温度主导的换热器。 温度波动的主因是进料温度变化，属于内外环之间的扰动（§45.1.2 第二类）。厂里上了蒸汽流量串级，投运后温度波动只从 ±3 ℃ 降到 ±2.8 ℃，操作工认为“串级没用”。实际不是串级没用，是选错了对象：应该测进料温度做前馈（第 46 章），或者改变副变量的选取。判据 1 不满足。

案例二：副变量用带 5 s 滤波的流量计。 副对象时间常数 0.5 s，但流量信号经过 5 s 的一阶滤波才进控制器，内环带宽被压到 0.2 rad/s 以下，带宽比只有 0.6。投运后主变量不但没平稳，反而出现 20 s 周期的振荡。原因是 S_1 在低频就接近 1，内环不仅没抑制扰动，还把测量滞后变成了回路里的纯滞后。判据 2 不满足——**滤波时间必须算进副对象**，这是 §45.5.2 强调过的。

案例三：阀门行程只剩 10%。 工艺为扩产把阀门选小了一号，行程余量不足 10%。串级投运瞬间阀位冲击 3.0 倍于正常工况，直接顶到限幅，主变量超调 22.59%，操作工被迫把 K_{p2} 降到 0.5 以下，串级退化成“两个都很慢的回路”。判据 4 不满足，正确做法是换阀或改单回路 + 前馈。

三个案例的共同点是：**结构本身没错，错在把结构套在了不满足前提的对象上**。串级对前提的敏感度高于单回路，这是它的固有特性，不是实现缺陷。

45.11.6 本章边界与后续

本章的结论建立在四个前提上：对象近似线性、副对象一阶、主副时间常数比在 5–20、执行器有足够余量。任何一条被打破，数字要重新算，但定性结论（扰动位置决定收益、带宽比决定倍数、两级增益决定冲击）仍然成立。

四个前提之外的问题由后续章节接手：

- 扰动可测但副变量不可测 → 前馈与复合控制（第 46 章），本章 §45.9.4 已给出选择路径；
- 主对象含大纯滞后（$\tau/T > 0.5$）→ Smith 预估与内模控制（第 47 章），此时串级的内环再快也无法补偿主回路的延迟；
- 对象有明显非线性（阀特性、pH 中和）→ 相平面与描述函数（第 48、49 章）分析极限环，必要时做增益调度（§45.9.3）；

- 多变量耦合（一个副变量受多个执行器影响）→ 解耦与相对增益阵（第 108 章）。

换句话说，串级解决的是“扰动位置”问题，不解决“延迟”“非线性”“耦合”问题。把这三类问题误当成扰动位置问题去上串级，就是 §45.11.5 的三个案例。

四个前提里最容易被忽视的是“执行器有足够余量”。本章不限幅时超调 3.46%、调节时间 10.010 s；阀位一旦被限到 ±1.2，即使加了抗饱和，超调也涨到 14.64%、调节时间 23.940 s（表 45-14）。**前提被打破时，最先失真的不是结构结论，而是所有性能数字**：通道分析与带宽比仍然成立，但“改善 11.8 倍”“超调 3.46%”这类数不能再引用。时间常数比同理，$T_1 = 1$ s 时改善倍数降到 7–9 倍、绝对偏差都在 0.03 以下，$T_1 = 16$ s 时改善倍数只剩 2.23（表 45-5）。引用本章任何一个数字之前，先核对这四个前提是否与自己的工况同量级，比直接套公式可靠得多。

副对象不是一阶时（含纯滞后或二阶），T_1 在高频段会多出相位滞后，§45.6.6 的裕度表整体下移，5 倍带宽比这条经验线也要相应上调，必须按实际对象重算，不能照搬。这条提醒与 §45.12.7“代码是模板，数字不是模板”是同一件事。

45.11.7 决策：新设计与老装置改造

同一套判据，用于新设计与老装置改造时，权重不同。新设计里，多一个测量点的边际成本很低（设计阶段加一个测点、一根电缆），应当从工艺需求出发选最优结构；老装置改造要停机、动土建、改接线，风险和成本都高一个量级。

老装置改造前，建议先做三件事，用数据代替判断。

其一，扰动溯源。 连续记录主变量与所有可疑扰动源（阀后压力、进料温度、环境温度、公用工程压力）至少一周，做相关分析。若主变量波动与某一路扰动的相关系数超过 0.6，这一路就是主因。主因落在内环之内，串级才有意义。

其二，收益估算。 用本章的倍数关系做粗估：内环扰动主导时，峰值偏差可改善 8–12 倍；外环扰动主导时，改善不到 10%。把改善倍数换算成产品质量、能耗或产量，再与改造成本比较。若收益只体现在“曲线好看”，不建议改。

其三，风险清单。 改造会引入新的故障点（副变送器）、新的操作复杂度（两个手自动切换）、新的整定工作量。这些风险要有人负责、有预案，否则改造后的可用率可能低于改造前。

三件事做完仍决定改造，就按 §45.3 的六步做设计、按 §45.8 的顺序整定、按 §45.10.4 的清单投运。反过来，若三件事里有一件通不过，正确的动作往往不是“换个控制器试试”，而是回到工艺侧解决问题——把扰动源本身消掉，比任何控制结构都有效。

这也是本章想留下的最后一个判断：**串级是“用测量换抗扰”的结构，当扰动可以被测量时，它很划算；当扰动不能被测量、或测量本身成为负担时，先想办法消除扰动，再谈控制。** 控制理论能做的，是在给定对象与测量条件下把性能做到最好，不能替代工艺改进。

45.12 Python 仿真代码

本章所有数字、曲线、图表都由两个脚本生成，不含任何手工填入的结果。本节说明它们的组织方式、核心循环，以及如何改造成自己的算例。

45.12.1 文件与运行方式

文件	作用	输出
`code/ch045_sim.py`	对象、控制器、仿真器、指标；十二段输出（十一段实验 + 裕度）	终端指标表
`code/ch045_figs.py`	调用 `ch045_sim.py` 的接口绘图	`figs/ch045/*.svg` 与 `*.pdf`

运行命令（解释器必须用工程指定的环境，不能用系统 PATH 上的 python）：

```
& "D:\Anaconda3\envs\py311\python.exe" code\ch045_sim.py
& "D:\Anaconda3\envs\py311\python.exe" code\ch045_figs.py
```

`ch045_sim.py` 依赖 `numpy`、`control` 与 `simlib`。`control` 只用于两处：把连续对象离散成状态空间（`_zoh`）与计算闭环带宽（`bandwidth`）；逐步仿真循环本身只用 `numpy`。`ch045_figs.py` 额外依赖 `matplotlib` 与 `styles/` 下的绘图助手。

45.12.2 对象与接口

对象用两个独立的传递函数表示，分别离散化后串联：

```
def plant_inner(gain=1.0, T=0.5):
    """副对象：一阶，时间常数 0.5 s。"""
    return sl.tf([gain], [T, 1.0])

def plant_outer(T1=4.0, T2=1.0):
    """主对象：二阶过阻尼，4 s 与 1 s。"""
    return sl.tf([1.0], np.polymul([T1, 1.0], [T2, 1.0]))
```

核心是 `simulate()`，它用同一个循环同时支持串级与单回路，靠 `cascade` 开关切换。关键参数：`c1`、`c2` 为两级的 (K_p, K_i, K_d)；`dist`、`dist_pos` 指定扰动序列与注入位置；`sat`、`tt` 为限幅与回算时间常数；`ratio` 为外环降速倍数；`tau_r` 为内环设定值滤波。返回值是字典 `{"t","y1","y2","u","r1"}`，其中 `r1` 是外环输出序列，用来观察设定值冲击。

仿真器内部用零阶保持把连续对象离散成状态空间，每个采样周期推进一次；控制器按位置式差分实现，积分项用“当前误差 × 周期”累加，与 §45.2.6 的式 (45-13)、式 (45-14) 一一对应。

45.12.3 主循环

下面是 `simulate()` 的核心循环（省略了参数校验与数组预分配）：

```
for k in range(N):
    y1k = float((C1 @ x1 + D1 @ np.array([[uprev]]))[0, 0])
    y2k = float((C2m @ x2 + D2 @ np.array([[y1k]]))[0, 0])
    y1[k], y2[k] = y1k, y2k
    y2m = y2k + (rng.normal(0.0, noise) if noise else 0.0)

    if cascade:
        # 外环：每 ratio 拍执行一次，输出即内环设定
        if k % ratio == 0:
            e2 = ref - y2m
            d2 = (tf * d2 + Ts * ratio * e2) / (tf + Ts * ratio)
            r1 = kp2 * e2 + ki2 * xi2 + kd2 * (e2 - d2) / tf
            xi2 = xi2 + Ts * ratio * e2
        r1f = (tau_r * r1f + Ts * r1) / (tau_r + Ts) if tau_r > 0 else r1
        e1 = r1f - y1k
        d1 = (tf * d1 + Ts * e1) / (tf + Ts)
        uk_raw = kp1 * e1 + ki1 * xi1 + kd1 * (e1 - d1) / tf
        corr = 0.0
        if sat:
            uk = float(np.clip(uk_raw, sat[0], sat[1]))
            corr = (uk - uk_raw) / tt if tt > 0 else 0.0
        else:
            uk = uk_raw
        xi1 = xi1 + Ts * (e1 + corr)
    else:
        # 单回路：一个 PI(D) 直接控阀，积分器为外环所有
        e2 = ref - y2m
        d2 = (tf * d2 + Ts * e2) / (tf + Ts)
        uk_raw = kp2 * e2 + ki2 * xi2 + kd2 * (e2 - d2) / tf
        if sat:
            uk = float(np.clip(uk_raw, sat[0], sat[1]))
            corr = (uk - uk_raw) / tt if tt > 0 else 0.0
        else:
            uk = uk_raw
            corr = 0.0
        xi2 = xi2 + Ts * (e2 + corr)

    u[k] = uk
    r1_seq[k] = r1

    # 扰动注入：inner 加在 G1 入口，outer 加在 G2 入口
    dk = dseq[k]
    if dist_pos == "inner":
        v1, v2 = uk + dk, y1k
    else:
        v1, v2 = uk, y1k + dk

    x1 = A1 @ x1 + B1 @ np.array([[v1]])
    x2 = A2 @ x2 + B2 @ np.array([[v2]])
    uprev = uk
```

四行代码值得单独看。

`if k % ratio == 0:`：多速率。外环只在整除时刻执行，其余时刻 `r1` 保持不变，等效于零阶保持。积分项用 `Ts * ratio` 而不是 `Ts`，这是 §45.5.1 强调的“积分时间基准不能混用”的代码实现。

`r1f = (tau_r * r1f + Ts * r1) / (tau_r + Ts)`：内环设定值的一阶滤波，对应式 (45-23)。`tau_r=0` 时直接取 `r1`，不引入额外动态。

`corr = (uk - uk_raw) / tt`：回算抗饱和，对应式 (45-27)。`tt=0` 表示不做抗饱和，此时 `corr` 恒为 0，与死区一样绕死积分。

先算 `y1k` 再用 `y1k`：对象用状态空间推进，`y1` 的当前值由上一拍的输入 `uprev` 算出，`y2` 再由 `y1` 算出。这个顺序保证两级对象之间没有代数环，也保证扰动注入点的位置与框图一致（`inner` 加在 G_1 入口，`outer` 加在 G_2 入口）。

45.12.4 十二段输出与正文对应

表 45-17 给出 `main()` 的十二段输出与正文的对应关系，便于核对每一个数字的出处。

段	实验	正文位置	代表数字
一	单回路 K_p 扫描	§45.4.1	$K_p = 1.5$：$M_p = 7.18\%$
一（续）	跟踪对比（单回路 vs 串级）	§45.4.2、表 45-3	3.46% / 3.000
二	带宽分离	§45.3.4、表 45-2	$r_b = 1.49$–22.68
三	内环扰动	§45.4.3、表 45-4	0.1855 → 0.0157
四	外环扰动	§45.4.4	0.1888 / 0.1787
五	增益失配	§45.6.4、表 45-7	0.00%–28.29%
六	多速率	§45.5.3、表 45-6	3.46% → 25.10%
七	限幅与抗饱和	§45.10.1、表 45-14	22.59% → 14.64%
八	内环快慢	§45.7.1、表 45-8	22.70% → 2.15%
九	设定值滤波	§45.9.1、表 45-13	3.000 → 1.878
十	主副时间常数分离	§45.4.5、表 45-5	改善 11.83 → 2.23 倍
十一	外环 K_{p2} 与 T_{i2} 扫描	§45.7.3、§45.7.4、表 45-9、表 45-10	0.00%–29.63%
十二	外环开环裕度	§45.6.6	PM $45.90°$–$68.02°$

表 45-17 的“代表数字”一列只是索引，完整数值以脚本输出为准。正文中出现的每一个百分比、秒数、峰值，都能在这十二段里找到对应行。

45.12.5 复现与绘图注意

解释器。 必须用 `D:\Anaconda3\envs\py311\python.exe`。系统 PATH 上的 python 可能缺少 `numpy` 或版本不符，报错信息往往指向 `simlib` 导入失败，容易被误判为代码问题。

曲线口径。 `metrics()` 直接调用 `simlib.step_metrics()`，稳态值取末 1/50 均值、上升时间按 10%→90%、调节时间按 ±2% 带。换用别的口径（例如按 ±5% 或按首次进入带内）会让表 45-3 至表 45-14 的数字整体漂移，比较时必须同口径。

恢复时间。 `dist_metrics()` 在窗口内未回到带内时返回 `nan`，正文中显示为“未出带”。若把窗口从 80 s 缩短到 40 s，部分“未出带”会变成“未恢复”，读表时要注意窗口长度。

图内文字。 所有坐标轴标签用纯中文或纯公式，不混排。`matplotlib` 的 mathtext 在遇到中文时会丢字形（显示为方框），这是本章绘图过程中实际踩过的坑；`plot_styles.apply_cjk_font()` 只解决字体族问题，不解决混排问题。

图幅。 本项目把 `DOUBLE` 定为 17 cm × 9.6 cm（双栏 16:9），`SINGLE` 定为 8.5 cm × 5.7 cm（单栏 3:2）。双图统一用 `plt.subplots(2, 1)` 加 `sharex=True`，保证上下两图的横轴严格对齐。

45.12.6 三个练习

练习一，把抗饱和补到外环。 当前实现只在内环做了回算（式 45-27），外环的条件积分没有做。在 `simulate()` 的串级分支里，当 `r1` 超出内环可达范围（可由 `sat` 与 K_{p1} 反推）时冻结 `xi2`，重跑第八段，比较调节时间能否从 23.940 s 进一步缩短。

练习二，给副变量加噪声。 `simulate()` 已预留 `noise` 参数，但目前只加在主变量上。把噪声改加到 `y1k`，取 0.005–0.02 的标准差，观察内环 K_{p1} 从 2 提到 4 时阀位抖动幅度的变化，验证 §45.1.5“内环越快越放大噪声”的定性结论。

练习三，把内环改成纯 P。 令 `c1=(2.0, 0.0, 0.0)`，重跑第四段与第八段。前者用于观察“去掉内环积分后，内环扰动的稳态偏差是否还能被外环消掉”，后者用于观察“内环无积分时抗饱和是否还必要”。这两个结果会与 §45.2.4“内环通常只用 P”的工程惯例形成对照，也能解释本章为什么特意保留了 $K_{i1}=4$。

45.12.7 改造成自己的算例

本章代码可以直接换对象运行，四步即可把自己的工艺套进去。

第一步，换对象。 修改 `plant_inner()` 与 `plant_outer()` 的返回表达式。例如副对象是带延迟的流量回路 $G_1=1.0e^{-0.2s}/(0.8s+1)$：`_zoh()` 只做零阶保持离散，不会自动处理纯滞后，需要先用 Padé 近似（`control.pade`）把它变成有理函数，或在状态空间里串一段延迟链。延迟存在时内环带宽上限会下降，$K_{p1}=2$ 可能不再合适，需重跑内环扫描。主对象若是三阶，直接改多项式系数即可。

第二步，改采样周期与仿真长度。 `simulate()` 的 `Ts` 默认 0.01 s，对应副对象时间常数 0.5 s。若副对象是 5 s 的慢回路，`Ts` 要放大到 0.1 s，`N` 相应放大，否则时间轴只有几十秒，看不到稳态。判据仍是 §45.5.2 的 $T_{s1}\le 1/(10\omega_{b1})$。

第三步，重定控制器初值。 用 §45.3 的规则给一组起步参数：内环 K_{p1} 按副对象增益的倒数乘 2 取，T_{i1} 取 $3T_1$；外环 K_{p2} 按等效增益 $T_1(0)$ 反算，T_{i2} 取主对象主导时间常数的 1–2 倍。这组初值不必最优，目的是让 `simulate()` 能跑出可读的曲线，再按 §45.8 的顺序细调。

第四步，校核三件事。 一是带宽比是否 ≥5（用 `bandwidth()` 与 `margins_db_deg()`）；二是阀位峰值是否在行程内（看 `res["u"]` 的最大值）；三是内环扰动试验的改善倍数是否与预期同量级（用 `dist_test()`）。三件事都过关，才说明对象换得对。

最容易踩的坑有两个。其一，换了对象却忘了改 K_{p1}，仿真直接发散，误以为模型有问题——其实是增益差了几十倍。其二，对象的增益与时间常数改了，但本章正文的表 45-3 至表 45-15 是旧对象的结论，不能直接对照，必须重新跑 `main()` 生成新数。**代码是模板，数字不是模板。**

若要把结果写进论文或报告，建议保留 `main()` 的分段结构：每段对应一个结论，每段打印的指标与正文的某张表一一对应。这样换对象后重跑一遍，就能得到一套与新对象匹配的完整数据，不必逐张表手工重算。

45.12.8 怎么读 `main()` 的输出

`main()` 一共打印十二段，段号与正文的对应关系是固定的。读输出时先看段号，再看数字，能省掉很多“这个数是在说什么”的疑问。

第一段到第二段是基线与带宽。 第一段扫九个 K_{p2}，打印超调、上升时间、调节时间、阀位峰值四列，用来选单回路基线；第二段固定外环、只改内环，打印 ω_{b1}、ω_{c2}、r_b 与内环 $T_i = K_p/K_i$。第二段的 r_b 列是设计阶段唯一需要“卡阈值”的数，要求 ≥5。

第三段到第五段是三条通道的时域对照。 第三段用 `dist_test()` 的默认参数：$N = 8000$、$T_s = 0.01$ s，即 80 s 窗口，扰动在 $t = 30$ s 加入，实际只有 50 s 的观察时间。若输出“未恢复”，意思是 50 s 末偏差仍大于 0.02（`dist_metrics()` 的 `band` 默认值），**不是发散**；要确认这一点，把 `N` 加到 20000 再看。第五段换副对象增益，控制器参数一律不动，因此它测的是鲁棒性，不是最优性。

第六段到第七段是离散与非线性。 第六段的 `ratio` 是外环每几个内环周期执行一次，$ratio = 200$ 时外环周期 2 s，已经接近 §45.5.3 的边界；第七段的“饱和占比”按 $|u| \geq 1.199$ 统计，统计的是“贴在限幅上的采样点比例”，不是“超限的幅度”——这两个概念在现场常被混用，读数时要分清。

第八段到第十二段是参数影响。 第八段改内环、第九段加设定值滤波、第十段扫主对象时间常数、第十一段扫外环 K_{p2} 与 T_{i2}、第十二段算外环开环裕度。第十段的两组数据分别用 `N=12000`（扰动试验）与 `N=8000`（跟踪试验）生成，窗口不同是有意的：扰动试验需要更长的恢复观察期，跟踪试验只需覆盖调节时间。

两个容易误读的地方。其一，第三段与第四段的“峰值偏差”是相对扰动加入前的稳态值算的，不是相对设定值，所以两段之间不能直接横向比较绝对值，只能比较“单回路与串级”的比值。其二，所有超调都按 `simlib.step_metrics()` 的口径算，参考值取 1.0；若把 `ref` 改成 2.0，超调百分比不变，但绝对偏差翻倍，**改参考值时不要连百分比一起“修正”**。

最后一句提醒：这十二段没有随机性（`noise=0`），同一台机器上重复运行结果逐位一致；一旦把 `noise` 打开，指标会在小数点后第二、三位抖动，此时应固定 `seed` 再比较，否则容易把随机差异当成参数效应。

45.12.9 把 `simulate()` 嵌进参数搜索

本章所有表格都是“手挑几档、逐档打印”，这是为了正文叙述清楚。若要做参数搜索，`simulate()` 的接口本身就能直接用，不必改动内部结构。

写法。 两层循环遍历 `c1=(kp1, kp1/Ti1, 0)` 与 `c2=(kp2, kp2/Ti2, 0)`，每次调用 `simulate(G1, G2, cascade=True, c1=..., c2=..., N=...)`，再用 `metrics(res)` 取超调、上升时间、调节时间、稳态值，用 `np.max(np.abs(res["u"]))` 取阀位峰值。四列结果直接拼成一张表，与表 45-8 至表 45-11 同构。

先筛不可行，再排序。 参数搜索最容易犯的错是把所有点按超调排序，然后选一个“超调最小”的点——它往往是阀位峰值超标或调节时间为 `nan` 的点。正确顺序是先用硬约束过滤：阀位峰值是否在行程内、饱和占比是否可接受、调节时间是否有限；过滤完再按超调或调节时间排序。**硬约束不过关的点，指标再好也不能用。**

三个口径必须统一。 其一，所有候选点用同一个 `N`，否则调节时间会因观察窗口不同而不可比；其二，`ref` 一律取 1.0，与正文一致；其三，若要比较抗扰性能，必须用 `dist_test()` 而不是阶跃跟踪，两者的最优参数并不相同（§45.4.7 已说明这个折中）。

成本。 每次调用是一个 N 步的 Python 循环，$N = 8000$ 时单次耗时在可接受范围内，几十到上百组参数可以在一轮内跑完。真正的瓶颈不是 `simulate()`，而是把结果整理成可读的表——建议每跑完一组就打印一行，而不是全部存下来最后再格式化，这样中途发现异常可以立刻停下。

不要用它做优化器的内层。 `simulate()` 是带状态机的逐步循环，不可微、噪声为零但不平滑（限幅、多速率都会引入跳变），把它塞进梯度类优化器只会得到无意义的结果。它适合网格搜索、坐标轮换、以及“人工挑几档看趋势”，这也正是本章的用法。

留档。 搜索出的每组参数都应连同当时的对象模型、采样周期、指标口径一起记下来。同一组 K_{p1}, K_{p2} 配在不同的 T_{s1} 上，得到的带宽比与超调并不相同；只记参数不记条件，下次复现时会对不上。§45.8.8 的整定记录表可以直接拿来当模板。表格按章节归档，不要散落在聊天记录与临时文件里，否则半年后没人能复原当时的口径。

第46章 前馈控制与复合控制

46.1 动机与直观理解

46.1.1 一个现场场景

第 45 章的串级解决的是“扰动进入对象之后，用快回路把它尽早压住”。但它有一个前提：扰动本身不可测，只能等它对副变量产生影响后再反应。如果扰动其实是可以测量的，还有更早的一步可走——**在扰动进入对象之前就动手**。

考虑一台换热器：蒸汽流量阀开度 u 控制出口温度 y，入口物料温度 d 是主要扰动。入口温度突然下降 1\,^\circC，物料要走完管道、经过管壁传热，出口温度才开始下降；等温度变送器看到变化、控制器算出差值、阀门动作，扰动已经在对象里走了十几秒。反馈控制再快，也只能“事后补救”。

本章的算例把这件事量化。取主通道与扰动通道分别为

$$G_p(s)=\frac{1.2\,e^{-2s}}{10s+1},\qquad G_d(s)=\frac{0.8\,e^{-6s}}{4s+1}$$

扰动幅值 -1.0、$t=40$ s 加入阶跃，纯反馈的峰值偏差为 0.4706，恢复到 $\pm 2\%$ 带内要 31.65 s。若入口温度可以测量，前馈可以在同一时刻就给出一个反向的阀门动作，让扰动还没传到出口就被抵消掉。

46.1.2 反馈为什么慢

反馈是“误差驱动”的：扰动先改变被控量，测量到误差，控制器才动作。这条链上有四段时间。

对象纯滞后。 本章主通道 2 s、扰动通道 6 s。也就是说，扰动从测量点走到出口要 6 s，而阀门动作走到出口只要 2 s——两者差 4 s。这 4 s 是前馈可以“抢”回来的时间。

对象惯性。 扰动通道时间常数 4 s、主通道 10 s，阶跃要走过几个时间常数才显现。

测量与采样。 变送器有滤波，DCS 有扫描周期，本章取 $T_s=0.05$ s，这一项相对前两项很小，但它决定了前馈的最短反应时间。

控制器运算。 常规 PID 一拍算完，可忽略。

四段加起来，反馈的“看见—动作”至少晚一个扰动通道的滞后加惯性。前馈不改变这四段时间，它改变的是**起点**：不等误差出现，直接根据扰动测量值算出该给多少控制量。

46.1.3 前馈在做什么：把扰动通道抵消掉

设前馈通道为 $G_{ff}(s)$，控制量由两部分相加：

$$u(s)=u_{fb}(s)+G_{ff}(s)\,d(s)$$

若暂时不管反馈（令 $u_{fb}=0$），被控量为

$$y(s)=\left[G_d(s)+G_p(s)G_{ff}(s)\right]d(s)$$

要让它对任意 d 都为零，只需

$$G_{ff}(s) = -\frac{G_d(s)}{G_p(s)} \tag{46-1}$$

这就是**理想前馈**。代入本章对象：

$$G_{ff}(s) = -\frac{0.8}{1.2}\cdot\frac{10s+1}{4s+1}\,e^{-4s} = -0.667\cdot\frac{10s+1}{4s+1}\,e^{-4s} \tag{46-2}$$

三个因子各有含义。负号表示“扰动使温度下降，前馈就让蒸汽阀开大”，方向相反；$(10s+1)/(4s+1)$ 是超前-滞后环节，用来匹配两个通道的动态差异；e^{-4s} 表示**要等 4 s 再动**——扰动比控制作用多走 4 s，前馈若立刻动作，反而会早到 4 s 而帮倒忙（§46.6 会给出延迟差 0.5 s 就使前馈失效的数据）。

46.1.4 结构：三个信号相加

图 46-1 给出复合回路的信号关系。与第 45 章的串级相比，它多了一条从扰动测量直接到执行器的通路，少了“副变量”这一环。

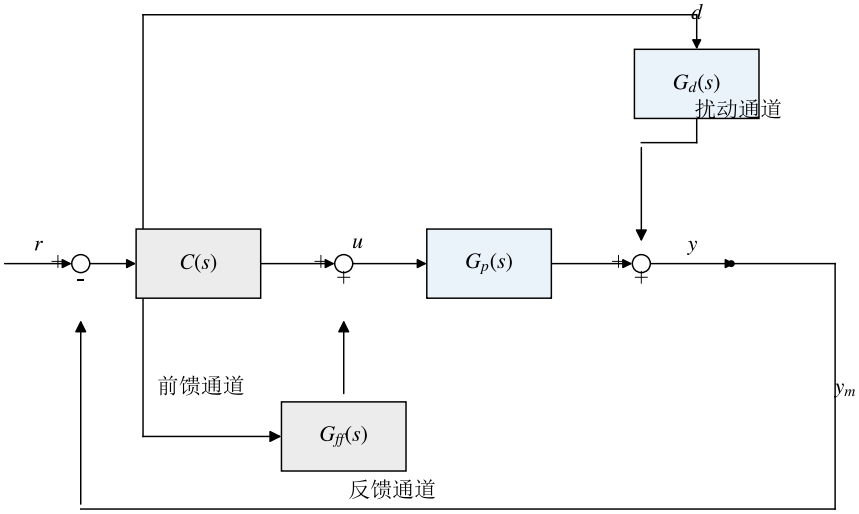

图 46-1　前馈-反馈复合回路：扰动 d 经 G_d 进入输出，同时经 G_ff 前馈到控制量求和点

图中有三个信号：扰动测量 d、前馈输出 u_{ff}、反馈输出 u_{fb}。执行器收到的是二者之和。三条通道的分工是：

- **扰动通道** G_d：扰动如何影响被控量，决定前馈“要抵消多少”；
- **前馈通道** G_{ff}：按扰动测量算出补偿量，是开环的，不参与反馈；
- **反馈通道** $C(s)$：兜底，负责前馈没抵消干净的部分、模型误差、以及其他不可测扰动。

前馈是**开环**的：它不看 y，因此不改变闭环特征方程，也就不改变稳定性（§46.2.4 严格说明）。代价是它的误差没有自我修正能力——模型错多少，残差就留多少，最后仍要靠反馈收尾。

46.1.5 三个常见误解

误解一：有了前馈就不需要反馈。 前馈只对“可测且模型已知”的扰动有效。本章把扰动通道增益改小 20%（前馈仍按名义值设计），动态前馈的峰值偏差从 0.0012 涨到 0.1188，是原来的 99 倍；稳态偏差最终仍由反馈积分拉回零。**前馈管动态峰值，反馈管稳态与模型误差**，两者缺一不可。

误解二：前馈越复杂越好。 理想动态前馈把峰值压到 0.0012，但前馈输出峰值 1.654，是静态前馈 0.667 的 2.5 倍；若扰动测量有 $\sigma = 0.02$ 的噪声，动态前馈输出的抖动标准差 0.0309，静态前馈只有 0.0124。复杂前馈用执行器行程和噪声换来更小的峰值，是否划算要看阀门余量与测量品质（§46.9）。

误解三：静态前馈没什么用。 静态前馈只有一个增益，却把峰值从 0.4706 降到 0.2154，减少 54%，而且不放大噪声、不要求准确的动态模型。对大多数慢过程，静态前馈加反馈已经能拿到大部分收益，动态前馈是“锦上添花”而不是“必需”。

46.1.6 术语

- **前馈（feedforward）**：按扰动测量直接产生控制作用，不经过误差比较。
- **复合控制（composite control）**：前馈与反馈并存的结构，本章的主角。
- **不变性（invariance）**：输出对某扰动完全无响应。式 (46-1) 叫绝对不变性；只让稳态无差叫稳态不变性。
- **二自由度（2-DOF）**：设定值响应与扰动响应可以分别设计。参考前馈是其中一种实现（§46.2.7）。
- **静态前馈 / 动态前馈**：前者只有增益，后者含超前-滞后等动态环节。
- **参考前馈**：从设定值而不是扰动引出的前馈，用于改善跟踪。

46.1.7 本章要回答的三个问题

问题一，前馈通道怎么算、能不能实现？ 理想解 $G_{ff} = -G_d/G_p$ 可能非因果、可能分子阶次高于分母，工程上要判断哪些部分能实现、哪些必须近似（§46.2–§46.3）。

问题二，模型不准、延迟对不齐时还剩多少收益？ 本章会给出增益偏差 $\pm 20\%$、延迟偏差 ± 0.5 s 的定量结果，并说明为什么“前馈只在自己准确的频段内有效”（§46.4–§46.7）。

问题三，工程上怎么落地？ 滤波、限幅、无扰投切、模型在线校正，每一项都会影响前馈能不能长期用下去（§46.8–§46.11）。

本章路线与全书一致：先建立直观与数学（§46.1–§46.2），再给设计步骤与连续、离散结果（§46.3–§46.5），然后讨论稳定性、参数与整定（§46.6–§46.8），最后是改进、落地、边界与代码（§46.9–§46.12）。所有数字来自 `code/ch046_sim.py` 的实跑输出。

46.1.8 前馈与串级：两条不同的路

第 45 章的串级与本章的前馈常被拿来比较，因为二者解决的是同一类问题——把扰动挡在主被控量之外——但手段完全不同。

串级靠**副回路**。它把扰动进入的那条通道包进一个快速内环，扰动先影响副变量，内环在它传到主变量之前就把它压住。串级不要求知道扰动具体是什么，只要求存在一个能及时反映扰动的副变量，并且内环比外环快得多。

前馈靠**测量**。它直接量出扰动，按模型算出一个抵消量。前馈不引入新的闭环，因此不带来新的稳定性问题；但它要求扰动可测，而且测量必须早于扰动对输出的作用。

判据因此很清楚：

- **扰动从副回路内部进入、副变量可测**，优先选串级。副回路的抑制不依赖扰动模型，鲁棒性更好。
- **扰动可测但构不成副回路**（入口温度、原料浓度、环境温度、燃料热值），选前馈。这类量没有“流量”那样的中间可调变量，只能靠测量加模型。

- **两者都满足**，叠加使用：串级压住阀门与蒸汽侧的快速波动，前馈削掉负荷侧的大幅慢变。这是后续章节常见的组合结构。

本章的换热器可以用一句话分清：蒸汽压力波动走串级，入口温度波动走本章的前馈。若把两者用反——用前馈去对付压力波动（压力测点噪声大、且与蒸汽流量构成不了副回路），或用串级去对付入口温度（入口温度没有可调的中间变量）——结构上都装得上，但性能与维护成本都会明显变差。

46.1.9 一条趋势线上的时间账

前馈的作用可以用一条时间线看清。本章扰动在 $t_0 = 40$ s 加入，扰动通道纯滞后 6 s，主通道纯滞后 2 s，前馈延迟 4 s。于是：

- **40 s**：扰动发生，扰动测量立即变化，但出口温度还没动；
- **40–44 s**：前馈在延迟缓冲里等待，输出保持原值。这 4 s 不是浪费，而是必须——若此时就动作，补偿会早于扰动 4 s 到达出口，反而制造一个反向偏差；
- **44 s**：前馈开始输出，经主通道 2 s 纯滞后与 10 s 一阶惯性逐步作用；
- **46 s**：扰动经 6 s 滞后到达出口，同一时刻前馈的补偿也到达出口，两者在这一点上“撞车”并相互抵消。

这条时间线是判断前馈参数对不对的最快方法：把 u_{ff} 与出口温度画在同一张趋势图上，若 u_{ff} 的起点比出口温度开始变化的时刻**早** τ_p，延迟就对了；早得太多说明 n_{ff} 偏小，晚得太多说明 n_{ff} 偏大。现场调试时，这一眼往往比算一遍传函更可靠（§46.8.4 会给出细扫方法）。

46.1.10 两条通道的物理来源

本章从头到尾用 $G_p = 1.2e^{-2s}/(10s+1)$、$G_d = 0.8e^{-6s}/(4s+1)$ 这两条通道，但没有解释它们为什么长这样。理解这一点，才能判断换一台设备时参数该怎么估。

主通道是“蒸汽流量→出口温度”。蒸汽凝结放热，热量先传给管壁，再由管壁传给物料，两次热阻串联，宏观上表现为一个一阶惯性，时间常数 10 s 对应换热器与物料的热容。纯滞后 2 s 来自蒸汽阀到换热段的输送与混合时间。增益 1.2 的量纲是“单位阀门开度引起多少度”，取决于换热面积与蒸汽潜热。

扰动通道是“入口温度→出口温度”。物料带着热量直接流过去，不经过管壁，因此惯性小得多，时间常数 4 s；但入口温度的测点通常装在离换热器很远的上游管道上（为了抢出提前量），物料从测点走到出口要 6 s，所以纯滞后反而比主通道长。增益 0.8 小于 1，因为沿途有散热与混合，入口的 1 ℃ 波动传到出口已经衰减成 0.8 ℃。

两条通道的这三个差别不是巧合，而是一般规律：

- **扰动通道惯性小**：扰动直接改变物料本身的状态，而控制作用要经过执行器与传热环节；
- **扰动通道滞后长**：测点为了“提前”必须放在上游，这段距离就是天然的时间窗；
- **增益比接近 1**：同一股物料、同一个被控量，两个增益量级通常相当，因此 K_{ff} 的绝对值常在 0.5–2 之间。

由此可以推出一条工程判据：**前馈可行性取决于“测点离扰动源近、离执行器远”**。若把入口温度测点装在换热器出口附近，滞后差变成零甚至为负，前馈就失去了立足点。反过来，若测点在上游很远，时间窗很大，但测量滞后也随之增大（§46.3.9 的 τ_m 预算），两者需要折中。

46.2 数学原理

46.2.1 三条通道的代数关系

把图 46-1 写成方程。记设定值 r、被控量 y、可测扰动 d、控制量 u，反馈控制器 $C(s)$、主通道 $G_p(s)$、扰动通道 $G_d(s)$、前馈通道 $G_{ff}(s)$。执行器收到两路之和，前馈用的是扰动测量值（含噪声 n）：

$$u = u_{fb} + u_{ff}, \qquad u_{fb} = C(s)\,[r - y], \qquad u_{ff} = G_{ff}(s)\,[d + n] \tag{46-3}$$

被控量是扰动通道与主通道的叠加：

$$y = G_d(s)\,d + G_p(s)\,u \tag{46-4}$$

把式 (46-3) 代入式 (46-4)，令 $n = 0$（噪声单独在 §46.9 讨论），整理得

$$y = \frac{G_p C}{1 + G_p C}\,r + \frac{G_d + G_p G_{ff}}{1 + G_p C}\,d \tag{46-5}$$

式 (46-5) 是本章所有结论的出发点。它把输出分成两块：跟踪项只与 C、G_p 有关，扰动项则多了一个可以自由设计的 G_{ff}。注意分母 $1 + G_p C$ 里没有 G_{ff}——这一点在 §46.2.4 会展开，它是“前馈不影响稳定性”的全部原因。

46.2.2 绝对不变性条件

要让扰动对输出完全没有影响，只需式 (46-5) 第二项的分子恒为零：

$$G_d(s) + G_p(s) G_{ff}(s) \equiv 0 \tag{46-6}$$

式 (46-6) 称为**绝对不变性条件**。它的解就是式 (46-1) 的 $G_{ff} = -G_d / G_p$。这里换一个角度看：不变性是一个关于 s 的多项式恒等式，要求两个通道在所有频率上幅值相等、相位相反。只要模型有一点点偏差，恒等式就不成立，只能做到“在某个频段内接近成立”。这解释了为什么工程上前馈永远与反馈配对使用。

式 (46-6) 还有一个容易忽略的含义：**前馈抵消的是通道之差，不是扰动本身**。前馈并不“知道”扰动有多大，它只是让主通道产生一个与扰动通道等大反向的输出。因此扰动测量一旦有偏，前馈就会按同样的比例产生错误动作。

46.2.3 可实现性：因果与阶次

把本章对象代入式 (46-1)：

$$G_{ff}(s) = -\frac{K_d}{K_p}\cdot\frac{T_p s + 1}{T_d s + 1}\,e^{-(\tau_d - \tau_p)s} = -0.667 \cdot \frac{10s + 1}{4s + 1}\,e^{-4s} \tag{46-7}$$

一个传递函数要在实时系统里实现，必须满足两个条件。

因果性。 式 (46-7) 含 $e^{-(\tau_d - \tau_p)s}$，指数为负才能用缓冲区延迟实现。要求

$$\tau_d \geq \tau_p \tag{46-8}$$

本章 $\tau_d - \tau_p = 6 - 2 = 4$ s，可以做成 4 s 的纯延迟。反之，若扰动通道比主通道快（$\tau_d < \tau_p$），理想前馈需要 $e^{+(\tau_p - \tau_d)s}$，即“预知未来”，物理上不可实现。这时只能退而求其次：删掉超前项做静态前馈，或把扰动测量点前移，让测量真正提前。

真性（**relative degree**）。式 (46-7) 的分子、分母同阶，是 proper 的，可以直接用超前-滞后环节实现。一般地，要求

$$\deg D_d - \deg N_d \;\geq\; \deg D_p - \deg N_p \tag{46-9}$$

即扰动通道的相对阶不低于主通道。若不满足，G_{ff} 的分子阶次高于分母，需要理想微分；工程上用带滤波的近似微分代替，代价是高频段残差变大。

本章两项都满足，理论上可以做到峰值 0.0012（相对扰动幅值 1.0 仅 0.12%）。这不是“前馈特别好”，而是“这个算例的通道结构刚好允许绝对不变性”。

46.2.4 前馈不改变闭环特征方程

式 (46-5) 的两项共用分母 $1 + G_pC$。也就是说，闭环极点由 $1 + G_pC = 0$ 决定，与 G_{ff} 无关。前馈只改变扰动项的**分子**，相当于给扰动通道加了一对零点。

这条结论有三个直接推论。

第一，前馈不能把一个不稳定的反馈回路救回来。若 $1 + G_pC$ 有右半平面根，无论 G_{ff} 怎么设计，扰动响应都会发散。

第二，前馈也不会破坏一个稳定的回路。在线性范围内，加入前馈后增益裕度、相位裕度、穿越频率都不变。§46.6 会用实测裕度验证这一点。

第三，一旦进入非线性（前馈输出限幅、阀门饱和），这条结论就失效。本章实测：不限幅时峰值 0.0012，前馈限到 $[0, 1.0]$ 后峰值升到 0.1066，限到 $[0, 0.3]$ 后升到 0.3520——此时前馈已经退化成“半开环”，残差全部压给反馈。所以“前馈不影响稳定性”这句话必须加上“线性、不限幅”的前提。

46.2.5 稳态不变性与静态前馈

令 $s \to 0$，式 (46-7) 中惯性项趋于 1、延迟项趋于 1：

$$K_{ff} = G_{ff}(0) = -\frac{K_d}{K_p} = -\frac{0.8}{1.2} = -0.667 \tag{46-10}$$

只取这个常数的前馈叫**静态前馈**，它满足的是**稳态不变性**：扰动过去很久、系统稳定后，输出回到设定值，前馈不需要积分器也能做到无静差。

代价是动态过程完全没有补偿。静态前馈的残差为

$$E_{\text{stat}}(s) = G_d(s) + K_{ff}G_p(s) = K_d\left[\frac{e^{-6s}}{4s+1} - \frac{e^{-2s}}{10s+1}\right] \tag{46-11}$$

低频时两项几乎抵消（$\omega = 0.01$ rad/s 处残差 0.01612），频率升高后相位差拉开，残差迅速变大：$\omega = 0.249$ 处 0.35953，$\omega = 0.497$ 处 0.41361。这就是静态前馈“只能压低峰值、压不到零”的数学原因。

46.2.6 残差通道与“有效频段”

定义残差通道

$$E(s) = G_d(s) + G_{ff}(s)G_p(s) \tag{46-12}$$

它就是式 (46-5) 中扰动项的分子，也是前馈“没抵消掉的部分”。两种常见失配有简洁的解析形式。

增益失配。 设实际前馈是理想值的 κ 倍，即 $G_{ff,a} = \kappa G_{ff}$，则

$$E(s) = (1 - \kappa)\, G_d(s) \tag{46-13}$$

残差形状与扰动通道完全相同，只差一个比例。本章 $\kappa = 0.8$ 时，$|E|$ 在低频为 $0.2 \times 0.8 = 0.16$，实测 0.15987；到 $\omega = 0.992$ rad/s 降为 0.03909，因为 $|G_d|$ 本身随频率衰减。$\kappa = 1.2$ 时残差为 $0.2|G_d|$，与 $\kappa = 0.8$ 完全对称——实测两组数字逐点相同，说明增益失配的方向不改变残差大小，只改变符号。

静态前馈。 残差即式 (46-11)。低频很小、中频最大、高频又回落，形状不是单调的。这提示一件事：**静态前馈的有效频段在低频，动态前馈的有效频段可以推到中频**。若扰动主要是慢漂移，静态前馈足够；若扰动含快速成分，必须补动态环节。

有了 $E(s)$，复合回路的扰动响应可以写成

$$\frac{y(s)}{d(s)} = \frac{E(s)}{1 + G_p(s)C(s)} \tag{46-14}$$

前馈把“扰动 → 输出”的分子从 G_d 换成 E，剩下的仍由反馈的灵敏度函数收尾。这也说明前馈与反馈不是竞争关系，而是串联在同一根分子上的两级衰减。

46.2.7 二自由度分解

把式 (46-5) 改写成标准形式：

$$y = T(s)\, r + S(s)\, E(s)\, d, \qquad T = \frac{G_p C}{1 + G_p C}, \quad S = \frac{1}{1 + G_p C} \tag{46-15}$$

T 是补灵敏度函数，S 是灵敏度函数。反馈控制器 C 同时决定 T 与 S，二者被 $S + T = 1$ 绑死——想加快跟踪就必然放大某些频段的扰动。前馈在 S 的分子上乘了一个 $E(s)$，等于在**不改变 S 的前提下**单独压低扰动通道。这就是“二自由度”的确切含义：一个自由度（C）定回路形状，另一个（G_{ff}）定扰动抑制。

参考前馈是同一思想的另一用法：从设定值而不是扰动引出一条前馈，

$$u_r = \frac{1}{K_p}\, r \tag{46-16}$$

它让执行器在误差出现之前就先给出稳态所需的开度，跟踪因此变快。但式 (46-16) 是纯比例、无延迟匹配的，本章实测无滤波时超调 22.72%，执行器峰值 2.273；把设定值经 10 s 一阶滤波后再送入，超调降到 5.01%，峰值 1.022。**参考前馈的收益与冲击是同一枚硬币的两面**，滤波就是在两者之间取平衡（§46.7）。

46.2.8 从连续到离散的入口

工程实现时，式 (46-7) 要拆成三块：增益 -0.667、超前-滞后 $(10s + 1)/(4s + 1)$、纯延迟 e^{-4s}。

增益直接乘；超前-滞后用 Tustin 或零极点匹配离散；纯延迟在 $T_s = 0.05$ s 下就是 80 拍的环形缓冲区。三块都不难，难的是**三块必须同步**：延迟少一拍、超前-滞后系数差一点，残差就会从 0 升到可观测的量级。

本章实测了采样周期的影响：T_s 从 0.05 s 增到 2 s，峰值从 0.0012 升到 0.0578，IAE 从 0.0206 升到 0.6989。采样越慢，延迟量化的误差越大（80 拍变成 2 拍），前馈的动作时刻越粗。这条曲线是 §46.5 的主题。

46.2.9 与前馈相邻的另一种思路：由果推因

前馈不是唯一利用模型抵消扰动的办法。扰动观测器走的是另一条路：先用主通道的名义模型算出“这点控制量本应产生多少输出”，再与实际输出相减，把差值归因于一个等效扰动，然后反向补偿。前馈是**由因推果**——看到扰动，按模型算它的影响；观测器是**由果推因**——看到偏差，按模型反推扰动的等效大小。

两者的模型需求不同。前馈需要扰动通道与主通道的**开环模型** G_d、G_p，两个都要准；观测器主要需要主通道的名义模型，并要求它可逆。前馈的模型误差原样进入残差；观测器的误差被反馈闭合，有自我修正的成分，但它必须等偏差出现才能估计，时间上天然晚一步。

可实现性的困难也相似。观测器求逆时，若名义模型相对阶较高，逆是非真的，必须加低通滤波截断高频——这与本章给前馈加 τ_f 是同一个交易：用带宽换可实现性。滤波越宽，估计越快、噪声越大；越窄，越平滑、越迟钝。

有一条判据值得记住：**扰动可测且测量足够早，用前馈；扰动不可测或测点太晚，才考虑观测器或纯反馈**。观测器的性能上限由模型精度与滤波带宽共同决定，它无法突破“偏差出现之后才能动作”这一条，本质上更接近“带模型预测的反馈”。

还有一处本质差别。前馈只看 d、不看 y，所以式 (46-5) 的分母里没有 G_{ff}，闭环极点不变；观测器用了 y，它属于反馈，会改变闭环极点，滤波设计不当还会吃掉裕度。这也是工程上“能测就做前馈、测不到才做观测器”的顺序由来。

46.2.10 时域残差与频域残差是同一件事

式 (46-12) 把残差写成 $E(s) = G_d + G_{ff}G_p$，式 (46-13) 又把它拆成 $G_d(1 - e^{-\Delta s})$ 这样的形式。§46.4 用极值算峰值，§46.6 用 $|E(j\omega)|$ 画幅频，看起来是两套方法，其实是同一个量的两个投影。

时域里，残差对阶跃扰动的响应是 $E(s)/s$ 的拉氏反变换，峰值就是这条曲线的最大值。频域里，$|E(j\omega)|$ 描述的是“每个频率成分被残留多少”。两者通过阶跃的频谱 $1/(j\omega)$ 联系：**低频段决定拖尾，中频段决定峰值**。这也解释了为什么静态前馈的峰值降了一半、拖尾反而变长（§46.4.2）——它在低频段补得准，在中频段补不准。

延迟误差是理解这个联系的最好例子。设前馈的延迟偏差为 Δt，则

$$E(j\omega) = G_d(j\omega)\left(1 - e^{-j\omega\Delta t}\right), \qquad |1 - e^{-j\omega\Delta t}| = 2\left|\sin\frac{\omega\Delta t}{2}\right|$$

在低频（$\omega\Delta t \ll 1$）时，这个因子近似等于 $\omega\Delta t$，残差随频率线性上升——这就是“高通形状”的来历。频率越高残留越多，但 G_d 本身在高频衰减，两者相乘后在某个中频处达到最大。

用这组式子可以解释表 46-7 里那个看似矛盾的现象：延迟差 0.5 s 时峰值放大 78 倍，IAE 只放大 22 倍。峰值由中频段的最大残留决定，那里 $\omega\Delta t$ 已接近 1，放大倍数大；IAE 是对时间的积分，等效于按 $1/\omega$ 加权，低频权重更大，而低频段 $\omega\Delta t$ 很小，放大倍数自然小。**同一个残差，峰值看最坏频段，IAE 看全频段平均**。

实用上，这套对应关系给了一个省事的判断法：调参数时先看 $|E(j\omega)|$ 的曲线（不用跑时域仿真，几行代码就能画），确认残差在扰动的主要频段内是否被压住；再用时域仿真验证峰值与 IAE。前者快，后者真，两者互相校验，比只看其中一个可靠。

至此数学准备完成：式 (46-6) 给出目标，式 (46-8)(46-9) 给出可行性判据，式 (46-12) 给出误差的度量，式 (46-15) 给出与反馈的分工。§46.3 把这些变成可执行的设计步骤。

46.3 设计步骤

46.3.1 六步流程

把 §46.2 的结论变成工程动作，可以分成六步（图 46-2）。前两步是“能不能做”，中间两步是“做哪一种”，后两步是“做得对不对”。

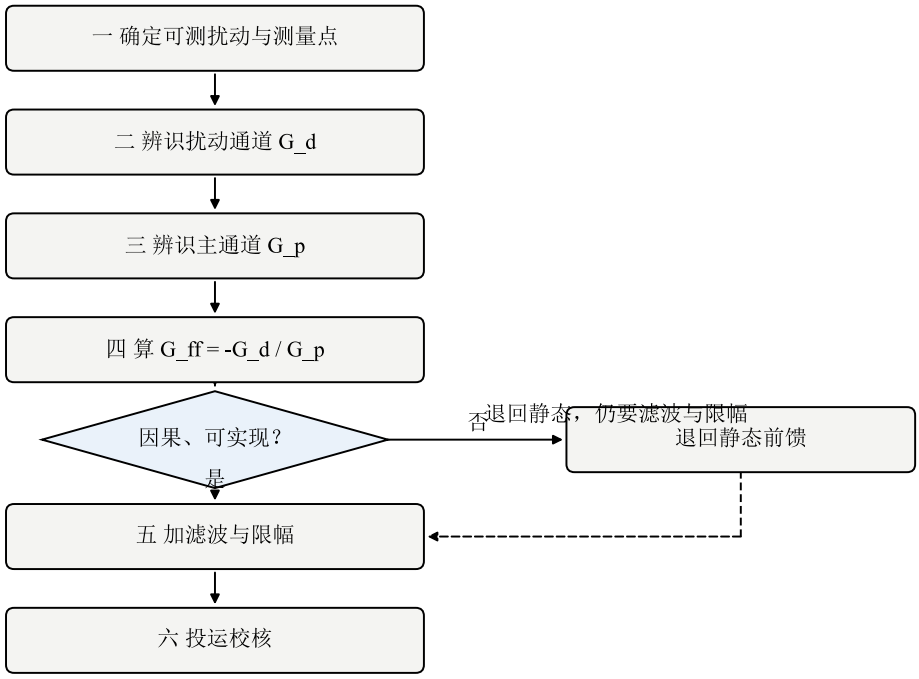

图 46-2　前馈设计六步流程：可行性判断在前，静态与动态分流在中，投切验收在后

图 46-2 右侧有一条回到“静态前馈”的支路。它对应最常见的情形：动态模型辨识不出来、或者扰动测量噪声太大，此时不要硬上动态前馈，退回静态前馈加反馈，收益仍有 50% 左右（§46.4）。设计流程要有退路，这是与前馈“开环、无自校正”的本质相匹配的。

表 46-1 把六步的输入、输出与本章取值列在一起，后文逐条展开。

步骤	要回答的问题	输入	输出	本章取值
一 可行性	扰动可测吗？来得及吗？	测量点位置、变送器滞后	是否继续	$\tau_m \ll 4$ s，继续
二 辨识	两条通道各是什么？	阶跃试验数据	$K_p, T_p, \tau_p, K_d, T_d, \tau_d$	$1.2, 10, 2, 0.8, 4, 6$
三 静态	稳态该补多少？	两个增益	K_{ff}	-0.667
四 选型	要静态还是动态？	扰动频谱、残差要求	结构	动态
五 动态	超前-滞后、延迟、滤波取多少？	四个时间常数	$T_1, T_2, \tau_{ff}, \tau_f$	$10, 4, 4, 1$
六 投切	怎么上线、怎么验收？	限幅、切换逻辑	可投运的前馈	$[0, 1.0]$，斜坡投入

表 46-1　前馈设计六步的输入、输出与本章取值

46.3.2 第一步：扰动可测，而且“来得及”

可测是前提，但“可测”不等于“可用”。前馈要抢的是 $\Delta\tau = \tau_d - \tau_p$ 这段时间，本章为 4 s。如果扰动测量本身要经过 3 s 的取样管、5 s 的分析仪滞后，那么等前馈算出结果，扰动早已到达出口，前馈就变成了“迟到的反馈”。

工程判据可以写得很朴素：**测量链路的总滞后（取样 + 变送 + 滤波 + 扫描）应小于 $\Delta\tau$ 的三分之一**。本章 4 s 的窗口对应 1.3 s 的测量预算，普通热电偶加 0.5 s 滤波可以满足；气相色谱这类分钟级滞后的测量则完全不可用。

还有一条容易被忽略：测量点必须位于扰动向被控量传播的路径**上游**。换热器里测入口物料温度可以，测出口管壁温度就没有意义——那时扰动已经作用完了。位置错了，后面的模型再准也没用。

46.3.3 第二步：辨识两条通道

前馈需要的是两条通道的**比值**，不是各自的绝对精度。这一点降低了辨识难度：只要两次阶跃试验在同一工况、同一负荷下做，增益的公共偏差会在比值里抵消一部分。

本章的辨识结果直接取自对象参数：主通道 $K_p = 1.2$、$T_p = 10$ s、$\tau_p = 2$ s；扰动通道 $K_d = 0.8$、$T_d = 4$ s、$\tau_d = 6$ s。阶跃响应两点法即可读出这四个数：取响应达到稳态值 63.2% 与 28.3% 的时刻，两者之差给出时间常数，外推给出纯滞后。现场若有噪声，多做几次取中位数比做一次精细拟合更可靠。

辨识要记录三件事：试验时的负荷、阀门开度、以及两条通道的增益符号。符号错了，前馈会从“抵消”变成“加倍”，这是投运阶段最危险的低级错误。本章 $K_p > 0$、$K_d > 0$，故 $K_{ff} < 0$：扰动使温度下降时，前馈要让阀门开大。

46.3.4 第三步：先把静态前馈做出来

不要一上来就做动态前馈。静态前馈只需要两个增益，当天就能算出来、当天就能投：

$$K_{ff} = -\frac{K_d}{K_p} = -\frac{0.8}{1.2} = -0.667 \tag{46-17}$$

本章实测，单加这一项，扰动峰值从 0.4706 降到 0.2154，降幅 54.2%；IAE 从 5.5520 降到 2.8975，降幅 47.8%。用两个常数换一半的扰动抑制，这是全书性价比最高的一处改进。

但要注意一个反直觉现象：恢复时间从 31.65 s **延长**到 44.95 s。原因是静态前馈把响应曲线从“高而窄”压成“低而宽”——峰值下来了，可拖尾变长，进入 $\pm 2\%$ 带反而更晚。这说明**峰值、IAE、恢复时间是三个不同口径**，不能只看一个。若工艺指标是“最大偏差不超限”，静态前馈很合适；若指标是“尽快回到带内”，它可能帮倒忙。§46.7 会专门讨论这三个口径的取舍。

46.3.5 第四步：判断要不要动态

判断依据是**扰动的主要频率成分落在残差的哪个频段**。静态前馈的残差（式 46-11）在 $\omega = 0.01$ rad/s 处只有 0.01612，到 0.249 rad/s 已涨到 0.35953，接近扰动通道本身的低频幅值 0.8 的一半。

换算成时间尺度：$\omega = 0.01$ rad/s 对应 628 s 的周期，$\omega = 0.25$ rad/s 对应 25 s。也就是说，静态前馈能对付“几分钟才变一次”的慢漂移，对付不了“几十秒一个起伏”的扰动。本章的阶跃扰动含有丰富的快变成分，因此动态前馈才有 0.0012 对 0.2154 的巨大差距。

现场可按三条问：

- 扰动是阶跃、慢斜坡、还是周期脉动？前两者静态前馈够用，后者需要动态。

- 工艺对峰值的要求是“不超报警线”还是“几乎不动”？前者静态够，后者要动态。
- 有没有能力维护动态模型？没有就退回静态，别让前馈成为“投运三个月就没人敢动”的黑盒。

46.3.6 第五步：动态前馈的三个参数

动态前馈在静态增益之外再加三件东西：超前-滞后、纯延迟、以及一个可选的滤波。

超前-滞后由两条通道的时间常数决定：

$$\frac{T_1 s + 1}{T_2 s + 1} = \frac{T_p s + 1}{T_d s + 1} = \frac{10 s + 1}{4 s + 1} \tag{46-18}$$

分子时间常数取主通道、分母取扰动通道。物理含义是：扰动通道快（$T_d = 4$ s）、主通道慢（$T_p = 10$ s），前馈必须“先冲一下再收”，才能在动态上匹配。取反等于把快慢关系弄反，前馈的形状与两条通道之差不再相消，收益会明显缩水。

纯延迟取 $\tau_{ff} = \tau_d - \tau_p = 4$ s，$T_s = 0.05$ s 下为 80 拍。这一项对精度最敏感：偏差 0.5 s 峰值就从 0.0012 升到 0.0938，偏差 2 s 升到 0.3138，已经接近静态前馈的水平（§46.6 有完整数据）。

滤波 τ_f 是工程上的折中。本章扰动测量叠加 $\sigma = 0.02$ 噪声时，不加滤波的前馈输出抖动标准差 0.0309，$\tau_f = 0.5$ s 降到 0.0065，$\tau_f = 2$ s 降到 0.0030。代价是峰值从 0.0012 升到 0.1256（$\tau_f = 1$ s）再到 0.1957（$\tau_f = 2$ s）。本章推荐 τ_f 取 $\Delta\tau$ 的 1/8 到 1/4，即 0.5–1 s。

46.3.7 第六步：投切与验收

前馈是开环通道，投切必须无扰。做法是：投运前先让前馈输出跟踪当前稳态值（把 u_{ff} 初始化成 $K_{ff} \cdot d_0$，d_0 为当前扰动测量），再以 10–20 s 的斜坡把前馈从“跟随即刻值”过渡到“正常运算”，避免切换瞬间给阀门一个阶跃。

验收建议用四个指标，缺一不可：

指标	含义	本章目标值	实测
峰值降幅	相对纯反馈的峰值减少比例	≥ 50%	99.7%（动态）、54.2%（静态）
IAE 降幅	全过程偏差积分减少比例	≥ 40%	99.6%（动态）、47.8%（静态）
前馈峰值	是否超出阀门余量	≤ 阀门可用行程	1.654（需 1.7 倍余量）
噪声抖动	静默段前馈输出的标准差	≤ 量程 2%	0.0045（$\tau_f = 1$ s）

表 46-2　前馈投运的四项验收指标

四项里最容易失守的是第三项。动态前馈的峰值 1.654 是静态值 0.667 的 2.5 倍，若阀门只剩 1.0 的行程，前馈会在最需要它的时刻被限幅卡住。本章实测限到 $[0, 1.0]$ 后峰值回到 0.1066，收益从 99.7% 掉到 77.3%；限到 $[0, 0.7]$ 就基本等于静态前馈（0.2153）。**先算阀门余量，再决定要不要动态前馈**，顺序不能反。

46.3.8 设计核对表

把六步压缩成一张投运前必须逐项打勾的清单：

1. 扰动测量点在传播路径上游，测量总滞后 $< \Delta\tau/3$；
2. 两条通道在同一负荷下辨识，增益符号已确认；

3. 静态增益 $K_{ff} = -K_d/K_p$ 已算出并单独投运验证；
4. 已用扰动频谱确认需要动态环节，而非默认“越复杂越好”；
5. 超前-滞后时间常数取自 T_p/T_d，未取反；
6. 延迟 $\tau_{ff} = \tau_d - \tau_p$ 已按采样拍数取整并核对；
7. 滤波 τ_f 在噪声抖动与峰值之间取过折中；
8. 前馈输出限幅不高于阀门可用行程，且限幅后的性能已实测；
9. 投切有无扰逻辑，初始化值等于当前稳态前馈值；
10. 四项验收指标全部记录，并留一份纯反馈的对照曲线。

这十条里，第 3、5、6 条决定前馈“有没有用”，第 8、9 条决定前馈“能不能长期用”。前者靠数学，后者靠工程纪律。

46.3.9 先选对扰动变量

六步流程的第一步是“确认扰动可测”，但“可测”只是门槛，选哪个变量做前馈，对最终效果的影响比参数整定大得多。三条标准按优先级排列。

第一，要早于输出到达。 前馈的全部价值来自时间差 $\tau_d - \tau_p$，本章是 4 s。若测量环节自身滞后 τ_m（热电偶套管、取样管线、分析仪预处理），可用时间窗缩成 $\tau_d - \tau_p - \tau_m$。经验上要求 $\tau_m < (\tau_d - \tau_p)/3$，即本章不超过 1.3 s；超过这个数，前馈的动作时刻被推到扰动到达之后，收益迅速消失。工程上换一支细套管热电偶、把取样点前移，往往比调参数有效。

第二，要对输出的贡献显著。 前馈只能抵消它测量的那一路。若某变量波动大但对出口温度影响很小（K_d 小），做前馈的收益低于维护成本。判断方法是算稳态贡献 $K_d \Delta d$ 与总允许偏差的比值，超过 30% 才值得单独做一路。

第三，测量要有代表性。 单点测温可能落在混合不均的位置；换热器入口温度若分层，应取多点平均或装在混合器之后。测量没有代表性，前馈会按一个局部值去补偿整个截面，误差无法通过整定消除。

多个扰动都显著时，处理顺序是：先做贡献最大的那一路，验收后再加第二路。多路前馈的结构是各自独立的前馈块，输出在同一个求和点相加，各自限幅、各自滤波。不要图省事把几路信号先加权合成一个“等效扰动”——除非它们的动态确实相同（例如同一股物流的流量与温度可按热负荷 $F\Delta T$ 合成），否则合成会引入额外的模型误差。

最后一条容易忽略：**不要用被控量的下游信号做前馈**。例如用出口温度之后的回水温度做前馈，那个信号已经包含了控制作用，等于把反馈绕了一圈接进前馈，闭环特性会被悄悄改掉，§46.2.4 的“不进特征方程”也就不再成立。

46.4 连续情形

46.4.1 四种方案的响应形状

把纯反馈、静态前馈、动态前馈、动态前馈加一阶滤波四条曲线画在同一张图上（图 46-3），差别一眼可见。

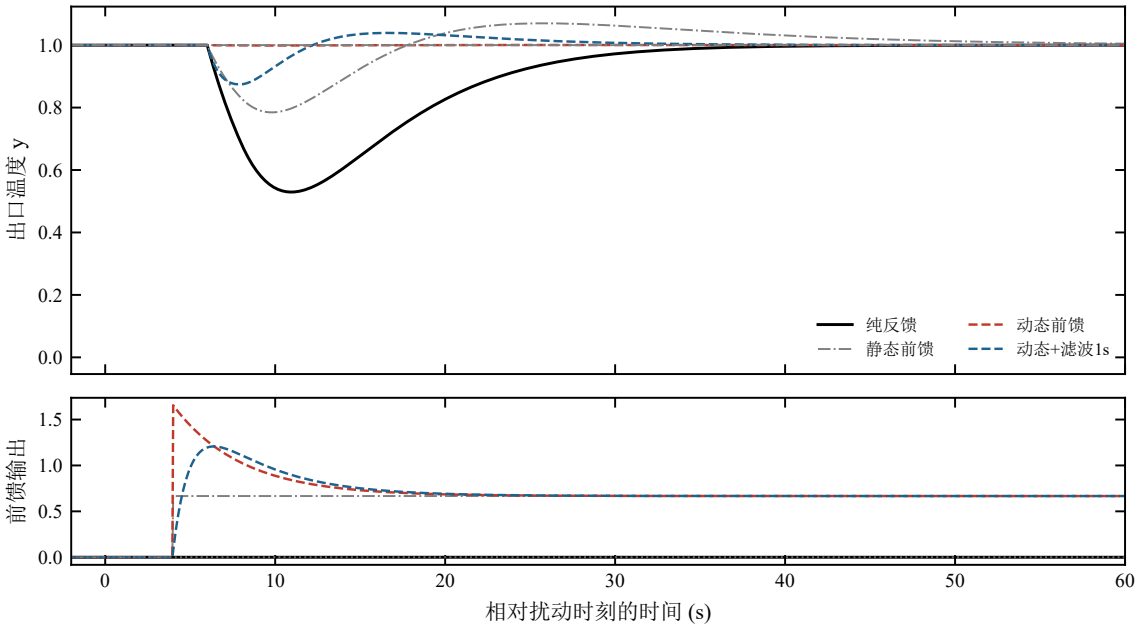

图 46-3　四种方案的扰动响应：纯反馈高而窄，静态前馈低而宽，动态前馈几乎贴住设定值，滤波后介于两者之间

图 46-3 上半幅是输出，下半幅是前馈输出。四条曲线的形状可以这样概括：

- **纯反馈**：峰值 0.4706，曲线先冲高再缓慢回落，恢复 31.65 s。这是“等误差出现再纠正”的典型形状。
- **静态前馈**：峰值 0.2154，曲线低而宽，恢复反而拉长到 44.95 s。前馈在扰动测量到之后 4 s 动作，再经主通道 2 s 滞后，恰好与扰动到达出口的时刻对齐，把第一波削掉一半；但它没有能力匹配动态，剩余偏差靠反馈慢慢磨。
- **动态前馈**：峰值 0.0012，曲线几乎是一条水平线。前馈输出在下半幅形成一个 1.654 的尖峰，形状与扰动通道的响应互补。
- **动态前馈 + 1 s 滤波**：峰值 0.1256，恢复 23.70 s。滤波把尖峰削到 1.207，代价是补偿动作变钝。

四条曲线的指标列在表 46-3。注意“恢复”一列：动态前馈为 0，因为它从未越过 $\pm 2\%$ 带；静态前馈的 44.95 s 比纯反馈还长，这不是数据错误，而是“低而宽”曲线的必然结果。

方案	峰值偏差	IAE	恢复时间/s	前馈峰值
纯反馈	0.4706	5.5520	31.65	0
静态前馈	0.2154	2.8975	44.95	0.667
动态前馈	0.0012	0.0206	0	1.654
动态 + 滤波 1 s	0.1256	0.9243	23.70	1.207
动态 + 滤波 2 s	0.1957	1.7013	29.20	1.035

表 46-3　四种方案与两种滤波的扰动响应（扰动 -1.0，$t_0 = 40$ s）

表 46-3 里最值得琢磨的是“动态 + 滤波 2 s”这一行：峰值 0.1957 与静态前馈的 0.2154 相差无几，但 IAE 只有 1.7013，比静态前馈的 2.8975 小 41%，恢复时间也短 15 s。**峰值相同不等于性能相同**，滤波后的动态前馈在拖尾段仍然比静态前馈更贴合扰动通道。这说明选方案时至少要同时看峰值与 IAE 两个口径。

46.4.2 静态前馈为什么只拿走一半

静态前馈的残差可以算得很干净。扰动与主通道的延迟已经由 4 s 的前馈延迟对齐，此后扰动通道的输出是 $-0.8(1-e^{-t/4})$，前馈经主通道产生的补偿是 $+0.8(1-e^{-t/10})$，两者相加：

$$e(t) = 0.8\left(e^{-t/10} - e^{-t/4}\right), \qquad t \geq 0 \tag{46-19}$$

两个指数项的稳态值相同，所以 $t \to \infty$ 时残差为零——这正是稳态不变性。但在中间过程，慢的 $e^{-t/10}$ 还没衰减完，快的 $e^{-t/4}$ 已经掉下去了，差值先增后减。

对式 (46-19) 求极值：令导数为零，得 $0.25e^{-t/4} = 0.1e^{-t/10}$，解出 $t^{*} = 6.1$ s，代回得 $|e|_{\max} = 0.262$。本章闭环实测峰值 0.2154，比开环估算小 18%，差额由反馈在 6 s 内已经动作提供。**静态前馈的极限就是这 0.26 的“形状差”**，再怎么调增益也消不掉，因为它是两个不同时间常数的差，不是一个比例问题。

这段推导也解释了为什么静态前馈的恢复时间会变长：式 (46-19) 的拖尾是 $0.8e^{-t/10}$，时间常数 10 s，比扰动通道的 4 s 慢得多。峰值被削掉一半，拖尾却换成了更慢的指数，进入 $\pm 2\%$ 带的时刻自然推后。

46.4.3 增益扫描：峰值最优不等于稳态最优

把静态增益从 -1.2 扫到 0，得到图 46-4。两条曲线的极小点不在同一位置，这是本章最值得记住的一张图。

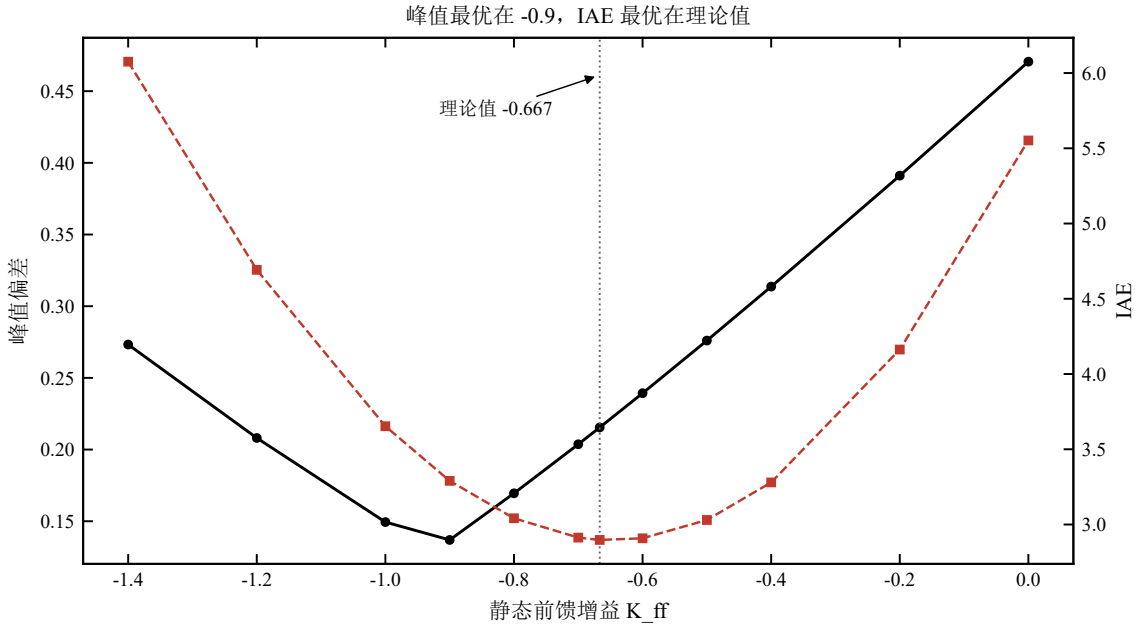

图 46-4　静态前馈增益扫描：峰值最优在 -0.9，IAE 最优在理论稳态值 -0.667

峰值曲线在 $K_{ff} = -0.9$ 处最低（0.1370），而 IAE 曲线在 $K_{ff} = -0.667$ 处最低（2.8975）。理论稳态值给的是 IAE 最优，不是峰值最优。原因还是式 (46-19)：多补一点（$|K_{ff}|$ 更大）会让前馈的“冲劲”超过扰动，在峰值段形成反向偏差，把正向峰压得更低；但多补的部分在拖尾段要由反馈反向拉回，IAE 因此变大。

表 46-4 摘了八个点。可以清楚看到：K_{ff} 从 -0.667 加到 -0.9，峰值降 36%，IAE 升 14%；继续加到 -1.2，峰值反弹到 0.2081，IAE 升到 4.6923。**过补偿有一个最优点，过了就开始两头受损。**

K_{ff}	峰值	IAE	恢复/s
-1.2	0.2081	4.6923	51.30
-1.0	0.1494	3.6531	49.40
-0.9	0.1370	3.2900	48.25
-0.8	0.1695	3.0415	47.00
-0.667	0.2154	2.8975	44.95
-0.5	0.2760	3.0301	41.40
-0.2	0.3911	4.1627	26.15
0	0.4706	5.5520	31.65

表 46-4　静态前馈增益扫描（真值 -0.667）

恢复时间一列更说明问题：它从 -1.2 的 51.30 s 单调降到 -0.2 的 26.15 s，随后在 $K_{ff}=0$ 处又回升到 31.65 s。三个指标给出三个不同的“最优”，工程上必须事先声明用哪个口径验收，否则调试时会陷入“怎么调都有人说不行”的循环。

对本章对象，建议仍取 $K_{ff}=-0.667$。理由不是它峰值最低，而是它对应稳态不变性，模型漂移时偏差方向可预期；靠过补偿压峰值，等于把系统的鲁棒余量换成一次性的指标好看。

46.4.4 增益失配：动态前馈的红利很脆弱

动态前馈的 0.0012 依赖模型准确。把扰动通道增益按 $0.5, 0.75, 1.0, 1.25, 1.5$ 倍变化（前馈仍按名义值设计），得到图 46-5。

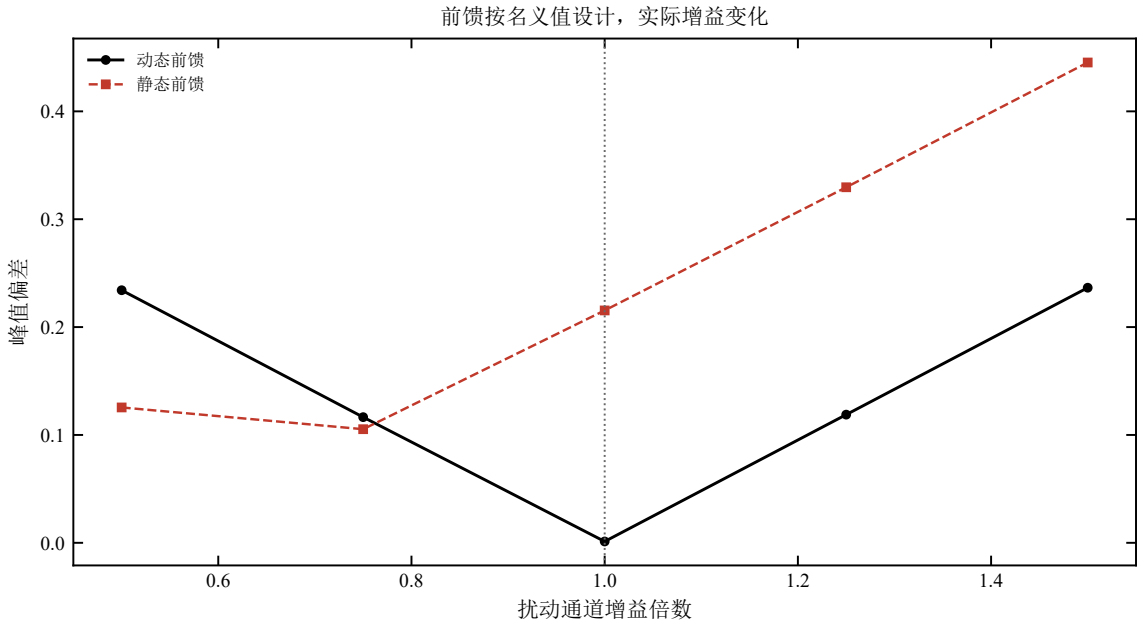

图 46-5　增益失配下的动态前馈：残差与偏差倍数近似成正比，0.5 倍与 1.5 倍的峰值几乎相同

设扰动通道实际增益是名义值的 κ 倍、前馈仍按名义值设计，则残差为 $(\kappa-1)G_d$，幅值与式 (46-13) 的 $|1-\kappa||G_d|$ 相同。峰值应随 $|1-\kappa|$ 线性增长。实测峰值 0.2342、0.1165、0.0012、0.1188、0.2365，与 $|1-\kappa|=$

$0.5, 0.25, 0, 0.25, 0.5$ 基本成比例：残差减半，峰值也减半。两端的细微不对称（0.2342 对 0.2365，差约 1%）来自扰动加入前基线未完全稳恒与峰值取样点的离散化，可视为对称。

这里有一个很实用的结论：**增益误差 50% 时，动态前馈的峰值 0.2342 已经不如静态前馈的 0.2154**。也就是说，动态前馈的高精度是一次“全有或全无”的红利——模型准，收益是数量级的；模型差一半，连静态前馈都不如，还要多承担 2.5 倍的阀门行程和噪声放大。投运前必须问一句：这条扰动通道的增益，我能保证在 ±10% 以内吗？

IAE 的对称性更好：0.5 倍与 1.5 倍分别为 2.7824 与 2.7754，差 0.25%。这说明积分型指标对失配方向不敏感，适合做长期趋势监控；峰值对失配幅值敏感，适合做报警限设计。

46.4.5 连续域的三条结论

把本节收拢成三句话。

第一，**静态前馈的收益有上限**。上限由两条通道时间常数之差决定，本章为 0.26，实测峰值 0.2154，已经接近这个上限。想再往下压，只能引入动态环节。

第二，**增益的选择取决于验收口径**。峰值、IAE、恢复时间三个最优值分别是 -0.9、-0.667、-0.2，彼此不重合。工程上应取稳态值 -0.667，把峰值指标让给动态环节去解决，而不是靠过补偿硬压。

第三，**动态前馈对模型精度的要求是陡峭的**。增益误差 25% 时峰值 0.1165，误差 50% 时 0.2342，后者已不如静态前馈。这决定了 §46.10 要用在线校正来维持模型精度，也决定了 §46.11 要把“模型可维护性”列为适用边界的第一条。

以上都是连续域结论。实际系统按 $T_s = 0.05$ s 采样，延迟要量化成整数拍，超前-滞后要离散化，这些会带来额外的性能损失，是 §46.5 的主题。

46.4.6 动态前馈的 0.0012 是从哪来的

绝对不变性在理论上要求峰值严格为零，实测是 0.0012，为扰动幅值的 0.12%。这个数字值得拆开看，因为它决定了“还能不能更好”。

残差有三个来源。第一是**采样离散化**：前馈的延迟、超前-滞后都在离散域实现，输出在 T_s 内保持常值，等效于给通道加了约 $T_s/2$ 的附加滞后，与连续域的精确反相不再重合。第二是**前馈与反馈的叠加**：前馈按测量值算，反馈按 y 算，两者在同一个求和点相加，反馈的微小动作会破坏前馈的精确抵消。第三才是**参数误差**：K_{ff}、T_1/T_2、n_{ff} 都按名义值取，与仿真对象的真值之间有舍入差。

三者中哪一项主导，表 46-5 已经给了答案：T_s 从 0.05 s 增到 2 s，峰值从 0.0012 涨到 0.0578，放大 48 倍，而模型参数一个都没动。这说明 0.0012 主要是**数值残差**，不是设计残差。设计残差要看增益失配那一组数据：增益差 25% 就是 0.1165，比 0.0012 大两个数量级。

这个区分有实际意义。追求 0.001 量级的峰值没有工程价值：本章 $\sigma = 0.02$ 的测量噪声，即使加了 1 s 滤波，前馈输出本身仍有 0.0045 的抖动（表 46-2），比 0.0012 大一个数量级；阀门的分辨率、定位器的死区也都远大于此。**动态前馈做得好不好，应该用 0.05 与 0.2 两条线来判断**——0.05 以内视为理想，0.2 左右视为与静态前馈相当，超过 0.25 说明动态环节没有起到作用，应回头查延迟与时间常数，而不是继续微调增益。

46.4.7 扰动变大时，结论怎么变

本章所有实验都用扰动 -1.0。读者自然会问：如果扰动是 -2.0 或 -0.5，前面这些数字还成立吗？

在无限幅、无饱和的理想条件下，结论按比例缩放。 对象是线性的、PI 是线性的、前馈通道（超前-滞后加延迟）也是线性的，三者串联仍是线性系统。扰动幅值乘 2，输出偏差、IAE、前馈输出峰值都乘 2，而**降幅百分比不变**：扰动 -2.0 时，纯反馈峰值应为 0.9412、静态前馈 0.4308、动态前馈 0.0024，与 -1.0 时的 0.4706、0.2154、0.0012 严格成二倍关系。这也是为什么正文用“降幅”而不是“绝对值”来比较方案——降幅是线性系统的无量纲指标，可以跨工况引用。

但**绝对量不能这样推**。前馈输出峰值 1.654 是按扰动 -1.0 算的；若最大扰动是 -2.0，前馈需要 3.3 的行程，阀门必须留出这么多余量。§46.3.7 的第三条验收指标（前馈峰值不超过阀门可用行程）必须按**最大可能扰动**校核，而不是按试验时用的那一个。

限幅一旦起作用，线性就不再成立。本章限到 $[0, 1.0]$ 时峰值 0.1066；若扰动加倍，前馈需求远超限幅，实际能提供的补偿仍是 1.0，相对补偿量减半，峰值会明显高于“0.1066 的两倍”。这种“扰动越大、前馈相对越弱”的特性，是限幅前馈的固有非线性，验收时应专门测一组不同幅值的扰动，画出“峰值—扰动幅值”曲线，看它在哪个幅值开始弯折（弯折点就是限幅开始起作用的点）。

实践上有两条用法。第一，**验收试验从小扰动起步**，逐级加倍，直到设计幅值，每级都记录峰值；若某级开始偏离线性，说明限幅或阀门速率已经介入。第二，**报警限按最大扰动设计，不要按试验扰动设计**：本章的动态前馈在 -1.0 时几乎完美，操作员容易误以为“任何扰动都没问题”，实际大幅扰动时它会退回限幅状态，行为接近静态前馈。

46.5 离散情形

46.5.1 三条通道都要落到同一个时标

连续域的式 (46-7) 在 DCS 里由三段代码实现：一个乘法、一个二阶差分方程、一个环形缓冲区。三者必须在**同一个任务、同一个采样时刻**执行，否则前馈内部就会出现拍级错位。

本章代码的顺序是：先读扰动测量 d_k，延迟 80 拍得到 $d_{ff,k}$，送超前-滞后得到 $u_{ff,k}$，同时用同一拍的 y_k 算反馈 $u_{fb,k}$，两者相加后输出。这个顺序保证前馈与反馈看到的是同一时刻的世界。若把前馈放在另一个扫描周期更慢的任务里，等效于给前馈额外加了半个到一个采样周期的滞后，§46.4 的延迟敏感性会立刻体现出来。

46.5.2 纯延迟的整数拍实现

纯延迟在离散域最自然：

$$n_{ff} = \mathrm{round}\!\left(\frac{\tau_d - \tau_p}{T_s}\right) = \mathrm{round}\!\left(\frac{4}{0.05}\right) = 80 \tag{46-20}$$

80 拍就是 80 个浮点数的环形缓冲区，内存开销可以忽略。取整带来的延迟误差不超过 $T_s/2$，本章 $T_s = 0.05$ s 时为 25 ms，相对 4 s 只有 0.6%，可以忽略。

需要注意两点。第一，**不要用小数延迟插值**。线性插值本质是一个低通滤波器，会额外引入相位滞后，把好不容易对齐的 4 s 又拖回去；整数拍加取整是更干净的做法。第二，n_{ff} 必须由两个延迟分别取整后相减，而不是先算差值再取整：

$$n_{ff} = \mathrm{round}\!\left(\frac{\tau_d}{T_s}\right) - \mathrm{round}\!\left(\frac{\tau_p}{T_s}\right) \tag{46-21}$$

两种算法在本章都得到 120−40=80，但当 τ_p 不是 T_s 的整数倍时，式 (46-21) 才与“两条通道各自延迟”的物理事实一致。

46.5.3 超前-滞后的离散化

代码用零阶保持（ZOH）离散，因为它对分段常值输入是精确的，且与执行器的实际行为一致。对

$$G(s)=K\frac{T_1 s+1}{T_2 s+1},\qquad K=-0.667,\ T_1=10,\ T_2=4 \tag{46-22}$$

ZOH 离散后有

$$G(z)=\frac{b_0+b_1 z^{-1}}{1+a_1 z^{-1}},\qquad a_1=-e^{-T_s/T_2}=-0.98758 \tag{46-23}$$

$$b_0=K\frac{T_1}{T_2}=-1.6667,\qquad b_1=-K\left(a_1+\frac{T_1}{T_2}-1\right)=1.6584 \tag{46-24}$$

注意 b_0 的物理含义：它是前馈在扰动阶跃瞬间的**跳变幅值**，等于静态增益乘时间常数比 $T_1/T_2=2.5$。本章实测前馈峰值 1.654，与解析值 1.667 只差 0.8%，差额来自采样与反馈的微小作用。这条关系很好用：看到 u_{ff} 的峰值，就能反推 T_1/T_2 有没有取错。

离散化还有两个必须核对的地方。**直流增益**：把 $z=1$ 代入式 (46-23)，应得 $K=-0.667$；若系数舍入后偏差超过 1%，稳态不变性就被破坏。**极点位置**：$a_1=-0.98758$ 对应 $z=0.98758$，反算时间常数 $-T_s/\ln 0.98758=4.00\,\text{s}$，与 T_2 一致。这两项核对花不了一分钟，却能挡住大部分手工离散的低级错误。

也可以改用 Tustin，系数为 $b_0=2.4907$、$b_1=-2.4783$、$a_1=-0.98758$（未乘增益）。Tustin 在低频段与连续域吻合更好，但高频段会翘尾；对前馈这种工作在低频的通道，两种方法差别很小，选哪种取决于组态软件现成的功能块。

46.5.4 采样周期的影响

把 T_s 从 0.05 s 逐步放大到 2 s，其余参数不变，得到图 46-8。

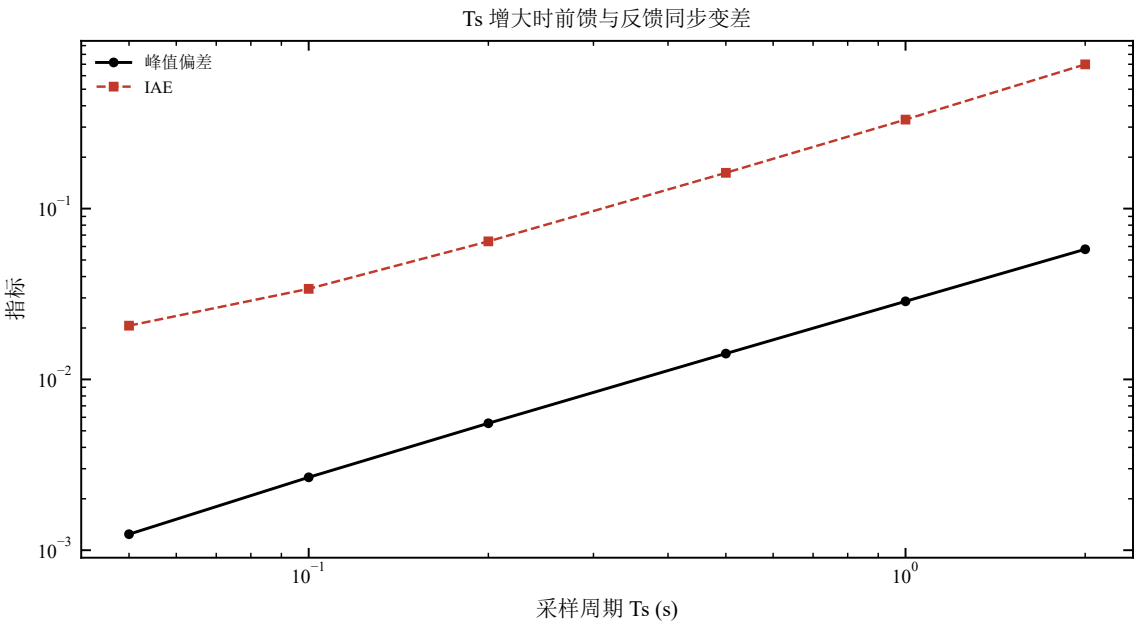

图 46-8　采样周期对动态前馈的影响：峰值与 IAE 随 Ts 单调增大，但即使 2 s 仍优于静态前馈

T_s/s	峰值	IAE	恢复/s
0.05	0.0012	0.0206	0
0.10	0.0027	0.0339	0
0.20	0.0055	0.0643	0
0.50	0.0142	0.1620	0
1.00	0.0287	0.3320	14.0
2.00	0.0578	0.6989	16.0

表 46-5　采样周期对动态前馈性能的影响（扰动 -1.0）

峰值从 0.0012 增到 0.0578，放大了 48 倍；IAE 从 0.0206 增到 0.6989，放大约 34 倍。这个退化不是延迟量化造成的——本章的 4 s 在六个采样周期下都能被整除，n_{ff} 分别为 80、40、20、8、4、2 拍，没有取整误差。退化来自两个机制。

零阶保持的相位滞后。 前馈输出在 T_s 内保持不变，等效于给通道加了约 $T_s/2$ 的平均延迟。$T_s = 2$ s 时，在 $\omega = 0.5$ rad/s 处额外滞后约 0.5 rad，即 29°，足以让原本精确反相的补偿变得不对齐。

测量与控制的阶梯化。 扰动测量每 T_s 才更新一次，前馈的“先冲一下”被拉成阶梯；反馈 PI 也同步变慢，闭环带宽下降，残差收尾更慢。两项叠加，才有了 48 倍的峰值退化。

但要把这张表读对：即使 $T_s = 2$ s，峰值 0.0578 仍只有静态前馈 0.2154 的 27%，IAE 0.6989 也只有 2.8975 的 24%。**采样慢不会让前馈失效，只是把它从“几乎完美”降到“仍明显优于静态”**。真正致命的是延迟对不准（§46.6）和模型失配（§46.4），而不是采样周期。

从工程角度，T_s 的选择应由闭环带宽决定，而不是由前馈决定。本章 PI 闭环的上升时间约 10 s，取 $T_s = 0.05$ s 是每上升时间 200 拍，余量很大；现场常见 0.5–1 s 的扫描周期，对应的峰值约 0.014–0.029，完全够用。

46.5.5 离散实现的四条纪律

第一，**延迟用整数拍**，且按式 (46-21) 分别取整。不要用插值延迟，那会引入额外低通。

第二，**超前-滞后核对直流增益与极点**。$z=1$ 处增益必须等于 K_{ff}，极点反算的时间常数必须等于 T_2。

第三，**前馈与反馈同拍计算**。放在同一个控制任务里，用同一个时间戳；跨任务传递要带时间标签，不能让前馈“看旧数据”。

第四，**系数用双精度或至少 32 位浮点**。$a_1=-0.98758$ 离单位圆很近，定点数舍入会明显改变极点位置；现场的组态软件多用浮点，这一条通常自动满足，但移植到嵌入式平台时要专门核对。

这四条都不涉及控制理论，却决定了 §46.4 的连续域结论能不能在 DCS 里复现。工程上“理论对、投运不对”的案例，多半栽在这类细节上。

46.5.6 延迟量化误差与扫描周期的匹配

§46.5.4 说 T_s 应按闭环带宽选，这里补一条来自前馈的约束：T_s 还要受延迟预算限制。

式 (46-21) 的两个取整各自带来不超过 $T_s/2$ 的误差，最坏情况叠加为 T_s。本章 $\tau_p=2$ s、$\tau_d=6$ s 都恰好是 $T_s=0.05$ s 的整数倍，量化误差为零，这是算例偏理想的地方。换成 $T_s=0.3$ s，$n_p=\mathrm{round}(6.67)=7$（2.1 s）、$n_d=\mathrm{round}(20)=20$（6.0 s），延迟差变成 3.9 s，误差 -0.1 s；换成 $T_s=0.9$ s，$n_p=2$（1.8 s）、$n_d=7$（6.3 s），延迟差 4.5 s，误差 $+0.5$ s——已经等于 §46.6.2 里“抹掉大半收益”的那个阈值。

若把 §46.6.4 的工程容差（延迟误差不超过 0.2 s）当作硬指标，则 $T_s\le 0.2$ s。现场常见的 0.5–1 s 扫描周期恰好做不到这一点：量化误差 0.5–1 s，与前馈的全部时间窗 4 s 相比占 12%–25%，动态前馈很难达到 0.05 的峰值。这类装置要么提高扫描频率（把前馈放在快速任务里），要么退回静态前馈——静态前馈不依赖延迟精度，只依赖增益比。

还有一处需要说明。式 (46-21) 是“分别取整再相减”，另一种写法是“先算延迟差再取整”，两者在不能整除时最多差一拍。前者与两条通道各自被离散的物理事实一致，后者直接最小化前馈的时刻误差。工程上不必在这半拍上纠结：实际延迟本身就有辨识误差，按式 (46-21) 算出初值，再用 §46.8.4 的细扫修正，比在纸面上争半拍有效得多。

46.5.7 计算量与存储：最不成问题的一环

初学者常担心“前馈会不会算不过来”。把这笔账算一遍，结论恰好相反：**计算量是这个回路里最不重要的一环**。

一阶超前-滞后的差分方程每拍只需要两次乘法、两次加法（$b_0d_k+b_1d_{k-1}-a_1u_{k-1}$）；纯延迟是一次数组取址；一阶滤波两次乘加；限幅两次比较；再加大约十次，一拍之内全部完成。存储上，80 拍的延迟缓冲区是 80 个浮点数，约 320 字节；加上几个状态变量，不到 1 KB。

对比一下：$T_s=0.05$ s 意味着 50 ms 内要算完，现代 DCS 的一个控制任务能在这段时间里执行上千个类似的块；即便用 8 位单片机，几十次浮点运算是微秒量级。**前馈从来不是被算力卡住的**。

真正卡住工程实现的是另外三件事。第一是**时序**：前馈必须与反馈在同一拍、用同一时间戳计算（§46.5.1），跨任务或跨网络传递会引入几十毫秒的抖动，比计算时间长一个数量级。第二是**数据质量**：坏值、冻结、超时（§46.10.7）比运算本身更容易出错，而且错得更隐蔽。第三是**数值精度**：$a_1=-0.98758$ 离单位圆很近，定点数舍入会改变极点位置（§46.5.5 第四条）。

所以组态时不必在前馈块上省资源，反而应该给它足够的字长、独立的采样任务和完整的数据质量判断。省下来的那点运算时间，换不来任何性能；省掉的时序保证，却会让前面所有的分析失效。

离散化之后，下一步要回答的是：前馈加进来，闭环还稳不稳？裕度变不变？这是 §46.6 的主题。

46.6 稳定性与性能

46.6.1 裕度不变：从公式到数字

§46.2.4 已经证明前馈不进特征方程，这里把数字补上。回路传递函数为

$$L(s) = C(s)G_p(s) = 1.2\left(1 + \frac{1}{10s}\right)\cdot\frac{1.2\,e^{-2s}}{10s+1} \tag{46-25}$$

在 10^{-3} 到 10 rad/s 的网格上逐点计算 $L(j\omega)$，得到增益穿越频率 $\omega_c = 0.1441$ rad/s、相位裕度 73.49°，相位穿越频率 $\omega_{180} = 0.7847$ rad/s、增益裕度 14.73 dB。这两个数字与第 45 章整定 PI 时看到的量级一致：相位裕度七十多度，属于“偏保守但很稳”的配置。

关键在于：式 (46-25) 里**没有** G_{ff}。不论前馈取静态、动态、加不加滤波，$L(s)$ 都不变，因此 ω_c、PM、GM 一个数字都不会动。代码第十二段没有对四种方案分别算裕度，因为算了也是同一组数——这不是偷懒，而是结构决定的。

同一段代码还打印了两种配置的跟踪指标：纯反馈与动态前馈都是 Mp 0.00%、t_r 10.068 s、t_s 19.750 s，逐位相同。原因是扰动为 0 时前馈输出恒为 0，前馈通道根本不参与设定值响应。这从另一个侧面说明：**前馈是扰动通道上的并联支路，不是反馈回路的一部分**。

46.6.2 延迟对不准：最敏感的一项

把前馈延迟在标称 4 s 上下拨动，其余参数不变，得到图 46-6。

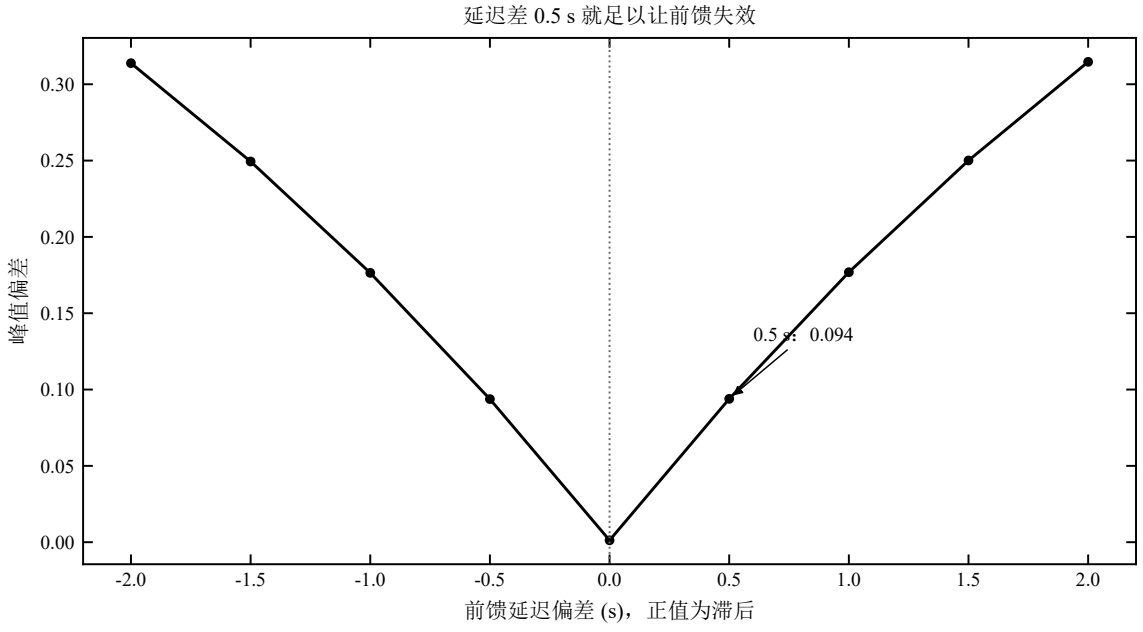

图 46-6　前馈延迟偏差对扰动响应的影响：±0.5 s 已使峰值放大约 78 倍，±2 s 后不如静态前馈

延迟偏差/s	峰值	IAE
-2.0	0.3138	1.8519
-1.0	0.1764	0.9272
-0.5	0.0938	0.4603
0	0.0012	0.0206
$+0.5$	0.0939	0.4833
$+1.0$	0.1769	0.9514
$+2.0$	0.3147	1.8769

表 46-6　前馈延迟偏差对性能的影响（标称 4 s）

正负偏差几乎对称，这与 §46.4 的增益失配一致：残差只与偏差的幅值有关。偏差 0.5 s 时峰值 0.0938，是理想值的 78 倍；偏差 2 s 时 0.3138，已经**不如静态前馈的 0.2154**。换句话说，延迟错 2 s，动态前馈就白做了。

这个结果有干净的解析解释。设实际延迟比标称多 Δ，则实际前馈为 $G_{ff}e^{-\Delta s}$，残差为

$$E(s) = G_d + G_{ff}e^{-\Delta s}G_p = G_d\left(1 - e^{-\Delta s}\right) \tag{46-26}$$

在频域，$|1 - e^{-j\omega\Delta}| = 2|\sin(\omega\Delta/2)| \approx \omega\Delta$（小 $\omega\Delta$ 时）。这是一个**高通形状**：直流处为零，频率越高残差越大。所以延迟误差不破坏稳态，专门破坏动态峰值——这正好解释了为什么峰值放大 78 倍，IAE 只放大 22 倍。

式 (46-26) 还给出一个工程推论：**前馈补偿的频段越高，对延迟精度的要求越严**。若只想补偿 $\omega < 0.05$ rad/s 的慢漂移，0.5 s 的延迟误差只带来 $0.05 \times 0.5 = 2.5\%$ 的残差；若要补偿到 0.5 rad/s，同样的误差就是 25%。这决定了动态前馈必须先把延迟核准，再谈超前-滞后。

46.6.3 残差频率特性：有效频段在哪里

图 46-10 把三种情况的残差幅频曲线画在一起。

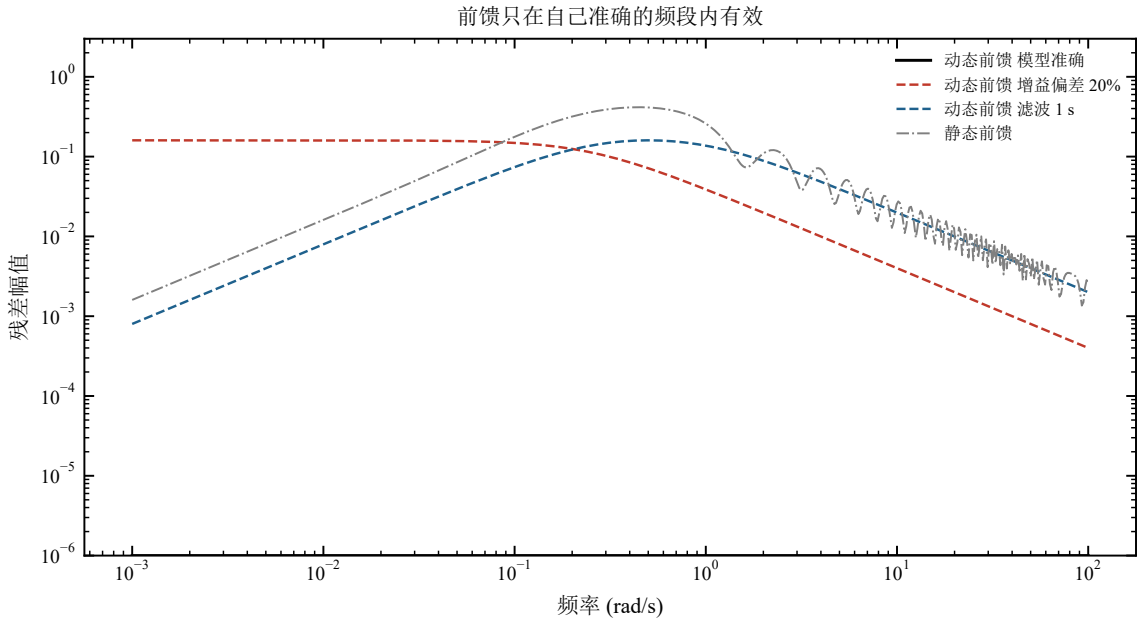

图 46-10　前馈残差幅频特性：模型准确时全频段为零；增益偏差时残差近似常数；静态前馈的残差随频率上升

三条曲线对应三种失效模式，形状完全不同。

模型准确（实线）：全频段残差为 0，图上贴着 10^{-6} 的下限。这是理想情况，只在仿真里成立。

增益偏差（虚线）：$\kappa = 0.8$ 与 $\kappa = 1.2$ 两条曲线重合，低频 0.15987，随频率缓慢下降，$\omega = 0.992$ 处 0.03909。按式 (46-13)，残差是 $0.2|G_d|$，形状就是扰动通道的幅频特性——一个 4 s 惯性环节，转折频率 0.25 rad/s，之后按 -20 dB/dec 衰减。

静态前馈（点线）：低频 0.01612，$\omega = 0.101$ 处 0.17849，$\omega = 0.497$ 处达到 0.41361，之后回落到 0.26264。它不是单调曲线，因为式 (46-11) 是两个不同极点、不同延迟的环节之差，幅值与相位都在变。

三条曲线放在一起，可以读出“有效频段”的确切含义。若以残差 0.1 为界：

- 静态前馈的有效频段约为 $\omega < 0.065$ rad/s（对应周期 97 s 以上）；
- 增益偏差 20% 的动态前馈，全频段残差都在 0.16 以上，**有效频段为零**——它在任何频率都没有把残差压到 0.1 以下，只是把 0.8 的扰动压到 0.16；
- 只有增益误差小于约 12% 时，动态前馈才能在低频段把残差压到 0.1 以下。

这个结论比“动态前馈更好”精确得多：**动态前馈的优点是残差形状平坦，缺点是残差下限由模型精度决定**。静态前馈相反，残差在低频可以很小，但随频率迅速上升。选择哪一种，取决于扰动的主要频率落在哪里，以及模型能做到多准。

46.6.4 四类失配的横向比较

把本章测过的失配放在一张表里，可以看清哪一项最要命。

失配类型	失配量	峰值	相对理想倍数
无	0	0.0012	1
增益偏低	25%	0.1165	97
增益偏低	50%	0.2342	195
延迟偏大	0.5 s	0.0938	78
延迟偏大	1.0 s	0.1769	147
一阶滤波	1 s	0.1256	105
前馈限幅	$[0, 1.0]$	0.1066	89
前馈限幅	$[0, 0.7]$	0.2153	179

表 46-7　四类失配的峰值对比（理想值 0.0012）

按相对失配量归一化，延迟最敏感：4 s 的 12.5%（0.5 s）就造成 78 倍退化；增益 25% 造成 97 倍，二者量级相当；滤波 1 s 造成 105 倍；限幅到 1.0（约 60% 行程）造成 89 倍。**没有哪一项可以忽略，但延迟最容易在投运时被低估**——它不像增益那样能从稳态数据反推，必须单独做延迟辨识。

由此给出本章的工程容差建议：延迟误差不超过 0.2 s（5%），增益误差不超过 10%，滤波时间常数不超过 1 s，前馈限幅不低于 1.7（即静态值的 2.5 倍）。四项同时满足，峰值才可能控制在 0.2 以内，与静态前馈相当或更好；任何一项超差，动态前馈的收益都会被抹掉大半。

46.6.5 稳定性验收与执行器速率

裕度不变，不等于投运时不用做稳定性检查。原因有两个。

第一，**限幅会把线性结论打破**。前馈限到 $[0, 0.7]$ 后峰值 0.2153，与静态前馈持平，此时前馈通道实际上处于“长期饱和”，其行为接近开环，回路对扰动的抑制能力退回到纯反馈加一个常数偏置。验收时要专门做“限幅边界”试验：把扰动加大到前馈刚好饱和，观察输出是否出现持续振荡。

第二，**执行器速率是新的约束**。本章前馈的初始跳变 $b_0 = 1.667$，在 $T_s = 0.05$ s 内完成，等效阀门速度 33/s。实际调节阀全行程时间通常 10–60 s，根本跟不上。阀门跟不上，前馈的“先冲一下”就被削成斜坡，等效于额外加了滞后，§46.6.2 的延迟敏感性立刻出现。这就是为什么工程上必须给前馈加滤波或速率限制，也是 §46.7 要把 τ_f 作为独立参数讨论的原因。

验收顺序建议是：先在前馈手动状态下测回路阶跃，确认 PM/GM 与设计值一致；再以小扰动投入前馈，逐级加大到设计幅值，每级观察阀门是否跟得上、输出是否单调回落；最后做限幅边界试验。三步都通过，才能认为“前馈不影响稳定性”这句话在本装置上成立。

性能的上限已经清楚：模型精度定残差下限，延迟精度定峰值，执行器速率定前馈能有多“陡”。下一节把这些参数逐个拆开，说明它们各自改变曲线的哪一段。

46.6.6 前馈不会凭空消掉扰动

本章的单回路仿真假设扰动只影响这一个回路。真实装置里，前馈把扰动“抵消”的方式是让执行器多走一段行程，这段行程本身会作用到别处。

最典型的耦合路径是公用工程。前馈检测到入口温度下降，立刻开大蒸汽阀；蒸汽总管的压降随之增大，同一总管上的另一台换热器蒸汽流量减少，出口温度开始下降。对那台换热器来说，扰动不是“入口温度”，而是“总管

压力”，而它的前馈测不到。于是前馈把原来只影响一个回路的小扰动，放大成了影响一片装置的大扰动。

这类问题不能靠调参数解决，只能靠结构。三条常用措施：

- **限制前馈的速率与幅值**，让执行器动作的“冲击”被摊平。§46.7.5 的滤波与 §46.7.6 的限幅都有这个副作用，设计时应有意识地利用。
- **在总管上加压力补偿**，把压力作为第二路前馈送进各台换热器，或让总管压力回路先动作。这属于多变量协调，超出本章范围，但工程上很常见。
- **按总负荷校核**，投运前算一遍“所有前馈同时动作时总管的最大需求”，确认不超过公用工程的可用量。

还有一条更隐蔽的耦合：前馈输出进入执行器后，若执行器是分程控制或与其他回路共用，前馈的跳变会在另一条支路上产生反向跳变。这类问题在 P&ID 上就能看出来，不需要仿真，但需要有人在投运前认真看一遍。

前馈抵消的是扰动对某一个输出的影响，不是扰动本身。 能量与物料仍然要经过装置，只是换了一条路径。把这句话记住，就不会指望前馈“把问题消灭”，而会去问“问题被搬到了哪里”。

46.6.7 四项容差如何合成一个预算

表 46-7 给的是单项失配的峰值。投运时四项误差同时存在，需要回答一个更实际的问题：**预算怎么分**。

先定总目标。若要求动态前馈的峰值不超过 0.2（与静态前馈相当），相当于理想值 0.0012 的 167 倍。四项单项失配的倍数分别是：延迟 0.5 s 为 78 倍、增益 25% 为 97 倍、滤波 1 s 为 105 倍、限幅到 1.0 为 89 倍——每一项单独都在预算内，但没有一项留出了足够余量给其他项。

不能简单相加。78+97+105+89 远超 167，但这个加法假设四项误差的峰值在同一时刻叠加，实际不会：延迟误差造成的峰值出现在补偿到达后的最初几秒，滤波造成的峰值出现在补偿的上升沿，增益误差造成的偏差则贯穿全过程。峰值是取最大值，不是求和。

工程上可行的分配方法是**把误差分成两类**：

- **时刻类**（延迟、滤波、执行器速率）：它们改变补偿“什么时候到位”，残差集中在扰动到达后的短时间内；
- **幅值类**（增益、限幅）：它们改变补偿“补多少”，残差表现为一段持续偏差。

两类误差的峰值很少同时出现，因此可以分别给预算。建议的时刻类总预算为峰值的 1/2（约 0.1），幅值类总预算为 1/3（约 0.067），剩下 1/6 留给未建模因素（阀门非线性、测量滞后、采样）。

按这个分配反推单项容差：延迟按 0.2 s、滤波按 0.5 s、执行器速率不低于前馈跳变的 1/5；增益按 10%，限幅不低于 1.7。用表 46-7 的倍数近似线性外推，0.2 s 延迟约对应 31 倍（0.037）、10% 增益约对应 39 倍（0.047）、0.5 s 滤波约对应 50 倍（0.06），三类各自都只占预算的一半左右，留出了余量。

这组数字是按本章对象的实测数据外推的，不是通用标准；换一台设备，应先做一遍单项扫描，再按同样的方法分配。但方法本身通用：**先定总目标，再按“峰值是否同时出现”分类，最后反推单项容差**。直接把总目标平均分给四项，往往会导致最敏感的那一项超差而不自知。

46.7 参数意义与作用

46.7.1 七个参数各管一段

前馈-反馈复合回路有七个可调量，它们不是并列关系，而是各自负责响应曲线的一段。表 46-8 先给全貌。

参数	符号	本章值	主要影响	失配后果
静态增益	K_{ff}	-0.667	稳态与低频残差下限	误差 50% 峰值 0.2342
超前时间	T_1	10 s	中频相位超前量	形状不匹配
滞后时间	T_2	4 s	中频相位滞后量	形状不匹配
前馈延迟	τ_{ff}	4 s	补偿与扰动的时间对齐	偏差 0.5 s 峰值 78 倍
滤波时间	τ_f	0–1 s	高频噪声与动作陡度	1 s 峰值 0.1256
前馈限幅	$[u_{lo}, u_{hi}]$	$[0, 1.0]$	执行器保护	限到 0.7 退化到静态水平
反馈参数	K_c, T_i	1.2 / 10 s	残差收尾速度与裕度	见 §46.7.7

表 46-8　复合回路的七个可调量

读这张表的正确方式是“从后往前”：先看限幅与反馈，因为它们决定前馈能不能安全地用；再看延迟与增益，因为它们决定前馈有没有用；最后看 T_1, T_2 与 τ_f，它们只决定前馈用得“顺不顺”。顺序反了，就会在细节上耗掉大部分调试时间。

46.7.2 静态增益：定“补多少”

K_{ff} 是唯一一个能直接从稳态数据算出来的参数，也是唯一一个错了会立即在稳态上暴露的参数。它的理想值 $-K_d/K_p = -0.667$ 对应稳态不变性；偏离它，稳态会出现一个与扰动成比例的固定偏差，由反馈积分慢慢消掉。

但 §46.4 的扫描表明，K_{ff} 的作用不止稳态：从 -0.667 加到 -0.9，峰值还能降 36%。所以这个参数实际上同时管“稳态补多少”和“峰值压多低”两件事，只是两个目标的最优点不重合。

工程上取 -0.667，理由是它对应可解释的物理量（两个增益之比），模型变化时偏差方向可预测。若工艺明确要求压峰值、且能接受更大的拖尾，可以取 -0.8 到 -0.9；再大就进入“两头受损”区，没有意义。

46.7.3 超前-滞后：定“补的形状”

T_1 与 T_2 单独看没有意义，起作用的是它们的比值和绝对大小。比值决定初始跳变：

$$\frac{b_0}{K_{ff}} = \frac{T_1}{T_2} = 2.5 \tag{46-27}$$

本章前馈在扰动阶跃瞬间的理论跳变为 1.667（实测峰值 1.654），就是这个比值造成的。比值越大，前馈“冲”得越猛，对阀门速率要求越高；比值越小，前馈越平缓，但动态匹配越差。

绝对大小决定补偿的时间尺度。$T_1 = 10$ s、$T_2 = 4$ s 对应两条通道的惯性；若现场辨识出的时间常数是 20 s 与 8 s，比值仍是 2.5，但补偿过程整体拉长一倍，滤波与限幅也要跟着放大。**比值管形状，绝对值管尺度**，调参时不要把两者混在一起。

一个常见错误是把 T_1 与 T_2 取反。取反后比值变成 0.4，前馈在阶跃瞬间只跳到 0.267，随后缓慢爬升，完全跟不上扰动的快速上升段；此时即使增益准确，峰值也会明显高于静态前馈。

46.7.4 延迟：定“什么时候补”

延迟是七个参数里唯一“不能用增益补偿”的。增益错了可以调 K_{ff}，滤波大了可以减小 τ_f，延迟错了只能重新辨识或改测量点。

它的影响形状由式 (46-26) 决定：残差正比于 $\left|1-e^{-j\omega\Delta}\right|$，是一个随频率上升的高通。这意味着延迟误差专门破坏高频补偿，对稳态几乎无影响。本章 0.5 s 误差使峰值放大 78 倍，却只让 IAE 放大 22 倍，就是这个原因。

现场辨识延迟的可靠办法是**双通道阶跃试验**：同时记录扰动测量与输出，分别数出两次响应开始变化的时刻，差值就是 $\tau_d-\tau_p$。不要用“阀门动作到输出变化”的单一试验去推，那条路径只给出 τ_p，推不出 τ_d。

46.7.5 滤波：定“补多快”

τ_f 是噪声与峰值之间的旋钮。本章在扰动测量上叠加 $\sigma=0.02$ 的噪声，结果如表 46-9。

τ_f/s	std(u_{ff})	$\lvert u_{ff}\rvert_{\max}$	IAE
0	0.0309	1.644	0.1325
0.2	0.0100	1.488	0.3096
0.5	0.0065	1.351	0.5856
1.0	0.0045	1.218	1.0140
2.0	0.0030	1.035	1.7612

表 46-9　前馈滤波对噪声与性能的影响（$\sigma=0.02$）

噪声标准差从 0.0309 降到 0.0030，改善 10 倍；IAE 从 0.1325 升到 1.7612，恶化 13 倍。这是一条典型的“用性能换平稳”的曲线，没有免费的中间点。

选择 τ_f 的依据是**噪声引起的阀门抖动是否可接受**。若阀门定位器对 0.03 的指令抖动不敏感，$\tau_f=0$ 最好；若有明显抖动或定位器频繁动作，取 0.5–1 s，牺牲一部分峰值换设备寿命。本章推荐 1 s，对应 std 0.0045、峰值 0.1256，仍在静态前馈之上。

46.7.6 限幅：定“最多补多少”

限幅不是控制参数，是保护参数。它的取值应由执行器余量决定，而不是由前馈的理想峰值决定。本章的理想峰值 1.654，若阀门只剩 1.0 的行程，就必须限到 1.0。

限幅	峰值	IAE	恢复/s
不限	0.0012	0.0206	0
$[0,1.0]$	0.1066	1.0224	28.00
$[0,0.7]$	0.2153	2.8957	44.90
$[0,0.5]$	0.2760	3.0301	41.40
$[0,0.3]$	0.3520	3.6574	23.75

表 46-10　前馈输出限幅的影响

限到 0.7 时峰值 0.2153，与静态前馈的 0.2154 几乎相同——这不是巧合：0.7 刚好等于静态前馈的稳态输出 0.667，动态前馈的“超前”部分被完全削掉，只剩下静态分量。**限幅值低于静态输出，等于把动态前馈退化成静**

态前馈，这是选限幅时的一个实用判据。

限到 0.5 与 0.3 时峰值反而上升、恢复时间却缩短，因为深度限幅让前馈变成一个“短促的脉冲”，削掉了拖尾。这种形状对峰值不利、对恢复有利，一般不应作为设计目标，只在阀门严重受限时被动接受。

46.7.7 反馈参数：定“残差收多快”

前馈把大头抵消后，剩下的残差由反馈收尾。反馈越快，残差消得越快；但反馈太快会吃掉稳定裕度。本章扫了 K_c 与 T_i，结果如表 46-11。

K_c	T_i/s	纯反馈峰值	复合峰值	纯反馈 IAE	复合 IAE
0.6	10	0.5165	0.0391	9.4796	1.9006
0.9	10	0.4962	0.0045	7.2344	0.2200
1.2	10	0.4706	0.0012	5.5520	0.0206
1.5	10	0.4500	0.0014	4.4481	0.0144
1.8	10	0.4344	0.0013	3.7061	0.0131
1.2	5	0.4508	0.0125	5.1339	0.6301
1.2	20	0.4470	0.0776	7.0153	3.0887

表 46-11　反馈 PI 参数与前馈的配合（动态前馈按名义模型）

这张表最有价值的一列是“复合峰值”。K_c 从 0.6 增到 1.2，纯反馈峰值只从 0.5165 降到 0.4706，变化 9%；复合峰值却从 0.0391 降到 0.0012，变化 30 倍。原因很简单：前馈抵消后剩下的残差很小，反馈的每一次动作都直接作用在这点残差上，增益高低被放大。

T_i 的影响更明显：$T_i = 20$ s 时复合峰值 0.0776，是 $T_i = 5$ s 时 0.0125 的 6 倍。积分慢，残差停留久，峰值自然高。但 T_i 也不是越短越好：$T_i = 5$ s 时 K_i 翻倍，反馈会对前馈残留的微小误差过度反应，复合 IAE 反而从 0.0206 升到 0.6301。本章的最优点就在 10 s 附近。

但不能反过来推“前馈投运后可以把 K_c 调很大”。K_c 从 1.2 增到 1.8，复合峰值只从 0.0012 变到 0.0013，几乎没有收益，相位裕度却从 73.49° 降到 65.24°。前馈不改变裕度，也不替反馈承担稳定性责任；反馈参数应按回路裕度整定，而不是按复合峰值整定。

46.7.8 参考前馈的滤波：定“设定值冲击多大”

参考前馈的参数是 τ_r，作用与扰动前馈的 τ_f 类似，但权衡的对象不同：这里换的是“跟踪速度”与“超调/执行器冲击”。

方案	Mp/%	t_r/s	t_s/s	$\lvert u\rvert_{\max}$
仅反馈	0.00	10.068	19.750	1.440
参考前馈 无滤波	22.72	4.044	43.700	2.273
参考前馈 2 s	21.13	5.405	45.950	1.813
参考前馈 5 s	14.44	8.256	50.200	1.360
参考前馈 10 s	5.01	13.876	54.700	1.022
参考前馈 20 s	0.01	31.798	63.800	0.833

表 46-12　参考前馈与设定值滤波的权衡

这张表给出的结论有点扫兴：参考前馈把上升时间从 10.068 s 缩短到 4.044 s，代价是 22.72% 的超调和 2.273 的执行器峰值；把滤波加到 10 s，超调降到 5.01%，但上升时间反而比纯反馈慢；加到 20 s，超调没了，上升时间却是纯反馈的 3 倍。

也就是说，**本章这个对象并不需要参考前馈**。PI 本身已经给出零超调、10 s 上升时间的响应，参考前馈只能在“更快”与“更稳”之间搬家，搬完还不如原来。参考前馈真正有价值的场合是：设定值频繁大幅变化、执行器余量充足、且工艺更看重跟踪速度而非超调。三条不同时满足，就不要加。

参数讲完，接下来是整定顺序：七个参数先调哪个、后调哪个、每步看什么曲线。这是 §46.8 的内容。

46.7.9 三个参数对应曲线的三段

K_{ff}、T_1/T_2、T_2 这三个参数在式 (46-23)(46-24) 里是耦合的：$b_0 = K_{ff}T_1/T_2$ 同时含增益与时间常数比，$a_1 = -e^{-T_s/T_2}$ 只含 T_2。耦合看起来麻烦，反过来却给了一个很好的诊断工具：**前馈自己的输出曲线上，三段形状分别对应三个参数**。

- **阶跃瞬间的跳变**读 T_1/T_2。本章跳变 1.654，对应 $0.667 \times 2.5 = 1.667$；若把 T_1 与 T_2 取反，跳变只有 $0.667 \times 0.4 = 0.267$，前馈初期严重不足，只能靠滞后段慢慢补，结果是峰值大、拖尾长——这是时间常数比取反的典型症状。
- **跳变之后的衰减速度**读 T_2。T_2 取大，衰减慢，前馈“补得久”，容易出现反向过冲；取小，衰减快，前馈“补一下就撤”，拖尾补偿不足。
- **长时间后的稳态值**读 K_{ff}。稳态时超前-滞后环节增益为 1，u_{ff}/d 直接等于 K_{ff}，与两个时间常数无关。

三段可分离，意味着现场可以只凭一条前馈输出趋势反推三个参数有没有取错。这比重新做一次双通道辨识省事得多，也是 §46.10.6 要把 u_{ff}/d 作为长期监控量的原因。

需要提醒的是，三段可分离只在**扰动是阶跃**时成立。若扰动是斜坡或脉冲，跳变段与稳态段混在一起，读数会失真。现场验证参数时，应尽量找一次真实的阶跃扰动（例如切泵、切换原料罐），或在前馈手动状态下人为制造一个小阶跃。

46.7.10 把不同误差折算成同一个尺度

增益误差用百分比表示，延迟误差用秒表示，滤波误差用时间常数表示——三个量纲不同，无法直接比较谁更严重。本章的实测数据恰好可以把它们折算到同一个尺度：**等效峰值**。

先看增益。扰动通道增益偏差 κ 时，峰值 0.2342（$\kappa = 0.5$）、0.1165（$\kappa = 0.25$）、0.0012（$\kappa = 0$），三者与 $0.4706\lvert 1-\kappa\rvert$ 几乎完全吻合（$0.4706 \times 0.5 = 0.2353$，$0.4706 \times 0.25 = 0.1177$）。也就是说：

$$\text{峰值} \approx 0.4706 \times |\text{相对增益误差}|$$

系数 0.4706 正是纯反馈的峰值。物理含义很清楚：前馈完全失效时，系统退化为纯反馈；前馈部分失效时，剩下的残差按“失效比例”从纯反馈峰值往下降。**增益误差 30%，等于把前馈的收益退回 70% 的纯反馈水平。**

再看延迟。0.5 s 偏差给出 0.0938，1.0 s 给出 0.1769，换算成“等效增益误差”分别是 $0.0938/0.4706 = 20\%$ 与 $0.1769/0.4706 = 38\%$。线性拟合给出一个很好记的近似：

$$\text{等效增益误差} \approx 0.4 \times \Delta t \ (\text{s})$$

即**每 1 s 的延迟误差，相当于 40% 的增益误差**。这条换算在本章对象上成立（Δt 在 0.5–1 s 范围内），换对象需要重测，但量级可以借用。

折算之后，容差分配就有了统一语言。§46.6.7 建议延迟 0.2 s、增益 10%，用这条换算看，0.2 s 相当于 8% 的增益误差，与 10% 的增益容差基本等重——两项被分配了相近的预算，这与“延迟更敏感”的直觉一致，也说明那组容差不是随手定的。

两类误差同时存在时，不能直接把等效值相加。延迟误差的残差与增益误差的残差在时间上错开、在相位上不同，保守估计可用平方和开方：$\sqrt{0.08^2 + 0.10^2} = 12.8\%$，仍低于“把前馈收益退回 87%”的水平。这个估算方法给出的是保守上界，够用来判断“当前误差水平下前馈还值不值得留”。

46.8 调参方法与经验

46.8.1 四条顺序原则

前馈整定最容易犯的错误是“一上来就调动态参数”。正确顺序由四条原则决定。

先手动，后自动。 整定反馈时把前馈切手动、输出置零，先得到一条干净的纯反馈基线。本章基线是峰值 0.4706、IAE 5.5520、恢复 31.65 s。没有这条基线，后面所有“改善百分比”都无从谈起。

先静态，后动态。 静态前馈只有两个增益，投运当天就能验证符号和量级；动态前馈有四个参数，任何一个错了都会掩盖其他错误。先用静态把“方向对不对”确认掉，再上动态。

先延迟，后形状。 延迟误差的残差是高通，会污染整个动态段；形状参数（T_1, T_2）的误差是低通，主要影响中频。先对齐时间，再修形状，否则调 T_1 时看到的改善可能只是延迟碰巧对了一点。

先安全，后性能。 限幅与滤波决定前馈能不能安全地用，应该在追求峰值之前定下来。反过来做，往往是把峰值调到 0.001，投运第一天就因为阀门饱和被打回原形。

46.8.2 第一步：把反馈调到“可用”

反馈是兜底，必须先独立可用。本章取 $K_c = 1.2$、$T_i = 10$ s，对应相位裕度 73.49°、增益裕度 14.73 dB。这个裕度偏保守，但对前馈有利：前馈的残差要靠反馈收尾，反馈越稳，残差收得越干净。

整定目标建议设在相位裕度 60°–75°。低于 60°，前馈残差容易激发振荡；高于 75°，反馈太慢，残差拖尾长，复合 IAE 反而大。本章 73.49° 在上沿，是因为对象纯滞后 2 s，留够余量更稳妥。

这一步不要追求“纯反馈的峰值最小”。纯反馈峰值从 $K_c = 0.6$ 的 0.5165 到 $K_c = 1.8$ 的 0.4344，只差 16%，而裕度掉了 16.5°。用裕度换这点峰值不划算，峰值应该交给前馈去压。

46.8.3 第二步：静态前馈的三个检查

静态前馈投运前做三个检查，每个都有明确的通过标准。

符号检查。 手动给扰动测量加一个正偏置，观察前馈输出方向：本章 $K_{ff} < 0$，扰动增大时前馈应减小。符号错了，前馈会从“抵消”变成“加倍”，峰值成倍上升，一眼就能看出来。

量级检查。 用稳态数据核对 $u_{ff} = K_{ff} \cdot d$。本章扰动 -1.0 时前馈应为 $+0.667$；若现场读到 0.3 或 1.3，说明增益比算错或测量有标度问题。

稳态检查。 投入静态前馈，等扰动稳定后看输出是否回到设定值。若稳态有固定偏差，说明 K_{ff} 与真实的 K_d/K_p 不符，或者反馈积分被限幅卡住。

三项通过后，峰值应从 0.4706 降到 0.2154 附近。若降幅不到 30%，不要急着上动态，先查测量点位置和延迟——静态前馈都拿不到一半收益，动态前馈也不会凭空变好。

46.8.4 第三步：延迟对齐的细扫法

延迟是唯一必须“扫”出来的参数。解析值 4 s 只是起点，现场要按拍细扫。

做法是：从解析值 $n_{ff} = 80$ 开始，依次取 78、79、80、81、82 拍，每拍记录峰值。本章的粗扫结果呈明显的 V 形：偏差 0.5 s（10 拍）峰值 0.0938，偏差 0 时 0.0012。用 V 形底部三个点做抛物线拟合，可以把对齐精度推到 ± 0.05 s，即一拍以内。

两个判据决定细扫是否可信。**V 形要尖**：若底部很平，说明前馈的其他参数（增益或 T_1/T_2）有明显误差，先修那些，再回来扫延迟。**最小值要低**：若扫遍所有拍，峰值最低仍高于 0.05，说明模型结构不对（例如扰动通道不是一阶），此时继续调延迟没有意义。

细扫时要用同一段扰动数据反复回放，不要每次重新做阶跃试验。现场的负荷波动会让两次试验不可比，把延迟的 0.05 s 差异淹没在噪声里。

46.8.5 第四步：形状参数的微调

T_1 与 T_2 来自辨识，原则上不应大改。现场允许的修正幅度是 ±20%，超过这个范围应先怀疑辨识数据。

微调时看两个特征。**峰值段**由 T_1/T_2 的比值决定：峰值偏高，说明前馈“冲”得不够，可略增 T_1；峰值出现反向过冲，说明冲过头，略减 T_1。**拖尾段**由 T_2 的绝对值决定：拖尾长，略减 T_2 让前馈收得更快；拖尾出现振荡，略增 T_2。

两条要一起看。只调 T_1 会把比值带偏，只调 T_2 会把时间尺度带偏。经验做法是保持比值不变、整体缩放，先确认形状对不对，再确认尺度对不对。

一个反例：现场看到峰值高，就把 T_1 从 10 s 加到 20 s，比值变成 5，前馈初始跳变从 1.667 涨到 3.33，阀门直接饱和，峰值反而更高。**形状参数的调整必须受执行器余量约束**，这是 §46.7.6 限幅讨论的延续。

46.8.6 第五步：限幅与滤波的先后

正确顺序是**先定限幅，再定滤波**。原因：限幅改变的是前馈的有效形状，滤波改变的是前馈的平滑度，前者对峰值的影响更大。先把限幅定在阀门可用行程，再在剩余空间里用滤波换平稳。

本章单独测过两项：限幅 $[0, 1.0]$ 使峰值从 0.0012 退到 0.1066；单独加 1 s 滤波使峰值升到 0.1256、噪声 std 从 0.0309 降到 0.0045。两项叠加后的峰值不能简单相加，要在限幅值确定后重新实测一次。

反过来做——先加滤波把峰值调到 0.1256，再发现阀门只能到 1.0，限幅与滤波的联合效果还得重测——等于白走一遍。顺序错了，返工是必然的。

46.8.7 第六步：复核反馈参数

前馈投运后要复核反馈，但复核的口径是“复合 IAE”，不是“复合峰值”。

本章数据：K_c 在 1.2–1.5 之间复合 IAE 分别为 0.0206 与 0.0144，差别很小；$K_c = 0.6$ 时升到 1.9006，明显变差。T_i 在 10 s 时复合 IAE 0.0206，5 s 时 0.6301，20 s 时 3.0887，最优点明确。

复核的结论通常是“反馈不用大改”。前馈已经把大头拿走，反馈只需要按原裕度稳定工作；为追 0.001 的峰值去动 K_c，代价是裕度，不划算。

46.8.8 六个常见错误

1. **符号错**：把 K_{ff} 取成正的，扰动被放大一倍。
2. **忘记延迟**：直接拿扰动测量乘增益，前馈早到 4 s，峰值比不加还高。
3. **滤波放在延迟前**：先把测量滤平滑再延迟，等效延迟变了，对齐白做。正确顺序是延迟 → 超前-滞后 → 滤波 → 限幅。
4. **限幅加在总输出上**：把 $u_{fb} + u_{ff}$ 一起限，反馈积分会被前馈拖进饱和。限幅只应加在前馈支路。
5. **投切无扰缺失**：前馈从 0 直接跳到 0.667，阀门受一次冲击。应初始化到当前稳态值再斜坡投入。
6. **只记峰值不记 IAE**：静态前馈峰值降 54%，恢复时间却从 31.65 s 拉到 44.95 s，只看峰值会得出错误结论。

46.8.9 整定记录表

每次整定留一份记录，至少包含：日期与负荷、K_{ff}、T_1/T_2、n_{ff}（拍）、τ_f、限幅、四项验收指标（峰值、IAE、恢复、前馈峰值）、以及当次的纯反馈对照。

记录的作用不是存档，而是**下次模型漂移时能快速定位**：峰值变大而稳态正常，多半是延迟或 T_1/T_2 变了；稳态有偏差，多半是 K_{ff} 对应的增益比变了；噪声变大而峰值不变，多半是测量回路的问题。三类症状对应三组参数，有记录就能一次查对。

整定方法讲完，接下来讨论超出基本结构的改进：前馈模型在线校正、增益调度、以及参考前馈与扰动前馈的组合。这些是 §46.9 的内容。

46.8.10 三个“不要调”

整定现场最常见的低效，是用一个参数去补另一个参数的错。三种情形要特别警惕。

不要用 K_{ff} 补延迟误差。 延迟差 0.5 s 时峰值 0.0938，形状是“先补早了、再补晚了”的双峰。此时加大 $|K_{ff}|$ 会把前一个峰压下去、后一个峰抬起来，峰值可能短暂变小，IAE 却明显变差。表 46-4 里 $K_{ff} = -1.2$ 的峰值 0.2081、恢复 51.30 s，就是“过补偿掩盖时机错误”的样子：峰值与纯反馈相当，拖尾却比纯反馈多出近 20 s。正确做法是先按 §46.8.4 细扫 n_{ff}，把双峰合成单峰，再谈增益。

不要用滤波掩盖增益误差。 滤波能把尖锐的残差磨平，1 s 滤波就把动态前馈的峰值从 0.0012 抬到 0.1256，同时也把 IAE 从 0.0206 抬到 0.9243。它磨平的是**所有**快速成分，包括正确的补偿。增益误差的残差是慢变的持续偏差，滤波对它几乎无效，只会让整个回路更迟钝。增益错了就改增益，这是唯一有效的办法。

不要在反馈还没稳的时候调前馈。 前馈的开环结论建立在小信号线性之上，若反馈本身在振荡或接近饱和，前馈的动作会被叠加到不稳定的基线上，任何整定都读不出因果。顺序必须是：先按 §46.6.5 验收反馈（阶跃、PM/GM、限幅边界），再投前馈。

这三条的共同点是：**先定位误差来源，再动对应的参数**。前馈支路的可调量本来就不多，两两之间又高度耦合，盲目试凑的空间很小；把症状与参数对上，往往一两次试验就能收敛。

46.9 优化与改进

46.9.1 模型为什么会漂移

§46.4 的数据说得很直白：增益误差 50%，动态前馈的峰值 0.2342，已经不如静态前馈。而工业对象的增益恰恰是最容易漂移的量——换热器结垢、催化剂老化、原料批次变化、负荷大幅调整，都会让 K_p 或 K_d 偏离辨识值。

有意思的是，$K_{ff} = -K_d/K_p$ 只用**比值**。若结垢让两条通道的增益同比例下降，比值不变，前馈不需要改；真正有害的是**两条通道不同步变化**：扰动测量点保温损坏使 K_d 虚高、主通道阀门特性变化使 K_p 偏移、或者负荷变化让某一侧的增益先饱和。

这给出在线校正的第一个判断：不是所有漂移都要校正，只有“比值漂移”才需要。工程上可以通过定期做一次双通道阶跃试验来区分：若两条通道增益同向同幅变化，只更新模型记录、不动 K_{ff}；若比值变了，才启动校正。

46.9.2 稳态比值法：用反馈的积分反推误差

前馈误差最终会由反馈补上。稳态时，反馈输出里就含着“前馈少补或多补了多少”的信息，可以拿来反推。

推导很短。稳态下 $y = r$，主通道满足

$$0 = K_d\, d + K_p\,(u_{ff} + u_{fb}) \tag{46-28}$$

把 $u_{ff} = K_{ff} d$ 代入，解出

$$\frac{u_{fb}}{d} = K_{ff}^{*} - K_{ff} \tag{46-29}$$

其中 $K_{ff}^{*} = -K_d/K_p$ 是真实值。于是有一个极简的校正律：

$$K_{ff} \leftarrow K_{ff} + \gamma\,\frac{u_{fb}}{d} \tag{46-30}$$

γ 取 0.01–0.05，每 10–60 分钟更新一次。举例：真实值 -0.667、当前值 -0.5、扰动 -1.0，则稳态 $u_{fb} = 0.167$，$u_{fb}/d = -0.167$，更新后 $K_{ff} = -0.667$，一步到位（$\gamma = 1$ 时）；实际取小 γ 是为了抗噪。

这个方法的优点是不需要额外试验、不需要扰动辨识，直接用运行数据。缺点有四个，必须逐条设防。

只在稳态用。 动态过程中 u_{fb} 含比例项和未衰减的积分，式 (46-29) 不成立。判据是 $|y - r|$ 小于阈值且持续一段时间。

只在扰动主导时用。 若同时有其他不可测扰动，u_{fb} 里混入了它们的贡献，反推会偏。判据是 $|d|$ 大于阈值，且扰动测量与 u_{fb} 的相关性足够高。

除法要用带符号的 d。 d 可正可负，除以 d 而不是 $|d|$，否则校正方向会错。实现时对 $|d|$ 设下限，避免除零。

更新要限幅。 单次更新不超过名义值的 10%，累计不超过 ±50%，防止一段异常数据把前馈带跑。

46.9.3 增益调度：按负荷切参数

当对象非线性明显时，单一 K_{ff} 不够用。典型场景是负荷从 30% 升到 100%，主通道增益下降一半，而扰动通道增益基本不变，比值随之变化。

做法是把负荷（或流量、产量）作为调度变量，存 3–5 个断点的 K_{ff}，中间线性插值：

$$K_{ff}(L) = K_{ff,i} + \frac{L - L_i}{L_{i+1} - L_i}\left(K_{ff,i+1} - K_{ff,i}\right) \tag{46-31}$$

三个工程要点。**断点要覆盖实际运行区间**，不要外推；**切换要无扰**，负荷跨越断点时用斜坡过渡 10–20 s；**调度变量要与扰动解耦**，若负荷本身也是扰动，调度会与前馈互相打架。

调度表的每个断点都要有试验依据。常见错误是“按机理估算几个点”，投运后发现中间负荷段反而变差——插值区间内的非线性未必单调，必须实测。

46.9.4 参考前馈与扰动前馈的组合

两种前馈可以同时存在：扰动前馈管 d，参考前馈管 r，执行器收到三路之和。图 46-7 给出参考前馈单独作用时的四条曲线。

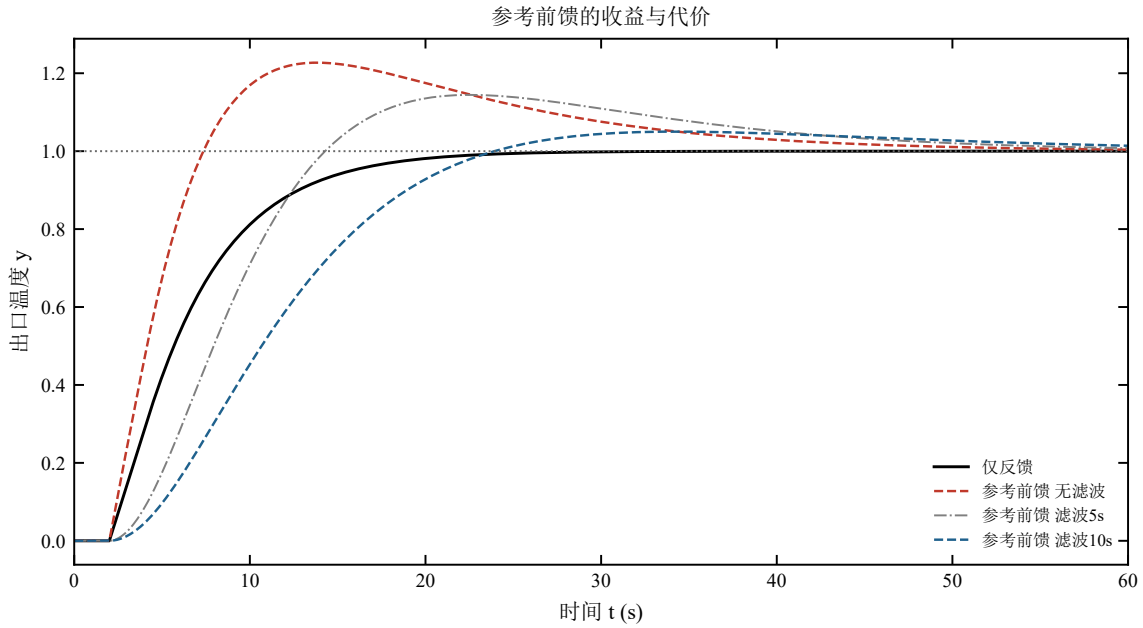

图 46-7　参考前馈与设定值滤波：无滤波时上升最快但超调 22.72%，滤波 10 s 后超调降到 5.01%

组合的第一约束是**执行器预算**。本章扰动前馈峰值 1.654，参考前馈稳态 0.833，两者在最不利时刻叠加可达 2.49，远超阀门余量 1.0。也就是说，本章对象根本装不下两路前馈——不是理论不允许，是物理行程不够。

第二约束是**目标冲突**。参考前馈要“快”，扰动前馈要“准”，两者都要求阀门快速大幅动作。当阀门成为瓶颈时，先保扰动前馈：扰动是外来的、不可避免的，设定值变化是人为的、可以放缓。工程上的优先级通常是“扰动前馈 > 设定值成形 > 参考前馈”。

第三约束是**调试复杂度**。两路前馈同时在线，出现异常时很难判断是哪一路的问题。稳妥做法是分时投运：先扰动前馈稳定运行一个月，再评估是否需要参考前馈；需要时也先加设定值滤波，最后才加前馈增益。

对本章对象，结论是明确的：不加参考前馈。§46.7.8 的数据已经说明，PI 本身的跟踪响应（零超调、10.068 s 上升）比任何参考前馈配置都好；参考前馈只能把上升时间压到 4 s，代价是 22.72% 超调和 2.273 的执行器峰值。这个交易在本对象上不划算。

46.9.5 与串级控制结合

第 45 章的串级与本章的前馈可以叠加，形成“前馈 + 串级 + 反馈”的三层结构。这时前馈加在哪一层，有三种选择。

加在内环输出。 前馈直接叠加到副回路控制器的输出，与副回路执行器共用。优点是响应最快，缺点是通过副回路对象的动态，前馈模型要按“扰动 → 内环输出 → 主变量”重新辨识。

加在内环设定值。 前馈改变副回路的设定值，由副回路去执行。优点是不直接碰执行器，副回路的抗扰与限幅仍然有效；缺点是前馈要经过副回路的闭环动态，等效延迟增加，补偿精度下降。

加在外环输出（即内环设定值之前）。 与前一种类似，但多经过一层外环控制器，最慢。

选择依据是**扰动进入的位置**。若扰动直接作用于内环对象（如蒸汽压力波动），加在内环输出最直接；若扰动作用于外环对象（如入口物料温度），加在内环设定值更合理，因为它与外环的控制意图在同一层。

三种方式都需要重新辨识前馈通道。串级的引入改变了“扰动 → 被控量”的等效传递函数，第 45 章式 (45-13) 给出的 T_1、S_1 会进入前馈模型。直接套用单回路的前馈参数，通常只能拿到一半收益。

46.9.6 抗饱和与无扰切换

前馈是开环支路，它的饱和与反馈的饱和是两件事，必须分开处理。

前馈支路的限幅只限制 u_{ff}，不限制 u_{fb}。本章第九段实验就是这么做的。若把限幅加在总和上，前馈的大幅动作会把反馈积分项到饱和，扰动过去后积分要很久才能退出来，表现为“恢复特别慢”。

反馈的抗饱和要在前馈存在时重新核对。前馈已经把执行器推到接近上限，反馈能用的余量更小，抗饱和阈值应相应收紧。第 45 章式 (45-27) 的回算方法仍然适用，但回算的起点要改成“总和减去前馈”，否则前馈会被误判为反馈的输出。

无扰切换要处理三个时刻：前馈投入、前馈切除、前馈参数在线修改。三个时刻的共同要求是“切换前后执行器指令连续”。做法是维护一个跟踪值 u_{ff}^{trk}，手动时让它跟随实际前馈输出，切自动时从 u_{ff}^{trk} 起步，再用 10–20 s 斜坡过渡到计算值。

参数在线修改（例如 §46.9.2 的增益校正）也属于切换。若校正每 10 分钟改一次 K_{ff}，而 d 是慢变量，单次改动带来的 u_{ff} 变化很小，可以不做斜坡；若 d 接近满量程，单次 10% 的增益改动就会造成 0.067 的指令跳变，必须加斜坡或限制变化率。

46.9.7 改进的收益递减

本章的改进路径可以排成一个收益序列：

- 纯反馈 → 静态前馈：峰值 0.4706 → 0.2154，降 54%；
- 静态 → 动态：0.2154 → 0.0012，降 99.4%；
- 动态 → 动态加在线校正：把漂移后的残差拉回设计值附近，收益取决于漂移幅度，需现场验证；
- 动态 → 动态加增益调度：只在非线性显著时有收益；
- 动态 → 动态加参考前馈：本章对象无收益。

每一步的投入产出比在快速下降。静态前馈只需要两个数，当天见效；动态前馈要辨识四个参数，还要扫延迟；在线校正要写自适应逻辑、设四个判据；增益调度要维护一张表。**改进到哪一步为止，取决于模型能维护多久，而不是取决于理论能压到多低。**

一条实用的停止准则：当“当前峰值已经低于工艺报警线的 1/3”且“模型参数半年内没有明显漂移”时，停止改进。继续投入的边际收益，已经小于维护复杂度带来的风险。

工程落地要处理的还不止这些：测量回路、DCS 组态、投运步骤、故障预案。这些是 §46.10 的内容。

46.9.8 从单回路前馈到解耦与预测控制

本章的前馈是单输入单输出的：一个扰动、一个执行器、一个被控量。装置规模一大，同样的思想会以两种形式出现。

解耦器是多变量版本的前馈。当两个回路通过对象耦合（例如两个串联换热器共用蒸汽），一个回路的阀门动作会影响另一个回路的输出。解耦器在控制器与对象之间插入一个矩阵 $D(s)$，使 $G_p(s)D(s)$ 近似对角——本质是矩阵求逆，与单回路的 $G_{ff} = -G_d/G_p$ 同源。它同样要求模型准确、同样可能非因果、同样不改变（在理想解耦下的）各个单回路的稳定性；模型一错，解耦反而会把扰动“送”到另一个回路。

模型预测控制把前馈做进了预测模型：可测扰动作为已知的未来输入进入预测，控制器在优化时自动算出抵消量。它比本章的前馈多了两件事——处理约束、多步预测；代价是需要在线求解、需要完整的多变量模型、需要专人维护。本章的单回路前馈可以看作它的退化情形：一步预测、无约束、单变量、目标函数只有跟踪误差。

三条选择判据：

- 通道少（两三个）、耦合弱、模型准，用**解耦器加单回路控制器**，组态简单、行为可解释；
- 通道多、有硬约束（阀位、温度上限）、经济目标明确，用**预测控制**；
- 只有一个主导扰动、一个执行器，就是**本章的复合控制**，不要为了“先进”去上更大的框架。

工程上最常见的错误是“用预测控制解决一个前馈就能解决的问题”。预测控制的模型维护成本比前馈高一个数量级，而它相对前馈的增量收益，往往只体现在约束边界附近。

46.9.9 改进效果怎么算数

本章所有数字都来自理想条件：扰动是干净的阶跃、初始状态完全稳恒、噪声固定种子。现场不可能这样，因此“投运后峰值从 0.47 降到 0.21”这类结论不能靠一两次事件下判断。

可靠的做法是**比较分布，而不是比较极值**：

1. 取投运前 20–30 次同类扰动事件（同一扰动源、同一负荷区间），记录每次的峰值与 IAE；
2. 投运后再取同样数量的事件，同样记录；
3. 比较两组的中位数与 90 分位，不要比最大值——最大值由最异常的那一次决定，与方案好坏关系不大。

判读规则也很直接。中位数与 90 分位同时改善，说明改进是普遍的；只有中位数改善、90 分位没动，说明改进只对小扰动有效，多半是前馈在大扰动时被限幅卡住（§46.7.6）；只有 90 分位改善、中位数没动，说明改进只对大幅扰动有效，通常是静态前馈的增益偏保守。

还有一个容易忽略的污染源：**工况漂移**。前后两组事件的负荷、环境温度、原料批次若不同，比较就没有意义。正确做法是按工况分层，每一层内部分别比较；层内样本不足时，宁可延长观察期，也不要把不同工况混在一起算平均。

最后一条纪律：**留对照**。投运后每隔一段时间（例如一个月）把前馈退出一天，采一组纯反馈数据。历史数据只能说明“过去怎样”，不能说明“现在的前馈是否还有效”；定期对照才能发现模型漂移带来的收益衰减，这比任何离线辨识都及时。

46.9.10 前馈在信号优先级里的位置

DCS 里一个执行器往往接收多路指令，前馈只是其中之一。它的位置必须摆对，否则会在异常时与联锁、手动操作打架。

优先级从高到低通常是：**联锁与停车 > 操作员手动 > 反馈自动 > 前馈修正**。前馈永远是被叠加的“修正量”，不能覆盖手动值，更不能绕过联锁。实现上有三条具体要求：

1. **手动时前馈要跟踪**。操作员切手动后，前馈块继续计算但输出被旁路，跟踪值等于实际前馈输出；切回自动时从跟踪值起步，避免跳变（§46.9.6）。
2. **联锁时前馈强制清零**。联锁动作会把阀门推到安全位置，此时若前馈仍在累加，会在联锁复位瞬间给阀门一个错误的偏置。
3. **联锁复位后斜坡恢复**。清零是瞬时的，恢复不能瞬时；用 10–20 s 斜坡把前馈拉回计算值，让反馈有时间接管。

报警设计上，除了 §46.10.4 的状态报警，还有一条诊断性的报警值得加：**前馈与反馈长期反向**。本章 $K_p > 0$、$K_d > 0$、$K_{ff} < 0$，扰动使温度下降时，反馈要开大阀门（$u_{fb} > 0$），前馈也要开大阀门（$u_{ff} = K_{ff} d > 0$），两者**同向**。若观察到两者持续反向，只有三种可能：增益符号取错、扰动通道符号变了（例如换了一种物料）、或者前馈的延迟错得离谱，导致它在扰动过后还在补。这条报警不增加任何硬件，却能在模型失效的早期给出提示。

最后一条纪律：**前馈不能改变手动/自动的状态**。有些老组态把前馈输出直接写进 PID 的输出端，绕过了手自动切换逻辑，结果操作员切手动后前馈仍在动作，阀门不听人。正确接法是前馈进入 PID 块的“前馈输入”端子（若有），或在 PID 输出之后、AO 之前用独立的求和块，且求和块受手自动状态控制。

46.10 工程落地

46.10.1 测量回路是前馈的眼睛

前馈是开环的，它唯一的输入是扰动测量。测量错了，前馈会“认真地”把错误放大到执行器上，而且没有反馈那样的自我纠正。所以工程落地的第一件事不是组态前馈块，而是把测量回路查清楚。

位置。 测量点必须在扰动传播路径的上游，且尽量靠近扰动源。位置偏下游，$\Delta\tau$ 变小，前馈可用的时间窗口缩短；位置偏上游但取样管太长，测量滞后又会吃掉窗口。两者要一起权衡。

滞后。 取样、变送、滤波、扫描四段滞后之和应小于 $\Delta\tau/3$。本章 4 s 的窗口对应 1.3 s 预算；若变送器自带 2 s 阻尼，前馈还没动作，扰动已经到出口。

噪声。 噪声不会被前馈平均掉，只会被原样放大。本章 $\sigma = 0.02$ 的测量噪声，在不滤波时让前馈输出抖动 0.0309，是静态前馈稳态值 0.667 的 4.6%。图 46-9 给出滤波与噪声、性能之间的完整折中。

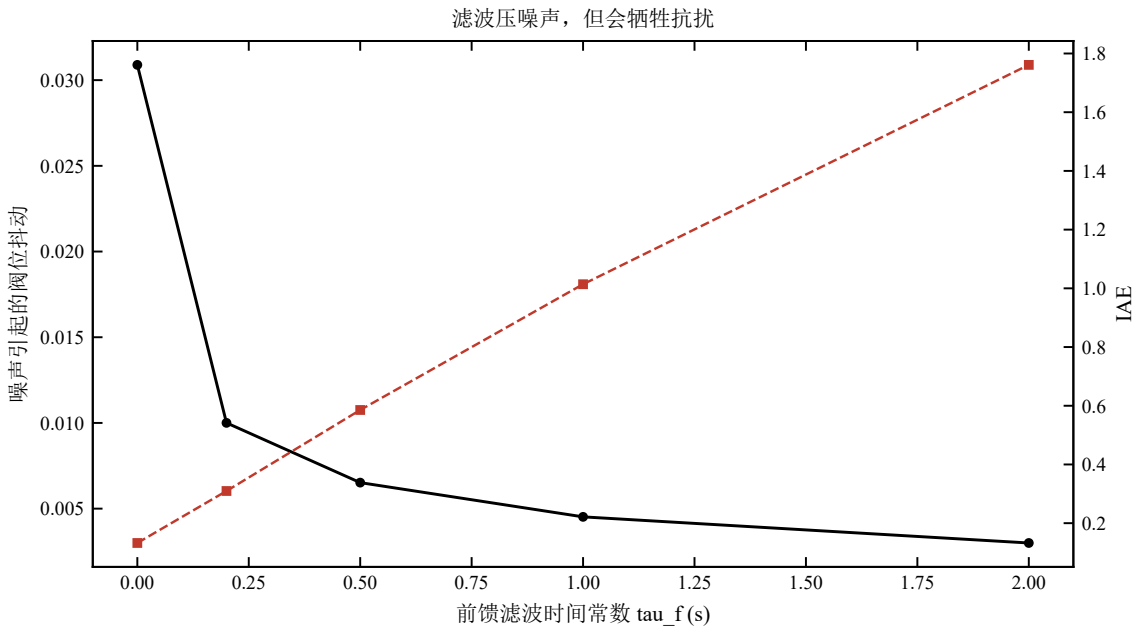

图 46-9　前馈滤波的折中：噪声标准差随滤波时间下降，IAE 随之上扬，两条曲线没有共同的极小点

图 46-9 的横轴是滤波时间常数，纵轴分别是噪声标准差与 IAE。两条曲线的走向相反，说明这是一个纯粹的权衡，不存在“又稳又准”的滤波参数。选择依据只能是工艺对阀门动作频率的容忍度。

标度与零点。 这是最容易被忽略的一项。噪声是零均值的，长期看不影响稳态；零点漂移是系统性的，会让前馈长期偏一个固定量，稳态偏差被反馈默默补掉，运行人员看不到，直到前馈输出顶到限幅才发现。建议每季度核对一次扰动测量的零点，尤其是差压、流量这类容易漂的变量。

46.10.2 DCS 组态：块的顺序就是算法的顺序

前馈在 DCS 里是一串功能块，块的连接顺序决定了算法的正确性。推荐顺序是：

1. 模拟输入与质量位判断；
2. 纯延迟（整数拍缓冲区）；
3. 超前-滞后；
4. 一阶滤波；
5. 前馈限幅；
6. 与反馈输出相加；
7. 执行器输出与跟踪。

有两个顺序细节必须强调。**延迟放在最前，滤波放在超前-滞后之后。**线性环节在数学上可以交换，工程上这样排有三个理由：延迟拍数直接对应物理时间 $\tau_d - \tau_p$，不会被滤波器的滞后“污染”；滤波直接作用在前馈指令上，能压住超前-滞后的初始跳变；调试时可以单独旁路滤波，观察它对峰值和噪声各自的影响。

限幅在相加之前。前馈限幅只约束前馈支路，不能约束总和；否则反馈的动态会被前馈的饱和拖住。这一点在 §46.9.6 已经从控制角度说过，在组态上就是“限幅块必须接在前馈支路的末端”。

扫描周期与相位也要对齐。前馈块、反馈块、输出块应在同一个任务里，周期相同；若前馈在慢任务（如 1 s）、反馈在快任务（如 0.1 s），前馈的等效延迟会增加 0.5–1 s，§46.6.2 的敏感性会立刻显现。

46.10.3 投运的八个步骤

把 §46.8 的整定方法落成现场步骤，可以写成八步。

一、回路检查。 确认扰动测量、主变量测量、阀门方向与量程正确；手动给阀门几个开度，记录主变量响应，核对 τ_p 与 T_p。

二、反馈整定。 前馈切手动、输出置零，按 §46.8.2 把 PI 调到相位裕度 60°–75°，记录纯反馈基线（本章 0.4706 / 5.5520 / 31.65 s）。

三、静态前馈。 按 §46.8.3 做符号、量级、稳态三项检查，确认峰值降到 0.2154 附近。

四、延迟对齐。 按 §46.8.4 细扫 n_{ff}，找到 V 形底部；记录最优拍数与对应的峰值。

五、动态环节。 投入超前-滞后，核对 T_1/T_2 与初始跳变；观察峰值是否进入 0.01 量级。

六、滤波与限幅。 按 §46.8.6 先定限幅、再定滤波；记录两项叠加后的峰值与噪声。

七、扰动试验。 人为制造 3–5 次不同幅值的扰动（建议从 -1.0 到 -0.25 逐档减小），确认线性度；若大幅扰动下峰值比例明显偏离，说明存在非线性，需要考虑增益调度。

八、72 小时试运行。 连续记录前馈输出、限幅状态、扰动测量、主变量；每天统计一次峰值与 IAE（只在有扰动的时段统计），确认没有漂移、没有持续饱和、没有异常抖动。

46.10.4 故障预案

前馈的开环特性决定了它对故障没有自愈能力，必须靠外部逻辑兜底。表 46-13 列出六种常见故障与对应动作。

故障	检测方式	前馈动作	反馈动作
测量质量坏	质量位、超量程	切手动，输出斜坡归零	正常，接管全部扰动
测量冻结	长时间方差为零	切手动并报警	正常
前馈持续饱和	限幅标志持续 5 min	报警，启动增益校正	正常
校正参数越界	$\lvert K_{ff}\rvert > 1.5$ 倍名义值	冻结校正，保留原值	正常
控制任务超时	看门狗计数	保持上一拍输出	正常
阀门到限	输出贴限	前馈限幅生效	抗饱和回算

表 46-13　前馈回路的六种故障与动作

三条设计原则贯穿这张表。

失效要往“无前馈”退，不要往“满前馈”退。 测量坏了，最安全的动作是让前馈退出、把扰动交还给反馈；绝不能保持最后一个前馈值不动，那相当于给阀门加了一个错误的固定偏置。

退出要斜坡。 前馈从 0.667 直接切到 0，等于给阀门一个反向阶跃。正确做法是用 10–20 s 斜坡降到零，让反馈有时间接管。

报警要报“状态”，不要报“数值”。 操作员需要知道的是“前馈已退出”“前馈在限幅”，而不是当前 u_{ff} 等于 0.42。状态量能直接对应动作，数值只会增加判断负担。

46.10.5 操作员接口

前馈回路对操作员应该只有三个可见元素：一个投切开关、一个手动偏置、两个状态指示（运行/退出、正常/限幅）。

投切开关用于检修和异常处置；手动偏置用于小范围修正（一般 ±10%），不要做成第二个增益旋钮；两个状态指示让操作员一眼判断前馈是否在工作。

T_1、T_2、n_{ff} 这些参数不应暴露在操作画面上。它们属于模型参数，改动需要重新辨识和验收，不适合运行中随手调整。把它们藏进工程师权限，是对前馈的一种保护。

46.10.6 长期监控的三条趋势

前馈投运后不是“设好就不管”，需要三条长期趋势来监控健康度。

静默段的前馈标准差。 没有扰动时 u_{ff} 应接近常数，其标准差反映测量噪声与滤波效果。本章 $\tau_f = 1$ s 时为 0.0045；若某天升到 0.02，说明测量回路出了问题（接地、屏蔽、变送器老化）。

u_{ff}/d 的比值。 稳态时这个比值应等于 K_{ff}。它的慢漂移直接反映模型失配，可以作为 §46.9.2 在线校正的输入，也可以作为“该重新辨识了”的提醒。

限幅时间占比。 前馈输出贴限的时间比例，反映执行器余量是否足够。若长期超过 5%，说明前馈设计超出了阀门能力，应该降低动态前馈的激进程度（增大 τ_f 或退回静态前馈）。

三条趋势对应三个部件：测量、模型、执行器。每月看一次，比每年做一次大修式的重新辨识更有效，也更省人力。

46.10.7 数据质量位比数值更重要

前馈块拿到的不是一个干净的浮点数，而是“数值加质量”。工程上必须把质量位当成第一等输入来处理，否则会出现“数值看着正常、其实是坏值”的隐性故障。

四类要检测的异常：

- **坏值**：变送器故障、断线，DCS 给出 BAD。前馈应立即退出，不能参与运算。
- **超量程**：读数贴在量程上下限，多半是仪表故障或工艺异常。此时按坏值处理。
- **冻结**：数值长期完全不变，而相邻变量仍在变化。这类故障最危险，因为质量位往往是 GOOD。检测方法是“连续 N 拍方差为零”且“关联变量有变化”，N 取 20–30 拍即可。
- **通信超时**：数据超过 2–3 个扫描周期未更新。用时间戳判断，不要用数值变化判断。

处理策略统一为一条：**任何一项异常，前馈退出、切到零、由反馈接管**。不要用替代值，不要保持最后值，也不要用 0 以外的常数——替代值本身就是一个错误的前馈量（§46.10.4）。

量程也需要核对。若扰动测量的量程远大于实际波动范围（例如正常波动 5 ℃、量程 0–500 ℃），量化台阶会把前馈输出变成阶梯状，看起来像“前馈在抖”。经验上量程不应超过正常波动范围的 3 倍；已经装好的宽量程仪表，可以在 DCS 里做一次线性变换后再送前馈，但要注意变换不改变噪声的相对大小。

还有一处时序问题：若 AI 通道自带滤波（很多 DCS 默认开一阶滤波），这个滤波会叠加到 §46.7.5 的 τ_f 上，等效时间常数是两者之和。组态时必须查清 AI 的滤波是否开启，否则会出现“参数按 1 s 整定、实际却是 3 s”的情况。

46.10.8 移交什么，才算交接完成

前馈回路最容易被“交接”毁掉。投运时一切都对，两年后换了一批人，参数还在、模型早就不对，没人知道该怎么判断。避免这种情况，靠的是一份完整的移交包。

必须移交的六项：

1. **辨识数据**：两条通道的阶跃响应原始曲线与辨识结果，注明当时的负荷、工况、日期；
2. **模型参数与不确定度**：不只是 K_{ff}、T_1、T_2、n_{ff} 的数值，还要写明每个值可能的误差范围；
3. **整定记录**：按 §46.8.9 的格式，含每次改动前后的四项指标；
4. **验收曲线**：纯反馈、静态、动态、动态加滤波四条曲线的对照图，这是后续判断“性能是否退化”的基准；
5. **故障处理卡**：一页纸，写清“前馈退出后怎么办”“测量坏了怎么办”“限幅长期贴着怎么办”；
6. **假设清单**：$\tau_d \geq \tau_p$、增益比在某区间内、负荷在某范围内——所有让这套参数成立的前提。

第 6 项最常被漏掉，却最要命。工艺改造（换换热器、加保温、改管线走向）会直接改变 τ_d、τ_p 与增益比，参数表上的数字一个都没变，前馈却已经失效。变更管理里应有一条硬规定：**凡是影响扰动路径或主通道动态的改造，投运前必须重新做双通道辨识**。

最后一条是习惯问题：把“如何退出前馈”写成操作票，贴在操作室。前馈是开环的，出问题时操作员的第一反应必须是退出它，而不是调它。

移交包还应随 DCS 组态一起做版本管理：每次改参数留痕，注明改动人、原因与前后指标。没有版本管理的参数表，两年后基本无法追溯——“这个数是谁改的、为什么改”答不上来，等于没有移交。

工程落地的内容到此为止。下一节把前馈的优缺点摆开，明确它适合什么、不适合什么。

46.11 优缺点与适用边界

46.11.1 五个优点

第一，动作早。 这是前馈唯一的、也是不可替代的优势。反馈必须等误差出现，前馈在扰动测量到的那一刻就能动手。本章 4 s 的时间窗，把峰值从 0.4706 压到 0.2154（静态）甚至 0.0012（动态），靠的就是这 4 s。

第二，不改变稳定性。 前馈不进特征方程，ω_c、PM、GM 都不变（本章 0.1441 rad/s、73.49°、14.73 dB）。这意味着可以在一个已经调好的回路上“加装”前馈，而不必重新整定反馈。对不能停产的装置，这一点极为重要。

第三，作用有针对性。 反馈对所有扰动一视同仁，前馈只针对它测量的那一个。对于“主要扰动明确、其他扰动很小”的场合，前馈的投入产出比远高于把反馈调快。

第四，静态前馈极其便宜。 两个增益、一行乘法，当天就能投运，收益 54%。这是全书所有改进措施里成本最低的一项。

第五，物理意义清楚。 $K_{ff} = -K_d/K_p$、$\tau_{ff} = \tau_d - \tau_p$、$T_1/T_2 = T_p/T_d$，每个参数都能对应到对象的物理量。运行人员能理解，工程师能复核，出了问题能定位。

46.11.2 五个缺点

第一，完全依赖模型。 增益误差 50% 时，动态前馈的峰值 0.2342，已经不如静态前馈。前馈没有自校正能力，模型错多少，残差就留多少。

第二，对延迟极其敏感。 4 s 的 12.5%（0.5 s）就使峰值放大 78 倍；错 2 s 直接不如静态前馈。延迟又偏偏是最难在线辨识的量。

第三，放大测量噪声。 不滤波时前馈输出抖动 0.0309，滤波又牺牲峰值。噪声与性能之间没有免费的解。

第四，占用执行器行程。 动态前馈峰值 1.654，是静态值 0.667 的 2.5 倍。行程不够，前馈会在最需要它的时候被限幅卡住，收益从 99.7% 掉到 77.3%。

第五，维护成本高。 模型会漂移，延迟会变，测量会老化。前馈投运只是开始，后面是长期的核对、校正、重新辨识。

46.11.3 适用条件清单

前馈能用，需要同时满足六条。缺一条，收益都会大打折扣。

1. **扰动可测**，且测量点在上游；
2. **测量滞后**小于 $\Delta\tau/3$；
3. $\tau_d \geq \tau_p$，即扰动通道不比主通道快；
4. **两条通道可辨识**，增益与时间常数在 ±10% 内可复现；
5. **执行器有余量**，至少能提供静态值的 2.5 倍行程；
6. **有人维护模型**，能定期做双通道试验。

这六条里，第 3 条是硬约束，不满足就只能做静态前馈或改测量点；第 5 条是物理约束，不满足就只能限幅；其余四条是工程约束，可以通过投入资源改善。

46.11.4 不适用的六种场景

扰动不可测。 这是最根本的排除条件。负荷、环境温度、原料批次这类“知道存在但测不到”的扰动，只能靠反馈或软测量。

扰动通道比主通道快。 $\tau_d < \tau_p$ 时理想前馈非因果，物理上不可实现。此时前馈只能做静态，或者把测量点前移到真正“提前”的位置。

测量滞后大于时间窗。 在线分析仪、取样管长的场合，等测量出来扰动已经作用完，前馈变成“迟到的反馈”，不如不加。

模型频繁变化且无法在线校正。 批次生产、原料频繁切换的场合，前馈参数刚整定好就过时，维护成本会超过收益。

执行器已经饱和。 阀门长期在 90% 以上开度，前馈没有可用行程，加了也白加，还会加剧饱和。

多扰动且都不可忽略。 前馈只能对付它测量的那一个；若同时有三四个量级相当的扰动，需要多路前馈，执行器与调试复杂度都会迅速失控。

46.11.5 四种结构的选型对照

把第 44–46 章的结构放在一起比较，选型思路会更清楚。

结构	核心机制	最适合	主要代价	稳定性影响
单回路反馈	误差驱动	扰动不可测、模型差	动作晚	基准
串级	快回路压内扰	副变量可测、内扰频繁	需副变量测量与整定	外环特性改变
前馈	扰动测量直接补偿	主扰动可测、$\tau_d > \tau_p$	依赖模型与延迟	不变
复合	前馈 + 反馈	主扰动可测且要求高	前馈的全部代价	不变

表 46-14　四种抗扰结构的选型对照

选型的顺序建议是：先问“主扰动可测吗”，可测且 $\tau_d > \tau_p$ 就上前馈；再问“有中间变量可测吗”，有就考虑串级；两者都不满足，就把反馈调到最好，并接受它的物理极限。

前馈与串级不是互斥的。§46.9.5 已经说明，两者可以叠加成三层结构，但每加一层都要重新辨识、重新验收，复杂度是累加的。

46.11.6 三条隐含边界

本章的所有结论都建立在三个前提上，越界时要重新评估。

线性。 式 (46-1) 的推导用了叠加原理。若阀门有明显死区、对象增益随负荷变化，前馈的“抵消”只在工作点附近成立。本章的增益调度（§46.9.3）就是为这条边界准备的。

时不变。 K_{ff}、T_1、T_2 都假设不随时间变。实际对象会结垢、老化，所以需要 §46.9.2 的在线校正。

单扰动。 推导只考虑一个 d。多扰动时，各路前馈线性叠加，但执行器行程与测量噪声也叠加，实际可用性要重新评估。

三条边界都不难理解，难的是在投运前想到它们。工程上出问题的前馈，多半不是公式错了，而是越过了其中一条边界却没人察觉。

46.11.7 什么时候该拆掉前馈

前馈不是装上就必须永久保留的设备。四种情况下，拆掉它（或降级为静态）比继续维护更合理。

扰动本身消失了。 工艺改造常会意外消掉扰动源：上游加了缓冲罐，入口温度波动被抹平；管线加了伴热与保温，环境温度不再影响；换了变频泵，压力波动减小。这时前馈仍在“忠实地”补偿一个几乎不存在的扰动，它的输出主要由噪声驱动，反而给阀门增加了无谓的动作。

模型无法维护。 一年内做了两次辨识，参数仍然在几个月内漂到验收线以外，说明这个对象的增益比或延迟本身不稳定，超出了开环补偿能覆盖的范围。此时应退回静态前馈（只保留增益比，对动态不敏感），或干脆退回反馈。

执行器没有余量。 §46.10.6 的限幅时间占比长期超过 5%，且扩容不可行。前馈在关键时刻被限幅，收益已经名存实亡，却仍占用阀门行程、干扰反馈。

风险大于收益。 前馈误动作的后果很严重（例如把阀门推到工艺联锁边界），而它带来的峰值改善相对有限。这种场合应把前馈改成“只报警、不动作”的监视模式，或者加更严格的限幅与速率限制。

拆的方式也有讲究，不要一步切到零：先把动态降为静态（只留 K_{ff}），观察一个周期；确认无异常后再退出。测量回路建议保留，作为扰动报警与后续分析的输入——拆掉的是补偿，不是信息。

降级不是失败。 从动态退回静态、从静态退回反馈，都是根据对象可维护性做出的合理工程判断。真正不该发生的是“参数早就失效，却因为没人敢动而一直挂着”——那才是前馈最容易造成的隐性损失。

46.11.8 新回路的六问判别顺序

把本章的判断压缩成一个可以照着走的顺序，遇到新回路时按这六问问下去，每一步的“否”都对应一个明确的退路。

一问：扰动可测吗？ 不可测就停在这里，改用反馈、串级或观测器（§46.2.9），不要试图“用模型猜”。

二问：测量比扰动到达早吗？ 要求 $\tau_m < (\tau_d - \tau_p)/3$。不满足就先改测点或换仪表（§46.3.9），改不了就停。

三问：执行器有 2.5 倍余量吗？ 没有就只做静态前馈（§46.7.6），或者先扩容。

四问：扰动主要是慢变吗？ 是，静态前馈就够（§46.3.5），不必上动态。

五问：有人能维护动态模型吗？ 没有就停在静态。动态前馈的收益会被模型漂移吃掉，而维护成本是长期的（§46.9.1）。

六问：需要参考前馈吗？ 先算一遍表 46-12 那样的对比。本章对象不需要；只有设定值频繁大幅变化、执行器余量充足、工艺更看重跟踪速度时才考虑。

六问都通过，才进入 §46.3 的六步设计与 §46.8 的整定。这个顺序的价值在于：**它把“能不能做”放在“做得多好”之前**，而现场失败的回路，绝大多数是跳过了前两问。

46.11.9 本章结论

前馈控制的价值可以用一句话概括：**它把“等误差出现再纠正”变成“在扰动到达之前就抵消”**。本章用 4 s 的时间窗，换来了峰值 99.7% 的下降；代价是对模型、延迟、测量、执行器的全面依赖。

对工程实践，最重要的三条结论是：

第一，**先做静态前馈**。两个增益、54% 收益、不改变稳定性，没有理由跳过。

第二，**延迟比增益更重要**。0.5 s 的延迟误差就能抹掉大半收益，而它又最容易被忽略。投运时把细扫延迟放在调形状之前。

第三，**前馈不替反馈负责**。它不改裕度、不做稳态校正、不处理不可测扰动。前馈做得再好，反馈仍要按原裕度稳定运行。

本章与第 47 章有一层对照关系。前馈是“用模型提前算出一个控制动作”，因为它有一个可测的扰动源；Smith 预估器则是“用模型把纯滞后搬到闭环之外”，它面对的是不可测的滞后，只能让模型在内部先跑一遍。两者都靠模型精度吃饭，也都会在模型失配时明显退化，但失效方式不同：前馈的模型误差表现为“补多补少”，不改变稳定性；Smith 的模型误差会让被搬走的滞后重新回到闭环里，直接影响稳定裕度。把这两章放在一起读，会对“模型在控制里到底起什么作用”有更完整的理解。

§46.12 给出本章全部仿真的代码结构与阅读方法，读者可以据此复现每一个数字。

46.12 Python 仿真代码

本章所有数字都可以在本机复现，不依赖任何外部数据。这一节说明代码的组织方式、接口含义与阅读顺序，读者据此可以逐个复核正文中的指标，也可以把自己的对象参数换进去。

46.12.1 文件与运行

三个位置分工明确：

- `code/ch046_sim.py`：对象参数、离散化工具、`simulate()`、指标函数、频域函数，以及 `main()` 的十三段输出。正文里的每一个峰值、IAE、恢复时间都来自它的终端输出。
- `code/ch046_figs.py`：调用 `ch046_sim.py` 里的函数生成十张图，每张同时输出 svg 与 pdf，统一放在 `figs/ch046/`，文件名形如 `fig_046_03_dist_compare.svg`。
- `figs/ch046/`：正文引用的十张图，编号 46-1 至 46-10 与文件名中的序号一一对应。

运行方式（Windows，py311 环境）：

```
"D:\Anaconda3\envs\py311\python.exe" code\ch046_sim.py
"D:\Anaconda3\envs\py311\python.exe" code\ch046_figs.py
```

依赖只有三个外部库：`numpy`、`control`、`matplotlib`；`simlib` 是本书自带的工具模块，提供 `step_metrics` 等指标函数，与前面各章口径一致。整章仿真在普通笔记本上几秒内跑完，可以放心反复改参数。

46.12.2 为什么不用 simlib 的单回路接口

`simlib` 的单回路接口适合“一个控制器加一个对象”的结构，本章需要的四件事它表达不了：

1. 前馈支路与反馈支路要分别记录，才能画出图 46-3 下半幅的 u_{ff}；
2. 纯延迟只能加在前馈通道上，对象自身的延迟另算；
3. 限幅只能加在前馈支路，不能把 $u_{fb}+u_{ff}$ 一起限（§46.8.8 第 4 条错误）；
4. 参考前馈是第三路信号，与反馈、扰动前馈在同一个求和点相加。

所以 `simulate()` 自己写了逐步循环。对象仍用 ZOH 离散（`control.c2d`），与 `simlib` 的口径一致；设定值跟踪指标直接复用 `sl.step_metrics`，保证与第 44、45 章的数字可比。

46.12.3 simulate() 的接口

`simulate()` 有十九个参数，按用途分三组。表 46-15 给全貌。

参数	默认值	作用	正文对应
`cascade_ff`	`"none"`	选择 `"none"` / `"static"` / `"dynamic"`	§46.4.1
`k_ff`	-0.6667	前馈静态增益，改它即制造增益失配	§46.4.3、§46.4.4
`t_lead`、`t_lag`	10、4	超前-滞后的两个时间常数	§46.7.3
`tau_f`	0	前馈通道一阶滤波时间常数	§46.7.5、§46.9
`ff_limit`	`None`	前馈输出限幅，元组 `(lo, hi)`	§46.7.6
`ref_ff`、`tau_r`	`False`、0	参考前馈开关与其设定值滤波	§46.7.8、§46.9.4
`Ts`、`N`	0.05、2400	采样周期与总拍数，$2400 \times 0.05 = 120$ s	§46.5.4
`t0`、`dist_amp`	40、-1.0	扰动加入时刻与幅值	全章
`ref`	1.0	设定值，扰动实验里保持不变	§46.7.8
`noise`、`seed`	0、0	扰动测量的高斯噪声标准差与随机种子	§46.7.5、§46.10.7
`k_p`、`k_d`	1.2、0.8	**对象真值**，改它即制造对象失配	§46.4.4
`kc`、`ti`	1.2、10	反馈 PI 的增益与积分时间	§46.7.7、§46.8.7

表 46-15　`simulate()` 的参数与正文对应

三组参数的用法要分清。第一组决定**结构**，`cascade_ff` 一次只选一种，比较不同方案就是换这个值；第二组是**前馈整定**的重点，也是全书反复讨论的五个量；第三组是**仿真环境**，其中 `k_p`、`k_d` 是对象真值——想制造模型失配，改它们，而不是改 `k_ff`。这一点很容易搞反：改 `k_ff` 是“设计错了”，改 `k_p`、`k_d` 是“对象变了、设计没跟上”，两者在 §46.4.4 里是同一件事的两种说法，但在代码里必须区分清楚，否则无法复现“前馈按名义值设计、对象已漂移”的场景。

46.12.4 主循环的时序

逐步循环里，每一拍的顺序固定为六步，顺序本身就是设计的一部分：

1. **算输出**：y_k 由两个对象的状态直接相加得到，此时对象还没推进，所以这一步读的是“上一拍作用后的结果”；
2. **先算设定值通道**：`ref_ff` 打开时，先由 τ_r 滤波得到 r_f，再取 $u_{ref} = r_f / K_p$，同时把 r_f 作为反馈的设定值 `r_eff`。**这一步必须在误差之前**，否则参考前馈用的是本拍设定值、反馈用的是上拍设定值，两者错开一拍；
3. **算反馈**：$u_{fb} = K_c e + K_i x_i$，其中 $e = r_{eff} - y_k$；
4. **算前馈**：先从延迟缓冲区取 $d_{ff,k}$，送超前-滞后的状态方程，得到 u_{ff}；再依次过一阶滤波与限幅。滤波用的是上一拍的输出 `uff_seq[k-1]`，系数 $\alpha = T_s/(\tau_f + T_s)$，与连续域的一阶惯性对应；
5. **相加输出**：$u_k = u_{fb} + u_{ff} + u_{ref}$，三条支路都在这一拍合成；
6. **推进**：积分器累加 $T_s e$，主通道用 u_{k-n_p} 作为输入（前 n_p 拍补零），扰动通道用已经延迟 n_d 拍的 d。

第 6 步里“主通道用 u_{k-n_p}”是延迟的另一种写法：不在对象内部设延迟，而是让输入回到历史缓冲区取值。这样对象的离散状态方程保持一阶、干净，纯延迟的拍数也可以随时改——§46.6.2 的延迟扫描就是这么做的。

还有一处是刻意简化的：积分器没有抗饱和。原因是本章的扰动幅值小、前馈又削掉了大部分偏差，积分器几乎不会长时间饱和；把抗饱和加进来会让“前馈与反馈的配合”这一主题变得难以分离。真实工程必须加，§46.9.6 与

§46.10.4 给的是工程做法，不在仿真里体现。

46.12.5 三个工具函数

全部离散化工作由三个短函数完成，每个都对应正文的一条纪律。

`_ss(sys, Ts)` 把连续传递函数转成 ZOH 离散状态空间四元组。逐步循环里需要的是 $x_{k+1} = Ax_k + Bu_k$ 这种矩阵形式，状态空间比传递函数少一次转换；`control.c2d` 与 `simlib` 用的是同一个方法，因此本章与前面各章的对象离散化口径一致。

`_leadlag(gain, t_lead, t_lag, Ts)` 构造 $K(T_1 s + 1)/(T_2 s + 1)$ 的离散四元组。分子写成 `[gain*t_lead, gain]`，顺序不能反；若写成 `[gain, gain*t_lead]`，直流增益会变成无穷大，仿真一开始就发散。构造完可以顺手核一次直流增益：$z = 1$ 处应等于 `gain`，这是 §46.5.3 那条纪律的代码版。

`_delay(seq, n)` 是整数拍延迟，`out[:n]` 用初值填充、`out[n:]` 取 `seq[:-n]`。前 n 拍填初值而不是零，对应“仿真从稳态开始”的假设：对象初始为零、扰动初始也为零，填初值与填零等价；若扰动初值不为零（例如研究一段已有的偏差），则应改成零填充，否则会凭空多出一段延迟后的阶跃。

46.12.6 两个指标函数的口径

`dist_metrics()` 计算扰动响应的四个量：峰值偏差、IAE、恢复时间、执行器最大偏移。口径上有三处必须注意。

基线取 t_0 前一拍的值，不是取零。本章设定值为 1.0，若用零做基线，峰值会变成设定值本身（约 1.0），扰动造成的 0.47 变化被完全淹没。这也是为什么扰动实验里必须让设定值保持不变：基线一旦漂移，指标就失去意义。

恢复时间取“最后一次越界”的时刻，不是“第一次进入 $\pm 2\%$ 带的时刻”。前者对噪声与二次回升更稳健；后者一旦曲线短暂穿过带又出去，会给出一个虚假的短恢复时间。

窗口取 60 s，必须覆盖整个拖尾。本章静态前馈的恢复时间 44.95 s 已经接近窗口上限；若把窗口缩到 40 s，它会因为“窗口结束时仍在带外”被判为 `nan`，而不是给出一个偏小的数。读表时看到 `nan`，先查窗口，再查控制器。

`ref_metrics()` 直接复用 `simlib.step_metrics`，返回 `overshoot`、`rise_time`、`settling_time` 三个键。注意键名是 `settling_time` 而不是 `settle_time`，写错会直接抛 `KeyError`——这是本章代码调试时踩过的一个坑，写在这里省得读者再踩一次。

46.12.7 频域函数与一个符号陷阱

`ff_freq()` 给出前馈通道自身的幅频与相频，用来解释图 46-10 里“前馈是一个高通形状”这件事：超前-滞后在低频增益为 1，在高频增益趋于 $T_1/T_2 = 2.5$，因此扰动测量里的高频噪声会被放大 2.5 倍送到阀门。

`residual_freq()` 直接按复数算残差的模：

$$|E(j\omega)| = |G_d(j\omega) + G_{ff}(j\omega) G_p(j\omega)|$$

这里有一个反复出现的符号陷阱。G_{ff} 的定义里已经含负号（$-K_d/K_p$），所以残差是“加”而不是“减”。若写成 $G_d - G_{ff} G_p$，模型准确时会算出 $2|G_d|$ 的残差，图上看起来像“前馈把扰动放大了一倍”——这个错误在讲义与论文里都不止出现过一次。判断自己有没有写错，最快的办法是看 $\omega \to 0$ 的极限：正确写法应趋于零，写错则趋于 $2|K_d|$。

同一个函数里还有一处容易漏：G_{ff} 必须带上 $e^{-(\tau_d-\tau_p)s}$。漏掉延迟项，低频残差会凭空变大，而且相位曲线会整体平移，看起来像“模型不准”，实际是代码少了一项。

46.12.8 十三段输出与正文的对应

`main()` 从基线到参数配合共十三段，每段对应正文的一处结论。表 46-16 是索引。

段	内容	对应正文	关键输出
一	纯反馈基线	§46.4.1	Mp 0.00%、t_r 10.068 s、峰值 0.4706
二	四方案对比	§46.4.1	0.2154 / 0.0012 / 0.1256
三	静态增益扫描	§46.4.3	峰值最优 -0.9，IAE 最优 -0.667
四	增益失配	§46.4.4	0.2342 与 0.2365
五	延迟扫描	§46.6.2	0.5 s 偏差即 0.0938
六	参考前馈	§46.7.8	Mp 22.72% 至 0.01%
七	采样周期	§46.5.4	0.0012 至 0.0578
八	测量噪声	§46.7.5	std 0.0045（$\tau_f = 1$ s）
九	前馈限幅	§46.7.6	0.1066（限到 1.0）
十	前馈频响	§46.6.3	低频 0.667、高频 1.667
十一	残差频响	§46.6.3	峰值放大 78 倍、IAE 放大 22 倍
十二	闭环裕度	§46.6.1	PM 73.49°、GM 14.73 dB
十三	反馈参数配合	§46.7.7	复合峰值 0.0012 对纯反馈 0.4706

表 46-16　`main()` 十三段输出与正文的对应

建议的阅读顺序不是从第一段读到最后，而是：先看第一、二段建立基线（纯反馈有多差、前馈能好多少），再看第十二段确认“前馈没有改变裕度”这个前提，然后按第五、四、八、九段的顺序看四类失配——顺序按“最敏感→最不敏感”排，与表 46-7 一致；最后看第十三段，理解反馈参数为什么要按裕度而不是按复合峰值整定。

第十一段常有读者疑惑：为什么峰值放大 78 倍而 IAE 只放大 22 倍？原因是残差通道是高通形状，它把误差集中在扰动到达后的很短一段时间里；峰值只看那一个点，IAE 却把整段时间积分平均。两张口径的差别正是 §46.6.3 的结论。

46.12.9 复现与三个扩展练习

复现只需两条命令（§46.12.1）。若想验证自己对参数的理解，建议做三个练习，每个都能用现有接口完成，不需要改代码。

练习一：把采样放慢。 令 `Ts=0.5`，总拍数改成 `N=240`，其余不动，重跑第二段。结果应与表 46-5 的 0.0142 一致。这个练习的目的是确认“采样变慢不等于前馈失效”。

练习二：把阀门关小。 加 `ff_limit=(0.0, 1.0)`，重跑第二段，峰值应为 0.1066。再把限幅放到 `(0.0, 0.667)`，峰值回到静态前馈的水平。这个练习验证“动态前馈的收益依赖执行器余量”。

练习三：让对象漂移。 把 `k_d` 改成 0.4（名义值仍是 0.8，前馈不变），重跑第四段。峰值应为 0.2342 左右，与 $\kappa = 1.5$ 时的 0.2365 基本对称——因为残差按 $|1 - \kappa|$ 成比例。这个练习是理解“在线校正为什么必要”的最短路径。

若要把 `simulate()` 嵌进参数搜索，有两点需要注意。第一，**先固定采样周期与反馈参数**（`Ts`、`kc`、`ti`），只搜索前馈的 K_{ff}、τ_f 与延迟拍数；否则维度上升，网格很快失去意义。第二，**先筛硬约束再排序**：把“峰值不超过 0.2”“前馈峰值不超过阀门行程”作为过滤条件，再在通过的组合里按 IAE 排序。直接按 IAE 排序容易选出“峰值很低但阀门早已饱和”的组合，那种解在现场无法投运。

延迟拍数不在 `simulate()` 的参数表里，它由 $n_{ff} = n_d - n_p$ 自动算出；要做延迟方向的搜索，需参照 `_delay_scan_sim()` 的写法，把 n_{ff} 提成一个可选参数（默认值仍为 $n_d - n_p$）。该函数单独复制了一遍主循环，就是因为最初没有预留这个参数——这也算一处可以改进的地方，读者不妨把它合并回 `simulate()`。

代码讲完，本章也就结束了。不同版本的 `numpy` 与 `control` 在末位可能有微小差异，但四位有效数字应当一致；若某一行对不上，先查采样周期与总拍数，再查是否改过默认参数。回到最初的问题：前馈值不值得做？答案是——**只要扰动可测、测量够早、模型可维护，它就是用最小代价换最大峰值改善的手段；三条缺一条，就应该退回静态前馈或纯反馈**。本章的 4 s 时间窗、0.4706 到 0.0012 的对比，说的都是这件事。

第47章 Smith预估器与大延迟系统

47.1 动机与直观理解

47.1.1 一段八秒钟的沉默

假设你站在一台换热器前，手里握着蒸汽阀。出口温度偏低，你把阀门开大一点，然后等。等多久？在这台设备上，从阀门动作到出口温度探头感受到变化，中间要经过八秒钟：蒸汽先走一段管道，再穿过管壁，热量传给工艺介质，介质再流到测温点。这八秒里，你什么也看不见，阀门已经动了，温度却纹丝不动。

八秒之后，温度开始上升。可这时你已经等了八秒，心里发慌，很可能在等待期间又开大了几次。等到温度终于响应，它冲过头了；你再关小，又要等八秒才看见效果。于是阀门来回摆，温度画出一条越来越大的振荡曲线。这不是操作员手艺差，而是延迟把“看见后果”的时间推后了，人也好、PID 也好，都容易在看不见后果的这段时间里重复动作。

把这件事写成传递函数，就是本章的对象：

$$G(s) = \frac{K e^{-\tau s}}{T s + 1} \tag{47-1}$$

其中 K 是增益，T 是时间常数，τ 是纯滞后。本章取 $K = 1.0$、$T = 5\,\text{s}$、$\tau = 8\,\text{s}$，于是 $\tau/T = 1.6$。这个比值很关键：τ/T 小于 0.2 时，延迟只是让响应稍微迟钝；到了 1 附近，常规 PID 的可用增益就被压得很低；超过 1.5，纯反馈基本只能“慢慢磨”，稍一着急就振荡。

47.1.2 延迟的四个来源

纯滞后不是一个数学游戏，它在工业现场有明确的物理来源，而且不同来源的延迟性质不同。

第一类是输送延迟。物料从 A 点流到 B 点，流速有限，距离除以流速就是滞后。皮带秤到配料仓、管道里的浆料到下游反应器，都属于这一类。它的特点是随流量变化：流量减半，延迟翻倍。

第二类是混合与扩散延迟。示踪剂进入搅拌罐，出口浓度不会立刻变化，而是先平缓、后上升。这类过程更接近“纯滞后串联一阶惯性”，式 (47-1) 只是它的近似。

第三类是分析仪延迟。在线色谱、红外分析仪往往有几十秒到几分钟的采样与预处理周期，测到的是“过去的成分”。这类延迟最大，也最难压缩。

第四类是通信与计算延迟。现场总线周期、上位机扫描周期、云平台往返，单看都不大，叠加起来可能有一两秒。

四类延迟里，第一类会随工况漂移，第二类随停留时间分布变化，第三类基本固定但数值大，第四类与设备负载有关。Smith 预估器要面对的不是一个常数 τ，而是一个“大致知道、但不完全准”的 τ。这一点决定了本章后半程的重点：不是怎么把预估器搭出来，而是模型不准时它还能不能用。

47.1.3 延迟为什么难：一笔相位账

线性系统里，纯滞后对幅值没有影响，只改相位：

$$G(j\omega) = |G(j\omega)|\, e^{-j\omega\tau}, \qquad \angle G(j\omega) = -\arctan(\omega T) - \omega\tau \tag{47-2}$$

在穿越频率 ω_c 处，闭环稳定的条件是相位滞后不到 180°。延迟项 $-\omega_c\tau$ 是白送的滞后：$\tau = 8$ s、$\omega_c = 0.2$ rad/s 时，它一项就贡献 1.6 rad，约 91.7°。也就是说，一半的相位预算被延迟吃掉了，留给控制器和对象惯性的只有另一半。

相位预算被吃掉，直接后果是增益上不去。增益上不去，闭环带宽就窄，响应就慢；而响应越慢，操作员越容易重复动作，形成前面说的恶性循环。纯反馈在大延迟对象上的困境，本质是“相位不够→增益不敢大→速度上不去”的死结。

47.1.4 一句话说清 Smith

Smith 预估器的想法只有一句话：既然延迟让反馈“看见后果”太晚，那就让一个模型先替对象把后果算出来，把“预演结果”送给控制器，让它以为自己面对的是一个没有延迟的对象。

这句话里有三个关键词。第一是“模型”，必须知道对象大致长什么样；第二是“预演”，模型要和对象同时吃同一个控制量 u；第三是“没有延迟”，送给控制器的是“假如没有滞后，现在应该到多少”，而不是真实测量值。

于是控制器不再等八秒。它拿到的信号里，延迟造成的“空白”被模型补上了，它可以在阀门动作后的下一拍就知道“这一动作最终会把温度推到哪”，从而及时收敛，而不是反复加码。

47.1.5 预演的三个动作

具体怎么做？把模型拆成两块：无延迟部分 $G_{m0}(s) = K_m/(T_m s + 1)$ 和延迟部分 $e^{-\tau_m s}$。然后做三个动作。

动作一，让无延迟模型和真实对象吃同一个控制量，得到“假如没有延迟，输出现在应该是多少”，记作 y_{m0}。

动作二，把这个信号再延迟 τ_m，得到“模型认为真实测量现在应该是多少”，记作 $y_{m\tau}$。它对应的是真实对象里那条走了八秒的路。

动作三，把二者之差加回真实测量：

$$y_{pred}(t) = y(t) + \left[y_{m0}(t) - y_{m\tau}(t) \right] \tag{47-3}$$

这个 y_{pred} 就是送给控制器的“等效无延迟输出”。模型准确时，$y_{m0} - y_{m\tau}$ 恰好等于“真实对象里还在管道中、尚未到达探头的那部分变化”，把它加回去，就把延迟从反馈回路里“搬”了出去。

结构上，这三步对应图 47-1 里虚线框内的并联模型：一个 $G_{m0}(s)$、一个 $e^{-\tau_m s}$、一个减法节点。它不改变执行机构接口，也不改变控制器形式，只是把测量信号换成了 y_{pred}。这是 Smith 预估器最容易落地的地方：DCS 里加几个功能块就能实现，不需要换控制器。

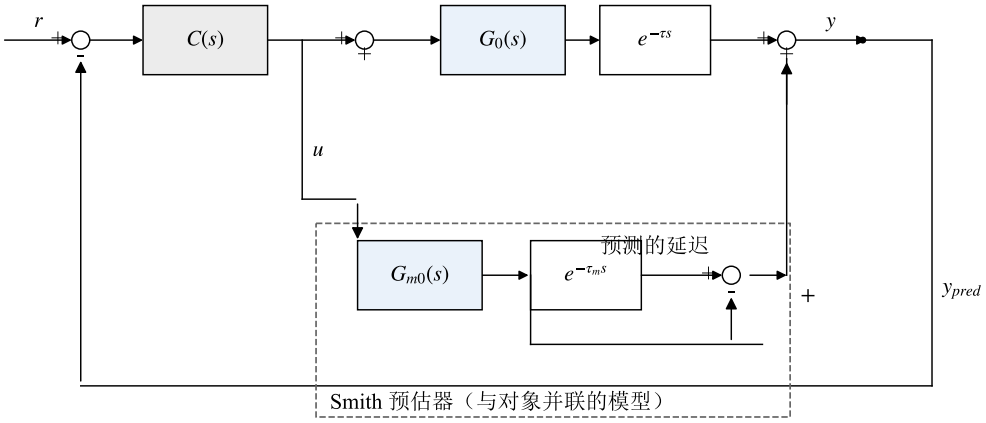

图 47-1　Smith 预估器结构：模型与对象并联，双线框内为预演支路，虚线框把模型的无延迟部分与延迟部分分开

47.1.6 预演靠什么成立

预演成立的前提是模型准。模型准的时候，式 (47-3) 里的两个模型项刚好抵消掉真实对象中的延迟，控制器面对的是 $G_{m0}(s)$，一个没有延迟的一阶惯性环节。这时候 PI 可以按常规方法整定，增益可以取得比纯反馈高好几倍。

模型不准的时候，抵消不干净，剩下的残差会以“虚假的预测”形式进入反馈。最危险的是延迟估错：模型以为八秒，实际十秒，那么模型在第八秒就宣称“变化已经到了”，控制器据此动作，而真实变化还要两秒才到——这两秒的误判会被闭环放大，轻则超调，重则振荡。本章后面会用数据说明，延迟偏差 2 s 就能把超调从 0 推到 31.22%，偏差 4 s 就直接失稳。

所以 Smith 预估器不是“装上就灵”的万能结构，它是一笔交易：用模型精度换反馈速度。模型越准，收益越大；模型越差，风险越高。工程上真正要做的，是判断这笔交易划不划算，以及划不划算的边界在哪里。

47.1.7 与前馈、串级的分工

第 46 章的前馈解决的是“扰动可测”的问题：扰动一出现，不等它影响输出，先按通道关系补一个控制量。Smith 预估器解决的是“输出测量滞后”的问题：不是扰动看不见，而是后果看不见。两者经常被混为一谈，其实判据很清楚。

如果扰动可以测量，而且扰动通道的延迟比主通道长，前馈是首选，因为它从源头上抵消。如果扰动不可测，或者主要矛盾是设定值跟踪与测量滞后，Smith 预估器更合适，因为它改善的是反馈回路本身的相位。

串级控制解决的是“副回路扰动”的问题，它要求有一个响应更快的副变量。Smith 预估器不需要副变量，它需要的是一个能反映对象动态的模型。三者可以叠加：前馈管可测扰动，串级管副回路，Smith 管主回路的大延迟。叠加时要注意，Smith 的模型只应对主回路建模，不要把副回路的快速动态也塞进一阶模型里，否则模型阶次不够，预演反而失真。

47.1.8 本章的数字背景

为了让后面的每句话都能对上数，先把对象和控制器定下来，见表 47-1。对象取式 (47-1)，$K=1.0$、$T=5$ s、$\tau=8$ s；采样周期 $T_s=0.05$ s，延迟对应 160 拍。控制器统一用 PI：

$$C(s)=K_c\left(1+\frac{1}{T_i s}\right) \tag{47-4}$$

表 47-1　本章对象与控制器参数

项目	符号	数值	说明
对象增益	K	1.0	稳态：控制量 1 对应输出 1
对象时间常数	T	5 s	去掉延迟后的一阶惯性
纯滞后	τ	8 s	$\tau/T=1.6$，属大延迟
采样周期	T_s	0.05 s	延迟 160 拍
Smith 用 PI 增益	K_c	2.5	按无延迟模型整定
Smith 用积分时间	T_i	6 s	与 T 同量级
纯反馈保守整定	K_c, T_i	0.6, 8 s	试凑得到的可用值

表 47-1 里有两个 K_c，这是本章对比的核心。$K_c=2.5$ 是按“没有延迟”整定出来的，纯反馈用它会直接发散；Smith 用它却能稳定，而且调节时间只有 20.05 s。同一组参数，一个发散一个收敛，差别只在于反馈信号是真实测量还是预演值。

47.1.9 先看结果：同一组参数

图 47-2 把三条曲线画在一起：纯反馈用 $K_c=2.5$，几拍之内就冲出画面；Smith 用同一组 $K_c=2.5$，输出在 8 s 死区之后平滑上升，20.05 s 进入 ±2% 带，超调几乎为零；纯反馈退到 $K_c=0.6$ 才能稳住，但上升要 8.84 s、调节要 48.50 s，IAE 从 10.40 涨到 14.53。

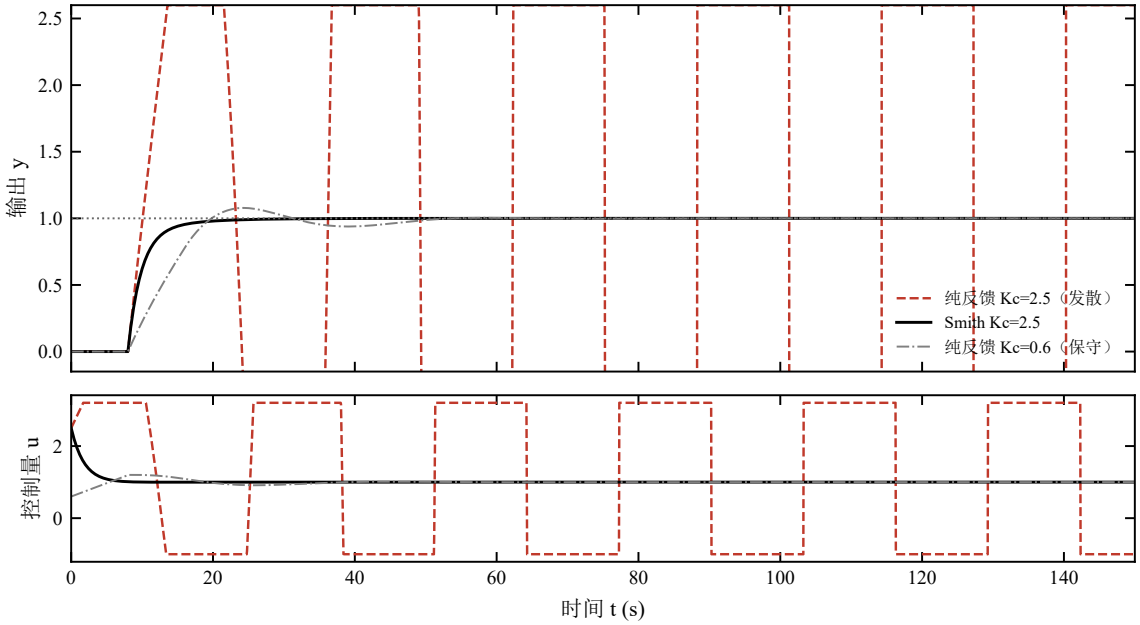

图 47-2　同一组 PI 下的三条响应：纯反馈 $K_c=2.5$ 发散，Smith $K_c=2.5$ 平滑，纯反馈退到 $K_c=0.6$ 才稳住但慢得多

这张图是本章的“预告片”。它说明两件事：第一，Smith 的收益不是靠更激进的控制量堆出来的，它的 $|u|_{\max} = 2.500$，确实比保守 PI 的 1.202 大，但换来的是两倍多的速度；第二，纯反馈不是不能稳，而是只能“慢慢稳”，一旦想把速度提上来，延迟立刻把相位预算耗尽。

47.1.10 本章路线与边界

本章按“原理—设计—连续—离散—稳定—参数—整定—改进—落地—边界—代码”的顺序展开。§47.2 推导预估器为什么能把延迟搬到环外，给出模型失配时的特征方程；§47.3 给出八步设计流程；§47.4 与 §47.5 分别在连续域和离散域核对；§47.6 用三张失配表说明它有多脆；§47.7 逐个参数讲作用；§47.8 给整定经验；§47.9 讨论改进型与鲁棒化，包括三种手段的实测对比；§47.10 讲现场落地；§47.11 给适用边界；§47.12 逐段讲代码。

边界先说清楚：本章只讲 Smith 预估器这一条路线。PID 整定的细节见第 44 章，前馈与复合控制见第 46 章，模型预测控制见第 58 章与第 80 章，内模控制的完整体系见第 107 章。Smith 预估器可以看作内模控制在大延迟对象上的一个特例，本章不展开这层等价关系，只在 §47.9 点到为止。

还有一条边界：本章假设对象是线性、时不变的，延迟是一个常数。真实对象里延迟会随流量漂移，这时固定参数的 Smith 预估器只能在一个工况附近有效。§47.10 会讲延迟在线估计，§47.11 会讲什么情况下应该干脆放弃 Smith、改用别的结构。

47.1.11 三个常见的误判

在进入数学之前，先把三个容易混淆的概念分开。它们都表现为“输入变了、输出暂时不动”，但在模型里的地位完全不同。

第一个误判：把延迟当成惯性。一阶惯性的响应是“立刻开始、逐渐加速”，延迟是“完全不动、然后突然开始”。两者的阶跃曲线在开头几秒很像，用一条惯性曲线去拟合带延迟的数据，也能拟合得不错，但拟合出来的时间常数会把延迟“吸收”进去。用这样的模型做预估器，预演值会提前起势，控制器以为已经见效而收手，实际输出还没到。§47.7.3 的数据说明，T_m 估错一倍的后果比 τ_m 估错 1 s 温和，但“用惯性代替延迟”不是估错，而是模型结构错了，其后果接近延迟全错。

第二个误判：把死区当成延迟。阀门有死区、变送器有不灵敏区，输入变化小于死区时输出完全不动，看起来像延迟。区别在于：延迟会随时间自己走完，死区不会——只要输入没越过死区边界，输出就永远不动。死区要靠补偿（如阀门特性校正、加抖动），不能靠“等一等”。把死区误认成延迟，会得到一个偏大的 τ_m，而按 §47.7.4，延迟高估是最危险的方向。

第三个误判：把分布延迟当成集中延迟。长管道、大储罐的响应不是“先平后陡”，而是“先缓后陡”，因为物料在管道里有速度分布。用纯延迟加一阶惯性去近似，在响应的中段会有系统性偏差。这种对象的 τ/T 往往看起来不大，但预估器的效果不如预期，原因就在这里。工程上的处理是用二阶或高阶惯性加延迟，或者干脆用阶跃响应数据做非参数模型。

三个误判的共同点是：它们都会让 τ_m 偏大，而 τ_m 偏大恰好是 §47.7.4 说的“最贵的方向”。所以建模的第一步不是拟合，而是判断“这段不动到底是哪一种不动”。

47.1.12 Smith 的历史与两次“复活”

Smith 预估器不是新方法。它由 Otto J. M. Smith 在 1957 年提出，比现代 DCS 早了二十多年。它在历史上经历过两次“复活”，这两次复活的原因，恰好对应本章的两个主题。

第一次是 1980–1990 年代，DCS 与 PLC 普及。在气动仪表时代，实现一个纯延迟需要延迟线、磁带或一串气容，精度差、漂移大，预估器的理论收益被实现误差吃掉了。DCS 出现后，延迟变成一个环形缓冲区加一个下标，精度只取决于采样周期，预估器才真正变得“可实现”。

第二次是 1990 年代以后，内模控制与预测控制的兴起。研究者发现 Smith 预估器是 IMC 的一个特例，也是“只预测一步、模型固定”的 MPC。这个理论统一让 Smith 从“一个巧妙的技巧”变成“一类结构的起点”，也让它的整定方法（式 47-21）有了系统解释。

这段历史给今天的学习者一个提醒：Smith 的难点从来不是“想不想得到”，而是“模型准不准、实现细不细”。1957 年的公式和今天的公式一模一样，差别全在工程实现与模型维护上。本章把大量篇幅放在失配分析与落地细节，原因也在这里。

47.2 数学原理

47.2.1 记号：对象、模型、控制器

先统一记号。真实对象为

$$G(s) = \frac{K e^{-\tau s}}{T s + 1} \tag{47-5}$$

预估器内部用的名义模型为

$$G_m(s) = \frac{K_m e^{-\tau_m s}}{T_m s + 1} = G_{m0}(s) e^{-\tau_m s}, \qquad G_{m0}(s) = \frac{K_m}{T_m s + 1} \tag{47-6}$$

把模型拆成“无延迟部分”和“延迟部分”，是全部推导的起点。控制器仍记为 $C(s)$，本章用 PI，如式 (47-4)。真实输出 y、控制量 u、设定值 r、预演值 y_{pred}，四者构成闭环。

模型准确时，$K_m = K$、$T_m = T$、$\tau_m = \tau$；失配时分别用三个倍数描述：$K_m = K/\kappa$、$T_m = T/\theta$、$\tau_m = \tau - \delta\tau$。本章的数据表统一用“实际/名义”的口径：$\kappa = K/K_m$，$\theta = T/T_m$，$\delta\tau = \tau - \tau_m$。这样 $\kappa > 1$ 表示实际增益比模型大，$\delta\tau > 0$ 表示实际延迟比模型长，读表时方向一致。

47.2.2 闭环特征方程：延迟在哪一项

没有预估器时，闭环方程很简单：

$$y = \frac{CG}{1 + CG} r \tag{47-7}$$

特征方程 $1 + C(s)G(s) = 0$ 里，延迟 $e^{-\tau s}$ 与控制器、对象惯性乘在一起，直接吃掉相位裕度。这就是 §47.1.3 那笔相位账的代数形式。

有预估器时，闭环多了一条“模型并联”的支路。延迟并没有消失，它仍然在 $G(s)$ 里，只是多了一项可以和它相消的东西。推导的关键是看清这一点：Smith 预估器不是“消除延迟”，而是“用模型的延迟去抵消对象的延迟”，抵消得干不干净，取决于模型准不准。

47.2.3 预估器的信号方程

把图 47-1 的连线写成方程。控制器输出同时送给真实对象和模型：

$$u = C(s)\big[r - y_{pred}\big] \tag{47-8}$$

预演值由真实测量加上模型修正量构成：

$$y_{pred} = y + G_{m0}(s)u - G_{m0}(s)e^{-\tau_m s}u = y + G_{m0}(s)\big(1 - e^{-\tau_m s}\big)u \tag{47-9}$$

式 (47-9) 是本章的核心式子。括号里的 $\big(1 - e^{-\tau_m s}\big)$ 可以读成“模型认为还在路上的那部分”：无延迟模型的输出减去它延迟后的版本，剩下的正是“已经发生、但还没到达测量点”的增量。把它加回测量，就把这部分提前“看见”了。

47.2.4 消去延迟：三步代数

把式 (47-9) 代入式 (47-8)，再把 $y = G(s)u$ 代进去，整理得

$$y = \frac{CG}{1 + CG_{m0}\big(1 - e^{-\tau_m s}\big) + CG}r \tag{47-10}$$

对应的特征方程为

$$1 + CG_{m0}\big(1 - e^{-\tau_m s}\big) + CG = 0 \tag{47-11}$$

这是本章最重要的一行。它说明：预估器确实进入了特征方程，它不是前馈那种“环外支路”；它改变的是延迟项的组合方式，把单独的 CG 拆成了“无延迟部分 + 延迟部分 - 延迟部分”。

47.2.5 模型准确时，延迟被搬到环外

令 $G = G_{m0}e^{-\tau_m s}$，代入式 (47-11)：

$$1 + CG_{m0} - CG_{m0}e^{-\tau_m s} + CG_{m0}e^{-\tau_m s} = 1 + CG_{m0} = 0 \tag{47-12}$$

两个含延迟的项精确相消，特征方程退化成“控制器 + 无延迟一阶惯性”的方程。这就是 Smith 预估器的全部秘密：它没有让延迟消失，而是让延迟在特征方程里出现两次、符号相反，正好抵消。

对应的闭环传递函数为

$$\frac{y}{r} = \frac{CG_{m0}}{1 + CG_{m0}}e^{-\tau_m s} \tag{47-13}$$

式 (47-13) 右端有两个因子：前一半是没有延迟的二阶闭环（PI 加一阶惯性），后一半是纯延迟。这解释了图 47-2 的形状：输出仍然有 8 s 死区，死区之后才按“无延迟闭环”的规律上升。延迟没有被消灭，它只是从“参与稳定性判断”退成了“串在输出端的运输环节”。

这一点常被误解。有人以为 Smith 预估器能让输出“提前响应”，其实物理上不可能：阀门动了，物料没走到，探头就是看不到。预估器能做到的，是让控制器“提前知道”，从而不再重复加码；输出端的死区一秒也少不了。

47.2.6 模型失配时的特征方程

模型不准时，把真实对象写成“模型乘一个相对误差”：

$$G(s) = G_m(s)\big[1 + \Delta(s)\big], \qquad \Delta(s) = \frac{G(s)}{G_m(s)} - 1 \tag{47-14}$$

代入式 (47-11)，利用 $G_m = G_{m0}e^{-\tau_m s}$，整理得

$$1 + CG_{m0}\left[1 + e^{-\tau_m s}\Delta(s)\right] = 0 \tag{47-15}$$

式 (47-15) 把“失配”放到了它该在的位置：误差 $\Delta(s)$ 被模型延迟 $e^{-\tau_m s}$ 加权，幅值不被衰减（延迟的幅值恒为 1），只改相位。这意味着任何失配都会原封不动地进入特征方程，预估器对模型误差没有“天然免疫力”。

47.2.7 三种失配，三种形状

式 (47-15) 里的 $\Delta(s)$ 有三种典型形状，危害差别很大。

增益失配：$G/G_m = \kappa$，于是 $\Delta = \kappa - 1$，是一个常数。它把延迟项变成 $\kappa e^{-\tau_m s}$，相当于在环里放了一个“增益可调的延迟”。$\kappa > 1$ 时，这一项的幅值大于 1，相位仍是延迟，闭环容易在穿越频率附近失稳。

时间常数失配：$G/G_m = (T_m s + 1)/(Ts + 1)$，于是

$$\Delta(s) = \frac{(T_m - T)s}{Ts + 1} \tag{47-16}$$

它在低频趋近于 0、高频趋近于常数 $(T_m - T)/T$，是一个典型的高通形状。也就是说，时间常数估错主要影响高频段，对低频跟踪和稳态影响很小。这解释了后面表 47-6 的现象：T/T_m 从 0.5 变到 2.0，超调只从 15.79% 变到 15.70%，远不如延迟失配剧烈。

延迟失配：$G/G_m = e^{-\delta\tau s}$，于是 $\Delta = e^{-\delta\tau s} - 1$，而

$$1 + e^{-\tau_m s}\Delta = e^{-\delta\tau s} \tag{47-17}$$

代回式 (47-15)，特征方程变成

$$1 + CG_{m0}e^{-\delta\tau s} = 0 \tag{47-18}$$

这个结果非常干净：延迟估错 $\delta\tau$，等价于在“理想无延迟回路”里又串回了 $\delta\tau$ 的纯滞后。模型以为没有延迟，实际还有 2 s；控制器按“没有延迟”整定的高增益去动作，却要面对 2 s 的残余滞后，稳定性自然迅速恶化。

47.2.8 延迟误差的相位解释

式 (47-18) 还能再往下读一层。残余延迟在穿越频率处贡献的相位是

$$\delta\varphi = -\omega_c\,\delta\tau \tag{47-19}$$

本章 $\omega_c \approx 0.25$–0.3 rad/s 量级，$\delta\tau = 2$ s 对应 $\delta\varphi \approx -0.5$ rad，约 -28.6°。这个数字看起来不大，但 Smith 回路在模型准确时的相位裕度本来就只有九十多度，再扣掉近三十度，加上幅值裕度只剩 4.31 dB，系统就进入“能稳但很勉强”的区域。$\delta\tau = 4$ s 时相位扣掉约 -57°，幅值裕度转负，直接失稳。

把延迟误差折算成“等效增益误差”是一个有用的工程习惯。在小误差下，$\delta\tau$ 造成的相位滞后可以用“增益略微放大”来近似补偿，两者在穿越频率附近对回路的影响同阶。本章的数据给出的经验换算是：1 s 延迟误差大致相当于 30% 的增益误差。这个换算不精确，但足以让现场工程师判断“我的延迟估计要准到什么程度”。

47.2.9 稳态与型别：Smith 不改变积分作用

特征方程 (47-15) 在 $s \to 0$ 时的行为，决定了稳态误差。PI 控制器在原点有一个极点，$C(s) \to \infty$；只要闭环稳定，积分作用仍会把稳态误差压到零。预估器的加入不改变这一点：它只是在反馈通道里做加减，没有引入新的原点极点，也没有引入新的零点去抵消积分。

所以 Smith 预估器不改变系统的“型别”。原来是一型系统，加了预估器还是一型；原来对斜坡有稳态误差，加了预估器仍然有。它的收益全部在动态：让同样的 PI 参数在更大的增益下保持稳定，从而加快响应、减小超调。这一点在第 44 章讲 PID 型别时已经铺垫过，这里不再重复推导。

47.2.10 等价开环与裕度计算

要在频域里算裕度，需要把式 (47-11) 写成“$1 + L_{eq} = 0$”的形式。定义等价开环

$$L_{eq}(s) = C(s)\Big[G(s) + G_{m0}(s)\big(1 - e^{-\tau_m s}\big)\Big] \tag{47-20}$$

则式 (47-11) 就是 $1 + L_{eq} = 0$。模型准确且 C 为 PI 时，$L_{eq} = CG_{m0}$，相位从 -90° 单调趋向 -180°，幅值裕度为无穷大；模型失配时，L_{eq} 的相位会出现多次穿越，相位裕度与幅值裕度可能给出不一致的结论，这时要取两者中更保守的那个。

式 (47-20) 也是 §47.12 里 `loop_eq()` 函数的依据。它不需要把延迟离散化，直接用 $e^{-j\omega\tau}$ 在频域里算，适合画 Bode 图、扫裕度。时域仿真则必须把延迟做成环形缓冲或分数拍插值，两条路各有各的用途，正文里的时域数字全部来自 `simulate()`，频域数字全部来自 `loop_eq()` 与 `margins()`。

47.2.11 同一结论的三条推导路线

式 (47-11) 到式 (47-13) 走的是框图代数。这条路最直观，但容易让人以为 Smith 预估器只是一个“凑出来的技巧”。其实同一个结论可以从三个角度得到，三者互为印证。

第一条是框图代数。把预估器看成一条并联支路，写出 y 与 u 的关系，消去中间变量，得到闭环传递函数。优点是每一步都能在图上找到对应，适合第一次学。

第二条是内模视角。把模型 G_m 放进控制器内部，控制器输出先经过模型，再与实测输出比较，差值送回控制器。这种“内部模型 + 误差反馈”的结构，在模型准确时闭环等于“控制器串对象、再乘一个参考滤波”。Smith 结构只是把 G_m 拆成无延迟与延迟两段，数学上完全等价。优点是整定公式自然浮现（式 47-21），而且能看清“为什么延迟不影响稳定性”。

第三条是状态空间。把延迟看成一串移位寄存器（离散情形就是环形缓冲），系统增广成“对象状态 + 缓冲状态”，预估器等价于一个状态观测器，估计“如果现在没有延迟，输出应该是多少”。优点是便于推广到多变量与最优估计，也便于在代码里实现——`simulate()` 里的 `ymf_seq` 与 `n_m` 就是这条路的离散版本。

三条路给同一组结论，但适用场合不同：教学用第一条，整定用第二条，实现与推广用第三条。读者如果只记住一条，建议记住第二条，因为它是后面 IMC 与 MPC 的共同语言。

47.2.12 延迟被搬到了哪里：灵敏度视角

模型准确时，闭环传递函数是

$$T(s) = \frac{y(s)}{r(s)} = \frac{CG_{m0}}{1 + CG_{m0}} e^{-\tau_m s}$$

而灵敏度函数是

$$S(s) = \frac{1}{1 + CG_{m0}}$$

两相对照，延迟只出现在 T 的分子上，不出现在 S 的分母里。这就是“搬到环外”的准确含义：延迟不再参与极点配置，它只是一个作用在输出上的运输环节。

这个视角能解释本章三组看似无关的数据。

第一，为什么模型准确时幅值裕度是无穷。S 的分母 $1+CG_{m0}$ 是二阶的，相位从 -90° 趋向 -180° 但永远不到，所以不存在 -180° 穿越。

第二，为什么失配后裕度掉得那么快。一旦 $\Delta \neq 0$，S 的分母里重新出现 $e^{-\tau_m s}$ 因子，穿越频率附近又多了一份相位，裕度立刻从无穷掉到几 dB。

第三，为什么负载扰动几乎不受益。扰动加在对象输入端，它到输出的通道不经过 T 的分子，只经过 S 与对象本身。Smith 把 S 在中频压小了，所以 IAE 改善 23%；但扰动响应的峰值由低频增益与延迟决定，这两者都没变，所以峰值只降 3.6%。

灵敏度视角还有一个实用推论：调 K_c 本质上是在调 S 的形状。K_c 大，S 在中频小，抗扰好、跟踪快，但穿越频率右移、延迟相位变大。所谓“整定”，就是在“S 足够小”与“相位足够多”之间找平衡。本章的所有表格，都可以看成这句话在不同失配下的定量版本。

47.2.13 Nyquist 图上的形状

把式 (47-20) 的 $L_{eq}(j\omega)$ 画在复平面上，能直观看到失配是怎么把回路推向临界点的。

模型准确时，$L_{eq}=CG_{m0}$ 是一个二阶系统：$\omega=0$ 时幅值无穷、相位 -90°；随频率升高，幅值单调下降，相位趋向 -180° 但不到。整条曲线在第三象限，不包围 -1 点，所以幅值裕度无穷。图 47-2 里那条“超调为零”的响应，对应的就是这条干净的曲线。

延迟失配后，L_{eq} 多了一个 $e^{-\delta\tau s}$ 因子，曲线开始“打卷”：每增加一个 π 的相位，就绕原点转半圈，幅值同时被惯性衰减。于是曲线会多次穿过负实轴，每次穿越都对应一个可能的幅值裕度。表 47-9 里 $\delta\tau=+4$ s 那行出现的“相位裕度不单调”，根源就在这里——多次穿越时，“哪一次穿越离 -1 最近”取决于幅值衰减的速度，而不是相位本身。

二维失配（图 47-6）在 Nyquist 图上表现为“曲线整体向 -1 点靠拢”。$\kappa>1$ 把曲线往外推（幅值变大），$\delta\tau>0$ 让曲线多卷一圈，两者叠加，曲线可能从“离 -1 很远”变成“擦着 -1 过去”。所谓“安全区”，就是曲线与 -1 之间还留着一段距离的区域。

这个视角给了一个比表格更快的现场判断法：如果你能画出 L_{eq} 的 Nyquist 图，就看曲线离 -1 最近的那一点有多远。距离大于 0.5（对应约 6 dB 幅值裕度），基本安全；小于 0.2，就要准备降增益了。

47.2.14 为什么不用超前环节直接抵消延迟

看到 $e^{-\tau s}$，一个自然的想法是：在控制器里串一个 $e^{+\tau s}$ 把它抵消掉。这条路走不通，原因有三层，值得单独说清，因为现场不止一次有人这样试过。

第一层是因果性。$e^{+\tau s}$ 要对“未来 τ 秒的输入”作响应，物理上不可实现。工程上只能用 Padé 近似，一阶形式是

$$e^{-\tau s}\approx\frac{1-\tau s/2}{1+\tau s/2},\qquad e^{+\tau s}\approx\frac{1+\tau s/2}{1-\tau s/2}$$

后者的分母在 $s=2/\tau$ 处有一个右半平面极点。本章 $\tau=8$ s，这个极点在 0.25 rad/s——恰好落在需要补偿相位的频段上。用不稳定的极点去抵消对象的延迟，属于“内部不稳定”：输入输出看似正常，中间变量却在指数发

散，一点扰动就暴露。

第二层是测量通道。Smith 预估器不是串联补偿，而是“并联模型 + 相减”，测量值 y 以系数 1 直接进入反馈，静态增益和低频特性都没有被改动。串联超前则不同，它改变的是整个环路的频响：在补偿相位的频段抬高幅值，也把该频段的噪声一起抬高。两类结构对噪声的态度完全不同，这就是 §47.6.9 里 Smith 的抖动来自修正量、而不是来自“增益太高”的原因。

第三层是失配的传播方式。串一个近似逆，误差是“逆模型的误差”，它直接乘在环路里；Smith 的误差则进入式 (47-15) 的 Δ 项，而 Δ 在低频趋零，所以稳态不受影响。换句话说，预估器把模型误差限制在“动态形状”上，串联逆把模型误差扩散到“全天候”。

提高 Padé 阶数也解决不了问题。阶数越高，近似在低频越准，但右半平面极点也跟着变多，而且当延迟本身随流量变化时，$e^{+\tau s}$ 根本不存在一个固定的逆——补偿器要跟着 τ 实时改结构。预估器没有这个负担：延迟变了，只改缓冲区的长度。

所以正确的问法不是“怎么把延迟抵消掉”，而是“怎么让延迟不参与极点配置”。Smith 的回答是把它移到环外，预测控制的回答是把它写进预测模型，两者都不试图在频域里“反向旋转”相位。

47.3 设计步骤

47.3.1 第零步：先确认是不是延迟问题

上预估器之前，先排除三种“看起来像延迟”的情况。

第一种是测量滞后。温度探头插在保护套管里，响应慢，但它是一阶惯性，不是纯滞后，用 Smith 预估器收益有限，应该先改探头安装或做动态补偿。

第二种是执行机构死区。阀门有回差，指令变了阀门不动，输出自然要等。这是非线性问题，预估器帮不上忙，应该先修阀门或加阀门定位器。

第三种是采样与滤波。分析仪 30 s 出一个数，前面还串了 10 s 滑动平均，看起来像 40 s 纯滞后。这种情况先把采样和滤波的账算清楚，能压缩的压缩，剩下的才是真延迟。

排除之后，用一段手动阶跃试验确认：控制量阶跃后，输出要等一段时间才开始动，而且开始动之后是一条平滑的一阶曲线。这个“等一段时间 + 平滑上升”的形状，才是式 (47-1) 的适用对象。

47.3.2 第一步：阶跃辨识三个参数

从阶跃响应上读三个数。增益 K 用稳态变化量比控制量变化量；时间常数 T 用“响应开始后走到 63.2% 的时间”；纯滞后 τ 用“指令时刻到响应开始时刻”的间隔。

三个数里，τ 最难读准，因为“响应开始”没有明确判据。工程上常用 5% 阈值或切线法，两种方法都有系统偏差。§47.10 会给出实测数据：5% 阈值平均偏高 0.243 s，50% 阈值平均偏高 3.495 s。这里的“偏高”不能当成保守：按 §47.7.4，模型高估延迟（$\delta\tau < 0$）反而比低估更危险，因为残余项变成超前环节。所以阈值法的系统偏差必须按式 (47-30) 扣掉，不能指望“估大一点更保险”。

辨识时还要注意工况。延迟往往随流量变化，阶跃试验要在常用工况附近做，不要在最满负荷或最小负荷下做，然后把结果当常数用。

47.3.3 第二步：算延迟比，判断值不值得

拿到 K、T、τ 后，先算 τ/T。这个比值决定了预估器能带来多少收益。

$\tau/T < 0.2$：延迟相对时间常数很小，常规 PID 稍加滤波就能应付，上预估器收益有限，反而增加维护负担。

$0.2 \le \tau/T \le 1.0$：预估器有明显收益，但纯反馈也还能用。这时要比较“预估器带来的速度提升”与“模型维护成本”，一般流程行业倾向使用。

$\tau/T > 1.0$：纯反馈的可用增益已经被压得很低，预估器收益最大。本章对象 $\tau/T = 1.6$，正属于这一档：纯反馈要把 K_c 压到 0.6 才稳，Smith 用 2.5 还能保持 93.42° 的相位裕度。

还有一条辅助判据：如果延迟主要是分析仪造成的、数值固定但很大（比如 120 s），预估器的收益更大，因为固定延迟比漂移延迟好估。反过来，如果延迟随流量大幅度漂移（比如 3 s 到 15 s），固定参数的预估器只能覆盖中间一段，需要用 §47.9 的在线估计或增益调度。

47.3.4 第三步：按无延迟模型整定 PI

预估器的好处是把问题拆成了两半：稳定性由无延迟模型决定，跟踪速度由 PI 决定。所以第三步不要对着带延迟的对象整定，而要对着 $G_{m0}(s) = K_m/(T_m s + 1)$ 整定。

对一阶对象用 IMC 口径的 PI，参数有闭式解：

$$K_c = \frac{T_m}{K_m \lambda}, \qquad T_i = T_m \tag{47-21}$$

其中 λ 是期望闭环时间常数，取得越小越快，但控制量越大。本章取 $K_m = 1.0$、$T_m = 5$ s、$\lambda = 2$ s，得 $K_c = 2.5$；T_i 取 6 s，比 T_m 略大，留一点积分余量，避免控制量在阶跃初期过冲。

式 (47-21) 只在模型准确时成立。模型有失配时，λ 要放大，相当于把 K_c 降下来。§47.8 会给出按失配程度降增益的经验系数。

47.3.5 第四步：搭并联模型

结构上要搭三块：无延迟模型 G_{m0}、延迟环节 $e^{-\tau_m s}$、减法节点，如图 47-1 的虚线框。三块的输入都是控制器输出 u，输出是修正量 $y_{m0} - y_{m\tau}$。

实现时有三个细节。第一，模型必须和对象吃同一个 u，包括限幅后的 u，不能拿限幅前的指令去喂模型，否则模型算的是“没限幅的世界”，预演会偏。第二，延迟用环形缓冲实现，缓冲区长度按 τ_m/T_s 取整，缓冲区里存的是 y_{m0} 的历史值。第三，减法节点后面可以加一个一阶滤波，用于抑制噪声，这就是 §47.9 的改进型，先留接口。

模型参数放在独立的参数块里，不要在程序里写死。现场调模型时只改参数块，不动逻辑，这是可维护性的基本要求。

47.3.6 第五步：算失配裕度

模型搭好后，不要急着投运，先算三种失配下的裕度。做法是：固定名义模型，分别让 K、T、τ 偏离 20%、50%，用式 (47-20) 算相位裕度与幅值裕度，看最坏情况是否还能接受。

判据可以借用常规回路的标准：相位裕度不低于 30°，幅值裕度不低于 6 dB。本章的数据显示，$\kappa = 1.5$ 时相位裕度 68.41°、幅值裕度仍为无穷（因为相位不穿越 -180°），增益失配不算最危险；$\delta\tau = +2$ s 时相位裕度

31.17°、幅值裕度 4.31 dB，已经踩线；$\delta\tau = +4$ s 时幅值裕度 -1.46 dB，失稳。所以延迟估计的精度是裕度预算里最紧的一项。

这一步还要回答一个问题：模型参数在多大范围内变化时，回路仍然满足判据？这个范围就是现场允许的工况窗口，写进操作规程，超出窗口要报警或切回纯反馈。

47.3.7 第六步：现场阶跃验证

离线算完，还要在现场做一次小阶跃。阶跃幅度取正常调节量的 5%–10%，观察三件事。

第一，输出死区是否与模型一致。如果不一致，先修 τ_m，不要动 K_c。第二，死区之后的第一段上升斜率是否与 K_m/T_m 一致。如果偏快，说明实际增益或时间常数比模型大，按比例修模型。第三，回到稳态后有没有残余振荡。如果有，说明相位裕度不够，先把 K_c 降 30% 再试。

现场验证的原则是“一次只改一个参数”。先修模型，再调控制器；模型修好之前，调控制器是在错误的被控对象上做优化，越调越乱。

47.3.8 第七步：限幅、抗饱和、无扰投切

预估器投运前必须把三件事做完，否则一次限幅就可能让回路失控。

限幅：控制量限幅要同时作用于对象和模型，模型吃的是限幅后的 u。如果模型吃限幅前的值，限幅期间模型会算出“输出已经到位”，而实际对象卡在阀位上限，预演与真实严重背离，退饱和时会产生大超调。

抗饱和：PI 的积分器要在限幅时停止累积，或者用反算抗饱和。预估器把反馈信号换成了 y_{pred}，抗饱和逻辑仍按真实 u 与限幅值的差来反算，不要按 y_{pred} 反算。

无扰投切：预估器投入与退出时，y_{pred} 与 y 之间会有一个跳变，必须做无扰切换。做法是让修正量从 0 开始，按时间常数 2–5 s 斜坡升到全值；退出时反向。切换期间 PI 的积分器要保持连续，不能清零。

47.3.9 第八步：文档与移交

预估器比普通 PID 多了一套模型，移交时必须把这套模型讲清楚，否则下一班人不知道怎么维护。

移交包至少包含六项：对象模型参数及其辨识工况；预估器结构图与功能块位置；三种失配下的裕度计算结果；延迟估计方法与最近一次实测值；限幅、抗饱和、无扰切换的参数；什么情况下应该切回纯反馈。

表 47-2 把八步整理成检查表，图 47-10 给出流程。表里“通过判据”一列是可以直接拿去核对的硬指标，“常见失败”一列来自现场经验，照着排查能省很多时间。

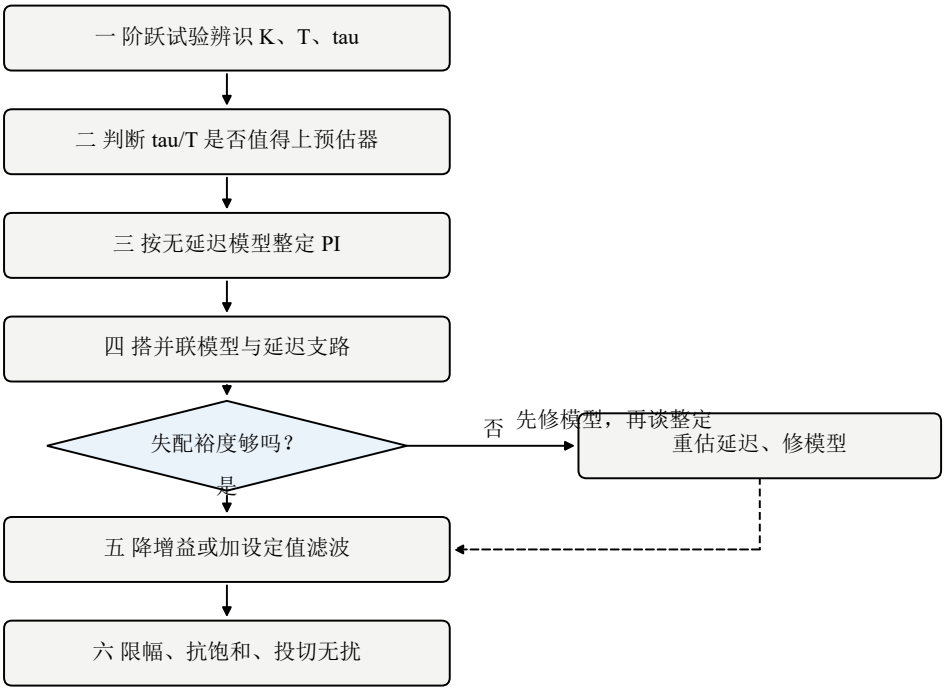

图 47-10　Smith 预估器的设计流程：可行性判断在前，辨识与整定在中，失配裕度校核是投运前的最后一道闸

表 47-2　Smith 预估器设计步骤与检查项

步骤	做什么	通过判据	常见失败
零	排除假延迟	阶跃呈“死区+一阶”形状	把滤波当延迟
一	辨识 K, T, τ	三次试验离散度小于 10%	只在极端工况做
二	算 τ/T	大于 0.2 才考虑	忽略延迟漂移
三	整定 PI	按 G_{m0} 得到 K_c, T_i	对着带延迟对象整定
四	搭并联模型	模型与对象吃同一个 u	模型吃限幅前的值
五	算失配裕度	PM 大于 30°，GM 大于 6 dB	只看名义模型
六	现场阶跃	死区、斜率、残余振荡三项都对	同时改模型和增益
七	限幅与投切	限幅期间预演不背离	积分器不清零
八	文档移交	六项齐全	只写“已投运”

47.3.10 把八步走一遍：本章对象的投运算例

把本章对象当成一台待投运的换热器，把八步走一遍，看每一步得到什么、下一步怎么用。

第零步，确认是不是延迟问题。手动把蒸汽阀开 10%，出口温度先平了约 8 s，然后平滑上升，没有超调、没有台阶。形状符合“死区 + 一阶”，不是死区、不是分布延迟。

第一步，辨识。稳态温度升高 5.0，阀位升高 5%，归一化后 $K = 1.0$；从起势算起走到 63.2% 用了 5 s，所以 $T = 5$ s；起势时刻距阀门动作 8 s，用 5% 阈值读得 8.243 s，扣掉 0.0513×5=0.26 s，得 $\tau = 8.0$ s。三个数与仿真设定一致。

第二步，算比值。$\tau/T = 1.6 > 1.0$，属于“预估器收益最大”的那一档，值得上。

第三步，整定。取 $\lambda = 2$ s，$K_c = 5/(1 \times 2) = 2.5$，$T_i$ 取 6 s。这一步得出的参数是“名义参数”，先记下来，不要急着投。

第四步，搭模型。三个功能块：$1/(5s+1)$、8 s 延迟、减法。延迟用 160 拍缓冲（$T_s = 0.05$ s），模型输入取限幅后的 u。

第五步，算失配裕度。名义 93.42°，很好。再按现场可能的漂移算最坏情形：延迟多 2 s（$\delta\tau = +2$ s），相位裕度 31.17°、幅值裕度 4.31 dB，时域超调 31.22%；如果增益再偏 30%，相位裕度只剩 17.72°。结论是“名义能投，但必须限定工况范围”。

第六步，现场阶跃。用 2.5 的增益做一次 5% 阶跃，看死区是否仍是 8 s、上升是否仍是 5 s 量级、有无残余振荡。三项都对，说明模型可信。

第七步，处理限幅与投切。把 K_c 从 1.0 开始，按 2–5 s 斜坡升到 2.5；修正量同样斜坡投入。这一步是为了避免投运瞬间的控制量冲击。

第八步，移交。把 $K = 1.0$、$T = 5$ s、$\tau = 8$ s、$K_c = 2.5$、$T_i = 6$ s、延迟估计方法、最坏失配裕度、降级逻辑写进文档。

这个算例里最值得注意的，是第五步的结论与第三步的乐观之间的落差。第三步给出的 93.42° 是“模型完全准确”时的数字，第五步的 17.72° 才是“现场可能发生”的数字。投运决策应该建立在后者上：或者限定工况（延迟漂移不超过 2 s、增益漂移不超过 30%），或者按表 47-16 把 K_c 降到 0.8，或者加 t_{ref} 把超调压下去。三条路都行，但不能假装第五步不存在。

47.4 连续情形

47.4.1 连续域里的三条通道

把图 47-1 拆开看，连续域里有三条通道同时在动。

第一条是对象通道 $u \to G(s) \to y$，它带着 8 s 延迟。第二条是模型通道 $u \to G_{m0}(s) \to y_{m0}$，没有延迟。第三条是模型的延迟支路 $u \to G_{m0}(s)e^{-\tau_m s} \to y_{m\tau}$，带 8 s 延迟。

三条通道的差，构成预演值 $y_{pred} = y + y_{m0} - y_{m\tau}$。模型准确时，第一条与第三条完全一样，$y - y_{m\tau} = 0$，于是 $y_{pred} = y_{m0}$：控制器看到的正是“无延迟模型”的输出。这是连续域里最干净的解读，也是式 (47-12) 的物理含义。

47.4.2 理想闭环：延迟只剩在分子上

模型准确时，闭环传递函数是式 (47-13)。把它拆成两部分看：

$$\frac{y}{r} = \underbrace{\frac{CG_{m0}}{1 + CG_{m0}}}_{\text{无延迟闭环}} \cdot \underbrace{e^{-\tau_m s}}_{\text{运输环节}} \tag{47-22}$$

前一项决定上升、超调、调节时间，后一项只决定“什么时候开始”。两者相乘，意味着延迟不会改变响应的形状，只把它整体向右平移 τ_m。这是 Smith 预估器最理想的工况，也是本章所有对比的基准。

把 $C = K_c(1 + 1/(T_i s))$、$G_{m0} = K_m/(T_m s + 1)$ 代进去，前一项是二阶系统：

$$\left.\frac{y}{r}\right|_{\text{无延迟}} = \frac{K_c K_m (T_i s + 1)}{T_i T_m s^2 + T_i (1 + K_c K_m) s + K_c K_m} \tag{47-23}$$

它的阻尼比与自然频率由 K_c、T_i、T_m 决定，与 τ 无关。这就是“延迟被搬到环外”的代数证据：特征方程里没有 τ，响应形状自然也与 τ 无关。

47.4.3 死区八秒，上升五点一秒

图 47-2 里 Smith 那条曲线，前 8 s 是平的，这是物理延迟，任何控制器都消不掉。8 s 之后，输出按式 (47-23) 的二阶规律上升，从 10% 到 90% 用了 5.10 s，20.05 s 进入 ±2% 带，超调几乎为零。

这三个数要分清口径。死区 8 s 是“指令到响应开始”；上升 5.10 s 是“10% 到 90%”，不含死区；调节 20.05 s 是“从阶跃时刻算起，最后一次离开 ±2% 带的时刻”，含死区。现场汇报时如果把这三个数混着说，很容易让人以为 Smith 把 8 s 延迟消掉了，其实一秒也没消。

与纯反馈对比：保守整定的 PI 上升 8.84 s、调节 48.50 s、超调 7.84%。Smith 的上升快了 42%，调节快了 59%，代价是控制量峰值从 1.202 升到 2.500。这个代价是否可接受，取决于执行机构有没有余量，§47.4.6 会专门算这笔账。

47.4.4 纯反馈能到多快

纯反馈不是不能用，而是有一个很低的天花板。表 47-3 是固定 $T_i = 6$ s、只改 K_c 的扫描结果，图 47-3 把超调与 IAE 画在一起。

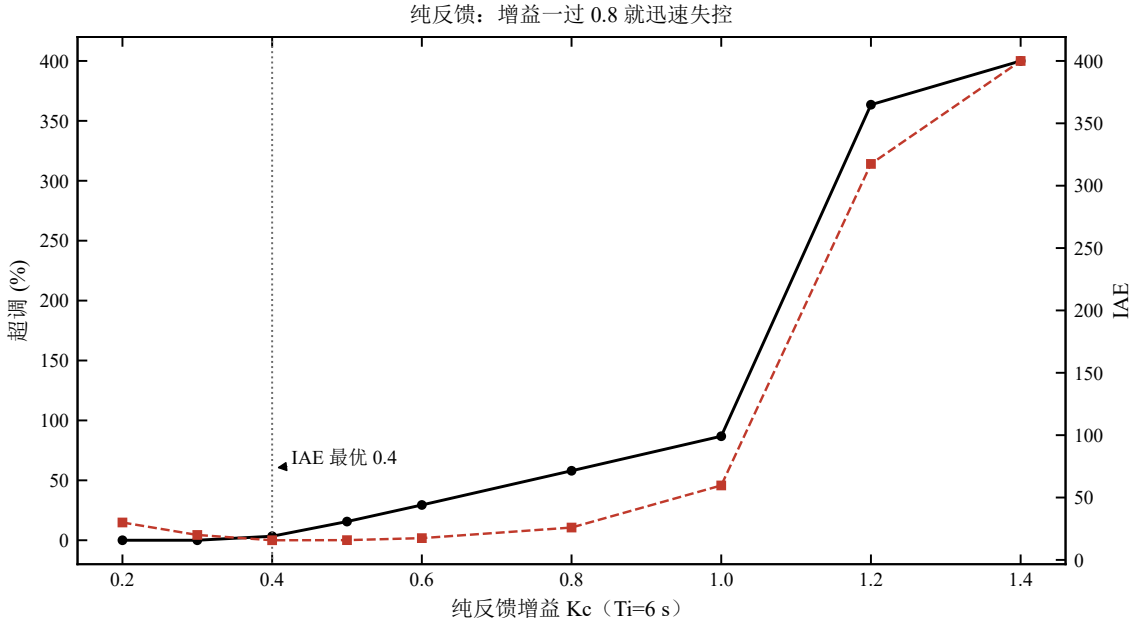

图 47-3　纯反馈增益扫描：K_c 到 0.5 后超调迅速上扬，IAE 在 0.4 附近有极小点，速度与稳定性不可兼得

表 47-3　纯反馈增益扫描（$T_i = 6$ s）

K_c	超调 (%)	峰值输出	IAE	调节时间 (s)
0.3	0.0	1.000	20.00	51.9
0.4	3.3	1.033	15.75	38.5
0.5	15.6	1.156	15.84	53.1
0.6	29.4	1.294	17.45	67.0
0.8	58.0	1.580	25.90	125.0
1.0	86.8	1.868	56.79	未稳
1.2	300.6	4.006	217.81	未稳

表 47-3 的形状很典型：K_c 从 0.3 加到 0.4，IAE 从 20.00 降到 15.75，这是“增益不足”段；从 0.4 再往上，超调迅速变大，IAE 反而回升，这是“相位不够”段。最优在 $K_c = 0.4$ 附近，此时调节时间 38.5 s，仍比 Smith 的 20.05 s 慢近一倍。

注意 $K_c = 0.3$ 的超调是 0.0%，但 IAE 20.00 最大。这是“稳但太慢”的典型：输出慢慢爬，永远不超调，可是离设定值远的时间最长。只看超调会误判它最好，必须同时看 IAE 与调节时间。

47.4.5 极限增益的估算

纯比例控制时，极限增益可以用相位条件估出来。令环路相位等于 -180°：

$$\omega_u \tau + \arctan(\omega_u T) = \pi, \qquad K_u = \frac{\sqrt{1 + (\omega_u T)^2}}{K} \tag{47-24}$$

本章 $\tau = 8$ s、$T = 5$ s，解得 $\omega_u \approx 0.275$ rad/s，$K_u \approx 1.70$。这是纯比例的天花板；加上积分后，$T_i = 6$ s 在 ω_u 处再贡献约 -53° 相位，极限增益降到 1.0 附近。表 47-4 里 $K_c = 1.0$ 已经 86.8% 超调、无法在 220 s 内稳定，$K_c = 1.2$ 直接冲到 4 倍，与估算一致。

Smith 回路在模型准确时没有这个天花板：$L_{eq} = CG_{m0}$ 的相位从 -90° 趋向 -180° 但永不穿越，幅值裕度为无穷大。相位裕度 93.42° 是在 $K_c = 2.5$ 下算的，继续加大 K_c 仍能稳定，只是控制量和噪声放大要另算。这就是“延迟被搬到环外”带来的自由度：稳定性不再由 τ 卡脖子。

47.4.6 控制量代价

表 47-4 把三种方案的控制量峰值、上升时间、调节时间放在一起。

表 47-4　三种方案的跟踪指标（模型准确）

方案	超调 (%)	上升 (s)	调节 (s)	IAE	$\lvert u \rvert_{\max}$
纯反馈 $K_c = 2.5$	发散	—	—	—	—
Smith $K_c = 2.5$	0.0	5.10	20.05	10.40	2.500
纯反馈 $K_c = 0.6$	7.84	8.84	48.50	14.53	1.202

Smith 的控制量峰值 2.500，正好等于 K_c。这是 PI 在阶跃瞬间的行为：误差为 1，比例项输出 $K_c \times 1 = 2.5$，积分项还没起来。纯反馈 $K_c = 0.6$ 的峰值 1.202，约为 $2K_c$，因为输出迟迟不响应，误差一直保持 1，积分项在等

待期间累积到与比例项同量级。这解释了一个反直觉现象：纯反馈虽然增益低，控制量却可能是 Smith 的两倍，因为它在死区里“空转”了很久。

控制量峰值决定了三件事：阀门是否饱和、执行机构是否磨损、下游设备是否受冲击。$|u|_{\max}=2.5$ 意味着阀门要能开到额定流量的 2.5 倍，很多现场没有这个余量。这时要么把 K_c 降到 1.5 左右，要么加设定值滤波，让误差慢慢建立，§47.9 会给出实测对比。

47.4.7 连续情形的适用条件

上面所有结论都建立在三个假设上：对象是一阶加纯滞后、延迟是常数、模型准确。三个假设在连续域里可以写得很干净，到了离散域就会多出两个新问题：延迟取整和采样周期。这两个问题在 §47.5 处理。

连续域的分析价值在于给出上限。它告诉我们：模型准确时，Smith 能把稳定性与延迟解耦，PI 可以按无延迟对象整定；模型失配时，式 (47-15) 会把误差原封不动地送进特征方程，没有任何缓冲。后面所有的离散实现、参数整定、鲁棒化，都是在“接近这个上限”和“防止失配越界”之间做平衡。

47.4.8 二阶与高阶对象怎么套

本章从头到尾用的是一阶加纯滞后。现场对象很少这么干净，多数是“二阶惯性加延迟”或更高阶。遇到这类对象，有两条路。

第一条是降阶近似。二阶对象 $G=K/[(T_1s+1)(T_2s+1)]$、$T_1\ge T_2$，用一个一阶加延迟去近似：时间常数取 $T_1+T_2/2$，延迟增加 $T_2/2$，原有的纯滞后直接加上去。这条“半规则”的直觉是：把第二个极点的一半算作延迟，另一半算作惯性。它在本章的对象上误差最小，因为 τ/T 大时，延迟项主导相位，惯性的小误差影响不大。

第二条是两点法。从阶跃响应上读两个时刻：t_{28} 是到 28.3% 的时刻，t_{63} 是到 63.2% 的时刻，则时间常数约为 $1.5(t_{63}-t_{28})$，延迟为 t_{63} 减去这个时间常数。这条公式对二阶、三阶对象都适用，前提是响应单调、无超调。

两条路的共同前提是“响应单调”。如果对象是欠阻尼二阶（阶跃有超调），一阶加延迟根本表达不了那个超调，硬套 Smith 会把超调误判成延迟误差，越调越乱。这种情况要用二阶加延迟模型，预估器内部也要相应改成二阶，结构不再是本章的三块，而是“二阶无延迟模型 + 延迟 + 减法”。

47.4.9 为什么上升只快 42%，调节却快 59%

§47.4.3 给过一组数：上升时间从 8.84 s 降到 5.10 s，改善 42.3%；调节时间从 48.50 s 降到 20.05 s，改善 58.7%。同样是“变快”，两个指标的改善幅度差了 16 个百分点，这不是巧合。

上升时间主要由闭环带宽决定。纯反馈的 $K_c=0.6$ 把带宽压得很低，但它毕竟还能推得动，所以从 10% 到 90% 的那一段并不算太慢。Smith 的 $K_c=2.5$ 把带宽抬高，这一段自然更快，但受限于对象本身的 $T=5$ s，提升有上限。

调节时间还取决于“进带之后能不能待住”。纯反馈有 7.84% 的超调，进带之后还会出带、再进带，来回几次才稳定；Smith 超调为零，单调进带，一次就到位。调节时间的差距，一大半来自这个“反复”。

这个区别在评价方案时很重要。只看上升时间，会低估 Smith 的收益；只看调节时间，又会高估——尤其当某个方案超调很大时，调节时间会被超调拖长，数字很难看（§47.8.6 里 t_{ref} 把调节时间从 155.30 s 缩到 76.25 s，就是这个机制的反向利用）。稳妥的做法是三个指标一起看：上升、调节、IAE，再加一个控制量峰值。

47.4.10 极限增益是怎么算出来的

§47.4.5 给过 $\omega_u \approx 0.275$ rad/s、$K_u \approx 1.70$，这两个数不是试出来的，而是解出来的。

先看纯比例。临界振荡的条件是相位到 -180°、幅值为 1：

$$\arctan(\omega_u T) + \omega_u \tau = \pi$$

把 $T = 5$、$\tau = 8$ 代进去，$\omega_u = 0.275$ 时左边是 $\arctan(1.375) + 2.2 = 0.942 + 2.200 = 3.142$，正好是 π。这个方程没有闭式解，只能用数值方法，但它的结构很清楚：延迟项 $\omega\tau$ 是线性的，惯性项 $\arctan(\omega T)$ 是饱和的，两者的和要达到 π。延迟越大，能容纳的 ω_u 越小——这就是“延迟压低带宽”的定量版本。

有了 ω_u，临界增益由幅值条件给出：

$$K_u = \frac{\sqrt{1 + (\omega_u T)^2}}{K} = \frac{\sqrt{1 + 1.375^2}}{1} = 1.70$$

也就是说，纯比例增益超过 1.70，回路就会等幅振荡。表 47-3 里 $K_c = 1.2$ 还没到 1.70，但已经 300.6% 超调，因为积分项又多吃了几十度相位，把有效极限拉低到 1.0 附近。

这两个数还有一个用途：估算 Smith 的“等效增益上限”。Smith 在模型准确时把延迟搬到环外，临界频率由 T 单独决定，不再受 τ 约束，所以可用增益可以提高一个数量级。本章取 2.5，远低于理论上限，留出了失配余量——这也是 §47.8.4 那张降增益表的由来。

47.5 离散情形

47.5.1 离散化要动三处

数字实现里，式 (47-1) 的三块都要离散化：对象的一阶惯性、模型的一阶惯性、以及两处纯延迟。前两处用零阶保持器（ZOH）离散，延迟用整数拍缓冲。三处的处理方式不同，误差来源也不同。

一阶惯性用 ZOH 离散后是

$$G(z) = \frac{(1 - a)K}{1 - a z^{-1}}, \qquad a = e^{-T_s/T} \tag{47-25}$$

它的零极点位置与连续域一一对应，没有近似误差，只有采样带来的高频折叠。本章 $T_s = 0.05$ s，$T = 5$ s，$T_s/T = 0.01$，$a = 0.99005$，离散化本身几乎不损失精度。

纯延迟没有“离散化”，只有“取整”：

$$n_m = \operatorname{round}\left(\frac{\tau_m}{T_s}\right), \qquad \tau_{m,\text{eff}} = n_m T_s \tag{47-26}$$

$\tau_{m,\text{eff}}$ 才是数字预估器真正使用的延迟。它与设计值 τ_m 的差，就是量化误差。

47.5.2 量化误差的上界

取整误差满足

$$\left|\delta\tau_q\right| = \left|\tau_{m,\text{eff}} - \tau_m\right| \le \frac{T_s}{2} \tag{47-27}$$

这个上界看起来很小，但它是“额外的延迟失配”，会和 §47.6 的模型失配叠加。本章 $T_s = 0.05$ s 时上界只有 0.025 s，可以忽略；$T_s = 1.5$ s 时上界 0.75 s，实际算出来是 -0.5 s。单看这一项，按表 47-8 还是 0 超调，可实测已经出现 10.62% 超调、调节拖到 28.50 s——说明采样滞后本身也在吃相位，不能只记在量化误差账上。

更麻烦的是 $T_s = 3$ s 这一档。$\tau/T_s = 2.67$，取整成 3 拍，$\tau_{m,\text{eff}} = 9$ s，量化误差 $+1.0$ s。按表 47-8，$+1.0$ s 的失配对应 14.70% 超调、29.25 s 调节；而实际采样周期扫描给出 9.82% 超调、78.00 s 调节。超调对得上，调节时间却差了近三倍，原因是 $T_s = 3$ s 本身已经太粗，PI 的积分与微分都被采样拖慢，两个误差源叠在一起。这说明采样周期不能只按“延迟量化”一项来选。

47.5.3 采样周期怎么选

工程上有三条经验，按优先级排。

第一条，T_s 要小于延迟的十分之一：$T_s \le \tau/10$。本章 $\tau = 8$ s，对应 $T_s \le 0.8$ s。这条保证延迟量化误差不超过 0.4 s，落在“可接受”区间。

第二条，T_s 要小于时间常数的十分之一：$T_s \le T/10 = 0.5$ s。这条保证 PI 的离散化不引入明显的相位滞后。

第三条，一个延迟至少要有 10 拍，即 $\tau/T_s \ge 10$。它与第一条等价，但更好记，现场调试时直接数缓冲区的长度就知道够不够。

三条取交集，本章 $T_s \le 0.5$ s。实际取 0.05 s，比要求严十倍，原因是仿真要看清上升沿的细节；现场 DCS 取 0.5 s 就够了，再小只是浪费计算资源。

47.5.4 实测：采样周期从 0.05 s 放到 3 s

表 47-5 是固定对象与控制器、只改采样周期的结果，图 47-8 把超调与 IAE 画在对数横轴上。

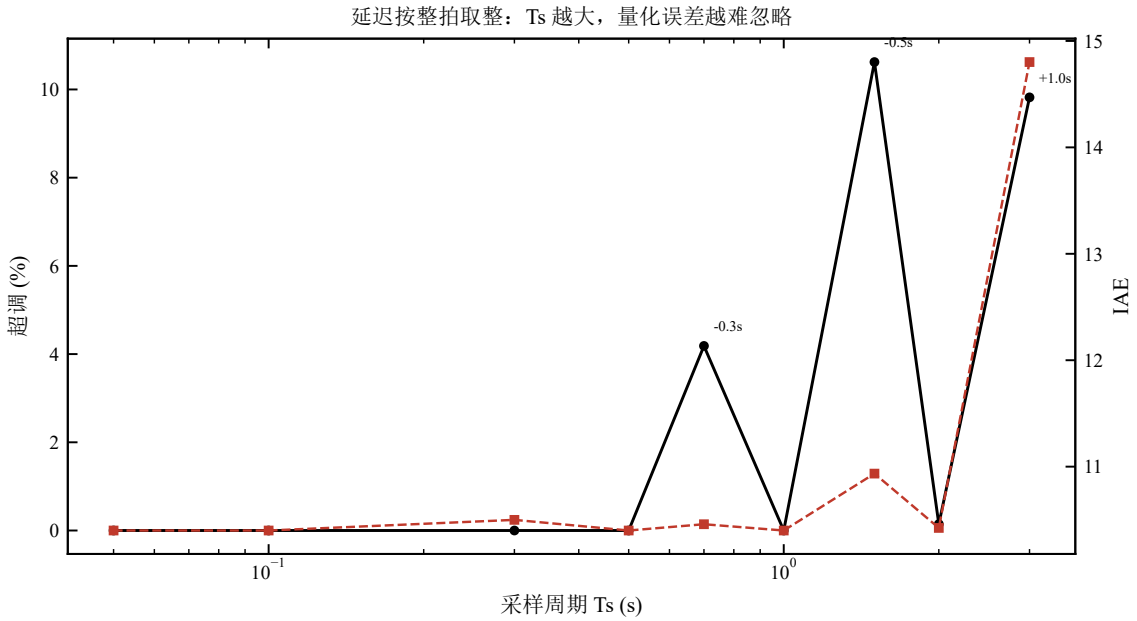

图 47-8　采样周期与延迟量化：量化误差在 ±0.5 s 内时超调仍小，$T_s = 3$ s 后调节时间成倍拉长

表 47-5　采样周期与延迟量化（模型延迟按整拍取整）

T_s (s)	量化误差 (s)	超调 (%)	调节 (s)	IAE
0.05	0.000	0.00	20.05	10.400
0.30	+0.100	0.00	21.90	10.500
0.70	−0.300	4.18	21.70	10.459
1.50	−0.500	10.62	28.50	10.935
3.00	+1.000	9.82	78.00	14.802

表 47-5 有两个值得注意的地方。第一，量化误差为负（模型延迟比实际短）时超调更大：-0.3 s 就有 4.18%，$+0.1$ s 却仍是 0。这与 §47.2.8 的相位分析一致：模型低估延迟，等于在环里多串了一段残余延迟，相位更紧。第二，$T_s = 3$ s 的 IAE 跳到 14.802，比 $T_s = 0.05$ s 高 42%，这不是量化一项造成的，而是采样太粗导致 PI 的积分动作“一步跨太大”。

所以选采样周期时，“延迟拍数够”只是必要条件，还要看控制器的积分时间。经验上 $T_s \le T_i/10$，本章 $T_i = 6$ s，对应 $T_s \le 0.6$ s，与前面的结论一致。

47.5.5 环形缓冲与计算量

离散预估器需要两个缓冲区：一个存无延迟模型的输出 y_{m0}，长度 $n_m + 1$ 拍；一个存控制量 u，长度 $n_a + 1$ 拍，供真实对象的延迟使用。两个都是环形缓冲，写入指针每拍加一，读出指针落后 n 拍。

本章 $n_m = 160$ 拍，每个数按双精度 8 字节算，一个缓冲区约 1.3 KB；两个加起来不到 3 KB。这个存储量对任何 PLC 都是零头。计算量也很小：每拍一次一阶模型递推、一次减法、一次 PI，几十条浮点指令。Smith 预估器的计算代价从来不是问题，问题永远在模型精度与参数维护。

如果延迟特别大，比如分析仪 600 s、$T_s = 1$ s，缓冲区 600 拍，仍只有 4.8 KB。真正需要担心的是“延迟随工况变化”时缓冲区的长度要不要跟着变，这属于 §47.10 的在线估计问题。

47.5.6 计算延迟一拍的影响

数字实现里还有一个容易忽略的延迟：控制器算完 u，要到下一拍才真正输出，这一拍（T_s）是纯滞后，会叠加到模型与对象上。如果模型里没有这一拍，预估器就少算了 T_s 的延迟，相当于 $\delta\tau = -T_s$。

本章 $T_s = 0.05$ s，一拍的影响可以忽略；现场 $T_s = 0.5$ s 时，一拍就是 0.5 s，按表 47-8 相当于 $\delta\tau = -0.5$ s，超调仍是 0，但调节会从 20.05 s 拖到 23.45 s。处理办法很简单：在模型延迟里补一拍，即 $n_m = \mathrm{round}(\tau_m/T_s) + 1$，让模型和实际执行时序对齐。

47.5.7 离散预估器的伪代码

把上面的约定写成伪代码，逻辑就清楚了。注意模型用的是限幅后的 u，延迟用环形缓冲，预演值在每拍开头算。

```
初始化：n_m = round(tau_m / Ts) + 1
        buf = zeros(n_m + 1)          # 存无延迟模型输出
        x_m = 0                       # 模型状态
        xi  = 0                       # PI 积分状态
每拍 k：
    y = 读取真实测量
    y_m0 = C_m * x_m                  # 无延迟模型输出
    buf[k % (n_m+1)] = y_m0
    y_mtau = buf[(k - n_m) % (n_m+1)] # 模型延迟输出
    y_pred = y + (y_m0 - y_mtau)
    e = r - y_pred
    u = Kc * e + Ki * xi
    xi = xi + Ts * e                  # 限幅时按抗饱和处理
    u = clip(u, u_min, u_max)
    x_m = A_m * x_m + B_m * u
    输出 u
```

伪代码里有两处容易写错。第一处是缓冲区下标，必须用模运算，不能直接写 `buf[k-n_m]`，否则数组越界。第二处是 y_{m0} 的写入时机：要先写入当前值，再读 n_m 拍之前的值，顺序反了会少一拍。

47.5.8 离散与连续的差别有多大

把表 47-5 的 $T_s = 0.05$ s 一行与 §47.4 的连续结果对比：超调 0.00%、调节 20.05 s、IAE 10.400，与连续域完全一致。这说明 0.05 s 的采样已经足够细，离散化没有带来可见误差。

$T_s = 0.3$ s 时，调节从 20.05 s 变成 21.90 s，慢了 9.2%；$T_s = 0.7$ s 时出现 4.18% 超调。这条曲线给出了一个实用结论：只要 $T_s \le \tau/10$，离散 Smith 的表现与连续设计基本一致；超过这个界限，量化误差与采样滞后开始显形，需要按表 47-8 重新核对失配预算。

47.5.9 z 域里延迟长什么样

把连续结论搬到 z 域，形式几乎不变。模型准确时，对象与模型的无延迟部分都是式 (47-25) 的形状，延迟是 z^{-n_m}，于是闭环变成

$$T(z) = \frac{C(z)G_{m0}(z)}{1 + C(z)G_{m0}(z)}\, z^{-n_m}$$

延迟仍然只在分子上。z^{-n_m} 在单位圆内没有极点，所以它不影响稳定性；它只是把输出推后 n_m 拍。这与连续域的 $e^{-\tau_m s}$ 完全对应：一个是“推迟 n_m 拍”，一个是“推迟 τ_m 秒”。

这个对应关系可以用来复核实现。如果你写出的离散闭环里 z^{-n_m} 出现在分母，那一定是把延迟放错了位置——最常见的原因是把“模型的延迟输出”当成反馈，而不是“实测加修正”。

离散域还多一个连续域没有的现象：z^{-n_m} 的相位是 $-n_m \omega T_s$，它对频率是严格线性的，而连续域的 $e^{-j\omega\tau}$ 也是线性的，两者在采样点上完全一致。差别只出现在采样点之间——连续域里延迟是“真正的时间平移”，离散域里是“整拍平移”，中间的信息丢了，这就是 §47.5.2 的量化误差。

47.5.10 计算延迟与扫描周期抖动

§47.5.6 讲过一拍计算延迟，做法是把 n_m 补一拍。真正麻烦的不是这一拍，而是这一拍不稳定。

PLC 的扫描周期不是严格的常数。通信任务多的时候，扫描周期可能从 50 ms 变成 80 ms，甚至偶尔跳一下。对普通回路，这点抖动无关紧要；对 Smith 回路，它等效于延迟在 ± 1 拍之间随机跳变。按表 47-8，延迟误差 2 s 已经让超调到 31%，而 1 拍的抖动在 $T_s = 0.5$ s 时就是 0.5 s，相当于 15% 的增益误差——够不上失稳，但足以让控制量抖动。

处理办法有三条。第一，用时间戳而不是拍数来记延迟：每次采样记录时刻，延迟缓冲按“时刻差”取值，这样扫描周期变化不会改变物理延迟。第二，积分项按实际时间步长累加，而不是固定 T_s，否则扫描变慢时积分会偏小。第三，把预估器的模型推进放在高优先级任务里，避免被通信任务打断。

三条里第一条最有效，也最容易被忽略。很多现场把 τ_m 写成“16 拍”，运行半年后扫描周期改了一次，延迟就悄悄错了。写成“8.0 s”、由程序按时钟换算成拍数，才是可维护的做法。

47.5.11 三种实现形态

同一个离散算法，在三种平台上落地的方式差别很大，坑也不同。

第一种是 DCS 功能块。主流 DCS 都提供“纯滞后”块（型号各异，功能相同：输入、输出、滞后时间、采样周期四个参数）。预估器用三个块搭：一阶惯性块、纯滞后块、减法块。优点是组态简单、不用写代码；缺点是滞后块的内部实现不透明，有些型号按整拍取整、有些支持插值，投运前必须用阶跃试验确认它到底是哪一种。§47.5.2 的量化误差，在这里会以“厂家实现差异”的形式出现。

第二种是 PLC 梯形图或结构化文本。需要自己写环形缓冲，缓冲长度 $n_m + 1$，下标用模运算。优点是完全可控，想用分数拍插值也行；缺点是要自己处理边界（$k < n_m$ 时缓冲区里是初始值）、自己处理扫描周期抖动。§47.10.4 提到的“用时间戳而不是拍数”，在 PLC 里最容易做到，也最容易被忽略。

第三种是上位机或 APC 平台。可以用状态空间、可以用矩阵运算、可以做在线辨识。优点是灵活；缺点是通信延迟与数据质量不可控——上位机读到的是“几秒前的数据”，这段延迟必须算进 τ_m，否则预估器会系统性地提前。

三种形态的共同点是：延迟缓冲都是核心，都要回答“存多少拍、怎么取整、异常时怎么办”。差别只在“谁来保证这三件事”。选型时不要只看算法是否先进，要看平台能不能把这三件事做扎实。

47.6 稳定性与性能

47.6.1 三个误差源，一笔预算

预估器的稳定性由三样东西共同决定：控制器 C、模型的无延迟部分 G_{m0}、以及真实对象与模型之间的误差 Δ。前两样在设计时就定死了，第三样在运行中一直变。所以讨论稳定性，本质上是在讨论“误差能有多大”。

误差有三个来源：增益 K、时间常数 T、延迟 τ。三者对回路的作用方式不同，危害也不同。下面三张表分别扫描，第四张表看它们叠加，第五张表看频域裕度。所有数据都来自同一套对象、同一组控制器，只改一个失配量，便于横向比较。

47.6.2 增益失配：最温和的一种

表 47-6 是固定模型、只改真实增益的结果，图 47-4 画出四条响应曲线。

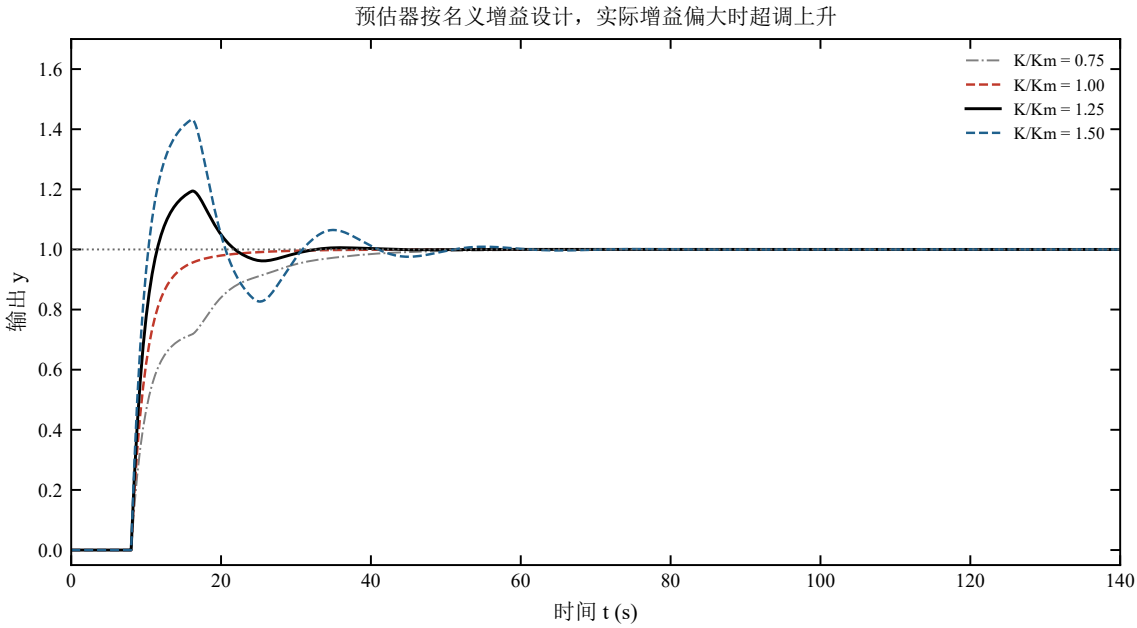

图 47-4　增益失配：$\kappa = 0.5$ 与 0.75 只是变慢，$\kappa = 1.25$ 起出现超调，$\kappa = 2.0$ 振荡发散

表 47-6　增益失配（模型 $K_m = 1.0$）

K/K_m	超调 (%)	调节 (s)	IAE	相位裕度 (°)	幅值裕度 (dB)
0.50	0.00	66.20	20.799	67.90	无穷
0.75	0.00	37.80	13.867	80.95	无穷
1.00	0.00	20.05	10.400	93.42	无穷
1.25	19.45	29.00	10.676	90.04	无穷
1.50	43.27	47.00	13.431	68.41	无穷
2.00	90.98	未稳	37.057	23.56	无穷

表 47-6 有两个要点。

第一，失配的方向不对称。实际增益偏小（$\kappa < 1$）时，超调始终是 0，代价只是变慢：$\kappa = 0.5$ 时调节 66.20 s，IAE 20.799，是名义值的三倍，但曲线很稳。实际增益偏大（$\kappa > 1$）时，超调迅速上升：1.25 倍就有 19.45%，1.5 倍 43.27%，2 倍 90.98% 且无法稳定。工程上宁可把 K_m 估大一点，也不要估小，这是“保守建模”的一条具体依据。

第二，增益失配时幅值裕度恒为无穷。原因是式 (47-15) 里 Δ 是实常数，等价开环的相位不会穿过 -180°，只会在 -90° 与 -180° 之间移动。这时幅值裕度没有信息量，必须看相位裕度。$\kappa = 2.0$ 时相位裕度 23.56°，已经低于 30° 的工程下限，与 90.98% 的超调互相印证。

47.6.3 时间常数失配：高频误差

表 47-7 是只改时间常数的结果。

表 47-7　时间常数失配（模型 $T_m = 5$ s）

T/T_m	超调 (%)	调节 (s)	IAE
0.50	15.79	60.60	13.784
0.75	2.68	28.05	10.575
1.00	0.00	20.05	10.400
1.25	4.58	36.55	11.810
1.50	9.11	44.00	13.435
2.00	15.70	52.45	16.563

表 47-7 的跨度比表 47-6 小得多：时间常数从一半变到两倍，超调最多 15.79%，没有失稳。这与式 (47-16) 的高通形状一致：时间常数误差在低频趋近于 0，只影响高频段，而高频段的回路增益已经被对象惯性压得很低，所以危害有限。

但“危害有限”不等于“可以忽略”。$T/T_m = 0.5$ 时调节时间 60.60 s，比名义值慢三倍；IAE 13.784，涨了 32.5%。如果现场对调节速度有要求，时间常数估错一倍仍然不能接受。工程上一般要求 T 的估计误差在 ±30% 以内，这个要求比延迟宽松得多。

47.6.4 延迟失配：最致命的一项

表 47-8 是只改延迟的结果，图 47-5 画出四条曲线。

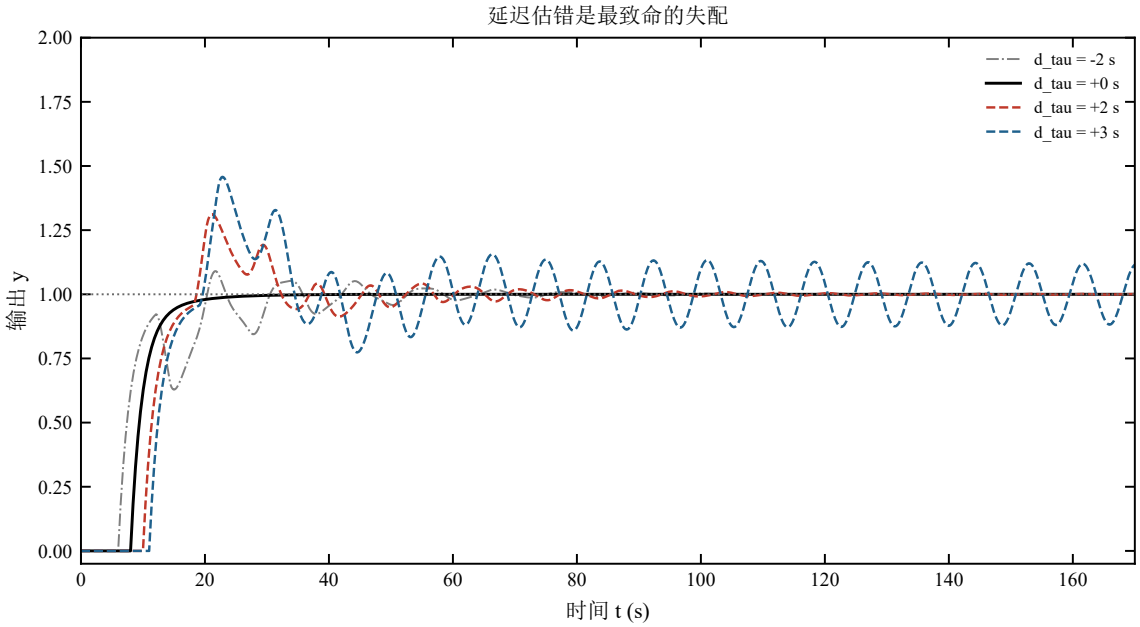

图 47-5　延迟失配：± 2 s 已是临界，模型高估 4 s 直接失稳，低估 4 s 超调也接近 100%，两个方向都要留余量

表 47-8　延迟失配（模型 $\tau_m = 8$ s）

$\delta\tau$ (s)	超调 (%)	调节 (s)	IAE	相位裕度 (°)	幅值裕度 (dB)
−4.0	984.25	未稳	328.305	−17.61	−1.84
−2.0	9.05	61.55	11.918	36.16	7.76
−1.0	1.34	31.85	10.445	66.46	11.15
−0.5	0.00	23.45	10.400	80.64	23.79
0.0	0.00	20.05	10.400	93.42	无穷
+0.5	5.99	22.85	11.013	85.95	19.26
+1.0	14.70	29.25	12.190	65.97	10.08
+2.0	31.22	75.90	15.939	31.17	4.31
+4.0	96.15	未稳	64.713	−14.63	−1.46

表 47-8 的信息量最大，至少读出四层。

第一层，容差很窄。± 0.5 s 时还能接受（超调不超过 6%，调节不超过 23.45 s），到 ± 2 s 就已经很难看（超调 9.05% 到 31.22%，调节 61.55 s 到 75.90 s），到 ± 4 s 直接失稳。本章 $\tau = 8$ s，± 0.5 s 只有 6.25% 的相对误差，± 2 s 是 25%。也就是说，延迟估计的相对误差要控制在 10% 以内，才能保住“接近名义”的性能。

第二层，方向不对称，而且与增益失配相反。$\delta\tau = -4$ s（模型把延迟估长了 4 s）比 $\delta\tau = +4$ s 更糟：前者超调 984.25%，后者 96.15%。原因是式 (47-18)：$\delta\tau < 0$ 时 $e^{-\delta\tau s} = e^{+4s}$ 是一个“超前”环节，相当于让预估器提前 4 s 宣布结果，控制器据此猛动，而真实输出还没到，形成正反馈式的大超调。$\delta\tau > 0$ 时是额外的滞后，系统变慢、变振荡，但不会立刻炸掉。

第三层，1 s 的延迟误差，约等于把调节时间拖长 46%（20.05 s 到 29.25 s），约等于 30% 的增益误差。用这个换算可以把不同量纲的容差放进同一张预算表：如果现场增益可能变 20%、延迟可能变 1 s，那么总误差预算已经接近“临界”，不能再把控制器调得更激进。

第四层，频域与时域对得上。$\delta\tau = +2$ s 时相位裕度 31.17°、幅值裕度 4.31 dB，时域 31.22% 超调、75.90 s 调节；$\delta\tau = +4$ s 时两个裕度都为负，时域失稳。这说明 §47.2.10 的等价开环 L_{eq} 可以用来做投运前的裕度校核，不必每次都跑长时仿真。

47.6.5 二维失配：误差会叠加

图 47-6 是增益与延迟同时失配的超调地图，横轴 $\delta\tau$ 从 -2 s 到 $+2$ s，纵轴 κ 从 0.75 到 1.75，格子里是超调百分数。

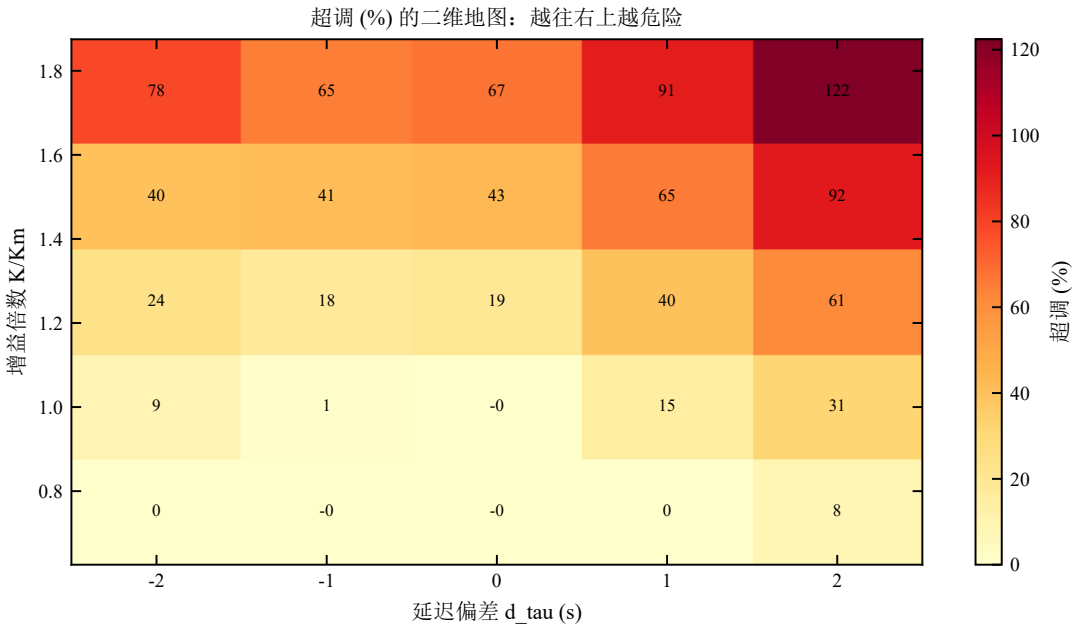

图 47-6　增益与延迟的二维失配地图：格子内为超调百分数，左下角安全，右上角接近失稳

地图上有三条清晰的等高线。左下角（$\kappa = 0.75$、$\delta\tau = -2$ s）是 0.5%，几乎无超调；对角线附近（$\kappa = 1.25$、$\delta\tau = +2$ s）是 61.5%；右上角（$\kappa = 1.5$、$\delta\tau = +2$ s）是 91.9%，已经接近失稳。

这张图说明两件事。第一，误差不是线性叠加的。$\kappa = 1.25$ 单独 19.45%，$\delta\tau = +2$ s 单独 31.22%，两者叠加 61.5%，比“相加”的 50.7% 还高，因为增益放大与相位滞后在穿越频率附近互相加剧。第二，安全区很窄。整张图 20 个格子里，超调低于 20% 的只有 8 个，且集中在 $\kappa \le 1.0$ 或 $\delta\tau \le 0$ 的一侧。

工程上的用法是：把这张图当作“投运许可范围”。如果现场工况会让 κ 在 0.8–1.2、$\delta\tau$ 在 ± 1 s 内变化，那么回路基本安全；如果 κ 可能到 1.5、延迟可能多 2 s，就必须先降增益或加滤波，不能直接投。

47.6.6 裕度怎么读

表 47-9 把几种典型情形的裕度列在一起。

表 47-9　典型情形的相位裕度与幅值裕度

情形	相位裕度 (°)	幅值裕度 (dB)	判读
纯反馈 $K_c = 0.6$	62.96	6.78	稳，但慢
Smith 模型准确	93.42	无穷	稳，裕度充足
Smith $\kappa = 1.5$	68.41	无穷	稳，超调偏大
Smith $\delta\tau = +1$ s	65.97	10.08	稳，可接受
Smith $\delta\tau = +2$ s	31.17	4.31	临界
Smith $\delta\tau = -2$ s	36.16	7.76	临界
Smith $\kappa = 1.3, \delta\tau = +2$ s	17.72	1.97	危险
Smith $\delta\tau = +4$ s	−14.63	−1.46	失稳

读表 47-9 有三条经验。

第一条，相位裕度与幅值裕度要给“更保守”的那个。模型准确时幅值裕度无穷，只看相位裕度 93.42° 会显得很安全；但一旦延迟偏差 2 s，幅值裕度掉到 4.31 dB，比相位裕度的 31.17° 更早报警。两个指标一起看，取差的。

第二条，不要用“名义模型下的裕度”给现场打包票。名义模型下 93.42° 是纸上数字，现场只要延迟估错 1 s 就掉到 65.97°。裕度校核必须按“最坏失配”做，不能按名义值做。

第三条，多次穿越时相位裕度会失去单调性。$\delta\tau = +4$ s 与 $\kappa = 1.3, \delta\tau = +2$ s 这两行，相位裕度数值上并不总是随失配单调下降，因为 L_{eq} 的相位会多次穿过 $-180°$。这时以幅值裕度为准，或者直接看时域仿真是否收敛。

47.6.7 负载扰动：预估器帮不上大忙

前面的表都是设定值阶跃。负载扰动是另一回事，表 47-10 对比了纯反馈与 Smith 在 $t = 60$ s 加入 -0.3 阶跃扰动后的表现，图 47-9 是响应曲线。

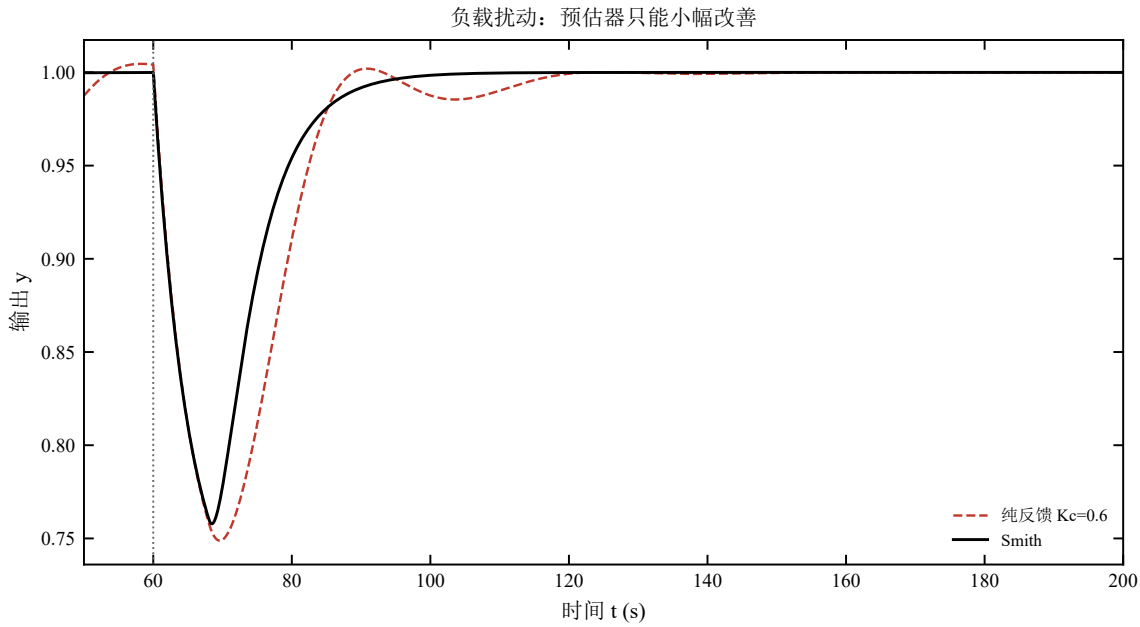

图 47-9　负载扰动响应：两条曲线几乎重合，预估器把峰值偏差只压低了 3.6%

表 47-10　负载扰动抑制（扰动加在对象输入端）

方案	峰值偏差	IAE	恢复时间 (s)
纯反馈 $K_c = 0.6$	0.251	4.048	25.1
Smith $K_c = 2.5$	0.242	3.120	24.8

表 47-10 的对比很“扫兴”：峰值偏差只从 0.251 降到 0.242（改善 3.6%），恢复时间几乎一样，只有 IAE 改善了 23%。这与前面设定值跟踪“调节时间快 59%”的收益完全不成比例。

原因是预估器的工作方式。负载扰动加在对象输入端、延迟之后，它不经过模型的“预演通道”，模型对它是“不知情”的：模型只知道自己吃了 u，不知道对象还额外吃了扰动。所以 y_{pred} 里的修正量只修正了 u 造成的部分，扰动造成的那部分仍然要等真实输出反映出来，预估器无法提前。它唯一能做的是让 PI 的增益更高，从而在扰动被看见之后反应更快，这就是 IAE 改善 23% 的来源。

这条结论很重要，它划清了 Smith 的适用边界：它擅长设定值跟踪，不擅长抑制不可测的负载扰动。如果现场的主要矛盾是负载扰动，应该优先考虑前馈（第 46 章）或串级（第 45 章），而不是 Smith。

47.6.8 性能小结：三个指标要一起看

本节的数据可以浓缩成三句话。

第一，模型准确时，Smith 用同一组 PI 参数把调节时间从 48.50 s 压到 20.05 s，代价是控制量峰值从 1.202 升到 2.500。收益与代价都真实，不是数字游戏。

第二，失配的排序是延迟 $\gg$ 增益 $>$ 时间常数。延迟 ± 2 s 就能让超调从 0 到 31.22%，增益 1.5 倍是 43.27%，时间常数 2 倍只有 15.70%。投运前的时间应该按这个顺序花：先把延迟估准，再校增益，最后才管时间常数。

第三，负载扰动几乎不受益。把 Smith 当成“设定值跟踪加速器”是准确的，把它当成“抗扰神器”是误解。下一章讲前馈时会看到，抗扰要靠“提前看见扰动”，而不是“提前看见输出”。

47.6.9 噪声：第四个误差源

前面三节讨论的都是模型失配，误差是“确定性的”。现场还有一个随机误差源：测量噪声。它在 Smith 回路里的破坏方式与失配完全不同——不失稳，只让控制量抖。

表 47-11 是加入标准差 0.01 的测量噪声后，四种方案在稳态段（60 s 之后）的表现。

表 47-11　测量噪声下的代价（噪声 0.01，统计 60 s 后的稳态段）

方案	IAE	u 标准差	u 峰值	y 标准差
纯反馈 $K_c = 0.6$	14.590	0.0062	1.217	0.0014
Smith	10.506	0.0252	2.491	0.0010
Smith + $T_f = 2$ s	11.395	0.0029	1.846	0.0010
Smith + $t_{ref} = 5$ s	15.479	0.0252	1.085	0.0010

表 47-11 有四个读法。

第一，Smith 的控制量抖动是纯反馈的四倍（0.0252 对 0.0062）。原因很直接：修正量 $y_{m0} - y_{m\tau}$ 把噪声原样送入控制器，而 K_c 又高了四倍，两个因素乘起来就是四倍左右的抖动。输出标准差反而更小（0.0010 对 0.0014），因为对象本身有低通作用；噪声主要伤的是阀门，不是产品质量。

第二，前置滤波 $T_f = 2$ s 把抖动压到 0.0029，比纯反馈还低，代价是 IAE 从 10.506 涨到 11.395。这是本章唯一一个“滤波明显优于降增益”的场景——噪声是高频的，正是滤波器的用武之地。

第三，设定值滤波对噪声毫无作用（0.0252 不变）。它在参考通道上，噪声从测量通道进来，两者不相遇。它唯一改变的是 u 峰值（从 2.491 降到 1.085），因为阶跃激励变缓了。

第四，加 $t_{ref} = 5$ s 后 IAE 反而比纯反馈差（15.479 对 14.590）。原因是上升被拖慢，误差积分变大。这提醒我们：t_{ref} 是“用速度换超调”的工具，不是“全面提升性能”的工具，在噪声场景下它甚至可能是负收益。

把这四条与 §47.6.2–§47.6.4 的失配合起来看，Smith 回路的误差预算一共有四项：延迟、增益、时间常数、噪声。前三项决定稳定性，第四项决定控制量品质。四项的来源不同，对策也不同：前三项靠辨识与降增益，第四项只能靠滤波。

47.6.10 误差预算怎么编

现场做失配校核，不可能把每个组合都仿真一遍。实用的做法是编一张“相位损耗预算表”，把每种失配折算成相位损耗，再看总损耗是否吃掉了裕度。

表 47-12 从表 47-6 到表 47-8 里摘出单项损耗。基准是名义模型的 93.42°。

表 47-12　单项失配的相位损耗

失配	相位裕度 (°)	损耗 (°)	占 48.4° 预算
增益 +25%	90.04	3.38	7%
增益 +50%	68.41	25.01	52%
时间常数 +50%	78.01	15.41	32%
延迟 +1 s	65.97	27.45	57%
延迟 +2 s	31.17	62.25	129%
延迟 −2 s	36.16	57.26	118%

第三列的“48.4°”是这么来的：如果要求最坏情形下相位裕度不低于 45°，可用预算就是 93.42−45=48.42°。表里最后一列表示“这一项单独就吃掉了预算的百分之多少”。

读表 47-12，三条结论立刻出来。

第一，延迟 2 s 一项就超预算 29%，无论其他项多准，回路都进不了 45° 以内。这解释了为什么 §47.10 把延迟估计放在第一位：它不是“重要”，而是“一票否决”。

第二，延迟 1 s、时间常数 +50%、增益 +25% 三项叠加，损耗是 27.45+15.41+3.38=46.24°，刚好卡在 48.42° 预算内。这就是“三项都可以有一点偏差，但都不能大”的量化含义。

第三，叠加不能简单相加。本章 $\kappa = 1.3$、$\delta\tau = +2$ s 的实测相位裕度是 17.72°，而按加法估算是 62.25° 左右的损耗、剩 31°。实测比估算更糟，因为增益放大会把穿越频率右移，延迟项 $\omega_c\tau$ 随之变大，两项互相加剧。所以用加法编预算时，要在最后留 20%–30% 的余量。

工程上可以按这个流程走：列出所有可能漂移的项 → 查表得单项损耗 → 相加 → 乘 1.25 的安全系数 → 与 48.4° 比较。超了，就按表 47-16 降 K_c，或者加 t_{ref} 把超调压下去，直到预算够用。

47.7 参数意义与作用

47.7.1 两套参数要分开看

Smith 预估回路里有七个可调量，很多人把它们混在一张参数表里，结果现场一出问题就不知道该动哪一个。正确的分法是两类：模型参数 K_m、T_m、τ_m 描述“对象长什么样”，由辨识决定；控制器参数 K_c、T_i 描述“要多快”，由整定决定。另外两个 T_f、t_{ref} 是鲁棒化旋钮，只在模型不准或超调偏大时才用。表 47-13 把七个量列在一起。

表 47-13　Smith 回路的七个可调量

符号	含义	单位	由什么决定	改错的后果
K_m	模型稳态增益	无量纲	稳态数据	偏小变慢，偏大超调
T_m	模型时间常数	s	阶跃曲线	两头都变差，幅度温和
τ_m	模型纯滞后	s	延迟辨识	最敏感，方向不对称
K_c	控制器增益	无量纲	按 G_{m0} 整定	过大振荡，过小迟滞
T_i	积分时间	s	按 G_{m0} 整定	过大恢复慢，过小抖动
T_f	控制器前置滤波	s	失配程度	非单调，有最优值
t_{ref}	设定值滤波	s	超调容忍度	只压超调，不救失稳

这张表最重要的一列是最后一列。它告诉你：调错了会以什么方式表现出来。下面按“模型参数在前、控制器参数在后、鲁棒旋钮收尾”的顺序逐个说。

47.7.2 K_m：偏小是慢，偏大是冲

增益失配用 $\kappa = K/K_m$ 表示，表 47-6 的六行数据可以读成两条。

$\kappa < 1$（模型增益估大了）时，超调始终是 0，但一切都变慢：$\kappa = 0.5$ 的调节时间是 66.20 s，是准确模型 20.05 s 的三倍多，IAE 从 10.400 涨到 20.799。原因是等效开环增益被压低，闭环带宽变窄，PI 推不动。这种失配在现场很隐蔽——曲线很“干净”，没有振荡，操作员只会觉得“这回路怎么这么肉”。

$\kappa > 1$（模型增益估小了）时，情况急转直下：$\kappa = 1.25$ 超调 19.45%，$\kappa = 1.5$ 超调 43.27%，$\kappa = 2.0$ 直接失稳。注意这里的机理不只是“增益变大”：开环增益升高会把穿越频率往右推，而穿越频率一右移，延迟项 $-\omega_c\tau$ 吃掉的相位就更多。所以表 47-6 里相位裕度从 93.42° 一路掉到 23.56°，掉得比增益本身的变化更快。增益失配通过“移动穿越频率”间接放大了延迟的危害，这是 Smith 回路比普通回路更怕增益偏大的原因。

工程含义很清楚：K_m 宁可估大一点，不要估小。估大了只是慢，估小了会振。

47.7.3 T_m：只改中频形状，两头都变差

时间常数失配的影响呈明显的 U 形，见表 47-7。$T/T_m = 0.5$ 时超调 15.79%、调节 60.60 s；$T/T_m = 1.0$ 时是 0 与 20.05 s；$T/T_m = 2.0$ 时又回到 15.70% 与 52.45 s。两头都比中间差，但最坏也只有 16% 超调，始终没有失稳。

为什么是 U 形？因为 T_m 决定模型极点的位置。T_m 偏小，模型比对象“快”，预演值提前到位，控制器误以为已经见效而收手，实际输出还没跟上；T_m 偏大，模型比对象“慢”，预演值滞后，控制器又会在该收的时候继续加码。两种错误都会削弱预演的准确性，只是方向相反。

这一节给现场一个安心结论：三个模型参数里，T_m 是最不敏感的。辨识时间常数时不必追求小数点后一位，能从阶跃曲线的 63.2% 点读出量级就够了。真正要花力气的是 τ_m。

47.7.4 τ_m：最贵的那个参数

把表 47-8 的数字换算成一句话：延迟误差 1 s，约等于增益误差 30%。这个换算不是巧合，在穿越频率附近有简单的关系：

$$\frac{\delta K}{K} \approx \omega_c \, \delta\tau \tag{47-28}$$

本章的穿越频率在 0.3 rad/s 附近，$\delta\tau = 1$ s 就对应 0.3 的等效增益误差。式 (47-28) 的价值在于把两种不同量纲的失配放进同一张预算表：如果现场增益会漂 20%、延迟会漂 1 s，两项加起来已经 50%，回路就处在表 47-9 里“临界”那一档，不能再按名义模型整定。

延迟失配还有两个特殊性。第一是方向不对称，$\delta\tau = -4$ s 超调 984.25%，$\delta\tau = +4$ s 只有 96.15%，因为前者让 $e^{-\delta\tau s}$ 变成超前环节。第二是没有“安全的高估”。很多人以为“模型延迟取大一点更保险”，实测恰好相反：取大 4 s 比取小 4 s 危险得多。所以 τ_m 的辨识要单独做、要在线校核，不能靠“留余量”糊过去。

47.7.5 K_c：唯一能立刻改变速度的旋钮

模型定下来之后，能动的只有 K_c 和 T_i。K_c 的作用最直接：它同时决定速度和超调。

在模型失配的情形下（$\kappa = 1.3$、$\delta\tau = +2$ s），把 K_c 从 2.5 降到 1.0，超调从 67.55% 降到 26.86%，相位裕度从 17.72° 升到 68.65°。这条曲线的形状值得注意：从 2.5 降到 1.5，超调掉了 23.8 个百分点；从 1.5 再降到 1.0，只掉 16.9 个百分点，而调节时间却明显变长。降增益的收益是递减的，降到某个点之后，你只是在用速度换一点点稳定性。

所以 K_c 的正确用法不是“出问题就降”，而是先判断问题出在哪。如果模型是准的，$K_c = 2.5$ 有 93.42° 裕度，根本不需要降；如果模型不准，降 K_c 只是给失配买保险，买多少要按表 47-9 的裕度倒推，而不是凭感觉。

47.7.6 T_i：与延迟无关，与采样周期有关

T_i 在本章取 6 s，比 $T_m = 5$ s 略大。式 (47-21) 给出的闭式解是 $T_i = T_m$，现场取略大一点，是为了让阶跃初期的控制量不那么冲——积分作用在误差最大的头几秒贡献最多，T_i 放大 20%，控制量峰值就能明显降下来，代价是调节时间略微变长。

T_i 与延迟的关系很弱，与采样周期的关系却很强。§47.5 已经算出约束 $T_s \le T_i/10$，本章对应 0.6 s。这条约束的物理含义是：积分器在每个采样周期累加一次，如果 T_s 接近 T_i，积分就变成了“大步跳”，等效于一个粗糙的阶梯，容易激发振荡。现场如果因为设备限制只能取 1 s 采样，那就必须把 T_i 放大到 10 s 以上，否则积分本身就变成了不稳定源。

T_i 与 K_c 的搭配还有一个经验比例：T_i/T_m 在 1.0–1.5 之间时，Smith 回路的设定值响应最平顺。偏离这个区间，要么积分太弱导致稳态爬行，要么积分太强导致控制量在死区里空转——§47.4 里那个“纯反馈控制量反而更小”的反常现象，根源就在这里。

47.7.7 T_f：连续可调，但不是单调的

T_f 是控制器前面的一阶滤波，作用是压低高频增益、抑制噪声和振荡。直觉上“滤波越强越稳”，实测却不是这样。表 47-14 是在 $\kappa = 1.3$、$\delta\tau = +2$ s 这组失配下扫描 T_f 的结果。

表 47-14　前置滤波 T_f 的扫描（$\kappa = 1.3$，$\delta\tau = +2$ s）

T_f (s)	超调 (%)	相位裕度 (°)
0	67.55	17.72
1	74.88	−1.50
2	69.38	8.47
4	67.22	35.20
8	89.94	14.59

表 47-14 有两处反直觉。

第一处，$T_f = 1$ s 比不滤波还差：超调从 67.55% 升到 74.88%，相位裕度从 17.72° 掉到 −1.50°。原因是滤波在低频段就开始贡献相位滞后：

$$\varphi_f(\omega) = -\arctan(\omega T_f) \tag{47-29}$$

在 0.3 rad/s 处，$T_f = 1$ s 已经贡献 $-16.7°$，而它带来的幅值衰减只有 4% 左右。相位白送、衰减不够，回路自然更差。

第二处，$T_f = 4$ s 时相位裕度回到 35.20°，超调却几乎没变（67.22%）。这说明相位裕度与超调不是一一对应的：$T_f = 4$ s 与 $K_c = 2.0$ 的相位裕度几乎相同（35.20° 与 35.10°），超调却差 10 个百分点。原因是大延迟系统的 L_{eq} 有多次穿越，穿越点附近的相位只描述了局部，真正的超调还取决于低频段的幅值积累。

结论是 T_f 要“按失配程度选一档”，不要连续微调，也不要指望它救失稳。它的合理区间在本章是 3–5 s：再小不起作用，再大就开始吃相位。

47.7.8 t_{ref}：最便宜的旋钮

设定值滤波 t_{ref} 是七个参数里唯一“只压超调、几乎不花代价”的。同样在 $\kappa = 1.3$、$\delta\tau = +2$ s 下，t_{ref} 从 0 加到 10 s，超调从 67.55% 一路降到 5.82%，几乎没有拐点。

它的机理与 T_f 完全不同：T_f 在反馈通道里，改的是稳定性；t_{ref} 在参考通道里，改的是“给控制器看的目标有多急”。它不改变闭环极点，只改变激励信号的频谱，所以不会破坏稳定性，代价仅仅是上升变慢。

这也划出了它的边界：t_{ref} 能压超调，不能救失稳。如果回路本身已经振荡（比如 $\delta\tau = -4$ s），加多大的 t_{ref} 都没用，因为振荡不是设定值激励出来的，而是回路自身的极点跑到右半平面。判断方法很简单：看扰动响应是否也振荡。如果扰动响应干净、只有阶跃超调，用 t_{ref}；如果扰动响应也振荡，说明是稳定性问题，必须回去修模型或降 K_c。

47.7.9 参数之间可以互相折算

七个参数不是独立的，它们通过式 (47-28) 和裕度指标连成一张网。现场最常用的是三种折算。

第一种，延迟折增益：1 s 延迟误差 $\approx$ 30% 增益误差。用途是统一误差预算。

第二种，滤波折增益：$T_f = 4$ s 的超调表现（67.22%）与不滤波时几乎一样，但相位裕度提高了 17.5°。也就是说，滤波买到的是“抗失配的余量”，不是“当下的性能”。它的价值要在工况漂移之后才体现出来。

第三种，设定值滤波折算速度：$t_{ref} = 5$ s 把超调从 67.55% 压到 29.63%，代价是上升时间被拉长到 5 s 量级。如果工艺允许“慢一点但别超调”，这笔交易非常划算；如果工艺要求快速跟踪（比如批量切换），就只能靠修模型。

47.7.10 参数速查

把上面九节压缩成表 47-15，现场调试时可以照着走。

表 47-15　参数调整方向速查

现象	先查	调整方向	备注
响应很肉、无超调	K_m 是否估大	重辨识 K_m，或加 K_c	别用降 T_i 硬催
超调大、有等幅振荡	τ_m 是否偏大	重辨识延迟	高估比低估危险
超调大、振荡渐弱	K_c 偏大	降 K_c	有噪声时改用 T_f
稳态爬行	T_i 偏大	降 T_i	不低于 $10T_s$
控制量抖动	噪声或 T_s 偏大	加 T_f，减小 T_s	$T_s \le T_i/10$
阶跃超调、扰动正常	设定值激励过急	加 t_{ref}	不影响稳定性
扰动也振荡	回路本身不稳	修模型或降 K_c	t_{ref} 无效

表 47-15 的读法是“从上往下排除”：先看曲线有没有振荡，分清是稳定性问题还是跟踪问题；再看是稳态问题还是动态问题；最后才动参数。顺序反了，就会陷入“降增益—变慢—再降增益”的循环，把一个本来只需重辨识延迟的回路调成一条慢爬曲线。

47.7.11 三组必须一起动的参数

七个参数里，有三组是“牵一发而动全身”的，单独改一个往往越改越糟。

第一组是 T_m 与 K_c。式 (47-21) 里 $K_c = T_m/(K_m\lambda)$，T_m 变了，K_c 必须跟着变，否则 λ 就跟着漂。现场重辨识时间常数之后，如果只更新 T_m 不更新 K_c，等效于把闭环速度改了一档：T_m 从 5 s 改成 7 s，K_c 仍是 2.5，λ 就从 2 s 变成 2.8 s，响应慢了 40%。这类“半个参数”的更新，是交接班时最常见的隐患。

第二组是 T_i 与 T_s。§47.8.2 的经验是 $T_s \le T_i/10$，T_i 改小，采样周期就得跟着改小。反过来，如果设备只能提供 1 s 采样，T_i 就不能小于 10 s。这两个参数一个在控制器里、一个在硬件配置里，改动常常不同步，结果就是“控制器调好了、扫描周期没跟上”。

第三组是 τ_m 与 K_c。这是本章数据支持最充分的一组：表 47-16 里，$\delta\tau = +2$ s 要把 K_c 从 2.5 降到 1.7，降幅 32%；延迟再叠加增益失配，要降到 0.8，降幅 68%。也就是说，延迟每变 1 s，K_c 大约要变 15%——与式 (47-28) 的“1 s 折 30% 增益”方向一致，只是作用在整定值上时打了个对折。

三组之外，T_f 与 t_{ref} 相对独立：它们不进入特征方程的核心结构，只改局部形状。所以现场可以“先动模型与 K_c，再动两个滤波”，顺序不要反。

47.8 调参方法与经验

47.8.1 总原则：模型参数不许“顺手调”

初学者调 Smith 回路，最常见的做法是把七个参数放在一张表里一起试，看曲线好就停下。这样调出来的参数一定过不了工况变化这一关，因为你根本不知道哪个参数在补偿哪个误差。

正确的顺序是刚性的：先把 K_m、T_m、τ_m 辨识准，再按无延迟模型整定 K_c、T_i，最后才用 T_f、t_{ref} 处理残余问题。模型参数是“事实”，控制器参数是“选择”，事实不能为了曲线好看而修改——把 K_m 从 1.0 调成 1.3 让

曲线变平滑，等于在模型里埋了一个 30% 的谎言，下次负荷一变就会露出来。

这条原则还有一个推论：调参过程中改动的参数必须记下来，并注明理由。三个月后回路出问题，那张记录决定了你是五分钟修好还是两天找不到原因。

47.8.2 第一步：开环阶跃，拿三个数

辨识在开环或手动模式下做，给一个 5%–10% 的阶跃，记录输出直到稳定。三个数这样取：

增益 K_m 用稳态两点法，输出变化量除以输入变化量。这一步最不容易错，但要注意量程换算——阀门开度 5% 对应流量多少、温度变送器 4–20 mA 对应多少度，换算错了，后面全错。

时间常数 T_m 取输出到达稳态值 63.2% 的时刻。对大延迟对象，从阶跃发生算起还是从延迟结束算起，差别很大，必须统一口径：本章一律从延迟结束算起。

延迟 τ_m 用阈值法。§47.10 会详细讲，这里先给结论：取输出变化 5% 的时刻，减去 5% 阈值对应的一阶响应时间，本章算出来是 8.243 s，而真值是 8.0 s，偏差只有 0.243 s。如果改用 50% 阈值，估计值是 11.495 s，偏差 3.495 s——按式 (47-28)，这相当于 100% 的增益误差，回路必然振荡。所以“用半值点读延迟”这个在教科书上很常见的做法，对大延迟对象是有害的。

47.8.3 第二步：按无延迟模型算整定值

有了三个数，按式 (47-21) 算 K_c 与 T_i：$K_c = T_m / (K_m \lambda)$，$T_i = T_m$。$\lambda$ 从 $T_m/2.5$ 起试，本章 $T_m = 5$ s，$\lambda = 2$ s，得 $K_c = 2.5$。

为什么 λ 从 $T_m/2.5$ 起？因为再小，控制量峰值会超过执行机构的可用行程；再大，K_c 就低于纯反馈的保守值，预估器白装。$T_m/2.5$ 是“用得上预估器、又不至于饱和”的分界。

这一步算出来的参数是“名义参数”，不是“最终参数”。它对应的是模型完全准确的情形，此时相位裕度 93.42°，超调 0。接下来的每一步都只做减法，不做加法。

47.8.4 第三步：按失配程度降增益

§47.3.4 承诺过要给出降增益的经验系数，表 47-16 就是答案。做法是：对每种失配，扫描 K_c，找出同时满足“超调不超过 20%、相位裕度不低于 45°”的最大值。

表 47-16　失配程度与最大可用增益（超调 $\le 20\%$，相位裕度 $\ge 45°$）

失配情形	最大 K_c	该点超调 (%)	该点相位裕度 (°)	相对 2.5
名义模型	2.50	0.00	93.42	1.00
$K/K_m = 1.25$	2.50	19.45	90.04	1.00
$K/K_m = 1.50$	1.00	18.37	68.13	0.40
$T/T_m = 1.50$	2.50	9.11	78.01	1.00
$\delta\tau = +1$ s	2.50	14.70	65.97	1.00
$\delta\tau = +2$ s	1.70	18.22	60.30	0.68
$\delta\tau = -2$ s	2.00	2.20	46.01	0.80
$K/K_m = 1.3$，$\delta\tau = +2$ s	0.80	18.44	69.98	0.32

表 47-16 有四条用法。

第一，单项失配在 25% 以内时，不用降增益。$K/K_m = 1.25$ 与 $T/T_m = 1.5$ 都能保持 2.50，T_m 这一项甚至完全不敏感。这意味着辨识精度做到 ±25% 就够用了，不必追求高精度。

第二，增益失配到 50% 时，K_c 只能取 1.00，是名义值的 40%。这一档已经低于纯反馈的保守整定（$K_c = 0.6$ 的 1.7 倍），预估器的收益被大幅压缩。此时应该先怀疑辨识数据，而不是接受这个结果。

第三，延迟失配是双向收费。$+2$ s 降到 0.68，-2 s 降到 0.80，两个方向都要降，没有“留余量”的做法。

第四，两项叠加不是取小，而是相乘。$K/K_m = 1.3$ 单独看不用降，$\delta\tau = +2$ s 单独看降 0.68，两项叠加只剩 0.32，比 0.68 低得多。所以多因素失配时，经验系数要连乘，再打个八折。

47.8.5 第四步：降增益还是加滤波

失配已经存在、又不想把 K_c 降太多时，加 T_f 是另一条路。两者在这组失配（$\kappa = 1.3$、$\delta\tau = +2$ s）下的对比很说明问题。

降 K_c 到 2.0：超调 56.69%，调节 87.95 s，IAE 19.102。 加 $T_f = 4$ s：超调 67.22%，调节 139.90 s，IAE 33.327。

两者的相位裕度几乎一样（35.10° 与 35.20°），但降增益在三个指标上全面胜出。原因还是 §47.7.7 说的：滤波在压低高频增益的同时白送了相位滞后，而相位滞后对延迟系统是最稀缺的资源；降增益虽然也损失带宽，但不额外吃相位。

那滤波什么时候用？答案是“有噪声的时候”。降增益对高频噪声的抑制是有限的，而滤波是专门干这个的。本章的仿真没有加测量噪声，所以降增益占优；现场变送器有 0.5% 的噪声时，结论会反过来——此时应该先加 T_f 把噪声压住，再考虑降增益。

47.8.6 第五步：用设定值滤波收尾

前四步做完，稳定性有余量了，但阶跃超调可能仍然偏大。这时用 t_{ref} 收尾，它的效果在表 47-14 所在的那组失配下是这样的：t_{ref} 取 0、2、5、10 s，超调 67.55%、52.26%、29.63%、5.82%，调节时间反而从 155.30 s 缩到 76.25 s。

调节时间变短，不是笔误。大超调会把“进入 2% 误差带”的时刻推得很晚，压住超调相当于把整条曲线拉回带内，所以调节时间跟着缩短。这提醒我们：调节时间这个指标在超调很大时是失真的，比较方案时要同时看超调和 IAE。

t_{ref} 的取值有一个上限：不能超过工艺允许的响应时间。如果工艺要求 30 s 内到位，$t_{ref} = 10$ s 就不能用，只能退回去修模型。

47.8.7 现场验证：三个试验

参数算好、仿真通过，不等于现场能用。投运前至少做三个试验。

试验一，设定值阶跃。幅度取正常工况的 5%–10%，看超调与调节时间是否与仿真同量级。差太多，说明模型不对。

试验二，负载扰动。手动改一下上游流量或进料温度，看恢复时间。这个试验用来区分“跟踪问题”与“稳定性问题”：如果扰动响应也振荡，说明是后者，回去查模型。

试验三，变工况。把负荷拉到 50% 和 100% 各做一次阶跃。大延迟对象的延迟常随负荷变化（§47.1.2 的输送延迟），两个工况下如果表现差异很大，说明固定 τ_m 不够用，需要 §47.10 的在线估计。

47.8.8 五个常见错误

第一个，喂给模型的是限幅前的 u。模型算的是“没有限幅的世界”，预演值会持续偏大，积分饱和时尤其严重。必须用限幅后的实际控制量。

第二个，延迟按四舍五入取整就不管了。$T_s = 1$ s、$\tau = 8.4$ s 时，取整误差 0.4 s，按式 (47-28) 相当于 12% 的增益误差，已经吃掉一半裕度。要么减小 T_s，要么用分数拍延迟。

第三个，以为加滤波能救失稳。表 47-14 里 $T_f = 1$ s 反而把相位裕度打到 $-1.50°$，这个坑很常见。

第四个，只调 K_c 不查 τ_m。回路振了就降增益，降到不振为止，结果是响应慢得没法用。先查延迟，往往发现是辨识错了 1–2 s。

第五个，用闭环数据辨识模型。闭环下 u 与 y 互相影响，直接拟合会得到有偏的参数。辨识必须在开环或足够弱的闭环下做。

47.8.9 调参流程小结

把这一节压缩成一条流程：开环阶跃拿三个数 → 按 G_{m0} 算 K_c、T_i → 用表 47-16 按失配打折 → 有噪声加 T_f、超调大加 t_{ref} → 三个试验验证。

流程里没有“反复试凑”这一步，因为每一步都有明确的判据：K_c 由裕度和超调定，T_f 由噪声水平定，t_{ref} 由工艺允许的响应时间定。试凑只应该出现在最后微调 10%–20% 的时候，而不是从零开始。这也是 Smith 相比于常规 PID 的一个隐性优势：它的参数有物理含义，调参可以“算”，不必“摸”。

47.8.10 回路已经在振，按什么顺序救

上面的流程是“从零投运”。更常见的情形是：回路已经投运了，某天开始振，操作员把 K_c 一降再降，越降越慢，振动却没根治。这时需要的是一张排查顺序表，而不是继续试。

第一步，判断振动的性质。看三条曲线：等幅振荡、发散振荡、还是衰减振荡后又有新的扰动。等幅或发散，是稳定性问题；衰减但有重复激励，是扰动问题。前者要动模型或增益，后者要查工艺。

第二步，旁路预估器。把 Smith 切回纯反馈（K_c 同时切到保守值），看振动是否消失。消失，说明问题在预估器或模型；不消失，说明问题在对象或执行机构，与 Smith 无关。

第三步，查延迟。这是最可能的根因。把最近一次延迟实测值与投运时的值对比，如果差超过 1 s，按表 47-16 重算 K_c，而不是凭感觉降。

第四步，看 y_{pred} 与 y 的背离。正常运行时两者之差应该很小，且缓慢变化。如果差值持续增大或剧烈抖动，说明模型跑飞了——可能是限幅后没喂给模型、可能是扫描周期改了、也可能是模型参数被谁改了。

第五步，查控制量。阀门是否长期停在限位、是否有大幅抖动、定位器是否 hunting。控制量的问题会被预估器放大，看起来像“算法不稳”，实际是执行机构的问题。

第六步，才轮到降增益和加滤波。这两步在 §47.8.5 已经比较过：没有噪声时降增益更有效，有噪声时先加 T_f。

顺序的关键是“先查模型，后调参数”。反过来的后果是：模型错了 2 s，你把 K_c 从 2.5 降到 1.0，振动确实小了，但响应慢了三倍，操作员不满意，又把 K_c 加回去，循环开始。本章的数据说明，这种循环的根源往往只是一

个没被更新的 τ_m。

47.9 优化与改进

47.9.1 原始 Smith 的三个失效模式

原始 Smith 结构只有一条修正通道、一组固定参数，它在三种情形下会失效。

第一种，模型失配。§47.6 的数据已经说明，延迟差 2 s 就足以让超调从 0 涨到 31.22%。

第二种，负载扰动。§47.6.7 说明预估器对输入侧扰动几乎无感，峰值只降 3.6%。

第三种，测量噪声。修正量 $y_{m0} - y_{m\tau}$ 直接叠加在测量值上，噪声被原样送进控制器，而预估器为了速度把 K_c 调得很高，等于把噪声放大后灌进执行机构。

三种失效模式对应三类改进：结构上挪滤波器、控制上做二自由度、参数上做调度或自适应。本节按这个顺序讲，图 47-7 把前两类里最常用的三种手段画在一起。

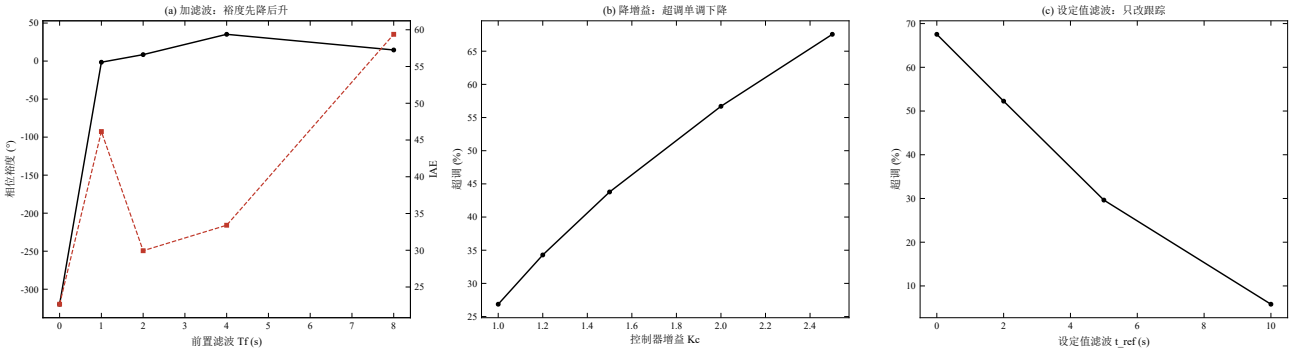

图 47-7　三种改进手段：前置滤波非单调、降增益单调但变慢、设定值滤波几乎只降超调

47.9.2 改进一：把滤波器挪到该在的位置

原始 Smith 结构里没有滤波器。改进型最常见的做法，是在控制器前面加一节一阶滤波，即把 $C(s)$ 换成 $C(s)/(1+T_f s)$。

这个改动看起来只是“加个滤波”，实际改变了三件事。第一，它压低了高频增益，噪声不再被 K_c 放大。第二，它给回路增加了相位滞后，而延迟系统最缺的就是相位，所以 T_f 不能大。第三，它不改变稳态，因为滤波器的直流增益是 1。

图 47-7 的左栏是 T_f 的扫描结果，数值已在表 47-14 给出：不滤波 67.55%，$T_f = 1$ s 反而升到 74.88%，$T_f = 4$ s 回到 67.22%，$T_f = 8$ s 又跳到 89.94%。这条非单调曲线说明滤波器有一个“最优档”，本章在 3–5 s。

滤波器还可以放在另外两个位置：放在设定值通道（就是 §47.8 的 t_{ref}），或者放在模型修正通道（$y_{m0} - y_{m\tau}$ 之后）。三个位置的物理效果不同：放控制器前改稳定性，放设定值前改激励，放修正通道后改的是“预演值有多可信”。工程上最常见的是前两种，第三种只在测量噪声特别大、又不想牺牲跟踪速度时使用。

47.9.3 改进二：二自由度

原始 Smith 只有一个 K_c，跟踪快了抗扰就差，抗扰好了跟踪就慢，两个要求互相牵制。二自由度结构把这两个要求拆开：设定值走一条带滤波的通道，扰动走另一条通道。

具体做法是给设定值加一节滤波 $1/(1+t_{ref}s)$，反馈回路不动。这样闭环极点完全不变，稳定性、抗扰能力都不受影响，只有“给控制器看的目标”变缓了。

图 47-7 的右栏是 t_{ref} 的扫描：0、2、5、10 s 对应 67.55%、52.26%、29.63%、5.82%。这条曲线几乎是单调下降的，没有 T_f 那种反复，因为它不进入特征方程。

二自由度的代价是跟踪变慢，而且这个代价不能无限支付。$t_{ref}=10$ s 时超调只剩 5.82%，但上升时间已经被拉到 10 s 量级，对于要求 30 s 内到位的回路，这笔交易就不划算了。

47.9.4 改进三：增益调度

输送延迟随流量变化，这是 §47.1.2 提到的第一类延迟的固有性质。流量减半、延迟翻倍，固定的 τ_m 只能覆盖一个工况。

增益调度的做法是把工况变量（流量、负荷）作为调度变量，为每个工况点辨识一组 (K_m, T_m, τ_m)，运行时按调度变量插值。实现上就是一张表加一个线性插值，不需要在线辨识。

它的适用条件是：调度变量可测、延迟与调度变量的关系稳定、工况变化不是太快。三个条件缺一个，调度就会引入新的失配——插值出来的模型可能比固定模型更糟。

47.9.5 改进四：自适应与在线辨识

比调度更进一步的是在线辨识：用运行数据实时更新 K_m、τ_m。这条路理论上有吸引力，工程上要谨慎。

难点有三个。第一，闭环辨识的有偏性问题（§47.8.8 第五条），必须有持续的激励信号才能辨识准，而正常运行的回路恰恰缺少激励。第二，辨识算法的收敛速度与稳定性要兼顾，参数跳变会引起控制量跳变。第三，模型参数一变，K_c 是否跟着变？如果跟着变，就变成了自适应控制，稳定性证明要重做。

本书不展开自适应 Smith 的设计，只给一条工程建议：把在线辨识的结果用于“报警与监视”，而不是直接用于“改参数”。让系统告诉你“延迟从 8 s 变成 10 s 了”，由人来决定是否重新整定，这样风险可控。

47.9.6 与 IMC 的等价性

Smith 预估器与内模控制（IMC）在结构上是同一件事的两种画法。IMC 把模型 G_m 放在控制器内部，用“模型输出与实测输出之差”作为反馈；Smith 把这个差拆成“无延迟部分”与“延迟部分”两段。模型准确时，两者的闭环传递函数完全相同。

用 IMC 口径整定 PI（式 47-21）之所以有效，根源就在这里：Smith 结构在模型准确时等价于“用无延迟模型做 IMC”，所以整定公式里只出现 T_m、K_m、λ，不出现 τ_m。延迟被搬到了环外，自然不参与稳定性设计。

这个等价性还有一条实用推论：IMC 的滤波器时间常数 λ 与 Smith 的 K_c 是一一对应的，λ 减小等价于 K_c 增大。所以 §47.8.4 里“按失配降增益”，也可以理解成“按失配放大 λ”。两种说法是一回事，前者在现场更好操作。

47.9.7 预测控制的视角

把 Smith 预估器看成“只预测一步、且模型固定”的预测控制，很多设计选择就变得自然了。

y_{m0} 是“当前控制量作用下、无延迟的输出预测”，y_{pred} 是“用预测值替代实测值的反馈”。这正是预测控制里“用模型预测未来、用预测值做反馈”的最小版本。区别在于：预测控制会预测未来 N 步并在线优化控制量，Smith 只预测“现在”，控制律仍是 PI。

这个视角解释了两件事。第一，为什么 Smith 对负载扰动无效：它没有扰动模型，无法预测扰动的影响；预测控制如果有扰动观测器，就能部分解决。第二，为什么模型失配时 Smith 会振：预测值偏离真实值，反馈被“错误的预测”污染，而预测控制用滚动优化与反馈校正来缓解这个问题。

本书第 58 章会系统讲预测控制，这里只留下这个连接点，不展开。

47.9.8 改进的收益与代价

前四种改进不是越复杂越好，各自的适用场景差别很大。

滤波器最便宜，一行代码，但收益有限，只解决噪声与轻微失配。 二自由度同样便宜，收益明确（超调压到 5.82%），代价是跟踪变慢。 增益调度需要额外的工况表和切换逻辑，收益在延迟随负荷大幅变化时才明显。 在线辨识最复杂，风险也最高，除非延迟漂移无法用调度覆盖，否则不建议上。

一条实用的选择顺序是：先加 t_{ref}（最安全），再加 T_f（对付噪声），然后考虑调度（对付漂移），最后才考虑自适应。前两步在 PLC 里半天能做完，后两步往往要几周的工程时间。

47.9.9 小结：改进的是“容错”，不是“性能”

本节讲的前四种改进，没有一个能让模型准确时的性能更好——名义情形下 $K_c = 2.5$、超调 0、调节 20.05 s 已经是这组参数的上限。它们改善的都是“模型不准时还能不能用”，也就是容错能力。

这个认识很重要。很多现场把改进型 Smith 当成“更先进的 Smith”，指望它又快又稳，结果调不出效果就怀疑算法。正确的预期是：名义性能不变，失配时的性能下降变缓，噪声下的控制量更干净。评价改进型 Smith 的指标，应该是“失配 30% 时超调从 67.55% 降到多少”，而不是“名义超调能不能从 0 变成负的”。

47.9.10 改进五：把滤波放进修正通道

§47.7.7 的 T_f 放在控制器前面，它的相位滞后直接进入回路，所以稍大一点就把裕度吃掉。另一种放法是把滤波放进修正通道：

$$y_{pred} = y + \frac{1}{1 + T_c s}\left(y_{m0} - y_{m\tau}\right)$$

这样处理的是“预演值”本身，而不是控制器的输入。它的好处是：模型准确时，修正量本来就在缓慢变化，滤波对它的影响很小；噪声大时，修正量里的高频成分被压掉，控制量随之干净。

代价是预演的“及时性”下降。修正量被延迟了 T_c，相当于预估器对“对象与模型的差异”反应变慢。如果失配是缓慢漂移（比如延迟随负荷慢慢变），这个代价可以接受；如果失配是突发的（比如阀门特性突然变化），预演跟不上，回路会先恶化再恢复。

所以两个滤波位置的分工很清楚：T_f 放在控制器前，用来压“测量噪声进入回路”；T_c 放在修正通道，用来压“模型输出里的噪声”。前者影响稳定性，后者影响预演速度。本章没有单独扫描 T_c，因为仿真里测量噪声是白噪声、模型本身没有噪声，这个位置的优势体现不出来；现场如果模型输出经过数值微分或查表，T_c 就很有必要。

47.9.11 改进六：观测器型 Smith

把 §47.2.11 的第三条路线做实，就得到观测器型 Smith：不再显式地搭“无延迟模型 + 延迟 + 减法”，而是把对象写成状态空间，用观测器估计“当前的真实状态”，再用状态反馈算控制量。延迟用增广状态（一串移位寄存器）表示。

这个结构有三个好处。第一，它能自然地处理多变量：每个输出对应一个观测器，通道间的延迟各自用缓冲，不必手工拆解。第二，它能与卡尔曼滤波结合，在噪声统计已知时给出最优估计，比一阶滤波更精细。第三，它容易加约束：状态估计出来之后，可以在控制量上做限幅、在状态上做软约束。

代价是实现复杂度上一个台阶。要写状态矩阵、要设计观测器增益、要处理数值稳定性，普通 PLC 很难承载，一般出现在 APC 或 DCS 的高级控制模块里。

工程上的取舍是：单回路、延迟固定，用经典 Smith 就够；多变量、噪声大、有约束，才考虑观测器型。两者不是替代关系，而是同一个思想在不同实现层级上的投影。

47.10 工程落地

47.10.1 落地三件事

算法在纸面上成立，到现场还要过三关：延迟估得准、回路投得上、异常守得住。

第一关是辨识。Smith 的全部收益都建立在“模型对”这个前提上，而三个模型参数里只有 τ_m 会随工况漂移，所以工程上真正要反复做的是延迟估计。

第二关是投运。预估器是一个“并联支路”，投切时如果处理不当，会在切换瞬间给控制器一个阶跃，控制量猛跳。

第三关是异常。传感器坏了、阀门卡了、模型彻底失配了，回路要能安全降级，而不是把一个错误的预演值当成真值继续用。

三关里第一关决定性能，后两关决定能不能长期运行。这一节按这三关展开。

47.10.2 延迟为什么会漂

§47.1.2 列过四类延迟，其中会漂的主要是第一类（输送）和第二类（混合）。

输送延迟等于距离除以流速，流速与流量成正比，所以流量减半、延迟翻倍。一台皮带输送机在满负荷时延迟 30 s，半负荷时可能变成 60 s，这个变化足以让固定 τ_m 的预估器从“有用”变成“有害”。

混合延迟与停留时间分布有关，搅拌罐的液位、进料组成变化都会改变它。这一类漂移通常比输送延迟慢，但幅度可能更大。

分析仪延迟和通信延迟基本固定，前者大但稳定，后者小且随机。工程上把这两类当成常数处理，把注意力放在前两类。

判断延迟是否会漂，有一个简单办法：看工艺有没有“流量”这个变量。有流量、有输送段，延迟就会漂；全是就地混合、没有输送段，延迟基本固定。

47.10.3 阈值法：为什么 5% 比 50% 准

阈值法的做法是：做一次开环阶跃，记录输出首次达到稳态变化量某个百分比 f 的时刻 t_f，再扣掉一阶惯性本身爬升到该百分比所需的时间：

$$\tau_{est} = t_f - T_m \ln \frac{1}{1-f} \tag{47-30}$$

对 5%，扣掉 $0.0513T_m$，本章是 0.26 s；对 50%，扣掉 $0.693T_m$，本章是 3.47 s。

表 47-17 是两种阈值各做 20 次、噪声 0.02 的实测结果。

表 47-17　阈值法估计延迟（真值 8.0 s，噪声 0.02，各 20 次）

阈值	估计均值 (s)	标准差 (s)	偏差 (s)
5%	8.243	0.016	+0.243
50%	11.495	0.027	+3.495

5% 阈值的偏差 0.243 s，正好等于式 (47-30) 里那一项 0.0513×5=0.26 s——说明偏差主要来自“没扣这一项”，而不是噪声。50% 阈值的偏差 3.495 s，同样对应 0.693×5=3.47 s。

两种阈值的标准差都很小（0.016 s 与 0.027 s），说明重复性不是问题，偏差才是问题。这解释了一个现场常见现象：同一个人用同一种方法估延迟，每次结果都很接近，但就是系统性偏大。偏大 3.5 s 意味着什么？按式 (47-28)，相当于 100% 的增益误差，回路必振。

所以方法本身不是“估不准”，而是“用了错误的扣减项”。要么用 5% 阈值（扣减项小，误差可忽略），要么用 50% 阈值但老老实实扣 0.693T_m。现场偏爱“半值点”是因为它好读，但记住要扣减。

47.10.4 阈值法的工程细节

第一，阶跃幅度取 5%–10%。太小，噪声淹没信号；太大，对象进入非线性区，K_m 与 T_m 都变了。

第二，先做 1 s 滑动平均再判阈值。本章的估计器就是这么做的，加与不加，标准差差一个数量级。

第三，只取单调上升段。如果输出有二次扰动（比如上游流量波动），要等曲线平稳后再判，或者重复三次取中位数。

第四，延迟估计要定期做，不是投运时做一次。建议在每次大修后、每次工艺配方变更后各做一次，并把结果记进参数表。

47.10.5 备选方法：互相关与模型拟合

阈值法要求能做开环阶跃，很多连续生产装置不允许。这时可以用另外两种方法。

互相关法：在控制量上叠加一个小幅伪随机信号，算输入与输出的互相关，峰值位置就是延迟。优点是不用停车，缺点是需要足够长的数据、而且激励信号会影响产品质量。

模型拟合：用一段历史数据，同时拟合 K_m、T_m、τ_m，使模型输出与实测输出的误差最小。优点是能同时得到三个参数，缺点是对数据质量要求高，且闭环数据有偏（§47.8.8）。

三种方法的选择：能开环就用阈值法，不能开环但有历史数据就用拟合，两者都不行才用互相关。精度上阈值法最好（偏差 0.243 s），拟合次之，互相关最差但最不影响生产。

47.10.6 鲁棒化第一层：结构

结构上的鲁棒化有四件事，做完之后回路的“下限”就有保障了。

第一，控制量与预估器的输入都取限幅后的值。这一点 §47.8.8 已经强调过，它保证模型与对象吃的是同一个 u。

第二，抗积分饱和。执行机构到顶时，积分器要停止累加，或者用反算法把超出的部分回灌。不做这一步，阀门饱和十分钟，积分就能累到让回路恢复后猛冲。

第三，无扰投切。预估器投入时，先把模型状态初始化成“与当前实测值一致”，再闭合开关。否则切换瞬间 y_{pred} 会跳变，控制器以为出现了大误差。

第四，预演值的合理性限幅。y_{pred} 不应该离实测值太远，可以给它加一个“偏差不超过量程 20%”的限制，超出就报警并暂时退回纯反馈。这是一道保险，防止模型跑飞。

47.10.7 鲁棒化第二层：参数

参数上的鲁棒化就是 §47.8.4 的降增益与 §47.9 的滤波器，这里只补充一条原则：宁可保守，不要激进。

理由是大延迟系统的失稳是“硬失稳”——不像欠阻尼那样慢慢收敛，而是一旦越过边界就等幅或发散振荡，操作员来不及干预。表 47-9 里 $\delta\tau = +2$ s 的相位裕度 31.17° 看起来还行，但同一行幅值裕度只有 4.31 dB，控制量稍有波动就可能越界。

具体取值建议：相位裕度不低于 40°，幅值裕度不低于 6 dB。这两个数比常规回路的 30°/6 dB 更严，因为 Smith 的等效开环相位随频率下降得更快，裕度的“缓冲带”更窄。

47.10.8 鲁棒化第三层：监控与降级

回路投运后要有监控，监控三个量。

第一个，超调。连续三个阶跃的超调都比投运时大 10 个百分点以上，说明模型漂了。

第二个，稳态误差。稳态误差持续不为零，说明 K_m 或积分器出了问题。

第三个，控制量方差。方差突然变大，往往是延迟估错或噪声变大。

三个量里任何一个越界，触发两级响应：一级是报警，提示重新辨识；二级是自动降级，把预估器旁路、退回纯反馈（K_c 用保守值）。降级会变慢，但不会失稳，这是可以接受的失败方式。

降级逻辑要写进程序，而不是靠操作员判断。人在夜班、在报警堆积的时候，最容易做的事就是“再等等看”，而大延迟回路的失稳往往只需要几分钟。

47.10.9 投运检查清单

把这一节的内容压缩成表 47-18，投运前逐项打勾。

表 47-18　Smith 预估器投运检查清单

序号	检查项	合格标准
1	开环阶跃辨识	K_m 偏差 < 20%，τ_m 偏差 < 0.5 s
2	延迟估计方法	用 5% 阈值，或 50% 阈值扣 0.693T_m
3	模型输入	取限幅后的 u
4	采样周期	$T_s \le \tau_m/10$ 且 $T_s \le T_i/10$
5	名义裕度	相位裕度 $\ge 40°$，幅值裕度 ≥ 6 dB
6	最坏失配裕度	相位裕度 $\ge 25°$，且时域不发散
7	抗饱和	已实现，阀门到顶时积分停止
8	无扰投切	切换瞬间 y_{pred} 跳变 < 2% 量程
9	预演值限幅	偏差超量程 20% 时报警并旁路
10	降级逻辑	可一键退回纯反馈，K_c 为保守值
11	参数记录	七个参数及辨识日期已归档

清单里第 6 项最容易被跳过，“名义裕度够”不等于“最坏失配够”。本章的数据说明，名义 93.42° 的回路在 $\delta\tau = +2$ s 时只剩 31.17°，在 $\kappa = 1.3$ 叠加 $\delta\tau = +2$ s 时只剩 17.72°。第 6 项就是拦住这类回路的。

47.10.10 落地的本质是“管理不确定性”

这一节的四层内容——准确辨识、结构保险、参数保守、监控降级——本质上都在做同一件事：管理模型的不确定性。

Smith 预估器是一个“信任模型”的算法，模型准的时候它比 PID 快得多，模型不准的时候它比 PID 危险得多。工程落地的全部工作，就是把“信任”变成“有条件信任”：用辨识保证条件成立，用结构防止条件破坏时的后果放大，用监控在条件被破坏时及时退出。

理解了这一点，就不会把 Smith 当成一个“装上就快”的模块，而会把它当成一个需要维护的回路。维护得好，它值那 59% 的调节时间；维护不好，它不如一个保守的 PI。

47.10.11 一次投运的时间线

把 §47.3.10 的算例拉成一条真实的时间线，看每个阶段该花多少时间、可能卡在哪里。

第一天上午，读历史趋势，确认延迟形状。这一步不需要停车，只需要调出过去一周的阶跃记录（配方切换、负荷调整都算）。如果历史数据里找不到干净的阶跃，才需要安排一次手动试验。

第一天下午，做开环阶跃，辨识三个参数。用 5% 阈值读延迟，用 63.2% 点读时间常数，用稳态两点法读增益。三个数各做三次，离散度应小于 10%。

第二天上午，整定与仿真。按式 (47-21) 算出 $K_c = 2.5$、$T_i = 6$ s，在仿真里跑一遍名义情形与三种失配，确认最坏情形的超调在可接受范围内。这一步常常被跳过，但它决定了“投运之后要不要反复调”。

第二天下午，搭模型、做无扰投切逻辑、设限幅与抗饱和。这部分是纯工程工作，与算法无关，但最容易出问题。§47.8.8 的五个错误，有四个发生在这里。

第三天上午，低增益投运。先把 K_c 设成 1.0，确认回路稳定、控制量平稳，再按斜坡升到 2.5。每升一档做一次小阶跃，看超调是否与仿真一致。

第三天下午，做三个验证试验：设定值阶跃、负载扰动、变工况。三个都通过，才算投运完成。任何一个不通过，回到第一步查模型，不要在参数上找补。

这条时间线里，真正的“算法时间”只有第二天上午的两小时，其余都是工程时间。这也解释了为什么很多团队觉得 Smith“难落地”——难的从来不是公式，而是辨识、切换、验证这些琐碎但不可省的工作。

47.11 优缺点与适用边界

47.11.1 四条优点

第一，它真的能提速。同一组 PI 参数下，纯反馈发散，Smith 把调节时间从保守整定的 48.50 s 压到 20.05 s，IAE 从 14.53 降到 10.40。这个提升不是靠牺牲稳定性换来的：相位裕度反而从 62.96° 升到 93.42°，幅值裕度从 6.78 dB 变成无穷。

第二，它的参数有物理含义。K_m、T_m、τ_m 是对象的三个可测特征，K_c、T_i 由闭式解给出（式 47-21），现场不需要从零试凑。这一点在换型、扩产、交接班时价值很大。

第三，结构简单。三个环节加两个减法节点，不需要求解优化问题，不需要矩阵运算，在 PLC 里用几个环形缓冲就能实现。

第四，它与既有系统兼容。预估器只是给控制器换了一个反馈信号，原来的 PI 模块、手自动切换、限幅逻辑都可以保留，改造量小。

47.11.2 五条缺点

第一，依赖模型。这是最根本的一条。延迟估计偏 2 s，超调从 0 变 31.22%；偏 4 s 直接失稳。而延迟恰恰是最容易漂的参数。

第二，不抗负载扰动。峰值偏差只改善 3.6%，恢复时间几乎不变。它解决的是“跟踪慢”，不是“扰动大”。

第三，对噪声敏感。修正量 $y_{m0} - y_{m\tau}$ 把测量噪声原样送入控制器，而 K_c 又比纯反馈高四倍，噪声被放大后灌进阀门。必须配滤波器。

第四，难以推广到多变量。单回路的 Smith 结构很清楚，多变量时“哪个输入对应哪段延迟”会变成组合问题，且通道间的延迟不一致会破坏解耦。

第五，对时变、非线性对象不友好。增益随负荷变化、时间常数随液位变化，固定模型只能覆盖一个工况点。

47.11.3 定量对照

表 47-19 把三种情形的关键指标放在一起。

表 47-19　纯反馈与 Smith 的指标对照

指标	纯反馈 $K_c = 0.6$	Smith 名义	Smith 最坏失配
超调 (%)	7.84	0.00	67.55
上升时间 (s)	8.84	5.10	—
调节时间 (s)	48.50	20.05	155.30
IAE	14.53	10.40	22.50
控制量峰值	1.202	2.500	—
相位裕度 (°)	62.96	93.42	17.72
幅值裕度 (dB)	6.78	无穷	1.97

这张表要横着读，也要竖着读。

横着读第一行：名义情形下 Smith 完胜，速度快 59%、超调为 0、裕度更高。这是它存在的理由。

横着读第二行：最坏失配下 Smith 完败，超调 67.55%、调节时间 155.30 s，比保守的纯反馈还差三倍。这是它需要被管理的原因。

竖着读第三列：从名义到最坏，同一个算法的表现差了三个数量级。这说明 Smith 不是一个“性能确定”的方案，而是一个“性能取决于模型质量”的方案。评价它时必须说明“在什么失配下”，只报名义指标是误导。

47.11.4 适用边界：先看 τ/T

τ/T 是最快的判据，§47.3.3 给过三档，这里重申并补充。

$\tau/T < 0.2$：预估器收益很小，纯反馈加个设定值滤波就够了。此时延迟只吃十几度相位，Smith 带来的那点提速抵不上建模与维护成本。

$0.2 \le \tau/T \le 1.0$：收益明显，但纯反馈也还能用。这一档要做的决策是“值不值得为速度付出模型维护成本”，流程行业一般倾向用，因为产量对速度敏感。

$\tau/T > 1.0$：收益最大。本章对象 $\tau/T = 1.6$，纯反馈要把 K_c 压到 0.6 才稳，Smith 用 2.5 还有 93.42° 裕度。这一档不用预估器，基本等于放弃这条回路的性能。

还有两个辅助判据。延迟固定还是漂移：固定的（分析仪、通信）适合 Smith，漂移大的（输送）需要调度或在线辨识。延迟是集中还是分布：集中延迟（管道输送）适合，分布延迟（长管、大型储罐）更适合用高阶模型近似，Smith 的效果会打折扣。

47.11.5 六种不适用的场景

第一种，对象开环不稳定。Smith 的推导假设开环稳定，遇到积分或右半平面极点，结构要重做。

第二种，有右半平面零点。非最小相位对象的“反向响应”与纯延迟在频域上相似但机理不同，直接套 Smith 会误判。

第三种，延迟远大于时间常数且变化剧烈。$\tau/T > 5$ 且随负荷翻倍变化时，固定预估器的有效工况窗口太窄。

第四种，主要矛盾是负载扰动。此时应该上前馈或串级，Smith 帮不上忙（表 47-10）。

第五种，测量噪声极大且无法滤波。噪声会通过修正通道放大，回路控制量抖动，阀门寿命受损。

第六种，对象强非线性。比如反应器的增益随转化率变化几倍，任何线性模型都覆盖不了，需要增益调度或非线性控制。

47.11.6 四种方案的选型对照

表 47-20 把解决“大延迟”的几种常用方案放在一起比较。

表 47-20　大延迟回路的方案对照

方案	主要解决	需要什么	主要代价
纯 PI 保守整定	稳定性	无	慢，调节 48.50 s
PI + 设定值滤波	超调	无	跟踪变慢，不解决延迟
串级	内环扰动	可测的中间变量	需要多一个变送器与回路
前馈	可测扰动	扰动通道模型	不能解决设定值跟踪
Smith 预估	设定值跟踪	三个模型参数	依赖模型，需维护
预测控制	多变量、约束	完整模型与算力	工程量大，需专门平台

选型的顺序建议是：先问“主要矛盾是什么”。是设定值跟踪慢，用 Smith；是负载扰动大，用前馈或串级；是多变量耦合带约束，才考虑预测控制。不要因为 Smith 比 PI“高级”就上 Smith，也不要因为预测控制“先进”就越级上 MPC。

47.11.7 三条隐含边界

除了技术条件，还有三条工程边界常被忽略。

第一条，算力与扫描周期。Smith 需要保存 τ_m/T_s 个历史值，本章 160 拍、每拍一个浮点数，内存 1.3 KB，任何 PLC 都够。但如果延迟是 600 s、采样 0.1 s，就是 6000 拍，老型号 PLC 的存储区可能吃紧。

第二条，投运成本。辨识要停一次车或做一次扰动试验，整定要跑几个阶跃，验证要做三个试验。这些时间成本在小回路上可能超过收益。

第三条，维护成本。模型参数需要随工况更新，监控需要人看，降级逻辑需要测试。Smith 回路不是“装完就不管”的回路，它的长期表现取决于维护制度。

47.11.8 什么时候该拆掉预估器

有三种情形，应该主动把预估器旁路。

第一种，模型长期失配且无法更新。比如输送延迟随原料批次大幅变化，又没有在线估计，此时预估器带来的风险大于收益。

第二种，工艺改了、对象变了，而回路没重辨识。这时名义模型已经是错的，预估器在“用错误的预演值指挥控制器”。

第三种，回路的主要任务从跟踪变成了抗扰。比如从“按配方切换”变成“稳定进料波动”，Smith 不再是对的工具。

拆掉不是失败，是承认工具与任务不匹配。拆掉之后退回保守 PI，回路会变慢，但至少可预测。

47.11.9 设定值滤波能不能替代 Smith

这是评审和现场都会问的问题：既然 Smith 的作用是“压超调”，而设定值滤波也能压超调，那为什么还要搭一个带模型的预估器？答案取决于缺的到底是什么。

先看纯反馈那一栏的数据。$K_c = 0.6$ 的保守整定，超调只有 7.84%，上升 8.84 s，调节 48.50 s。它的超调并不难看，难看的是速度——48.50 s 的调节时间，是 Smith 20.05 s 的两倍多。问题不在超调，在带宽。给一个已经“没有超调”的回路再加 t_{ref}，只会让它更慢，不会让它更快。

这就是两类手段的分界线。设定值滤波作用在参考通道上，它不进入特征方程，改变不了闭环极点，因此改变不了回路“能跑多快”；Smith 作用在反馈结构上，它改变的是特征方程本身，把延迟从极点配置里拿掉，因此能提高可用增益。前者是“把目标说得缓一点”，后者是“把路修直一点”。目标说得再缓，路还是弯的。

再看一个反面数据。在 $\kappa = 1.3$、$\delta\tau = +2$ s 的失配下，用 $t_{ref} = 5$ s 把 Smith 的超调从 67.55% 压到 29.63%，看着改善很大，但调节时间是 88.70 s、IAE 是 20.079——两项都比保守纯反馈的 48.50 s 和 14.53 差。也就是说，一个失配的 Smith 靠设定值滤波硬压超调，最终并不比退回保守 PI 更好。滤波压下去的是“看得见的超调”，压不下去的是“模型错了”这件事。

正确的用法是把两者叠起来，而不是让它们互相替代。先用模型把回路的结构问题解决（延迟移出环外、K_c 提上去），再用 t_{ref} 把残余的超调和控制量峰值收一收。§47.8.6 的流程就是这个顺序：先整定、再降增益、最后加设定值滤波。顺序反过来，就会得到一个“很温和但很慢”的回路，然后误以为 Smith 没用。

一条简单的判别规则：如果回路的症状是“超调大但响应够快”，先试 t_{ref}，成本最低；如果症状是“怎么调都慢，一加增益就振”，那是延迟在限制带宽，只有 Smith 这类改结构的手段能解决。

47.11.10 本章结论

本章可以收束成四句话。

第一，Smith 预估器把延迟搬到环外，模型准确时闭环等于“无延迟对象 + PI”，延迟只体现在输出上，不影响稳定性。

第二，收益与风险都来自同一个地方——模型。名义情形提速 59%，延迟偏 2 s 就超调 31%，偏 4 s 失稳。

第三，它对负载扰动几乎无效，这是结构决定的，不是参数没调好。

第四，工程上真正要做的不是“搭出预估器”，而是“管理模型的不确定性”：辨识准、裕度足、能监控、能降级。

下一章开始进入非线性系统的分析工具。延迟是线性系统里最“良性”的一种非线性——它不改变波形，只推迟波形；而相平面、描述函数要面对的，是波形本身会变形、会跳变、会出现极限环的对象。

47.12 Python 仿真代码

本章所有数字都可在本机复现，不依赖外部数据。这一节说明代码的组织、接口与阅读顺序，读者据此可以逐项复核正文，也可以换掉对象参数做自己的实验。

47.12.1 文件与运行

三个位置分工明确：

- `code/ch047_sim.py`：对象与控制器参数、ZOH 离散化、`simulate()`、指标函数、频域裕度函数、延迟估计，以及 `main()` 的十四段输出。正文的每个峰值、IAE、裕度都来自它的终端输出。
- `code/ch047_figs.py`：调用 `ch047_sim.py` 生成十张图，同时输出 svg 与 pdf，统一放在 `figs/ch047/`，文件名形如 `fig_047_03_pi_gain_scan.svg`。
- `figs/ch047/`：正文引用的十张图，编号 47-1 至 47-10 与文件名中的序号对应。

运行方式（Windows，py311 环境）：

```
"D:\Anaconda3\envs\py311\python.exe" code\ch047_sim.py
"D:\Anaconda3\envs\py311\python.exe" code\ch047_figs.py
```

依赖 `numpy`、`control`、`matplotlib` 与本书自带的 `simlib`、`plot_styles`、`block_styles`、`flow_styles`。仿真主体十几秒跑完，图脚本约十秒。

47.12.2 为什么不用 simlib 的单回路接口

`simlib` 的单回路接口适合“一个控制器加一个对象”，本章有四件事它表达不了：

1. 预估器需要一条与对象并联的模型支路，还要保存它的历史输出；
2. 延迟要分别放在对象、模型两处，且两处的取整方式不同（见 §47.12.4）；
3. 需要同时记录 y、u、y_{pred} 三条曲线，图 47-2 的下半幅就是 u；
4. 失配要能独立地加在 K、T、τ 上，而模型保持不变。

所以 `simulate()` 自己写逐步循环。对象仍用 ZOH 离散，指标复用 `sl.step_metrics` 的上升时间口径，保证与第 44–46 章可比。

47.12.3 simulate() 的接口

`simulate()` 有十八个参数，按用途分四组，见表 47-21。

表 47-21　`simulate()` 的参数与正文对应

参数	默认值	作用	正文对应
`mode`	`"smith"`	`"pi"` 纯反馈或 `"smith"` 预估	§47.4.2
`km`、`tm`、`taum`	1.0、5.0、8.0	预估器内部模型参数	§47.7.2–§47.7.4
`tf`	0	控制器前置滤波	§47.7.7、§47.9.2
`t_ref`	0	设定值滤波（二自由度）	§47.7.8、§47.9.3
`kc`、`ti`	2.5、6.0	PI 增益与积分时间	§47.7.5、§47.7.6
`k_gain`、`t_gain`、`d_tau`	1、1、0	对象相对名义值的失配	§47.6.2–§47.6.4
`Ts`、`N`	0.05、3600	采样周期与拍数，3600×0.05=180 s	§47.5.4
`ref`	1.0	设定值	全章
`dist_amp`、`t_dist`	0、60	负载扰动幅值与加入时刻	§47.6.7
`noise`、`seed`	0、0	测量噪声标准差与随机种子	§47.10.3

两组参数要分清：`km`、`tm`、`taum` 是**模型**，`k_gain`、`t_gain`、`d_tau` 是**对象相对模型的偏离**。想复现“模型按名义值设计、对象已漂移”，就改后三个，不要改前三个。这个区分很重要，改 `km` 是“设计成另一个模型”，改 `k_gain` 是“对象变了、设计没跟上”，两者在图上可能相似，物理含义完全不同。

47.12.4 主循环的时序

每一拍的顺序固定，顺序本身就是设计的一部分：

```
for k in range(N):
    yk = float((Cp @ xp)[0, 0])            # 1 读对象输出
    yk_meas = yk + (rng.normal(0.0, noise) if noise else 0.0)

    ymf = float((Cm @ xm)[0, 0])           # 2 无延迟模型输出
    ymf_seq[k] = ymf
    ymd = ymf_seq[k - n_m] if k >= n_m else 0.0   # 3 取 tau_m 前的值
    ypred = yk_meas + (ymf - ymd if mode == "smith" else 0.0)

    e = (rf if t_ref > 0 else ref) - ypred  # 4 误差（可带设定值滤波）
    ef = ef + Ts / (tf + Ts) * (e - ef) if tf > 0 else e
    uk = kc * ef + ki * xi                 # 5 PI
    xi = xi + Ts * ef

    if k >= n_a + 1:                       # 6 对象吃延迟后的 u
        ua = (1.0 - f_a) * u[k - n_a] + f_a * u[k - n_a - 1]
    elif k >= n_a:
        ua = (1.0 - f_a) * u[k - n_a]
    else:
        ua = 0.0
    xp = Ap @ xp + Bp * (ua + d[k])
    xm = Am @ xm + Bm * uk                 # 模型无延迟，当拍推进
```

三个细节值得指出。

第一，`ymf - ymd` 就是式 (47-3) 的修正量。`ymf_seq` 存模型的无延迟输出，`n_m` 拍之前的值就是“模型认为测量现在应该是多少”。

第二，模型当拍推进（`xm` 用 `uk`），对象下一拍才响应（`xp` 用 `ua`）。这不是笔误，而是离散实现的必然：模型是算出来的，对象是物理的。

第三，`xi` 没有抗饱和。本章的阶跃幅值小、T_s 也小，积分不会长时间饱和；把抗饱和加进来会让“预估器本身的作用”这一主题难以分离。真实工程必须加，做法见 §47.10.6。

47.12.5 分数拍延迟：一个容易掩盖结论的坑

对象延迟用分数拍实现：

```
tau_a = max(0.0, TAU_P + d_tau) / Ts
n_a = int(np.floor(tau_a))
f_a = tau_a - n_a
```

模型延迟仍按整拍取整（`n_m = round(taum / Ts)`）。为什么不对称？因为现场就是这样：对象的延迟是物理的、连续的，模型的延迟是程序员按采样周期取的整。

这个不对称是 §47.5 那张采样表能出结论的前提。最初两处都取整时，$T_s = 0.7$ s 的量化误差被“对象也取整”抵消，五次扫描的量化误差全是 0，结论完全错误。改成对象分数拍之后，才出现 -0.3、-0.5、$+1.0$ s 这些真实存在的误差，也才有“负量化误差更糟”这条结论。

47.12.6 频域函数与一个符号陷阱

`loop_eq()` 直接实现式 (47-20)：

```
def loop_eq(s, k_gain=1.0, t_gain=1.0, d_tau=0.0, tf=0.0,
            kc=KC_SMITH, ti=TI_SMITH):
    C = kc * (1.0 + 1.0 / (ti * s)) / (1.0 + tf * s)
    G = K_P * k_gain * np.exp(-s * (TAU_P + d_tau)) / (T_P * t_gain * s + 1.0)
    Gm0 = K_P / (T_P * s + 1.0)
    return C * (G + Gm0 * (1.0 - np.exp(-s * TAU_P)))
```

注意 `Gm0` 用的是名义参数，不带失配——失配只加在 G 上，这正是“模型没跟上对象”的数学表达。

`margins()` 里有一个坑：相位裕度出现 -308.91° 这种值。原因是 `np.unwrap` 的累积相位可以超过一圈，直接取最小值会选到错误分支。修法是先折回 $(-180^\circ, 180^\circ]$：

```
pm_all = (180.0 + ph[i] + 180.0) % 360.0 - 180.0
pm = float(np.min(pm_all))
```

另外，相位不穿越 -180° 时幅值裕度无解，`margins()` 返回 `inf`。正文统一写“无穷”，不给数字，避免“无穷大 dB”这种别扭表达。

47.12.7 十四段输出与正文的对应

`main()` 的输出分十四段，与正文的对应关系见表 47-22。

表 47-22　`main()` 的十四段输出与正文对应

段	内容	正文
一	同一组 PI 下纯反馈与 Smith	§47.4.2、表 47-4
二	纯反馈增益扫描	§47.4.4、表 47-3
三	增益失配扫描	§47.6.2、表 47-6
四	时间常数失配扫描	§47.6.3、表 47-7
五	延迟失配扫描	§47.6.4、表 47-8
六	二维失配地图	§47.6.5、图 47-6
七	三种改进手段	§47.7.7、§47.8.5、图 47-7
八	采样周期与延迟量化	§47.5.4、表 47-5
九	负载扰动	§47.6.7、表 47-10
十	裕度对比	§47.6.6、表 47-9
十一	阈值法估计延迟	§47.10.3、表 47-17
十二	控制量代价	§47.4.6、表 47-4
十三	失配与最大可用增益	§47.8.4、表 47-16
十四	测量噪声下的控制量抖动	§47.6.9、表 47-11

第十三段回答“给定失配，K_c 最大能取多少”，判据是超调不超过 20%、相位裕度不低于 45°，扫描步长 0.1。表 47-16 的每一行都来自这一段，读者可以改判据（比如把相位裕度改成 50°）重跑，得到更保守的系数。

第十四段是写 §47.6.9 时补的，统计的是 60 s 之后稳态段的标准差，所以不包含阶跃初期的瞬态。这一点在读表时要注意：它衡量的是“稳态抖动”，不是“控制量峰值”。峰值那一列同时给出，方便判断阀门行程是否够用。

47.12.8 图脚本的结构

`ch047_figs.py` 是十个独立函数 `fig01()`–`fig10()`，每个函数只做一件事：准备数据、画图、调用 `save()`。统一风格来自 `plot_styles`，框图与流程图分别用 `block_styles` 与 `flow_styles`。

十张图分三类。数据图八张（47-2 至 47-9），全部由 `ch047_sim` 的同一套参数生成；结构图一张（47-1），用 `block_styles` 画预估器的并联支路；流程图一张（47-10），用 `flow_styles` 画设计步骤。

两处绘图处理值得一提。图 47-2 里纯反馈发散的曲线会被裁到 2.6（`np.minimum(y, 2.6)`），否则纵轴被拉到几百，正常曲线挤成一条线。图 47-6 的热图在格子里写了数值，因为灰度打印时颜色分辨不出来。

47.12.9 复现与三个练习

复现只需两条命令。若数字与正文有差异，先确认三件事：Python 环境是 py311、`Ts` 没被改、`noise` 为 0。

三个练习，由易到难。

练习一，把 τ 改成 12 s、T 改成 4 s（$\tau/T=3$），重跑第一段与第十二段。看纯反馈的可用增益掉到多少，Smith 的控制量峰值涨到多少。这个练习能体会“延迟越大，预估器的收益与控制量代价同时上升”。

练习二，把 `dist_amp` 改成 -0.5，重跑第九段。看 Smith 与纯反馈的峰值偏差差距是否仍只有几个百分点。如果差距变大，想想为什么——提示：扰动幅值变大后，K_c 高的回路反应更快，这部分收益与预估器无关。

练习三，给 `simulate()` 加一个 `tau_est` 参数，把模型延迟设成估计值 8.243 s（而不是真值 8.0），重跑第三段到第五段，看超调变化多少。这个练习把 §47.10 的辨识误差与 §47.6 的失配分析连了起来，也是现场最常见的情形：你以为模型是准的，其实它带着 0.24 s 的偏差。

47.12.10 六个常见报错

第一个，`ModuleNotFoundError: control`。缺 `python-control` 库，在 py311 环境里 `pip install control` 即可。本书所有章节都只用它的 `c2d` 与 `tf`，不依赖高级功能。

第二个，`metrics()` 返回 `inf`。说明曲线在 180 s 内发散，最常见的原因是 K_c 给得太大（比如纯反馈用了 2.5）。这不是代码错误，而是仿真在告诉你“这个方案不稳”。表格里用 `_num()` 打成“—”，避免出现 `inf` 字样。

第三个，相位裕度出现 -300° 之类的值。`np.unwrap` 的累积相位超过一圈，按 §47.12.6 折回 $(-180^\circ, 180^\circ]$ 即可。如果折回后仍异常，检查是否在 $\omega = 0$ 附近取了对数点。

第四个，幅值裕度打印 `nan`。相位全程没穿过 -180°，数学上无解。`margins()` 已改成返回 `inf`，正文写“无穷”。

第五个，图中中文变成方框。缺中文字体，`apply_cjk_font()` 会按系统可用字体依次尝试；如果全都没有，需要装一个思源黑体或设置 `matplotlib.rcParams["font.sans-serif"]`。

第六个，结果与正文对不上。按顺序检查三件事：`Ts` 是否被改过（正文全部基于 0.05 s）、`noise` 是否为 0（除第十四段）、`seed` 是否一致（噪声实验固定为 1）。三件都对还不对，检查 Python 版本——`control` 库在不同版本里 `c2d` 的默认方法可能不同，本书统一用 `method="zoh"`。

这六个报错覆盖了九成以上的复现问题。真正需要读代码排查的，通常只有“结果对不上”这一类，而它几乎总是参数问题，不是逻辑问题。